

Is Parallel Programming Hard, And, If So, What Can You Do About It?

Edited by:

Paul E. McKenney
Linux Technology Center
IBM Beaverton
paulmck@linux.vnet.ibm.com

Translated by:

SeongJae Park
sj38.park@gmail.com

March 2, 2019 (m)

Legal Statement

This work represents the views of the editor and the authors and does not necessarily represent the view of their respective employers.

Trademarks:

- IBM, z Systems, and PowerPC are trademarks or registered trademarks of International Business Machines Corporation in the United States, other countries, or both.
- Linux is a registered trademark of Linus Torvalds.
- i386 is a trademark of Intel Corporation or its subsidiaries in the United States, other countries, or both.
- Other company, product, and service names may be trademarks or service marks of such companies.

The non-source-code text and images in this document are provided under the terms of the Creative Commons Attribution-Share Alike 3.0 United States license.¹ In brief, you may use the contents of this document for any purpose, personal, commercial, or otherwise, so long as attribution to the authors is maintained. Likewise, the document may be modified, and derivative works and translations made available, so long as such modifications and derivations are offered to the public on equal terms as the non-source-code text and images in the original document.

Source code is covered by various versions of the GPL.² Some of this code is GPLv2-only, as it derives from the Linux kernel, while other code is GPLv2-or-later. See the comment headers of the individual source files within the CodeSamples directory in the git archive³ for the exact licenses. If you are unsure of the license for a given code fragment, you should assume GPLv2-only.

Combined work © 2005-2019 by Paul E. McKenney.

¹ <http://creativecommons.org/licenses/by-sa/3.0/us/>

² <http://www.gnu.org/licenses/gpl-2.0.html>

³ <git://git.kernel.org/pub/scm/linux/kernel/git/paulmck/perfbook.git>

Contents

1	How To Use This Book	1
1.1	Roadmap	1
1.2	Quick Quizzes	2
1.3	Alternatives to This Book	2
1.4	Sample Source Code	3
1.5	Whose Book Is This?	4
2	Introduction	7
2.1	Historic Parallel Programming Difficulties	7
2.2	Parallel Programming Goals	8
2.2.1	Performance	9
2.2.2	Productivity	9
2.2.3	Generality	10
2.3	Alternatives to Parallel Programming	12
2.3.1	Multiple Instances of a Sequential Application	12
2.3.2	Use Existing Parallel Software	12
2.3.3	Performance Optimization	13
2.4	What Makes Parallel Programming Hard?	13
2.4.1	Work Partitioning	13
2.4.2	Parallel Access Control	14
2.4.3	Resource Partitioning and Replication	15
2.4.4	Interacting With Hardware	15
2.4.5	Composite Capabilities	15
2.4.6	How Do Languages and Environments Assist With These Tasks?	15
2.5	Discussion	15
3	Hardware and its Habits	17
3.1	Overview	17
3.1.1	Pipelined CPUs	17
3.1.2	Memory References	18
3.1.3	Atomic Operations	19
3.1.4	Memory Barriers	19
3.1.5	Cache Misses	20
3.1.6	I/O Operations	20
3.2	Overheads	21
3.2.1	Hardware System Architecture	21
3.2.2	Costs of Operations	22
3.2.3	Hardware Optimizations	22

3.3	Hardware Free Lunch?	23
3.3.1	3D Integration	24
3.3.2	Novel Materials and Processes	24
3.3.3	Light, Not Electrons	24
3.3.4	Special-Purpose Accelerators	25
3.3.5	Existing Parallel Software	25
3.4	Software Design Implications	25
4	Tools of the Trade	27
4.1	Scripting Languages	27
4.2	POSIX Multiprocessing	28
4.2.1	POSIX Process Creation and Destruction	28
4.2.2	POSIX Thread Creation and Destruction	29
4.2.3	POSIX Locking	30
4.2.4	POSIX Reader-Writer Locking	32
4.2.5	Atomic Operations (GCC Classic)	33
4.2.6	Atomic Operations (C11)	34
4.2.7	Per-Thread Variables	34
4.3	Alternatives to POSIX Operations	35
4.3.1	Organization and Initialization	35
4.3.2	Thread Creation, Destruction, and Control	35
4.3.3	Locking	36
4.3.4	Accessing Shared Variables	37
4.3.5	Atomic Operations	42
4.3.6	Per-CPU Variables	42
4.4	The Right Tool for the Job: How to Choose?	43
5	Counting	45
5.1	Why Isn't Concurrent Counting Trivial?	45
5.2	Statistical Counters	47
5.2.1	Design	47
5.2.2	Array-Based Implementation	47
5.2.3	Eventually Consistent Implementation	48
5.2.4	Per-Thread-Variable-Based Implementation	49
5.2.5	Discussion	50
5.3	Approximate Limit Counters	50
5.3.1	Design	51
5.3.2	Simple Limit Counter Implementation	52
5.3.3	Simple Limit Counter Discussion	55
5.3.4	Approximate Limit Counter Implementation	55
5.3.5	Approximate Limit Counter Discussion	56
5.4	Exact Limit Counters	56
5.4.1	Atomic Limit Counter Implementation	56
5.4.2	Atomic Limit Counter Discussion	59
5.4.3	Signal-Theft Limit Counter Design	59
5.4.4	Signal-Theft Limit Counter Implementation	60
5.4.5	Signal-Theft Limit Counter Discussion	62
5.4.6	Applying Exact Limit Counters	63
5.5	Parallel Counting Discussion	63
5.5.1	Parallel Counting Performance	64

5.5.2	Parallel Counting Specializations	64
5.5.3	Parallel Counting Lessons	65
6	Partitioning and Synchronization Design	67
6.1	Partitioning Exercises	67
6.1.1	Dining Philosophers Problem	67
6.1.2	Double-Ended Queue	71
6.1.3	Partitioning Example Discussion	75
6.2	Design Criteria	76
6.3	Synchronization Granularity	77
6.3.1	Sequential Program	77
6.3.2	Code Locking	78
6.3.3	Data Locking	79
6.3.4	Data Ownership	80
6.3.5	Locking Granularity and Performance	81
6.4	Parallel Fastpath	83
6.4.1	Reader/Writer Locking	83
6.4.2	Hierarchical Locking	83
6.4.3	Resource Allocator Caches	84
6.5	Beyond Partitioning	87
6.5.1	Work-Queue Parallel Maze Solver	88
6.5.2	Alternative Parallel Maze Solver	89
6.5.3	Performance Comparison I	90
6.5.4	Alternative Sequential Maze Solver	92
6.5.5	Performance Comparison II	92
6.5.6	Future Directions and Conclusions	93
6.6	Partitioning, Parallelism, and Optimization	93
7	Locking	95
7.1	Staying Alive	95
7.1.1	Deadlock	96
7.1.2	Livelock and Starvation	101
7.1.3	Unfairness	102
7.1.4	Inefficiency	103
7.2	Types of Locks	103
7.2.1	Exclusive Locks	103
7.2.2	Reader-Writer Locks	103
7.2.3	Beyond Reader-Writer Locks	104
7.2.4	Scoped Locking	104
7.3	Locking Implementation Issues	106
7.3.1	Sample Exclusive-Locking Implementation Based on Atomic Exchange	106
7.3.2	Other Exclusive-Locking Implementations	107
7.4	Lock-Based Existence Guarantees	109
7.5	Locking: Hero or Villain?	110
7.5.1	Locking For Applications: Hero!	110
7.5.2	Locking For Parallel Libraries: Just Another Tool	110
7.5.3	Locking For Parallelizing Sequential Libraries: Villain!	113
7.6	Summary	114

8 Data Ownership	115
8.1 Multiple Processes	115
8.2 Partial Data Ownership and pthreads	116
8.3 Function Shipping	116
8.4 Designated Thread	116
8.5 Privatization	116
8.6 Other Uses of Data Ownership	117
9 Deferred Processing	119
9.1 Running Example	119
9.2 Reference Counting	120
9.3 Hazard Pointers	122
9.4 Sequence Locks	124
9.5 Read-Copy Update (RCU)	127
9.5.1 Introduction to RCU	127
9.5.2 RCU Fundamentals	129
9.5.3 RCU Usage	136
9.5.4 RCU Linux-Kernel API	146
9.5.5 RCU Related Work	150
9.5.6 RCU Exercises	152
9.6 Which to Choose?	153
9.7 What About Updates?	155
10 Data Structures	157
10.1 Motivating Application	157
10.2 Partitionable Data Structures	157
10.2.1 Hash-Table Design	158
10.2.2 Hash-Table Implementation	158
10.2.3 Hash-Table Performance	159
10.3 Read-Mostly Data Structures	161
10.3.1 RCU-Protected Hash Table Implementation	161
10.3.2 RCU-Protected Hash Table Performance	162
10.3.3 RCU-Protected Hash Table Discussion	164
10.4 Non-Partitionable Data Structures	165
10.4.1 Resizable Hash Table Design	165
10.4.2 Resizable Hash Table Implementation	165
10.4.3 Resizable Hash Table Discussion	169
10.4.4 Other Resizable Hash Tables	171
10.5 Other Data Structures	173
10.6 Micro-Optimization	173
10.6.1 Specialization	174
10.6.2 Bits and Bytes	174
10.6.3 Hardware Considerations	175
10.7 Summary	176
11 Validation	177
11.1 Introduction	177
11.1.1 Where Do Bugs Come From?	177
11.1.2 Required Mindset	178
11.1.3 When Should Validation Start?	180

11.1.4 The Open Source Way	180
11.2 Tracing	181
11.3 Assertions	182
11.4 Static Analysis	182
11.5 Code Review	182
11.5.1 Inspection	183
11.5.2 Walkthroughs	183
11.5.3 Self-Inspection	183
11.6 Probability and Heisenbugs	185
11.6.1 Statistics for Discrete Testing	186
11.6.2 Abusing Statistics for Discrete Testing	187
11.6.3 Statistics for Continuous Testing	187
11.6.4 Hunting Heisenbugs	188
11.7 Performance Estimation	191
11.7.1 Benchmarking	192
11.7.2 Profiling	192
11.7.3 Differential Profiling	192
11.7.4 Microbenchmarking	193
11.7.5 Isolation	193
11.7.6 Detecting Interference	194
11.8 Summary	196
12 Formal Verification	199
12.1 State-Space Search	199
12.1.1 Promela and Spin	199
12.1.2 How to Use Promela	202
12.1.3 Promela Example: Locking	204
12.1.4 Promela Example: QRCU	205
12.1.5 Promela Parable: dynticks and Preemptible RCU	210
12.1.6 Validating Preemptible RCU and dynticks	213
12.2 Special-Purpose State-Space Search	225
12.2.1 Anatomy of a Litmus Test	225
12.2.2 What Does This Litmus Test Mean?	226
12.2.3 Running a Litmus Test	227
12.2.4 PPCMEM Discussion	227
12.3 Axiomatic Approaches	228
12.3.1 Axiomatic Approaches and Locking	229
12.3.2 Axiomatic Approaches and RCU	230
12.4 SAT Solvers	231
12.5 Stateless Model Checkers	232
12.6 Summary	233
13 Putting It All Together	235
13.1 Counter Conundrums	235
13.1.1 Counting Updates	235
13.1.2 Counting Lookups	235
13.2 Refurbish Reference Counting	235
13.2.1 Implementation of Reference-Counting Categories	236
13.2.2 Linux Primitives Supporting Reference Counting	239
13.2.3 Counter Optimizations	240

13.3 RCU Rescues	241
13.3.1 RCU and Per-Thread-Variable-Based Statistical Counters	241
13.3.2 RCU and Counters for Removable I/O Devices	242
13.3.3 Array and Length	243
13.3.4 Correlated Fields	244
13.4 Hashing Hassles	244
13.4.1 Correlated Data Elements	244
13.4.2 Update-Friendly Hash-Table Traversal	245
14 Advanced Synchronization	247
14.1 Avoiding Locks	247
14.2 Non-Blocking Synchronization	247
14.2.1 Simple NBS	248
14.2.2 NBS Discussion	249
14.3 Parallel Real-Time Computing	249
14.3.1 What is Real-Time Computing?	250
14.3.2 Who Needs Real-Time Computing?	254
14.3.3 Who Needs Parallel Real-Time Computing?	254
14.3.4 Implementing Parallel Real-Time Systems	255
14.3.5 Implementing Parallel Real-Time Operating Systems	256
14.3.6 Implementing Parallel Real-Time Applications	266
14.3.7 Real Time vs. Real Fast: How to Choose?	269
15 Advanced Synchronization: Memory Ordering	271
15.1 Ordering: Why and How?	271
15.1.1 Why Hardware Misordering?	272
15.1.2 How to Force Ordering?	273
15.1.3 Basic Rules of Thumb	275
15.2 Tricks and Traps	277
15.2.1 Variables With Multiple Values	277
15.2.2 Memory-Reference Reordering	278
15.2.3 Address Dependencies	281
15.2.4 Data Dependencies	282
15.2.5 Control Dependencies	283
15.2.6 Cache Coherence	284
15.2.7 Multicopy Atomicity	284
15.3 Compile-Time Consternation	291
15.3.1 Memory-Reference Restrictions	291
15.3.2 Address- and Data-Dependency Difficulties	293
15.4 Hardware Specifics	294
15.4.1 Alpha	296
15.4.2 ARMv7-A/R	298
15.4.3 ARMv8	298
15.4.4 Itanium	299
15.4.5 MIPS	299
15.4.6 POWER / PowerPC	300
15.4.7 SPARC TSO	301
15.4.8 x86	302
15.4.9 z Systems	302
15.5 Where is Memory Ordering Needed?	303

16 Ease of Use	305
16.1 What is Easy?	305
16.2 Rusty Scale for API Design	305
16.3 Shaving the Mandelbrot Set	306
17 Conflicting Visions of the Future	309
17.1 The Future of CPU Technology Ain't What it Used to Be	309
17.1.1 Uniprocessor Über Alles	309
17.1.2 Multithreaded Mania	310
17.1.3 More of the Same	311
17.1.4 Crash Dummies Slamming into the Memory Wall	311
17.2 Transactional Memory	312
17.2.1 Outside World	313
17.2.2 Process Modification	316
17.2.3 Synchronization	319
17.2.4 Discussion	322
17.3 Hardware Transactional Memory	323
17.3.1 HTM Benefits WRT to Locking	324
17.3.2 HTM Weaknesses WRT Locking	325
17.3.3 HTM Weaknesses WRT to Locking When Augmented	329
17.3.4 Where Does HTM Best Fit In?	333
17.3.5 Potential Game Changers	333
17.3.6 Conclusions	335
17.4 Formal Regression Testing?	335
17.4.1 Automatic Translation	336
17.4.2 Environment	336
17.4.3 Overhead	337
17.4.4 Locate Bugs	338
17.4.5 Minimal Scaffolding	338
17.4.6 Relevant Bugs	338
17.4.7 Formal Regression Scorecard	339
17.5 Functional Programming for Parallelism	340
A Important Questions	343
A.1 What Does “After” Mean?	343
A.2 What is the Difference Between “Concurrent” and “Parallel”?	345
A.3 What Time Is It?	346
B “Toy” RCU Implementations	347
B.1 Lock-Based RCU	347
B.2 Per-Thread Lock-Based RCU	347
B.3 Simple Counter-Based RCU	348
B.4 Starvation-Free Counter-Based RCU	349
B.5 Scalable Counter-Based RCU	351
B.6 Scalable Counter-Based RCU With Shared Grace Periods	352
B.7 RCU Based on Free-Running Counter	354
B.8 Nestable RCU Based on Free-Running Counter	355
B.9 RCU Based on Quiescent States	356
B.10 Summary of Toy RCU Implementations	358

C Why Memory Barriers?	359
C.1 Cache Structure	359
C.2 Cache-Coherence Protocols	360
C.2.1 MESI States	361
C.2.2 MESI Protocol Messages	361
C.2.3 MESI State Diagram	362
C.2.4 MESI Protocol Example	363
C.3 Stores Result in Unnecessary Stalls	363
C.3.1 Store Buffers	364
C.3.2 Store Forwarding	365
C.3.3 Store Buffers and Memory Barriers	365
C.4 Store Sequences Result in Unnecessary Stalls	367
C.4.1 Invalidate Queues	367
C.4.2 Invalidate Queues and Invalidate Acknowledge	368
C.4.3 Invalidate Queues and Memory Barriers	368
C.5 Read and Write Memory Barriers	370
C.6 Example Memory-Barrier Sequences	370
C.6.1 Ordering-Hostile Architecture	370
C.6.2 Example 1	371
C.6.3 Example 2	371
C.6.4 Example 3	372
C.7 Are Memory Barriers Forever?	372
C.8 Advice to Hardware Designers	372
D Read-Copy Update Implementations	375
D.1 Sleepable RCU Implementation	375
D.1.1 SRCU Implementation Strategy	376
D.1.2 SRCU API and Usage	376
D.1.3 Implementation	378
D.1.4 SRCU Summary	380
D.2 Hierarchical RCU Overview	381
D.2.1 Review of RCU Fundamentals	381
D.2.2 Brief Overview of Classic RCU Implementation	382
D.2.3 RCU Desiderata	382
D.2.4 Towards a More Scalable RCU Implementation	383
D.2.5 Towards a Greener RCU Implementation	385
D.2.6 State Machine	385
D.2.7 Use Cases	386
D.2.8 Testing	389
D.2.9 Conclusion	392
D.3 Hierarchical RCU Code Walkthrough	392
D.3.1 Data Structures and Kernel Parameters	393
D.3.2 External Interfaces	398
D.3.3 Initialization	402
D.3.4 CPU Hotplug	405
D.3.5 Miscellaneous Functions	408
D.3.6 Grace-Period-Detection Functions	408
D.3.7 Dyntick-Idle Functions	414
D.3.8 Forcing Quiescent States	418
D.3.9 CPU-Stall Detection	422

D.3.10	Possible Flaws and Changes	423
D.4	Preemptible RCU	423
D.4.1	Conceptual RCU	424
D.4.2	Overview of Preemptible RCU Algorithm	424
D.4.3	Validation of Preemptible RCU	433
E	Read-Copy Update in Linux	437
E.1	RCU Usage Within Linux	437
E.2	RCU Evolution	437
E.2.1	2.6.27 Linux Kernel	437
E.2.2	2.6.28 Linux Kernel	437
E.2.3	2.6.29 Linux Kernel	437
E.2.4	2.6.31 Linux Kernel	438
E.2.5	2.6.32 Linux Kernel	439
E.2.6	2.6.33 Linux Kernel	439
E.2.7	2.6.34 Linux Kernel	439
E.2.8	2.6.35 Linux Kernel	439
E.2.9	2.6.36 Linux Kernel	439
E.2.10	2.6.37 Linux Kernel	440
E.2.11	2.6.38 Linux Kernel	440
E.2.12	2.6.39 Linux Kernel	440
E.2.13	3.0 Linux Kernel	440
E.2.14	3.1 Linux Kernel	441
E.2.15	3.2 Linux Kernel	441
E.2.16	3.3 Linux Kernel	441
E.2.17	3.4 Linux Kernel	441
E.2.18	3.5 Linux Kernel	442
E.2.19	3.6 Linux Kernel	442
E.2.20	3.7 Linux Kernel	442
E.2.21	3.8 Linux Kernel	442
E.2.22	3.9 Linux Kernel	442
E.2.23	3.10 Linux Kernel	442
E.2.24	3.11 Linux Kernel	443
E.2.25	3.12 Linux Kernel	443
E.2.26	3.13 Linux Kernel	443
E.2.27	3.14 Linux Kernel	443
F	Style Guide	445
F.1	Paul's Conventions	445
F.2	NIST Style Guide	446
F.2.1	Unit Symbol	446
F.2.2	NIST Guide Yet To Be Followed	447
F.3	L <small>A</small> T <small>E</small> X Conventions	447
F.3.1	Monospace Font	447
F.3.2	Non Breakable Spaces	451
F.3.3	Hyphenation and Dashes	451
F.3.4	Punctuation	452
F.3.5	Floating Object Format	453
F.3.6	Improvement Candidates	453

G Answers to Quick Quizzes	459
G.1 How To Use This Book	459
G.2 Introduction	459
G.3 Hardware and its Habits	463
G.4 Tools of the Trade	466
G.5 Counting	469
G.6 Partitioning and Synchronization Design	481
G.7 Locking	486
G.8 Data Ownership	493
G.9 Deferred Processing	494
G.10 Data Structures	504
G.11 Validation	507
G.12 Formal Verification	512
G.13 Putting It All Together	517
G.14 Advanced Synchronization	519
G.15 Advanced Synchronization: Memory Ordering	521
G.16 Ease of Use	529
G.17 Conflicting Visions of the Future	530
G.18 Important Questions	534
G.19 “Toy” RCU Implementations	534
G.20 Why Memory Barriers?	539
G.21 Read-Copy Update Implementations	542
H Glossary and Bibliography	555
I Credits	595
I.1 L ^A T _E X Advisor	595
I.2 Reviewers	595
I.3 Machine Owners	595
I.4 Original Publications	595
I.5 Figure Credits	596
I.6 Other Support	597

If you would only recognize that life is hard, things would be so much easier for you.

Louis D. Brandeis

Chapter 1

How To Use This Book

이 책의 목적은 당신이 shared-memory parallel machine을 정확성을 해치지 않으면서 프로그램하는 것을 돋는 것입니다.¹ 우린 이 책의 디자인 원칙이 당신이 적어도 몇몇 병렬 프로그래밍의 함정들은 피하는데 도움을 주길 바랍니다. 즉, 당신은 이 책을 완성된 성당이라기보단 새로 건물을 지을 토대라고 생각해야 합니다. 이를 따르기로 한다면, 당신의 임무는 이 신나는 병렬 프로그래밍 세계의 —결국엔 이 책을 구식으로 만들게 될—발전을 돋는겁니다. 병렬 프로그래밍은 일부 사람들이 말하는 것처럼 어렵지 않고, 우리는 이 책이 당신의 병렬 프로그래밍 프로젝트를 더 쉽고 재밌게 만들길 바랍니다.

짧게 말해서, 병렬 프로그래밍이 일단 과학, 연구, 뭔가 대단한 과제에 적용되면 곧바로 엔지니어링 문제가 되어버립니다. 따라서 우리는 병렬 프로그래밍에서 하는 특정 작업들을 알아보고, 그것들을 어떻게 해결하는지 설명합니다. 그러한 해결책들은 놀라울정도로 흔한 경우들에서 자동화조차도 가능합니다.

이 책은 성공적 병렬 프로그래밍 프로젝트에 숨어있는 엔지니어링 비법들을 알려주는 것이 새로운 세대의 병렬성 해커들을 느리고 고통스럽게 오래된 바퀴를 다시 만들어내는 대신, 그들의 에너지와 창의성을 새로운 영역에 집중하도록 도울 수 있길 바라는 마음으로 쓰였습니다. 우린 병렬 프로그래밍이 당신에게 재미와 흥분, 그리고 도전을 그것이 우리에게도 가져다 주었던 만큼은 가져다 주길 바랍니다.

1.1 Roadmap

Cat: Where are you going?

Alice: Which way should I go?

Cat: That depends on where you are going.

Alice: I don't know.

Cat: Then it doesn't matter which way you go.

Lewis Carroll, Alice in Wonderland

이 책은 극소수의 영역에만 적용 가능한 최적의 알고리즘의 모음이라기보다는 폭넓게 적용될 수 있고 많이 사용된 디자인 테크닉들을 소개하는 안내서입니다. 여러분은 지금 Chapter 1을 읽고 있습니다, 알고 있겠지만요. Chapter 2 은 병렬 프로그래밍에 대해 전반적으로 간단히 살펴봅니다.

Chapter 3 는 shared-memory parallel hardware에 대해 소개합니다. 어쨌든, 여러분이 코드가 동작하게 될 하드웨어에 대해 모르면 병렬성 있는 좋은 코드를 작성하기가 어렵습니다. 하드웨어는 계속 발전할테니, 이 챕터는 항상 시대에 뒤쳐질겁니다. 따라서 우리는 내용을 최신으로 유지하기 위해 최선을 다할겁니다. Chapter 4 는 이어서 shared-memory 병렬 프로그래밍의 기본을 매우 간략히 소개합니다.

Chapter 5 에서는 상상할 수 있는 가장 간단한 문제인 카운팅을 병렬화 하는 작업에 대해 자세히 알아봅니다. 대부분은 카운팅에 대해서는 잘 알고 있을테니, 이 챕터에서는 보다 흔한 컴퓨터 사이언스에서의 문제들에 정신을 뺏기지 않고 병렬 프로그래밍 이슈에 대해서만 집중할 수 있을 겁니다. 제 생각에는 이 챕터가 병렬 프로그래밍 수업에서 가장 많이 활용되곤 합니다.

Chapter 6 에서는 Chapter 5 에서 파악한 문제들을 해결하는 설계 레벨의 방법들을 소개합니다. 가능할때엔 병렬성을 설계 레벨에서 해결하는 것이 중요합니다: Dijkstra [Dij68] 의 말을 바꿔쓰자면, “개선된 병렬성은 최적이 아닌 것으로 본다” [McK12b].

이어지는 세개의 챕터는 세개의 중요한 동기화 방법

¹ 또는, 좀 더 정확히는, 병렬성 없는 프로그래밍에 비해 정확성을 털 해치면서요.

을 각각 설명합니다. Chapter 7 에서는 적어도 2014년에 와서는 제품 수준의 병렬 프로그래밍에 있어 가장 많이 사용되지도 않고, 일반적으로 병렬 프로그래밍의 가장 악랄한 악당으로 여겨지는 락킹에 대해 알아봅니다. Chapter 8 는 과소평가되곤 하지만 실제로는 놀랍도록 여러 분야에 사용 가능하고 강력한 방법인 데이터 소유권에 대해 알아봅니다. 마지막으로 Chapter 9 에서는 레퍼런스 카운팅, 해저드 포인터, 순차적 락킹, 그리고 RCU 를 포함한 deferred-processing 메커니즘들을 소개합니다.

Chapter 10 에서는 앞에서 배운 내용들을 해시 테이블에 적용해 봅니다. 해시 테이블은 그 훌륭한 데이터 분리성으로 인해 널리 사용되고 있고, 때문에 (보통은) 훌륭한 성능과 확장성을 보입니다.

많은 사람들이 그들의 슬픔에서 배웠듯이, validation (실증) 없이 이루어지는 병렬 프로그래밍은 비참한 실패로의 분명한 지름길입니다. Chapter 11 에서는 다양한 테스트 방법을 다룹니다. 물론 모든 부분에 대해 프로그램의 신뢰성을 테스트 하는 것은 불가능합니다. 따라서 Chapter 12 에서는 몇개의 실용적인 형식적 검증 (formal verification) 방법에 대해 간단히 다룹니다.

Chapter 13 에서는 적당한 크기의 병렬 프로그래밍 문제들을 다룹니다. 이런 문제들의 난이도는 다양하지만 앞 챕터들의 내용을 이해한 사람에게는 적당할 겁니다.

Chapter 14 에서는 non-blocking 동기화와 병렬 리얼타임 컴퓨팅을 포함한 고급 동기화 방법을 알아보며, Chapter 15 에서는 메모리 순서 규칙에 대한 고급 주제를 다룹니다. 이어지는 Chapter 16 는 몇몇 ease-of-use 기법들을 이야기합니다. 마지막으로, Chapter 17 에서는 공유 메모리 병렬 시스템 설계, 소프트웨어 / 하드웨어 트랜잭션 메모리, 병렬성을 위한 함수형 프로그래밍, 그리고 양자 컴퓨팅을 포함해 몇몇 가능할 법한 미래의 방향에 대해 알아봅니다.

이 책의 끝에는 여러개의 부록이 있습니다. 그中最 가장 인기 있는건 메모리 배리어에 대해 다루고 있는 Appendix C 일 겁니다. Appendix G 는 다음 섹션에서 이야기할, Quick Quizz 들의 답을 담고 있습니다.

1.2 Quick Quizzes

Undertake something difficult, otherwise you will never grow.

Abbreviated from Ronald E. Osburn

“Quick quizzes” 는 이 책 전반에 걸쳐 나오고, 그에 대한 답은 page 459 부터 시작하는 Appendix G 에서 볼 수 있습니다. 그 중 일부는 해당 퀴즈가 나온 곳의 내용에

기반하지만, 몇몇은 그 섹션 이외의 내용에 대해서도 생각해야 할 거고, 일부는 당신이 알고 있는 모든 내용을 필요로 할 수도 있습니다. 최대한 노력했다는 가정 하에, 당신이 이 책으로부터 얻을 수 있는 것은 당신이 배운 내용을 얼마나 실제로 응용하는지에 달려있습니다. 따라서, 답을 보기 전에 퀴즈를 풀기 위해 많은 노력을 기울인 독자들은 그 노력의 결실이 향상된 병렬 프로그래밍에 대한 이해와 함께 돌아온 것을 알 수 있을 것입니다.

Quick Quiz 1.1: 이 Quick Quiz 들의 답은 어디에 있나요? ■

Quick Quiz 1.2: 몇몇 퀴즈는 저자의 입장이 아니라 독자의 입장에서 쓰인 것 같은데요. 의도적으로 그렇게 한 건가요? ■

Quick Quiz 1.3: 이 Quick Quizzes 는 제 취향이 아니예요. 어떡하죠? ■

간략히 정리하자면, 당신이 해당 내용에 대해 깊은 이해가 필요하다면, 어느 정도의 시간은 Quick Quizzes 의 답을 구하는데 사용할 필요가 있습니다. 가만히 내용을 읽기만 하는 것도 물론 의미있습니다만, 완벽한 문제 해결 능력을 갖기 위해선 실질적인 문제를 풀어보는 것도 필요합니다.

저는 이 깨달음을 저의 늦깎이 박사 과정에서 힘들게 얻었습니다. 저는 제게 익숙한 주제를 공부했는데, 제가 해당 챕터의 연습문제 중에 제가 곧바로 머리 속에서 답 할 수 있는 내용이 얼마 안된다는 사실에 놀랐습니다.² 그 문제들을 풀도록 저 자신을 강제하는 것은 해당 내용에 대한 제 기억을 매우 개선시켰습니다. 따라서 저는 이 Quick Quizzes 에 대해 제가 스스로 하지 않았던 것을 여러분에게 강요하고 있지는 않아요!

마지막으로, 가장 흔한 학습 장애는 당신이 이미 알고 있다고 생각하는 것입니다. Quick Quizzes 는 그에 대한 매우 효과적인 치유책이 될 수 있습니다.

1.3 Alternatives to This Book

Between two evils I always pick the one I never tried before.

Mae West

Knuth 가 깨달았던 것과 같이, 당신의 책에 끝이 있으려면 그 책의 내용은 어딘가에 집중되어 있어야 합니다. 이 책은 운영체계 커널, 병렬 데이터 관리 시스템, 저수준 라이브러리 등과 같은 소프트웨어 스택의 바닥 쪽에 있는 소프트웨어를 주요 대상으로 두고 공유메모리 기반 병렬 프로그래밍에 중점을 둡니다. 이 책에서 사용하는 프로그래밍 언어는 C 언어입니다.

² 아마 그래서 제 교수님들은 제가 그 수업을 포기하지 못하게 하셨다고 생각합니다

당신이 병렬성의 다른 분야에 관심있다면, 다른 책을 보는 편이 좋을 겁니다. 다행히도, 여러분을 위한 많은 대안이 존재합니다:

1. 보다 학술적이고 정밀하게 병렬 프로그래밍을 다루고 싶다면, Herlihy 와 Shavit 의 책 [HS08]이 당신에게 적합할 겁니다. 이 책은 높은 수준의 하드웨어 추상화에서의 원초적 기능들의 흥미로운 조합으로 시작해서 락킹과 리스트, 큐, 해시 테이블, 그리고 카운터를 포함한 간단한 자료구조들을 다루고, 마지막으로 트랜잭션 메모리를 다룹니다. Michael Scott 의 책 [Sco13]은 비슷한 내용을 보다 소프트웨어 엔지니어링에 중점을 두어서 접근합니다. 그리고, 제가 알기로는 최초로 RCU 에 대한 내용의 섹션을 담은 챕터로 정식으로 학계에 출간된 최초의 책입니다.
2. 당신이 프로그래밍 언어적 실리적 관점에서의 병렬 프로그래밍에 대한 학술적 취급을 알고 싶다면 Scott 이 저술한 프로그래밍 언어의 실리에 대한 책 [Sco06]의 concurrency (동시성) 챕터를 재밌게 볼 수 있을 겁니다.
3. 객체 지향 패턴 전문가들이 병렬 프로그래밍을 어떻게 취급하는지 C++ 위주로 알고 싶다면 Schmidt 의 POSA 시리즈 [SSRB00, BHS07] 의 Volume 2 와 4 를 읽어봐도 좋을 겁니다. 특히 Volume 4 는 그 작업물을 도매점 어플리케이션에 적용해보는 내용의 재미있는 챕터들이 있습니다. 이 예제가 얼마나 실제 상황에 가까운지는 병렬성에 내재된 문제들은 종종 실제 세계의 응용사례에서 시작된다는 이야기를 하는 “Partitioning the Big Ball of Mud” 라는 제목의 섹션에서 증명되었습니다.
4. 당신이 리눅스 커널 디바이스 드라이버를 다루고 싶다면 Corbet, Rubini, 그리고 Kroah-Hartman 이 쓴 “Linux Device Drivers” [CRKH05], 그리고 Linux Weekly News 웹사이트 (<http://lwn.net/>) 를 반드시 봐야 합니다. 리눅스 커널 내부에 대한 일반적 내용에 대해서는 많은 책과 자료들이 있습니다.
5. 당신의 주요 관심사가 과학 / 기술 분야 컴퓨팅이라면, 그리고 패턴주의자의 접근방법을 선호한다면, Mattson 등의 책 [MSM05] 을 읽어 보십시오. 그 책에서는 Java, C/C++, OpenMP, 그리고 MPI 를 다룹니다. 거기서 이야기하는 패턴들은 첫째로 설계, 다음으로 구현에 매우 집중되어 있습니다.
6. 당신의 주요 관심사가 과학 / 기술 분야 컴퓨팅이고 GPU, CUDA, 그리고 MPI 에 관심이 있다면,

Norm Matloff 의 “Programming on Parallel Machines” [Mat13] 을 한번쯤 보세요. 물론, GPU 제조사들은 추가적인 정보들을 많이 가지고 있습니다 [AMD17, Zel11, NVi17a, NVi17b].

7. POSIX 쓰레드에 관심 있다면, David R. Butenhof 의 책 [But97] 을 읽어보세요. 또한, W. Richard Stevens 의 책 [Ste92] 은 UNIX 와 POSIX 를 다루고, Stewart Weiss 의 수업노트 [Wei13] 는 훌륭한 예제들과 함께 완전하고 접근 가능한 소개를 제공합니다.
8. C++11 에 관심 있다면, Anthony Williams 의 “C++ Concurrency in Action: Practical Multithreading” [Wil12] 를 좋아할 수도 있을 겁니다.
9. C++ 에 관심 있지만 Windows 환경에 있다면 Dr. Dobb 의 잡지 [Sut08] 에 실린 Herb Sutter 의 “Effective Concurrency” 시리즈를 읽어보세요. 이 시리즈는 병렬성에의 일반적 접근을 잘 소개합니다.
10. Intel Threading Building Blocks 를 사용해 보고 싶다면, James Reinder 의 책 [Rei07] 이 아마 찾으시는 책일 겁니다.
11. 다양한 종류의 멀티 프로세서 하드웨어 캐시 구성이 커널 내부 구현에 어떤 영향을 끼치는지 궁금한 사람이라면 이 연구 [Sch94] 에 실린 Curt Schimmel 의 고전적 접근을 한번 봐야 합니다.
12. 마지막으로, Java 사용자라면 Doug Lea 의 교재 [Lea97, GPB⁺07] 가 큰 도움이 될 수 있을 겁니다.

하지만, low level 의, 특히 C 로 구현된 소프트웨어를 위한 병렬적 설계의 기본적 원칙에 관심이 있다면, 이 책을 계속 읽으세요!

1.4 Sample Source Code

Use the source, Luke!

Unknown Star Wars fan

이 책은 적법하게 인용한 많은 소스 코드를 가지고 이야기 하며, 많은 경우 그 소스 코드는 이 책의 git tree 안의 CodeSamples 디렉토리 안에 있습니다. 예를 들어 UNIX 시스템에서는 다음과 같이 명령을 내릴 수 있을 겁니다:

```
find CodeSamples -name rcu_rcpl.c -print
```

이 명령문은 Appendix B에 사용된 `rcu_rcpl.c` 파일의 위치를 알려줄 겁니다. 다른 종류의 시스템에는 파일 이름으로 파일의 위치를 찾는 잘 알려진 다른 방법들이 있을 겁니다.

1.5 Whose Book Is This?

If you become a teacher, by your pupils you'll be taught.

Oscar Hammerstein II

표지에서 이야기했듯, 이 책의 편집자는 Paul E. McKenney입니다. 하지만, Paul은 `perfbook@vger.kernel.org` 이메일 리스트를 통한 기여를 받습니다. 이런 기여는 텍스트 이메일, 책의 `LATEX` 소스에 대한 패치, 심지어는 `git pull` 요청까지 어떤 형태라도 상관 없습니다. 당신에게 가장 좋은 방법을 사용하세요.

패치를 만들거나 `git pull` 요청을 보내기 위해서는, `git://git.kernel.org/pub/scm/linux/kernel/git/paulmck/perfbook.git`에 있는 이 책의 `LATEX` 소스가 필요할 겁니다. 또한, 당연하게도 `git`과 `LATEX`이 필요하겠죠. `git`과 `LATEX`은 대부분의 주요 리눅스 배포본에 포함되어 있습니다. 그 외에도 여러분이 사용하고 있는 배포본에 따라 다른 패키지들도 필요할 수 있습니다. 일부 유명한 배포본에 대해 필요한 패키지 목록은 이 책의 `LATEX` 소스의 `FAQ-BUILD.txt` 파일에 있습니다.

이 책의 `LATEX` 소스 트리를 만들고 보려면 Listing 1.1에 있는 리눅스 커맨드를 사용하세요. 일부 환경에서는 `perfbook.pdf`를 표시하는데 사용되는 `evince` 커맨드가 `acroread`라던지 다른 커맨드로 바뀌어야 할 수도 있습니다. `git clone` 커맨드는 PDF를 최초 만들 때 한번만 수행되면 됩니다. 한번 `pdf`를 생성한 후로는 Listing 1.2의 커맨드를 수행함으로써 그사이 업데이트된 내용을 얻어오고 업데이트된 내용이 포함된 PDF를 만들 수 있습니다. Listing 1.2의 커맨드는 반드시 Listing 1.1에 나온 커맨드가 생성한 `perfbook` 디렉토리 안에서 수행되어야 합니다.

이 책의 PDF들은 가끔마다 <http://kernel.org/pub/linux/kernel/people/paulmck/perfbook/perfbook.html>과 <http://www.rdrop.com/users/paulmck/perfbook/>에 업로드 됩니다.

실제 패치를 보내고 `git pull` 요청을 보내는 과정은 리눅스 소스 트리의 `Documentation/SubmittingPatches`에 문서화되어 있는 리눅스 커널의 방식과 유사합니다. 한가지 중요한 필수사항은 각 패치 (`git pull` 요청의 경우라면 커밋)은 반드시 다음과

같은 형태의, 유효한 `Signed-off-by`: 행을 포함해야 합니다:

`Signed-off-by: My Name <myname@example.org>`

`Signed-off-by`: 라인을 포함한 패치의 예를 보려면 <http://lkml.org/lkml/2007/1/15/219>를 보십시오.

`Signed-off-by`: 라인은 매우 중요한 의미를 갖는데, 다음과 같은 내용을 당신이 선서한다는 의미입니다:

- (a) 해당 기여는 모두 또는 부분적으로 나에 의해 만들어졌고, 나는 해당 파일에 표시된 오픈 소스 라이센스 아래 해당 기여를 제출할 권리를 갖는다; 또는
- (b) 해당 기여는 내가 알기로는 적절한 오픈 소스 라이센스 하에 만들어진 기존의 작업물에 기초하며, 파일에 표시된 대로 나는 해당 라이센스 아래 해당 작업물을 모두 또는 일부분 내가 수정하고 기존과 같은 오픈 소스 라이센스 아래(내가 다른 라이센스로 제출할 권리를 갖지 않았다면) 제출할 권리를 갖는다; 또는
- (c) 해당 기여는 내게 (a), (b) 또는 (c)를 선서해 준 다른 사람에 의해 제공되었고 나는 이를 수정한 바가 없다.
- (d) 나는 이 프로젝트와 해당 기여가 공적이며 이 기여에 대한 기록(내가 기여와 함께 제공한 모든 개인적 정보와 나의 sign-off를 포함하여)이 불특정 기간 유지되고 이 프로젝트나 사용된 오픈 소스 라이센스(들)과 연관되어 재배포 될 수 있음을 이해하고 동의한다.

이건 리눅스 커널에서 사용되는 개발자의 유래에 대한 선서 (DCO) 1.1과 상당히 유사합니다.

이 때 여러분은 진짜 이름을 사용해야만 합니다: 안타깝지만 저는 익명으로 제공된 기여는 받을 수 없습니다.

이 책은 미국식 영어를 사용합니다만, 오픈소스라는 환경상 이 책은 번역이 허용되고, 전 개인적으로 번역을 장려합니다. 이 책에 붙어 있는 오픈 소스 라이센스는 추가적으로, 원한다면 여러분이 여러분의 번역을 판매할 수도 있게 허용합니다. 번역본의 복사본을 (가능하다면 하드카피로) 보내 주실 것을 부탁드립니다만, 이는 어디까지나 부탁드리는 것이고, 여러분이 이미 Creative Commons와 GPL license로 갖는 권리에 우선하지 않습니다. 현재 진행중인 번역 작업의 목록을 보려면 `FAQ.txt` 파일을 봐 주십시오. 전 최소 한개의 챕터 이상이 이미 모두 번역되었다면 번역 작업이 “진행 중”이라고 여깁니다.

Listing 1.1: Creating an Up-To-Date PDF

```
1 git clone git://git.kernel.org/pub/scm/linux/kernel/git/paulmck/perfbook.git
2 cd perfbook
3 # You may need to install a font here. See item 1 in FAQ.txt.
4 make
5 evince perfbook.pdf & # Two-column version
6 make perfbook-1c.pdf
7 evince perfbook-1c.pdf & # One-column version for e-readers
```

Listing 1.2: Generating an Updated PDF

```
1 git remote update
2 git checkout origin/master
3 make
4 evince perfbook.pdf & # Two-column version
5 make perfbook-1c.pdf
6 evince perfbook-1c.pdf & # One-column version for e-readers
```

이 섹션의 시작에서 이야기 했듯, 전 이 책의 편집자입니다. 하지만, 여러분이 기여를 하기로 하면, 이것은 여러분의 책이기도 합니다. 이제, Chapter 2, introduction 을 시작합니다.

Chapter 2

Introduction

병렬 프로그래밍은 해커가 덤벼볼 수 있는 가장 어려운 영역 중 하나라는 평판을 가지고 있습니다. 논문과 서적들은 데드락, 라이브락, 레이스 컨디션, 비결정성 (non-determinism), 확장성에서의 암달의 법칙 한계, 그리고 가혹한 리얼타임 환경에서의 응답시간의 위험을 경고하고 있습니다. 그리고 이런 위험들은 진짜로 존재합니다; 우리 저자들은 감정적 상처, 하얗게 세는 머리카락, 그리고 탈모를 겪어야면서 셀 수 없을 만큼 오랜 시간 그 문제들을 다뤄왔습니다.

하지만, 모든 새로운 기술들이 처음엔 곧바로 사용하기엔 너무 어려웠지만, 시간의 흐름에 따라 점점 사용하기 쉽게 되어왔습니다. 예컨대, 과거엔 자동차를 운전하는 것이 흔치 않은 능력이었지만 지금은 흔한 일입니다. 이런 극적인 변화는 두 가지 기본적 이유에서 나옵니다: (1) 자동차가 점점 싸고 흔해져서 더 많은 사람들이 운전을 배울 기회를 갖습니다, 그리고 (2) 자동 변속기, 자동 쿠크, 자동 발진기, 매우 향상된 신뢰도, 그리고 다른 향상된 기술의 접목 등으로 인해 자동차를 운전하기가 보다 쉬워집니다.

컴퓨터를 포함해서, 다른 기술들도 마찬가지입니다. 더 이상 프로그램을 짜기 위해 천공카드를 만질 필요 없습니다. 스프레드시트 프로그램들은 프로그래머가 아닌 사람들도 그들의 컴퓨터에서 수십년 전이었다면 전문가 집단이 필요했을 계산 결과를 쉽게 얻을 수 있게 해줍니다. 가장 반박하기 어려운 예는 2000년대 초쯤부터 전문적으로 교육받지 않은 사람에 의해서도 지금은 흔해진 다양한 소셜 네트워킹 도구를 사용해서 쉽게 이루어지는 웹서핑과 컨텐츠 제작일 겁니다. 1968년만 해도, 그런 컨텐츠 제작은 연구 주제 [Eng68]에 가까웠습니다. 그 당시엔 “UFO 가 백악관 잔디밭에 착륙하기처럼” [Gri00] 어렵다고 이야기 하곤 했죠.

그러니, 병렬 프로그래밍이 지금 그렇듯이 영원히 어려운 주제로 남을 거라고 주장하고자 한다면, 과거 수백, 수천년의 다양한 노력에서 만들어진 반례를 생각하세요. 그래도 주장하고자 한다면, 증명은 당신의 몫입니다.

If parallel programming is so hard, why are there any parallel programs?

Unknown

2.1 Historic Parallel Programming Difficulties

Not the power to remember, but its very opposite, the power to forget, is a necessary condition for our existence.

Sholem Asch

제목에서 알 수 있듯이, 이 책은 좀 다른 접근법을 취합니다. 병렬 프로그래밍이 어렵다고 이야기하기보다는, 먼저 병렬 프로그래밍이 어려운 이유를 알아보고나서 독자들이 이 어려움들을 이겨낼 수 있도록 돕습니다. 이어서 설명하겠지만, 이 어려움들은 다음의 카테고리들로 분류될 수 있습니다:

1. 역사적으로 비싸고 흔치 않았던 병렬 시스템들.
2. 연구자와 전문가들의 병렬 시스템에 대한 경험의 부족.
3. 공식적으로 접할 수 있는 병렬 코드의 양의 부족.
4. 병렬 프로그래밍에 대해 널리 알려진 공학적 규칙의 부족.
5. 심지어 치밀하게 설계된 공유메모리 컴퓨터에서도 존재하는, 처리에 비해 높은 커뮤니케이션의 오버헤드.

역사적으로 존재했던 이런 문제들 중 다수는 해결되어 가는 중입니다. 먼저, 지난 수십년간, 무어의 법칙 덕에 병렬 시스템의 가격은 집 여러채 가격에서 자전거 한대 가격 정도로 떨어졌습니다. 멀티코어 CPU의 장점에 대한 논문은 1996년초 [ONH⁺96]에도 나왔습니다. IBM은 2000년도에 동시에 수행되는 멀티쓰레딩 기능을 그들의 하이엔드 POWER 제품군에 넣었고, 2001년에는 멀티코어를 구현했습니다. 2000년 11월, Intel

은 일반 시장용 제품인 Pentium 에 하이퍼쓰레딩 기능을 넣었고, 2005년에는 AMD 와 Intel 둘 다 멀티코어 CPU를 내놓았습니다. Sun 은 2005년 후반, 멀티코어/멀티쓰레드 기능을 갖춘 Niagara 로 그 뒤를 이었습니다. 2008년에 이르러서는 사실상 싱글 CPU 데스크탑을 찾아보기 어려워졌습니다. 이 시점부터 싱글코어 CPU 는 넷북이나 임베디드 기기에서나 사용되었습니다. 2012년에 이르러, 심지어 스마트폰도 여러 CPU 를 사용하기 시작했습니다.

둘째로, 저가에 쉽게 구할 수 있는 멀티코어 시스템이 많아진 것은, 한때엔 흔치 않았던 병렬 프로그래밍 경험을 거의 모든 연구자와 전문가가 겪을 수 있게 되었다는 뜻입니다. 실제로, 병렬 시스템은 이제 학생이나 취미로 컴퓨터 만지는 사람도 살 수 있는 가격입니다. 따라서 우리는 병렬 시스템을 둘러싼 발명과 혁신이 엄청나게 많아질 것임을 예상할 수 있고, 이렇게 친숙해진 병렬 시스템 환경은 한때 엄청나게 접근하기 어렵던 병렬 프로그래밍 영역을 훨씬 편하고 일반적인 영역으로 만들 것입니다.

셋째로, 20세기에는 병렬 소프트웨어로 구현된 거대 시스템은 거의 항상 독점과 비밀로 숨겨져 있었습니다. 반면, 21세기에는 다행히도 리눅스 커널 [Tor03c], 데이터베이스 시스템들 [Pos08, MS08], 그리고 메세지 패싱 시스템들 [The08, Uni08a] 을 포함해, 많은 오픈소스(따라서 공개적으로 접할 수 있는) 병렬 소프트웨어 프로젝트들이 존재합니다. 이 책은 주로 리눅스 커널의 경우를 소개할 겁니다만 유저 레벨 어플리케이션에서도 적용 가능한 것들을 많이 다룰 겁니다.

넷째로, 1980년대와 1990년대의 거대 규모의 병렬 프로그래밍 개발 프로젝트들은 모두 독점 프로젝트였던 합니다만, 이런 프로젝트들이 다른 커뮤니티들에 상용 퀄리티의 병렬 코드를 개발하는데 필요한 공학적 규칙을 알고 있는 개발자들을 심어주었습니다. 이 책의 주요 목적은 이런 공학적 규칙을 소개하는 것입니다.

불행히도, 다섯번째 문제인 연산에 비해 비싼 커뮤니케이션의 비용은 여전히 많이 남아있습니다. 이 문제는 2000년대 들어 많은 주목을 받았지만, Stephen Hawking 에 따르자면 유한한 빛의 속도와 물질의 원자적 특성이 이 분야의 발전을 제한할 것으로 보입니다 [Gar07, Moo03]. 다행히도, 이 문제는 1980년대 후반부터 존재했으며, 덕분에 앞서 이야기한 공학적 규칙들은 이 문제를 다루기에 실용적이고 효과적인 방법으로 진화되었습니다. 또한, 하드웨어 설계자들은 점점 더 이 문제에 주목하고 있어서, 미래의 하드웨어는 아마도 Section 3.3에서 이야기하는 것처럼 보다 병렬 소프트웨어에 친화적인 형태가 될 것입니다.

Quick Quiz 2.1: 이봐요!!! 병렬 프로그래밍은 수십년간 엄청나게 어렵다고 알려졌다고요. 근데 당신은 그게 그렇게 어렵지 않다고 슬쩍 이야기하는 것 같네요. 뭘가

사기치는 거 아닌가요? ■

하지만, 병렬 프로그래밍이 흔히 이야기하는 것보다는 어렵지 않을 수 있다고는 해도, 일반적으로는 순차적 프로그래밍보다는 어려운 경우가 많습니다.

Quick Quiz 2.2: 어떻게 병렬 프로그래밍이 순차적 프로그래밍만큼 쉬운게 가능한가요? ■

그러니 병렬 프로그래밍의 대안을 찾아보는 것도 말이 됩니다. 하지만, 병렬 프로그래밍의 목표를 이해하지 않은채 병렬 프로그래밍의 대안을 찾아본다는 것은 말이 안됩니다. 이 주제는 다음 섹션에서 다룹니다.

2.2 Parallel Programming Goals

If you don't know where you are going, you will end up somewhere else.

Yogi Berra

순차적 프로그래밍을 넘어서 병렬 프로그래밍이 이루고자 하는 주된 목표 세가지는 다음과 같습니다:

1. 성능(Performance).
2. 생산성(Productivity).
3. 일반성(Generality).

불행히도, 현재로썬 어떤 병렬 프로그램도 이 세가지의 목표들 중 두개의 목표까지만 달성 가능합니다. 그러니까, 말하자면 이 세개의 목표는 구부릴 수 없는, 병렬 프로그래밍의 쇠로 만들어진 삼각형을 구성하는 세개의 꼭지점인 거죠.¹

Quick Quiz 2.3: 헐, 진짜요? 정확성, 관리성, 내구성이 같은 것들은요? ■

Quick Quiz 2.4: 그리고 정확성, 관리성, 내구성이 해당되지 않는데 왜 생산성과 Generality 는 해당되는거죠? ■

Quick Quiz 2.5: 병렬 프로그램은 정확성을 증명하기가 어렵다고 알고 있는데, 정말 정확성도 그 목록에 올라갈 수 없는 건가요? ■

Quick Quiz 2.6: 그냥 재미를 목표로 하는건 어떤가요? ■

이 목표들은 다음 섹션에서 각각 자세히 설명됩니다.

¹ 쇠로 만들어진 삼각형이라는 이름을 지어준 Michael Wong 에게 감사합니다.




Figure 2.1: MIPS/Clock-Frequency Trend for Intel CPUs

2.2.1 Performance

성능은 병렬 프로그래밍에서의 최우선 목표입니다. 만약 성능이 주안점이 아니라면, 그냥 순차적 코드를 작성하고 행복해지도록 여러분 스스로에게 호의를 베푸는 게 좋을 겁니다. 그렇게 하는게 훨씬 쉽고 빠르게 일을 끝낼 수 있을 겁니다.

Quick Quiz 2.7: 성능 이외의 이유로 병렬 프로그래밍을 하는 경우는 없나요? ■

참고로, 여기서 “성능” 이란 용어는 확장성 (CPU 당 성능) 과 효율성 (예를 들어, watt 당 성능) 를 포함해 넓은 범주를 포함합니다.

그렇지만, 성능의 포커스는 하드웨어에서 병렬 소프트웨어로 옮겨졌습니다. 이런 포커스의 변화는 무어의 법칙은 여전히 트랜지스터 밀집도를 높이고 있지만, 그렇게 늘어난 트랜지스터들을 전통적 방식대로 싱글쓰레드 성능 향상에 사용하는 것을 그만뒀다는 사실에 기인합니다. Figure 2.1² 은 싱글쓰레드로 도는 코드를 작성하고 단순히 성능 목표를 만족할 더 빠른 컴퓨터가 나오길 1, 2년 정도 기다리는건 더이상 선택지가 아니란 걸 보여줍니다. 모든 주요 제조사가 멀티코어/멀티쓰레드 시스템으로 개발 방향을 바꾼 이상, 병렬성만이 그런

² 이 그림은 이론상으로 한 클락에 한개 이상의 명령어를 처리할 수 있는 최신 CPU에서는 클락 주파수를, 그리고 가장 간단한 명령어의 처리에도 여러 클락이 필요한 구형 CPU에서는 MIPS(오래된 Dhrystone 벤치마크에서 주로 사용하던, millions of instructions per second) 를 보여줍니다. 이렇게 서로 다른 두개의 측정 결과를 보여주는 이유는, 한 클락에 여러 명령어를 처리할 수 있는 최신 CPU의 기능이 일반적으로는 메모리쪽 성능에 의해 제한되기 때문입니다. 뿐만 아니라, 구형 CPU에서 일반적으로 사용되던 벤치마크는 너무 구식이고, 구형 CPU는 구하기도 어려워서 최신의 벤치마크들을 구형 CPU에서 돌리는건 불가능에 가깝기 때문입니다.

시스템의 최대 성능을 끌어낼 수 있는 방법입니다.

그렇다고 하더라도, 첫번째 목표는 성능이지 확장성이 아닌데, 선형적인 확장성을 얻을 수 있는 가장 쉬운 방법이 각 CPU의 성능을 떨어뜨리는 것 [Tor01]이란 점을 놓고 보면 특히나 그렇습니다. 네개의 CPU를 갖는 시스템을 갖게 되었다면, 여러분은 어떤 걸 더 선호하겠어요? 한개 CPU 위에서 초당 100개 트랜잭션을 처리하지만 CPU 확장성이 아예 없는 프로그램? 아니면 한개 CPU 위에선 초당 10개 트랜잭션만 처리하지만 완벽하게 CPU를 늘려줄 때 따라 성능이 늘어나는 프로그램? 아마 첫번째 프로그램이 더 나은 선택 같아 보이겠지만, 여러분에게 32개 CPU를 갖는 시스템이 생길 수 있다고 하면 또 달라질겁니다.

그렇다곤 하지만, 특히나 요즘 멀티 CPU 시스템의 가격이 하락하고 있다곤 하지만, 단순히 멀티 CPU 머신이 있기 때문이란 게 그 모든 CPU를 다 사용해야 한다는 이유가 되진 않습니다. 여기서 이해해야 하는 핵심 포인트는 병렬 프로그래밍은 기본적으로 성능 최적화를 위한 여러 방법 중 하나란 거죠. 여러분의 프로그램이 지금도 충분히 빠르다면 프로그램을 병렬화 시키거나 병렬화 이외의 다른 방법들을 통해 최적화를 할 필요 자체도 없습니다.³ 같은 이유로, 순차적 프로그램에의 최적화 방법으로 병렬성을 도입하려 한다면, 병렬 알고리즘들을 최선의 순차적 알고리즘과 비교해야 합니다. 많은 병렬 알고리즘 성능 분석 문서들이 순차적 알고리즘의 케이스를 아예 무시하고 있기 때문에 여기에 많은 주의가 필요할 수 있습니다.

2.2.2 Productivity

Quick Quiz 2.8: 왜 이런 비기술적인 주제를 이야기하는거죠??? 그저 비기술적일 뿐 아니라, 심지어 생산성이라니요? 누가 그런걸 신경써요? ■

지난 수십년간 생산성은 매우 중요해졌습니다. 이를 이해하기 위해, 엔지니어들의 연봉은 수천달러 정도인데 컴퓨터의 가격은 수천만 달러였던 과거를 생각해봅시다. 그 당시의 컴퓨터에 10명의 엔지니어로 구성된 팀을 만들어서 성능을 10 % 라도 개선할 수 있다면, 그들은 많은 보너스를 받을 수 있었을겁니다.

CSIRAC는 그런 부류의 머신 중 하나로, 가장 오래되었지만 여전히 온전한, stored-program 컴퓨터로 1949년 [Mus04, Dep06]에 운영되었습니다. 이 머신은 트랜지스터 시대 이전에 만들어졌기 때문에, 2,000 개의 진공관으로 구성되었고 1kHz 클락 주파수로 동작했으며, 30kW 의 전력을 사용하고, 그 무게는 3톤이 넘었습니다. 하지만 이 머신은 768 워드밖에 안되는 용량의 RAM

³ 물론, 여러분이 그저 취미로 병렬 소프트웨어를 만드는 사람이라면 그것만으로도 그 소프트웨어가 뭐건 병렬화를 할 충분한 이유가 되지요.

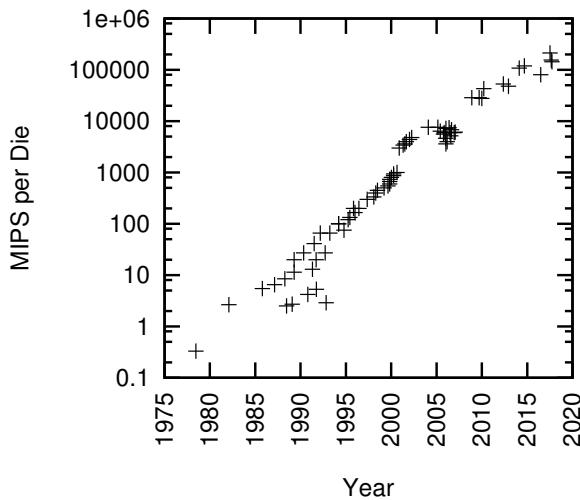


Figure 2.2: MIPS per Die for Intel CPUs

을 가지고 있었기에, 오늘날의 거대한 소프트웨어 프로젝트에서 종종 골치를 앓게 하는 생산성 문제로부터 자유로웠습니다.

오늘날에 그렇게 성능이 떨어지는 기계를 구입하는건 매우 어렵습니다. 그나마 가장 비슷한 예는 Z80 [Wik08]과 같은 8-bit 임베디드 마이크로프로세서가 될 수 있을 것 같습니다만, 그 Z80 조차도 CSIRAC 보다 1,000 배는 빠른 CPU 클락 주파수를 가지고 있었습니다. Z80 CPU는 8,500 개의 트랜지스터를 사용했고, 2008년도에 개당 \$2 US 에 1,000개 단위로 구매할 수 있었습니다. CSIRAC 와 반대로 Z80에서 소프트웨어 개발 비용은 그렇게 크게 중요하지 않았습니다.

오랫동안의 트렌드를 Figure 2.2 를 통해 보면 CSIRAC 와 Z80 은 그 가운데 두개의 점으로 표현될 수 있습니다. 이 그림은 지난 30여년간의 다이 (die) 당 컴퓨터이션 파워 변화를 간략히 보여주는데, 40년의 기간동안 100만배라는 인상적인 증가를 보입니다. 멀티코어 CPU 의 성장은 2003년에 마주한 클락 주파수의 한계 장벽에도 불구하고 50개 하드웨어 쓰레드 이상을 지원한 덕분에 이런 증가 추세를 지속시켰음을 알아두시기 바랍니다.

이렇게 가파른 하드웨어 가격 하락은 소프트웨어 생산성이 점점 중요해짐을 의미합니다. 이제는 그저 하드웨어를 효과적으로 사용하는 것만으로는 충분하지 않습니다: 이젠 소프트웨어 개발자들을 가능한한 효과적으로 사용하는 것이 중요합니다. 순차적 하드웨어에서는 예전부터 이런 문제가 있었지만, 병렬 하드웨어는 최근에서야 낮은 가격으로 상품이 나오기 시작했습니다. 따라서, 병렬 소프트웨어를 만들때의 생산성은 최근에 들어서야 매우 중요해졌습니다.

Quick Quiz 2.9: 병렬 시스템이 그렇게 싼 가격이

되었다면, 어떤 사람이 그걸 프로그램 하라고 월급을 줘가며 프로그래머를 고용하겠어요? ■

적어도 한때에는 병렬 소프트웨어의 유일한 목표가 성능이었습니다. 하지만, 지금은 생산성이 점점 주목을 받고 있습니다.

2.2.3 Generality

병렬 소프트웨어를 개발하는 높은 비용을 정당화 할 수 있는 한가지 방법은 최대한의 generality 를 위해 노력하는 것입니다. 다른 게 모두 똑같다면, 보다 일반적인 소프트웨어 제품의 개발 비용은 덜 일반적인 것에 비해 더 많은 사용자들로 분산되어 보상되기 때문입니다. 실제로, 이런 경제적 이유가 generality 의 중요한 특별 케이스라 할 수 있는 이식성에 대한 마니악한 관심을 설명합니다.⁴

불행히도, generality 는 종종 성능이나 생산성, 또는 둘 다를 하락시키기도 합니다. 예를 들어, 이식성은 종종 중간 레이어를 두는 식으로 이루어지는데, 중간 레이어가 추가되는 것은 피할 수 없는 성능 하락을 야기합니다. 보다 일반적인 환경에서의 이 현상을 보기 위해, 다음의 널리 쓰이는 병렬 프로그래밍 환경들을 생각해봅시다:

C/C++ “락킹과 쓰레드”: POSIX 쓰레드 (pthreads) [Ope97], Windows 쓰레드, 그리고 많은 운영체제 커널 환경을 포함하는 이 카테고리는 (최소 하나의 SMP 시스템에서는) 엄청난 성능과 훌륭한 generality 를 제공합니다. 비교적 낮은 생산성은 아쉽지만요.

Java: 이 범용적이고 본질적으로 멀티쓰레드를 고려한 프로그래밍 환경은 자동 가비지 컬렉터와 풍부한 클래스 라이브러리를 덕에 C 나 C++ 보다 훨씬 높은 생산성을 제공하는 것으로 널리 알려졌습니다. 하지만, 그 성능은 2000년대 초에 상당히 개선되긴 했지만 여전히 C 와 C++ 보다 부족합니다.

MPI: 이 메세지 패싱 인터페이스 [MPI08] 는 세계에서 가장 큰 과학 분야와 기술 분야 컴퓨팅 클러스터들을 뒷받침하며 병렬화 되지 않은 성능과 확장성을 제공합니다. 이는 이론적으로는 범용적으로 사용 가능하다고 하지만 대부분의 경우 과학 분야와 기술 분야 컴퓨팅에서 사용됩니다. 그 생산성은 심지어 C/C++ “락킹과 쓰레드” 환경보다도 떨어진다고 많은 사람들이 생각합니다.

OpenMP: 이 컴파일러 지시어 집합은 루프문을 병렬화 하는데 사용될 수 있습니다. 때문에 이 특정한

⁴ 이걸 지적해준 Michael Wong 에게 찬사를.




Figure 2.3: Software Layers and Performance, Productivity, and Generality

작업에 한정적이고, 이런 제약이 종종 그 성능을 제한합니다. 하지만, MPI나 C/C++ “락킹과 쓰레드”보다는 사용하기 쉬운 편입니다.

SQL: SQL (Structured Query Language [Int92])는 관계형 데이터베이스 쿼리에 제한적입니다. 하지만, 그 성능은 트랜잭션 처리 성능 의회 (TPC) 벤치마크 결과들 [Tra01]로 볼 때 상당히 좋습니다. 생산성도 대단합니다: 실제로, 이 병렬 프로그래밍 환경은 병렬 프로그래밍 컨셉을 잘 모르거나 아예 모르는 사람들도 커다란 병렬 시스템을 잘 사용할 수 있게 돋습니다.

훌륭한 성능, 생산성, 그리고 generality 를 제공하는 병렬 프로그래밍 환경의 천국은 아직 존재하지 않습니다. 그런 천국이 오기 전까지는 성능, 생산성, 그리고 generality 사이에서 엔지니어링적 트레이드오프를 가질 수밖에 없습니다. 그런 트레이드오프의 한 예가 Figure 2.3에 있습니다; 이 그림은 시스템 스택의 상위 레이어로 갈수록 생산성은 점점 중요해지고 성능과 generality 는 하위 레이어로 갈수록 중요해진다는 점을 보여줍니다. 하위 레이어에서 발생하는 커다란 개발 비용은 똑같이 커다란 사용자 수로 나뉘어져야 하고 (그래서 generality 가 중요하죠), 하위 레이어에서 잃은 성능은 위쪽에서 쉽게 회복시킬 수 없습니다. 스택의 윗단에서는 해당 특정 어플리케이션에 대해서는 매우 적은 사용자만 존재할 것이고, 따라서 생산성 고려가 중요해집니다. 이게 스택의 위로 갈수록 “bloatware”가 되는 경향을 설명합니다: 많은 경우 여러분의 하드웨어가 여분의 개발자보다 싸게 먹히니까요. 이 책은 성능과

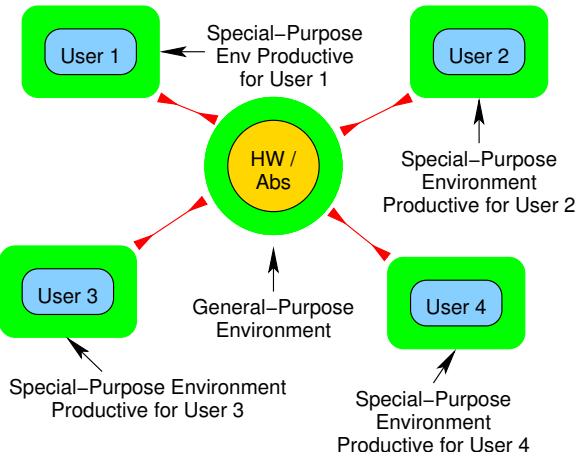


Figure 2.4: Tradeoff Between Productivity and Generality

generality 가 주요 관심사인, 스택의 바닥 근처에 있는 개발자를 대상으로 합니다.

생산성과 generality 사이에서의 트레이드오프가 많은 영역에서 수백년간 존재했음을 알아둘 필요가 있습니다. 하나만 예를 들자면, 못을 박는데 망치보다 레일건이 생산적이지만 망치는 못박는 거 말고도 많은 영역에 사용될 수 있죠. 그러니 병렬 컴퓨팅에서도 비슷한 트레이드오프들을 발견하는건 그다지 놀라운 일이 아닙니다. 이런 트레이드오프는 추상적으로 Figure 2.4에 나타나 있습니다. 여기서 user 1, 2, 3, 그리고 4는 컴퓨터의 도움이 필요한 특정한 작업을 가지고 있습니다. 특정 사용자에게 가장 생산적인 언어 또는 환경은 어떤 프로그래밍이나 환경 설정, 환경 구축을 할 필요 없이 간단하게 그 사용자의 작업을 해내는 언어 또는 환경입니다.

Quick Quiz 2.10: 이건 달성 불가한 이상에 불과해요! 현실적으로 달성 가능한 무언가에 집중하는게 어때요?

■

불행히도, user 1에 의해 요청된 작업을 수행하는 시스템은 user 2의 작업을 처리하지 못하는 경우가 많습니다. 달리 말하자면, 대부분의 생산성 좋은 언어와 환경은 영역이 한정되어 있어서, generality 가 부족할 수 있다는 것이죠.

다른 선택지는 Figure 2.4의 가운데 영역처럼 프로그래밍 언어나 환경을 (assembly, C, C++, 또는 Java 같은 로우 레벨 언어들처럼) 주어진 하드웨어에 맞추거나 (Haskell, Prolog, 또는 Snobol처럼) 추상화에 맞추는 것입니다. 이런 언어들은 user 1, 2, 3, 4에 의해 요청된 작업들에 모두 맞춰져 있지 않다는 점에서 일반적이라고 할 수 있습니다. 다시 말해, 그런 언어들의 generality 는 해당 영역에 한정된 언어와 환경에 비해 생산성을 떨어뜨려야만 얻을 수 있다는 거죠. 뿐만 아니라, 특정

추상화에 맞춰진 언어는 누군가가 그 추상화와 실제 하드웨어 사이의 매핑을 효과적으로 하기 전까지는 성능과 확장성 문제를 심하게 겪을 확률이 높습니다.

성능, 생산성, generality라는 쇠로된 삼각형의 세 가지 목표에서의 탈출은 불가능한 걸까요?

실은 종종 탈출구가 있는데, 예를 들면, 다음 섹션에서 이야기할 병렬 프로그래밍의 대안책을 사용하는 것이죠. 병렬 프로그래밍은 상당한 재미를 가져다 주는 선택일 수 있지만, 항상 최고의 선택인 건 아닙니다.

2.3 Alternatives to Parallel Programming

Experiment is folly when experience shows the way.

Roger M. Babson

병렬 프로그래밍의 대안을 제대로 고려해보려면, 여러분이 병렬성에 기대하는게 뭔지 정확히 정해야 합니다. Section 2.2에서 본것과 같이, 병렬 프로그래밍의 주요 목표는 성능, 생산성, 그리고 generality입니다. 이 책은 소프트웨어 스택의 바닥 근처에서 성능에 큰 영향을 끼치는 코드를 다루는 개발자들을 대상으로 하고 있기 때문에, 이 섹션의 나머지 부분은 성능 개선 쪽에 포커스를 맞춥니다.

하지만 병렬성은 성능을 개선하기 위한 방법 중 하나에 불과하단 것을 명심해야 합니다. 병렬성 외의 잘 알려진 방법들을 대략적으로 쉬운 것에서 어려운 것 순서로 나열해 보자면 다음과 같습니다:

1. 순차적 어플리케이션의 여러 인스턴스를 실행하는 것.
2. 어플리케이션이 이미 존재하는 병렬 소프트웨어를 사용하게 하는 것.
3. 성능 개선책을 순차적 어플리케이션에 적용하는 것.

이 방법들 각각을 다음의 섹션들에서 설명합니다.

2.3.1 Multiple Instances of a Sequential Application

순차적 어플리케이션의 여러 인스턴스를 실행시키는 것으로 실제로는 병렬 프로그래밍을 하지 않으면 병렬 프로그래밍을 한것과 같은 효과를 얻을 수 있습니다. 어플리케이션의 구조에 따라 이런 접근법을 취하는 여러 방법이 있습니다.

여러분의 프로그램이 매우 많은 개별적 시나리오를 분석하거나 매우 많은 독립적 데이터 집합들을 분석하는 것이라면 쉽고 효과적인 방법 하나는 하나의 분석을 수행하는 하나의 순차적 프로그램을 만들고 (예를 들면 `bash` 셸 같은) 스크립트 환경을 사용해 그 시퀀셜 프로그램의 여러 인스턴스를 병렬적으로 수행시키는 것입니다. 이 접근법은 경우에 따라서는 여러 머신으로 구성된 클러스터로도 쉽게 확장될 수 있습니다.

이런 접근법은 사기처럼 보일 수도 있겠죠, 그리고 어떤 사람들은 그런 프로그램들을 “당황스러울 정도로 병렬적이다”며 폄하합니다. 그리고 실제로, 이런 접근법은 메모리 소비량의 증가, 공통적인 중간 결과를 다시 계산함으로써 발생하는 CPU 사이클의 낭비, 그리고 데이터 복사의 증가와 같은 잠재적 단점을 갖습니다. 하지만, 이 접근은 종종 매우 생산적이어서 추가적인 노력을 매우 적게, 또는 아예 하지 않고도 상당한 생산성 증가를 달성 가능하게 해줍니다.

2.3.2 Use Existing Parallel Software

관계형 데이터베이스 [Dat82], 웹 어플리케이션 서버, 그리고 맵 리듀스 환경 등과 같이 싱글 쓰레드 프로그래밍으로 동작시킬 수 있는 병렬 소프트웨어 환경이 오늘날에는 결코 적지 않습니다. 예를 들어, 혼란 설계 중 하나는 각 사용자를 위한 각각의 SQL 프로그램을 생성하는 별개의 프로그램을 제공하는 것입니다(역주: SQL 클라이언트 같은거죠). 이런 사용자별 SQL 프로그램들은, 자동으로 사용자들의 쿼리들을 동시에 처리하는 일반적인 관계형 데이터베이스와 동시적으로 상호 동작합니다. 사용자에게 배포된 프로그램은 단지 사용자 인터페이스만 책임지면 되고, 병렬성과 데이터 정합성 등의 어려운 일은 모두 관계형 데이터베이스의 책임입니다.

또한, 특히 수학 계산 쪽에서, 병렬 라이브러리 함수들도 많이 생겨나고 있습니다. 심지어 일부 라이브러리는 벡터 연산 유닛과 범용 그래픽 처리 유닛 (GPGPU) 와 같은, 특수 목적으로 만들어진 하드웨어를 활용하기도 합니다.

이런 접근법은 매우 신경써서 조심스럽게 만들어진 완전히 병렬적인 어플리케이션에 비교했을 때엔 일부 성능을 희생하는 경우가 많습니다. 하지만, 그정도 희생은 대부분의 경우 개발 비용의 상당한 축소로 보상됩니다.

Quick Quiz 2.11: 잠깐만요! 이런 접근법은 개발을 위한 노력을 당신으로부터 이미 존재하는 병렬 소프트웨어를 만드는 사람인 누군가에게 전가할 뿐인 거 아닌가요? ■

2.3.3 Performance Optimization

2000년대 초까지, CPU 성능은 매 18개월마다 두배씩 빨라졌습니다. 그런 환경에서는 대부분의 경우에 주의깊게 성능 최적화를 하는 것보다 새로운 기능을 추가하는 것이 훨씬 중요합니다. 이제 무어의 법칙은 트랜지스터 집적도와 트랜지스터당 성능을 높이는 게 아니라, 트랜지스터 집적도 “만”을 올리고 있기에, 지금은 성능 최적화의 중요성에 대해 다시 생각해볼 좋은 기회입니다. 무엇보다, 새로운 하드웨어들은 더이상 싱글 쓰레드 성능의 대단한 향상을 가져오지 않습니다. 더우기, 많은 성능 최적화는 에너지 소모를 줄일 수도 있습니다.

이런 관점에서 병렬 프로그래밍은 그런 성능 최적화 방법 중 하나에 불과하지만, 병렬 시스템이 점점 싸고 시장에 많이 출시되고 있는 덕분에 점점 매력적인 선택지가 되고 있습니다. 하지만, 병렬성을 활용해 얻을 수 있는 성능 향상 정도는 대략적으로 CPU 수에 제한됨을 명심하는게 좋을 겁니다. 반면, 전통적인 싱글 쓰레드 소프트웨어 최적화에서의 최적화 기법을 통한 성능 향상은 그보다 훨씬 클 수 있습니다. 예를 들어, 긴 링크드 리스트를 해시 테이블 (hash table)이나 탐색 트리 (search tree)로 교체하는 것은 수십수백배 성능을 향상시킬 수 있습니다. 이 고도로 최적화된 싱글 쓰레드 프로그램은 최적화 되지 않은 병렬 프로그램에 비해 훨씬 빠를 것이어서 병렬화가 불필요하게 만들 겁니다. 물론, 고도로 최적화된 병렬 프로그램은 추가적인 개발 노력이 필요하겠지만 최적화된 싱글쓰레드 프로그램보다도 나은 성능을 보일테죠.

더욱이, 서로 다른 프로그램은 서로 다른 성능 병목지점을 가질 수도 있습니다. 예를 들어, 당신의 프로그램이 대부분의 시간을 디스크 드라이브로부터 데이터가 읽혀져 들어오기를 기다리며 보낸다면, 여러 CPU를 사용하는 것은 디스크로부터 데이터를 기다리며 낭비하는 시간을 증가시키기만 할 수도 있습니다. 실제로, 프로그램이 하드디스크처럼 회전하는 디스크에 연속해서 쓰여져 있는 하나의 큰 파일을 읽으려 할 때, 그 프로그램을 병렬화 하면 추가된 탐색 오버헤드 때문에 프로그램이 더 느려질 수 있습니다. 그보다는 해당 파일이 더 작아질 수 있도록 (그래서 더 빨리 읽어들일 수 있도록) 데이터 구조를 최적화 하고, 그 파일이 여러 드라이브들로부터 병렬적으로 접근될 수 있도록 여러 조각으로 나누거나, 자주 접근되는 데이터를 메인 메모리에 캐시해 놓거나, 가능하다면, 읽어야 하는 데이터의 양 자체를 줄여야 합니다.

Quick Quiz 2.12: 어떤 다른 병목지점들이 CPU를 추가해도 성능이 개선되지 않게 할 수 있을까요? ■

병렬성은 강력한 최적화 기법이 될 수 있지만, 유일한 기법도 아니고 모든 상황에 맞는 것도 아닙니다. 물론, 여러분의 프로그램이 병렬화 하기 쉬울수록 최적화 방법으로 병렬화가 더 매력적인 선택일 겁니다. 병렬화는

매우 어렵다는 평판을 얻어왔고, 이로 인해 “정확히 뭐가 병렬 프로그래밍을 그렇게 어렵게 하지?”라는 질문이 나옵니다.

2.4 What Makes Parallel Programming Hard?

Real difficulties can be overcome; it is only the imaginary ones that are unconquerable.

Theodore N. Vail

병렬 프로그래밍의 어려움은 병렬 프로그래밍 문제의 기술적 특성이기에 인간 공학에서의 이슈만큼이나 어렵다는 것을 알아두는 것이 중요합니다. 우리는 인간이 병렬 시스템에게 뭘 해야하는지 말하는 법, 다른 말로 하자면 프로그래밍을 알아야 하길 바랍니다. 하지만 병렬 프로그래밍은 프로그램의 성능과 확장성이라는, 기계로부터 인간으로의 커뮤니케이션을 포함하는 쌍방향 커뮤니케이션에 연관되어 있습니다. 요약하면, 사람은 컴퓨터가 뭘 해야하는지 말하는 프로그램을 작성하고, 컴퓨터는 이 프로그램을 그 성능과 확장성으로 비평합니다. 따라서, 추상화나 수학적 분석으로의 접근은 종종 매우 제한된 쓰임새만을 보일 겁니다.

산업혁명 때, 인간과 기계 사이의 인터페이스는 인간 공학 연구에 의해 평가되었고, 그때는 time-and-motion 연구라 불렸습니다. 비록 그때도 병렬 프로그래밍을 조사하는 인간공학 연구 [ENS05, ES05, HCS⁺05, SS94]도 있었지만, 이런 연구는 매우 좁은 주제로 한정되어 있었고, 따라서 일반적인 결과를 내놓지는 못했습니다. 더욱이, 일반적인 프로그래머 생산성의 범위가 10배 이상도 차이나는 점을 생각하면, 생산성의 (대략) 10% 차이를 알 수 있는 적당한 비용의 연구를 원하는 건 비현실적입니다. 그런 연구가 신빙성 있게 파악할 수 있는 수백 수천배 차이들도 매우 가치있지만, 대부분의 의미 있는 개선들은 10% 개선의 연장선입니다.

따라서 우리는 다른 접근법을 가져야 합니다.

그런 접근법 중 하나는 순차적 프로그래머와 달리 병렬 프로그래머가 반드시 해야 하는 작업을 신중히 고려해 보는 것입니다. 그러면 우린 개발자가 특정 작업을 처리하는데에 특정 프로그래밍 언어나 환경이 얼마나 도움을 주는지 평가할 수 있습니다. 이런 작업들은 Figure 2.5에 보여진, 각각 다음의 섹션들에서 다루어질 네개의 카테고리로 나누어집니다.

2.4.1 Work Partitioning

워크 파티셔닝은 병렬 수행을 위해 반드시 필요합니다: 만약 오로지 하나의 일 “덩어리”만 있다면, 한번에 한개

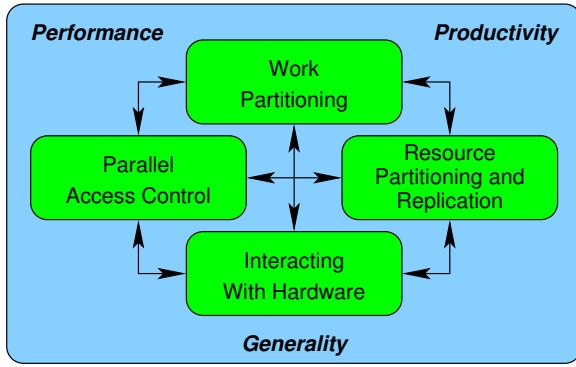


Figure 2.5: Categories of Tasks Required of Parallel Programmers

의 CPU에 의해서만 수행될 수 있는데, 이는 곧 순차적 수행이죠. 하지만, 코드를 조개는데에는 매우 큰 주의가 필요합니다. 예를 들어, 균등하지 않게 일을 조개는 경우 작은 조각들이 수행 완료된 후에는 순차적 수행이 일어납니다 [Amd67]. 덜 극단적인 경우에는 하드웨어를 모두 사용하고 성능과 확장성을 올리기 위해 로드 밸런싱이 사용될 수 있습니다.

파티셔닝이 성능과 확장성을 엄청 끌어올릴 수 있긴 하지만, 복잡도도 높일수가 있습니다. 예를 들어, 파티셔닝은 글로벌한 에러와 이벤트의 처리를 복잡하게 만들 수 있습니다: 병렬 프로그램은 그런 글로벌한 이벤트를 안전하게 처리하기 위해 복잡한 동기화를 해야만 할 수 있습니다. 좀 더 일반적으로 말해, 각각의 조각은 커뮤니케이션을 필요로 합니다: 무엇보다, 한 쓰레드가 전혀 커뮤니케이션을 하지 않는다면, 그건 어떤 효과도 일으키지 못할테고, 따라서 애초에 수행될 필요가 없는거죠. 하지만, 커뮤니케이션은 오버헤드를 일으키기 때문에, 생각없는 파티셔닝은 커다란 성능 하락을 가져올 수 있습니다.

더구나, 동시에 수행되는 쓰레드들은 종종 CPU 캐시 공간과 같은 공유 자원을 모조리 사용해 벼릴 수 있기 때문에 그 갯수는 자주 조정되어야 합니다. 너무 많은 쓰레드들이 동시에 수행되도록 된다면 CPU 캐시는 부족해질 것이고, 이는 높은 캐시 미스 비율을 초래해 성능을 떨어뜨릴 겁니다. 반대로, I/O 기기들을 모두 활용하기 위해서는 컴퓨터에 I/O를 겹치게 하기 위해 많은 수의 쓰레드가 필요한 경우가 많습니다.

Quick Quiz 2.13: CPU 캐시 용량 외에, 동시에 수행되는 쓰레드들의 갯수를 제한해야 하는 요인이 또 뭐가 있을 수 있을까요? ■

마지막으로, 쓰레드들을 동시에 수행되도록 두는 것은 프로그램의 상태 공간을 엄청나게 증가시켜서 프로그램을 이해하고 디버깅 하기 어렵게 만들어 생산성을 떨어뜨립니다. 다른것들은 똑같다 해도, 더 정규적인

구조를 갖는 더 작은 상태 공간은 이해하기 쉽습니다만, 이건 기술적 또는 수학적 표현만큼이나 인간공학적 표현입니다. 나쁜 병렬 설계는 비교적 작은 상태 공간을 갖더라도 이해하기 어렵겠지만 좋은 병렬 설계는 엄청나게 큰 상태 공간을 가지더라도 정규적 구조 덕분에 불필요할 정도로 이해하기 어렵지는 않을 겁니다. 최고의 설계는 당황스러운 병렬성을 노출하거나 문제 자체를 당황스럽게 병렬적인 해결책으로 바꿔버립니다. 어떤 경우든, “당황스럽도록 병렬적임”은 사실 부자들의 골칫거리입니다. 현존하는 최고의 기술은 좋은 설계들을 나열합니다; 상태공간 크기와 구조에 대해 더 일반적 평가를 하기 위해선 더 많은 노력이 필요합니다.

2.4.2 Parallel Access Control

싱글쓰레드로 수행되는 순차적 프로그램에서는 하나의 쓰레드가 프로그램의 모든 리소스에 접근합니다. 이런 리소스들은 대부분의 경우 메모리 위의 데이터 구조들 이지만 CPU, 메모리 (캐시 포함), I/O 기기, 연산 가속 장치, 파일, 그 외에도 다른 것들이 얼마든지 있을 수 있습니다.

첫번째 병렬-접근-제어(parallel-access-control) 문제는 어떤 리소스에의 접근 형태가 그 리소스의 위치에 의존적인가 하는 것입니다. 예를 들어, 많은 메세지 전달 환경에서는 지역변수 접근은 expression과 assignment를 통해 이루어지지만, 원격 변수에의 접근은 일반적으로 메세징과 관련된, 완전 다른 문법을 사용합니다. 메세지 패싱 인터페이스 (MPI) [MPI08]에서는 원격 데이터에 접근하는데에는 명시적 메세징이 필요하기 때문에 명시적 접근방법을 제공하는 반면, POSIX 쓰레드 환경 [Ope97], Structured Query Language (SQL) [Int92], 그리고 Universal Parallel C (UPC) [EGCD03] 같은 분할된 전체 주소공간(PGAS) 환경에서는 묵시적 접근을 제공합니다.

다른 병렬-접근-제어 문제는 쓰레드들이 리소스로의 접근에 있어 상호 순서 등을 맞출 것인가입니다. 이런 순서는 메세지 패싱, 락킹, 트랜잭션, 레퍼런스 카운팅, 명시적 타이밍, 공유된 어토믹 변수, 그리고 데이터 소유권 등을 포함한 다양한 병렬 언어와 환경에서 제공하는 매우 많은 동기화 메커니즘들을 통해 이루어집니다. 많은 전통적 병렬 프로그래밍이 이 순서 문제로부터 발생하는 데드락, 라이브락, 그리고 트랜잭션 룰백 등에 많은 고려를 합니다. 락킹 vs 트랜잭션 메모리 [MMW07] 와 같은 동기화 메커니즘들의 비교를 포함하도록 할 수도 있겠지만, 그런 설명은 이 섹션의 범위를 넘어갑니다. (트랜잭션 메모리에 대한 더 많은 정보를 위해선 Section 17.2 와 17.3 를 보기 바랍니다.)

Quick Quiz 2.14: “명시적 타이밍” 이런 무엇인가요??? ■

2.4.3 Resource Partitioning and Replication

대부분의 효과적인 병렬 알고리즘과 시스템은 자원의 병렬성을 활용하는데, 쓰기가 많이 일어나는 자원은 분할하고 읽기가 많이 일어나는 자원은 사본을 여럿 만드는 것이 현명하게 하는 식입니다. 여기서 말하는 자원은 대부분의 경우 컴퓨터 시스템, 대용량 저장장치, NUMA 노드, CPU 코어 (또는 다이 또는 하드웨어 쓰레드들), 페이지, 캐시 라인, 동기화 수단의 인스턴스, 또는 코드의 크리티컬 섹션으로 분할되곤 하는 데이터입니다. 예를 들어, 락킹으로 분할하는 것을 가리켜 “data locking” [BK85]라고 합니다.

자원 분할은 많은 경우 어플리케이션에 종속적입니다. 예를 들어, 수학적 어플리케이션은 종종 행렬을 행, 열, 또는 서브 행렬로 분할하며, 상용 어플리케이션은 많은 경우 쓰기 위주 데이터 구조는 분할시키고 읽기 위주 데이터 구조는 사본을 만듭니다. 따라서, 상용 어플리케이션은 특정 고객을 위한 데이터는 커다란 클러스터의 일부 컴퓨터에 할당할 겁니다. 일부 어플리케이션은 데이터를 정적으로, 또는 수행시간동안 동적으로 분할할 수도 있습니다.

자원 분할은 매우 효과적입니다만 복잡하게 연결되어 있는 데이터 구조에서는 꽤 달성하기 어려운 문제이기도 합니다.

2.4.4 Interacting With Hardware

하드웨어와의 상호작용은 일반적으로 운영체제, 컴파일러, 라이브러리, 또는 다른 소프트웨어 환경 인프라의 영역입니다. 하지만, 최신 하드웨어 기능과 컴포넌트를 바탕으로 일하는 개발자들 같은 경우는 그런 하드웨어를 직접 다뤄야 하는 경우가 종종 있습니다. 또한, 주어진 시스템에서 마지막 한방을까지 성능을 짜내야 하는 경우에도 하드웨어에 직접 접근해야 하는 경우가 있을 수 있습니다. 이런 경우, 개발자는 어플리케이션을 타겟 하드웨어의 캐시 구조, 시스템 구성, 또는 해당 하드웨어의 연결 프로토콜에 맞춰줘야 하게 됩니다.

어떤 경우에는, 하드웨어는 앞의 섹션에서 이야기한 것처럼 분할되거나 접근이 제어되어야 하는 자원으로 여겨질 수도 있습니다.

2.4.5 Composite Capabilities

앞서 살펴본 네가지 방법이 기본적이지만, 좋은 공학적 실천법은 이 네개의 방법을 조합해서 사용하는 것입니다. 예를 들어, 데이터 병렬 접근법은 Figure 2.6에서 보여지듯이 먼저 데이터를 파티션간 커뮤니케이션이 최소화 되도록 분할하고, 코드 역시 비슷하게 분할한 후에, 쓰레드간 커뮤니케이션이 최소화되면서 처리량은




Figure 2.6: Ordering of Parallel-Programming Tasks

최대화 할 수 있도록 데이터 파티션과 쓰레드 사이를 매핑합니다. 개발자는 각 파티션을 개별적으로 처리할 수 있어서 관련된 상태 공간의 크기를 상당히 줄여서 결국 생산성을 높일 수 있습니다. 일부 문제는 분할이 불가능 하긴 하지만, 분할 가능한 형태로의 현명한 변환은 간혹 성능과 확장성에 큰 향상을 주기도 합니다 [Met99].

2.4.6 How Do Languages and Environments Assist With These Tasks?

많은 환경이 이런 일을 개발자가 직접 할 것을 필요로 하지만, 상당한 자동화를 제공하는 환경도 오래전부터 있었습니다. 이런 환경의 대표적인 예는 SQL로, 하나의 거대한 쿼리를 자동으로 병렬화시키고 독립적인 쿼리와 업데이트들의 동시수행을 자동화 해주는 많은 구현체가 존재합니다.

모든 병렬 프로그램은 이런 네가지 카테고리의 최적화 작업들이 반드시 수행되어져야만 하지만 당연하게도 개발자가 하나 하나 손으로 해야 한다는 의미는 아닙니다. 병렬 시스템의 가격이 계속해서 인하되고 접할 수 있는 곳이 더 많아질수록 이 네가지 최적화 작업의 자동화가 늘어날 것을 기대할 수 있을 겁니다.

Quick Quiz 2.15: 병렬 프로그래밍에 다른 어려움은 없나요? ■

2.5 Discussion

Until you try, you don't know what you can't do.

Henry James

이 섹션에서는 병렬 프로그래밍의 어려움과 목표, 그리고 그 대안에 대해 간략히 살펴봤습니다. 그 뒤를 이어 무엇이 병렬 프로그래밍을 어렵게 만드는지, 그리고 그

어려움을 해결하기 위한 high-level에서의 방법에 대해 알아봤습니다. 여전히 병렬 프로그래밍은 손댈 수 없을 정도로 어렵다고 생각하는 분은 병렬 프로그래밍에의 좀 더 오래된 안내서 [Seq88, Dig89, BK85, Inm85]를 다시 한번 보시기 바랍니다. 특히, Andrew Birrell의 전공 논문 [Dig89]에서는 다음과 같이 이야기합니다:

동시성을 가진 프로그램을 짜는 것은 생소하고 어렵다는 인식이 있습니다. 전 생소하지도 어렵지도 않다고 믿습니다. 여러분에게는 좋은 기능과 알맞은 라이브러리들을 제공하는 시스템, 기본적인 주의와 조심, 유용한 테크닉, 그리고 흔한 함정들에 대한 지식이 필요합니다. 전 이 논문이 저의 믿음을 여러분에게 공유하는데 도움이 되었길 바랍니다.

이 오래된 안내서들의 저자들은 1980년대의 병렬 프로그래밍 문제에 잘 대응했습니다. 따라서, 21세기에 와서 병렬 프로그래밍 문제에 도전하는 것을 거절할 명분은 없습니다!

이제 다음 챕터로 넘어가도 좋을 것 같습니다. 다음 챕터에서는 병렬 소프트웨어 아래에 존재하는 병렬 하드웨어의 관련 있는 부분들에 대해 깊이 이야기 해 봅니다.

Premature abstraction is the root of all evil.

A cast of thousands

Chapter 3

Hardware and its Habits

대부분의 사람들은 시스템간에 메세지를 주고받는 것은 단일 시스템 안에서 간단한 계산을 하는 것보다 비싸다는 것을 직관적으로 이해하고 있습니다. 하지만, 단일 공유메모리 시스템 안에서 쓰레드간에 커뮤니케이션하는 것도 매우 비쌀 수 있다는 것은 항상 앞의 이야기만큼 분명해 보이진 않습니다. 그래서 이 챕터는 공유메모리 시스템에서의 동기화와 커뮤니케이션 비용에 대해서 알아봅니다. 이 몇장의 내용은 공유메모리 병렬 하드웨어 설계의 겉면만 훑어 볼 겁니다; 더 깊이 알고 싶은 독자분들은 Hennessy 와 Patterson 의 고전 교과서 [HP95] 최신판을 보면 좋을 겁니다.

Quick Quiz 3.1: 왜 병렬 프로그래머가 하드웨어의 로우 레벨 요소들까지 배워야 하죠? 하이 레벨의 추상 계층만 보는게 더 쉽고, 낫고, 일반적이지 않겠어요? ■

3.1 Overview

Mechanical Sympathy: Hardware and software working together in harmony.

Martin Thompson

컴퓨터 시스템 스펙 문서를 생각없이 읽으면 CPU 성능이란 Figure 3.1에 그려진 것과 같은, 제일 빠른 사람이 항상 경주에서 이기는, 깨끗한 운동장에서의 도보 경주와 같다고 생각하기 쉽습니다.

Figure 3.1에 보여진 이상적 상황으로 접근하는 CPU 바운드 벤치마크들도 몇개 있긴 합니다만, 일반적인 프로그램은 경주용 운동장보다는 장애물 코스에 더 가깝습니다. 무어의 법칙에 의해 CPU의 내부 구조가 지난 수십년간 엄청나게 변해왔기 때문이죠. 이런 변경들을 다음 섹션들에서 설명합니다.

3.1.1 Pipelined CPUs

1980년대 초, 인스트럭션을 가져오고, 디코드하고, 실행하는 대부분의 마이크로 프로세서는 일반적으로 다음




Figure 3.1: CPU Performance at its Best

인스트럭션을 가져오기 전에 인스트럭션 하나를 실행 완료하는데 최소 3 클락 사이클을 소모했습니다. 대조적으로, 1990년대 후반에서 2000년대 초반의 CPU는 CPU로의 인스트럭션 전달 흐름을 내부적으로 조절하는데 깊은 “파이프라인”을 사용해 많은 인스트럭션들을 동시에 수행할 수 있습니다. 이러한 근래의 하드웨어의 기능들은 Figure 3.2에 보여진 것처럼 성능을 대폭 향상시킬 수 있습니다.

긴 파이프라인을 가지고 CPU의 최대 성능을 얻기 위해서는 프로그램의 컨트롤 플로우 (코드 실행 흐름)를 매우 정밀하게 예측할 수 있어야 합니다. 큰 행렬이나 벡터 계산과 같이 기본적으로 꽉 짜여진 루프로 구성된 프로그램에서는 적당한 컨트롤 플로우를 얻을 수 있습니다. 그런 경우 CPU는 루프 마지막의, 루프의 처음으로 돌아갈지 루프를 빠져나갈지에 대한 분기 조건이 거의 항상 참일 거라는 것을 올바르게 예측해서 파이프라인이 꽉 차있게 해 CPU가 최대 속도로 돌아갈 수 있게 할겁니다.




Figure 3.2: CPUs Old and New




Figure 3.3: CPU Meets a Pipeline Flush

하지만, 분기 예측이 항상 그렇게 쉬운 건 아닙니다. 예를 들어, 작지만 무작위적인 횟수만큼 도는 많은 루프로 구성된 프로그램을 생각해보세요. 또 다른 예로, 수많은 진짜 객체를 레퍼런스 할 수 있는 가상 객체들이 있는데, 이 진짜 객체들은 자주 호출되는 멤버 함수들을 모두 다르게 구현한 객체지향 프로그램을 생각해보세요. 이런 경우, CPU는 다음 분기가 실행 흐름을 어디로 이끌지를 예측하는 건 어렵거나 심지어 불가능할 수 있습니다. 그렇게 되면 CPU는 그 브랜치가 어디로 실행 흐름을 이끌지가 확실해질 때까지 기다리며 멈춰있거나, 추측이라도 해야 합니다. 예측 가능한 컨트롤 플로우를 갖는 프로그램에서는 추측하는 방법이 매우 잘 동작하지만, (이진 탐색과 같은) 예측 불가능한 분기문들에 대해서는 추측이 대부분 틀릴 겁니다. 추측이 잘못된 경우 CPU는 그 분기문을 따르는, 투기적으로 그간 수행된 인스트럭션들을 모두 폐기시켜야 해서 파이프라인의 내용을

모두 비우게 되기 때문에 잘못된 예측은 매우 비싼 비용을 지불합니다. 만약 파이프라인 플러시가 너무 자주 일어난다면, Figure 3.3에서 그려진 것처럼 엄청난 성능 하락을 겪을 수 있습니다.

불행히도, 파이프라인 플러시는 근래의 CPU들이 달려야 하는 장애물 코스의 유일한 위험이 아닙니다. 다음 섹션에서는 메모리 참조에 존재하는 위험들을 다룹니다.

3.1.2 Memory References

1980년대에는, 대부분의 경우 마이크로프로세서가 메모리에서 값을 하나 얻어오는데 걸리는 시간이 인스트럭션 하나를 수행하는데 걸리는 시간보다 적었습니다. 2006년에 와서는, 마이크로프로세서는 메모리에 접근 한번 하는데 걸리는 시간 동안 수백, 심한 경우 수천개의 인스트럭션을 수행할 수 있습니다. 이 간극은 Moore의 법칙이 CPU 성능 향상을 메모리 반응속도의 감소 정도에 비해 너무 크게 이끌었기 때문입니다; 메모리의 발전은 반응속도 감소보다 용량 증가에 치중되었던 것도 한 이유죠. 예를 들어, 1970년대의 평범한 미니컴퓨터는 4KB (네, 메가바이트가 아니라 킬로바이트요. 기가바이트는 입밖에 꺼내지도 마요) 메인 메모리를 가졌고, 그 메모리는 한 사이클만에 접근 가능했습니다.¹ 2008년에도 CPU 설계자들은 여전히 단일 사이클만에 접근 가능한 4KB 메모리를 만들 수 있습니다; 심지어 수 GHz 주파수의 시스템에서도요. 그리고 실제로 그런 메모리를 만들니다만, 그들은 이제 그걸 “레벨 0 캐시”라 부르고, 그것들은 보통은 4KB 보다는 아주 약간은 크기도 합니다.

근래의 마이크로프로세서에 장착되는 큰 캐시들은 메모리 접근 시간과 맞서 싸우는데 꽤 도움을 줄 수 있습니다만, 이런 캐시들이 그 시간들을 제대로 숨기기 위해서는 고도로 예측 가능한 데이터 접근 패턴이 필요합니다. 불행히도, 링크드 리스트를 순회하는 것과 같은 많은 일들이 예측 불가능한 메모리 접근 패턴을 갖습니다. 무엇보다, 만약 패턴이 예측 가능하다면, 소프트웨어는 포인터 탐색이란 것 자체를 만들지도 않았겠죠, 그렇죠? 따라서, Figure 3.4에서 보여지듯, 메모리 참조는 종종 근래의 CPU들에게 거대한 장애물입니다.

지금까지는 주어진 CPU가 싱글 쓰레드 코드를 돌릴 때 만날 수 있는 문제들만 이야기했습니다. 멀티쓰레드 수행은 다음 섹션에서 설명할 텐데, CPU에게 추가적인 문제들을 내놓습니다.

¹ 물론 그 한개의 사이클은 1.6 마이크로 세컨드 이상이었음을 언급하는 게 공정하겠죠.

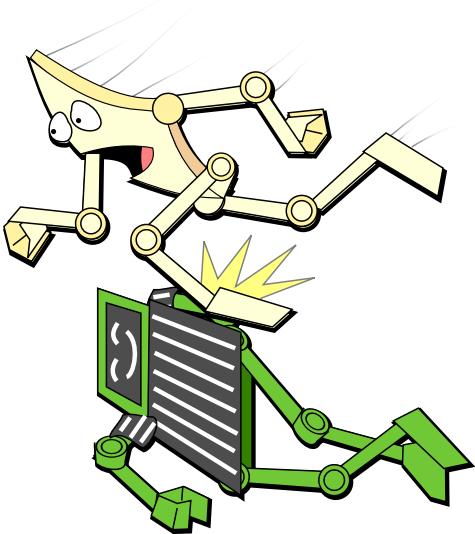


Figure 3.4: CPU Meets a Memory Reference

3.1.3 Atomic Operations

그런 장애 중 하나는 어토믹 오퍼레이션 (Atomic Operation) 들입니다. 여기서의 문제는 모든 어토믹 오퍼레이션은 어셈블리 언어 상으로는 하나의 오퍼레이션이지만 파이프라인 내에서는 여러 조각들로 나뉘어 수행되는 오퍼레이션들과 한번씩은 충돌한다는 것입니다. 하드웨어 설계자들의 업적으로 인해, 근래의 CPU 들은 그런 오퍼레이션들이 실은 여러 조각으로 나뉘어져 수행되지만 월자적으로 수행되는 것처럼 보이게 하기 위해 여러개의 굉장히 현명한 트릭들을 사용하는데, 그런 트릭 중 흔한 한 가지는 어토믹하게 수행되어야 하는 데이터를 담고 있는 캐시라인들을 모두 파악해두고, 이 캐시라인들은 해당 어토믹 오퍼레이션을 수행하는 CPU 에 소유되어 있음을 분명하게 하고, 그리고 나서야만 해당 캐시라인들이 해당 CPU 에 의해 여전히 소유되어 있음을 분명히 한 채로 어토믹 오퍼레이션을 수행하는 것입니다. 모든 데이터가 해당 CPU 만 접근할 수 있는 상태이기에, 다른 CPU 들은 실제로는 조각으로 나뉘어 수행되는 CPU 파이프라인의 현실에도 불구하고 해당 어토믹 오퍼레이션에 간섭을 끼칠 수 없습니다. 말할 필요도 없겠지만, 이런 종류의 트릭은 그 셋업이 수행되도록 주어진 어토믹 오퍼레이션이 완전히 끝날 때까지 파이프라인이 지연되거나 심지어 비워질 수도 있습니다.

반대로, 어토믹 오퍼레이션이 아닌 오퍼레이션을 수행할 때에는 CPU 는 값을 캐시라인에 올라오는대로 가져올 수 있고, 수행 결과를 캐시라인 소유권을 가지기




Figure 3.5: CPU Meets an Atomic Operation

위해 기다릴 필요 없이 곧바로 버퍼에 써넣을 수 있습니다. 다행히도, CPU 설계자들은 어토믹 오퍼레이션에 신경을 많이 쏟았고, 덕분에 2014년 초에 이르러서는 그 오버헤드를 상당히 감소시켰습니다. 하지만 그래도, 그 성능에 끼치는 효과는 Figure 3.5 에 보이는 대로입니다.

불행히도, 어토믹 오퍼레이션들은 보통 데이터의 한 개 요소에만 적용 가능합니다. 많은 병렬 알고리즘들이 복수개의 데이터 요소로의 업데이트 간에도 순서가 이루어지길 필요로 하기 때문에, 대부분의 CPU 들은 메모리 배리어들을 제공합니다. 이런 메모리 배리어들 역시 성능에 문제를 일으키는데, 다음 섹션에서 이에 대해 이야기 합니다.

Quick Quiz 3.2: 어떤 기계가 복수 데이터 요소에 대한 어토믹 오퍼레이션을 허용하겠어요? ■

3.1.4 Memory Barriers

메모리 배리어에 대해서는 Chapter 15 와 Appendix C 에서 좀 더 깊게 다룰 겁니다. 그 전에, 여기서는 다음의 간단한 락을 사용한 크리티컬 섹션을 생각해 봅시다:

```
1 spin_lock(&mylock);
2 a = a + 1;
3 spin_unlock(&mylock);
```

만약 CPU 에 코드가 보여지는 순서대로 수행되어야 한다는 제약이 존재하지 않는다면, 변수 “a”는 “mylock”의 보호 없이 값이 증가할 것이고, 이렇게 되면 락을 잡는 목표가 이뤄지지 않은 셈입니다. 그런 문제되는 순서 재배치를 막기 위해, 락킹에 사용되는 기본 기능들은 명시적이든 묵시적이든 메모리 배리어를 사용합니다. 이런 메모리 배리어의 목적은 CPU 가 성능을 향상시키기 위해 할 수 있는 코드의 순서 재배치를 막기 위한 것이기 때문에, 메모리 배리어는 거의 항상 Figure 3.6 에서 보여지듯 성능을 떨어뜨립니다.



Figure 3.6: CPU Meets a Memory Barrier

어토믹 오퍼레이션과 같이, CPU 설계자들은 메모리 베리어 오버헤드를 줄이려 열심히 노력해왔고, 꽤 많은 진전을 이뤘습니다.

3.1.5 Cache Misses

멀티 쓰레딩에서의 CPU 성능에의 또하나의 장애물은 “캐시 미스”입니다. 앞서 말했듯, 근래의 CPU들은 큰 메모리 응답시간으로 인해 발생할 수 있는 성능 하락을 줄이기 위해 큰 캐시를 장착하고 있습니다. 하지만, 이런 캐시들은 CPU 간에 자주 공유되는 변수들에 대해서는 생산적이지 못합니다. 하나의 CPU 가 어떤 변수를 수정하려 할 때, 다른 CPU 가 그 값을 최근에 바꾼 경우가 있을 가능성이 크기 때문이죠. 이런 경우, 해당 변수는 지금 수정하려는 CPU의 캐시가 아니라 최근에 값을 수정한 CPU의 캐시에 있을 것이고, 이로 인해 비싼 캐시 미스(더 자세한 내용을 위해선 Section C.1 를 보세요)를 일으킬 것입니다. 이런 캐시 미스들은 Figure 3.7에서 보여진 것처럼 CPU 성능의 주요 장애가 됩니다.

Quick Quiz 3.3: 그래서, CPU 설계자들은 캐시 미스 오버헤드 역시 많이 개선 했나요? ■

3.1.6 I/O Operations

캐시 미스는 곧 CPU 와 CPU 사이의 I/O 오퍼레이션으로 볼 수 있고, 이것은 가능한 I/O 오퍼레이션 중 가장 비용이 낮은 것들 중 하나입니다. 네트워킹이나 대용량 저장장치, 또는 사람을 포함하는 I/O 오퍼레이션들은

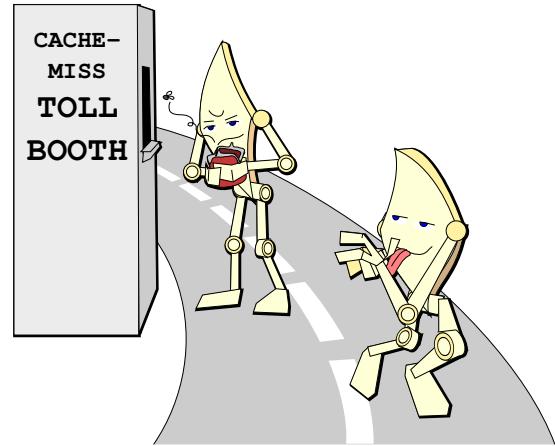


Figure 3.7: CPU Meets a Cache Miss




Figure 3.8: CPU Waits for I/O Completion

Figure 3.8에서 보여지듯, 앞의 섹션들에서 이야기 되었던 내부적 장애들보다 훨씬 커다란 장애를 야기합니다.

이건 공유메모리와 분산시스템의 병렬성 사이의 차이 중 하나입니다: 공유메모리 병렬 프로그램에서는 일반적으로 캐시 미스보다 더한 장애는 겪지 않지만, 분산 병렬 프로그램은 보통 네트워크 커뮤니케이션으로 인한 더 큰 응답시간을 야기합니다. 두 경우 모두, 문제의 응답시간들은 커뮤니케이션의 비용으로 생각될 수 있습니다. 순차적 프로그램에서는 존재하지 않는 비용이죠. 따라서, 실제 수행되는 일과 커뮤니케이션 오버헤드 간의 비율이 핵심 설계 결정 요소입니다. 병렬 하드웨어 설계의 주요 목표는 이 비율을 적절한 성능과 확장성 목표를 달성 가능한 수준으로 낮추는 것입니다. 뒤이어 Chapter 6에서 볼테지만, 병렬 소프트웨어 설계의

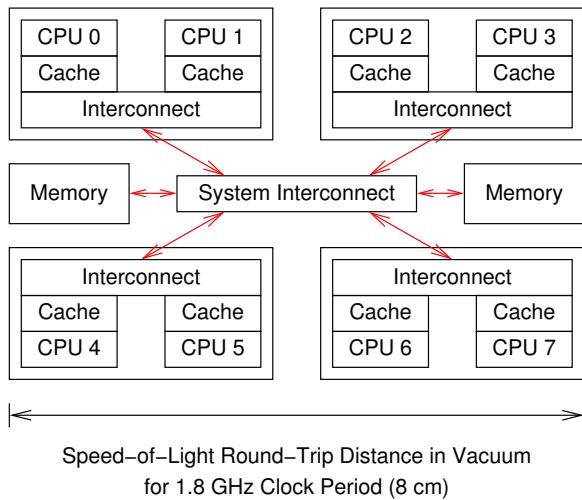


Figure 3.9: System Hardware Architecture

중요한 목표는 커뮤니케이션 캐시 미스와 같은 비싼 동작들의 빈번도를 낮추는 것입니다.

물론, 주어진 동작이 장애라는 이야기는 그 이야기이고, 그 동작이 심각한 장애라는 건 또 따로 보여줘야하지요. 이 차이를 다음의 섹션에서 이야기 합니다.

3.2 Overheads

Don't design bridges in ignorance of materials, and don't design low-level software in ignorance of the underlying hardware.

—————
Unknown

이 섹션에서는 앞의 섹션에서 나열했던 장애들의 실제 성능에의 오버헤드를 보입니다. 하지만, 그 전에 하드웨어 시스템 아키텍처에 대해서 간략히 알아볼 필요가 있는데, 다음 섹션에서 이를 다룹니다.

3.2.1 Hardware System Architecture

Figure 3.9 는 어느 8 코어 컴퓨터 시스템의 간략한 구조를 보여줍니다. 각 다이어그램은 CPU 코어 한쌍을 가지고, 각 코어는 캐시를 가지고, 각 캐시는 쌍을 이루는 코어와 통신을 할 수 있도록 연결이 되어 있습니다. 그림 중간의 system interconnect 는 네개의 다이어그램이 통신할 수 있도록 하며, 각 다이어그램은 메모리로 연결합니다.

이 시스템에서 데이터는 보통 32 dptj 256 바이트 사이의 2의승수 크기로 정렬된 메모리의 블락인, “캐시 라인” 단위로 움직입니다. CPU 는 메모리로부터 자신의 레지스터로 변수를 가져오려면, 그 변수를 가지고 있는

캐시 라인을 자신의 캐시로 가져와야 합니다. 비슷하게, CPU 는 자신의 레지스터로부터 메모리로 어떤 값을 쓰려 할 때, 일단 그 변수를 담고 있는 캐시 라인을 자신의 캐시로 가져와야 합니다만, 동시에 다른 CPU 가 그 캐시 라인의 복사본을 들고 있지 않음을 보장해야 합니다.

예를 들어, 만약 CPU 0 가 CPU 7 의 캐시에 있는 캐시라인이 있는 변수에 compare-and-swap (CAS) 오퍼레이션을 하려 하면, 간략히 표현해서 다음과 같은 이벤트들이 일어날 겁니다:

1. CPU 0 는 자신의 로컬 캐시를 체크해 보고, 그 캐시라인이 로컬 캐시에 없음을 발견합니다.
2. 요청은 CPU 0 와 CPU 1 사이의 연결로 넘겨져서 CPU 1 의 로컬 캐시를 확인해봅니다만, 역시 해당 캐시라인이 없음을 발견합니다.
3. 요청은 시스템 연결부로 넘겨지고, 다른 세 개의 다이어그램을 체크합니다. 결과, 해당 캐시라인은 CPU 6 과 CPU 7 이 위치한 다이어그램에 있음을 확인합니다.
4. 요청은 CPU 6 과 CPU 7 연결부로 넘겨져 각 CPU 의 캐시를 확인해 해당 캐시 라인이 CPU 7 의 캐시에 있음을 발견합니다.
5. CPU 7 은 해당 캐시라인을 자신의 연결부로 넘기고, 자신의 캐시에서 해당 캐시라인을 비워버립니다.
6. CPU 6 와 CPU 7 의 연결부는 해당 캐시 라인을 시스템 연결부로 넘깁니다.
7. 시스템 연결부는 해당 캐시 라인을 CPU 0 과 CPU 1 연결부로 넘깁니다.
8. CPU 0 와 CPU 1 연결부는 해당 캐시라인을 CPU 0 의 캐시로 보냅니다.
9. CPU 0 는 이제 자신의 캐시 안에 있는 변수에 CAS 오퍼레이션을 수행할 수 있습니다.

Quick Quiz 3.4: 이게 간략히 표현한 거라구요? 이것 보다 더 복잡한 어떻게 가능하죠? ■

Quick Quiz 3.5: 왜 CPU 7 의 캐시에서 해당 캐시라인을 비워야 하죠? ■

이 간략화된 시나리오는 Appendix C 에서 자세히 설명되는 캐시 일관성 프로토콜 [HP95, CSG99, MHS12, SHW11] 의 시작일 뿐입니다. CAS 오퍼레이션으로 시작되는 이벤트 시퀀스에서 볼 수 있듯이, 하나의 인스트럭션에 상당한 양의 프로토콜 트래픽을 일으킬 수 있으며, 이는 병렬 프로그램의 성능을 상당히 떨어뜨릴 수 있습니다.

Table 3.1: Performance of Synchronization Mechanisms on 4-CPU 1.8 GHz AMD Opteron 844 System

Operation	Cost (ns)	Ratio (cost/clock)
Clock period	0.6	1.0
Best-case CAS	37.9	63.2
Best-case lock	65.6	109.3
Single cache miss	139.5	232.5
CAS cache miss	306.0	510.0
Comms Fabric	5,000	8,330
Global Comms	195,000,000	325,000,000

운좋게도 특정 변수가 업데이트 되지 않는 사이에 빈번하게 읽혀진다면, 해당 변수는 모든 CPU들의 캐시 위에 복사될 수 있습니다. 이 복사는 모든 CPU들이 이 읽기가 대부분인 변수로의 매우 빠른 접근을 즐길 수 있도록 해줄 겁니다. Chapter 9는 이 중요한 하드웨어의 읽기가 대부분인 경우의 최적화의 장점을 최대한 취하는 동기화 메커니즘들을 소개합니다.

3.2.2 Costs of Operations

Table 3.1에 병렬 프로그램에 흔히 사용되는 중요 오퍼레이션들의 오버헤드가 표시되어 있습니다. 이 시스템의 클락 시간은 약 0.6 ns입니다. 많은 근래의 마이크로프로세서가 한 클락 시간동안 여러 인스트럭션을 수행 완료시킬 수 있긴 합니다만, 여기서의 오퍼레이션 비용은 클락 시간을 기준으로 해서 “Ratio”라고 표시한 세번째 행의 값으로 나타냅니다. 이 표에서 가장 먼저 눈여겨 봄은 큰 비율의 값들입니다.

Compare-and-swap (CAS) 오퍼레이션은 최선의 경우 약 40 나노세컨드를 소모하는데, 이는 클락 시간보다 60배 이상 큽니다. 여기서 “최선의 경우”란 변수에 CAS 오퍼레이션을 수행하는 CPU와 해당 변수를 마지막으로 건든 CPU가 동일해서 해당 변수의 캐시 라인이 이미 자신의 캐시 안에 있는 경우입니다. 비슷하게, 최선의 경우 락 오퍼레이션 (락 획득과 해제 두개 오퍼레이션의 수행 시간의 합)은 100 클락 사이클이 넘는 시간인 60 나노 세컨드를 소비합니다. 다시 말하지만, “최선의 경우”는 락을 나타내는 데이터 구조가 이미 락의 획득과 해제를 수행하는 CPU의 캐시 위에 있는 경우입니다. 락 오퍼레이션은 락 데이터 구조에 대한 두번의 어토믹 오퍼레이션을 필요로 하기 때문에 CAS 보다 비쌉니다.

캐시 미스가 난 오퍼레이션은 거의 200 클락 사이클인 140 나노세컨드를 소모합니다. 이 캐시 미스 비용 측정을 위해 사용된 코드는 미스가 난 데이터를 다른 CPU의 캐시에서 얻어옵니다. 즉, 이 캐시 미스 오퍼레이션은 메모리까지 접근하지는 않습니다. 변수의 기준

값을 보는 것은 물론, 새로운 값을 쓰기도 해야 하는 CAS 오퍼레이션은 500 클락 사이클인 300 나노세컨드를 소비합니다. 이걸 조금 생각해 봅시다. CPU는 하나의 CAS 오퍼레이션을 수행하는데 필요한 시간 동안, 500개의 평범한 인스트럭션을 수행할 수도 있습니다. 이건 fine-grained 락킹만이 아니라 fine-grained 전역적 규칙에 기반한 모든 동기화 메커니즘의 한계를 보여줍니다.

Quick Quiz 3.6: 하드웨어 설계자들은 분명이 상황을 개선하려 노력할 수 있었을 거예요! 왜 그들은 이 단일 인스트럭션 오퍼레이션들의 끔찍한 성능을 만족하고 있는거죠? ■

I/O 오퍼레이션들은 이보다도 더 비쌉니다. “Comms Fabric” 열에서 나타나 있듯이, InfiniBand나 몇몇 독점 연결장치와 같은 고성능의 (그리고 고비용의!) 통신 장치들은 단말간 왕복에 약 5 마이크로세컨드의 응답시간을 갖는데, 이는 8천개의 인스트럭션을 수행될 수도 있는 시간입니다. 표준에 기반한 통신 네트워크들은 종종 몇몇 프로토콜 프로세싱을 필요로 하고, 이는 대기시간을 더욱 증가시킵니다. 물론, 지형적 거리도 대기시간을 늘리는데, 광섬유를 통해 빛의 속도로 움직인다 해도 지구를 한바퀴 돌기 위해서는 3억 클락 사이클보다도 큰 약 195 밀리세컨드의 시간을 필요로 하며, 이 수치는 “Global Comms” 열에 있습니다.

Quick Quiz 3.7: 숫자가 미친듯이 크군요! 어떡해야 제 머리로 이걸 이해할 수 있을까요? ■

3.2.3 Hardware Optimizations

하드웨어가 어떻게 도움을 주고 있는지 묻는건 자연스럽고, 그에 대한 대답은 “상당히!”입니다.

하드웨어 최적화 중 하나는 큰 캐시라인입니다. 이는 소프트웨어가 메모리를 순차적으로 접근할 때 특히 성능을 크게 향상시킬 수 있습니다. 예를 들어, 64바이트 캐리아닝에서 소프트웨어가 64비트 변수를 접근할 때, 첫번째 접근은 빛의 속도의 지연으로 인해 느릴 수 있습니다만, 뒤이은 일곱번은 상당히 빠를 겁니다. 하지만, 이 최적화는 같은 캐시라인에 있는 다른 변수가 다른 CPU들에 의해 업데이트 되는 경우에 발생하여 상당한 캐시 미스 발생율을 일으키는 false sharing이라 하는 어두운 측면을 갖습니다. 소프트웨어는 많은 컴파일러에서 사용할 수 있는 정렬 지시어를 사용해서 false sharing을 없앨 수 있으며, 그런 지시어를 추가하는건 병렬 소프트웨어를 최적화하는 흔한 방법입니다.

두번째의 관련된 하드웨어 최적화는 캐시 프리페칭으로, 하드웨어가 연속된 접근에 대해 연속된 캐시라인을 미리 얻어옴으로써 빛의 속도의 지연을 이 연속된 캐시라인들에 대해 제거하는 겁니다. 물론, 이 하드웨어는 언제 프리페치를 할 것인지에 대한 단순한 휴리스틱

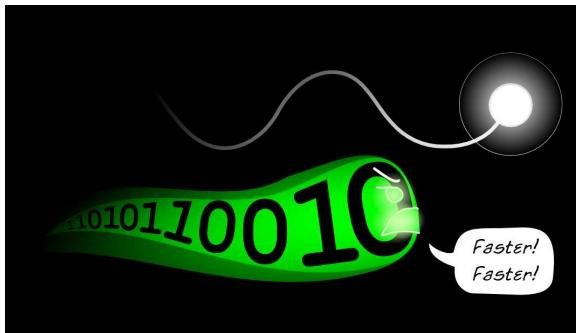


Figure 3.10: Hardware and Software: On Same Side

을 사용해야 하며, 이 휴리스틱은 많은 어플리케이션의 복잡한 데이터 패턴에 의해 명청해 질 수 있습니다. 운좋게도, 일부 CPU 제품군들은 특별한 프리페치 명령을 제공하므로 이를 허용합니다. 불행히도, 일반적인 경우에서 이런 명령어들의 효율성은 일부 경우에 효과적이지 못합니다.

세번째 하드웨어 최적화는 스토어 버퍼로, 이는 비연속적인 주소에 대한 스토어들도, 그리고 필요한 캐시라인들이 해당 CPU의 캐시에 있지 않을 때도 빨리 행해지게 만듭니다. 이 최적화의 어두운 부분은 메모리 순서의 잘못됨으로, 이에 대해서는 Chapter 15를 보시기 바랍니다.

네번째 하드웨어 최적화는 예측적 수행으로, 하드웨어가 스토어 버퍼를 메모리 순서 잘못됨 없이 사용할 수 있게 해줍니다. 이 최적화의 어두운 면은 예측된 수행이 잘못되어서 롤백되고 다시 수행되어야 할 때 일어나는 에너지 비효율성과 하락되는 성능입니다. 더 나쁜게, Spectre 와 Meltdown 의 등장 [Hor18]으로 인해 하드웨어 예측적 수행은 메모리 보호 하드웨어를 무효화 시켜서 권한이 없는 프로세스가 접근할 수 없어야 하는 메모리를 읽을 수 있게 하는 공격이 가능하게 할 수 있음이 분명해졌습니다. 예측적 수행과 클라우드 컴퓨팅의 조합은 다시 작업해야 하는게 적지 않음이 분명합니다!

다섯번째 최적화는 커다란 캐시로, 개별 CPU들이 비싼 캐시 미스 없이 커다란 데이터셋을 사용할 수 있게 합니다. 커다란 캐시가 전역 효율성과 캐시 미스 응답시간을 악화시킬 수 있지만, 제품화된 마이크로 프로세서들의 캐시 사이즈가 계속증가되고 있는 캐시 크기는 이 최적화의 힘을 증명합니다.

마지막 하드웨어 최적화는 읽기가 대부분인 경우의 복사로, 자주 읽혀지지만 가끔씩만 업데이트 되는 데이터에 대한 것입니다. 이 최적화는 읽기가 대부분인 데이터가 매우 효율적으로 접근될 수 있게 하는 것이며, Chapter 9의 주제입니다.

짧게 말해서, 하드웨어와 소프트웨어 엔지니어들은 사실 Figure 3.10에 우리의 데이터 스트림이 빛의 속도를

넘으려 노력하는 그림으로 나타낸 것처럼, 컴퓨터들이 물리적 법칙에도 불구하고 더 빨리 동작할 수 있도록 우리와 같은 편에서 고군분투하고 있습니다. 다음 섹션은 최근의 연구가 실제로는 어떻게 적용되는가에 따라 하드웨어 엔지니어들이 할수도(또는 안할수도) 있는 것들에 대해 알아봅시다. 이 짜움에서 소프트웨어가 할 수 있는 공헌을 이 책의 남은 챕터들에서 이야기 합니다.

3.3 Hardware Free Lunch?

The great trouble today is that there are too many people looking for someone else to do something for them. The solution to most of our troubles is to be found in everyone doing something for themselves.

Henry Ford, updated

동시성이 최근들어 기준보다 주목을 받게 된 것은 페이지 9의 Figure 2.1에서 보이는 대로 무어의 법칙에 의한 싱글 쓰레드 성능 증가(또는 “공짜 점심” [Sut08])가 멈췄기 때문입니다. 이 섹션에서는 하드웨어 설계자들이 “공짜 점심”을 약간이라도 다시 가져올 수 있는 몇 가지 방법을 간략히 알아봅니다.

하지만, 앞의 섹션에서는 동시성을 노출하는데 생기는 상당한 하드웨어적 문제를 알아봤습니다. 하드웨어 설계자들이 직면하는 강력한 물리적 한계점들 중 하나는 빛의 유한한 속도입니다. 페이지 21의 Figure 3.9에 보여진 것처럼, 빛은 진공에서 1.8 GHz 클락 시간동안 8 센티미터만을 왕복할 수 있습니다. 이 거리는 5 GHz 클락에서는 3 센티미터로 줄어듭니다. 근래의 컴퓨터 시스템의 크기에 비교해 보면 둘 다 비교적 작은 거리입니다.

상황이 더 나빠지는게, 실리콘에서의 전자파는 진공에서의 빛에 비해 세배에서 서른배까지 느리게 움직이고, 일반적인 클락 주파수에 맞춰 움직이는 논리 회로들은 더욱 느리게 동작하는데, 예를 들어 메모리 접근은 접근 요청이 시스템의 나머지 영역으로 넘어가기 전에로컬 캐시 검색의 완료를 기다려야 합니다. 더욱이, 예를 들어 CPU와 메인 메모리 사이의 통신의 경우와 같이, 전기 신호를 한 실리콘 다이에서 다른 다이로 넘기기 위해서는 상대적으로 느린 속도와 큰 파워의 드라이버가 필요합니다.

Quick Quiz 3.8: 하지만 개별의 전자들은 컨덕터 내에서 조차도 그렇게 빠르지 않아요!!! 반도체에서 발견된 저전압 컨덕터 안에서의 전자 이동 속도는 초당 겨우 1 밀리미터 정도라구요. 뭔가요??? ■

그러나, 이를 개선할 기술이 (하드웨어에도 소프트웨어에도) 약간 있습니다:

1. 3D 용합,

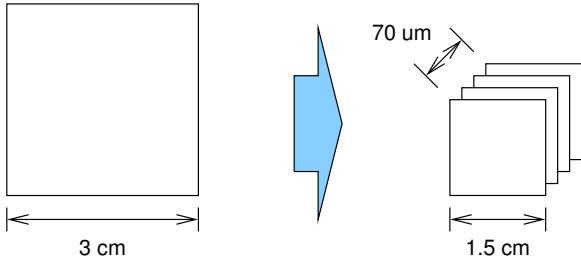


Figure 3.11: Latency Benefit of 3D Integration

2. 훌륭한 물질과 프로세스들,
3. 전자를 빛으로 대체하는것,
4. 특수 목적의 가속기, 그리고
5. 존재하는 병렬 소프트웨어.

이것들 각각을 다음 섹션에서 설명합니다.

3.3.1 3D Integration

3차원 접적 (3DI)은 매우 얇은 실리콘 다이들을 수직으로 쌓아 올려 붙이는 기술입니다. 이 기술은 잠재적 이득을 제공하지만, 또한 대단한 공정적 어려움 [Kni08]을 품고 있습니다.

3DI가 가져올 수 있는 가장 중요한 이점은 Figure 3.11에 그려진대로, 시스템 전체적으로 짧아지는 경로의 길이일 것입니다. 해당 그림에서는 3 센티미터의 실리콘 다이가 네개의 1.5 센티미터 다이들의 더미로 바뀌었고, 각 레이어 사이의 거리가 상당히 얇다는 것을 고려하면 이론적으로 시스템을 관통하는 최대 경로의 길이가 두 배 가까이 줄어든 셈입니다. 또한, 설계와 배치에 충분한 고려를 한다면, (느리고 전력도 많이 소모함) 수평적인 전자적 연결들은 빠르기도 하고 전력 소모도 적은, 얇은 수직적 전자적 연결로 대체될 수 있을 것입니다.

하지만, 클락으로 동작하는 논리회로의 단계들로 인한 지연은 3D 융합으로 감소되진 못할 것이고, 상기한 장점들을 달성하면서도 상품화하기 위해서는 3D 융합에서의 제조, 테스트, 전력 제공, 그리고 발열 처리 등의 상당한 수준의 문제들이 해결되어야 합니다. 발열 처리는 훌륭한 열의 전도체이지만 전자에는 절연체인 다이아몬드에 기반한 반도체를 사용해 해결될 수 있을 것입니다. 그렇지만, 웨이퍼를 만들기 위한 커다란 단일 다이아몬드 크리스탈을 만드는 것은 어려운 것으로 알려져 있습니다. 또한, 이런 기술들 중 어느 것도 몇몇 사람들은 이미 익숙해진 이 문제에 커다란 개선을 가져다 주진 못할 것 같습니다. 그렇지만, 짐 그레이의 “연기나는 텔루성이 골프공들” [Gra02]로 가기 위해서는 해결되어야만 하는 단계입니다.

3.3.2 Novel Materials and Processes

스티븐 호킹은 반도체 제조사들이 두개의 근본적 문제를 가지고 있다고 이야기했다고 합니다: (1) 빛의 제한된 속도와 (2) 물질의 원자적 본질 [Gar07]. 반도체 제조사에서 이런 제약을 해결해 보려 하는건 가능하겠지만, 이런 근본적 한계들을 비켜나가는데 집중해온 연구와 개발 과정에서 얻어진 몇가지 방법만이 존재할 뿐입니다.

물질의 원자적 본질에 대한 한개의 회피책은 보다 큰 기기가 실현 불가능하도록 작은 기기의 전자적 특성을 흉내내게 하는, “high-K dielectric”이라 불리는 물질들입니다. 이 물질들은 일부 쉽게 해결하기 어려운 제조 공정 문제를 가지고 있지만, 선도자들이 한걸음 더 나아가는데 도움을 줄수도 있습니다. 또다른 좀 더 신기한 회피법은 하나의 전자는 여러 에너지 레벨을 가질 수 있다는 점을 이용해 여러 비트들을 하나의 전자에 저장하는 것입니다. 이 방법이 상품화된 반도체 기기에서 안정적으로 동작하게 될 수 있을지는 아직 확실하지 않습니다.

또다른 제안된 회피책은 훨씬 작은 기기 크기들을 이용하는 “quantum dot” 방법입니다만 아직 연구 단계에 머물러 있습니다.

여기서의 도전사항은 많은 최근의 하드웨어 기기 수준의 타개책들은 어떤 원자가 어디에 위치해야 하는지에 대한 매우 세밀한 조정을 필요로 한다는 겁니다 [Kel17]. 따라서 원자들을 칩 위의 수십억개의 기기들 각각에 세밀하게 위치시킬 수 있는 좋은 방법을 찾는 누군가는 가장 대단한 자랑거리를 가질 수 있을 겁니다!

3.3.3 Light, Not Electrons

빛의 속도는 매우 가혹한 제약이지만, 반도체 물질 내부의 전자파는 진공에서의 빛의 속도의 3 %에서 30 % 사이 속도로 움직이기 때문에, 반도체 기기는 빛의 속도보다는 전자의 속도에 제한되고 있다고 볼 수 있습니다. 실리콘 기기에서 구리로된 접합부를 사용하는 것은 전자의 속도를 높이는 한 방법이고, 그 외에도 추가적인 방법을 사용하면 실제 빛의 속도에 더 가까이 다가갈 수 있을 것입니다. 덧붙이자면, 유리에서의 빛의 속도는 진공에서의 빛의 속도의 60 % 이상이라는 사실에 기초해 칩들 사이에 작은 광섬유를 연결부로 사용한 실험도 있었습니다. 그런 광섬유 사용의 한가지 문제는 전자와 빛 사이의 변환의 효율성이 떨어진다는 점으로, 이는 에너지 소모와 발열 처리 문제를 일으킵니다.

그렇다면 하나, 물리학 쪽에서의 근본적 진전이 없이는 데이터 흐름 속도의 폭발적인 증가는 진공에서의 빛의 속도에 제한될 것입니다.

3.3.4 Special-Purpose Accelerators

특수한 문제를 푸는데 범용 CPU 가 사용되면, 실제 문제에는 크게 관련되지 않은 부분에 많은 시간과 에너지를 소모하고 있는 경우가 많습니다. 예를 들어, 두개의 벡터의 내적을 구하는 경우, 범용 CPU 는 일반적으로 루프 카운터를 사용해 루프 (아마도 루프 언롤링을 적용하지 않은채) 를 돌릴 겁니다. 인스트럭션을 디코드하고, 루프 카운터를 증가시키고, 이 카운터의 값을 체크하고, 루프의 시작지점으로 실행흐름을 다시 옮기는 일은 어떻게 보면 좀 낭비스럽습니다: 실제 목표는 그게 아니라 두 벡터의 연관된 원소들을 곱하는 거니까요. 따라서, 벡터들을 곱하는데 특수하게 설계된 특별한 하드웨어 부품은 해당 작업을 보다 에너지를 적게 쓰면서 보다 빠르게 해결할 수 있습니다.

이게 실제로 많은 상용 마이크로프로세서에 존재하는 벡터 연산 명령어들의 모티베이션이 되었습니다. 이런 명령어들은 여러 데이터 항목들에 동시에 적용되기 때문에, 보다 적은 인스트럭션 디코드와 루프 오버헤드만으로 내적 연산을 완료할 겁니다.

비슷하게, 특수화된 하드웨어는 보다 효율적으로 암호화와 복호화, 압축과 압축 해제, 인코딩과 디코딩, 그리고 그외에도 여러 많은 작업을 처리할 수 있습니다. 안타깝게도, 이런 효율성은 공짜로 오진 않습니다. 이런 특수화된 하드웨어를 내장하는 컴퓨터 시스템은 더 많은 트랜지스터를 장착하게 되고, 이는 곧 일부 전력의 소모를 의미하는데, 심지어 사용중이지 않을때도 전력을 소모할 수 있습니다. 이 특수 하드웨어의 장점을 활용하기 위해선 소프트웨어도 수정되어야 하며, 이 특수 하드웨어는 웃단 프론트엔드 설계 비용이 충분히 많은 사용자에게 나뉘어져 구매할 수 있을만한 가격이 될 정도로 충분히 일반적으로 유용해야만 합니다. 부분적으로는 이런 부류의 경제적 고려사항 때문에 특수화된 하드웨어는 그래픽 처리 (GPU), 벡터 처리기 (MMX, SSE, 그리고 VMX 명령어들), 그리고 암호화 등의 적은 어플리케이션 분야에만 나타나곤 했습니다.

서버와 PC 분야와 달리, 스마트폰은 다양한 하드웨어 가속기를 사용해 왔습니다. 이런 하드웨어 가속기는 미디어 디코딩에 주로 사용되어서, 고성능의 MP3 플레이어가 CPU 가 완전히 잠든 채로 오디오를 몇분간 재생 가능하도록 했습니다. 이런 가속기의 목적은 에너지 효율성을 개선해서 배터리 수명을 늘리는 것입니다: 특수 목적 하드웨어는 많은 경우 범용 CPU 보다 더 효율적으로 연산을 처리할 수 있습니다. 이건 Section 2.2.3 에서 다룬 기본 요소에 대한 또하나의 예입니다: 제너럴리티는 거의 항상 공짜가 아닙니다.

무어의 법칙으로 인한 싱글 쓰레드 성능 향상이 멈춘 이상, 앞으로는 더 다양한 특수 목적 하드웨어가 나타날 것이라고 보여집니다.

3.3.5 Existing Parallel Software

멀티코어 CPU 는 컴퓨팅 산업을 놀라게 한 것 같지만, 사실 공유 메모리 병렬 컴퓨터 시스템은 25년여 전부터 판매되었습니다. 이건 중대한 병렬 소프트웨어가 나타나기에 충분한 시간이 되고도 남고, 그리고 실제로 그려했습니다. 병렬 운영 체제는 상당히 흔하고, 병렬 쓰레딩 라이브러리와 병렬 관계형 데이터베이스 관리 시스템, 그리고 병렬 수학 분야 소프트웨어가 그렇습니다. 이미 존재하는 병렬 소프트웨어를 사용하는 것은 우리가 마주한 어떤 병렬 소프트웨어 위기를 해결하는데 많은 도움을 줄 수 있습니다.

아마도 가장 대표적인 예는 병렬 관계형 데이터베이스 관리 시스템일 것입니다. 종종 하이 레벨 스크립트 언어로 짜여지는 싱글 쓰레드 프로그램들에서는 중앙의 관계형 데이터베이스에 동시적으로 접근할 일이 별로 없을 겁니다. 최종적으로 사용되는 고도로 병렬화된 시스템에서는 데이터베이스 자체만이 실질적으로 병렬성을 직접 고려하면 되는 존재입니다. 제대로 먹힌다면 매우 훌륭한 트릭이죠!

3.4 Software Design Implications

One ship drives east and another west
While the self-same breezes blow;
'Tis the set of the sail and not the gail
That bids them where to go.

Ella Wheeler Wilcox

Table 3.1 에 나온 비율 값들은 주어진 병렬 어플리케이션의 효율성을 제한하기 때문에 매우 중요합니다. 해당 병렬 어플리케이션이 쓰레드들간에 통신을 하기 위해 CAS 를 사용한다고 생각해 보세요. 이 CAS 오퍼레이션들은 쓰레드들이 자기 혼자 하는게 아니라 다른 쓰레드들과 통신을 하기 위해 사용하는 것이기 때문에 자주 캐시 미스를 낼 것입니다. 더 나아가서 각각의 CAS 통신 오퍼레이션에 뒤따르는 일의 단위가 부동 소수점 연산 작업 정도는 충분히 할 수 있는 시간인 300ns 인 경우를 상상해 보세요. 그렇게 되면 실행 시간의 절반 가량이 CAS 통신 오퍼레이션만으로 소모되는 겁니다! 이건 결국 그런 병렬 프로그램을 돌리는 두개짜리 CPU 로 구성된 시스템은 한개짜리 CPU 시스템에서 돌아가는 순차적 구현보다도 빠르게 동작하지는 못한다는 이야기입니다.

단일 통신 오퍼레이션의 대기시간이 수천 또는 심지어 수백만 부동소수점 연산만큼이나 느린 분산 시스템의 경우엔 더 상황이 나빠집니다. 이는 통신 작업이 극단적으로 가끔만 일어나야 하고 매우 큰 단위의 연

산을 가능하게 해야 하는 것이 얼마나 중요한지를 잘 보여줍니다.

Quick Quiz 3.9: 분산 시스템에서 통신이 그렇게까지 비싸다면 누가, 그리고 왜 그런 시스템을 쓰려 하는 건가요? ■

교훈은 분명합니다: 병렬 알고리즘들은 이런 하드웨어 특성을 분명히 마음 속에 기억해둔 채 분명하게 설계되어야만 합니다. 그런 한가지 방법은 거의 독립적인 쓰레드들을 수행시키는 것입니다. 어토믹 오퍼레이션을 사용하든, 락이나 명시적 메세지를 사용하든, 쓰레드들의 커뮤니케이션이 덜 빈번할수록 어플리케이션의 성능과 확장성은 나아질 것입니다. 이런 방법은 Chapter 5에서 간단히 알아보고, Chapter 6에서 자세히 알아본 후, 그 논리적 극단에 대해 Chapter 8에서 알아봅니다.

또 다른 방법은 공유된 것들에 가해지는 접근은 읽기 가 대부분이도록 하는 것인데, 이렇게 되면 CPU들이 캐시에 읽기만 대부분 가해지는 데이터를 복사해 들 수 있게 해서, 모든 CPU들이 빠른 접근을 할 수 있게 합니다. 이런 방법은 Section 5.2.3에서 간단히 알아보고, Chapter 9에서 좀 더 깊게 다뤄봅니다.

요약하자면, 훌륭한 병렬 성능과 확장성을 달성하는 것은 조심스럽게 데이터 구조와 알고리즘을 선택해서든, 존재하는 병렬 어플리케이션과 환경을 사용해서든, 또는 문제를 당황스럽도록 병렬적인 해결책이 존재하는 문제로 변환해서든 당황스럽도록 병렬적인 알고리즘과 구현을 위해 노력하는 것입니다.

Quick Quiz 3.10: 좋아요, 우리가 분산 프로그래밍 기법들을 공유 메모리 병렬 프로그램에 적용하려 한다면, 항상 이런 분산 기법들을 사용하고 공유 메모리 없이 살면 안되나요? ■

자, 정리해 보죠:

1. 좋은 소식은 멀티코어 시스템이 저렴하고 어디서든 구할 수 있게 되었다는 겁니다.
2. 더 좋은 소식도 있어요: 많은 동기화 오퍼레이션의 오버헤드는 2000년대 초의 병렬 시스템에서의 그것에 비해 훨씬 낮아졌습니다.
3. 나쁜 소식은 캐시 미스의 오버헤드는, 특히 큰 시스템에서는 여전히 높다는 것입니다.

이 책의 뒷부분에서는 이 나쁜 소식을 처리하는 방법들을 설명합니다.

특히, Chapter 4에서는 병렬 프로그래밍에서 사용되는 일부 로우 레벨 도구들을 다룰 거고, Chapter 5에서는 병렬 카운팅에서의 문제와 해결책을 알아볼겁니다. 그리고 Chapter 6에서는 성능과 확장성을 올릴 수 있는 설계 원칙을 이야기해 봅니다.

Chapter 4

You are only as good as your tools, and your tools are only as good as you are.

Unknown

Tools of the Trade

이 챕터에서는 리눅스와 유사한 운영체제에서 돌아가는 어플리케이션에서 사용할 수 있는 것들에 집중해서 몇몇 기본적인 병렬 프로그래밍 도구를 소개합니다. Section 4.1은 스크립트 언어로 시작을 하고, Section 4.2에서는 POSIX API로 지원되는 멀티 프로세스 병렬성을 설명하고 POSIX 쓰레드를 다뤄보고, Section 4.3은 다른 환경들에서의 비슷한 오퍼레이션들을 선보이며, 마지막으로, Section 4.4에서는 일을 완료하기 위해 어떤 도구를 골라야 할지 선택을 도와드립니다.

Quick Quiz 4.1: 이것들을 도구라고 하셨나요??? 제게 이것들은 도구라기보다는 낮은 단계의 동기화 기능들처럼 보이는데요! ■

이 챕터는 간략한 소개만을 제공한다는 점을 기억해 두세요. 더 자세한 내용은 (특히 인터넷에서) 인용된 참조 목록들에서 볼 수 있으며, 이 도구들을 어떻게 사용하는지 최선인지는 뒤의 챕터들에서 설명합니다.

4.1 Scripting Languages

The supreme excellence is simplicity.

Henry Wadsworth Longfellow, abbreviated

리눅스 셸 스크립트 언어들은 병렬성을 관리하는 간단하지만 효과적인 방법들을 제공합니다. 예를 들어, 당신이 `compute_it`이라는 이름의 프로그램을 가지고 있는데 두개의 다른 인자들로 두번 수행해야 한다고 생각해 봅시다. 이는 UNIX 셸 스크립트를 사용해서 다음과 같이 이뤄질 수 있습니다:

```
1 compute_it 1 > compute_it.1.out &
2 compute_it 2 > compute_it.2.out &
3 wait
4 cat compute_it.1.out
5 cat compute_it.2.out
```

라인 1과 2는 이 프로그램의 인스턴스를 두개 실행시키고, 각 인스턴스의 결과물을 두개의 별개의 파일에




Figure 4.1: Execution Diagram for Parallel Shell Execution

집어넣는데, & 문자는 셸이 그 두 프로그램 인스턴스를 백그라운드에서 실행하도록 합니다. 라인 3은 두개의 인스턴스 모두가 종료되길 기다리고, 라인 4와 5에서는 그들의 결과값을 화면에 출력합니다. 실행 흐름은 Figure 4.1에 나타낸 대로입니다: `compute_it`의 두개의 인스턴스는 병렬적으로 수행되고, `wait`은 두개 인스턴스 모두가 완료된 뒤에 완료되며, 그 뒤에 `cat`의 두개의 인스턴스가 순차적으로 수행됩니다.

Quick Quiz 4.2: 하지만 이 간단한 셸 스크립트는 진짜 병렬 프로그램이 아니잖아요! 왜 이런 별거아닌 걸 신경쓰는거죠??? ■

Quick Quiz 4.3: 병렬 셸 스크립트를 작성하는 좀 더 간단한 방법은 없나요? 만약 있다면, 어떻게 하나요? 없다면, 왜 없죠? ■

다른 예로, 소프트웨어 빌드 스크립트 언어인 `make`는 얼마나 많은 병렬성이 해당 빌드 작업에 주어져야 하는지 결정하는 `-j` 옵션을 제공합니다. 예를 들어, 리눅스 커널을 빌드할 때 `make -j4` 명령을 입력하는 것은 최대 4개의 병렬 컴파일이 동시에 수행될 것을 말합니다.

이런 간단한 예가 당신에게 병렬 프로그래밍이 항상 복잡하거나 어려울 필요는 없음을 납득시켜 주길 바랍니다.

Quick Quiz 4.4: 하지만 스크립트 기반 병렬 프로그래밍이 그렇게 쉽다면, 왜 다른 것들을 신경쓰는거죠?

4.2 POSIX Multiprocessing

A camel is a horse designed by committee.

Unknown

이 섹션에서는 사용 가능하고 널리 구현되어 있는, `pthread` [Ope97]를 포함해 POSIX 환경의 일부분을 알아봅니다. Section 4.2.1에서는 POSIX `fork()` 와 관련된 기능들을 살짝 훑어보고, Section 4.2.2에서는 쓰레드 생성과 소멸에 대해 간단히 알아본 후, Section 4.2.3에서는 POSIX 락킹에 대한 짧은 개요를 제공할 예정이며, 마지막으로, Section 4.2.4에서 여러 쓰레드에 의해 읽히고 가끔만 갱신되는 데이터에 대해 사용되곤 하는 특정한 락에 대해 설명합니다.

4.2.1 POSIX Process Creation and Destruction

프로세스는 `fork()`를 통해 생성되고, `kill()`를 통해 소멸 당할 수도, 스스로 `exit()`를 통해 소멸될 수도 있습니다. `fork()`를 실행하는 프로세스는 새로 생성되는 프로세스의 “부모”라고 불리웁니다. 부모는 `wait()`를 통해 자기 자식들을 기다릴 수도 있습니다.

이 섹션의 예제들은 상당히 간단한 것들이란 점을 기억해 두시기 바랍니다. 이 간단한 도구들을 사용하는 실제 어플리케이션들은 시그널, 파일 디스크립터, 공유된 메모리 조작, 그리고 또 다른 많은 자원들을 제어해야 할 수도 있을 겁니다. 또한, 어떤 어플리케이션은 어떤 자식 프로세스가 종료되었을 때 특별한 행동을 취해야 할 수도 있고, 또한 자식 프로세스가 어떤 이유로 종료되었는지에 대해서도 신경써야 할 수 있습니다. 이렇게 신경써야 하는 부분들은 물론 코드에 상당한 복잡도를 추가할 수 있습니다. 더 많은 내용을 위해서는, 해당 주제에 대한 교재들 [Ste92, Wei13]을 보시기 바랍니다.

`fork()`가 성공하면, `fork()`는 한번은 부모에게, 또 한번은 자식에게 두번 리턴합니다. `fork()`가 리턴하는 값은 Listing 4.1 (`forkjoin.c`)에 보여진 것처럼 호출자가 그 차이를 알 수 있게 합니다. 라인 1은 `fork()` 함수를 실행하고, 그 리턴값을 지역 변수 `pid`에 저장합니다. 라인 2에서는 `pid`가 0인지 체크하는데, 만약 맞다면 자신은 자식 프로세스라는 뜻이며, 이 경우 코드

Listing 4.1: Using the `fork()` Primitive

```

1 pid = fork();
2 if (pid == 0) {
3     /* child */
4 } else if (pid < 0) {
5     /* parent, upon error */
6     perror("fork");
7     exit(EXIT_FAILURE);
8 } else {
9     /* parent, pid == child ID */
10 }
```

Listing 4.2: Using the `wait()` Primitive

```

1 int pid;
2 int status;
3
4 for (;;) {
5     pid = wait(&status);
6     if (pid == -1) {
7         if (errno == ECHILD)
8             break;
9         perror("wait");
10        exit(EXIT_FAILURE);
11    }
12 }
```

실행은 라인 3으로 이어집니다. 앞서 이야기 했듯, 자식 프로세스는 `exit()` 기능을 통해 종료될 수 있습니다. 만약 `fork()` 리턴값이 0이 아니어서 자신이 부모 프로세스라면, 라인 4에서 얻은 `fork()` 리턴값을 가지고 에러가 있었는지 확인하고, 에러가 있었다면 라인 5-7에서 에러를 화면에 출력하고 종료합니다. 그렇지 않고 `fork()`가 성공적으로 수행되었다면, 자식 프로세스의 프로세스 ID 값을 가지고 있는 변수 `pid`와 함께 라인 9로 넘어갑니다.

부모 프로세스는 자식 프로세스가 완료될 때까지 `wait()` 함수를 이용해 기다릴 수도 있습니다. 하지만, 하나의 `wait()` 호출은 오로지 한개의 자식 프로세스만 기다리기 때문에, 이 함수의 사용은 셀 스크립트에서의 같은 이름의 기능을 사용할 때보다 좀 더 복잡합니다. 그래서 Listing 4.2 (`api-pthread.h`)에서 보여진, 셀 스크립트에서의 `wait` 명령과 유사한 의미를 가진, `waitall()` 함수와 비슷한 함수로 `wait()`를 감싸는게 일반적입니다. 라인 4-12에서의 루프의 각 패스에서는 한개 자식 프로세스를 기다립니다. 라인 5에서는 `wait()` 함수를 호출하는데, 이 함수는 자식 프로세스 하나가 종료될 때까지 부모 프로세스를 블록시키고, 자식 프로세스가 종료된 후 자식 프로세스의 프로세스 ID를 리턴합니다. 만약 프로세스 ID가 아니라 -1이 리턴된다면, 이는 `wait()` 함수가 자식 프로세스를 기다릴 수 없었음을 의미합니다. 만약 그렇다면, 라인 7에서 `errno`가 `ECHILD`로 되었는지 여부를 체크하는데, 만약 그렇다면 더이상 자식 프로세스가 존재하지 않는다는 의미로, 이 때엔 라인 8에서 루프를 빠져나옵니다. 그렇지 않다면, 라인 9과 10에서 에러를 출력하고 종

Listing 4.3: Processes Created Via `fork()` Do Not Share Memory

```

1 int x = 0;
2
3 int main(int argc, char *argv[])
4 {
5     int pid;
6
7     pid = fork();
8     if (pid == 0) { /* child */
9         x = 1;
10    printf("Child process sees x=%d\n", x);
11    exit(EXIT_SUCCESS);
12 }
13 if (pid < 0) { /* parent, upon error */
14     perror("fork");
15     exit(EXIT_FAILURE);
16 }
17 /* parent */
18
19 waitall();
20 printf("Parent process sees x=%d\n", x);
21
22 return EXIT_SUCCESS;
23 }
```

료합니다.

Quick Quiz 4.5: 왜 이 `wait()` 함수는 그렇게 복잡해야만 하는거죠? 왜 그냥 셸 스크립트의 `wait` 같이 동작하도록 만들지 않는 거예요? ■

부모와 자식 프로세스가 메모리를 공유하지 않는다는 점은 매우 중요하므로 반드시 기억해야 합니다. 이는 Listing 4.3 (`forkjoinvar.c`)의 프로그램으로 보여지는데, 자식 프로세스는 라인 9에서 전역 변수 `x`를 1로 만들고 라인 10에서 메세지를 프린트한 후, 라인 11에서 종료합니다. 부모는 라인 20에서 실행 흐름을 이어서 자식 프로세스를 기다리고 라인 21에서 변수 `x`의 값을 보지만 여전히 그 값은 0입니다. 따라서 이 프로그램의 출력은 다음과 같습니다:

```
Child process set x=1
Parent process sees x=0
```

Quick Quiz 4.6: 여기서 이야기한 것 외에도 `fork()`와 `wait()`에 대해 이야기할 것들이 많지 않나요? ■

가장 잘게 크리티컬 섹션을 쪼갠 병렬성은 공유 메모리를 필요로 하며, 이는 Section 4.2.2에서 다릅니다. 하지만, 공유 메모리 병렬성은 `fork-join` 병렬성에 비해 상당히 복잡할 수 있습니다.

4.2.2 POSIX Thread Creation and Destruction

프로세스 내에서 쓰레드를 생성하려면 Listing 4.4 (`pcreate.c`)의 라인 16와 17에 보인 것처럼 `pthread_create()` 함수를 호출해야 합니다.

Listing 4.4: Threads Created Via `pthread_create()` Share Memory

```

1 int x = 0;
2
3 void *mythread(void *arg)
4 {
5     x = 1;
6     printf("Child process set x=%d\n", x);
7     return NULL;
8 }
9
10 int main(int argc, char *argv[])
11 {
12     int en;
13     pthread_t tid;
14     void *vp;
15
16     if ((en = pthread_create(&tid, NULL,
17                             mythread, NULL)) != 0) {
18         fprintf(stderr, "pthread_join: %s\n", strerror(en));
19         exit(EXIT_FAILURE);
20     }
21
22     /* parent */
23
24     if ((en = pthread_join(tid, &vp)) != 0) {
25         fprintf(stderr, "pthread_join: %s\n", strerror(en));
26         exit(EXIT_FAILURE);
27     }
28     printf("Parent process sees x=%d\n", x);
29
30     return EXIT_SUCCESS;
31 }
```

`pthread_t` 타입 변수로의 포인터로, 해당 쓰레드의 ID를 저장하게 되며, 예제에서는 `NULL` 값을 준 두번째 인자는 필요하면 추가하게 되는 `pthread_attr_t` 타입 변수로의 포인터이며, 세번째 인자는 새로 생성된 쓰레드에 의해 호출될 함수(이 경우, `mythread()`)이고, 여기선 `NULL`을 준 마지막 인자는 `mythread`에게 전달될 인자입니다.

이 예제에서, `mythread()`는 단순히 리턴하지만, 대신 `pthread_exit()`를 사용할 수도 있습니다.

Quick Quiz 4.7: Listing 4.4의 `mythread()` 함수가 그냥 리턴해도 된다면, 왜 `pthread_exit()`를 신경쓰는 거죠? ■

라인 24에 있는 `pthread_join()` 함수는 `fork-join`에서의 `wait()` 함수와 유사합니다. 이 함수는 `tid` 변수로 명시된 쓰레드가 `pthread_exit()` 함수를 통해서, 또는 쓰레드의 탑 레벨 함수가 리턴을 해서 실행을 완료할 때까지 기다립니다. 쓰레드의 종료 값은 `pthread_join()` 함수에 두번째 인자로 넘겨진 포인터를 통해 저장됩니다. 쓰레드의 종료 값은 쓰레드가 어떻게 종료되었는지에 따라 다른데, `pthread_exit()` 함수에 넘겨진 값이거나 쓰레드의 탑 레벨 함수에서 리턴한 값입니다.

Listing 4.4에 보여진 프로그램은 다음과 같이 결과를 내놓는데, 이는 두 쓰레드 간에 메모리가 공유됨을 보여줍니다:

```
Child process set x=1
Parent process sees x=1
```

이 프로그램은 변수 x에 값을 저장하는 쓰레드가 한번에 하나 뿐일 것을 주의깊게 보장하고 있음을 알아두시기 바랍니다. 한 쓰레드가 어떤 변수에 값을 저장하는 동안 다른 쓰레드가 그 변수의 값을 읽거나 쓰려 하는 상황을 가리켜 “data race(데이터 레이스)”라 합니다. C 언어는 데이터 레이스의 결과에 대해 어떤 보장도 하지 않기 때문에, 우리는 다음 섹션에서 이야기할 락킹 도구들과 같이 데이터에의 동시적 접근과 수정을 안전하게 할 수 있는 방법이 필요합니다.

Quick Quiz 4.8: C 언어가 데이터 레이스에 대해 어떤 보장도 하지 않는다면, 왜 리눅스 커널은 그렇게 많은 데이터 레이스들을 가지고 있는거죠? 지금 리눅스 커널이 완전 영망이라고 이야기 하려는 거예요??? ■

4.2.3 POSIX Locking

POSIX 표준은 프로그래머가 “POSIX 락킹”을 이용해 데이터 레이스 상황을 회피할 수 있게 합니다. POSIX 락킹은 여러개의 기본 기능을 제공하는데, 가장 기본적인 것들은 `pthread_mutex_lock()`과 `pthread_mutex_unlock()`입니다. 이 기본 기능들은 `pthread_mutex_t` 타입인 락에 대해 동작합니다. 이 락들은 정적으로 선언되고 `PTHREAD_MUTEX_INITIALIZER`를 통해 초기화 될 수도, 동적으로 할당된 후 `pthread_mutex_init()`를 통해 초기화 될 수도 있습니다. 이 섹션의 예제 코드는 앞의 경우들을 취할 것입니다.

`pthread_mutex_lock()` 함수는 명시된 락을 “획득”하고, `pthread_mutex_unlock()` 함수는 명시된 락을 “해제”합니다. 이것들은 “배타적” 락킹 함수들이기 때문에, 한 순간에 하나의 쓰레드만이 특정 락을 “가질” 수 있습니다. 예를 들어, 두개의 쓰레드가 같은 락을 동시에 획득하려 하면, 그 중 하나만이 먼저 락을 “얻게” 되고, 다른 쓰레드는 첫번째 쓰레드가 락을 해제할 때까지 기다려야 합니다. 간단하고 합리적 수준으로 유용한 프로그래밍 모델은 특정 데이터 아이템이 연관된 락을 잡고 있을 때에만 접근될 수 있도록 합니다 [Hoa74].

Quick Quiz 4.9: 제가 여러 쓰레드들이 동시에 같은 락을 쥐고 있게 하고 싶으면 어떻게 하죠? ■

Listing 4.5 (`lock.c`)에 명시적 락킹의 사용 예가 있습니다. 라인 1은 `lock_a`라는 이름의 POSIX 락을 정의와 함께 초기화하고, 라인 2에서는 비슷하게 `lock_b`라는 이름의 락을 정의하고 초기화 합니다. 라인 4에서는 공유 변수 `x`를 정의와 함께 초기화 합니다.

라인 6-33은 `arg`로 가리켜진 락을 잡고서 공유 변수 `x`를 반복적으로 읽는 `lock_reader()` 함수를 정의합니다. 라인 12은 `arg`를 `pthread_mutex_lock()`

Listing 4.5: Demonstration of Exclusive Locks

```
1 pthread_mutex_t lock_a = PTHREAD_MUTEX_INITIALIZER;
2 pthread_mutex_t lock_b = PTHREAD_MUTEX_INITIALIZER;
3
4 int x = 0;
5
6 void *lock_reader(void *arg)
7 {
8     int en;
9     int i;
10    int newx = -1;
11    int oldx = -1;
12    pthread_mutex_t *pmlp = (pthread_mutex_t *)arg;
13
14    if ((en = pthread_mutex_lock(pmlp)) != 0) {
15        fprintf(stderr, "lock_reader:pthread_mutex_lock: %s\n",
16                strerror(en));
17        exit(EXIT_FAILURE);
18    }
19    for (i = 0; i < 100; i++) {
20        newx = READ_ONCE(x);
21        if (newx != oldx) {
22            printf("lock_reader(): x = %d\n", newx);
23        }
24        oldx = newx;
25        poll(NULL, 0, 1);
26    }
27    if ((en = pthread_mutex_unlock(pmlp)) != 0) {
28        fprintf(stderr, "lock_reader:pthread_mutex_unlock: %s\n",
29                strerror(en));
30        exit(EXIT_FAILURE);
31    }
32    return NULL;
33 }
34
35 void *lock_writer(void *arg)
36 {
37     int en;
38     int i;
39     pthread_mutex_t *pmlp = (pthread_mutex_t *)arg;
40
41     if ((en = pthread_mutex_lock(pmlp)) != 0) {
42         fprintf(stderr, "lock_writer:pthread_mutex_lock: %s\n",
43                 strerror(en));
44         exit(EXIT_FAILURE);
45    }
46    for (i = 0; i < 3; i++) {
47        WRITE_ONCE(x, READ_ONCE(x) + 1);
48        poll(NULL, 0, 5);
49    }
50    if ((en = pthread_mutex_unlock(pmlp)) != 0) {
51        fprintf(stderr, "lock_writer:pthread_mutex_unlock: %s\n",
52                strerror(en));
53        exit(EXIT_FAILURE);
54    }
55    return NULL;
56 }
```

Listing 4.6: Demonstration of Same Exclusive Lock

```

1 printf("Creating two threads using same lock:\n");
2 en = pthread_create(&tid1, NULL, lock_reader, &lock_a);
3 if (en != 0) {
4     fprintf(stderr, "pthread_create: %s\n", strerror(en));
5     exit(EXIT_FAILURE);
6 }
7 en = pthread_create(&tid2, NULL, lock_writer, &lock_a);
8 if (en != 0) {
9     fprintf(stderr, "pthread_create: %s\n", strerror(en));
10    exit(EXIT_FAILURE);
11 }
12 if ((en = pthread_join(tid1, &vp)) != 0) {
13     fprintf(stderr, "pthread_join: %s\n", strerror(en));
14     exit(EXIT_FAILURE);
15 }
16 if ((en = pthread_join(tid2, &vp)) != 0) {
17     fprintf(stderr, "pthread_join: %s\n", strerror(en));
18     exit(EXIT_FAILURE);
19 }

```

과 `pthread_mutex_unlock()` 함수에 사용하기 위해 `pthread_mutex_t` 포인터로 캐스팅 합니다.

Quick Quiz 4.10: 왜 그냥 Listing 4.5 라인 5에서 `lock_reader()` 가 곧바로 `pthread_mutex_t` 포인터를 받도록 하지 않는거죠? ■

Quick Quiz 4.11: Listing 4.5 의 line 20 의 `READ_ONCE()` 와 line 47 의 `WRITE_ONCE()` 는 뭔가요? ■

라인 14-18 는 명시된 `pthread_mutex_t` 를 획득하고, 에러를 체크한 후 만약 에러가 있었다면 프로그램을 종료합니다. 라인 19-26 은 반복적으로 `x` 의 값을 체크하고, 그 값이 바뀔 때마다 새로운 값을 화면에 출력합니다. 라인 25 는 이 예제가 싱글 프로세서 머신에서도 잘 돌아 가도록 1 밀리세컨드씩 잠을 잡습니다. 라인 27-31 에서는 `pthread_mutex_t` 를 해제하고, 다시 에러를 체크한 후 에러가 났다면 프로그램을 종료합니다. 마지막으로, 라인 32 에서는 `pthread_create()` 에서 요구된 함수 타입을 맞춰주기 위해 `NULL` 을 리턴합니다.

Quick Quiz 4.12: `pthread_mutex_t` 의 획득과 해제에 매번 4줄이나 써야한다니 좀 고통스러울 것 같군요! 더 나은 방법은 없나요? ■

Listing 4.5 의 라인 35-56 는 주기적으로 명시된 `pthread_mutex_t` 를 잡고서 공유 변수 `x` 를 업데이트 하는 `lock_writer()` 함수를 보여줍니다. `lock_reader()` 에서처럼 라인 39 에서는 `arg` 를 `pthread_mutex_t` 포인터로 캐스팅하고 라인 41-45 에서 해당 락을 얻어오고, 라인 50-54 에서 락을 놓아줍니다. 락을 잡고 있는 동안, 라인 46-49 에서는 5 밀리세컨드 씩 자면서 공유 변수 `x` 를 자면서 증가시킵니다. 마지막으로 라인 50-54 에서는 락을 놓아줍니다.

Listing 4.6 는 같은 락인 `lock_a` 사용하도록 하면서 `lock_reader()` 와 `lock_writer()` 를 쓰레드로 실행시키는 코드를 보여줍니다. 라인 2-6 은 `lock_reader()` 를 실행하는 쓰레드를 생성하고, 라인 7-11 에서는 `lock_writer()` 를 실행하는 쓰레드를 생성합

Listing 4.7: Demonstration of Different Exclusive Locks

```

1 printf("Creating two threads w/different locks:\n");
2 x = 0;
3 en = pthread_create(&tid1, NULL, lock_reader, &lock_a);
4 if (en != 0) {
5     fprintf(stderr, "pthread_create: %s\n", strerror(en));
6     exit(EXIT_FAILURE);
7 }
8 en = pthread_create(&tid2, NULL, lock_writer, &lock_b);
9 if (en != 0) {
10     fprintf(stderr, "pthread_create: %s\n", strerror(en));
11     exit(EXIT_FAILURE);
12 }
13 if ((en = pthread_join(tid1, &vp)) != 0) {
14     fprintf(stderr, "pthread_join: %s\n", strerror(en));
15     exit(EXIT_FAILURE);
16 }
17 if ((en = pthread_join(tid2, &vp)) != 0) {
18     fprintf(stderr, "pthread_join: %s\n", strerror(en));
19     exit(EXIT_FAILURE);
20 }

```

니다. 라인 12-19 에서는 두 쓰레드가 완료되기를 기다립니다. 이 코드가 내놓는 결과는 다음과 같습니다:

Creating two threads using same lock:
`lock_reader(): x = 0`

두 쓰레드가 모두 같은 락을 사용하기 때문에, `lock_reader()` 쓰레드는 `lock_writer()` 가 락을 잡고서 만들어내는 `x` 의 중간 값들을 볼 수 없습니다.

Quick Quiz 4.13: “`x=0`” 만이 Listing 4.6 의 코드에서 발생 가능한 오로지 하나의 결과인가요? 만약 그렇다면, 왜죠? 아니라면, 어떤 다른 결과가 가능할까요, 그리고 왜일까요? ■

Listing 4.7 에서 비슷한, 하지만 이번엔 다른 락을 사용하는 코드를 보여줍니다: `lock_reader()` 를 위해선 `lock_a` 를, `lock_writer()` 를 위해선 `lock_b` 를 사용합니다. 이 코드의 수행 결과는 다음과 같습니다:

Creating two threads w/different locks:
`lock_reader(): x = 0`
`lock_reader(): x = 1`
`lock_reader(): x = 2`
`lock_reader(): x = 3`

두 쓰레드가 다른 락을 사용하기 때문에, 서로를 배제하지 않고, 동시에 수행됩니다. 그래서 `lock_reader()` 함수는 `lock_writer()` 가 저장한 `x` 중간값을 볼 수 있습니다.

Quick Quiz 4.14: 서로 다른 락을 사용하는건 쓰레드가 서로 상대의 중간 상태를 볼 수 있는등 혼란스럽게 할 수 있는 것같은데요. 잘 짜여진 병렬 프로그램은 이런 혼란을 막기 위해서는 하나의 락만을 사용해야만 하는 건가요? ■

Quick Quiz 4.15: Listing 4.7 에 보여진 코드에서, `lock_reader()` 는 `lock_writer()` 가 생성하는 값 모

두를 보도록 보장되어 있나요? 그렇다면, 또 그렇지 않다면, 왜죠? ■

Quick Quiz 4.16: 잠깐만요!!! Listing 4.6에서는 공유 변수 `x`를 초기화 하지 않았는데, Listing 4.7에서는 왜 초기화 해야 했던거죠? ■

이외에도 POSIX 배타적 락킹이 몇가지 더 있지만, 여기 소개한 것만으로도 좋은 시작이 될 수 있고, 많은 상황에는 이것만으로도 충분할 겁니다. 다음 섹션에서는 POSIX 리더-라이터 락킹에 대해 간략히 알아봅니다.

4.2.4 POSIX Reader-Writer Locking

POSIX API 는 `pthread_rwlock_t` 로 대표되는, 리더-라이터 락을 제공합니다. `pthread_mutex_t` 처럼, `pthread_rwlock_t` 는 `PTHREAD_RWLOCK_INITIALIZER` 를 사용해 정적으로 초기화 될 수도, `pthread_rwlock_init()` 함수를 이용해 동적으로 초기화 될 수도 있습니다. `pthread_rwlock_rdlock()` 함수는 특정 `pthread_rwlock_t` 의 읽기 권한 락을 얻어오고, `pthread_rwlock_wrlock()` 함수는 쓰기 권한 락을 얻어오며, `pthread_rwlock_unlock()` 함수는 락을 놓습니다. `pthread_rwlock_t` 의 쓰기 권한 락은 항상 하나의 쓰레드만이 획득 가능하며, 읽기 권한 락은 여러 쓰레드가 동시에 가질 수 있습니다만, 동시에 쓰기 권한을 줄 쓰레드가 없는 경우에 국한됩니다.

예상했겠지만, 리더-라이터 락은 읽기 작업이 대부분인 경우를 위해 설계되었습니다. 이런 상황에서, 리더-라이터 락은 배타적 락에 비해 훨씬 나은 확장성을 제공할 수 있는데, 배타적 락은 그 정의에 의해 한번에 락을 잡을 수 있는 쓰레드의 수가 하나로 제한되는데 반해 리더-라이터 락은 임의의 많은 수의 읽기 작업 하는 쓰레드가 동시에 락을 잡을 수 있기 때문입니다. 하지만, 실제로 리더-라이터 락이 얼마나 추가적인 확장성을 제공하는지 알 필요가 있습니다.

Listing 4.8 (`rwllockscale.c`) 는 리더-라이터 락의 확장성을 측정하는 한가지 방법을 보여줍니다. 라인 1 은 리더-라이터 락의 정의와 초기화를 보이고, 라인 2에서는 각 쓰레드가 해당 리더-라이터 락을 잡는 시간을 조절하는 `holdtime` 인자를 보여주며, 라인 3에서는 리더-라이터 락의 해제와 다음 획득 사이의 시간을 조절하는 `thinktime` 인자를 보여주고, 라인 4에서는 각 리더 쓰레드가 자신이 락을 획득한 횟수를 저장하는 `readcounts` 배열을 정의하며, 라인 5에서는 언제 모든 리더 쓰레드들이 수행을 시작했는지 알려주는 `nreadersrunning` 변수를 정의합니다.

라인 7-10 은 테스트의 시작과 끝을 동기화 시키는 `goflag`를 정의합니다. 이 변수는 처음엔 `GOFLAG_INIT` 로 설정되어 있고, 이후에 모든 리더 쓰레드들이 시작된 후에 `GOFLAG_RUN` 으로 변경된 후, 마지막으로 테스트

Listing 4.8: Measuring Reader-Writer Lock Scalability

```

1 pthread_rwlock_t rwl = PTHREAD_RWLOCK_INITIALIZER;
2 int holdtime = 0;
3 int thinktime = 0;
4 long long *readcounts;
5 int nreadersrunning = 0;
6
7 #define GOFLAG_INIT 0
8 #define GOFLAG_RUN 1
9 #define GOFLAG_STOP 2
10 char goflag = GOFLAG_INIT;
11
12 void *reader(void *arg)
13 {
14     int en;
15     int i;
16     long long loopcnt = 0;
17     long me = (long)arg;
18
19     __sync_fetch_and_add(&nreadersrunning, 1);
20     while (READ_ONCE(goflag) == GOFLAG_INIT) {
21         continue;
22     }
23     while (READ_ONCE(goflag) == GOFLAG_RUN) {
24         if ((en = pthread_rwlock_rdlock(&rwl)) != 0) {
25             fprintf(stderr,
26                     "pthread_rwlock_rdlock: %s\n", strerror(en));
27             exit(EXIT_FAILURE);
28         }
29         for (i = 1; i < holdtime; i++) {
30             barrier();
31         }
32         if ((en = pthread_rwlock_unlock(&rwl)) != 0) {
33             fprintf(stderr,
34                     "pthread_rwlock_unlock: %s\n", strerror(en));
35             exit(EXIT_FAILURE);
36         }
37         for (i = 1; i < thinktime; i++) {
38             barrier();
39         }
40         loopcnt++;
41     }
42     readcounts[me] = loopcnt;
43     return NULL;
44 }
```

를 종료시키기 위해 `GOFLAG_STOP` 으로 값을 바꿉니다.

라인 12-44 은 리더 쓰레드인 `reader()` 함수를 정의 합니다. 라인 19 은 이 쓰레드가 이제 수행됨을 알리기 위해 `nreadersrunning` 변수의 값을 어토믹하게 증가시키고, 라인 20-22 은 테스트가 시작되길 기다립니다. `READ_ONCE()` 함수는 컴파일러가 루프의 매 수행마다 `goflag` 를 실제로 읽어오도록 합니다—그러지 않으면 컴파일러는 `goflag` 의 값이 영영 변하지 않을 거라고 가정하고 동작하는 권리를 행사할 수도 있습니다.

Quick Quiz 4.17: 여기 저기 모든 곳에서 `READ_ONCE()` 를 쓰는 대신에, Listing 4.8 의 line 10에서 `goflag` 를 `volatile` 로 선언하는게 어때요? ■

Quick Quiz 4.18: `READ_ONCE()` 는 컴파일러에만 영향을 주지, CPU 에는 영향을 안주죠. Listing 4.8 의 `goflag` 의 값의 변화가 시간 순서대로 다른 CPU 에게도 전파되게 하려면 메모리 배리어도 쳐야 하지 않나요?




Figure 4.2: Reader-Writer Lock Scalability

Quick Quiz 4.19: 예를 들어 GCC의 `__thread` 스토리지 클래스를 사용해 선언된 쓰레드별 변수에 접근할 때에도 `READ_ONCE()` 가 필요할까요? ■

루프가 선언된 라인 23-41은 성능 테스트를 합니다. 라인 24-28은 락을 얻어오고, 라인 29-31는 정해진 시간 동안 락을 쥐고 있고(그리고 `barrier()` 지시어를 통해 컴파일러가 루프를 없애는 것을 막습니다), 라인 32-36에서 락을 풀어주고, 라인 37-39에서 락을 다시 얻어오기 전에 특정 시간동안 기다립니다. 라인 40은 이 락 획득 횟수를 셉니다.

라인 42에서는 해당 락 획득 횟수를 `readcounts` [] 배열에서 해당 쓰레드에 할당된 원소에 저장하고, 라인 43에서는 리턴해서 쓰레드를 종료합니다.

Figure 4.2에서는 테스트를 코어당 2개 하드웨어 쓰레드를 지원해 소프트웨어에는 총 128개의 CPU가 존재하는 것으로 보이는 64-코어 POWER5 시스템에서 돌린 결과입니다. `thinktime` 패러미터는 모든 테스트에서 0이었고, `holdtime`은 1000(그림에서는 “1K”로 표시되었습니다)부터 1억(그림에선 “100M”으로 표시됩니다)까지 값을 변화시켰습니다. 그림으로 그려진 실제 값은 다음과 같습니다:

$$\frac{L_N}{NL_1} \quad (4.1)$$

여기서 N 은 쓰레드의 갯수이고, L_N 은 N 쓰레드들의 락 획득 횟수, 그리고 L_1 은 쓰레드 하나만 썼을 때의 락 획득 횟수입니다. 이상적인 하드웨어와 소프트웨어 확장성이 주어졌다면, 이 값은 항상 1.0이 될 것입니다.

그림에서 보여지듯이, 리더-라이터 락킹의 확장성은 이상적이진 않고, 특히 작은 크기의 크리티컬 섹션에서 더 그렇습니다. 왜 읽기 권한 락 획득이 그렇게 느린지 알아보려면, 모든 락 획득을 원하는 쓰레드들이 `pthread_rwlock_t` 데이터를 수정해야 함을 상기해 보십시오. 따라서, 모든 128개의 수행되는 쓰레드들이 리더-라이터 락으로부터 동시에 읽기 권한 락 획득을 하려 하면, 그 쓰레드들은 `pthread_rwlock_t`를 한번씩 반드시 수정해야만 합니다. 운좋은 쓰레드는 곧바로 그렇게 할 수 있을테지만, 가장 불행한 쓰레드는 다른 127개의 쓰레드들이 수정을 완료할 때까지 기다려야 합니다. 이 상황은 CPU를 추가할수록 나빠지기만 할 겁니다.

Quick Quiz 4.20: 단일 CPU 성능에 비교하는 건 좀 심한 거 아닌가요? ■

Quick Quiz 4.21: 하지만 1,000 개의 인스트럭션은 크리티컬 섹션 치고 그렇게 작은 크기는 아니예요. 수십 개의 인스트럭션 정도만을 가지는 훨씬 작은 크리티컬 섹션이 필요하면 어떻게 해야하죠? ■

Quick Quiz 4.22: Figure 4.2에서 100M에서의 경우 이외의 값들은 이상적인 선에서 부드럽게 멀어집니다. 반면, 100M에서의 값은 64 CPU에서 갑자기 이상적인 선으로부터 멀어지는군요. 또, 100M 값과 10M 값 사이의 거리는 10M 값과 1M 값 사이의 거리보다 작아요. 왜 100M 값은 이렇게 남들과 다른거죠? ■

Quick Quiz 4.23: POWER5는 나온지 몇년이 넘었고, 최신 하드웨어는 분명 더 빠를 거예요. 그런데 왜 리더-라이터 락의 느린 속도에 걱정해야 하죠? ■

이런 한계점에도 불구하고, 리더-라이터 락킹은 많은 경우, 예를 들어 리더들이 대기시간이 긴 파일이나 네트워크 I/O를 해야만 경우 등에 매우 유용합니다. 다른 대안들도 있는데, 그런 것들 중 일부는 Chapter 5와 Chapter 9에서 다루겠습니다.

4.2.5 Atomic Operations (GCC Classic)

Figure 4.2가 리더-라이터 락킹의 오버헤드는 크리티컬 섹션이 작을수록 커진다는 것을 보여줬으니, 매우 작은 크리티컬 섹션을 보호할 다른 나은 방안을 찾아봐야 하겠습니다. 그런 한가지 방안은 어토믹 오퍼레이션의 사용입니다. 우린 Listing 4.8의 라인 18에서 `__sync_fetch_and_add()`를 통해 어토믹 오퍼레이션 중 하나를 본 바 있습니다. 이 기능은 첫번째 인자로 참조된 값에 두번째 인자로 주어진 값을 어토믹하게 더하고, 예전 값(이 경우엔 그냥 무시되었었죠)을 리턴합니다. 두개의 쓰레드가 같은 변수에 대해 동시에 `__sync_fetch_and_add()`를 실행하면 변수의 값은 두 더하기 연산이 모두 수행된 값이 됩니다.

GNU C 컴파일러는 이외에도 아래와 같이 추가적인 어토믹 오퍼레이션들을 제공하는데, `__sync_`

`fetch_and_sub()`, `__sync_fetch_and_or()`, `__sync_fetch_and_and()`, `__sync_fetch_and_xor()`, 그리고 `__sync_fetch_and_nand()`는 기존 값을 리턴합니다. 기존 값이 아니라 새롭게 바뀐 값이 필요하다면, `__sync_add_and_fetch()`, `__sync_sub_and_fetch()`, `__sync_or_and_fetch()`, `__sync_and_and_fetch()`, `__sync_xor_and_fetch()`, 그리고 `__sync_nand_and_fetch()`를 사용할 수 있습니다.

Quick Quiz 4.24: 정말로 이것들이 다 필요한 거 맞나요? ■

고전적인 `compare-and-swap` 오퍼레이션은 `__sync_bool_compare_and_swap()`과 `__sync_val_compare_and_swap()` 두개의 함수로 제공됩니다. 두 함수 모두 변수의 현재 값이 제시한 값과 같을 경우 어토믹하게 새로운 값으로 변경해 줍니다. 첫번째 함수는 오퍼레이션이 성공하면 1을, 그리고 실패하면 (예를 들어, 기존 값이 제시한 값과 같지 않은 경우) 0을 리턴합니다. 두번째 함수는 기존 값을 리턴합니다. 따라서 리턴받은 값이 제시했던 기존값과 같다면 오퍼레이션이 성공했음을 의미합니다. 앞의 오퍼레이션들이 적용 가능한 영역에선 대부분 `compare-and-swap` 보다 더 효율적이지만 하나의 변수에 대한 어떤 어토믹 오퍼레이션도 `compare-and-swap`을 사용해서 구현 가능하기 때문에, `compare-and-swap` 오퍼레이션은 “보편적”이라 할 수 있습니다. 뿐만 아니라 `compare-and-swap` 오퍼레이션은 더 넓은 어토믹 오퍼레이션 집합의 토대 역할을 할 수도 있습니다. 그렇게 만들어진 것들은 보통 복잡도, 확장성, 성능 문제 [Her90]를 겪지만요.

Quick Quiz 4.25: 이 어토믹 오퍼레이션들이 인스트럭션 집합에서 곧바로 지원하는 인스트럭션들을 만들 어낼 수 있다면, 그게 바로 동작하는 가장 빠른 방법 아닐까요? ■

`__sync_synchronize()` 함수는 Chapter 15에서 이야기 되는대로, 컴파일러와 CPU의 오퍼레이션 재배치 기능을 제한하는 “메모리 배리어”를 발생시킵니다. 어떤 경우에는 CPU의 재배치 가능성은 두고 컴파일러의 오퍼레이션 재배치를 제한하는 것만으로도 충분한데, 이 경우에는 Listing 4.8의 라인 28에서처럼 `barrier()` 기능이 사용될 수 있을 겁니다. 어떤 경우에는 컴파일러가 주어진 메모리 접근의 최적화를 하는 것을 막는 것만으로도 충분한 경우가 있을 수 있는데, 이 경우에는 Listing 4.5의 라인 17에서처럼 `READ_ONCE()` 함수가 사용될 수 있을 겁니다. 비슷하게, 컴파일러가 특정 메모리로의 쓰기를 최적화해 버리는 것을 막기 위해 `WRITE_ONCE()` 기능이 사용될 수 있습니다. 이 마지막 세개의 함수들은 GCC에 의해 제공되지는 않습니다만, Listing 4.9에 보인 것처럼 단순하게 구현될 수도 있고, 이 세가지 모두 Section 4.3.4에서 어느정도 써 이야기 됩니다.

Listing 4.9: Compiler Barrier Primitive (for GCC)

```
#define ACCESS_ONCE(x) (*(volatile typeof(x) *)&(x))
#define READ_ONCE(x) \
  ({ typeof(x) __x = ACCESS_ONCE(x); __x; })
#define WRITE_ONCE(x, val) ({ ACCESS_ONCE(x) = (val); })
#define barrier() __asm__ __volatile__ ("": : : "memory")
```

Quick Quiz 4.26: `ACCESS_ONCE()`에 무슨 일이 벌어진거죠? ■

4.2.6 Atomic Operations (C11)

C11 표준은 어토믹 오퍼레이션들을 추가했는데, 이는 로드 (`atomic_load()`), 스토어 (`atomic_store()`), 메모리 배리어 (`atomic_thread_fence()` 와 `atomic_signal_fence()`), 그리고 read-modify-write 어토믹 오퍼레이션들을 포함합니다. Read-modify-write 어토믹 오퍼레이션들은 `atomic_fetch_add()`, `atomic_fetch_sub()`, `atomic_fetch_and()`, `atomic_fetch_xor()`, `atomic_exchange()`, `atomic_compare_exchange_strong()`, 그리고 `atomic_compare_exchange_weak()`를 포함합니다. 이것들은 Section 4.2.5에서 설명한 것들과 비슷한 방식으로 동작합니다만 모든 오퍼레이션의 `_explicit` 변종들은 메모리 순서 인자를 추가로 받습니다. 메모리 순서 인자 없이는, 모든 어토믹 오퍼레이션들은 완전히 순서를 맞추고, 인자가 주어진다면 완화된 순서규칙을 허용합니다. 예를 들어, “`atomic_load_explicit(&a, memory_order_relaxed)`”는 리눅스 커널의 “`READ_ONCE()`”와 대략적으로 유사합니다.¹

C11 어토믹 오퍼레이션들의 한가지 한계점은 특수한 어토믹 타입들에만 적용된다는 것으로, 문제가 될 수 있습니다. 따라서 GNU C 컴파일러는 `__atomic_load()`, `__atomic_load_n()`, `__atomic_store()`, `__atomic_store_n()` 등을 제공합니다. 이런 기능들은 C11에서 대응되는 것들과 동일한 semantic을 제공합니다만, atomic 타입이 아닌 평범한 객체에 대해서도 사용될 수도 있습니다. 이 기능들 중 일부는 이 목록의 메모리 순서 인자를 받을 수도 있습니다: `__ATOMIC_RELAXED`, `__ATOMIC_CONSUME`, `__ATOMIC_ACQUIRE`, `__ATOMIC_RELEASE`, `__ATOMIC_ACQ_REL`, and `__ATOMIC_SEQ_CST`.

4.2.7 Per-Thread Variables

Thread-specific 데이터, thread-local storage, 그리고 그 외의 다른 이름으로도 불리는 per-thread 변수는 Chapter 5

¹ 메모리 순서 규칙은 Chapter 15와 Appendix C에서 더 자세히 설명됩니다.

와 8에서 알아보겠지만, 동시성 코드에서 매우 많이 사용됩니다. POSIX는 하나의 per-thread 변수를 만들기 위해(그리고 연관된 키를 리턴받기 위해) `pthrad_key_create()` 함수를, 해당 키에 연관된 해당 per-thread 변수를 삭제하기 위해 `pthread_key_delete()`를, 현재 쓰레드의 특정 키에 연관된 변수에 값을 지정하기 위해 `pthread_setspecific()`을, 그리고 그 값을 받기 위해 `pthread_getspecific()`을 제공합니다.

여러개의(GCC를 포함한) 컴파일러들이 변수를 per-thread로 지정하기 위해 변수의 정의에 사용될 수 있는 `__thread` 지시어를 제공합니다. 그렇게 지정되면 해당 변수의 이름은 현재 쓰레드의 해당 변수의 인스턴스에 접근하기 위해 평범하게 사용될 수 있습니다. 물론, `__thread`는 POSIX thread-specific data 보다 사용하기가 쉽고, `__thread`는 GCC나 `__thread`를 지원하는 컴파일러에서만 빌드될 코드에서는 일반적으로 더 선호됩니다.

다행히도, C11 표준은 `__thread` 대신 사용될 수 있는 `Thread_local` 키워드를 새로 도입했습니다. 시간이 충분히 지나면, 이 새로운 키워드는 `__thread`의 간편한 사용성과 POSIX thread-specific data의 호환성을 결합해낼 겁니다.

4.3 Alternatives to POSIX Operations

The strategic marketing paradigm of Open Source is a massively parallel drunkard's walk filtered by a Darwinistic process.

Bruce Perens

불행히도, 쓰레딩 오퍼레이션들, 락킹 기능들, 그리고 어토믹 오퍼레이션들은 다양한 표준 위원회가 그것들을 표준화하기 전부터 매우 많이 사용되었습니다. 그 결과, 이 오퍼레이션들이 지원되는 방법에 상당한 다양성이 있습니다. 역사적 이유로든 특정 환경에서 더 나은 성능을 얻기 위해서든, 어셈블리 언어로 구현된 오퍼레이션들도 여전히 많습니다. 예를 들어, GCC의 `__sync_` 류 기능들은 완전한 메모리 순서 의미를 제공해서 많은 개발자들이 메모리 순서 의미가 요구되지 않는 상황을 위한 각자의 구현을 만들도록 이끈 바 있습니다. 다음 섹션들은 리눅스 커널에서의 일부 대안들과 이 책의 예제 코드에서 사용된 역사적 기능들 일부를 보입니다.

4.3.1 Organization and Initialization

많은 환경들이 특수한 초기화 코드를 필요로 하지 않지만, 이 책의 샘플 코드는 `pthread_t`로부터 연속적

Listing 4.10: Thread API

```
int smp_thread_id(void)
thread_id_t create_thread(void *(*func)(void *), void *arg)
for_each_thread(t)
for_each_running_thread(t)
void *wait_thread(thread_id_t tid)
void wait_all_threads(void)
```

인 정수들 사이의 매핑을 초기화하는 `smp_init()` 함수의 호출로 시작합니다. Userspace RCU 라이브러리는 비슷하게 `rcu_init()` 호출을 필요로 합니다. 이런 함수 호출들은 생성자를 지원하는(GCC와 같은) 환경에서는 숨겨질 수 있긴 하지만, userspace RCU 라이브러리에 의해 지원되는 대부분의 RCU 버전들은 각 쓰레드가 쓰레드 생성 직후 `rcu_register_thread()`를, 그리고 쓰레드 종료 전에 `rcu_unregister_thread()`를 호출할 것을 필요로 합니다.

리눅스 커널의 경우, 커널이 특수한 초기화 코드로의 호출을 필요로 하는지 여부나 커널의 부팅 시점 코드가 실제로는 필요시되는 초기화 코드인가 여부와 같은 것들은 철학적인 질문입니다.

4.3.2 Thread Creation, Destruction, and Control

리눅스 커널은 kthread들의 정보를 관리하는데에 `struct task_struct` 포인터를, 그것들을 생성하는데 `kthread_create()`를, 그것들이 멈출 것을 외부로 제안하는데에(POSIX에는 똑같은 일을 하는 게 없습니다) `kthread_should_stop()`을, 그것들이 멈추길 기다리는데에 `kthread_stop()`을, 그리고 지정된 시간동안의 대기를 위해서 `schedule_timeout_interruptible()`을 사용합니다. 몇가지 더 kthread 관리 API들이 있습니다만, 이것만으로도 괜찮은 시작점과 검색어 키워드가 됩니다.

CodeSamples API는 “thread”에 집중하는데, 이는 제어를 위한 하나의 위치입니다.² 그런 쓰레드 각각은 `thread_id_t` 타입의 식별자를 가지고, 동시에 수행중인 어떤 두 쓰레드도 같은 식별자를 갖지는 않습니다. 쓰레드들은 `program counter`와 `stack`을 포함하는 쓰레드별 지역적 상태³를 제외하고는 어떤 것도 공유하지 않습니다.

이 쓰레드 API는 Listing 4.10에 보여져 있으며, 이것을 각각은 뒤의 섹션들에서 설명됩니다.

² 비슷한 소프트웨어 구성물을 위한 많은 다른 이름들이 있는데, “process”, “task”, “fiber”, “event”, 등등이 있습니다. 이것들 모두에 비슷한 설계 철학이 적용됩니다.

³ 순환정의에서는 이게 어떻게 될까요?

4.3.2.1 `create_thread()`

`create_thread()` 기능은 새로운 쓰레드를 생성하고, `create_thread()`의 첫번째 인자로 명시된 `func` 함수에서부터 이 새로운 쓰레드의 수행을 시작하는데, 이때 `create_thread()`의 두번째 인자로 명시된 인자를 넘겨줍니다. 이렇게 새로 생성된 쓰레드는 `func`로 명시된 함수가 리턴할 때에 종료됩니다. `create_thread()` 기능은 새로 생성된 자식 쓰레드에 연관된 `thread_id_t`를 리턴합니다.

이 기능은 프로그램의 수행동안 생성된 쓰레드의 갯수를 내부적으로 세다가, 만약 `NR_THREADS` 보다 많은 쓰레드가 생성되면 프로그램을 종료시킵니다. `NR_THREADS`는 컴파일 시점에서 지정되는 상수로, 그 값은 수정될 수도 있지만 일부 시스템에서는 허용 가능한 쓰레드의 수에 최대값이 정해져 있을 수 있습니다.

4.3.2.2 `smp_thread_id()`

`create_thread()`로부터 리턴받는 `thread_id_t`는 시스템에 종속적이므로, `smp_thread_id()` 기능은 요청받은 쓰레드에 연관된 쓰레드 인덱스를 리턴합니다. 이 인덱스는 프로그램이 시작한 아래로 존재한 쓰레드의 최대 숫자보다 작을 것이 보장되어지고, 따라서 bitmask, 배열 인덱스, 등등에 유용합니다.

4.3.2.3 `for_each_thread()`

`for_each_thread()` 매크로는 생성되면 존재하게 될 모든 쓰레드들을 포함해서 모든 존재하는 쓰레드들을 루프합니다. 이 매크로는 Section 4.2.7에서 보게 될 per-thread 변수들을 다루는데에 유용합니다.

4.3.2.4 `for_each_running_thread()`

`for_each_running_thread()` 매크로는 현재 존재하는 쓰레드들만을 루프합니다. 필요할 경우 쓰레드 생성과 삭제에 동기화를 하는 것은 호출자의 역할입니다.

4.3.2.5 `wait_thread()`

`wait_thread()` 기능은 거기 넘겨주는 `thread_id_t`로 명시되는 쓰레드의 완료를 기다립니다. 이 기능은 명시된 쓰레드의 수행에 어떠한 간섭도 끼치지 않습니다; 그저, 그것을 기다릴 뿐입니다. `wait_thread()`는 연관된 쓰레드로부터 리턴된 값을 리턴함을 알아두세요.

4.3.2.6 `wait_all_threads()`

`wait_all_threads()` 기능은 현재 수행중인 모든 쓰레드의 완료를 기다립니다. 필요하다면 쓰레드 생성, 소

Listing 4.11: Example Child Thread

```

1 void *thread_test(void *arg)
2 {
3     int myarg = (intptr_t)arg;
4
5     printf("child thread %d: smp_thread_id() = %d\n",
6            myarg, smp_thread_id());
7     return NULL;
8 }
```

멸과 동기화를 맞추는건 호출자의 역할입니다. 하지만, 이 기능은 일반적으로 프로그램 수행 종료 시에 정리를 하는데에 사용되므로, 그런 동기화는 보통은 필요하지 않습니다.

4.3.2.7 Example Usage

Listing 4.11 (`threadcreate.c`)는 `hello-world` 같은 자식 쓰레드의 예제를 보입니다. 앞서서 이야기 되었듯, 각각의 쓰레드는 자신의 스택을 할당받고, 따라서 각각의 쓰레드는 자신만의 `arg` 인자와 `myarg` 변수를 갖습니다. 각각의 자식은 단순히 각자의 인자와 각자의 `smp_thread_id()`를 종료되기 전에 출력합니다. 라인 7의 `return` 문은 쓰레드를 종료시키고, 누구든 이 쓰레드에 대해 `wait_thread()`를 호출한 쪽에 `NULL`을 리턴함을 알아두시기 바랍니다.

그 부모 프로그램이 Listing 4.12에 보여져 있습니다. 이 프로그램은 line 6에서 쓰레드 시스템을 초기화 하기 위해 `smp_init()`를 호출하고, line 8-15에서 인자들을 분석한 후, line 16에서 자신의 존재를 공지합니다. 이 프로그램은 이어서 지정된 수의 자식 쓰레드들을 line 18-19에서 생성하고, 그것들이 완료되기를 line 21에서 기다립니다. `wait_all_threads()`는 여기선 그 값이 `NULL`로써 큰 의미가 없는, 쓰레드들이 리턴하는 값들을 무시함을 알아두시기 바랍니다.

Quick Quiz 4.27: 리눅스 커널의 `fork()` 와 `wait()` 대체물은 어디갔죠? ■

4.3.3 Locking

리눅스 커널의 락킹 API 가운데 처음 알아보기 시작하는데 좋은 부분집합들이 Listing 4.13에 보여져 있는데, 각각의 API 원소는 다음 섹션들에서 설명됩니다. 이 책의 CodeSamples 락킹 API는 리눅스 커널의 그것을 거의 유사하게 따라갑니다.

4.3.3.1 `spin_lock_init()`

`spin_lock_init()` 기능은 명시된 `spinlock_t` 변수를 초기화하며, 이 변수가 다른 spinlock 기능들에 전달되기 전에 반드시 호출되어야 합니다.

Listing 4.12: Example Parent Thread

```

1 int main(int argc, char *argv[])
2 {
3     int i;
4     int nkids = 1;
5
6     smp_init();
7
8     if (argc > 1) {
9         nkids = strtoul(argv[1], NULL, 0);
10    if (nkids > NR_THREADS) {
11        fprintf(stderr, "nkids = %d too large, max = %d\n",
12            nkids, NR_THREADS);
13        usage(argv[0]);
14    }
15 }
16 printf("Parent thread spawning %d threads.\n", nkids);
17
18 for (i = 0; i < nkids; i++)
19     create_thread(thread_test, (void *)(intptr_t)i);
20
21 wait_all_threads();
22
23 printf("All spawned threads completed.\n");
24
25 exit(0);
26 }
```

Listing 4.13: Locking API

```

void spin_lock_init(spinlock_t *sp);
void spin_lock(spinlock_t *sp);
int spin_trylock(spinlock_t *sp);
void spin_unlock(spinlock_t *sp);
```

4.3.3.2 spin_lock()

`spin_lock()` 기능은 필요하다면 해당 스핀락이 획득 가능해질 때까지 기다리고 명시된 스핀락을 획득합니다. Pthread 와 같은 일부 환경에서 이 기다림은 “spinning” 을 포함할 수도 있는 반면에, 리눅스 커널과 같은 다른 경우에는 blocking 을 포함합니다.

여기서의 핵심은, 언제든 하나의 스핀락은 하나의 쓰레드만이 잡을 수 있다는 것입니다.

4.3.3.3 spin_trylock()

`spin_trylock()` 기능은 곧바로 스핀락을 획득할 수 있을 때에만 명시된 스핀락을 획득합니다. 스핀락을 획득 할 수 있었다면 `true` 를 리턴하고 그렇지 않다면 `false` 를 리턴합니다.

4.3.3.4 spin_unlock()

`spin_unlock()` 기능은 명시된 스핀락을 놓아주어서 다른 쓰레드들이 해당 스핀락을 획득할 수 있도록 해줍니다.

Listing 4.14: Living Dangerously Early 1990s Style

```

1 ptr = global_ptr;
2 if (ptr != NULL && ptr < high_address)
3     do_low(ptr);
```

Listing 4.15: C Compilers Can Invent Loads

```

1 if (global_ptr != NULL &&
2     global_ptr < high_address)
3     do_low(global_ptr);
```

4.3.3.5 Example Usage

변수 `counter` 를 보호하는데에 `mutex` 라는 이름의 스핀락을 다음과 같이 사용할 수 있습니다:

```

spin_lock(&mutex);
counter++;
spin_unlock(&mutex);
```

Quick Quiz 4.28: 변수 `counter` 의 값이 `mutex` 의 보호 없이 증가된다면 어떤 문제가 있을 수 있나요? ■

하지만, `spin_lock()` 과 `spin_unlock()` 기능들은 성능상의 문제가 있는데, Chapter 10 에서 다루어집니다.

4.3.4 Accessing Shared Variables

C 표준은 2011년에 와서야 공유된 변수로의 동시의 read/write 액세스에 대해 어떤 일이 벌어지는지 정의했습니다만, 동시성 있는 C 코드는 그보다 최소 25년은 전부터 쓰여졌습니다 [BK85, Inm85]. 이 사실은 오늘 날의 노인들이 C11 이전 시대에는 뭘 했는지 궁금하게 만들니다. 이에 대한 짧은 대답은 “그들은 위험하게 살았다”입니다.

그들은 최소한 2018년도의 컴파일러를 사용하면 위험하게 살았을 겁니다. (대략) 1990년대 초, 컴파일러는 덜 유능했는데, 부분적으로는 많은 연구와 발전이 이루어지지 않았기 때문이고, 한편으로는 당시의 상대적으로 작은 메모리에 제한되어 있었기 때문입니다. 그러나, Listing 4.14 에 보인 것처럼 문제는 있었는데, 컴파일러는 이 코드를 Listing 4.15 처럼 바꿀 수 있었습니다. Listing 4.14 의 라인 1 에 있는 임의의 메모리 접근이 사라져서, `global_ptr` 는 최대 세번까지 로드될 수 있게 되었습니다.

Quick Quiz 4.29: Listing 4.14 의 `global_ptr` 를 최대 세번까지 로드하게 된게 뭐가 문제죠? ■

Section 4.3.4.1 은 평범한 접근들로 인해 생길 수 있는 또 다른 문제들을 설명하고, Sections 4.3.4.2 과 4.3.4.3 은 C11 이전 시대의 해결책 일부를 소개합니다. 물론, 실용적이라면 Section 4.2.5 이나 (특히) Section 4.2.6 에 소개된 기능들이 데이터 레이스를 없애기 위해, 즉, 특정

변수에 동시적으로 여러 접근이 가해진다면 그것들이 모두 읽기임을 보장하기 위해 사용되어야 합니다.

4.3.4.1 Shared-Variable Shenanigans

평범한 로드와 스토어⁴를 하는 코드를 가지고, 컴파일러는 영향을 받는 변수들은 다른 쓰레드에 의해 접근되지도 수정되지도 않는다고 가정할 수 있는 권한을 갖습니다. 이 가정은 컴파일러가 많은 변화를 가할 수 있도록 하는데, 여기엔 로드 찢기 (Load tearing), 스토어 찢기 (store tearing), 로드 합치기 (load fusing), 스토어 합치기 (store fusing), 코드 재배치, 로드 만들어내기 (invented loads), 스토어 만들어내기 (invented store) 와 같은 것들이 포함되며 싱글 쓰레드 코드에서는 잘 동작합니다. 하지만 동시성 있는 코드는 이 변화들 각각, 또는 공유 변수 장난으로 인해 아래에 설명될 것처럼 망가질 수 있습니다.

Load tearing은 컴파일러가 하나의 액세스를 위해 여러 로드 인스트럭션을 상요할 때 발생합니다. 예를 들어, 컴파일러는 이론적으로 `global_ptr`로부터의 로드를 (Listing 4.14의 라인 1을 참고하세요) 일련의 1바이트 로드들로 만들 수 있습니다. 만약 다른 쓰레드가 `global_ptr`을 `NULL`로 설정하고 있었다면, 하나의 바이트 빼고는 0으로 채워진 포인터가 만들어 져서 “야생의 포인터”를 만들게 될 겁니다. 이런 야생의 포인터를 사용한 스토어는 메모리의 임의의 영역을 오염시켜서 드물게 일어나고 디버깅 하기 어려운 크래시를 유발할 겁니다.

아직 더 나쁜게, (예컨대) 16비트 포인터를 사용하는 8비트 시스템에서, 컴파일러는 해당 포인터를 접근하기 위해 두개의 8비트 인스트럭션들을 사용할 수밖에 없을 겁니다. C 표준은 모든 형태의 시스템을 지원해야 하므로, 이 표준은 일반적 경우에 있어서의 로드 찢기를 금지할 수 없습니다.

Store tearing은 컴파일러가 하나의 액세스를 위해 여러개의 스토어 인스트럭션을 사용할 때 발생합니다. 예를 들어, 한 쓰레드가 4바이트 정수형 변수에 `0x1234`를 저장하는 동안 다른 쓰레드는 `0xabcd`를 저장할 수 있습니다. 이 컴파일러가 각 액세스에 16비트 스토어들을 사용했다면, 결과는 `0x12cd`가 될 수도 있는데, 이 변수로부터 값을 읽는 코드에는 매우 놀라운 결과가 될 겁니다. 다시 말하지만, C 표준은 16비트 시스템에서 32비트 정수형을 사용하는 코드의 가능성과 같은 일반적 경우에 대해 다른 선택의 여지가 없습니다.

Load fusing은 컴파일러가 로드를 반복하는 대신 해당 변수의 앞의 로드의 결과를 사용할 때 발생합니다. 이런 종류의 최적화는 싱글 쓰레드 코드에서만이 아

Listing 4.16: C Compilers Can Fuse Loads

```

1 if (!need_to_stop)
2     for (;;) {
3         do_something_quickly();
4         do_something_quickly();
5         do_something_quickly();
6         do_something_quickly();
7         do_something_quickly();
8         do_something_quickly();
9         do_something_quickly();
10        do_something_quickly();
11        do_something_quickly();
12        do_something_quickly();
13        do_something_quickly();
14        do_something_quickly();
15        do_something_quickly();
16        do_something_quickly();
17        do_something_quickly();
18        do_something_quickly();
19    }

```

나라 멀티쓰레드 코드에서도 많은 경우에 유효합니다. 불행히도, 이 “많은 경우”라는 단어는 진짜 짜증나는 예외를 감추고 있습니다.

예를 들어, `need_to_stop` 변수의 값이 적혀질 때 까지 `do_something_quickly()`를 반복적으로 수행하는 리얼타임 시스템이 있고, 컴파일러가 `do_something_quickly()`는 `need_to_stop`에 쓰기를 하지 않는다는 것을 볼 수 있다고 해봅시다. 이 컴파일러는 루프의 끝에서의 뒤로의 브랜치를 줄이기 위해 이 루프를 16회씩 풀 수 있을 겁니다. 더 나쁜 것이, 컴파일러는 `do_something_quickly()`가 `need_to_stop`에 쓰기를 하지 않는다는 것을 알기 때문에, 이 컴파일러는 이 변수를 한번만 체크하도록 할 수 있어서, Listing 4.16에 보인 것과 같은 코드를 초래할 수 있을 겁니다. 라인 2-19의 루프는 한번 진입하면 다른 쓰레드가 몇번이나 `need_to_stop`에 0이 아닌 값을 저장했는가에 관계없이 멈추지 않게 됩니다. 그 결과는 최선의 경우에도 실망스러울 것이고, 상당한 물리적 손상을 가져올 수도 있을 겁니다.

Store fusing은 컴파일러가 특정 변수로의 연속적인 쓰기들이 중간에 그 변수로부터의 읽기 없이 이루어 진다는 걸 컴파일러가 알아낼 때 발생합니다. 이 경우, 컴파일러는 첫번째 쓰기를 없애버릴 수 있는 권한을 갖습니다. 이건 싱글 쓰레드 코드에서는 문제가 안되고, 올바르게 작성된 동시성 있는 코드에서도 일반적으로는 그렇습니다. 무엇보다, 만약 두개의 쓰기가 빠르게 수행된다면, 다른 쓰레드가 첫번째 쓰기로 인한 값을 읽을 확률은 매우 적을 겁니다.

하지만, 예외가 존재하는데, 예를 들면 Listing 4.17에 보인 것과 같습니다. `shut_it_down()` 함수는 라인 3과 8에서 공유 변수 `status`에 스토어를 하고, 따라서 `start_shutdown()`과 `finish_shutdown()`도 `status`에 접근하지 않는다고 가정하며, 컴파일러는 라인 3에서의 `status`로의 스토어를 제거할 수 있습니다.

⁴ 즉, C11의 어토믹 기능들, 인라인 어셈블리, 또는 volatile 액세스가 아닌 평범한 로드와 스토어.

Listing 4.17: C Compilers Can Fuse Stores

```

1 void shut_it_down(void)
2 {
3     status = SHUTTING_DOWN; /* BUGGY!!! */
4     start_shutdown();
5     while (!other_task_ready) /* BUGGY!!! */
6         continue;
7     finish_shutdown();
8     status = SHUT_DOWN; /* BUGGY!!! */
9     do_something_else();
10 }
11
12 void work_until_shut_down(void)
13 {
14     while (status != SHUTTING_DOWN) /* BUGGY!!! */
15         do_more_work();
16     other_task_ready = 1; /* BUGGY!!! */
17 }

```

불행히도, 이는 `work_until_shut_down()` 이 라인 14과 15의 루프를 결코 빠져나오지 못해서, `other_task_ready`의 값을 결코 쓰지 못하게 될 것을 의미하는데, 이는 결국 `shut_it_down()` 이 라인 5과 6의 루프를 설령 컴파일러가 line 5에서의 `other_task_ready`로부터의 연속된 로드를 합치지 않는다 하더라도 빠져나오지 못하게 될것임을 의미합니다.

그리고 Listing 4.17 의 코드에는 코드 재배치를 포함한 더 많은 문제들이 있습니다.

Code reordering은 일반적인 표현문들을 합치고, 레지스터 사용률을 줄이고, 오늘날의 슈퍼스칼라 마이크로프로세서들의 기능 유닛들의 사용률을 개선하는데 사용되는 흔한 컴파일 기술입니다. 이게 Listing 4.17 의 코드가 왜 버그를 가지고 있는가에 대한 또다른 이유입니다. 예를 들어, 라인 15의 `do_more_work()` 함수가 `other_task_ready` 를 접근하지 않는다고 해봅시다. 그러면 컴파일러는 라인 16에서의 `other_task_ready`로의 값 할당을 라인 14를 앞서게 만들 수 있는데, 이는 라인 15에서의 `do_more_work()` 호출이 라인 7에서의 `finish_shutdown()` 호출 후에 일어났길 바라는 사람들에게는 큰 아쉬움일 겁니다.

Invented loads는 Listings 4.14 과 4.15 의 코드에 대해서 보여지는데, 컴파일러가 임시 변수를 최적화로 없애버려서 공유변수로부터의 로드를 의도한 것보다 자주 일어나게 만들어서 발생합니다.

만들어진 로드는 성능상의 문제가 될수도 있습니다. 이런 문제는 “자주 접근되는” 캐시라인의 변수로부터의 로드가 `if` 문 밖으로 빠져나올 때 발생합니다. 이런 빠내기 최적화는 드물지 않으며, 캐시 미스를 크게 늘릴 수 있어서, 성능과 확장성에 상당한 저하를 일으킬 수 있습니다.

Invented stores는 다양한 상황에서 발생될 수 있습니다. 예를 들어, 컴파일러는 Listing 4.17 의 `work_until_shut_down()` 를 위한 코드를 만들어내는 컴파일러는 `other_task_ready` 이 `do_more_work()` 에 의해 접근

Listing 4.18: Inviting an Invented Store

```

1 if (condition)
2     a = 1;
3 else
4     do_a_bunch_of_stuff();

```

Listing 4.19: Compiler Invents an Invited Store

```

1 a = 1;
2 if (!condition) {
3     a = 0;
4     do_a_bunch_of_stuff();
5 }

```

되지 않고 라인 16에서 스토어 됨을 알 수 있습니다. 만약 `do_more_work()` 함수가 복잡한 인라인 함수였다면, 레지스터 엎지르기를 해야 할 수 있는데, 이 경우 `other_task_ready`는 임시 저장소로 사용하기에 적당해 보일 겁니다. 무엇보다, 거기에 접근하는 게 없는데, 뭐가 해롭겠어요?

물론, 잘못된 시점에 이 변수로 0이 아닌 값을 저장하는 행위는 라인 5에서의 `while` 루프가 지나치게 빨리 종료되게 만들어서, `finish_shutdown()`이 `do_more_work()` 와 동시에 수행되게 만들 겁니다. 이 `while` 문의 의도가 그런 동시성을 제거하기 위함이란 걸 놓고 보면, 이는 좋은 일이 아닙니다.

값이 저장된 변수를 임시 저장소로 사용하는 건 희한해 보이지만, 표준에 의해 허용됩니다. 그러나, Listing 4.18 과 4.19 의 덜 희한해 보이는 예제를 봐도 좋을 겁니다.

Listing 4.18 의 코드를 만들어내는 컴파일러는 `a`의 값이 초기에 0이란 걸 알텐데, 이는 이 코드를 Listing 4.19 의 코드로 변형함으로써 브랜치를 하나 없애버리고 싶은 욕망을 갖게 될겁니다. 여기서, 라인 1는 부조건적으로 `a`에 1을 저장하고, 이어서 `condition` 이 값 설정되지 않았다면 라인 3에서 이 값을 다시 0으로 만듭니다. 이는 이 `if-then-else` 문을 `if-then` 으로 변형해서, 브랜치를 하나 아낍니다.

마지막으로, C11 전의 컴파일러는 쓰여진 변수에 인접해서 일어났던 연관없는 변수로의 쓰기를 만들어 낼 수 있습니다 [Boe05, Section 4.2]. 이 invented stores 의 변종은 데이터 레이스를 만들어내는 컴파일러 최적화의 금지로 인해 없어졌습니다.

안정적인 동시성 코드는 컴파일러가 중요한 액세스들의 횟수와 순서를 분명히 지키도록 할 필요가 있는데, 이 주제는 뒤의 Section 4.3.4.2 과 4.3.4.3 에서 다루어집니다.

4.3.4.2 A Volatile Solution

지금은 훨씬 나아졌지만, C11 과 C++11 [Bec11] 의 발전 전까지는, `volatile` 키워드가 별별 프로그래머의 도구

상자에 없어서는 안될 도구였습니다. 이는 `volatile` 이 의미하는 바가 정확히 무엇인가라는 질문을 유발하는데, 이는 이 표준의 최신 버전에서조차도 [Smi18] 매우 자세히 답변된 바가 없습니다.⁵ 이 버전은 “`volatile gvalues` 를 통한 접근은 추상적 며신의 규칙을 엄격히 따라서 평가된다”는 것을 보장하고, `volatile` 액세스는 사이드 이펙트이고, 이는 네개의 forward-progress 알림 중 하나이며, 그것의 정확한 의미는 구현 종속적입니다. 가장 분명한 안내는 아마도 이 노트를 통해 제공됩니다:

`volatile` 은 구현이 해당 오브젝트에 대한 적극적인 최적화를 해당 오브젝트의 값이 이 구현에 의해서 파악될 수 없는 방법으로 변경될 수도 있는 경우를 위해 막기 위한 힌트입니다. 더 나아가서, 일부 구현의 경우, `volatile` 은 해당 오브젝트를 접근하는데에 특수한 하드웨어 명령어를 필요로 함을 의미할 수도 있습니다. 자세한 의미를 보기 위해선 6.8.1 을 참고하세요. 일반적으로, `volatile` 의 의미는 C에서와 C++에서와 동일하도록 의도되어 있습니다.

이 표현이 낮은 단계의 코드를 작성하는 사람들에게 더 명확할테지만, 컴파일러를 작성하는 사람들은 표준화 되지 않은 노트를 완전히 무시할 수 있다는 사실은 예외입니다. 병렬 프로그래머들은 그 대신 컴파일러 작성자들이 (디바이스 드라이버 개발자들과의 “솔직하고 개방된” 토론 뒤에만 그렇겠지만) 디바이스 드라이버를 망가뜨리지 않으려 할거라는 걸 분명히 할 거고, 디바이스 드라이버는 적어도 다음의 제약사항들을 가질 겁니다 [MWPF18a]:

1. 액세스의 크기와 타입이 기계 명령어에 알려진다면 구현은 정렬된 `volatile` 액세스를 쪼개는 것을 알지 않아도 될 겁니다.⁶ 동시성 코드는 불필요한 로드와 스토어 쪼개짐을 막기 위해 이 제약 사항에 의존합니다.
2. 구현은 `volatile` 액세스의 의미에 대해서도, 값을 리턴하는 `volatile` 액세스의 경우 어떤 값이 리턴될 수 있는지 가능한 값들의 집합에 대해서도 어떤 가정도 가져선 안됩니다.⁷ 동시성 코드는 다른 프로세서가 현재 접근 중인 위치를 접근할 수 있다는

⁵ JF Bastien 은 C++에서의 `volatile` 키워드의 역사와 사용 예들을 완벽하게 문서화 했습니다 [Bas18].

⁶ 이는 128비트 CAS 는 있지만 128비트 로드와 스토어는 갖지 않는 CPU 위에서 128비트 로드와 스토어가 무슨 일을 할지 불명확하게 둔다는 것을 알아 두시기 바랍니다.

⁷ 이는 뒤에서 이야기 될 구현 종속적 의미에 의해 분명히 유도됩니다.

Listing 4.20: Avoiding Danger, 2018 Style

```
1 ptr = READ_ONCE(global_ptr);
2 if (ptr != NULL && ptr < high_address)
3     do_low(ptr);
```

Listing 4.21: Preventing Load Fusing

```
1 while (!READ_ONCE(!need_to_stop))
2     do_something_quickly();
```

Listing 4.22: Preventing Store Fusing and Invented Stores

```
1 void shut_it_down(void)
2 {
3     WRITE_ONCE(status, SHUTTING_DOWN); /* BUGGY!!! */
4     start_shutdown();
5     while (!READ_ONCE(other_task_ready)) /* BUGGY!!! */
6         continue;
7     finish_shutdown();
8     WRITE_ONCE(status, SHUT_DOWN); /* BUGGY!!! */
9     do_something_else();
10 }
11
12 void work_until_shut_down(void)
13 {
14     while (READ_ONCE(status) != SHUTTING_DOWN) /* BUGGY!!! */
15         do_more_work();
16     WRITE_ONCE(other_task_ready, 1); /* BUGGY!!! */
17 }
```

점을 생각하면 적절치 않은 최적화를 막기 위해 이 제약사항에 의존합니다.

3. 정렬되고 기계에서 지원하는 크기의, 다른 것들과 섞이지 않은 크기의 `volatile` 액세스들은 앞과 뒤의 `volatile` 어셈블리 코드들과 자연적으로 상호작용 합니다. 일부 디바이스는 `volatile` MMIO 액세스와 특수목적 어셈블리어 인스트럭션들의 조합으로 접근되어야 하기 때문에 이 제약사항이 필요합니다. 동시성 코드는 `volatile` 액세스와 Section 4.3.4.3에서 이야기 되는 다른 수단의 조합으로부터의 의도된 순서를 지키기 위해 이 제약사항에 의존합니다.

동시성 코드는 또한, 모든 액세스가 정렬되었고 기계 지원 크기라는 가정 하에, 특정 오브젝트에의 어떤 액세스가 어토믹하지 않거나 `volatile` 하지 않은 경우 발생 가능한 데이터 레이스로 발생할 수 있는 정의되지 않은 동작을 막기 위해 앞의 두 제약 사항을 이용합니다. 같은 변수로의 뒤섞인 크기의 액세스는 더 복잡한데, 나중으로 설명을 미뤄두겠습니다.

그럼 앞의 예제에 대해 `volatile` 은 어떻게 동작할까요?

Listing 4.14 의 라인 1에서의 `READ_ONCE()` 사용은 Listing 4.20에서 보인 코드를 만들어내는 invented loads 를 막습니다.

Listing 4.21에 보인 것처럼, `READ_ONCE()` 는 Listing 4.16의 loop unrolling 도 막을 수 있습니다.

Listing 4.23: Disinviting an Invented Store

```

1 if (condition)
2   WRITE_ONCE(a, 1);
3 else
4   do_a_bunch_of_stuff();

```

Listing 4.24: Preventing C Compilers From Fusing Loads

```

1 while (!need_to_stop) {
2   barrier();
3   do_something_quickly();
4   barrier();
5 }

```

READ_ONCE() 와 WRITE_ONCE() 는 또한 Listing 4.22에 보인 store fusing 과 invented stores 를 Listing 4.22 와 같이 방지할 수 있습니다. 하지만, 이는 코드 재배치를 막지는 못하는데, 이를 위해선 Section 4.3.4.3 에서 배운 추가적인 트릭들이 필요합니다.

마지막으로, WRITE_ONCE() 는 Listing 4.18 에 보인 store invention 을 Listing 4.23 처럼 제거할 수 있습니다.

요약하자면, volatile 키워드는 로드와 스토어가 메신에서 제공하는 사이즈고 올바르게 정렬되어 있다면 load tearing 과 store tearing 을 막습니다. 이 키워드는 또한 load fusing, store fusing, invented loads, 그리고 invented stores 를 막습니다. 하지만, 이게 컴파일러가 volatile 액세스를 다른 그것들과 재배치하는 건 막지만, CPU 가 이 액세스들을 재배치 하는 것은 막지 않습니다. 더 나아가서, 컴파일러나 CPU 가 volatile 액세스가 아닌 것을 그것들끼리, 또는 volatile 액세스와 재배치 하는 것은 막지 않습니다. 이런 종류의 재배치를 막기 위해서는 다음 섹션에서 이야기하는 기술들이 필요합니다.

4.3.4.3 Assembling the Rest of a Solution

전로엇 그 으로 어셈블리어로의 리소스를 통해 추가적인 순서 규칙이 주어졌는데, 예를 들면 GCC asm 지시어입니다. 이상하게 들리겠지만, 이 지시어들은 실제로 어셈블리어를 담고 있을 필요 없습니다, 예컨대 Listing 4.9에 보인 barrier() 매크로 처럼요.

barrier() 매크로 내에서, __asm__ 은 asm 지시어를 소개하고, __volatile__ 은 컴파일러가 어셈블리 코드를 최적화해 없애는 걸 막고, 빈 문자열은 실제 인스트럭션의 만들어질 필요는 없음을 의미하며, 마지막의 "memory" 는 컴파일러에게 이 아무것도 하지 않는 asm 은 메모리를 어떻게든 바꿀 수 있음을 알립니다. 이에 대한 응답으로, 컴파일러는 모든 메모리 접근을 barrier() 매크로 앞 또는 뒤로 옮기는 것을 막을 겁니다. 이는 Listing 4.16에 보인 real-time-destroying loop unrolling 이 Listing 4.24 의 라인 2 과 4에 보인 것처럼 barrier() 를 호출함으로써 막아질 수 있습니다. 이 두

Listing 4.25: Preventing Reordering

```

1 void shut_it_down(void)
2 {
3   WRITE_ONCE(status, SHUTTING_DOWN);
4   smp_mb();
5   start_shutdown();
6   while (!READ_ONCE(other_task_ready))
7     continue;
8   smp_mb();
9   finish_shutdown();
10  smp_mb();
11  WRITE_ONCE(status, SHUT_DOWN);
12  do_something_else();
13 }
14
15 void work_until_shut_down(void)
16 {
17   while (READ_ONCE(status) != SHUTTING_DOWN) {
18     smp_mb();
19     do_more_work();
20   }
21   smp_mb();
22   WRITE_ONCE(other_task_ready, 1);
23 }

```

라인의 코드는 컴파일러가 need_to_stop 으로부터의 로드가 do_something_quickly() 뒤로 또는 앞으로 재배치 되는 걸 막아줍니다.

하지만, 이 코드는 CPU 가 메모리 접근을 재배치하는 걸 막지는 않습니다. 하드웨어는 특정 정도만 재배치 할 수 있기 때문에, 많은 경우에 이게 문제가 되지 않습니다. 하지만, 하드웨어가 제어되어야만 하는 Listing 4.17 같은 경우가 있습니다. Listing 4.22 은 store fusing 과 invention 을 막고, Listing 4.25 은 더 나아가 라인 4, 8, 10, 18, 그리고 21.에 smp_mb() 를 추가함으로써 이 남아있는 재배치 가능성을 없애버립니다. 이 smp_mb() 매크로는 Listing 4.9 에 보인 barrier() 와 비슷합니다만, 빈 문자열이 전체 메모리 배리어를 위한 인스트럭션을 담은 문자열로 바뀐게 차이점인데, 예를 들어 x86 에선 "mfence", PowerPC 에서는 "sync" 입니다.

Quick Quiz 4.30: 하지만 전체 메모리 배리어를 너무 무겁지 않나요? Listing 4.25 의 순서 규칙을 강제하는데에 더 비용이 적은 방법도 있지 않아요? ■

Section 4.3.5 에 일부가 소개된 일부 read-modify-write 어토믹 오퍼레이션들로도 제공됩니다. 일반적인 경우, 메모리 순서 규칙은 Chapter 15. 상당히 애매할 수 있습니다. 다음 섹션은 메모리 순서 규칙의 대안을 알아보는데, 말하자면 데이터 레이스를 제한하거나 아예 없애는 겁니다.

4.3.4.4 Avoiding Data Races

“의사 선생님, 공유된 변수를 동시적으로 접근하는 걸 생각하면 머리가 아파요!”

“그럼 동시적으로 공유된 변수에 접근하질 마세요!!!”

이 의사 선생님의 조언은 도움이 되지 않는다 생각할 수도 있겠지만, 단순화는 많은 경우에 매우 좋은 일입니다. 그리고 동시적으로 공유 변수에 접근하는 걸 막는 방법 중 시간이 겹중한 방법 중 하나는 Chapter 7에서 이야기 된 것처럼 락킹을 사용하는 겁니다. 또 다른 방법은 Chapter 8에서 이야기한 것처럼 “공유된” 변수를 하나의 쓰레드 또는 CPU에서만 접근하는 겁니다. 이것들을 조합하는 것도 가능한데, 예를 들어, 특정 변수는 특정 락이 잡혀 있는 동안 하나의 CPU 또는 쓰레드에 의해 서만 수정되고, 같은 쓰레드 또는 CPU에 대해서, 또는 같은 락을 잡고 있는 다른 누군가에 대해서 읽혀질 수도 있습니다. “모든 작은 것들이 도움이 된다”는 정신에 입각해서, 일부 경우에 평범한 로드와 스토어를 허용하는 경우들을 나열합니다, 다른 경우들에는 마킹이 필요하지만요 (말하자면 `READ_ONCE()` 와 `WRITE_ONCE()`):

1. 만약 어떤 공유 변수가 특정 주인 CPU나 쓰레드에 의해 특정 락을 잡고 있는 동안만 수정된다면, 모든 스토어는 `WRITE_ONCE()` 를 사용해야 하고, 이 락을 잡고 있지 않은 주인이 아닌 CPU 또는 쓰레드들은 로드를 위해 `READ_ONCE()` 를 사용해야만 합니다. 다른 CPU나 쓰레드가 해당 락을 잡게 되므로, 주인 CPU 또는 쓰레드는 평범한 로드를 써도 됩니다.
2. 공유 변수가 특정 락을 잡고 있는 동안만 수정된다면, 모든 스토어가 `WRITE_ONCE()` 를 사용해야 합니다. 이 락을 잡지 않고 있는 CPU 또는 쓰레드는 로드를 위해 `READ_ONCE()` 를 사용해야 합니다. 이 락을 잡고 있는 CPU 또는 쓰레드는 평범한 로드를 사용해도 됩니다.
3. 공유 변수가 주인 CPU 또는 스레드에 대해서만 수정된다면, 모든 스토어는 `WRITE_ONCE()` 를 사용해야 하고 주인이 아닌 CPU 또는 쓰레드는 로드를 위해 `READ_ONCE()` 를 사용해야 합니다. 주인 CPU 또는 쓰레드는 평범한 로드를 사용해도 됩니다.

대부분의 경우, 공유 변수로의 로드와 스토어는 반드시 `READ_ONCE()` 와 `WRITE_ONCE()` 또는 이보다 강한 것들을 각각 사용해야 합니다. 하지만 `READ_ONCE()` 도 `WRITE_ONCE()` 도 어떤 순서 보장을 제공하지 않는다는 의문이 떠오르게 될겁니다. 순서 보장을 제공하는데 대한 정보를 위해선 앞의 Section 4.3.4.3 또는 Chapter 15를 참고하시기 바랍니다.

한가지 중요한 특수 케이스는 특정 변수가 프로세스 수준 코드로 공유되면서 언터럽트나 시그널 핸들러에 대해서도 공유되지만, 다른 CPU 또는 쓰레드에 대해서는 접근되지 않는 경우입니다. 이 경우, 프로세스 수준 코드는 이 변수에 접근하기 위해 `READ_ONCE()` 와

`WRITE_ONCE()` 또는 그보다 강한 것들을 사용해야 합니다.

Quick Quiz 4.31: 특정 언터럽트나 시그널 핸들러가 그 스스로 언터럽트 되면 어떻게 되나요? ■

이런 데이터 레이스 제거 패턴의 많은 예제가 Chapter 5에 있습니다.

4.3.5 Atomic Operations

리눅스 커널은 다양한 어토믹 오퍼레이션들을 제공합니다만, `atomic_t` 타입으로 정의되어 있는 것들이 좋은 시작점이 될겁니다. 일반적인 non-tearing read 와 store 들은 `atomic_read()` 와 `atomic_set()` 으로 각각 제공됩니다. Acquire load 는 `smp_load_acquire()` 로, release store 는 `smp_store_release()` 로 제공됩니다.

값을 리턴하지 않는 `fetch-and-add` 오퍼레이션들은 `atomic_add()`, `atomic_sub()`, `atomic_inc()`, 그리고 `atomic_dec()` 으로 제공됩니다. 값이 0이 되는 경우에 대한 알림을 리턴하는 어토믹 값 감소 연산은 `atomic_dec_and_test()` 와 `atomic_sub_and_test()` 로 제공됩니다. 새로운 값을 리턴하는 어토믹 값 증가 연산은 `atomic_add_return()` 으로 제공됩니다. `atomic_add_unless()` 와 `atomic_inc_not_zero()` 는 어토믹 변수들의 원래 값이 명시된 값과 다르다면 아무일도 일어나지 않는 조건적 어토믹 오퍼레이션들을 제공합니다 (예컨대, 레퍼런스 카운터를 관리하는데에 이것들이 매우 유용합니다).

어토믹 값 교환 오퍼레이션은 `atomic_xchg()` 로 제공되고, 찬양되는 compare-and-swap (CAS) 오퍼레이션은 `atomic_cmpxchg()` 로 제공됩니다. 이것들을 둘 다 기존 값을 리턴합니다. 리눅스 커널에서는 더 많은 어토믹 RMW 기능들이 사용 가능한데, 리눅스 커널 소스 트리의 `Documentation/atomic_ops.txt` 파일을 참고하시기 바랍니다.

이 책의 CodeSamples API 는 리눅스 커널의 것들을 거의 비슷하게 따라합니다.

4.3.6 Per-CPU Variables

리눅스 커널은 per-CPU 변수 (CPU 별로 인스턴스를 하나씩 소유하는 변수)를 정의하기 위해 `DEFINE_PER_CPU()` 를, 현재 CPU 가 소유한 특정 per-CPU 변수의 인스턴스를 참조하는데에 `this_cpu_ptr()` 를, 특정 CPU 가 소유한 특정 per-CPU 변수의 인스턴스를 접근하는데에 `per_cpu()` 를 사용하며, 그 외에도 많은 특수 목적의 per-CPU 오퍼레이션들이 존재합니다.

`Listing 4.26` 는 이 책의 per-thread-variable API 를 보이는데, 리눅스 커널의 per-CPU-variable API 의 패턴을 따랐습니다. 이 API 는 쓰레드별 전역변수와 동일한 것을 제공합니다. 엄격하게 말하자면 이 API 가 꼭 필요한

Listing 4.26: Per-Thread-Variable API

```
DEFINE_PER_THREAD(type, name)
DECLARE_PER_THREAD(type, name)
per_thread(name, thread)
__get_thread_var(name)
init_per_thread(name, v)
```

건 아닙니다만⁸, 이 API 는 리눅스 커널 코드와 유사한 유저스페이스를 제공할 수 있습니다.

Quick Quiz 4.32: Per-thread-variable API 를 제공하지 않는 시스템에서는 어떻게 이를 우회할 수 있을까요? ■

4.3.6.1 DEFINE_PER_THREAD()

DEFINE_PER_THREAD() 기능은 per-thread 변수를 정의합니다. 불행하게도, 리눅스 커널의 DEFINE_PER_THREAD() 기능과 같은 방식으로 초기화 기능을 제공하는 건 불가능합니다만, 실행 중의 초기화를 쉽게 할 수 있게 해주는 init_per_thread() 기능이 있습니다.

4.3.6.2 DECLARE_PER_THREAD()

DECLARE_PER_THREAD() 기능은 정의에 반대되는, C에서의 방식의 선언입니다. 따라서, DECLARE_PER_THREAD() 기능은 다른 파일에서 정의된 per-thread 변수에 접근하기 위해 사용될 수 있습니다.

4.3.6.3 per_thread()

per_thread() 기능은 특정 쓰레드의 변수를 접근합니다.

4.3.6.4 __get_thread_var()

__get_thread_var() 기능은 현재 쓰레드의 변수를 접근합니다.

4.3.6.5 init_per_thread()

init_per_thread() 기능은 모든 쓰레드의 특정 변수 인스턴스들을 특정 값으로 설정합니다. 리눅스 커널은 이를 링커 스크립트와 CPU-online 프로세스 동안 수행되는 코드를 잘 사용해서 평범한 C 초기화를 통해 해냅니다.

4.3.6.6 Usage Example

매우 자주 그 값이 증가하지만 아주 가끔씩만 그 값이 읽어지는 카운터를 가지고 있다고 해봅시다. Section ??

⁸ 이 API 대신에 __thread 나 _Thread_local 을 사용하실 수도 있습니다.

에서 자명해지겠지만, 그런 카운터는 per-thread 변수를 사용해 구현하는게 좋습니다. 그런 변수는 다음과 같이 정의될 수 있습니다:

```
DEFINE_PER_THREAD(int, counter);
```

이 카운터는 다음과 같이 초기화 되어야 합니다:

```
init_per_thread(counter, 0);
```

쓰레드는 이 카운터의 자신에게 할당된 인스턴스의 값을 다음과 같이 증가시킬 수 있습니다:

```
p_counter = &__get_thread_var(counter);
WRITE_ONCE(*p_counter, *p_counter + 1);
```

이 카운터의 값은 그 인스턴스들의 값의 합입니다. 따라서 이 카운터의 값의 스냅샷은 다음과 같이 얻어질 수 있습니다:

```
for_each_thread(t)
    sum += READ_ONCE(per_thread(counter, t));
```

다시 말하지만, 다른 메커니즘을 사용해서도 비슷한 효과를 얻을 수 있습니다만, per-thread 변수들은 높은 성능과 편리성을 함께 제공합니다.

4.4 The Right Tool for the Job: How to Choose?

If you get stuck, change your tools; it may free your thinking.

Paul Arden, abbreviated

경험으로 얻은 간단한 교훈으로 말씀드리건대, 해야하는 일을 완수해주는 가장 간단한 도구를 사용하세요. 만약 가능하다면, 그냥 순차적으로 프로그램을 짜세요. 그게 충분치 않다면, 셸 스크립트를 사용해 병렬성을 다루세요. 그로 말미암은 셸 스크립트의 fork()/exec() 오버헤드(Intel Core Duo 랩탑에서의 작은 C 프로그램의 경우 약 480 마이크로세컨드)가 지나치게 크다면, C 언어의 fork() 와 wait() 함수를 사용해 보세요. 이 함수들의 오버헤드(가장 작은 자식 프로세스에 약 80 마이크로세컨드)도 너무 크다면, POSIX 쓰레딩 도구들에서 적절한 락킹과 필요하면 어토믹 오퍼레이션을 골라서 사용해야 할겁니다. POSIX 쓰레딩 도구들의 오버헤드(대부분의 경우 마이크로세컨드 미만) 조차도 너무 크다면, Chapter 9에서 소개되는 도구들이 필요할 수

있습니다. 프로세스간 통신과 메세지 전달은 공유 메모리 멀티 쓰레드 실행의 좋은 대안이 될 수 있다는 점을 항상 기억하세요.

Quick Quiz 4.33: 셀은 기본적으로 `fork()` 가 아니라 `vfork()` 를 사용하지 않나요? ■

물론, 실제 오버헤드는 당신의 하드웨어에도 의존적 이겠지만, 그보다는 당신이 해당 기능들을 어떤 방식으로 사용하느냐가 훨씬 더 영향을 끼칠 겁니다. 특히, 멀티 쓰레드로 짜여진 코드를 무작위로 해킹하는 건 공유 메모리 병렬 시스템은 당신의 지능을 당신에게 사용하기 때문에 엄청나게 나쁜 생각입니다: 당신이 똑똑할 수록, 당신은 당신이 문제 [Pok16] 에 빠져 있음을 깨닫기 전까지 점점 깊은 구멍에 빠져들 겁니다. 따라서, 뒤의 챕터들에서 이야기하겠지만 개별 도구를 고르는 것 만큼이나 올바른 설계를 하는 것이 중요합니다.

Chapter 5

Counting

카운팅은 아마도 컴퓨터가 할 수 있는 가장 간단하고 가장 자연스런 일 중 하나일 것입니다. 하지만, 거대한 공유 메모리 멀티 프로세서에서 효율적이고 확장성 있게 카운팅을 하는 것은 꽤 어려운 일이 될 수 있습니다. 더우기, 카운팅의 간단함은 정교한 데이터 구조나 복잡한 동기화 도구에 의한 혼란 없이 기본적인 동시성 문제만을 바라볼 수 있게 합니다. 그래서 카운팅은 별별 프로그래밍으로의 훌륭한 소개 역할을 합니다.

이 챕터는 간단하고 빠르고 확장성 있는 카운팅 알고리즘들 여럿을 다룹니다. 하지만 먼저, 당신이 얼마나 동시적 카운팅에 대해 알고 있는지 알아보죠.

Quick Quiz 5.1: 대체 왜 효과적이고 확장성 있는 카운팅이 어려운가요? 무엇보다, 컴퓨터들은 카운팅, 더하기, 빼기, 그 외에도 여러 가지를 위한 전용 하드웨어도 가지고 있는데, 그걸 못하나요??? ■

Quick Quiz 5.2: 네트워크 패킷 카운팅 문제. 당신이 송수신된 네트워크 패킷의 갯수에 대한 통계를 구해야 한다고 생각해 봅시다. 패킷들은 시스템의 어떤 CPU를 통해서든 송신/수신될 수 있을 겁니다. 더 나아가서 이 시스템이 CPU 당 초당 백만개의 패킷을 다룰 수 있고, 그 갯수를 매 5초마다 읽어내야 하는 시스템 모니터링 패키지가 있다고 가정해 봅시다. 당신이라면 이 통계 카운터를 어떻게 구현하시겠어요? ■

Quick Quiz 5.3: 대략적 구조체 할당 한계 문제. 할당된 구조체의 갯수가 어떤 한계(한 10,000 정도)를 넘어가면 추가 할당을 막기 위해 할당된 구조체의 갯수를 유지해야 한다고 생각해 봅시다. 또, 이 구조체들은 할당되고 나서 곧바로 해제되고, 한계치를 넘기는 일은 매우 드물고, “대략적인” 한계치 설정이 가능하다고 생각해 봅시다. ■

Quick Quiz 5.4: 정교한 구조체 할당 한계 문제. 할당된 구조체의 갯수가 어떤 정확한 한계(여기서도, 한 10,000 정도)를 넘어가면 추가 할당을 막기 위해 할당된 구조체의 갯수를 유지해야 한다고 생각해 봅시다. 이 구조체들은 할당되고 얼마 안되 해제되고, 그 한계는 드물게 초과되며, 거의 항상 최소 한개의 구조체는

사용중이 됩니다. 또한 예를 들어, 하나의 구조체도 사용되지 않고 있다면 해제 할 수 있는 어떤 메모리를 위해 카운터가 0이 되는 시점을 정확히 알 필요가 있습니다.

■ **Quick Quiz 5.5: 제거될 수 있는 I/O 디바이스 접속 카운트 문제.** 매우 빈번하게 사용되는 제거 가능한 대용량 디바이스에 대해 사용자에게 해당 디바이스를 제거해도 안전한지 알려주기 위해 그 참조 횟수를 관리해야 한다고 가정해 봅시다. 사용자는 디바이스를 제거하고 싶을 때 그 의사를 알려주며, 시스템은 사용자에게 언제 디바이스를 제거해도 안전한지 알려주는 일반적 디바이스 제거 절차를 따릅니다. ■

이 챕터의 뒷부분은 이 문제들에 대한 답을 만들어 볼겁니다. Section 5.1에서는 왜 멀티코어 시스템에서의 카운팅이 간단하지 않은지 다루고, Section 5.2에서는 네트워크 패킷 카운팅 문제를 푸는 방법들을 봅니다. Section 5.3에서는 대략적 구조체 할당 한계 문제, Section 5.4에서는 정교한 구조체 할당 한계 문제를 풀어봅니다. 마지막으로, Section 5.5에서는 성능 측정과 함께 이 챕터를 마무리 합니다.

Section 5.1와 Section 5.2는 소개적인 내용들을 담고 있고, 이외의 섹션들은 좀 더 전문적인 학생들에게 적당할 겁니다.

5.1 Why Isn't Concurrent Counting Trivial?

Seek simplicity, and distrust it.

Alfred North Whitehead

일단 간단한, 예를 들어, Listing 5.1 (`count_nonatomic.c`)에 나온 것과 같이 직관적인 알고리즘부터 보도록 하죠. 여기서, 우리는 라인 1에서 카운터를 정의하고, 라인 5에서 그 값을 증가시키며, 라인 10에서 그 값을 읽어옵니다. 이보다 간단할 수는 없겠죠?

Listing 5.1: Just Count!

```

1 unsigned long counter = 0;
2
3 static __inline__ void inc_count(void)
4 {
5     WRITE_ONCE(counter, READ_ONCE(counter) + 1);
6 }
7
8 static __inline__ unsigned long read_count(void)
9 {
10     return READ_ONCE(counter);
11 }

```

Listing 5.2: Just Count Atomically!

```

1 atomic_t counter = ATOMIC_INIT(0);
2
3 static __inline__ void inc_count(void)
4 {
5     atomic_inc(&counter);
6 }
7
8 static __inline__ long read_count(void)
9 {
10     return atomic_read(&counter);
11 }

```

이 방법은 당신이 대부분의 경우 읽기만을 하고 값의 증가는 아주 가끔만 한다면 매우 빠르다는 장점을 가지고, 또한 작은 시스템에서는 훌륭한 성능을 보일 겁니다.

다만 여기에는 한가지 커다란 문제가 있습니다: 이 방법은 카운트를 놓칠 수 있습니다. 제 듀얼 코어 랩탑에서 짧은 시간동안 `inc_count()`를 100,014,000 번 수행했을 때, 카운터의 마지막 값은 52,909,118 이었습니다. 컴퓨팅에서는 대략적인 값도 충분한 경우도 있지만 그렇다 해도 50% 이상의 정밀도는 거의 항상 필요합니다.

Quick Quiz 5.6: 하지만 영리한 컴파일러는 Listing 5.1의 라인 5 이 `++` 연산자와 동일함을 증명하고 x86 add-to-memory 인스트럭션을 만들어 낼 수 있지 않나요? ■

Quick Quiz 5.7: 실패 횟수의 8-figure 정확도는 당신이 진짜로 이 테스트를 한 것을 보여주는군요. 왜 이런 사소한 프로그램을, 특히나 버그가 이렇게 쉽게 직관적으로 보이는데도 굳이 테스트 해야 하나요? ■

정확하게 카운트를 하는 직관적 방법은 Listing 5.2 (`count_atomic.c`)에 나온 것처럼 어토믹 오퍼레이션을 사용하는 것입니다. 라인 1은 어토믹 변수를 정의하고, 라인 5에서 어토믹하게 값을 증가시키고, 라인 10에서 읽어냅니다. 이건 어토믹하기 때문에, 완벽한 카운트를 유지합니다. 하지만, 느립니다: Intel Core Duo 랩탑에서 이것은 어토믹하지 않은 방법에 비해 싱글쓰레드에서 여섯배, 그리고 두 쓰레드를 사용했을 때엔 열배 느립니다.¹

¹ 흥미롭게도, 어토믹하지 않게 카운터를 증가시키는 두개의 쓰레드는 어토믹하게 카운터를 증가시키는 두개의 쓰레드보다 더 빨리




Figure 5.1: Atomic Increment Scalability on Nehalem

Chapter 3에서 이야기했던 걸 떠올려 보면 성능이 느린 것도, Figure ??에서 보여지듯 어토믹 증가 연산의 성능이 CPU와 쓰레드의 숫자가 증가할수록 느려지는 것도 그다지 놀라운 일은 아닙니다. 이 그림에서, x 축에 붙어있는 수평의 점선은 완벽하게 확장하는 알고리즘에 의해서만 얻어질 수 있는 이상적인 성능입니다: 그런 알고리즘이라면, 카운트 증가는 싱글쓰레드에서 와 동일한 오버헤드만을 일으킬 것입니다. 하나의 전역 변수에 대한 어토믹 증가 연산은 분명하게 이상적이지 않으며, CPU를 추가할수록 성능이 나빠집니다.

Quick Quiz 5.8: 왜 x 축의 점선은 $x = 1$ 에서 대각선의 선과 만나지 않죠? ■

Quick Quiz 5.9: 하지만 어토믹 증가 연산은 여전히 꽤 빠릅니다. 그리고 빽빽한 루프에서 하나의 변수를 증가시키는 건 제겐 꽤 비현실적인 것 같아 보이구요, 무엇보다, 프로그램의 실행은 실제로 일을 하는데 쓰여야지, 자기가 한 일을 세는데 쓰여야 하는게 아니라구요! 왜 제가 이걸 빠르게 하는걸 고민해야 하나요? ■

전역 어토믹 증가에 대한 다른 관점을 위해, Figure 5.2를 보세요. 각 CPU가 주어진 전역 변수를 증가시킬 기회를 얻기 위해서, 해당 변수를 가지고 있는 캐시 라인은 빨간 화살표로 표시된 것처럼 모든 CPU 사이를 순환해야 합니다. 이런 순환은 상당한 시간을 요할 것이고, 이는 Figure 5.3와 같은 상황을 초래해서 Figure ??에서 보여진 낮은 성능을 야기할 것입니다.

다음 세션들에서는 이런 순환에서 발생하는 지연들을 없앤 고성능 카운팅에 대해 알아봅니다.

Quick Quiz 5.10: 그런데 왜 CPU 설계자들은 단순히

그 값을 증가시킵니다. 물론, 당신의 목표가 단순히 카운터를 더 빨리 증가시키는 거라면, 그냥 카운터에 큰 값을 넣으면 되겠습니다. 그러나, 거대한 성능과 확장성을 위해선 정확성을 주의깊게 완화한 알고리즘의 역할도 있을 수 있습니다 [And91, ACMS03, Ung11].




Figure 5.2: Data Flow For Global Atomic Increment




Figure 5.3: Waiting to Count

데이터에의 증가 연산을 추가함으로써 데이터를 담고 있는 캐시 라인의 순환이 증가하는걸 막지 못한 거죠? ■

5.2 Statistical Counters

Facts are stubborn things, but statistics are pliable.

Mark Twain

이 섹션은 카운트는 매우 자주 업데이트 되지만 매우 가끔씩만 그 값이 읽혀지는, 통계적 카운터의 혼란 특수 케이스들을 다룹니다. 이것들은 Quick Quiz 5.2에서 이야기한 네트워크 패킷 카운팅 문제를 푸는데 사용되곤 할 겁니다.

Listing 5.3: Array-Based Per-Thread Statistical Counters

```

1 DEFINE_PER_THREAD(unsigned long, counter);
2
3 static __inline__ void inc_count(void)
4 {
5     unsigned long *p_counter = &__get_thread_var(counter);
6
7     WRITE_ONCE(*p_counter, *p_counter + 1);
8 }
9
10 static __inline__ unsigned long read_count(void)
11 {
12     int t;
13     unsigned long sum = 0;
14
15     for_each_thread(t)
16         sum += READ_ONCE(per_thread(counter, t));
17     return sum;
18 }

```

5.2.1 Design

통계적 카운팅은 보통 쓰레드별로 (또는, 커널에서라면 CPU별로) 카운터를 제공해서 각 쓰레드가 자신의 카운터를 업데이트 하도록 합니다. 이 카운터들의 전체 통합 값은 더하기의 상호성과 결합성에 기반해, 단순히 모든 쓰레드의 카운터의 값을 더하는 것으로 구해질 수 있습니다. 이건 Section 6.3.4에서 소개될 데이터 소유권 패턴의 한 예입니다.

Quick Quiz 5.11: 하지만 C의 “정수들”의 제한된 크기가 일을 복잡하게 만들지는 않나요? ■

5.2.2 Array-Based Implementation

쓰레드별 변수를 제공하는 방법 중 하나는 쓰레드별로 (false sharing을 막기 위해 캐시 라인 크기에 맞춰 정렬되어있고 채워져 있는) 원소 하나를 갖는 배열을 만드는 겁니다.

Quick Quiz 5.12: 배열이요??? 하지만 그럼 쓰레드의 갯수가 제한되지 않나요? ■

그런 배열은 Listing 5.3 (count_stat.c)에 보여진 것처럼 per-thread 기능을 사용할 수도 있습니다. 라인 1은 long 타입의 쓰레드별 카운터들을 담는, counter라는 이름의 배열을 정의합니다.

라인 3-8은 이 카운터를 증가시키는 함수로, __get_thread_var() 함수를 사용해 counter 배열에서 현재 수행중인 쓰레드의 원소를 얻어옵니다. 이 원소는 연관된 쓰레드에 의해서만 수정되므로, 어토믹하지 않은 방식으로도 충분합니다. 하지만, 이 코드는 위험한 컴파일러 최적화를 막기 위해 WRITE_ONCE()를 사용하고 있습니다. 하나만 예를 들자면, 컴파일러는 쓰기가 될 값을 담는 곳을 임시적 저장소로 대신할 수 있어서, 모든 의도와 목적을 담는 쓰기는 실제 쓰기가 되기 전에 쓰레기가 되어 버릴 겁니다. 물론 이는 이 카운트를 읽으려 하는 모든 시도를 혼란스럽게 만들 겁니다. WRITE_ONCE()




Figure 5.4: Data Flow For Per-Thread Increment

ONCE()는 이런 부류의 최적화를 방지합니다.

Quick Quiz 5.13: 이거 말고도 GCC가 할 수 있는 이상한 최적화는 어떤게 있나요? ■

라인 10-18는 현재 수행중인 쓰레드의 리스트를 순회하기 위해 `for_each_thread()` 기능을 사용하고 특정 쓰레드의 카운터를 읽어오기 위해 `per_thread()` 기능을 사용해 카운터의 합산값을 구하는 함수를 보이고 있습니다. 이 코드는 또한 컴파일러가 이 읽기를 잊지도록 만드는 최적화를 하지 않도록 보장하기 위해 `READ_ONCE()`를 사용하고 있습니다. 하나만 예를 들자면, `read_count()`를 연속해서 호출하는 코드는 inline 코드로 변환될 수 있고, 용기 있는 최적화 장치는 같은 위치의 값들의 합이 연속해 구해짐을 알아채서 그 값들의 합을 한번만 구하고 재사용하려 할 수 있습니다. 이런 종류의 최적화는 나중의 `read_count()` 호출이 더 큰 값을 리턴할 거라 기대하는 사람들을 당황하게 만들겁니다. `READ_ONCE()`의 사용은 이 최적화와 비슷한 것들을 방지할 겁니다.

Quick Quiz 5.14: Listing 5.3의 쓰레드별 counter 변수는 어떻게 초기화 되나요? ■

Quick Quiz 5.15: Listing 5.3의 코드가 어떻게 복수의 카운터를 가능하게 할 수 있죠? ■

이 방법은 `inc_count()`를 호출하는 업데이터 쓰레드의 수가 늘어나더라도 선형적으로 성능이 확장됩니다. Figure 5.4의 각 CPU 위의 초록색 화살표로 보여지듯, 각 CPU는 시스템 사이를 통과하는 비싼 비용의 통신 없이 자신의 쓰레드의 변수를 빠르게 증가시킬 수 있기 때문입니다. 이와 같이, 이 섹션은 이 챕터의 시작에서 소개된 네트워크 패킷 카운팅 문제를 해결합니다.

Quick Quiz 5.16: 읽기 오퍼레이션은 쓰레드별 값을 모두 더하는 시간을 가져야 할 것이고, 그동안에도 카운터는 값이 변할 수 있어요. 이는, Listing 5.3의 `read_count()`는 정확하지 않다는 것을 의미합니다. 이 카운터는 단위시간당 r 만큼 값이 증가되고 `read_count()`

는 Δ 단위시간을 소모한다고 해봅시다. 반환되는 값의 예상 오류값은 얼마입니까? ■

하지만, 이 업데이트 쪽 확장성은 쓰레드의 수가 늘어날 경우 읽기 쪽에 큰 부담으로 다가옵니다. 다음 섹션에서는 업데이트 쪽 확장성을 유지하면서 읽기 쪽 부담을 줄이는 방법을 알아봅니다.

5.2.3 Eventually Consistent Implementation

읽기 쪽 성능을 크게 개선하면서 업데이트 쪽 확장성도 지키는 한가지 방법은 일관성에 대한 요구사항을 약화시키는 것입니다. 앞 섹션의 카운팅 알고리즘은 이상적인 카운터가 `read_count()` 실행 직전에 내놓을 값과 실행 직후에 내놓을 값 사이의 값을 내놓는 것을 보장했습니다. 최종적 일관성(*eventual consistency* [Vog09])는 더 완화된 보장사항을 제공합니다: `inc_count()` 호출이 없을 때라는 조건 하에, `read_count()`는 최종적으로는 정확한 값을 리턴할 것입니다.

우리는 글로벌 카운터를 사용해 최종적 일관성을 제공할 것입니다. 하지만, 업데이트 쓰레드는 쓰레드별 카운터만을 사용합니다. 이 쓰레드별 카운터를 글로벌 카운터로 이동시키는 별도의 쓰레드가 제공됩니다. 읽기 쓰레드는 단순히 글로벌 카운터의 값을 읽습니다. 업데이트 쓰레드가 수행 중이라면, 읽기 쓰레드가 읽어낸 값은 과거의 값일 것입니다만, 일단 업데이트가 중단되면 글로벌 카운터는 최종적으로 진짜 값을 가질 겁니다—따라서 이 방법은 최종적 일관성에 부합합니다.

Listing 5.4 (`count_stat_eventual.c`)에 그 구현이 있습니다. 라인 1-2는 카운터의 값을 갖는 쓰레드별 변수와 글로벌 변수를 보여주며, 라인 3은 프로그램을 정확한 카운터 값과 함께 종료하고자 할 경우를 위해 종료 조건을 알리는 `stopflag`를 보입니다. 라인 5-10의 `inc_count()` 함수는 Listing 5.3의 것과 비슷합니다. 라인 12-10의 `read_count()` 함수는 단순히 `global_count` 변수의 값을 리턴합니다.

하지만, 라인 36-46의 `count_init()` 함수는 라인 17-34의 `eventual()` 쓰레드를 생성하는데, 이 쓰레드는 모든 쓰레드를 순회하며 쓰레드별로 `counter`를 더해서 `global_count` 변수에 저장하는 일을 반복합니다. `eventual()` 쓰레드는 일의 반복 사이에 임의로 선택된 1 밀리세컨드 동안 기다립니다. 라인 48-54의 `count_cleanup()` 함수는 프로그램 종료를 관리합니다.

이 방법은 여전히 선형적인 카운터 업데이트 성능을 유지하면서 극단적으로 빠른 카운터 읽기 속도를 보입니다. 하지만, 이 훌륭한 읽기 성능과 업데이트 성능 확장성은 `eventual()`이라는 추가된 쓰레드의 수행이

Listing 5.4: Array-Based Per-Thread Eventually Consistent Counters

```

1 DEFINE_PER_THREAD(unsigned long, counter);
2 unsigned long global_count;
3 int stopflag;
4
5 static __inline__ void inc_count(void)
6 {
7     unsigned long *p_counter = &__get_thread_var(counter);
8
9     WRITE_ONCE(*p_counter, *p_counter + 1);
10 }
11
12 static __inline__ unsigned long read_count(void)
13 {
14     return READ_ONCE(global_count);
15 }
16
17 void *eventual(void *arg)
18 {
19     int t;
20     unsigned long sum;
21
22     while (READ_ONCE(stopflag) < 3) {
23         sum = 0;
24         for_each_thread(t)
25             sum += READ_ONCE(per_thread(counter, t));
26         WRITE_ONCE(global_count, sum);
27         poll(NULL, 0, 1);
28         if (READ_ONCE(stopflag)) {
29             smp_mb();
30             WRITE_ONCE(stopflag, stopflag + 1);
31         }
32     }
33     return NULL;
34 }
35
36 void count_init(void)
37 {
38     int en;
39     thread_id_t tid;
40
41     en = pthread_create(&tid, NULL, eventual, NULL);
42     if (en != 0) {
43         fprintf(stderr, "pthread_create: %s\n", strerror(en));
44         exit(EXIT_FAILURE);
45     }
46 }
47
48 void count_cleanup(void)
49 {
50     WRITE_ONCE(stopflag, 1);
51     while (READ_ONCE(stopflag) < 3)
52         poll(NULL, 0, 1);
53     smp_mb();
54 }
```

Listing 5.5: Per-Thread Statistical Counters

```

1 unsigned long __thread counter = 0;
2 unsigned long *counterp[NR_THREADS] = { NULL };
3 unsigned long finalcount = 0;
4 DEFINE_SPINLOCK(final_mutex);
5
6 static __inline__ void inc_count(void)
7 {
8     WRITE_ONCE(counter, counter + 1);
9 }
10
11 static __inline__ unsigned long read_count(void)
12 {
13     int t;
14     unsigned long sum;
15
16     spin_lock(&final_mutex);
17     sum = finalcount;
18     for_each_thread(t)
19         if (counterp[t] != NULL)
20             sum += READ_ONCE(*counterp[t]);
21     spin_unlock(&final_mutex);
22     return sum;
23 }
24
25 void count_register_thread(unsigned long *p)
26 {
27     int idx = smp_thread_id();
28
29     spin_lock(&final_mutex);
30     counterp[idx] = &counter;
31     spin_unlock(&final_mutex);
32 }
33
34 void count_unregister_thread(int nthreadsexpected)
35 {
36     int idx = smp_thread_id();
37
38     spin_lock(&final_mutex);
39     finalcount += counter;
40     counterp[idx] = NULL;
41     spin_unlock(&final_mutex);
42 }
```

라는 비용을 가집니다.

Quick Quiz 5.17: Listing 5.4 의 inc_count() 는 왜 어토믹 명령을 사용하지 않죠? 쓰레드별 카운터를 여러 쓰레드에서 접근하고 있잖아요! ■

Quick Quiz 5.18: Listing 5.4 의 단일 글로벌 쓰레드인 eventual() 함수는 글로벌 락처럼 큰 병목이 되거나 하진 않나요? ■

Quick Quiz 5.19: Listing 5.4 의 read_count() 에서 리턴하는 추정값은 쓰레드의 갯수가 늘어날수록 부정확해져 가지 않을까요? ■

Quick Quiz 5.20: Listing 5.4 의 최종적 일관성 알고리즘은 읽기에도 쓰기에도 매우 적은 오버헤드와 극단적인 확장성을 보이는데, 과연 누가 Section 5.2.2 같이 읽기 쪽이 비싼 구현을 사용하겠습니까? ■

5.2.4 Per-Thread-Variable-Based Implementation

다행히도, GCC는 쓰레드별 저장소인 `__thread` 스토리지 클래스를 제공합니다. 이 스토리지 클래스는 Listing 5.5 (`count_end.c`)에 보여진 것처럼 확장성을 뿐만 아니라, 간단하고 어토믹하지 않은 증가 방법에 비해 카운트를 증가시키는 쪽에 거의 성능 페널티를 주지 않는 통계적 카운터를 구현하는데 사용될 수 있습니다.

라인 1-4는 필요한 변수들을 정의합니다: `counter`는 쓰레드별 카운터 변수이고, `counterp[]` 배열은 쓰레드들이 다른 쓰레드의 카운터들을 볼 수 있게 하며, `finalcount`는 개별 쓰레드가 끝날 때마다 전체 카운트를 계산해 가지고 있으며, `final_mutex`는 쓰레드들 사이에서 전체 카운트를 계산하는 작업과 종료되는 쓰레드의 종료 작업 사이 동기화를 조정합니다.

Quick Quiz 5.21: 다른 쓰레드의 카운터를 찾는데 왜 별개의 배열이 필요하죠? 왜 GCC는 리눅스 커널이 `per_cpu()`를 통해 쓰레드들이 다른 쓰레드의 쓰레드별 변수를 쉽게 접근할 수 있도록 하는 것처럼 `per_thread()` 같은 인터페이스를 제공하지 않나요? ■

업데이트 쓰레드들에 의해 사용되는 `inc_count()` 함수는 라인 6-9에서 볼 수 있듯이 상당히 간단합니다.

읽기 쓰레드에 의해 사용되는 `read_count()` 함수는 약간 복잡합니다. 라인 16에서 종료되는 쓰레드들을 배제하기 위해 락을 획득하고, 라인 21에서 이 락을 풍니다. 라인 17에서는 이미 종료한 쓰레드들에 의해 계산된 카운트 값으로 카운트의 합을 초기화하고, 라인 18-20에서 현재 동작 중인 쓰레드들에서 얻어온 카운트 값을 더합니다. 마지막으로, 라인 22에서 그 합을 리턴합니다.

Quick Quiz 5.22: Listing 5.5의 라인 19에서의 NULL 체크는 브랜치 예측 실패를 가져오지 않나요? 항상 0인 변수 집합을 두고 더이상 사용되지 않는 카운터로의 포인터를 NULL로 만드는 대신 그 변수로 향하게 하는게 어떤가요? ■

Quick Quiz 5.23: 도대체 왜 Listing 5.5의 `read_count()` 함수의 합을 계산하는 곳에서 무거운 `lock`을 사용하는거죠? ■

라인 25-32는 `count_register_thread()` 함수를 보여주는데, 각 쓰레드는 자신의 카운터를 처음 사용하기 전에 이 함수를 반드시 호출해야 합니다. 이 함수는 단순히 해당 쓰레드를 위한 `counterp[]` 배열의 원소가 자신의 쓰레드별 `counter` 변수를 가리키도록 만듭니다.

Quick Quiz 5.24: 대체 왜 Listing 5.5의 `count_register_thread()` 함수에서 락을 잡아야 하는거죠? 여기서 사용하는건 다른 쓰레드가 접근하지 않는, 제대로 정렬된 기계의 워드 사이즈 데이터에 대한 스토어 오퍼레이션이니 어토믹할 거잖아요, 아닌가요? ■

라인 34-42는 `count_unregister_thread()` 함수

를 보이는데, 각 쓰레드는 종료되기 직전에 반드시 이 함수를 호출해야 합니다. 라인 38에서는 락을 잡고, 라인 41에서 푸는데, 이로써 `read_count()` 호출과 다른 `count_unregister_thread()` 호출을 배제시킵니다. 라인 39에서는 이 쓰레드의 `counter`를 글로벌 `finalcount`에 더하고, 그 후 라인 40에서 자신의 `counterp[]` 배열에서의 원소를 NULL로 만듭니다. 이후의 `read_count()` 호출은 종료된 쓰레드의 카운트는 글로벌 변수 `finalcount`에서 볼 수 있을 것이고, 종료된 쓰레드의 카운터는 `counterp[]` 배열을 통해 무시할 수 있으므로 올바른 전체 값을 얻을 수 있을 것입니다.

이 방법은 업데이트 쓰레드에 어토믹하지 않은 더하기와 거의 똑같은 성능을 주면서도 선형적 확장성을 갖습니다. 반면, 동시적으로 수행되는 읽기 동작은 하나의 글로벌 락을 두고 경쟁하므로 성능과 확장성 모두 최악으로 떨어집니다. 하지만, 카운트의 증가가 주로 일어나고 읽기는 잘 발생하지 않는 통계적 카운터에선 문제가 되지 않습니다. 물론, 이 방법은 쓰레드 종료 시 쓰레드별 변수의 중발 문제 처리로 인해 배열 기반의 방법보다는 좀 더 복잡하긴 합니다.

Quick Quiz 5.25: 좋아요, 하지만 리눅스 커널은 CPU별 카운터의 값을 합칠 때 락을 잡지 않아요. 유저 스페이스 코드에선 왜 이게 필요한거죠? ■

5.2.5 Discussion

이 세가지 구현은 병렬 머신에서 돌아감에도 통계적 카운터가 유니프로세서에서의 성능을 얻는게 가능함을 보여줍니다.

Quick Quiz 5.26: 패킷의 사이즈가 다양하다면 패킷의 갯수를 세는 것과 패킷의 전체 바이트 수를 세는 것에 어떤 기본적 차이가 있나요? ■

Quick Quiz 5.27: 읽기 쓰레드는 쓰레드들의 카운터를 모두 더해야 하므로, 쓰레드의 갯수가 들어나면 더 많은 시간을 쓰게 될겁니다. 읽기 쓰레드에게도 쓸만한 성능과 확장성을 주면서 쓰기 작업도 여전히 빠르고 확장성 있게 하는 방법은 없을까요? ■

이 섹션에서 이야기된 것을 바탕으로, 독자 여러분은 이제 이 챕터의 시작에 있던 네트워킹에 대한 통계적 카운터에 관한 Quick Quiz에 답변을 할 수 있을 겁니다.

5.3 Approximate Limit Counters

Errors using inadequate data are much less than those using no data at all.

Charles Babbage

카운팅에 관계된 또 다른 특수 케이스는 한계점 체크

입니다. 예를 들면, 5.3의 대략적인 구조체 할당 한계 문제처럼, 할당된 구조체의 갯수를 세고 있다가 할당된 구조체의 갯수가 특정 한계치, 이 경우, 10,000을 넘어가면 이어지는 할당을 실패 처리해야 하는 경우를 생각해 봅시다. 이 구조체들은 또한 잠시동안만 사용되어서, 한계치는 가끔만 초과되며, 이 한계치는 대략적이어서 어느정도까지는 넘어가도 되는 경우를 생각해 봅시다 (한계치가 정확해야 한다면 Section 5.4를 참고하세요).

5.3.1 Design

한계 카운터를 위해 사용할 수 있을 설계 중 하나는 한계치 10,000을 쓰레드의 수로 나눠서 각 쓰레드에게 크기가 고정된 구조체 풀을 주는 것입니다. 예를 들어, 100개의 쓰레드가 있다면, 각 쓰레드가 100개의 구조체를 갖는 풀을 관리하게 하는 것입니다. 이 방법은 간단하고, 어떤 경우에는 잘 동작합니다만, 구조체를 할당하는 쓰레드와 해제하는 쓰레드가 다른 많은 경우 [MS93]에는 동작하지 못합니다. 일단, 만약 한 쓰레드가 자신이 해제하는 모든 구조체에 대해 관리 책임을 갖는다면, 대부분의 해제를 하는 쓰레드가 구조체 해제 처리를 하느라 바쁜 동안 대부분의 할당을 하는 쓰레드는 풀의 구조체가 바닥나게 할겁니다. 다른 한편, 구조체를 할당한 CPU에게 해당 구조체의 메모리 해제 책임이 있다면, CPU들은 다른 CPU들의 카운터를 모두 돌아봐야 할 거고, 이는 비싼 어토믹 명령이나 다른 쓰레드간 통신 비용을 발생시킬 것입니다.²

짧게 말해서, 완전히 분할된 카운터는 많은 중요 워크로드에서 사용할 수 없습니다. 카운터를 분할하는 방법은 Section 5.2에서 이야기한 세가지 방법에서 훌륭한 업데이트 쪽 성능을 가져온 방법이었으나, 비관적으로 보일 수도 있겠습니다. 하지만, Section 5.2.3에서 보여진 최종적 일관성 (eventually consistent) 알고리즘이 흥미로운 힌트를 제공합니다. 이 알고리즘은 업데이트를 위한 쓰레드별 counter 변수와 읽기를 위한 `global_count` 변수 두개의 저장소를 유지하고, 주기적으로 `global_count`를 업데이트해서 최종적으로는 쓰레드별 counter의 값과 `global_count`를 일관되게 만들어주는 `eventual()` 쓰레드를 운용합니다. 쓰레드별 counter는 카운터 값을 완벽하게 분할했고 `global_count`는 전체 값을 유지합니다.

한계 카운터를 위해 우리는 이 방법의 변종을 사용할 수 있는데, 카운터를 부분적으로 분할하는 것입니다. 예를 들어, 네개의 쓰레드가 각각 쓰레드별 counter를 가질 수 있지만, 각각은 또한 쓰레드별 최대값 (`countermax`라고 해봅시다)을 가지는 것입니다.

하지만, 한 쓰레드가 자신의 `counter`의 값을 증가시키려 하는데, `counter`의 값이 자신의 `countermax`와 동일하면 어떻게 될까요? 그 쓰레드의 `counter` 값의 절반을 `globalcount`로 옮기고, `counter`를 증가시키는 트릭을 씁니다. 예를 들어, 한 쓰레드의 `counter`와 `countermax` 변수가 똑같이 10이라면, 다음의 일을 합니다:

1. 글로벌 락을 잡는다.
2. `globalcount`에 5를 더한다.
3. 앞의 합과 균형을 맞추기 위해, 이 쓰레드의 `counter`에서 5를 뺀다.
4. 글로벌 락을 놓는다.
5. 이 쓰레드의 `counter`의 값을 증가시켜서 6으로 만든다.

이 방법은 여전히 글로벌 락을 필요로 하지만, 그 락은 다섯번의 증가 오퍼레이션마다 한번씩만 사용되므로, 락 경쟁을 상당히 줄여줄 겁니다. 이 경쟁의 정도는 `countermax` 값을 올려줌으로써 필요한 정도까지 낮춰 줄 수 있습니다. 하지만, `countermax`를 늘리는데 대한 페널티가 존재하는데 `globalcount`의 정확도가 떨어진다는 점입니다. 예를 들어 4개 CPU가 있는 시스템에서 `countermax`는 10이라 하면 `globalcount`는 최대 40의 어려값을 가질 수 있습니다. 반면, `countermax`가 100 까지 늘어나면, `globalcount`는 최대 400의 어려값을 가질 수 있습니다.

이는 `globalcount`와, `globalcount`와 각 쓰레드의 `counter` 변수의 값의 합으로 만들어지는 값 사이의 차이를 얼마나 많이 신경써야 하나 하는 질문을 가져옵니다. 답은 합으로 만들어진 값이 카운터의 리미트 (`globalcountmax`라고 해두죠)와 얼마나 차이가 나나에 달려 있습니다. 이 두 값 사이의 차이가 크면 클수록 `countermax`는 `globalcountmax` 리미트를 넘지는 않는다는 한계 내에서 커져도 괜찮습니다. 이 말은 주어진 쓰레드의 `countermax` 변수는 이 차이에 맞춰 설정될 수 있다는 겁니다. 한계점이 한참 남았다면, `countermax` 쓰레드별 변수는 성능과 확장성을 위한 최적화를 위해 큰 값을 가질 수 있고, 반대로 한계점이 가깝다면, 이 값들은 `globalcountmax` 리미트에의 체크의 어려움을 줄이기 위해 작은 값으로 설정되어야 합니다.

이 디자인은 일반적인 경우는 쓰레드간의 상호작용과 비싼 동작 없이 수행하되 결국 사용해야만 할 때에는 보수적으로 설계된 (그리고 오버헤드가 큰) 알고리즘을 사용하는 유명한 디자인 패턴인 병렬 패스트패스 (*parallel fastpath*)의 한 예입니다. 이 디자인 패턴은 Section 6.4에서 더 자세히 다룹니다.


² 그렇지만, 만약 각 구조체가 항상 같은 CPU (또는 쓰레드)에 의해 해제된다면, 이 간단한 쪼개기 전략은 매우 잘 동작합니다.

Listing 5.6: Simple Limit Counter Variables

```

1 unsigned long __thread counter = 0;
2 unsigned long __thread countermax = 0;
3 unsigned long globalcountmax = 10000;
4 unsigned long globalcount = 0;
5 unsigned long globalreserve = 0;
6 unsigned long *counterp[NR_THREADS] = { NULL };
7 DEFINE_SPINLOCK(gblcnt_mutex);

```

**Figure 5.5:** Simple Limit Counter Variable Relationships

5.3.2 Simple Limit Counter Implementation

Listing 5.6 는 이 구현에서 사용되는 쓰레드별 변수들과 글로벌 변수를 보여줍니다. 쓰레드별 `counter` 와 `countermax` 변수들은 각각 연관되는 쓰레드의 로컬 카운터와 그 카운터의 최대 허용값입니다. 라인 3 의 `globalcountmax` 변수는 합계 카운터의 최대값을 가지며, 라인 4 의 `globalcount` 변수는 글로벌 카운터입니다. `globalcount` 와 각 쓰레드의 `counter` 의 합은 전체 카운터의 합산 값이 됩니다. 라인 5 의 `globalreserve` 변수는 모든 쓰레드별 `countermax` 변수의 값의 합입니다. 이 변수들 간의 관계가 Figure 5.5 에 나타나 있습니다:

1. `globalcount` 와 `globalreserve` 의 합은 `globalcountmax` 보다 작거나 같아야만 합니다.
2. 모든 쓰레드의 `countermax` 값의 합은 `globalreserve` 보다 작거나 같아야만 합니다.
3. 각 쓰레드의 `counter` 는 해당 쓰레드의 `countermax` 보다 작거나 같아야만 합니다.

Listing 5.7: Simple Limit Counter Add, Subtract, and Read

```

1 static __inline__ int add_count(unsigned long delta)
2 {
3     if (countermax - counter >= delta) {
4         WRITE_ONCE(counter, counter + delta);
5         return 1;
6     }
7     spin_lock(&gblcnt_mutex);
8     globalize_count();
9     if (globalcountmax -
10         globalcount - globalreserve < delta) {
11         spin_unlock(&gblcnt_mutex);
12         return 0;
13     }
14     globalcount += delta;
15     balance_count();
16     spin_unlock(&gblcnt_mutex);
17     return 1;
18 }
19
20 static __inline__ int sub_count(unsigned long delta)
21 {
22     if (counter >= delta) {
23         WRITE_ONCE(counter, counter - delta);
24         return 1;
25     }
26     spin_lock(&gblcnt_mutex);
27     globalize_count();
28     if (globalcount < delta) {
29         spin_unlock(&gblcnt_mutex);
30         return 0;
31     }
32     globalcount -= delta;
33     balance_count();
34     spin_unlock(&gblcnt_mutex);
35     return 1;
36 }
37
38 static __inline__ unsigned long read_count(void)
39 {
40     int t;
41     unsigned long sum;
42
43     spin_lock(&gblcnt_mutex);
44     sum = globalcount;
45     for_each_thread(t)
46         if (counterp[t] != NULL)
47             sum += READ_ONCE(*counterp[t]);
48     spin_unlock(&gblcnt_mutex);
49     return sum;
50 }

```

`counterp[]` 배열의 각 원소는 연관된 쓰레드의 `counter` 변수를 가리키며, 마지막으로, `gblcnt_mutex` 스픈락은 모든 글로벌 변수들을 보호하는데, 달리 말하자면 `gblcnt_mutex` 를 잡지 못했다면 모든 쓰레드는 어떤 글로벌 변수들도 접근하거나 수정하지 못합니다.

Listing 5.7 (`count_lim.c`) 은 `add_count()`, `sub_count()`, 그리고 `read_count()` 함수를 보이고 있습니다.

Quick Quiz 5.28: 어째서 Listing 5.7 는 Section 5.2 에서 나왔던 `inc_count()` 와 `dec_count()` 인터페이스 대신에 `add_count()` 와 `sub_count()` 를 제공하나요?

■

라인 1-18 은 `add_count()` 를 보여주는데, 이 함수

는 특정값 `delta`를 카운터에 더합니다. 라인 3에서는 `delta`를 위한 공간이 이 쓰레드의 `counter`에 남아 있는지 확인하고, 만약 그렇다면 라인 4에서 그 값을 더하고 라인 5에서 성공했음을 리턴합니다. 이게 `add_counter()`의 가장 빠른 수행경로로, 어토믹 오퍼레이션을 하지 않으며, 쓰레드별 변수만 참조하므로 어떤 캐시 미스도 만들지 않을 겁니다.

Quick Quiz 5.29: Listing 5.7 line 3의 저 이상한 조건은 뭔가요? 왜 다음과 같이 더 직관적인 형태의 빠른 수행경로를 사용하지 않는거죠?

```
3 if (counter + delta <= countermax) {
4     counter += delta;
5     return 1;
6 }
```

라인 3에서의 테스트가 실패한다면, 글로벌 변수들에 접근해야 하므로, 라인 7의 `gblcnt_mutex`를 반드시 잡아야 하고, 이 락은 실패하는 경우 라인 16에서, 성공하는 경우는 라인 11에서 놓아집니다. 라인 8에서는 Listing 5.8의 `globalize_count()`를 호출하는데, 이 함수는 쓰레드 로컬 변수들을 초기화하고, 글로벌 변수들을 필요한 대로 맞춰줘서 전역적인 처리를 단순화시킵니다. (하지만 제 말을 믿지만 말고, 직접 코딩해보세요!) 라인 9와 10에서는 `delta`를 더하는 것이 합법적인지 Listing 5.5에서 가장 왼쪽 두 빨간 막대의 높이 차이로 나타난 크기 규칙이 지켜지는지로 체크합니다. `delta`의 합이 이루어져선 안된다면, 라인 11은 (앞서 이야기했듯) `gblcnt_mutex`를 풀고 라인 12에서 실패를 알리는 리턴을 합니다.

만약 아니라면, 느린 수행경로를 실행하게 됩니다. 라인 14는 `delta`를 `globalcount`에 더하고, 라인 15에서 글로벌 변수들과 쓰레드별 변수들을 모두 업데이트하기 위해 (Listing 5.8에서 나왔던) `balance_count()`를 호출합니다. 이 `balance_count()` 호출은 대부분의 경우 이 쓰레드가 다음엔 빠른 수행경로로 수행되도록 `countermax`를 조정할 것입니다. 그러고나서 라인 16에서 `gblcnt_mutex`를 (역시 앞에서 언급했듯) 놓아주고, 마지막으로 라인 17에서 성공을 의미하는 값을 리턴 합니다.

Quick Quiz 5.30: Listing 5.7에서 왜 `globalize_count()`는 나중에 `balance_count()`가 쓰레드별 변수를 다시 채우도록 쓰레드별 변수를 0으로 바꾸나요? 왜 그냥 쓰레드별 변수를 0이 아닌 채로 놔두질 않는거죠? ■

라인 20-36은 `sub_count()` 함수를 보여주는데, 이 함수는 `delta`만큼을 카운터에서 제거합니다. 라인 22는 쓰레드별 카운터를 체크해서 이 빼기를 해도 되는지 보고, 만약 그렇다면 라인 23에서 그 빼기를 수행한 후 라인 24에서 성공을 리턴합니다. 이 부분들이 `add_count()`에서의 그것과 같은 `sub_count()`의 빠른

수행경로로, 이 경로에서는 비용이 심한 동작은 하지 않습니다.

빠른 수행경로에서 `delta`의 빼기가 적절치 못하다고 판단된다면, 실행은 라인 26-35의 느린 수행경로로 이어집니다. 느린 실행 경로는 글로벌 상태에 접근해야 하기 때문에, 라인 26에서 `gblcnt_mutex`를 잡고, 이 락은 (실패의 경우) 라인 29에서, 또는 (성공의 경우) 라인 34에서 해제됩니다. 라인 27은 Listing 5.8의 `globalize_count()`를 실행하는데, 앞서 설명했듯 쓰레드 로컬 변수의 값을 지우고, 글로벌 변수들을 적당한 값으로 설정합니다. 라인 28은 카운터가 `delta`의 빼기를 해도 좋을지 보고, 좋지 않다면 라인 29에서 `gblcnt_mutex`를 (앞서 설명했듯) 해제하고 라인 30에서 실패를 리턴합니다.

Quick Quiz 5.31: Listing 5.7에서 `globalreserve`는 `add_count()`에서 값이 구해지는데, 왜 `sub_count()`에서 값을 구하지 않나요? ■

Quick Quiz 5.32: 한 쓰레드가 Listing 5.7의 `add_count()`를 호출하고, 다른 쓰레드가 `sub_count()`를 호출한다고 해봅시다. `sub_count()`는 카운터의 값이 0이 아님에도 실패하지 않겠습니까? ■

한편, 만약 라인 28에서 카운터가 `delta` 빼기를 해도 적합하다고 판단되면, 느린 수행경로를 걷게 됩니다. 라인 32에서 실제 빼기를 행하게 되고, 이후 라인 33에서 (Listing 5.8에 나온) `balance_count()`를 호출해서 글로벌 변수들과 쓰레드별 변수들을 모두 (가능하면 다음엔 빠른 수행경로로 돌 수 있도록) 업데이트 합니다. 라인 34에서는 `gblcnt_mutex`를 해제하고, 라인 35에서 성공을 리턴합니다.

Quick Quiz 5.33: Listing 5.7에서는 왜 `add_count()`와 `sub_count()`를 모두 가지고 있는 거죠? 그냥 `add_count()`에 음수를 넘기면 되지 않나요? ■

라인 38-50은 `read_count()`를 보이는데, 이 함수는 카운터의 합산된 값을 리턴합니다. 먼저 라인 48에서 해제하는 `gblcnt_mutex`를 라인 43에서 잡는데, 이 락으로 `add_count()`와 `sub_count()`의 글로벌한 동작들을 배제시키고, 또한 쓰레드 생성과 종료 역시 배제시킵니다. 라인 44는 로컬 변수 `sum`을 `globalcount`의 값으로 초기화하고, 라인 45-47의 루프는 쓰레드별 `counter` 변수의 합을 구합니다. 그러고나서 라인 49에서 합을 리턴합니다.

Listing 5.8에서는 Listing 5.7에서 봤던 `add_count()`, `sub_count()`, and `read_count()`에서 사용하던 함수들을 보입니다.

라인 1-7은 `globalize_count()` 함수인데, 이 함수는 현 쓰레드의 쓰레드별 카운터를 0으로 만들고, 글로벌 변수들을 적당한 값으로 만듭니다. 이 함수는 카운터의 합산값을 바꾸진 않지만 어떻게 카운터의 현재 값이 보여야 하는지를 바꾼다는 점이 중요합니다. 라인 3은

Listing 5.8: Simple Limit Counter Utility Functions

```

1 static __inline__ void globalize_count(void)
2 {
3     globalcount += counter;
4     counter = 0;
5     globalreserve -= countermax;
6     countermax = 0;
7 }
8
9 static __inline__ void balance_count(void)
10 {
11     countermax = globalcountmax -
12         globalcount - globalreserve;
13     countermax /= num_online_threads();
14     globalreserve += countermax;
15     counter = countermax / 2;
16     if (counter > globalcount)
17         counter = globalcount;
18     globalcount -= counter;
19 }
20
21 void count_register_thread(void)
22 {
23     int idx = smp_thread_id();
24
25     spin_lock(&gblcnt_mutex);
26     counterp[idx] = &counter;
27     spin_unlock(&gblcnt_mutex);
28 }
29
30 void count_unregister_thread(int nthreadsexpected)
31 {
32     int idx = smp_thread_id();
33
34     spin_lock(&gblcnt_mutex);
35     globalize_count();
36     counterp[idx] = NULL;
37     spin_unlock(&gblcnt_mutex);
38 }

```

쓰레드의 counter 변수를 globalcount 에 더하고 라인 4 는 counter 를 0 으로 만듭니다. 비슷하게, 라인 5 는 쓰레드별 countermax 를 globalreserve 에서 빼고, 라인 6 은 countermax 를 0 으로 만듭니다. 이어서 설명될 balance_count() 함수와 이 함수를 함께 이해 하려면 Figure 5.5 를 참고하는게 도움이 될겁니다.

라인 9-19 는 balance_count() 함수를 보이는데, 이 함수는 간단히 말해서 globalize_count() 의 반대입니다. 이 함수가 하는일은 현 쓰레드의 countermax 변수를 카운터가 globalcountmax 한계치를 넘지 않는 한계에서 가장 큰 값을 갖도록 하는 것입니다. 현재 쓰레드의 countermax 변수를 바꾸기 위해선 Figure 5.5 에서 보여진 규칙을 지키도록 counter, globalcount, 그리고 globalreserve 역시 적절하게 조정해야 합니다. 이렇게 함으로써, balance_count() 는 add_count() 와 sub_count() 의 오버헤드가 적은 빠른 수행경로의 수행을 최대화 합니다. globalize_count() 와 마찬가지로, balance_count() 는 카운터의 합산값을 바꾸지 못합니다.

라인 11-13 은 globalcount 나 globalreserve 로 다뤄지지 않은 globalcountmax 에서 이 쓰레드의 지

분을 계산하고, 계산된 값을 이 쓰레드의 countermax 에 대입합니다. 라인 14 는 globalreserve 를 올바르게 조정합니다. 라인 15 는 이 쓰레드의 counter 를 countermax 절반으로 만듭니다. 라인 16 은 이 counter 값이 규칙을 깨지 않는 선에서 가능한 값인지 globalcount 를 보고, 그렇지 않다면 라인 17 에서 counter 를 적절하게 감소시킵니다. 앞의 조건과 관계없이 마지막으로, 라인 18 에서는 globalcount 를 적절하게 조정합니다.

Quick Quiz 5.34: Listing 5.8 의 라인 15 에서는 왜 counter 를 countermax / 2 로 만들죠? 그냥 countermax 값을 가져오는게 더 간단하지 않나요? ■

Figure 5.6 에 그린 것처럼 globalize_count() 와 balance_count 에 의해서 카운터 값들이 어떻게 바뀌는지 개요를 그려보는 게 도움이 될 겁니다. 시간은 왼쪽에서 오른쪽으로 흐르고, 가장 왼쪽의 구성은 Figure 5.5 에 보인 것과 대략적으로 같습니다. 중간의 구성은 globalize_count() 가 쓰레드 0 에 의해 수행되고 난 후의 각 카운터들의 관계입니다. 그림에서 볼 수 있듯, 쓰레드 0 의 counter (그림에서의 “c 0”) 는 globalcount 에 더해지고, globalreserve 는 그만큼 줄었습니다. 쓰레드 0 의 counter 와 countermax (그림에서의 “cm 0”) 는 0 이 되었습니다. 다른 세 쓰레드의 카운터들은 그대로입니다. 가장 왼쪽 구성과 중간 구성 사이의 바닥쪽 점선을 보면 알 수 있듯이 이 변화는 전체 카운터의 값을 바꾸지 않았음을 참고하십시오. 바꿔 말하자면, globalcount 와 네 쓰레드의 counter 변수들의 값의 합은 두 구성 모두에서 동일합니다. 비슷하게, 위쪽 점선을 보면 알 수 있듯이, 이 변경은 globalcount 와 globalreserve 의 합에도 어떤 영향을 끼치거나 하지 않았습니다.

가장 오른쪽의 구성은 쓰레드 0 에 의해 balance_count() 가 수행된 이후의 카운터들의 관계를 보여줍니다. 다른 두개의 구성에 비해 올라간 수직의 선으로 보여지듯, 남은 카운트의 4분의 1이 쓰레드 0 의 countermax 에, 절반이 쓰레드 0 의 counter 에 더해졌습니다. 쓰레드 0 의 counter 에 더해진 양은 가운데와 오른쪽 구성의 가장 아래쪽의 두개의 점선으로 보여지듯이 전체 카운터의 값 (globalcount 와 세 쓰레드의 counter 변수의 값의 합) 을 바꾸지 않기 위해 globalcount 에서 빼졌습니다. globalreserve 변수 또한 이 변수가 네 쓰레드의 countermax 변수의 합과 동일하게 조정되었습니다. 쓰레드 0 의 counter 는 해당 쓰레드의 countermax 보다 작기 때문에, 쓰레드 0 은 또다시 자신의 카운터에서 곧바로 카운트 증가를 할 수 있습니다.

Quick Quiz 5.35: Figure 5.6 에서 보면, 가운데와 오른쪽 구성의 점선을 보면 알 수 있듯이, 한계까지 남은 카운트의 4분의 1이 쓰레드 0 에게 주어졌




Figure 5.6: Schematic of Globalization and Balancing

음에도, 8분의 1 만이 사용되었습니다. 왜 그런건가요?

■ 라인 21-28 은 `count_register_thread()` 함수인데, 이 함수는 새로 생성된 쓰레드를 위한 상태를 만듭니다. 이 함수는 단순히 새로 생성된 쓰레드의 `counter` 변수로의 포인터를 상응하는 `counterp[]` 배열에서의 원소에 `gblcnt_mutex` 의 보호 아래 설정합니다.

마지막으로, 라인 30-38 은 `count_unregister_thread()` 함수를 보여주는데, 이 함수는 곧 종료될 쓰레드를 위해 상태를 정리합니다. 라인 34 에서는 라인 37에서 해제될 `gblcnt_mutex` 를 잡습니다. 라인 35 에서는 `globalize_count()` 를 호출해서 이 쓰레드의 카운터 상태를 정리하고, 라인 36 에서 이 쓰레드의 `counterp[]` 배열에서의 상응하는 원소를 정리합니다.

5.3.3 Simple Limit Counter Discussion

이 유형의 카운터는 `add_count()` 와 `sub_count()` 의 빠른 수행경로에서의 비교문과 브랜치로 인한 약간의 오버헤드가 있지만 합산값이 0에 가까울 때엔 매우 빠릅니다. 하지만, 쓰레드별 `coutnermax` 의 사용으로 인해 카운터의 합산값은 `globalcountmax` 근처도 안갔는데도 `add_count()` 가 실패할 수도 있습니다. 비슷하게, `sub_count()` 는 합산값이 0 근처도 안갔는데 실패할 수 있습니다.

이는 많은 경우에 문제가 됩니다. 설령

Listing 5.9: Approximate Limit Counter Variables

```

1 unsigned long __thread counter = 0;
2 unsigned long __thread countermax = 0;
3 unsigned long globalcountmax = 10000;
4 unsigned long globalcount = 0;
5 unsigned long globalreserve = 0;
6 unsigned long *counterp[NR_THREADS] = { NULL };
7 DEFINE_SPINLOCK(gblcnt_mutex);
8 #define MAX_COUNTERMAX 100

```

`globalcountmax` 가 대략적인 한계치로 의도되었다고 해도, 얼마나 대략적으로 조정되어야 하는지에 대한 한계가 일반적으로 존재합니다. 추정 정도를 제한하는 한 방법은 쓰레드별 `coutnermax` 인스턴스의 값에 최대값 한계를 내포시키는 겁니다. 이 방법이 다음 섹션에서 사용됩니다.

5.3.4 Approximate Limit Counter Implementation

이 구현 (`count_lim_app.c`) 은 앞 섹션의 것 (Listing 5.6, 5.7, 그리고 5.8)들과 상당히 비슷하기 때문에, 여기에선 다른 부분만 이야기 합니다. Listing 5.9 는 쓰레드별 `countermax` 의 허용되는 최대값을 나타내는 `MAX_COUNTERMAX` 가 추가되었다는 점을 제외하곤 Listing 5.6 와 똑같습니다.

비슷하게, Listing 5.10 는 라인 6 과 7 에서 쓰레드

Listing 5.10: Approximate Limit Counter Balancing

```

1 static void balance_count(void)
2 {
3     countermax = globalcountmax -
4         globalcount - globalreserve;
5     countermax /= num_online_threads();
6     if (countermax > MAX_COUNTERMAX)
7         countermax = MAX_COUNTERMAX;
8     globalreserve += countermax;
9     counter = countermax / 2;
10    if (counter > globalcount)
11        counter = globalcount;
12    globalcount -= counter;
13 }

```

별 countermax 변수에 MAX_COUNTERMAX 한계를 적용하는 내용이 추가된 걸 제외하고는 Listing 5.8 의 balance_count() 함수와 동일합니다.

5.3.5 Approximate Limit Counter Discussion

이런 차이점들은 앞 섹션에서 보았던 한계치의 비정확성을 크게 줄여줍니다만, 다른 문제를 드러냅니다: MAX_COUNTERMAX 값은 워크로드에 따라 빠른 수행경로 접근 비율을 달라지게 합니다. 쓰레드의 수가 늘어나면, 빠른 수행경로 이외의 경로를 통하는 것은 성능과 확장성에 모두 문제가 될겁니다. 하지만, 이 문제는 일단 미뤄두고 정확한 한계치를 갖는 카운터에 대해 이야기해 봅시다.

5.4 Exact Limit Counters

Exactitude can be expensive. Spend wisely

Unknown

5.4에서 이야기한, 정확한 구조체 할당 한계 문제를 풀기 위해선 그 한계를 넘겼을 때 정확히 알려주는 리미트 카운터가 필요합니다. 그런 리미트 카운터를 구현하는 방법 중 한가지는 예약된 카운트를 가지고 있는 쓰레드들이 예약된 값을 넘겼을 때 카운터 사용을 포기하게 하는 것입니다. 이렇게 하는 방법 중 하나는 어토믹 인스트럭션을 사용하는 것입니다. 물론, 어토믹 인스트럭션들은 빠른 수행경로를 느리게 만듭니다만, 시도조차 해보지 않는 것도 우스운 일일 겁니다.

5.4.1 Atomic Limit Counter Implementation

불행히도, 한 쓰레드가 다른 쓰레드의 카운트를 안전하게 없애려면, 두 쓰레드 모두 각자의 counter 와 countermax 변수를 함께 어토믹하게 조정해야 할 겁니다. 이걸 해결하는 일반적인 방법은, 예를 들어 32-비트

Listing 5.11: Atomic Limit Counter Variables and Access Functions

```

1 atomic_t __thread counterandmax = ATOMIC_INIT(0);
2 unsigned long globalcountmax = 1 << 25;
3 unsigned long globalcount = 0;
4 unsigned long globalreserve = 0;
5 atomic_t *counterp[NR_THREADS] = { NULL };
6 DEFINE_SPINLOCK(gblcnt_mutex);
7 #define CM_BITS (sizeof	atomic_t) * 4
8 #define MAX_COUNTERMAX ((1 << CM_BITS) - 1)
9
10 static __inline__ void
11 split_counterandmax_int(int cami, int *c, int *cm)
12 {
13     *c = (cami >> CM_BITS) & MAX_COUNTERMAX;
14     *cm = cami & MAX_COUNTERMAX;
15 }
16
17 static __inline__ void
18 split_counterandmax(atomic_t *cam, int *old, int *c, int *cm)
19 {
20     unsigned int cami = atomic_read(cam);
21
22     *old = cami;
23     split_counterandmax_int(cami, c, cm);
24 }
25
26 static __inline__ int merge_counterandmax(int c, int cm)
27 {
28     unsigned int cami;
29
30     cami = (c << CM_BITS) | cm;
31     return ((int)cami);
32 }

```

변수가 있다면, 앞쪽 16 비트는 counter를, 뒷쪽 16 비트는 countermax 를 나타내게 하는 식으로 두 변수를 한개의 변수로 합치는 것입니다.

Quick Quiz 5.36: 쓰레드의 counter 와 countermax 변수를 한번에 어토믹하게 수정해야 하는 이유가 뭐죠? 각 변수를 개별적으로 어토믹하게 수정해도 충분하지 않나요? ■

간단한 어토믹 리미트 카운터를 위한 변수와 액세스 함수들을 Listing 5.11 (count_lim_atomic.c)에 보였습니다. 앞의 알고리즘에서의 counter 와 countermax 변수들은 라인 1에 있는 하나의 변수 ctrandmax 의 앞쪽 절반에 counter 가, 뒷쪽 절반에는 countermax 가 위치하도록 합쳐졌습니다. 이 변수는 결국 int 인 atomic_t 타입입니다.

라인 2-6은 globalcountmax, globalcount, globalreserve, counterp, 그리고 gblcnt_mutex의 정의를 보이는데, 이들은 Listing 5.9에 있는 것들과 비슷한 역할을 합니다. 라인 7은 ctrandmax의 각 절반에 사용되는 비트의 수를 나타내는 CM_BITS를 정의하고, 라인 8에서는 ctrandmax의 각 절반이 가질 수 있는 최대값을 나타내는 MAX_COUNTERMAX를 정의합니다.

Quick Quiz 5.37: Listing 5.11의 line 7에서는 C 표준을 어기는거 아닌가요? ■

라인 10-15는 split_ctrandmax_int() 함수를

보여주는데, 이 함수는 `atomic_t` `ctrandmax` 변수로부터 얻어온 `int` 값을 받아서, `counter` (`c`) 와 `countermax` (`cm`) 으로 조깁니다. 라인 13 은 이 `int`로부터 앞쪽 절반을 빼어내어 인자로 받은 `c` 에 넣고, 라인 14 에서는 뒷쪽 절반을 빼어내어 인자로 받은 `cm`에 넣습니다.

라인 17-24 는 `split_ctrandmax()` 함수를 보여주는데, 이 함수는 라인 20 에서 주어진 변수로부터 `int` 값을 읽어내고, 라인 22 에서 그 값을 인자로 받은 `old`에 저장하고, 라인 23 에서 `split_ctrandmax_int()` 를 호출해 조개는 작업을 합니다.

Quick Quiz 5.38: `ctrandmax` 변수는 하나 뿐인데, Listing 5.11 의 라인 18에서는 왜 굳이 포인터로 받는거죠? ■

라인 26-32 은 `merge_ctrandmax()` 함수인데, 이 함수는 `split_ctrandmax()` 함수의 반대의 일을 하는 것으로 볼 수 있습니다. 라인 30 에서 `c` 와 `cm` 으로 받은 `counter` 와 `countermax` 값을 합쳐서 그 결과값을 리턴합니다.

Quick Quiz 5.39: Why does `merge_` `counterandmax()` in Listing 5.11 return an `int` rather than storing directly into an `atomic_t`? ■

Listing 5.12 는 `add_count()` 와 `sub_count()` 함수를 보입니다.

라인 1-32 는 `add_count()` 함수를 보이는데, 이 함수는 라인 8-?? 에 빠른 수행 경로가, 나머지에는 느린 수행경로가 있습니다. 빠른 수행경로의 라인 8-14 는 라인 13-14 에서 실제 CAS 를 `atomic_cmpxchg()` 함수로 수행하는 compare-and-swap (CAS) 루프를 구성합니다. 라인 9 는 현재 쓰레드의 `ctrandmax` 변수를 `counter` (`c`) 와 `countermax` (`cm`) 로 조개고, 기존의 `ctrandmax` 가 갖는 `int` 값을 `old` 에 넣어 둡니다. 라인 10 에서는 `delta` 값이 로컬하게 처리 가능할지 (인티저 오버플로 우를 막기 위한 처리를 하면서) 체크하고, 만약 그렇지 않다면 라인 11 의 느린 수행경로를 밟게 됩니다. 로컬하게 처리 가능하다면, 라인 12 에서 업데이트된 `counter` 값을 원본 `countermax` 값과 조합해서 `new` 를 만듭니다. 라인 13-14 에서는 `atomic_cmpxchg()` 함수를 이용해 이 쓰레드의 `ctrandmax` 변수를 `old` 와 어도막하게 비교하고, 만약 비교 결과 같다면 그 값을 `new` 로 어도막하게 업데이트 합니다. 만약 비교 결과가 같다면 라인 15 에서 성공을 리턴하고, 그렇지 않았다면 라인 8 의 루프에서 실행을 계속합니다.

Quick Quiz 5.40: 우웩! Listing 5.12 라인 11 의 저더러운 `goto` 는 웬건가요? `break` 모르시나요???

Quick Quiz 5.41: Listing 5.12 의 라인 ??-14 의 `atomic_cmpxchg()` 함수는 어떻게 실패할 수 있죠? 우린 이전 값을 라인 9 에서 가져오고 나서 바꾼 적 없잖아요! ■

Listing 5.12: Atomic Limit Counter Add and Subtract

```

1 int add_count(unsigned long delta)
2 {
3     int c;
4     int cm;
5     int old;
6     int new;
7
8     do {
9         split_counterandmax(&counterandmax, &old, &c, &cm);
10        if (delta > MAX_COUNTERMAX || c + delta > cm)
11            goto slowpath;
12        new = merge_counterandmax(c + delta, cm);
13    } while (atomic_cmpxchg(&counterandmax,
14                           old, new) != old);
15    return 1;
16 slowpath:
17     spin_lock(&gblcnt_mutex);
18     globalize_count();
19     if (globalcountmax - globalcount -
20         globalreserve < delta) {
21         flush_local_count();
22         if (globalcountmax - globalcount -
23             globalreserve < delta) {
24             spin_unlock(&gblcnt_mutex);
25             return 0;
26         }
27     }
28     globalcount += delta;
29     balance_count();
30     spin_unlock(&gblcnt_mutex);
31     return 1;
32 }
33
34 int sub_count(unsigned long delta)
35 {
36     int c;
37     int cm;
38     int old;
39     int new;
40
41     do {
42         split_counterandmax(&counterandmax, &old, &c, &cm);
43         if (delta > c)
44             goto slowpath;
45         new = merge_counterandmax(c - delta, cm);
46     } while (atomic_cmpxchg(&counterandmax,
47                           old, new) != old);
48     return 1;
49 slowpath:
50     spin_lock(&gblcnt_mutex);
51     globalize_count();
52     if (globalcount < delta) {
53         flush_local_count();
54         if (globalcount < delta) {
55             spin_unlock(&gblcnt_mutex);
56             return 0;
57         }
58     }
59     globalcount -= delta;
60     balance_count();
61     spin_unlock(&gblcnt_mutex);
62     return 1;
63 }
```

Listing 5.13: Atomic Limit Counter Read

```

1 unsigned long read_count(void)
2 {
3     int c;
4     int cm;
5     int old;
6     int t;
7     unsigned long sum;
8
9     spin_lock(&gblcnt_mutex);
10    sum = globalcount;
11    for_each_thread(t)
12        if (counterp[t] != NULL) {
13            split_counterandmax(counterp[t], &old, &c, &cm);
14            sum += c;
15        }
16    spin_unlock(&gblcnt_mutex);
17    return sum;
18 }

```

Listing 5.12 의 라인 16-31 은 `add_count()` 의 느린 수행경로를 보이는데, 라인 17 에서 얻어오고 라인 24 와 30 에서 해제하는 `gblcnt_mutex` 로 보호됩니다. 라인 18 에서는 `globalize_count()` 를 호출하는데, 이 함수는 이 쓰레드의 상태를 글로벌 카운터로 옮겨줍니다. 라인 19-20 은 `delta` 값이 현재의 글로벌 상태에 사용 가능한지 체크하고, 불가능하다면 라인 21 에서 `flush_local_count()` 를 호출해서 모든 쓰레드의 로컬 스테이트를 글로벌 카운터로 몰아넣고, 라인 22-23 에서 `delta` 가 이제는 사용 가능한지 다시 체크합니다. 이후에도 `delta` 더하기가 불가능하다면, 라인 24 에서 `gblcnt_mutex` 를 해제하고 라인 25 에서 실패를 리턴 합니다.

그렇지 않다면, 라인 28 에서 `delta` 를 글로벌 카운터에 더하고, 라인 29 에서 만약 적절하다면 카운트를 로컬 스테이트에 분산시킨 후, 라인 30 에서 `gblcnt_mutex` 를 해제하고, 마지막으로 라인 31 에서 성공을 리턴합니다.

Listing 5.12 의 라인 34-63 에서는 `sub_count()` 를 보이는데, 이 함수는 `add_count()` 와 유사하게 구성되어 있어서, 라인 41-48 에 빠른 수행경로를, 그리고 라인 49-62 에 느린 수행경로를 갖습니다. 이 함수의 각 라인별 분석은 독자 여러분의 연습문제로 남겨두겠습니다.

Listing 5.13 는 `read_count()` 함수를 보입니다. 라인 9 에서 `gblcnt_mutex` 를 잡고 라인 16 에서 해제합니다. 라인 10 에서는 로컬 변수 `sum` 을 `globalcount` 의 값으로 초기화하고, 라인 11-15 의 루프에서는 쓰레드별 카운터를 이 합에 더하고 라인 13 에서 각 쓰레드별 카운터를 `split_ctrandmax` 를 사용해서 고립시킵니다. 마지막으로, 라인 17 에서 아까 만든 합을 리턴합니다.

Listing 5.14 와 5.15 는 유틸리티처럼 사용되는 함수들인 `globalize_count()`, `flush_local_count()`, `balance_count()`, `count_register_thread()`, 그리고 `count_unregister_thread()` 의 코드를 보입니

Listing 5.14: Atomic Limit Counter Utility Functions 1

```

1 static void globalize_count(void)
2 {
3     int c;
4     int cm;
5     int old;
6
7     split_counterandmax(&counterandmax, &old, &c, &cm);
8     globalcount += c;
9     globalreserve -= cm;
10    old = merge_counterandmax(0, 0);
11    atomic_set(&counterandmax, old);
12 }
13
14 static void flush_local_count(void)
15 {
16     int c;
17     int cm;
18     int old;
19     int t;
20     int zero;
21
22     if (globalreserve == 0)
23         return;
24     zero = merge_counterandmax(0, 0);
25     for_each_thread(t)
26         if (counterp[t] != NULL) {
27             old = atomic_xchg(counterp[t], zero);
28             split_counterandmax_int(old, &c, &cm);
29             globalcount += c;
30             globalreserve -= cm;
31         }
32 }

```

다. `globalize_count()` 의 코드는 Listing 5.14 의 라인 1-12 에 있는데 앞의 알고리즘과 거의 같지만 라인 7 의, `counter` 와 `countermax` 를 `ctrandmax` 에서 분할해 내기 위한 코드의 추가가 차이점입니다.

모든 쓰레드의 로컬 카운터 상태를 글로벌 카운터로 옮기는, `flush_local_count()` 의 코드는 라인 14-32 에 있습니다. 라인 22 에서는 `globalreserve` 의 값이 모든 쓰레드별 카운트를 허용하는지 체크하고 아니라면 라인 23 에서 리턴합니다. 그렇지 않다면, 라인 24 에서 로컬 변수 `zero` 를 `counter` 와 `countermax` 조합된 0 으로 만듭니다. 라인 25-31 의 루프에서는 각 쓰레드를 순회합니다. 라인 26 에서 현재 쓰레드가 카운터 상태를 가지고 있는지 보고, 만약 그렇다면 라인 27-30 에서 그 상태를 글로벌 카운터로 옮깁니다. 라인 27 에서는 현재 쓰레드의 상태를 어도믹하게 0 으로 바꿈과 동시에 얻어옵니다. 라인 28 에서는 이 상태를 자신의 `counter` (로컬 변수 `c` 로) 와 `countermax` (로컬 변수 `cm` 으로) 로 분할합니다. 라인 29 에서 이 쓰레드의 `counter` 를 `globalcount` 에 더하고 라인 30 에서 이 쓰레드의 `countermax` 를 `globalreserve` 에서 뺍니다.

Quick Quiz 5.42: Listing 5.14 의 라인 14 에서 `flush_local_count()` 가 `ctrandmax` 변수를 0 으로 만든 후 그냥 다시 값을 넣을 수 없는 이유는 뭐죠? ■

Quick Quiz 5.43: Listing 5.14 의 라인 27 에서 `flush_local_count()` 가 `ctrandmax` 변수를 비우는 동안

Listing 5.15: Atomic Limit Counter Utility Functions 2

```

1 static void balance_count(void)
2 {
3     int c;
4     int cm;
5     int old;
6     unsigned long limit;
7
8     limit = globalcountmax - globalcount -
9         globalreserve;
10    limit /= num_online_threads();
11    if (limit > MAX_COUNTERMAX)
12        cm = MAX_COUNTERMAX;
13    else
14        cm = limit;
15    globalreserve += cm;
16    c = cm / 2;
17    if (c > globalcount)
18        c = globalcount;
19    globalcount -= c;
20    old = merge_counterandmax(c, cm);
21    atomic_set(&counterandmax, old);
22 }
23
24 void count_register_thread(void)
25 {
26     int idx = smp_thread_id();
27
28     spin_lock(&gblcnt_mutex);
29     counterp[idx] = &counterandmax;
30     spin_unlock(&gblcnt_mutex);
31 }
32
33 void count_unregister_thread(int nthreadsexpected)
34 {
35     int idx = smp_thread_id();
36
37     spin_lock(&gblcnt_mutex);
38     globalize_count();
39     counterp[idx] = NULL;
40     spin_unlock(&gblcnt_mutex);
41 }

```

add_count() 나 sub_count() 의 빠른 수행경로가 ctrandmax 를 함께 사용하면서 동시에 수행되지 못하는 이유는 뭐죠? ■

Listing 5.15 의 라인 1-22 는 호출한 쓰레드의 로컬 ctrandmax 변수를 재설정 하는 balance_count() 함수의 코드를 보여줍니다. 이 함수는 앞의 알고리즘과 상당히 유사합니다만, ctrandmax 변수의 병합 작업을 처리하는 부분이 추가되었습니다. 해당 코드의 자세한 분석은 라인 24 에 시작하는 count_register_thread() 함수와 라인 33 에서 시작하는 count_unregister_thread() 함수와 함께 독자 여러분의 연습문제로 남겨 두겠습니다.

Quick Quiz 5.44: atomic_set() 은 주어진 atomic_t 에 단순히 스토어를 할 뿐인데, 어떻게 Listing 5.15 의 라인 21 에서의 balance_count() 는 flush_local_count() 의 해당 변수에 동시에 가해지는 업데이트에도 불구하고 올바르게 동작할 수 있는 거죠? ■

다음 섹션에서는 이 설계를 질적으로 평가해 봅니다.




Figure 5.7: Signal-Theft State Machine

5.4.2 Atomic Limit Counter Discussion

이것은 실제로 카운터가 그 리미트를 가지면서도 어떤 방법으로든 사용될 수 있는 최초의 구현입니다만, 일부 시스템에서는 빠른 수행경로를 매우 느리게 만들 수 있는 어토믹 오퍼레이션을 빠른 수행경로에 추가하는 비용을 갖습니다. 일부 워크로드에서는 이 성능 저하가 조절될 수 있겠지만, 더 나은 읽기 쪽 성능을 위한 알고리즘을 찾아보는 것도 좋을 것입니다. 그런 알고리즘 중 하나는 다른 쓰레드로부터 카운트를 훔치기 위해 시그널 핸들러를 사용합니다. 다음 섹션에서 살펴보겠지만, 시그널 핸들러는 시그널을 받은 쓰레드의 컨텍스트에서 동작하기 때문에 어토믹 오퍼레이션이 필요 없습니다.

Quick Quiz 5.45: 하지만 시그널 핸들러는 수행 중에 다른 CPU 로 옮겨져서 수행될 수도 있잖아요. 이런 가능성을 쓰레드와 해당 쓰레드를 인터럽트 하는 시그널 핸들러 사이의 안정적인 통신을 위해 어토믹 인스트럭션과 메모리 배리어를 필요로 하게 만들지 않을까요? ■

5.4.3 Signal-Theft Limit Counter Design

쓰레드별 상태는 이제 연관된 쓰레드에 의해서만 조정된다고는 해도, 여전히 시그널 핸들러를 이용해 동기화를 할 필요가 있습니다. 이 동기화는 Figure 5.7 에 보여지는 스테이트 머신에 의해 제공됩니다. 해당 스테이트 머신은 IDLE 상태에서 시작하고 add_count() 나 sub_count() 가 로컬 쓰레드의 카운트의 합과 글로벌 카운트가 주어진 요청을 수용할 수 없다는 걸 알았을

때, 관련된 느린 수행 경로는 각 쓰레드의 `theft` 상태를 `REQ`로 만듭니다 (해당 쓰레드가 카운트가 있을 경우이고, 그렇지 않다면 `READY`로 곧바로 변환시킵니다). 초록색으로 표시되어 있듯, `gblcnt_mutex` 락을 쥐고 있는 느린 수행경로만이 `IDLE` 상태로부터의 변환을 할 수 있습니다.³ 이 느린 수행 경로는 이후 각 쓰레드에 시그널을 보내고, 그에 상응하는 시그널 핸들러들이 연관된 쓰레드의 `theft`와 `counting` 변수들을 체크합니다. 만약 `theft` 상태가 `REQ`가 아니라면 시그널 핸들러는 상태를 바꿀 권한이 없고, 따라서 그냥 리턴합니다. 그렇지 않고, `counting` 변수가 값이 있어 현재 쓰레드의 빠른 수행경로가 실행 중이란 것을 알게 된다면, 시그널 핸들러는 `theft` 상태를 `ACK`로, 그렇지 않다면 `READY`로 바꿉니다.

파란색으로 표시되어 있듯, `theft` 상태가 `ACK`라면 빠른 수행 경로만이 `theft` 상태를 바꿀 수 있습니다. 빠른 수행 경로가 완료되면, `theft` 상태를 `READY`로 바꿉니다.

느린 수행 경로가 한 쓰레드의 `theft` 상태가 `READY`임을 일단 봤다면, 이 느린 수행 경로는 해당 쓰레드의 카운트를 훔칠 권한을 갖습니다. 이 느린 수행 경로는 이후 해당 쓰레드의 `theft` 상태를 `IDLE`로 만듭니다.

Quick Quiz 5.46: Figure 5.7에서 `REQ` `theft` 상태는 왜 빨간색으로 칠해졌나요? ■

Quick Quiz 5.47: Figure 5.7에서, 두개의 분리된 `REQ`와 `ACK` `theft` 상태를 갖는 이유가 뭐죠? 왜 그 두 상태를 하나의 `REQACK` 상태로 만들어서 스테이트 머신을 간단하게 만들지 않는 거예요? 만약 그렇게 하면 그 상태에 먼저 도달하는 시그널 핸들러나 빠른 수행 경로가 상태를 `READY`로 바꿀 수 있을 텐데요. ■

5.4.4 Signal-Theft Limit Counter Implementation

Listing 5.16 (`count_lim_sig.c`)는 signal-theft based counter 구현에 사용되는 데이터 구조를 보입니다. 라인 1-7에서는 앞의 섹션에서 설명한 쓰레드별 `theft` 스테이트 머신을 위한 상태와 값들을 정의합니다. 라인 8-17은 앞의 구현과 비슷합니다만, 라인 14와 15에 쓰레드의 `countermax`와 `theft` 변수에의 원격에서의 접근을 허가하기 위한 코드가 추가되었습니다.

Listing 5.17는 쓰레드별 변수와 전역 변수 사이에 카운트를 옮겨주는 함수를 보입니다. 라인 1-7은 `globalize_count()` 함수를 보이는데, 이 함수는 앞의 구현과 동일합니다. 라인 9-19는 `flush_local_count_sig()` 함수로, 훔치기 과정에서 사용되는 시그널 핸들러입니다. 라인 11과 12에서는 `theft` 상태가

³ 이 책의 흑백 버전을 위해 말해두자면, `IDLE`과 `READY`는 초록, `REQ`는 빨강, 그리고 `ACK`는 파란색으로 되어 있습니다.

Listing 5.16: Signal-Theft Limit Counter Data

```

1 #define THEFT_IDLE 0
2 #define THEFT_REQ 1
3 #define THEFT_ACK 2
4 #define THEFT_READY 3
5
6 int __thread theft = THEFT_IDLE;
7 int __thread counting = 0;
8 unsigned long __thread counter = 0;
9 unsigned long __thread countermax = 0;
10 unsigned long globalcountmax = 10000;
11 unsigned long globalcount = 0;
12 unsigned long globalreserve = 0;
13 unsigned long *counterp[NR_THREADS] = { NULL };
14 unsigned long *countermaxp[NR_THREADS] = { NULL };
15 int *theftp[NR_THREADS] = { NULL };
16 DEFINE_SPINLOCK(gblcnt_mutex);
17 #define MAX_COUNTERMAX 100

```

`REQ`인지 확인하고, 아니라면 변경 없이 리턴합니다. 라인 13에서는 `theft` 변수의 샘플링이 해당 변수에의 변경 이전에 이루어졌음을 분명히 하기 위해 메모리 배리어를 칩니다. 라인 14는 `theft` 상태를 `ACK`로 놓고, 라인 15에서는 이 쓰레드의 빠른 수행 경로가 수행중인지 확인 후, 라인 16에서 `theft` 상태를 `READY`로 놓습니다.

Quick Quiz 5.48: Listing 5.17의 `flush_local_count_sig()` 함수에서는 왜 `theft` 쓰레드별 변수의 사용을 `ACCESS_ONCE()`로 감싼거죠? ■

라인 21-49는 `flush_local_count()`를 보이는데, 이 함수는 느린 수행 경로에서 모든 쓰레드의 로컬 카운트를 비우기 위해 호출됩니다. 라인 26-34의 루프에서는 로컬 카운트가 있는 모든 쓰레드의 `theft` 상태를 바꾸고, 해당 쓰레드들에 시그널을 날립니다. 라인 27에서는 존재하지 않는 쓰레드들을 스kip합니다. 그렇지 않다면, 라인 28에서 현재 쓰레드가 로컬 카운트를 가지고 있는지 보고, 가지고 있지 않다면 라인 29에서 해당 쓰레드의 `theft` 상태를 `READY`로 바꾸고 라인 30에서 다음 쓰레드로 넘어갑니다. 그렇지 않고 현재 쓰레드가 로컬 카운트를 가지고 있다면, 라인 32에서 해당 쓰레드의 `theft` 상태를 `REQ`로 바꾸고, 라인 33에서 시그널을 날립니다.

Quick Quiz 5.49: Listing 5.17에서, 왜 다른 쓰레드의 `countermax` 변수를 바로 접근해도 안전한 거죠? ■

Quick Quiz 5.50: Listing 5.17에서, 왜 라인 33은 현재 쓰레드가 자기 자신에게 시그널을 보내는지 체크하지 않나요? ■

Quick Quiz 5.51: Listing 5.17의 코드는 GCC와 POSIX에서 동작합니다. ISO C 표준에서 동작하게 하려면 뭐가 필요할까요? ■

라인 35-48의 루프는 각 쓰레드가 `READY` 상태에 도달하길 기다리고, 이후 해당 쓰레드의 카운트를 훔칩니다. 라인 36-37은 존재하지 않는 쓰레드들을 스kip하고, 라인 38-42의 루프에서 현재 쓰레드의 `theft` 상태가

Listing 5.17: Signal-Theft Limit Counter Value-Migration Functions

```

1 static void globalize_count(void)
2 {
3     globalcount += counter;
4     counter = 0;
5     globalreserve -= countermax;
6     countermax = 0;
7 }
8
9 static void flush_local_count_sig(int unused)
10 {
11     if (READ_ONCE(theft) != THEFT_REQ)
12         return;
13     smp_mb();
14     WRITE_ONCE(theft, THEFT_ACK);
15     if (!counting) {
16         WRITE_ONCE(theft, THEFT_READY);
17     }
18     smp_mb();
19 }
20
21 static void flush_local_count(void)
22 {
23     int t;
24     thread_id_t tid;
25
26     for_each_tid(t, tid)
27     {
28         if (theftp[t] != NULL) {
29             if (*countermaxp[t] == 0) {
30                 WRITE_ONCE(*theftp[t], THEFT_READY);
31                 continue;
32             }
33             WRITE_ONCE(*theftp[t], THEFT_REQ);
34             pthread_kill(tid, SIGUSR1);
35         }
36     for_each_tid(t, tid) {
37         if (theftp[t] == NULL)
38             continue;
39         while (READ_ONCE(*theftp[t]) != THEFT_READY) {
40             poll(NULL, 0, 1);
41             if (READ_ONCE(*theftp[t]) == THEFT_REQ)
42                 pthread_kill(tid, SIGUSR1);
43             globalcount += *counterp[t];
44             *counterp[t] = 0;
45             globalreserve -= *countermaxp[t];
46             *countermaxp[t] = 0;
47             WRITE_ONCE(*theftp[t], THEFT_IDLE);
48     }
49 }
50
51 static void balance_count(void)
52 {
53     countermax = globalcountmax - globalcount -
54         globalreserve;
55     countermax /= num_online_threads();
56     if (countermax > MAX_COUNTERMAX)
57         countermax = MAX_COUNTERMAX;
58     globalreserve += countermax;
59     counter = countermax / 2;
60     if (counter > globalcount)
61         counter = globalcount;
62     globalcount -= counter;
63 }

```

Listing 5.18: Signal-Theft Limit Counter Add Function

```

1 int add_count(unsigned long delta)
2 {
3     int fastpath = 0;
4
5     WRITE_ONCE(counting, 1);
6     barrier();
7     if (READ_ONCE(theft) <= THEFT_REQ &&
8         countermax - counter >= delta) {
9         WRITE_ONCE(counter, counter + delta);
10        fastpath = 1;
11    }
12    barrier();
13    WRITE_ONCE(counting, 0);
14    barrier();
15    if (READ_ONCE(theft) == THEFT_ACK) {
16        smp_mb();
17        WRITE_ONCE(theft, THEFT_READY);
18    }
19    if (fastpath)
20        return 1;
21    spin_lock(&gblcnt_mutex);
22    globalize_count();
23    if (globalcountmax - globalcount -
24        globalreserve < delta) {
25        flush_local_count();
26        if (globalcountmax - globalcount -
27            globalreserve < delta) {
28            spin_unlock(&gblcnt_mutex);
29            return 0;
30        }
31    }
32    globalcount += delta;
33    balance_count();
34    spin_unlock(&gblcnt_mutex);
35    return 1;
36 }

```

READY 가 되길 기다립니다. 라인 39에서는 우선순위 역전(priority-inversion) 문제를 막기 위해 1 밀리세컨드 동안 블락되고, 라인 40에서 해당 쓰레드의 시그널이 아직 도착하지 않은 것으로 판단되면 라인 41에서 시그널을 다시 날립니다. 현재 살펴보고 있는 쓰레드의 상태가 마침내 READY 가 되면 실행 흐름은 라인 43에 도달해 라인 43-46에서 훔치기를 시전합니다. 라인 47은 해당 쓰레드의 theft 상태를 다시 IDLE로 되돌립니다.

Quick Quiz 5.52: In Listing 5.17, why does line 41 resend the signal? ■

라인 51-63에서는 balance_count() 함수를 보이는 데, 앞의 예제와 비슷합니다.

Listing 5.18은 add_count() 함수를 보입니다. 라인 5-20에는 빠른 수행 경로가, 라인 21-35에는 느린 수행 경로가 있습니다. 라인 5에서는 쓰레드별 counting 변수를 1로 만들어서 이후에 이 쓰레드를 인터럽트하는 어떤 시그널 핸들러도 theft 상태를 READY가 아니라 ACK로 설정하게 해둠으로써, 이 빠른 수행 경로가 올바르게 완료되도록 합니다. 라인 6은 캠파일러가 빠른 수행 경로의 본체가 counting 설정보다 앞에 위치하도록 재배치 하는 것을 막아줍니다. 라인 7과 8은

Listing 5.19: Signal-Theft Limit Counter Subtract Function

```

1 int sub_count(unsigned long delta)
2 {
3     int fastpath = 0;
4
5     WRITE_ONCE(counter, 1);
6     barrier();
7     if (READ_ONCE(theft) <= THEFT_REQ &&
8         counter >= delta) {
9         WRITE_ONCE(counter, counter - delta);
10    fastpath = 1;
11 }
12 barrier();
13 WRITE_ONCE(counter, 0);
14 barrier();
15 if (READ_ONCE(theft) == THEFT_ACK) {
16     smp_mb();
17     WRITE_ONCE(theft, THEFT_READY);
18 }
19 if (fastpath)
20     return 1;
21 spin_lock(&gblcnt_mutex);
22 globalize_count();
23 if (globalcount < delta) {
24     flush_local_count();
25     if (globalcount < delta) {
26         spin_unlock(&gblcnt_mutex);
27         return 0;
28     }
29 }
30 globalcount -= delta;
31 balance_count();
32 spin_unlock(&gblcnt_mutex);
33 return 1;
34 }
```

쓰레드별 데이터가 `add_count()`를 처리할 수 있는지 확인하고 현재 수행중인 훔치기 작업이 없다면 라인 9에서 빠른 수행 경로 더하기 연산을 수행하고 라인 10에서 빠른 수행 경로가 진행됨을 알립니다.

어떤 경우든, 라인 12에서 컴파일러가 빠른 수행 경로 본체가 라인 13 뒤에 오도록 재배치해 이후의 시그널 핸들러가 훔치기 작업을 하는 사태를 만들지 못하게 합니다. 라인 14에서는 다시 컴파일러 재배치를 막고, 라인 15에서 시그널 핸들러가 `theft` 상태를 `READY`로 바꿨는지 보고, 만약 그렇다면 라인 16에서 라인 17에서 `READY`로 설정한 상태를 본 CPU는 라인 9의 결과도 보도록 해줍니다. 라인 9에서의 빠른 수행 경로 더하기가 실행되었다면, 라인 20에서 성공을 리턴합니다.

그렇지 않다면, 라인 21부터 시작되는 느린 수행 경로로 떨어집니다. 느린 수행 경로의 구조는 앞의 예제들과 유사하므로, 분석은 독자 여러분의 연습 문제로 놔두겠습니다. 비슷하게, Listing 5.19의 `sub_count()`의 구조는 `add_count()`와 동일하므로, `sub_count()` 역시, 그리고 Listing 5.20의 `read_count()`와 함께 그 분석을 독자 여러분의 몫으로 남겨 두겠습니다.

Listing 5.21의 라인 1-12는 `count_init()`를 보여주는데, 이 함수에선 `flush_local_count_sig()`를 `SIGUSR1`의 시그널 핸들러로 설정해서

Listing 5.20: Signal-Theft Limit Counter Read Function

```

1 unsigned long read_count(void)
2 {
3     int t;
4     unsigned long sum;
5
6     spin_lock(&gblcnt_mutex);
7     sum = globalcount;
8     for_each_thread(t)
9         if (counterp[t] != NULL)
10            sum += READ_ONCE(*counterp[t]);
11     spin_unlock(&gblcnt_mutex);
12     return sum;
13 }
```

Listing 5.21: Signal-Theft Limit Counter Initialization Functions

```

1 void count_init(void)
2 {
3     struct sigaction sa;
4
5     sa.sa_handler = flush_local_count_sig;
6     sigemptyset(&sa.sa_mask);
7     sa.sa_flags = 0;
8     if (sigaction(SIGUSR1, &sa, NULL) != 0) {
9         perror("sigaction");
10        exit(EXIT_FAILURE);
11    }
12 }
13
14 void count_register_thread(void)
15 {
16     int idx = smp_thread_id();
17
18     spin_lock(&gblcnt_mutex);
19     counterp[idx] = &counter;
20     countermaxp[idx] = &countermax;
21     theftp[idx] = &theft;
22     spin_unlock(&gblcnt_mutex);
23 }
24
25 void count_unregister_thread(int nthreadexpected)
26 {
27     int idx = smp_thread_id();
28
29     spin_lock(&gblcnt_mutex);
30     globalize_count();
31     counterp[idx] = NULL;
32     countermaxp[idx] = NULL;
33     theftp[idx] = NULL;
34     spin_unlock(&gblcnt_mutex);
35 }
```

`flush_local_count()`에서 `pthread_kill()` 호출로 `flush_local_count_sig()`를 실행시킬 수 있게 합니다. 쓰레드 등록과 해제를 위한 코드는 앞의 예제와 비슷하므로, 이 코드의 분석은 독자의 몫으로 남겨 두겠습니다.

5.4.5 Signal-Theft Limit Counter Discussion

Signal-theft 구현은 제 Intel Core Duo 랩탑에서 어토미 인스트럭션 구현보다 두배 이상 빠르게 동작합니다. 항상 그럴까요?

Signal-theft 구현은 펜티엄-4 시스템에서는 어토믹 인스트럭션들이 느리기 때문에 선호될 만 합니다만 과거의 80386 기반 Sequent Symmetry 시스템에서는 어토믹 오퍼레이션을 사용한 구현의 더 짧은 코드를 더 빨리 수행할 것입니다. 하지만, 이 업데이트 쪽의 성능 향상은 읽는 쪽의 높아진 오버헤드와 함께 옵니다: POSIX 시그널은 공짜가 아닙니다. 결국 핵심이 성능이라면, 두 구현 모두를 어플리케이션이 배포될 시스템 위에서 돌려보는게 좋을 겁니다.

Quick Quiz 5.53: POSIX 시그널만 느린게 아니라, 시그널을 각 쓰레드에 보내는 행위 자체가 확장성이 없어요. 만약 10,000 개의 쓰레드가 있고 읽는 쪽도 빨라야 한다면 어떻게 하시겠어요? ■

이건 왜 높은 품질의 API 가 그렇게 중요한지를 보여주는 한가지 예이기도 합니다: 높은 품질의 API 는 바뀌는 하드웨어 성능 특성에 따라 요구되는 구현 변경이 가능하게 해줍니다.

Quick Quiz 5.54: 아래쪽 한계는 명확하게 지키지만 위쪽 한계는 좀 정확하지 않아도 되는 한계 카운터를 원한다면 어떻게 하면 될까요? ■

5.4.6 Applying Exact Limit Counters

이 섹션에서 소개한 정확한 리미트 카운터 구현은 매우 유용할 수 있지만, 예를 들어 I/O 디바이스로의 액세스 수를 세는 경우와 같이 카운터의 값이 항상 0에 가깝게 유지된다면 별로 유용하지 않을 겁니다. 그런 경우에서의 높은 오버헤드는 일반적으로 얼마나 많은 레퍼런스들이 존재하는지 신경쓰지 않는다는 점을 감안하면 특히나 큰 문제가 됩니다. 5.5 에서 이야기한, 제거 가능한 I/O 디바이스 액세스 카운트 문제에서 이야기 했듯, 액세스의 갯수는 누군가가 정말로 해당 디바이스를 제거하려 하고 있는 드문 경우가 아니고는 무의미합니다.

이 문제에 대한 간단한 해결책은 카운터에 커다란 “바이어스” (예를 들어, 10억 정도) 를 더해 값이 0 보다 충분히 커서 카운터가 효과적으로 동작할 수 있도록 보장해 주는 것입니다. 누군가가 디바이스를 제거하려 한다면, 이 바이어스 값이 카운터 값에서 빠집니다. 마지막의 몇개 액세스들을 카운팅 하는 건 매우 비효율적이 되겠지만, 중요한 건, 그 앞의 많은 액세스들은 최대 속도로 카운트 될 것이라는 점입니다.

Quick Quiz 5.55: 바이어스된 카운터를 사용할 때 그 외에 뭘 하면 좋을까요? ■

바이어스된 카운터는 매우 유용하고 도움이 될 수 있지만, page 45 에서 이야기된 제거 가능한 I/O 디바이스 액세스 카운트 문제의 부분적 해결책에 불과합니다. 디바이스를 제거하려 시도할 때, 우린 현재 I/O 액세스들의 정확한 갯수를 알아야 할뿐만 아니라, 이후의 액세스가 발생하지 않도록 막아야 합니다. 이걸 해내는 한가지

방법은 리더-라이터 락을 사용해 카운터를 업데이트 할 때 읽기 권한을 획득하고, 카운터를 체크할 때 같은 리더-라이터 락에서 쓰기 권한을 획득하는 것입니다. I/O 를 위한 코드는 다음과 같이 될겁니다:

```

1 read_lock(&mylock);
2 if (removing) {
3     read_unlock(&mylock);
4     cancel_io();
5 } else {
6     add_count(1);
7     read_unlock(&mylock);
8     do_io();
9     sub_count(1);
10 }
```

Line 1 read-acquires the lock, and either line 3 or 7 releases it. Line 2 checks to see if the device is being removed, and, if so, line 3 releases the lock and line 4 cancels the I/O, or takes whatever action is appropriate given that the device is to be removed. Otherwise, line 6 increments the access count, line 7 releases the lock, line 8 performs the I/O, and line 9 decrements the access count.

Quick Quiz 5.56: 이거 참 웃기네요! 카운터를 업데이트 하기 위해 리더-라이터 락의 읽기 권한 획득을 한다니요? 뭐하는거예요??? ■

디바이스를 제거하는 코드는 다음과 같을 겁니다:

```

1 write_lock(&mylock);
2 removing = 1;
3 sub_count(mybias);
4 write_unlock(&mylock);
5 while (read_count() != 0) {
6     poll(NULL, 0, 1);
7 }
8 remove_device();
```

Line 1 write-acquires the lock and line 4 releases it. Line 2 notes that the device is being removed, and the loop spanning lines 5-7 wait for any I/O operations to complete. Finally, line 8 does any additional processing needed to prepare for device removal.

Quick Quiz 5.57: 실제 시스템에 적용하려면 해결해야 할 문제들이 또 뭐가 있을 수 있을까요? ■

5.5 Parallel Counting Discussion

This idea that there is generality in the specific is of far-reaching importance.

Douglas R. Hofstadter

이 챕터에서는 전통적인 카운팅 도구들의 신뢰성, 성능, 그리고 확장성 문제를 보았습니다. C 언어의 ++ 오퍼레이터는 멀티쓰레드 코드에서 신뢰성 있게 동작함을

보장하지 않고, 하나의 변수에 어토믹 오퍼레이션을 행하는 것은 성능도 떨어지고 확장성도 좋지 않습니다. 그래서 이 챕터에서는 일부 특정한 경우에 성능도 좋고 확장성도 매우 좋은 카운팅 알고리즘 일부를 보았습니다.

이 카운팅 알고리즘들에서 얻은 교훈을 리뷰해 보는 것은 가치 있는 일일 것입니다. 그러기 위해, Section 5.5.1에서 성능과 확장성을 정리하고, Section 5.5.2에서 특수화를 위한 필요성을 이야기해 보고, 그리고 마지막으로 Section 5.5.3에서 이번에 배운 교훈들을 나열해보아 이 교훈들로부터 더 나아갈 뒤의 챕터에 대해 간단히 알아봅니다.

5.5.1 Parallel Counting Performance

Table 5.1에 네개의 병렬 통계성 카운팅 알고리즘의 성능이 나열되어 있습니다. 네개의 알고리즘 모두 업데이트에 있어 완벽에 가까운 선형적 확장성을 제공합니다. 쓰레드별 변수 구현(`count_end.c`)은 특히나 어레이 기반 구현(`count_stat.c`)에 비해 업데이트가 빠릅니다만, 코어의 수가 많을 때 읽기 쪽에선 느리며, 많은 읽기 오퍼레이션이 병렬적으로 수행될 때에는 상당한 락 경쟁 상황으로 성능이 떨어집니다. 이 경쟁 상황은 Table 5.1의 `count_end_rcu.c` 열에서 볼 수 있듯, Chapter 9에서 소개되는 지연 처리(deferred-processing) 테크닉으로 해결될 수 있습니다. 지연 처리 기법은 `count_stat_eventual.c` 열에서도 그 효과를 보이는데, 결과적 일관성의 덕입니다.

Quick Quiz 5.58: Table 5.1의 `count_stat.c` 열에 보면 읽기 성능이 쓰레드 수에 따라 선형적으로 확장되는데요. 쓰레드 수가 늘어나면 더 많은 쓰레드별 카운터의 합이 이루어져야 하는데 어떻게 그게 가능하죠? ■

Quick Quiz 5.59: Table 5.1의 마지막 열을 보더라도 통계적 카운터 구현의 읽기 쪽 성능은 매우 나쁘군요. 왜 이렇게 성능 나쁜 알고리즘을 신경쓰는거죠? ■

Figure 5.2는 병렬 리미트 카운팅 알고리즘들의 성능을 보여줍니다. 리미트가 정확히 지켜져야 한다는 제약은 상당한 성능 저하를 가져옵니다만, 적어도 이 4.7GHz POWER6 시스템에서는 어토믹 오퍼레이션을 시그널로 대체하는 것으로 그 성능 저하를 줄일 수 있습니다. 이 구현들은 모두 동시적 읽기에 의해 유발되는 읽기 쪽의 락 경쟁으로 인한 성능 저하 문제를 갖습니다.

Quick Quiz 5.60: Table 5.2에 보여진 성능 데이터를 놓고 보자면, 우리는 항상 어토믹 오퍼레이션보다는 시그널을 사용해야겠군요, 그렇죠? ■

Quick Quiz 5.61: Table 5.2에 보여진 읽는 쓰레드간의 락 컨텐션을 해결하기 위해 고급 테크닉들이 사용될 수 있을까요? ■

한마디로, 이 챕터는 특수한 경우들에 한해 성능도 좋고 확장성도 매우 좋은 카운팅 알고리즘들을 보였습니다. 하지만 우리의 병렬 카운팅은 특정한 경우에만 한정되어야 하는 걸까요? 모든 경우에 효율적으로 동작하는 일반적 알고리즘이 있다면 더 좋지 않을까요? 다음 섹션에서는 이런 질문에 대해 알아봅니다.

5.5.2 Parallel Counting Specializations

이 알고리즘들은 각각 특별한 경우에 대해서만 잘 동작한다는 사실은 일반적인 병렬 프로그래밍에 있어서는 중요한 문제로 여겨질 것입니다. 무엇보다, C 언어의 `++` 오퍼레이터는 싱글 쓰레드 코드에서는, 그것도 특수한 경우에 대해서만 아니라 일반적인 경우에서 잘 동작합니다, 그렇죠?

이 생각의 흐름은 진실을 담고 있긴 하나, 본질적으로는 잘못 유추되어졌습니다. 문제는 병렬성이 아니라, 확장성입니다. 이걸 이해하기 위해, 먼저 C 언어의 `++` 오퍼레이터를 생각해 봅시다. 사실, `++` 오퍼레이터는 일반적인 경우에 동작하지 않고, 그저 제한된 수의 영역 내에서만 동작합니다. 1,000 자리 십진수 숫자를 다뤄야 한다면, C 언어 `++` 오퍼레이터는 동작하지 않을 겁니다.

Quick Quiz 5.62: `++` 오퍼레이터는 1,000 자리 숫자에도 잘 동작해요! 연산자 오버로딩이라고 못들어봤어요??? ■

이 문제는 수에 국한되지 않습니다. 데이터를 저장하고 찾아와야 한다고 생각해 봅시다. ASCII 파일을 써야 할까요? XML? 관계형 데이터베이스? 링크드 리스트? 덴스 어레이(Dense Array)? B-트리? 래디스 트리(Radix Tree)? 또는 데이터를 저장하고 찾아오는 것을 허락하는 다른 수많은 데이터 구조와 환경 중 하나? 그건 무엇을 해야 하는가, 얼마나 빨리 해야 하는가, 그리고 얼마나 데이터가 큰가에 달려 있습니다—심지어 순차적 시스템에서도요.

비슷하게, 카운팅이 필요하다면, 해설책은 얼마나 큰 숫자를 다뤄야 하고, 얼마나 많은 CPU가 동시에 그 숫자를 조정할 것이며, 어떻게 그 숫자가 사용될 것이고, 어떤 수준의 성능과 확장성이 필요한지에 따라 달라집니다.

또한 이 문제는 소프트웨어에 국한되지도 않습니다. 사람들이 작은 개울을 건널 수 있게 해주는 다리의 설계는 하나의 나무판자처럼 간단할 수도 있습니다. 하지만 당신은 수 킬로미터 폭의 콜럼비아 강을 위해서는 물론, 콘크리트 트럭이 지나가야 하는 다리를 설계해야 한다고만 해도 나무판자를 사용하진 않을 겁니다. 짧게 말해서, 다리 설계가 거리와 부하에 따라 달라져야만 하는 만큼, 소프트웨어 설계 역시 CPU 갯수에 따라 달라져야만 합니다. 그렇다고 하나, 이 작업을 자동화 해서 소프트웨어가 하드웨어 구성과 워크로드의 변화를 수

Table 5.1: Statistical Counter Performance on POWER6

Algorithm	Section	Updates (ns)	Reads (ns)	
			1 Core	32 Cores
count_stat.c	5.2.2	11.5	408	409
count_stat_eventual.c	5.2.3	11.6	1	1
count_end.c	5.2.4	6.3	389	51,200
count_end_rcu.c	13.3.1	5.7	354	501

Table 5.2: Limit Counter Performance on POWER6

Algorithm	Section	Exact?	Updates (ns)	Reads (ns)	
				1 Core	64 Cores
count_lim.c	5.3.2	N	3.6	375	50,700
count_lim_app.c	5.3.4	N	11.7	369	51,000
count_lim_atomic.c	5.4.1	Y	51.4	427	49,400
count_lim_sig.c	5.4.4	Y	10.2	370	54,000

용할 수 있도록 하면 좋을 것입니다. 실제로 그런 자동화 같은 것들을 위한 연구 [AHS⁺03, SAH⁺03] 가 있어왔고, 리눅스 커널 역시 제한된 바이너리 수정을 포함해, 부팅 타임 재구성을 합니다. 이런 종류의 적용 기능은 주요 시스템에서의 CPU 개수 증가 현상이 유지됨에 따라 더욱 중요해질 것입니다.

요약하자면, Chapter 3에서 이야기 했듯, 물리 법칙은 다리와 같은 기계적 인공물에 제약을 가하듯이 병렬 소프트웨어에도 제약을 가합니다. 이런 제약으로 인해 특수화가 필요하게 됩니다. 다만 소프트웨어의 경우에는 그 특수화를 요구되는 하드웨어와 워크로드에 걸맞는 특수화로 선택하는 것 자체를 자동화 하는게 가능할 수도 있습니다.

물론, 일반화된 카운팅조차도 상당히 특수화 되어 있습니다. 컴퓨터를 가지고는 그 외에도 수많은 일을 해야 합니다. 다음 섹션에서는 카운터로부터 배운 것과 이 책의 뒤에서 다루게 될 주제 사이의 관계를 알아봅니다.

5.5.3 Parallel Counting Lessons

이 챕터를 시작하는 문단에서 우리의 카운팅에 대한 분석은 병렬 프로그래밍에 대한 훌륭한 소개를 제공할 것이라 이야기 했습니다. 이 섹션에서는 이 챕터에서 얻은 교훈과 뒤의 챕터들에서 다룰 것들 사이의 구체적 연결을 만듭니다.

이 챕터에서의 예제들은 분할하기 (*partitioning*) 가 확장성과 성능을 위한 중요한 도구임을 보였습니다. 카운터들은 Section 5.2에서 다룬 통계적 카운터들처럼 완벽하게 분할되어질 수도 있고, Section 5.3 와 Section 5.4

에서 다루어진 리미트 카운터들처럼 부분적으로 분할될 수도 있습니다. 분할은 Chapter 6에서 훨씬 폭넓게 다루어질 것이고, 부분적 분할은 특히 Section 6.4에서 *parallel fastpath* 라 불리며 다루어질 것입니다.

Quick Quiz 5.63: 하지만 우리가 모든 것을 분할할 거라면, 왜 공유 메모리 멀티쓰레딩을 신경쓰죠? 그냥 문제를 완벽하게 분할해버리고 각 분할된 조각들을 여러 프로세스들로, 각자의 어드레스 스페이스에서 처리하도록 돌리지 않는건가요? ■

부분적 분할 카운팅 알고리즘들은 글로벌 데이터를 락킹으로 보호하고, 락킹은 Chapter 7의 주제입니다. 반면, 분할된 데이터는 완전히 연관된 쓰레드의 제어 하에 있어서 어떤 동기화도 필요하지 않게 되는 경향이 있습니다. 이 데이터 소유권은 Section 6.3.4에서 소개하고 Chapter 8에서 더 자세히 다룹니다.

정수의 더하기와 빼기는 일반적인 동기화 오퍼레이션들에 비해 매우 비용이 싸기 때문에, 합리적인 확장성을 얻기 위해선 동기화 오퍼레이션들을 아껴 쓸 것이 요구됩니다. 이를 이루는 방법 중 한가지는 더하기와 빼기 오퍼레이션들 여러개를 한번에 처리해서 (batch) 하나의 동기화 오퍼레이션으로 이 수많은 비용 적은 오퍼레이션들이 처리되게 하는 것입니다. 한 부류의 또는 또 다른 부류의 몰아서 처리하기 (Batching) 최적화는 Table 5.1 와 Table 5.2 에 보인 카운팅 알고리즘들에서 각각 사용되었습니다.

마지막으로, Section 5.2.3에서 다룬 결과적으로 일관적인 통계적 카운터는 뒤로 미루는 (deferring) 행위 (이 경우, 글로벌 카운터를 업데이트 하는 것) 가 성능 향상과 확장성에 상당한 도움을 줄 수 있음을 보였습니

다. 이런 접근은 일반적인 경우의 코드가 다른 경우에 사용할 수 있는 것들보다 훨씬 비용이 싼 동기화 오퍼레이션들을 사용할 수 있게 합니다. Chapter 9는 여러 미루기 방법들이 성능, 확장성, 그리고 심지어는 실시간 응답 (real-time response)에까지 개선을 줄 수 있음을 보일 겁니다.

요약을 요약하자면:

1. 분할하기는 성능과 확장성을 높입니다.
2. 부분 분할은 일반적인 코드 패스에만 분할을 적용한 것으로, 대부분 잘 동작합니다.
3. 부분 분할은 (Section 5.2의 통계적 카운터의 분할된 업데이트와 분할되지 않은 읽기처럼) 코드에만 적용 가능한 것이 아니라, (Section 5.3과 Section 5.4의 리미트 카운터들이 리미트와 멀때는 빠르게, 하지만 리미트에 가까워졌을 때는 느리게 동작하듯이) 시간에도 적용될 수 있습니다.
4. 시간을 분할하는 것은 종종 비싼 글로벌 오퍼레이션을 줄임으로써 동기화 오버헤드를 줄여서 결과적으로 성능과 확장성을 개선하기 위해 업데이트를 지역적으로 돌아서 하도록 합니다. Table 5.1과 Table 5.2에 보여진 모든 알고리즘들은 몰아 처리하기 (Batching)을 많이 사용합니다.
5. 읽기만 하는 코드 패스는 읽기만 하도록 유지되어야 합니다: 공유 메모리에의 의미없는 동기화된 쓰기는 Table 5.1의 `count_end.c` 열에 보여진 것처럼 성능과 확장성을 떨어뜨립니다.
6. 현명한 딜레이의 사용은 Section 5.2.3에서 보았듯이 성능과 확장성을 증진시킵니다.
7. 병렬 성능과 확장성은 대부분의 경우 균형잡기입니다: 특정한 지점 이후부터는, 일부 코드 패스를 최적화하는 것은 다른쪽의 성능을 떨어뜨릴 겁니다. Table 5.1의 `count_stat.c`와 `count_end_rcu.c` 열이 이 지점을 보여줍니다.
8. 다른 수준의 성능과 확장성은 다른 여러 요소들이 그렇듯이 알고리즘과 데이터 구조 설계에 영향을 끼칠 겁니다. Figure ??가 이 점을 보이고 있습니다: 두개의 CPU로 구성된 시스템에서 어토믹 증가는 사용하기 적당합니다만, 8개 CPU로 구성된 시스템에서는 결코 적당치 않습니다.

계속해서 요약해 보자면, 우린 성능과 확장성을 개선할 수 있는 “세개의 커다란” 방법을 가지고 있는데, 각각 (1) CPU와 쓰레드들을 분할하기 (*partitioning*), (2) 한번의 비싼 동기화 오퍼레이션마다 더 많은 일이




Figure 5.8: Optimization and the Four Parallel Programming Tasks

처리되도록 몰아서 처리하기 (*batching*), 그리고 (3) 가능하다면 동기화 오퍼레이션들을 약화시키기. 대략적 경험적 법칙상으로는, page 15의 Figure 2.6에서 이야기 한 것처럼 이 방법들을 이 순서대로 적용해야 합니다. 분할하기 최적화 기법, 몰아서 처리하기 최적화 기법, 그리고 동기화 약화 최적화 기법은 각각 Figure 5.8의 “리소스 분할하기와 복사하기”, “일 분할하기”, “병렬 접근 제어”에 적용될 수 있습니다. 물론, 당신이 digital signal processors (DSPs), field-programmable gate arrays (FPGAs), 또는 general-purpose graphical processing units (GPGPUs)와 같은 특별한 용도의 하드웨어를 사용한다면, 설계 과정에서 “하드웨어와 상호작용하기” 부분에 큰 집중을 기울여야 할 겁니다. 예를 들어, GPGPU의 하드웨어 쓰레드와 메모리 연결 구조는 조심스런 분할과 몰아처리하기 설계 결정에 큰 영향을 끼칠 겁니다.

짧게 말해서, 이 챕터의 시작에서 이야기했듯, 카운팅의 단순성이 우리가 복잡한 동기화 도구들이나 정교한 구조체에 정신을 팔리지 않은채 기본적인 동시성 문제를 알아볼 수 있게 했습니다. 그런 동기화 도구들과 데이터 구조들은 뒤의 챕터들에서 다룹니다.

Chapter 6

Partitioning and Synchronization Design

이 챕터는 상용 시스템에서 지속적으로 나타나는 멀티 CPU로부터의 이점을 얻기 위해서 소프트웨어를 어떻게 설계해야 하는지 설명합니다. 이를 위해 성능, 확장성, 그리고 반응시간 사이의 균형을 잡는데 도움을 줄 수 있을, 여러개의 관용구, 또는 “디자인 패턴” [Ale79, GHJV95, SSRB00] 들을 소개합니다. 앞의 챕터에서 이야기 했듯, 병렬 소프트웨어를 만들 때 하게 되는 가장 중요한 결정은 파티셔닝을 어떻게 할것인지 입니다. 잘 분할된 문제들은 간단하고, 확장성 있으며, 높은 성능을 갖는 해결책을 이끌어냅니다만, 잘못 분할된 문제들은 느리고 복잡한 해결책을 만듭니다. 이 챕터는 몰아서 처리하기 (batching) 와 약화시키기 (weakening) 에 대한 토론과 함께 파티셔닝을 코드로 설계하는 것을 도울 것입니다. “설계”란 단어는 매우 중요합니다: 파티셔닝이 첫번째, 몰아 처리하기가 두번째, 약화시키기가 세번째이며, 코딩은 네번째입니다. 이 순서를 바꾸는 행위는 낮은 성능과 좌절스러운 확장성을 이끌어 낼 겁니다.

이를 위해, Section 6.1 에서는 파티셔닝 연습문제들을 소개하고, Section 6.2 에서 분할가능성 설계 기준을 알아보고, Section 6.3 에서 적절한 동기화 정도의 선택에 대해 이야기 하고, Section 6.4 에서 일반적인 경우에는 속도와 확장성을 제공하는 중요한 병렬적 빠른 수행 경로를 사용하고 일반적이지 않은 상황에는 확장성이 덜한 대안인 “슬로우 패스” 사용 설계의 개요를 알아본 후, 마지막으로 Section 6.5 에서 파티셔닝의 다음을 간략히 봅니다.

6.1 Partitioning Exercises

이 섹션은 파티셔닝의 가치를 보이기 위해 한 쌍의 연습 문제 (고전의, 식사하는 철학자들 문제와 양극단 큐)를 사용합니다.




Figure 6.1: Dining Philosophers Problem

6.1.1 Dining Philosophers Problem

Figure 6.1 는 고전적인 식사하는 철학자들 문제 [Dij71] 를 보이고 있습니다. 이 문제에는 다섯 명의 철학자들이 존재하는데, 이 철학자들은 아무 일도 하지 않고 그저 생각을 하고 두개의 포크를 사용해 먹어야 하는 “매우 먹기 어려운 종류의 스파게티” 를 먹는 것만을 반복합니다. 철학자는 그(또는 그녀)의 오른쪽과 왼쪽에 놓인 포크만을 사용해야 하는데, 일단 포크를 하나들면, 배를 채우기 전까지는 내려놓지 않습니다.¹

이 문제의 목표는 스타베이션 (starvation: 기아) 을 막는 알고리즘을 만드는 것입니다. 스타베이션 시나리오 중 하나는 모든 철학자가 동시에 각자의 왼쪽 포크를 집어드는 것입니다. 철학자들은 스파게티를 다 먹기 전까지는 아무도 포크를 내려놓지 않을 것이고, 최소 한명이 식사를 끝내기 전까지는 아무도 두번째 포크를 들 수 없으므로, 모두 굶어 죽게 됩니다. 최소 한명의

¹ 두개의 포크를 사용하는 음식을 떠올리기 어려운 독자분은 것 가락을 생각해 봅시다.




Figure 6.2: Partial Starvation Is Also Bad




Figure 6.3: Dining Philosophers Problem, Textbook Solution

철학자는 먹게 해주는 것만으로는 문제 해결에 충분치 않음을 알아두시기 바랍니다. Figure 6.2 가 보이듯이, 일부 철학자의 스타베이션도 없어야 합니다.

Dijkstra 의 해결책은 글로벌 세마포어를 사용하는 것으로, 무시해도 좋은 통신 딜레이를 가정하면 잘 동작하지만, 이 가정은 1980년대 후반이나 1990년대 초반 들어서는 타당하지 않게 되었습니다.² 따라서, 최근의 해결책은 Figure 6.3 처럼 포크에 숫자를 매기는 것입니다. 철학자는 자신의 접시 옆의 것 중 가장 낮은 숫자의 포크를 먼저 들고, 이후에 가장 높은 숫자의 포크를 듭

니다. 이 그림에서 가장 위쪽에 자리한 철학자는 따라서 왼쪽 포크를, 그 후 오른쪽 포크를 집어들게 되고, 그동안 다른 철학자들은 오른쪽 포크를 먼저 들게 됩니다. 두명의 철학자들은 포크 1 을 먼저 집어들으려 할 것이기 때문에, 그리고 두 철학자 중 한명만 성공할 것이기 때문에, 네명의 철학자들에게는 다섯개의 포크가 사용 가능할 것입니다. 이 네명 중 최소 한명은 두개의 포크를 집어드는데 성공함이 보장되고, 따라서 식사를 계속할 수 있습니다.

리소스에 숫자를 매기고 숫자 순서대로 획득하는 이 일반적인 방법은 데드락 예방 기술로 매우 많이 사용되고 있습니다. 하지만, 모두가 배고픈데 한번에 한명의 철학자만 식사를 하게 되는 경우를 초래하는 일련의 이벤트를 떠올리기는 쉽습니다:

1. P2 가 포크 1 을 집어들고, P1 이 포크를 집어들지 못하게 합니다.
2. P3 가 포크 2 를 집어듭니다.
3. P4 가 포크 3 을 집어듭니다.
4. P5 가 포크 4 를 집어듭니다.
5. P5 가 포크 5 를 집어들고 식사를 합니다.
6. P5 가 포크 4 와 5 를 내려놓습니다.
7. P4 가 포크 4 를 집어들고 식사를 합니다.

즉, 다섯명의 철학자들이 모두 배고풀 때에, 두명의 철학자들이 동시에 식사를 해도 될만큼 충분한 양의 포크가 있음에도 한번에 한명의 철학자만 식사를 할 수 있는 경우가 존재합니다.

계속해서 읽기 전에 식사하는 철학자들 문제를 분할할 방법을 생각해 보시기 바랍니다.

² 그 해결책이 나온지 40년이 넘게 지난 2012년의 관점에서 Dijkstra 를 모욕하는 것은 너무도 쉽습니다. 여전히 Dijkstra 를 모욕해야겠다고 생각한다면, 제가 드리고 싶은 말은, 뭔가 공개하고, 40년 동안 기다린 후, 당신의 말들이 그 시간동안 어떻게 겹중되었는지 보시기 바랍니다.

(Intentional blank page)




Figure 6.4: Dining Philosophers Problem, Partitioned

한가지 방법이 Figure 6.4에 그려져 있는데, 이 방법을 좀 더 잘 보이기 위해 철학자들의 수를 다섯명에서 네명으로 바꿨습니다. 여기서 위쪽과 오른쪽의 철학자들이 한 짹의 포크를 공유하고, 아래쪽과 왼쪽의 철학자들이 다른 한 짹의 포크를 공유합니다. 모든 철학자들이 동시에 배고파진다면, 최소 두명은 항상 동시적으로 식사를 할 수 있을 것입니다. 또한, 이 그림에서 보여지듯, 포크들은 동시에 집어들고 내려놓을 수 있도록 뮤음으로 취급될 수 있어서 그 획득과 해제 알고리즘을 간단하게 만들어 줍니다.

Quick Quiz 6.1: 식사하는 철학자들 문제를 위한 더 나은 해결책은 없을까요? ■

이것은 “수평적 병렬성” [Inm85] 또는 “데이터 병렬성”의 한 예인데, 두명씩으로 이루어진 철학자 그룹들 사이에 종속성이 없기 때문입니다. 수평적으로 병렬적인 데이터 처리 시스템에서 데이터의 개별 아이템은 소프트웨어 컴포넌트 집합의 복제본들 중 하나에서만 처리될 겁니다.

Quick Quiz 6.2: 그리고 어떤 관점에서 이 “수평적 병렬성”은 “수평적”이라 이야기 될 수 있는 걸까요? ■

6.1.2 Double-Ended Queue

Double-ended 큐는 원소가 리스트의 양쪽 끝 중 어디로든 삽입되고 삭제될 수 있는 자료구조입니다 [Knu73]. 양 끝으로 원소가 동시에 삽입 / 삭제될 수 있는 Double-ended 큐를 락 기반으로 구현하는 것은 어렵다고 알려져 있습니다 [Gro07]. 이 섹션은 파티셔닝 디자인 전략이 어떻게 상당히 간단한 구현을 가능하게 하는지를 다음 섹션들에서 세개의 일반적인 방법들을 살펴봄으로써 알아봅니다.




Figure 6.5: Double-Ended Queue With Left- and Right-Hand Locks

6.1.2.1 Left- and Right-Hand Locks

직관적이어 보이는 방법 중 하나는 양방향 링크드 리스트 (Doubly linked list)를 왼쪽 인큐와 디큐를 위해 왼쪽 락을, 오른쪽의 같은 작업들을 위해 오른쪽 락을 사용하는 것으로, Figure 6.5에 그림으로 그려져 있습니다. 하지만, 이 방법의 문제는 이 리스트에 원소가 네개 미만일 때 두 락의 도메인이 겹쳐야 한다는 것입니다. 이 겹침은 어떤 원소의 삭제가 그 원소만이 아니라, 그것의 왼쪽 또는 오른쪽 이웃 원소에게도 영향을 끼치기 때문입니다. 이 도메인들은 그림에 색으로 표시되었는데, 아래로 향하는 줄무늬의 파란색이 왼쪽 락의 도메인을, 위쪽 줄무늬의 붉은색이 오른쪽 락의 도메인을, 그리고 줄무늬 없는 보라색은 겹치는 도메인을 의미합니다. 이 방법으로 동작하는 알고리즘을 만드는 것도 가능하겠지만, 최소 다섯개의 특별한 케이스들이 있다는 사실은 커다란 문제인데, 특히나 리스트의 다른 끝에서 동시에 이루어지는 동작이 언제든지 이 큐의 상태를 하나의 특별한 케이스에서 다른 케이스로 언제든지 바꿀 수 있습니다. 다른 설계를 생각해 보는게 아무래도 낫습니다.

6.1.2.2 Compound Double-Ended Queue

락 도메인이 겹치지 않게 하는 한가지 방법이 Figure 6.6에 그려져 있습니다. 두개의 별도의 double-ended 큐가 직렬로 연결되며, 각각은 각자의 락으로 보호됩니다. 이




Figure 6.6: Compound Double-Ended Queue

는 원소들은 결국은 하나의 double-ended 큐에서 다른 것으로 옮겨가게 된다는 것을 의미하며, 이 경우 두 락을 모두 잡아야만 하게 됩니다. 데드락을 방지하기 위해 간단한 락 계층구조를 사용할 수 있는데, 예를 들면, 항상 오른쪽 락을 잡기 전에 왼쪽 락부터 잡는 것입니다. 이 방법은 조건 없이 왼쪽에 들어온 원소를 왼쪽의 큐에, 그리고 오른쪽으로 들어온 원소를 오른쪽 큐에 넣을 수 있기 때문에, 두개의 락을 하나의 double-ended 큐에 사용하는 것보다 훨씬 간단합니다. 빈 큐에서 원소를 꺼내려 할 때 좀 복잡한 문제가 생기는데, 이 경우에는 다음과 같은 작업이 필요합니다:

1. 오른쪽 락을 잡고 있다면, 오른쪽 락을 놓고 왼쪽 락을 다시 잡습니다.
2. 오른쪽 락을 잡습니다.
3. 두 큐 사이의 원소들의 균형을 다시 잡습니다.
4. 원소가 존재하면 요청받은대로 원소를 제거합니다.
5. 두 락을 모두 놓습니다.

Quick Quiz 6.3: 이 compound double-ended 큐 구현에서, 비어있던 큐가 락을 놓고 다시 잡는 과정 사이에 더이상 비어있지 않게 된다면 어떻게 해야 할까요? ■

그 결과로 만들어지는 코드 (`locktdeq.c`)는 매우 직관적입니다. 균형을 다시 잡는 작업은 원소를 두 큐 사이에서 옮길 수도 있어서 시간을 소모할 수 있으므로 최적의 성능을 위해선 실제 워크로드에 따른 휴리스틱이 필요할 수 있을 겁니다. 어떤 경우엔 이게 최선의 방법이겠지만, 더 결정론적인 알고리즘을 시도해 보는 것도 재미있을 겁니다.

6.1.2.3 Hashed Double-Ended Queue

데이터 구조를 결정론적으로 쪼개는 가장 간단하고 효과적인 방법은 해싱입니다. 각 원소에 그 리스트에서의 위치에 기반해서, 빈 큐에 왼쪽으로 들어온 첫번째 원소는 0을 가지고, 빈 큐에 오른쪽으로 들어온 원소에는 1을 할당하는식으로 숫자를 할당함으로써 double-ended 큐를 간단히 해시하는 것이 가능합니다. 이후 큐에 왼쪽으로 들어온 원소들은 감소하는 숫자 (-1, -2, -3, ...)를 갖고, 오른쪽으로 들어온 원소들은 증가하는 수를




Figure 6.7: Hashed Double-Ended Queue

갖습니다 (2, 3, 4, ...). 해싱은, 이 숫자는 해당 큐에서의 위치를 의미하기 때문에, 특정 원소의 수를 실제로 나타낼 필요는 없다는 것입니다.

이 방법에서, 왼쪽 인덱스를 지키는데 한 락을 할당하고, 오른쪽 인덱스를 지키는데 또 하나를, 그리고 각 해시 체인을 위해 락을 하나 더 할당합니다. Figure 6.7 가 이로 인해 구성되는 데이터 구조를 네개의 해시 체인들로 표현하고 있습니다. 락 도메인은 겹치지 않고, 체인 락에 앞서 인덱스 락을 획득하고 한번에 한 타입(인덱스 또는 체인)의 락만을 획득하게 함으로써 데드락이 발생 불가능하게 했습니다.

각 해시 체인은 그 자체로 double-ended 큐이며, 이 예제에서, 각각이 네개의 원소를 모두 가지고 있습니다. Figure 6.8 의 가장 위에는 하나의 원소 (“ R_1 ”)이 오른쪽으로 들어온 후의, 오른쪽 인덱스가 해시 체인 2를 참조하게 증가된 상황이 그려져 있습니다. 이 그림의 중간 부분에는 세개의 원소가 더 오른쪽으로 들어온 후의 상황을 그립니다. 볼 수 있듯, 인덱스들은 최초의 상태 (Figure 6.7 를 참고하세요)로 돌아갔지만, 각 해시 체인은 이제 비어있지 않습니다. 이 그림의 아랫쪽은 추가적으로 원소들이 왼쪽으로, 그리고 오른쪽으로 들어온 후의 상태를 그립니다.

Figure 6.8 에 보여진 마지막 상황에서, 왼쪽 꺼내기 오퍼레이션은 “ L_2 ”를 리턴하고 왼쪽 인덱스가 이제는 하나의 원소 (“ R_2 ”)만을 가지고 있는 해시 체인 2를 가리키도록 할 겁니다. 이 상태에서, 동시에 왼쪽 집어넣기와 오른쪽 집어넣기가 실행되면 락 경쟁 상황에 빠지게 됩니다만, 그런 경쟁 상황은 더 큰 해시 테이블을 사용함으로써 비교적 적은 수준으로 경감될 수 있을 겁니다.

Figure 6.9 는 네개의 해시 버킷을 갖는 별렬 double-ended 큐에 16개의 원소가 들어가면 어떻게 구성되는지 보입니다. 전체 double-ended queue 를 구성하는, 단일 락으로 지켜지는 각각의 double-ended 큐는 전체 별렬 double-ended queue 의 4분의 1 조각을 갖는다고 볼 수 있겠습니다.

Listing 6.1 는 관련된 C-언어 데이터 구조를 보여주는 데, `struct deq` 가 간단히 락을 사용하는 double-ended




Figure 6.8: Hashed Double-Ended Queue After Insertions

큐 구현을 제공한다고 가정합니다. 이 데이터 구조는 왼쪽 락을 line 2에서 포함하고 있고, 왼쪽 인덱스는 line 3에, 오른쪽 락을 line 4에서 (실제 구현에서는 캐시 라인 크기로 정렬되어 있겠습니다만), 오른쪽 인덱스를 line 5에서, 그리고 마지막으로 간단한 락 기반의 double-ended 큐들의 해시된 배열을 line 6에서 갖습니다. 고성능의 구현은 거짓 공유 (false sharing)를 막기 위해 패딩이나 특별한 정렬 지시어를 사용할 겁니다.

Listing 6.2 (lockhdeq.c)는 집어넣기 (enqueue) 와 꺼내기 (dequeue) 기능 구현을 보입니다.³ 이야기는 왼쪽 오퍼레이션들에 집중해서 진행될텐데, 오른쪽 오퍼레

³ 다른 언어들로 다양한 형태의 구현을 하는 것도 쉬울 것입니다만, 그건 독자 여러분의 몫으로 남겨두겠습니다.

Listing 6.1: Lock-Based Parallel Double-Ended Queue Data Structure

```
1 struct pdeq {
2     spinlock_t llock;
3     int lidx;
4     spinlock_t rlock;
5     int ridx;
6     struct deq_bkt[bkt[PDEQ_N_BKTS]];
7 };
```

Listing 6.2: Lock-Based Parallel Double-Ended Queue Implementation

```
1 struct cds_list_head *pdeq_pop_l(struct pdeq *d)
2 {
3     struct cds_list_head *e;
4     int i;
5
6     spin_lock(&d->llock);
7     i = moveright(d->lidx);
8     e = deq_pop_l(&d->bkt[i]);
9     if (e != NULL)
10         d->lidx = i;
11     spin_unlock(&d->llock);
12     return e;
13 }
14
15 struct cds_list_head *pdeq_pop_r(struct pdeq *d)
16 {
17     struct cds_list_head *e;
18     int i;
19
20     spin_lock(&d->rlock);
21     i = moveleft(d->ridx);
22     e = deq_pop_r(&d->bkt[i]);
23     if (e != NULL)
24         d->ridx = i;
25     spin_unlock(&d->rlock);
26     return e;
27 }
28
29 void pdeq_push_l(struct cds_list_head *e, struct pdeq *d)
30 {
31     int i;
32
33     spin_lock(&d->llock);
34     i = d->lidx;
35     deq_push_l(e, &d->bkt[i]);
36     d->lidx = moveleft(d->lidx);
37     spin_unlock(&d->llock);
38 }
39
40 void pdeq_push_r(struct cds_list_head *e, struct pdeq *d)
41 {
42     int i;
43
44     spin_lock(&d->rlock);
45     i = d->ridx;
46     deq_push_r(e, &d->bkt[i]);
47     d->ridx = moveright(d->ridx);
48     spin_unlock(&d->rlock);
49 }
```

R ₄	R ₅	R ₆	R ₇
L ₀	R ₁	R ₂	R ₃
L ₋₄	L ₋₃	L ₋₂	L ₋₁
L ₋₈	L ₋₇	L ₋₆	L ₋₅

Figure 6.9: Hashed Double-Ended Queue With 16 Elements

이션들은 왼쪽의 그것과 비슷하기 때문입니다.

Line 1-13은 왼쪽에서 꺼내고 원소가 있었다면 그 원소를, 그렇지 않다면 NULL을 리턴하는 pdeq_pop_l()를 보입니다. Line 6에서는 왼쪽 스펀락을 획득하고, line 7에서 꺼내어질 인덱스를 계산합니다. Line 8에서 해당 원소를 꺼내고, line 9에서 그 결과가 NULL이 아니라는 걸 확인하면, line 10에서 새 왼쪽 인덱스를 기록합니다. 어느쪽이건, line 11에서 락을 풀고, line 12에서 마침내 원소가 있었다면 그것을, 아니면 NULL을 리턴합니다.

Line 29-38은 왼쪽에 특정 원소를 집어넣는 pdeq_push_l()을 보이고 있습니다. Line 33은 왼쪽 락을 잡고, line 34에서 왼쪽 인덱스를 잡습니다. Line 35에서 왼쪽 인덱스로 가리켜진 double-ended 큐에 원소를 왼쪽으로 집어넣습니다. Line 36에서는 왼쪽 인덱스를 업데이트하고 line 37에서 락을 풁니다.

앞서 언급되었듯, 오른쪽 오퍼레이션들은 왼쪽의 그 것들과 비슷하므로, 그쪽의 분석은 독자 여러분의 연습 문제로 남겨두겠습니다.

Quick Quiz 6.4: 해시를 사용한 double-ended 큐는 좋은 해결책인가요? 그렇다면 왜 그렇고 그렇지 않다면 또 왜 그렇죠? ■

6.1.2.4 Compound Double-Ended Queue Revisited

이 섹션에서는 비어있지 않은 큐의 모든 원소들을 이제 비어있는 큐로 모두 옮기는 간단한 균형잡기 방법을 사용해서 compound double-ended 큐를 다시 생각해 봅니다.

Quick Quiz 6.5: 비어진 큐로 모든 원소들을 옮긴다 구요? 대체 어떤 세상에서는 이런 정신나간 방법이 어떤 이유로든 최적인 거죠??? ■

앞의 섹션에서 이야기한 해시 기반 구현과 대조적으로, compound 기반 구현은 락도 어토믹 오퍼레이션도 사용하지 않는, 순차적 구현으로 만들어진 double-ended 큐 위에서 만들어집니다.

Listing 6.3에 그 구현이 있습니다. 해시 기반 구현과 달리, 이 compound 기반 구현은 왼쪽과 오른쪽이 비대칭적이므로, pdeq_pop_l()과 pdeq_pop_r() 구현을

Listing 6.3: Compound Parallel Double-Ended Queue Implementation

```

1 struct cds_list_head *pdeq_pop_l(struct pdeq *d)
2 {
3     struct cds_list_head *e;
4
5     spin_lock(&d->llock);
6     e = deq_pop_l(&d->ldeq);
7     if (e == NULL) {
8         spin_lock(&d->rlock);
9         e = deq_pop_l(&d->rdeq);
10    cds_list_splice(&d->rdeq.chain, &d->ldeq.chain);
11    CDS_INIT_LIST_HEAD(&d->rdeq.chain);
12    spin_unlock(&d->rlock);
13 }
14 spin_unlock(&d->llock);
15 return e;
16 }
17
18 struct cds_list_head *pdeq_pop_r(struct pdeq *d)
19 {
20     struct cds_list_head *e;
21
22     spin_lock(&d->rlock);
23     e = deq_pop_r(&d->rdeq);
24     if (e == NULL) {
25         spin_unlock(&d->rlock);
26         spin_lock(&d->llock);
27         spin_lock(&d->rlock);
28         e = deq_pop_r(&d->ldeq);
29         if (e == NULL) {
30             e = deq_pop_r(&d->ldeq);
31             cds_list_splice(&d->ldeq.chain, &d->rdeq.chain);
32             CDS_INIT_LIST_HEAD(&d->ldeq.chain);
33         }
34         spin_unlock(&d->llock);
35     }
36     spin_unlock(&d->rlock);
37     return e;
38 }
39
40 void pdeq_push_l(struct cds_list_head *e, struct pdeq *d)
41 {
42     spin_lock(&d->llock);
43     deq_push_l(e, &d->ldeq);
44     spin_unlock(&d->llock);
45 }
46
47 void pdeq_push_r(struct cds_list_head *e, struct pdeq *d)
48 {
49     spin_lock(&d->rlock);
50     deq_push_r(e, &d->rdeq);
51     spin_unlock(&d->rlock);
52 }

```

각각 고려해야 합니다.

Quick Quiz 6.6: 왜 compound parallel double-ended queue 구현은 대칭적으로 만들어질 수 없는거죠? ■

이 그림의 line 1-16에 pdeq_pop_l()의 구현이 보여져 있습니다. Line 5는 왼쪽 락을 얻어오고, line 14에서 이 락을 해제합니다. Line 6에서는 왼쪽의 아래에 있는 double-ended 큐에서 왼쪽 디큐를 하려 시도하고, 성공하면 그냥 그 원소를 리턴하기 위해 line 8-13을 건너뜁니다. 그렇지 않다면, line 8에서 오른쪽 락을 잡고, line 9에서 오른쪽 큐로부터 왼쪽 디큐하고, line 10에서 오른쪽 큐의 모든 남아있는 원소들을 왼쪽 큐로 옮

거버리며, line 11에서 오른쪽 큐를 초기화하고, line 12에서 오른쪽 락을 놓습니다. Line 10에서 디큐된 원소가 존재했다면, 그 원소가 리턴됩니다.

`pdeq_pop_r()` 구현은 이 그림의 line 18-38에 보여져 있습니다. 앞에서 그랬듯, line 22에서 오른쪽 락을 잡고 (line 36에서 놓습니다), line 23에서 오른쪽 큐로부터 원소 하나를 오른쪽 디큐하려 시도하고, 성공하면 line 24-35를 건너뛰고 그냥 이 원소를 리턴합니다. 하지만, line 24가 디큐할 원소가 없음을 알게 된다면, line 25에서 오른쪽 락을 놓고 line 26-27에서 올바른 순서로 두 락을 모두 잡습니다. Line 28에서는 이제 오른쪽 큐에서 원소 하나를 오른쪽 디큐하려 시도하고, line 29에서 이 두 번째 시도도 실패했음을 깨닫게 되면, line 30에서 왼쪽 큐로부터 (원소가 있다면) 원소 하나를 오른쪽 디큐하고, line 31에서 왼쪽 큐로부터 남아있는 모든 원소를 오른쪽 큐로 옮기고, line 32에서 왼쪽 큐를 초기화합니다. 어떤 경우든, line 34에서 왼쪽 락을 놓습니다.

Quick Quiz 6.7: Listing 6.3의 line 28에서 왜 오른쪽 디큐를 또 시도하는거죠? ■

Quick Quiz 6.8: 왼쪽 락은 언젠가는 사용 가능할 겁니다!!! 그런데 Figure 6.3의 line 25에서는 왜 오른쪽 락을 무조건적으로 놔버려야 하는거죠? ■

`pdeq_push_1()`의 구현이 Figure 6.3의 line 40-47에 있습니다. Line 44에서는 왼쪽 스펀락을 잡고, line 45에서 왼쪽 큐에 왼쪽 인큐를 하고, 마지막으로 line 46에서 이 락을 놓습니다. `pdeq_enqueue_r()` 구현 (line 49-56에 있습니다)은 상당히 비슷합니다.

Quick Quiz 6.9: 하지만 데이터가 한방향으로만 흐르는 경우에는, Listing 6.3에 보인 알고리즘은 디큐를 하는쪽 끝이 그 아래에 있는 double-ended queue를 비워버리게 되면 두 끝단이 모두 같은 락을 획득하려 시도할 겁니다. 이는 이 알고리즘이 어떤 경우에 있어서는 큐가 임의의 많은 수의 원소들을 가지고 있을 때 조차도 큐의 양끝에 동시의 액세스를 제공하는데 실패한다는 의미가 아닌가요? ■

6.1.2.5 Double-Ended Queue Discussion

Compound 기반 구현은 Section 6.1.2.3에서 이야기한 해시 기반 구현에 비해 좀 복잡하지만, 여전히 간단한 편이라 말할 수 있겠습니다. 물론, 더 똑똑한 균형잡기 방법들은 어느정도 복잡할 수 있겠습니다만, 여기 소개한 간단한 방법들은 다른 소프트웨어 기반 방법들 [DCW⁺11]과 비교해서도, 심지어 하드웨어의 도움을 받는 알고리즘들 [DLM⁺10]과 비교해서도 잘 동작한다고 알려져 있습니다. 그러나, 이런 방법에서 우리는 최대 2배의 확장성까지만 기대할 수 있는데, 최대 두개의 쓰레드가 디큐를 위한 락들을 동시에 잡고 있을 수 있기 때문입니다. 이런 제약은 Michael의 compare-and-swap 기반 디큐 알고리즘 [Mic03]과 같은 non-blocking

동기화 알고리즘에도 적용됩니다.⁴

Quick Quiz 6.10: double-ended 큐 문제에 왜 한개가 아니라 두개나 해결책이 있는거죠? ■

사실, Dice 등 [DLM⁺10]에 의해 이야기 되었듯, 동기화 되지 않은 단일 쓰레드 기반 double-ended 큐는 그들이 알아본 다른 어떤 병렬 구현들보다도 성능이 좋습니다. 따라서, 공유된 큐에 enqueue와 dequeue를 하는 데에는 실제 구현과 관계 없이 커다란 오버헤드가 존재한다는 점이 핵심입니다. Chapter 3에서의 내용과 이 큐들의 FIFO 특성을 생각하면 크게 놀라운 일도 아닙니다.

더우기, 이런 철저한 FIFO 큐들은 사실 그 사용자들에게는 보이지 않는 *linearization point*⁵들에 대해서만 엄격하게 FIFO 인데, 이 예에서, linearization point들은 락 기반의 크리티컬 섹션들 안에 있습니다. 개별적인 오퍼레이션들이 시작된 시점의 관점에서 보기에는 큐들은 엄격한 FIFO는 아닙니다 [HKLPI2]. 이는 동시적 프로그램들에서 철저한 FIFO 속성을 그렇게 가치 있는 것은 아님을 의미하며, 실제로 Kirsch 등은 향상된 성능과 확장성을 제공하는 덜 철저한 큐들을 선보였습니다 [KLP12].⁶ 그렇다고는 하나, 당신이 당신의 동시적 프로그램에서 사용하는 모든 데이터를 하나의 큐를 통해 집어넣는다면, 전체 설계를 다시 한번 생각해 볼 필요가 있습니다.

6.1.3 Partitioning Example Discussion

Section 6.1.1의 Quick Quiz에 대한 답으로 이야기된 식사하는 철학자들 문제의 최적화된 해결책은 “수평적 병렬성” 또는 “데이터 병렬성”의 훌륭한 예 중 하나입니다. 이 경우의 동기화 오버헤드는 거의 (또는 정확히) 없습니다. 반면, double-ended 큐 구현은 “수직적 병렬성” 또는 “파이프라이닝”的 예로, 데이터를 한 쓰레드에서 다른 쓰레드로 옮깁니다. 파이프라이닝에 필요한 더 밀착된 협동은 일의 더 큰 단위가 특정 수준의 효율성을 가질 것을 필요로 합니다.

Quick Quiz 6.11: 직렬화된 double-ended 큐는 해시 기반 double-ended 큐보다 두배나 빠른데, 이런 현상은

⁴ 이 논문은 double-ended 큐들의 lock-free 구현에 특별한 double-compare-and-swap (DCAS) 인스트럭션들이 필요치 않음을 보였다는 점에서 흥미롭습니다. 대신, 일반적인 compare-and-swap (예: x86 cmpxchq)만으로도 충분합니다.

⁵ 짧게 요약해서, linearization point는 한 함수 내에서 그 함수가 수행 결과를 만들어냈다고 할 수 있는 하나의 지점입니다. 이 락 기반의 구현에서 linearization point들은 실제 일을 하는 크리티컬 섹션 안의 어떤가라고 할 수 있습니다.

⁶ Nir Shavit은 대략적으로는 같은 이유로 완화된 스택들을 만들었습니다 [Sha11]. 이런 상황은 몇몇 사람들에게 linearization point들을 개발자들보다는 이론가들에게 유용하다고 믿게 하고, 그런 데이터 스트럭처들과 알고리즘들의 설계자들은 얼마나 사용자들의 필요에 고려를 하고 있었는지 의아해하게 합니다.

제가 해시 테이블의 크기를 미친듯이 크게 만들어줘도 그렇습니다. 왜 그런거죠? ■

Quick Quiz 6.12: double-ended 큐들을 위한 동시성 제어에 대한 훨씬 나은 방법이 있나요? ■

이 두개의 예들은 병렬 알고리즘을 고안하는데 파티셔닝이 얼마나 강력하지 보여줍니다. Section 6.3.5 에서는 세번째 예인 행렬 곱셈을 간단히 볼 겁니다. 하지만, 이 세개의 예 모두 병렬 프로그램들의 더 나은 디자인 표준을 필요로 하는데, 이는 다음 섹션의 주제입니다.

6.2 Design Criteria

최고의 성능과 확장성을 얻는 방법 중 하나는 달성 가능한 최고의 병렬 프로그램이 만들어 질 때까지 해킹을 계속하는 것입니다. 하지만, 여러분의 프로그램이 현미경으로 봐야할 정도로 작지 않은 한, 가능한 병렬 프로그램의 공간은 우주의 수명이라는 거대한 시간 동안에도 최고의 달성 가능한 프로그램에 이르기를 보장하지 못할 정도로 커다랗습니다. 그리고 또, “달성 가능한 최고의 병렬 프로그램”이란 무엇일까요? 어쨌든, Section 2.2 에서는 성능, 생산성, 그리고 범용성의 세가지 병렬 프로그래밍 목표를 이야기 했고, 달성 가능한 최고의 병렬 프로그램은 생산성과 범용성에의 비용으로 다가올 확률이 큽니다. 프로그램이 너무 구식이 되기 전에 충분히 받아들여질만큼 좋은 병렬 프로그램 정도는 되도록 하기 위해, 우리는 설계 단계에서 높은 수준에서의 선택들을 할 수 있어야 합니다.

하지만, 정말로 실제 세계의 설계를 하기 위해선 디자인 규범들이 필요한데, 이 섹션에서 다룰 것입니다. 실제 세계에서, 이 규범들은 종종 더 크거나 작은 정도에서 충돌하므로, 설계자들은 그로 인한 트레이드오프들을 잘 균형 맞춰야 합니다.

이 규범들은 그 자체로써 설계에 동작하는 “힘”들로 생각될 수 있으며, 특히 이런 힘들 간의 좋은 트레이드오프들은 “디자인 패턴” [Ale79, GHJV95] 이라 불릴 수 있을 것입니다.

세개의 병렬 프로그래밍 목표들을 얻기 위한 디자인 규범들은 속도 향상, 경쟁, 오버헤드, 읽기-쓰기 비율, 그리고 복잡도입니다:

Speedup: Section 2.2 에서 이야기했듯, 성능이야말로 우리가 대부분의 시간을 할애해야 하는 곳이고 병렬화를 해야 하는 문제입니다. 속도 향상은 순차적 버전의 프로그램을 돌리는데 드는 시간 대비 병렬 버전을 돌리는데 드는 시간 사이의 비율입니다.

Contention: 더 많은 CPU 들이 한 병렬 프로그램에 사용되면 그 프로그램에 의해 CPU들이 바삐 일하게 될 것이고, 여러분의 CPU들은 다른 CPU들과의 경쟁으로 인해 유의미한 일을 하지 못하게 되어버립니다.

다. 이런 경쟁은 락 경쟁, 메모리 경쟁, 또는 다른 성능 문제 부분으로부터의 것일 수도 있습니다.

Work-to-Synchronization Ratio: 유니프로세서, 싱글 쓰레드, preemption 불가, 그리고 인터럽트 불가⁷ 한 버전의 병렬 프로그램은 어떤 동기화 도구들도 필요가 없을 겁니다. 따라서, 이런 도구들 (커뮤니케이션 캐시 미스, 메세지 응답시간, 락킹 도구, 어토믹 인스트럭션들, 그리고 메모리 배리어 등)에 의해 소모되는 시간은 프로그램이 완수하려 의도한 유용한 일에 직접적으로 도움을 주지 않는 오버헤드일 뿐입니다. 중요하게 측정해 봐야 할 것은 동기화 오버헤드와 크리티컬 섹션 코드의 오버헤드 사이의 관계로, 더 큰 크리티컬 섹션은 더 큰 동기화 오버헤드를 정당화 시킴을 알아두시기 바랍니다. 일 대비 동기화 비율은 동기화 효율성과 연관됩니다.

Read-to-Write Ratio: 아주 가끔만 업데이트 되는 데이터 구조체는 분할되기보다는 복제가 될 수 있을 것이고, 더 나아가서 쓰는 쪽에 부담을 주는 대신 읽는 쪽의 동기화 오버헤드를 완화시켜주는 비대칭적 동기화 도구를 사용해서 보호하는 식으로 전체 동기화 오버헤드를 줄일 수 있을 것입니다. 관련된 최적화들은 Chapter 5 에서 이야기 되었듯 자주 업데이트 되는 데이터 구조체에도 적용될 수 있습니다.

Complexity: 병렬 프로그램은 똑같은 일을 하는 순차적 프로그램에 비해 복잡한데, 병렬 프로그램은 순차적 프로그램에 비해 훨씬 큰 상태 공간을 갖기 때문입니다만, 충분한 질서와 구조가 주어진다면 이 상태 공간도 쉽게 이해될 수 있긴 합니다. 병렬 프로그램을 만드는 사람은 이 커다란 상태 공간의 문맥에서 동기화 도구들, 메세지, 락킹 설계, 크리티컬 섹션 식별, 그리고 데드락을 고려해야 합니다. 이 거대한 복잡도는 종종 높은 개발 / 유지 비용으로 변환됩니다. 따라서, 예산의 제한이 존재하는 프로그램에서는 가할 수 있는 변경의 수와 종류를 제한할 수 있는데, 속도 향상은 많은 시간과 문제를 개선할 때에만 가치가 있기 때문입니다. 더 나쁜 것은, 추가된 복잡도가 실제로 성능과 확장성을 줄일 수 있다는 것입니다.

따라서, 어떤 특정한 지점 이후부터는 병렬화보다는 더 싸고 효과적인 순차적 최적화가 잠재하고 있을 수 있습니다. Section 2.2.1 에서 이야기 했듯, 병렬화는 많은 성능 최적화 방법 중 하나일 뿐이고, 더 나아가서 CPU 기반 병목 문제에 적용될 수 있는 최적화입니다.

⁷ 인터럽트 마스킹을 하거나 그것들을 감지하지 못해서.

이런 규범들은 최대의 속도향상을 위해 함께 동작할 것입니다. 앞의 세개의 규범들은 깊게 관계되어 있으므로, 이 섹션의 뒷부분은 이 상호관계에 대해 분석해 보겠습니다.⁸

이런 규범들은 또한 요구사항의 일부분으로 나타날 수도 있음을 알아 두십시오. 예를 들어, 속도 향상은 상대적 요구사항으로 (“더 빠르게, 더 좋게”) 나올 수도 있고 워크로드의 절대적 요구사항으로 (“시스템은 최소한 초당 1,000,000 웹 헛을 지원해야 한다”) 나올 수도 있습니다. 고전의 디자인 패턴 언어들은 상대적 요구사항을 효력으로, 그리고 절대적 요구사항을 문맥으로 이야기 합니다.

이 디자인 규범들 사이의 관계에 대한 이해는 병렬 프로그램을 위한 적절한 설계 트레이드오프를 정하는데에 많은 도움이 될 수 있을 겁니다.

1. 프로그램이 크리티컬 섹션들에서 더 적은 시간을 보낼수록, 잠재적인 속도 향상은 커집니다. 이는 Amdhal의 법칙 [Amd67] 과, 주어진 시간 동안 크리티컬 섹션은 오로지 하나의 CPU에서만 실행될 수 있다는 사실로 인한 결과입니다.

더 자세히 이야기 하자면, 특정한 갯수의 CPU들에서 실제 성능 향상을 얻기 위해선, 프로그램이 배타적 크리티컬 섹션에서 소모하는 시간의 비율은 CPU들의 수의 역수보다 작아야 합니다. 예를 들어, 10 개의 CPU들을 사용하는 프로그램은 잘 확장하기 위해선 가장 제한적인 크리티컬 섹션에서 자신의 전체 시간 중 10분의 1 미만을 사용해야 합니다.

2. 경쟁은 많은 CPU 그리고/또는 실제 시간을 소모할 것이어서 실제 성능 향상은 사용 가능한 CPU들의 수보다 작을 겁니다. CPU들의 수와 실제 속도 향상 사이의 차이가 클수록, CPU들은 더 비효율적으로 사용될 겁니다. 유사하게, 원하는 효율성이 클수록 얻을 수 있는 속도 향상을 줄어들 겁니다.
3. 사용 가능한 동기화 도구들이 그것들이 지키는 크리티컬 섹션들에 비해 높은 오버헤드를 갖는다면, 속도 향상을 개선하는 최선의 방법은 그 도구들이 사용되는 횟수를 줄이는 것입니다 (크리티컬 섹션들을 합치거나, 데이터 소유권을 사용하거나, 비대칭적으로 도구를 사용하거나(Section 9을 참고하세요), 코드 락킹과 같이 더 큰 단위를 사용하는 디자인으로 옮겨가거나 하는 방법으로).
4. 만약 크리티컬 섹션들이 그것들을 지키는 도구들에 비해 높은 오버헤드를 갖는다면, 속도 향상을




Figure 6.10: Design Patterns and Lock Granularity

개선하는 최선의 방법은 reader/writer 락킹, 데이터 락킹, 비대칭적, 또는 데이터 소유권을 사용하는 쪽으로 옮겨가서 병렬성을 높이는 것입니다.

5. 크리티컬 섹션들이 그것들을 지키는 도구들에 비해 높은 오버헤드를 갖고 보호되는 데이터 구조체에는 수정보다 읽기가 훨씬 많이 수행된다면, 병렬성을 높이는 최고의 방법은 reader/writer 락킹이나 비대칭적 도구들을 사용하는 것입니다.
6. SMP 성능을 개선하는 많은 변경들, 예를 들어 락 경쟁을 줄이는 것은 실시간 응답시간도 향상시킵니다 [McK05d].

Quick Quiz 6.13: 크리티컬 섹션과 관련한 이 모든 문제들은 우리가 크리티컬 섹션이 아예 없는 non-blocking 동기화 [Her90]를 사용해야 한다는 의미는 아닌가요?

■

6.3 Synchronization Granularity

Figure 6.10는 서로 다른 동기화 단위 크기의 단계를 그림으로 보여주는데, 각각의 단계는 뒤의 섹션에서 다루어질 것입니다. 여기서의 섹션들은 주로 락킹에 중점을 맞춥니다만, 비슷한 단위 크기 문제가 모든 동기화 문제에 존재합니다.

6.3.1 Sequential Program

프로그램이 싱글 프로세서 위에서 충분히 빨리 돌아간다면, 그리고 다른 프로세스들이나 쓰레드, 또는 인터럽트 핸들러들과의 상호작용이 없다면, 동기화 기능들을

⁸ 실제 세계의 병렬 시스템은 많은 디자인 규범들에 반하는 사례가 있을 것인데. 데이터 구조체 레이아웃, 메모리 사이즈, 메모리 구조 대기시간, 대역폭 제한, I/O 문제등이 그것입니다.




Figure 6.11: MIPS/Clock-Frequency Trend for Intel CPUs

모두 제거해서 그것들의 오버헤드와 복잡성을 당신으로부터 떼어놓아야 합니다. 몇년 전에는, Moore의 법칙이 결국은 모든 프로그램을 이 카테고리로 만들 것이라 주장하던 사람들도 있었습니다. 하지만, Figure 6.11에서 볼 수 있듯이, 싱글 쓰레드의 성능의 기하급수적인 증가는 2003년 정도에 멈췄습니다. 따라서, 성능을 늘리기 위해선 병렬성이 필요합니다.⁹ 이 새로운 트렌드가 수천개의 CPU들을 갖는 하나의 칩을 나타나게 할 것인지에 대한 논쟁은 금방 끝나지 않겠지만, Paul이 이 문장을 듀얼코어 랩탑으로 쓰고 있다는 점을 볼 때, SMP의 시대는 우리에게 와 있는 것으로 보입니다. Figure 6.12에서 볼 수 있듯이 이더넷 대역폭이 지속적으로 성장하고 있음을 알아두는 것 역시 중요합니다. 이런 추세는 커뮤니케이션 부하를 처리하기 위해 멀티쓰레드 서버들이 나타나도록 촉진하는 역할을 할 것입니다.

이는 당신이 모든 프로그램을 멀티쓰레드 방식으로 코딩해야 한다는 의미가 아닙니다. 다시 말하지만, 프로그램이 싱글 프로세서에서 충분히 빨리 동작한다면, SMP 동기화 기능들의 오버헤드와 복잡성으로부터 당신을 멀리 하십시오. Listing 6.4에 나와 있는 해시 테이블 탐색 코드의 단순성이 이 점을 강조합니다.¹⁰ 핵심은 병렬성으로 인한 속도향상이 CPU들의 갯수에 제한된다는 것입니다. 반면, 예컨대 조심스럽게 선택된 데이터




Figure 6.12: Ethernet Bandwidth vs. Intel x86 CPU Performance

구조와 같은 순차적 최적화를 통한 속도향상은 얼마든지 클 수 있습니다.

Listing 6.4: Sequential-Program Hash Table Search

```

1 struct hash_table
2 {
3     long nbuckets;
4     struct node **buckets;
5 };
6
7 typedef struct node {
8     unsigned long key;
9     struct node *next;
10 } node_t;
11
12 int hash_search(struct hash_table *h, long key)
13 {
14     struct node *cur;
15
16     cur = h->buckets[key % h->nbuckets];
17     while (cur != NULL) {
18         if (cur->key >= key) {
19             return (cur->key == key);
20         }
21         cur = cur->next;
22     }
23     return 0;
24 }
```

반면, 이런 행복한 상황에 처해 있는 게 아니라면, 계속 읽으세요!

6.3.2 Code Locking

코드 락킹은 글로벌 락들만을 사용하기 때문에 상당히 간단합니다.¹¹ 기존의 프로그램을 멀티 프로세서 위에

⁹ 이 그림은 이론적으로 클락당 하나 이상의 인스트럭션들을 처리할 수 있는 최신 CPU들의 경우 클락 주파수를, 그리고 하나의 간단한 인스트럭션을 처리하는데 여러 클락을 필요로 하는 오래된 CPU들의 경우 MIPS를 보입니다. 이런 접근을 취하는 이유는 클락당 여러 인스트럭션들을 처리하는 최신 CPU들의 기능들은 일반적으로 메모리 시스템 성능에 제한되기 때문입니다.

¹⁰ 이 섹션의 예들은 Hart 등 [HMB06]으로부터 얻어졌으며, 여러 파일들로부터 관련된 코드를 모음으로써 경쾌함을 위해 적용되었습니다.

¹¹ 여러분의 프로그램이 데이터 구조체 안에 락들을 가지고 있거나, 자바의 경우, synchronized 인스턴스로 클래스들을 사용한다면,

서 동작하도록 하기 위해 코드 락킹을 사용하도록 수정하는 것은 특히 쉽습니다. 만약 프로그램이 하나의 공유자원만을 가지고 있다면, 코드 락킹은 최적의 성능을 제공할 것입니다. 하지만, 많은 거대하고 복잡한 프로그램들은 크리티컬 세션에서 많은 작업이 수행되어야 할 것을 필요로 하고, 이는 곧 코드 락킹이 그 프로그램의 확장성을 크게 제한하게 합니다.

따라서, 전체 실행시간 중 작은 부분만을 크리티컬 세션에서 수행하거나 작은 확장성만이 필요한 프로그램들에 대해서만 코드 락킹을 사용해야 합니다. 이런 경우, 코드 락킹은 Listing 6.5에서 볼 수 있듯, 순차적인 버전과 매우 유사하고 상대적으로 간단한 프로그램을 제공할 것입니다. 하지만, Listing 6.4의 `hash_search()`에서의 단순한 비교값 리턴은 이제 리턴 전에 락을 풀어야 하기 때문에 세개의 문장이 되었음을 알아 두시기 바랍니다.

Listing 6.5: Code-Locking Hash Table Search

```

1 spinlock_t hash_lock;
2
3 struct hash_table
4 {
5     long nbuckets;
6     struct node **buckets;
7 };
8
9 typedef struct node {
10     unsigned long key;
11     struct node *next;
12 } node_t;
13
14 int hash_search(struct hash_table *h, long key)
15 {
16     struct node *cur;
17     int retval;
18
19     spin_lock(&hash_lock);
20     cur = h->buckets[key % h->nbuckets];
21     while (cur != NULL) {
22         if (cur->key >= key) {
23             retval = (cur->key == key);
24             spin_unlock(&hash_lock);
25             return retval;
26         }
27         cur = cur->next;
28     }
29     spin_unlock(&hash_lock);
30     return 0;
31 }
```

안타깝게도, 코드 락킹은 여러 CPU들이 락을 동시에 획득하려 하는, “락 경쟁” 상황에 빠지기 쉬운 경향이 있습니다. 한 무리의 어린 아이들(또는 아이처럼 행동하는 어른들의 무리들)을 보살펴 본 SMP 프로그래머라면 Figure 6.13에 그려진 것처럼 뭔가 단 하나를 사용하는 것의 위험성을 깨달을 겁니다.

이 문제에 대한 해결책인 “데이터 락킹”이 다음 섹션에 설명됩니다.

Section 6.3.3에 설명된 “데이터 락킹”을 사용하고 있는 겁니다.




Figure 6.13: Lock Contention

6.3.3 Data Locking

많은 데이터 구조체들이 각자 자기의 락을 갖는 조각들로 분할될 수 있습니다. 이렇게 되면 데이터 구조체의 각 조각들의 크리티컬 세션들은 병렬적으로 실행될 수 있습니다. 각 조각의 크리티컬 세션의 인스턴스는 한번에 하나씩만 수행될 수 있긴 하지만요. 경쟁상황이 줄어야만 하고, 동기화 오버헤드가 속도향상을 제한하지 않는 경우에는 데이터 락킹을 사용해야 합니다. 데이터 락킹은 여러 데이터 구조체 사이에 존재하는 너무 큰 크리티컬 세션 인스턴스들을 분산시킴으로써 경쟁상황을 줄여주는 데, 예를 들어 Listing 6.6처럼 해시 테이블에서 해시 베킷 별로 크리티컬 세션을 두는 식입니다. 향상된 확장성은 `struct bucket`와 같이 추가된 데이터 구조체의 형태로 복잡도를 약간 증가시킵니다.

Figure 6.13에서 보였던 경쟁적인 상황과 달리, 데이터 락킹은 Figure 6.14에 그려진 것처럼 조화를 향상시킵니다 — 그리고 병렬 프로그램에서, 이는 거의 항상 향상된 성능과 확장성으로 이어집니다. 이런 이유로, 데이터 락킹은 DYNIX와 DYNIX/ptx 운영체제의 Sequent에서 매우 많이 사용되었습니다 [BK85, Imm85, Gar90, Dov90, MD92, MG92, MS93].

하지만, 어린 아이들을 둘 봄 사람이라면 이야기 할 수 있겠지만, 충분히 놀 수 있는 공간을 주는 것이 평안을 보장하지는 않습니다. 예를 들어, 리눅스 커널은 파일과 디렉토리들의 캐시(“dcache”라 불립니다)를 갖습니다. 이 캐시의 각 원소들은 자신의 락을 갖습니다만, 루트 디렉토리에 해당하는 원소들과 그것의 직접적인 자식들은 다른 원소들에 비해 훨씬 많이 순회됩니다. 이는 많은 CPU들이 이 자주 접근되는 원소들의 락에 경쟁을 하게 되는 결과를 초래해서, Figure 6.15에 보여진 것과

Listing 6.6: Data-Locking Hash Table Search

```

1 struct hash_table
2 {
3     long nbuckets;
4     struct bucket **buckets;
5 };
6
7 struct bucket {
8     spinlock_t bucket_lock;
9     node_t *list_head;
10 };
11
12 typedef struct node {
13     unsigned long key;
14     struct node *next;
15 } node_t;
16
17 int hash_search(struct hash_table *h, long key)
18 {
19     struct bucket *bp;
20     struct node *cur;
21     int retval;
22
23     bp = h->buckets[key % h->nbuckets];
24     spin_lock(&bp->bucket_lock);
25     cur = bp->list_head;
26     while (cur != NULL) {
27         if (cur->key >= key) {
28             retval = (cur->key == key);
29             spin_unlock(&bp->bucket_lock);
30             return retval;
31         }
32         cur = cur->next;
33     }
34     spin_unlock(&bp->bucket_lock);
35     return 0;
36 }



```

같은 상황을 초래하고 맙니다.

많은 경우, 알고리즘들은 데이터 쓸음을 줄이도록 설계될 수 있고, 어떤 경우에는 아예 그것들을 없애버릴 수도 있습니다 (리눅스 커널의 dcache에서도 가능한 것으로 나타난 것처럼요 [MSS04]). 데이터 락킹은 종종 해시 테이블처럼 분할될 수 있는 데이터 구조체에 사용됩니다만, 여러 존재가 각각 어떤 데이터 구조체의 인스턴스로 표현될 수 있는 경우에도 사용됩니다. 리눅스 커널 2.6.17 버전의 태스크 리스트는 후자의 한 예로, 각 태스크 구조체는 자신의 `proc_lock`을 갖습니다.

다이나믹하게 할당되는 구조체들에서의 데이터 락킹의 핵심 문제는 해당 구조체가 해당 락이 잡혀있는 동안은 존재하는 상태를 유지해야 한다는 것입니다. Listing 6.6 의 코드는 이 문제를 락들을 정적으로 할당된 해시 버킷들에 넣어두고, 절대 메모리에서 해제시키지 않는 것으로 해결합니다. 하지만, 이 트릭은 해시 테이블의 크기가 바뀔 수 있다면 락들이 다이나믹하게 할당되어야 하므로 제대로 동작하지 않을 것입니다. 이 경우, 해시 버킷들을 그 락들이 잡혀있는 동안은 메모리 해제되지 않도록 하는 어떤 수단이 필요할 것입니다.

Quick Quiz 6.14: 자신의 락이 잡혀 있는 동안은 구조체가 메모리 해제 되지 않도록 할 수 있는 방법들은

**Figure 6.14:** Data Locking**Figure 6.15:** Data Locking and Skew

어떤 것들이 있을까요? ■

6.3.4 Data Ownership

데이터 소유권은 각 쓰레드/CPU가 자신에게 할당된 데이터의 부분집합을 어떤 동기화 오버헤드 없이 접근할 수 있게끔 데이터 구조를 쓰레드나 CPU 단위로 쪼갭니다. 하지만, 어떤 쓰레드가 다른 쓰레드의 데이터에 접근하길 원한다면, 그냥 할 수 없습니다. 대신, 이 쓰레드는 다른 쓰레드와 먼저 통신을 해서 다른 쓰레드가 그 일을 대신 해주거나 그 데이터의 소유권을 이전해 주도록 해야 합니다.

데이터 소유권은 불가사의해 보일 수도 있지만, 매우

자주 사용됩니다:

1. 한 CPU 나 쓰레드에 의해서만 접근될 수 있는 변수(C 와 C++에서의 `auto` 변수와 같은)들은 모두 해당 CPU 나 프로세스에게 소유되어 있습니다.
2. 사용자 인터페이스의 한 인스턴스는 해당 사용자의 컨텍스트를 소유합니다. 병렬 데이터베이스 엔진과 상호작용하는 어플리케이션들은 그것들이 순차적 프로그램인 것마냥 작성되는 것이 매우 흔한 일입니다. 그런 어플리케이션들은 사용자 인터페이스와 그/그녀의 현재 동작을 소유합니다. 따라서 명시적인 병렬성은 데이터베이스 엔진 그 자체에 국한되어 있습니다.
3. 파라미터를 사용하는 시뮬레이션들은 종종 각 쓰레드가 파라미터 공간의 특정 영역에 소유권을 갖게 하는 방법으로 병렬화 되곤 합니다. 이런 태입의 문제를 위한 컴퓨팅 프레임워크도 존재합니다 [Uni08a].

상당히 많은 공유가 존재한다면, 쓰레드들이나 CPU들 사이의 통신은 상당한 복잡도와 오버헤드를 만들어 낼 것입니다. 더 나아가서, 가장 많이 사용되는 데이터가 단일 CPU에게 소유되어 있게 된다면, 이 CPU는 “핫스팟”이 될 것이고, Figure 6.15에 그려진 것과 같은 결과를 낼 것입니다. 하지만, 공유가 필요하지 않은 상황이라면, Listing 6.4에 보여진 것처럼 데이터 소유권은 이상적인 성능을 내고, 순차적 프로그램처럼 간단해질 수 있을 것입니다. 그런 상황은 종종 “당황스러울 정도로 병렬적”이라 불리곤 하고, Figure 6.14에서 앞서 본 것과 같은 상황과 닮아 있습니다.

또 다른 중요한 데이터 소유권 상황은 데이터가 읽기 전용이어서 모든 쓰레드가 복사본을 통해 그것을 “소유” 할 수 있는 경우입니다.

데이터 소유권은 Chapter 8에서 좀 더 자세히 다뤄질 겁니다.

6.3.5 Locking Granularity and Performance

이 섹션은 락킹 빈도와 성능 사이의 관계를 수학적인 동기화 효율성 관점에서 살펴봅니다. 수학이 지루한 독자분들은 이 섹션을 건너뛰셔도 됩니다.

사용할 방법은 하나의 공유되는 글로벌 변수에 대해 동작하는 동기화 메커니즘의 효율성을 위한 간단한 큐잉 모델을 M/M/1 큐를 기반으로 사용해 보는 것입니다. M/M/1 큐잉 모델은 지수적으로 분포되는 “도착간 비율(inter-arrival rate)” λ 와 지수적으로 분포되는 “서비스 비율(service rate)” μ 에 기반합니다. 도착간 비율 λ 는

만약 동기화 비용이 전혀 들지 않는다면 시스템이 처리할 수 있는, 초당 동기화 오퍼레이션들의 평균 숫자로 생각될 수 있는데, 달리 말하자면 λ 는 작업의 비동기 유닛의 오버헤드의 역수입니다. 예를 들어, 일의 각 유닛이 트랜잭션이고, 각 트랜잭션이 처리되는데 동기화 오버헤드를 제외하고 1 밀리세컨드가 걸린다면, λ 는 초당 1,000 트랜잭션이 될 것입니다.

서비스 비율 μ 는 비슷하게 정의됩니다만, CPU들이 각자의 동기화 오퍼레이션들을 완료하기를 기다려야 한다는 사실을 무시하고 각 트랜잭션의 오버헤드가 존재하지 않는다면 시스템이 1초 안에 처리할 수 있는 동기화 오퍼레이션들의 수의 평균으로, 달리 말하자면, μ 는 컨텐션이 없을 때의 동기화 오버헤드라고 생각될 수 있겠습니다. 예를 들어, 각 동기화 오퍼레이션이 어토믹 값 증가 인스트럭션을 내포하고 있고, 컴퓨터 시스템은 각 CPU에서 각자의 변수에 25 나노세컨드마다 어토믹 값 증가 인스트럭션을 수행할 수 있다고 해 봅시다.¹² 따라서 μ 의 값은 초당 40,000,000 어토믹 값 증가 일 것입니다.

물론, λ 의 값은 CPU 수가 늘어나면 함께 늘어날텐데, 각 CPU가 독립적으로 트랜잭션들을 처리할 수 있기 때문입니다 (다시 말하지만, 동기화를 무시합니다):

$$\lambda = n\lambda_0 \quad (6.1)$$

n 은 CPU의 갯수이고 λ_0 는 단일 CPU의 트랜잭션 처리 가능량입니다. 단일 CPU가 하나의 트랜잭션을 처리하는데 걸릴 것으로 기대되는 시간은 $1/\lambda_0$ 임을 기억해 두십시오.

이 CPU들은 다른 CPU들이 각각 하나의 공유 변수의 값을 증가시킬 동안 “줄을 서서 기다려야” 하기 때문에, 기대되는 전체 대기 시간을 표현하는데 M/M/1 큐잉 모델을 다음과 같이 사용할 수 있습니다:

$$T = \frac{1}{\mu - \lambda} \quad (6.2)$$

앞의 λ 값을 대입하면:

$$T = \frac{1}{\mu - n\lambda_0} \quad (6.3)$$

이제, 효율성은 동기화 없을 때 트랜잭션 하나를 처리하는데 필요한 시간 ($1/\lambda_0$)과 동기화를 포함해서 필

¹² 물론, 같은 공유 변수의 값을 증가시키는 8 개의 CPU가 존재한다면, 각각의 CPU는 자신의 값 증가 작업을 위해 25 나노세컨드를 소모하기 전에 다른 CPU들이 각자의 값 증가 작업을 마무리 할 때 까지 175 나노세컨드를 기다려야 할 것입니다. 실제로는, 이 대기는 더 길어질텐데 그 변수를 한 CPU에서 다른 CPU로 옮기는 시간도 걸리기 때문입니다.




Figure 6.16: Synchronization Efficiency

요한 시간 ($T + 1/\lambda_0$) 사이의 비율입니다:

$$e = \frac{1/\lambda_0}{T + 1/\lambda_0} \quad (6.4)$$

앞의 T 값을 대입하고 간략화 하면:

$$e = \frac{\frac{\mu}{\lambda_0} - n}{\frac{\mu}{\lambda_0} - (n - 1)} \quad (6.5)$$

하지만 μ/λ_0 의 값은 그저 트랜잭션을 처리하는데 필요한 시간과 (경쟁상황이 없는 상태에서의) 동기화 자체 오버헤드 간의 비율입니다. 이 비율을 f 라고 하면, 이렇게 됩니다:

$$e = \frac{f - n}{f - (n - 1)} \quad (6.6)$$

Figure 6.16는 동기화 효율성 e 가 CPU/쓰레드 수 n 에 의해 변화되는 모습을 오버헤드 비율 f 몇개의 값과 함께 보여줍니다. 예를 들어, 25 나노세컨드 걸리는 어토미к 값 증가 연산을 사용하면 $f = 10$ 선은 각 CPU가 매 250 나노세컨드마다 어토미к 값 증가 연산을 시도하고, $f = 100$ 라인은 각 CPU가 수천개의 인스트럭션을 처리될 수 있는 시간인 2.5 마이크로세컨드마다 어토미к 값 증가 연산을 시도합니다. 각 조합의 결과가 CPU나 쓰레드의 수가 늘어남에 따라 급격하게 떨어지는 것으로 보아, 하나의 글로벌 공유 변수에의 어토미к 조정을 통한 동기화 메커니즘은 현재의 하드웨어에서 많이 사용되면 잘 확장되지 못할 것이라 결론 내릴 수 있습니다. 이건 이 규칙들을 수학적으로 그려본 것으로, Chapter 5에서 이야기한 병렬 카운팅 알고리즘을 이끌어내게 합니다.




Figure 6.17: Matrix Multiply Efficiency

이 효율성 컨셉은 정규적인 동기화가 적거나 아예 없을 때에도 효과적입니다. 예를 들어, 한 행렬의 행을 (“dot product”로) 다른 행렬의 열과 곱해서 세번째 행렬을 만들어내는 행렬 곱셈을 생각해 봅시다. 이 오퍼레이션들은 서로 겹치지 않기 때문에, 첫번째 행렬의 행들을 쓰레드들에 분할시켜서 각 쓰레드가 결과 행렬의 연관된 행을 계산하는 것이 가능합니다. 따라서 이 쓰레드들은 `matmul1.c`에서와 같이 아무런 동기화 오버헤드 없이 완전히 독립적으로 동작할 수 있습니다. 따라서 병렬적 행렬 곱셈은 완벽한 효율성, 1.0을 가질 것이라 예상할 수도 있습니다.

하지만, Figure 6.17는 다르게 이야기하는데, 특히 64 행 64 열 행렬 곱셈에서는 0.7보다 나은 효율성을 절대 갖지 못합니다. 싱글쓰레드로 동작하는데도 불구하고 말이지요. 512 행 512 열 행렬 곱셈의 효율성은 10 쓰레드 아래에서는 1.0보다 조금 작은 것으로 측정되며 심지어 1024 행 1024 열 행렬 곱셈조차도 수십 쓰레드에서는 완벽한 효율성을 벗어나게 되고 맙니다. 더도 아니고 덜도 아니고, 이 그림은 몰아서 처리하기의 성능과 확장성에서의 이점을 분명하게 보여주고 있으며, 이로 인해 당신의 돈의 가치도 알 수 있게 해줍니다.

Quick Quiz 6.15: 싱글쓰레드로 동작하는 64 행 64 열 행렬 곱셈이 어떻게 1.0보다 낮은 효율성을 가질 수 있죠? Figure 6.17의 모든 조합에서의 결과들이 한 쓰레드에서만 돌아갈 때에는 정확히 1.0의 효율성을 보여야 하는 거 아닌가요? ■

이런 비효율성 아래, Section 6.3.3에서 이야기한 데이터 락킹과 같이 더 확장성 있는 방법을 생각해 보거나 다음 섹션에서 다룰 병렬 상황 빠른 수행 경로 해결책을 고려해 보는 것도 가치가 있을 것입니다.

Quick Quiz 6.16: 행렬 곱셈에서 데이터 병렬화 기법이 어떻게 도움이 될 수 있나요? 그건 이미 병렬적인 데이터잖아요!!! ■




Figure 6.18: Parallel-Fastpath Design Patterns

6.4 Parallel Fastpath

잘게 쪼개진 (그리고 따라서 일반적으로 높은 성능을 갖는) 설계들은 굵게 쪼개진 설계들에 비해 일반적으로 더 복잡합니다. 많은 경우, 대부분의 오버헤드는 코드의 작은 부분에서 발생합니다 [Knu73]. 그러니 그 작은 부분에 집중하는 노력을 가져보는게 어떨까요?

이게 병렬 고속 수행 경로 디자인 패턴을 뒷받침하는 아이디어로, 전체 알고리즘을 공격적으로 병렬화 하려 할 때 요구되는 복잡성 없이 일반적인 경우를 위한 코드 수행 경로를 공격적으로 병렬화 시키는 것입니다. 이를 위해선 병렬화 하려는 특정 알고리즘만 이해해선 안되고, 그 알고리즘이 목표로 하는 워크로드에 대해서도 이해해야만 합니다. 병렬 고속 수행 경로를 만들기 위해선 커다란 창조성과 설계에 들이는 노력이 많은 경우에 필요합니다.

병렬 고속 수행 경로는 서로 다른 패턴들 (고속 수행 경로를 위해 하나, 다른 경우를 위해 또 하나)을 조합하며, 따라서 임시적 패턴입니다. 아래에 나열된 병렬 고속 수행 경로의 예들은 Figure 6.18에 그려진 것처럼 그 자신의 패턴을 정당화 하기 충분할 만큼 자주 사용됩니다:

1. Reader/Writer 락킹 (Section 6.4.1에서 설명합니다).
2. 고성능을 위해 Reader/Writer 락킹을 대체할 수 있으며 이 챕터에서는 더이상 설명되지 않은 Read-copy update (RCU).
3. Section 6.4.2에서 다뤄질 계층적 락킹 ([McK96]).
4. 리소스 할당자 캐시 ([McK96, MS93]). 더 자세한 내용을 위해선 Section 6.4.3을 참고하십시오.

Listing 6.7: Reader-Writer-Locking Hash Table Search

```

1 rwlock_t hash_lock;
2
3 struct hash_table
4 {
5     long nbuckets;
6     struct node **buckets;
7 };
8
9 typedef struct node {
10     unsigned long key;
11     struct node *next;
12 } node_t;
13
14 int hash_search(struct hash_table *h, long key)
15 {
16     struct node *cur;
17     int retval;
18
19     read_lock(&hash_lock);
20     cur = h->buckets[key % h->nbuckets];
21     while (cur != NULL) {
22         if (cur->key >= key) {
23             retval = (cur->key == key);
24             read_unlock(&hash_lock);
25             return retval;
26         }
27         cur = cur->next;
28     }
29     read_unlock(&hash_lock);
30     return 0;
31 }
  
```

6.4.1 Reader/Writer Locking

동기화 오버헤드가 무시할만 하다면 (예를 들어, 프로그램이 커다란 크리티컬 섹션과 굵게 쪼개진 병렬성을 사용한다면), 그리고 그 크리티컬 섹션의 작은 부분들만이 데이터를 수정한다면, 여러개의 읽기 작업을 병렬로 수행될 수 있도록 하면 확장성이 크게 개선될 겁니다. 쓰기 작업은 읽기 작업과도, 다른 쓰기 작업들과도 배타적으로 수행되어야 합니다. Reader-writer 락킹의 많은 구현이 존재하는데, Section 4.2.4에 설명된 POSIX 구현도 그 중 하나입니다. Listing 6.7은 해시 테이블이 reader-writer 락킹을 사용해 어떻게 구현될 수 있는지 보입니다.

Reader/writer 락킹은 비대칭적 락킹에 대한 하나의 간단한 예입니다. Smanan [ST87]은 여러 클러스터 시스템에서 사용된, 더 화려한 여섯개 모드의 비대칭적 락킹 디자인을 설명합니다. 일반적인 락킹과 reader-writer 락킹은 Chapter 7에서 자세히 설명됩니다.

6.4.2 Hierarchical Locking

계층적 락킹의 아이디어는 잘게 쪼개진 (fine-grained) 락을 잡는 동작을 하는 동안만 잡는 굵은 (coarse-grained) 락을 두자는 것입니다. Listing 6.8은 해시 테이블 탐색에 계층적 락킹이 어떻게 사용될 수 있을지 보여주는데, 또한 이 방법의 커다란 단점 역시 보여줍니다: 두 번째

Listing 6.8: Hierarchical-Locking Hash Table Search

```

1 struct hash_table
2 {
3     long nbuckets;
4     struct bucket **buckets;
5 };
6
7 struct bucket {
8     spinlock_t bucket_lock;
9     node_t *list_head;
10 };
11
12 typedef struct node {
13     spinlock_t node_lock;
14     unsigned long key;
15     struct node *next;
16 } node_t;
17
18 int hash_search(struct hash_table *h, long key)
19 {
20     struct bucket *bp;
21     struct node *cur;
22     int retval;
23
24     bp = h->buckets + key % h->nbuckets;
25     spin_lock(&bp->bucket_lock);
26     cur = bp->list_head;
27     while (cur != NULL) {
28         if (cur->key >= key) {
29             spin_lock(&cur->node_lock);
30             spin_unlock(&bp->bucket_lock);
31             retval = (cur->key == key);
32             spin_unlock(&cur->node_lock);
33             return retval;
34         }
35         cur = cur->next;
36     }
37     spin_unlock(&bp->bucket_lock);
38     return 0;
39 }

```

락을 잡기 위한 오버헤드를 가져야 하지만, 그 락은 짧은 시간동안만 잡습니다. 이 경우, 간단한 데이터 락킹 방법은 더 간단하고 더 좋은 성능을 보일 것입니다.

Quick Quiz 6.17: 계층적 락킹이 잘 동작할 만한 상황은 뭐가 있을까요? ■

6.4.3 Resource Allocator Caches

이 섹션에서는 병렬로 동작하는 고정 크기 블럭 메모리 할당자의 간단한 개요를 제공합니다. 더 자세한 설명은 *literature* [MG92, MS93, BA01, MSK01] 나 리눅스 커널 [Tor03c]에서 찾을 수 있습니다.

6.4.3.1 Parallel Resource Allocation Problem

병렬 메모리 할당자가 마주하게 되는 기본적인 문제는 일반적인 경우에 고속의 메모리 할당과 해제 기능을 제공해야 하는 필요성과 선호되지 않는 할당/해제 패턴을 마주했을 때 효과적으로 메모리를 분산시켜야 하는 필요성 사이의 갈등입니다.




Figure 6.19: Allocator Cache Schematic

이 갈등을 보기 위해, 이 문제에 데이터 소유권을 직접적으로 활용한 경우를 생각해 봅시다 — 단순히 각 CPU가 자기 뭉을 소유하도록 메모리를 분할하는 방법입니다. 예를 들어, 두개의 CPU를 갖고 2기가바이트의 메모리를 갖는 시스템 (제가 바로 지금 글을 쓰고 있는 기계와 같습니다)이라고 생각해 봅시다. 간단히 각 CPU에 1기가바이트씩 메모리를 할당해 주고 각 CPU가 자신이 소유하고 있는 메모리 덩어리에 접근하도록 할 수 있는데, 이렇게 되면 락킹의 필요성과 복잡성, 그리고 오버헤드들이 없습니다. 불행히도, 이 간단한 계획은 간단한 생산자-소비자 워크로드 같은 경우에서 일어날 수 있는, CPU 0이 모든 메모리를 할당받고 CPU 1이 그걸 해제하는 알고리즘이 있다면 망가질 수 있습니다.

다른 극단적 방법인 코드 락킹의 경우에는 과한 락 경쟁과 오버헤드로 고통받게 될 수 있습니다 [MS93].

6.4.3.2 Parallel Fastpath for Resource Allocation

일반적으로 사용되는 방법은 각각의 CPU가 블럭들의 적당한 캐시를 소유하는 병렬적 빠른 수행 경로를 사용하고 추가적인 블럭들을 위한 공유 풀에는 커다란 코드 락킹을 사용해서 관리하는 방법입니다. 한 CPU가 메모리 블럭을 독점하는 것을 막기 위해, 각 CPU의 캐시에 존재할 수 있는 블럭의 갯수에 제한을 걸어둡니다. 두 개의 CPU가 있는 시스템에서, 메모리 블럭들의 흐름은 Figure 6.19에 보여진 대로일 겁니다: 한 CPU가 자신의 풀이 꽉 차서 블럭을 하나 해제하려고 할 때에는 블럭들을 글로벌 풀에 보내고, 비슷하게, 그 CPU가 자신의 풀이 비어서 블럭을 할당받으려 할 때에는 글로벌 풀로부터 블럭들을 얻어옵니다.

Listing 6.9: Allocator-Cache Data Structures

```

1 #define TARGET_POOL_SIZE 3
2 #define GLOBAL_POOL_SIZE 40
3
4 struct globalmempool {
5     spinlock_t mutex;
6     int cur;
7     struct memblock *pool[GLOBAL_POOL_SIZE];
8 } globalmem;
9
10 struct perthreadmempool {
11     int cur;
12     struct memblock *pool[2 * TARGET_POOL_SIZE];
13 };
14
15 DEFINE_PER_THREAD(struct perthreadmempool, perthreadmem);

```

6.4.3.3 Data Structures


Listing 6.9에 할당자 캐시의 “간단한” 구현을 위한 실제 데이터 구조체가 있습니다. Figure 6.19의 “Global Pool”은 `struct globalmempool` 타입의 `globalmem`으로 구현되었고 `struct percpumempool` 타입의 `percpu` 변수 `percpumem`으로 두개의 CPU 별 풀이 구현되었습니다. 이 데이터 구조체 둘 다 각자의 pool 필드 안의 블럭들로의 포인터 배열을 가지고 있는데, 이것들은 인덱스 0부터 위쪽으로 채워져 나갑니다. 따라서, 만약 `globalmem.pool[3]`이 NULL이라면, 인덱스 4부터 위쪽인 이 배열의 나머지들 역시 모두 NULL이어야 합니다. `cur` 필드는 pool 배열의 채워진 원소들 중 가장 높은 숫자의 인덱스를 갖는데, 만약 모든 원소들이 비어있다면 -1을 갖습니다. `globalmem.pool[0]`부터 `globalmem.pool[globalmem.cur]` 사이의 모든 원소들은 반드시 채워져 있어야 하고, 나머지 것들은 모두 비어있어야만 합니다.¹³

풀 데이터 구조체의 동작이 어떻게 될지에 대한 그림이 Figure 6.20에 있는데, 여섯개의 박스들은 pool 필드를 구성하는 포인터들의 배열을 의미하며, 그 앞의 숫자는 `cur` 필드를 의미합니다. 색이 칠해진 박스들은 NULL이 아닌 포인터들을 의미하며, 비어있는 박스들은 NULL 포인터들을 의미합니다. 좀 혼란스러울 수 있지만 중요한 점은, 이 데이터 구조체가 항상 지키게 되는 사실(불변식, invariant)은, `cur` 필드는 항상 NULL이 아닌 포인터들의 수보다 하나 작을 것이란 점입니다.

6.4.3.4 Allocation Function

할당을 하는 함수인 `memblock_alloc()`을 Listing 6.10에 보였습니다. Line 7에서는 현재 쓰레드의 per-thread 풀을 가져오고, line 8에서 그게 비어있는지 확인합니다.

¹³ 두 풀 사이즈 (`TARGET_POOL_SIZE`와 `GLOBAL_POOL_SIZE`) 모두 비현실적으로 작습니다만, 이 작은 크기가 이 프로그램의 행동이 어떻게 이루어지는지 이해하기 위해 프로그램을 한단계씩 실행시켜 나가기 편하게 도와줄 겁니다.

**Figure 6.20:** Allocator Pool Schematic**Listing 6.10:** Allocator-Cache Allocator Function

```

1 struct memblock *memblock_alloc(void)
2 {
3     int i;
4     struct memblock *p;
5     struct perthreadmempool *pcpp;
6
7     pcpp = __get_thread_var(perthreadmem);
8     if (pcpp->cur < 0) {
9         spin_lock(&globalmem.mutex);
10        for (i = 0; i < TARGET_POOL_SIZE &&
11             globalmem.cur >= 0; i++) {
12            pcpp->pool[i] = globalmem.pool[globalmem.cur];
13            globalmem.pool[globalmem.cur--] = NULL;
14        }
15        pcpp->cur = i - 1;
16        spin_unlock(&globalmem.mutex);
17    }
18    if (pcpp->cur >= 0) {
19        p = pcpp->pool[pcpp->cur];
20        pcpp->pool[pcpp->cur--] = NULL;
21        return p;
22    }
23    return NULL;
24 }

```

만약 그렇다면, line 9-16의 코드는 line 9에서 획득하고 line 16에서 해제하는 스팬락의 보호 아래 글로벌 풀로부터 해당 per-thread 풀을 채우려 시도합니다. Line 10-14는 블럭들을 글로벌에서 per-thread 풀로로 캔 풀이 목표로 하는 크기(절반)에 도달하거나 글로벌 풀이 텅 빌 때까지 옮기고, line 15에서는 per-thread 풀의 수를 올바른 값으로 설정합니다.

어떤 경우든, line 18에서 per-thread 풀이 여전히 비어 있는지 확인하고, 만약 그렇지 않다면, line 19-21에서 블럭 하나를 제거하고 그걸 리턴합니다. 그렇지 않다면, line 23에서 메모리가 부족하다는 슬픈 이야기를 전합니다.

Listing 6.11: Allocator-Cache Free Function

```

1 void memblock_free(struct memblock *p)
2 {
3     int i;
4     struct perthreadmempool *pcpp;
5
6     pcpp = &__get_thread_var(perthreadmem);
7     if (pcpp->cur >= 2 * TARGET_POOL_SIZE - 1) {
8         spin_lock(&globalmem.mutex);
9         for (i = pcpp->cur; i >= TARGET_POOL_SIZE; i--) {
10             globalmem.pool[+globalmem.cur] = pcpp->pool[i];
11             pcpp->pool[i] = NULL;
12         }
13         pcpp->cur = i;
14         spin_unlock(&globalmem.mutex);
15     }
16     pcpp->pool[+pcpp->cur] = p;
17 }
```

6.4.3.5 Free Function

Listing 6.11 는 메모리 블럭 해제 함수를 보입니다. Line 6 에서는 이 쓰레드의 풀을 가리키는 포인터를 얻어오고 line 7 에서 이 per-thread 풀이 꽉 차 있는지 확인합니다.

만약 그렇다면, line 8-15 에서 이 per-thread 풀의 절반을 글로벌 풀로 비워내는데, 이 때 line 8 과 14 에서 글로벌 풀을 위한 스핀락을 잡고 놓습니다. Line 9-12 에서는 로컬에서 글로벌 풀로 블럭들을 옮기는 루프를 구현하고 있으며, line 13 에서는 per-thread 풀의 카운트를 올바른 값으로 재조정 합니다.


어떤 경우든, line 16 에서는 새로 해제된 블럭을 per-thread 풀에 넣습니다.

Quick Quiz 6.18: 이 자원 할당자 설계는 Section 5.3에서 다룬 대략적 한계 카운터의 것과 닮지 않았나요?

6.4.3.6 Performance

대략적인 성능 결과¹⁴ 가 Figure 6.21 에 보여져 있는데, 이 데이터를 위한 성능 평가 실험은 1GHz 로 동작하는 듀얼코어 Intel x86 (CPU 당 4300 bogomips)에서 각 CPU 의 캐시에 최대 여섯개의 블럭들을 주고 수행되었습니다. 이 마이크로 벤치마크에서, 각 쓰레드는 반복적으로 한 그룹의 블럭들을 할당받고 그 그룹의 모든 블럭들을 해제하는데, 이 그룹에 속하는 블럭들의 갯수는 x 축에 표시되는 “allocation run length (할당 수행 시간 길이)” 와 같습니다. Y 축은 마이크로세컨드당 성공한 할당/해제 횟수입니다 — 실패한 할당들은 카운트 되지 않습니다.

¹⁴ 이 데이터는 통계적으로 유의미한 방식으로 수집되지는 않았으므로 많은 비판적 시각과 의심을 가지고 봐야만 합니다. 좋은 데이터 수집과 요약을 위한 방법은 Chapter 11 에서 이야기 됩니다. 그렇다고나마, 반복해서 진행한 수행은 비슷한 결과를 내놓았고, 이 값들은 비슷한 알고리즘들의 더 세심하게 설계된 성능 평가 실험과 비슷한 결과를 보입니다.

**Figure 6.21:** Allocator Cache Performance

니다. “X”는 두 쓰레드 수행의 결과이고, “+”는 단일 쓰레드 수행의 결과입니다.

할당 수행 시간 길이가 6일 때까지는 선형적으로 확장되고 훌륭한 성능을 보이지만, 6보다 큰 할당 수행 시간 길이에서는 부족한 성능을 보이고 거의 항상 음의 확장도를 보임에 주의하시기 바랍니다. 따라서 TARGET_POOL_SIZE 의 크기를 충분히 크게 잡는게 상당히 중요한데, 다행히도 실제 사례 [MSK01] 에서는 그렇게 하기가 상당히 쉬운 경우가 일반적이고, 특히 오늘날의 큰 메모리에선 더욱 그렇습니다. 예를 들어, 대부분의 시스템에서 TARGET_POOL_SIZE 를 100 으로 잡는 것은 상당히 합리적으로, 이 경우 전체 시간의 99 % 에서 할당과 해제 작업들이 per-thread 풀에서만 이루어질 것이 보장됩니다.

이 그림에서 볼 수 있듯이, 데이터 소유권이 적용될 수 있는 일반적인 경우의 상황 (할당 수행 시간이 6 미만일 때)에서는 락을 반드시 사용해야만 하는 상황들에 비해 훨씬 향상된 성능을 보입니다. 일반적인 경우에 동기화를 피하는 것은 이 책 전체에 걸쳐 반복되는 주제가 될 것입니다.

Quick Quiz 6.19: Figure 6.21 에서, 세개의 챈들들마다 할당 수행 시간 길이가 증가함에 따라 성능이 따라 증가하는 패턴이 존재하는데, 예를 들어, 할당 수행 시간 길이 10, 11, 12 의 경우입니다. 왜 그런거죠? ■

Quick Quiz 6.20: 두개 쓰레드를 사용한 테스트에서 할당 수행 길이가 19 이상일 때 할당 실패가 발견되었습니다. 글로벌 풀 사이즈가 40 이고 per-thread 풀 사이즈 s 가 3 이고, 쓰레드의 갯수 n 가 2 이며, per-thread 풀들은 초기에 비어있고 메모리를 아무도 사용하고 있지 않다고 가정하는 조건 하에서, 할당 실패가 발생할 수 있는 최소의 할당 수행 시간 길이 m 은 무엇일까요? (각 쓰레드는 메모리의 m 블럭을 할당받고 m 블럭의 메

모리를 해제하는 것을 반복함을 다시 이야기 드립니다.) 그 대신에, n 개 쓰레드가 각각 풀 사이즈 s 를 갖는다면, 그리고 각 쓰레드가 먼저 메모리의 m 개 블럭을 할당받고 그 m 개 블럭을 해제하는 것을 반복한다고 하는 조건이라면, 글로벌 풀 사이즈는 얼마나 커야 할까요? Note: 올바른 답을 얻기 위해서는 `smpalloc.c` 소스 코드를 자세히 들여다보고, 한단계 한단계씩 들여다봐야 할 겁니다. 분명 경고했어요! ■

6.4.3.7 Real-World Design

이 장난감 병렬 리소스 할당자는 상당히 간단했습니다. 만 실제 세계에서의 설계는 이 방법으로부터 여러 가지 방법으로 확장됩니다.

먼저, 실제 세계에서의 할당자는 넓은 범위의 할당 크기들을 다룰 수 있어야 하는데, 이 장난감 예제에서 보았던 단일한 크기와 반대됩니다. 널리 사용되는 이에 대한 해결 방법 중 하나는 1980년대 후반 BSD 메모리 할당자 [MK88] 같은 방식으로, 고정된 크기의 집합을 제공하는 것인데, 외부의, 그리고 내부의 파편화 문제를 균형 맞추기 위해 그렇게 공간을 사용합니다. 이렇게 하는 것은 곧 “globalmem” 변수가 크기별로 복사본이 존재해야 함을 의미하고, 연관된 락 역시 비슷하게 복사되어야 해서, 이 장난감 프로그램의 코드 락킹보다는 데이터 락킹에 가까운 결과를 이끌어낼 것입니다.

두 번째로, 상품 단계 품질의 시스템들은 메모리의 용도를 바꿀 수도 있어야만 하는데, 다시 말해 그것들은 블럭들을 합체해서 페이지 [MS93]와 같은 더 큰 구조체로 만들어질 수도 있어야만 합니다. 이 합체 역시 락으로 보호되어야 하는데, 이것 역시 앞의 것들과 마찬가지로 크기별로 복사본이 있어야 할 수 있습니다.

세 번째로, 합쳐진 메모리는 아랫단의 메모리 시스템에 반환되어야만 하고, 메모리의 페이지들은 또한 그 아래 단의 메모리 시스템들로부터 할당되어야만 합니다. 이 단계에서 필요한 락킹은 이 아랫단의 메모리 시스템에 의존적일 것입니다만, 코드 락킹이 될 수도 있습니다. 코드 락킹은 종종 이 단계에서 받아들여질 수 있는데, 이 단계에 도달하는 것은 잘 설계된 시스템에서는 매우 희박하게 이루어지기 때문입니다 [MSK01].

이 실제 세계 설계의 커다란 복잡도에도 불구하고, 그 아래 자리잡고 있는 아이디어는 똑같습니다—Table 6.1에 보인 것과 같은 병렬 빠른 수행 경로의 반복적인 적용.

6.5 Beyond Partitioning

이 챕터에서는 데이터 파티셔닝이 간단한 선형적으로 확장 가능한 병렬 프로그램을 설계하는데 사용될 수 있는지 알아봤습니다. Section 6.3.4에서는 데이터 복사

Table 6.1: Schematic of Real-World Parallel Allocator

Level	Locking	Purpose
Per-thread pool	Data ownership	High-speed allocation
Global block pool	Data locking	Distributing blocks among threads
Coalescing	Data locking	Combining blocks into pages
System memory	Code locking	Memory from/to system

가능성에서 힌트를 얻었는데, 이는 Section 9.5에서 커다란 효과를 가져올 것입니다.

파티셔닝과 복사본 사용을 적용하는 주요 목표는 선형적인 속도 향상을 얻기 위한 것으로, 달리 말하자면 CPU나 쓰레드의 수가 늘어남에 따라 전체적으로 필요한 일의 양이 크게 늘어나지는 않음을 보장하기 위한 것입니다. 파티셔닝과 복사본 사용을 통해 해결될 수 있어서 선형적인 속도 향상이 가능한 문제들은 당혹스럽게 병렬적입니다. 하지만 이보다 더 잘할 수는 없을까요?

이 질문에 답을 하기 위해, 미궁과 미로의 해결책을 생각해 보도록 합시다. 물론, 미궁과 미로는 수천년 동안 매력적인 것이었으며 [Wik12], 따라서 그것들이 바이오 컴퓨터 [Ada11], GPGPU [Eri08], 심지어는 분리된 하드웨어 [KFC11] 등의 컴퓨터들을 사용해서 만들어지고 해결되었음을 별로 놀라운 일도 아닙니다. 미로의 병렬적 해결책은 대학 수업에서의 과제 프로젝트 [ETH11, Uni10]로도 사용되었고, 병렬 프로그래밍 프레임워크의 이점을 보이기 위한 매개물 [Fos10]로도 사용되었습니다.

흔한 조언은 병렬 일거리-대기열 알고리즘(PWQ: Parallel work-queue algorithm) [ETH11, Fos10]을 사용하는 것입니다. 이 섹션은 무작위적으로 생성된 정사각형 미로를 푸는 모든 경우에 대해 순차적 알고리즘(SEQ: SEQuential algorithm)과 대안적인 병렬 알고리즘, 그리고 PWQ를 비교하는 것으로 이 조언을 평가해보겠습니다. Section 6.5.1에서는 PWQ를 이야기하고, Section 6.5.2에서 대안적인 병렬 알고리즘을 설명하며, Section 6.5.3에서는 그것의 문제 있는 성능에 대해 이야기 한 후, Section 6.5.4에서 앞의 대안적 병렬 알고리즘으로부터 향상된 순차적 알고리즘을 소개하며, Section 6.5.5에서 성능을 비교해 보고, 마지막으로 Section 6.5.6에서 미래의 방향을 알아보고 결론을 내려봅니다.

Listing 6.12: SEQ Pseudocode

```

1 int maze_solve(maze *mp, cell sc, cell ec)
2 {
3     cell c = sc;
4     cell n;
5     int vi = 0;
6
7     maze_try_visit_cell(mp, c, c, &n, 1);
8     for (;;) {
9         while (!maze_find_any_next_cell(mp, c, &n)) {
10             if (++vi >= mp->vi)
11                 return 0;
12             c = mp->visited[vi].c;
13         }
14         do {
15             if (n == ec) {
16                 return 1;
17             }
18             c = n;
19         } while (!maze_find_any_next_cell(mp, c, &n));
20         c = mp->visited[vi].c;
21     }
22 }
```

6.5.1 Work-Queue Parallel Maze Solver

PWQ 는 Listing 6.12(maze_seq.c) 에 있는 SEQ 에 기반합니다. 미로는 셀들의 2D 배열과 \rightarrow visited 로 이름 붙여진 선형적 배열 기반 일거리 대기열로 나타내어집니다.

Line 7에서 첫번째 셀에 들어가고, line 8-21에 있는 루프의 매 반복에서 하나의 셀에 의해 향해지는 통로를 획단합니다. Line 9-13의 루프에서는 \rightarrow visited[] 배열을 방문되지 않은 이웃을 가지고 방문된 셀을 위해 스캔하고, line 14-19의 루프에서는 그 이웃을 통해 향해지는 작은 미로를 획단합니다. Line 20에서는 밖의 루프에 의해 통과될 다음 경로를 위해 초기화를 합니다.

`maze_try_visit_cell()`의 슈도코드가 Listing 6.13 (maze.c)의 line 1-12에 나타나 있습니다. Line 4에서 셀 c 와 n 이 근처에 있고 연결되어 있는지 체크해 보고, line 5에서는 셀 n 이 아직 방문되지 않았는지 확인해 봅니다. `celladdr()` 함수는 지목된 셀의 주소를 리턴합니다. 두 체크 중 하나라도 실패하면, line 6에서 실패했음을 리턴합니다. Line 7에서는 다음 셀을 알리고, line 8에서 이 셀을 \rightarrow visited[] 배열의 다음 슬롯에 기록해 두고, line 9에서 이 슬롯이 이제 채워졌음을 알리며, line 10에서 이 셀을 방문되었음을 마크하고 미로의 시작점으로부터의 거리를 기록해둡니다. Line 11은 이제 성공했음을 리턴합니다.

`maze_find_any_next_cell()`의 슈도코드가 Listing 6.13 (maze.c)의 line 14-28에 있습니다. Line 17에서는 현재 셀의 거리 더하기 1을 얻어오고, 라인 19, 21, 23, 25에서는 각 방향의 해당 셀들을 체크하고, line 20, 22, 24, 26에서는 연관된 셀이 다음 셀 후보라면 `true`를 리턴합니다. `prevcol()`, `nextcol()`, `prevrow()`, 그리고 `nextrow()`는 각각 배열 인덱스 변환 작업을 수행합니다.

Listing 6.13: SEQ Helper Pseudocode

```

1 int maze_try_visit_cell(struct maze *mp, cell c, cell t,
2                         cell *n, int d)
3 {
4     if (!maze_cells_connected(mp, c, t) ||
5         (*celladdr(mp, t) & VISITED))
6         return 0;
7     *n = t;
8     mp->visited[mp->vi] = t;
9     mp->vi++;
10    *celladdr(mp, t) |= VISITED | d;
11    return 1;
12 }
13
14 int maze_find_any_next_cell(struct maze *mp, cell c,
15                             cell *n)
16 {
17     int d = (*celladdr(mp, c) & DISTANCE) + 1;
18
19     if (maze_try_visit_cell(mp, c, prevcol(c), n, d))
20         return 1;
21     if (maze_try_visit_cell(mp, c, nextcol(c), n, d))
22         return 1;
23     if (maze_try_visit_cell(mp, c, prevrow(c), n, d))
24         return 1;
25     if (maze_try_visit_cell(mp, c, nextrow(c), n, d))
26         return 1;
27     return 0;
28 }
```




Figure 6.22: Cell-Number Solution Tracking

니다. 어떤 셀도 후보가 아니라면, line 27에서 `false`를 리턴합니다.

해당 경로는 Figure 6.22에 보여지는 것처럼, 미로에서 시작점으로부터의 셀들의 수를 세는 것으로 기록되는데, 시작 셀은 좌상단에 위치해 있고 끝의 셀은 우하단에 위치해 있습니다. 끝 셀로부터 시작해서 연속적으로 줄어드는 셀 숫자들을 따라가는 것으로 해결 경로를 따라 획단할 수 있습니다.

병렬 작업 대기열 처리자 (work-queue solver)는 Listing 6.12와 6.13에 보여진 알고리즘의 단순한 병렬화입니다. Listing 6.12의 line 10은 `fetch-and-add`를 사용해야만 하고 지역 변수인 vi 는 여러 쓰레드를 사이에 공유되어야만 합니다. Listing 6.13의 Line 5와 10은 CAS 루프로 구성되어야만 하는데, 이 때 CAS의 실패는 미로 루프를 의미하게 됩니다. 이 그림의 Line 8-9는 셀들을 \rightarrow visited[] 배열에 동시적으로 기록하려 시도하는 것을 처리하기 위해 `fetch-and-add`를 사용해야만 합니다.




Figure 6.23: CDF of Solution Times For SEQ and PWQ

이 접근법은 Figure 6.23에서 볼 수 있듯이 2.53 GHz의 속도로 동작하는 dual-CPU Lenovo W500에서 상당한 속도 향상을 보여주는데, 두 알고리즘의 해결책을 얻는데 걸리는 시간의 누적 분포 함수들 (CDF)을 500개의 다른 500행 500열의 정사각으로 무작위적으로 만들어진 미로들에 대해 측정되었습니다. 이 CDF들을 x 축에 투영해서 만들어지는 실질적인 겹쳐진 모습은 Section 6.5.3에서 다루어질 것입니다.

상당히 흥미롭게도, 순차적인 해결책의 경로 탐색은 병렬 알고리즘에서도 바뀌지 않았습니다. 하지만, 이는 병렬 알고리즘의 상당한 약점을 드러냈습니다: 어떤 주어진 시간 동안 최대 하나의 쓰레드만이 해결책 경로의 진행을 만들 수 있습니다. 이 약점은 다음 섹션에서 다루어집니다.

6.5.2 Alternative Parallel Maze Solver

유용한 미로 풀기 방법들은 양 끝에서 시작해야 한다는 주장이 종종 있었고, 이런 조언은 자동화된 미로 해법 [Uni10]의 맵락에서 최근들어 더 반복되었습니다. 이 조언은 파티셔닝과 같은 것으로, 파티셔닝은 병렬 프로그래밍의 맵락에서 운영체제 커널에 대해서도 [BK85, Inm85] 어플리케이션에 대해서도 [Pat10] 강력한 병렬화 전략이 되어왔습니다. 이 섹션에서는 이 전략을 적용해 보는데, 해결책 경로의 양 끝단에서 시작하는 두개의 자식 쓰레드를 사용하고, 성능과 확장성에 대한 결과를 간단히 알아봅니다.

Listing 6.14 (`maze_part.c`)에 보여진 파티션을 사용한 병렬 알고리즘 (PART)는 SEQ와 비슷하지만 몇 가지 중요한 차이점이 있습니다. 첫번째로, 각 자식 쓰레드는 자신의 `visited` 배열을 가지고 있는데, line 1에서 보듯이 부모로부터 전달받은 것이며, 모두 $[-1, -1]$ 로 초기화되어 있어야만 합니다. Line 7에서는 이 배열로의 포인터를 per-thread 변수 `myvisited`에 저장해서 도우미

Listing 6.14: Partitioned Parallel Solver Pseudocode

```

1 int maze_solve_child(maze *mp, cell *visited, cell sc)
2 {
3     cell c;
4     cell n;
5     int vi = 0;
6
7     myvisited = visited; myvi = &vi;
8     c = visited[vi];
9     do {
10         while (!maze_find_any_next_cell(mp, c, &n)) {
11             if (visited[+vi].row < 0)
12                 return 0;
13             if (READ_ONCE(mp->done))
14                 return 1;
15             c = visited[vi];
16         }
17         do {
18             if (READ_ONCE(mp->done))
19                 return 1;
20             c = n;
21         } while (maze_find_any_next_cell(mp, c, &n));
22         c = visited[vi];
23     } while (!READ_ONCE(mp->done));
24     return 1;
25 }
```

함수들로부터의 접근을 가능하게 하고, 비슷하게 지역적으로 방문한 곳의 인덱스로의 포인터를 저장합니다. 두번째로, 부모는 각 자식의 입장에서 첫번째 셀을 방문하는데, 이는 자식들이 line 8에서 얻어옵니다. 세번째로, 미로는 한 자식이 다른 자식에 의해 방문되었던 셀을 발견하면 그 즉시 풀이됩니다. `maze_try_visit_cell()`이 이를 발견하게 되면, 이 함수는 해당 미로 구조체의 `->done` 필드에 값을 넣습니다. 넷째로, 따라서 각 자식은 line 13, 18, 23에 보여진 것처럼 주기적으로 `->done` 필드를 체크해야만 합니다. `ACCESS_ONCE()` 기능은 다음의 연속적인 로드들을 합치거나 값을 다시 읽어올 수도 있는 어떤 컴파일러 최적화도 무력화 되도록 해야만 합니다. 이는 C++1x volatile relaxed load만으로도 충분합니다 [Bec11]. 마지막으로, `maze_find_any_next_cell()` 함수는 한 셀을 방문된 것으로 마크하기 위해 `compare-and-swap`을 사용해야 합니다만, 쓰레드 생성과 합치기에 의해 만들어지는 순서 이후에 어떤 순서 제약도 필요시 되지 않습니다.


`maze_find_any_next_cell()`의 슈도코드는 Listing 6.13에 보여진 것과 동일합니다만, `maze_try_visit_cell()`의 슈도코드는 좀 다른데, Listing 6.15에 보여져 있습니다. Line 8-9는 해당 셀들이 연결되어 있는지 체크하고, 그렇지 않다면 `failure`를 리턴합니다. Line 11-18의 루프에서는 새 셀을 방문된 것으로 마크합니다. Line 13은 해당 셀이 이미 방문된 적 있는지 체크하고, 이 경우엔 line 16에서 `failure`를 리턴합니다만, line 14에서 다른 쓰레드와 마주친 것인지 체크한 후, 마주친 경우라면 line 15에서 해법이 찾아졌음을 알립니다. Line 19에서는 새 셀에 업데이트를 하고, line 20과 21에서 이 쓰레드의 방문된 곳 배열을 업데이트 하며,

Listing 6.15: Partitioned Parallel Helper Pseudocode

```

1 int maze_try_visit_cell(struct maze *mp, int c, int t,
2                         int *n, int d)
3 {
4     cell_t t;
5     cell_t *tp;
6     int vi;
7
8     if (!maze_cells_connected(mp, c, t))
9         return 0;
10    tp = celladdr(mp, t);
11    do {
12        t = READ_ONCE(*tp);
13        if (t & VISITED) {
14            if ((t & TID) != mytid)
15                mp->done = 1;
16            return 0;
17        }
18    } while (!CAS(tp, t, t | VISITED | myid | d));
19    *n = t;
20    vi = (*myvi)++;
21    myvisited[vi] = t;
22    return 1;
23 }

```



**Figure 6.24:** CDF of Solution Times For SEQ, PWQ, and PART

line 22에서 success를 리턴합니다.

성능 테스트는 Figure 6.24에 보여진 것과 같이 심각한 변칙적 결과를 보였습니다. PART의 평균 해법 탐색 시간(17밀리세컨드)은 SEQ의 그것(79밀리세컨드) 보다 두개의 쓰레드만 사용함에도 네배 넘게 빨랐습니다. 다음 섹션에서 이 결과를 분석해 봅니다.

6.5.3 Performance Comparison I

이례적 성능 결과에 대한 첫번째 대응은 버그 유무를 체크하는 것입니다. 이 알고리즘들은 모두 올바른 해결책을 찾아내고 있습니다만, Figure 6.24에 나타난 CDF 그림은 독립적인 데이터를 가정하고 있습니다. 이건 올바른 경우가 아닙니다. 이 성능 테스트들은 무작위적으로 미로를 생성하고, 그 미로에 대해 모든 알고리즘들을

**Figure 6.25:** CDF of SEQ/PWQ and SEQ/PART Solution-Time Ratios**Figure 6.26:** Reason for Small Visit Percentages

돌려보고 있습니다. 따라서 각각의 생성된 미로에 대해 해결책을 찾는데 걸린 시간의 비율의 CDF를 그려보는 게 좀 더 말이 될텐데, Figure 6.25에 그 그림이 그려져 있으며, 여기선 CDF들의 중복이 훨씬 줄어들었습니다. 쓰레드 두개로 이루어진 40배의 성능 향상은 설명이 필요합니다. 무엇보다, 이것은 일을 쪼갤 수 있음이 쓰레드를 추가하는 것으로 인해 전체 연산 비용의 증가를 불러일으키지 않음을 당혹스러울 정도의 병렬성도 아닙니다. 그 대신, 이것은 굴욕적일 정도의 병렬성입니다: 쓰레드를 추가하는 것이 전체 연산 비용을 상당히 줄여줘서 커다란 알고리즘적인 선형적인 성능향상을 초월하는 결과를 이끌어낸 것입니다.

더 나아가서 들여다본 결과 PART는 가끔 미로의 셀들 중 2% 미만만을 방문했는데, SEQ와 PWQ는 9% 미만을 방문한 적이 없었습니다. 이런 차이점에 대한 이유는 Figure 6.26에 보여져 있습니다. 만약 좌상단부터 시작해서 해결책을 찾는 쓰레드가 원에 도달하면 다른 쓰레드는 미로의 우상단에 도착할 수 없습니다. 비슷하게, 만약 다른 쓰레드가 네모에 도달하면, 첫번째 쓰레드는 미로의 좌하단에 도착할 수 없습니다. 따라서, PART는 해법이 아닌 셀들로 이루어진 경로 중 더 작은 부분만을 방문하게 될 것입니다. 한마디로, 선형을




Figure 6.27: Correlation Between Visit Percentage and Solution Time




Figure 6.28: PWQ Potential Contention Points

초월하는 속도 향상은 쓰레드들이 서로의 길을 만들어 주기 때문입니다. 이는 일하는 쓰레드들이 쓰레드들 각자의 길에서 다른 쓰레드들을 벗어나게 하기 위해 노력해왔던 수십년의 병렬 프로그래밍의 경험에 상당히 반대되는 이야기입니다.

Figure 6.27 는 세개의 모든 방법들에 대해 방문된 셀들의 수와 해결책 탐색에 걸리는 시간 사이의 강한 상관관계를 확실히 보여주고 있습니다. PART 의 그림의 경사도는 SEQ 의 그것에 비해 작은데, 이것이 PART 의 쓰레드들이 SEQ 의 단일 쓰레드에 비해 미로의 주어진 부분을 더 빠르게 방문할 것임을 이야기 합니다. PART 의 그림은 또한 작은 방문 퍼센티지에 몰려 있는데, 이는 PART 가 더 적은 일을 하게 되며, 따라서 우리가 관측한 굴욕적인 병렬성을 갖는 것입니다.

PWQ 에 의해 방문되는 셀들로 이루어진 부분들은 SEQ 의 그것과 유사합니다. 또한, PWQ 의 해결책 탐색에 걸리는 시간은 동일한 방문 부분들에도 불구하고 PART 의 그것에 비해 훨씬 큽니다. 이에 대한 이유가 Figure 6.28 에 그려져 있는데, 이 그림에는 두개 이상의 이웃을 가지고 있는 셀마다 붉은 원을 그려두었습니다. 그러한 각각의 셀은 PWQ 에서 경쟁 상황을 초래할 수 있는데, 한 쓰레드는 들어갈 수 있지만 두 쓰레드들이




Figure 6.29: Effect of Compiler Optimization (-O3)

나갈 수 있기 때문에, 이 챕터의 앞부분에서 설명했듯이 성능을 악화시킬 수 있기 때문입니다. 반면에 PART 는 그런 경쟁상황을 한번만 일으키는데, 해법이 찾아졌을 때입니다. 물론, SEQ 는 경쟁상황은 일으키지 않습니다.

PART 의 성능 향상이 인상적이긴 하지만, 순차적인 최적화를 게을리 하지는 않아야 합니다. Figure 6.29 는 SEQ 가 -O3 옵션을 가지고 컴파일 되었을 때에는 최적화 되지 않은 PWQ 보다 두배 정도나 빠르고, 최적화 되지 않은 PART 의 성능에 근접합니다. 세개의 알고리즘을 모두 -O3 옵션을 주고 컴파일한 결과는 (더 빠르긴 하지만) Figure 6.25 에 보여진 그것들과 비슷한 양상을 보입니다만, PWQ 가 SEQ 에 비해 속도향상을 거의 보이지 않는다는 예외를 갖는데, 이는 Amdahl 의 법칙 [Amd67] 에 의함입니다. 하지만, 최적화 되지 않은 SEQ 에 비해 두배의 속도를 갖는게 목표라면, 컴파일러 최적화는 상당히 매력적인 방법이라 할 수 있겠습니다.

캐시 정렬과 패딩이 종종 거짓 공유 (false sharing) 을 줄여서 성능을 개선시키곤 합니다. 하지만, 이 미로 해법 알고리즘들에 있어서는, 미로 셀 배열에 정렬과 패딩을 적용하는 것은 1000x1000 미로에 대해 42 % 까지 성능을 떨어뜨립니다. 캐시 로컬리티는 거짓 공유를 없애는 것보다 더 중요한데, 특히나 큰 미로에선 더욱 그렇습니다. 작은 20x20이나 50x50 미로에서라면, 정렬과 패딩이 PART 에 대해 성능을 40 % 까지 향상시킬 수 있습니다만 이런 작은 크기의 미로에 대해서는 PART 가 쓰레드를 생성하고 소멸시키는데 드는 오버헤드를 상쇄시키기에 충분한 시간을 갖지 못하기에 SEQ 가 더 좋은 성능을 보입니다.

정리하자면, 파티셔닝을 사용한 병렬 미로 해결책은 알고리즘적으로 선형을 초월한 속도향상의 하나의 재미있는 예입니다. 만약 “알고리즘적으로 선형을 초월한 속도 향상” 이 인지 부조화를 일으킨다면, 다음 섹션으로 넘어가 보시기 바랍니다.




Figure 6.30: Partitioned Coroutines




Figure 6.32: Varying Maze Size vs. COPART




Figure 6.31: Varying Maze Size vs. SEQ




Figure 6.33: Mean Speedup vs. Number of Threads, 1000x1000 Maze

6.5.4 Alternative Sequential Maze Solver

알고리즘적으로 선형을 초월한 속도 향상의 존재는 코루틴 (co-routine) 을 통한 병렬성 모의실험을 해볼 가치가 있음을 제시하는데, 예를 들어, Listing 6.14 의 do-while 루프의 각 패스에서 수동으로 컨텍스트 스위칭을 해보는 겁니다. 이 컨텍스트 스위칭은 간단한데, 이 컨텍스트는 변수들 c 와 vi 로만 구성되어 있기 때문입니다: 이 효과를 낼 수 있는 많은 방법들 중, 이 방법이 컨텍스트 스위칭 오버헤드와 방문 퍼센티지 사이의 좋은 트레이드오프입니다. Figure 6.30 에서 볼 수 있듯이 이 코루틴 알고리즘 (COPART) 은 상당히 효과적으로, 한 쓰레드에서의 성능이 두 쓰레드를 사용한 PART 의 30 % 입니다(maze_2seq.c).

6.5.5 Performance Comparison II

Figure 6.31 와 6.32 는 미로의 크기 변화에 따른 효과를 두개의 쓰레드로 동작하는 PWQ 와 PART 를 SEQ 또는 COPART 와 각각 비교해 90 % 의 정확성 에러

막대와 함께 보여주고 있습니다. PART 는 100행 100 열 이상 크기의 미로들에서 SEQ 에 비해 선형성을 초월한 확장성을 보이고 COPART 에 비해서는 적당한 확장성을 보입니다. 에너지 소모가 높은 주파수에서는 대략 주파수의 제곱 정도로 에너지 소모가 증가한다는 가정 [Mud01] 에 기반해서 보면 두 쓰레드를 사용해서 1.4 배의 확장성을 갖는 것은 단일 쓰레드가 같은 해법 탐색 시간을 필요로 할 때 소모하는 에너지와 동일하므로 PART 는 COPART 에 비교했을 때 대략 200행 200 열 크기 미로에서 이론적인 에너지 효율성 손익분기를 넘어섭니다. 반면, PWQ 는 SEQ 에 대해서도 COPART 에 대해서도 빈약한 확장성을 보이는데, 이는 최적화가 적용되었을 때 이야기입니다: Figure 6.31 와 6.32 는 -O3 옵션을 사용해 만들어졌습니다.

Figure 6.33 는 PWQ 와 PART 의 성능을 COPART 에 비교해서 보여주고 있습니다. 두개가 넘는 쓰레드들을 사용해 동작하는 PART 의 경우, 추가된 쓰레드들은 미로의 시작점과 끝점 사이를 대각선으로 동일한

거리로 나뉘어진 위치에서부터 경로 탐색을 시작합니다. 두개가 넘는 쓰레드들을 사용해 동작하는 PART의 이론 종료를 알아채기 위해서는 간략화된 링크 상태 라우팅 [BG87]이 사용되었습니다 (해법은 한 쓰레드가 시작점과 끝점과 연결되면 찾아진 것으로 표시됩니다). PWQ는 상당히 나쁜 성능 결과를 보입니다만, PART는 두개 쓰레드에서, 그리고 다섯개 쓰레드에서 한번 더 손익분기에도 달하는데 다섯개 쓰레드를 넘어서고부터는 적당한 속도향상을 이루어냅니다. 이론적인 에너지 효율성 손익분기는 7개와 8개 쓰레드들에 대해서는 90% 신뢰구간 안에 있습니다. 두개 쓰레드에서 성능이 뾰족하게 솟아오르는 이유는 (1) 두개 쓰레드의 경우의 덜 복잡한 해법 탐색 종료 파악 과정과 (2) 세번째와 그 뒤의 쓰레드들이 유용한 진전을 만들 확률이 좀 더 낮은 편이라는 사실입니다: 오직 처음의 두 쓰레드만이 해법의 경로에 직결됨이 보장됩니다. Figure 6.32에 비해 비교적 실망스러운 이 성능 결과는 2.66GHz로 동작하는 더 크고 오래된 Xeon®에 사용되는 덜 밀접하게 융합된 하드웨어의 탓입니다.

6.5.6 Future Directions and Conclusions

앞으로 해야할 일들이 많이 남아있습니다. 첫째로, 이 섹션은 사람이 미로 해법 탐색에 사용하는 방법 가운데 하나의 방법만을 적용해 보았습니다. 이외의 방법으로는 미로의 일부를 제거하기 위해 벽을 따라가는 방법과 이전에 탐색한 경로의 위치에 기반해서 내부 시작 지점을 고르는 방법 등이 있습니다. 둘째로, 시작지점과 끝지점의 다른 선택은 다른 알고리즘에 좀 더 효과적일 수 있습니다. 셋째로, PART 알고리즘의 첫번째 적용했던 방법인 두개 쓰레드 사용이 단순하기 하지만, 다른 여분의 쓰레드들을 사용하기 위한 방법들이 여럿 있습니다. 최적의 쓰레드 사용은 시작지점과 끝지점에도 의존적일 겁니다. 넷째로, 해결이 불가능한 미로들과 순환적인 미로들에 대한 연구는 재미있는 결과를 내놓을 수 있을 겁니다. 다섯째로, 가벼운 C++11 어토믹 오퍼레이션들은 성능을 개선시킬 수도 있습니다. 여섯째로, 3 차원 미로 (또는 그보다도 높은 차원의 미로들)의 속도 향상을 비교해 보는 것도 재미있을 겁니다. 마지막으로, 미로의 경우, 굴욕적 병렬성은 코루틴들을 사용한 보다 효과적인 순차적 구현을 의미했습니다. 굴욕적 병렬성 알고리즘은 항상 더 효과적인 순차적 구현을 이끌게 될까요, 아니면 코루틴 컨텍스트 스위치 오버헤드가 속도향상을 압도해버리는 고유의 굴욕적 병렬성 알고리즘이 존재할까요?

이 섹션은 미로 해법 탐색 알고리즘의 병렬화를 선보이고 분석해 보았습니다. 일반적인 일거리 대기열 기반의 알고리즘은 컴파일러 최적화가 꺼져있을 때에만 잘 동작했는데, 이는 기준에 고수준의/오버헤드가 많은

언어를 사용해 얻어졌던 결과들 중 일부는 진보된 최적화에 의해서 무효화 될 수도 있음을 의미합니다.

이 섹션은 병렬화를 적용하는 것을 순차적 알고리즘의 파생물로 생각하기보다는 최적화를 위한 첫번째 선택지로 생각하는 것이 개선된 순차적 알고리즘을 위한 길의 기반을 닦는다는 확연한 예 하나를 선보였습니다. 고수준 설계 레벨에서의 병렬성의 응용은 결실 있는 연구가 될 가능성이 큽니다. 이 섹션은 미로 탈출 경로를 탐색하는 문제를 느슨하게 확장성 있는 경우부터 굴욕적으로 병렬적인 경우까지 그리고 그 반대로 풀어보았습니다. 이 경험에 병렬성에 기반한 작업을 무식하게 별로 최적이지 않은 경우가 많은, 이미 존재하는 프로그램에 개조의 형태로 적용되는 기존 성능 결과에 기반한 작은 최적화와 같은 것보다는 설계시점에서의 전체 어플리케이션을 위한 최적화 기법의 첫번째 선택지로 여겨지도록 하는데 동기를 부여하길 바랍니다.

6.6 Partitioning, Parallelism, and Optimization

가장 중요한 건, 이 챕터가 설계 단계에서부터 병렬성을 적용하는 것이 훌륭한 결과를 내놓기는 함에도 불구하고, 이 마지막 섹션에서는 이것만으로 충분하지는 않다는 걸 보입니다. 미로 해법 찾기와 같은 탐색 문제들을 위해, 이 섹션은 병렬 설계보다도 검색 전략이 더 중요함을 보였습니다. 그렇습니다, 이 특별한 미로의 타입에 대해서만큼은 현명하게 병렬성을 적용하는 것이 훌륭한 검색 전략이었습니다만, 이런 부류의 행운은 검색 전략 그 자체에 대한 명확한 초점으로 충분하지 않습니다.

Section 2.2에서 앞서 이야기 했듯이, 병렬성은 많은 최적화 방법 중 하나의 잠재적인 최적화 수단일 뿐입니다. 성공적인 설계는 가장 중요한 최적화에 집중해야 합니다. 저는 다르게 주장하고 싶은 마음이 간절하긴 하지만, 그 최적화는 병렬성일 수도, 병렬성이 아닐 수도 있습니다.

하지만, 병렬성이 올바른 최적화인 많은 경우들을 위해서, 다음 섹션에서는 대부분의 경우 동기화 작업을 처리하는 도구인 락킹에 대해 다룹니다.

Chapter 7

Locking

최근의 동시성 관련 연구에서는 락킹이 악당 역할을 자주 맡았습니다. 많은 논문과 발표들에서, 락킹은 데드락, 컨보잉 (convoying), 스타베이션, 비공정성, 데이터 레이스, 그리고 그외의 모든 동시성에서의 죄악들을 일으킨다고 비난받아왔습니다. 그런데 흥미롭게도, 제품 수준의 공유 메모리 병렬 소프트웨어에서 대부분의 일을 처리하는 역할은, 짐작하시겠지만, 락킹에게 맡아졌습니다. 이 챕터는 이런 악당과 영웅 사이의 이분법에 대해 Figure 7.1 와 7.2 에 그려진 것처럼 그럴싸하게 들여다 보겠습니다.

이런 지킬과 하이드 같은 이분법 뒤에는 많은 이유가 있습니다:

1. 많은 락킹의 죄악들은 대부분의 경우 잘 동작하는 실용적인 설계적 해결책이 존재하는데, 예를 들면:
 - (a) 데드락을 막기 위한 계층적 락의 사용.
 - (b) 리눅스 커널의 lockdep 기능 [Cor06a] 과 같은 데드락 탐지 도구들.
 - (c) Chapter 10에서 다루어지게 되는 배열, 해시 테이블, 그리고 래디스 트리와 같은, 락킹에 친화적인 데이터 구조.
2. 락킹의 죄악들 중 일부는 높은 수준의 경쟁 상황에서만 발생하는데, 그런 수준은 잘못 설계된 프로그램들에서만 도달 가능한 수준입니다.
3. 락킹의 죄악들 중 일부는 락킹과 함께 사용되는 다른 동기화 메커니즘의 사용으로 막아질 수도 있습니다. 이런 다른 메커니즘들에는 통계적 카운터 (Chapter 5 을 참고하세요), 레퍼런스 카운터 (Section 9.2 을 참고하세요), 해저드 포인터 (Section 9.3 를 참고하세요), 시퀀스 락 (Sequence lock)을 사용하는 읽기 (Section 9.4 를 참고하세요), RCU (Section 9.5 를 참고하세요), 그리고 간단한 non-blocking 데이터 구조체들이 있습니다 (Section 14.2 을 참고하세요).

Locking is the worst general-purpose synchronization mechanism except for all those other mechanisms that have been tried from time to time.

*With apologies to the memory of Winston Churchill
and to whoever he was quoting*

4. 아주 최근까지도 대부분의 거대 공유 메모리 병렬 프로그램들은 비밀리에 개발되었고, 따라서 대부분의 연구자들은 이런 실용적인 해결책에 대해 배우기가 어려웠습니다.
5. 락킹은 일부 소프트웨어 제품들에서는 매우 잘 동작하지만 다른 것들에서는 매우 안좋게 동작합니다. 락킹이 잘 동작하는 소프트웨어를 만들었던 개발자들은 락킹이 나쁘게 동작하는 소프트웨어를 작업했던 사람들에 의해 락킹에 대해 훨씬 더 궁정적인 의견을 가질 수 있는데 이는 Section 7.5에서 다루어질 것입니다.
6. 모든 좋은 이야기는 악당이 필요하고, 락킹은 연구 논문의 희생양으로써의 길고 명예로운 역사를 맡아왔습니다.

Quick Quiz 7.1: 희생양 역할을 한게 어떻게 명예로운 것으로 여겨질 수가 있나요??? ■

이 챕터는 락킹의 더 심각한 죄악들을 막는 여러 방법들에 대해 간략히 살펴봅니다.

7.1 Staying Alive

I work to stay alive.

Bette Davis

락킹이 데드락과 스타베이션으로 인해 고발당한다는 사실을 놓고 보면, 공유 메모리 병렬 프로그램 개발자들의 중요한 관심사는 그저 프로그램이 동작하는 상태를 유지하는 겁니다. 따라서 다음의 섹션들에서는 데드락, 라이브락, 스타베이션, 비공정성, 그리고 비효율성에 대해 다뤄봅니다.




Figure 7.1: Locking: Villain or Slob?




Figure 7.2: Locking: Workhorse or Hero?

7.1.1 Deadlock

데드락은 한 무리의 쓰레드들이 각각 최소 하나의 락을 잡은 상태로 같은 무리의 다른 멤버가 잡고 있는 락을 놓기를 기다리고 있을 때 발생합니다.

어떤 외부의 간섭 같은 것 없이는 데드락은 영원히 존재합니다. 어떤 쓰레드도 자신이 기다리고 있는 락을 쥐고 있는 쓰레드가 그 락을 놓아주기 전까지는 얻을 수 없습니다만, 그 락을 쥐고 있는 쓰레드는 그 락을 얻기 위해 기다리고 있는 쓰레드가 쥐고 있는 락을 얻기 전까지는 자신의 락을 놓을 수 없습니다.

데드락 시나리오를 쓰레드와 락을 노드로 표현한 방향성이 존재하는 그래프로 표현해 볼 수 있는데, Fig-




Figure 7.3: Deadlock Cycle

ure 7.3에 그러한 표현이 그려져 있습니다. 락에서 쓰레드로의 화살표는 해당 쓰레드가 해당 락을 쥐고 있음을 의미하는데, 예를 들어 Thread B는 Lock 2와 4를 쥐고 있습니다. 쓰레드에서 락으로의 화살표는 해당 쓰레드가 해당 락을 얻기 위해 기다리고 있음을 의미하는데, 예를 들어 Thread B는 Lock 3를 얻기 위해 기다리고 있습니다.

데드락 시나리오는 항상 최소한 하나 이상의 데드락 사이클을 갖게 됩니다. Figure 7.3에서는 Thread B, Lock 3, Thread C, Lock 4, 그리고 다시 Thread B로 이어지는 사이클이 존재합니다.

Quick Quiz 7.2: 하지만 데드락의 정의는 단지 각 쓰레드가 최소 하나 이상의 락을 잡고 일부 쓰레드에 의해 잡혀 있는 또다른 락을 기다리고 있는 것이잖아요. 어떻게 거기에 사이클이 존재하는지 알 수 있죠? ■

데드락 상태로부터 시스템을 복구하는 데이터베이스 시스템과 같은 소프트웨어 환경도 존재합니다만, 이런 방법은 한 쓰레드가 죽거나 락이 강제로 다른 쓰레드로부터 강탈될 수 있을 것을 필요로 합니다. 이와 같이 죽이고 강탈하는 방법은 트랜잭션들에 대해서는 적당할 수 있겠지만, 커널과 어플리케이션 수준에서의 락킹의 사용에는 많은 경우 문제가 될 수 있습니다: 그로 인해 발생하는 부분적으로만 업데이트된 구조체를 처리하는 것은 상당히 복잡하고 위험하고 오류를 만들기 쉽습니다.

따라서 커널과 어플리케이션들은 데드락으로부터 회복을 하기보다는 데드락을 회피하는 방법을 사용하려 합니다. 여러개의 데드락 회피 전략이 존재하는데, 계층적 락킹 (Section 7.1.1.1), 지역적 계층적 락킹 (Section 7.1.1.2), 레이어를 사용한 계층적 락킹 (Section 7.1.1.3), 락들로의 포인터들을 갖는 API들을 다루는 전략들 (Section 7.1.1.4), 조건적 락킹 (Section 7.1.1.5), 필요한 락들 전체를 처음에 획득하기 (Section 7.1.1.6),

한번에 하나의 락만 사용하기 설계 (Section 7.1.1.7), 그리고 시그널/인터럽트 핸들러 전략이 포함됩니다. (Section 7.1.1.8). 모든 상황에 완벽하게 동작하는 데드락 회피 전략이 존재하긴 합니다만, 그 중에서도 데드락 회피 도구를 잘 선택하는 방법이 있습니다.

7.1.1.1 Locking Hierarchies

락킹 계층은 락들 사이에 순서를 만들고 순서에 위배되게 락들을 획득하는 행위를 막습니다. Figure 7.3 의 상황에서는 한 쓰레드가 획득하려 하는 락과 같거나 더 큰 숫자의 락을 이미 쥐고 있다면 해당 그래프에서 사라지도록, 락들을 숫자에 기반한 규칙으로 순서세울 수 있을겁니다. Thread B 는 이 계층을 위반한 셈인데, Lock 4 를 쥔 상태에서 Lock 3 를 획득하려 하고 있기 때문이고, 이로인해 데드락이 발생했습니다.

다시 말하지만, 락킹 계층을 적용하기 위해서는 락들 사이에 순서를 잡아주고 순서에 위배되게 락을 획득하는 행위를 막아야 합니다. 커다란 프로그램에서는 락킹 계층을 강제하기 위해 도구를 사용하는 것이 현명할 겁니다 [Cor06a].

7.1.1.2 Local Locking Hierarchies

하지만, 전역적이라는 락킹 계층의 본연적 특성은 이 방법을 라이브러리 함수에 적용하기 어렵게 합니다. 어쨌든, 주어진 라이브러리 함수를 사용하는 프로그램은 아직 작성되지도 않았는데 어떻게 이 불쌍한 라이브러리 함수 구현자가 아직 작성되지 않은 프로그램의 락킹 계층에 충실할 수 있기를 바랄 수 있겠어요?

다행히도 일반적인 특수한 경우가 있는데 해당 라이브러리 함수가 호출자의 코드를 전혀 사용하지 않을 때입니다. 이 경우, 호출자의 락들은 라이브러리의 락들을 잡은 상태에서 잡혀지지 않고, 따라서 라이브러리와 호출자 둘 다의 락들로부터 생성되는 데드락 사이클은 존재할 수 없습니다.

Quick Quiz 7.3: 이 규칙에 대한 어떤 예외가 존재해서, 라이브러리 코드가 호출자의 어떤 함수도 실행하지 않는다는 조건 하에서도 라이브러리와 호출자 둘 다의 락을 포함하는 데드락 사이클이 실제로는 존재할 수도 있을 수 있나요? ■

하지만 라이브러리 함수가 실제로 호출자의 코드를 실행하는 경우를 생각해 봅시다. 예를 들어, `qsort()` 함수는 호출자가 제공하는 비교 함수를 실행합니다. `qsort()` 의 동시성 있는 구현은 아마도 락킹을 사용할 텐데, 이는 아마도 그렇지 않을 확률이 크긴 한 케이스지만 비교 함수가 락킹에도 관여되는 좀 복잡한 함수인 경우라면 데드락을 일으킬 수 있습니다. 이 라이브러리 함수는 어떻게 데드락을 막을 수 있을까요?




Figure 7.4: Without Local Locking Hierarchy for `qsort()`




Figure 7.5: Local Locking Hierarchy for `qsort()`

이 경우의 황금률은 “알 수 없는 코드를 실행하기 전에 모든 락을 놓아버리기”입니다. 이 규칙을 따르기 위해선, 앞서 언급한 `qsort()` 함수는 비교 함수를 실행하기 전에 모든 락을 해제해야만 합니다.

Quick Quiz 7.4: 하지만 `qsort()` 가 비교 함수를 실행하기 전에 그 자신의 락들을 모두 해제해버리면, 다른 `qsort()` 쓰레드들과의 경주 문제로부터 안전성을 어떻게 지킬 수 있나요? ■

지역적 락킹 계층화의 장점을 보기 위해, Figure 7.4 와 7.5 를 비교해 보시기 바랍니다. 두개의 그림에서, 어플리케이션의 함수들인 `foo()` 와 `bar()` 는 각각 Lock A 와 B 를 잡은 상태로 `qsort()` 를 호출합니다. 이것은 `qsort()` 의 병렬화된 구현이기 때문에, 이 함수

는 Lock C 를 잡습니다. 함수 `foo()` 는 `cmp()` 함수를 `qsort()` 에게 전달하고, `cmp()` 함수는 Lock B 를 잡습니다. 함수 `bar()` 는 간단한 정수 비교 함수 (그림에는 보이지 않습니다)를 `qsort()` 에게 전달하고, 이 간단한 함수는 어떤 락을 잡거나 하지 않습니다.

이제, `qsort()` 가 앞서 이야기한 모든 락을 놓기 황금률을 어기게 되어서 Figure 7.4 에 보인 것처럼 `cmp()` 를 호출하는 동안 Lock C 를 잡고 있는다면 데드락이 일어날 수 있습니다. 이를 좀 더 자세히 보기 위해, 한 쓰레드가 `foo()` 를 호출했고 두번째 쓰레드가 그사이 `bar()` 를 호출하는 경우를 생각해 봅시다. 첫번째 쓰레드는 Lock A 를 잡고 두번째 쓰레드는 Lock B 를 잡게 됩니다. 만약 첫번째 쓰레드의 `qsort()` 함수 호출이 Lock C 를 잡게 된다면, 이제 `qsort()` 안에서 `cmp()` 함수를 호출했을 때 Lock B 를 잡는 것은 불가능해집니다. 하지만 첫번째 쓰레드가 Lock C 를 잡고 있어서 두번째 쓰레드의 `qsort()` 호출은 그걸 잡지 못하게 되고, 따라서 Lock B 를 놓을 수도 없게 되므로, 데드락을 초래하게 됩니다.

반면에, 만약 `qsort()` 가 비교 함수 (`qsort()` 의 관점에서 보기에는 알 수 없는 코드입니다) 를 호출하기 전에 Lock C 를 놓게 된다면, 데드락은 Figure 7.5 에 보이는 것처럼 막아집니다.

만약 각 모듈이 알 수 없는 코드를 실행하기 전에 모든 락들을 내려놓게 된다면, 그리고 각 모듈이 개별적으로 데드락을 막고 있다면 데드락은 생기지 않게 됩니다. 따라서 이 규칙은 데드락 분석을 크게 간략화 시키고 모듈성을 크게 향상시킵니다.

7.1.1.3 Layered Locking Hierarchies

불행하게도, `qsort()` 가 앞서 이야기한 비교 함수를 호출하기 전에 자신의 모든 락들을 해제하는 것은 불가능 할 수 있습니다. 이런 경우, 알 수 없는 코드를 실행하기 전에 모든 락들을 해제하는 지역적 락킹 계층을 사용할 수 없습니다. 하지만, 그 대신에 층을 이룬 (Layered) 락킹 계층을 사용할 수 있는데, 이 방법은 Figure 7.6 에 그려져 있습니다. 여기서, `cmp()` 함수는 Lock A, B, C 가 잡힌 이후에 새로운 Lock D 를 사용함으로써 데드락을 막습니다. 따라서 전역적인 데드락 계층에 세개의 층이 존재하는 셈인 것으로, 첫번째 층은 Lock A 와 B 를, 그리고 두번째 층은 Lock C 를 가지며, 세번째 층은 Lock D 를 포함합니다.

기계적 방법으로 `cmp()` 함수가 새로운 락인 Lock D 를 사용하도록 수정하는건 일반적으로 불가능하다는 것을 알아 두시기 바랍니다. 오히려 그 반대입니다: 그러한 변경을 위해서는 대부분의 경우 기초적인 설계 레벨에서의 수정을 필요로하게 됩니다. 하지만 더도 아니고 덜도 아니고, 그런 변경을 위해 필요한 노력은




Figure 7.6: Layered Locking Hierarchy for `qsort()`

일반적으로 데드락을 막기 위해서 치뤄야 하는 대가 치고는 적은 편입니다.

알 수 없는 코드를 실행하기 전에 모든 락을 해제하는 것이 비현실적인 또 다른 예를 들어보기 위해서는, Listing 7.1 (`locked_list.c`) 에 보여진 것과 같이 링크드 리스트를 순회하는 반복자 (iterator) 를 생각해 보시기 바랍니다. `list_start()` 함수는 리스트의 락을 잡고서 첫번째 원소를 리턴하고 (원소가 존재한다면), `list_next()` 함수는 리스트의 그 다음 원소로의 포인터를 리턴하는데, 리스트의 끝에 도달한 경우에는 앞서 잡았던 락을 해제하고 `NULL` 을 리턴합니다.

Listing 7.2 는 이 리스트 반복자가 어떻게 사용될 수 있는지 보여줍니다. Line 1-4 는 하나의 정수를 포함하는 `list_ints` 원소를 정의하고 line 6-17 에서는 이 원소가 포함된 리스트에의 순회를 어떻게 반복하는지 보입니다. Line 11 에서는 이 리스트를 잡고 첫번째 원소로의 포인터를 얻어온 후, line 13 에서 해당 원소에 동봉되어 있는 `list_ints` 구조체로의 포인터를 얻어오고, line 14 에서 연관된 정수를 출력하고서, line 15 에서 다음 원소로 넘어갑니다. 이 코드는 상당히 간단하고, 락킹을 모두 숨겼습니다.

즉, 각 리스트의 원소를 처리하는 코드가 그 스스로 `list_start()` 나 `list_next()` 를 호출하는 다른 코드와 함께 사용하는 행위, 즉 데드락을 초래할 수 있는 행위를 하지 않는 한 이 락킹은 계속 숨겨져 있을 수

Listing 7.1: Concurrent List Iterator

```

1 struct locked_list {
2     spinlock_t s;
3     struct cds_list_head h;
4 };
5
6 struct cds_list_head *list_start(struct locked_list *lp)
7 {
8     spin_lock(&lp->s);
9     return list_next(lp, &lp->h);
10 }
11
12 struct cds_list_head *list_next(struct locked_list *lp,
13                                 struct cds_list_head *np)
14 {
15     struct cds_list_head *ret;
16
17     ret = np->next;
18     if (ret == &lp->h) {
19         spin_unlock(&lp->s);
20         ret = NULL;
21     }
22     return ret;
23 }

```

Listing 7.2: Concurrent List Iterator Usage

```

1 struct list_ints {
2     struct cds_list_head n;
3     int a;
4 };
5
6 void list_print(struct locked_list *lp)
7 {
8     struct cds_list_head *np;
9     struct list_ints *ip;
10
11     np = list_start(lp);
12     while (np != NULL) {
13         ip = cds_list_entry(np, struct list_ints, n);
14         printf("\t%d\n", ip->a);
15         np = list_next(lp, np);
16     }
17 }

```

있습니다. 이렇게 리스트 반복자 락킹을 구현하면서 데드락을 막기 위해 락킹 계층을 여러 레이어에 층층이 놓을 수 있습니다.

이 층쌓기 방법은 임의의 많은 수의 레이어들로 확장될 수도 있습니다만, 각각의 추가된 레이어는 락킹 설계의 복잡도를 증가시킵니다. 그런 증가된 복잡도는 특히 객체지향적 설계의 어떤 타입들에는 불편할 수 있는데, 코드의 제어와 수행이 많은 수의 객체들 사이를 규칙이 정해지지 않은 형태로 왔다 갔다하게 되는 경우가 그런 경우입니다.¹ 이런 객체지향적 설계의 습관들과 데드락 회피의 필요성 사이의 미스매치는 병렬 프로그래밍이 어떤 사람들에게는 매우 어렵다고 인지되는 중요한 이유입니다.

수많은 레이어를 사용하는 락킹 계층들에 대한 일부 대안책은 Chapter 9에서 다뤄집니다.

¹ 이런 것들을 일컫기를 “객체지향적 스파게티 코드”라고 합니다.

Listing 7.3: Protocol Layering and Deadlock

```

1 spin_lock(&lock2);
2 layer_2_processing(pkt);
3 nextlayer = layer_1(pkt);
4 spin_lock(&nextlayer->lock1);
5 layer_1_processing(pkt);
6 spin_unlock(&lock2);
7 spin_unlock(&nextlayer->lock1);

```

7.1.1.4 Locking Hierarchies and Pointers to Locks

일부 예외가 있긴 하지만, 락으로의 포인터를 갖는 외부의 API는 대부분의 경우 잘못 설계된 API입니다. 내부의 락을 어떤 다른 소프트웨어 컴포넌트에서 처리하는 것은 정보 은닉이라는 핵심 설계 원칙에 위배되는 행위입니다.

Quick Quiz 7.5: 락으로의 포인터를 함수에 넘기는 게 완벽하게 합리적인 예외를 하나만 들어 보세요. ■

예외 가운데 하나는 어떤 것을 띠맡게 되는 함수들인데, 호출자의 락은 띠맡겨지기 전에 반드시 잡혀야만 하지만 그 락은 해당 함수가 리턴하기 전에는 해제되어야만 하는 경우입니다. 그런 함수의 한 예는 POSIX `pthread_cond_wait()` 와 같은 함수가 될텐데, `pthread_mutex_t` 로의 포인터를 넘김으로써 일어날 조건을 놓쳐서 계속 깨어날 조건을 기다리고만 있게 되는 일을 방지합니다.

Quick Quiz 7.6: `pthread_cond_wait()` 함수가 먼저 그 뮤텍스를 해제하고 나서 다시 획득한다는 사실은 데드락의 가능성을 제거하는 거 아닌가요? ■

다시 말해, 어떤 락으로의 포인터를 인자로 받거나 리턴 값으로 취하는 API를 외부로 노출시키고자 한다면 그 API 설계를 다시한번 조심스럽게 고려해 보시기 바랍니다. 그건 해야만 할 옳은 일일 수도 있을지 모르겠습니다만, 그간의 경험은 그렇지 않을 가능성이 높음을 이야기 합니다.

7.1.1.5 Conditional Locking

하지만 합리적인 락킹 계층이 존재하지 않는다고 생각해봅시다. 이런 상황은 실제 세상에 존재할 수 있는데, 예를 들어보자면 패킷이 양방향에서 오가는 계층적 네트워크 프로토콜 스택을 생각해 볼 수 있겠습니다. 이 경우, 한 패킷을 한 계층에서 다른 계층으로 보내고자 할 때 양 계층에서 모두 락을 잡아야 할 필요가 있을 수 있습니다. 패킷들은 이 프로토콜 스택의 위로도 아래로도 이동될 수 있다는 점을 생각해 보면, 이는 Listing 7.3에 보여진 것처럼 데드락을 유발하기 좋은 경우입니다. 여기서, 랜선을 향해 스택의 아래 방향으로 이동하게 되는 패킷은 다음 계층의 락을 위에서 아래 순서로 잡아야만 합니다. 랜선으로부터 스택의 위 방향으로 이동하게 되는 패킷들은 그 락들을 아래에서 위 순서대로 잡아야

Listing 7.4: Avoiding Deadlock Via Conditional Locking

```

1 retry:
2   spin_lock(&lock2);
3   layer_2_processing(pkt);
4   nextlayer = layer_1(pkt);
5   if (!spin_trylock(&nextlayer->lock1)) {
6     spin_unlock(&lock2);
7     spin_lock(&nextlayer->lock1);
8     spin_lock(&lock2);
9     if (layer_1(pkt) != nextlayer) {
10       spin_unlock(&nextlayer->lock1);
11       spin_unlock(&lock2);
12       goto retry;
13     }
14   }
15   layer_1_processing(pkt);
16   spin_unlock(&lock2);
17   spin_unlock(&nextlayer->lock1);

```

한다는 점을 상기해 보면, 해당 그림의 line 4에서의 락 획득은 데드락을 초래할 수 있습니다.

이 경우에 데드락을 막을 수 있는 한가지 방법은 락킹 계층을 적용하되, 락을 위에서 아래 순서로 잡아야 할 경우에는 Listing 7.4에 보인 것처럼 조건적으로 잡는 것입니다. 무조건적으로 layer-1 락을 획득하는 대신에, line 5에서는 그 락을 `spin_trylock()` 기능을 사용해 조건적으로 획득합니다. 이 기능은 만약 락이 획득 가능하다면 곧바로 락을 획득해 버리고 (0이 아닌 값을 리턴합니다), 그렇지 않다면 락을 잡지 않고 0을 리턴합니다.

만약 `spin_trylock()`이 성공했다면, line 15는 필요한 layer-1의 처리를 진행합니다. 그렇지 않다면, line 6에서 락을 해제하고 line 7과 8에서 올바른 순서대로 그 락들을 다시 잡습니다. 불행히도, 시스템에는 여러 네트워킹 디바이스들이 존재할 수 있는데 (예: 이더넷과 WiFi), 따라서 `layer_1()` 함수는 라우팅 결정을 해야만 합니다. 이 결정은 언제든 바뀔 수도 있는데, 특히 그 시스템이 모바일 기기라면 더욱 그렇습니다.² 따라서, line 9는 그 결정을 다시 한번 체크해 봐야 하고, 바뀌었다면 그 락들을 놓고 일을 처음부터 다시 시작해야 합니다.

Quick Quiz 7.7: Listing 7.3에서 Listing 7.4로의 변경이 어디서나 적용될 수 있는 걸까요? ■

Quick Quiz 7.8: 그렇지만 Listing 7.4에서의 추가된 복잡도는 그게 데드락을 막는다는 점을 생각하면 꽤 가치있는 거예요, 맞죠? ■

7.1.1.6 Acquire Needed Locks First

조건적 락킹의 중요하고 특수한 한 케이스에서는 모든 필요한 락들이 추후의 작업 진행을 이루기 전에 획득됩니다. 이런 경우에, 처리하는 일이 면등성을 가질 필요는

없습니다: 이미 쥐고 있는 락들 가운데 하나를 먼저 놓지 않고는 어떤 락을 잡는 것이 불가능함이 밝혀진다면, 그냥 모든 락을 놓아버리고 다시 락 획득을 시도합니다. 모든 필요한 락들을 한번이라도 모두 잡기만 한다면 추후의 작업이 진행됩니다.

하지만, 이런 처리 방법은 *livelock*을 초래할 수 있는데, 이에 대해서는 Section 7.1.2에서 이야기 합니다.

Quick Quiz 7.9: Section 7.1.1.6에서 이야기한 “필요한 락들을 먼저 획득하기” 방법을 사용할 때에, 어떻게 하면 *livelock*을 막을 수 있을까요? ■

관련된 방법으로 two-phase 락킹 [BHG87]이 있는데, 이 방법은 트랜잭션을 제공하는 상용 수준의 데이터베이스 시스템들에서 오랫동안 사용되어 왔습니다. Two-phase 락킹 트랜잭션의 첫번째 페이즈 (phase)에서는 락들은 획득은 되지만 해제는 되지 않습니다. 모든 필요한 락들이 획득된다면, 이 트랜잭션은 두번째 페이즈로 들어가게 되는데, 이 페이즈에서는 락들이 해제만 되고, 획득은 되지 않습니다. 이 락킹 방법은 데이터베이스들이 `serializability`를 트랜잭션들에게 보장해줄 수 있게 하는데, 달리 말하자면, 트랜잭션들에 의해 만들어지고 보여지는 모든 값들이 모든 트랜잭션들의 어떤 전체적인 순서에 대해 일관적이게 될 것을 보장해 주기 위해 사용됩니다. 그런 많은 시스템들은 트랜잭션들을 중단 (abort) 시킬 수 있는 기능에 의존하는데, 사실 모든 필요한 락들이 획득되기 전까지는 공유된 데이터에 어떤 변경도 가하지 않도록 하는 것으로 단순화 시킬 수도 있습니다. *Livelock*과 *deadlock*은 그런 시스템들에서의 문제거리들인데, 실용적인 해결책들은 많은 데이터베이스 서적들에서 찾을 수 있을 겁니다.

7.1.1.7 Single-Lock-at-a-Time Designs

어떤 경우에는, 락으로 보호되는 영역을 중첩시키는 걸 막아서 데드락을 막을 수 있습니다. 예를 들어, 만약 문제가 완벽하게 분리될 수 있는 성질의 것이라면, 각 분리된 영역에 락을 하나씩 할당할 수 있을 겁니다. 이렇게 되면 하나의 파티션을 작업하는 쓰레드는 그에 연관된 락 하나만 잡으면 됩니다. 어떤 쓰레드도 한번에 하나 이상의 락을 잡지는 않으므로, 데드락은 발생할 수 없습니다.

하지만, 어떤 락도 잡혀있지 않은 때에도 필요한 데이터 구조체들은 존재함을 보장해줄 어떤 메커니즘이 반드시 있어야만 합니다. 그런 메커니즘 가운데 하나를 Section 7.4에서 이야기 해보고, Chapter 9에서 그 외에 몇가지 다른 메커니즘들을 살펴봅니다.

7.1.1.8 Signal/Interrupt Handlers

시그널 핸들러와 연관된 데드락들은 시그널 핸들러 안에서 `pthread_mutex_lock()` 함수를 호출하는 것은

² 그리고, 1900년대와는 다르게, 모바일 기기는 상당히 흔해졌죠.

허용되지 않는 행위라는 것을 알리는 것만으로도 빠르게 없앨 수 있습니다 [Ope97]. 하지만, 시그널 핸들러 안에서 사용될 수 있는 손으로 만든 락킹 도구(대부분의 경우 지혜롭지 못한 행동입니다만)를 사용할 가능성도 존재합니다. 그와는 별개로, 모든 운영체제 커널들은 커널에서는 시그널 핸들러와 유사한 인터럽트 핸들러 안에서의 락 획득을 허가합니다.

여기서의 트릭은 인터럽트 핸들러 안에서 잡을 수도 있는 락이라면 어떤 락이든지 잡을 때마다 시그널들을 막아버리는(또는, 경우에 따라서, 인터럽트를 무효화 시킬 수도 있습니다) 겁니다. 더 나아가서, 그런 락을 잡고 있다면, 시그널들을 블락시키지 않은 채로 시그널 핸들러 밖에서 한번이라도 잡은 적 있는 락을 잡으려 하는 것 역시 안됩니다.

Quick Quiz 7.10: 시그널 핸들러 안에서 획득되는 Lock B 를 잡은 채로 시그널들을 블락시키지 않고 시그널 핸들러 밖에서 획득되는 Lock A 를 잡는 행위가 해선 안되는 행위인 이유가 뭐죠? ■

일부 시그널들을 위한 핸들러들에서 한 락을 잡았다면, 그 시그널들 모두는 그 락이 획득될 때마다, 심지어 그 락이 시그널 핸들러 안에서 잡힐 때 조차도 블락되어야만 합니다.

Quick Quiz 7.11: 시그널 핸들러 안에서 어떻게 시그널들을 블락시킬 수가 있죠? ■

안타깝게도, 시그널들을 블락하고 블락 해제하는 행위는 일부 운영체제에서는 많은 비용을 필요로 할 수 있는데, 특히 리눅스도 포함되고, 따라서 성능에 주안점을 둔다는 말은 곧 시그널 핸들러들 안에서 획득되는 락들은 시그널 핸들러들 안에서만 획득되며, 어플리케이션 코드와 시그널 핸들러 사이의 통신에는 락을 사용하지 않는 동기화 메커니즘만을 사용한다는 의미가 되곤 합니다.

또는 치명적인 문제 상황을 처리하기 위한 경우를 제외하고는 시그널 핸들러를 아예 사용하지 않는 방법도 있습니다.

Quick Quiz 7.12: 시그널 핸들러들 안에서 락을 잡는 행위가 그렇게 나쁜 생각이라면, 그걸 안전하게 해내기 위한 생각 자체는 대체 왜 하는거죠? ■

7.1.1.9 Discussion

공유 메모리 병렬 프로그래머가 사용할 수 있는 수많은 데드락 방지 전략이 존재합니다만 그 중 어느 것도 잘 들어맞지 않는 순차적 프로그램들도 존재하지요. 이게 전문적인 프로그래머들이라면 자신의 도구상자에 두개 이상의 도구를 갖추고 있는 이유입니다: 락킹은 훌륭한 동시성 제어 도구이지만, 다른 도구들을 가지고 다를 수 있는 일들도 많습니다.

Quick Quiz 7.13: 다양한 객체들 사이로 실행 제어가 완전 자유롭게 오가는 객체 지향 어플리케이션이어서

Listing 7.5: Abusing Conditional Locking

```

1 void thread1(void)
2 {
3     retry:
4     spin_lock(&lock1);
5     do_one_thing();
6     if (!spin_trylock(&lock2)) {
7         spin_unlock(&lock1);
8         goto retry;
9     }
10    do_another_thing();
11    spin_unlock(&lock2);
12    spin_unlock(&lock1);
13 }
14
15 void thread2(void)
16 {
17     retry:
18     spin_lock(&lock2);
19     do_a_third_thing();
20     if (!spin_trylock(&lock1)) {
21         spin_unlock(&lock2);
22         goto retry;
23     }
24     do_a_fourth_thing();
25     spin_unlock(&lock1);
26     spin_unlock(&lock2);
27 }
```

직관적인 락킹 계층, 레이어, 또는 다른 것들이 존재하지 않는 경우³ 라면 그 어플리케이션은 어떻게 병렬화 시켜야 할까요? ■

과장 없이 이야기 하건대, 이 섹션에서 이야기된 전략들은 많은 환경에서 꽤 유용한 것으로 입증되었습니다.

7.1.2 Livelock and Starvation

조건적 락킹은 효과적인 데드락 예방책이긴 하지만, 남용될 수도 있습니다. 예를 들어서, Listing 7.5에 보여진 것과 같이 아름답도록 대칭적인 예제 코드에 대해 생각해 봅시다. 이 예제의 아름다운 부분은 추한 livelock의 가능성을 감추고 있습니다. 이를 드러내 보이기 위해, 다음과 같은 일련의 이벤트들이 일어나는 경우를 생각해 봅시다:

1. Thread 1 이 line 4에서 lock1 을 잡는데 성공하고 do_one_thing() 을 호출합니다.
2. Thread 2 가 line 18에서 lock2 를 잡고 do_a_third_thing() 을 호출합니다.
3. Thread 1 이 line 6에서 lock2 를 잡으려 시도합니다만 Thread 2 가 그 락을 이미 잡고 있기 때문에 실패합니다.
4. Thread 2 가 line 20에서 lock1 을 획득하려 시도하지만, Thread 1 이 그 락을 이미 잡고 있으므로 실패합니다.

³ “객체 지향 스파게티 코드”라고도 알려져 있죠.

Listing 7.6: Conditional Locking and Exponential Backoff

```

1 void thread1(void)
2 {
3     unsigned int wait = 1;
4     retry:
5         spin_lock(&lock1);
6         do_one_thing();
7         if (!spin_trylock(&lock2)) {
8             spin_unlock(&lock1);
9             sleep(wait);
10            wait = wait << 1;
11            goto retry;
12        }
13        do_another_thing();
14        spin_unlock(&lock2);
15        spin_unlock(&lock1);
16    }
17
18 void thread2(void)
19 {
20     unsigned int wait = 1;
21     retry:
22         spin_lock(&lock2);
23         do_a_third_thing();
24         if (!spin_trylock(&lock1)) {
25             spin_unlock(&lock2);
26             sleep(wait);
27             wait = wait << 1;
28             goto retry;
29         }
30         do_a_fourth_thing();
31         spin_unlock(&lock1);
32         spin_unlock(&lock2);
33 }

```


5. Thread 1 이 line 7에서 lock1 을 해제하고 line 3의 retry 로 점프합니다.
6. Thread 2 가 line 21에서 lock2를 해제하고 line 17의 retry 로 점프합니다.
7. 이런 livelock 댄스가 시작부터 다시 반복됩니다.

Quick Quiz 7.14: Listing 7.5 에 보여진 livelock 은 어떻게 예방할 수 있나요? ■

Livelock 은 starvation 의 한 극단적인 예로 생각되어 질 수 있는데, 여러 쓰레드들 중 하나만이 아니라 모든 쓰레드들이 굽게 되는 경우라고 볼 수 있습니다.⁴

Livelock 과 starvation 은 소프트웨어 트랜잭션을 메모리 구현에 있어서의 심각한 문제이고, 따라서 이런 문제들을 해결하기 위해 *contention manager*의 개념이 만들어졌습니다. 락킹의 경우에는 exponential backoff 방법으로 이 livelock 과 starvation 을 해결할 수 있습니다. 이 방법은 Listing 7.6 에 보여진 것처럼 매번 재시도를 할때마다 시도에 실패한 다음 재시도하기 전까지

⁴ Livelock, starvation, 그리고 unfairness 같은 단어들의 정확한 정의에 너무 매달리지 말기 바랍니다. 어떤 쓰레드 무리가 일의 진행을 만들거나 가지 못하고 있는 상황은 그 상황에 어떤 이름을 붙일지에 상관없이 해결되어야만 하는 문제일 뿐입니다.

**Figure 7.7:** System Architecture and Lock Unfairness

기다리는 딜레이 시간을 지수적으로 증가시키는 방법입니다.

Quick Quiz 7.15: Listing 7.6 에서 어떤 문제를 발견할 수 있나요? ■

하지만, 더 나은 결과를 위해, 이 backoff 의 최대 크기는 어딘가에 바운드 되어야만 하고, 심지어 이보다도 높은 경쟁상황에서의 더 나은 결과가 Section 7.3.2 에서 이야기 되는 대기열을 서는 락킹 [And90] 을 통해 관찰되었습니다. 물론, 가장 최선의 방법은 락 경쟁이 낮은 수준으로 유지되는 좋은 별렬 설계를 사용하는 것입니다.

7.1.3 Unfairness

불공정성은 starvation 의 덜 심각한 형태라고 생각되어 질 수 있는데, 특정 락을 가지고 경쟁하고 있는 쓰레드들 가운데 일부 쓰레드들이 그 락을 획득하는데 더 높은 우선순위를 갖는 경우입니다. 이는 공유된 캐시나 NUMA 특성을 가지고 있는 기계들에서 일어날 수 있는 일인데, 예를 들어 Figure 7.7 와 같은 경우입니다. CPU 0 가 다른 모든 CPU 들이 획득하려 하고 있는 락을 놓게 되는 경우, CPU 0 과 1 사이의 공유된 접합부는 CPU 1 이 CPU 2-7 에 비해 혜택을 갖게 될 것임을 의미합니다. 따라서 CPU 1 은 그 락을 잡는데 성공할 확률이 큽니다. CPU 1 이 그 락을 CPU 1 이 놓게 되는 시점에 CPU 0 이 그 락을 다시 잡으려 시도할 만큼 충분히 오래 잡고 있다가 놓게 되거나 그 반대 경우라면, 이 락은 CPU 0 과 1 사이에서만 오가게 되고 CPU 2-7 은 소외되어 버리게 됩니다.

Quick Quiz 7.16: 락 경쟁정도가 충분히 낮아서 비공정성을 예방할 수 있을 정도가 되는 좋은 별렬 설계를

사용하는 편이 더 낫지 않을까요? ■

7.1.4 Inefficiency

락은 어토믹 인스트럭션과 메모리 배리어를 사용해서 구현되고, 자주 캐시 미스를 유발합니다. Chapter 3에서 봤듯이, 이런 인스트럭션들은 그 비용이 상당히 비싼데, 간단한 인스트럭션에 비해 대략 수백배에 달할 정도로 더 큰 비용입니다. 이는 락킹에 있어 상당한 문제가 될 수 있습니다: 만약 하나의 인스트럭션을 락으로 보호하게 된다면 그 오버헤드를 약 100배 정도 증가시키는 겁니다. 완벽한 확장성이 제공된다고 가정해도, 똑같은 코드를 락킹 없이 수행하는 하나의 CPU의 성능을 따라 잡기 위해서는 100개의 CPU가 필요할 수 있는 겁니다.

이런 상황이 Section 6.3에서, 특히 Figure 6.16를 통해 이야기한 동기화의 단위에 대한 트레이드오프의 중요성을 강조합니다: 너무 큰 단위로 동기화를 하게 되는 것은 확장성을 제한하지만, 너무 작은 단위로 동기화를 하게 되면 지나치게 큰 동기화 오버헤드를 초래하게 됩니다.

그렇다고는 하나, 일단 락이 잡히면, 그 락에 의해 보호되는 데이터는 그 락을 잡은 쓰레드에 의해서는 별다른 간섭 없이 접근될 수 있습니다. 락을 잡는 행위는 비용이 비쌀 수도 있습니다, 하지만 일단 잡고 난 다음에는, 그 CPU의 캐시들은 효과적으로 성능을 끌어올려주는데, 적어도 커다란 크리티컬 섹션에 대해서는 그렇습니다.

Quick Quiz 7.17: 락을 잡은 쓰레드는 어떻게 다른 쓰레드로부터 간섭을 받을 수도 있을까요? ■

7.2 Types of Locks

Only locks in life are what you think you know, but don't. Accept your ignorance and try something new.

Dennis Vickers

놀라우리만치 많은 종류의 락이 존재하는데, 이 짧은 챕터가 모두 다룰 수 없을 정도입니다. 다음의 섹션들에서는 배타적 락 (Section 7.2.1), reader-writer 락 (Section 7.2.2), 다양한 역할의 락 (Section 7.2.3), 그리고 범위 락킹 (Section 7.2.4)에 대해 알아봅니다.

7.2.1 Exclusive Locks

배타적 락은 이름이 말하는 그대로입니다: 한번에 하나의 쓰레드만이 그 락을 잡고 있을 수 있습니다. 따라서 그런 락을 잡고 있는 쓰레드는 그 락에 의해 보호되는 모든 데이터에 대한 배타적인 접근을 할 수 있게 됩니다.

물론, 이 모든 이야기는 이 락은 그 락에 의해 보호된다고 여겨지는 데이터에 대한 모든 접근 동안 잡혀 있게 된다는 가정을 하고 있습니다. 모든 필요한 코드 수행 경로에 이 락이 잡혀져 있도록 보장하는 막대한 책임은, 비록 그 책임의 수행을 도와주는 도구들도 있기는 하지만 (예를 위해선 Section 12.3.1을 참고하세요), 결국은 그 코드의 개발자에게 있습니다.

Quick Quiz 7.18: 배타적 락을 잡고나서 곧바로 풀어버리는, 즉, 텅 빈 크리티컬 섹션과 같은 것을 갖는 행위가 어떤 의미를 가질 수 있을까요? ■

7.2.2 Reader-Writer Locks

Reader-writer 락 [CHP71]은 그 락이 보호하는 데이터를 읽는 쓰레드는 다른 쓰레드와 동시에도 얼마든지 잡을 수 있게 하는 반면 그 데이터를 쓰는 쓰레드는 단 하나의 쓰레드만이 그 락을 잡을 수 있도록 합니다. 이렇게 되면, 이론상으로는, reader-writer 락들은 주로 읽히기만하고 쓰여지는 일은 매우 드문 데이터에 대해서는 훌륭한 확장성을 보여야만 합니다. 실전에서의 실제 확장성은 해당 reader-writer 락의 구현 내용에 따라서 달라질 겁니다.

고전적인 reader-writer 락 구현은 어토믹하게 조정되는 여러개의 카운터들과 플래그들을 사용했습니다. 이런 종류의 구현들은 짧은 크리티컬 섹션으로 인해 배타적 락킹이 받는 것과 같은 문제로 어려움을 겪었습니다: 락을 획득하고 해제하는데 드는 오버헤드가 간단한, 실제 할일만 하는 인스트럭션의 오버헤드에 비해 수백배 가까이 크게 되는 현상입니다. 물론, 이 크리티컬 섹션이 충분히 길다면 그 락을 획득하고 해제하는데 드는 오버헤드는 무시해도 좋은 정도가 됩니다. 하지만, 한번에 하나의 쓰레드만이 그 락을 조정할 수 있으므로, CPU의 수가 늘어남에 따라 필요시되는 크리티컬 섹션의 크기는 커집니다.

쓰레드별 배타적 락을 사용해서 읽기를 하는 쓰레드에 훨씬 더 바람직한 형태로 reader-writer 락을 설계하는 것도 가능합니다 [HW92]. 읽기를 하기 위해서는, 쓰레드는 자신의 락만을 획득합니다. 쓰기를 하기 위해서는, 쓰레드는 모든 락들을 획득해야만 합니다. 쓰기를 하려는 쓰레드가 존재하지 않는 상황이라면, 각 읽기를 하는 쓰레드는 어토믹 인스트럭션과 메모리 배리어 오버헤드만을 만들어내고, 캐시 미스도 내지 않는데, 이는 락킹 기능에 있어 상당히 좋은 상황입니다. 불행히도, 쓰기를 하는 쓰레드는 캐시 미스는 물론이고 어토믹 인스트럭션과 메모리 배리어 오버헤드까지 모두 만들어내게 됩니다—그 오버헤드는 또한 쓰레드들의 수만큼 배가 되지요.

요약하자면, reader-writer 락들은 여러 상황에 상당히 유용할 수 있습니다만, 그 구현은 각 종류마다 그 나름의

Table 7.1: VAX/VMS Distributed Lock Manager Policy

	Null (Not Held)	Concurrent Read	Concurrent Write	Protected Read	Protected Write	Exclusive
Null (Not Held)	■	■	■	■	■	■
Concurrent Read	■	■	■	■	■	X
Concurrent Write	■	■	X	X	X	
Protected Read	■	■	X	■	X	X
Protected Write	■	■	X	X	X	X
Exclusive	■	X	X	X	X	X

단점을 가지고 있습니다. 규범적인 reader-writer 락킹의 사용은 상당히 큰 읽기 쓰레드 쪽 크리티컬 섹션을 가지고 있을 때에만 이뤄지는데 그 크리티컬 섹션의 크기는 수백 마이크로세컨드부터 심지어 밀리세컨드까지 될 수 있습니다.

7.2.3 Beyond Reader-Writer Locks

Reader-writer 락과 배타적 락은 각자 허용하는 범위에 대한 정책에서 차이를 보입니다: 배타적 락은 하나의 쓰레드만 락을 잡고 있기를 허용하는 반면, reader-writer 락은 읽기 권한으로 락을 잡는 쓰레드는 얼마든지 락을 잡고 있을 수 있게 허용합니다 (하지만 쓰기 권한의 경우는 하나만 가능하죠). 매우 많은 락 허용 범위 정책이 있을 수 있는데, 그 중 하나는 VAX/VMS 분산 락 매니저 (DLM) [ST87] 으로, Table 7.1에 표시되어 있습니다. 비어 있는 셀들은 호환 가능한 모드들을 의미하며 “X”로 표시된 셀은 호환 불가한 모드들을 가리킵니다.

VAX/VMS DLM은 여섯개의 모드를 사용합니다. 비교를 위해 다른 락들의 모드를 이야기해보면, 배타적 락들은 두개의 모드를 (not held 와 held), reader-writer 락은 세개의 모드 (not held, read held, write held) 를 갖는다고 이야기 할 수 있습니다.

첫번째 모드는 null, 또는 not held 라 불립니다. 이 모드는 모든 다른 모드들과 호환되는데, 즉 다음과 같은 해석이 가능합니다: 한 쓰레드가 락을 잡고 있지 않다면, 그 쓰레드는 다른 어떤 쓰레드가 락을 획득하려 할 때 어떤 방해도 하지 않습니다.

두번째 모드는 concurrent read 인데, exclusive 를 제외한 다른 모든 모드들과 호환됩니다. concurrent-read 모드는 데이터 구조에의 업데이트가 동시적으로 진행되도록 허용하는 가운데 데이터의 대략적 통계치를 구하기 위해 사용될 수도 있습니다.

세번째 모드는 concurrent write 로 null, concurrent read, 그리고 concurrent write 와 호환됩니다. concurrent-write 모드는 데이터의 읽기와 수정이 동시적으로 진행될 수 있도록 허용하는 가운데 대략적인 통계치를 업데이트 하기 위해 사용될 수 있습니다.

네번째 모드는 protected read 로, null, concurrent read, 그리고 protected read 와 호환되는 모드입니다. protected-read 모드는 동시적인 읽기는 허용하되 업데이트는 허용하지 않는 가운데 데이터 구조체의 일관성을 갖는 스냅샷을 만들거나 할 때 사용될 수도 있습니다.

다섯번째 모드는 protected write 인데, 이 모드는 null 과 concurrent read 모드와 호환됩니다. protected-write 모드는 protected read 모드의 읽기 작업에는 영향을 받을 수 있지만 concurrent read 모드의 읽기 작업에는 문제가 없는 데이터 구조체에의 업데이트를 하는데 사용될 수도 있습니다.

마지막으로 여섯번째 모드는 exclusive 모드인데, 이 모드는 null 모드만 호환됩니다. exclusive 모드는 모든 다른 액세스들을 제외시켜야만 할 때 사용될 수 있습니다.

배타적 락과 reader-writer 락이 VAX/VMS DLM 으로 모방될 수 있다는 사실은 흥미로운 일입니다. 배타적 락은 null 과 exclusive 모드만을 사용하는 반면 reader-writer 락은 null, protected-read, 그리고 protected-write 모드를 사용할 것입니다.

Quick Quiz 7.19: VAX/VMS DLM 이 reader-writer 락을 다른 방법으로 모방해낼 수도 있을까요? ■

VAX/VMS DLM 정책은 분산 데이터베이스 분야의 상용 제품에 널리 사용되고 있긴 합니다만, 공유 메모리 어플리케이션에서는 그렇게 폭넓게 사용되고 있지 않은 것으로 보입니다. 이에 대한 그럴싸한 이유 중 하나는 공유 메모리 시스템에서의 것에 비해 엄청나게 큰 분산 데이터베이스에서의 통신 오버헤드가 VAX/VMS DLM 의 좀 더 복잡해지는 관리 정책의 오버헤드를 숨겨줄 수 있다는 것입니다.

더도 아니고 덜도 아니고, VAX/VMS DLM은 락킹 뒤의 개념이 얼마나 유연해질 수 있는지를 보여주는 하나의 흥미로운 예입니다. VAX/VMS DLM은 또한 최신 DBMS 들에서 사용되는, 서른개가 넘는 락킹 모드를 가지기도 해서 VAX/VMS의 여섯개 모드에 비해 훨씬 복잡한 락킹 개념에 대한 매우 간단한 소개 역할을 하기도 합니다.

7.2.4 Scoped Locking

따라서, 앞서 이야기된 락킹 기능들은 명시적인 획득과 해제 기능을 필요로 하게 되는데, 예를 들면 `spin_lock()` 과 `spin_unlock()` 같은 것들이 각각 획득과 해제를 위해 사용됩니다. 다른 방법은 객체 지향적인

“자원 할당이 곧 초기화” (RAII: Resource Allocation Is Initialization) 패턴 [ES90]을 사용하는 것입니다.⁵ 이 패턴은 C++ 같은 언어의 auto 변수들에 자주 사용되는 것으로, 어떤 객체의 범위에 진입할 때에는 연관된 생성자 (constructor)가 호출되고, 그 객체의 범위에서 빠져나올 때에는 연관된 소멸자 (destructor)가 호출되는 방식입니다. 이 패턴은 생성자가 락을 획득하고 소멸자는 락을 놓는 형태로 락킹에 적용될 수 있습니다.

이런 접근법은 상당히 유용할 수 있는데, 실제로 1990년도에 저는 이것이야말로 필요한 락킹의 유일한 형태라고 설득되었던 바 있습니다.⁶ RAII 락킹의 매우 훌륭한 특성 가운데 하나는 그 범위를 빠져나가는 모든 코드 수행경로 각각에 대해서 조심스럽게 락을 해제할 필요가 없다는 것으로, 이로 인해 문제가 될 여지가 있는 여러 버그들이 제거되어버립니다.

하지만, RAII 락킹은 또한 어두운 부분을 가지고 있습니다. RAII는 락 획득과 해제의 캡슐화를 매우 어렵게 해주는데, 반복자에서의 경우가 한 예가 될 것입니다. 많은 반복자 구현에서, 사람들은 반복자의 “start” 함수에서 락을 잡아 놓고 이 반복자의 “stop” 함수에서 그 락을 풀고 싶어 할 겁니다. RAII 락킹은 그러지 않고 락 획득과 해제가 같은 수준의 범위에서 이뤄지도록 함으로써 그러한 종류의 캡슐화를 어렵게하고 심지어는 불가능하게 하기도 합니다.

RAII 락킹은 또한 크리티컬 섹션들을 겹치게 배치하는 것을 불가능하게 하는데, 범위가 내포되어야 한다는 사실 때문입니다. 이런 불가능성은 여러개의 유용한 구조를 어렵거나 아예 불가능하게 만들어 버리는데, 예를 들면 어떤 이벤트를 내세우려는 여러개의 동시적인 시도들 사이에서 중재를 하는, 락을 사용하는 트리 자료구조 같은 것입니다. 임의의 수많은 동시적인 시도들 가운데 오직 하나의 시도만이 성공할 수 있어야 하고, 그 성공한 시도 이외의 것들을 위한 최선의 전략은 가능한 한 빨리, 그리고 가능한 한 별다른 고통 없이 실패에 이르는 것입니다. 그러지 않는다면, 락 경쟁정도가 커다란 규모의 시스템에서는 고통스러울 정도가 될 겁니다 (“커다란 규모”는 수백개의 CPU들을 의미합니다).

예로 들 수 있는 데이터 구조체들(리눅스 커널의 RCU 구현에서 가져온 것들입니다)이 Figure 7.8에 보여져 있습니다. 여기서, 각 CPU는 leaf rcu_node 구조체를 할당받아 가지고 있고, 각 rcu_node 구조체는 자신의 부모로의 포인터 (기묘하게도, `->parent` 라 이름붙여져 있습니다)를 가지고 있어서 이 구조는 트리의 루트 rcu_node 구조체까지 이어지는데, 이 루트는 `->parent` 포인터의 값으로 NULL을 갖습니다. 하나의




Figure 7.8: Locking Hierarchy

부모 rcu_node 구조체당 가질 수 있는 자식들의 수는 다양할 수 있는데, 일반적으로는 32 또는 64가 사용됩니다. 각각의 rcu_node 구조체는 또한 `->fqsllock`이라 이름 붙여진 락을 갖습니다.

일반적인 접근 방법은 토너먼트로, 한 CPU는 조건적으로 자신에게 할당된 leaf rcu_node 구조체의 `->fqsllock`을 잡고, 그 락을 잡는데 성공했다면, 그 구조체의 부모의 락을 잡으려 시도하고, 자식의 락은 해제하는 방법입니다. 또한, 각 레벨에서, 이 CPU는 글로벌한 `gp_flags` 변수를 체크하는데, 만약 이 변수가 어떤 다른 CPU가 그 이벤트를 내세웠다면, 이 첫번째 CPU는 더이상의 경쟁을 그만둡니다. 이 획득한 후 해제하기 시퀀스는 `gp_flags` 변수가 누군가가 토너먼트에 승리했다는 것을 알리게 되거나, `->fqsllock` 획득에 실패했거나, 또는 root rcu_node 구조체의 `->fqsllock`이 획득될 때까지 반복됩니다. 루트 rcu_node 구조체의 `->fqsllock`이 획득된다면, `do_force_quiescent_state()`라는 이름의 함수가 호출되지만, 이 함수는 100밀리세컨드에 최대 한번 호출되어야 합니다.

이를 구현하는 간략화된 코드가 Listing 7.7에 보여져 있습니다. 이 함수의 목적은 동시적으로 `do_force_quiescent_state()` 함수를 실행해야 할 필요성을 감지한 CPU들 사이의 중재를 하는 것입니다. 어떤 때에든, `do_force_quiescent_state()` 함수의 하나의 실행 흐름만이 실행되고 있어야만 의미가 지켜지며, 따라서 이 함수에의 여러 동시적인 호출자들이 존재한다면, 그들 중 하나만이 정말로 `do_force_quiescent_state()` 함수를 호출하고, 나머지들은 (가능한 빠르고 고통 없이) 포기하고 떠나도록 해야만 합니다. 더 나아

⁵ http://www.stroustrup.com/bs_faq2.html#finally에 더 분명하게 설명되어 있긴 합니다.

⁶ 이후의 Sequent Computer Systems에서의 병렬성 관련한 업무 경험을 통해 저는 곧바로 이 잘못된 개념에 대한 오해를 풀 수 있었습니다.

Listing 7.7: Conditional Locking to Reduce Contention

```

1 void force_quiescent_state(struct rcu_node *rnp_leaf)
2 {
3     int ret;
4     struct rcu_node *rnp = rnp_leaf;
5     struct rcu_node *rnp_old = NULL;
6
7     for (; rnp != NULL; rnp = rnp->parent) {
8         ret = (READ_ONCE(gp_flags)) ||
9             !raw_spin_trylock(&rnp->fqslck);
10        if (rnp_old != NULL)
11            raw_spin_unlock(&rnp_old->fqslck);
12        if (ret)
13            return;
14        rnp_old = rnp;
15    }
16    if (!READ_ONCE(gp_flags)) {
17        WRITE_ONCE(gp_flags, 1);
18        do_force_quiescent_state();
19        schedule_timeout_interruptible(HZ / 10);
20        WRITE_ONCE(gp_flags, 0);
21    }
22    raw_spin_unlock(&rnp_old->fqslck);
23 }

```

가서, `do_force_quiescent_state()` 가 과거의 100 밀리세컨드 내에 호출된 적 있다면, 그 함수를 다시 한번 호출할 필요는 없습니다.

이런 결론에 따라, line 7-15의 루프에서의 실행 흐름은 `rcu_node` 계층에서 한단계 위의 레벨로 올라가려는 시도를 합니다. `gp_flags` 변수가 이미 설정되었거나 (line 8) 현재의 `rcu_node` 구조체의 `->fqslck` 을 획득하려는 시도가 실패한다면 (line 9), 지역변수 `ret` 는 1로 설정됩니다. 만약 line 10 이 지역변수 `rnp_old` 가 `NULL` 이 아님을 확인한다면, 그 말은 `rnp_old` 의 `->fqslck` 을 잡았다는 의미이므로, line 11에서 그 락을 해제합니다 (하지만 이는 그 부모 `rcu_node` 구조체의 `->fqslck` 을 잡은 후의 일입니다). 만약 line 12에서 line 8이나 line 9에서 경쟁을 그만둘 이유를 발견했음을 확인하면 line 13에서 호출자에게 리턴해 버립니다. 그렇지 않다면, 현재의 `rcu_node` 구조체의 `->fqslck` 을 잡은 것이므로, 이 루프의 다음 실행경로를 위한 준비과정으로 line 14에서 이 구조체로의 포인터를 지역 변수 `rnp_old`에 집어넣습니다.

만약 코드 수행 제어가 line 16 까지 도달한다면 토티먼트에 우승했고, 지금 root `rcu_node` 구조체의 `->fqslck` 을 잡고 있다는 이야기입니다. Line 16 이 여전히 `gp_flags` 전역 변수의 값이 0임을 확인하면, line 17에서 `gp_flags` 를 1로 설정하고 line 18에서 `do_force_quiescent_state()` 를 호출한 후, line 19에서 100 밀리세컨드를 기다리고, line 20에서 `gp_flags` 를 0으로 되돌려 놓습니다. 어떤 경우였든, line 22에서 root `rcu_node` 구조체의 `->fqslck` 을 해제합니다.

Quick Quiz 7.20: Listing 7.7 의 코드는 황당할 정도로 복잡하군요! 왜 그냥 조건적으로 하나의 글로벌 락을

Listing 7.8: Sample Lock Based on Atomic Exchange

```

1 typedef int xchglock_t;
2 #define DEFINE_XCHG_LOCK(n) xchglock_t n = 0
3
4 void xchg_lock(xchglock_t *xp)
5 {
6     while (xchg(xp, 1) == 1) {
7         while (READ_ONCE(*xp) == 1)
8             continue;
9     }
10 }
11
12 void xchg_unlock(xchglock_t *xp)
13 {
14     (void)xchg(xp, 0);
15 }

```

잡지 않나요? ■

Quick Quiz 7.21: 잠깐만요! Listing 7.7 의 line 16에서 토티먼트에 “승리” 했다면, `do_force_quiescent_state()` 의 모든 일을 해야만 하잖아요. 어떻게 이걸 승리라고 할 수 있어요, 진짜로? ■

이 함수는 드물지 않게 사용되는 계층적 락킹의 패턴을 보여주고 있습니다. 이 패턴은 앞서 이야기한 iterator 캡슐화와 마찬가지로 엄격한 RAII 락킹을 사용해서 구현하기 상당히 어렵고, 따라서 미래에는 명시적 `lock`/`unlock` 기능들이 필요하게 될 것입니다.

7.3 Locking Implementation Issues

When you translate a dream into reality, it's never a full implementation. It is easier to dream than to do.

Shai Agassi

개발자들은 거의 항상 시스템에 의해서 제공되는, 예를 들면 POSIX pthread mutex lock [Ope97, But97] 와 같은 락킹 도구들을 사용하도록 서비스 받을 것입니다. 그러나, 일부 샘플 구현을 연구해 보는게 도움이 될 수 있는데, 극단적인 워크로드와 환경에서 유발되는 구현상의 어려움 등을 알아볼 수 있을 것이기 때문입니다.

7.3.1 Sample Exclusive-Locking Implementation Based on Atomic Exchange

이 섹션은 Listing 7.8에 보인 구현을 리뷰해 봅니다. 이 락을 위한 데이터 구조체는 line 1에 보여졌듯이 그저 하나의 int 인데, 그 외에도 다른 정수형 타입이 어도 상관없습니다. 이 락의 최초 값은 0으로, line 2에 보여졌듯이 “락이 잡히지 않았음”을 의미합니다.

Quick Quiz 7.22: 왜 C 언어에서 기본적으로 제공하는 0으로의 초기화 메커니즘을 사용하지 않고 List-

ing 7.8 의 line 2 에 보여진 것처럼 명시적으로 초기화를 하는 거죠? ■

Lock 획득은 line 4-10 의 `xchg_lock()` 함수에 의해 수행됩니다. 이 함수는 중첩된 루프를 사용하는데, 바깥의 루프를 통해서는 반복적으로 어토믹하게 락의 값을 1 (“락이 걸렸음” 을 의미) 과 바꿉니다. 만약 이전의 값이 이미 값 1 이었다면 (다시 말해, 누군가가 이미 락을 잡고 있다면), 안의 루프 (line 7-8) 에서는 그 락이 풀려서 다시 잡으려 시도할 수 있을 때까지 루프를 돌면서 기다리는데, 기다림이 끝나면 바깥 루프에서 다시 한번 락을 잡기 위한 시도를 할 수 있게 됩니다.

Quick Quiz 7.23: 왜 Listing 7.8 의 line 7-8 의 안쪽 루프를 귀찮게 수행해야 하나요? 왜 그냥 간단하게 line 6 에서 계속해서 어토믹한 값 교환 오퍼레이션을 수행하지 않는거죠? ■

락의 해제는 line 12-15 의 `xchg_unlock()` 함수에 의해 이루어집니다. Line 14 는 어토믹하게 락의 값을 0 (“락이 걸리지 않았음”) 으로 교체해서 그 락이 풀려 있는 상태임을 알립니다.

Quick Quiz 7.24: Listing 7.8 의 line 14 에서는 왜 그냥 간단하게 락에 0 값을 저장하지 않는거죠? **Quick Quiz 7.25:**

■
이 락은 test-and-set 락 [SR84] 의 한가지 간단한 예입니다만, 실제 상용 제품에서도 매우 비슷한 메커니즘이 순수한 스피드을 위해 상당히 많이 사용됩니다.

7.3.2 Other Exclusive-Locking Implementations

어토믹 인스트럭션을 사용해서 구현 가능한 수많은 락킹 방법들이 존재하는데, 그 중 많은 것들이 Mellor-Crummey 와 Scott 에 의해 검토되었습니다 [MCS91]. 예를 들어, 앞의 섹션에서 보았던 어토믹 교환 오퍼레이션에 기반한 test-and-set 락은 경쟁 정도가 낮을 때 잘 동작하고 메모리 사용량이 적다는 장점을 갖습니다. 또한 당장 락을 받아도 사용할 수 없는 쓰레드에게 락을 넘겨주거나 하지 않습니다만, 그 결과로 비공정성 문제가 생길 수 있으며 심지어는 높은 경쟁 수준 아래에서는 starvation 상황도 나타날 수 있습니다.

반면, 리눅스 커널에서 사용되는 티켓 락 [MCS91]의 경우에는 높은 경쟁 상황에서도 비공정성 문제를 없앨니다만, first-in-first-out 정책은 락을 받아도 당장 그 락을 사용할 수 없는, 예를 들면 다른 쓰레드에게 preemption 당했거나 인터럽트 당했거나 또는 그외에도 어떤 이유 등이 있는 쓰레드에게 락을 넘겨줄 수 있습니다. 하지만, 이런 preemption 과 인터럽트의 가능성에 대해 지나치게 걱정하지는 않는 것이 좋은데, 이 preemption 과 인터럽트는 대부분의 경우 락이 획득된 뒤에나 일어날 수 있기

때문입니다.⁷

test-and-set 락과 티켓 락을 포함해서, 기다리는 쓰레드가 하나의 메모리 위치를 보며 루프를 도는 모든 락킹 구현은 높은 락 경쟁 수준에서는 성능에 문제를 겪게 됩니다. 문제는 락을 해제하는 쓰레드는 연관된 메모리 위치의 값을 업데이트 해야 한다는 점입니다. 경쟁 수준이 낮은 경우에는 이런 문제가 되지 않습니다: 연관된 캐시 라인은 여전히 락을 잡은 CPU 의 캐시에 있고 곧바로 쓸 수 있는 상태일 확률이 큽니다. 반면, 경쟁 수준이 높은 경우에는, 락을 획득하려 하는 각 쓰레드는 해당 캐시 라인의 read-only 복사본을 가지고 있을 것이고, 락을 쥐고 있는 쓰레드는 그 락을 해제하는 업데이트를 진행하기에 앞서 모든 read-only 복사본들을 무효화 시켜야 합니다. 일반적으로, 더 많은 CPU 와 쓰레드가 존재할수록 높은 경쟁 수준 아래에서 락을 해제하는데에 발생하는 오버헤드는 커집니다.

이런 잘못된 확장성은 여러개의 queued-lock 구현들 [And90, GT90, MCS91, WKS94, Cra93, MLH94, TS93] 을 만드는 동기가 되었습니다. Queued lock 은 각 쓰레드에게 대기열의 원소 하나를 할당하는 방식으로 높은 캐시 무효화 오버헤드를 제거합니다. 이런 대기열의 원소들은 서로 연결되어서 해당 락이 기다리는 쓰레드들에게 넘겨질 순서를 관장하는 하나의 대기열을 만들게 됩니다. 여기서 핵심은 각 쓰레드가 자신에게 할당된 대기열 원소를 바라보면서 루프를 돌기 때문에, 락을 잡고 있는 쓰레드는 다음 쓰레드의 CPU 의 캐시에 있는 원소 하나만 무효화 시키면 된다는 것입니다. 이런 구조는 높은 수준의 락 경쟁상황에서 락을 넘기는 일의 오버헤드를 대폭 줄여줍니다.

좀 더 최근의 queued-lock 구현들은 시스템의 구조 또한 신경을 쓰는 방식으로 만들어져서 락을 좀 더 지역적으로 가까운 쪽에 우선적으로 넘겨주되 여전히 starvation 도 막습니다 [SSVM02, RH03, RH02, JMRR02, MCM02]. 이런 것들 중 다수가 디스크 I/O 의 스케줄링에 전통적으로 사용되었던 엘레베이터 알고리즘과 유사한 것으로 이해될 수 있습니다.

불행히도, 높은 경쟁 수준에서 queued lock 의 효율성을 높여주는 스케줄링 로직은 낮은 경쟁 수준에서의 오버헤드도 증가시킬 수 있습니다. Beng-Hong Lim 과 Anat Agarwal 은 그래서 낮은 경쟁 수준에서는 간단한 test-and-set lock 을 사용하고 높은 수준의 경쟁 상황에서는 queued lock 을 사용하도록 락을 교환하는 방식으로 test-and-set 락과 queued lock 을 결합시켜서 [LA94] 낮은 수준의 경쟁 상황에서는 낮은 오버헤드를 가지고 높은 수준의 경쟁에서는 높은 처리량과 공정성을 가

⁷ 한편, 높은 락 경쟁 정도를 처리하는 최선의 방법은 일단 그런 상황이 생기지 않게 하는 것입니다! 하지만, 높은 락 경쟁 상황이 생겨날 수 있는 악마들 가운데 떨 중요한 것일 뿐인 상황도 존재하며, 어떤 경우가 되었든, 높은 수준의 경쟁에 대처하는 방법을 연구해보는 것은 심리적으로 좋은 연습이 됩니다.

질 수 있도록 했습니다. Browning 등은 비슷한 접근을 취했지만, 분리된 플래그의 사용을 막아서 test-and-set의 빠른 수행 경로가 간단한 test-and-set 락에 사용되는 것과 동일한 인스트럭션들을 사용할 수 있도록 했습니다 [BMM05]. 이런 접근법은 제품 수준에서 사용되었습니다.

높은 수준의 경쟁 상황에서 나타나는 또 다른 문제는 락을 잡고 있는 쓰레드의 수행이 지연되는 경우로, 특히 이 지연이 preemption에 의한 경우가 문제가 되는데, 이 경우에는 낮은 우선순위의 쓰레드가 락을 잡지만 중간 정도 우선순위의 CPU를 많이 사용하는 쓰레드에 의해 CPU 사용을 빼앗겨 높은 우선순위의 프로세스가 락을 잡을 수 있게 되기 전까지 기다려야 하는 우선순위 역전 문제를 초래하게 됩니다. 이로 인한 결과는 CPU를 많이 사용하는 중간 우선순위 프로세스가 높은 우선순위의 프로세스가 수행되는 것을 막고 있게 되는 현상입니다. 한가지 해결책은 우선순위 상속 [LR80]으로, 이 방법에 대해 여전히 남아있는 논쟁 [Yod04a, Loc02]에도 불구하고 real-time 컴퓨팅에서 널리 사용된 방식입니다 [SRL90a, Cor06b].

우선순위 역전 문제를 없애기 위한 또 다른 방법은 락이 잡혀 있는 동안의 preemption을 막는 것입니다. 락이 잡혀 있는 동안의 preemption을 막는 것은 또한 처리량 역시 증가시키기 때문에, 대부분의 독점 UNIX 커널들은 어떤 형태의 스케줄러를 의식하는 동기화 메커니즘 [KWS97]을 제공하는데, 일부 거대 규모 데이터베이스 제조사들의 노력 때문입니다. 이런 메커니즘들은 보통 preemption이 적절치 못할 것이라는 정보를 힌트와 같은 형태로 받습니다. 이런 힌트들은 종종 특정한 기계의 레지스터의 특정 bit을 1로 만드는 형태로 주어지는데, 이 메커니즘을 위해 락 획득마다 추가되는 오버헤드를 매우 낮게 유지시켜줍니다. 반면에, 리눅스는 이런 힌트를 받지 않고, 대신 futex [FRK02, Mol06, Ros06, Dre11] 라 불리는 메커니즘을 사용해 비슷한 결과를 만들어냅니다.

흥미롭게도, 락을 구현하는데 어토믹 인스트럭션이 반드시 필요한 것만은 아닙니다 [Dij65, Lam74]. 간단한 읽기와 쓰기만을 가지고 락킹을 구현하는 과정을 둘러싼 문제들에 대한 훌륭한 소개를 Herlihy와 Shavit의 교재에서 찾을 수 있습니다 [HS08]. 여기서도 되돌이 되는 핵심 포인트는, 이것들에 대한 조심스러운 연구는 재미도 있고 배우게 되는 점도 많겠지만, 그런 구현들에 대한 현재 실용적인 사용에는 적다는 점입니다. 그러나, 아래에 설명되는 예외를 포함해서, 그런 연구는 독자 여러분의 연습으로 남겨두겠습니다.

Gamsa 등 [GKAS99, Section 5.3] CPU를 사이를 순환하는 토큰을 사용한, 토큰에 기반한 메커니즘을 설명합니다. 이 토큰이 특정 CPU에 도달하면, 그 CPU는 그 토큰에 의해 보호되는 모든 것에 배타적인 접근 권한

을 갖게 됩니다. 이 토큰 기반의 메커니즘을 구현하는데 사용될 수 있는 수많은 설계가 존재하는데, 예를 들면 다음과 같습니다:

1. CPU 별로 플래그를 가지고 있는데, 각 플래그는 하나를 제외하고는 모두 0으로 초기화 되어 있습니다. 한 CPU의 플래그가 0이 아니라면, 그 CPU는 그 토큰을 쥐게 된 것입니다. 그 CPU가 그 토큰의 사용을 마무리하면, 자신의 플래그를 0으로 설정하고 다음 CPU의 플래그를 1로 (또는 어떤 다른 0이 아닌 값으로) 설정합니다.
2. CPU 별 카운터를 가지고 있는데, 각 카운터는 연관된 CPU의 숫자로 설정되며, 그 숫자는 시스템의 전체 CPU의 갯수가 N 이라고 할 때 0부터 $N - 1$ 사이의 값을 갖게 될겁니다. 한 CPU의 카운터가 다음 CPU의 것보다 높은 값을 갖는다면 (카운터가 오버플로우 되어 값이 초기화 되는 것을 고려해야 합니다) 첫번째 CPU가 그 토큰을 잡은 것입니다. 그 토큰을 사용하는게 끝났다면, 토큰을 사용했던 CPU는 다음 CPU의 카운터를 자신의 카운터보다 1 큰 값으로 설정합니다.

Quick Quiz 7.26: 카운터의 값이 오버플로우 되어 초기화 되는 경우를 고려하면서 어떻게 하나의 카운터가 다른 카운터보다 큰지를 판단할 수 있나요? ■

Quick Quiz 7.27: 카운터 사용과 플래그 사용 중 뭐가 더 나을까요? ■

이 락은 CPU가 락을 곧바로 얻을 수 없을 수도 있는데, 심지어 다른 CPU가 락을 당장 사용하고 있지 않다 하더라도 그렇다는 점에서 일반적이지 않습니다. 대신, CPU는 토큰이 자신에게 올때까지 기다려야만 합니다. 이는 CPU들이 주기적으로 크리티컬 섹션에의 접근을 해야 하지만 토큰의 순환율이 변화되는 것을 받아들일 수 있는 경우에는 유용합니다. Gamsa 등 [GKAS99]은 이걸 사용해서 read-copy update (Section 9.5을 참고하세요)의 또 다른 변종을 구현했는데, 이는 또한 메모리 할당자들에 의해 사용되는 CPU 별 캐시 비우기 작업이나 CPU 별 데이터 구조체의 garbage collection, 또는 CPU 별 데이터를 공유된 저장 영역 (또는 대용량 저장장치라던지, 필요에 따라)으로 옮기는 작업과 같은, 주기적인 CPU 별 작업을 보호하는데에도 사용될 수 있습니다 [MS93].

갈수록 많은 사람들이 병렬 하드웨어에 친숙해지고 더 많은 코드를 병렬화 하는 것을 보아, 더 특수한 목적의 락킹 도구들이 나타날 것을 예상해 볼 수 있습니다. 더도 아니고 덜도 아니고, 독자 여러분은 이 중요한 안전성 팁을 조심스럽게 고려해야 합니다: 언제든 인간적으로 사용이 가능하다면 표준적인 동기화 도구들을 사용하세요. 자신을 위한 동기화 도구를 직접 만드는

Listing 7.9: Per-Element Locking Without Existence Guarantees

```

1 int delete(int key)
2 {
3     int b;
4     struct element *p;
5
6     b = hashfunction(key);
7     p = hashtable[b];
8     if (p == NULL || p->key != key)
9         return 0;
10    spin_lock(&p->lock);
11    hashtable[b] = NULL;
12    spin_unlock(&p->lock);
13    kfree(p);
14    return 1;
15 }

```

것에 비해 표준 동기화 도구들을 사용하는 것의 커다란 장점은 표준 기능들은 일반적으로 버그가 훨씬 적다는 것입니다.⁸

7.4 Lock-Based Existence Guarantees

Existence precedes and rules essence.

Jean-Paul Sartre

병렬 프로그래밍에서의 핵심적인 난제는 존재 보장 [GKAS99]을 제공하는 것으로, 어떤 객체에 접근하려 시도하는 것은 그 객체가 이 접근 시도 동안 존재하는지 여부에 의존적입니다. 어떤 경우에는 존재 보장이 명시적이지 않기도 합니다:

1. 기본 모듈의 글로벌 변수와 static 지역 변수들은 어플리케이션이 돌아가는 동안은 존재할 것입니다.
2. 로드된 모듈의 글로벌 변수들과 static 지역 변수들은 그 모듈이 로드된 상태를 유지하는 동안은 존재할 것입니다.
3. 하나의 모듈은 자신의 함수들 중 최소한 하나는 실행중인 실행 흐름을 가지고 있되 동안은 로드된 상태를 유지할 것입니다.
4. 어떤 함수의 실행중인 흐름의 스택 위에 할당되는 변수들은 그 함수의 실행 흐름이 리턴을 하기 전까지는 존재할 것입니다.

⁸ 그리고, 맞아요, 저는 적어도 저의 직접 만드는 동기화 도구에 대해서는 공유를 했어요. 하지만, 제 머리카락은 그런 일을 시작하기 전에 비해 훨씬 하얗게 세어버렸습니다. 우연의 일치일까요? 그럴지도 모르죠. 하지만, 독자 여러분은 정말로 머리카락이 빨리 하얗게 되는 리스크를 지고 싶으신가요?

5. 어떤 함수 위에서 코드를 수행 중이거나 (직접적 이든 간접적이든) 그 함수로부터 호출되었다면, 그 함수는 실행중인 흐름을 가지고 있는 것입니다.

비록 명시적이지 않은 존재 보장과 연관된 버그들이 실제로 만들어질 수 있긴 하지만 이런 명시적이지 않은 존재 보장은 직관적인 이야기입니다.

Quick Quiz 7.28: 어떻게 비명시적인 존재 보장에 의존하는게 버그를 만들어낼 수 있나요? ■

하지만 그보다 더 흥미로운—그리고 문제를 일으키는—보장은 heap 메모리에 연관된 것입니다: 동적으로 할당된 데이터 구조체는 그 메모리가 해제되기 전까지 존재할 것입니다. 여기서 해결해야 할 문제는 구조체에 대한 동시적인 접근들과 그 구조체가 존재하는 메모리의 해제를 동기화 시키는 것입니다. 이를 해결하는 방법 가운데 하나는 락킹과 같은 명시적 보장입니다. 만약 어떤 구조체가 어떤 주어진 락을 잡은 채로만 메모리 해제될 수 있다고 한다면, 그 락을 잡는 행위는 그 구조체의 존재를 보장합니다.

하지만 이 보장은 또다시 그 락 자체의 존재 여부에 의존적입니다. 이 락의 존재를 보장하기 위한 한가지 직선적인 방법은 그 락을 글로벌 변수로 위치시키는 것입니다만, 글로벌한 락킹은 제약된 확장성이라는 단점을 갖습니다. 데이터 구조체의 크기가 커질수록 향상되는 확장성을 제공하는 한가지 방법은 락을 구조체의 각 원소마다에 위치시키는 것입니다. 불행히도 데이터 원소 자체 내에 그 데이터 원소를 지키기 위한 락을 위치시키는 것은 Listing 7.9 미묘한 경쟁 상황을 일으키기 쉽습니다.

Quick Quiz 7.29: 우리가 삭제해야 하는 원소가 Listing 7.9의 line 8의 리스트의 첫번째 원소가 아니면 어떻게 하죠? ■

Quick Quiz 7.30: Listing 7.9에서 어떤 경쟁 조건이 발생할 수 있나요? ■

이 예제를 고치는 한가지 방법은 해싱을 사용한 글로벌 락들의 집합을 사용하는 것으로, Listing 7.10에 보여진 것처럼 각각의 해시 bucket 이 자신의 락을 가지고 있는 형태입니다. 이 방법은 그 데이터 원소로의 포인터를 얻어오기 (line 10에서) 전에 올바른 락을 얻어올 수 있도록 합니다 (line 9에서). 이 접근법은 이 그림에 보여진 해시 테이블처럼 하나의 분할 가능한 데이터 구조체에 대해서는 잘 동작하지만 주어진 데이터 원소가 여러 해시 테이블의 멤버이거나 트리나 그래프와 같은 보다 복잡한 데이터 구조체의 멤버라면 문제가 생길 수도 있습니다. 사실, 이런 문제들은 해결될 수 있는데, 그런 해결책들이 락에 기반한 소프트웨어 트랜잭션 메모리 구현의 기반을 이룹니다 [ST95, DSS06]. 하지만, Chapter 9에서 더 간단한—그리고 더 빠른—존재 보장을 제공하는 방법을 알아보겠습니다.

Listing 7.10: Per-Element Locking With Lock-Based Existence Guarantees

```

1 int delete(int key)
2 {
3     int b;
4     struct element *p;
5     spinlock_t *sp;
6
7     b = hashfunction(key);
8     sp = &locktable[b];
9     spin_lock(sp);
10    p = hashtable[b];
11    if (p == NULL || p->key != key) {
12        spin_unlock(sp);
13        return 0;
14    }
15    hashtable[b] = NULL;
16    spin_unlock(sp);
17    kfree(p);
18    return 1;
19 }
```

7.5 Locking: Hero or Villain?

You either die a hero or live long enough to become the villain.

Aaron Eckhart

실제 삶에서도 종종 그런 경우가 있듯, 락킹은 그것이 어떻게 사용되는지에 따라, 그리고 당장 해결해야 할 문제가 무엇인지에 따라 영웅이 될 수도 있지만 악당이 될 수도 있습니다. 제 경험상으로는, 어플리케이션 전체를 개발하는 사람들은 락킹 사용을 좋아하고, 병렬 라이브러리를 작성하는 사람들은 덜 좋아하며, 존재하는 순차적 방식의 라이브러리를 병렬화 하는 사람들은 매우 싫어합니다. 다음의 섹션들은 이런 시점의 차이에 대한 이유 몇 가지를 이야기해 봅니다.

7.5.1 Locking For Applications: Hero!

어플리케이션 전체 (또는 커널 전체)를 만들 때, 개발자들은 동기화 설계를 포함해 전체 설계를 제어할 수 있습니다. 그 설계가 Chapter 6에서 이야기한 것처럼 패티셔닝을 잘 사용하고 있다면, 락킹은 극단적일 정도로 효과적인 동기화 메커니즘이 될 수 있는데, 제품 품질의 병렬 소프트웨어에서의 많은 락킹의 사용이 이를 입증합니다.

그런 소프트웨어가 자신의 동기화 설계를 보통 락킹 기반으로 한다고는 하지만, 더도 아니고 덜도 아니고, 그런 소프트웨어는 거의 항상 다른 동기화 메커니즘 또한 사용하는데, 여기에는 특별한 카운팅 알고리즘 (Chapter 5), 데이터 소유권 (Chapter 8), 레퍼런스 카운팅 (Section 9.2), 순서적 락킹 (Section 9.4), 그리고 read-copy update (Section 9.5) 등이 포함됩니다. 또한, 실제 코드를 짜는 사람들은 다양한 도구들을 사용하는데 이

도구들이 돋는 일은 데드락 감지 [Cor06a], 락 획득/해제 밸러싱 [Cor04b], 캐시 미스 분석 [The11], 그리고 하드웨어 카운터 기반의 프로파일링 [EGMdB11, The12], 그리고 그 외에도 여러 가지입니다.

잘 짜여진 설계와 여러 동기화 메커니즘들의 좋은 조합, 훌륭한 도구의 사용 아래에서는 락킹은 어플리케이션과 커널을 위해선 상당히 잘 동작합니다.

7.5.2 Locking For Parallel Libraries: Just Another Tool

어플리케이션과 커널의 경우와 달리, 라이브러리 설계자는 라이브러리와 함께 동작하게 될 코드의 락킹 설계에 대해서 알 수 없습니다. 사실, 그 코드는 몇년 이후에야 쓰여질 수도 있습니다. 따라서 라이브러리의 설계자는 마음대로 제어할 수 있는 부분이 더 적고 라이브러리의 동기화 설계를 만들 때 더 많은 주의를 기울여야만 합니다.

Deadlock은 물론 특별히 신경 써야 하는 부분이고, 따라서 Section 7.1.1에서 언급한 기술들이 적용되어야 합니다. 유명한 deadlock 방지 방법 가운데 하나는 라이브러리의 락들은 라이브러리를 둘러싼 프로그램의 락킹 계층의 독립적인 부집합이라 보장을 하는 것입니다. 하지만, 이는 보이는 것보다 좀 더 어려울 수 있습니다.

그런 복잡한 문제들 중 하나가 Section 7.1.1.2에서 이야기 되었는데, `qsort()`의 비교 함수를 인자로 사용해서 라이브러리 함수가 어플리케이션 코드를 호출할 때가 이 경우가 될 수 있겠습니다. 또 다른 복잡한 문제는 시그널 핸들러와의 상호작용입니다. 어떤 어플리케이션의 시그널 핸들러가 라이브러리 함수 수행 중 받은 시그널에 의해 호출되는 경우, 그 라이브러리 함수가 그 시그널 핸들러를 직접 호출한다면 분명 deadlock이 발생할 수 있습니다. 마지막으로, 또 하나의 복잡한 문제가 일어날 수 있는 경우는 `fork()/exec()` 사이에서 사용될 수 있는 라이브러리 함수인데, 예를 들면 `system()` 함수의 사용으로 인한 경우입니다. 이런 경우, 라이브러리 함수가 `fork()` 시점에 어떤 락을 잡고 있었다면, 자식 프로세스는 그 락을 잡은 채 수행을 시작합니다. 그런데 그 락을 놓아줄 쓰레드는 자식 프로세스가 아니라 부모 프로세스에서 돌아가고 있으므로, 만약 자식이 라이브러리 함수를 또 다시 호출하게 되면 deadlock이 발생할 것입니다.

다음의 전략들은 이런 경우들에서 deadlock 문제를 해결하기 위해 사용될 수 있을 것입니다:

1. 콜백도 시그널도 사용하지 말 것.
2. 콜백이나 시그널 핸들러 안에서 락을 잡지 말 것.
3. 호출자가 동기화를 제어하도록 할 것.

4. 락킹을 호출자에게 넘길 수 있도록 라이브러리 API 를 조정할 것.
5. 명시적으로 콜백 deadlock 을 없앨 것.
6. 명시적으로 시그널 핸들러 deadlock 을 없앨 것.

이 전략들 각각이 다음 섹션들에서 설명됩니다.

7.5.2.1 Use Neither Callbacks Nor Signals

라이브러리 함수가 콜백을 허용하지 않고 어플리케이션 전체가 시그널을 막는다면, 그 라이브러리 함수에 의해 잡히는 모든 락은 락킹 계층 tree 의 leaf 들이 될 겁니다. 이런 구성은 Section 7.1.1.1 에서 이야기했듯 데드락을 막습니다. 이 전략은 적용 가능한 곳에서는 매우 잘 동작하지만, 시그널 핸들러를 사용해야만 하는 어플리케이션들도 존재하게 마련이고, 콜백을 필요로 하는 라이브러리 함수들 (Section 7.1.1.2 에서 이야기한 `qsort()` 함수와 같은) 도 일부 있게 마련입니다.

다음 섹션에서 이야기하는 전략이 이런 경우에 많이 사용될 수 있을 겁니다.

7.5.2.2 Avoid Locking in Callbacks and Signal Handlers

어떤 콜백도 시그널 핸들러도 락을 잡지 않는다면, 이것들은 데드락 사이클에 포함될 수가 없는데, 이 사실은 다시 한번 일직선적인 락킹 계층에서 라이브러리 함수들을 락킹 계층 tree 의 leaf 로 만들어주는 방법을 고려해보게 합니다. 이 전략은 콜백이 자신에게 넘겨진 두개의 값을 비교하기만 하는 `qsort` 에서는 매우 잘 동작합니다. 이 전략은 또한 많은 시그널 핸들러들에 대해서도 놀라우리만큼 잘 동작하는데, 특히 시그널 핸들러 안에서 락을 잡는 행위는 일반적으로 좋지 않은 일이라는 사실 [Gro01]⁹ 을 놓고 보면 더욱 그렇습니다만 어플리케이션이 시그널 핸들러 안에서 복잡한 데이터 구조체를 조작해야 할 필요가 있다면 잘 동작하지 못할 수도 있습니다.

복잡한 데이터 구조체를 조작해야 하는 상황에서도 시그널 핸들러에서 락을 잡는 향위를 막을 수 있는 몇 가지 방법은 다음과 같습니다:

1. Section 14.2.1 에서 이야기된 non-blocking 동기화를 사용하는 간단한 데이터 구조체들을 사용하세요.

2. 데이터 구조체가 non-blocking 동기화를 합리적으로 사용하기 어려울 정도로 너무 복잡하다면, non-blocking 한 집어넣기 오퍼레이션을 제공하는 대기열을 하나 만드세요. 시그널 핸들러에서는 그 복잡한 데이터 구조체를 직접 제어하는 대신, 필요한 변경사항을 의미하는 원소를 이 대기열에 집어넣으세요. 별도의 쓰레드는 이 큐에서 원소를 꺼내서 일반적인 락킹을 사용해서 그 요청된 변경을 대신 해줍니다. 이미 사용 가능한 동시적 대기열의 구현들이 여럿 있습니다 [KLP12, Des09b, MS96].

이 전략은 임시의 매뉴얼이나 콜백들과 시그널 핸들러들의 자동화된 검사기능 (이편이 더 좋습니다) 아래에서만 사용되어야 합니다. 이런 검사기능을 수행할 때에는 현명한 코더들이 (지혜롭지 못하게도) 만들어낸, 어토믹 오퍼레이션을 사용해 만들어진 그들만의 락을 사용할 수도 있다는 점에 조심해야만 합니다.

7.5.2.3 Caller Controls Synchronization

호출자가 동기화를 제어하게 하기. 이 방법은 라이브러리 함수들이 호출자가 볼 수 있는 데이터 구조체 인스턴스들 가운데 독립적이어서 각자 개별적으로 동기화가 될 수 있는 것들을 가지고 동작할 때 매우 잘 동작합니다. 예를 들어 라이브러리 함수가 탐색 tree 를 가지고 동작한다면, 그리고 어플리케이션은 여러개의 독립적인 탐색 tree 들을 가지고 있어야 한다면, 어플리케이션은 각 tree 별로 락을 두어 관리할 수 있을 겁니다. 이렇게 되면 어플리케이션은 필요한대로 락을 잡고 풀어서 라이브러리가 병렬성에 대해 전혀 신경쓰지 않아도 되도록 할 수 있을 겁니다. 대신에 Section 7.5.1 에서 이야기 했듯 락킹이 매우 잘 동작하도록 어플리케이션이 병렬성을 제어하게 되는 셈입니다.

하지만, 이 전략은 라이브러리가 동시성을 필요로 하는 데이터 구조체를 내부적으로 구현하고 있다면 실패할 수 있는데, 예를 들면 해시 테이블이나 병렬적 정렬입니다. 이런 경우에, 라이브러리는 반드시 자신의 동기화 제어를 해야만 합니다.

7.5.2.4 Parameterize Library Synchronization

여기서의 아이디어는 라이브러리의 API 에 인자를 추가해서 어떤 락들을 잡아야 하는지, 또는 어떻게 잡아야 하며 어떻게 해제해야 하는지, 또는 둘 다를 알릴 수 있게 하자는 겁니다. 이 전략은 어플리케이션이 (락들로의 포인터를 넘겨줌으로써) 어떤 락을 잡아야 하며 (락 획득과 해제 작업을 하는 함수로의 포인터를 넘김으로써) 어떻게 그것들을 잡아야 하는지 알림으로써 데드락을 방지하기 위한 전체 작업을 하게 됩니다만, 라이브러리

⁹ 하지만 표준의 말이 똑똑한 코더들이 어토믹 오퍼레이션을 가지고 자신만의 락킹 도구들을 만드는 걸 막지는 못합니다.

함수는 락들을 어디서 잡고 해제할지 직접 결정함으로써 자신의 동시성을 제어할 수 있도록 합니다.

더 구체적으로는, 이 전략은 락 획득과 해제 함수들이 필요에 따라 시그널이 발생되지 않도록 막음으로써 라이브러리 코드는 어떤 락에 대해 어떤 시그널이 막혀야 하는지 알 필요가 없게 해줍니다. 이 전략에 의해 주의해야 할 부분들이 분리되는 효과는 상당합니다만, 어떤 경우에는 뒤의 섹션들에서 설명할 전략이 더 잘 동작할 수 있습니다.

그렇다고는 하나, Section 7.1.1.4에서 이야기 되었듯, 락으로의 명시적인 포인터를 외부의 API에 넘겨주는 것은 매우 조심히 숙고되어야 합니다. 이 방법이 가끔은 해야 마땅한 옳은 일이긴 하지만, 다른 대안의 설계는 없는지 먼저 알아보아야만 합니다.

7.5.2.5 Explicitly Avoid Callback Deadlocks

이 전략의 기본적인 규칙은 Section 7.1.1.2에서 이야기된 바 있습니다: “모르는 코드를 실행하기 전에 모든 락을 놓기.” 이 방법은 어플리케이션이 라이브러리의 락킹 계층에 대해 몰라도 되게 해주기 때문에 일반적으로 최선의 방법입니다: 라이브러리는 어플리케이션의 전체 락킹 계층에서 leaf 또는 격리된 subtree로 남아 있습니다.

모르는 코드를 실행하기 전에 모든 락을 놓기 불가능한 경우에는 Section 7.1.1.3에서 이야기한 layer를 갖는 락킹 계층이 잘 동작할 수 있습니다. 예를 들어, 모르는 코드가 시그널 핸들러라면, 이는 해당 라이브러리 함수가 모든 락 획득을 가로질러 시그널을 블록하게 될 것임을 의미하는데, 이는 매우 느리고 복잡한 일이 될 것입니다. 따라서, 시그널 핸들러가 (아마도 지혜롭지 못하게도) 락을 획득하는 경우라면 다음 섹션에서 이야기하는 전략이 도움이 될 수 있을 겁니다.

7.5.2.6 Explicitly Avoid Signal-Handler Deadlocks

특정 라이브러리 함수가 락을 잡지만, 시그널을 막지 않는다고 알려졌다고 생각해 봅시다. 또한, 이 함수를 시그널 핸들러의 안과 밖에서 모두 호출해야 하며, 이 라이브러리 함수를 수정할 수는 없다고 생각해 봅시다. 물론, 특수한 행동이 취해지지 않는다면, 이 라이브러리 함수가 락을 잡는 동안 시그널이 도착하면 시그널 핸들러가 같은 라이브러리 함수를 호출해서 똑같은 락을 또다시 잡으려 시도하면 데드락이 발생할 수 있습니다.

그런 데드락은 다음과 같은 방법으로 회피될 수 있습니다:

1. 어플리케이션이 라이브러리 함수를 시그널 핸들러에서 실행한다면, 그 시그널은 시그널 핸들러 밖에서 해당 라이브러리 함수가 호출될 때마다 블락되어야만 합니다.

2. 어플리케이션이 어떤 시그널 핸들러 안에서 잡은 락을 쥐고 있는 채로 라이브러리 함수를 실행한다면, 그 시그널은 이 라이브러리 함수가 시그널 핸들러 밖에서 호출될 때마다 블락되어야 합니다.

이런 규칙들은 리눅스 커널의 lockdep 락 의존성 체크 도구 [Cor06a]와 비슷한 도구들을 사용해서 강제될 수 있습니다. Lockdep의 강력한 점 중 하나는 사람의 직관에 의해 잘못된 실수를 저지르지 않는다는 점입니다 [Ros11].

7.5.2.7 Library Functions Used Between `fork()` and `exec()`

앞에서 이야기 했듯이, 라이브러리 함수를 수행하는 쓰레드가 또 다른 어떤 쓰레드가 `fork()`를 수행할 때 락을 쥐고 있었다면, 부모 프로세스의 메모리가 자식 프로세스를 만들기 위해 복사된다는 사실은 이 락이 자식 프로세스의 컨텍스트에는 잡힌 채로 자식 프로세스가 태어나게 됨을 의미합니다. 이 락을 해제하는 쓰레드는 부모 프로세스에서 동작하고 있지 자식 프로세스에서 동작하고 있지 않으므로, 자식 프로세스의 이 락의 복사본은 결코 해제되지 않을 것입니다. 따라서, 자식 프로세스 쪽에서 같은 라이브러리 함수를 실행하려는 시도는 모두 deadlock을 초래하고 말 것입니다.

이 문제를 해결하는 한가지 방법은 그 락의 소유자가 여전히 수행중인지 이 라이브러리 함수가 확인해 보고, 만약 그렇지 않다면 그 락을 다시 초기화시킴으로써 “깨버리고” 다시 잡는 것입니다. 하지만, 이 방법에는 두개의 취약점이 존재합니다:

1. 그 락에 의해 보호되던 데이터 구조체들은 어떤 중간 상태에 빠져 있어서 낙관적으로 락을 깨는 행위는 임의의 메모리 오염을 초래할 수 있습니다.
2. 자식 프로세스가 추가적인 쓰레드들을 생성하면, 두 쓰레드들은 그 락을 동시에 깰 수 있고, 이렇게 되면 두 쓰레드 모두 자신이 락을 잡고 있다고 생각하게 될 것입니다. 이는 또다시 임의의 메모리 오염 상황을 초래할 수 있습니다.

이런 상황을 처리하는 걸 돋기 위해 `atfork()` 함수가 존재합니다. 아이디어는 세개의 함수들을 등록해 두는데, 이 함수들 중 하나는 `fork()` 전에 부모 프로세스에 의해서 호출되고, 또 하나는 `fork()` 후에 부모 프로세스에 의해서 호출되고, 마지막 하나는 `fork()` 후에 자식 프로세스에 의해 호출됩니다. 이런 상황에서는 이 세개의 시점에서 적절한 처리를 함으로써 이 상황을 해결할 수 있습니다.

하지만, `atfork()` 핸들러의 코딩은 일반적으로 상당히 섬세하게 되어야 함에 주의하시기 바랍니다.

`atfork()` 방식이 가장 잘 동작할 수 있는 경우들은 사용되는 데이터 구조체들이 자식 프로세스에 의해 간단히 다시 초기화 될 수 있는 경우들입니다.

7.5.2.8 Parallel Libraries: Discussion

어떤 전략을 사용하는가에 관계없이, 라이브러리의 API에 대한 명세는 사용하는 전략과 호출자가 그 전략과 어떻게 상호작용 해야 하는지에 대한 분명한 설명을 가지고 있어야만 합니다. 요약하자면, 락킹을 사용해서 병렬 라이브러리를 구성하는 것은 가능한 일이긴 합니다만, 병렬 어플리케이션을 구성하는 것만큼 쉽지는 않습니다.

7.5.3 Locking For Parallelizing Sequential Libraries: Villain!

쉽게 접할 수 있는 저가의 멀티코어 시스템들이 늘어남에 따라, 싱글 쓰레드 기반만을 상정하고 설계된 기존의 라이브러리들을 병렬화 하는건 흔한 작업이 되었습니다. 병렬성에 무관심하게 이루어지는 이런 모든 흔한 작업들은 병렬 프로그래밍 관점에서는 심각한 결점을 포함하는 라이브러리 API를 만들어지게 할 수 있습니다. 결점이 될 수 있는 것들은 다음과 같습니다:

1. 명시적이지 않은 파티셔닝의 금지.
2. 락킹을 필요로 하는 콜백 함수.
3. 객체 지향 스파게티 코드.

이런 결점들과 락킹에 대한 중요성들을 다음의 섹션들에서 이야기 해보겠습니다.

7.5.3.1 Partitioning Prohibited

싱글 쓰레드로 해시 테이블을 구현하고 있다고 생각해 봅시다. 해시 테이블의 모든 아이템의 정확한 갯수를 쉽고 빠르게 유지할 수 있을 것이고, 또한 이 정확한 갯수를 매 원소 추가와 삭제 작업마다 알려주는 것도 쉽고 빠르게 할 수 있을 것입니다. 그런데 왜 병렬화가 어려울까요?

한가지 이유는 정확한 카운터는 Chapter 5에서 봤듯이 멀티코어 시스템에서는 성능도 확장성도 그렇게 좋지 못하다는 점입니다. 결국, 이 해시 테이블의 병렬화된 구현은 성능도 확장성도 그다지 좋지 않을 것입니다.

이 문제를 어떻게 하면 좋을까요? 한가지 방법은 Chapter 5에서 이야기한 알고리즘들 가운데 하나를 사용해서 대략적인 수치를 주는 겁니다. 또 다른 방법은 원소 갯수 카운트 기능을 없애버리는 겁니다.

어떤 방법을 사용하든, 해시테이블에 원소를 추가하거나 삭제할 때마다 정확한 원소 갯수를 알아야 하는 이유를 알기 위해 해시 테이블의 사용 패턴을 잘 알아볼 필요가 있을 겁니다. 여기 몇 가지 가능한 경우를 열거해 보면:

1. 해시 테이블의 크기를 재조정 해야할 때를 결정하기 위해. 이 경우, 대략적인 카운트도 상당히 잘 동작할 것입니다. 또한 크기 재조정 작업을 가장 긴 체인의 길이에 따라서 시작하도록 하는 것도 효율적일텐데, 이는 체인 별로 잘 파티셔닝 된 형태로 계산되고 관리될 수 있을 것입니다.
2. 전체 해시 테이블을 돌아다니는데 필요한 시간을 계산하기 위해서. 대략적인 카운트는 이 경우에도 역시 잘 동작할 것입니다.
3. 예를 들면 해시 테이블에 집어넣고 빼내는 항목이 없어진 경우의 확인 등을 위한 검사의 목적을 위해서. 이 경우는 분명히 정확한 카운트를 필요로 합니다. 하지만, 이런 사용은 기본적으로 검사를 위한 것이기 때문에 해시 체인들의 길이를 유지하면서 가끔 가다 원소 추가와 삭제 작업을 막아 두고 그 합을 구하는 것만으로도 충분할 것입니다.

병렬 라이브러리 API 자체에 존재하는 성능과 확장성에 대한 일부 제약에 대한 강한 이론적 토대가 존재함이 밝혀졌습니다 [AGH⁺11a, AGH⁺11b, McK11b]. 병렬 라이브러리를 설계하는 사람들은 모두 그런 제약에 대해 깊이 알아볼 필요가 있습니다.

락킹을 동시성에 친화적이지 않은 API 때문에 문제라고 비난하는 것은 너무 쉬운 일이지만 그렇게 하는게 현실적으로 큰 도움이 되지 않습니다. 반면에, (대략) 1985년에 그 설계 선택을 내려야만 했던 불운한 개발자에게 공감을 하는 소수의 선택을 할 수도 있을 것입니다. 그 당시에는 병렬성의 필요성을 예전에는 개발자는 매우 드물고 용기 있는 개발자였을 것이고, 심지어 실제로 좋은 병렬성 친화적인 API를 만드는데에는 용기와 행운의 조합이 필요했을 것입니다.

시간은 흐르게 마련이고, 코드도 그에 따라 변화해 갑니다. 그렇다고는 하나, 유명한 라이브러리라면 수많은 사용자가 존재할 수 있고, 그런 경우에 호환성을 잃는 변경을 API에 가하는 것은 매우 어리석은 짓일 겁니다. 이미 존재하고 매우 많이 사용되고 있는 순차적으로만 동작하는 API를 보완하기 위한 병렬성 친화적 API를 추가하는 것이 이런 상황에서는 최선의 선택일 겁니다.

그렇다고 하나, 인간사가 그렇듯이, 우리의 불운한 개발자는 자신의 (이해할 수 있기는 하지만) 잘못된 API 설계 선택보다는 락킹 자체를 비난할 가능성이 더 클 것을 예상할 수 있습니다.

7.5.3.2 Deadlock-Prone Callbacks

Section 7.1.1.2, 7.1.1.3, 그리고 7.5.2 에서 아무런 고려 없이 사용되는 콜백이 어떻게 락킹의 비극을 초래할 수 있는지를 알아보았습니다. 이 섹션들은 또한 이런 문제를 없애기 위해 라이브러리 함수를 어떻게 설계해야 하는지에 대해서도 설명했습니다만, 병렬 프로그래밍에 대한 경험이 없는 1990년대의 프로그래머가 그런 설계 원칙을 따랐기를 기대하는 것은 비현실적입니다. 따라서, 콜백을 많이 사용하는 기존의 싱글 쓰레드 기반 라이브러리를 병렬화 하려는 사람은 락킹의 악행과 마주칠 가능성이 큽니다.

콜백을 많이 사용하는 라이브러리가 이미 여러 곳에서 사용되고 있다면, 앞 섹션에서 이야기 했듯 기존 사용자들이 그들의 코드를 점진적으로 바꿔갈 수 있도록 라이브러리에 병렬성 친화적 API를 추가하는 것이 현명할 것입니다. 어떤 사람들은 이런 경우에 대안적으로 트랜잭션 메모리의 사용을 추천합니다. 아직 독자 여러분께 트랜잭션 메모리에 대해 설명드리지 않았지만, Section 17.2 에서는 그 강점과 약점에 대해 논의해 봅니다. 하드웨어 트랜잭션 메모리 (Section 17.3 에서 논의됩니다) 는 실제 하드웨어 트랜잭션 메모리 구현이 일의 진행을 보장하지 않는다면 (대부분의 구현이 그런 보장을 하지 않습니다) 이 경우에 도움이 되지 않음을 알아둘 필요가 있습니다. 상당히 실용적인 것으로 알려진 (과대광고 되지 않았다면) 다른 대안으로는 Sections 7.1.1.5, 7.1.1.6, 그리고 Chapter 8 와 9 에서 논의되는 방법들이 있습니다.

7.5.3.3 Object-Oriented Spaghetti Code

객체지향 프로그래밍은 1980 년대 또는 1990 년대의 언젠가에 주류가 되었고, 그 결과로 상용 제품에는 많은 양의 객체지향 코드가 존재하게 되었는데, 대부분이 싱글 쓰레드 기반입니다. 객체지향성은 가치 있는 소프트웨어 테크닉이 될 수 있지만, 생각 없이 사용된 객체들은 객체지향적 스파게티 코드를 만들어 낼 수 있습니다. 객체지향 스파게티 코드에서, 실행 흐름 제어는 필수적으로 무작위한 형태로 객체와 객체 사이에서 훌러다니게 되어서 코드를 더더욱 이해하기 어렵게 만들고 락킹 계층을 수용하기가 불가능하게 될 수도 있습니다.

그런 코드는 어떤 경우에든 정리되어야 한다고 주장하는 사람도 많겠지만, 실제로 그렇게 정리를 하는 일은 말하는 것보다 훨씬 어렵습니다. 그런 코드를 병렬화하는 작업을 맡게 되었다면, Section 7.1.1.5, 와 7.1.1.6, 그리고 Chapter 8 와 9 에서 논의되고 설명된 기법들을 사용함으로써 락킹을 원망할 기회를 줄일 수 있습니다. 이런 상황은 트랜잭션 메모리에 대한 아이디어를 떠올리게 한 사용 예인 것으로 여겨지며, 따라서 한번 시도해 보는 것도 좋을 것입니다. 그렇다고는 하나, 동기화

메커니즘의 선택은 Chapter 3 에서 이야기된 하드웨어의 특성에 따라서 만들어져야만 합니다. 어쨌거나, 동기화 메커니즘의 오버헤드가 보호되는 오퍼레이션들의 오버헤드보다 열배 이상 높다면, 그 결과는 그다지 보기 좋지 않을 겁니다.

그리고 그런 것들이 이런 상황에서 이런 질문을 해보는게 가치있게 할겁니다: 코드가 순차적인 형태로 남아있어야 하는가? 예를 들어, 병렬성은 쓰레드 수준이 아니라 프로세스 수준에서 사용될 수도 있습니다. 일반적으로, 특정 작업이 극단적으로 어려움이 증명되었다면, 가끔은 그 특정한 작업을 해결하기 위한 대안들만이 아니라 그 작업을 해야하게 만드는 문제 자체를 해결하는 대안적 방법들도 생각해 볼 필요가 있습니다.

7.6 Summary

Achievement unlocked.

Unknown

락킹은 아마도 가장 많이 사용되고 있고 일반적으로 가장 유용한 동기화 도구입니다. 하지만, 락킹은 어플리케이션이나 라이브러리에 작성 초기부터 고려되어서 설계되었을 때 가장 잘 동작합니다. 기존에 존재하던 싱글 쓰레드 기반의 거대한 코드를 하루만에 병렬적으로 동작하도록 만들어야 한다면, 락킹은 병렬 프로그래밍 도구상자의 유일한 도구여서는 안될 겁니다. 다음의 챕터들에서는 다른 도구들을 알아보고, 그것들이 락킹과 또 다른 것들과 함께 어떻게 사용되는게 최선인지에 대해서 알아봅니다.

It is mine, I tell you. My own. My precious. Yes, my precious.

*Gollum in “The Fellowship of the Ring”,
J.R.R. Tolkien*

Chapter 8

Data Ownership

락킹에 따라오는 동기화 오버헤드를 없애는 가장 간단한 방법들 중 하나는 데이터를 쓰레드들 각각에 맞춰(또는, 커널의 경우라면, CPU 들 사이로) 포장을 해서 데이터의 한 조각은 하나의 쓰레드에 의해서만 접근되고 수정되도록 하는 것입니다. 흥미롭게도, 데이터 소유권은 병렬 설계 기법의 “큰 세가지 전략”을 모두 충족합니다: 이 기법은 쓰레드별로(또는, 경우에 따라서는 CPU 별로) 데이터를 쪼개고, 모든 지역적 작업을 몰아서 처리하고, 그 극단적인 논리에 의해 동기화 오퍼레이션이 제거됩니다. 따라서 데이터 소유권이 굉장히 많은 곳에서 사용된다는 사실은 놀랄 만한 일이 아니고, 실제로 초심자들도 거의 본능적으로 사용하는 사용 패턴입니다. 사실, 그 사용처는 너무 많아서 이 챕터는 새로운 예제를 소개하지는 않을 것이고, 대신 앞의 챕터들에서 보았던 예제들을 참조하겠습니다.

Quick Quiz 8.1: 어떤 형태의 데이터 소유권이 C 나 C++를 사용해서(예를 들어, pthreads를 사용해서) 공유 메모리 병렬 프로그램을 만들 때 방지하기가 극단적으로 어려울까요? ■

데이터 소유권을 적용하는 다양한 방법이 존재합니다. Section 8.1에서는 각 쓰레드가 자신의 개인적 주소 공간을 갖는, 데이터 소유권의 논리적 극단을 보여드립니다. Section 8.2에서는 반대의 극단을 소개하는데, 데이터가 공유되지만 다른 쓰레드들은 데이터에의 다른 접근 권한을 갖는 경우입니다. Section 8.3에서는 함수 전달을 서명하는데, 다른 쓰레드들이 특정 쓰레드가 소유하는 데이터에 간접적인 액세스를 하도록 허용하는 방법입니다. Section 8.4에서는 어떻게 특정 쓰레드들이 특정 함수와 그에 연관된 데이터들의 소유권을 할당받을 수 있는지 설명합니다. Section 8.5에서는 공유 데이터를 사용하는 알고리즘을 데이터 소유권을 사용하도록 변환함으로써 성능을 개선시키는 것에 대해 논의해 봅니다. 마지막으로, Section 8.6에서는 데이터 소유권을 일등시민으로 두는 몇 가지 소프트웨어 환경을 나열해 봅니다.

8.1 Multiple Processes

A man's home is his castle

Ancient Laws of England

Section 4.1에서 다음의 예를 소개한 바 있습니다:

```
1 compute_it 1 > compute_it.1.out &
2 compute_it 2 > compute_it.2.out &
3 wait
4 cat compute_it.1.out
5 cat compute_it.2.out
```

이 예는 `compute_it` 프로그램의 두개의 인스턴스를 메모리를 공유하지 않는 별개의 프로세스들을 통해 병렬로 수행합니다. 따라서, 해당 프로세스의 모든 데이터는 그 프로세스에 소유되어 있어서, 위 예제의 모든 데이터는 소유되어 있습니다. 이 방법은 거의 모든 동기화 오버헤드를 제거합니다. 그 결과 나타나는 극단적인 단순함과 최적의 성능의 조합은 상당히 매력적입니다.

Quick Quiz 8.2: Section 8.1에서 보인 예제에 남아 있는 동기화 작업은 무엇이 있을까요? ■

Quick Quiz 8.3: Section 8.1에서 보여진 예제에 어떤 공유된 데이터가 있나요? ■

`sh`에서 했던 것과 똑같은 패턴을 C로도 구현할 수 있는데, Listing 4.1과 4.2에 그 구현이 그려져 있습니다.

이 간단한 형태의 병렬성은 속임수이거나 책임을 회피하는게 아니라, 여러분의 코드를 빠르게 수행하기 위한 간단하고 우아한 방법이란 이야기를 반복하겠습니다. 이 방법은 빠르고, 잘 확장되고, 프로그램하기 쉽고, 유지보수하기 쉬우며, 일을 해냅니다. 또한, 이 방법을 (사용할 수 있는 곳에) 취하는 것은 개발자가 `compute_it`의 싱글스레드 기반 최적화를 적용하는 것 또는 이 방법이 적용되기 어려운 코드 부분에 괜찮은 병렬 프로그래밍 패턴을 적용하는 것 등의 다른 부분에 신경쓸 시간을 벌어줍니다. 이걸 싫어할 이유가 있나요?

다음 섹션은 공유 메모리 병렬 프로그램에서의 데이터 소유권 사용에 대해 논의해 봅니다.

8.2 Partial Data Ownership and *pthreads*

Give thy mind more to what thou hast than to what thou hast not.

Marcus Aurelius Antoninus

Chapter 5 는 데이터 소유권을 많이 사용하고 있습니다만, 한가지 새로운 방식을 가지고 있습니다. 쓰레드들은 다른 쓰레드들에 의해 소유되는 데이터를 수정할 수 없도록 되어있지만, 그것들을 읽을 수는 있습니다. 요약해서, 공유 메모리의 사용은 소유권과 접근 권한들에 대한 더 많은 묘한 개념이 조재하게 합니다.

예를 들어, page 49 의 Listing 5.5 에 있는 쓰레드 별 통계적 카운터 구현을 생각해 봅시다. 여기서, `inc_count()` 는 연관된 쓰레드의 `counter` 인스턴스를 수정할 뿐입니다만, `read_count()` 는 모든 쓰레드의 `counter` 인스턴스들을 접근하되 수정하지는 않습니다.

Quick Quiz 8.4: 각각의 쓰레드가 자신의 쓰레드 별 변수만을 읽을 수 있지만 다른 쓰레드의 인스턴스들에는 쓰기를 할 수도 있는 부분적 데이터 소유권도 말이 될까요? ■

순수한 데이터 소유권은 또한 일반적이면서 유용한데, page 84 부터 시작되는 Section 6.4.3 에서 이야기된 쓰레드 별 메모리 할당자 캐시가 한 예입니다. 이 알고리즘에서, 각 쓰레드의 캐시는 그 쓰레드에게 완전히 소유되어 있습니다.

8.3 Function Shipping

If the mountain will not come to Muhammad, then Muhammad must go to the mountain.

Essays, Francis Bacon

앞의 섹션에서는 쓰레드들이 다른 쓰레드들의 데이터에 접근할 수 있는 약한 형태의 데이터 소유권에 대해 이야기했습니다. 이런 형태는 함수에 필요한 데이터를 가져다 주는 것으로 생각될 수 있습니다. 대안적인 접근법은 데이터에 함수를 가져다 주는 것입니다.

그런 접근법이 page 59 에서 시작하는 Section 5.4.3 중 page 61 의 Listing 5.17 에 있는 `flush_local_count_sig()` 와 `flush_local_count()` 함수로 그려져 있습니다.

`flush_local_count_sig()` 함수는 전달되는 함수처럼 동작하는 시그널 핸들러입니다. `flush_local_count()` 의 `pthread_kill()` 함수는 시그널을 보내고—함수를 전달하는 행위—전달된 함수가 실행되기를

기다립니다. 이 전달된 함수는 일반적이지 않은, 동시적으로 수행되는 `add_count()` 나 `sub_count()` 함수들과의 상호작용의 필요로 인해 추가된 복잡성을 갖습니다 (page 61 의 Listing 5.18 와 page 62 의 Listing 5.19 를 참고하세요).

Quick Quiz 8.5: 함수를 전달하는데 POSIX 시그널 외에 어떤 다른 메커니즘이 사용될 수 있을까요? ■

8.4 Designated Thread

Let a man practice the profession which he best knows.

Cicero

앞의 섹션들에서는 각 쓰레드가 데이터 복사본을 또는 데이터의 특정 부분을 소유하는 여러가지 방법들을 설명했습니다. 반대로, 이 섹션에서는 특별한 선택된 쓰레드가 프로그램이 일을 하는데 필요한 데이터를 소유하는 함수적 분해 방법을 설명합니다. Section 5.2.3 에서 설명했던, 결과적으로 일관적인 카운터 구현이 그에 대한 예를 제공합니다. 이 구현은 Listing 5.4 의 line 15-32 에서 보이는 `eventual()` 함수를 수행하는 정해진 쓰레드를 가지고 있습니다. 이 `eventual()` 쓰레드는 주기적으로 쓰레드 별 카운트를 글로벌 카운터로 가져와서 글로벌 카운터로의 접근이 이름이 말하는 바와 같이 결과적으로는 실제 값에 수렴하게 합니다.

Quick Quiz 8.6: 하지만 Listing 5.4 의 line 15-32 에 보여진 `eventual()` 함수의 어떤 데이터도 실제로는 `eventual()` 쓰레드에게 소유되어 있지 않습니다! 이게 어떻게 데이터 소유권인가요??? ■

8.5 Privatization

There is, of course, a difference between what a man seizes and what he really possesses.

Pearl S. Buck

공유 메모리 병렬 프로그램의 성능과 확장성을 개선하는 방법 가운데 하나는 공유된 데이터를 특정 쓰레드에 의해 사유된 데이터로 변환시키는 것입니다.

이런 방법의 좋은 예가 Section 6.1.1 의 Quick Quiz 중 하나의 답변에 있는데, 식사하는 철학자 문제를 데이터 사유화를 통해 교재의 표준적인 해결책보다 훨씬 좋은 성능과 확장성으로 해결하는 해결책입니다. 원래의 문제는 다섯명의 철학자들이 테이블에 앉아있고 인접한 두 철학자 사이에 하나의 포크만이 놓여 있어서 최대

두명의 철학자만이 동시에 식사를 할 수 있게 되어 있었습니다.

우린 여기에 다섯개의 포크를 추가함으로써 각각의 철학자가 그 또는 그녀 자신만의 포크 한쌍을 가질 수 있게 하는것으로 간단히 문제에 사유화를 적용할 수 있습니다. 이 방법은 모든 다섯명의 철학자들이 동시에 식사를 할 수 있도록 하고, 또한 그런 종류의 문제의 확산을 주목할만하게 감소시킬 수 있습니다.

다른 경우에는, 사유화는 비용을 의미합니다. 예를 들어, page 52 의 Listing 5.7 에 나온 간단한 리미트 카운터를 생각해 봅시다. 이는 쓰레드들이 서로의 데이터를 읽을 수 있지만 자신의 데이터만 업데이트 할 수 있도록 허용되는 알고리즘의 한가지 예입니다. 해당 알고리즘을 간단히 살펴본 결과 쓰레드간의 접근은 `read_count()` 의 합산을 위한 루프 뿐임을 알 수 있습니다. 이 루프가 사라진다면, 더 효과적인 순수 데이터 소유권으로 옮겨갈 수 있습니다만, `read_count()` 의 덜 정확한 결과값을 비용으로 지불하게 될겁니다.

Quick Quiz 8.7: 쓰레드별 데이터의 완전한 사유화를 유지하면서 좋은 정확도를 얻을 수도 있을까요? ■

요약하자면, 사유화는 병렬 프로그래머의 도구상자에 있는 강력한 도구입니다만 충분한 고려 없이 사용되어선 안됩니다. 모든 다른 동기화 도구들처럼, 이 방법 역시 성능과 확장성을 떨어뜨리고 복잡도를 높일 수 있는 잠재적 가능성이 존재합니다.

5. 프로세스별로 분리된 주소공간을 갖는 Fork-join 시스템들.

6. Erlang 언어와 같은 프로세스 기반 병렬성.

7. 쓰레드 환경에서 C 언어의 스택 위에 할당되는 auto 변수들과 같은 사유 변수들.

8. 특히나 GPGPU 에 적합한, 많은 병렬 선형 대수 알고리즘들.¹

9. 네트워킹에 최적화 되어서 각각의 네트워크 연결 (*flow* 라고도 불립니다 [DKS89, Zha89, McK90a]) 이 특정 쓰레드로 할당되는 운영체제 커널들. 이런 방법의 최근의 한 예는 IX 운영체제입니다 [BPP⁺16]. IX는 Section 9.5 에서 설명할 동기화 메커니즘을 사용하는 공유 데이터 구조를 일부 갖습니다.

데이터 소유권은 아마도 존재하는 동기화 메커니즘들 중 가장 감사받지 못하고 있는 메커니즘입니다. 제대로 사용된다면, 이것은 적수를 찾기 어려울 만큼의 간단함과 성능, 그리고 확장성을 제공합니다. 아마도 이 간단함이 이것이 누리기 마땅한 존중의 이유입니다. 바라건대 데이터 소유권의 섬세함과 힘에 대한 감사함이 늘어나는 것은 더 많은 존중을 이끌어내어서 더 훌륭한 성능과 확장성에 더해 줄여든 복잡성을 이끌어낼 수 있게 할 것입니다.

8.6 Other Uses of Data Ownership

Everything comes to us that belongs to us if we create the capacity to receive it.

Rabindranath Tagore

데이터 소유권은 쓰레드간 데이터 액세스나 업데이트가 격거나 없을 수 있도록 분할 될 수 있을 때에 가장 잘 동작합니다. 다행히도, 이런 상황은 충분히 흔하고, 다양한 병렬 프로그래밍 환경에 존재합니다.

데이터 소유권의 예에는 다음의 것들도 포함됩니다:

1. MPI [MPI08] 와 BOINC [Uni08a] 같은 모든 메세지 전달 환경.
2. Map-reduce [Jac08].
3. RPC, 웹 서비스, 그리고 백엔드 데이터베이스 서버를 갖는 수많은 시스템들과 같은 클라이언트-서버 시스템들.
4. 아무것도 공유하지 않는 데이터베이스 시스템들.

¹ 하지만 굉장히 많은 다른 부류의 어플리케이션들 또한 GPGPU로 포팅되었음을 알아두시기 바랍니다 [Mat13, AMD17, NVi17a, NVi17b].

Chapter 9

Deferred Processing

일을 뒤로 미루는 전략은 역사의 기록이 시작되기 전부터 있었습니다. 이것은 미루기나 완전한 게으름으로 여겨져 종종 비웃음을 받아왔습니다. 하지만, 사람들은 지난 수십년간 병렬 알고리즘의 단순화와 능률화에 있어서의 이 전략의 가치를 깨달았습니다 [KL80, Mas92]. 이걸 믿든 믿지 않든, 병렬 프로그래밍에서의 “게으름”은 많은 경우 근면성에 비해 성능과 확장성이 좋습니다! 이런 성능과 확장성에서의 장점은 일을 뒤로 미루는 것은 종종 동기화 기능들을 약화시키는게 가능하게 하고, 따라서 동기화 오버헤드를 줄이게 된다는 사실에서 기인합니다. 일을 뒤로 미루는 일반적인 전략은 레퍼런스 카운팅 (Section 9.2), 해저드 포인터 (Section 9.3), 순차적 락킹 (Section 9.4), 그리고 RCU (Section 9.5) 등을 포함합니다. 마지막으로, Section 9.6 에서는 이 챕터에서 다루어진 일 뒤로 미루기 전략들 가운데 선택을 어떻게 해야 하는지 이야기 하고, Section 9.7 에서는 업데이트의 역할에 대해 논합니다.

하지만 먼저 이런 방법들을 비교하고 대비하는데에 사용될 예제 알고리즘을 소개하겠습니다.

9.1 Running Example

An ounce of application is worth a ton of abstraction.

Booker T. Washington

이 챕터는 이 접근법들의 가치를 보이고 또 그것들을 서로 비교할 수 있게끔 단순화된 패킷 라우팅 알고리즘을 사용할 겁니다. 라우팅 알고리즘은 운영체제 커널에서 각각의 바깥으로 나가는 TCP/IP 패킷들을 알맞는 네트워크 인터페이스로 전달하는데 사용됩니다. 여기서 사용하는 알고리즘은 고전적인 1980년대의 packet-train-optimized 알고리즘으로 BSD UNIX [Jac88]에서 사용되었으며, 단순한 링크드 리스트로 구성되었습니다.¹




Figure 9.1: Pre-BSD Packet Routing List

최신 라우팅 알고리즘들은 더 복잡한 데이터 구조를 사용합니다만, Chapter 5 에서와 같이, 극단적으로 간단한 알고리즘이 극단적으로 이해하기 쉬운 구성에서의 병렬성에 특정된 문제들을 밝히는데 도움을 줄 것입니다.

우리는 더 나아가서 출발지와 목적지 IP 주소와 포트, 네가지 정보로 구성되는 검색 키를 간단한 정수로 교체함으로써 알고리즘을 더욱 단순화할 겁니다. 검색되고 리턴되는 값 또한 간단한 정수로 바꿔질 것이어서, 데이터 구조는 Figure 9.1 에서와 같이 될건데, 이 그림대로라면 address 42 의 패킷을 interface 1 로, address 56 의 패킷을 interface 2 로, 그리고 address 17 의 패킷을 interface 7 로 전달할 겁니다. 외부의 네트워크는 안정적일 것을 가정하면, 이 리스트는 매우 자주 검색되고 아주 가끔씩만 업데이트 될 것입니다. Chapter 3 에서 우리는 빛의 제한된 속도와 물질의 원자성의 자연적 법칙과 같은 불편한 물리 법칙을 회피하는 가장 좋은 방법은 데이터를 쪼개거나 읽기가 대부분인 공유에 기대는 것임을 배웠습니다. 이 챕터에서, 우리는 이 Pre-BSD 패킷 라우팅 리스트를 사용해 읽기가 대부분인 상황을 위한 동기화 기법을 평가해 보도록 하겠습니다.

Listing 9.1 (`route_seq.c`)는 Figure 9.1 의 간단한 싱글 쓰래드 구현을 보입니다. Line 1-5 는 `route_entry`

¹ 달리 말하자면, 이건 OpenBSD, NetBSD 도 아니고 심지어

FreeBSD 도 아니었고 Pre-BSD 였습니다.

Listing 9.1: Sequential Pre-BSD Routing Table

```

1 struct route_entry {
2     struct cds_list_head re_next;
3     unsigned long addr;
4     unsigned long iface;
5 };
6 CDS_LIST_HEAD(route_list);
7
8 unsigned long route_lookup(unsigned long addr)
9 {
10     struct route_entry *rep;
11     unsigned long ret;
12
13     cds_list_for_each_entry(rep, &route_list, re_next) {
14         if (rep->addr == addr) {
15             ret = rep->iface;
16             return ret;
17         }
18     }
19     return ULONG_MAX;
20 }
21
22 int route_add(unsigned long addr, unsigned long interface)
23 {
24     struct route_entry *rep;
25
26     rep = malloc(sizeof(*rep));
27     if (!rep)
28         return -ENOMEM;
29     rep->addr = addr;
30     rep->iface = interface;
31     cds_list_add(&rep->re_next, &route_list);
32     return 0;
33 }
34
35 int route_del(unsigned long addr)
36 {
37     struct route_entry *rep;
38
39     cds_list_for_each_entry(rep, &route_list, re_next) {
40         if (rep->addr == addr) {
41             cds_list_del(&rep->re_next);
42             free(rep);
43             return 0;
44         }
45     }
46     return -ENOENT;
47 }

```

구조체를 정의하고 line 6 는 `route_list` 헤더를 정의합니다. Line 8-21 은 `route_lookup()` 을 정의하는데, 이 함수는 순차적으로 `route_list` 를 검색하고 검색에 성공하면 연관되는 `->iface` 를 리턴하고, 검색에 실패하면 `ULONG_MAX` 를 리턴합니다. Line 23-35 는 `route_add()` 를 정의하는데, 이 함수는 `route_entry` 구조체를 메모리 할당받고, 초기화 한 후, 리스트에 추가하는데 메모리 할당에 실패한 경우에는 `-ENOMEM` 을 리턴합니다. 마지막으로, line 37-50 은 `route_del()` 을 정의하는데, 이 함수는 특정 `route_entry` 구조체가 존재한다면 제거하고 그렇지 않다면 `-ENOENT` 를 리턴합니다.

이 싱글쓰레드 구현은 이 챕터 안의 다양한 동시성을 사용한 구현의 하나의 프로토 타입 역할을 하고, 또한 이상적인 성능과 확장성의 평가를 위한 역할도 합니다.

Listing 9.2: Reference-Counted Pre-BSD Routing Table Lookup

(BUGGY!!!)

```

1 struct route_entry {
2     atomic_t re_refcnt;
3     struct route_entry *re_next;
4     unsigned long addr;
5     unsigned long iface;
6     int re_freed;
7 };
8 struct route_entry route_list;
9 DEFINE_SPINLOCK(routelock);
10
11 static void re_free(struct route_entry *rep)
12 {
13     WRITE_ONCE(rep->re_freed, 1);
14     free(rep);
15 }
16
17 unsigned long route_lookup(unsigned long addr)
18 {
19     int old;
20     int new;
21     struct route_entry *rep;
22     struct route_entry **repp;
23     unsigned long ret;
24
25     retry:
26     repp = &route_list.re_next;
27     rep = NULL;
28     do {
29         if (rep && atomic_dec_and_test(&rep->re_refcnt))
30             re_free(rep);
31         rep = READ_ONCE(*repp);
32         if (rep == NULL)
33             return ULONG_MAX;
34         do {
35             if (READ_ONCE(rep->re_freed))
36                 abort();
37             old = atomic_read(&rep->re_refcnt);
38             if (old <= 0)
39                 goto retry;
40             new = old + 1;
41         } while (atomic_cmpxchg(&rep->re_refcnt,
42                                old, new) != old);
43         repp = &rep->re_next;
44     } while (rep->addr != addr);
45     ret = rep->iface;
46     if (atomic_dec_and_test(&rep->re_refcnt))
47         re_free(rep);
48     return ret;
49 }

```

9.2 Reference Counting

I am never letting you go!

Unknown

레퍼런스 카운팅은 특정 오브젝트가 아직 사용중인데 메모리 해제되는 것을 막기 위해 오브젝트로의 레퍼런스의 갯수를 추적합니다. 이 방법은 1960년대 초로 거슬러 올라갈만큼 매우 긴 역사를 가지고 있습니다 [Wei63].² 따라서 레퍼런스 카운팅은 동시적인 Pre-

² Weizenbaum 은 레퍼런스 카운팅을 이미 잘 알려진 것처럼 이야기 했는데, 따라서 레퍼런스 카운팅의 역사는 1950년대, 심지어는

Listing 9.3: Reference-Counted Pre-BSD Routing Table Add/Delete (BUGGY!!!)

```

1 int route_add(unsigned long addr, unsigned long interface)
2 {
3     struct route_entry *rep;
4
5     rep = malloc(sizeof(*rep));
6     if (!rep)
7         return -ENOMEM;
8     atomic_set(&rep->re_refcnt, 1);
9     rep->addr = addr;
10    rep->iface = interface;
11    spin_lock(&routelock);
12    rep->re_next = route_list.re_next;
13    rep->re_freed = 0;
14    route_list.re_next = rep;
15    spin_unlock(&routelock);
16    return 0;
17 }
18
19 int route_del(unsigned long addr)
20 {
21     struct route_entry *rep;
22     struct route_entry **repp;
23
24     spin_lock(&routelock);
25     repp = &route_list.re_next;
26     for (;;) {
27         rep = *repp;
28         if (rep == NULL)
29             break;
30         if (rep->addr == addr) {
31             *repp = rep->re_next;
32             spin_unlock(&routelock);
33             if (atomic_dec_and_test(&rep->re_refcnt))
34                 re_free(rep);
35             return 0;
36         }
37         repp = &rep->re_next;
38     }
39     spin_unlock(&routelock);
40     return -ENOENT;
41 }

```

BSD 라우팅 구현의 훌륭한 후보입니다.

그런 생각 아래, Listing 9.2 는 데이터 구조들과 `route_lookup()` 함수를 보이고 있고, Listing 9.3 는 `route_add()` 와 `route_del()` 함수들을 보이고 있습니다 (모두 `route_refcnt.c` 안에 있습니다). 이 알고리즘들은 Listing 9.1 에 보인 순차적 알고리즘과 상당히 비슷하므로, 차이점들만을 이야기 하겠습니다.

Listing 9.2 부터 시작해 보면, line 2 는 실제 레퍼런스 카운터를 추가했고, line 6 에서는 해제 후 사용을 체크하는 필드인 `->re_freed` 를 추가하며, line 9 에서는 동시의 업데이트들을 동기화 시키는데 사용될 `routelock` 을 추가하며, line 11-15 는 `re_free()` 를 추가하는데, 이 함수는 `->re_freed` 의 값을 넣어서 `route_lookup()`

1940년대까지도 거슬러 올라갈 수 있을 겁니다. 그리고 심지어 더 거슬러 올라갈 수도 있겠죠. 커다란 기계를 고치고 관리하는 사람들은 각 일꾼들이 자물쇠를 갖는, 기계적 레퍼런스 카운팅 테크닉을 사용해 왔습니다. 이 기계에 들어가기 전에, 각 일꾼은 이 기계의 on/off 스위치에 자물쇠를 채워서 이 일꾼이 기계 안에 있는 동안 기계가 켜지지 못하게 했습니다.




Figure 9.2: Pre-BSD Routing Table Protected by Reference Counting

이 해제 후 사용 버그를 체크할 수 있게 합니다. `route_lookup()` 내에서, line 29-31 은 앞의 원소의 레퍼런스 카운트 값을 감소시키고 그 카운트가 0이 되었다면 해제시키며, line 35-43 은 새로운 원소로의 레퍼런스를 얻어오는데, line 36 과 37 은 해제 후 사용 체크를 수행합니다.

Quick Quiz 9.1: 해제 후 사용 체크를 왜 신경쓰죠? ■
Listing 9.3 에서, line 12, 16, 25, 33, 그리고 40 은 동시의 업데이트 작업들을 동기화 시키기 위한 락킹을 보이고 있습니다. Line 14 는 해제 후 사용 체크 필드인 `->re_freed` 를 초기화 하고, 만약 레퍼런스 카운트의 새 값이 0이라면 line 34-35 에서 마침내 `re_free()` 를 호출합니다.

Quick Quiz 9.2: Listing 9.3 의 `route_del()` 은 해제될 원소를 찾는 과정을 보호하기 위해 레퍼런스 카운트를 사용하지 않는 이유가 뭐죠? ■

Figure 9.2 는 싱글 소켓, 4 코어, 하이퍼쓰레드 가능한 2.5GHz x86 시스템에서 돌아가는 10개 원소 리스트에서의 read-only 워크로드가 레퍼런스 카운팅을 사용했을 때의 성능과 확장성을 보이고 있습니다. “ideal” 은 Listing 9.1 에서 보인, 이게 읽기만 하는 워크로드여서 동작할 수 있는 순차적 코드를 돌리는 것으로 만들어졌습니다. “refcnt” 선이 x 축에 붙어버리는 모습으로 볼 수 있듯 레퍼런스 카운팅 성능은 저참하고 그 확장성은 그보다도 더합니다. Chapter 3 를 생각하면 이는 놀라운 일은 아닙니다: 레퍼런스 카운트 획득과 해제는 read-only 워크로드에서도 빈번한 공유 메모리로의 쓰기를 추가했고, 따라서 물리 법칙의 상당한 보복을 이끌어냈습니다. 이 세상의 바람직한 생각은 최신 디지털 전자 기술에서 빛의 속도를 늘리거나 원자의 크기를 줄이는 것이 아님을 생각할 때 당연한 일입니다.

Quick Quiz 9.3: Figure 9.2 에서 “ideal” 선은 왜 똑바

로 증가하지 않고 계단 형태로 증가하죠? ■

Quick Quiz 9.4: 요즘과 같은 시대에, Figure 9.2 는 왜 겨우 여덟개의 CPU 까지만 사용하는 거죠??? ■
이게 끝이 아닙니다.

반복적으로 `route_add()` 와 `route_del()` 을 호출하는 여러개의 업데이트 쓰레드들을 수행시키게 되면 Listing 9.2 의 line 37 의 해제 후 사용 버그를 알리는 `abort()` 문이 곧 수행될 겁니다. 이는 곧 레퍼런스 카운터가 확장성과 성능을 심각하게 저하시킬 뿐만 아니라, 필요한 보호를 제대로 제공하는데에도 실패함을 의미합니다.

Figure 9.1 에 보인 리스트에서 해제 후 사용 버그를 이끌어내는 이벤트 시퀀스 중 하나는 아래와 같습니다.

1. Thread A 가 address 42 를 탐색해서 Listing 9.2 `route_lookup()` 의 line 33 에 도달합니다. 달리 말해, Thread A 는 첫번째 원소로의 포인터를 갖고 있지만, 아직 이 원소로의 레퍼런스를 획득하진 못한 상태입니다.
2. Thread B 가 address 42 의 route 원소를 지우려고 Listing 9.3 의 `route_del()` 을 호출합니다. 이 호출이 성공적으로 완료되어, 이 원소의 `->re_refcnt` 필드는 그 값이 1이므로, `->re_freed` 필드를 설정하고 원소를 해제하기 위해 `re_free()` 를 호출합니다.
3. Thread A 는 `route_lookup()` 의 수행을 계속합니다. `rep` 로의 포인터는 NULL 이 아니지만, line 36 은 자신의 `->re_freed` 필드가 0이 아님을 보게 되어서 line 37 에서 `abort()` 를 호출하게 됩니다.

문제는 이 레퍼런스 카운트가 보호되어야 할 오브젝트 안에 위치해 있다는 것인데, 이는 레퍼런스 카운트 자체가 획득되는 시점에서는 어떤 보호도 없음을 의미합니다! 이는 Gamsa 등 [GKAS99] 에 의해 이야기되었던 락킹에서의 문제의 레퍼런스 카운팅에서의 비슷한 경우입니다. Route 원소별로 레퍼런스 카운트 획득을 보호하기 위한 글로벌 락이나 레퍼런스 카운트를 생각해 볼 수도 있겠지만, 이는 상당한 경쟁 문제를 초래할 수 있습니다. 동시성 있는 환경에서 안전한 레퍼런스 카운트 획득을 위한 알고리ズム들이 존재하긴 합니다만 [Val95], 그들은 굉장히 복잡할 뿐더러 에러를 만들기가 쉽고 [MS95] 처참한 수준의 성능과 확장성만을 제공합니다 [HMBW07].

한마디로, 동시성은 레퍼런스 카운팅의 유용성을 분명히 저하시켰습니다!

Quick Quiz 9.5: 동시성이 “레퍼런스 카운팅의 유용성을 분명히 저하시켰다”면, 리눅스 커널은 왜 그렇게 레퍼런스 카운터를 많이 사용하는거죠? ■

Listing 9.4: Hazard-Pointer Storage and Erasure

```

1 int hp_store(void **p, void **hp)
2 {
3     void *tmp;
4
5     tmp = READ_ONCE(*p);
6     WRITE_ONCE(*hp, tmp);
7     smp_mb();
8     if (tmp != READ_ONCE(*p) || tmp == HAZPTR_POISON) {
9         WRITE_ONCE(*hp, NULL);
10        return 0;
11    }
12    return 1;
13 }
14
15 void hp_erase(void **hp)
16 {
17     smp_mb();
18     WRITE_ONCE(*hp, NULL);
19     hp_free(hp);
20 }

```

그렇다곤 하지만, 가끔은 문제를 성공적으로 해결하기 위해선 문제를 완전히 다른 방법으로 바라볼 필요가 있습니다. 다음 섹션에서는 상당한 성능과 확장성을 제공하는, 안에서 바깥으로의 레퍼런스 카운트에서 생각해 볼수 있는 것들을 논해 봅니다.

9.3 Hazard Pointers

If in doubt, turn it inside out.

Zara Carpenter

동시적으로 수행되는 레퍼런스 카운팅에서의 문제를 해결하는 한가지 방법은 레퍼런스 카운터들을 뒤집어서 구현하는 것으로, 데이터 원소에 저장되어 있는 정수를 증가시키는 게 아니라, CPU 별(또는 쓰레드 별) 리스트에 그 데이터 원소로의 포인터를 저장해 두는 것입니다. 이런 리스트의 각 원소들은 해저드 포인터 [Mic04] 라고 불립니다.³ 주어진 데이터 원소의 “가상 레퍼런스 카운터”의 값은 그 원소를 레퍼런스 하고 있는 해저드 포인터들의 갯수를 세는 것으로 얻어질 수 있습니다. 따라서, 그 원소가 읽기기를 하는 쓰레드들에 의해 접근할 수 없게 된다면, 그리고 더이상 그 원소를 레퍼런스 하고 있는 해저드 포인터가 더이상 존재하지 않는다면, 그 원소는 안전하게 메모리 해제될 수 있습니다.

물론, 이 말은 해저드 포인터 획득은 동시의 삭제들에 의한 버그(파열의 경주-destructive race- 라고도 합니다)를 막기 위해 매우 조심스럽게 행해져야만 함을 의미합니다. 그런 한가지 구현이 Listing 9.4 에 보여져 있는데, line 1-14 에서 `hp_store()` 를 보이고 line 16-21 에서 `hp_erase()` 를 보이고 있습니다. `smp_mb()` 기능은

³ 그와 독립적으로 다른 사람들에 의해 개발된 것도 있습니다 [HLM02].

Chapter 15에서 자세히 설명될 겁니다만, 이 간단한 개략적 설명의 목표를 위해서는 무시되어도 될 겁니다.

`hp_store()` 함수는 동시에 수정을 체크하면서 `p`에 의해 레퍼런스되는 포인터가 있는 데이터 원소를 위한 해저드 포인터를 `hp`에 저장합니다. 동시에 수정이 이뤄졌다면, `hp_store()`는 해저드 포인터를 저장하는 것을 거부하고 0을 리턴함으로써 호출자는 처음부터 데이터 접근을 다시 시작해야 함을 알립니다. 그렇지 않다면, `hp_store()`는 해당 데이터 원소를 위한 해저드 포인터를 성공적으로 기록했음을 알리기 위해 1을 리턴합니다.

Quick Quiz 9.6: Figure 9.4의 `hp_store()`는 왜 데이터 원소로의 접근을 두번이나 간접적으로 하는거죠? 왜 `void *`가 아니라 `void **`인 건가요? ■

Quick Quiz 9.7: `hp_store()`의 호출자는 실패했을 때 왜 데이터 접근을 처음부터 다시 시작해야 하는거죠? 데이터 구조체가 매우 크다면 좀 비효율적이지 않나요? ■

Quick Quiz 9.8: 해저드 포인터들에 대한 논문들은 각각의 포인터의 아래 비트들을 지워진 원소들을 마크하기 위해 사용한다고 하는데, HAZPTR_POISON은 뭔가요? ■

해저드 포인터들을 사용하는 알고리즘들은 데이터 구조체를 탐색하는 중 어떤 단계에서든 재시작할 수 있으므로, 그런 알고리즘들은 모든 필요한 해저드 포인터들을 얻어오는 작업이 끝나기 전까지는 이 데이터 구조체에 어떤 변경도 가하지 않도록 특별한 주의를 반드시 기울여야만 합니다.

Quick Quiz 9.9: 하지만 해저드 포인터에 있는 이런 제약사항들은 다른 형태의 레퍼런스 카운팅에도 똑같이 적용되는 거 아닌가요? ■

이런 제약사항은 읽기를 하는 쓰레드들에는 커다란 이득이 되는데, 해저드 포인터는 각 CPU/쓰레드에 지역적으로 저장되기 때문으로, 이에 의해 데이터 구조체를 탐색하는 작업은 완전히 읽기만 하면서 행해질 수 있다는 사실 덕입니다. page 66의 Figure 5.8를 다시 인용하자면, 해저드 포인터는 CPU 캐시들이 리소스 복사를 할 수 있게 해서 병렬 액세스 컨트롤 메커니즘을 완화시키는 걸 가능하게 하고, 따라서 성능과 확장성을 높여줍니다. 다른 메커니즘들과의 성능 비교는 Chapter 10와 다른 출간물들 [HMBW07, McK13, Mic04]에서 얻을 수 있을 겁니다.

해저드 포인터는 레퍼런스 카운터보다 훨씬 더 확장성 있습니다만 여전히 읽기를 하는 쓰레드들이 공유 메모리에 쓰기를 하게 합니다. 다음 섹션의 주제인 시퀀스 카운터들은 읽기 쪽의 쓰기를 완전히 막습니다.

Pre-BSD 라우팅 예제는 해저드 포인터를 사용할 수 있는데, Figure 9.5에서 그런 데이터 구조들과 `route_lookup()`을 보이고 있고, Figure 9.6에서 `route_`

Listing 9.5: Hazard-Pointer Pre-BSD Routing Table Lookup

```

1 struct route_entry {
2     struct hazptr_head hh;
3     struct route_entry *re_next;
4     unsigned long addr;
5     unsigned long iface;
6     int re_freed;
7 };
8 struct route_entry route_list;
9 DEFINE_SPINLOCK(routelock);
10 hazard_pointer __thread *my_hazptr;
11
12 unsigned long route_lookup(unsigned long addr)
13 {
14     int offset = 0;
15     struct route_entry *rep;
16     struct route_entry **repp;
17
18     retry:
19     repp = &route_list.re_next;
20     do {
21         rep = READ_ONCE(*repp);
22         if (rep == NULL)
23             return ULONG_MAX;
24         if (rep == (struct route_entry *)HAZPTR_POISON)
25             goto retry;
26         my_hazptr_offset.p = &rep->hh;
27         offset = !offset;
28         smp_mb();
29         if (READ_ONCE(*repp) != rep)
30             goto retry;
31         repp = &rep->re_next;
32     } while (rep->addr != addr);
33     if (READ_ONCE(rep->re_freed))
34         abort();
35     return rep->iface;
36 }
```

`add()`와 `route_del()`을 보이고 있습니다 (`route_hazptr.c`). 레퍼런스 카운팅에서와 마찬가지로, 해저드 포인터 구현은 page 120의 Figure 9.1에서 보인 순차적 알고리즘과 상당히 유사하므로 차이점만 이야기하겠습니다.

Figure 9.5부터 보면, line 2에서는 해저드 포인터가 해제되길 지연시키는 오브젝트들을 넣어두기 위한 `->hh` 필드를 보이며, line 6는 해제 후 사용 버그를 발견하기 위한 `->re_freed` 필드를 보이며 line 24-30에서는 해저드 포인터를 획득하려 시도하고, 실패하면 line 18의 `retry` 라벨로 브랜치하게 됩니다.

Figure 9.6에서, line 11에서는 `->re_freed`를 초기화시키고, line 32와 33에서는 새로 제거된 오브젝트의 `->re_next`를 파괴하고, line 35는 그 오브젝트를 해당 해저드 포인터들의 `hazptr_free_later()` 함수에 넘기는데, 이 함수는 해당 오브젝트가 해제되도 안전할 때 해제시킬 겁니다. 스피너들은 Figure 9.3에서와 동일하게 동작합니다.

Figure 9.3는 해저드 포인터로 보호되는 Pre-BSD 라우팅 알고리즘의 Figure 9.2에서와 동일한 `read-only` 워크로드에서의 성능을 보입니다. 해저드 포인터가 레퍼런스 카운팅에 비해 훨씬 잘 확장되긴 하지만, 해저드

Listing 9.6: Hazard-Pointer Pre-BSD Routing Table Add/Delete

```

1 int route_add(unsigned long addr, unsigned long interface)
2 {
3     struct route_entry *rep;
4
5     rep = malloc(sizeof(*rep));
6     if (!rep)
7         return -ENOMEM;
8     rep->addr = addr;
9     rep->iface = interface;
10    rep->re_freed = 0;
11    spin_lock(&routelock);
12    rep->re_next = route_list.re_next;
13    route_list.re_next = rep;
14    spin_unlock(&routelock);
15    return 0;
16 }
17
18 int route_del(unsigned long addr)
19 {
20     struct route_entry *rep;
21     struct route_entry **repp;
22
23     spin_lock(&routelock);
24     repp = &route_list.re_next;
25     for (;;) {
26         rep = *repp;
27         if (rep == NULL)
28             break;
29         if (rep->addr == addr) {
30             *repp = rep->re_next;
31             rep->re_next = (struct route_entry *)HAZPTR_POISON;
32             spin_unlock(&routelock);
33             hazptr_free_later(&rep->hh);
34             return 0;
35         }
36         repp = &rep->re_next;
37     }
38     spin_unlock(&routelock);
39     return -ENOENT;
40 }

```

포인터는 여전히 읽기 쓰레드가 공유 메모리에 쓰기를 할 것을 필요로 하며 (대신 훨씬 개선된 레퍼런스의 로컬리티를 제공합니다), 각 오브젝트 방문마다 메모리 배리어와 재시도 여부 검사를 필요로 합니다. 그로 인해 해저드 포인터의 성능은 이상적인 것에 비하면 훨씬 떨어집니다. 반면에, 해저드 포인터는 동시에 업데이트가 존재할 때에도 올바르게 동작합니다.



Quick Quiz 9.10: 논문 “Structured Deferral: Synchronization via Procrastination” [McK13] 은 해저드 포인터가 이상적인 경우에 가까운 성능을 보인다는 걸 보였습니다. Figure 9.3 에선 무슨 일이 일어난거죠???

다음 섹션은 해저드 포인터에서 더 개선을 하기 위해서 read-side에서의 쓰기도 오브젝트별 메모리 배리어도 없애주는 시퀀스 락을 사용해 보겠습니다.

9.4 Sequence Locks

It'll be just like starting over.

John Lennon

**Figure 9.3:** Pre-BSD Routing Table Protected by Hazard Pointers**Figure 9.4:** Reader And Uncooperative Sequence Lock

시퀀스 락은 주로 읽기가 이루어지는, 그리고 읽기를 하는 쓰레드들에게 일관적인 상태로 보여야 하는 데이터를 위해 리눅스 커널에서 사용됩니다. 하지만, reader-writer 락킹과 달리, 읽기를 하는 쓰레드들은 쓰기를 하는 쓰레드들을 배타시키지 않습니다. 대신에, 시퀀스 락들은 해저드 포인터처럼 읽기를 하는 쓰레드들이 동시에 수행중인 쓰기를 하는 쓰레드들로부터의 동작이 험지되면 오퍼레이션을 재시도 하도록 강제합니다. Figure 9.4 에 보여지는 것처럼, 읽기를 하는 쓰레드들이 재시도를 하는 경우는 매우 드문 경우일 수 있도록 시퀀스 락을 사용해 코드를 설계하는 것이 중요합니다.

Quick Quiz 9.11: 왜 이 시퀀스 락에 대한 토론은 Chapter 7 에서, locking 의 하나로써 다루어지지 않았던 거죠??

시퀀스 락킹에서의 핵심 컴포넌트는 시퀀스 넘버로,

이 수는 업데이트를 하는 쓰레드가 존재하지 않는다면 짹수를 가지고 진행 중인 업데이트가 있다면 홀수를 갖습니다. 읽기를 하는 쓰레드들은 각각의 액세스 전과 후로 이 값을 스냅샷 뜰 수 있습니다. 만약 두 스냅샷 중 하나라도 홀수이거나, 두 스냅샷이 서로 다르다면, 동시에 업데이트가 있었다는 것이고, 따라서 읽기를 한 쓰레드는 해당 액세스의 결과를 버리고 다시 읽기를 시도해야 합니다. 시퀀스 락으로 보호되는 데이터에 대해 읽기를 하기 위해서는 `read_seqbegin()` 과 `read_seqretry()` 함수들이 Listing 9.7 와 같이 사용되어야 합니다. 쓰기를 하는 쓰레드들은 각 업데이트 전과 후에 그 값을 증가시켜야 하는데, 한번에 하나의 읽기 쓰레드의 수행만이 허가되어 있습니다. 쓰기를 하는 쓰레드들은 시퀀스 락으로 보호되는 데이터를 업데이트 하기 위해서는 `write_seqlock()` 과 `write_sequnlock()` 함수를 Listing 9.8 에 보여진 것처럼 사용합니다.

따라서 시퀀스 락으로 보호되는 데이터는 상당히 많은 수의 동시에 수행되는 읽기를 하는 쓰레드들을 가질 수 있습니다만, 쓰기를 하는 쓰레드는 한번에 하나씩만 가능합니다. 시퀀스 락킹은 시간 계측에 사용되는 값의 측정을 보호하기 위해 사용됩니다. 시퀀스 락킹은 또한 동시적인 이름 바꾸기 오퍼레이션들을 파악해내기 위한 경로명 탐색에도 사용됩니다.

시퀀스 락의 간단한 구현이 Listing 9.9 (`seqlock.h`)에 있습니다. Line 1-4 에 `seqlock_t` 데이터 구조체가 있는데, 쓰기를 하는 쓰레드들을 직렬화 시키기 위한 락과 시퀀스 넘버를 가지고 있습니다. Line 6-10 에서는 `seqlock_init()` 를 보이는데, 이 함수는 이름이 의미 하듯이 `seqlock_t` 의 초기화를 합니다.

Line 12-19 는 `read_seqbegin()` 함수로, 시퀀스 락의 read-side 크리티컬 섹션을 시작합니다. Line 16 에서 시퀀스 카운터의 스냅샷을 하나 만들고, line 17 에서 이 스냅샷이 만들어진 순서가 호출자의 크리티컬 섹션보다 앞이 되도록 순서를 세웁니다. 마지막으로, line 18 에서 스냅샷의 값을 (least-significant bit 를 비운 상태로) 리턴하는데, 이 값은 호출자가 뒤의 `read_seqretry()` 호출에 넘겨줄 값입니다.

Quick Quiz 9.12: Listing 9.9 의 `read_seqbegin()`은 왜 내부적으로 가장 낮은 자리의 비트를 검사하고 재

Listing 9.7: Sequence-Locking Reader

```
1 do {
2     seq = read_seqbegin(&test_seqlock);
3     /* read-side access. */
4 } while (read_seqretry(&test_seqlock, seq));
```

Listing 9.8: Sequence-Locking Writer

```
1 write_seqlock(&test_seqlock);
2 /* Update */
3 write_sequnlock(&test_seqlock);
```

Listing 9.9: Sequence-Locking Implementation

```
1 typedef struct {
2     unsigned long seq;
3     spinlock_t lock;
4 } seqlock_t;
5
6 static inline void seqlock_init(seqlock_t *slp)
7 {
8     slp->seq = 0;
9     spin_lock_init(&slp->lock);
10 }
11
12 static inline unsigned long read_seqbegin(seqlock_t *slp)
13 {
14     unsigned long s;
15
16     s = READ_ONCE(slp->seq);
17     smp_mb();
18     return s & ~0x1UL;
19 }
20
21 static inline int read_seqretry(seqlock_t *slp,
22                                 unsigned long oldseq)
23 {
24     unsigned long s;
25
26     smp_mb();
27     s = READ_ONCE(slp->seq);
28     return s != oldseq;
29 }
30
31 static inline void write_seqlock(seqlock_t *slp)
32 {
33     spin_lock(&slp->lock);
34     ++slp->seq;
35     smp_mb();
36 }
37
38 static inline void write_sequnlock(seqlock_t *slp)
39 {
40     smp_mb();
41     ++slp->seq;
42     spin_unlock(&slp->lock);
43 }
```

시도를 하지 않고 어차피 망할 읽기를 시작하는 건가요? ■

Line 21-29 는 `read_seqretry()` 함수인데, 이 함수는 연관된 `read_seqbegin()` 의 실행 아래로부터 쓰기를 하는 쓰레드가 존재하지 않았다면 true 를 리턴합니다. Line 26 에서는 호출자의 앞의 크리티컬 섹션을 line 27 에서의 시퀀스 카운터의 새로운 스냅샷을 얻어오는 작업 이전에 완료되도록 순서를 맞춥니다. 마지막으로, line 28 에서는 시퀀스 카운터가 변하지 않았음을 검사하는데, 달리 말하자면 그동안 쓰기가 행해지지 않았음을 확인하고, 그렇다면 true 를 리턴합니다.

Quick Quiz 9.13: Listing 9.9 의 line 26 에서의 `smp_mb()` 는 왜 필요한 건가요? ■

Quick Quiz 9.14: Listing 9.9 의 코드는 완화된 형태의 메모리 배리어를 사용할 수는 없을까요? ■

Quick Quiz 9.15: 시퀀스 락킹을 사용하는 경우, 업데이트 쓰레드들이 읽기 쓰레드들이 진행 못하게 하는 걸 막는 건 무엇일까요? ■

Listing 9.10: Sequence-Locked Pre-BSD Routing Table Lookup (BUGGY!!!)

```

1 struct route_entry {
2     struct route_entry *re_next;
3     unsigned long addr;
4     unsigned long iface;
5     int re_freed;
6 };
7 struct route_entry route_list;
8 DEFINE_SEQ_LOCK(sl);
9
10 unsigned long route_lookup(unsigned long addr)
11 {
12     struct route_entry *rep;
13     struct route_entry **repp;
14     unsigned long ret;
15     unsigned long s;
16
17     retry:
18     s = read_seqbegin(&sl);
19     repp = &route_list.re_next;
20     do {
21         rep = READ_ONCE(*repp);
22         if (rep == NULL) {
23             if (read_seqretry(&sl, s))
24                 goto retry;
25             return ULONG_MAX;
26         }
27         repp = &rep->re_next;
28     } while (rep->addr != addr);
29     if (READ_ONCE(rep->re_freed))
30         abort();
31     ret = rep->iface;
32     if (read_seqretry(&sl, s))
33         goto retry;
34     return ret;
35 }

```

Line 31-36 는 `write_seqlock()` 함수로, 단순히 락을 획득하고, 시퀀스 넘버를 증가시키고, 이 값 증가 연산이 호출자의 크리티컬 섹션 전으로 순서맞춰짐을 분명히 하도록 메모리 배리어를 실행합니다. Line 38-43은 `write_sequnlock()` 함수를 보여주는데, 이 함수는 호출자의 크리티컬 섹션이 line 44에서의 시퀀스 넘버 값 증가 전으로 순서맞춰지는 것을 분명히 하도록 메모리 배리어를 실행하고 락을 해제합니다.

Quick Quiz 9.16: 다른 뭔가가 쓰기 쓰레드들을 직렬화 시켜서 락이 필요치 않다면 어떻게 되죠? ■

Quick Quiz 9.17: Listing 9.9의 line 2의 `seq`는 왜 `unsigned`가 아니라 `unsigned long`인가요? 무엇보다, `unsigned`가 리눅스 커널에서 충분히 좋은 것이라면 모두에게도 충분히 좋지 않을까요? ■

시퀀스 락킹이 Pre-BSD 라우팅 테이블에 적용되면 어떻게 될까요? Listing 9.10은 데이터 구조들과 `route_lookup()`을 보이고, Listing 9.11은 `route_add()`와 `route_del()`을 보이고 있습니다(`route_seqlock.c`). 이 구현은 역시 앞 섹션의 같은 것들과 비슷하므로 차이점들만을 이야기 하겠습니다.

Listing 9.10에서, line 5에는 `->re_freed`가 있는데, line 29와 30에서 체크됩니다. Line 8에는 시퀀스 락이

Listing 9.11: Sequence-Locked Pre-BSD Routing Table Add/Delete (BUGGY!!!)

```

1 int route_add(unsigned long addr, unsigned long interface)
2 {
3     struct route_entry *rep;
4
5     rep = malloc(sizeof(*rep));
6     if (!rep)
7         return -ENOMEM;
8     rep->addr = addr;
9     rep->iface = interface;
10    rep->re_freed = 0;
11    write_seqlock(&sl);
12    rep->re_next = route_list.re_next;
13    route_list.re_next = rep;
14    write_sequnlock(&sl);
15    return 0;
16 }
17
18 int route_del(unsigned long addr)
19 {
20     struct route_entry *rep;
21     struct route_entry **repp;
22
23     write_seqlock(&sl);
24     repp = &route_list.re_next;
25     for (;;) {
26         rep = *repp;
27         if (rep == NULL)
28             break;
29         if (rep->addr == addr) {
30             *repp = rep->re_next;
31             write_sequnlock(&sl);
32             smp_mb();
33             rep->re_freed = 1;
34             free(rep);
35             return 0;
36         }
37         repp = &rep->re_next;
38     }
39     write_sequnlock(&sl);
40     return -ENOENT;
41 }

```

있는데, `route_lookup()`에 의해 line 18, 23, 32에서 사용되며 line 24와 33은 line 17의 `retry` 라벨로 수행을 되돌립니다. 이로 인해 업데이트와 동시에 수행되는 탐색은 재시도를 하게 됩니다.

Listing 9.11에서, line 12, 15, 24, 그리고 40은 시퀀스 락을 잡고 풀고 있는데, line 11과 34는 `->re_freed`를 처리합니다. 따라서 이 구현은 상당히 간단합니다.

Figure 9.5에서 볼 수 있듯이, 이 구현은 또한 read-only 워크로드에서 상당히 좋은 성능을 보입니다. 이상적인 성능에 비하면 여전히 멀었지만요.

안타깝지만, 이 구현 역시 해제 후 사용 문제를 가지고 있습니다. 문제는 읽기 쓰레드가 `read_seqretry()`를 하기 전에 이미 해제된 구조체에 접근할 수 있기 때문에 segmentation violation을 낼 수 있다는 점입니다.

Quick Quiz 9.18: 이 버그는 고쳐질 수 있을까요? 달리 말해서, 동시의 삽입, 삭제, 탐색을 지원하는 링크드리스트를 보호하는 동기화 메커니즘으로 시퀀스락 하나만 사용할 수 있을까요? ■




Figure 9.5: Pre-BSD Routing Table Protected by Sequence Locking

시퀀스 락의 read-side 크리티컬 섹션도, write-side 크리티컬 섹션도 트랜잭션으로 생각될 수 있고, 따라서 시퀀스 락킹은 제한적인 형태의 트랜잭션 네트워크로 생각될 수 있겠는데, 트랜잭션 네트워크에 대해서는 Section 17.2에서 이야기 하겠습니다. 시퀀스 락킹의 제약점들은: (1) 시퀀스 락킹은 업데이트를 제약하고 (2) 시퀀스 락킹은 업데이트 쓰레드에 의해 해제되었을 수 있는 오브젝트로의 포인터의 획단을 허용하지 않습니다. 이런 제약점들은 물론 트랜잭션 네트워크를 사용해 극복될 수 있습니다만, 다른 동기화 도구들을 시퀀스 락킹과 함께 사용해서도 극복될 수 있습니다.

시퀀스 락들은 쓰기를 하는 쓰레드들이 읽기를 하는 쓰레드들을 뒤로 미뤄지도록 할 수 있지만, 그 반대는 불가능합니다. 이는 공정하지 않고 쓰기가 대부분인 워크로드에서는 스타베이션 상황을 만들 수도 있습니다. 반면, 쓰기 쓰레드가 없다면, 시퀀스 락을 사용하는 읽기 쓰레드들은 합리적인 수준으로 빠르고 선형적으로 확장이 가능할 것입니다. 두 가지 모두 최선인 경우를 원하는 게 사람입니다: 읽는 쪽의 실패나 스타베이션의 가능성 없는 빠른 읽기. 또한, 포인터들에 대한 제약점들 역시 극복된다면 좋을 겁니다. 다음 섹션은 이런 속성을 가진 동기화 메커니즘을 소개합니다.

9.5 Read-Copy Update (RCU)

Nothing is faster than doing nothing!

Unknown

앞의 섹션들에서 다루어진 모든 메커니즘들은 특정 동작을 그것이 안전하게 행해질 수 있을 때까지 유예하는 여러개의 방법들 가운데 하나를 사용했습니다. Sec-

tion 9.2에서 다른 레퍼런스 카운터는 읽기 쓰레드들을 방해할 수 있는 행위들을 유예하기 위해 명시적 카운터를 사용하는데, 이는 읽기 쪽의 혼잡과 그로 말미암은 낮은 확장성을 유발합니다. Section 9.3에서 다루어진 해저드 포인터는 per-thread 포인터 리스트 안의 무시적 카운터를 사용합니다. 이는 읽기 쪽의 혼잡을 줄입니다만, 읽기 쪽 기능에 전체 메모리 배리어를 필요로 합니다. Section 9.4에서 보인 시퀀스 락 또한 읽기 쪽의 혼잡을 막습니다만, 포인터 traversal을 보호해주지는 않고, 해저드 포인터처럼 읽기 쪽 기능에 전체 메모리 배리어를 필요로 합니다. 이런 단점은 더 좋은 방법은 없는지에 대한 질문을 이끌어냅니다.

이 섹션은 딜레이가 공유된 데이터에의 비싼 업데이트보다는 소스코드에 의해 인식되도록 하는 API를 제공하는 *read-copy update* (RCU)를 소개합니다. 이 섹션의 나머지 부분들에서는 여러개의 다른 관점에서 RCU를 알아봅니다. Section 9.5.1에서는 RCU에 대한 고전적인 소개를 제공하고, Section 9.5.2에서는 기본적인 RCU 컨셉을 다루며, Section 9.5.3에서는 RCU의 일부 공통적인 사용 예를 소개하고, Section 9.5.4에서는 리눅스 커널 API를 보이고, Section 9.5.5에서는 RCU에 관련된 최근의 것들을 이야기하고, 마지막으로 Section 9.5.6에서 일부 RCU 연습을 제공합니다.

9.5.1 Introduction to RCU

앞의 섹션들에서 이야기된 방법들은 어느정도 확장성 있긴 했지만 모두 Pre-BSD 라우팅 테이블을 위한 성능에 있어서 이상적이지 못했습니다. Pre-BSD 탐색 오버헤드가 싱글 쓰레드 탐색에서와 동일하게끔, 병렬로 수행되는 탐색이 싱글 쓰레드에서의 탐색과 동일한 어셈블리어 인스트럭션 시퀀스를 수행한다면 좋을 겁니다. 이는 좋은 목표가 될 수 있지만, 그러기 위해서는 구현 단계에서 많은 심각한 질문을 이끌어냅니다. 하지만 이걸 시도하면 어떤 일이 벌어질지 알아보고 삽입과 삭제를 구분해서 다뤄봅시다.

아이템 추가를 위한 고전적인 방법이 Figure 9.6에 표현되어 있습니다. 첫번째 열은 기본 상태를 보입니다. `gptr`은 `NULL` 값을 갖습니다. 두번째 열에서는 하나의 구조체를 메모리 할당하는데, 초기화되지 않은 부분들은 물음표로 표시되어 있습니다. 세번째 열에서는 이 구조체를 초기화 시킵니다. 다음으로, `gptr`이 이 새로운 원소를 가리키도록 그 값을 할당합니다.⁴ 최근의 범용 시스템에서 이 값 할당은 어토믹해서 동시에 수행되는, 읽기를 하는 쓰레드들은 `NULL` 포인터 또는 새로운 구조체 `p`로의 포인터 둘 중 하나만을 보게 되지,

⁴ 많은 컴퓨터 시스템들에서, 컴파일러와 CPU가 간섭을 끼칠 수 있기 때문에 단순한 값 할당은 충분하지 못합니다. 이런 문제에 대해서는 Section 9.5.2에서 다루게 될 겁니다.




Figure 9.6: Insertion With Concurrent Readers

두 값 중 일부가 합쳐져 있는 값은 보지 못합니다. 따라서, 각각의 읽기를 하는 쓰레드는 기본값인 NULL을 보거나 기본값이 아닌 값을 보게 되거나일 것이며 어느 쪽이든 읽기는 일관적인 결과만을 보게 됨이 보장됩니다. 이뿐만이 아니라, 읽기를 수행하는 쓰레드는 다른 비싼 동기화 기능을 사용할 필요가 없어서, 이 방법은 리얼타임 쪽의 사용에 꽤 적합할 겁니다.⁵

하지만 동시에 읽기 쓰레드에 의해 레퍼런스 되고 있는 데이터는 언젠가는 없어져야 할 겁니다. Figure 9.7 와 같이 링크드 리스트에서 원소를 삭제하는, 더 복잡한 예제를 봅시다. 이 리스트는 초기에 원소 A, B, 그리고 C를 가지고 있으며, 여기서 원소 B를 삭제해야 합니다. 먼저 `list_del()`을 사용해 삭제를 진행하는데,⁶ 모든 새로운 읽기 쓰레드들은 원소 B를 리스트에서 삭제된 것으로 보게 될 겁니다. 하지만, 이 원소를 여전히 보

⁵ 다시 말하지만, 많은 컴퓨터 시스템들에서 컴파일러와 DEC Alpha 시스템에서라면 CPU가 간섭을 행하는 것을 막기 위한 추가 작업이 필요합니다. 이에 대해서는 Section 9.5.2에서 이야기합니다.

⁶ 역시 앞서 말했듯 이는 추상화된 예이고, Section 9.5.2에서 이에 관련해서 더 이야기 합니다.




Figure 9.7: Deletion From Linked List With Concurrent Readers

고 있는 오래된 읽기 쓰레드들도 있을 수 있습니다. 이 오래된 읽기 쓰레드들이 종료되고 나면, 원소 B를 안전히 메모리 해제시켜서 그림의 아래쪽에 그려진 상태를 만들 수 있을 겁니다.

하지만, 그 종료 시점을 어떻게 알까요?

레퍼런스 카운팅 방법의 경우는, Chapter 5의 Figure ?? 가 락킹과 시퀀스 락킹처럼 긴 딜레이를 가져올 수 있음을 보이므로 어렵습니다.

읽기 쓰레드들이 그 존재를 알리기 위한 일을 전혀 안하는, 극단적인 상황을 생각해 봅시다. 이는 읽기 쓰레드들에 최적의 성능을 가능하게 하겠지만 (아무것도 안해도 되니까요), 업데이트 쓰레드는 어떻게 모든 예전 읽기 쓰레드들의 종료를 알지에 대한 질문이 남습니다. 여기에 합리적 답을 하기 위해서는 추가적인 제약이 분명 필요합니다.

일부 운영체제 커널에 적합한 제약은 쓰레드가 CPU를 빼앗기지 않는 상황 (non-preemptible)을 고려하는 겁니다. CPU를 빼앗길 수 없는 환경에서 쓰레드는 명시적이고 자발적으로 블락킹 되기 전까지는 수행을 계속합니다. 즉, 블락킹 없이 반복되는 무한루프는 CPU를 무한루프 이외의 목적으로는 사용될 수 없게 하다는

의미입니다.⁷ CPU를 빼길 수 없다는 특성은 또한 쓰레들이 스핀락을 잡고 있는 동안은 블락킹 되지 않아야 할 것을 필요로 합니다. 이런 금지사항이 없다면, 블락된 쓰레드에 의해 잡혀 있는 스핀락을 회득하려 시도하며 루프를 도는 쓰레드들에 의해 모든 CPU가 소모되게 될 수도 있습니다. 루프를 도는 쓰레드는 락을 잡기 전까지는 자신의 CPU를 놓지 않을 텐데, 락을 잡고 있는 쓰레드는 이 루프를 돌고 있는 쓰레드들이 CPU를 놓기 전까지는 그 락을 놓을 수가 없습니다. 이는 고전적인 deadlock 상황입니다.

이와 똑같은 제약사항을 링크드 리스트를 횡단하며 읽기를 하는 쓰레드들에도 가해봅시다: 그런 쓰레드들은 리스트 횡단이 완료되기 전까지는 블락되는 것이 허용되지 않습니다. 업데이트 쓰레드가 `list_del()`을 실행 완료한 직후인 Figure 9.7의 두 번째 줄로 돌아가서, CPU 0이 컨텍스트 스위칭을 한다고 생각해 봅시다. 읽기 쓰레드들은 링크드 리스트 횡단 중에 블락되는 것은 허용되지 않으므로, CPU 0에서 수행되던 모든 시간상 앞의 읽기 쓰레드들은 완료되었음이 보장됩니다. 이 이야기를 다른 CPU들에도 적용해 보자면, 각 CPU가 일단 컨텍스트 스위칭이 수행됨을 확인했다면, 모든 시간상 앞의 읽기 쓰레드들은 완료되었고, 더 이상 원소 B를 레퍼런스하고 있는 읽기 쓰레드는 더 이상 없을 것이 보장된다고 볼 수 있습니다. 그렇다면 업데이트 쓰레드는 안전하게 원소 B를 메모리 해제해서 Figure 9.7의 가장 아래의 상태를 만들어낼 수 있습니다.

이런 방법은 *quiescent state based reclamation* (QSBR) [HMB06]이라 명명되어 있습니다. QSBR 방법이 Figure 9.8에 그림의 꼭대기부터 바닥까지로 시간의 흐름에 따라 그려져 있습니다.

이런 방법의 제품 수준 구현은 매우 복잡할 수 있지만, 장단감 수준 구현은 상당히 간단합니다:

```
1 for_each_online_cpu(cpu)
2   run_on(cpu);
```

이 `for_each_online_cpu()` 함수는 모든 CPU들에 루프를 돌고, `run_on()` 함수는 현재 쓰레드가 특정 CPU에서 수행되게 해서 목적지 CPU가 컨텍스트 스위칭을 수행하게 만듭니다. 따라서, 일단 한번 `for_each_online_cpu()`가 완료되면, 각 CPU는 컨텍스트 스위치를 수행한 것이고, 따라서 모든 시간상 앞의 읽기 쓰레드들은 완료되었음이 보장됩니다.

이 방법은 제품 수준의 품질이 아님을 알아 두시기 바랍니다. 일반적이지 않은 경우에서의 정확성 처리와 강력한 최적화 여력을 필요로 하는 제품 수준 품질의




Figure 9.8: RCU QSBR: Waiting for Pre-Existing Readers

구현의 성질은 상당한 추가적 복잡도를 의미합니다. 또한, CPU 강탈이 가능한 환경에서의 RCU 구현은 읽기 쓰레드들이 실제로 뭔가를 할 것을 필요로 합니다. 하지만, 이 간단한 CPU 강탈이 불가한 상황의 접근법은 개념적으로는 완벽하고, 다음 섹션에서 다루어질 RCU의 기본을 이해하기 위한 좋은 초기 토대가 될 겁니다.

9.5.2 RCU Fundamentals

Read-copy update (RCU)는 2002년 10월에 리눅스 커널에 추가된, 하나의 동기화 메커니즘이다. RCU는 읽기 작업들이 업데이트 작업들과 동시에 일어날 수 있도록 함으로써 확장성 개선을 달성합니다. 기존에 일반적으로 사용되어온, 동시에 수행되는 쓰레드들에 대해 그것들이 읽기를 하는지 업데이트를 하는지와 상관없이 상호 배제를 보장하는 락킹 기능들 또는 동시에 읽기 작업은 허용하지만 업데이트가 함께 수행되는 것은 막는 reader-writer 락들과는 대조적으로 RCU는 하나의 업데이트 쓰레드와 여러 읽기 쓰레드들 사이의 동시성을 지원합니다. RCU는 객체의 여러 버전을 유지하고 그것들이 이전부터 존재해온 읽기쪽 크리티컬 섹션들이 모두 완료되기 전까지는 메모리에서 해제하지 않음으로써 읽기 작업의 일관성을 보장합니다. RCU는 객체를 읽고, 새 버전을 내놓고, 더 이상 필요 없는 오래된 버전의 객체들의 정리 작업을 뒤로 미루어 한번에 처리하는데에 효과적이고 확장성 있는 메커니즘을 정의하고 사용합니다. 이런 메커니즘들은 작업을 읽기와 업데이트쪽 수행경로로 해저드 포인터와 유사하지만

⁷ 반면, CPU를 빼앗길 수 있는 환경에서의 무한루프는 여전히 CPU 시간을 낭비하고 있긴 하지만, 이 CPU는 다른 일을 할 수 있을 겁니다.

Listing 9.12: Data Structure Publication (Unsafe)

```

1 struct foo {
2     int a;
3     int b;
4     int c;
5 };
6 struct foo *gp = NULL;
7
8 /* . . . */
9
10 p = kmalloc(sizeof(*p), GFP_KERNEL);
11 p->a = 1;
12 p->b = 2;
13 p->c = 3;
14 gp = p;

```

읽기 쪽의 재시도를 하지 않는 복제와 규칙 완화를 통한 최적화를 사용해 읽기 쪽 수행경로가 극단적으로 빠르게 만듭니다. 일부 경우에는 (CPU를 뺏기지 않는 커널들), RCU의 읽기 쪽 기능들의 오버헤드가 아예 존재하지 않습니다.

Quick Quiz 9.19: 하지만 Section 9.4의 시퀀스 락 역시 읽기 쓰레드들과 업데이트 쓰레드들이 동시에 일을 할 수 있도록 하지 않던가요? ■

이는 “RCU는 정확히 무엇인가?” 그리고 아마도 “RCU는 어떻게 동작할 수 있는가?”라는 질문을 이끌어낼 수 있을 겁니다 (또는, 드물지 않게, RCU는 동작할 수 없을 것이라는 단정을). 이 문서는 이런 질문들을 기본적 관점에서부터 다룹니다; 뒤의 일부는 RCU를 사용법과 API 관점에서 살펴봅니다. 마지막 부분은 또한 참고할 문서 목록을 포함합니다.

RCU는 세개의 기본적 메커니즘으로 만들어지는데, 첫번째는 항목 삽입에 사용되고, 두번째 것은 항목 삭제에, 그리고 세번째 것은 읽기 쓰레드가 동시에 항목 추가/삭제에 문제 없이 동작하도록 하는데 사용됩니다. Section 9.5.2.1은 항목 추가를 위한 publish-subscribe 메커니즘을 설명하고, Section 9.5.2.2에서는 먼저 시작된 RCU 읽기 쓰레드들을 어떻게 기다려서 항목 삭제가 가능하게 하는지 설명하며, Section 9.5.2.3에서는 최근에 업데이트된 오브젝트들의 여러 버전들을 어떻게 관리해서 동시에 항목 추가/삭제를 가능하게 하는지 설명합니다. 마지막으로, Section 9.5.2.4에서는 RCU 기본사항을 요약합니다.

9.5.2.1 Publish-Subscribe Mechanism

RCU의 핵심 요소 중 하나는 데이터가 동시에 수정되고 있는데도 불구하고 안전하게 그 데이터를 읽을 수 있는 능력입니다. 동시에 항목 삽입에 이런 능력을 제공하기 위해, RCU는 공개-구독 (publish-subscribe) 메커니즘이라 생각될 수 있는 방법을 사용합니다. 예를 들어, 초기에 NULL인 전역 포인터 gp가 새로 할당되고 초기화된 데이터 구조체로의 포인터로 수정되려 한다

고 생각해 봅시다. Figure 9.12에 보이는 코드 조각 (추가로 적절한 락킹을 포함해서)이 이 목적으로 사용될 수 있을 것입니다.

안타깝게도, 컴파일러와 CPU가 마지막 네개의 할당문을 순서대로 수행하도록 강제하는 것이 전혀 없습니다. gp로의 할당이 p 필드들의 초기화 전에 일어난다면, 동시 수행중인 읽기 작업들은 이 초기화되지 않은 값을 볼 수 있을 겁니다. 이것들이 순서를 지키도록 하기 위해 메모리 배리어들이 필요합니다만, 메모리 배리어들은 사용하기가 어렵기로 악명 높습니다. 그래서 우리는 메모리 배리어들을 공개 의미를 갖는 `rcu_assign_pointer()` 기능에 집어넣었습니다. 따라서 마지막 네 줄은 다음과 같이 될겁니다:

```

1 p->a = 1;
2 p->b = 2;
3 p->c = 3;
4 rcu_assign_pointer(gp, p);

```

이 `rcu_assign_pointer()`는 새 구조체를 공개하고, 컴파일러와 CPU가 p로 참조되는 필드들의 할당 후에 gp로의 할당을 수행하도록 강제할 겁니다.

하지만, 업데이트 작업에 순서를 맞추는 것만으로는 충분치 않은데, 읽기 작업도 적절하게 순서가 맞춰져야 하기 때문입니다. 다음과 같은 코드 조각의 예를 생각해 봅시다:

```

1 p = gp;
2 if (p != NULL) {
3     do_something_with(p->a, p->b, p->c);
4 }

```

이 코드 조각은 잘못된 순서에 문제가 없을 것처럼 보이지만, 안타깝게도 DEC Alpha CPU [McK05a, McK05b]와 같은 예측하는 컴파일러 최적화는, 모든 안믿든, p->a, p->b, 그리고 p->c가 p의 값을 읽기 전에 메모리로부터 가져와질 수 있게 할 수 있습니다. 이런 현상은 컴파일러가 p의 값을 추측하고 p->a, p->b, 그리고 p->c 값을 가져온 후에 그 추측이 맞았는지 보기 위해 p의 실제 값을 가져오는, 컴파일러의 값 추측 최적화의 경우에서 보기 가장 쉬울 겁니다. 이런 종류의 최적화는 상당히 공격적이고 미친 행위 같지만, 프로파일 기반의 최적화의 문맥에서는 실제로 일어나는 일입니다.

분명히, 우리는 컴파일러와 CPU로부터 이런 종류의 야바위질을 막아야 합니다. `rcu_dereference()` 기능은 이런 목적을 위해 필요한 어떤 메모리 배리어 인스트럭션과 컴파일러 지시어들을 사용합니다:⁸

⁸ 리눅스 커널에서, `rcu_dereference()`는 volatile 캐싱으로 구현되고, DEC Alpha에서는 메모리 배리어 인스트럭션으로 구현됩니다. C11과 C++11 표준에서는 `memory_order_consume`이 `rcu`




Figure 9.9: Linux Circular Linked List



Figure 9.10: Linux Linked List Abbreviated

```

1 rCU_read_lock();
2 p = rCU_dereference(gp);
3 if (p != NULL) {
4     do_something_with(p->a, p->b, p->c);
5 }
6 rCU_read_unlock();

```

따라서 `rcu_dereference()` 함수는 특정 포인터로 주어지는 값에 대한 구독이고, 뒤따르는 `dereference` 오퍼레이션들은 해당 포인터를 공개한, 연관된 `rcu_assign_pointer()` 오퍼레이션 전에 발생한 초기화 작업의 결과들을 보게 될 것이 보장된다고 이해될 수 있습니다. `rcu_read_lock()` 과 `rcu_read_unlock()` 함수 호출은 반드시 필요합니다: 이것들은 RCU read-side 크리티컬 섹션을 정의합니다. 이것들의 목적은 Section 9.5.2.2에서 설명됩니다만, 이것들은 결코 스파닝하거나 블락킹 하지 않고, `list_add_rcu()` 가 동시에 수행되는 것을 막지도 않습니다. 사실, `CONFIG_PREEMPT` 옵션이 켜져있지 않은 커널에서 이것들은 아무 코드도 생성하지 않습니다.

이론상으로는 `rcu_assign_pointer()` 와 `rcu_dereference()` 를 사용해 RCU 로 보호되며, 상상할 수 있는 데이터 구조는 얼마든지 만들 수 있지만, 실제로는 고차원의 방법을 사용하는게 나은 경우가 많이 있습니다. 그런 이유로, `rcu_assign_pointer()` 와 `rcu_dereference()` 함수들이 리눅스에 있는 리스트 조정 API 의 특별한 RCU 사용 버전에 내장되어 있습니다. 리눅스는 이중 링크드 리스트의 두가지 버전을 가지고 있는데, 순환 형태의 `struct list_head` 와 선형의 `struct hlist_head/struct hlist_node` 쌍입니다. 앞의 버전은 Figure 9.9 에 그려져 있는데, (왼쪽의) 초록 상자는 리스트 헤더를 나타내고 (오른쪽의 세개의) 파란 박스들은 리스트의 원소들을 의미합니다. 이 방법

`dereference()` 를 위한 장기적 지원을 제공하기 위한 의도로 만들어졌습니다만, 이를 native로 구현한 컴파일러는 아직 없습니다. (컴파일러들은 대신 `memory_order_consume` 을 `memory_order_acquire` 로 강화시켜서, 약한 순서 규칙의 시스템에서는 필요없는 메모리 배리어 인스트럭션을 만들니다.)

Listing 9.13: RCU Data Structure Publication

```

1 struct foo {
2     struct list_head *list;
3     int a;
4     int b;
5     int c;
6 };
7 LIST_HEAD(head);
8
9 /* . . . */
10
11 p = kmalloc(sizeof(*p), GFP_KERNEL);
12 p->a = 1;
13 p->b = 2;
14 p->c = 3;
15 list_add_rcu(&p->list, &head);

```




Figure 9.11: Linux Linear Linked List

은 다루기가 힘들기 때문에 Figure 9.10 에 보인 것처럼 헤더 없이(파란) 원소들만을 보이는 형태로 간략화해서 나타낼 수 있습니다.

이 링크드 리스트에 포인터 공개 예제의 기법을 적용하는 것은 Figure 9.13 에 보여진 코드와 같은 형태로 귀결될 겁니다.

Line 15 는 여러개의 `list_add_rcu()` 가 동시에 수행되는 것을 막기 위해 어떤 다른 동기화 메커니즘(가장 흔하게는 어떤 종류의 락)을 사용해야만 합니다. 하지만, 그런 동기화는 이 `list_add()` 의 수행을 RCU 읽기 작업들과 동시에 수행되는 것을 못하게 하지는 않습니다.

RCU 로 보호되는 리스트를 구독하는 행위는 간단합니다:

```

1 rCU_read_lock();
2 list_for_each_entry_rcu(p, head, list) {
3     do_something_with(p->a, p->b, p->c);
4 }
5 rCU_read_unlock();

```

앞의 `list_add_rcu()` 함수는 원소를 공개하고, 특정 리스트의 헤드에 집어넣고, 이에 연관된 `list_for_each_entry_rcu()` 호출이 정상적으로 같은 원소를 구독하게 될것을 보장합니다.

Quick Quiz 9.20: `list_add_rcu()` 와 정확히 똑같은 시간에 `list_for_each_entry_rcu()` 이 수행되면 segfault 가 날 수 있을 것 같은데, 이걸 무엇이 방지해 주나요? ■

리눅스의 다른 이중 링크드 리스트인 `hlist` 는 선형 리스트인데, 이는 헤더로의 포인터만이 필요하지 Fig-

Listing 9.14: RCU hlist Publication

```

1 struct foo {
2     struct hlist_node *list;
3     int a;
4     int b;
5     int c;
6 };
7 HLIST_HEAD(head);
8
9 /* . . . */
10
11 p = kmalloc(sizeof(*p), GFP_KERNEL);
12 p->a = 1;
13 p->b = 2;
14 p->c = 3;
15 hlist_add_head_rcu(&p->list, &head);

```

Figure 9.11에 보여진 순환 형태의 리스트처럼 두개의 포인터가 필요하진 않습니다. 따라서, hlist의 사용은 해시 버킷 배열들이나 커다란 해시 테이블에서는 메모리 사용량을 반으로 줄일 수 있습니다. 앞에서와 같이 이 형태는 다루기가 까다로우므로, hlist들은 Figure 9.10에 보인 것과 같은 형태로 간략화 될 겁니다.

새로운 원소를 RCU로 보호되는 hlist에 공개하는 건 Figure 9.14에 보여진 것처럼, 순환형 리스트에서 했던 것과 상당히 유사합니다.

앞에서와 같이, line 15는 예를 들면 락과 같은, 어떤 종류의 동기화 메커니즘으로 보호되어야만 합니다.

RCU로 보호되는 hlist를 구독하는 행위 역시 순환형 리스트에서와 비슷합니다:

```

1 rCU_read_lock();
2 hlist_for_each_entry_rcu(p, head, list) {
3     do_something_with(p->a, p->b, p->c);
4 }
5 rCU_read_unlock();

```

RCU 공개와 구독 기능들의 집합이 Table 9.1에 “구독취소 (Retract)” 또는 철회를 위한 추가적인 기능들과 함께 표시 되어 있습니다.

`list_replace_rcu()`, `list_del_rcu()`, `hlist_replace_rcu()`, and `hlist_del_rcu()` API들이 복잡도를 더함을 알아두세요. 교체되거나 삭제된 데이터 원소를 메모리에서 해제하는데 안전한 시점은 언제일까요? 구체적으로, 모든 읽기 작업들이 특정 데이터 원소로의 레퍼런스들을 해제한 시점을 어떻게 하면 알 수 있을까요?

이 질문들은 다음의 섹션에서 다루어집니다.

9.5.2.2 Wait For Pre-Existing RCU Readers to Complete

가장 기본적인 형태에서, RCU는 일들이 끝나기를 기다리는 방법입니다. 물론, RCU 외에도 일들이 끝나길




Figure 9.12: Readers and RCU Grace Period

기다리는 훌륭한 방법들이 여럿 있는데, 레퍼런스 카운팅, reader-writer lock, 이벤트 등등이 포함됩니다. RCU의 커다란 장점은 (대략) 20,000 개의 서로 다른 일들을 명시적으로 그 모든 것들을 각각 정보를 쫓아가지 않으면서 성능 하락, 확장성 제한, 복잡한 테드릭 시나리오, 그리고 명시적으로 정보를 쫓는 방법에서는 필연적인 메모리 누수 문제를 걱정할 필요 없이 기다릴 수 있다는 겁니다.

RCU의 경우에, 기다려지고 있는 일들은 “RCU read-side 크리티컬 섹션”이라 불립니다. 하나의 RCU read-side 크리티컬 섹션은 `rcu_read_lock()` 함수로 시작되고, 그에 연관되는 `rcu_read_unlock()` 함수로 종료됩니다. RCU read-side 크리티컬 섹션들은 중첩될 수 있고, 어떤 코드든 그 코드가 명시적으로 블락하거나 잠들지 않는 한 (SRCU [McK06b] 라고 불리는 특별한 형태의 RCU가 SRCU read-side 크리티컬 섹션 내에서의 일반적인 잠들기를 가능하게 하긴 하지만), 그 안에 얼마든지 들어갈 수 있습니다. 이런 규칙에 동의한다면, 코드의 모든 원하는 부분이 완료되기를 기다리는데에 RCU를 사용할 수 있습니다.

RCU는 언제 이 일들이 종료되었는지를 간접적으로 판단해내는 것으로 이 기능을 구현합니다 [McK07h, McK07a].

보다 자세히 말하자면, Figure 9.12에 보여진 것처럼, RCU는 전부터 존재했던 RCU read-side 크리티컬 섹션들이 그 크리티컬 섹션들에서 수행되는 메모리 오퍼레이션 등이 완전히 끝나기를 기다리는 한가지 방법입니다. 하지만, 주어진 grace period의 시작 후에 시작된 RCU read-side 크리티컬 섹션들은 그 grace period의 종료 이후까지 수행될 수도 있음을 기억해 두십시오.

다음의 슈도코드는 RCU를 이용해 읽기 작업들을 기다리는 알고리즘들의 기본적 형태를 보입니다:

- 링크드 리스트에서 한 원소를 바꿔치기하거나 하는 식으로 변경을 만듭니다.

Table 9.1: RCU Publish and Subscribe Primitives

Category	Publish	Retract	Subscribe
Pointers	<code>rcu_assign_pointer()</code>	<code>rcu_assign_pointer(..., NULL)</code>	<code>rcu_dereference()</code>
Lists	<code>list_add_rcu()</code>		
	<code>list_add_tail_rcu()</code>	<code>list_del_rcu()</code>	<code>list_for_each_entry_rcu()</code>
Hlists	<code>hlist_add_behind_rcu()</code>		
	<code>hlist_add_before_rcu()</code>	<code>hlist_del_rcu()</code>	<code>hlist_for_each_entry_rcu()</code>
	<code>hlist_add_head_rcu()</code>		
	<code>hlist_replace_rcu()</code>		

Listing 9.15: Canonical RCU Replacement Example

```

1 struct foo {
2     struct list_head *list;
3     int a;
4     int b;
5     int c;
6 };
7 LIST_HEAD(head);
8
9 /* . . . */
10
11 p = search(head, key);
12 if (p == NULL) {
13     /* Take appropriate action, unlock, & return. */
14 }
15 q = kmalloc(sizeof(*p), GFP_KERNEL);
16 *q = *p;
17 q->b = 2;
18 q->c = 3;
19 list_replace_rcu(&p->list, &q->list);
20 synchronize_rcu();
21 kfree(p);

```

- 전부터 존재했던 RCU read-side 크리티컬 섹션들이 완전히 종료되길 기다립니다 (예를 들어, `synchronize_rcu()` 기능이나 그 비동기 버전으로 다음 grace period 가 끝난 후에 특정 함수를 호출해주는 `call_rcu()`를 이용해서). 여기서의 핵심은 뒤이어지는 RCU read-side 크리티컬 섹션들은 이제는 제거된 원소로의 레퍼런스를 얻을 수 없다는 점입니다.
- 예를 들어 앞서 교체된 원소를 메모리에서 해제하는 식으로 정리를 합니다.

Figure 9.15에 보여진 코드 조각은 Section 9.5.2.1에서 가져와진 것으로, 이 프로세스를 보여주는데, 필드 a는 검색을 위한 키로 사용됩니다.

Line 19, 20, 그리고 21은 앞에서 이야기한 세 단계를 보입니다. Line 16-19이 RCU (“read-copy update”)에 그 이름을 줍니다: 동시에 *read*를 허용하면서, line 16은 *copy*를 하고 line 17-19에서 실제 *update*를 합니다.

Section 9.5.1에서 이야기된 것처럼, `synchronize_rcu()` 기능은 매우 간단할 수 있습니다 (“장난감” RCU

구현을 더 보기 위해선 Appendix B을 참고하시기 바랍니다). 더 나아가서, RCU의 간단하고 수행 가능한 정형적 모델이 Section 12.3.2에서 논의되었듯 리눅스 커널 v4.17 이후 버전의 한 부분으로 존재합니다. 하지만, 상품 수준의 구현들은 복잡하고 희귀한 경우들을 처리해야하고 강력한 최적화를 포함해야하는데, 둘 다 상당한 복잡도가 생기게 하고 맙니다. `synchronize_rcu()`의 간단한 개념적 구현이 있음을 알게 된 건 좋지만, 다른 질문들이 남습니다. 예를 들어, RCU 읽기 작업들은 동시에 업데이트 되는 리스트를 돌아다니면서 정확히 뭘 보게 되는 걸까요? 이 질문을 다음 섹션에서 다루도록 합니다.

9.5.2.3 Maintain Multiple Versions of Recently Updated Objects

이 섹션은 RCU가 동기화로부터 자유로운 읽기 작업이 가능하게 하기 위해 리스트의 여러 버전을 어떻게 관리하는지 보입니다. 특정 읽기 쓰레드에 의해 레퍼런스될 수도 있는 원소가 해당 읽기 쓰레드가 자신의 RCU read-side 크리티컬 섹션을 유지하고 있는 동안에도 손상되지 않은 채로 어떻게 유지될 수 있는지를 두개의 예제로 보일 겁니다. 첫번째 예제는 리스트 원소의 삭제를 보이고, 두번째 예제는 원소의 교체를 보이도록 하겠습니다.

Example 1: Maintaining Multiple Versions During Deletion 이제 Section 9.5.1에서의 원소 삭제 예제를 다시 들여다 보는데, 이번에는 그 아래의 RCU에 있는 기본적인 개념에 대한 확실한 이해와 함께 들여다 볼 수 있을 겁니다. 이 새로운 버전의 삭제 예제를 시작하기 위해, Listing 9.15의 line 11-21을 다음과 같이 보이게 수정할 겁니다:

```

1 p = search(head, key);
2 if (p != NULL) {
3     list_del_rcu(&p->list);
4     synchronize_rcu();
5     kfree(p);
6 }

```




Figure 9.13: RCU Deletion From Linked List

이 코드는 Figure 9.13에 보인 것처럼 리스트를 업데이트 할겁니다. 각 원소의 세개의 숫자는 필드 a, b, c의 값들을 각각 나타냅니다. 빨간색으로 칠해진 원소들은 RCU 읽기 쓰레드들이 그것들로의 레퍼런스를 가질 수 있음을 나타내는데, 따라서 다이어그램의 꼭대기에 있는 최초의 상태에서는 모든 원소들이 빨간색으로 칠해져 있습니다. 이전 원소로의 포인터들과 리스트의 tail로부터 head로의 링크는 가독성을 위해 삭제해 두었다는 점을 알아 두시기 바랍니다.

Line 3에서의 `list_del_rcu()`가 완료된 후에, 5,6,7 원소는 Figure 9.13의 두번째 줄에 보여진 것처럼 리스트에서 삭제되어 있습니다. 읽기 쓰레드는 업데이트 쓰레드와 직접적으로 동기화를 하지 않으므로, 읽기 쓰레드는 이 리스트를 동시에 스캔하고 있을 수 있습니다. 이런 동시의 읽기 쓰레드는 이번에 삭제된 원소를 탐색에 따라서는 볼수도, 보지 않을 수도 있습니다. 하지만, 이번에 삭제된 원소로의 포인터를 가져온 후에 한동안 지연된 (예: 인터럽트나 ECC 메모리 에러, 또는 CONFIG_PREEMPT_RT 커널에서라면 `preemption`으로 인해서) 읽기 쓰레드는 이 삭제로부터 상당한 시간이 흐른 후에도 이 리스트의 과거 버전을 보게 될 수도 있습니다. 따라서, 이 리스트의 두개의 버전이 존재하는 셈인데, 하나는 5,6,7 원소를 가지고 있고 또 다른 하나는 가지고 있지 않습니다. 이 그림에서 두번째 줄의 5,6,7 원소는 노란색으로 칠해져 있는데, 오래된 읽기 쓰레드는

여전히 레퍼런스를 가지고 있을 수 있지만, 새로 시작된 읽기 쓰레드는 그로의 레퍼런스를 얻을 수 없음을 의미합니다.

읽기 쓰레드들은 각자의 RCU read-side 캐리터컬 션션에서 빠져나온 후에는 element 5,6,7로의 레퍼런스를 얻을 수 없음을 기억하기 바랍니다. 따라서, 일단 line 4에서의 `synchronize_rcu()`가 완료되면, 모든 앞서 존재하던 읽기 쓰레드는 완료된 것이 보장되므로, 이 원소를 레퍼런스 하는 읽기 쓰레드는 존재할 수 없어지는데 Figure 9.13의 세번째 줄에 녹색으로 색칠함으로써 이 상황을 나타내었습니다.

이 시점에서, 5,6,7 원소는 Figure 9.13의 마지막 줄에 나타나 있듯이 안전하게 메모리 해제될 수 있습니다. 이 시점에서, 원소 5,6,7의 삭제가 완료되었습니다. 다음 섹션에서는 교체를 다룹니다.

Example 2: Maintaining Multiple Versions During Replacement 교체의 경우의 예제 설명을 위해, 여기 Listing 9.15 예제의 마지막 몇줄의 코드를 붙여넣습니다:

```

15 q = kmalloc(sizeof(*p), GFP_KERNEL);
16 *q = *p;
17 q->b = 2;
18 q->c = 3;
19 list_replace_rcu(&p->list, &q->list);
20 synchronize_rcu();
21 kfree(p);

```

리스트의 초기 상태는 p 포인터를 포함해서 삭제 예제와 동일한데, Figure 9.14의 첫번째 줄에 보여져 있습니다.

앞에서와 마찬가지로, 각 원소의 세개의 숫자는 필드 a, b, c를 각각 나타냅니다. 빨간 원소들은 읽기 쓰레드에 의해 레퍼런스 될 수도 있고, 읽기 쓰레드들은 업데이트 쓰레드와 직접 동기화를 하지 않기 때문에 읽기 쓰레드는 이 교체 과정 전체와 동시에 수행될 수 있습니다. 이번에도 뒤쪽으로의 포인터들과 리스트의 tail에서 head로의 링크는 가독성을 위해 제거되었음을 참고 바랍니다.

아래의 글은 5,6,7 원소를 5,2,3으로 모든 읽기 쓰레드가 이 두 값들 중 하나만 보도록 하면서 어떻게 교체해야 하는지 설명합니다.

Line 1은 교체할 원소를 `kmalloc()` 해서 Figure 9.14의 두번째 줄에 보여진 것과 같은 상태가 만들어지게 합니다. 이 시점에서는, 어떤 읽기 쓰레드도 이 새로 만들어진 원소로의 레퍼런스를 가질 수 없고(녹색 색깔로 이를 나타냅니다), 이 원소는 아직 초기화되지 않았습니다(물음표로 나타내어집니다).

Line 2에서는 예전 원소의 값을 새 원소로 복사해서 Figure 9.14의 세번째 줄에 보여진 상태를 만듭니다.




Figure 9.14: RCU Replacement in Linked List

이 새로 만들어진 원소는 여전히 읽기 쓰레드들에 의해 레퍼런스될 수는 없지만, 이제 초기화는 되었습니다.

Line 3는 Figure 9.14의 네번째 줄에 보여진 것처럼 $q \rightarrow b$ 를 값 “2”로, 그리고 line 4는 $q \rightarrow c$ 를 값 “3”으로 바꿉니다.

이제, line 5는 교체를 행해서 새 원소가 읽혀질 수 있게 만드는데, 따라서 Figure 9.14의 다섯번째 줄에 빨간색으로 칠해져 있습니다. 이 시점에서는 앞에서와 같이, 두가지 버전의 리스트가 존재합니다. 전부터 있던 읽기 쓰레드들은 5,6,7 원소를 볼 수 있지만(따라서 노란색으로 칠해져 있습니다), 새 읽기 쓰레드들은 그대신 5,2,3 원소를 볼겁니다. 하지만 어떤 읽기 쓰레드들이든 대체로 형태를 갖춘 리스트만을 볼 것이 보장됩니다.

Line 6의 `synchronize_rcu()`가 리턴한 후에는, grace period는 지나갔고, 따라서 `list_replace_rcu()` 전에 시작된 모든 읽기는 완료된 상태입니다. 특히, 5,6,7 원소로의 레퍼런스를 가지고 있는 모든 읽기 쓰레드들은 각자의 RCU read-side 크리티컬 섹션들을 빠져나왔음이 보장되고, 따라서 레퍼런스를 계속해서 잡고 있을 수 없습니다. 따라서, 과거의 원소로의 레퍼런스를 여전히 잡고 있는 읽기 쓰레드는 더이상 있을 수 없는데, 이 상황이 Figure 9.14의 여섯번째 줄에 초록색으로 나타내어져 있습니다. 읽기 쓰레드들의 관점에서 우리는 리스트의 단일 버전만이 존재하는 상태로 돌아왔습니다만, 예전 원소는 새 원소로 바뀌어 있습니다.

Line 7에서의 `kfree()` 후에 이 리스트는 Figure 9.14의 마지막 줄에 보여진 것처럼 됩니다.

RCU는 교체의 경우에 대해서 이름지어졌다는 사실에도 불구하고, 리눅스 커널 안에서의 RCU 사용 예의 대다수는 Section 9.5.2.3.의 간단한 삭제의 케이스에 기반해 있습니다.

Discussion 이 예제들은 모든 업데이트 오퍼레이션이 뮤텍스를 잡고 있다고 가정을 하고 있는데, 이 말은 리스트의 버전은 한 순간에 최대 두개까지만 존재할 수 있음을 의미합니다.

Quick Quiz 9.21: 리스트의 버전이 두개보다 많을 수 있도록 하기 위해서는 삭제 예제를 어떻게 수정해야 할까요? ■

Quick Quiz 9.22: 하나의 리스트는 한 순간에 RCU 버전들을 몇개까지 가질 수 있을까요? ■

이 일련의 이벤트들은 RCU 업데이트가 어떻게 여러 버전들을 사용해 동시에 수행중인 읽기 작업들에도 불구하고 안전하게 변경을 처리하는지 보입니다. 물론, 일부 알고리즘들은 여러 버전들을 잘 처리하지 못합니다. 그런 알고리즘을 RCU에 적용하는 테크닉 [McK04]들이 있지만, 이것들은 이 섹션의 범위를 넘어섭니다.

Table 9.2: RCU Usage

Mechanism RCU Replaces	Section
Reader-writer locking	Section 9.5.3.2
Restricted reference-counting mechanism	Section 9.5.3.3
Bulk reference-counting mechanism	Section 9.5.3.4
Poor man's garbage collector	Section 9.5.3.5
Existence Guarantees	Section 9.5.3.6
Type-Safe Memory	Section 9.5.3.7
Wait for things to finish	Section 9.5.3.8

9.5.2.4 Summary of RCU Fundamentals

이 섹션에서는 RCU 기반 알고리즘의 세 가지 기본 컴포넌트를 설명했습니다:

1. 새로운 데이터의 추가를 위한 공개-구독 메커니즘,
2. 전부터 존재했던 RCU 읽기 쓰레드들이 종료되기 를 기다리는 방법, 그리고
3. 동시에 수행중인 RCU 읽기 쓰레드들에 피해를 주거나 너무 오래 기다리게 하지 않고 변화를 가할 수 있도록 여러 버전을 관리하는 방법.

Quick Quiz 9.23: `rcu_read_lock()` 과 `rcu_read_unlock()` 함수는 스판하지도 블락하지도 않는데 어떻게 RCU 업데이트 쓰레드들이 RCU 읽기 쓰레드들을 대기시킬 수가 있나요? ■

이 세 개의 RCU 컴포넌트는 동시에 수행되는 읽기 쓰레드에 상관 없이 데이터가 업데이트 되도록 하고, 놀랄도록 다양한 다른 종류의 RCU 기반의 알고리즘들을 구현하는 다른 방법들로 조합될 수 있는데, 그 중 일부는 다음 섹션에서 설명하겠습니다.

9.5.3 RCU Usage

이 섹션은 “RCU 는 무엇인가?”라는 질문에 대해 RCU 가 사용될 수 있는 경우에 대한 관점에서 답변해 보겠습니다. RCU는 존재하는 메커니즘 중 일부를 대체하는데 용도로 가장 자주 사용되기 때문에, Table 9.2에 보여진 것처럼 그런 메커니즘들과의 관계에 대한 점을 중심적으로 알아보겠습니다. 이 테이블에 나열된 섹션들을 뒤이어서, Section 9.5.3.9에서는 요약을 제공합니다.

9.5.3.1 RCU for Pre-BSD Routing

Listing 9.16 와 9.17 는 RCU로 보호되는 Pre-BSD 라우팅 테이블을 위한 코드를 보이고 있습니다 (`route_rcu.c`). 앞의 것은 데이터 구조들과 `route_lookup()`

Listing 9.16: RCU Pre-BSD Routing Table Lookup

```

1 struct route_entry {
2     struct rcu_head rh;
3     struct cds_list_head re_next;
4     unsigned long addr;
5     unsigned long iface;
6     int re_freed;
7 };
8 CDS_LIST_HEAD(route_list);
9 DEFINE_SPINLOCK(routelock);
10
11 unsigned long route_lookup(unsigned long addr)
12 {
13     struct route_entry *rep;
14     unsigned long ret;
15
16     rcu_read_lock();
17     cds_list_for_each_entry_rcu(rep, &route_list, re_next) {
18         if (rep->addr == addr) {
19             ret = rep->iface;
20             if (READ_ONCE(rep->re_freed))
21                 abort();
22             rcu_read_unlock();
23             return ret;
24         }
25     }
26     rcu_read_unlock();
27     return ULONG_MAX;
28 }
```

Listing 9.17: RCU Pre-BSD Routing Table Add/Delete

```

1 int route_add(unsigned long addr, unsigned long interface)
2 {
3     struct route_entry *rep;
4
5     rep = malloc(sizeof(*rep));
6     if (!rep)
7         return -ENOMEM;
8     rep->addr = addr;
9     rep->iface = interface;
10    rep->re_freed = 0;
11    spin_lock(&routelock);
12    cds_list_add_rcu(&rep->re_next, &route_list);
13    spin_unlock(&routelock);
14    return 0;
15 }
16
17 static void route_cb(struct rcu_head *rhp)
18 {
19     struct route_entry *rep;
20
21     rep = container_of(rhp, struct route_entry, rh);
22     WRITE_ONCE(rep->re_freed, 1);
23     free(rep);
24 }
25
26 int route_del(unsigned long addr)
27 {
28     struct route_entry *rep;
29
30     spin_lock(&routelock);
31     cds_list_for_each_entry(rep, &route_list, re_next) {
32         if (rep->addr == addr) {
33             cds_list_del_rcu(&rep->re_next);
34             spin_unlock(&routelock);
35             call_rcu(&rep->rh, route_cb);
36             return 0;
37         }
38     }
39     spin_unlock(&routelock);
40     return -ENOENT;
41 }
```




Figure 9.15: Pre-BSD Routing Table Protected by RCU




Figure 9.16: Pre-BSD Routing Table Protected by RCU QSBR

을, 뒤의 것은 `route_add()` 와 `route_del()` 을 위한 코드입니다.

Listing 9.16에서, line 2는 RCU reclamation에 사용되는 `->rh` 필드를 보이고, line 6는 해제 후 사용 검사를 위한 `->re_freed` 필드를 보이며, line 16, 17, 23, 그리고 27은 RCU read-side 보호 코드를 보이고, line 21과 22에서 해제 후 사용 여부 검사를 합니다. Listing 9.17에서, line 12, 14, 31, 36, 그리고 41에서 update-side 락킹을 하며, line 13과 35에서 RCU update-side 보호를 하고, line 37에서 grace period 가 하나 지나간 후에 `route_cb()` 를 호출되게 하고, line 18-25에서 `route_cb()` 를 정의합니다. 이는 똑바로 동작하는 구현을 위해 추가되는 최소한의 코드입니다.

Figure 9.15는 read-only 워크로드에서의 성능을 보입니다. RCU는 상당히 잘 확장되어서, 이상적 성능에 가까운 성능을 보입니다. 하지만, 이 데이터는 userspace RCU의 RCU_SIGNAL 사용 버전 [Des09b, MDJ13c]을 사용해서 생성된 것으로, `rcu_read_lock()` 과 `rcu_read_unlock()` 이 약간의 코드를 생성합니다. `rcu_read_lock()` 과 `rcu_read_unlock()` 에 아무 코드도 생성하지 않는 QSBR 버전의 RCU를 사용한다면 어떻게 될까요? (Section 9.5.1를 참고하고, RCU QSBR에 대한 논의를 위해선 Figure 9.8를 참고하세요.)

그에 대한 답이 RCU QSBR 결과를 RCU와 ideal 사이에 보여주는 Figure 9.16에 있습니다. RCU QSBR은 바랬던 대로 동기화를 아예 하지 않는, 이상적인 워크로드와 거의 동일한 성능과 확장성을 갖습니다.

Quick Quiz 9.24: RCU QSBR은 왜 이상적 결과와 동일한 결과를 보이지 않는 거죠? ■

Quick Quiz 9.25: RCU QSBR의 read-side 성능이 이렇게 좋은데, 왜 다른 종류의 userspace RCU를 신경써야 하죠? ■

9.5.3.2 RCU is a Reader-Writer Lock Replacement

리눅스 커널에서 가장 흔한 RCU의 사용 경우는 읽기가 대부분인 상황들에서의 reader-writer 락킹의 대체입니다. 더도 아니고 덜도 아니고, 이런 RCU의 사용은 제게는 처음부터 곧장 그래야 할 것처럼 보이진 않았는데, 실제로 저는 1990년대 초기에 범용의 RCU 구현을 만들기 전에 경량의 reader-writer 락 [HW92]⁹ 을 구현하려 했습니다. 제가 그 경량 reader-writer 락을 위해 상상했던 모든 사용 케이스들은 대신 RCU로 구현되었습니다. 사실, 그건 그 경량 reader-writer 락이 처음으로 사용되기보다 3년도 더 전의 일입니다. 이봐요, 과연 제가 절바보라고 생각했을꺼라고 생각해요?

RCU와 reader-writer 락 사이의 핵심적인 유사점은 둘 다 별별로 수행될 수 있는 read-side 크리티컬 섹션들을 가지고 있다는 점입니다. 사실, 어떤 경우에 있어서는, RCU API로 연관된 reader-writer 락 API 멤버들을 기계적으로 대체하는 것이 가능합니다. 하지만 그전에, 왜 그러려 하나요?

RCU의 장점에는 성능, 데드락에의 내성, 그리고 리얼타임 대기시간이 포함됩니다. 물론, RCU에도 한계가 있는데, 읽기 쓰레드와 업데이트 쓰레드가 동시에 수행될 수 있고, 낮은 중요도의 RCU 읽기 쓰레드들이 grace period가 지나가길 기다리고 있는 높은 중요도의 쓰레드들을 블락시킬 수 있으며, 이 grace-period 대기시간은 수 밀리세컨드를 넘길 수 있다는 점 등이 포함됩니다. 이런 장점들과 제한점들을 다음 섹션들에서 이야기하겠습니다.

⁹ 2.4 리눅스 커널의 `brlock`과 더 최신의 리눅스 커널 버전들의 `lglock`과 유사합니다




Figure 9.17: Performance Advantage of RCU Over Reader-Writer Locking




Figure 9.18: Performance Advantage of Preemptible RCU Over Reader-Writer Locking

Performance RCU 의 reader-writer 락킹에 대비한 읽기 작업 성능의 이점이 Figure 9.17 에 그려져 있습니다.

Quick Quiz 9.26: 이게 뭐죠? 3GHz 에서 클락 시간은 300 피코세컨드 가 넘는데 대체 어떻게 RCU 는 100 펜토세컨드의 오버헤드를 갖는다고 제가 믿을 수 있을 거라고 생각하세요? ■

reader-writer 락킹은 단일 CPU 위에서 RCU 보다 열배 가량 느리고 16개의 CPU 위에서는 100배가 더 느리다는 점을 알아두세요. 반면, RCU 는 상당히 잘 확장됩니다. 두 케이스 모두, 에러바들은 양쪽으로 표준편차만큼의 크기를 갖습니다.

더 적당한 그림은 CONFIG_PREEMPT 커널에서 볼 수 있을텐데, 그렇다 하더라도 Figure 9.18 에서 볼 수 있듯이 RCU 는 여전히 reader-writer 락킹을 10배에서 1000 배까지 압도하는 모습을 보입니다. 많은 수의 CPU 들에서의 reader-writer 락킹 성능의 높은 가변성을 보세요. 그림의 에러바들은 양쪽으로 표준편차만큼의 크기를 갖습니다.

물론, Figure 9.18 에 보인 reader-writer 락킹의 낮은 성능은 비현실적이게 짧은 크리티컬 섹션들로 인해 상당히 과장되었습니다. RCU 의 성능상 이점은 16-CPU 환경에서 y 축은 read-side 기능들의 오버헤드와 크리티컬 섹션의 오버헤드의 합을 나타내는 Figure 9.19 에서 보인 것처럼, 크리티컬 섹션의 오버헤드가 늘어날수록 떨 뿐입니다.

Quick Quiz 9.27: 크리티컬 섹션 오버헤드가 늘어나면 왜 rwlock 의 오버헤드와 가변성이 모두 줄어드는 거죠? ■

하지만, 이 관측은 여러 시스템 콜들이(그리고 따라서 그것들이 포함하고 있는 모든 RCU read-side 크리티컬 섹션들도) 수 마이크로세컨드 내에 완료될 수 있다는 사실에 맞춰서 좀 완화되어야만 합니다.

또한, 다음 섹션에서 이야기 되겠지만, RCU read-side 기능들은 거의 전부 데드락에 내성을 가지고 있습니다.

Deadlock Immunity RCU 가 읽기가 대부분인 워크로드에 상당한 성능 이득을 제공하긴 하지만, 사실 RCU 를 만들게 된 첫번째 목적은 read-side 의 데드락에 대한 내성을입니다. 이 내성은 RCU 의 read-side 기능들은 블락도, 스피닝도, 심지어 뒤로 돌아가기도 하지 않으며, 따라서 그것들의 수행 시간이 결정론적이라는 사실에서 기인합니다. 따라서 이것들이 데드락 사이클에 연관되는 것은 불가능합니다.

Quick Quiz 9.28: 이 데드락 내성에 어떤 예외가 있을까요, 그리고 만약 그렇다면, 어떤 일련의 이벤트들이 데드락을 이끌어 낼 수 있을까요? ■

RCU 의 read-side 데드락 내성의 흥미로운 결론은 무조건적으로 RCU 읽기 쓰레드를 RCU 업데이트 쓰레드로 업그레이드 시키는게 가능하다는 것입니다. Reader-writer 락킹을 사용해서 그런 업그레이드를 하려 하면 데드락이 날 것입니다. RCU read-to-update 업그레이드를 하는 예제 코드 조각은 다음과 같습니다:

```

1 rCU_read_lock();
2 list_for_each_entry_rcu(p, &head, list_field) {
3     do_something_with(p);
4     if (need_update(p)) {
5         spin_lock(my_lock);

```




Figure 9.19: Comparison of RCU to Reader-Writer Locking as Function of Critical-Section Duration

```

6     do_update(p);
7     spin_unlock(&my_lock);
8   }
9 }
10 rCU_read_unlock();

```

do_update() 는 락의 보호 하에 실행되었다는 점, 그리고 RCU read-side 보호 하에 실행되었다는 점에 주의하세요.

RCU의 데드락 내성의 또 다른 흥미로운 결론은 우선순위 역전 문제의 커다란 클래스에의 내성이입니다. 예를 들어, 낮은 우선순위 RCU 읽기 쓰레드들은 높은 우선순위의 RCU 업데이트 쓰레드가 update-side 락을 잡는 걸 막을 수 없습니다. 유사하게, 낮은 우선순위 RCU 업데이트 쓰레드는 높은 우선순위 RCU 읽기 쓰레드들이 RCU read-side 크리티컬 섹션에 들어가는 걸 막을 수 없습니다.

Quick Quiz 9.29: 데드락과 우선순위 역전 모두에 내성이 있다고요??? 사실이라기엔 너무 좋은 이야기 같은데요. 제가 이게 가능하다는 걸 어떻게 믿을 수 있을까요? ■

Realtime Latency RCU read-side 기능들은 스피닝도 블락도 하지 않으므로, 훌륭한 리얼타임 대기시간을 제공합니다. 추가적으로, 앞에서도 이야기했듯, 이 말은 RCU read-side 기능들과 락들에 관련된 우선순위 역전 문제에도 내성이 있음을 뜻합니다.

하지만, RCU는 좀 더 미묘한 우선순위 역전 시나리오에는 취약한데, 예를 들어, -rt 커널에서 어떤 RCU grace period 가 종료되기를 기다리느라 블락되어 있는




Figure 9.20: Response Time of RCU vs. Reader-Writer Locking

높은 우선순위의 프로세스는 낮은 우선순위의 RCU 읽기 쓰레드에 의해 블락될 수 있습니다. 이 문제는 RCU priority boosting [McK07e, GMTW08]에 의해 해결될 수 있습니다.

RCU Readers and Updaters Run Concurrently RCU 읽기 쓰레드는 스피닝도 블락도 하지 않고, 업데이트 쓰레드는 rollback이나 abort 비슷한 것을 하지 않기 때문에, RCU 읽기 쓰레드와 업데이트 쓰레드는 동시에 수행될 수 있습니다. 이는 RCU 읽기 쓰레드는 낮은 데이터에 접근할 수 있고, 비일관적인 상태를 보게 될수 있어서, reader-writer 락킹에서 RCU로의 변환이 간단하지 않을 것을 의미합니다.

하지만, 놀랍도록 많은 상황에서 비일관성과 낮은 테이터가 문제 되지 않습니다. 그런 고전적인 예는 네트워킹 라우팅 테이블입니다. 라우팅 업데이트는 시스템에 가해지는데 상당한 시간(몇초에서 심지어 몇분까지도)을 필요로 할 수 있기 때문에, 시스템은 업데이트가 도착했을 때 상당한 시간동안은 패킷들을 잘못된 방향으로 보낼 수도 있습니다. 몇 밀리세컨드동안 잘못된 방향으로 업데이트를 보내는 건 일반적으로 문제가 되지 않습니다. 더욱이, RCU 업데이트 쓰레드는 RCU 읽기 쓰레드가 끝나기를 기다리지 않고 변경을 가하기 때문에, RCU 읽기 쓰레드는 이 변경을 reader-writer 락킹의 읽기 쓰레드보다 빠르게 볼 수 있게 되는데, Figure 9.20에 이 점이 그려져 있습니다.

일단 업데이트가 도착하면, rwlock 쓰기 쓰레드는 마지막 읽기 쓰레드가 완료되기 전까지, 뒤따르는 읽기 쓰레드는 이 쓰기가 완료되기 전까지 진행될 수 없습니다. 하지만, 뒤의 읽기 쓰레드는 새로운 값은 볼것이 보장되는데, 가장 오른쪽 박스들의 녹색 색깔로 표시되어 있습니다. 반면, RCU 읽기 쓰레드와 업데이트 쓰레드

는 서로를 막지 않아, RCU 읽기 쓰레드가 업데이트된 값을 더 빨리 볼 수 있게 합니다. 물론, RCU 업데이트 쓰레드와 겹쳐 수행되기 때문에, 업데이트 전에 시작된 세개의 읽기 쓰레드를 포함해 모든 RCU 읽기 쓰레드는 업데이트된 값을 보게 될 수도 있을 겁니다. 하지만 가장 오른쪽의 녹색으로 칠해진 RCU 읽기 쓰레드들만이 업데이트된 값을 볼 것이 보장됩니다.

Reader-writer 락킹과 RCU는 그저 다른 보장을 제공합니다. Reader-writer 락킹에서는, 쓰기 쓰레드보다 시작을 늦게 한 읽기 쓰레드는 모두 새 값을 볼 것이 보장되고, 쓰기 쓰레드가 스피닝하는 중에 시작되려 시도하는 읽기 쓰레드는 rwlock의 읽기/쓰기 우선권 구현에 따라 새 값을 볼 수도 못 볼 수도 있습니다. 반면에, RCU에서는 업데이트 쓰레드가 완료된 후에 시작된 읽기 쓰레드는 모두 새 값을 볼 것이 보장되고, 업데이트가 시작된 후에 완료된 모든 읽기 쓰레드는 타이밍에 따라 새 값을 볼 수도 못 볼 수도 있습니다.

여기서의 핵심은, reader-writer 락킹이 컴퓨터 시스템에 국한해서는 실제로 일관성을 보장하지만, 이 일관성이 그 바깥 세계에서는 더 증가된 비일관성이라는 비용이 되는 상황이 존재한다는 것입니다. 달리 말해, reader-writer 락킹은 바깥 세계의 관점에서는 조용히 망가져버린 데이터의 비용으로 내부의 일관성을 얻습니다.

그러나, 시스템에 국한된 비일관성과 망가진 데이터가 허용될 수 없는 상황이 존재합니다. 다행히도, 비일관성과 망가진 데이터를 방지하는 방법들이 여럿 [McK04, ACMS03] 있고, 일부 방법은 Section 9.2에서 논의한 레퍼런스 카운팅에 기반합니다.

Low-Priority RCU Readers Can Block High-Priority Reclaimers 리얼타임 RCU [GMTW08], SRCU [McK06b], 또는 QRCU [McK07g] (Section 12.1.4를 참고하세요)에서, preemption 당한 읽기 쓰레드는 grace period가 종료되는 걸 막을 것인데, 높은 우선순위 태스크가 해당 grace period가 완료되기를 기다리느라 블락되어 있더라도 그럴 겁니다. 리얼타임 RCU는 call_rcu()를 synchronize_rcu()로 대체하거나 2008년 초인 지금 시점까지는 아직 실험적 단계인 RCU priority boosting [McK07e, GMTW08]을 사용해서 이 문제를 해결 할 수 있습니다. SRCU와 QRCU에 priority boosting을 합치는게 필요할 수도 있겠지만, 그전에 실제 세계에서의 분명한 필요성이 보여져야 합니다.

RCU Grace Periods Extend for Many Milliseconds QRCU와 Appendix B에 설명된 일부 “장난감” RCU 구현의 예외가 있지만, RCU grace period는 수 밀리세컨드 까지 늘어납니다. 사용 가능한 비동기적인 인터페이스 (call_rcu()와 call_rcu_bh())를 사용하는 방법을

포함해, 그런 긴 딜레이를 위험하지 않게 만드는 몇 가지 테크닉들이 있긴 하지만, 이 상황이 RCU가 읽기가 대부분인 상황에서만 사용되어야 한다는 규칙의 주요 이유입니다.

Comparison of Reader-Writer Locking and RCU Code 가장 적합한 경우, reader-writer 락킹에서 RCU로의 변경은 위키피디아에서 가져온 [MPA⁰⁶] Listing 9.18, 9.19, 그리고 9.20에서처럼 매우 간단합니다.

Reader-writer 락킹을 RCU로 바꾸는 더 정교한 경우들은 이 문서의 범위 밖입니다.

9.5.3.3 RCU is a Restricted Reference-Counting Mechanism

RCU read-side 크리티컬 섹션이 진행중인 동안은 grace period들이 완료될 수 없기 때문에, RCU read-side 기능들은 제한적인 레퍼런스 카운팅 메커니즘으로 사용될 수도 있습니다. 예를 들어, 다음과 같은 코드 조각을 생각해 봅시다:

```
1 rcu_read_lock(); /* acquire reference. */
2 p = rcu_dereference(head);
3 /* do something with p. */
4 rcu_read_unlock(); /* release reference. */
```

이 rcu_read_lock()은 p로의 레퍼런스를 얻어오는 것으로 볼 수 있는데, rcu_dereference()를 통한 p로의 값 할당 후 시작되는 grace period는 연관되는 rcu_read_unlock() 전까지는 끝나지 않을 것이기 때문입니다. 이 레퍼런스 카운팅 방식은 RCU read-side 크리티컬 섹션 안에서는 블락이 허용되지 않고, 다른 태스크로 RCU read-side 크리티컬 섹션을 넘겨줄 수도 없다는 점에서 제한적입니다.

그런 제한에도 불구하고, 다음의 코드는 안전하게 p를 삭제할 수 있습니다:

```
1 spin_lock(&mylock);
2 p = head;
3 rcu_assign_pointer(head, NULL);
4 spin_unlock(&mylock);
5 /* Wait for all references to be released. */
6 synchronize_rcu();
7 kfree(p);
```

head로의 할당은 뒤이은 p로의 레퍼런스 획득을 방지하고, synchronize_rcu()는 앞서 획득된 레퍼런스들이 해제되기를 기다립니다.

Quick Quiz 9.30: 근데 잠깐만요! 이건 RCU를 reader-writer 락킹 대용으로 하려 할 때 쓸법한 코드와 완전 똑같잖아요! 뭐가 새로운 거죠? ■

물론, RCU는 Section 13.2에서 논의된 것처럼, 전통적인 레퍼런스 카운팅과 함께 조합될 수도 있습니다.

Listing 9.18: Converting Reader-Writer Locking to RCU: Data

```

1 struct el {           1 struct el {
2   struct list_head lp; 2   struct list_head lp;
3   long key;           3   long key;
4   spinlock_t mutex;  4   spinlock_t mutex;
5   int data;           5   int data;
6   /* Other data fields */ 6   /* Other data fields */
7 };                   7 };
8 DEFINE_RWLOCK(listmutex); 8 DEFINE_SPINLOCK(listmutex);
9 LIST_HEAD(head); 9 LIST_HEAD(head);

```

Listing 9.19: Converting Reader-Writer Locking to RCU: Search

```

1 int search(long key, int *result) 1 int search(long key, int *result)
2 { 2 {
3   struct el *p; 3   struct el *p;
4   4
5   read_lock(&listmutex); 5   rcu_read_lock();
6   list_for_each_entry(p, &head, lp) { 6   list_for_each_entry_rcu(p, &head, lp) {
7     if (p->key == key) { 7     if (p->key == key) {
8       *result = p->data; 8       *result = p->data;
9       read_unlock(&listmutex); 9       rcu_read_unlock();
10      return 1; 10      return 1;
11    } 11    }
12  } 12  }
13  read_unlock(&listmutex); 13  rcu_read_unlock();
14  return 0; 14  return 0;
15 } 15 }

```

Listing 9.20: Converting Reader-Writer Locking to RCU: Deletion

```

1 int delete(long key) 1 int delete(long key)
2 { 2 {
3   struct el *p; 3   struct el *p;
4   4
5   write_lock(&listmutex); 5   spin_lock(&listmutex);
6   list_for_each_entry(p, &head, lp) { 6   list_for_each_entry(p, &head, lp) {
7     if (p->key == key) { 7     if (p->key == key) {
8       list_del(&p->lp); 8       list_del_rcu(&p->lp);
9       write_unlock(&listmutex); 9       spin_unlock(&listmutex);
10      synchronize_rcu(); 10      synchronize_rcu();
11      kfree(p); 11      kfree(p);
12      return 1; 12      return 1;
13    } 13    }
14  write_unlock(&listmutex); 14  spin_unlock(&listmutex);
15  return 0; 15  return 0;
16 } 16 }

```




Figure 9.21: Performance of RCU vs. Reference Counting

하지만 왜 이런 신경을 쓰는 걸까요? 다시 말하지만, 그에 대한 답 중 하나는 성능으로, 16-CPU 3GHz Intel x86 시스템에서의 데이터가 Figure 9.21에 그려져 있습니다.

Quick Quiz 9.31: 6 CPU 근처에서 refcnt 오버헤드의 증가도가 확 떨어지는건 왜그렇죠? ■

그리고, reader-writer 락킹처럼, RCU의 성능상 이들은 Figure 9.22에 16-CPU 시스템에서의 결과로 보여지듯 짧은 길이의 크리티컬 섹션들에서 가장 효과를 발합니다. 또한, reader-writer 락킹에서처럼, 많은 시스템 콜들은 (그리고 그것들을 포함하는 RCU read-side 크리티컬 섹션들은) 수 마이크로세컨드 내에 끝납니다.

하지만, RCU에 따라오는 이 제약들은 상당히 성가십니다. 예를 들어, 많은 경우에 RCU read-side 크리티컬 섹션 내에서 잠들기가 금지된다는 점은 목표 달성을 불가하게 할 수 있습니다. 다음 섹션에서는 적어도 일부 경우에는 전통적인 레퍼런스 카운팅의 복잡도를 낮추면서도 이 문제를 해결하는 방법들을 알아보겠습니다.

9.5.3.4 RCU is a Bulk Reference-Counting Mechanism

앞의 섹션에서 이야기 했듯, 전통적인 레퍼런스 카운터들은 보통 특정 데이터 구조 또는 데이터 구조체들의 특정 그룹과 연관되어 있습니다. 하지만, 다양한 데이터 구조체에 하나의 글로벌 레퍼런스 카운터를 사용하는 것은 이 레퍼런스 카운트를 담고 있는 캐시 라인의 바운싱 (cache line bouncing)을 초래합니다. 그런 캐시 라인 바운싱은 성능을 심각하게 저하시킬 수 있습니다.

반면, RCU의 가벼운 read-side 기능들은 무시해




Figure 9.22: Response Time of RCU vs. Reference Counting

도 좋을 만한 성능 저하만을 가지면서 굉장히 빈번한 read-side 실행이 가능하게 해서 적거나 아예 없는 퍼포먼스 저하를 갖는 “밸크 레퍼런스 카운팅” 메커니즘으로 RCU가 사용될 수 있습니다. 블록을 하는 코드 섹션들을 가로질러 하나의 태스크가 하나의 레퍼런스를 쥐고 있어야만 하는 상황에는 Sleepable RCU (SRCU) [McK06b]가 사용될 수 있을 겁니다. 이는 레퍼런스가 한 태스크에서 다른 태스크로 “전달”되는, 예를 들어 레퍼런스가 I/O의 시작에 획득되어지고 연관된 완료 인터럽트 핸들러에서 해제되는, 희귀하지 않은 상황들을 처리하지는 못할 겁니다. (원칙적으로, 이는 SRCU 구현으로 처리될 수도 있지만, 실제로 이게 좋은 트레이드오프인지는 아직 명확하지 않습니다.)

물론, SRCU도 그 자신의 제약을 가지는데, `srcu_read_lock()`의 리턴값은 연관된 `srcu_read_unlock()`으로 전달되고, 어떤 SRCU 기능도 하드웨어 인터럽트 핸들러나 non-maskable interrupt (NMI) 핸들러 안에서 실행될 수 없다는 것입니다. 이런 제약들에 의해 얼마나 많은 문제들이 존재하게 되는지, 그리고 그것들이 어떻게 가장 잘 처리될 수 있는지에 대한 판단은 아직 진행 중입니다.

9.5.3.5 RCU is a Poor Man's Garbage Collector

RCU를 처음 공부하는 사람들이 갖는, 희귀하지 않은 느낌 가운데 하나는 “RCU는 가비지 컬렉터 같은 것이다!”입니다. 이 느낌은 커다란 진실을 품고 있기는 하지만, 오해가 될 수도 있습니다.

RCU와 자동화된 가비지 컬렉터 (GC) 사이의 관계를

Listing 9.21: Existence Guarantees Enable Per-Element Locking

```

1 int delete(int key)
2 {
3     struct element *p;
4     int b;
5
6     b = hashfunction(key);
7     rCU_read_lock();
8     p = rCU_dereference(hashtable[b]);
9     if (p == NULL || p->key != key) {
10         rCU_read_unlock();
11         return 0;
12     }
13     spin_lock(&p->lock);
14     if (hashtable[b] == p && p->key == key) {
15         rCU_read_unlock();
16         rCU_assign_pointer(hashtable[b], NULL);
17         spin_unlock(&p->lock);
18         synchronize_rcu();
19         kfree(p);
20         return 1;
21     }
22     spin_unlock(&p->lock);
23     rCU_read_unlock();
24     return 0;
25 }

```

생각하는 가장 좋은 방법은 RCU 는 콜렉션의 타이밍이 자동으로 정해진다는 점에서 RCU 가 GC 와 닮았다는 점입니다만, RCU 는 GC 와 다음과 같은 면에서 다릅니다: (1) 프로그래머는 언제 특정 데이터 구조체가 정리되어도 좋은지를 일일이 알려야만 하고, (2) 프로그래머는 레퍼런스들이 합법적으로 불잡힐 수 있는 RCU read-side 크리티컬 섹션들을 일일이 표시해야만 합니다.

이런 차이점들에도 불구하고, 유사한 부분들 역시 상당히 깊은 영역까지 들어가는 편이고, RCU 에 대한 최소한 하나의 이론적인 분석이 될수도 있습니다. 더 나아가서, 제가 신경썼던 첫번째 RCU 같은 메커니즘은 grace period 를 처리하기 위해 가비지 콜렉터를 사용했습니다. 하지만, RCU 를 생각하는 더 나은 방법이 다음 섹션에 설명되어 있습니다.

9.5.3.6 RCU is a Way of Providing Existence Guarantees

Gamsa 등 [GKAS99] 은 존재 보장에 대해 논하고 어떻게 RCU 를 닮은 메커니즘이 이런 존재 보장을 제공하기 위해 사용되는지 설명 (해당 PDF 의 7 페이지의 section 5 를 보세요) 했고, Section 7.4 에서는 락킹을 사용해서 어떻게 존재 보장을 하는지를 그렇게 하는 것의 단점과 함께 이야기했습니다. 만약 RCU 로 보호되는 데이터 항목이 RCU read-side 크리티컬 섹션 내에서 접근된다면, 그 데이터 항목은 그 RCU read-side 크리티컬 섹션 기간 동안은 존재하는 상태로 유지되는 것이 보장됩니다.

Listing 9.21 은 RCU 기반의 존재 보장이 어떻게 원소별 락킹을 가능하게 하는지를 해시 테이블에서 원소를

하나 삭제하는 함수를 통해 보이고 있습니다. Line 6 는 해시 함수를 수행하고, line 7 에서 RCU read-side 크리티컬 섹션에 들어갑니다. Line 9 에서 연관된 해시 테이블의 베킷이 비어있거나 베킷에 있는 항목이 우리가 삭제하려 하는 것이 아니라고 판단되면 line 10 에서 RCU read-side 크리티컬 섹션을 빠져나오고 line 11 에서 실패했음을 알립니다.

Quick Quiz 9.32: 우리가 삭제하려는 원소가 Listing 9.21 의 line 9 의 리스트의 첫번째 원소가 아니라면 어떡하죠? ■

그렇지 않다면, line 13 에서 update-side 스팬락을 얻어오고, line 14 에서 해당 원소가 여전히 지우려는 원소인지 확인합니다. 맞다면, line 15 에서 RCU read-side 크리티컬 섹션을 나오고 line 16 에서 해당 원소를 테이블에서 삭제하고 line 17 에서 락을 놓은 후, line 18 에서 모든 앞서 존재한 RCU read-side 크리티컬 섹션들이 완료되길 기다리고, line 19 에서 새로 삭제된 원소를 메모리 해제시키고서 line 20 에서 성공을 알립니다. 만약 그 원소가 더이상 원하던 원소가 아니라면, line 22 에서 락을 놓고 line 23 에서 RCU read-side 크리티컬 섹션을 나온 후, line 24 에서 삭제에 실패했음을 알립니다.

Quick Quiz 9.33: Listing 9.21 의 line 17 에서 락을 놓기 전에 line 15 에서 RCU read-side 크리티컬 섹션을 빠지는게 왜 안전한거죠? ■

Quick Quiz 9.34: Listing 9.21 의 line 23 에서 RCU read-side 크리티컬 섹션을 빠져나가는 건 왜 line 22 에서 락을 내려놓기 전에 될 수 없나요? ■

기민한 독자들은 이게 Section 9.5.3.8 에서 다뤄진, “RCU 는 일들이 끝나길 기다리는 한가지 방법이다” 테마의 사소한 변종이라는 걸 눈치챘을 겁니다. 그런 독자들은 또한 Section 7.4 에서 이야기한 락 기반의 존재 보장에 비해서 얻어지는 데드락 내성의 장점도 알 것입니다.

9.5.3.7 RCU is a Way of Providing Type-Safe Memory

여러 lockless 알고리즘들이 데이터 원소가 그것을 레퍼런스 하고 있는 RCU read-side 크리티컬 섹션동안 그 아이덴티티를 유지하고 있을 것을 필요로 하지 않습니다—다만 그 데이터가 같은 타입을 유지한다는 가정 아래의 이야기입니다. 달리 말하자면, 이런 lockless 알고리즘들은 데이터 원소가 레퍼런스 되고 있는 와중에도 메모리 해제되고 같은 타입의 구조체로 재할당 되는 상황을 처리할 수 있지만 타입의 변화는 없어야만 합니다. 이와 같은, 학술적 문맥에서는 “type-safe memory” 라 불리는 [GC96] 보장사항은 앞 섹션에서 이야기한 존재 보장보다 더 완화된 형태이고, 따라서 이걸 가지고 일을 처리하기는 약간 더 어렵습니다. 리눅스 커널 안의 Type-safe 메모리 알고리즘들은 slab 캐시들을 사용하

는데, 특히 이런 캐시들을 SLAB_DESTROY_BY_RCU 로 표시해서 사용되지 않는 slab 을 시스템 메모리로 반환할 때 RCU 가 사용되게 합니다. 이런 RCU 의 사용은 slab 의 사용중인 원소들은 그 slab 안에 남아 있을 것을 보장해서 앞서 존재한 RCU read-side 크리티컬 섹션들의 기간동안은 그 타입을 유지하게 됩니다.

Quick Quiz 9.35: 하지만 여러 쓰레드에 상당히 긴 RCU read-side 크리티컬 섹션이 존재해서 어떤 특정한 시점에든 시스템의 최소 하나의 쓰레드는 RCU read-side 크리티컬 섹션을 수행하고 있으면 어떡하죠? 그게 어떤 데이터가 SLAB_DESTROY_BY_RCU 슬랩에서 시스템으로 반환되는 걸 막아서 OOM 이벤트를 유발하지는 않을까요? ■

이런 알고리즘들은 새로 레퍼런스된 데이터 구조체가 정말로 요청된 타입이란 것을 분명히 하기 위해 일반적으로 검증 단계를 갖습니다 [LS86, Section 2.5]. 이런 검증은 데이터 구조체의 특정 부분이 메모리 해제-재할당 프로세스에서 수정되지 않았을 것을 요구합니다. 그런 검증은 일반적으로 잘 수행되기가 매우 어렵고, 애매하고 어려운 버그들을 숨길 수 있습니다.

따라서, type-safety 기반의 락을 사용하지 않은 알고리즘들은 매우 드물고 어려운 상황에서는 큰 도움이 될 수 있지만, 가능하다면 존재 보장을 사용해야 합니다. 더 간단하게 거의 항상 더 낫습니다!

9.5.3.8 RCU is a Way of Waiting for Things to Finish

Section 9.5.2 에서 이야기했듯이, RCU 의 중요한 부분 중 하나는 RCU 읽기 쓰레드들이 끝나기를 기다리는 방법입니다. RCU 의 큰 장점 가운데 하나는 수천개의 서로 다른 것들이 각자 끝나기를 기다리면서 그것들 각각의 정보를 명시적으로 추적할 필요가 없고, 명시적인 정보 추적 방식에서는 심각한 성능 저하, 확장성 제한, 복잡한 데드락 시나리오, 그리고 메모리 누수 문제를 걱정할 필요도 없다는 겁니다.

이 섹션에서는 read-side 쪽의 (하드웨어 오퍼레이션들과 인터럽트를 불가능하게 하는 기능들을 사용해서 preemption 을 불가능하게 하는 기능을 포함하는) synchronize_sched() 비슷한 기능이 락킹을 사용한다면 상당히 어려울 non-maskable interrupt (NMI) 핸들러들과의 상호작용을 어떻게 할 수 있게 하는지 알아보겠습니다. 이 방법은 “Pure RCU” [McK04] 라 불렸으며, 리눅스 커널의 여러 곳에서 사용됩니다.

그런 “Pure RCU” 디자인의 기본적인 형태는 다음과 같습니다:

1. 예를들면 OS 가 NMI 에 반응하는 것과 같은 방식으로 변경을 만듭니다.
2. 모든 앞서 존재한 read-side 크리티컬 섹션들이 완전히 종료되기를 기다립니다 (예를 들어,

Listing 9.22: Using RCU to Wait for NMIs to Finish

```

1 struct profile_buffer {
2     long size;
3     atomic_t entry[0];
4 };
5 static struct profile_buffer *buf = NULL;
6
7 void nmi_profile(unsigned long pcvalue)
8 {
9     struct profile_buffer *p = rcu_dereference(buf);
10
11     if (p == NULL)
12         return;
13     if (pcvalue >= p->size)
14         return;
15     atomic_inc(&p->entry[pcvalue]);
16 }
17
18 void nmi_stop(void)
19 {
20     struct profile_buffer *p = buf;
21
22     if (p == NULL)
23         return;
24     rcu_assign_pointer(buf, NULL);
25     synchronize_sched();
26     kfree(p);
27 }

```

synchronize_sched() 기능을 사용해서). 여기서의 핵심은 뒤따르는 RCU read-side 크리티컬 섹션들은 만들어진 변경을 볼 수 있게 보장된다는 것입니다.

3. 예를 들어 메모리를 반환하는 작업은 변경이 성공적으로 만들어졌음을 알리는 상태를 반환합니다.

이 섹션의 나머지 부분은 리눅스 커널에서 가져온 예제 코드를 선보입니다. 이 예제에서, timer_stop 함수는 모든 NMI 노티피케이션들이 연관된 리소스들을 반환하기 전에 완료되었음을 보장하기 위해 synchronize_sched() 를 사용합니다. 이 코드의 간략화된 버전이 Listing 9.22 에 있습니다.

Line 1-4 는 크기와 애매한 원소들의 배열을 갖는 profile_buffer 구조체를 정의합니다. Line 5 는 profile buffer 로의 포인터를 정의하는데, 아마 어디선가 동적으로 할당된 메모리의 영역을 가리키게 될겁니다.

Line 7-16 은 NMI 핸들러 안에서 호출되는 nmi_profile() 함수를 정의합니다. 그런 것들이 그려하듯, 이 함수는 preemption 당할 수 없고, 평범한 인터럽트 핸들러에 인터럽트될 수도 없습니다만, 캐시 미스, ECC 에러, 그리고 같은 코어에 위치한 다른 하드웨어 쓰레드에 의한 cycle stealing 에는 취약합니다. Line 9 는 DEC Alpha 에서도 메모리 순서를 강제하기 위해 rcu_dereference() 함수를 이용해 profile buffer 로의 지역 포인터를 가져오고, line 11 과 12 에서 현재 할당된 profile buffer 가 없다면 이 함수에서 빠져나가며, line 13 과 14 에서는 pcvalue 인자가 범위 밖이라면 이 함수에

서 빠져나갑니다. 그렇지 않다면, line 15에서 `pcvalue` 인자로 색인된 profile-buffer 원소의 값을 증가시킵니다. 버퍼와 그 크기를 함께 저장하는 것은 설령 커다란 버퍼가 갑자기 작은 것으로 바뀌더라도 크기 검사로 버퍼를 맞출 수 있음을 보장한다는 것을 기억해 두세요.

Line 18-27은 `nmi_stop()`을 정의하는데, 이 함수의 호출자는 알아서 상호 배제를 지켜야 합니다(예를 들면, 올바른 락을 잡는식으로). Line 20은 profile buffer로의 포인터를 가져오고, line 22와 23은 버퍼가 없다면 이 함수를 빠져나갑니다. 그렇지 않다면, line 24는 profile-buffer 포인터를 `NULL`로 만들고 (완화된 순서규칙의 기계에서 메모리 순서를 유지하기 위해 `rcu_assign_pointer()`를 사용합니다) line 25에서 RCU Sched grace period가 지나가기를 기다리는데, 정확히는 NMI 핸들러를 포함해서 모든 preemption 불가능 영역의 코드들이 완료되길 기다립니다. 일단 line 26으로 수행이 이어지면, 예전 버퍼로의 포인터를 가진 `nmi_profile()` 인스턴스는 모두 종료되었음이 보장됩니다. 따라서 이 버퍼를 메모리 해제해도 안전하며, 여기서는 `kfree()` 함수를 사용했습니다.

Quick Quiz 9.36: `nmi_profile()` 함수가 preemption 당할 수 있다고 해봅시다. 이 예제가 제대로 동작하도록 하기 위해 뭘 바꿔야 할까요? ■

짧게 말해서, RCU는 동적으로 profile buffer 들 사이를 옮겨다니는 것을 쉽게 해줍니다(그냥 효율적이도록 어토믹 오퍼레이션들을 시도 해보거나, 그냥 락킹을 사용할 수도 있습니다!). 하지만, RCU는 일반적으로 앞의 섹션들에서 봤듯이 더 높은 수준의 추상화에서 사용됩니다.

9.5.3.9 RCU Usage Summary

핵심적으로, RCU는 다음을 제공하는 API 이상도 이하도 아닙니다:

1. 새로운 데이터를 추가하기 위한 publish-subscribe 메커니즘,
2. 앞서 존재한 RCU 읽기 쓰레드들이 끝나길 기다리는 방법, 그리고
3. 동시의 RCU 읽기 쓰레드들에 해를 끼치거나 지연시키지 않고 변경을 가할 수 있도록 여러 버전들을 관리하는 규칙.

그러나, 앞의 섹션들에서 선보인 reader-writer 락킹, 레퍼런스 카운팅, 그리고 존재 보장 등의 더 높은 수준의 것을 RCU 위에 만드는 것이 가능합니다. 더 나아가서, 저는 리눅스 커뮤니티가 다른 동기화 기능들과 함께, RCU의 새롭고 흥미로운 사용처들을 찾아나갈 것이라 믿습니다.




Figure 9.23: RCU Areas of Applicability

그전까지는, Figure 9.23이 RCU가 가장 도움되는 곳들에 대한 대략적인 규칙을 보입니다.

그림의 꼭대기의 파란 박스가 보이듯, RCU는 넓고 비일관적인 데이터가 허용되고 읽기가 대부분인 데이터를 가지고 있을 때 가장 잘 동작합니다(하지만 넓고 비일관적인 데이터에 대한 더 많은 정보를 위해 아래를 읽으세요). 리눅스 커널에서의 이런 케이스의 표준적 예제는 라우팅 테이블입니다. 라우팅 경로 업데이트가 인터넷을 통해 전파되기까지는 수초에서 심지어 분단위까지도 걸릴 수 있기 때문에, 시스템은 상당히 가끔 패킷들을 잘못된 방향으로 보낼 겁니다. 일부 패킷들을 잘못된 방향으로 보내는 작은 가능성을 수 밀리세컨드 동안 갖는 것은 결코 문제가 되지 않습니다.

일관적인 데이터가 필요하며 읽기가 대부분인 워크로드라면, RCU는 초록색의 “read-mostly, need consistent data” 박스로 보인 것처럼 잘 동작합니다. 이런 케이스의 한가지 예는 리눅스 커널의 사용자 레벨 System-V 세마포어 ID에서 연관된 커널 내부 데이터 구조체들의 매핑이 되겠습니다. 세마포어들은 그것들이 생성되고 사라지는 것보다 훨씬 더 빈번하게 사용되고, 따라서 이 매핑은 읽기가 대부분입니다. 하지만, 이미 삭제된 세마포어를 가지고 세마포어 오퍼레이션을 수행하는 건 어려울 수 있습니다. 이런 일관성의 필요는 커널 내 세마포어 데이터 구조체 내에 있는 락과 세마포어가 지워질 때 세워지는 “deleted” 플래그를 사용해 처리됩니다. 어떤 사용자 ID가 “deleted” 플래그가 세워진 채 커널 내부 데이터 구조체에 매핑되면, 그 데이터 구조체는 무시되어서 그 사용자 ID는 무효로 처리됩니다.

이런 방법은 읽기 쓰레드들이 세마포어 자체를 나타내는 데이터 구조체의 락을 잡아야 하게 하지만, 데이터 구조체의 매핑에는 락킹이 필요없게 해줍니다. 읽기 쓰레드들은 따라서 락을 사용하지 않고 ID에서 데이터

구조체로의 매팅을 위해 사용된 트리를 횡단할 수 있는데, 이는 훨씬 향상된 성능, 확장성, 그리고 real-time 반응속도를 가져옵니다.

노란색의 “read-write” 박스로 보인 것처럼, RCU 는 일관적인 데이터가 필요한 read-write 워크로드에서도 유용하지만, 보통은 다른 동기화 도구들과 함께 사용될 때에 그렇습니다. 예를 들어, 최근의 리눅스 커널들의 디렉토리 엔트리 캐시는 시퀀스 락, CPU 별락, 그리고 데이터 구조체별 락과 함께 RCU 를 사용해서 일반적인 경우의 pathname 들의 횡단을 락을 사용하지 않고 가능하게 합니다. 비록 RCU 가 이 read-write 케이스에는 많은 이득을 가져다 줄 수 있지만, 그런 사용은 읽기가 대부분인 경우에 비해 대부분의 경우 더 복잡합니다.

마지막으로, 그림 바닥의 빨간 박스가 나타내듯이, 일관적인 데이터를 필요로 하고 업데이트가 대부분인 워크로드는 일부 예외가 있긴 하지만 [DMS+12] RCU 를 사용하기 좋은 곳이 아닐 확률이 높습니다. 또한, Section 9.5.3.7에서 이야기했듯, 리눅스 커널 내에서 SLAB_DESTROY_BY_RCU 슬랩 얼로케이터 플래그는 RCU 읽기 쓰레드들에게 type-safe 메모리를 제공하는데, 이는 non-blocking 동기화와 다른 락을 사용하지 않은 알고리즘들을 매우 간단하게 만들어줄 수 있습니다.

짧게 말해서, RCU 는 데이터 추가를 위한 publish-subscribe 메커니즘, 앞서 존재한 RCU 읽기 쓰레드들이 끝나길 기다리는 방법, 그리고 동시에 RCU 읽기 쓰레드들에 해를 끼치거나 지연시키지 않고 업데이트를 할 수 있도록 여러 버전들을 관리하는 규칙을 포함한 API 입니다. 이 RCU API 는 읽기가 대부분인 상황에 가장 잘 맞는데, 낚고 비일관적인 데이터가 허용되는 어플리케이션에서 특히 적합합니다.

9.5.4 RCU Linux-Kernel API

이 섹션은 RCU를 리눅스 커널 API 관점에서 봅니다. Section 9.5.4.1 은 RCU 의 wait-to-finish API들을, 그리고 Section 9.5.4.2 에서는 RCU 의 publish-subscribe 와 버전 관리 API 를 소개합니다. 마지막으로, Section 9.5.4.4 에서는 결론을 정리합니다.

9.5.4.1 RCU has a Family of Wait-to-Finish APIs

“RCU 는 무엇인가”에 대한 가장 단순한 답변은 RCU 는 리눅스 커널에서 사용되는 API 라는 것으로, 각각 잠들 수 없는 버전과 잠들 수 있는 버전 API 의 RCU 읽기 쓰레드 기다리기 부분을 보이는 Table 9.3, 그리고 그 API 의 publish-subscribe 부분을 보이는 Table 9.4에 요약되어 있습니다.

RCU 가 처음이라면 Table 9.3 의 행들 중 하나에만 집중해 볼 것을 고려해 볼만 한데, 각각의 행은 리눅스 커널의 RCU API 패밀리 중 하나의 멤버를 요약하고

있습니다. 예를 들어, 리눅스 커널에서 RCU 가 어떻게 사용되는지를 이해하고자 하는게 주된 목표라면, “RCU Classic”이 가장 자주 사용되므로 여기서부터 시작하는게 좋을 것입니다. 반면에, 자신의 이익을 위해 RCU 를 이해하고자 한다면 “SRCU”가 가장 간단한 API 를 제공합니다. 나중에도 언제든 다른 행을 볼 수 있습니다.

이미 RCU 에 친숙하다면, 이 표는 유용한 레퍼런스로 사용될 수 있을 겁니다.

Quick Quiz 9.37: Table 9.3 의 일부 셀들은 왜 느낌표 (“!”) 를 가지고 있나요? ■

이 “RCU Classic” 행은 RCU read-side 크리티컬 섹션들은 `rcu_read_lock()` 과 `rcu_read_unlock()` 으로 구분지어지고 중첩될 수도 있는, 최초의 RCU 구현에 해당합니다. 여기에 연관되는 동기적인 업데이트 쪽 기능들인 `synchronize_rcu()` 와 그것과 같은 의미인 `synchronize_net()` 은 동시에 실행중인 RCU read-side 크리티컬 섹션들이 모두 완료되기를 기다립니다. 이 기다림의 길이는 “grace period” 라고 알려져 있습니다. 비동기적 업데이트 쪽 기능인 `call_rcu()` 는 뒤따르는 grace period 후에 특정 함수를 특정 인자와 함께 호출해 줍니다. 예를 들어, `call_rcu(p,f)` 는 다음의 grace period 후에 “RCU callback” `f(p)` 의 호출이 이루어지게 합니다. `call_rcu()` 를 사용하는 리눅스 커널 모듈을 언로딩 한다던가 해서 모든 RCU callback들이 완료되기를 기다려야만 하는 상황도 존재합니다 [McK07f]. `rcu_barrier()` 기능이 그 일을 합니다. 더 최신의 계층적 RCU [McK08a] 구현 또한 “RCU Classic” 시맨틱을 고수함을 알아두세요.

마지막으로, RCU 는 Section 9.5.3.7에서 설명한 것처럼 type-safe 메모리 [GC96] 를 제공하는데 사용될 수도 있습니다. RCU 의 문맥에서, type-safe 메모리는 주어진 데이터 원소가 그것에 접근하는 모든 RCU read-side 크리티컬 섹션 사이에서 그 타입이 바뀌지 않는다는 것을 보장합니다. RCU 기반의 type-safe 메모리를 사용하기 위해서는 SLAB_DESTROY_BY_RCU 를 `kmem_cache_create()` 에 넘겨야 합니다. SLAB_DESTROY_BY_RCU 는 `kmem_cache_alloc()` 이 `kmem_cache_free()` 로 자유가 된 메모리를 즉시 재할당 하는 것을 막는 일은 결코 하지 않음을 알아두는 게 중요합니다! 사실, `rcu_dereference` 로 리턴된, SLAB_DESTROY_RCU 로 보호되는 데이터 구조체는 상당히 여러번 메모리 해제되고 재할당 될 수 있는데, 심지어 `rcu_read_lock()` 으로 보호되고 있을 때도 그러합니다. 대신, SLAB_DESTROY_BY_RCU 는 RCU grace period 가 끝나기 전까지는 `kmem_cache_free()` 가 완전히 해제된 데이터 구조체들의 slab 을 시스템에 반납하는 것을 방지해 줍니다. 요약해서, 비록 데이터 원소가 굉장히 자주 해제되고 재할당될 수 있지만, 최소한 그것의 타입은 똑같이 남아있을 겁니다.

Table 9.3: RCU Wait-to-Finish APIs

Attribute	RCU Classic	RCU BH	RCU Sched	Realtime RCU	SRCU
Purpose	Original	Prevent DDoS attacks	Wait for preempt-disable regions, hardirqs, & NMIs	Realtime response	Sleeping readers
Availability	2.5.43	2.6.9	2.6.12	2.6.26	2.6.19
Read-side primitives	<code>rcu_read_lock()</code> ! <code>rcu_read_unlock()</code> !	<code>rcu_read_lock_bh()</code> <code>rcu_read_unlock_bh()</code>	<code>preempt_disable()</code> <code>preempt_enable()</code> (and friends)	<code>rcu_read_lock()</code> <code>rcu_read_unlock()</code>	<code>srcu_read_lock()</code> <code>srcu_read_unlock()</code>
Update-side primitives (synchronous)	<code>synchronize_rcu()</code> <code>synchronize_net()</code>	<code>synchronize_rcu_bh()</code>	<code>synchronize_sched()</code>	<code>synchronize_rcu()</code> <code>synchronize_net()</code>	<code>synchronize_srcu()</code>
Update-side primitives (asynchronous/callback)	<code>call_rcu()</code> !	<code>call_rcu_bh()</code>	<code>call_rcu_sched()</code>	<code>call_rcu()</code>	<code>call_srcu()</code>
Update-side primitives (wait for callbacks)	<code>rcu_barrier()</code>	<code>rcu_barrier_bh()</code>	<code>rcu_barrier_sched()</code>	<code>rcu_barrier()</code>	N/A
Type-safe memory	<code>SLAB_DESTROY_BY_RCU</code>			<code>SLAB_DESTROY_BY_RCU</code>	
Read side constraints	No blocking	No bottom-half (BH) enabling	No blocking	Only preemption and lock acquisition	No <code>synchronize_srcu()</code> with same <code>srcu_struct</code>
Read side overhead	P preempt disable/enable (free on non-PREEMPT)	BH disable/enable	P preempt disable/enable (free on non-PREEMPT)	Simple instructions, IRQ disable/enable	Simple instructions, preempt disable/enable, memory barriers
Asynchronous update-side overhead	sub-microsecond	sub-microsecond	sub-microsecond	sub-microsecond	N/A
Grace-period latency	10s of milliseconds	10s of milliseconds	10s of milliseconds	10s of milliseconds	10s of milliseconds
Non-PREEMPT_RT implementation	RCU Classic	RCU BH	RCU Classic	Preemptible RCU	SRCU
PREEMPT_RT implementation	Preemptible RCU	Realtime RCU	Forced Schedule on all CPUs	Realtime RCU	SRCU

다.

Quick Quiz 9.38: 많은 수의 RCU read-side 크리티컬 섹션들이 `synchronize_rcu()` 실행을 무기한 블록시키는 걸 어떻게 막을 수 있나요? ■

Quick Quiz 9.39: `synchronize_rcu()` API는 전부터 존재한 인터럽트 핸들러들이 모두 완료되길 기다리죠, 맞죠? ■

“RCU BH” 행에서, `rcu_read_lock_bh()` 와 `rcu_read_unlock_bh()` 는 크리티컬 섹션을 구분짓고, `synchronize_rcu_bh()` 는 하나의 grace period 를 기다리며, `call_rcu_bh()` 는 다음 grace period 후에 특정 함수를 특정 인자와 함께 호출해 줍니다.

Quick Quiz 9.40: 이것들을 섞어서 활용하면 어떻게 되나요? 예를 들어, `rcu_read_lock()` 과 `rcu_read_unlock()` 을 RCU read-side 크리티컬 섹션을 구분하는데 사용하지만 `call_rcu_bh()` 를 RCU callback 을 위해 사용한다고 하면요? ■

Quick Quiz 9.41: 하드웨어 인터럽트 핸들러들은 묵시적인 `rcu_read_lock_bh()` 의 보호 아래 있다고 생각되어도 되겠죠? ■

“RCU Sched” 행에서, preemption 을 불가능하게 하는 모든 동작은 RCU read-side 크리티컬 섹션처럼 동작되고, `synchronize_sched()` 는 연관된 RCU grace period 를 기다립니다. 이 RCU API 패밀리는 2.6.12 커널에서 들어왔는데, 이것이 과거의 `synchronize_kernel()` API 를 (RCU Classic 을 위한) 지금의 `synchronize_rcu()` 와 (RCU Sched 를 위한) `synchronize_sched()` 로 나눴습니다. RCU Sched 는 처음부터 비동기적인 `call_rcu_sched()` 인터페이스를 가지고 있진 않았다가 2.6.26 에서 추가되었음을 알아두세요. 리눅스 커뮤니티의 어떤 의미에서의 minimalist 철학에 의해, API 들은 필요한 경우에 기반해서 추가됩니다.

Quick Quiz 9.42: RCU Classic 과 RCU Sched 를 섞어서 사용하면 어떻게 되나요? ■

Quick Quiz 9.43: 일반적으로, 모든 전부터 존재한 인터럽트 핸들러들을 기다리는데에 `synchronize_sched()` 에 의존해선 안됩니다. 맞죠? ■

“Realtime RCU” 행은 RCU Classic 과 똑같은 API 를 가지고 있는데, 차이점은 RCU read-side 크리티컬 섹션들이 preemption 당할 수 있고 spinlock 을 획득하는 사이 블락될 수 있다는 점 뿐입니다. Realtime RCU 의 설계는 다른곳에도 설명되어 있습니다 [McK07a].

Table 9.3 의 “SRCU” 행은 RCU read-side 크리티컬 섹션들 안에서 일반적인 잠들기를 허용하는 특수한 RCU API 를 보입니다 [McK06b]. 물론, SRCU read-side 크리티컬 섹션 안에서의 `synchronize_srcu()` 사용은 스스로의 deadlock 을 유발할 수 있으므로, 반드시 피해야 합니다. 앞의 RCU 구현들과 SRCU 의 차이점은 각각의 별개의 SRCU 사용처마다 호출자가 `srcu_struct` 를

할당해야 한다는 겁니다. 이 방법은 SRCU read-side 크리티컬 섹션의 연관되지 않은 `synchronize_srcu()` 실행을 블록하는 것을 방지합니다. 또한, 이 RCU 변종에서는 `srcu_read_lock()` 이 연관된 `srcu_read_unlock()` 에 전달되어야 하는 값을 리턴합니다.

Quick Quiz 9.44: `call_srcu()` 사용을 조심해야 하는 이유는 무엇일까요? ■

Quick Quiz 9.45: 어떤 조건에서 `synchronize_srcu()` 가 SRCU read-side 크리티컬 섹션 내에서 안전하게 사용될 수 있을까요? ■

리눅스 커널은 분명히 놀랍도록 많은 RCU API 와 구현을 가지고 있습니다. 이 수를 줄였으면 하는 바람이 있는데, 리눅스 커널의 특정 빌드는 현재 세개의 API 뒤에 최대 네개의 구현을 가지고 있다는 사실 (RCU Classic 과 Realtime RCU 는 같은 API 를 공유합니다) 이 그 증거입니다. 하지만, 많은 락킹 API 가운데 하나를 제거하려면 필요한 것처럼 충분한 조사와 분석이 필요할 겁니다.

이 다양한 RCU API 들은 RCU read-side 크리티컬 섹션들이 반드시 제공해야 하는 forward-progress 보장 사항과 그 범위로 차별화되는데, 다음과 같습니다:

1. RCU BH: read-side 크리티컬 섹션들은 NMI 와 인터럽트 핸들러를 제외한 모든 것에 대해 forward progress 를 보장해야만 합니다만 software-interrupt (softirq) 핸들러는 제외입니다. RCU BH 는 범위 내에서 글로벌 합니다.
2. RCU Sched: read-side 크리티컬 섹션들은 NMI 와 softirq 핸들러를 포함한 IRQ 핸들러들을 제외한 모든 것들에 forward progress 를 보장해야 합니다. RCU Sched 는 범위내에서 글로벌합니다.
3. RCU (Classic 과 Real-time 둘 다): read-side 크리티컬 섹션들은 NMI 핸들러, IRQ 핸들러, softirq 핸들러, 그리고 (real-time 의 경우) 더 높은 우선순위의 real-time task 를 제외한 모든 것에 forward progress 를 보장해야 합니다. RCU 는 범위내에서 글로벌합니다.
4. SRCU: read-side 크리티컬 섹션은 다른 태스크가 연관된 grace period 가 완료되기를 기다리고 있지 않다면 forward progress 를 보장하지 않아도 됩니다. 이런 상황에서 이 read-side 크리티컬 섹션들은 수초 이내에는 완료되어야 합니다 (그리고 더 빠르면 더 좋습니다).¹⁰ SRCU 의 범위는 각각 연관된 `srcu_struct` 의 사용에 따라 정의됩니다.

¹⁰ 단순히 forward-progress guarantee 가 없다고 말하는 대신 이런 명확한 설명을 하도록 재촉해준 James Bottomley 에게 감사의 말씀을 드립니다.

달리 말하자면, SRCU 는 개발자가 그 범위를 제한 할 수 있도록 하는 것으로 극단적으로 약한 forward-progress 보장사항의 문제를 보완합니다.

9.5.4.2 RCU has Publish-Subscribe and Version-Maintenance APIs

다행히도, 다음의 표에 보여진 RCU publish-subscribe 와 버전 관리 기능은 앞서 언급된 RCU 의 변종들 모두에 적용됩니다. 이 공통성은 어떤 경우들에는 더 많은 코드가 공유될 수 있게 해서, 그렇지 않다면 일어날 수 있는 API 종식을 확실히 줄여줍니다. RCU publish-subscribe API 의 원래 목적은 메모리 배리어를 이 API 안에 내장시켜서 리눅스 커널 프로그래머들이 리눅스가 지원하는 20 종류가 넘는 CPU [Spr01] 의 메모리 순서 모델 전문가가 되지 않더라도 RCU 를 사용할 수 있게 하려는 것이었습니다.

카테고리들 중 처음 두개의 카테고리는 순환형의 이중 링크드 리스트인 리눅스 `struct list_head` 리스트들에 동작합니다. `list_for_each_entry_rcu()` 함수는 RCU 로 보호되는 리스트를 type-safe 하게 횡단하는데 새로운 리스트 원소가 횡단과 동시에 삽입되는 상황을 위한 메모리 순서 강제 역시 합니다. Alpha 외의 플랫폼에서 이 함수는 `list_for_each_entry()` 에 비해 성능을 하락시키긴 하지만 그 정도는 적거나 아예 없습니다. `list_add_rcu()`, `list_add_tail_rcu()`, 그리고 `list_replace_rcu()` 함수는 RCU 아닌 비슷한 것들과 유사합니다만 완화된 순서의 기계들에서는 추가적인 메모리 배리어로 인한 오버헤드를 갖습니다. `list_del_rcu()` 함수 또한 RCU 아닌 비슷한 것과 유사합니다만, `list_del()` 이 그래야 하는 것처럼 `prev` 와 `next` 포인터들을 모두 파괴하는게 아니라 `prev` 포인터만 파괴하기 때문에 신기하게도 매우 조금 빠릅니다. 마지막으로, `list_splice_init_rcu()` 함수는 역시 RCU 아닌 비슷한 것들과 유사합니다만 grace-period 대기시간을 갖습니다. 이 grace period 의 목적은 RCU 읽기 쓰레드가 원본 리스트의 횡단을 그것이 리스트 헤더로부터 분리되기를 완료하기 전까지 안전하게 마치도록 하는 것입니다 – 이에 실패하는 것은 그런 읽기 쓰레드들이 그 횡단을 마무리하지 못하게 할수도 있습니다.

Quick Quiz 9.46: `list_del_rcu()` 는 왜 `next` 와 `prev` 두 포인터를 모두 파괴하지 않는거죠? ■

다음의 두 카테고리는 리눅스의 선형 링크드 리스트인 `struct hlist_head` 에 대해 동작합니다. `struct list_head`에 비해 `struct hlist_head` 의 장점은 하나의 포인터를 갖는 리스트 헤더만이 필요해서 커다란 해시 테이블에서는 상당한 양의 메모리를 아낄 수 있다는 점입니다. 이 표에서의 `struct hlist_head` 의 기능들과 RCU 를 사용하지 않는 비슷한 것들과의 관계는 `struct list_head` 기능들이 그러한 것과 거의




Figure 9.24: RCU API Usage Constraints

같습니다.

마지막의 두 카테고리는 포인터에 직접적으로 동작하는데, RCU 로 보호되는 배열이나 tree 와 같은, RCU 로 보호되지만 리스트가 아닌 데이터 구조체들에 사용하기에 유용합니다. `rcu_assign_pointer()` 함수는 완화된 순서 규칙의 기계들에서도 앞의 초기화 같은 것이 포인터로의 할당 전으로 순서지어지게 합니다. 유사하게, `rcu_dereference()` 함수는 Alpha CPU 에서는, 뒤따르는 해당 포인터를 디레퍼런스하는 코드가 연관된 `rcu_assign_pointer()` 앞의 초기화 코드의 효과를 볼 수 있도록 합니다. Alpha 외의 CPU 에서 `rcu_dereference()` 는 어떤 포인터 디레퍼런스가 RCU 로 보호되고 있음을 표시합니다.

Quick Quiz 9.47: 일반적으로, `rcu_dereference()`에 사용되는 모든 포인터는 반드시 항상 `rcu_assign_pointer()` 로 업데이트 되어야만 합니다. 이 규칙에 예외는 뭐가 있을까요? ■

Quick Quiz 9.48: 이런 횡단과 업데이트 기능들이 어떤 RCU API 패밀리 멤버들과 함께 사용된다 하더라도 어떤 문제는 없나요? ■

9.5.4.3 Where Can RCU's APIs Be Used?

Figure 9.24 는 커널 내의 어떤 환경에서 어떤 API 들이 사용될 수 있는지 보입니다. RCU read-side 기능은 NMI 를 포함해 어떤 환경에서도 사용될 수 있고, RCU 의 변경 기능과 비동기적인 grace-period 기능은 NMI 를 제외한 모든 환경에서 사용될 수 있으며, RCU 의 동기적인 grace-period 기능은 프로세스 컨텍스트에서만 사용될 수 있습니다. RCU 리스트 횡단 기능은 `list_for_each_entry_rcu()`, `hlist_for_each_entry_rcu()` 등을 포함합니다. 비슷하게, RCU list 변경 기능은 `list_add_rcu()`, `hlist_del_rcu()` 등을 포함합니다.

Table 9.4: RCU Publish-Subscribe and Version Maintenance APIs

Category	Primitives	Availability	Overhead
List traversal	<code>list_for_each_entry_rcu()</code>	2.5.59	Simple instructions (memory barrier on Alpha)
List update	<code>list_add_rcu()</code>	2.5.44	Memory barrier
	<code>list_add_tail_rcu()</code>	2.5.44	Memory barrier
	<code>list_del_rcu()</code>	2.5.44	Simple instructions
	<code>list_replace_rcu()</code>	2.6.9	Memory barrier
	<code>list_splice_init_rcu()</code>	2.6.21	Grace-period latency
Hlist traversal	<code>hlist_for_each_entry_rcu()</code>	2.6.8	Simple instructions (memory barrier on Alpha)
Hlist update	<code>hlist_add_behind_rcu()</code> (Renamed from <code>hlist_add_after_rcu()</code> in 3.17)	2.6.14	Memory barrier
	<code>hlist_add_before_rcu()</code>	2.6.14	Memory barrier
	<code>hlist_add_head_rcu()</code>	2.5.64	Memory barrier
	<code>hlist_del_rcu()</code>	2.5.64	Simple instructions
	<code>hlist_replace_rcu()</code>	2.6.15	Memory barrier
Pointer traversal	<code>rcu_dereference()</code>	2.6.9	Simple instructions (memory barrier on Alpha)
Pointer update	<code>rcu_assign_pointer()</code>	2.6.10	Memory barrier

다른 종류의 RCU로부터의 기능은 대체될 수도 있는데, 예를 들어 `srcu_read_lock()`은 `rcu_read_lock()`이 사용될 수 있는 모든 컨텍스트에서 사용될 수 있습니다.

9.5.4.4 So, What is RCU Really?

그 핵심에 있어서, RCU는 더도 덜도 아니고 데이터 삽입의 공개와 구독을 지원하고 모든 RCU 읽기 쓰레드들이 완료되길 기다리며, 여러 버전들을 관리하는 API입니다. 그렇다면 하나, RCU 위에 reader-writer 락킹, 레퍼런스 카운팅, 그리고 Section 9.5.3에서 열거한 존재 보장과 같은 고차원의 것들을 만드는 것이 가능합니다. 더 나아가서, 리눅스 커뮤니티가 RCU의 흥미롭고 새로운 사용처를 찾을 것이라 믿어 의심치 않습니다, 커널의 여러 동기화 기능들에 대해서 그랬듯이요.

물론, 더 완벽한 RCU에 대한 이해는 이 API들을 가지고 할 수 있는 일에 대한 것들도 포함할 것입니다.

하지만, 많은 사람들의 경우 RCU에 대한 완벽한 이해에는 RCU 구현의 예가 포함될 겁니다. 따라서 Appendix B는 복잡도와 기능성을 늘려가는 일련의 “장난감” RCU 구현들을 소개합니다. 그렇지 않은 모두를 위해, 다음 섹션은 학계와 산업계에서의 RCU 사용에 대한 개괄을 제공합니다.

9.5.5 RCU Related Work

RCU 비슷한 것들에 대한 알려진 첫번째 언급은 FORTRAN을 위한 J. Weizenbaum의 SLIP 리스트 처리 설비 [Wei63]에 대한 Donald Knuth의 버그 레포트 [Knu73, page 413 of Fundamental Algorithms]였습니다. Knuth는 SLIP이 grace-period 보장과 같은 것을 갖고 있지 않다고 이야기했습니다.

RCU 비슷한 것들에 대한 버그 레포트가 아닌 첫번째 언급은 Kung과 Lehman의 획기적인 논문 [KL80]이었습니다. 이 기법의 학계에서의 추가적인 사용 [ML82, ML84, Lis88, Pug90, And91, PAB⁺95, CAK⁺96, RSB⁺97, GKAS99]이 있었습니다만, 이 영역에서의 대부분의 작업은 실제 일을 하는 사람들에 의해 진행되었습니다 [RTY⁺87, HOS89, Jac93, Joh95, SM95, SM97, SM98, MS98a]. 2000년에 이르러, 주도권은 오픈소스 프로젝트들로, 그 중에서도 리눅스 커널 커뮤니티로 넘겨졌습니다 [Rus00a, Rus00b, MS01, MAK⁺01, MSA⁺02, ACMS03].¹¹

하지만, 2010년대 중반에 이르러, 커뮤니티와 기관들을 통한 RCU에 대한 연구와 개발 [Kaa15]이 급증했습니다. Section 9.5.5.1은 RCU의 사용들에 대해 설명하고, Section 9.5.5.2는 RCU 구현들을 (그리고 구현을 만들고 사용한 일들) 설명하고, 마지막으로, Section 9.5.5.3

¹¹ 200 개가 넘는 인용처 목록은 이 책의 LATEX 소스의 `bib/RCU.bib`에서 찾을 수 있을 겁니다.

에서는 RCU 의 겸증과 그 사용을 이야기합니다.

9.5.5.1 RCU Uses

Portland State University (PSU) 의 Phil Howard 와 Jon Walpole 은 RCU 를 소프트웨어 트랜잭션 메모리를 사용해 동기화된 업데이트와 조합해서 red-black tree 에 적용 [How12, HW11] 했습니다. Josh Pripplott 과 Jon Walpole (다시 말하지만 PSU) 은 RCU 를 resizable hash table 에 적용했습니다 [Tri12, TMW11, Cor14b, Cor14c]. RCU 로 보호되는 또 다른 resizable hash table ① Herbert Xu [Xu10] 와 Mathieu Desnoyers [MDJ13a] 에 의해 만들어졌습니다.

MIT 의 Austin Clements, Frans Kaashoek, 그리고 Nickolai Zeldovich 는 RCU 에 최적화된 balanced binary tree (Bosai) [CKZ12] 을 만들었고, 리눅스 커널의 `mmap_sem` 의 read-side contention 을 줄이기 위해 이 트리를 리눅스 커널의 VM 에 적용했습니다. 이 작업은 많은 수의 minor page fault 로 구성된 microbenchmark 에서 최소 80 개의 CPU 들까지는 열배 이상의 속도 향상과 확장성을 보였습니다. 이는 앞서 Peter Zijlstra 에 의해 개발된 패치 [Zij14] 와 비슷하며, 둘 다 파일시스템 데이터 구조는 RCU 읽기 쓰레드들에게 안전하지 않다는 한계점을 가지고 있습니다. Clements 등은 이 한계점을 page-fault 처리 경로를 anonymous page 들로만 제한함으로써 피했습니다. 더 최근에 들어서는 파일시스템 데이터 구조도 RCU 읽기 쓰레드들에게 안전하게 되었고 [Cor10a, Cor11], 따라서 이 작업은 anonymous page 만이 아니라 모든 종류의 page 들에 대해 구현될 수 있을 겁니다—실제로, Peter Zijlstra 는 최근에 이에 대한 프로토타입을 만들었습니다.

MIT 의 Yandong Mao 와 Robert Morris, 그리고 Harvard University 의 Eddie Kohler 는 B+ tree 와 tries 의 아이디어를 조합한, Masstree 라는 이름의, RCU 로 보호되는 또 다른 트리를 만들었습니다 [MKM12]. 이 tree 는 RCU 로 보호되는 hash table 에 비해 2.5배 가량 느리지만 hash table 과 달리 key range 에 대한 오퍼레이션들을 지원합니다. 또한, Masstree 는 긴 shared key prefix 에 대해 효율적인 오브젝트 저장소를 지원하며, 더 나아가서 대용량 저장소로의 로깅을 통한 persistency 를 제공합니다.

해당 페이퍼는 Masstree 의 성능이 memcached 의 것과 견주어질 수 있으며, 심지어 Masstree 는 memcached 가 제공하지 않는 업데이트의 지속성을 제공한다고 이야기 했습니다. 이 논문은 또한 Masstree 의 성능을 지속성 있는 데이터베이스인 MongoDB, VoltDB, Redis 와 비교해서 어떤 경우에는 100배가 넘는 성능 이득을 보였습니다. MIT 의 Stephen Tu, Wenting Zheng, Barbara Liskov, 그리고 Samuel Madden 과 Kohler 의 또 다른 논문 [TZK⁺13] 은 Masstree 를 Silo 라는 이름의

in-memory 데이터베이스에 적용해서 잘 알려진 트랜잭션 처리 벤치마크에서 초당 700K 트랜잭션 (분당 42M 트랜잭션) 을 달성했습니다. 흥미롭게도, Silo 는 락을 잡으면서 grace period 의 오버헤드를 일으키지 않고도 linearizability 를 보장합니다.

Technion 의 Maya Arbel 과 Hagit Attiya 는 Masstree 와 같이 동시의 업데이트를 가능하게 해주는 더 정밀한 방법 [AA14] 을 RCU 로 보호되는 탐색 tree 에 적용했습니다. 이 논문은 올바름의 증명과 이 tree 의 모든 오퍼레이션들이 linearizable 하다는 증명을 포함합니다. 불행히도, 이 구현은 lock 을 잡으면서 기다리는 동안 grace-period 전체 응답시간을 필요로 함으로써 linearizability 를 얻는데, 이는 update 로만 이루어진 workload 에서는 확장성을 떨어뜨립니다. 이 문제를 해결하는 한가지 방법은 linearizability 를 포기하는 것 [HKLP12, McK14b] 입니다만, Arbel 과 Attiya 는 그대신 low-end grace-period 응답시간을 줄인 RCU 변종을 만들었습니다. 물론, 어떤 것도 공짜로 얻어지지는 않고, 이 RCU 변종은 32개 CPU 에서 확장성의 한계를 드러내는 결과를 나타냈습니다. Linearizability 를 포기해서 성능과 확장성을 모두 얻는 것에 대해서도 더 이야기 할 부분이 많지만, 학계에서 대안적 RCU 구현들로 한 실험들을 보는 것도 좋을 겁니다.

9.5.5.2 RCU Implementations

Mathieu Desnoyers 는 tracing 에 사용하기 위해 user-space RCU 를 만들었고 [Des09b, Des09a, DMS⁺12] 이는 여러 프로젝트들 [BD13] 에 사용되었습니다.

프라하에 위치한 Charles University 의 연구원들 역시 RCU 구현들에 대한 연구를 진행했는데, Andrej Podzimek 의 박사 학위 논문 [HKLP12] 과 Adam Hraska 의 박사학위 논문 [Hra13] 이 그것들입니다.

Yujie Liu (Lehigh University), Victor Luchangco (Oracle Labs), 그리고 Michael Spear (Lehigh University) [LLS13] 는 서비스에 scalable non-zero indicators (SNZI) [ELLM07] 를 사용했습니다. 여기서 의도된 목적은 결국은 확장성을 제한할 수 있는, linearizability 를 갖는 software transactional memory (Section 17.2 를 참고하세요) 를 구현하는 것입니다.

RCU 같은 메커니즘들이 Java 에도 도입되고 있습니다. Sivaramakrishnan 등 [SZJ12] 은 RCU 같은 메커니즘을 사용해서 Java 의 가비지 컬렉터와 상호작용할 때 필요한 read barrier 를 제거해 상당한 성능 향상을 냈습니다.

Shanghai Jiao Tong University 의 Ran Liu, Heng Zhang, 그리고 Haibo Chen 은 최적화된 “passive reader-writer lock” 에 사용하기 위한 특수화된 RCU 변종 [LZC14] 을 만들었는데, 이는 Gautham Shenoy [She06] 의 것과

Srivatsa Bhat [Bha14] 의 것과 비슷합니다. Liu 등의 논문은 여러 측면에서 흥미롭습니다 [McK14e].

Mike Ash는 Apple 의 Objective-C 런타임에 있는 RCU 같은 기능들에 대한 설명을 기재했습니다 [Ash15]. 이 방법은 read-side 크리티컬 섹션들을 코드 영역을 이야기하는 것으로 파악하게 하고, 이로 인해 다른 제로에 가까운 read-side 오버헤드를 달성하는 방법들처럼 높은 성능을 보입니다만, 여러 함수들로 구성되는 커다란 read-side 크리티컬 섹션들을 어떻게 다룰 것인지에 대한 실용적인 측면의 도전사항을 갖습니다.

Pedro Ramalhete 와 Andreia Correia [RC15] 는 “Poor Man’s RCU” 를 만들었는데, 이는 reader-writer 락 한쌍을 사용하면서도 읽기 쓰레드들에게 lock-free forward-progress guarantee 를 제공합니다 [MP15a].

Maya Arble 과 Adam Morrison [AM15] 은 “Predicate RCU” 를 만들었는데, 이는 update-side 락들을 grace period 들 사이로 갖는 알고리즘들을 효과적으로 지원하기 위해 grace-period 기간을 줄이려 노력합니다. 이는 grace period 들 사이로의 업데이트의 batching 을 줄이고 확장성을 줄이는 결과를 초래했습니다만, 짧은 grace period 를 제공하는 데에는 성공했습니다.

Quick Quiz 9.49: Grace period 를 기다리기 전에 락을 내려놓거나 grace period 를 기다리는 대신에 `call_rcu()` 같은 걸 사용하는 게 어떤가요? ■

Alexander Matveev (MIT), Nir Shavit (MIT and Tel-Aviv University), Pascal Felber (University of Neuchâtel), 그리고 Patrick Marlier (also University of Neuchâtel) [MSFM15] 은 명시적으로 read-only 트랜잭션들을 표시하는 software transactional memory 라고 생각될 수 있는 RCU 같은 메커니즘을 만들었습니다. 이들의 사용에는 grace period 들 사이로 락을 잡을 것을 필요로 하는데, 이는 확장성을 제한합니다 [MP15a, MP15b]. 이는 `rcutorture` 테스트 도구를 잘 사용한 첫번째 학계의 RCU 관련 작업이었으며, 성능 향상 내용을 Linux-kernel RCU 에 제출한 첫번째였는데, v4.4 에 받아들여졌습니다.

Geoff Romer 와 Andrew Hunter (둘 다 Google) 는 싱글톤 데이터 구조체의 RCU 보호를 위한 cell 기반 API 를 C++ 표준에 포함될 수 있도록 제안했습니다 [RH17].

9.5.5.3 RCU Validation

2017 년 초에 이르러 모든 버그가 잠재적 보안 취약점이라는 것이 일반적으로 알려졌고, 따라서 검증은 첫번째로 신경써야 할 영역입니다.

Stony Brook University 의 연구자들은 RCU 를 인지하는 data-race detector [Dug10, Sey12, SRK⁺11] 를 만들었습니다. IMDEA 의 Alexey Gotsman, Tel Aviv University 의 Noam Rinetzky, 그리고 University of Oxford 의 Hongseok Yang 은 RCU 의 형식적 semantic 들을

speration logic 의 용어로 표현하는 논문 [GRY12] 을 발표했고 동시성의 다른 영역에 대해서도 작업을 계속하고 있습니다.

Joseph Tassarotti (Carnegie-Mellon University), Derek Dreyer (Max Planck Institute for Software Systems), 그리고 Viktor Vafeiadis (MPI-SWS) [TDV15] 는 userspace RCU 의 quiescent-state-based-reclamation (QSBR) 변종의 올바름에 대한 manual formal proof 를 만들었습니다. Lihao Liang (University of Oxford), Paul E. McKenney (IBM), Daniel Kroening, 그리고 Tom Melham (둘 다 Oxford) [LMKM16] 는 C bounded model checker (CBMC) [CKL04] 를 사용해 Linux-kernel Tree RCU 의 상당한 부분에 대한 올바름의 기계적 증명을 만들어냈습니다. Lance Roy [Roy17] 는 CBMC 를 사용해서 Linux-kernel sleepable RCU (SRCU) [McK06b] 의 상당한 부분에 대한 올바름의 증명을 만들었습니다. 마지막으로, Michalis Kokologiannakis 와 Konstantinos Sagonas (National Technical University of Athens) [KS17a] 는 Nighugg tool [LSLK14] 을 사용해서 Linux-kernel Tree RCU 의 더 커다란 영역에 대해 기계적 올바름의 증명을 만들었습니다.

이러한 노력을 중 어느 것도 해당 검증 도구들을 테스트하는데에 관여된 RCU 버그들 외에는 어떤 버그도 찾아내지 않았습니다. 반대로, Alex Groce (Oregon State University), Iftekhar Ahmed, Carlos Jensen (둘 다 OSU), 그리고 Paul E. McKenney (IBM) [GAJM15] 는 `rcutorture` 테스트 도구의 적용 범위를 테스트하기 위해 리눅스 커널 RCU 의 소스 코드를 자동적으로 변형시켰습니다. 이 방법은 이 테스트 도구의 적용 범위에 있는 여러 구멍들을 찾아냈으며, 그 중 하나는 Tiny RCU 의 진짜 버그 (지금은 고쳐진) 가 숨겨져 있는 것을 찾아냈습니다.

운이 좋다면, 이런 검증에 대한 작업들은 모두 결국은 동시성 코드의 검증을 위한 더 나은 도구들을 생겨나게 할겁니다.

9.5.6 RCU Exercises

이 섹션은 RCU 를 이 책에서 앞서 보인 여러 예제들에 적용하는 내용에 대한 여러개의 Quick Quizz 들로 구성되어 있습니다. 각 Quick Quiz 에의 답은 힌트를 일부 제공하고, 또한 그 해법이 자세히 설명되어 있는 뒤의 섹션으로의 포인터를 담고 있습니다. `rcu_read_lock()`, `rcu_read_unlock()`, `rcu_dereference()`, `rcu_assign_pointer()`, 그리고 `synchronize_rcu()` 기능들만으로도 이 문제들에 충분해야 할 겁니다.

Quick Quiz 9.50: Listing 5.5 (`count_end.c`) 에 보인 통계적 카운터의 구현은 `read_count()` 안에서 합계를

구하는 것을 보호하기 위해 글로벌 락을 사용했는데 이게 부족한 성능과 음의 확장성을 일으켰습니다. `read_count()` 가 훌륭한 성능과 좋은 확장성을 제공할 수 있게 하기 위해 RCU 를 어떻게 적용해 볼 수 있을까요. (`read_count()` 의 확장성은 모든 쓰레드의 카운터들을 스캔해야 한다는 필요성으로 인해 제한되어진다는 점을 명심하세요.) ■

Quick Quiz 9.51: Section 5.4.6 는 디바이스들을 제거하기 위해 I/O 액세스를 카운트하는 일을 처리하는 한쌍의 코드 조각을 보였습니다. 이 코드 조각은 reader-writer 락을 잡아야 하는 이유로 (I/O 를 시작하는) 빠른 수행 경로의 높은 오버헤드 문제를 겪었습니다. 여기에 훌륭한 성능과 확장성을 가져오기 위해 RCU 를 어떻게 사용할 수 있을까요? (I/O 액세스를 하는 일반적인 경우의 첫번째 코드 조각의 성능이 디바이스 제거 코드 조각의 것보다 훨씬 더 중요함을 명심하세요.) ■

9.6 Which to Choose?

Choose always the way that seems the best, however rough it may be; custom will soon render it easy and agreeable.

Pythagoras

Table 9.5 는 이 챕터에서 소개한 네개의 미뤄두고 처리하기 테크닉들 중 무엇을 선택해야 할지를 돋는 간단한 경험적 범칙을 제공합니다.

“Existence Guarantee” 열에서 보인 것처럼, 링크된 데이터 원소들에 대한 존재 보장이 필요하다면 레퍼런스 카운팅, 해저드 포인터, 또는 RCU 를 사용해야 합니다. 시퀀스 락은 존재 보장을 제공하지 않고, 업데이트의 발견과 업데이트를 마주한 read-side 크리티컬 섹션의 재시도 기능을 제공합니다.

물론, “Updates and Readers Progress Concurrently” 열에서 보인 것처럼, 이런 업데이트의 발견은 시퀀스 락킹이 업데이트 쓰레드와 읽기 쓰레드가 동시에 진행할 수는 없게 만듭니다. 무엇보다, 그런 진행을 방지하는 것이 시퀀스 락킹을 사용하는 첫번째 이유입니다! 이런 상황은 존재 보장과 업데이트 발견을 제공하기 위해서 시퀀스 락킹을 레퍼런스 카운팅, 해저드 포인터, 또는 RCU 와 함께 사용하는 방법을 보입니다. 실제로, 리눅스 커널은 경로 탐색을 할 때에 RCU 와 시퀀스 락킹을 함께 사용합니다.

“Contention Among Readers”, “Reader Per-Critical-Section Overhead”, 그리고 “Reader Per-Object Traversal Overhead” 열은 이 테크닉들의 대략적인 read-side 오버헤드를 보입니다. 레퍼런스 카운팅의 오버헤드는 읽기 쓰레드간의 완전히 순서 맞춰진 read-modify-write 어

토믹 오퍼레이션이 각각의 모든 오브젝트 방문에 필요하기 때문에 상당히 클 수 있습니다. 해저드 포인터는 마주치는 각각의 데이터 원소에 메모리 배리어 오버헤드를 끼치고 시퀀스 락은 크리티컬 섹션을 실행하고자 하는 각 시도마다 두개의 메모리 배리어 오버헤드를 만듭니다. RCU 구현의 오버헤드는 아예 없는 경우부터 각각의 read-side 크리티컬 섹션에서의 한쌍의 메모리 배리어까지 다양하고, 따라서 RCU 는 최고의 성능을 제공하는데, 많은 데이터 원소들을 마주치게 되는 read-side 크리티컬 섹션들에 대해서는 특히 그렇습니다.

“Reader Forward Progress Guarantee” 열은 RCU 만이 bounded wait-free forward-progress 보장을 가짐을 보이는데, 이는 유한한 갯수의 인스트럭션들을 수행하는 것으로 유한한 방문을 할 수 있음을 의미합니다.

“Reader Reference Acquisition” 열은 RCU 만이 무조건적으로 레퍼런스를 얻어오는 것이 가능함을 알립니다. 시퀀스 락의 항목은 “Unsafe” 라 표기되어 있는데, 다시 말하지만 시퀀스 락은 레퍼런스를 얻는게 아니라 업데이트를 발견하기 때문입니다.

레퍼런스 카운팅과 해저드 포인터 둘 다 특정 레퍼런스 획득에 실패했을 때에는 획단을 처음부터 다시 시작할 것이 요구됩니다. 이를 자세히 보기 위해, 오브젝트 A, B, C, 그리고 D 가 순서대로 담겨 있는 링크드 리스트에 다음과 같은 이벤트들이 발생한다고 생각해 봅시다:

1. 한 읽기 쓰레드가 오브젝트 B 로의 레퍼런스를 얻습니다.
2. 업데이트 쓰레드가 오브젝트 B 를 제거하지만, 읽기 쓰레드가 레퍼런스를 잡고 있으므로 해제하지는 않습니다. 이 리스트는 이제 오브젝트 A, C, 그리고 D 를 가지고 있고, 오브젝트 B 의 `->next` 포인터는 `HAZPTR_POISON` 으로 설정되어 있습니다.
3. 앞의 업데이트 쓰레드는 오브젝트 C 를 제거하고, 이에 의해 리스트는 오브젝트 A 와 D 만 가지고 있게 됩니다. 오브젝트 C 에는 레퍼런스가 잡혀 있지 않으므로, 곧바로 해제됩니다.
4. 앞의 읽기 쓰레드는 이제는 삭제된 오브젝트 B 의 다음 오브젝트로 넘어가려 하지만, poison 값은 가지고 있는 `->next` 포인터는 이를 못하게 합니다. 이는 좋은 일인데, 이렇게 되지 않으면 오브젝트 B 의 `->next` 포인터는 이미 해제된 메모리 영역을 가리킬 수도 있기 때문입니다.
5. 이 읽기 쓰레드는 따라서 리스트의 헤드부터 획단을 다시 시작해야 합니다.

Table 9.5: Which Deferred Technique to Choose?

Property	Reference Counting	Hazard Pointers	Sequence Locks	RCU
Existence Guarantees	Complex	Yes	No	Yes
Updates and Readers Progress Concurrently	Yes	Yes	No	Yes
Contention Among Readers	High	None	None	None
Reader Per-Critical-Section Overhead	N/A	N/A	Two <code>smp_mb()</code>	Ranges from none to two <code>smp_mb()</code>
Reader Per-Object Traversal Overhead	Read-modify-write atomic operations, memory-barrier instructions, and cache misses	<code>smp_mb()</code>	None, but unsafe	None (volatile accesses)
Reader Forward Progress Guarantee	Lock free	Lock free	Blocking	Bounded wait free
Reader Reference Acquisition	Can fail (conditional)	Can fail (conditional)	Unsafe	Cannot fail (unconditional)
Memory Footprint	Bounded	Bounded	Bounded	Unbounded
Reclamation Forward Progress	Lock free	Lock free	N/A	Blocking
Automatic Reclamation	Yes	No	N/A	No
Lines of Code	94	79	79	73

따라서, 레퍼런스를 획득하는데 실패했다면, 해저드 포인터나 레퍼런스 카운터를 사용하는 횡단은 처음부터 그 횡단을 재시작해야 합니다. 예를 들어 링크드 리스트를 담고 있는 트리와 같이 중첩된 링크드 데이터 구조의 경우 이 횡단은 가장 바깥의 데이터 구조로부터 재시작되어야 합니다. 이런 상황은 RCU에 훨씬 사용하기 쉬운 이점을 가져다 줍니다.

하지만, RCU의 사용성 이득은 공짜로 오는 것은 아닙니다, “Memory Footprint” 열에서 이를 볼 수 있습니다. RCU의 무조건적 레퍼런스 획득 지원은 곧 어떤 RCU 읽기 쓰레드에게 보이는 오브젝트는 그 읽기 쓰레드가 완료되기 전까지는 해제될 수 없음을 의미합니다. 따라서 RCU는 무한한 메모리 사용량 가능성을 갖는데, 업데이트가 인공적으로 조절되지 않는 한은 그렇습니다. 반면에, 레퍼런스 카운팅과 해저드 포인터는 정말로 동시의 읽기 쓰레드들이 레퍼런스하고 있는 데이터 원소만을 유지할 겁니다.

이런 메모리 사용량과 획득 실패 사이의 미묘한 긴장감이 리눅스 커널에서는 일부 경우 RCU와 레퍼런스 카운터를 함께 사용하는 것으로 해결되기도 합니다. RCU는 잠깐 사용되는 레퍼런스들에 사용되는데, 이는 RCU read-side 크리티컬 섹션들이 짧을 수 있음을 의미합니다. 이런 짧은 RCU read-side 크리티컬 섹션들은 곧 연관된 RCU grace period 들 역시 짧을 수 있어서, 메모리 사용량을 제한할 수 있음을 의미합니다. 긴 시간

사용될 수 있는 레퍼런스를 필요로 하는 일부 데이터 원소들을 위해서는 레퍼런스 카운팅이 사용됩니다. 이 말이 의미하는 바는 레퍼런스 획득 실패의 복잡도를 처리하는 건 그런 일부 데이터 원소들에서만 필요시 된다는 뜻입니다: 대량의 레퍼런스 획득은 RCU 덕분에 고려되지 않습니다. 레퍼런스 카운팅을 다른 동기화 메커니즘과 결합하는 방법에 대한 더 많은 정보를 위해선 Section 13.2을 보시기 바랍니다.

“Reclamation Forward Progress” 열은 해저드 포인터가 non-blocking 업데이트를 제공할 수 있음을 이야기합니다 [Mic04, HLM02]. 레퍼런스 카운팅은 구현에 따라서 그럴 수도 그러지 않을 수도 있습니다. 하지만, 시퀀스 락킹은 update-side 락 때문에 non-blocking 업데이트를 제공할 수 없습니다. RCU 업데이트 쓰레드들은 읽기 쓰레드를 기다려야만 하는데, 이 역시 non-blocking 업데이트의 규칙을 완전히 벗어납니다. 하지만, 블록킹 오퍼레이션은 메모리를 해제하기 위한 기다림 뿐인 상황이 존재하는데, 많은 경우에 이런 상황은 non-blocking 만큼이나 좋은 상황입니다 [DMS⁺12].

“Automatic Reclamation” 열에 보여진 것처럼, 레퍼런스 카운팅만이 메모리 해제를 자동화 할 수 있는데, non-cyclic 데이터 구조들에서만 그렇습니다.

마지막으로, “Lines of Code” 열은 Pre-BSD 라우팅 테이블 구현의 크기를 보이는데, 상대적인 사용의 편리성에 대한 대략적 정보를 제공합니다. 그렇다면 하나,

레퍼런스 카운팅과 시퀀스 락킹 구현은 버그가 존재하며, 정확히 동작하는 레퍼런스 카운팅 구현은 더 복잡할 것으로 여겨짐 [Val95, MS95]을 알아둘 필요가 있습니다. 그런 부분을 위해, 올바른 시퀀스 락킹 구현은 추가적인 또 다른 동기화 메커니즘을 필요로 하여서, 예를 들어 해저드 포인터나 RCU를 사용할 수 있는데, 시퀀스 락킹은 동시에 업데이트를 발견하고 다른 메커니즘은 안전한 레퍼런스 획득을 제공할 수 있을 겁니다.

이런 테크닉들을 조합해서 또는 각각 사용하는 경험 이 더 쌓여감에 따라서 이 섹션에 놓인 경험적 법칙은 수정될 수 있을 겁니다. 하지만, 이 섹션은 현재로써는 최선의 결과를 반영하고 있습니다.

9.7 What About Updates?

The only thing constant in life is change.

François de la Rochefoucauld

이 챕터에서 이야기된 미뤄서 처리하기 테크닉들은 읽기가 대부분인 환경에는 거의 곧바로 적용할 수 있는데, 이는 곧 “그렇지만 업데이트는 어떻게 하지?”라는 질문을 갖게 합니다. 읽기 쓰레드의 성능과 확장성을 증가시키는 것은 잘 되었지만, 쓰기 쓰레드에도 훌륭한 성능과 확장성을 원하는건 자연스러운 일입니다.

이미 쓰기 쓰레드에게 높은 성능과 확장성을 가져다주는 상황을 이미 봤는데, Chapter 5에서 이야기된 카운팅 알고리즘들입니다. 이 알고리즘들은 부분적으로 분할된 데이터 구조를 사용해서 쓰기 쓰레드가 지역적으로 일어날 수 있게 하면서도 더 비싼 읽기들은 전체 데이터 구조를 횡단하며 더하기를 해야만 하게 합니다. Silas Boyd-Wickhize는 이런 방향을 OpLog를 만들도록 일반화 시켰는데, 그는 이를 리눅스 커널의 경로 탐색, VM 역 매핑, 그리고 stat() 시스템콜에 적용시켰습니다 [BW14].

“Disruptor”라고 불리는 또 다른 방법은 입력 데이터의 커다란 스트림을 처리하는 어플리케이션을 위해 설계되었습니다. 이 방법은 single-producer-single-consumer FIFO 큐를 위한 것으로, 동기화의 필요성을 최소화 시킵니다 [Sut13]. 자바 어플리케이션에서 Disruptor는 가비지 컬렉터의 사용을 최소화 시키기도 합니다.

그리고 물론, 가능하다면, 완전히 분할되었거나 “파편화된 (sharded)” 시스템들은 Chapter 6에서 이야기한 것처럼 굉장히 성능과 확장성을 제공합니다.

다음 챕터는 여러 종류의 데이터 구조의 맥락에서 업데이트들을 살펴보겠습니다.

Chapter 10

Data Structures

데이터로의 효율적인 접근은 중요해서, 알고리즘에 대한 논의는 관련된 데이터 구조의 시간 복잡도를 포함합니다 [CLRS01]. 하지만, 병렬 프로그램에서는 시간 복잡도의 측정은 동시성에의 영향을 포함해야 합니다. 이런 영향은 Chapter 3에서 보인 것처럼 지배적일 정도로 클 수 있는데, 이는 동시적인 데이터 구조의 설계는 순차적 시간 복잡도에 그러한 것만큼 동시성에도 신경을 써야 함을 의미합니다. 달리 말하자면, 훌륭한 병렬 프로그래머가 데이터 구조 관계에서 걱정해야 할 중요한 부분 중 하나는 동시성에 관련된 부분입니다.

Section 10.1은 이 챕터에서 소개되는 데이터 구조들을 평가하는데 사용되며 모티베이션을 줄 어플리케이션을 선보입니다.

Chapter 6에서 논의된 대로, 높은 확장성을 얻는 방법은 파티셔닝입니다. 이는 분할 가능한 데이터 구조를 위한 방법을 이야기하게 되는데, 이 주제는 Section 10.2에서 다룹니다. Chapter 9는 일부 동작들을 미뤄두는 게 어떻게 성능과 확장성을 모두 크게 개선할 수 있는지 설명했습니다. 특히 Section 9.5에서는 성능과 확장성을 쫓음에 있어서 미뤄두기가 어떻게 대단한 효과를 보이는지를 보였는데, 이 주제는 Section 10.3에서 다릅니다.

모든 데이터 구조가 분할 가능하지는 않습니다. Section 10.4는 다소 파티셔닝이 어려운 데이터 구조를 알아봅니다. 이 섹션은 이걸 어떻게 읽기가 대부분이고 파티셔닝 가능한 영역으로 쪼개서 빼르고 확장성 있는 구현을 가능하게 하는지 보입니다.

이 챕터는 사용되어온 모든 동시적 데이터 구조의 자세한 부분들까지 이야기할 수는 없으므로 Section 10.5에서는 대부분의 유명하고 중요한 것들에 대한 간략한 조사 내용을 제공합니다. 최고의 성능과 확장성을 만들 어진 내용에서의 세세한 최적화보다는 설계를 만들어내게 되긴 합니다만, 분명한 최고의 달성 가능한 성능과 확장성을 얻는데에 세세한 최적화가 중요한 위치를 차지하는건 분명합니다. 따라서 이 주제를 Section 10.6에서 다루도록 합니다.

마지막으로, Section 10.7에서는 이 챕터의 요약을

Bad programmers worry about the code. Good programmers worry about data structures and their relationships.

Linus Torvalds

제공합니다.

10.1 Motivating Application

우리는 성능을 평가하는데에 Schrödinger의 Zoo 어플리케이션을 사용하도록 하겠습니다 [McK13]. Schrödinger는 많은 수의 동물을 수용하고 있는 동물원을 하나 가지고 있고, 그는 이 동물들을 in-memory 데이터베이스를 사용해 관리하려 할텐데, 동물원에 수용된 각각의 동물은 이 데이터베이스에 데이터 항목으로 표현됩니다. 각 동물은 키로 사용되는 유일한 이름을 가지고, 각 동물마다 관리되는 다양한 데이터를 갖습니다.

출산, 포획, 그리고 구매는 데이터 삽입이 되고, 사망, 방출, 그리고 판매는 삭제가 됩니다. Schrödinger의 동물원은 쥐와 곤충 등을 포함해 많은 수의 단명하는 동물들을 수용하고 있으므로 이 데이터베이스는 높은 비율의 업데이트를 지원해야 합니다.

Schrödinger의 동물들에 관심있는 사람들은 그것들에 대해 쿼리를 던질 수 있습니다만, Schrödinger는 그의 고양이에의 굉장히 높은 비율의 쿼리가 존재함을 알렸고, 따라서 그는 그의 쥐들은 이 데이터베이스를 죽을 때에나 사용하게 될거라 생각합니다. 이말은 Schrödinger의 어플리케이션은 하나의 데이터 항목으로의 높은 비율의 쿼리를 지원할 수 있어야 한다는 의미입니다.

다양한 데이터 구조들이 소개되는 중에도 이 어플리케이션을 마음속에 담아 두시기 바랍니다.

10.2 Partitionable Data Structures

오늘날 사용되는 데이터 구조들은 굉장히 많아서, 그것들을 다루는 책도 여럿 있습니다. 이 작은 섹션은 하나의 데이터 구조인 해시 테이블에 집중해 봅니다. 이렇게 집중을 해보는 것은 어떻게 동시성이 데이터 구조와 상호작용하는지에 대한 깊은 이해를 가능하게 하고, 또한 실제 상황에서 굉장히 많이 사용되는 데이터 구조에 집

Listing 10.1: Hash-Table Data Structures

```

1 struct ht_elem {
2     struct cds_list_head hte_next;
3     unsigned long hte_hash;
4 };
5
6 struct ht_bucket {
7     struct cds_list_head htb_head;
8     spinlock_t htb_lock;
9 };
10
11 struct hashtable {
12     unsigned long ht_nbuckets;
13     int (*ht_cmp)(struct ht_elem *htep, void *key);
14     struct ht_bucket ht_bkt[0];
15 };

```

중할 수 있게 합니다. Section 10.2.1에서는 이 디자인을 전체적으로 보고, Section 10.2.2에서는 그 구현을 제공합니다. 마지막으로, Section 10.2.3에서는 그 결과로 나오는 성능과 확장성을 알아봅니다.

10.2.1 Hash-Table Design


Chapter 6에서는 괜찮은 성능과 확장성을 얻기 위해서는 파티셔닝을 적용해야 함을 알아보았고, 따라서 파티셔닝 적용 가능성은 데이터 구조를 선택할 때 첫번째로 고려할 기준이어야만 할 겁니다. 이 기준은 병렬성을 위해 많이 사용되는 해시 테이블에서 잘 만족됩니다. 해시 테이블은 개념적으로 간단하고, *hash bucket*들의 배열로 구성됩니다. 하나의 *hash function*은 주어진 원소의 *key*로부터 이 원소가 저장되게 될 *hash bucket*으로의 매팅을 담당합니다. 따라서, 각각의 *hash bucket*은 원소들의 링크드 리스트를 갖게되는데, 이는 *hash chain*이라 불립니다. 제대로 구성된다면, 이런 *hash chain*들은 상당히 짧을 것이어서 해시 테이블이 주어진 키를 가지고 해당 원소에 접근하는 것은 매우 효율적이게 될 겁니다.

Quick Quiz 10.1: 하지만 많은 종류의 해시 테이블들이 존재하고, 여기 설명된 체인 기반 (chained) 해시 테이블은 그 중 하나의 종류일 뿐입니다. 왜 체인 사용 해시 테이블에 집중하는 걸까요? ■

또한, 각각의 *bucket*은 각자의 락을 가질 수도 있어서, 해시 테이블의 서로 다른 *bucket*의 원소들은 완전히 독립적으로 더해지고 삭제되고 탐색될 수 있습니다. 많은 수의 원소들을 담고 있는 커다란 해시 테이블은 따라서 훌륭한 확장성을 제공합니다.

10.2.2 Hash-Table Implementation

Listing 10.1 (*hash_bkt.c*)는 chaining과 *bucket* 별 락킹을 사용하는 간단한 고정 크기 해시 테이블에 사용되는 데이터 구조들을 보이고 있고, Figure 10.1은 그 것들이 어떻게 함께 동작하는지 보이고 있습니다. (List-

**Figure 10.1:** Hash-Table Data-Structure Diagram**Listing 10.2:** Hash-Table Mapping and Locking

```

1 #define HASH2BKT(htp, h) \
2     (&(htp)->ht_bkt[h % (htp)->ht_nbuckets])
3
4 static void hashtable_lock(struct hashtable *htp,
5                             unsigned long hash)
6 {
7     spin_lock(&HASH2BKT(htp, hash)->htb_lock);
8 }
9
10 static void hashtable_unlock(struct hashtable *htp,
11                             unsigned long hash)
12 {
13     spin_unlock(&HASH2BKT(htp, hash)->htb_lock);
14 }

```

ing 10.1의 line 11-14의) *hashtable* 구조체는 (Listing 10.1의 line 6-9의) *ht_bucket* 구조체를 네개 가지고 있으며, *->ht_nbuckets* 필드로 이 *bucket*들의 갯수를 조절합니다. 그런 각각의 *bucket*은 리스트 헤더 *->htb_head*와 락 *->htb_lock*을 갖습니다. 이 리스트 헤더들은 (Listing 10.1의 line 1-4의) *->ht_elem* 구조체들을 *->hte_next* 필드를 이용해 연결하고, 각각의 *ht_elem* 구조체는 또한 연관된 원소의 해시 값을 *->hte_hash* 필드에 저장해 둡니다. *ht_elem* 구조체는 이 해시 테이블에 위치한 더 큰 구조체의 안에 포함될 수도 있는데, 이런 경우의 이 큰 구조체는 복잡한 키를 가질 겁니다.

Figure 10.1에 보인 다이어그램에서 *bucket* 0은 두 개의 원소를 가지고 있고 *bucket* 2는 하나의 원소를 가지고 있습니다.

Listing 10.2는 매팅과 락킹 함수들을 보입니다. Line 1과 2는 HASH2BKT() 매크로를 보이는데, 이 매크로는 해시 값으로부터 연관된 *ht_bucket* 구조체로의 매팅을 합니다. 이 매크로는 간단한 모듈로 연산을 사용합니다. 더 적극적인 해싱이 필요하다면, 이 함수의 호출자는 키로부터 해시 값을 매팅할 때 이를 구현해야 합니다. 남아있는 두 함수들은 특정 해시 값에 연관된 *->htb*-

Listing 10.3: Hash-Table Lookup

```

1 struct ht_elem *
2 hashtab_lookup(struct hashtab *htp, unsigned long hash,
3                 void *key)
4 {
5     struct ht_bucket *htb;
6     struct ht_elem *htep;
7
8     htb = HASH2BKT(htp, hash);
9     cds_list_for_each_entry(htep, &htb->htb_head, hte_next) {
10        if (htep->hte_hash != hash)
11            continue;
12        if (htp->ht_cmp(htep, key))
13            return htep;
14    }
15    return NULL;
16 }

```

Listing 10.4: Hash-Table Modification

```

1 void hashtab_add(struct hashtab *htp, unsigned long hash,
2                   struct ht_elem *htep)
3 {
4     htep->hte_hash = hash;
5     cds_list_add(&htep->hte_next,
6                  &HASH2BKT(htp, hash)->htb_head);
7 }
8
9 void hashtab_del(struct ht_elem *htep)
10 {
11     cds_list_del_init(&htep->hte_next);
12 }

```

lock 을 각각 획득하고 해제합니다.

Listing 10.3 는 hashtab_lookup() 을 보아는데, 이 함수는 특정 해시 값과 키를 가지고 있는 원소가 존재한다면 그 원소로의 포인터를, 그렇지 않다면 NULL 을 리턴합니다. 이 함수는 해시 값과 그 키로의 포인터를 받는데 이는 이 함수의 사용자들이 임의의 키와 임의의 해시 함수를 사용할 수 있게 하며, qsort() 에서와 비슷하게 cmp() 를 통해 넘겨지는 키 비교 함수를 사용할 수 있게 하기 때문입니다. Line 11 은 해시 값으로부터 그에 연관된 bucket 으로의 포인터를 매핑해 줍니다. Line 12-19 의 루프를 통한 각각의 수행은 bucket 의 해시 체인의 원소 하나를 조사합니다. Line 15 에서는 해시 값이 들어맞는지 보고, 그렇지 않다면 line 16 에서 다음 원소로 넘어갑니다. Line 17 에서는 실제 키가 맞는지 확인해보고, 그렇다면 line 18 에서 그 원소로의 포인터를 리턴합니다. 어떤 원소도 들어맞지 않는다면, line 20 에서 NULL 을 리턴합니다.

Quick Quiz 10.2: 하지만 Listing 10.3 의 line 15-18 에서의 두번의 비교는 키가 unsigned long 에 들어맞는 경우라면 비효율적이지 않나요? ■

Listing 10.4 는 hashtab_add() 와 hashtab_del() 함수들을 보아는데, 이 함수들은 각각 해시 테이블에 원소를 더하고 삭제합니다.

hashtab_add() 함수는 단순히 원소의 해시 값을 line 6 에서 설정하고 line 7 과 8 에서 연관된 bucket 에

Listing 10.5: Hash-Table Allocation and Free

```

1 struct hashtab *
2 hashtab_alloc(unsigned long nbuckets,
3                int (*cmp)(struct ht_elem *htep, void *key))
4 {
5     struct hashtab *htp;
6     int i;
7
8     htp = malloc(sizeof(*htp) +
9                  nbuckets * sizeof(struct ht_bucket));
10    if (htp == NULL)
11        return NULL;
12    htp->ht_nbuckets = nbuckets;
13    htp->ht_cmp = cmp;
14    for (i = 0; i < nbuckets; i++) {
15        CDS_INIT_LIST_HEAD(&htp->ht_bkt[i].htb_head);
16        spin_lock_init(&htp->ht_bkt[i].htb_lock);
17    }
18    return htp;
19 }
20
21 void hashtab_free(struct hashtab *htp)
22 {
23     free(htp);
24 }

```

이 원소를 집어넣습니다. hashtab_del() 함수는 hash chain 리스트의 이중 연결의 원리 덕에 단순히 무엇이든 원소가 속해 있는 hash chain 으로부터 자신을 제거합니다. 이 두 함수들을 수행하기 전에, 호출자는 다른 어떤 쓰레드도 같은 bucket 을 접근하거나 수정하고 있지 않음을 분명히 해야 하는데, 예를 들어 hashtab_lock() 을 미리 호출할 수 있을 겁니다.

Listing 10.5 는 hashtab_alloc() 과 hashtab_free() 를 보아는데, 이 함수들은 각각 해시 테이블 할당과 해제를 합니다. 할당은 line 7-9 에서의 필요한 메모리 할당으로 시작합니다. Line 10 에서 메모리가 부족하다는 걸 알게 된다면 line 11 에서 호출자에게 NULL 을 리턴합니다. 그렇지 않다면, line 12 에서는 bucket 들의 갯수를 초기화하고, line 13-16 의 루프는 bucket 각각을 초기화하는데, line 14 에서의 chain 리스트 헤더와 line 15 에서의 락 초기화를 포함합니다. 마지막으로, line 17 에서는 이 새로 할당된 해시 테이블로의 포인터를 리턴합니다. Line 20-23 에서의 hashtab_free() 함수는 단순합니다.

10.2.3 Hash-Table Performance

여덟개의 2 GHz Intel® Xeon® CPU 를 사용한 시스템에서 bucket 별 락을 사용하며 1024개 bucket 을 가진 해시 테이블을 사용한 성능 결과가 Figure 10.2 에 있습니다. 이 성능은 거의 선형적으로 증가합니다만, 8개의 CPU 만 사용함에도 이상적인 성능 기준의 절반을 넘지 못합니다. 이는 락 획득과 해제가 하나의 CPU 에서는 캐시 미스를 내지 않지만, 두개 이상의 CPU 에서는 캐시 미스를 내기 때문입니다.




Figure 10.2: Read-Only Hash-Table Performance For Schrödinger's Zoo




Figure 10.3: Read-Only Hash-Table Performance For Schrödinger's Zoo, 60 CPUs

그리고 CPU 의 수가 커져갈수록 상황은 더 나빠져 가는데, 이를 Figure 10.3 가 보이고 있습니다. 여기선 이상적 성능을 위한 선을 추가적으로 보일 필요도 없습니다: 9개 이상의 CPU 에서의 성능은 끔찍합니다. 이는 적당한 수의 CPU 이상으로 CPU 를 늘리는 것의 위험성을 분명하게 강조합니다.

물론, 이렇게 성능이 떨어지는 것은 bucket 의 수가 부족해서일 수도 있습니다. 일단, 우리는 각 bucket 이 cache line 에 맞아 떨어지도록 패딩을 넣지 않았고, 따라서 하나의 캐시 라인에 여러 bucket 들이 존재할 겁니다. 이로 인해 9개 CPU 에서부터 캐시 쓰래싱이 시작되었을 수 있습니다. 당연하게도 이는 bucket 의 수를 늘리는 것으로 테스트 해볼 수 있을 겁니다.

Quick Quiz 10.3: 단순히 bucket 들의 수를 늘리는 대신에 이미 있는 bucket 들을 캐시에 정렬 시키는게 더




Figure 10.4: Read-Only Hash-Table Performance For Schrödinger's Zoo, Varying Buckets

낫지 않을까요? ■

하지만, Figure 10.4, 에서 볼 수 있듯이, bucket 들의 수를 늘리는 것이 실제로 성능을 어느정도 증가시키기는 하지만, 확장성은 여전히 끔찍합니다. 특히, 아홉개 이상의 CPU 들에서는 여전히 현격한 성능 저하를 볼 수 있습니다. 더 나아가서, 8,192 개 bucket 에서 16,384 개의 bucket 으로 넘어가는것부터는 더이상 성능이 늘어나지도 않습니다. 분명 뭔가가 잘못되어 있습니다.

문제는 이 시스템이 Figure 10.5 에 보인 것처럼 CPU 0-7 과 32-39 가 첫번째 소켓에 위치하는 멀티 소켓 시스템이라는 점입니다. 따라서, 처음 여덟개 CPU 에 국한되어 돌아가는 테스트는 상당히 잘 동작하지만, 소켓 0 의 CPU 0-7 과 소켓 1 의 CPU 8 이 관여되는 테스트에서는 데이터를 소켓 너머로 주고받는 오버헤드가 생겨납니다. 이는 Section 3.2.1 에서 보인 것처럼, 성능을 상당히 저하시킬 수 있습니다. 요약해서, 커다란 멀티 소켓 시스템에서는 완전한 파티셔닝에 더해서 메모리 참조의 높은 로컬리티를 필요로 합니다.

Quick Quiz 10.4: Schrödinger 의 동물원 어플리케이션의 소켓을 넘어가면서 보이는 음의 확장성을 가지고 생각해보면, 어플리케이션의 복사본을 여럿 만들어서 각각의 복사본이 전체 동물의 부분집합만을 가지고 하나의 소켓 위에서만 각자 돌도록 하는 건 어떨까요? ■

지금까지 논의된 Schrödinger's-zoo 수행의 한가지 핵심적 특성은 이것들이 모두 읽기만 했다는 것입니다. 이는 락 획득이 초래한 캐시 미스들로 인해 발생한 성능 하락을 더욱 심하게 만듭니다. 이 아래에 깔려 있는 해시 테이블 자체에 대해 업데이트를 하지 않더라도, 메모리에 쓰기를 하기 위한 비용은 여전히 지불되고 있는 것입니다. 물론, 이 해시 테이블이 절대 업데이트 되지 않는다면, 상호 배타성을 완전히 제거할 수 있을 겁니다. 이 방법은 상당히 단순하고, 따라서 독자들의 연습으로

Socket	Core							
0	0	1	2	3	4	5	6	7
	32	33	34	35	36	37	38	39
1	8	9	10	11	12	13	14	15
	40	41	42	43	44	45	46	47
2	16	17	18	19	20	21	22	23
	48	49	50	51	52	53	54	55
3	24	25	26	27	28	29	30	31
	56	47	58	59	60	61	62	63

Figure 10.5: NUMA Topology of System Under Test

Listing 10.6: RCU-Protected Hash-Table Read-Side Concurrency Control

```

1 static void hashtab_lock_lookup(struct hashtab *htp,
2                                 unsigned long hash)
3 {
4     rcu_read_lock();
5 }
6
7 static void hashtab_unlock_lookup(struct hashtab *htp,
8                                  unsigned long hash)
9 {
10    rcu_read_unlock();
11 }
```

남겨두겠습니다. 하지만 결국은 일어나는 업데이트가 있다 하더라도, 쓰기를 막는 것은 캐시 미스를 막을 것이고, 이는 읽기가 대부분인 데이터의 복사본을 모든 캐시에 만들어두는 것으로 메모리 참조의 로컬리티를 높여줄 수 있을 것입니다.

따라서 다음 섹션에서는 읽기가 대부분이지만 업데이트가 가끔씩이지만 언제든 일어날 수 있는 경우를 위한 최적화들을 알아보겠습니다.

10.3 Read-Mostly Data Structures

파티셔닝이 적용된 데이터 구조가 훌륭한 확장성을 제공할 수 있긴 하지만, NUMA 효과는 성능과 확장성 모두를 심각하게 저하시킬 수 있습니다. 더불어, 읽기 쓰레드가 쓰기 쓰레드와 배타적으로 동작해야 한다는 필요성이 읽기가 대부분인 상황에서의 성능을 저하시킬 수 있습니다. 하지만, Section 9.5에서 소개된 바 있는 RCU를 사용해서 성능과 확장성을 모두 달성할 수 있습니다. 비슷한 결과를 해저드 포인터를 이용해서 얻을 수도 있는데(hazptr.c), 이는 이 섹션의 성능 결과에서 보여질 겁니다 [McK13].

10.3.1 RCU-Protected Hash Table Implementation

Bucket 별 락킹을 사용하는 RCU로 보호되는 해시

Listing 10.7: RCU-Protected Hash-Table Lookup

```

1 struct ht_elem *hashtab_lookup(struct hashtab *htp,
2                                 unsigned long hash,
3                                 void *key)
4 {
5     struct ht_bucket *htb;
6     struct ht_elem *htep;
7
8     htb = HASH2BKT(htp, hash);
9     cds_list_for_each_entry_rcu(htep,
10                                &htb->htb_head,
11                                hte_next) {
12         if (htep->hte_hash != hash)
13             continue;
14         if (htp->ht_cmp(htep, key))
15             return htep;
16     }
17     return NULL;
18 }
```

테이블에서, 업데이트 쓰레드는 Section 10.2에서 설명된 것과 똑같이 락킹을 사용하지만 읽기 쓰레드는 RCU를 사용합니다. 데이터 구조는 Listing 10.1에서 보인 것과 똑같이 남아 있고, HASH2BKT(), hashtab_lock(), 그리고 hashtab_unlock() 함수들은 Listing 10.2에서 보인 것과 똑같습니다. 하지만, 읽기 쓰레드는 Listing 10.6에 보인 것과 같이 hashtab_lock_lookup()와 hashtab_unlock_lookup()로 둘러싸인 더 가벼운 동시성 제어 방법을 사용할 겁니다.

Listing 10.7은 bucket 별 락킹을 사용하며 RCU로 보호되는 해시 테이블에 사용되는 hashtab_lookup() 함수를 보입니다. 이 함수는 cds_list_for_each_entry()가 cds_list_for_each_entry_rcu()로 바뀌었다는 점을 제외하고는 Listing 10.3에서 보인 버전과 동일합니다. 이것들 둘 다 htb->htb_head로 레퍼런스되는 해시 체인을 따라간다는 점에서는 동일합니다만 cds_list_for_each_entry_rcu()는 추가적으로, 동시의 삽입이 존재하는 경우에 올바른 메모리 액세스 순서를 강제합니다: 순수한 bucket 별 락킹 사용 구현과 달리, RCU로 보호되는 구현에서는 검색 작업이 삽입이나 삭제 작업과 동시에 수행되는 것이 허용되고, RCU를 신경쓰는 기능인 cds_list_for_each_entry_rcu()와 같은 것들은 이 추가적 동시성을 올바로 제어할 것이 요구됩니다. 또한 hashtab_lookup()의 호출자는 RCU read-side 크리티컬 섹션 안에 있어야 한다는 점을 알아둬야 하는데, 예를 들어 호출자는 hashtab_lookup()을 호출하기 전에 hashtab_lock_lookup()을 호출해야만 합니다 (그리고 나중에는 당연히 hashtab_unlock_lookup()을 호출해야겠죠).

Quick Quiz 10.5: 하지만 해시 테이블의 원소가 검색과 동시에 삭제될 수가 있다면, 그 말은 검색 기능은 검색된 직후에 삭제된 원소로의 레퍼런스를 리턴할 수도 있다는 의미 아닌가요? ■


Listing 10.8은 hashtab_add()와 hashtab_del()

Listing 10.8: RCU-Protected Hash-Table Modification

```


1 void hashtab_add(struct hashtab *htp,
2                   unsigned long hash,
3                   struct ht_elem *htep)
4 {
5     htep->hte_hash = hash;
6     cds_list_add_rcu(&htep->hte_next,
7                       &HASH2BKT(htp, hash)->htb_head);
8 }
9
10 void hashtab_del(struct ht_elem *htep)
11 {
12     cds_list_del_rcu(&htep->hte_next);
13 }

```

**Figure 10.6:** Read-Only RCU-Protected Hash-Table Performance For Schrödinger's Zoo

함수를 보이는데, 둘 다 Listing 10.4에서 보인 RCU를 사용하지 않는 해시 테이블에서의 같은 기능을 하는 것들과 상당히 비슷합니다. `hashtab_add()` 함수는 검색되고 있는 도중에 동시에 해시 테이블에 더해지는 원소의 경우에 대해 올바른 순서를 강제하기 위해서 `cds_list_add()` 대신에 `cds_list_add_rcu()` 함수를 사용합니다. `hashtab_del()` 함수는 삭제되기 직전에 검색되는 원소의 경우를 위해서 `cds_list_del_init()` 대신에 `cds_list_del_rcu()` 함수를 사용합니다. `cds_list_del_init()` 와 달리, `cds_list_del_rcu()`는 다음 원소로의 포인터를 온전하게 남겨 두어서 `hashtab_lookup()`이 삭제된 원소의 다음 원소로도 갈 수 있게 해줍니다.

물론, `hashtab_del()`을 호출한 후에, 호출자는 이번에 삭제한 원소의 메모리를 해제하거나 재사용하기 전에 (`synchronize_rcu()`를 호출하거나 하는 식으로) 하나의 RCU grace period를 기다려야만 합니다.

**Figure 10.7:** Read-Only RCU-Protected Hash-Table Performance For Schrödinger's Zoo, Linear Scale

10.3.2 RCU-Protected Hash Table Performance

Figure 10.6는 RCU로 보호되는 버전과 해저드 포인터로 보호되는 버전의 해시 테이블들의 읽기만 일어나는 상황에서의 성능을 앞 섹션에서 본 bucket 별 락킹 사용 구현 버전과 비교해 보이고 있습니다. 볼 수 있듯이, RCU와 해저드 포인터 둘 다 큰 수의 쓰레드들에서는 NUMA 영향을 받기는 하지만 이상적인 경우에 가까운 성능과 확장성을 보이고 있습니다. 테이블 전체를 하나의 락으로 보호하는 구현의 결과도 보이고 있는데, 그런 상황에서의 성능은 기대된 대로 bucket 별 락킹 구현 버전에 비해서 조차도 나쁨을 볼 수 있습니다. RCU는 해저드 포인터보다 아주 약간 좋은 성능을 보이기는 하지만, 그 차이는 이 로그스케일 그림에서는 거의 보이지도 않을 정도입니다.

Figure 10.7는 같은 데이터를 로그스케일이 아닌 리니어스케일 (linear scale)로 보입니다. 여기서는 테이블 전체를 하나의 락으로 보호하는 구현의 경우는 x 축에 붙어버려 제대로 볼 수가 없지만, RCU와 해저드 포인터 사이의 상대적 성능 차이를 좀 더 분간할 수 있습니다. 둘 다 32 CPU를 넘어가면서 성능 증가정도가 떨어지기 시작하는 걸 볼 수 있는데, 이는 하드웨어 멀티쓰레딩 때문입니다. 32개 이하의 CPU에서, 각각의 쓰레드는 각각의 코어를 갖고 있습니다. 이 버전에서, RCU는 해저드 포인터보다 좋은 성능을 보이는데 이는 해저드 포인터의 read-side 메모리 배리어가 해당 코어 내에서의 시간을 잡아먹기 때문입니다. 요약하자면, RCU는 하나의 하드웨어 쓰레드를 가지고 있을 때에는 해저드 포인터보다 코어를 더 잘 활용합니다.

이 상황은 32개보다 많은 CPU들의 상황에서 변합니다. RCU는 각 코어의 반이 넘는 리소스를 하나의 하드웨어 쓰레드에서 사용하므로, RCU를 수행하는 코




Figure 10.8: Read-Side Cat-Only RCU-Protected Hash-Table Performance For Schrödinger's Zoo at 60 CPUs




Figure 10.9: Read-Side RCU-Protected Hash-Table Performance For Schrödinger's Zoo at 60 CPUs

어 각각에 두개의 하드웨어 쓰레드가 존재하게 되면 그 성능 이득이 상대적으로 적어지게 됩니다. 해저드 포인터의 성능 그림에서의 경사도 역시 32 CPU 를 넘어서면서 줄어듭니다만, RCU 에 비해서는 좀 덜 극적으로 줄어들고 있는데, 이는 두번째 하드웨어 쓰레드는 첫 번째 하드웨어 쓰레드가 메모리 배리어 대기시간으로 멈춰서 있는 사이의 시간을 활용할 수 있기 때문입니다. 뒤의 섹션에서 보게 되겠지만, 하드웨어 포인터의 두 번째 하드웨어 쓰레드 상황에서의 이득은 워크로드의 특성에 종속적입니다.

앞서 언급했듯, Schrödinger 는 그의 고양이의 인기에 놀랐고 [Sch35], 이 인기도를 그의 설계에 반영해야 할 필요가 있음을 깨달았습니다. Figure 10.8 는 60-CPU 가 동작하는 상황에서 고양이를 검색하는 CPU 의 숫자를 바꿔가면서 성능 결과를 비교해 봅니다. RCU 와 해저드 포인터 모두 이 상황에 잘 동작하지만 bucket 락킹은 오히려 성능이 떨어지는데, 결국에는 심지어 하나의 락을 사용하는 경우보다도 나쁜 결과를 보입니다. 만약 모든 CPU 가 고양이만을 검색하고 있다면 그 고양이의 bucket 에 연관된 락에 모두가 매이게 될테고 이는 하나의 락을 사용하는 것과 같으므로 그다지 놀라운 일도 아닙니다.

이 고양이만을 위한 벤치마크는 완전히 파티셔닝된 샤딩 방법에 존재할 수 있는 잠재적 문제를 보이고 있습니다. 이 고양이의 파티션에 연관된 CPU 만이 그 고양이에 접근할 수 있게 되어서, 고양이만 검색될 때의 성능을 제한하게 됩니다. 물론, 수많은 어플리케이션이 로드 오퍼레이션을 다양하게 흘뿌리는 특성을 가지고 있고, 그런 어플리케이션들에서 샤딩 방법은 매우 잘 동작할 겁니다. 하지만, 샤딩은 “핫 스팟” 을 아주 잘 처리하지는 못하고, Schrödiger 의 고양이 예제는 그런 하나의 케이스를 보이고 있습니다.

물론, 데이터를 읽기만 할 셈이라면, 애초에 동시성




Figure 10.10: Update-Side RCU-Protected Hash-Table Performance For Schrödinger's Zoo at 60 CPUs

제어가 필요하지도 않을 겁니다. 따라서, Figure 10.9 는 업데이트의 영향을 보입니다. 이 그래프의 왼쪽 끝에서는 60 개의 모든 CPU 들이 검색만을 하고, 오른쪽 끝에서는 모든 60개의 CPU 들이 업데이트만을 합니다. 네개의 구현 모두, 밀리세컨드당 검색의 수는 업데이트를 하는 CPU 들의 수가 늘어날수록 감소되고, 60개의 모든 CPU 들이 업데이트를 하게 될 때에는 밀리세컨드당 검색의 수가 0이 되어버립니다. RCU 는 해저드 포인터에 비해 상대적으로 좋은 결과를 보이는데 해저드 포인터의 read-side 메모리 배리어는 업데이트가 증가함에 따라 더 커다란 오버헤드를 내기 때문입니다. 따라서 최신의 하드웨어는 메모리 배리어 수행을 많이 최적화 해서 읽기만 할 때의 메모리 배리어 오버헤드를 많이 줄일 것으로 보입니다.

Figure 10.9 는 검색을 하는 와중에 업데이트의 비율에 따른 영향을 보았다면, Figure 10.10 는 업데이트 자신에

대해 증가하는 업데이트 비율의 영향을 보이고 있습니다. 해저드 포인터와 RCU는 시작점부터 상당히 좋은 성능을 가지고 시작하는데, bucket 락킹과 달리, 읽기 쓰레드들은 업데이트 쓰레드들을 막지 않기 때문입니다. 하지만, 업데이트를 하는 CPU의 수가 늘어남에 따라, 업데이트 쪽 오버헤드는 그 존재를 드러내기 시작해서, RCU에서 먼저 드러내고, 뒤이어 해저드 포인터에서도 보입니다. 물론, 이 세개의 구현 모두 하나의 락을 사용하는 경우에 비해서는 훨씬 좋은 성능을 보입니다.

물론, 검색 성능에서의 차이는 업데이트 비율의 차이에 의해 영향을 받았을 가능성이 큽니다. 이를 확인할 수 있는 한가지 방법은 인공적으로 bucket 별 락킹과 해저드 포인터에서의 업데이트 비율을 RCU에서의 그것에 맞도록 바꿔보는 것입니다. 그렇게 하는 것은 bucket 별 락킹에서의 검색 성능을 많이 끌어올리지는 못하고, 해저드 포인터와 RCU 사이의 차이를 줄이지도 못합니다. 하지만, 해저드 포인터의 읽기 쪽 메모리 배리어를 제거하는 것은 (그렇게 해서 해저드 포인터의 불안전한 구현을 만드는 것은) 해저드 포인터와 RCU 사이의 성능 차이를 거의 없애버립니다. 비록 이 불안전한 해저드 포인터 구현은 벤치마킹 목적에 따라서는 사용될 수도 있겠지만, 제품 단계에서의 사용은 결코 추천되지 못할 것입니다.

Quick Quiz 10.6: 8개 CPU에서 60 CPU 상황을 쓰레드 수를 늘리는 것으로 시뮬레이션 해보는건 상당히 위험함이 Section 10.2.3에서 드러났었습니다. 하지만 60 CPU를 가지고 더 많은 CPU 상황을 시뮬레이션 해보는건 보다 안전할 수 있을까요? ■

10.3.3 RCU-Protected Hash Table Discussion

RCU와 해저드 포인터를 사용한 구현들로부터 얻어지는 한가지 결론은 동시에 수행되는 두개의 읽기 쓰레드들은 한 고양이의 상태에 대해 서로 다른 의견을 가질 수 있다는 겁니다. 예를 들어, 한 읽기 쓰레드는 고양이가 삭제되기 직전에 그 고양이의 데이터로의 포인터를 얻어오지만, 또 다른 읽기 쓰레드는 똑같은 포인터를 삭제 직후에 얻어올 수도 있습니다. 첫번째 읽기 쓰레드는 고양이가 살아있다고 믿겠지만, 두번째 읽기 쓰레드는 고양이가 죽었다고 생각할 겁니다.

물론, 이 상황은 Schrödinger의 고양이에 맞아 떨어집니다만, 이는 양자(quantum)가 아닌 고양이에도 상당히 합리적인 상황임이 드러납니다.

동물이 정확히 언제 태어나고 죽었는지 판단하는건 불가능하기 때문입니다.

이를 분명히 하기 위해, 고양이의 죽음을 맥박으로 판단한다고 생각해 봅시다. 이는 죽음을 판단하기 위해선 마지막 맥박으로부터 얼마나 오래 기다려야 하는지에



Figure 10.11: Even Veterinarians Disagree!

대한 질문을 만듭니다. 딱 1 밀리세컨드만 기다리는건 분명 우스운 일인데, 그렇게 되면 건강하게 살아있는 고양이도 1초 동안에도 여러번 죽은 것으로 판단될 것이기 때문입니다—그리고선 부활하겠죠—. 한달을 기다리는 것도 똑같이 우스운 일일텐데, 그렇게 되면 가여운 고양이의 죽음을 냄새로도 분명히 알 수 있게 될테니까요.

동물의 심장은 수초동안 멈췄다가 다시 동작할 수 있으므로, 죽음의 인식과 잘못된 알람의 가능성 사이의 트레이드오프가 있습니다. 두명의 전문가도 마지막 맥박으로부터 얼마나 기다려야 죽음을 판단할 수 있는지에 대해선 의견이 갈릴 수 있습니다. 예를 들어, 한 전문가는 마지막 맥박으로부터 30초 후에 죽음을 판단할 수 있는 반면, 다른 전문가는 1분을 기다려서야 인식할 수 있습니다. 이런 경우, 두명의 전문가는 Figure 10.11에 그린 것처럼 마지막 맥박으로부터 30초가 지난 후 30초 동안은 그 고양이의 상태에 대해 이견을 가질 것입니다.

물론, Heisenberg는 이런 종류의 불확실성과 함께 살아가야 한다고 가르쳤고 [Hei27], 이는 컴퓨팅 하드웨어와 소프트웨어 역시 비슷하게 동작하기 때문에 좋은 일입니다. 예를 들어, 컴퓨팅 하드웨어의 일부 부분이 고장났는지 어떻게 아시나요? 종종 시간적으로 응답을 하지 않을 때가 있죠. 고양이의 맥박처럼, 이는 하드웨어가 고장난건지 아닌지에 대한 불확실성의 기간을 만들 어냅니다.

더 나아가서, 대부분의 컴퓨팅 시스템은 바깥 세상의 것들과 상호 동작하도록 만들어졌습니다. 따라서 이 바깥 세상의 것들과의 일관성이 무엇보다 중요합니다. 하지만, page 139의 Figure 9.20에서 봤듯이 내부의 일관성을 향상시키는 것은 외부의 일관성을 얻기 위한 비용을 증가시킬 수 있습니다. RCU와 해저드 포인터와 같은 테크닉들은 향상된 외부 일관성을 얻기 위해 내부 일관성을 약간 포기합니다.




Figure 10.12: Partitioning Problems

요약해서, 내부의 일관성은 모든 문제 상황에서 자연적인 부분은 아니고, 종종 성능, 확장성, 외부 일관성, 그리고 그런 것들 모두의 측면에서 커다란 비용을 만듭니다.

10.4 Non-Partitionable Data Structures

고정크기 해시 테이블은 파티셔닝을 완전히 적용 가능하지만, 크기 조정이 가능한 해시 테이블은 크기를 키우거나 줄일 때, Figure 10.12에 보인 것처럼 파티셔닝에 있어서의 문제를 갖습니다. 하지만, 다음 섹션에서 설명하듯이 RCU로 보호되는 고성능의 확장성 있는 해시 테이블을 만드는 것이 가능한 것으로 드러났습니다.

10.4.1 Resizable Hash Table Design

2000년 초의 상황과 대조적으로, 이제는 다행히도 확장성 있고 RCU로 보호되는 해시 테이블이 세개 이상의 종류가 있습니다. 첫번째의 (그리고 가장 간단한) 것은 Herbert Xu [Xu10]에 의해 리눅스 커널을 위해 개발된 것이고, 다음 섹션에서 설명됩니다. 다른 두가지는 Section 10.4.4에서 간단히 다루겠습니다.

첫번째 해시테이블 구현의 기저에 깔린 핵심은 각 데이터 원소가 두개의 리스트 포인터를 가질 수 있는데, 하나는 현재 RCU 읽기 쓰레드들 (과 non-RCU 업데이트 쓰레드들)에 의해 사용되는 것이고 다른 하나는 크기가 재조정된 새로운 해시 테이블을 구성하는데 사용되는 것입니다. 이 방법은 검색, 삽입, 그리고 삭제 작업이 크기 재조정 작업과 동시에 수행될 수 있게 합니다.

크기 조정 오퍼레이션은 Figure 10.13에 보인 최초의




Figure 10.13: Growing a Double-List Hash Table, State (a)




Figure 10.14: Growing a Double-List Hash Table, State (b)

두개 bucket 상태로부터 시작해서 Figures 10.13-10.16에 보인 것처럼 진행되는데, 시간의 흐름에 따라 그림에서 그림으로 이동합니다. 최초의 상태는 원소들을 bucket 안에 연결하기 위해 zero-index 링크를 사용합니다. 네개의 새로운 bucket 배열이 할당되고, one-index 링크들이 원소들을 이 네개의 새로운 bucket 안으로 연결되는데 사용됩니다. 이는 Figure 10.14에 보인 state (b) 상황을 만드는데, 읽기 쓰레드들은 여전히 원래의 두개 bucket 배열을 사용하고 있습니다.

새로운 네개의 bucket 배열은 읽기 쓰레드들에게 노출되고, 모든 읽기 쓰레드들을 기다리기 위해 grace-period를 기다리게 되어서 state (c)에 도달하게 되는데, Figure 10.15에 그 상태가 그려져 있습니다. 이 상태에서, 모든 읽기 쓰레드들은 새로운 네개 bucket 배열을 사용하게 되는데, 이 말은 기존의 두개 bucket 배열은 해제되어도 좋다는 뜻이므로 Figure 10.16에 보여진 state (d)로의 이전을 하게 됩니다.

이 디자인은 상대적으로 간단한 구현을 이끄는데, 이 구현에 대해서는 다음 섹션에서 다룹니다.

10.4.2 Resizable Hash Table Implementation




Figure 10.15: Growing a Double-List Hash Table, State (c)




Figure 10.16: Growing a Double-List Hash Table, State (d)

크기 재조정은 전통적인 우회로 추가 방법으로 이루어지는데, 여기서 이 우회로는 Listing 10.9의 line 12-25에 보이는 ht 구조체입니다. Line 27-30에 보인 hashtable 구조체는 현재의 ht 구조체로의 포인터와 해시 테이블 크기 재조정을 하려는 동시적 시도를 직렬화하는데 사용되는 스핀락만을 담고 있습니다. 전통적인 lock 또는 어토믹 오퍼레이션 기반의 구현을 사용하려 했다면, 이 hashtable 구조체는 성능 측면에서도 확장성 측면에서도 심각한 병목지점이 될 수 있었을 겁니다. 하지만, 크기 재조정 작업은 상대적으로 가끔씩만 이뤄지므로 RCU를 잘 사용해 볼 수 있습니다.

ht 구조체는 line 13의 `->ht_nbuckets` 필드를 통해 해시 테이블의 크기를 나타냅니다. 이 크기는 bucket 배열을 담고 있는 똑같은 구조체 (line 24의 `->ht_bkt[]`)에도 저장되는데 이 크기와 배열 사이의 미스매치를 피하기 위해서입니다. Line 14에서의 `->ht_resize_cur` 필드는 현재 크기 재조정 작업이 진행중이지 않다면 -1이 되고, 크기 조정 작업이 진행 중이라면 line 15의 `->ht_new` 필드로 레퍼런스 될, 새로운 해시 테이블에 추가될 원소의 bucket의 인덱스를 가리키게 됩니다. 진행 중인 크기 조정 작업이 없다면, `->ht_new`는 NULL입니다. 따라서, 크기 조정 작업은 새로운 ht 구조체를 메모리 할당하고 `->ht_new` 포인터로 그것을 레퍼런스 한 후, `->ht_resize_cur`를 기존 테이블의 bucket 들

Listing 10.9: Resizable Hash-Table Data Structures

```

1 struct ht_elem {
2     struct rcu_head rh;
3     struct cds_list_head hte_next[2];
4     unsigned long hte_hash;
5 };
6
7 struct ht_bucket {
8     struct cds_list_head ht_b_head;
9     spinlock_t ht_b_lock;
10 };
11
12 struct ht {
13     long ht_nbuckets;
14     long ht_resize_cur;
15     struct ht *ht_new;
16     int ht_idx;
17     void *ht_hash_private;
18     int (*ht_cmp)(void *hash_private,
19                     struct ht_elem *htep,
20                     void *key);
21     long (*ht_gethash)(void *hash_private, void *key);
22     void *(*ht_getkey)(struct ht_elem *htep);
23     struct ht_bucket ht_bkt[0];
24 };
25
26 struct hashtable {
27     struct ht *ht_cur;
28     spinlock_t ht_lock;
29 };

```

을 거쳐 증가시켜갑니다. 새로운 테이블에 모든 원소가 추가되었다면, 새로운 테이블은 hashtable 구조체의 `->ht_cur` 필드로 연결됩니다. 기존의 읽기 쓰레드들이 모두 완료되면, 기존의 해시 테이블의 ht 구조체는 메모리에서 해제될 수 있을 겁니다.

Line 16에 있는 `->ht_idx` 필드는 이 두개의 리스트 포인터들 중 이 해시 테이블을 통해 무엇이 사용되고 있는가를 알리고, line 3의 ht_elem 구조체의 `->hte_next[]` 배열의 인덱스로 사용됩니다.

Line 17-23의 `->ht_hash_private`, `->ht_cmp()`, `->ht_gethash()`, 그리고 `->ht_getkey()` 필드는 원소 별 키와 해시 함수를 정의합니다. `->ht_hash_private`은 해시 함수가 혼란스러울 수 있게 해서 [McK90b, McK90a, McK91] 해시 함수에 사용되는 패러미터들에 대한 통계적 추측을 기반으로 하는 denial-of-service 공격을 막는데 사용될 수 있게 합니다. `->ht_cmp()` 함수는 특정 키를 특정 원소와 비교하고, `ht_gethash()`는 특정 키의 해시를 계산하며, `->ht_getkey()`는 키를 감싸고 있는 데이터 원소로부터 키를 꺼낼 수 있게 합니다.

ht_bucket 구조체는 앞에서와 동일하고, ht_elem 구조체는 앞에서의 하나의 리스트 포인터와 달리 두 개의 리스트 포인터의 원소 배열을 제공한다는 점만 다릅니다.

고정크기 해시 테이블에서의 bucket 선택은 상당히 간단합니다: 단순히 해시 값을 연관된 bucket 인덱스로 변환하면 됩니다. 반면에, 크기 조정이 진행되는 중이라

Listing 10.10: Resizable Hash-Table Bucket Selection

```

1 static struct ht_bucket *
2 ht_get_bucket_single(struct ht *htp, void *key, long *b)
3 {
4     *b = htp->ht_gethash(htp->ht_hash_private,
5                           key) % htp->ht_nbuckets;
6     return &htp->ht_bkt[*b];
7 }
8
9 static struct ht_bucket *
10 ht_get_bucket(struct ht **htp, void *key, long *b, int *i)
11 {
12     struct ht_bucket *htbp;
13
14     htp = ht_get_bucket_single(*htp, key, b);
15     if (*b <= (*htp)->ht_resize_cur) {
16         smp_mb();
17         *htp = (*htp)->ht_new;
18         htp = ht_get_bucket_single(*htp, key, b);
19     }
20     if (*i)
21         *i = (*htp)->ht_idx;
22     return htp;
23 }

```

면, 과거의 bucket 과 새로운 bucket 중 무엇을 선택할지 결정해야 합니다. 만약 과거 테이블에서 선택될 수 있는 bucket 이 이미 새로운 테이블에 분산되었다면, 새로운 테이블에서의 bucket 이 선택되어야 합니다. 거꾸로, 과거 테이블에서 선택될 수 있는 bucket 이 아직 분산되지 않았다면, 그 bucket 은 과거 테이블에서 선택되어야 합니다.

Bucket 선택은 Listing 10.10 에 ht_get_bucket_single() 을 line 1-8 에, 그리고 ht_get_bucket() 을 line 10-24 에 보이고 있습니다. ht_get_bucket_single() 함수는 특정 해시 테이블의 특정 키에 연관된 bucket 으로의 레퍼런스를 리턴하는데, 이때에는 크기 재조정을 고려하지 않습니다. 또한 해당 키에 연관된 해시 값을 line 5 와 6 에서 패러미터 b 로 레퍼런스되는 영역에 저장합니다. 그리고 나서 line 7 은 연관된 bucket 으로의 레퍼런스를 리턴합니다.

ht_get_bucket() 함수는 해시 테이블 선택을 처리하는데, line 16 에서 ht_get_bucket_single() 을 호출해서 현재 해시 테이블에서 해시 값에 연관된 bucket 을 선택하는데, 이 해시 값은 패러미터 b 에 저장됩니다. Line 17 에서 이 테이블이 크기 재조정 중이고 line 16 의 bucket 이 이미 새로운 해시 테이블로 분산되었다는 점을 알게 되면, line 18 에서 새 해시 테이블을 선택하고 line 19 에서 이 새로운 해시 테이블에서의 해시 값에 연관된 bucket 을 선택하고, 이때에도 해시 값은 패러미터 b 에 저장합니다.

Quick Quiz 10.7: Listing 10.10 의 코드는 해시 값을 두번 계산하네요! 왜 이렇게 비효율적이죠? ■

Line 21 에서 패러미터 i 가 NULL 이 아니란 걸 알게 되면, line 22 에서 선택된 해시 테이블로의 인덱스를 저장합니다. 마지막으로, line 23 에서는 선택된 해시

Listing 10.11: Resizable Hash-Table Update-Side Concurrency Control

```

1 static void
2 hashtab_lock_mod(struct hashtab *htp_master, void *key)
3 {
4     long b;
5     struct ht *htp;
6     struct ht_bucket *htbp;
7     struct ht_bucket *htbp_new;
8
9     rcu_read_lock();
10    htp = rcu_dereference(htp_master->ht_cur);
11    htp = ht_get_bucket_single(htp, key, &b);
12    spin_lock(&htbp->htb_lock);
13    if (b > htp->ht_resize_cur)
14        return;
15    htp = htp->ht_new;
16    htp_new = ht_get_bucket_single(htp, key, &b);
17    spin_lock(&htbp_new->htb_lock);
18    spin_unlock(&htbp->htb_lock);
19 }
20
21 static void
22 hashtab_unlock_mod(struct hashtab *htp_master, void *key)
23 {
24     long b;
25     struct ht *htp;
26     struct ht_bucket *htbp;
27
28     htp = rcu_dereference(htp_master->ht_cur);
29     htp = ht_get_bucket(&htp, key, &b, NULL);
30     spin_unlock(&htbp->htb_lock);
31     rcu_read_unlock();
32 }

```

bucket 으로의 레퍼런스를 리턴합니다.

Quick Quiz 10.8: Listing 10.10 의 코드는 선택된 bucket 에서 진행중일 수도 있는 크기 재조정 프로세스로부터의 보호는 어떻게 하나요? ■

이와 같은 ht_get_bucket_single() 와 ht_get_bucket() 의 구현은 크기 재조정 작업과 동시에 탐색과 수정이 가능하게 할 겁니다.

Read-side 동시성 제어는 Listing 10.6 에서 보인 것처럼 RCU 로 제공됩니다만, update-side 동시성 제어 함수인 hashtab_lock_mod() 와 hashtab_unlock_mod() 는 Listing 10.11 에 보인 것처럼 동시적인 크기 재조정 오퍼레이션의 존재 가능성을 처리해야 합니다.

이 일람표의 line 1-19 에 hashtab_lock_mod() 가 있습니다. Line 9 는 데이터 구조가 획득을 하는 도중에 해제되는 일을 막기 위해 RCU read-side 크리티컬 섹션에 들어가고, line 10 에서 현재 해시 테이블로의 레퍼런스를 얻어온 후, line 11 에서 이 해시 테이블에서 현재 키에 연관되는 bucket 으로의 레퍼런스를 얻어옵니다. Line 12 는 이 bucket 의 락을 획득하는데, 이 락은 동시에의 크기 재조정 오퍼레이션이 그 bucket 을 분산시키는 것을 막는데, 물론 크기 재조정 오퍼레이션이 이미 이 bucket 을 분산시켰다면 아무 영향이 없을 것임에도 불구하고 그렇습니다. Line 13 에서는 동시에의 크기 재조정 오퍼레이션이 이미 이 bucket 을 새 해시 테이블에

분산시켰는지 확인해보고, 그렇지 않다면 line 14에서 선택된 bucket의 락을 잡은채로 (그리고 RCU read-side 크리티컬 섹션 안에 들어와 있는 채로) 리턴합니다.

그렇지 않다면, 동시의 크기 재조정 오퍼레이션이 이미 이 bucket을 분산시킨 것이므로, line 15에서 새로운 해시 테이블로 넘어가고 line 16에서 키에 연관되는 bucket을 선택합니다. 마지막으로, line 17에서 해당 bucket의 락을 잡고 line 18에서 기존 해시 테이블의 bucket을 위한 락을 놓아줍니다. 다시 한번, `hashtab_lock_mod()`는 RCU read-side 크리티컬 섹션 안에 들어와 있는 채로 빠져나가집니다.

Quick Quiz 10.9: Listing 10.10 와 10.11 의 코드는 업데이트를 위해 해시 값을 계산하고 bucket 선택 로직을 두번 수행하네요! 왜 이렇게 비효율적인거죠? ■

`hashtab_unlock_mod()` 함수는 `hashtab_lock_mod()`로 잡아 두었던 락을 놓아줍니다. Line 28에서 현재 해시 테이블을 고르고, line 29에서 키에 연관된 bucket—당연히 이 bucket은 새로운 해시 테이블에 속해 있을 수도 있습니다—의 레퍼런스를 증가시키기 위해 `ht_get_bucket()`을 수행합니다. Line 30은 이 bucket의 락을 놓고 마지막으로 line 31에서 RCU read-side 크리티컬 섹션을 빠져나갑니다.

Quick Quiz 10.10: 크기 재조정 작업이 이루어지는 사이에 한 쓰레드가 새로운 해시 테이블에 원소를 넣는다고 생각해 봅시다. 뒤따르는 크기 재조정 작업이 이 삽입 작업 전에 완료됨으로 인해 이 삽입 작업이 없던 것처럼 되어버리는 문제는 어떻게 방지되고 있나요? ■

이제 bucket 선택과 동시성 제어를 다뤘으니, 이 크기 재조정 가능한 해시 테이블의 탐색과 업데이트를 할 준비가 되었습니다. `hashtab_lookup()`, `hashtab_add()`, 그리고 `hashtab_del()` 함수들이 Listing 10.12에 보여져 있습니다.

이 그림의 line 1-21의 `hashtab_lookup()` 함수는 탐색을 합니다. Line 11에서는 현재 해시 테이블을 가져오고 line 12에서 특정 키에 연관된 bucket으로의 레퍼런스를 얻어옵니다. 이 bucket은 크기 재조정 오퍼레이션이 원하는 데이터 원소를 담고 있는 예전 해시 테이블의 bucket에서 진행되었을 때에는 새로운 크기 재조정된 해시 테이블에 위치해 있을 겁니다. Line 12는 또한 각 원소의 포인터 쌍들 중 올바른 것을 고르기 위한 인덱스 역시 리턴한다는 점을 알아 두세요. Line 13-19의 루프는 bucket 내부를 탐색하는데, line 16에서는 매치되는지를 판단하고, line 18에서 데이터 원소로의 포인터를 리턴하는데, 매치되지 않는다면 line 20에서 실패를 알리는 NULL을 리턴합니다.

Quick Quiz 10.11: Listing 10.12의 `hashtab_lookup()` 함수에서, 코드는 탐색될 원소가 이미 동시의 크기 재조정 작업에 의해 분산되었다면 새로운 해시 테이블에 있는 올바른 bucket을 찾아옵니다. 이건 RCU로

Listing 10.12: Resizable Hash-Table Access Functions

```

1 struct ht_elem *
2 hashtab_lookup(struct hashtab *htp_master, void *key)
3 {
4     long b;
5     int i;
6     struct ht *htp;
7     struct ht_elem *htep;
8     struct ht_bucket *htbp;
9
10    htp = rcu_dereference(htp_master->ht_cur);
11    htp = ht_get_bucket(&htp, key, &b, &i);
12    cds_list_for_each_entry_rcu(htep,
13                                &htbp->htb_head,
14                                hte_next[i]) {
15        if (htp->ht_cmp(htp->ht_hash_private, htep, key))
16            return htep;
17    }
18    return NULL;
19 }
20
21 void hashtab_add(struct hashtab *htp_master,
22                   struct ht_elem *htep)
23 {
24     long b;
25     int i;
26     struct ht *htp;
27     struct ht_bucket *htbp;
28
29     htp = rcu_dereference(htp_master->ht_cur);
30     htp = ht_get_bucket(&htp, htp->ht_getkey(htep), &b, &i);
31     cds_list_add_rcu(&htep->hte_next[i], &htbp->htb_head);
32 }
33
34 void hashtab_del(struct hashtab *htp_master,
35                   struct ht_elem *htep)
36 {
37     long b;
38     int i;
39     struct ht *htp;
40
41     htp = rcu_dereference(htp_master->ht_cur);
42     (void)ht_get_bucket(&htp, htp->ht_getkey(htep), &b, &i);
43     cds_list_del_rcu(&htep->hte_next[i]);
44 }

```

보호되는 탐색에서는 좀 낭비가 있는 것 같은데요. 이 경우에는 왜 그냥 기존 해시 테이블에서 작업을 끝내지 않는 거죠? ■

그림의 line 23-37의 `hashtab_add()` 함수는 해시 테이블에 새로운 데이터 원소를 넣습니다. Line 32-34는 앞에서와 같이 키에 연관되는 bucket으로의 포인터 (그리고 인덱스)를 얻어오고, line 35는 새로운 원소를 테이블에 집어넣습니다. 호출자는 동시성을 잘 제어할 것이 요구되는데, 예를 들어 `hashtab_add()` 호출 전에 `hashtab_lock_mod()`를 호출하고, 후에 `hashtab_unlock_mod()`를 호출해야 하는 것 등입니다. 이런 두 개의 동시성 제어 함수들은 동시의 크기 재조정 작업들과 올바르게 순서를 맞출 겁니다: 만약 이 크기 재조정 작업이 이 데이터 원소가 넣어질 bucket에 대해서 이미 진행되었다면, 이 원소는 새로운 테이블에 추가될 겁니다.

그림의 line 39-52의 `hashtab_del()` 함수는 해시

테이블에서 존재하는 원소를 하나 제거합니다. Line 48-50에서는 앞에서와 같이 bucket과 인덱스를 제공하고, line 51에서 특정 원소를 제거합니다. `hashtab_add()`에서와 같이, 호출자는 동시성 제어를 할 책임을 갖게 되고 이 동시성 제어는 동시의 크기 재조정 작업과의 동기화를 처리합니다.

Quick Quiz 10.12: Listing 10.12의 `hashtab_del()` 함수는 원소를 항상 기존 해시 테이블에서 제거하지는 않는데요. 이 말은 읽기 쓰레드들이 이 새로 제거된 원소를 해제된 후에도 볼 수 있다는 의미 아닌가요? ■

실제로 자신의 크기를 재조정하는 일은 `hashtab_resize`로 수행되는데, page 170의 Listing 10.13에 보여져 있습니다. Line 17은 가장 높은 레벨의 `->ht_lock`을 조건적으로 얻어오는데, 만약 락을 잡는데 실패했다면 line 18에서 크기 재조정이 이미 진행중임을 알리기 위해 `-EBUSY`를 리턴합니다. 그렇지 않다면, line 19에서 현재 해시 테이블로의 레퍼런스를 가져오고, line 20-24에서 원하는 크기의 새로운 해시 테이블을 할당받습니다. 새로운 hash/key 함수들이 명시된다면, 이것들이 새로운 테이블을 위해 사용되고, 그렇지 않다면 기존 테이블의 것들을 사용합니다. Line 25에서 메모리 할당 실패를 확인하게 된다면 line 26에서 `->ht_lock`을 놓고 line 27에서 실패했음을 알리는 값을 반환합니다.

Line 29는 bucket 분산 프로세스를 새로운 해시 테이블로의 레퍼런스를 기존 테이블의 `->ht_new`에 넣음으로써 시작합니다. Line 30에서는 새로운 테이블의 존재를 알지 못하는 모든 읽기 쓰레드들이 크기 재조정 작업이 진행되기 전에 완료될 것을 보장합니다. Line 31에서는 현재 테이블의 인덱스를 얻어오고 그 역을 새로운 해시 테이블에 저장함으로써 두개의 해시 테이블이 서로의 링크드 리스트를 덮어쓰는 것을 막는 것을 보장합니다.

Line 33-44의 루프의 각 패스에서는 기존 해시 테이블의 bucket의 내용물 중 하나를 새로운 해시 테이블로 옮깁니다. Line 34에서는 기존 테이블의 현재 bucket으로의 레퍼런스를 가져오고, line 35에서 해당 bucket의 스픬락을 잡습니다.

Quick Quiz 10.13: Listing 10.12의 `hashtab_resize()` 함수에서, line 29에서의 `->ht_new`로의 업데이트가 line 36에서의 `->ht_resize_cur`로의 업데이트 전에 일어난 것으로 `hashtab_lookup()`, `hashtab_add()`, 그리고 `hashtab_del()`의 관점에 보일 것을 무엇이 보장하죠? ■

Line 37-42의 루프의 각 패스에서는 데이터 원소 하나를 현재의 기존 테이블의 bucket에서 연관된 새로운 테이블의 bucket으로 옮기는는데, 이 때 새로운 테이블의 bucket의 락을 잡고 있습니다. Line 42는 이 bucket이 분산되었다는 것을, 그리고 Listing 10.10에 보인 `ht_get_bucket()`의 결과 짹을 맞추는 전체 메모리 배리어에




Figure 10.17: Overhead of Resizing Hash Tables

의해 진행된다는 것을 알리기 위해 `->ht_resize_cur`를 업데이트 합니다. 마지막으로, line 43에서는 기존 테이블 bucket의 락을 놓게 됩니다.

Quick Quiz 10.14: Listing 10.10의 `ht_get_bucket()`과 Listing 10.13의 `hashtab_resize()`의 메모리 배리어는 왜 존재하는 건가요? ■

일단 모든 기존 테이블의 bucket들이 새로운 테이블로 분산되면 line 45가 수행됩니다. Line 45는 새로운 테이블을 현재의 것으로 보이게 만들고, line 46에서는 (여전히 기존 테이블을 레퍼런스하고 있을) 기존 읽기 쓰레드들이 완료되기를 기다립니다. 그리고 나서 line 47에서는 크기 재조정 직렬화 락을 놓고, line 48에서 기존 hash table을 해제하고, line 48에서 마침내 성공했음을 리턴합니다.

10.4.3 Resizable Hash Table Discussion

Figure 10.17는 크기 재조정 해시 테이블을 고정 크기 버전과 2048, 16,384, 그리고 131,072 개 원소를 가졌을 때에 대해 비교해 본 결과입니다. 이 그림은 각 원소 수마다 세개씩의 선을 보여주는데, 하나는 고정크기 1024-bucket 해시 테이블의 것이고, 하나는 고정크기 2048-bucket 해시 테이블, 나머지 하나는 1024 개와 2048 개 bucket 사이를 오갈 수 있는 크기 재조정 가능한 해시 테이블 버전으로, 각각의 크기 재조정 작업 사이에는 1밀리세컨드를 멈춥니다.

가장 위의 세개의 선들은 2048 개 원소의 해시 테이블의 것입니다. 위쪽 선은 2048개 bucket을 사용하는 고정 크기 해시 테이블의 것이고, 중간의 것은 1024개 bucket을 사용하는 고정크기 해시 테이블, 그리고 아래의 것은 크기 재조정 가능한 해시 테이블입니다. 이 경우, 짧은 해시 체인들이 평범한 탐색 오버헤드를 매우 낮게 만들어서 크기 재조정 오버헤드가 지배적이게

Listing 10.13: Resizable Hash-Table Resizing

```

1 int hashtab_resize(struct hashtab *htp_master,
2                     unsigned long nbuckets, void *hash_private,
3                     int (*cmp)(void *hash_private, struct ht_elem *htep, void *key),
4                     long (*gethash)(void *hash_private, void *key),
5                     void *(*getkey)(struct ht_elem *htep))
6 {
7     struct ht *htp;
8     struct ht *htp_new;
9     int i;
10    int idx;
11    struct ht_elem *htep;
12    struct ht_bucket *htbp;
13    struct ht_bucket *htbp_new;
14    long b;
15
16    if (!spin_trylock(&htp_master->ht_lock))
17        return -EBUSY;
18    htp = htp_master->ht_cur;
19    htp_new = ht_alloc(nbuckets,
20                      hash_private ? hash_private : htp->ht_hash_private,
21                      cmp ? cmp : htp->ht_cmp,
22                      gethash ? gethash : htp->ht_gethash,
23                      getkey ? getkey : htp->ht_getkey);
24    if (htp_new == NULL) {
25        spin_unlock(&htp_master->ht_lock);
26        return -ENOMEM;
27    }
28    htp->ht_new = htp_new;
29    synchronize_rcu();
30    idx = htp->ht_idx;
31    htp_new->ht_idx = !idx;
32    for (i = 0; i < htp->ht_nbuckets; i++) {
33        htbp = &htp->ht_bkt[i];
34        spin_lock(&htbp->htb_lock);
35        cds_list_for_each_entry(htep, &htbp->htb_head, hte_next[idx]) {
36            htbp_new = ht_get_bucket_single(htp_new, htp_new->ht_getkey(htep), &b);
37            spin_lock(&htbp_new->htb_lock);
38            cds_list_add_rcu(&htep->hte_next[!idx], &htbp_new->htb_head);
39            spin_unlock(&htbp_new->htb_lock);
40        }
41        smp_mb();
42        htp->ht_resize_cur = i;
43        spin_unlock(&htbp->htb_lock);
44    }
45    rcu_assign_pointer(htp_master->ht_cur, htp_new);
46    synchronize_rcu();
47    spin_unlock(&htp_master->ht_lock);
48    free(htp);
49    return 0;
50 }

```

만들었습니다. 하지만, 더 큰 고정 크기 해시 테이블이 분명한 성능 이득을 가졌으므로, 크기 재조정 작업 사이에 충분한 시간이 주어진다면 크기 재조정이 상당한 이득을 보일 겁니다: 1 밀리세컨드는 분명 너무 짧은 시간입니다.

중간의 세개 선들은 16,384 개 원소를 가진 해시 테이블의 결과입니다. 이번에도 위쪽의 선은 2048개 bucket 을 가진 고정 크기 해시 테이블을 위한 것입니다만, 중간의 선은 크기 재조정 해시 테이블의 것이고 아래의 것은 1024개 bucket 의 고정 크기 해시 테이블입니다. 하지만, 크기 재조정 버전과 1024개 bucket 버전 해시 테이블 사이의 성능 차이는 상당히 적은 것을 볼 수 있습니다. 원소의 수를 (따라서 해시 체인의 길이도) 8배로 증가시

켜본 실험의 결과 중 하나는, 끊임없는 크기 재조정은 이제 너무 작은 해시 테이블을 유지하는 것보다 더 나쁘지는 않다는 것입니다.

아래쪽의 세개 선은 131,072 원소를 갖는 해시 테이블입니다. 위쪽 선은 2048 개 bucket 의 고정 크기 해시 테이블이고, 중간의 것은 크기 재조정 가능 해시 테이블, 그리고 아래의 것은 1024개 bucket 사용 해시 테이블입니다. 이 경우, 더 길어진 해시체인은 높은 탐색 오버헤드를 가져왔고, 따라서 이 탐색 오버헤드가 해시 테이블의 크기 재조정을 넘어섰습니다. 하지만, 세개 해시 테이블 모두 131,072 원소 성능 수준은 2048개 원소에서의 수준보다 10배 이상 나빠졌는데, 이는 해시 테이블 크기를 64배 늘리는 것이 최고의 방법일 것임을

의미합니다.

이 데이터의 핵심은 RCU로 보호되는 크기 재조정 가능한 해시 테이블은 고정 크기 버전 만큼이나 성능을 보이고 확장될 수 있다는 겁니다. 실제 크기 재조정 작업 동안의 성능은 물론 안좋은데, 각 원소의 포인터들에의 업데이트가 일으키는 캐시 미스 때문일 것이고 이 영향은 해시 테이블 bucket 리스트가 짧을 때 두드러질 것입니다. 이는 해시 테이블은 상당한 크기에서 크기 재조정되어야 하고 너무 빈번한 크기 재조정 작업으로 인한 성능 저하를 막기 위해 기록에 따른 조정(hysteresis)을 가져야 할겁니다. 메모리가 충분히 큰 환경이라면, 해시 테이블 크기는 줄어들기보다는 더 공격적으로 증가될 수 있을 겁니다.

또 다른 중요한 점은 hashtable 구조체가 분할될 수는 없지만 이것도 읽기가 대부분이므로 RCU를 사용해 볼만 합니다. 이 크기 재조정 가능한 해시 테이블의 성능과 확장성이 RCU로 보호되는 고정크기 해시 테이블에 근접한다는 점을 놓고 보면, 이 방법이 상당히 성공적이라고 결론내릴 수 있을 겁니다.

마지막으로, 삽입, 삭제, 그리고 탐색은 크기 재조정 작업과 동시에 이뤄질 수 있다는 점이 중요합니다. 이 동시성은 커다란 해시 테이블을 크기 재조정할 때 매우 중요한데, 특히 상당한 응답시간 제약을 가진 어플리케이션에서 그려합니다.

물론, `ht_elem` 구조체의 포인터 집합 쌍은 약간의 메모리 오버헤드를 내포하는데, 이에 대해서는 다음 섹션에서 이야기 합니다.

10.4.4 Other Resizable Hash Tables

이 섹션의 앞에서 이야기한 크기 재조정 가능한 해시 테이블의 한계 중 하나는 메모리 사용량입니다. 각각의 데이터 원소는 한개가 아니라 두개의 링크드 리스트 포인터 쌍을 가지고 있습니다. 하나의 쌍만 가지고 일을 해낼 수 있으며 RCU로 보호되는 크기 재조정 가능한 해시 테이블을 만들 수는 없는 걸까요?

그에 대한 답은 “가능하다”로 드러났습니다. Josh Triplett 등은 연관된 해시 체인을 점진적으로 쪼개고 조합해서 읽기 쓰레드들은 크기 재조정 작업 중간의 모든 순간에 올바른 해시 체인을 바라보게 되는 상대론적 해시 테이블 [TMW11]을 만들었습니다. 이 점진적인 쪼개기와 조합하기는 읽기 쓰레드들이 다른 해시 체인에 있어야 하는 데이터 원소를 보게 되는 것은 문제가 되지 않는다는 사실에 기인합니다: 이런 일이 일어난다면, 읽기 쓰레드는 키가 맞지 않으므로 해당 데이터 원소를 무시해 버리게 됩니다.

상대론적 해시 테이블을 절반으로 축소시키는 과정이 Figure 10.18에 그려져 있는데, 이 경우에는 두개의 bucket을 가지고 있는 해시 테이블을 한개 bucket의




Figure 10.18: Shrinking a Relativistic Hash Table

해시 테이블, 달리 말해 하나의 선형 리스트로 축소시키고 있습니다. 이 과정은 기존의 커다란 해시 테이블의 한쌍의 bucket들을 새로운 작은 해시 테이블의 하나의 bucket으로 합치는 것으로 동작합니다. 이 프로세스가 잘 동작하려면, 두 테이블의 해시 함수에 대해 제약을 걸어야 하는 것이 분명합니다. 그런 제약 가운데 하나는 두 테이블 모두 같은 해시 함수를 사용해야 하지만, 큰 테이블에서 작은 테이블로 축소시킬 때에는 뒤쪽의 비트 하나는 버려야 한다는 것입니다. 예를 들어, 기존의 두개 bucket을 사용하는 해시 테이블은 값의 두개의 꼭대기 비트를 사용하는 반면, 새로운 한개 bucket의 해시 테이블은 그 값의 꼭대기 비트 하나를 사용할 겁니다. 이런 방식으로, 기존의 커다란 테이블의 인접한 짹수와 훌수 bucket들은 새로운 작은 해시 테이블의 하나의 bucket으로 합쳐질 수 있고, 그동안 하나의 해시 값이 하나의 bucket의 원소들을 다룰 수 있습니다.

최초의 상태가 그림의 꼭대기에 보여져 있는데, 아래쪽으로 갈수록 시간이 흐르게 되고, 최초의 상황 (a)에서 시작합니다. 축소 과정은 새로운, bucket들의 더 작은 배열을 할당하는 것으로 시작하고, 이 새로운 작은

배열의 각각의 bucket 이 기존의 커다란 해시 테이블의 연관된 bucket 들 중 하나의 첫번째 원소를 레퍼런스하도록 해서 상황 (b)가 되게 합니다.

이제 두개의 해시 체인들은 함께 연결되어서 상태 (c)가 됩니다. 이 상태에서, 짹수로 해시값의 원소를 보는 읽기 쓰레드들은 아무 변화도 보지 못하게 되고, 원소 1과 3 을 보는 읽기 쓰레드들은 역시 변화를 보지 못합니다. 하지만, 그와 다른 홀수 해시값의 원소를 찾는 읽기 쓰레드들은 원소 0 과 2 도 지나가게 될겁니다. 어떤 홀수 해시값도 이 두개의 원소들과 같지 않을것으로 이는 문제가 되지 않습니다. 이로 인한 약간의 성능 저하가 있지만, 반면에, 이는 새로운 작은 해시 테이블이 자리를 잡게 되면 겪게 될 성능 저하와 완전히 똑같은 정도입니다.

다음으로, 새로운 작은 해시 테이블은 읽기 쓰레드들에게 접근 가능하게 되어서 state (d) 가 됩니다. 오래된 읽기 쓰레드들은 여전히 기존의 커다란 해시 테이블을 횡단하고 있을 수 있으므로, 이 상태는 두개의 해시 테이블을 모두 사용중인 것으로 합니다.

다음 할 일은 모든 기존부터 존재한 읽기 쓰레드들이 완료되길 기다리는 것으로, state (e) 에 도달하게 됩니다. 이 상태에서, 모든 읽기 쓰레드들은 새로운 작은 해시 테이블을 사용하고 있으므로, 기존의 커다란 해시 테이블의 bucket 들은 해제될 수 있어서, 마지막 상태 (f)로 이르게 됩니다.

상대론적 해시 테이블의 크기를 키우는 건 축소 프로세스의 거꾸로입니다만, 더 많은 grace-period 단계를 필요로하게 되는데, Figure 10.19 에 그려져 있습니다. 최소 상태 (a) 가 그림의 맨 꼭대기에 있고, 시간에 따라 아래 방향으로 진행됩니다.

새로운 커다란 두개의 bucket 을 사용하는 해시 테이블을 할당하는 것으로 시작해서, state (b)로 이르게 됩니다. 이 새로운 bucket들 각각은 그 bucket 을 향하게 될 첫번째 원소를 레퍼런스함을 알아두세요. 이 새로운 bucket 들은 읽기 쓰레드들에게 공개되고, 이로 인해 state (c)로 이릅니다. 하나의 grace-period 가 지나고, 모든 읽기 쓰레드들은 새로운 커다란 해시 테이블을 사용하게 되어서 state (d) 에 이릅니다. 이 상태에서, 짹수 해시값의 원소를 찾는 읽기 쓰레드들만이 하얀 색으로 칠해진 원소 0 을 경유하게 됩니다.

이 시점에서, 기존의 작은 해시 bucket 들은 해제될 수 있지만, 많은 구현들은 아이템들의 리스트를 새로운 bucket 으로 “풀어 놓는” 작업의 진도 상황을 보기 위해 이 기존 bucket 들을 사용하고는 합니다. 그런 원소들의 첫번째 연속적 수행에서의 마지막 짹수 해시값 원소는 다음으로의 포인터가 다음의 짹수 해시값 원소를 가리키도록 업데이트 됩니다. 다음 grace priod 후에는, 상태 (e) 가 됩니다. 수직의 화살표는 다음으로 풀리게 될 원소를 가리키고, 원소 1 은 이제 홀수 해시값의 원소




Figure 10.19: Growing a Relativistic Hash Table

를 찾는 읽기 쓰레드들만이 다다르게 될 것을 가리키기 위해 검정색으로 칠해져 있습니다.

다음으로, 그런 원소들의 첫번째 연속적 수행에서의 마지막 홀수 해시값 원소가 다음 원소로의 포인터를 다음의 홀수 해시값 원소를 가리키도록 업데이트 합니다. 다음의 grace period 가 지난후, 상태 (f)로 다다릅니다. 마지막 풀어놓기 오퍼레이션 (하나의 grace priod 를 포함해서)은 마지막 상태 (g)로 이르게 합니다.

짧게 말해서, 상대론적 해시 테이블은 원소별 리스트 포인터의 수를 크기 재조정 동안 일어나는 추가적인 grace period 의 비용으로 대신합니다. 삽입, 삭제, 그리고 탐색은 크기 재조정 작업과 동시에 이루어질 수 있으므로, 이런 추가적인 grace period 들은 일반적으로 문제가 되지 않습니다.

원소별 메모리 오버헤드가 한쌍의 포인터에서 하나의 포인터로 줄어들 수 있으면서도 여전히 $O(1)$ 삭제를 유지할 수 있음이 드러났습니다. 이는 split-order 리스트

트 [SS06] 를 RCU 보호로 증강시킴으로써 가능합니다 [Des09b, MDJ13a]. 이런 해시 테이블 안의 데이터 원소는 하나의 정렬된 링크드 리스트로 정렬되고, 각각의 해시 bucket 은 그 bucket 내의 첫번째 원소를 레퍼런스하게 됩니다. 원소들은 다음 원소로의 포인터 필드의 아래쪽 비트를 설정하는 것으로 지워지고, 이 원소들은 그들을 마주하게 되는 나중의 횟단에 의해 리스트에서 제거됩니다.

RCU로 보호되는 이 split-order 리스트는 복잡하지만, lock-free 진행 보장을 모든 삽입, 삭제, 그리고 탐색 작업에 제공합니다. 그런 보장사항은 리얼타임 어플리케이션들에서는 중요할 수 있습니다. 최신 버전의 userspace RCU 라이브러리 [Des09b] 에서 이 구현을 사용할 수 있습니다.

10.5 Other Data Structures

앞의 섹션들은 파티셔닝 가능성 (Section 10.2), 읽기가 대부분인 액세스 패턴의 효과적인 처리 (Section 10.3), 또는 읽기가 대부분인 상황에서의 테크닉을 파티셔닝이 불가능함을 해결하기 위해 적용하기 (Section 10.4)로 동시성을 향상시킨 데이터 구조들에 대해 주목해 보았습니다. 이 섹션은 다른 데이터 구조들에 대해 간략한 리뷰를 합니다.

해시 테이블의 병렬 사용에서의 가장 훌륭한 이점은 완전히 파티셔닝 가능하다는 점인데, 적어도 크기 재조정이 되지 않는 동안은 그렇습니다. 파티셔닝 가능성과 크기 독립성을 둘 다 보호하기 위한 한가지 방법은 trie 라고도 불리는 래딕스 트리(radix tree) 의 사용입니다. Trie 들은 탐색 키를 분할하는데, 각각의 다음 키 부분을 다음 레벨의 trie 를 탐색하도록 사용하는 식입니다. 그렇게 되면, 하나의 trie 는 충첩된 해시 테이블들의 한집합으로 생각될 수 있으므로, 필요한 파티셔닝 가능성을 제공합니다. Trie 들의 한가지 단점은 드문드문한 키 스페이스는 메모리의 비효율적인 사용을 초래할 수 있다는 점입니다. 이런 단점을 보완할 수 있는 몇가지 압축 기법들이 존재하는데, 탐색 전에 키 값을 더 작은 키 스페이스로 해싱을 하는 방법 [ON06] 등이 있습니다. 래딕스 트리는 실제로 많이 사용되는데, 리눅스 커널도 포함됩니다 [Pig06].

해시 테이블과 trie 모두에서의 한가지 중요한 특수 케이스는 아마도 가장 오래된 데이터 구조체인 배열과 차원 배열이라 할 수 있는, 행렬입니다. 완전히 파티셔닝 가능하다는 행렬의 본성은 동시적 수학 알고리즘에서 상당히 많이 활용되었습니다.

스스로 밸런스를 잡는 트리는 순차적 코드에서 상당히 많이 사용되었는데, AVL 트리와 red-black 트리는 아마도 가장 널리 알려진 예일 겁니다 [CLRS01]. AVL 트리를 병렬화 하려 한 기준의 시도들은 복잡하고 그다

지 효율적이지 못했습니다만 [Ell80], 최근의 red-black 트리에서의 작업은 읽기 쓰레드에게 RCU 를 사용하고 읽기와 업데이트를 각각 보호하는데에 해시를 사용한 랙들의 배열¹ 을 사용해서 더 나은 성능과 확장성을 제공합니다 [HW11, HW13]. Red-black 트리는 적극적으로 밸런스 재조정을 수행한다는 사실이 드러났는데, 이는 순차적 프로그램에서는 잘 동작하지만 병렬적 사용에서는 꼭 그렇지만은 않습니다. 그래서 최근의 연구는 RCU로 보호되는 “bonsai tree” 를 만들어냈는데, 이 데이터 구조는 덜 적극적으로 밸런스 재조정을 해서 [CKZ12] 최적의 트리 깊이와 더 효과적인 동시의 업데이트 사이에서 트레이드 오프 합니다.

동시의 스kip 리스트들 역시 RCU 읽기 쓰레드들에게 좋은데, 실제로 RCU 를 사용하는 테크닉의 사용을 초기의 학계에서 선보였습니다 [Pug90].

동시적 double-ended 큐들은 Section 6.1.2 에서 다루었고, 동시적 스택과 큐들은 긴 역사를 가지고 있습니다만 [Tre86], 일반적으로는 인상적인 성능과 확장성을 보이진 못했습니다. 하지만 이것들은 동시성 라이브러리들의 혼란 기능일 뿐입니다 [MDJ13b]. 연구자들은 최근에 스택과 큐의 순서 규칙을 완화시키는 것을 제안했는데 [Sha11], 일부 작업은 완화된 순서 규칙의 큐가 실제로는 엄격한 FIFO 큐보다 더 나은 순서 특성을 실제로 가짐을 보이기도 했습니다 [HKLP12, KLP12, HHK⁺13].

동시적 데이터 구조에 대한 지속적 작업은 놀라운 특성을 가진 기발한 알고리즘들을 만들어낼 것으로 보입니다.

10.6 Micro-Optimization

이 섹션에 보인 데이터 구조들은 간단히 코딩 되었고, 시스템 캐시 구조의 적용도 없었습니다. 또한, 구현들 중 다수가 키에서 해시로의 변환 등의 빈번한 작업들에 함수 포인터를 사용했습니다. 이런 방법은 간단하고 호환성을 높여주지만, 많은 경우에 어느정도 성능을 포기하게 합니다.

뒤의 섹션들에서는 특수화, 메모리 절약, 그리고 하드웨어 고려에 대해 다뤄봅니다. 이 짧은 섹션들이 분명한 이 주제에 대한 전문적 정리된 내용이라고 생각하는 실수를 하지 마세요. 이 내용들은 특정 CPU에서의 최적화에 관해 쓰여진 것이므로 오늘날 흔히 사용되는 CPU 들과는 별개입니다.

¹ 개발자가 공유되지 않는 액세스를 직접 표시하는 소프트웨어 트랜잭션 메모리의 하나의 변종인 swissTM [DFGG11] 으로 가장 해서

10.6.1 Specialization

Section 10.4에 선보여진 크기 재조정 가능한 해시 테이블은 불확실한 탑입의 키를 사용했습니다. 이는 높은 유연성을 가능하게 해서, 어떤 종류의 키도 사용될 수 있게 했습니다만, 또한 함수로의 포인터를 사용한 함수 호출로 인해 상당한 오버헤드를 이끌었습니다. 최신의 하드웨어는 이런 오버헤드를 최소화하기 위해 세련된 브랜치 예측 테크닉을 사용합니다만, 다른 한편으로 실제 세상의 소프트웨어는 오늘날의 커다란 하드웨어 브랜치 예측 테이블로도 수용할 수 없을 만큼 큰 경우가 많습니다. 이는 특히 함수 포인터를 통한 호출의 경우에 그러한데, 이 경우에 브랜치 예측 하드웨어는 브랜치가 취해졌는지 안취해졌는지에 대한 정보에 대해서 포인터를 기록해야 하기 때문입니다.

이 오버헤드는 해시 테이블 구현을 특정 키 탑입과 해시 함수로 특수화 시킴으로써 제거될 수 있습니다. 그렇게 하는 것은 page 166의 Listing 10.9에서 보인 ht 구조체에서 `->ht_cmp()`, `->ht_gethash()`, 그리고 `->ht_getkey()` 함수 포인터들을 제거합니다. 이는 또한 연관된 포인터들을 통한 함수 호출도 제거하는데, 이는 컴파일러가 이 고정된 함수들을 인라인 시킬 수 있게 해서 호출 명령의 오버헤드만이 아니라 인자 관리 오버헤드 역시 제거할 겁니다.

또한, 이 크기 재조정 가능한 해시 테이블은 동시성 제어로부터 bucket 선택을 분리하는 API에 걸맞도록 설계되었습니다. 이는 하나의 테스트가 이 챕터의 모든 해시 테이블의 구현을 테스트할 수 있도록 해주지만, 또한 많은 연산작업들이 해시 값을 계산하고 만들어질 수 있는 크기 재조정 작업과 한번이 아니라 두번 상호작용해야 함을 의미합니다. 성능이 중요한 환경에서라면 `hashtab_lock_mod()` 함수 또한 선택된 bucket으로의 레퍼런스를 리턴해서 이어지는 `ht_get_bucket()` 호출을 제거할 겁니다.

Quick Quiz 10.15: `hashtorture.h`의 코드는 `hashtab_lock_mod()`가 `ht_get_bucket()`의 기능을 포섭하도록 수정될 수 없나요? ■

Quick Quiz 10.16: 이런 특수화는 정말로 얼마나 성능을 구하나요? 이게 정말 가치가 있나요? ■

그렇다고는 해도, 제가 처음 프로그램을 배우기 시작한 1970년대 초반에 사용할 수 있던 것들에 비해 최신 하드웨어의 커다란 장점 중 하나는 그렇게까지나 특수화가 필요하지는 않다는 것입니다. 이는 4킬로바이트 주소공간을 사용하던 시절에 그랬던 것에 비해 훨씬 큰 생산성을 가능하게 합니다.

10.6.2 Bits and Bytes

이 챕터에서 논의한 해시 테이블들은 메모리 절약을 위한 시도는 거의 하지 않고 만들어졌습니다. 예를 들어,

page 166의 Listing 10.9에 있는 ht 구조체의 `->ht_idx` 필드는 항상 0 또는 1의 값을 갖는데도 32비트의 메모리를 모두 가집니다. 이건 예를 들어 `->ht_resize_key` 필드에서 비트 하나를 훔쳐다 사용하는 식으로 제거될 수 있을 겁니다. 이 방법은 `->ht_resize_key` 필드가 메모리의 모든 바이트를 가리킬 수 있을 만큼 커다랗고 ht_bucket 구조체는 1바이트보다 크기 때문에 `->ht_resize_key` 필드는 몇 비트는 아낄 수 있을 것이기 때문에 동작 가능합니다.

이런 부류의 bit-packing 트릭은 리눅스에서의 page 구조체와 같이 많이 복제되는 데이터 구조체들에서 빈번하게 사용됩니다. 하지만, 이 크기 재조정 가능한 해시 테이블의 ht 구조체는 그렇게까지 많이 복제되지는 않습니다. 대신에 우리가 집중해야 할 것은 ht_bucket 구조체입니다. ht_bucket 구조체의 크기를 줄일 수 있는 두개의 커다란 기회가 존재합니다: (1) `->htb_lock` 필드를 `->htb_head` 포인터들 중 하나의 아래쪽 비트에 위치시키는 것과 (2) 필요한 포인터들의 갯수를 줄이는 것입니다.

첫번째 기회는 `include/linux/bit_spinlock.h`로 제공되는 리눅스 커널의 비트 스피너를 사용할 수도 있을 겁니다. 이것들은 리눅스 커널의 공간 크기에 민감한 데이터 구조체들에 사용됩니다만 그 단점도 존재합니다:

1. 기존의 스피너 기능들에 비해 상당히 느립니다.
2. 리눅스 커널의 데드락 파악 도구인 lockdep [Cor06a]과 함께 사용될 수 없습니다.
3. 락 소유권을 기록하지 않아서 디버깅을 복잡하게 만듭니다.
4. -rt 커널에서 우선권 상승 기능과 함께 동작하지 않는데, 이는 비트 스피너를 잡을 때에는 preemption 기능이 꺼져야 해서 리얼타임 대기시간을 나쁘게 만들 수 있습니다.

이런 단점들에도 불구하고, 비트 스피너은 메모리가 가장 중요할 때에 상당히 유용합니다.

두번째 기회에 대한 한가지 측면은 Section 10.4.4에서 다루어졌는데, Section 10.4에서 보여진 크기 재조정 가능 해시 테이블에서는 두개의 집합이 필요했던 자리에 한개의 bucket 리스트 포인터 집합만을 필요로 했습니다. 또 다른 방법은 이 챕터에서 사용된 양방향 링크드 리스트 대신에 단방향으로 링크된 bucket 리스트를 사용하는 것입니다. 이 방법의 한가지 단점은 삭제 작업이 추가적 오버헤드를 가져오게 될 것인데, 차후의 삭제를 위한 바깥으로 향하는 포인터를 마크하거나 삭제될 원소를 위해 bucket 리스트를 탐색하는 작업으로 인한 오버헤드가 될 것입니다.

Listing 10.14: Alignment for 64-Byte Cache Lines

```

1 struct hash_elem {
2     struct ht_elem e;
3     long __attribute__((aligned(64))) counter;
4 };

```

요약해서, 최소한의 메모리 오버헤드와 성능과 단순성 사이에는 트레이드오프가 존재합니다. 다행히도, 최신 시스템에서 사용 가능한 비교적 커다란 메모리들은 성능과 단순성을 메모리 오버헤드보다 우선시 할 수 있도록 해줍니다. 하지만, 오늘날의 커다란 메모리 시스템들에서도² 가끔은 메모리 오버헤드를 줄이기 위한 극단적인 조사가 필요합니다.

10.6.3 Hardware Considerations

최신 컴퓨터들은 일반적으로 CPU 와 메인 메모리 사이에서 데이터를 32바이트에서 256바이트 사이의 고정된 크기의 블록으로 읽습니다. 이 블록은 캐시 라인이라 불리는데, Section 3.2에서 논의된 것처럼, 높은 성능과 확장성에 있어 매우 중요합니다. 성능과 확장성을 모두 없애버리는 오래된 방법 중 하나는 호환불가한 변수들을 같은 캐시라인에 집어넣는 것입니다. 예를 들어, 크기 재조정 가능한 해시 테이블 데이터 원소가 `ht_elem` 구조체를 상당히 빠르게 증가되는 카운터와 같은 캐시라인에 위치시켰다고 생각해 보세요. 잣은 카운터 증가는 해당 캐시라인이 카운터 증가를 하는 CPU 에 게만 보여질 것입니다. 만약 다른 CPU 가 해당 원소를 담고 있는 bucket 리스트를 횡단하려 하면, 이는 비용이 큰 캐시 미스를 일으켜서 성능과 확장성을 모두 떨어뜨릴 겁니다.

64-바이트 캐시 라인의 시스템에서 이 문제를 해결하는 방법 가운데 하나가 Listing 10.14에 보여져 있습니다. 여기서 GCC의 `aligned` 속성은 `->counter` 와 `->ht_elem` 구조체가 서로 다른 캐시 라인에 위치하게 합니다. 이 코드는 잣은 카운터 증가가 있더라도 CPU 들이 bucket 리스트를 빠른 속도로 횡단할 수 있게 해줍니다.

물론, 이 코드는 “캐시 라인의 크기가 64 바이트라는 걸 어떻게 알았을까?”라는 질문을 떠올리게 합니다. 리눅스 시스템에서, 이 정보는 `/sys/devices/system/cpu/cpu*/cache/` 디렉토리에서 얻을 수 있고, 설치 과정에서 해당 시스템의 하드웨어 구조에 적합하도록 어플리케이션을 다시 빌드하게 만들 수도 있습니다. 더 나아가서, 설치 프로그램을 리눅스에서만 돌릴 생각이라 해도, 그와 같이 스스로 수정을 하는 설치 과정은 검증을 거쳐야 합니다.

다행히도, 1995년의 논문 [GKPS95]에는 합리적인 수준으로 잘 동작하는, 경험에 의거한 법칙들이 몇가지

있습니다.³ 규칙들의 첫번째 그룹은 구조체를 적합한 캐시의 기하학적 구조에 맞춰 재배치 하는 것에 관한 것입니다:

1. 읽기가 대부분인 데이터를 빈번하게 업데이트되는 데이터와 분리시키세요. 예를 들어, 읽기가 대부분인 데이터를 구조체의 앞에 위치시키고 빈번하게 업데이트되는 데이터는 끝에 위치시켜야 합니다. 가능하다면, 가끔만 접근되는 데이터를 그 사이에 위치시키세요.
2. 만약 구조체가 여러 그룹의 필드를 가져서 각각의 그룹이 독립적인 코드 수행 경로에서 업데이트된다면, 각각의 그룹을 분리시키세요. 여기서도 역시, 가끔만 접근되는 데이터를 그룹들 사이에 위치시키는 게 효과를 발휘할 수 있습니다. 일부 경우에 있어서는 각각의 그룹을 원본 구조체에서 래퍼런스될 수 있는 별개의 구조체들에 위치시키는 것도 효과를 발휘할 수 있습니다.
3. 가능하다면, 업데이트가 대부분인 데이터를 CPU, 쓰레드, 또는 태스크와 연관지으세요. Chapter 5에서의 카운터 구현에서 이 경험적 규칙의 효과적인 예를 본 바 있습니다.
4. 가능하다면 Chapter 8에서 논의된 것처럼 데이터를 CPU 별로, 쓰레드별로, 또는 태스크별로 분리시켜야 합니다.

최근에는 메모리 액세스 기록에 기반한 구조체 필드 재배열의 자동화를 위한 노력들이 있었습니다 [GDZE10]. 이는 멀티쓰레드 소프트웨어에서 훌륭한 성능과 확장성을 위해 필요시 되는 작업의 고통을 줄여줄 수 있을 겁니다.

락에 대한 추가적인 경험적 법칙들도 있습니다:

1. 자주 수정되는 데이터를 보호하며 상당히 경쟁을 받게 되는 락은 다음의 방법 중 하나를 따라야 합니다:
 - (a) 락을 그것이 보호하는 데이터와 다른 캐시라인에 위치시키는 것.
 - (b) 높은 경쟁수위에 맞춰 만들어진, `queued` 락과 같은 락을 사용할 것.
 - (c) 락 경쟁 수위를 줄이기 위해 설계를 다시 할 것. (이 방법이 최고입니다만 상당한 작업을 필요로 합니다.)

³ 이런 규칙들 여럿은 여기서는 Orran Krieger 의 허락 하에 의역되고 확장되었습니다.

² 수백 기가바이트 단위 메모리의 스마트폰, 있나요?

2. 경쟁을 하지 않는 락들은 그것들이 보호하는 데이터와 같은 캐시 라인에 위치시키세요. 이 방법은 락을 현재 CPU로 들고오는 캐시미스가 데이터도 함께 가져오도록 함을 의미합니다.
3. 읽기가 대부분인 데이터를 RCU로 보호하고, 만약 RCU가 사용될 수 없고 크리티컬 섹션이 굉장히 길다면, reader-writer 락을 사용하세요.

그렇다고는 하나, 성능과 확장성은 안정성 없이는 사용되기 어려우므로, 다음 챕터에서 검증에 대해 다룹니다.

물론, 이것들은 절대적 규칙이 아니라 경험적 규칙입니다. 특정 상황에서 무엇이 가장 적합한 것인지를 알아내기 위해서는 일부 실험이 필요합니다.

10.7 Summary

이 챕터는 기본적으로 해시 테이블에 집중했고, 완전히 분할 가능하지는 않은 크기 재조정 가능한 해시 테이블에 대해서도 알아봤습니다. Section 10.5에서는 일부 해시 테이블 외의 데이터 구조에 대해 빠르게 대략적으로 알아봤습니다. 하지만, 이 해시 테이블 소개는 고성능의 자료 액세스를 들러싼 다음과 같은 많은 문제들에 대한 훌륭한 소개입니다:

1. 완전히 파티셔닝 가능한 데이터 구조는 예를 들어 하나의 socket의 시스템과 같은 작은 시스템에서 잘 동작합니다.
2. 더 큰 시스템은 완전한 파티셔닝 가능성은 물론이고 레퍼런스의 지역성 (locality)를 필요로 합니다.
3. 해저드 포인터와 RCU 같은, 읽기가 대부분인 상황을 위한 기법들은 읽기가 대부분인 워크로드에서의 레퍼런스에 훌륭한 지역성을 제공하고, 따라서 커다란 시스템에서도 훌륭한 성능과 확장성을 제공합니다.
4. 읽기가 대부분인 상황을 위한 기법들은 또한, 크기 재조정 가능한 해시 테이블들과 같은, 일부의 파티셔닝이 불가능한 데이터 구조에서도 잘 동작합니다.
5. 데이터 구조를 특정 워크로드에 특수화 시킴으로써 추가적인 성능과 확장성을 얻을 수 있습니다. 예를 들어, 일반적인 키를 32-bit 정수로 교체하는 방법으로요.
6. 이식성과 높은 성능은 일반적으로 서로 상충하지만, 이 두개의 요구사항 사이에서 좋은 밸런스를 잡을 수 있는 일부 데이터 구조 레이아웃 기법이 존재합니다.

If it is not tested, it doesn't work.

Unknown

Chapter 11

Validation

전 잘 동작하는 병렬 프로그램 몇개를 한번에 만든 적 있는데, 그건 제가 지난 20년간 많은 수의 병렬 프로그램들을 작성했기 때문일 뿐입니다. 그리고 저는 처음부터 잘 동작한 거라고 생각했지만 실제로는 처음부터 문제를 있었어서 결국 저를 바보로 만들었던 많은 병렬 프로그램들을 만든 적 있습니다.

그래서 저는 제 병렬 프로그램들을 위한 검증의 필요성을 강하게 느꼈습니다. 병렬성 검증 뒤의 기본적인 요령은 다른 소프트웨어 검증과 마찬가지로, 컴퓨터는 뭐가 잘못된 것인지 알고 있음을 깨닫는 것입니다. 따라서 컴퓨터가 그걸 당신에게 이야기하도록 하는게 당신이 할 일입니다. 그러므로 이 챕터는 기계를 심문하는 방법에 대한 짧은 수업으로 생각해 볼 수 있습니다.¹

더 긴 수업을 검증에 대한 많은 최신의 책들은 물론, 오래되었지만 상당히 가치있는 것 [Mye79] 으로부터도 얻을 수 있을 겁니다. 검증은 모든 형태의 소프트웨어에 있어 상당히 중요한 주제이고, 따라서 그것 자체만으로도 상당한 공부를 할 가치가 있습니다. 하지만, 이 책은 기본적으로 동시성에 대한 것이므로, 이 챕터는 이 치명적이고 중요한 주제에 대해서 곁핥기보다 조금만 더 다룹니다.

Section 11.1 에서는 디버깅의 철학을 소개합니다. Section 11.2 은 트레이싱에 대해 논해보고, Section 11.3 에서는 단정을 논하며, Section 11.4 에서는 정적 분석을 논합니다. Section 11.5 은 황당하리만치 많은 10,000 개의 눈이 코드를 보고 있지는 않을 때에 도움이 될 수 있는 비정규적인 코드 리뷰 접근법을 설명합니다. Section 11.6 은 병렬 소프트웨어의 검증을 위한 확률의 사용을 간단히 알아봅니다. 성능과 확장성은 병렬 프로그래밍에 있어서의 첫번째 요구사항이므로, Section 11.7 에서는 이 주제를 다뤄봅니다. 마지막으로, Section 11.8 에서는 간단한 요약과 피해야 할 통계적 함정들의 짧은 목록을 제공합니다.

¹ 하지만 손톱 고문 도구와 물고문 도구들은 집에 놔두셔도 됩니다. 이 챕터는, 적어도 우리가 알기로는 대부분의 컴퓨터는 고통을 느끼지 않고 익사를 두려워하지도 않는다는 사실에 기반해서 훨씬 더 세련되고 효과적인 방법들을 다룰겁니다.

하지만 최선의 디버깅 도구 두개는 탄탄한 설계와 충분한 수면임을 잊지 마세요!

11.1 Introduction

The greatest mistake is to imagine that we never err.

Thomas Carlyle

Section 11.1.1 에서는 버그의 근원에 대해서 이야기를 나눠보고, Section 11.1.2 에서는 소프트웨어를 검증할 때 필요한 마음들을 간단히 알아봅니다. Section 11.1.3 에서는 언제 검증을 시작해야 하는지 이야기해 보고, Section 11.1.4 에서 놀랍도록 효과적인 오픈소스 방식의 코드 리뷰와 커뮤니티 테스트에 대해 설명합니다.

11.1.1 Where Do Bugs Come From?

버그는 개발자로부터 옵니다. 기본적인 문제는 인류의 뇌가 컴퓨터 소프트웨어와 함께 진화해 오지 않았다는 점입니다. 그대신, 인류의 뇌는 다른 인류의 뇌와 짐승의 뇌와 함께 진화해 왔습니다. 이런 역사 때문에, 다음과 같은 컴퓨터의 세가지 특성들이 사람의 직관에는 많은 경우에 충격적으로 다가옵니다.

- 수십년간의 연구가 인공 지능의 제단 위에서 희생되어 왔음에도 불구하고 컴퓨터는 일반적으로 상식이 부족합니다.
- 컴퓨터는 일반적으로 사용자의 의도를 이해하지 못하는데, 더 정규적으로 표현하자면, 컴퓨터는 마음을 이해하는 능력이 떨어집니다.
- 컴퓨터는 단편적인 계획을 가지고는 어떤 유용한 일도 하지 못해서, 모든 각각의 성립 가능한 시나리오의 모든 자세한 내용들이 설명되어야만 합니다.

앞의 두 가지는 쟁점을 갖지 않을게 분명한데, 그런 점들은 여러개의 실패한 제품들, 아마도 가장 유명한 걸로는 Clippy 와 Microsoft Bob 과 같은 예로 설명되기 때문입니다. 사용자와 사람의 모습으로 관계를 가지려 시도함으로써, 이 두개의 제품들은 상식과 마음 이해 능력이 있을 것이란 기대를 품게 했는데, 그것들은 결국 이뤄지지 못했음을 그것들 스스로 증명했습니다. 최근 들어 스마트폰에서 나타나기 시작한 (여주: 챗봇 형태의) 소프트웨어 조수들은 아마도 더 나은 결과를 보일 겁니다. 그렇다면 하나, 그것들을 개발하는 일을 하는 개발자들은 여전히 기존 방법으로 개발을 하고 있습니다: 이 조수들은 최종 사용자에게는 도움을 주겠지만, 그 개발자 스스로에게는 그렇게 많은 도움을 주지 못할 겁니다.

인간의 단편적 계획에 대한 사랑에 대해서는 더 많은 설명이 있어야 하는데, 이게 고전적인 양날의 검이라는 점에서 특히 그렇습니다. 이 단편적 계획을 선호하는 건 계획을 실제로 수행하는 사람이 (1) 상식과 (2) 그 계획 뒤에 있는 의도에 대한 충분한 이해를 가지고 있을 것이라는 가정이 있기 때문입니다. 이 가정은 계획을 짜는 사람과 계획을 수행하는 사람이 똑같은 사람인 경우에 특히나 상식적일 겁니다: 이 경우, 해당 계획은 문제가 생길 때마다 거의 무의식적으로 수정될 겁니다. 따라서, 단편적 계획에 대한 사랑은 인류에 대해서는 잘 동작했는데, 계획할 수 없는 것을 계획하려 시도하는 동안 짚어죽기보다는 음식을 가져올 확률이 큰 무작위적 행동을 취하는게 낫기 때문인 점도 있습니다. 하지만, 이 과거의 매일 단편적 계획을 세우는 유용함은 미래의 컴퓨터에 저장된 프로그램에서의 유용함을 보장하지 않습니다.

더 나아가서, 단편적 계획을 따라야 하는 필요성은 인간의 마음에 중요한 영향을 끼쳤는데, 인류의 역사의 대부분에 있어서, 삶은 어렵고 위험했다는 사실 때문입니다. 높은 확률로 날카로운 이빨과 발톱의 공격을 맞닥뜨릴 수 있는 단편적 계획을 수행하기 위해서는 거의 미친 듯한 수준의 낙관론이 필요함은 전혀 놀랍지 않은 일입니다—그 수준의 낙관론은 사실 대부분의 인간에게 심어져 있죠. 이 미친듯한 수준의 낙관론은 사소한 프로그램의 코딩과 함께 이뤄지는 인터뷰 테크닉의 효율성 (그리고 논쟁)이 증명하듯이, 프로그래밍 능력의 자기 평가로까지 확장됩니다. 사실, 인간의 미친 듯하지는 못한 수준의 낙관론에 대한 임상병리학적인 용어는 “임상적 우울증”입니다. 그런 사람은 일반적으로 그들의 일상에 극단적인 기능성 장애를 갖게 되는데, 이는 미친듯한 수준의 낙관론이 평범하고 건강한 삶을 위해 얼마나 중요한지를 반증합니다. 당신이 미친듯 낙관적이지 않다면, 가치가 있지만 어려운 프로젝트를

시작하지는 않을 가능성이 있습니다.²

Quick Quiz 11.1: 컴퓨팅에 있어서 단편적 계획을 따르는게 특히 중요한건 언제인가요? ■

중요한 특이 케이스 중 하나는 가치있지만 그걸 구현하는데 필요한 시간을 정당화 할만큼은 가치있지 않은 프로젝트가 되겠습니다. 이 특이 케이스는 상당히 흔한 케이스이고 이런 경우에 초기부터 생기는 문제는 결정권자들이 그 프로젝트를 실제 구현하는데 노력할 의지가 없다는 점입니다. 개발자들에게 있어 자연스러운 반응은 그 프로젝트의 시작을 허락받기 위해 비현실적으로 낙관적인 예측을 만드는 것입니다. 만약 그 기관(오픈소스 또는 독점적인)이 충분히 강하다면, 그 결과로 스케줄이 늦춰지고 예산을 초과하는 일에도 살아남아서 그 프로젝트가 결국 빛을 볼 날이 올겁니다. 하지만, 만약 그 기관이 충분히 강하지 못하고, 그 예측은 실은 쓰레기였다는 것이 분명해졌음에도 결정권자가 그 프로젝트를 취소하지 못한다면 그 프로젝트는 기관을 없애버릴 수도 있을 겁니다. 이는 또 다른 기관이 그 프로젝트를 가져가서 그걸 완료시키거나, 취소하거나, 또는 그것에 의해 사라져버리거나 하는 결과를 초래할 겁니다. 어떤 프로젝트는 여러 기관을 없애버린 후에야 성공할 수도 있습니다. 어떤 사람은 연쇄 기관 살해마 프로젝트의 최종적 성공을 이끌어낸 기관이 적당한 경손함을 유지해서 그 기관은 다음 프로젝트로 사라지지 않게 되길 바랄 수도 있습니다.

미친듯한 수준의 낙관론은 중요하지만, 버그의 (그리고 기관의 실패의) 핵심 원인입니다. 따라서 여기서의 질문은 “버그의 올부짖음을 조용하게 할 수 있기 충분하게 현실성을 가지면서도 커다란 프로젝트를 시작하는데 필요한 낙관을 가질 수 있을까요?”입니다. 다음 섹션에서는 이 수수께끼를 풀어봅니다.

11.1.2 Required Mindset

검증을 위한 노력을 시작하려 할 때면, 다음의 정의들을 마음에 새겨둬야 합니다:

1. 버그가 없는 프로그램은 간단한 프로그램들 뿐입니다.
2. 안정적인 프로그램은 알려진 버그들이 없습니다.

이 정의들로부터, 모든 안정적이고 간단하지 않은 프로그램은 알려지지 않은 버그가 최소 하나는 존재할

² 이 경험적 법칙에는 유명한 예외들이 존재합니다. 예외를 가운데 하나의 부류는 그들의 우울증으로부터 임시로라도 달아나기 위해 어렵거나 위협이 따르는 프로젝트들을 하는 사람들입니다. 또 다른 부류는 잃을 게 없는 사람들입니다: 이 프로젝트는 말 그대로 삶과 죽음의 문제입니다.

것이라는 결론이 논리적으로 따라나옵니다. 따라서, 간단하지 않은 프로그램에서 버그를 찾지 못하는 검증 시도는 그것 자체로 실패한 것입니다. 따라서 좋은 검증은 분해의 연습입니다. 이는 곧 여러분이 뭔가를 분해하는 것을 즐기는 유형의 사람이라면, 검증은 여러분에게 걸맞는 유형의 일이라는 것을 의미합니다.

Quick Quiz 11.2: 다음과 같은 `time` 커맨드의 출력을 처리하는 스크립트를 작성하고 있다고 해봅시다:

```
real    0m0.132s
user    0m0.040s
sys     0m0.008s
```

해당 스크립트는 에러를 처리하고 에러일 수 있는 `time` 출력을 받았을 경우 적절한 진단 내용을 제공하기 위해 자신에게 주어진 입력을 체크해야 합니다. 싱글 쓰레드 프로그램들로 생성된 `time` 출력의 사용에 대해 이 프로그램을 테스트하기 위해 어떠한 입력의 테스트를 제공해야 할까요? ■

하지만 당신은 슈퍼-프로그래머여서 당신이 짠 코드는 항상 처음부터 영원히 완벽한 것일 수도 있겠죠. 만약 그렇다면, 축하합니다! 이 챕터를 그냥 넘겨버리셔도 좋아요. 하지만 저는 당신이 제 비관주의를 용서해 주시기를 바랍니다. 보세요, 저는 처음부터 완벽한 코드를 짤 수 있다고 주장하는 매우 많은 사람들을 만났고, 앞서 언급한 낙관론과 지나친 자신감을 생각해 보면 너무 놀랍지는 않은, 이것을 정말로 어느정도 해낼 수 있는 사람들을 알고 있습니다. 그리고 당신이 정말로 슈퍼-프로그래머라 하더라도, 언젠가는 당신보다 덜 훌륭한 사람의 작업물을 디버깅하고 있는 자신을 보게 될거예요.

그외의 우리들을 위한 한가지 방법은 우리의 일반적인 상태를 미친듯한 낙관과 (물론, 난 그걸 프로그램할 수 있어!) 상당한 비관(동작할 것처럼 보이긴 해, 하지만 난 거기 어딘가에 더 많은 버그들이 숨어 있을 것이라 걸 분명 알아!) 사이에서 오가는 것입니다. 당신이 뭔가를 분해하는 걸 즐긴다면 이게 도움이 될겁니다. 당신은 그렇지 않다면, 또는 당신의 물건 분해에서의 즐거움은 다른 사람의 물건을 분해하는 것으로 제한되어 있다면, 당신의 코드를 분해하는 것을 좋아하는 누군가를 찾아 그들이 당신의 테스트를 돋게 하세요.

또 다른 도움이 될 수 있는 심리적 프레임은 다른 사람이 당신의 코드에 있는 버그를 찾는 걸 싫어하는 것입니다. 이 증오는 버그를 다른 누군가가 아니라 당신이 찾을 가능성을 높이기 위한 이유로 당신의 코드를 고문할 동기를 얻는데에 도움이 될겁니다.

마지막 심리적 프레임은 다른 누군가의 삶이 당신의 코드가 올바른지에 달려 있을 수 있는 가능성을 고려하는 것입니다. 이것 또한 버그가 어디있는지 밝혀내기 위해 당신의 코드를 고문하기 위한 동기가 될 수 있을겁니다.




Figure 11.1: Validation and the Geneva Convention




Figure 11.2: Rationalizing Validation

이런 다양한 마음의 프레임들은 서로 다른 마음의 프레임을 가진 사람들이 다양한 수준의 낙관을 가지고 프로젝트에 기여할 수 있는 가능성의 문을 열겁니다. 이는 적절히 조직된다면 잘 동작할 수 있습니다.

어떤 사람들에게 격렬한 검증은 Figure 11.1에 보여진 것 같은 고문의 형태로 보여질 수도 있습니다.³ 그런 사람들은 Figure 11.2에 그려진 Tux 그림과 달리, 실제로는 애니메이션이 아닌 물건들을 고문하고 있음을 마음에 되새기는게 도움이 될겁니다.

하지만, 이라고 마는건 프로젝트의 진행 과정 중 정확히 언제 검증이 시작되어야 하는지에 대한 의문을 남겨두게 되는데, 이 주제는 다음 섹션에서 다루어집니

³ 더 시니컬한 사람은 이런 사람들이 단순히 그 검증을 통해 그들이 고쳐야 할 버그를 찾는 것을 걱정하는 것 뿐 아니라는 질문을 할수도 있겠죠.

다.

11.1.3 When Should Validation Start?

검증은 프로젝트의 시작과 동시에 시작되어야 합니다.

이 점을 알기 위해, 버그를 추적하는 것은 작은 프로그램에서보다 큰 프로그램에서 훨씬 더 어렵단 점을 생각해 보세요. 따라서, 버그를 추적하는데 필요한 시간과 노력을 최소화하기 위해, 코드의 작은 단위들을 테스트해야 합니다. 모든 버그를 이런 방식으로 찾지는 않겠지만, 상당한 양을 이렇게 찾을 것이고, 이런 방식으로 버그를 찾아내고 고치는게 훨씬 더 쉬울 겁니다. 이 수준에서의 테스트는 전체 설계에 있는 더 커다란 결점을 알릴 수도 있어서, 설계로 인해 문자 그대로 상당히 고장나 있는 코드를 쓰느라 낭비하는 시간을 최소화 시켜줄 겁니다.

하지만 당신의 설계를 검증하기 전에 왜 코드가 만들 어지기를 기다려야 할까요?⁴ Chapter 3 와 4 를 읽으면 일부 유감스럽게도 흔한 설계상의 잘못들을 피하는데 필요한 정보들을 얻을 수 있을 겁니다만, 당신의 설계를 동료와 토론하거나 심지어 단순히 그걸 글자로 써보는 것만으로도 추가적인 결함을 찾아낼 수 있을 겁니다.

하지만, 설계를 마칠 때까지 검증의 시작을 기다리는 것은 너무나도 대부분의 경우 지나치게 오래 기다리고 있는 것입니다. 당신의 자연적인 수준의 낙관이 당신이 요구사항들을 완전히 이해하기 전에 설계를 시작하도록 하는 일은 없었을까요? 이 질문에 대한 대답은 거의 항상 “그렇다”입니다. 잘못된 요구사항을 막는 한 가지 좋은 방법은 당신의 사용자들에 대해서 아는 것입니다. 정말로 그들을 위한 봉사를 잘 하려 한다면, 그들과 함께 살아야만 합니다.

Quick Quiz 11.3: 지금 저에게 코딩을 시작하기도 전에 검증을 시작하라고 말씀하시는 거예요??? 그건 마치 아무것도 시작하지 않는 훌륭한 방법처럼 들리네요!!!

세상에 없던 새로운 종류의 프로젝트는 검증에 있어 다른 전략을 필요로 하는데, 예를 들면, 빠른 프로토타입 만들기입니다. 여기서, 처음의 몇개 프로토타입들의 목표는 이 프로젝트가 어떻게 구현되는지를 배우는 것 이지, 처음부터 올바른 구현을 만드는게 아닙니다. 하지만, 근본적으로 다른 전략을 취하기보다는, 검증을 누락시켜선 안된다는 것을 명심하는게 중요합니다.

이제 우리는 프로젝트를 시작할 때부터 검증을 시작해야 하는 걸로 합의했으니, 다음 섹션들에서는 그 가치가 이미 증명된 여러가지 검증 기술들과 방법들을 알아보겠습니다.

⁴ “일단 코드를 짜야 하고, 그러고 나면 생각을 할 수 있다는 보상을 얻는다”는 오래된 말은 통하지 않습니다.

11.1.4 The Open Source Way

오픈소스 프로그래밍 방법론은 상당히 효율적임이 증명되었고, 격렬한 코드 리뷰와 테스트 제도를 포함하고 있습니다.

전 개인적으로 오픈소스 커뮤니티의 격렬한 코드리뷰의 효율성을 증명할 수 있습니다. 제가 리눅스 커널을 위해 준비했던 첫번째 패치들은 분산 파일시스템에 관한 것이었는데, 이 파일시스템에서 한 노드의 사용자는 다른 노드의 사용자가 메모리에 매핑해둔 파일의 한 지역에 쓰기를 할 수 있었습니다. 이 경우, 이 파일시스템이 쓰기 작업 중에도 일관성을 유지할 수 있도록 하기 위해, 관련된 페이지들을 해당 매핑으로부터 무효화 시킬 필요가 있습니다. 저는 첫번째 시도를 패치로 코딩했고, 오픈 소스의 “빨리 공유하고, 자주 공유할 것”이라는 행동 원리를 명심하고 있었기에, 그 패치를 공유했습니다. 그리고나서 저는 제가 그걸 어떻게 테스트해야 하나 고민했습니다.

하지만 제가 전체적인 테스트 전략을 결정하기도 전에 저는 제가 공유한 내용에 대해 몇개의 버그를 지적하는 답변을 받았습니다. 전 그 버그들을 고쳐서 패치를 다시 공유했고, 다시 제 테스트 전략에 대해 생각하는 단계로 돌아왔습니다. 하지만, 제가 테스트 코드를 작성할 시간을 갖기도 전에, 저는 더 많은 버그들을 지적하는, 제가 재공유한 패치에 대한 답변을 받았습니다. 이 프로세스는 그 자체로 여러번 반복되었고, 전 제가 그 패치를 정말로 테스트할 기회를 갖기는 했었는지 확신하지 못하겠습니다.

이 경험은 오픈소스가 정말로 말하는 것이 무엇인지 알려줬습니다: 충분한 눈이 있다면, 모든 버그들은 쉽게 파악될 수 있다 [Ray99].

하지만, 당신이 어떤 코드나 패치를 공유하려 한다면, 몇가지 질문을 해보는게 좋을 겁니다:

1. 얼마나 많은 눈이 당신의 코드를 정말로 보게 될까요?
2. 얼마나 많은 눈이 당신의 버그를 정말로 찾기에 충분할 정도로 경험이 많고 현명할까요?
3. 정확히 언제 그들이 당신의 코드를 볼까요?

전 운이 좋았습니다: 제 패치로 제공되는 기능을 필요로 하는 누군가가 거기에 있었는데, 그는 분산 파일시스템에 오랜 경험을 가지고 있었고, 제 패치를 거의 바로 봤습니다. 아무도 제 패치를 보지 않았다면, 어떤 리뷰도 없었을 것이고, 따라서 버그를 찾지도 못했을 겁니다. 만약 제 패치를 보는 사람들이 분산 파일시스템에 대한 경험이 부족했다면, 그들이 모든 버그를 찾지는 못했을 겁니다. 그들이 코드를 보기 전에 몇달이나 심지어 몇년간을 기다려야 했다면, 전 그 패치가 어떻게

동작해야 했는지도 잊어버려서 그 버그들을 고치기도 훨씬 더 어려웠을 겁니다.

하지만, 우린 오픈소스 개발의 두번째 교리인 격렬한 테스트를 잊지 말아야만 합니다. 예를 들어, 엄청나게 많은 사람들이 리눅스 커널을 테스트 합니다. 어떤 사람들은 패치를 제출되자마자 테스트하는데, 당신의 것도 그 대상이 될 수 있습니다. 어떤 사람들은 -next 트리를 테스트하는데, 이는 도움이 되지만, 당신이 패치를 작성한 시점부터 그게 -next 트리에 들어가게 되는 시점 까지는 몇주에서 몇달까지의 지연이 있을 수도 있는데, 이는 그 패치가 당신의 기억 속에 여전히 아주 생생하게 남아있지는 않을 가능성 있는 시간입니다. 어떤 사람들은 메인테이너 트리들을 테스트하는데, 이때에도 비슷한 지연시간이 있곤 합니다.

소수의 사람들은 메인라인 또는 마스터 소스 트리 (리눅스 커널의 경우라면 Linus 의 트리)에 커밋되기 전까지는 코드를 테스트하지 않습니다. 당신의 메인테이너가 테스트 되기 전까지는 당신의 패치를 받아주지 않는다면, 이는 당신에게 데드락 상황을 보이게 합니다: 당신의 패치는 테스트 되기 전까지는 받아들여지지 않을텐데, 이 패치는 또한 받아들여지기 전까지는 테스트 되지 않을 겁니다. 그러나, 많은 사람들과 단체들이 코드가 리눅스 배포판에 들어가기 전까지는 그 코드를 테스트하지 않기 때문에, 메인라인 코드를 테스트하는 사람들은 여전히 상대적으로 공격적입니다.

그리고 누군가가 당신의 패치를 테스트한다고 하더라도, 그 사람이 당신의 버그를 찾아내는데 필요한 하드웨어와 소프트웨어 구성과 워크로드를 수행할것인지에 대해서는 보장이 없습니다.

따라서, 오픈소스 프로젝트를 위한 코드를 작성할 때 라 할지라도, 당신은 당신 스스로의 테스트 장비를 개발하고 수행할 준비를 할 필요가 있습니다. 테스트 개발은 실제 가치에 비해 덜 중요하게 평가되었지만 매우 중요한 기술이므로, 당신이 사용할 수 있는, 이미 존재하는 테스트 장비들의 장점을 모두 취할 수 있도록 하십시오. 테스트 개발은 이와 같이 중요하므로, 우리는 그에 대한 더이상의 토론은 그 주제 전용의 책들에게 떠넘기도록 하겠습니다. 따라서 다음의 섹션들은 당신이 이미 좋은 테스트 장비를 갖추고 있다는 가정 하에 당신의 코드 안의 버그들을 찾는 방법들을 다루겠습니다.

11.2 Tracing

The machine knows what is wrong. Make it tell you.

Unknown

다른 모든게 실패한다면, `printf()` 를 추가하세요! 만약 유저 모드 C-언어 어플리케이션을 작업 중이라면

`printf()` 를요.

논리적 근거는 간단합니다: 어떻게 실행이 코드의 특정 지점까지 가게 되었는지 알아낼 수가 없다면, 무슨 일이 벌어졌는지 알아내기 위해 코드의 앞부분에 프린트문을 여기저기 집어넣으세요. 비슷한 효과를 (유저 어플리케이션을 위한) `gdb` 나 (리눅스 커널 디버깅을 위한) `kgdb` 와 같은 디버거를 이용해서 더 편리하고 유연성 있게 얻을 수도 있습니다. 훨씬 더 세련된 도구들도 존재하는데, 그 중 최신의 일부는 문제가 발생한 시점부터 뒤로 시간을 되돌릴 수 있는 기능을 제공합니다.

이런 간단한 테스트 도구들은 모두 가치가 있는데, 일반적인 시스템들이 64K 보다 큰 메모리와 4MHz 보다 빠른 속도로 동작하는 지금에 있어선 특히 그렇습니다. 이런 도구들에 대해서는 더 많은 글들이 있으므로, 이 챕터는 그에 대해 조금만 더 이야기 하겠습니다.

하지만, 이런 도구들은 모두, 디버깅하려는 일이 고성능의 병렬 알고리즘의 빠른 수행경로에 뭐가 잘못되어 있는지를 알려고 하는 것일 경우에 심각한 단점을 가지고 있는데, 달리 말해 대부분의 경우 큰 오버헤드를 갖습니다. 이런 목적을 위한 특수한 추적 기술들이 있는데, 일반적으로 실행시간 데이터 수집의 오버헤드를 최소화하기 위해 데이터 소유권 테크닉 (Chapter 8을 참고하세요) 을 사용합니다. 리눅스 커널에서의 한가지에는 데이터가 극단적으로 낮은 오버헤드만을 가지고 수집될 수 있도록 하기 위해 CPU 별 버퍼를 사용하는 “trace events” [Ros10b, Ros10c, Ros10d, Ros10a] 입니다. 그렇다 하더라도, 추적 기능을 활성화시키는 것은 어떤 경우에는 버그를 숨기기 충분할 만큼 타이밍을 바꿀 수 있어서, Section 11.6 과 Section 11.6.4 에서 특별히 다루어질 *heisenbugs* 를 초래할 수 있습니다.

유저스페이스 코드에는, 여러분을 도울 수많은 도구들이 있습니다. 이를 알아보는데 있어 시작하기 좋은 것은 *Brendan Gregg* 의 블로그입니다.⁵

Heisenbug 를 막는다 하더라도, 다른 위험들이 기다리고 있습니다. 예를 들어, 비록 기계는 모든 것을 알고 있지만, 그것이 알고 있는 것은 거의 항상 당신의 머리가 쥐고 있을 수 있는 것보다 많은 정보입니다. 이런 이유로, 높은 품질의 테스트 장비들은 일반적으로 대량의 출력을 분석할 수 있도록 세련된 스크립트들을 함께 제공합니다. 하지만 조심하세요—스크립트들은 놀라운 일을 알려줘야만 하는 건 아닙니다. 제 `rcutorture` 스크립트는 그런 점에서의 한 경우입니다: 그 스크립트들의 초기 버전들은 RCU grace period 들이 불명확하게 늦춰지며 동작 (stall) 함에도 문제가 없다고 판단하고는 했습니다. 물론 해당 스크립트들은 RCU grace-period stall 문제를 파악할 수 있도록 수정되었습니다만, 제가 파악할 수 있게 하자고 생각하는 문제들만을 파악한다는 사실은 바뀌지 않습니다. 그 스크립트들은 유용합니다만, 가끔

⁵ <http://www.brendangregg.com/blog/>

rcutorture 출력을 일일이 읽는 행위를 대체할 수는 없습니다. 하지만 여러분이 훌륭한 설계를 갖지 않는다면, 여러분은 여러분의 스크립트가 무엇을 체크해야 하는지도 모를 수 있음을 알아두시기 바랍니다!

추적 기능과 특히 `printk()` 호출에 있어서의 또 다른 문제는 그 오버헤드가 제품에 사용되기에에는 너무 크다는 것입니다. 그런 경우들 중 일부에 있어서는, 단정문들이 도움이 될 수 있습니다.

11.3 Assertions

No man really becomes a fool until he stops asking questions.

Charles P. Steinmetz

단정문들은 일반적으로 다음과 같은 식으로 구현됩니다:

```
1 if (something_bad_is_happening())
2   complain();
```

이 패턴은 종종 C 전처리기 매크로나 프로그래밍 언어의 내재 기능으로 캡슐화 되어지는데, 예를 들어 리눅스 커널의 경우, 이는 `WARN_ON(something_bad_is_happening())` 으로 표현될 겁니다. 물론, 만약 `something_bad_is_happening()` 이 상당히 자주 벌어진다면 그로 말미암은 출력은 다른 문제들의 보고를 이해하기 어렵게 만들 수 있는데, 이런 경우에는 `WARN_ON_ONCE(something_bad_is_happening())` 이 더 적절할 겁니다.

Quick Quiz 11.4: `WARN_ON_ONCE()` 는 어떻게 구현 할 수 있을까요? ■

병렬 코드에서, 일어날 수도 있는 한가지 매우 나쁜 일은 특정한 락이 잡힌 상태에서 호출될 것으로 기대되는 어떤 함수가 그 락이 잡히지 않은 채로 호출되는 경우입니다. 그런 함수들은 어떤 경우에는 “호출자는 반드시 이 함수를 호출할 때 `foo_lock` 을 잡아야만 함”과 같은 이야기를 하는 헤더 주석을 가질 수도 있습니다만, 그런 주석은 누군가가 그걸 정말로 읽지 않는다면 어떤 좋은 일도 하지 않습니다. `lock_is_held(&foo_lock)` 과 같이 실행 가능한 이야기가 훨씬 많은 무게를 갖습니다.

리눅스 커널의 `lockdep` 기능 [Cor06a, Ros11] 은 이 과정을 좀 더 크게 취하는데, 잠재적인 데드락을 보고하는 것 뿐만 아니라 함수들이 올바른 락들을 잡았는지 검증할 수 있게 도와줍니다. 물론, 이 추가적인 기능은 상당한 오버헤드를 만들어내는데, 그로인해 `lockdep` 은 제품에서의 사용에는 적합하지 않습니다.

그래서 검사가 필요하지만 실행시간에서의 검사로 인한 오버헤드는 용인될 수 없는 경우에는 무엇을 해

볼 수 있을까요? 한가지 방법은 정적 분석인데, 다음 섹션에서 이에 대해 논해 보겠습니다.

11.4 Static Analysis

A lot of automation isn't a replacement of humans but of mind-numbing behavior.

Summarized from Stewart Butterfield

정적 분석은 첫번째 프로그램이 두번째 프로그램을 입력으로 받아서 두번째 프로그램 안에 있는 에러와 취약점을 보고해 주는 검증 테크닉입니다. 흥미롭게도, 거의 모든 프로그램이 컴파일러와 인터프리터를 통해 정적 분석을 합니다. 이런 도구들은 물론 완벽과는 거리가 멀니다만, 그것들의 에러를 찾아내는 기능은 과거의 수십년간 크게 개선되었는데, 일부분은 그 분석을 진행할 메모리의 크기가 64K 바이트보다 훨씬 더 커진 것도 한 이유입니다.

원래의 UNIX `lint` 도구 [Joh77] 는 상당히 유용합니 다만, 그것의 기능들 가운데 대부분의 것들은 C 컴파일러 안에 포함되었습니다. 하지만 `lint` 와 유사한, 개발되고 있고 사용되고 있는 도구들이 오늘날 존재합니다.

`Sparse` 정적 분석 도구 [Cor04b] 는 리눅스 커널의 높은 수준의 문제들을 찾아내는데, 다음과 같은 문제들을 포함합니다:

1. 유저 스페이스 구조체로의 포인터의 잘못된 사용.
2. 너무 긴 상수로부터의 값 할당.
3. 텅 빈 `switch` 문.
4. 잘못 매치된 락 획득과 해제.
5. Per-CPU 도구의 잘못된 사용.
6. RCU 포인터가 아닌 곳에서의 RCU 사용과 그 반대 경우.

컴파일러들이 자체적인 정적 분석 기능들을 계속해서 늘려갈 것 같긴 하지만, `sparse` 정적 분석 도구는 컴파일러 밖에서의 정적 분석의 효과를 보여주고 있는데, 특히 어플리케이션에 특정한 버그들을 찾는데 그려합니다.

11.5 Code Review

If a man speaks of my virtues, he steals from me; if he speaks of my vices, then he is my teacher.

Chinese proverb

다양한 코드 리뷰는 정적 분석의 특수한 경우입니다만, 사람이 분석을 한다는 차이가 있습니다. 이 섹션은 검사, 가상 리허설, 그리고 자가 검사에 대해서 다룹니다.

11.5.1 Inspection

전통적으로, 정규 (formal) 코드 검사는 정규적으로 정의된 역할을 가진 사람들이 얼굴을 맞대는 모임으로 이루어졌습니다: 중재자, 개발자, 그리고 한두명의 참가자. 여기서 개발자는 코드를 읽어내려가면서 그 코드가 하는 일이 무엇이며 왜 동작하는지 설명을 합니다. 한두명의 참가자들은 질문을 하고 문제를 제기하며, 중재자가 하는 일은 모든 충돌을 처리하고 기록을 하는 것입니다. 이 과정은 버그를 찾아내는 데에 상당히 효과적일 수 있는데, 모든 참가자가 이 코드에 친숙하다면 특히 그러합니다.

하지만, 이 얼굴을 맞대는 정규적 과정은 글로벌한 리눅스 커널 커뮤니티에서는 잘 동작하지 못할 수 있습니다. IRC 세션을 사용하면 어쩌면 잘 동작할 수도 있겠지만요. 대신에, 개인들은 코드를 개별적으로 리뷰하고 이메일이나 IRC를 통해 코멘트를 제공합니다. 기록을 하는 행위는 이메일 기록이나 IRC 로그를 통해 제공되며, 중재자들은 그들의 서비스들을 적절하게 자발적으로 봉사합니다. 이 프로세스는 간헐적인 격론을 주고 받으며 합리적인 수준으로 잘 동작하는데, 모든 참가자들이 처리해야 하는 코드에 모두 친숙하다면 더욱 그러합니다.⁶

리눅스 커널 커뮤니티의 리뷰 프로세스는 개선될 여지도 많습니다:

1. 가끔은 효과적인 리뷰를 하기에 충분한 시간과 전문성을 가진 사람이 부족할 때가 있습니다.
2. 모든 리뷰 과정의 토론들이 기록된다고는 하지만, 이 기록들은 통찰이 잊혀지거나 사람들이 그 토론을 열어보는데에 종종 실패하는 것과 같은 형태로 “누실” 되기도 합니다.
3. 가끔은 격렬한 토론으로 인한 싸움이 벌어졌을 때에 이를 해결하기가 어려울 수도 있는데, 싸우는 사람들이 합치될 수 없는 목표, 경험, 그리고 어휘를 사용할 때에 특히 그렇습니다.

따라서, 리뷰를 할 때에는 커밋 로그, 버그 레포트, 그리고 LWN 기사에 있는 적절한 문서들을 참고하는게 좋습니다.

⁶ 그렇다고 하나, 전통적인 정규적 검사에 비한 리눅스 커널 커뮤니티 방법의 장점 가운데 하나는 코드에 친숙하지 않은, 따라서 코드에 익숙한 사람들에게 품어져 있는 옳지 않은 가정에 의해 눈이 가려지지 않은 사람들의 기여의 가능성이 훨씬 더 높다는 것입니다.

11.5.2 Walkthroughs

전통적인 walkthrough (가상 리허설)는 정규적 검사와 비슷하지만, 사람들이 코드를 가지고 특정 테스트 케이스에 대해서 “컴퓨터인 척 한다”는 점이 다릅니다. 일반적인 walkthrough 팀은 중재자, 비서 (찾아낸 버그를 기록합니다), 테스트 전문가 (테스트 케이스를 만들어냅니다), 그리고 한두명의 추가적인 사람들을 포함합니다. 이것들은 굉장히 시간을 소모하지만 상당히 효과적일 수 있습니다.

제가 정식적인 walkthrough에 참여한지 수십년이 되었고, 저는 오늘날의 walkthrough는 단일단계 디버거들을 사용할 수도 있을 거라고 생각합니다. 어떤 사람은 다음과 같이 특히나 학제적인 과정을 떠올릴 수 있을 겁니다:

1. 테스터는 테스트 케이스를 제공합니다.
2. 중재자는 특정된 테스트 케이스를 입력으로 해서 디버거 위에서 코드를 동작시킵니다.
3. 각각의 명령문이 실행되기 전에, 개발자는 해당 명령문의 결과가 무엇일지를 예상하고 왜 그 결과가 옳은지를 설명합니다.
4. 만약 결과가 개발자에 의해 예상되었던 것과 다르다면, 이는 잠재적인 버그의 증거로 택해집니다.
5. 병렬 코드에서는 “동시성 업자 (concurrency shark)” 가 어떤 코드가 이 코드와 동시적으로 실행될 수 있을 것인지, 그리고 왜 그런 동시성이 해롭지 않은지 질문합니다.

학제입니다, 분명히. 효과적일까요? 아마도요. 참가자들이 요구사항, 소프트웨어 도구들, 데이터 구조들, 그리고 알고리즘들에 대해 잘 이해하고 있다면, 그 walkthrough는 상당히 효과적일 수 있습니다. 만약 그렇지 않다면, walkthrough는 시간 낭비인 경우가 많습니다.

11.5.3 Self-Inspection

개발자들이 모두 자신의 코드를 검사하는데 그렇게 효과적이지는 않은 게 일반적이지만, 합리적인 대안이 없는 상황들도 많이 존재합니다. 예를 들어, 해당 개발자가 그 코드를 볼 수 있도록 허가된 유일한 사람일 수 있고, 다른 능력 있는 개발자들은 모두 너무 바빠서 일수도 있고, 또는 문제의 해당 코드가 충분히 기묘하게 생겨서 프로토타입을 선보이기 전까지는 어떤 사람도 그걸 심각하게 바라보도록 설득할수가 없어서일 수도 있습니다. 이런 경우들에, 다음과 같은 방법은 상당히 도움이 되는데, 특히 복잡한 병렬 코드에서 그렇습니다:

1. 요구사항, 데이터 구조를 위한 다이어그램, 그리고 설계 선택 사항들에 대한 합리적 이유등을 가지고 설계 문서를 작성합니다.
2. 전문가에게 자문을 구하고 필요하다면 설계 문서를 업데이트 합니다.
3. 코드를 종이 위에 펜으로 써가면서 에러들을 고칩니다. 앞서 존재한 거의 동일한 코드 시퀀스를 참고하려는 유혹을 견뎌내고, 작성한 코드의 사본을 만듭니다.
4. 거기에 에러가 있었다면, 깨끗한 종이에 그 코드를 똑같이 쓰면서 에러들을 고쳐갑니다. 마지막 두 복사본이 동일할 때까지 이를 반복합니다.
5. 모든 분명치 않은 코드에 대해 정확성을 증명합니다.
6. 소스 코드 컨트롤 시스템을 사용합니다. 초기부터 커밋하고, 자주 커밋합니다.
7. 가능하다면, 코드 조각들을 바닥에서부터 테스트 합니다.
8. 모든 코드가 합쳐지면 (하지만 가능하면 합쳐지기 전부터), 기능성과 스트레스 테스트를 전부 합니다.
9. 코드가 모든 테스트를 통과한다면, 코드 레벨 문서를 작성하는데, 이는 앞서 이야기한 설계 문서의 확장판이 될수도 있습니다. 필요하면 코드와 테스트 코드를 모두 수정합니다.

제가 새로운 RCU 코드를 위해 성실하게 이 과정을 따라갔을 때, 과정의 마지막에 이르러서는 몇개의 버그만이 존재했습니다. 몇개의 두드러지는 (그리고 당황스러운) 예외가 있지만 [McK11a], 전 남들보다 앞서서 이런 버그들을 잡아내고는 합니다. 그렇다고는 하나, 리눅스 커널 사용자의 수와 다양성이 증가함에 따라 이는 점점 어려워지고 있습니다.

Quick Quiz 11.5: 어떤 사람이 존재하는 코드를 종이에 펜으로 사본을 만들려 하겠어요??? 그건 그냥 필사 과정에서의 에러의 가능성만 증가시키는 거 아닌가요? ■

Quick Quiz 11.6: 이 과정은 우스꽝스러울 정도로 지나치게 공업화 되어 있어요! 어떻게 당신은 소프트웨어의 충분한 부분이 이런 방식으로 작성되었을 거라고 생각할 수 있는거죠? ■

앞의 방법은 새로운 코드에 있어서는 잘 동작합니다만, 이미 작성한 코드에 대해서 검사가 필요하다면 어떻게 해야 할까요? 물론 기준의 코드에 앞의 방법을 당신이 투입된 특수한 경우 [FPB79]에 대해 적용할 수

있겠습니다만, 덜 절망적인 상황에서는 다음과 같은 방법도 도움이 될 수 있을 겁니다:

1. 당신이 가장 좋아하는 문서화 도구 (L^AT_EX, HTML, OpenOffice, 또는 ASCII)를 사용해서 문제가 되는 코드의 설계를 높은 수준에서 묘사하세요. 데이터 구조들과 이 구조들이 어떻게 업데이트 되는지를 묘사하기 위해 많은 다이어그램들을 사용하세요.
2. 해당 코드의 복사본을 만들고 모든 코멘트들을 지워버리세요.
3. 코드가 무슨 일을 하는지를 한줄 한줄씩 문서화하세요.
4. 발견되는 대로 버그를 고치세요.

이게 잘 동작하는 이유는 코드를 자세하게 설명하는 것은 버그를 찾아내는 훌륭한 방법이기 때문입니다 [Mye79]. 이 두번째 방법은 어떤 다른 사람의 코드를 이해하는데에도 좋은 방법이긴 합니다만, 많은 경우에 첫번째 단계만으로도 충분합니다.

다른 사람에 의한 리뷰와 검사가 더 효율적이고 효과적이긴 하지만, 앞의 방법들은 어떤 이유가 되었든 다른 사람들이 관여할 수가 없는 상황에서 상당히 도움이 됩니다.

이 시점에서, 당신은 이 모든 지루한 종이와 함께 하는 일들을 하지 않고서 병렬 코드를 작성하는 방법에 대해 궁금할 겁니다. 여기 그걸 달성하기 위한, 오랜 시간이 증명한 몇가지 방법이 있습니다:

1. 사용 가능한 병렬 라이브러리 함수의 사용을 통해 확장되는 순차적 프로그램을 작성하세요.
2. 맵리듀스, BOINC 또는 웹 어플리케이션서버와 같은 병렬 프레임워크를 위한 순차적 플러그인들을 작성하세요.
3. 문제가 완전히 분할 가능한 병렬 설계와 같은 멀진 일을 하고, 상호간 통신 없이 병렬로 수행되는 순차적 프로그램(들)을 구현하세요.
4. 어플리케이션 영역들 중 도구들이 자동으로 문제를 분해하고 병렬화 할 수 있는, (선형 대수와 같은) 하나의 영역에만 집중하세요.
5. 극단적으로 올바른 방법으로만 병렬 프로그래밍 도구들을 사용해서 그 결과 작성된 코드가 올바르단 것이 쉽게 보일 수 있게 하세요. 하지만 조심하세요: 항상 더 좋은 성능과 확장성을 위해서 그 규칙들을 “아주 조금만” 깨고 싶은 욕구가 생길겁니다. 그 규칙들을 깨는 건 일반적으로 문제를 야기합니다. 이 섹션에서 설명한 종이를 가지고 하는 일들을 조심스럽게 하지 않았다면 말이죠.




Figure 11.3: Passed on Merits? Or Dumb Luck?

하지만 슬픈 사실은 당신이 이 종이를 가지고 하는 일을 했거나 종이를 가지고 하는 일을 회피할 수 있는 더 또는 덜 안전한 방법들을 사용했다고 하더라도 버그는 존재할 거라는 겁니다. 모든 걸 제쳐두고, 더 많은 사용자들과 훨씬 많은 사용자의 다양성은 더 많은 버그를 더 빨리 노출시킬 것인데, 그런 사용자들이 최초의 개발자들이 고려하지 못했던 일들을 하게 되면 특히 그렇습니다. 다음 섹션은 병렬 소프트웨어를 검증하면 너무도 자주 발생하는 확률적 버그를 다루는 방법에 대해 설명하겠습니다.

11.6 Probability and Heisenbugs

With both heisenbugs and impressionistic art, the closer you get, the less you see.

Unknown

그리니까, 당신의 병렬 프로그램은 실패합니다. 가끔요.

하지만 당신은 그 문제들을 찾아내기 위해 앞의 섹션에서 얻은 방법들을 사용했고 이제 그것들을 고쳤어요! 축하합니다!!!

이제 질문은, 한편으로는 그 버그가 발생할 확률만을 줄였거나, 관련된 여러개의 버그들 중 하나만을 고쳤거나, 또는 관계없고 효과없는 변경만을 가한게 아니라 정말로 그 버그를 고쳤다는 점을 분명히 하기 위해서 얼마나 많은 테스트를 해야 하는가입니다. 짧게 말해서, Figure 11.3로 암시되는 영원한 질문에 대한 답은 뭘까요?

불행히도, 정직한 답은 절대적인 정확성을 얻기 위해서는 무한한 테스트가 필요하다는 것입니다.

Quick Quiz 11.7: 당신의 쓰레기 봉투에 굉장히 많은 시스템이 있다고 생각해 봅시다. 예를 들어, 현재의 클라우드 가격 정책대로라면, 당신은 충분히 낮은 가격에 수많은 CPU 시간을 구입할 수 있습니다. 모든 실용적인 목적에 있어서의 정확성을 충분히 가져가기 위해서 이 전략을 사용하는 건 어떤가요? ■

하지만 절대적인 정확성을 포기하고 높은 가능성에 치중하도록 하려 있다고 생각해 봅시다. 그렇다면 우린 이 문제를 해결하는데에 강력한 통계적 도구들을 사용할 수 있습니다. 하지만, 이 섹션은 간단한 통계 도구들에 집중해 봅니다. 이런 도구들은 굉장히 도움이 됩니다만, 이 섹션을 읽는 것이 훌륭한 통계 수업들을 듣는 것을 대체할 수는 없다는 점을 알아두시기 바랍니다.⁷

간단한 통계적 도구들을 알아보는 걸 시작하기 위해, 우리가 별개적인 테스트를 할 것인지 연속적인 테스트를 할 것인지 결정해야 합니다. 별개적 테스트는 잘 정의된 개별 테스트 수행들을 갖춥니다. 예를 들어, 리눅스 커널 패치의 부팅 테스트는 별개적 테스트의 한 예입니다. 커널을 부팅해 보고, 그게 부팅되거나 아니거나입니다. 비록 커널 부팅 테스트를 하는데에 한시간을 소비할 수도 있긴 하지만, 대부분의 경우에 있어서 커널을 부팅하기 위해 시도한 시도의 횟수와 부팅이 성공한 횟수가 테스트에 소비한 시간의 길이보다 더 흥미로운 것이 될 겁니다. 가능 테스트는 개별적이게 되는 경향이 있습니다.

한편, 만약 제 패치가 RCU에 관련되어 있다면, 저는 RCU를 테스트하는 커널 모듈인 `rcutorture`를 돌려볼 겁니다. 로그인 프롬프트 시그널이 띠워지는 것으로 성공을 의미하는 커널 부팅과 달리, `rcutorture`는 커널이 크래시 나거나 당신이 멈추라고 하기 전까지는 RCU를 고문하기를 계속할 겁니다. 따라서 `rcutorture` 테스트에 걸리는 시간이 (일반적으로) 당신이 그걸 시작하고 멈춘 시간보다 더 중요하게 됩니다. 따라서, `rcutorture`는 많은 스트레스 테스트가 포함되는 연속적 테스트 카테고리의 한 예입니다.

별개 테스트와 연속적 테스트를 운영하는 통계는 몇몇 부분에서 다릅니다. 하지만, 별개 테스트들을 위한 통계는 연속적 테스트를 위한 것보다 더 간단하고 친숙하며, 뿐만 아니라 별개 테스트들을 위한 통계는 종종 (약간의 정확성 손실과 함께) 연속적 테스트를 위한 서비스에 사용되기도 합니다. 따라서 우리는 별개 테스트들부터 시작하겠습니다.

⁷ 전 그려기를 강력하게 추천합니다. 제가 들었던 몇개의 통계 수업들을 제가 그것들을 공부하기 위해 쏟았던 시간에 비례해서 가치를 제공했습니다.

11.6.1 Statistics for Discrete Testing

버그가 한번의 프로그램 수행 사이에 10%의 발생 확률을 가지고 있고 우리는 프로그램을 다섯번 수행한다고 생각해 봅시다. 최소 한번의 수행은 실패할 확률을 어떻게 계산하면 될까요? 그런 한가지 방법은 다음과 같습니다:

1. 하나의 수행이 성공할 확률을 계산하는데, 이건 90%입니다.
2. 모든 다섯번의 수행이 성공할 확률을 계산하는데, 이는 0.9의 5승이어서, 약 59%입니다.
3. 두개의 가능성만이 존재합니다: 다섯번의 수행이 모두 성공하거나, 최소 한번은 실패하거나. 따라서, 최소 한번은 실패할 확률은 100%에서 59%를 제외한 나머지인 41%입니다.

하지만, 많은 사람들이 여러 단계보다는 하나의 공식을 사용하는게 더 쉽다고 생각하므로, 설령 여러분은 앞의 단계들이 더 편하다고 생각한다 하더라도, 한번 해봅시다! 공식을 더 선호하는 사람들을 위해, 한번의 실패할 확률을 f 라고 해봅시다. 그럼 한번의 성공을 할 확률은 $1 - f$ 이고, 따라서 n 개의 테스트들이 모두 성공할 확률은:

$$S_n = (1 - f)^n \quad (11.1)$$

실패할 확률은 $1 - S_n$, 또는:

$$F_n = 1 - (1 - f)^n \quad (11.2)$$

Quick Quiz 11.8: 뭐라구요??? 제가 앞에서 이야기 한 각각 10% 실패 확률을 갖는 다섯번의 테스트의 예를 이 공식에 집어넣어보면 59,050%를 얻게 되는데 이건 말이 안되잖아요!!! ■

따라서 특정 테스트가 10%의 확률로 실패하고 있다고 해봅시다. 당신이 가한 수정이 정말로 일을 개선시켰다고 99% 확신할 수 있으려면 얼마나 많은 테스트를 수행시켜 봐야 할까요?

이걸 다르게 질문해보면 “실패를 일으킬 확률을 99% 까지 올리려면 얼마나 많은 테스트를 돌려보아야 할까요?”입니다. 일단, 최소 하나의 실패를 볼 수 있는 확률이 99% 까지 되도록 테스트를 충분히 많이 돌린다면, 그리고 거기에 실패가 한번도 없다면, 이는 단지 1% 확률의 행운 덕입니다. 그리고 우리가 Equation 11.2에 $f = 0.1$ 을 집어넣고 n 을 변경시켜보면, 원래의 10%라는 테스트당 실패 확률에 대해서 43번의 수행이 98.92%의 최소 한번은 테스트가 실패할 확률을 가져오고, 44번의 수행은 99.03%의 최소 한번은 실패할 확률을 가져옵니다. 따라서 우리가 수정을 한 후에




Figure 11.4: Number of Tests Required for 99 Percent Confidence Given Failure Rate

44번 테스트를 진행하고 실패를 한번도 보지 못한다면, 우리의 수정이 정말로 실제 개선을 만들어냈을 확률이 99%인 것입니다.

하지만 계속해서 숫자들을 Equation 11.2에 집어넣어보는 것은 지켜울 수 있으므로, n 을 풀어봅시다:

$$F_n = 1 - (1 - f)^n \quad (11.3)$$

$$1 - F_n = (1 - f)^n \quad (11.4)$$

$$\log(1 - F_n) = n \log(1 - f) \quad (11.5)$$

마지막으로 요구되는 테스트의 횟수는 다음과 같이 구해집니다:

$$n = \frac{\log(1 - F_n)}{\log(1 - f)} \quad (11.6)$$

Equation 11.6에 $f = 0.1$ 와 $F_n = 0.99$ 를 대입해 보면 43.7이 나오는데, 이는 우리의 수정이 실제 개선을 만들어냈음을 99% 확신하려면 44번의 연속적인 성공적 테스트가 필요함을 의미합니다. 이는 안심스럽게도 앞의 방법에서 얻어진 숫자와 맞아떨어집니다.

Quick Quiz 11.9: Equation 11.6에서, 로그의 밑은 10인가요, 2인가요, 또는 e인가요? ■

Figure 11.4는 이 함수를 그래프로 그려보입니다. 놀랍지 않게, 각각의 테스트가 덜 빈번하게 실패할수록, 그 버그가 고쳐졌음을 99% 확신하는데에 더 많은 테스트 수행이 필요합니다. 테스트를 실패하게 하는 버그가 오직 1%의 확률만으로 나타난다면, 애끓는 심정의 458번의 테스트 수행이 필요합니다. 실패 확률이 줄어들수록, 필요한 테스트 수행 횟수가 증가해서, 실패 확률을 0으로 하려면 무한번의 테스트 수행이 필요해집니다.

이 이야기의 교훈은 가끔씩만 일어나는 버그를 발견했다면, 실패 확률을 훨씬 높이도록 잘 타겟팅 된 테스트를 사용한다면 테스트 업무가 훨씬 쉬워질 것이란 점입니다. 예를 들어, 타겟이 된 테스트가 실패 확률을 1%에서 30%로 늘린다면, 99% 확신을 갖기 위해 필요한 테스트 수행 횟수는 458 회에서 단지 13회까지로 떨어질 겁니다.

하지만 이 열세번의 테스트 수행은 당신의 수정 사항이 “어떤 개선”을 만들어냈다는 데에 99%의 확신만을 제공합니다. 당신이 원하는건 그게 아니라 당신의 수정 사항이 실패 확률을 10배 가량 줄인 것이라는 99%의 확신이라고 생각해 봅시다. 얼마나 많은 실패하지 않는 테스트 수행이 필요할까요?

30% 실패 확률에서 10배 개선된다면 3%의 실패 확률입니다. 이 숫자들을 Equation 11.6에 집어넣으면 다음과 같은 결과가 나옵니다:

$$n = \frac{\log(1 - 0.99)}{\log(1 - 0.03)} = 151.2 \quad (11.7)$$

따라서 우리의 10배 개선을 위해서는 대략 10배 이상의 테스트가 필요합니다. 확신은 불가능하고, 높은 확률은 상당히 비쌉니다. 테스트들이 수행은 더 빠르게 되고 실패는 더 잘 일어나도록 분명하게 만드는 것이 높은 수준의 안정성을 갖는 소프트웨어를 개발하는데에 있어 핵심의 기술들입니다. 이런 기술들은 Section 11.6.4에서 다루겠습니다.

11.6.2 Abusing Statistics for Discrete Testing

하지만 당신이 열번 수행하면 세번은 실패하는 연속적인 테스트를 가지고 있고, 그 실패를 유발했다고 당신이 생각하는 버그를 고쳤다고 생각해 봅시다. 당신이 실패의 가능성을 줄였다는 점을 99% 확신하려면 얼마나 많은 횟수의 실패 없는 테스트를 수행해야 할까요?

통계를 극단적으로 해치지 않으면서, 우리는 간단히 한시간동안의 수행을 30%의 실패 가능성을 가진 별개의 테스트로 재정의 할 수 있을겁니다. 그렇다면 앞의 섹션에서의 결과는 테스트가 13시간동안 실패 없이 돌아간다면, 우리의 수정사항은 실제로 프로그램의 안정성을 개선했을 가능성이 99%라고 이야기하게 됩니다.

교리적인 통계학자는 이런 접근을 허용하지 않을겁니다만, 슬픈 사실은 이런 종류의 통계 방법론의 오용으로 인해 발생하는 에러는 당신의 프로그램의 실패 확률의 측정에서 피할 수 없는 에러들보다는 훨씬 작다는 것입니다. 하지만, 다음 섹션에서는 약간 덜 사기적인 방법을 설명합니다.

11.6.3 Statistics for Continuous Testing

실패 확률을 위한 기본적인 공식은 Poisson 분포입니다:

$$F_m = \frac{\lambda^m}{m!} e^{-\lambda} \quad (11.8)$$

여기서 F_m 은 테스트에서 m 번 실패할 확률이고 λ 는 단위시간 동안 예상되는 실패 비율입니다. 더 엄격한 유도는 더 나은 확률에 대한 교재들에서 찾아볼 수 있을텐데, 예를 들어 Feller의 고전인 “An Introduction to Probability Theory and Its Application” [Fel50]이 있으며, 더 직관적인 접근법은 이 책의 첫번째 수정본 [McK14a]에서 찾아볼 수 있을 겁니다.

Section 11.6.2에서의 예제를 Poisson 분포를 이용해서 다시 한번 다뤄봅시다. 이 예제가 시간당 30% 실패 확률을 갖는 테스트에 관련된 거라는 점, 그리고 질문은 의심되는 수정사항에 대해 그 수정사항이 정말로 실패 확률을 줄였다고 99% 확신하기 위해서는 테스트가 얼마나 오래 실패 없이 돌아갈 수 있어야 하는가라는 점을 다시 상기합시다. 이 경우에, λ 는 0이므로, Equation 11.8는 다음과 같이 간략화 됩니다:

$$F_0 = e^{-\lambda} \quad (11.9)$$

이걸 풀기 위해서는 F_0 를 0.01로 설정해야 하며, 여기서 λ 를 구해 보면:

$$\lambda = -\ln 0.01 = 4.6 \quad (11.10)$$

우리가 시간당 0.3 회 실패하므로, 요구되는 시간은 $4.6/0.3 = 14.3$ 으로, Section 11.6.2에서 사용한 방법으로 계산한 13시간과 10% 오차 내에 있습니다. 일반적으로는 실패 확률이 10% 내라는 것은 알지 못할 것이라는 점을 놓고 보면, 이는 Section 11.6.2에서의 방법이 상당히 많은 상황에서 Poisson 분포를 대체할 수 있는 훌륭하고 충분한 대체제임을 의미합니다.

더 일반적으로 말해서, 단위시간당 n 번 실패한다면, 그리고 어떤 수정사항이 실패 확률을 줄였다고 $P\%$ 확신하려면 다음의 공식을 사용할 수 있습니다:

$$T = -\frac{1}{n} \ln \frac{100 - P}{100} \quad (11.11)$$

Quick Quiz 11.10: 어떤 버그가 평균적으로 시간당 세번의 테스트 실패를 유발한다고 생각해 봅시다. 수정 사항이 실패의 확률을 상당히 줄였음을 99.9% 증명할 수 있는 증거를 위해서 테스트는 에러 없이 얼마나 오래 돌아가야 할까요? ■

앞에서와 같이, 버그가 덜 빈번하게 발생하고 필요한 확신의 수준이 클수록 에러 없이 테스트가 수행되어야 하는 시간이 길어집니다.

테스트가 매 시간마다 한번씩 실패하지만, 버그 수 정 후, 24시간의 테스트에서 두번만 실패했다고 생각해 봅시다. 해당 버그로 만들어진 실패는 무작위적으로 발생한다고 하면, 두번째 테스트 수행에서의 적은 수의 실패들은 무작위적 기회로 발생한 것일 확률은 얼마일까요? 달리 말해서, 해당 수정이 정말로 버그에 대해서 어떤 영향을 끼쳤다고 얼마나 확신해야 하는 걸까요? 이 확률은 다음과 같이 Equation 11.8 를 합하는 것으로 구할 수 있을 겁니다:

$$F_0 + F_1 + \dots + F_{m-1} + F_m = \sum_{i=0}^m \frac{\lambda^i}{i!} e^{-\lambda} \quad (11.12)$$

이는 Poisson 누적분포지수 (cumulative distribution function) 인데, 더 간단하게는 다음과 같이 쓰일 수 있습니다:

$$F_{i \leq m} = \sum_{i=0}^m \frac{\lambda^i}{i!} e^{-\lambda} \quad (11.13)$$

여기서 m 은 긴 시간동안의 테스트에서의 에러의 갯수 (이 경우, 2) 이고, λ 는 긴 시간동안의 테스트에서 발생하리라 예측된 에러들의 갯수입니다 (이 경우, 24). $m = 2$ 와 $\lambda = 24$ 를 이 수식에 대입하면 약 1.2×10^{-8} 으로 2 언저리의 확률이 나오는데, 달리 말해서, 해당 수정 사항이 정말로 해당 버그에 어떤 관계를 맺었음을 말하는 높은 수준의 증거를 가질 수 있는 겁니다.⁸

Quick Quiz 11.11: 이 모든 계승식 (factorial) 들과 지수식 (exponential) 들을 더하고 있는건 진짜 고통스럽습니다. 좀 더 편한 길은 없나요? ■

Quick Quiz 11.12: 하지만 잠시만요!!! 실패의 어떤 횟수가 있어야 한다는 (실패가 없을 수 있다는 가능성을 포함해서) 점을 놓고 보면, Equation 11.13 에 보여진 더하기는 m 을 1로 놓으면 무한대가 되지 않나요? ■

이 Poisson 분포는 테스트 결과를 분석하기 위한 강력한 도구입니다만 이 마지막 예에서는 24시간동안의 테스트 수행에서의 두개의 실패들이 남아있다는 사실입니다. 그런 낮은 실패 확률은 매우 긴 테스트 수행을 필요로하게 됩니다. 다음 섹션에서는 이 상황을 개선하기 위한 반직관적인 방법들을 논해봅니다.

11.6.4 Hunting Heisenbugs

이런 종류의 생각을 해보는게 heisenbug 를 설명하는데에 도움이 됩니다: 추적 기능과 단정문을 추가하는 것은

버그의 발생 가능성을 줄여버릴 수 있습니다. 그리고 이게 극단적으로 가벼운 추적기능과 단정문 메커니즘이 그렇게 중요한 이유입니다.

“Heisenbug” 란 용어는 특정 입자의 위치와 속도를 어떤 특정 시점에 명시하는 것은 불가능하다는, 양자 물리학의 하이젠버그 불확정성 원리 [Hei27] (Heisenberg Uncertainty Principle) 에서 나왔습니다. 해당 입자의 위치를 좀 더 정확하게 측정하려는 모든 시도는 그것의 속도에 대한 불확정성을 더욱 증가시키는 결과를 낳습니다. 살짝 비슷한 효과가 heisenbug 에 대해서도 발생합니다: heisenbug 를 추적하려는 시도들은 그 버그의 증상을 철저히 바꿔버리거나 완전히 사라져 버리기 조차하게 합니다.⁹

물리학 방면에서 이 문제의 이름에 대한 영감을 받았다면, 그에 대한 해결책을 위해서도 물리학 방면을 찾아보는 것이 논리적입니다. 다행히도, 입자 물리학은 그에 대한 일을 하고 있습니다: Heisenbug 를 섬멸하기 위해 anti-heisenbug 를 창조하면 어떨까요? 또는, 좀 더 정확히 말하자면, heisenbug 의 heisen 스티커를 없애기 위해서?

이 섹션은 그러기 위한 몇가지 방법들을 설명합니다:

1. 레이스 컨디션을 일으키기 쉬운 영역에 딜레이를 추가하기.
2. 워크로드의 강도를 증가시키기.
3. 의심스러운 서브시스템을 격리시켜서 테스트하기.
4. 일반적이지 않은 이벤트를 시뮬레이션 해보기.
5. 실수에 가까운 것들의 수를 세어보기.

특정 heisenbug 를 위한 anti-heisenbug 를 만들어내는건 과학이라기보다는 예술에 가깝습니다만, 다음 섹션들은 anti-heisenbug 에 관련된 것들을 만들어내는데 몇가지 팁을 줄겁니다. 이것들은 토론 섹션인 Section 11.6.4.6 에서 이어집니다.

11.6.4.1 Add Delay

Section 5.1 의 카운트가 누실되는 코드를 생각해 봅시다. 여기에 `printf()` 문을 집어넣는 행위는 누실되는 카운트를 엄청나게 줄이거나 심지어 없애버릴 수도 있을 겁니다. 하지만, 읽어오고-더하고-저장하는 시퀀스를 읽어오고-더하고-기다리고-저장하는 시퀀스로 바꾸는 것은 누실되는 카운트의 발생률을 엄청나게 증가시킬 겁니다 (해보세요!). 레이스 컨디션에 관련되어 있는

⁸ 물론, 이 결과가 남은 두개의 실패들을 만들어낸 버그(들)을 찾아내고 고쳐야 한다는 사실에 대한 명명거리는 되지 않습니다!

⁹ “Heisenbug” 라는 용어는 잘못된 호칭인데, 대부분의 heisenbug 들은 고전 물리학의 관측자 효과로 완전히 설명되기 때문입니다. 그러나, “heisenbug” 라는 이름이 이미 사용되어버렸습니다.

버그를 일단 발견했다면, 이런 식으로 딜레이를 추가하는 것으로 anti-heisenbug 를 만들어내는게 많은 경우에 가능합니다.

물론, 이는 먼저 레이스 컨디션을 어떻게 찾아야 하느지에 대한 의문을 이끌어 냅니다. 이건 약간 어둠의 예술입니다만, 이를 찾기 위해 할 수 있는 것들이 몇 가지 있습니다.

한 가지 방법은, 레이스 컨디션은 많은 경우에 그레이스에 관련된 데이터를 오염시키는 결과를 이끌어 냄을 인식하는 것입니다. 따라서 모든 오염된 데이터의 동기화를 두번씩 체크하는 것은 좋은 습관입니다. 설령 당장은 그 레이스 컨디션을 인식할 수 없다고 해도, 오염된 데이터로의 액세스 전과 후에 딜레이를 추가하는 것은 실패 확률을 바꿀 것입니다. 딜레이들을 잘 조직된 형태 (ex: 이진 탐색) 로 넣고 빼는 것으로, 경주 조건의 동작에 대해 좀 더 알 수 있을 겁니다.

Quick Quiz 11.13: 만약 그 오염이 어떤 관계없는 포인터에 영향을 끼쳐서 그 포인터를 따라가서 오염을 일으키는 경우에 이 방법은 어떻게 도움을 줄 수 있을까요? ■

또 다른 중요한 방법은 소프트웨어와 하드웨어 구성 을 다양하게 해가면서 실패 확률의 통계적으로 심각한 차이를 찾아보는 것입니다. 그리고 나면 실패 확률에 가장 커다란 차이를 만들어낸 소프트웨어나 하드웨어 구성 변경점에 의해 암시되는 코드를 더 집중적으로 보는 것입니다. 예를 들어, 그 코드를 격리시켜서 테스트해보는 것도 도움이 될 수 있을 겁니다.

소프트웨어 구성의 한가지 중요한 측면은 변경의 역사인데, 이게 바로 `git bisect` 이 유용한 이유입니다. 변경 역사의 이등분된 한쪽은 heisenbug 의 원리에 의해 매우 가치있는 단서를 제공할 수 있습니다.

Quick Quiz 11.14: 하지만 제가 그렇게 이등분을 통한 탐색을 해봤는데, 결국 나온 범인은 거대한 커밋이었어요. 이제 뭘 해야 하죠? ■

어떻게든 의심스러운 코드 영역을 찾아냈다면, 이제 당신은 실패의 확률을 증가시키기 위해서 딜레이들을 넣을 수 있습니다. 앞서서 우리가 본 것처럼, 실패의 확률을 증가시키는 것은 관련된 수정사항에 대한 높은 신뢰를 얻기 쉽게 해줍니다.

하지만, 일반적인 디버깅 테크닉을 사용해서 그런 문제를 추적하는 것은 어떤 경우에는 상당히 복잡합니다. 뒤따르는 섹션들은 몇 가지 다른 대안들을 제시합니다.

11.6.4.2 Increase Workload Intensity

특정 테스트 셋이 특정 서브시스템에만 상대적으로 적은 스트레스를 가함으로 인해 타이밍에 대한 작은 변화가 생겨 heisenbug 를 사라지게 하는 경우가 종종 있습니다. 이런 경우를 위한 anti-heisenbug 를 만들어내는 한 가지 방법은 워크로드의 강도를 증가시키는 것으로,

이는 버그가 나타날 확률을 올립니다. 만약 확률이 충분히 증가한다면, 버그가 사라지게 하지 않으면서도 추적 기능과 같은 가벼운 디버깅 기능들을 추가할 수도 있을 겁니다.

워크로드의 강도를 어떻게 증가시킬 수 있을까요? 프로그램에 따라 다르긴 합니다만, 여기 몇 가지 시도해 볼만한 것들이 있습니다:

1. CPU 를 더 사용합니다.
2. 프로그램이 네트워크를 사용한다면, 더 많은 네트워크 어댑터와 원격의 시스템을 더 많이 추가하거나 더 빠른 것으로 바꾸세요.
3. 프로그램이 문제가 발생할 때 무거운 I/O 를 하고 있다면, (1) 더 많은 저장장치를 추가하거나, (2) 디스크를 SSD 로 대체하거나 하는 식으로 더 빠른 저장 장치를 사용하거나, (3) 대용량 저장장치를 메인 메모리로 대체하기 위해 RAM 기반 파일시스템을 사용하세요.
4. 예를 들어 병렬 행렬 곱셈을 하고 있다면 행렬의 크기를 바꾸는 식으로 문제의 크기를 바꾸세요. 더 큰 문제는 더 많은 복잡도를 가져올 수 있습니다만, 더 작은 문제는 종종 경쟁의 수준을 증가시킵니다. 더 크게 해야 할지 작게 해야 할지 모르겠다면, 그냥 둘 다 해보세요.

하지만, 버그가 특정 서브시스템 안에 있고, 프로그램의 구조가 그 서브시스템에 가해질 수 있는 스트레스의 양을 제약하고 있는 경우가 종종 있습니다. 다음 섹션은 이 상황을 다뤄봅니다.

11.6.4.3 Isolate Suspicious Subsystems

의심되는 서브시스템에 큰 스트레스를 가하는 것이 어렵거나 불가능한 구조로 프로그램이 짜여져 있는 경우에 유용한 anti-heisenbug 는 서브시스템을 격리시켜서 테스트하는 스트레스 테스트입니다. 리눅스 커널의 `rcutorture` 모듈은 RCU 에 대해 정확히 이 방법을 취하고 있습니다: 제품 환경에서 가능한 것보다 많은 스트레스를 RCU 에 가함으로 인해, 제품 사용 상황에서보다 `rcutorture` 테스트 중에 RCU 버그가 발견될 확률이 높아집니다.¹⁰

사실, 병렬 프로그램을 만들 때에는 컴포넌트들을 개별적으로 스트레스 테스트 하는게 현명합니다. 그런 컴포넌트 단계의 스트레스 테스트들을 만들어내는 것은 시간 낭비처럼 보일 수도 있습니다만 약간의 컴포넌트 단계 테스트가 수많은 시스템 단계 디버깅을 줄일 수 있습니다.

¹⁰ 슬프게도 확률이 1까지 되지는 못하긴 하지만 말이죠.

11.6.4.4 Simulate Unusual Events

Heisenbug 는 어떨 때에는 메모리 할당 실패, 조건적 락 획득 실패, CPU-hotplug 오퍼레이션, 타임아웃, 패킷 로스 등의 일반적이지 않은 이벤트로 인해 발생하기도 합니다. 이런 종류의 heisenbug 를 위한 anti-heisenbug 를 구성하는 한가지 방법은 가짜 실패를 만들어내는 겁니다.

예를 들어, `malloc()` 을 곧바로 호출하는 대신에, 그냥 무조건적으로 NULL 을 리턴하거나 정말로 `malloc()` 을 호출하고 그 결과로 나온 포인터를 리턴할지 NULL 을 리턴할지 무작위적으로 선택하는 wrapper 함수를 호출하는 겁니다. 가짜 실패를 만들어내는 것은 별로 프로그램은 물론, 순차적 프로그램에서도 견고성을 만들어내기 위한 좋은 방법입니다.

Quick Quiz 11.15: 이미 존재하는 조건적 락킹 도구들은 이런 가짜 실패 기능을 제공하지 않는 이유가 뭘까요? ■

11.6.4.5 Count Near Misses

버그는 대부분의 경우 그렇거나 아니거나인 것들이어서 버그는 발생하거나 그렇지 않거나일뿐, 중간의 것은 없습니다. 하지만, 버그가 실패를 만들어내지는 않지만 거의 명백한 경우인 *near miss* 를 정의하는게 가능한 경우가 간혹 있습니다. 예를 들어, 당신의 코드가 로봇을 걷게 한다고 생각해 봅시다. 이 로봇이 넘어지는 일은 당신의 프로그램 안에 버그가 있음을 나타낼 것입니다만, 비틀거리고서는 회복되는 것은 *near miss* 를 나타낼 수도 있습니다. 만약 로봇이 한시간에 한번만 넘어진다면, 하지만 몇분마다 비틀거린다면, 넘어지는 횟수에 대해서 비틀거리는 횟수를 셈으로써 디버깅 진도를 좀 더 빠르게 만들 수 있을 겁니다.

동시성이 존재하는 프로그램에서는 타임스탬프를 찍는 일이 가끔은 *near miss* 를 파악해 내는데 사용될 수 있습니다. 예를 들어, 락킹 도구들은 상당한 딜레이를 일으키는데, 같은 락에 대해서 서로 다른 획득을 통해 보호될 것으로 생각되는 한쌍의 오퍼레이션들 사이에 너무 짧은 딜레이가 존재한다면, 이 너무 짧은 딜레이는 *near miss* 로 카운트될 수도 있을 겁니다.¹¹

예를 들어, RCU 의 우선순위 올리기에 있는 낮은 확률의 버그는 `rcutorture` 의 집중된 테스트에서 대략 100 시간에 한번 일어났습니다. 그 버그가 일어날 확률이 상당히 감소되었음을 99% 확신하기 위해서는 거의 500 시간의 실패 없는 테스트 수행이 필요하기 때문에, 그 실패를 찾아내기 위한 `git bisect` 과정은 고통스러울 정도로 느릴겁니다—또는 극단적으로 거대한 테스트




Figure 11.5: RCU Errors and Near Misses

환경을 필요로 할겁니다. 다행히도, 테스트된 해당 RCU 오퍼레이션은 RCU grace period 를 위한 대기만이 아니라, 시작하기 위한 그 grace period 에 대한 앞선 대기와 그 RCU grace period 가 완료된 후에 호출될 RCU callback 을 위한 뒤이은 대기도 존재했습니다. `rcutorture` 에서와 *near miss* 사이의 차이가 Figure 11.5 에 보여져 있습니다. 완전히 본격적인 에러로 구분되기 위해서, RCU read-side 크리티컬 섹션은 grace period 를 시작한 `call_rcu()` 로부터 앞의 grace period 의 남아있는 부분과 `call_rcu()` 로 시작된 grace period 전체 (지그재그로 그어진 선으로 표시된 영역), 그리고 그 grace period 의 끝으로부터 callback 의 호출 사이의 딜레이까지 확장되는데, 이게 “Error” 화살표로 표시되어 있습니다.

하지만, 정형적 RCU 의 정의는 RCU read-side 크리티컬 섹션이 하나의 grace period 를 넘어 확장되는 것을 금지하는데, 이는 “Near Miss” 화살표로 나타내어져 있습니다. 이는 *near miss* 들을 예리 조건으로 사용할 것을 제안하지만, 다른 CPU 들은 해당 grace period 가 정확히 언제 시작되고 종료되었는지에 대해 지그재그로 그어진 선으로 보여지듯이 다른 의견을 가질 수 있기 때문에, 이는 문제가 될 수 있습니다.¹² 따라서 이 *near miss* 들을 예리 컨디션으로 사용하는 것은 거짓 양성 결과를 만들어낼 수 있는데, 이는 자동화된 `rcutorture` 테스트에서는 제거되어야 합니다.

순수히 바보같은 운으로 인해, `rcutorture` 는 grace period 의 *near-miss* 버전에 민감한 통계를 포함하게 되었습니다. 앞서 이야기한대로, 이런 통계들은 RCU 의 상태 변수들에 대한 동기화 되지 않은 액세스로 인해서 거짓 양성 결과에 영향을 받기 쉽습니다만, 이런 거짓 양성 결과는 IBM 메인프레임이나 x86 과 같은 강한 순서 규칙의 시스템들에서는 상당히 희귀하게 발생하는

¹¹ 물론, 이 경우 `lock_held()` 기능과 같은, 뭐가 됐든 당신의 환경 상에서 사용 가능한 것을 사용하는게 나을 수도 있을 겁니다. 만약 `lock_held()` 기능이 없다면, 하나 만들어서 쓰세요!

¹² 아무일도 하지 않고 있는 CPU 들은 최근의 수백개의 grace period 에 대해서도 전혀 알지 못하고 있을 수도 있기 때문에, 이 지그재그로 그어진 라인들은 상당히 과소평가 되어 있습니다.

것으로 드러났는데, 1000 시간의 테스트 가운데 한번 보다도 낮은 확률로 일어납니다.

이런 near miss 들은 대략 한시간에 한번 꼴로 발생했는데, 이는 실제 에러들보다 100배 이상 빈번하게 발생하는 겁니다. 이런 near miss 들의 사용은 버그의 원인을 일주일 안되는 시간 내에 파악해내고 수정된 내용의 효과를 하루 내에 확신하는 것을 가능하게 했습니다. 반면에, 진짜 에러만을 보기 위해서 near miss 들을 제외시키는 행위는 수개월의 디버그와 검증 시간을 필요로 했습니다.

Near-miss 카운팅을 정리하자면, 일반적인 방법은 빈번하지 않게 발생하는 실패의 횟수를 세는 것을 더 빈번하게 발생하며 그 실패들과 연관되어 있을 것으로 여겨지는 near miss 의 횟수를 세는 것으로 대체하는 것입니다. 이런 near-miss 들은 진짜 실패의 heisenbug에 대한 anti-heisenbug 로 여겨질 수 있는데, 더 빈번하게 발생하는 near-miss 들은 예를 들어 디버깅 코드를 추가하기 위해 만드는 것과 같은 코드의 변경이 있는 상황에서도 그 발생률이 더 일관될 것이기 때문입니다.

여태까지, 우리는 병렬 프로그램의 기능성에서의 버그에 대해서만 집중해 왔습니다. 하지만, 성능이 병렬 프로그램에서의 첫번째 필요사항이기 때문에 (그렇지 않다면, 순차적 프로그램을 짜지 그려세요?), 다음 섹션에서는 성능상의 버그들을 찾아내는 방법을 알아봅니다.

11.6.4.6 Heisenbug Discussion

주의깊은 독자라면 이 섹션이 Section 11.6.1, 11.6.2, 그리고 11.6.3의 정교한 수학에 비해 모호하고 계량적임을 눈치챘을 겁니다. 여러분이 정확성과 수학을 사랑한다면, 이 섹션이 적용될 수 있는 환경이 앞의 섹션들이 적용될 수 있는 것에 비해 상당히 더 흔하다는 사실에 실망할 수도 있을 겁니다.

여러분의 코드에 버그가 있을 것이라 믿는다 해도, 그 버그가 무엇인지, 무엇이 그것을 일으켰는지, 그것들이 어떻게 나타날 것인지, 또는 어떤 조건이 그것들의 발생 확률에 영향을 끼치는지를 알 수 없다는게 실제로 그 흔한 상황입니다. 이 모든-너무-흔한 경우에, 통계는 여러분을 돋지 못합니다.¹³ 바꿔 말하면, 통계가 여러분을 직접적으로 돋지는 못합니다. 하지만 통계는 간접적인 커다란 도움을 줄 수 있는데—만약 여러분이 (예를 들면, 충분히 sleep 을 해버린다던가 함으로써) 실수의 확률을 줄일 수도 있는 실수를 만들 수 있다는 걸 인정하는데 필요한, 그리고 여러분이 과거에 만들어낸 실수들의 수와 종류가 미래에도 일어날 수 있다는 걸 인정하는데 필요한 겸손을 갖는다면 그렇습니다. 예를 들어, 저는

¹³ 여러분의 프로그램이 해야 할 일이 무엇인지 (여러분 생각과 달리 그럴 확률이 적겠지만) 알고 여러분의 프로그램이 충분히 작다면 Chapter 12에서 설명한 정적 검증 도구가 도움이 될 수 있긴 합니다.

초기화 코드의 작지만 치명적인 부분들을 작성하는 걸 잊고 종종 병렬 프로그램의 정확성의 대부분 또는 전체를 망가뜨리는 개탄스러운 성향을 갖고 있습니다. 일단 제가 이런 종류의 실수에 취약하다는 사실을 스스로 인정하기로 한 후로, 저 자신이 제 초기화 코드를 두번씩 체크하도록 하는게 더 쉬워졌습니다 (하지만 쉽지 않아요!). 이렇게 하는게 제가 많은 버그들을 찾을 수 있게 해줬습니다.

Taleb의 명명법 [Tal07] 을 사용하면, white swan 은 우리가 재현할 수 있는 버그입니다. 우린 더 많은 수의 테스트를 수행하고, 그 버그의 확률을 추정하는데 보통의 통계를 사용하고, 우리의 수정 여부 신뢰성을 추정하는데 보통의 통계를 사용할 수 있습니다. 예상치 못한 버그는 black swan 입니다. 우린 그에 대해 아무것도 알지 못하고, 그걸 발생시킬 수 있는 테스트를 가지고 있지 않으며, 통계도 도움이 되지 못합니다. 우리 스스로의 행동을 연구하는 것, 특히 우리가 만들어내는 실수들의 수와 종류를 연구하는 것은 black swan 들을 grey swan 으로 바꿔 놓을 수 있습니다. 일반적인 통계는 (우리가 이 버그들을 재현할 수 있게 되기 전까지는) 여전히 도움이 되지 않을 뿐더러 취약합니다¹⁴ 테스트 방법론은 큰 도움이 될 수 있습니다. 따라서, 목표는 이 black swan 들을 grey swan 들로 바꾸는 경험과 좋은 검증 방법들을 사용하고, 이 grey swan 들을 white swan 들로 바꾸기 위해 집중된 테스트와 분석을 사용하고, 이 white swan 들을 고치는데 일반적 방법들을 사용하는 것입니다.

그렇다고는 하나, 우린 병렬 프로그램의 기능성에 대한 버그에만 집중해 왔습니다. 하지만, 성능이야말로 병렬 프로그램의 1급 필요성이기 때문에 (아니라면, 순차적 프로그램을 써야겠죠?), 다음 섹션에서는 성능 버그에 대해 이야기 하겠습니다.

11.7 Performance Estimation

There are lies, damn lies, statistics, and benchmarks.

—————
Unknown

병렬 프로그램은 보통 성능과 확장성에 대한 요구를 받게 됩니다. 무엇보다, 만약 성능이 문제가 아니라면, 순차적 프로그램을 사용하는게 낫겠죠? 궁극의 성능과 선형적 확장성까지는 필요하지 않을 수도 있습니다만, 순차적으로 같은 일을 하는 최적화된 프로그램보다 느리게 동작하는 병렬 프로그램은 많이 사용되지 않을 겁니다. 그리고 마이크로세컨드도 문제가 되고 나노세컨드라도 필요한 경우들이 정말로 존재합니다. 따라서,

¹⁴ 바꿔말하면 악독합니다.

병렬 프로그램에 있어서, 불충분한 성능은 올바르지 못하게 동작하는 것만큼이나 커다란 버그입니다.

Quick Quiz 11.16: 그건 웃긴 이야기네요!!! 어쨌든, 좀 늦더라도 올바른 답을 얻는게 잘못된 답을 얻는 것보다는 낫지 않겠어요??? ■

Quick Quiz 11.17: 하지만, 어플리케이션을 병렬화하기 위해 필요한 모든 어려운 일을 해내기로 했다면 왜 그걸 올바르게 하지 않는거죠? 왜 최적의 성능과 선형적인 확장성보다 못한 것에 안주하는 겁니까? ■

따라서 병렬 프로그램을 검증하는 일은 그 성능을 검증하는 것을 포함합니다. 하지만 성능을 검증하는 일은 수행시킬 워크로드와 그 프로그램을 평가할 성능 지표를 가지고 있음을 의미합니다. 이런 필요한 것들은 성능 벤치마크로 얻어지기도 하는데, 다음 섹션에서 이에 대해 논해 봅니다.

11.7.1 Benchmarking

자주 오남용되긴 하지만, 벤치마크는 유용하기도 하고 많이 사용되므로, 벤치마크에 너무 부정적인 도움이 되지 않습니다. 벤치마크는 임시 변통의 움직임들부터 국제적인 표준까지 그 범위가 다양합니다만, 그것들의 정형성의 수준과는 관계없이, 벤치마크는 네개의 주요 목적을 위해 사용됩니다:

1. 비교되는 구현들을 공정하게 비교하기 위한 프레임워크를 제공합니다.
2. 사용자에게 가치있는 방향으로 구현을 개선하기 위한 경쟁적 에너지에 집중합니다.
3. 벤치마크되는 구현의 예제적 사용으로서의 역할을 합니다.
4. 당신의 소프트웨어의 강점을 경쟁자가 제공하는 것에 대비해 강조하는 마케팅 도구의 역할을 합니다.

물론, 완전하게 공정한 프레임워크는 의도된 어플리케이션 그 자체밖에 없습니다. 그런데 벤치마킹에서의 공정성에 대해서 신경쓰는 사람이라면 단순히 그 어플리케이션 자체를 벤치마크로 사용하지 않고 왜 불완전한 벤치마크들을 만들어낼 생각을 하는 걸까요?

실제 어플리케이션을 수행하는 것은 그게 실용적인 곳에서라면 실제로 그게 최고의 방법입니다. 불행히도, 그건 다음과 같은 이유로 실용적이지 못한 경우가 많습니다:

1. 그 어플리케이션은 독점된 것이고, 당신이 그 어플리케이션을 수행할 권한을 갖고 있지 못할 수 있습니다.

2. 그 어플리케이션은 당신이 접근할 수 없는 더 많은 하드웨어를 필요로 할 수도 있습니다.
3. 그 어플리케이션은 예를 들어 개인정보 규제와 같은 이유로 여러분이 접근할 수 없는 데이터를 사용할 수도 있습니다.

그 어플리케이션을 모사하는 벤치마크를 만드는 것이 이런 문제들을 극복하는데 도움이 될 수 있습니다. 세심하게 구성된 벤치마크는 성능, 확장성, 에너지 효율성, 그리고 그 외에도 많은 것들을 향상시키는데 도움이 될 수 있습니다. 하지만, 벤치마크에 너무 많이 노력을 기울이진 않게 조심하세요. 어느정도는 어플리케이션 자체에 노력을 기울이는게 무엇보다 중요합니다 [Gra91].

11.7.2 Profiling

소프트웨어의 아주 작은 부분이 성능과 확장성 한계의 주요한 책임을 가지고 있는 경우가 많습니다. 하지만, 개발자들이 실제 병목지점을 손으로 찾아내기는 매우 어렵습니다. 예를 들어, 커널 버퍼 할당자의 경우에 있어서, 모든 관심은 밀집도가 높은 배열의 탐색에 집중되었습니다만 이는 할당자의 실행 시간 중 몇 퍼센트만을 차지하는 것으로 드러났습니다. 논리 분석기를 통해 수집된 수행 프로파일은 정말로 문제의 주요한 부분에 책임이 있었던 캐시 미스에 관심을 집중시켰습니다 [MS93].

성능과 확장성 버그를 추적하는데 있어 옛날 방식이지만 상당히 효과적인 한가지 방법은 프로그램을 디버거와 물려서 수행시키면서 주기적으로 프로그램을 인터럽트 하고서 매 인터럽트마다 모든 쓰레드의 스택을 기록하는 것입니다. 여기서의 이론은 무언가가 프로그램을 느리게 만들고 있다면, 그것은 쓰레드의 수행 과정에 보일 것이라는 겁니다.

그렇지만, 당신의 관심을 가장 필요한 곳에 집중할 수 있도록 도와주는데 있어 일반적으로는 훨씬 나은 일을 해주는 많은 도구들이 있습니다. 대중적인 두 가지 선택이 있는데 gprof 와 perf입니다. 단일 프로세스 프로그램에 perf를 사용하려 한다면 그 프로그램을 수행하는 커맨드 앞에 perf record 를 붙여서 수행하고, 그 커맨드가 완료된 후에, perf report 를 입력하세요. 멀티 쓰레드 프로그램의 성능 디버깅을 위한 도구를 위한 많은 노력들이 있었는데, 이것들은 이 중요한 일을 좀 더 쉽게 만들었습니다. 다시한번 말하지만, Brendan Gregg의 블로그가 시작점으로 좋습니다.¹⁵

11.7.3 Differential Profiling

확장성 문제는 프로그램을 매우 큰 시스템들에서 수행해보기 전까지 분명하지 않을 겁니다. 하지만, 훨씬 작은

¹⁵ <http://www.brendangregg.com/blog/>

시스템에서 프로그램을 수행할 때라고 해도 임박한 확장성 문제를 찾아내는 것이 가능할 때도 있습니다. 이를 위한 한 가지 테크닉은 차이점 프로파일링 (*differential profiling*)이라고 불립니다.

아이디어는 워크로드를 두 개의 서로 다른 조건들로 집합에서 수행해 보는 겁니다. 예를 들어, 워크로드를 두 개의 CPU 위에서 돌려볼 수 있고, 그리고나서는 또 다시 네 개의 CPU 위에서 해보는 겁니다. 또는 시스템에 가하는 부하의 정도, 네트워크 어댑터들의 갯수, 대용량 저장장치의 갯수, 등을 다양하게 변화시켜볼 수 있습니다. 그리고나서 두 수행의 프로파일 결과를 모으고, 수학적으로 관련된 프로파일 측정 결과를 조합해 보는 겁니다. 예를 들어, 주요한 관심이 확장성이라면, 연관된 측정의 비율을 취하고, 그 비율들을 숫자상으로 내림차순 정렬해 볼 수 있을 겁니다. 가장 의심스러운 확장성에 대한 용의자는 정렬된 리스트의 꼭대기에 위치하게 될 겁니다 [McK95, McK99].

`perf` 와 같은 일부 도구들은 내장된 차이점 프로파일링 지원 기능을 가지고 있습니다.

11.7.4 Microbenchmarking

マイクロベンチ마킹은 소프트웨어의 더 큰 부분에 포함되기에 어떤 알고리즘이나 데이터 구조가 더 적합할지를 결정하는데에 있어 더 깊은 평가를 위해 유용할 수 있습니다.

マイクロベンチ마킹을 하는 흔한 방법 한 가지는 시각을 측정하고, 테스트 되는 코드를 몇 번 반복해서 수행시키고, 다시 시각을 측정하는 것입니다. 두 개의 시각 사이의 차이를 반복 횟수로 나누면 테스트 되는 코드를 수행하는데 필요한 시간의 측정값이 나옵니다.

불행히도, 측정을 위한 이 방법은 여러 오류가 끼어들 수 있는데, 다음과 같은 것들이 있습니다:

1. 이 측정은 시각 측정의 오버헤드가 포함될 수 있습니다. 이 에러는 수행 반복 횟수를 증가시킴으로써 매우 작은 크기로 만들 수 있습니다.
2. 처음 몇 번의 테스트 수행 반복은 캐시 미스나 (더 나쁜) 페이지 폴트를 유발할 수도 있는데, 이는 측정된 값을 부풀릴 수도 있을 겁니다. 이런 에러 역시 수행 반복의 수를 늘림으로써 줄일 수 있으며, 측정 기간이 시작되기 전에 몇 번의 웜업 수행 반복을 수행시킴으로써 완전히 없앨 수 있는 경우도 많습니다.
3. 예를 들어 임의의 메모리 어러와 같은 간섭의 일부 종류들은 테스트의 수행 반복의 여러 세트를 수행시킴으로써 조치가 될 수 있을 정도로 드물게

발생합니다. 만약 간섭의 정도가 통계적으로 심각하다면, 모든 유난스럽게 다른 성능 결과들을 통계적으로 제거시킬 수 있습니다.

4. 모든 테스트 반복 수행이 시스템의 다른 활동에 의해 간섭을 받을 수 있습니다. 간섭의 근원은 다른 어플리케이션들, 시스템 유ти리티들과 데몬, 디바이스 인터럽트, 펌웨어 인터럽트(시스템 관리 인터럽트인 SMI 포함), 가상화, 메모리 어러, 그리고 그 외에도 다른 여러 가지가 있을 수 있습니다. 이런 간섭 유발 사건들이 무작위적으로 발생한다고 가정하면, 그것들의 효과는 반복 횟수를 줄임으로써 최소화 시킬 수 있습니다.

간섭 유발 사건들 중 첫번째와 네번째 것은 서로 상충되는 조언을 하고 있는데, 이는 우리가 실제 세계에 살고 있다는 한 가지 증거입니다. 이 섹션의 나머지 부분에서는 이런 상충되는 것을 어떻게 해결해야 할지 알아봅니다.

Quick Quiz 11.18: 하지만, 예를 들어 캐시와 메모리 배치 사이의 간섭에 의한 것과 같은 다른 여러 유발 요인들은 어떻게 하죠? ■

다음의 세션들은 측정 에러들을 처리하는 방법들을 이야기하는데, Section 11.7.5에서는 일부 형태의 간섭들을 막기 위해서 사용될 수 있는 격리화 테크닉들을 다루고, Section 11.7.6는 간섭으로 인해 오염되었을 수 있는 측정 데이터를 버릴 수 있도록 간섭을 파악하는 방법들을 다룹니다.

11.7.5 Isolation

리눅스 커널은 특정 CPU 들을 바깥의 간섭으로부터 격리시키는 몇 가지 방법들을 제공합니다.

먼저, 다른 프로세스, 쓰레드, 그리고 태스크에 의해 가해질 수 있는 간섭을 봅시다. `POSIX sched_setaffinity()` 시스템 콜은 많은 태스크들을 특정 CPU 들로부터 몰아내고 당신의 테스트들을 같은 그룹의 CPU 들에 가둬두는데 사용될 수 있습니다. 리눅스에 존재하는 사용자 레벨 `taskset` 커맨드도 같은 목적으로 사용될 수도 있습니다만 `sched_setaffinity()` 와 `taskset`은 모두 상승되는 권한을 필요로 하긴 합니다. 리눅스에 존재하는 control groups (cgroups)가 같은 목적으로 사용될 수도 있습니다. 이 방법은 간섭을 줄이는데 있어 상당히 효과적일 수 있고, 많은 경우에는 이걸로 충분합니다. 하지만, 이 방법도 한계가 있는데, 예를 들어, 태스크들을 잡아두기 위해 자주 사용되는 per-CPU 커널 쓰레드에 대해서는 아무일도 해주지 못합니다.

per-CPU 커널 쓰레드로부터의 간섭을 피하는 한 가지 방법은, 예를 들어 `POSIX sched_setscheduler()`

시스템 콜을 이용하거나 해서 테스트를 높은 real-time 우선순위로 수행시키는 겁니다. 하지만, 만약 이렇게 할 경우, 당신은 묵시적으로 무한 루프를 막는다는 책임을 갖게 되는 것인데, 그러지 않는다면 그 테스트는 커널의 한 부분이 동작을 못하게 만들어 버릴 것이기 때문입니다.¹⁶

이런 방법들은 프로세스, 쓰레드, 그리고 태스크들로부터의 간섭을 상당히 줄이고, 심지어 없애버릴 수도 있습니다. 하지만, 쓰레드 인터럽트가 없다 해도 디바이스 인터럽트로부터의 간섭을 막는 효과는 없습니다. 리눅스는 인터럽트 벡터당 하나씩 숫자로 된 디렉토리들을 담고 있는 /proc/irq 디렉토리를 통해 쓰레드 인터럽트를 일부 제어할 수 있게 해줍니다. 각각의 숫자 이름의 디렉토리는 smp_affinity 와 smp_affinity_list 를 담고 있습니다. 충분한 권한을 가지고 있다면, 특정 CPU 들로의 인터럽트를 제한하기 위해 이 파일들에 값을 써넣을 수 있습니다. 예를 들어, “sudo echo 3 > /proc/irq/23/smp_affinity” 는 vector 23 의 인터럽트들을 CPU 0 과 1 에 국한시킬 겁니다. 같은 결과가 “sudo echo 0-1 > /proc/irq/23/smp_affinity_list” 를 통해 얻어질 수도 있습니다. 시스템의 인터럽트 벡터들의 리스트, 각 CPU 에 의해 얼마나 많이 처리되는지, 그리고 어떤 기기가 각각의 인터럽트 벡터를 사용하는지에 대한 정보를 얻기 위해 “cat /proc/interrupts” 를 사용할 수도 있습니다.

비슷한 커맨드를 시스템 상의 모든 인터럽트 벡터들에 대해 수행시키면 인터럽트들이 CPU 0 과 1 에 모두 국한되어서, 나머지 CPU 들을 간섭으로부터 자유로워지게 만들 겁니다. 또는 간섭으로부터 거의 자유이긴 한데, 어쨌던지요. 스케줄링 클락 인터럽트가 유저 모드로 돌아가고 있는 각각의 CPU 에서 발생함이 드러났습니다.¹⁷ 또한 인터럽트들을 가둔 CPU 들이 그 부하를 충분히 처리할 수 있음이 분명하도록 신경을 써 주어야만 합니다.

하지만 이는 같은 운영체제 위에서 돌아가고 있는 프로세스와 인터럽트들만을 처리합니다. 예컨대, KVM 을 통해 수행되는 리눅스와 같이 그 자체로 하이퍼바이저 위에서 돌아가고 있는 게스트 OS 안에서 테스트를 돌린다고 생각해 봅시다. 이론적으로는 같은 테크닉을 게스트 OS 수준에서 할 수 있듯이 하이퍼바이저에게 가 할 수도 있겠지만, 하이퍼바이저 단계의 오퍼레이션들은 권한을 가진 개인에게만으로 제약되어 있는 경우가 상당히 흔합니다. 또한, 이런 테크닉들 중 어느 하나도

¹⁶ 이건 스파이더맨 원칙의 한 예입니다: “With great power comes great responsibility.”

¹⁷ Frederic Weisbecker 는 하나의 실행 가능한 태스크만을 가지고 있는 CPU 들에 대해서는 스케줄링 클락 인터럽트가 꺼지도록 하는 NO_HZ_FULL adaptive-ticks 프로젝트를 작업하고 있습니다만, 2017 년 초에 이르러 이 작업은 많이 완료되었지만 완전히 완료되지는 않았습니다.

Listing 11.1: Using getrusage() to Detect Context Switches

```

1 #include <sys/time.h>
2 #include <sys/resource.h>
3
4 /* Return 0 if test results should be rejected. */
5 int runtest(void)
6 {
7     struct rusage ru1;
8     struct rusage ru2;
9
10    if (getrusage(RUSAGE_SELF, &ru1) != 0) {
11        perror("getrusage");
12        abort();
13    }
14    /* run test here. */
15    if (getrusage(RUSAGE_SELF, &ru2 != 0) {
16        perror("getrusage");
17        abort();
18    }
19    return (ru1.ru_nvcsw == ru2.ru_nvcsw &&
20            ru1.ru_nivcsw == ru2.ru_nivcsw);
21 }

```

펌웨어 수준의 간섭에 대해서는 아무 일도 하지 못합니다.

Quick Quiz 11.19: 테스트 되는 코드를 격리시키기 위해 제안된 이 테크닉들은 특히나 그 코드가 커다란 어플리케이션에서 돌아가고 있다면 그 코드의 성능에 영향을 끼치지 않을까요? ■

이런 고통스운 상황에 놓여있다면, 간섭을 방지하고 하는 대신에, 다음 섹션에 설명된 것처럼 간섭을 찾아내야만 합니다.

11.7.6 Detecting Interference

간섭을 예방할 수 없다면, 증상에 기반해서 간섭을 찾아내고 그 간섭으로 영향을 받은 테스트 결과를 제거할 수 있을 겁니다. Section 11.7.6.1 에서는 추가적인 측정을 통한 잘못된 결과값 제거 방법을 알아보고, Section 11.7.6.2 에서는 통계 기반의 결과 제거 방법을 알아봅니다.

11.7.6.1 Detecting Interference Via Measurement

리눅스를 포함한 많은 시스템들에서는 뒤늦게라도 어떤 형태의 간섭이 일어났었는지를 판단할 수 있는 방법을 제공합니다. 예를 들어, 테스트가 프로세스 기반의 간섭을 만났었다면, 테스트 도중에 컨텍스트 스위치가 일어났을 겁니다. 리눅스 기반의 시스템에서 컨텍스트 스위치는 /proc/<PID>/sched 안의 nr_swatches 필드에 보여질 겁니다. 비슷하게, 인터럽트 기반의 간섭은 /proc/interrupts 파일을 통해 판단될 수 있습니다.

파일을 열고 읽는 것은 낮은 오버헤드를 위한 방법이 아니고, Listing 11.1 에 보여진 것처럼 getrusage() 시스템 콜을 사용해서 주어진 쓰레드의 컨텍스트 스위치

횟수를 얻는 것이 가능합니다. 마이너 페이지 폴트와 메이저 페이지 폴트를 파악하기 위해서 이와 같은 시스템 콜 (`ru_minflt`, `ru_majflt`)을 사용할 수 있습니다.

안타깝게도, 메모리 어러와 펌웨어 간섭을 파악하는 것은 가상화로 인한 간섭을 파악하는게 그런 것처럼 상당히 실제 시스템에 의존적입니다. 비록 간섭을 파악하는 것보다는 없애는게 낫고, 파악이 통계보다는 낫겠지만, 다음 섹션에서 다루게 될 주제인 통계에 기대야만 하는 경우도 있습니다.

11.7.6.2 Detecting Interference Via Statistics

모든 통계 분석은 데이터에 대한 가정을 기반으로 가지고 있고, 성능 마이크로 벤치마크는 많은 경우 다음과 같은 가정을 지원합니다:

- 작은 측정이 커다란 측정보다 더 정확할 것이다.
- 좋은 데이터의 측정에 대한 불확실성은 알려져 있다.
- 테스트 수행 결과 중 합리적 수준의 분량은 좋은 데이터를 내놓을 것이다.

더 작은 측정이 더 커다란 측정에 비해서 더 정확할 수 있다는 사실은 측정을 크기가 증가하는 순서대로 정렬하는 것이 생산적일 것임을 암시합니다.¹⁸ 측정의 불확실성이 알려졌다는 사실은 이 불확실성에 기반한 측정을 받아들일 수 있도록 합니다: 만약 간섭의 효과가 이 불확실성에 비해서 크다면, 이는 나쁜 데이터를 버리는 것을 덜어줄 겁니다. 마지막으로, 일부 분량(예를 들어, 3분의 1)은 좋은 데이터일 것이라 가정될 수 있다는 사실은 정렬된 리스트에서 첫번째 부분을 별다른 검사 없이 받아들이는 것을 가능하게 할 것이고, 이 데이터는 측정된 데이터의 자연적인 분포도를 가정된 측정의 오류를 넘어서서 추정하는 데에 사용될 수 있을 것입니다.

이 방법은 정렬된 리스트의 앞쪽의 특정 갯수의 원소들을 취하고, 이것들을 일반적인 원소간의 차이를 추정하는데에 사용하는 것으로, 이렇게 추정된 값은 받아들여질 수 있는 값의 최대 한계치를 얻기 위해서 리스트의 원소의 수를 곱하게 될 수도 있을 겁니다. 이 알고리즘은 이제 리스트의 다음 원소들을 반복적으로 받아들일 수 있을지 고려하게 됩니다. 만약 다음 원소의 값이 앞서 구한 최대 한계치 아래라면, 그리고 이 원소와 그 앞의 원소 사이의 거리가 앞서 받아들여진 리스트의 원소들 사이의 평균적 원소간 거리보다 너무 크지 않다면 그 원소는 받아들여지고 이 과정이 반복됩니다. 만약 그렇지 않다면, 리스트의 나머지 값들은 버려집니다.

¹⁸ 오랜 격언을 바꿔 말하자면, “정렬부터 하고 질문은 그다음에 하라.”

Listing 11.2: Statistical Elimination of Interference

```

1 divisor=3
2 relerr=0.01
3 trendbreak=10
4 while test $# -gt 0
5 do
6   case "$1" in
7     --divisor)
8     shift
9     divisor=$1
10    ;;
11   --relerr)
12     shift
13     relerr=$1
14    ;;
15   --trendbreak)
16     shift
17     trendbreak=$1
18    ;;
19   esac
20   shift
21 done
22
23 awk -v divisor=$divisor -v relerr=$relerr \
24   -v trendbreak=$trendbreak '{'
25   for (i = 2; i <= NF; i++)
26     d[i - 1] = $i;
27   asort(d);
28   i = int((NF + divisor - 1) / divisor);
29   delta = d[i] - d[1];
30   maxdelta = delta * divisor;
31   maxdelta1 = delta + d[i] * relerr;
32   if (maxdelta1 > maxdelta)
33     maxdelta = maxdelta1;
34   for (j = i + 1; j < NF; j++) {
35     if (j <= 2)
36       maxdiff = d[NF - 1] - d[1];
37     else
38       maxdiff = trendbreak * \
39         (d[j - 1] - d[1]) / (j - 2);
40     if (d[j] - d[1] > maxdelta && \
41         d[j] - d[j - 1] > maxdiff)
42       break;
43   }
44   n = sum = 0;
45   for (k = 1; k < j; k++) {
46     sum += d[k];
47     n++;
48   }
49   min = d[1];
50   max = d[j - 1];
51   avg = sum / n;
52   print $1, avg, min, max, n, NF - 1;
53 }

```

Listing 11.2는 이 방법을 구현한 sh/awk 스크립트를 보입니다. 입력값은 x축의 값에 이어 임의의 긴 y 축 값이고, 출력은 각각의 입력 라인에 대한 한 라인으로, 다음과 같은 필드를 갖습니다:

- x축 값.
- 선택된 데이터의 평균.
- 선택된 데이터의 최소값.
- 선택된 데이터의 최대값.

5. 선택된 데이터 항목들의 갯수.

6. 입력 데이터 항목들의 갯수.

이 스크립트는 다음과 같은 선택적 인자들을 갖습니다:

--divisor: 리스트를 나누게 될 세그먼트들의 갯수로, 예를 들어 4의 값을 갖게 되면 데이터 원소들의 앞쪽 4분의 1이 좋은 데이터라고 가정됩니다. 기본 값은 3입니다.

--relerr: 상대적 측정 에러. 이 스크립트는 이 에러 보다 적은 차이값을 갖는 값들은 모두 같은 의도로 만들어진 것이고 같은 목적을 위한 것이라고 가정합니다. 기본값은 0.01로, 이는 1%와 동일합니다.

--trendbreak: 데이터의 추세를 깨놓는 것으로 간주되는 원소간 거리의 비율. 예를 들어, 받아들여진 데이터의 평균 구간이 1.5라면, 그리고 만약 추세를 깨놓는 것으로 간주되는 비율이 2.0이라면, 다음 데이터 값이 마지막 것과 3.0 이상 차이나면, 이는 추세를 깨놓는 것으로 간주됩니다. (물론, 상대적 에러가 3.0 보다 크지 않다면, 이 “깨짐”은 무시됩니다.)

Listing 11.2의 Line 1-3는 패러미터들의 기본값을 설정하고, line 4-21은 이 패러미터들에 대한 커맨드 라인을 통한 재설정을 처리합니다. Line 23과 24의 awk 호출은 divisor, relerr, 그리고 trendbreak의 sh에서의 것에 대한 상대역을 설정합니다. 일반적인 awk 매너로, line 25-52는 각각의 입력 라인에 대해서 실행됩니다. Line 24와 26의 루프는 입력값의 y축 값들을 line 27에서 오름차순으로 정렬되는 d 배열에 복사합니다. Line 28은 divisor를 적용하고 반올림해서 절대적으로 믿을 수 있는 y축 값들의 수를 계산합니다.

Line 29-33은 y 축 값들의 하한과 상한으로 사용될 값인 maxdelta를 계산합니다. 여기까지 해서, line 29와 30은 신뢰되는 구간의 값들의 차이들을 divisor로 곱하는데, 이 값은 신뢰되는 구간에서의 값들의 차이를 y 축 값들 전체 집합에 적용하게 됩니다. 하지만, 이 값은 상대적 에러에 비해서는 상당히 작을 수 있으므로, line 31에서는 절대적 에러값 ($d[i] * \text{relerr}$)을 구하고 이를 데이터의 신뢰되는 구간에서의 차이값 delta에 더합니다. Line 32와 33은 이 두 값들의 최대값을 계산합니다.

Line 34-43의 루프의 각 패스는 다른 데이터 값을 좋은 데이터 집합에 더하여 시도합니다. Line 35-39는 추세를 깨는 차이값을 계산하고, line 36에서는 아직 추세를 계산하기에 충분한 값을 가지고 있지 않다면 이 한계점을 폐기하고, line 38와 39에서는 trendbreak



Figure 11.6: Choose Validation Methods Wisely

를 좋은 데이터 집합의 데이터 값들의 쌍 사이의 차이 값의 평균에 곱합니다. 만약 line 40에서 후보 데이터 값은 최대 상한값 (maxdelta)의 최소 하한을 넘기게 되었음이 파악되었다면, 그리고 line 41에서 후보 데이터 값과 그 앞의 값 사이의 차이가 추세를 깨는 차이값 (maxdiff)를 넘어선다고 판단된다면, line 42에서는 루프를 빠져나갑니다: 이제 모든 좋은 데이터를 얻었습니다.

Line 44-52는 이 데이터 셋의 통계를 출력합니다.

Quick Quiz 11.20: 이 방법은 좀 이상하군요! 왜 우리가 통계 수업시간에 배웠던 것처럼 평균과 표준편차를 사용하지 않죠? ■

Quick Quiz 11.21: 하지만 신뢰되는 데이터 그룹의 y 축 값들이 모조리 0이면 어떡하죠? 그러면 스크립트는 0이 아닌 값들을 제거하지 않을까요? ■

통계적 간섭 파악 방법은 상당히 유용할 수 있긴 하지만, 이는 마지막 방법으로만 사용되어야 합니다. 첫 번째로는 간섭을 제거하여 하는 것이 (Section 11.7.5), 그럴 수가 없다면 측정을 통해 간섭을 파악하는 것이 (Section 11.7.6.1) 훨씬 낫습니다.

11.8 Summary

To err is human! Stop being human!!!

Ed Nofziger

검증은 결코 엄밀한 과학이 될수는 없겠지만, 정리된 방법은 해야하는 일에 걸맞는 검증 도구를 선택하는 걸 도와서 Figure 11.6에 재밌게 그려진 것과 같은 상황을 피할 수 있게 할 것이기에 정리된 방법을 통해서 많은 것을 얻을 수 있을 겁니다.

선택의 핵심은 통계입니다. 이 챕터에서 소개된 방법들은 거의 모든 경우에 잘 동작하지만, 이것들은 한계를 가지고 있습니다. 이 한계들은 Halting Problem [Tur37, Pul00]에 의해 일반적으로 불가능한 것을 하려 하기 때문에 근본적으로 존재합니다. 다행히도 우리에게는

주어진 프로그램이 동작을 정지할 것인지 아닌지만이 아니라 Section 11.7에서 이야기된 것처럼 그것이 동작을 정지하기 전까지 얼마나 오래 돌아갈 수 있을 것인지 알내내도 되는 수많은 특수한 경우들이 있습니다. 그뿐만 아니라, 주어진 프로그램이 올바르게 동작할 것인지 아닌지를 알아야 하는 경우에는, Section 11.6에서 논의된 것처럼 전체 시간 중 얼만큼의 부분에서 올바르게 동작하는지 추측을 해볼 수 있는 경우가 많습니다.

이런 추측에 의존할 것을 생각하지 않는건 만용을 부리려는것 이상도 이하도 아닙니다. 무엇보다, 이는 코드와 데이터 구조에 있는 거대한 양의 복잡도를 하나의 독립적 숫자로 요약하고 있는 것입니다. 놀랄만큼 많은 경우에 있어서 그런 만용과 같은 객기를 가지고도 일을 할 수 있긴 하지만, 모든 코드와 데이터를 요약시켜 버리는 것은 결국은 상당한 문제들을 일으킬 것입니다.

생길 수 있는 한가지 문제는 다양성으로, 반복된 테스트 수행 각각은 상당히 다른 결과들을 내놓을 수도 있습니다. 이는 많은 경우에 평균과 표준편차를 관리함으로써 처리되어집니다만, 커다랗고 복잡한 프로그램의 동작을 두개의 숫자만으로 요약하려 하는 것은 그 동작을 오로지 하나의 숫자로 요약하려 하는 것만큼이나 용감한 것입니다. 컴퓨터 프로그래밍에 있어서, 놀랄만한 것은 평균이나 평균과 표준편차를 사용하는 것만으로도 충분한 경우가 갖다는 것입니다만, 거기에는 보장이 없습니다.

다양한 결과가 나타나는 한가지 이유는 혼동스러운 요소들입니다. 예를 들어, 링크드 리스트 탐색에 의해 소모되는 CPU 시간은 리스트의 길이에 의존적일 것입니다. 전혀 다른 리스트 길이를 가진 테스트 수행 결과들을 가지고 평균을 내는 것은 유용하지 못할 것이고, 그 평균값에 표준편차를 더하는 것이 더 좋은 결과를 이끌어내지는 못할 겁니다. 여기서 마땅히 해야 할 일은 리스트 길이에 대한 상수를 가지고 있거나 리스트 길이에 따른 CPU 시간의 관계를 측정하는 식으로 리스트의 길이를 제어하는 것입니다.

물론, 이 충고는 여러분이 혼동되는 요소들에 대해서 인지하고 있다는 가정을 가지고 있고, Murphy는 당신이 그렇지 않을 수 있다고 이야기 합니다. 전 (커질 때에 상당한 전력을 소모해버려서 컴퓨터에 공급되는 전압을 순간적으로 너무 낮아지게 만들어서, 가끔은 문제를 일으켰던) 에어컨, (성능에 있어서 이상한 다양성을 초래했던) 캐시 상태, (디스크 에러, 패킷 로스, 중첩된 이더넷 MAC 어드레스들을 포함한) I/O 에러들, 그리고 심지어 (돌고래가 없다면 상당히 정확한 음파를 통한 위치 선정과 운항을 위해 사용될 수 있는 전파 디지털 송수신기들과 놀고 싶은 마음을 자제할 수 없는) 돌고래들만큼이나 다양한 당황스러운 사실들을 가진 프로젝트들에 연관되어 왔습니다. 그리고 이는 숙면이 왜 효과적인 디버깅 도구인지에 대한 이유 중 하나일 뿐입니다.

니다.

요약하자면, 검증은 항상 시스템의 행동에 대한 어떤 측정을 필요로 합니다. 이 측정은 시스템에 대한 상당한 요약이 되어야 하기 때문에, 이는 잘못된 방향으로 움직일 수 있습니다. 따라서 말 그대로, “조심하세요. 그건 진짜 세계입니다.”

하지만 당신이 2017년 기준으로 전세계에 200억개가 넘는 인스턴스들이 존재하는 것으로 추정되는 리눅스 커널을 위한 작업을 하고 있다고 생각해 보세요. 그런 경우, 하나의 인스턴스에서 백만년에 한번 마주할 수 있는 버그는 전체 설치된 인스턴스에서는 하루에만 50번 넘게 마주할 수 있을 겁니다. 한시간동안 수행하면 이 버그를 50 % 확률로 발견할 수 있는 테스트는 버그를 마주칠 확률을 백억배 이상 높여야 할텐데, 이는 오늘날의 테스트 방법론으로는 상당히 어려운 도전입니다. 어떤 경우에는 이런 경우에 좋은 효과를 줄 수 있는 한가지 중요한 도구는 정형적 검증으로, 다음 챕터, 더 이론적으로는 Section 17.4의 주제입니다.

Chapter 12

Beware of bugs in the above code; I have only proved it correct, not tried it.

Donald Knuth

Formal Verification

병렬 알고리즘은 작성하기 어렵고, 디버깅하기는 그보다도 더 어렵습니다. 테스트가 필수라 하더라도 race condition은 극단적으로 낮은 발현 확률을 가질 수 있기 때문에, 그것만으로는 충분하지 않습니다. 올바름의 증명은 가치있을 수 있습니다만, 그것도 결국은 원래의 알고리즘이 그렇듯이 사람에 의한 에러에 취약합니다. 또한, 올바름의 증명은 가정 자체에 있는 에러, 요구사항의 한계, 아래에 있는 소프트웨어나 하드웨어 기능들에 대한 잘못된 이해, 또는 증명을 할 생각을 하지 못한 에러들은 찾지 못할 것입니다. 이는 정형적 방법들은 테스트를 대체할 수는 없음을 의미합니다만, 정형적 방법들은 검증 도구상자의 또 하나의 가치있는 한가지 도구입니다.

어떻게든 모든 race condition들을 찾아낼 수 있는 도구를 갖는다면 매우 도움이 될 겁니다. 그런 도구들이 여럿 존재하는데, 예를 들어서 Section 12.1은 범용 상태 공간 탐색 도구들인 Promela와 Spin을 소개하고, Section 12.2는 비슷하게 특수 목적의 ppcmem와 cppmem 도구들을 소개하며, Section 12.3은 자명한 방법의 예를 보고, Section 12.4에서는 간단히 SAT solver들을 살펴보며, 마지막으로 Section 12.5에서는 stateless model checker에 대한 간단한 개괄을 제공하고, Section 12.6에서는 병렬 알고리즘을 검증하기 위해 정형 검증을 사용하는 것에 대해 요약합니다.

12.1 State-Space Search

Follow every byway / Every path you know.

“Climb Every Mountain”, Rodgers & Hammerstein

이 섹션은 많은 종류의 멀티 쓰레드 기반 코드의 전체 상태 공간을 탐색하는데 사용될 수 있는 범용의 도구인 Promela와 spin을 알아봅니다. 이것들은 또한 데이터 통신 프로토콜을 증명하는 데에도 유용합니다. Section 12.1.1은 두개의 웜업을 위한 어토믹 하지 않은

버전과 어토믹한 버전의 값 증가를 증명하는 예제를 포함해서 Promela와 spin에 대해 소개합니다. Section 12.1.2은 커맨드 라인에서의 사용 예와 Promela와 C의 문법 비교를 포함해서 Promela를 설명합니다. Section 12.1.3에서는 락킹을 증명하는데에 Promela가 어떻게 사용될 수 있는지 보이고, Section 12.1.4는 일반적이지 않은 “QRCU”라는 이름의 RCU 구현을 증명하는데에 Promela를 사용해 보며, 마지막으로 Section 12.1.5에서는 RCU의 dyntick 구현에 Promela를 적용해 봅니다.

12.1.1 Promela and Spin

Promela는 증명 프로토콜들을 위해 설계된 언어입니다만, 작은 병렬 알고리즘들을 검증하는데에도 사용될 수 있습니다. 당신은 당신의 알고리즘과 정확성 제약을 C 같은 언어인 Promela로 다시 코딩하고, 그다음에 Spin을 사용해 그걸 C 프로그램으로 변환하고 나면 그걸 컴파일하고 실행해 볼 수 있습니다. 그 결과 나오는 프로그램은 당신의 알고리즘의 전체 상태 공간 탐색을 포함하고 있게 되어서, 당신이 당신의 Promela 프로그램에 넣어둔 단정문들에 대한 반례들을 찾아주거나 검증하게 됩니다.

이 전체 상태 공간은 매우 강력할 수 있습니다만, 양 날의 검이 될 수 있기도 합니다. 당신의 알고리즘이 너무 복잡하거나 당신의 Promela 구현이 주의깊게 만들어 지지 않았다면, 메모리에 들어갈 수 있는 것보다 더 많은 상태들이 존재할 수도 있습니다. 더 나아가서, 충분한 메모리를 가졌다 하더라도, 상태 공간 탐색은 예상된 전체 시간보다 더 긴 시간동안 수행될 수 있습니다. 그러므로, 이 도구는 조그맣지만 복잡한 병렬 알고리즘들을 위해 사용하시기 바랍니다. (전체 리눅스 커널은 말할 것도 없고) 보통 크기의 알고리즘들에 이걸 낙관적으로 적용하는 것도 나쁜 결과로 끝나게 될 겁니다.

Promela와 Spin은 <http://spinroot.com/spin/whatispin.html>에서 다운로드 받을 수 있습니다.

앞의 사이트는 또한 Gerard Holzmann의 Promela

Listing 12.1: Promela Code for Non-Atomic Increment

```

1 #define NUMPROCS 2
2
3 byte counter = 0;
4 byte progress[NUMPROCS];
5
6 proctype incrementer(byte me)
7 {
8     int temp;
9
10    temp = counter;
11    counter = temp + 1;
12    progress[me] = 1;
13 }
14
15 init {
16     int i = 0;
17     int sum = 0;
18
19     atomic {
20         i = 0;
21         do
22             :: i < NUMPROCS ->
23                 progress[i] = 0;
24                 run incrementer(i);
25                 i++
26             :: i >= NUMPROCS -> break
27             od;
28     }
29     atomic {
30         i = 0;
31         sum = 0;
32         do
33             :: i < NUMPROCS ->
34                 sum = sum + progress[i];
35                 i++
36             :: i >= NUMPROCS -> break
37             od;
38             assert(sum < NUMPROCS || counter == NUMPROCS)
39     }
40 }

```

와 Spin에 대한 훌륭한 책 [Hol03]으로의 링크를 제공하며, <http://www.spinroot.com/spin/Man/index.html>에서 시작하는 검색 가능한 온라인 레퍼런스들도 제공합니다.

이 문서의 뒷부분은 병렬 알고리즘들을 디버깅하는 데에 Promela를 어떻게 사용하는지를 간단한 예제로 시작해서 더 복잡한 경우들로 나아가면서 설명합니다.

12.1.1.1 Promela Warm-Up: Non-Atomic Increment

Listing 12.1은 어토믹하지 않은 값 증가로 인해 발생하는, 교범적인 race condition을 보이고 있습니다. Line 1은 수행할 프로세스들의 수를 정의하고 (우린 상태 공간에의 영향을 보기 위해 이 값을 바꿔볼 겁니다), line 3은 카운터를 정의하고, line 4는 line 29-39에 있는 단정문을 구현하는데 사용될 겁니다.

Line 6-13은 카운터를 어토믹하지 않게 증가시키는 프로세스를 정의합니다. 인자 `me`는 프로세스의 번호로, 코드의 뒤에 있는 초기화 블록에서 설정됩니다. 간단한 Promela 구문들은 모두 어토믹한 것으로 가정되기 때문

에, 우리는 이 값 증가를 line 10-11의 두개의 문장으로 쪼개야만 합니다. Line 12에서의 값 할당은 프로세스의 완료를 표시합니다. Spin 시스템은 모든 가능한 상태들의 시퀀스들을 포함해 상태 공간을 모두 탐색하기 때문에, 전통적인 테스트에서라면 사용되었을 수 있는 루프는 필요치 않습니다.

Line 15-40은 초기화 블락으로, 제일 처음에 수행됩니다. Line 19-28은 정말로 초기화를 하고, line 29-39는 단정을 수행합니다. 이 두 부분은 불필요하게 상태 공간을 증가시키는 걸 막기 위해 모두 어토믹 블락으로 되어 있습니다: 이것들은 테스트 하려는 알고리즘의 부분이 아니기 때문에, 그것들을 어토믹으로 만들고 써 검증 범위를 줄이는 것입니다.

Line 21-27의 do-od 구조는 Promela 루프를 구현하는데, case 라벨에 expression들을 허용하는 switch 문을 담고 있는 C for (;;) 루프로 생각될 수 있습니다. (:: 접두사를 갖는) 조건 블락들은 비결정론적으로 스캔됩니다만, 이 경우에는 한번에 하나의 조건만이 참이 될 것입니다. Line 22-25에 있는 do-od의 첫번째 블락은 i-번째 카운터 증가 프로세스의 progress 셀을 초기화하고, i-번째 카운터 증가 프로세스를 수행시키고, 변수 `i`를 증가시킵니다. line 26에 있는 do-od의 두번째 블락은 이 프로세스들이 모두 시작되면 루프를 빠져나옵니다.

Line 29-39의 어토믹 블락 또한 프로그레스 카운터를 더하는, 비슷한 do-od 루프를 담고 있습니다. Line 38의 assert() 문은 모든 프로세스가 완료되었는지, 그렇다면 모든 카운트가 정확히 기록되었는지 검증합니다.

독자 여러분은 이 프로그램들을 다음과 같이 빌드하고 실행해 볼 수 있습니다:

```

spin -a increment.spin # Translate the model to C
cc -DSAFETY -o pan pan.c # Compile the model
./pan # Run the model

```

이 수행의 결과로 나올 수 있는 출력이 Listing 12.2에 보여져 있습니다. 첫번째 줄은 우리의 단정이 깨졌음을 이야기 합니다 (어토믹하지 않은 값 증가로 인해 예상되었던대로입니다!). 두번째 줄은 어떻게 이 단정이 깨졌는지에 대한 설명을 `trail` 파일에 썼음을 이야기 합니다. “Warning” 줄은 우리의 모델에 있어서 모든 것이 좋지 않았음을 반복합니다. 두번째 문단은 진행된 상태 탐색의 타입을 설명하는데, 이 경우에는 단정 위반과 무효한 종료 상태들이었습니다. 세번째 문단은 상태 크기에 대한 통계를 보여줍니다: 이 작은 모델은 45개의 상태만을 가졌습니다. 마지막 줄은 메모리 사용량을 보입니다.

`trail` 파일 안의 정보는 다음의 커맨드를 통해 사람이 읽을 수 있는 형태로 만들어질 수 있습니다:

```
spin -t -p increment.spin
```

Listing 12.2: Non-Atomic Increment spin Output

```

pan: assertion violated ((sum<2)|| (counter==2)) (at depth 20)
pan: wrote increment.spin.trail
(Spin Version 4.2.5 -- 2 April 2005)
Warning: Search not completed
    + Partial Order Reduction
Full statespace search for:
    never claim          - (none specified)
    assertion violations + 
    cycle checks          - (disabled by -DSAFETY)
    invalid end states   + 
State-vector 40 byte, depth reached 22, errors: 1
    45 states, stored
    13 states, matched
    58 transitions (= stored+matched)
    51 atomic steps
hash conflicts: 0 (resolved)
2.622  memory usage (Mbyte)

```

Listing 12.3: Non-Atomic Increment Error Trail

```

Starting :init: with pid 0
1: proc 0 (:init:) line 20 "increment.spin" (state 1) [i = 0]
2: proc 0 (:init:) line 22 "increment.spin" (state 2) [((i<2))]
2: proc 0 (:init:) line 23 "increment.spin" (state 3) [progress[i] = 0]
Starting incrementer with pid 1
3: proc 0 (:init:) line 24 "increment.spin" (state 4) [(run incrementer(i))]
3: proc 0 (:init:) line 25 "increment.spin" (state 5) [i = (i+1)]
4: proc 0 (:init:) line 22 "increment.spin" (state 2) [((i<2))]
4: proc 0 (:init:) line 23 "increment.spin" (state 3) [progress[i] = 0]
Starting incrementer with pid 2
5: proc 0 (:init:) line 24 "increment.spin" (state 4) [(run incrementer(i))]
5: proc 0 (:init:) line 25 "increment.spin" (state 5) [i = (i+1)]
6: proc 0 (:init:) line 26 "increment.spin" (state 6) [((i>=2))]
7: proc 0 (:init:) line 21 "increment.spin" (state 10) [break]
8: proc 2 (incrementer) line 10 "increment.spin" (state 1) [temp = counter]
9: proc 1 (incrementer) line 10 "increment.spin" (state 1) [temp = counter]
10: proc 2 (incrementer) line 11 "increment.spin" (state 2) [counter = (temp+1)]
11: proc 2 (incrementer) line 12 "increment.spin" (state 3) [progress[me] = 1]
12: proc 2 terminates
13: proc 1 (incrementer) line 11 "increment.spin" (state 2) [counter = (temp+1)]
14: proc 1 (incrementer) line 12 "increment.spin" (state 3) [progress[me] = 1]
15: proc 1 terminates
16: proc 0 (:init:) line 30 "increment.spin" (state 12) [i = 0]
16: proc 0 (:init:) line 31 "increment.spin" (state 13) [sum = 0]
17: proc 0 (:init:) line 33 "increment.spin" (state 14) [((i<2))]
17: proc 0 (:init:) line 34 "increment.spin" (state 15) [sum = (sum+progress[i])]
17: proc 0 (:init:) line 35 "increment.spin" (state 16) [i = (i+1)]
18: proc 0 (:init:) line 33 "increment.spin" (state 14) [((i<2))]
18: proc 0 (:init:) line 34 "increment.spin" (state 15) [sum = (sum+progress[i])]
18: proc 0 (:init:) line 35 "increment.spin" (state 16) [i = (i+1)]
19: proc 0 (:init:) line 36 "increment.spin" (state 17) [((i>=2))]
20: proc 0 (:init:) line 32 "increment.spin" (state 21) [break]
spin: line 38 "increment.spin", Error: assertion violated
spin: text of failed assertion: assert(((sum<2)|| (counter==2)))
21: proc 0 (:init:) line 38 "increment.spin" (state 22) [assert(((sum<2)|| (counter==2)))]
spin: trail ends after 21 steps
#processes: 1
    counter = 1
    progress[0] = 1
    progress[1] = 1
21: proc 0 (:init:) line 40 "increment.spin" (state 24) <valid end state>
3 processes created

```

이는 Listing 12.3에 보여진 것과 같은 결과를 보입니다. 보여지듯이, 초기화 블락의 첫번째 부분이 두개의 카운터 증가 프로세스들을 생성했고, 두 프로세스는 모두 카운터 값을 가져간 후에 값을 증가하고 다시 저장시켰으며, 그중 하나의 카운트를 잃었습니다. 그리고 나서, 전체 상태가 표시된 후에 단정문이 판정되었습니다.

12.1.1.2 Promela Warm-Up: Atomic Increment

Listing 12.4: Promela Code for Atomic Increment

```

1 proctype incrementer(byte me)
2 {
3     int temp;
4
5     atomic {
6         temp = counter;
7         counter = temp + 1;
8     }
9     progress[me] = 1;
10 }

```

Listing 12.5: Atomic Increment spin Output

```

(Spin Version 4.2.5 -- 2 April 2005)
+ Partial Order Reduction
Full statespace search for:
    never claim           - (none specified)
    assertion violations  +
    cycle checks          - (disabled by -DSAFETY)
    invalid end states   +
State-vector 40 byte, depth reached 20, errors: 0
    52 states, stored
    21 states, matched
    73 transitions (= stored+matched)
    66 atomic steps
hash conflicts: 0 (resolved)
2.622 memory usage (Mbyte)
unreached in proctype incrementer
    (0 of 5 states)
unreached in proctype :init:
    (0 of 24 states)

```

이 예제의 값 증가 프로세스의 코드를 Listing 12.4에 보인 것처럼 고치기는 쉽습니다. Promela statement들은 어토믹하기 때문에, 단순히 두개의 statement들을 `counter = counter + 1`로 바꿀 수도 있겠습니다. 어떤 경우든, 이 수정된 모델을 돌려보면 Listing 12.5에 보여진 것처럼 에러 없는 상태 공간을 보여줍니다.

Table 12.1은 (NUMPROCS로 재정의된) 모델링된 카운터 증가 프로세스의 갯수에 대해 상태의 갯수와 소비된 메모리의 양을 보입니다:

따라서 불필요하게 커다란 모델들을 수행해 보는 것은 약간 권장되지 않습니다, 비록 652MB는 현대의 데스크탑과 랩탑 기계의 한계 내에 있긴 하지만요.

이 예제를 두고서, Promela 모델을 분석하는데 사용되는 커맨드들을 깊게 알아보고 더 자세한 예제들을 봅시다.

Table 12.1: Memory Usage of Increment Model

# incrementers	# states	megabytes
1	11	2.6
2	52	2.6
3	372	2.6
4	3,496	2.7
5	40,221	5.0
6	545,720	40.5
7	8,521,450	652.7

12.1.2 How to Use Promela

소스 파일 `qrcu.spin`을 가지고서, 다음과 같은 커맨드들을 사용할 수 있습니다:

`spin -a qrcu.spin`

상태 머신을 완전히 탐색하는 `pan.c` 파일을 만들어냅니다.

`cc -DSAFETY -o pan pan.c`

생성된 상태 머신 탐색 코드를 컴파일 합니다. `-DSAFETY`는 단정문만을 (그리고 `never` statement들을) 가지고 있다면 적절한 최적화를 만들어냅니다. 만약 여러분이 `liveness`, `fairness`, 또는 `forward-progress` 체크를 가지고 있다면, `-DSAFETY` 없이 컴파일을 해야할 수도 있습니다. 여러분이 그것을 사용할 수 있으면서 `-DSAFETY`를 사용하지 않는다면, 프로그램은 당신에게 그걸 알릴 겁니다.

`-DSAFETY`로 만들어지는 최적화는 일의 속도를 엄청나게 높여줄 것이므로, 사용할 수 있다면 사용해야 합니다. `-DSAFETY`를 사용할 수 없는 환경 가운데 예를 들어보자면 `-DNP`를 통해 (“non-progress cycles”라고도 알려져 있는) `livelock`을 체크할 때입니다.

`./pan`

이 커맨드는 정말로 상태 공간을 탐색하게 합니다. 매우 작은 상태 머신을 가지고도 상태의 갯수는 수천개에 달할 수 있으므로, 커다란 메모리를 가진 기계가 필요할 겁니다. 예를 들어, `qrcu.spin`을 3개의 읽기 쓰레드와 2개의 업데이트 쓰레드와 함께 동작시키려면 2.7GB의 메모리가 필요합니다.

당신의 기계가 충분한 메모리를 가지고 있는지 분명치 않다면, 한 윈도우에서는 `top`을 동작시키고 다른 윈도우에서 `./pan`을 수행하세요. 만약 필요하다면 곧바로 실행을 멈출 수 있게 할 수 있도록 포커스는 `./pan` 윈도우에 두세요. CPU 시간이

100 % 아래로 떨어지기 시작하면, `./pan` 의 수행을 중지시키세요. 당신이 `./pan` 을 수행중인 윈도우로부터 포커스를 옮겨 두었다면, 윈도우 시스템이 당신을 위해 뭔가 하기 위해 충분한 메모리를 가질 수 있을때까지 긴 시간을 기다려야 할겁니다.

출력을 캡쳐해 두는 것을 잊지 마세요. 특히나 당신이 원격의 기계에서 작업하고 있다면요.

만약 당신의 모델이 forward-progress 체크를 포함하고 있다면, `./pan` 에 커맨드 라인 인자로 `-f` 를 줌으로써 “weak fairness” 를 활성화 시켜야 할 수 있을겁니다. 당신의 forward-progress 체크가 `accept` 라벨과 관련되어 있다면, `-a` 인자 또한 필요할겁니다.

`spin -t -p qrcu.spin`

에러를 만나게 된 수행 시에 나온 결과 파일인 `trail` 파일을 받아서 그 에러를 마주하게 된 과정의 시퀀스를 출력합니다. `-g` 플래그는 또한 변경된 전역 변수들의 값들 또한 포함시킬 것이고, `-1` 플래그는 변경된 지역 변수들의 값들도 포함시킬겁니다.

12.1.2.1 Promela Peculiarities

모든 컴퓨터 언어들이 유사한 점들을 가지고 있음에도 불구하고, C, C++, 또는 Java 를 가지고 코딩하던 사람들에게 Promela 는 조금 놀라운 것들을 제공할겁니다.

1. C 에서, “;” 는 `statement` 의 종료를 알립니다. Promela 에서는 `statement` 들을 분리합니다. 다행히도, Spin 의 더 최신 버전은 “여분의” 세미콜론들에 훨씬 더 너그러워졌습니다.
2. Promela 에서 루프를 만드는 데 사용되는 `do` 문은 조건을 갖습니다. 이 `do` 문은 `if-then-else` 로 구성된 루프 문과 상당히 닮아 있습니다.
3. C 의 `switch` 문에서, 맞는 케이스가 존재하지 않는다면, 전체 `statement` 가 건너뛰어 집니다. Promela 의 같은 기능에서, 잘못 사용된 `if` 문에서 맞아 떨어지는 조건이 없다면, 알아들을 수 있는 관련된 에러 메세지 없이 에러를 내게 됩니다. 따라서, 에러 출력이 문제 없는 코드 라인을 가리킨다면, `if` 나 `do` 문에서 해당되지 않는 조건을 남겨둔 건 아닌지 확인해 보시기 바랍니다.
4. C 에서 스트레스 테스트를 만들 때, 어떤 사람은 의심되는 오퍼레이션들을 서로에 대해 반복적으로 경주시키곤 할겁니다. Promela 에서, 어떤 사람은 그 대신에 하나의 경주만을 만들텐데, Promela 는 그 한번의 경주로부터 가능한 모든 결과를 탐색할 것이기 때문입니다. 어떤 경우에는 Promela 에서 루프를 돌 필요가 있는데, 예를 들어 여러 오퍼레이션들이 겹치지만, 그렇게 하는게 당신의 상태 공간을 굉장히 증가시키는 경우가 그런 경우입니다.
5. C 에서, 하기 가장 쉬운 일은 루프의 진행 정도를 추적하고 종료하기 위해 루프 카운터를 사용하는 것입니다. Promela 에서, 루프 카운터는 역병처럼 방지되어야만 하는데, 그것들은 상태 공간을 폭발적으로 증가시키기 때문입니다. 다른 한편, Promela 에서 무한 루프는 변수들 가운데 단조적으로 증가하거나 감소하는 것들이 없다면 문제가 없습니다—Promela 는 루프에서 얼마나 수행이 돌아가면 정말로 영향을 끼칠 것인지를 알아챌 것이고, 자동적으로 그 지점 뒤의 실행을 없애버릴겁니다.
6. C 로 짜여진 고문 테스트 코드에서는 태스크별 제어 변수를 두는 것이 많은 경우에 현명합니다. 그것은 읽기기에 편하고, 테스트 코드를 디버깅하는데에 매우 도움이 됩니다. Promela 에서 태스크별 제어 변수는 다른 대안이 없을 때에만 사용되어야 합니다. 이를 자세히 보기 위해, 다섯개의 태스크 겸중을 해야 하는데 작업 완료를 나타내는 하나의 비트를 태스크 각각이 갖는다고 생각해 봅시다. 이는 32개의 상태들을 만들어냅니다. 반면에, 하나의 간단한 카운터만을 사용한다면 6개의 상태만을 가질 것이어서, 다섯배가 넘는 상태 갯수의 감소를 이루어냅니다. 이 다섯배는 문제처럼 보이지 않을 수도 있는데, 겸중 프로그램이 1억 5천만개의 상태들을 10GB 가 넘는 메모리를 소모해 가면서 처리하느라 고생하고 있지 않을 때에는 그럴겁니다!
7. C 고문 테스트 코드와 Promela 둘 다에서 가장 어려운 일들 중 하나는 좋은 단정문들을 만들어내는 것입니다. Promela 는 또한 `never` 가 모든 코드 라인들 사이에 복사되어 있는 단정문과 같은 것들에 대해서 주의를 내도록 하는 것도 가능하게 합니다.
8. 분할하고 지배하기는 Promela 에서 상태 공간을 제어하기에 굉장히 도움이 됩니다. 커다란 모델을 두개의 대략적으로 절반씩을 갖는 것들로 분할하는 것은 각각의 절반이 상태 공간의 루트 값만큼의 양을 갖는 결과를 만들겁니다. 예를 들어, 백만개의 상태가 결합된 모델은 두개의 천개 상태 모델들로 나뉘어질 수 있을겁니다. Promela 가 두개의 더 작은 모델을 더 적은 메모리를 가지고 더 빨리 처리할 뿐만 아니라, 두개의 작은 알고리즘이 사람이 이해하기에 더 쉽습니다.

Listing 12.6: Complex Promela Assertion

```

1 i = 0;
2 sum = 0;
3 do
4 :: i < N_QRCU_READERS ->
5   sum = sum + (readerstart[i] == 1 &&
6     readerprogress[i] == 1);
7   i++
8 :: i >= N_QRCU_READERS ->
9   assert(sum == 0);
10  break
11 od

```

Listing 12.7: Atomic Block for Complex Promela Assertion

```

1 atomic {
2   i = 0;
3   sum = 0;
4   do
5     :: i < N_QRCU_READERS ->
6       sum = sum + (readerstart[i] == 1 &&
7         readerprogress[i] == 1);
8       i++
9     :: i >= N_QRCU_READERS ->
10       assert(sum == 0);
11       break
12   od
13 }

```

12.1.2.2 Promela Coding Tricks

Promela 는 프로토콜을 분석하기 위해 설계되었으므로, 병렬 프로그램에 사용하는건 약간 오용에 가깝습니다. 다음의 트릭들은 Promela 를 안전하게 오용하는데 도움을 줄 겁니다:

1. 메모리 재배치. 전역 변수 x 와 y 를 지역 변수 r1 과 r2 에 복사하는 두개의 statement 가 있는데, 이것들은 그 순서가 중요한데 (ex: 락으로 보호되지 않음), 메모리 배리어를 사용하지 않았다고 생각해 봅시다. 이는 Promela 에서 다음과 같이 모델링될 수 있습니다:

```

1 if
2 :: 1 -> r1 = x;
3   r2 = y
4 :: 1 -> r2 = y;
5   r1 = x
6 fi

```

if 문의 두갈래 경우들은 비결정적으로 선택될 것인데, 둘 다 선택되는 것이 가능하기 때문입니다. 전체 상태 공간이 탐색될 것이므로, 둘 다의 선택들이 결국은 모든 경우들에 대해 만들어질 것입니다.

물론, 이 트릭은 너무 과하게 사용된다면 상태 공간을 폭증시켜 버릴 수 있습니다. 또한, 이 트릭은 가능한 재배치들을 예측할 것을 필요로 합니다.

2. 상태 감축. 복잡한 단정문들을 가지고 있다면, 그것들을 `atomic` 하에서 수행하세요. 무엇보다, 그것

Listing 12.8: Promela Code for Spinlock

```

1 #define spin_lock(mutex) \
2   do \
3     :: 1 -> atomic { \
4       if \
5         :: mutex == 0 -> \
6           mutex = 1; \
7           break \
8         :: else -> skip \
9       fi \
10    } \
11  od
12
13 #define spin_unlock(mutex) \
14   mutex = 0

```

들은 알고리즘의 한 부분이 아닙니다. 복잡한 단정문의 한 예는 (뒤에서 더 자세히 다루겠습니다만) Listing 12.6 에 보여져 있습니다.

이 단정문을 어토믹하지 않게 수행할 이유가 없는 데, 이는 알고리즘의 실제 부분이 아니기 때문입니다. 각각의 statement 가 상태에 영향을 끼치므로, Listing 12.7 에 보여진 것처럼 복잡한 단정문들을 `atomic` 안에 집어넣음으로써 불필요한 상태들의 수를 줄일 수 있습니다.

3. Promela 는 함수를 제공하지 않습니다. 그대신에 C 전처리기 매크로들을 사용해야만 합니다. 하지만, 조합에 의한 상태 수의 폭증을 막기 위해 조심스럽게 사용되어야만 합니다.

이제 더 복잡한 예제들을 볼 준비가 되었습니다.

12.1.3 Promela Example: Locking

락은 전반적으로 유용하기 때문에, Listing 12.8 에서 보여진 것처럼 여러 Promela 모델들에 include 될 수 있는 `lock.h` 에서 `spin_lock()` 과 `spin_unlock()` 매크로를 제공합니다. `spin_lock()` 매크로는 line 3 의 단 하나의 조건 “1” 덕분에 line 2-11 의 무한한 do-od 루프를 가지고 있습니다. 이 루프의 몸통은 하나의 if-fi 문을 담고 있는 하나의 어토믹 블락입니다. 이 if-fi 문은 루프를 돌기보다는 한번의 패스만을 취한다는 점을 제외하고는 do-od 문과 비슷합니다. 락이 line 5 에서 잡혀있지 않다면 line 6 에서 이를 획득하고 line 7 에서 감싸고 있는 do-od 루프를 깨고 나갑니다 (그리고 어토믹 블락에서도 나갑니다). 한편으로는, 만약 락이 line 8 에서 이미 잡혀 있었다면, 아무 일도 하지 않고 (`skip`), if-fi 문과 어토믹 블락을 빠져나오고 그 바깥 루프의 다음 반복을 진행해서 락이 획득 가능해질 때까지 반복하게 됩니다.

`spin_unlock()` 매크로는 단순히 이 락을 더이상 잡혀 있지 않았다고 표시합니다.

Listing 12.9: Promela Code to Test Spinlocks

```

1 #include "lock.h"
2
3 #define N_LOCKERS 3
4
5 bit mutex = 0;
6 bit havelock[N_LOCKERS];
7 int sum;
8
9 proctype locker(byte me)
10 {
11   do
12   :: 1 ->
13     spin_lock(mutex);
14     havelock[me] = 1;
15     havelock[me] = 0;
16     spin_unlock(mutex);
17   od
18 }
19
20 init {
21   int i = 0;
22   int j;
23
24 end: do
25   :: i < N_LOCKERS ->
26     havelock[i] = 0;
27     run locker(i);
28     i++
29   :: i >= N_LOCKERS ->
30     sum = 0;
31     j = 0;
32     atomic {
33       do
34       :: j < N_LOCKERS ->
35         sum = sum + havelock[j];
36         j = j + 1
37       :: j >= N_LOCKERS ->
38         break
39       od
40     }
41     assert(sum <= 1);
42     break
43   od
44 }

```

Promela 는 완전한 순서 규칙을 가정하기 때문에 메모리 배리어들은 필요치 않다는 점을 알아두세요. 어떤 Promela 상태에서도, 모든 프로세스는 현재 상태와 우리가 현재의 상태에 도달하게 되는 과정에서의 상태 변화 순서에 동의하게 됩니다. 이는 (1990년대 MIPS 와 PA-RISC 같은) 일부 컴퓨터 시스템에서 사용되는 “sequentially consistent” 메모리 모델과 비슷합니다. 앞서 언급되었듯이, 그리고 뒤의 예제에서 알아보게 되듯이, 약한 메모리 순서 규칙은 명시적으로 코딩되어야만 합니다.

이 매크로들은 Listing 12.9 에 보여진 Promela 코드에 의해 테스트 되었습니다. 이 코드는 line 3에서의 N_LOCKERS 로 정의된 락킹 프로세스의 숫자에 의해 값 증가를 테스트하는데 사용되었던 코드와 비슷합니다. 뮤텍스 자체는 line 5에 정의되었고, 락 소유자를 추적하기 위한 배열이 line 6에 정의되어 있으며, line 7은 하나의 프로세스만이 락을 잡고 있음을 증명하기 위한

단정문 코드에 사용됩니다.

락을 잡는 프로세스는 line 9-18에 있는데, line 13에서 락을 획득하고 line 14에서 락을 잡았음을 공표하고 line 15에서 락을 잡지 않고 있다고 이야기한 후, line 16에서 락을 놓습니다.

Line 20-44의 init 블락은 현재 락 잡는 프로세스의 havelock 배열 원소를 line 26에서 초기화하고, 현재 락 잡는 프로세스를 line 27에서 시작시키며, line 28에서 다음 락 잡는 프로세스로 넘어갑니다. 일단 모든 락 잡는 프로세스들이 시작되면, do-od 루프의 수행은 단정문을 체크하는 line 29로 넘어갑니다. Line 30과 31은 제어 변수들을 초기화하고, line 32-40은 어토믹하게 havelock 배열 원소들의 합을 구하고, line 41에서 단정문을 수행하고, line 42에서 루프를 빠져나옵니다.

우리는 Listing 12.8 와 12.9의 두개의 코드 조각들을 lock.h 와 lock.spin에 각각 집어넣는 것으로 이 모델을 수행할 수 있게 되며, 다음의 커맨드들을 사용해 돌릴 수 있습니다:

```

spin -a lock.spin
cc -DSAFETY -o pan pan.c
./pan

```

Listing 12.10: Output for Spinlock Test

```

(Spin Version 4.2.5 -- 2 April 2005)
+ Partial Order Reduction
Full statespace search for:
never claim           - (none specified)
assertion violations  +
cycle checks          - (disabled by -DSAFETY)
invalid end states   +
State-vector 40 byte, depth reached 357, errors: 0
  564 states, stored
  929 states, matched
  1493 transitions (= stored+matched)
  368 atomic steps
hash conflicts: 0 (resolved)
2.622  memory usage (Mbyte)
unreached in proctype locker
  line 18, state 20, "-end-"
  (1 of 20 states)
unreached in proctype :init:
  (0 of 22 states)

```

출력되는 결과는 Listing 12.10에 보여진 것과 비슷할 것입니다. 예상되었듯이, 이 수행은 단정문 실패가 없습니다 (“errors: 0”).

Quick Quiz 12.1: 왜 locker에 미치지 못한 statement 가 있는 거죠? 이건 전체 상태-공간 탐색이 아니었나요?

Quick Quiz 12.2: 이 예제에 있어서 Promela 코딩 스타일 문제들은 뭐가 있나요? ■

12.1.4 Promela Example: QRCU

이 마지막 예제는 synchronize_qrcu()의 빠른 수행로를 더 빠르게 하기 위해 수정된 Oleg Nesterov

의 QRCU [Nes06a, Nes06b] 를 위한 실제 세계에서의 Promela 사용을 보입니다.

하지만 먼저, QRCU 란 무엇일까요?

QRCU 는 극단적으로 낮은 grace period 대기시간이라는 장점을 더 높은 읽기 오버헤드(전역 변수에의 어토믹한 값 증가와 감소) 와 맞바꾸는, SRCU [McK06b] 의 한 변종입니다. 읽기 쓰레드가 없다면, grace period 는 1 마이크로세컨드도 되지 않는 시간에 파악되는데, 이는 대부분의 다른 RCU 구현들의 수 밀리세컨드 grace period 대기시간과 비교됩니다.

1. QRCU 도메인을 정의하는 `qrcu_struct` 가 존재 합니다. Ssrcu 처럼(그리고 다른 RCU 변종들과는 달리) QRCU 의 동작은 글로벌하지 않고, 그대신에 특정한 `qrcu_struct` 에 집중됩니다.
2. QRCU read-side 크리티컬 섹션들을 구분짓는 `qrcu_read_lock()` 과 `qrcu_read_unlock()` 이 있습니다. 연관되는 `qrcu_struct` 는 이 함수들에 넘겨져야 하고, `rcu_read_lock()` 으로부터의 리턴값은 `rcu_read_unlock()` 으로 넘겨져야만 합니다.

예를 들면 다음과 같습니다:

```
idx = qrcu_read_lock(&my_qrcu_struct);
/* read-side critical section. */
qrcu_read_unlock(&my_qrcu_struct, idx);
```

3. 이전부터 존재해온 QRCU read-side 크리티컬 섹션들이 모두 완료될 때까지 기다리는 `synchronize_qrcu()` 기능이 있습니다만, Ssrcu 의 `synchronize_srcu()` 처럼, QRCU 의 `synchronize_qrcu()` 는 같은 `qrcu_struct` 를 사용하는 read-side 크리티컬 섹션들만을 기다리면 됩니다.

앞의 예에 이어 예를 들면, `synchronize_qrcu(&your_qrcu_struct)` 는 이전의 QRCU read-side 크리티컬 섹션을 기다릴 필요가 없습니다. 반면에, `synchronize_qrcu(&my_qrcu_struct)` 는 기다려야 할 수 있는데, 같은 `qrcu_struct` 를 공유하기 때문입니다.

QRCU 를 위한 리눅스 커널 패치도 만들어졌습니다만 [McK07c], 2008년 4월 현재까지는 리눅스 커널에 포함되지 않았습니다.

QRCU 를 위한 Promela 코드로 돌아와서, 전역 변수들은 Listing 12.11 에 보인 것과 같습니다. 이 예제는 락킹을 사용하므로, `lock.h` 를 `include` 하고 있습니다. 읽기 쓰레드의 갯수와 쓰기 쓰레드의 갯수는 두개의 `#define` 문을 통해 변경될 수 있어서, 두개의 조합 증폭

Listing 12.11: QRCU Global Variables

```
1 #include "lock.h"
2
3 #define N_QRCU_READERS 2
4 #define N_QRCU_UPDATORS 2
5
6 bit idx = 0;
7 byte ctr[2];
8 byte readerprogress[N_QRCU_READERS];
9 bit mutex = 0;
```

가능한 방법을 제공합니다. `idx` 변수는 `ctr` 배열의 두 원소들 중 무엇이 읽기 쓰레드에 의해 사용될 것인지 결정하며, `readerprogress` 변수는 단정문이 언제 모든 읽기 쓰레드가 종료되었는지를 판단할 수 있게 합니다 (QRCU 업데이트는 모든 앞서 존재한 읽기 쓰레드가 그들의 QRCU read-side 크리티컬 섹션을 완료하기 전까지는 완료될 수 없기 때문입니다). `readerprogress` 배열의 원소는 다음과 같이 값을 가져서 연관된 읽기 쓰레드의 상태를 알립니다:

0: 시작되지 않았음.

1: QRCU read-side 크리티컬 섹션 안에 있음.

2: QRCU read-side 크리티컬 섹션을 끝냈음.

마지막으로, `mutex` 변수는 업데이트 쓰레드들의 느린 수행 경로들을 직렬화하는데 사용됩니다.

Listing 12.12: QRCU Reader Process

```
1 proctype qrcu_reader(byte me)
2 {
3     int myidx;
4
5     do
6     :: 1 ->
7         myidx = idx;
8         atomic {
9             if
10                :: ctr[myidx] > 0 ->
11                    ctr[myidx]++;
12                break
13                :: else -> skip
14            fi
15        }
16    od;
17    readerprogress[me] = 1;
18    readerprogress[me] = 2;
19    atomic { ctrl[myidx]-- }
20 }
```

QRCU 읽기 쓰레드는 Listing 12.12 에 보여진 `qrcu_reader()` 프로세스에 의해 모델링 됩니다. do-od 루프가 line 5-16 에 있는데, 하나의 “1” 조건을 line 6 에 가지고 있어서 이를 무한 루프로 만들어 줍니다. Line 7 은 글로벌 인덱스의 현재 값을 가져오고, line 8-15 는 그 값이 0이 아니었다면 이를 원자적으로 증가 (`atomic_inc_not_zero()`) 시킵니다(그리고 루프를 나옵니다). Line 17 은 RCU read-side 크리티컬 섹션으로의 진입을

표시하고, line 18 은 이 크리티컬 섹션으로부터 나오는 것을 표시하는데, 두 라인 모두 우리가 뒤에서 마주하게 될 `assert()` 문을 위해서입니다. Line 19 는 우리가 증가시켰던 같은 카운터를 어토믹하게 감소시키는데, 이렇게 함으로써 RCU read-side 크리티컬 섹션을 빠져 나오게 됩니다.

Listing 12.13: QRCU Unordered Summation

```

1 #define sum_unordered \
2   atomic { \
3     do \
4       :: i -> \
5         sum = ctr[0]; \
6         i = 1; \
7         break \
8       :: i -> \
9         sum = ctr[1]; \
10        i = 0; \
11        break \
12     od; \
13   } \
14   sum = sum + ctr[i]

```

Listing 12.13 에 보인 C 전처리기 매크로는 약한 메모리 순서 규칙을 애뮬레이션 하기 위해 두개의 카운터의 합을 구합니다. Line 2-13 은 카운터 중 하나를 가져오고, line 14 는 나머지 하나를 가져와서 그것들을 더합니다. 어토믹 블락은 하나의 `do-od` 문으로 구성되어 있습니다. 이 `do-od` 문 (line 3-12) 은 line 4 와 8 에 있는 두개의 무조건적인 브랜치들을 가지고 있다는 점에서 일반적이지 않은데, 이는 Promela 가 비결정적으로 두개의 브랜치 중 하나를 선택하게 합니다 (하지만 다시 말하지만, 전체 상태 공간 탐색은 Promela 가 결국은 모든 가능한 상황의 선택지를 만들게 할 겁니다). 첫번째 브랜치는 0번째 카운터를 가져오고 `i` 를 1 로 설정하고 (line 14 가 첫번째 카운터를 가져오도록), 두번째 브랜치는 그 반대 일을 해서, 첫번째 카운터를 가져오고 `i` 를 0 으로 설정합니다 (line 14 에서 두번째 카운터를 가져오도록).

Quick Quiz 12.3: 이 `do-od` 문을 좀 더 간단하게 코딩하는 방법은 없을까요? ■

`sum_unordered` 매크로와 함께, 우리는 이제 Listing 12.14 에 보여진 update-side 프로세스로 넘어갈 수가 있게 되었습니다. 이 update-side 프로세스는 line 7-57 의 관련된 `do-od` 루프를 애매하게 반복하게 됩니다. 이 루프를 통하는 각각의 패스는 먼저 line 12-21 에서 글로벌한 `readerprogress` 배열을 로컬의 `readerstart` 어레이로 스냅샷합니다. 이 스냅샷은 line 53 에서의 단정문에 사용될 겁니다. Line 23 은 `sum_unordered` 를 호출하고, 빠른 수행경로가 잠재적으로 사용 가능하다면 line 24-27 에서 `sum_unordered` 를 다시 호출합니다.

Line 28-40 은 필요하다면 느린 수행 경로의 코드를 수행하는데, line 30 과 38 에서 update-side 락을 각각 획득하고 해제하며, line 31-33 에서 인덱스를 뒤집고, line 34-37 에서 모든 이전부터 존재한 읽기 쓰레드들이

Listing 12.14: QRCU Updater Process

```

1 proctype qrcu_updater(byte me)
2 {
3   int i;
4   byte readerstart[N_QRCU_READERS];
5   int sum;
6
7   do
8   :: i ->
9
10  /* Snapshot reader state. */
11
12  atomic {
13    i = 0;
14    do
15      :: i < N_QRCU_READERS ->
16        readerstart[i] = readerprogress[i];
17        i++;
18      :: i >= N_QRCU_READERS ->
19        break
20    od
21  }
22
23  sum_unordered;
24  if
25    :: sum <= 1 -> sum_unordered
26    :: else -> skip
27  fi;
28  if
29    :: sum > 1 ->
30      spin_lock(mutex);
31      atomic { ctr[!idx]++ }
32      idx = !idx;
33      atomic { ctr[!idx]-- }
34      do
35        :: ctr[!idx] > 0 -> skip
36        :: ctr[!idx] == 0 -> break
37      od;
38      spin_unlock(mutex);
39    :: else -> skip
40  fi;
41
42  /* Verify reader progress. */
43
44  atomic {
45    i = 0;
46    sum = 0;
47    do
48      :: i < N_QRCU_READERS ->
49        sum = sum + (readerstart[i] == 1 &&
50                      readerprogress[i] == 1);
51        i++;
52      :: i >= N_QRCU_READERS ->
53        assert(sum == 0);
54        break
55    od
56  }
57  od
58 }

```

완료되길 기다립니다.

Line 44-56에서는 이제 `readerprogress` 배열의 현재 값들과 `readerstart` 배열 안의 앞서 수집된 값들과 비교하며, 이 업데이트 전에 시작된 읽기 쓰레드가 여전히 진행중이라면 단정문이 실패하도록 합니다.

Quick Quiz 12.4: 왜 line 12-21 과 line 44-56에 어토믹 블락이 있나요, 그 어토믹 블락들 안의 오퍼레이션들은 현존하는 제품화된 마이크로프로세서 중 어떤 것도 어토믹한 구현을 제공하지 않는는데 말이죠? ■

Quick Quiz 12.5: Line 24-27에서 카운터들을 다시 합해보는 것은 정말로 필요한 건가요? ■

Listing 12.15: QRCU Initialization Process

```

1  init {
2    int i;
3
4    atomic {
5      ctr[idx] = 1;
6      ctr[!idx] = 0;
7      i = 0;
8      do
9        :: i < N_QRCU_READERS ->
10       readerprogress[i] = 0;
11       run qrcu_reader(i);
12       i++;
13     :: i >= N_QRCU_READERS -> break
14   od;
15   i = 0;
16   do
17     :: i < N_QRCU_UPDATER ->
18     run qrcu_updater(i);
19     i++;
20   :: i >= N_QRCU_UPDATER -> break
21   od
22 }
23 }
```

이제 남은건 Listing 12.15의 초기화 블락 뿐입니다. 이 블락은 단순히 카운터 쌍을 line 5-6에서 초기화하고, line 7-14에서 읽기 프로세스들을 시작시킨 후, line 15-21에서 업데이트 프로세스들을 시작시킵니다. 이는 상태 공간의 크기를 줄이기 위해 모두 하나의 어토믹 블락 안에서 수행됩니다.

12.1.4.1 Running the QRCU Example

이 QRCU 예제를 수행하기 위해서는, 앞 섹션에서의 코드들을 `qrcu.spin`이라는 이름의 하나의 파일로 합치고, `spin_lock()`과 `spin_unlock()`의 정의를 `lock.h`라는 이름의 파일로 옮겨야 합니다. 그리고 나서 다음의 커맨드를 사용해서 QRCU 모델을 빌드하고 수행시킬 수 있습니다:

```
spin -a qrcu.spin
cc -DSAFETY -o pan pan.c
./pan
```

수행 결과 나오는 출력은 이 모델이 Table 12.2에 나온 모든 케이스들을 통과함을 보여줍니다. 이제, 이 케이스

Table 12.2: Memory Usage of QRCU Model

updaters	readers	# states	MB
1	1	376	2.6
1	2	6,177	2.9
1	3	82,127	7.5
2	1	29,399	4.5
2	2	1,071,180	75.4
2	3	33,866,700	2,715.2
3	1	258,605	22.3
3	2	169,533,000	14,979.9

를 세 개의 읽기 쓰레드와 세 개의 업데이트 쓰레드를 사용해 돌려보는 것도 좋을 겁니다만, 간단한 추정이 이는 최선의 경우에도 수십 테라바이트의 메모리를 필요로 할 것이란 점을 이야기 합니다. 그럼, 뭘 해야 할까요? 여기 몇 가지 가능한 방법들이 있습니다:

1. 더 적은 수의 읽기 쓰레드와 업데이트 쓰레드가 일반적인 경우를 증명하는데 충분한지 보세요.
2. 일일이 정확성의 증명을 구하세요.
3. 더 적합한 도구를 사용하세요.
4. 분할하고 정복하세요.

다음의 섹션은 이런 방법들 각각을 알아봅니다.

12.1.4.2 How Many Readers and Updaters Are Really Needed?

한 가지 접근법은 `qrcu_updater()`를 위한 Promela 코드를 주의 깊게 들여다보고 유일한 전역적 상태 변경은 락을 잡은 아래 일어남을 알아차리는 것입니다. 따라서, 한번에 하나의 업데이트 쓰레드만이 읽기 쓰레드들이나 다른 업데이트 쓰레드들에게 보일 수 있는 상태 변경을 가하고 있을 수 있습니다. 이는, Promela가 전체 상태 공간 검색을 한다는 사실로 인해, 어떤 시퀀스의 상태 변경들도 하나의 업데이트 쓰레드에 의해 순차적으로 이뤄질 것을 의미합니다. 따라서, 최대 두 개의 업데이트 쓰레드가 필요합니다: 하나는 상태를 바꾸기 위해, 나머지 하나는 헛갈려 하기 위해.

읽기 쓰레드들과 함께 있는 상황은 좀 더 분명한데, 각각의 읽기 쓰레드는 하나의 read-side 크리티컬 섹션만을 만들고 종료되기 때문입니다. 빠른 수행 경로는 카운터들에서 최대 0과 1만을 읽을 수 있다는 사실로 인해 유용한 읽기 쓰레드의 수가 제한되어 있다고 반론을 제기할 수도 있겠습니다. 실제로, 이는 수사에

있어서 알찬 방법으로, 다음 섹션에서 이야기하는 전체 정확성 증명을 이끌게 됩니다.

12.1.4.3 Alternative Approach: Proof of Correctness

비형식적인 증명 [McK07c] 은 다음과 같습니다:

1. `synchronize_qrcu()` 가 너무 일찍 종료되려면, 정의에 의해 `synchronize_qrcu()` 의 전체 수행 사이에 최소 하나의 읽기 쓰레드가 존재해야 합니다.
2. 이 읽기 쓰레드에 연관된 카운터는 이 시간 간격 동안 최소 1이 되었을 겁니다.
3. `synchronize_qruc()` 코드는 최소 하나의 카운터는 최소 1이 되도록 강제합니다.
4. 따라서, 어떤 시점에서든, 카운터들 가운데 하나는 최소 2가 되거나, 두개의 카운터들이 최소 1을 가질 겁니다.
5. 하지만, `synchronize_qrcu()` 빠른 수행 경로 코드는 한번에 하나의 카운터의 값밖에 읽지 못합니다. 따라서 빠른 수행 경로 코드가 첫번째 카운터를 값이 0일 동안 읽어오지만 카운터 뒤집기에서는 경주 상황이 벌어져서 두번째 카운터가 1로 보이는 경우가 있을 수 있습니다.
6. 그런 경주 조건 동안에 존재하는 최대 하나의 읽기 쓰레드가 있을 수 있는데, 그렇지 않다면 그 합은 2 이상이 될 것이기 때문으로, 이는 업데이트 쓰레드가 느린 수행경로를 취하도록 만들 것입니다.
7. 하지만 그 경주 상황이 빠른 수행경로의 첫번째 카운터 읽기에서 발생한다면, 그리고 그 두번째 읽기에서 다시 일어난다면, 두개의 카운터 뒤집기가 있었어야만 합니다.
8. 업데이트 쓰레드는 카운터를 한번만 뒤집으므로, 그리고 업데이트 쪽 락은 두개의 업데이트 쓰레드들이 동시에 카운터를 뒤집는 것을 방지하므로, 빠른 수행경로 코드가 뒤집기와 두번 경주 상황을 만들 수 있는건 첫번째 업데이트 쓰레드가 완료했을 때입니다.
9. 하지만 첫번째 업데이트 쓰레드는 모든 앞서 존재한 읽기 쓰레드들이 완료되기 전까지는 완료될 수 없습니다.
10. 따라서, 카운터를 두번 뒤집으며 빠른 수행경로 경주상황이 완료된다면, 모든 앞서 존재한 읽기 쓰레드들은 완료되었어야만 하고, 따라서 빠른 수행경로를 취해도 안전합니다.

물론 모든 병렬 알고리즘에 이런 간단한 증명이 통하지는 않습니다. 그런 경우에 있어서는 더 적합한 도구들을 모을 필요가 있을 겁니다.

12.1.4.4 Alternative Approach: More Capable Tools

Promela 와 Spin 이 상당히 유용하긴 하지만, 훨씬 더 적절한 도구들도 사용할 수 있는데, 특히 하드웨어를 검증할 때 그렇습니다. 이는 낮은 단계의 병렬 알고리즘들이 종종 그렇듯, 당신의 알고리즘이 하드웨어 설계용 VHDL 언어로 변환될 수 있다면, 이 도구들을 코드에 적용해 보는 것도 가능합니다(예를 들어, 최초의 realtime RCU 알고리즘을 위해 이 방법이 사용되었습니다). 하지만, 그런 도구들은 상당히 비싼 비용을 필요로 할 수 있습니다.

상품화된 멀티프로세싱의 발전이 결국에는 강력하고 멋진 상태 공간 최소화 기능을 가진 프리 소프트웨어 모델 검증기를 만들어낼 수 있겠지만, 현재 여기에 커다란 도움이 되지는 않습니다.

별개로, Spin 은 고정된 양의 메모리를 필요로 하는 대강의 탐색을 지원합니다만, 저는 병렬 알고리즘을 검증할 때 대략적 방법을 신뢰할 수는 없었습니다.

또 다른 방법은 분할하고 정복하기가 될 겁니다.

12.1.4.5 Alternative Approach: Divide and Conquer

커다란 병렬 알고리즘을 개별적으로 증명될 수 있는, 더 작은 조각들로 조각내는 것이 가능한 경우가 종종 있습니다. 예를 들어, 100억개의 상태를 갖는 모델은 두개의 10만개의 상태를 갖는 모델들로 조각질 수 있습니다. 이 방법은 Promela 와 같은 도구들이 알고리즘을 검증하는 것을 더 쉽게 해줄 뿐 아니라, 알고리즘을 더 이해하기 쉽게 만들어 줄 수 있습니다.

12.1.4.6 Is QRCU Really Correct?

QRCU 는 정말로 올바르게 동작할까요? 우리는 Promela 기반의 기계적 증명과 손으로 하는 증명을 했고 둘 모두 그렇다고 이야기했습니다. 하지만, Alglave 등 [AKT13] 의 최근 논문은 다르게 이야기합니다(해당 논문 page 12 아래쪽의 Section 5.1 을 보세요). 뭐가 맞을까요?

둘 다 맞는 것으로 드러났습니다! QRCU 가 formal-verification 벤치마크에 추가되었을 때, 그 안의 메모리 배리어들이 제거되어 있었고, 따라서 버그가 존재하는 버전의 QRCU 였습니다. 그러니 여기서의 진짜 새로운 소식은 여러개의 formal-verification 도구들이 이 버그가 존재하는 QRCU 를 올바르지 않게도 올바른 것으로 증명했다는 겁니다. 그리고 이게 formal-verification 도구들은 그들 스스로가 bug 가 추가된 버전의 코드를

검증해 보는 것으로 테스트 되어야 하는 이유입니다. 만약 특정 도구가 주입된 버그를 찾지 못한다면, 그 도구는 믿을 수 없는게 분명합니다.

Quick Quiz 12.6: 하지만 다른 formal-verification 도구들은 종종 특정 부류의 버그들을 찾기 위해 설계됩니다. 예를 들어, 극히 일부의 formal-verification 도구들은 해당 스펙 상의 에러만을 찾아낼 겁니다. 그러나, 이 “분명히 믿을 수 없습니다”라는 말은 약간 너무한 거 아닌가요? ■

따라서, 여러분이 QRCU 를 사용하려 한다면, 주의하시기 바랍니다. 그것의 올바름에 대한 증명은 그 자체가 옳을 수도, 아닐 수도 있습니다. 이는 Donald Knuth 가 오래전부터 지적한대로 formal verification 이 완전히 테스트를 교체할 수는 없을 거라 이야기 되는 이유입니다.

Quick Quiz 12.7: 여기에 설명된 QRCU 알고리즘의 정확성에 대한 두개의 독립적인 증명을 가지고 있고, 올바르지 않음에 대한 증명이 다른 알고리즘은 어떤지를 다루고 있는데, 왜 여전히 의문의 여지가 남는 거죠? ■

12.1.5 Promela Parable: dynticks and Preemptible RCU

2005년 8월부터 시작된 -rt 패치셋 [Mol05] 의 RCU 구현과 비슷한, RCU 의 preemption 가능한 변종이 2008년 초에 메인라인 리눅스에 realtime 워크로드에 대한 지원과 함께 받아들여졌습니다. Preemption 가능한 RCU 는 기존의 RCU 구현들이 RCU read-side 크리티컬 섹션 내에서의 preemption 을 불가능하게 하는 바람에 지나치게 긴 real-time 대기시간을 초래했기 때문에 real-time 워크로드를 위해 필요했습니다.

하지만, 기존의 -rt 구현의 한가지 단점은 각각의 grace period 가 모든 각각의 CPU 위에서, 설령 그 CPU 가 저전력의 “dynticks-idle” 상태에 있더라도, 작업을 해야 하고, 그로 인해 RCU read-side 크리티컬 섹션들을 수행하기가 불가능하다는 점이었습니다. Dynticks-idle 상태의 아이디어는 idle CPU 들은 에너지를 아끼기 위해 물리적으로 성능을 낮춰야 한다는 것입니다. 짧게 말해서, preemption 가능한 RCU 는 최신 리눅스 커널에서의 소중한 에너지 절약 기능을 무효화 시킬 수 있다는 점입니다. Josh Triplett 과 Paul McKenney 가 CPU 들이 RCU graceperiod 사이에도 저전력 상태를 유지할 수 있는(따라서 리눅스 커널의 에너지 절약 기능을 유지할 수 있는) 방법에 대해서 토론을 가졌습니다만, Steve Rostedt 가 새로운 dyntick 구현을 -rt 패치셋의 preemptpion 가능한 RCU 와 결합시키기 전까지는 해결책이 나오지 않았습니다.

이 조합은 Steve 의 시스템들 중 하나를 부팅 과정에서 멈춰있게 만들었고, 따라서 10월에, Paul 은 preemption 가능한 RCU 의 grace-period 처리 부분에 dynticks

에 친화적인 수정사항을 코딩 했습니다. Steve 는 irq_enter() 와 irq_exit() 인터럽트 진입/퇴장 함수들로부터 호출되는 rcu_irq_enter() 와 rcu_irq_exit() 인터페이스를 짰습니다. 이 rcu_irq_enter() 와 rcu_irq_exit() 함수는 dynticks-idle CPU 들이 RCU read-side 크리티컬 섹션들을 포함하고 있는 인터럽트 핸들러에 의해 순간적으로 성능을 올리게 되는 상황을 안정적으로 처리하기 위해 필요했습니다. 이런 변경 사항과 함께, Steve 의 시스템은 안정적으로 부팅되었습니다만, Paul 은 첫번째 시도만에 코드가 올바르게 작성되지는 않았을 것이라는 가정 하에 지속적으로 코드를 검사하기를 계속했습니다.

Paul 은 2007년 10월부터 2008년 2월까지 반복적으로 코드를 리뷰했고 거의 매번 최소 하나의 버그는 찾아냈습니다. 한 경우에는, Paul 은 심지어 그 버그가 실제가 없는 것이라 것을 깨닫기 전에도 수정사항을 코딩하고 테스트하기도 했고, 사실 모든 경우들에 있어서, “버그”는 실제가 없는 것으로 드러났습니다.

2월 말 즈음에, Paul 은 이 게임에 지쳐버렸습니다. 따라서 그는 Section 12 에서 이야기한 것처럼 Promela 와 spin [Hol03] 의 도움을 받기로 했습니다. 다음의 내용은 갈수록 현실적인 일곱개의 Promela 모델들을 보이는데, 그 중 마지막의 것은 상태 공간으로 약 40GB 의 메인 메모리를 소비합니다.

더 중요한건, Promela 와 Spin 은 제게 매우 미묘한 버그를 찾아줬습니다!

Quick Quiz 12.8: 와우, 거 참 대단하네요! 이제, 저는 40GB 의 메인 메모리를 가진 기계가 없다면 뭘 해야 하는거죠??? ■

여전히 더 나은 방향은 더 작은 상태 공간을 갖는, 더 간단하고 더 빠른 알고리즘을 사용하는 것일 겁니다. 그보다도 더 나은 방법은 그 정확성이 평상시의 관찰자에 의해서도 분명할 수 있을 만큼 간단한 알고리즘들을 사용하는 것이겠죠!

Section 12.1.5.1 은 preemption 가능한 RCU 의 dynticks 인터페이스에 대해 전체적으로 살펴보고, Section 12.1.6 와 Section 12.1.6.8 은 이로써 (다시) 배운 교훈들을 나열합니다.

12.1.5.1 Introduction to Preemptible RCU and dynticks

Per-CPU dynticks_progress_counter 변수가 dyntick 과 preemption 가능한 RCU 사이의 인터페이스의 중심 역할을 합니다. 이 변수는 연관된 CPU 가 dynticks-idle 모드일 때에는 짹수를 가지게 되고, 그렇지 않을 때에는 홀수를 갖게 됩니다. CPU 는 다음의 세가지 경우에 dynticks-idle 모드를 빠져나갑니다:

1. 태스크 수행을 시작하기 위해서,

2. 중첩되어 있을 수 있는 인터럽트 핸들러들 가운데 가장 바깥쪽의 것에 들어갈 때, 그리고
3. NMI 핸들러에 들어갈 때.

Preemption 가능한 RCU의 grace-period 장치는 언제 dynticks-idle CPU가 안전하게 무시될 수 있을지를 판단하기 위해서 dynticks_progress_counter 변수의 값을 샘플링 합니다.

다음의 세개의 섹션들은 태스크 인터페이스, 인터럽트/NMI 인터페이스, 그리고 grace-period 장치에 의한 dynticks_progress_counter 변수의 사용에 대해서 알아봅니다.

12.1.5.2 Task Interface

특정 CPU가 더이상 수행할 태스크가 존재하지 않아 dynticks-idle 모드로 들어갈 때에, 해당 CPU는 rcu_enter_nohz()를 호출합니다:

```
1 static inline void rcu_enter_nohz(void)
2 {
3     mb();
4     __get_cpu_var(dynticks_progress_counter)++;
5     WARN_ON(__get_cpu_var(dynticks_progress_counter) &
6             0x1);
7 }
```

이 함수는 단순히 dynticks_progress_counter의 값을 증가시키고 그 결과가 짹수인지를 체크합니다만, 그전에 먼저, dynticks_progress_counter의 새로운 값을 보게될 다른 CPU가 앞의 RCU read-side 크리티컬 섹션의 완료 역시 보게 될 것을 보장하기 위해 메모리 배리어를 실행합니다.

비슷하게, dynticks-idle 모드에 있는 CPU가 새로운 수행가능한 태스크를 실행하기를 시작할 준비를 할 때에는, rcu_exit_nohz()를 수행합니다:

```
1 static inline void rcu_exit_nohz(void)
2 {
3     __get_cpu_var(dynticks_progress_counter)++;
4     mb();
5     WARN_ON(!(__get_cpu_var(dynticks_progress_counter) &
6             0x1));
7 }
```

이 함수는 한번 더 dynticks_progress_counter의 값을 증가시킵니다만, 어떤 다른 CPU가 뒤의 RCU read-side 크리티컬 섹션의 결과를 보게 된다면 그 CPU는 dynticks_progress_counter의 증가된 값 역시 볼 수 있을 것을 보장하기 위해 값 증가에 이어 메모리 배리어를 실행시킵니다. 마지막으로, rcu_exit_nohz()는 값 증가의 결과가 허수임을 확인합니다.

rcu_enter_nohz()와 rcu_exit_nohz() 함수는 어떤 CPU가 dynticks-idle 모드를 태스크 수행으로 인해 들어가고 나갈 때를 제어합니다만, 인터럽트는 처리하지 않는 데, 이 부분은 다음 섹션에서 다룹니다.

12.1.5.3 Interrupt Interface

rcu_irq_enter()와 rcu_irq_exit() 함수는 인터럽트/NMI 진입과 종료를 각각 처리합니다. 물론, 중첩된 인터럽트들 또한 적절하게 처리되어야만 합니다. 중첩 인터럽트의 가능성은 인터럽트나 NMI 핸들러 진입 시에 (rcu_irq_enter()에서) 값이 증가되고 종료 시에 (rcu_irq_exit()에서) 값이 감소되는 두번째 per-CPU 변수, rcu_update_flag에 의해 처리됩니다. 추가적으로, 이전부터 존재해온 in_interrupt() 기능은 인터럽트/NMI가 가장 바깥의 것인지 중첩된 것인지 구별해 내는데에 사용됩니다.

인터럽트 진입은 아래 보여진 rcu_irq_enter()에서 처리됩니다:

```
1 void rcu_irq_enter(void)
2 {
3     int cpu = smp_processor_id();
4
5     if (per_cpu(rcu_update_flag, cpu))
6         per_cpu(rcu_update_flag, cpu)++;
7     if (!in_interrupt() &&
8         (per_cpu(dynticks_progress_counter,
9                  cpu) & 0x1) == 0) {
10        per_cpu(dynticks_progress_counter, cpu)++;
11        smp_mb();
12        per_cpu(rcu_update_flag, cpu)++;
13    }
14 }
```

Line 3는 현재 CPU의 숫자를 가져오고, line 5와 6는 rcu_update_flag 중첩 카운터가 0이 아니라면 그 값을 증가시킵니다. Line 7-9는 자신이 인터럽트의 가장 바깥 단계인지를 체크하고, 만약 그렇다면 dynticks_progress_counter가 증가되어야 합니다. 만약 그 경우라면, line 10에서 dynticks_progress_counter의 값을 증가시키고, line 11에서 메모리 배리어를 실행한 후, line 12에서 rcu_update_flag의 값을 증가시킵니다. rcu_exit_nohz()에서와 마찬가지로, 이 메모리 배리어는 이 인터럽트 핸들러 안에서의 RCU read-side 크리티컬 섹션의 영향을 본 CPU는 dynticks_progress_counter의 값의 증가 결과 역시 볼 수 있을 것을 보장합니다.

Quick Quiz 12.9: 왜 간단하게 rcu_update_flag의 값을 증가시키고, rcu_update_flag의 기존 값이 0일 경우에만 dynticks_progress_counter의 값을 증가시키는 방식을 사용하지 않는거죠???

Quick Quiz 12.10: 하지만 line 7이 우리가 가장 바깥의 인터럽트에 있음을 알게 된다면, 우린 항상 dynticks_progress_counter의 값을 증가시켜야 하는 것 아닌가요?

인터럽트 종료는 rcu_irq_exit()에 의해 비슷하게 처리됩니다:

```
1 void rcu_irq_exit(void)
2 {
```

```

3   int cpu = smp_processor_id();
4
5   if (per_cpu(rcu_update_flag, cpu)) {
6     if (--per_cpu(rcu_update_flag, cpu))
7       return;
8     WARN_ON(in_interrupt());
9     smp_mb();
10    per_cpu(dynticks_progress_counter, cpu)++;
11    WARN_ON(per_cpu(dynticks_progress_counter,
12                     cpu) & 0x1);
13  }
14 }

```

Line 3은 앞에서처럼 현재 CPU의 번호를 가져옵니다. Line 5는 `rcu_update_flag`의 값이 0이 아닌지 확인해보고, 그렇지 않다면 곧바로(함수의 마지막으로 제어를 넘김으로써) 리턴합니다. 그렇지 않다면, line 6부터 12가 수행됩니다. Line 6은 `rcu_update_flag`의 값을 감소시키고, 그 결과가 0이 아니라면 리턴합니다. Line 8은 우리가 정말로 중첩된 인터럽트를 가운데 가장 마지막 단계를 빠져나가고 있음을 검증하고, line 9에서 메모리 배리어를 수행한 후, line 10에서 `dynticks_progress_counter`의 값을 증가시키고, line 11과 12에서 이 변수가 이제는 짹수임을 검증합니다. `rcu_enter_nohz()`에서와 같이, 메모리 배리어는 `dynticks_progress_counter`의 값 증가를 본 다른 CPU는 해당 인터럽트 핸들러 내에서의 (`rcu_irq_exit()` 호출을 앞서 수행된) RCU read-side 크리티컬 섹션의 결과 역시 보게 될것을 보장합니다.

이 두 섹션은 `dynticks_progress_counter` 변수가 태스크들과 인터럽트, NMI에 의해 `dynticks-idle` 모드로 들어갈 때와 빠져나올 때에 어떻게 관리되는지를 설명했습니다. 다음 섹션은 이 변수가 `preemption` 가능한 RCU의 grace-period 장치에 의해 어떻게 사용되는지를 설명합니다.

12.1.5.4 Grace-Period Interface

Figure 12.1에 보인 네개의 `preemption` 가능한 RCU grace-period 상태 가운데, `rcu_try_flip_waitack_state()`와 `rcu_try_flip_waitmb_state()` 상태만이 다른 CPU들이 응답하길 기다려야 합니다.

물론, 한 CPU가 `dynticks-idle` 상태에 있다면, 그걸 기다릴 수는 없습니다. 따라서, 이 두개의 상태를 중 하나에 들어가기 직전에, 앞의 상태는 각 CPU들의 `dynticks_progress_counter` 변수의 값들의 스텝샷을 떠놓고, 그 스텝샷을 또 다른 per-CPU 변수인 `rcu_dyntick_snapshot`에 넣어둡니다. 이는 아래에 보여진 것과 같은 `dyntick_save_progress_counter()`를 호출함으로써 이뤄집니다:

```

1 static void dyntick_save_progress_counter(int cpu)
2 {
3   per_cpu(rcu_dyntick_snapshot, cpu) =
4     per_cpu(dynticks_progress_counter, cpu);
5 }

```




Figure 12.1: Preemptible RCU State Machine

`rcu_try_flip_waitack_state()` 상태는 아래에 보여진 것과 같은 `rcu_try_flip_waitack_needed()`를 호출합니다:

```

1 static inline int
2 rcu_try_flip_waitack_needed(int cpu)
3 {
4   long curr;
5   long snap;
6
7   curr = per_cpu(dynticks_progress_counter, cpu);
8   snap = per_cpu(rcu_dyntick_snapshot, cpu);
9   smp_mb();
10  if ((curr == snap) && ((curr & 0x1) == 0))
11    return 0;
12  if ((curr - snap) > 2 || (snap & 0x1) == 0)
13    return 0;
14  return 1;
15 }

```

Line 7과 8은 `dynticks_progress_counter`의 현재 버전과 스냅샷 버전을 각각 가져옵니다. Line 9에서의 메모리 배리어는 뒤의 `rcu_try_flip_waitzero_state()`에서의 카운터 체크가 이 카운터들을 읽어오는 행위 뒤에 이뤄짐을 보장합니다. Line 10과 11은 해당 CPU가 스냅샷이 찍힌 후로 `dynticks-idle` 상태를 유지했다면 0을 리턴 (해당 CPU 와의 커뮤니케이션이 필요치 않음을 의미) 합니다. 비슷하게, Line 12와 13은 해당 CPU가 초기에 `dynticks-idle` 상태였거나 `dynticks-`

idle 상태를 완전히 지나왔다면 0을 리턴합니다. 이 두 가지 경우 모두에 있어서, 해당 CPU가 grace-period 카운터의 옛날 값을 가져왔을 수는 없습니다. 이런 조건들 가운데 하나도 해당되지 않는다면, line 14에서 1을 리턴하는데, 이는 해당 CPU가 명시적인 응답을 필요로 함을 의미합니다.

`rcu_try_flip_waitmb_state()` 상태는 아래에 보인 것과 같은 `rcu_try_flip_waitmb_needed()`를 호출합니다:

```

1 static inline int
2 rCU_try_flip_waitmb_needed(int cpu)
3 {
4     long curr;
5     long snap;
6
7     curr = per_cpu(dynticks_progress_counter, cpu);
8     snap = per_cpu(rcu_dyntick_snapshot, cpu);
9     smp_mb();
10    if ((curr == snap) && ((curr & 0x1) == 0))
11        return 0;
12    if (curr != snap)
13        return 0;
14    return 1;
15 }
```

이는 `rcu_try_flip_waitack_needed()` 와 유사한데, 차이점은 line 12와 13 뿐으로, dynticks-idle 상태로부터 또는 dynticks-idle 상태로의 상태 전환은 모두 `rcu_try_flip_waitmb_state()` 상태에 의해 필요한 메모리 배리어를 실행하기 때문입니다.

이제 우리는 RCU와 dynticks-idle 상태 사이의 인터페이스에 관여된 모든 코드를 봤습니다. 다음 섹션은 이 코드를 검증하기 위해 Promela 모델을 만들어 봅니다.

Quick Quiz 12.11: 이 섹션에서 보인 모든 코드 가운데 버그들을 찾아냈나요? ■

12.1.6 Validating Preemptible RCU and dynticks

이 섹션은 dynticks와 RCU 사이의 인터페이스를 위한 Promela 모델을 단계별로 개발해 보며, 각각의 단계를 뒤따르는 섹션들에서 하나씩 설명하는데, 프로세스 단계 코드부터 시작해서, 단정문, 인터럽트, 그리고 마지막으로 NMI를 추가해 봅니다.

12.1.6.1 Basic Model

이 섹션은 프로세스 단계 dynticks 진입/종료 코드와 grace-period 처리를 Promela로 변환해 봅니다 [Hol03]. 우리는 2.6.25-rc4 커널에서의 `rcu_exit_nohz()`와 `rcu_enter_nohz()`로 시작해서, 이것들을 dynticks-idle 모드를 들어가고 빠져나오는 과정을 모델링하는 Promela 프로세스를 다음의 루프와 같이 만들 겁니다:

```

1 proctype dyntick_nohz()
2 {
3     byte tmp;
4     byte i = 0;
5
6     do
7         :: i >= MAX_DYNTICK_LOOP_NOHZ -> break;
8         :: i < MAX_DYNTICK_LOOP_NOHZ ->
9             tmp = dynticks_progress_counter;
10            atomic {
11                dynticks_progress_counter = tmp + 1;
12                assert((dynticks_progress_counter & 1) == 1);
13            }
14            tmp = dynticks_progress_counter;
15            atomic {
16                dynticks_progress_counter = tmp + 1;
17                assert((dynticks_progress_counter & 1) == 0);
18            }
19            i++;
20        od;
21 }
```

Line 6과 20은 루프를 정의합니다. Line 7은 i의 값이 MAX_DYNTICK_LOOP_NOHZ를 넘어서면 루프를 빠져나가게 합니다. Line 8은 루프의 각 패스가 line 9-19를 수행하도록 구성합니다. Line 7과 8의 조건들은 서로에게 배타적이기 때문에, 일반적인 Promela의 옳은 조건에 대한 무작위 선택은 무효화 됩니다. Line 9와 11은 `rcu_exit_nohz()`의 어토믹하지 않은 `dynticks_progress_counter` 값 증가를 모델링 하며, line 12는 `WARN_ON()`을 모델링 합니다. 여기서의 `atomic`은 `WARN_ON()`이 엄밀히 말해선 알고리즘의 한 부분이 아닌 만큼 단순히 Promela 상태 공간의 크기를 줄여주는 역할을 합니다. Line 14-18은 비슷하게 `rcu_enter_nohz()`의 값 증가와 `WARN_ON()`을 모델링 합니다. 마지막으로, line 19는 루프 카운터의 값을 증가시킵니다.

따라서 루프의 각 패스는 (예를 들어, 태스크를 시작하려고 해서) dynticks-idle 모드를 빠져나가는, 그리고 나서 다시 (예를 들어, 그 태스크가 블락 당해서) dynticks-idle 모드로 들어가는 CPU를 모델링합니다.

Quick Quiz 12.12: 왜 `rcu_exit_nohz()`와 `rcu_enter_nohz()` 사이의 메모리 배리어는 Promela에 모델링 되지 않은거죠? ■

Quick Quiz 12.13: `rcu_exit_nohz()`에 있어서 `rcu_enter_nohz()`가 뒤따르는 경우를 모델링 하는 건 좀 이상하지 않나요? 그보다는 진입 후에 빠져나가는 상황을 모델링하는게 더 자연스럽지 않을까요? ■

다음 단계는 RCU의 grace-period 처리를 위한 인터페이스의 모델링입니다. 이를 위해, 우리는 2.6.25-rc4 커널의 `dyntick_save_progress_counter()`, `rcu_try_flip_waitack_needed()`, `rcu_try_flip_waitmb_needed()`, `rcu_try_flip_waitmb()`를 모델링 해야 합니다. 다음의 `grace_period()` Promela 프로세스는 이 함수들을 그것들이 하나의 preemption 가능한 RCU의 grace-period 처리 과정 사이에서 호출될 것처럼 모델링 합니다.

```

1 proctype grace_period()
2 {
3     byte curr;
4     byte snap;
5
6     atomic {
7         printf("MDLN = %d\n", MAX_DYNTICK_LOOP_NOHZ);
8         snap = dynticks_progress_counter;
9     }
10    do
11        :: 1 ->
12        atomic {
13            curr = dynticks_progress_counter;
14            if
15                :: (curr == snap) && ((curr & 1) == 0) ->
16                    break;
17                :: (curr - snap) > 2 || (snap & 1) == 0 ->
18                    break;
19                :: 1 -> skip;
20                fi;
21        }
22    od;
23    snap = dynticks_progress_counter;
24    do
25        :: 1 ->
26        atomic {
27            curr = dynticks_progress_counter;
28            if
29                :: (curr == snap) && ((curr & 1) == 0) ->
30                    break;
31                :: (curr != snap) ->
32                    break;
33                :: 1 -> skip;
34                fi;
35        }
36    od;
37 }

```

Line 6-9 는 루프 리미트를 (에러가 났을 경우에 한해 .trail 파일에) 프린트하고 현재 CPU 의 dynticks_progress_counter 변수의 스냅샷을 얻어오는, rcu_try_flip_idle() 의 코드 한줄과 dyntick_save_progress_counter() 호출을 모델링 합니다. 이 두 라인은 상태 공간의 크기를 줄이기 위해 어토믹하게 수행됩니다.

Line 10-22 는 rcu_try_flip_waitack() 함수의 rcu_try_flip_waitack_needed() 함수 호출을 모델링합니다. 이 루프는 각 CPU 로부터 카운터 뒤집기 응답을 기다리는 grace-period 상태 머신을, 하지만 그 중에서도 dynticks-idle CPU 들과 상호작용하는 부분만을 모델링 합니다.

Line 23 은 또다시 CPU 의 dynticks_progress_counter 변수의 스냅샷을 얻어오는 rcu_try_flip_waitzero() 의 코드 중 한줄과 그것의 dyntick_save_progress_counter() 함수 호출을 모델링 합니다.

마지막으로, line 24-36 은 rcu_try_flip_waitack() 과 이 함수의 rcu_try_flip_waitack_needed() 호출을 모델링합니다. 이 루프는 각각의 CPU 가 메모리 배리어를 실행하기를 기다리는, 하지만 여기서도 역시 dynticks-idle CPU 들과 상호작용하는 부분만을 모델링 합니다.

Quick Quiz 12.14: 잠깐만요! 이 리눅스 커널에

서, dynticks_progress_counter 와 rcu_dyntick_snapshot 은 per-CPU 변수들입니다. 그런데 왜 그것들이 per-CPU 변수들이 아니라 하나의 글로벌 변수로 모델링 되거죠? ■

최종적인 모델 (dyntickRCU-base.spin) 은 runspin.sh 스크립트를 통해 돌아갈 때, 691 개의 상태를 생성하고 에러 없이 수행되는데, 이것은 실패를 찾을 수 있는 단정문이 존재하지 않는다는 점을 생각해 보면 놀라울 일이 아닙니다. 따라서 다음 섹션에서는 안전성을 위한 단정문들을 추가해 봅니다.

12.1.6.2 Validating Safety

안전한 RCU 구현에서 grace period 는 그 grace period 의 시작 전에 시작된 모든 RCU 읽기 쓰레드들이 완료되기 전에는 절대 완료될 수 없어야 합니다. 이는 다음과 같은 세개의 상태를 취할 수 있는 gp_state 변수를 사용해 모델링 될 수 있습니다:

```

1 #define GP_IDLE    0
2 #define GP_WAITING 1
3 #define GP_DONE    2
4 byte gp_state = GP_DONE;

```

grace_period() 프로세스는 이 변수를 아래에 보여진 것과 같이 grace-period 단계를 통해 진행되는 것처럼 설정합니다:

```

1 proctype grace_period()
2 {
3     byte curr;
4     byte snap;
5
6     gp_state = GP_IDLE;
7     atomic {
8         printf("MDLN = %d\n", MAX_DYNTICK_LOOP_NOHZ);
9         snap = dynticks_progress_counter;
10    gp_state = GP_WAITING;
11 }
12 do
13    :: 1 ->
14    atomic {
15        curr = dynticks_progress_counter;
16        if
17            :: (curr == snap) && ((curr & 1) == 0) ->
18                break;
19            :: (curr - snap) > 2 || (snap & 1) == 0 ->
20                break;
21            :: 1 -> skip;
22            fi;
23    }
24 od;
25 gp_state = GP_DONE;
26 gp_state = GP_IDLE;
27 atomic {
28     snap = dynticks_progress_counter;
29     gp_state = GP_WAITING;
30 }
31 do
32    :: 1 ->
33    atomic {
34        curr = dynticks_progress_counter;

```

```

35     if
36     :: (curr == snap) && ((curr & 1) == 0) ->
37     break;
38     :: (curr != snap) ->
39     break;
40     :: 1 -> skip;
41   fi;
42 }
43 od;
44 gp_state = GP_DONE;
45 }

```

Line 6, 10, 25, 26, 29, 그리고 44 는 기본적인 RCU 안전성을 검증하기 위해 dyntick_nohz() 프로세스를 허용할 수 있도록 이 변수를 (적당한 알고리즘적 오퍼레이션들을 어도막하게 섞어서) 업데이트 합니다. 이 검증의 형태는 RCU 읽기 쓰레드들이 그럴듯하게 존재하는 시간동안 gp_state 변수의 값이 GP_IDLE에서 GP_DONE 으로 바뀔 수 없음을 단정하려는 것입니다.

Quick Quiz 12.15: Line 25 와 26 에 gp_state 의 연속된 두개의 변경이 있는데, 어떻게 line 25 에서의 변경이 사라지지 않을거라고 확신할 수 있을까요? ■

dyntick_nohz() Promela 프로세스는 이 검증을 아래와 같이 구현합니다:

```

1 proctype dyntick_nohz()
2 {
3   byte tmp;
4   byte i = 0;
5   bit old_gp_idle;
6
7   do
8     :: i >= MAX_DYNTICK_LOOP_NOHZ -> break;
9     :: i < MAX_DYNTICK_LOOP_NOHZ ->
10    tmp = dynticks_progress_counter;
11    atomic {
12      dynticks_progress_counter = tmp + 1;
13      old_gp_idle = (gp_state == GP_IDLE);
14      assert((dynticks_progress_counter & 1) == 1);
15    }
16    atomic {
17      tmp = dynticks_progress_counter;
18      assert(!old_gp_idle ||
19             gp_state != GP_DONE);
20    }
21    atomic {
22      dynticks_progress_counter = tmp + 1;
23      assert((dynticks_progress_counter & 1) == 0);
24    }
25    i++;
26  od;
27  dyntick_nohz_done = 1;
28 }

```

Line 13 은 gp_state 변수의 값이 태스크 수행 시작 시점에서 GP_IDLE 이라면 old_gp_idle 플래그를 설정하고, gp_state 변수가 태스크 수행 중간에 GP_DONE 으로 바뀌었다면 하나의 RCU read-side 크리티컬 섹션이 전체 시간동안 존재할 수 있다는 점에서 비합법 적이므로 line 18 과 19 에서의 단정문이 실패합니다.

결과적으로 만들어지는 모델 (dyntickRCU-base-s.spin) 은 runspin.sh 스크립트를 통해 수행될 때, 964 개의 상태들을 생성하고 안심스럽게도 에러없이 돌아갑니다. 그렇다면 하나, 안전성이 상당히 중요하긴

하지만, 불명확하게 지연되는 grace period 를 막는 것 역시 굉장히 중요합니다. 따라서 다음 섹션에서는 liveness 의 검증을 다룹니다.

12.1.6.3 Validating Liveness

Liveness 는 증명하기 어려울 수 있지만, 여기 적용할 수 있는 간단한 트릭이 있습니다. 첫번째 단계는 다음의 line 27 에서 보이는 것과 같이 dyntick_nohz() 가 dyntick_nohz_done 을 통해 할일을 마쳤음을 알리는 것입니다:

```

1 proctype dyntick_nohz()
2 {
3   byte tmp;
4   byte i = 0;
5   bit old_gp_idle;
6
7   do
8     :: i >= MAX_DYNTICK_LOOP_NOHZ -> break;
9     :: i < MAX_DYNTICK_LOOP_NOHZ ->
10    tmp = dynticks_progress_counter;
11    atomic {
12      dynticks_progress_counter = tmp + 1;
13      old_gp_idle = (gp_state == GP_IDLE);
14      assert((dynticks_progress_counter & 1) == 1);
15    }
16    atomic {
17      tmp = dynticks_progress_counter;
18      assert(!old_gp_idle ||
19             gp_state != GP_DONE);
20    }
21    atomic {
22      dynticks_progress_counter = tmp + 1;
23      assert((dynticks_progress_counter & 1) == 0);
24    }
25    i++;
26  od;
27  dyntick_nohz_done = 1;
28 }

```

이 변수를 두면, 불필요한 블록들을 체크하기 위해 다음과 같이 grace_period() 에 단정문들을 추가할 수 있습니다:

```

1 proctype grace_period()
2 {
3   byte curr;
4   byte snap;
5   bit shouldexit;
6
7   gp_state = GP_IDLE;
8   atomic {
9     printf("MDLN = %d\n", MAX_DYNTICK_LOOP_NOHZ);
10    shouldexit = 0;
11    snap = dynticks_progress_counter;
12    gp_state = GP_WAITING;
13  }
14  do
15    :: 1 ->
16    atomic {
17      assert(!shouldexit);
18      shouldexit = dyntick_nohz_done;
19      curr = dynticks_progress_counter;
20      if
21        :: (curr == snap) && ((curr & 1) == 0) ->
22        break;

```

```

23      :: (curr - snap) > 2 || (snap & 1) == 0 ->
24          break;
25      :: else -> skip;
26      fi;
27  }
28 od;
29 gp_state = GP_DONE;
30 gp_state = GP_IDLE;
31 atomic {
32     shouldexit = 0;
33     snap = dynticks_progress_counter;
34     gp_state = GP_WAITING;
35 }
36 do
37 :: 1 ->
38     atomic {
39         assert(!shouldexit);
40         shouldexit = dyntick_nohz_done;
41         curr = dynticks_progress_counter;
42         if
43             :: (curr == snap) && ((curr & 1) == 0) ->
44                 break;
45             :: (curr != snap) ->
46                 break;
47             :: else -> skip;
48         fi;
49     }
50 od;
51 gp_state = GP_DONE;
52 }

```

우리는 line 10에서 0으로 초기화되는 `shouldexit` 변수를 line 5에서 추가했습니다. Line 17은 `shouldexit` 가 아직 0일 것을 단정하며, line 18에서는 `shouldexit` 를 `dyntick_nohz()`에 의해 관리되는 `dyntick_nohz_done`의 값으로 설정합니다. 따라서 이 단정은 `dyntick_nohz()` 가 수행 완료된 후의 카운터가 뒤집히는 응답을 기다리는 과정에서 하나 이상의 패스를 시도하게 되면 실패할 것입니다. 어쨌건, `dyntick_nohz()` 가 완료되었다면, 더이상 우리를 해당 루프의 바깥으로 나가게 할 상태 변화는 더이상 없고, 따라서 이 상태를 두번 이상 수행하게 됨은 곧 무한루프를 의미해서, grace period 가 끝나지 않을 것임을 의미하게 됩니다.

Line 32, 39, 그리고 40은 두번째 (메모리 배리어) 루프를 위해 비슷한 방식으로 수행됩니다.

하지만, 이 모델 (`dyntickRCU-base-sl-busted.spin`)을 수행하는 것은 실패로 끝나게 되는데, line 23이 잘못된 변수는 짹수라고 체크를 하기 때문입니다. 실패하게 되면, `spin`은 “trail” 파일 (`dyntickRCU-base-sl-busted.spin.trail`)을 쓰게 되는데, 이 파일은 실패로 이르게 된 상태들의 시퀀스를 기록합니다. `spin`이 이 상태들의 시퀀스를 재추적하게 하고 실행된 statement 들과 변수들의 값 (`dyntickRCU-base-sl-busted.spin.trail.txt`)을 프린트 하려면 `spin -t -p -g -l dyntickRCU-base-sl-busted.spin` 커맨드를 사용하세요. `Spin`은 두 함수를 모두 하나의 파일에서 취할 것이기 때문에 위에 리스트된 코드와 라인 수가 맞지 않을 수 있음을 알아 두세요. 하지만, 라인 수는 전체 모델 (`dyntickRCU-base-sl-busted.spin`과는

맞아떨어질 겁니다.

`dyntick_nohz()` 프로세스가 step 34에서 (“34:”를 검색해 보세요) 완료되었지만, `grace_period()` 프로세스는 루프를 빠져나가는데 실패했음을 볼 수 있습니다. `curr`의 값은 6이고 (step 35를 보세요) `snap`의 값은 5 (step 17을 보세요)입니다. 따라서 line 21에서의 첫번째 조건은 `curr != snap` 이므로 성립되지 않고, line 23에서의 두번째 조건은 `snap`이 훌수이고 `curr`는 `snap` 보다 1만큼 클 뿐이기 때문에 성립되지 않습니다.

따라서 이 두개의 조건들 중 하나는 올바르지 않습니다. `rcu_try_flip_waitack_needed()`의 첫번째 조건에 대한 코멘트를 따르면:

CPU 가 전체 시간동안 dynticks 모드에 빠져 있고 인터럽트, NMI, SNMI, 또는 뭐든 받지 않았다면, 해당 CPU는 `rcu_read_lock()`의 중간에 있을 수 없고, 따라서 그것이 수행하게 되는 다음의 `rcu_read_lock()`는 카운터의 새로운 값을 사용해야만 한다. 따라서 우리는 안전하게 이 CPU가 이미 그 카운터에 응답을 한 것처럼 행동을 한다.

첫번째 조건은 실제로 이와 들어맞는데, `curr == snap`이고 `curr`가 짹수라면, 연관된 CPU는 요구된 대로 dynticks-idle 모드에 전체 시간동안 존재한 것이기 때문입니다. 따라서 두번째 조건에 대한 코멘트를 보도록 합시다:

CPU 가 dynticks idle 단계를 활성화된 irq 핸들러 없이 거쳐왔거나 진입했다면, 앞에서와 같이 우린 이 CPU 가 카운터에 응답을 이미 한 것처럼 안전하게 행동할 수 있다.

조건의 첫번째 부분은 올바른데, `curr` 와 `snap` 이 2만큼 차이가 나면 그 사이에 최소 하나의 짹수가 존재할 수 있어서, 하나의 dynticks-idle 단계를 완전히 지나왔다고 볼 수 있기 때문입니다. 하지만, 조건의 두번째 부분은 dynticks-idle 모드가 시작되었지만, 이 모드가 아직 끝나지 않았음을 의미합니다. 따라서 우리는 짹수가 되어야 할 값으로 `snap` 이 아니라 `curr` 를 테스트해야합니다.

고쳐진 C 코드는 다음과 같습니다:

```

1 static inline int
2 rCU_try_flip_waitack_needed(int cpu)
3 {
4     long curr;
5     long snap;
6
7     curr = per_cpu(dynticks_progress_counter, cpu);
8     snap = per_cpu(rcu_dyntick_snapshot, cpu);
9     smp_mb();
10    if ((curr == snap) && ((curr & 0x1) == 0))

```

```

11     return 0;
12     if (((curr - snap) > 2 || (curr & 0x1) == 0)
13         return 0;
14     return 1;
15 }

```

Line 10-13 은 이제 다음과 같이 간단하게 결합될 수 있습니다. 비슷한 단순화가 `rcu_try_flip_waitmb_needed()`에 적용될 수 있습니다.

```

1 static inline int
2 rCU_try_flip_waitmb_needed(int cpu)
3 {
4     long curr;
5     long snap;
6
7     curr = per_cpu(dynticks_progress_counter, cpu);
8     snap = per_cpu(rcu_dyntick_snapshot, cpu);
9     smp_mb();
10    if (((curr - snap) >= 2 || (curr & 0x1) == 0)
11        return 0;
12    return 1;
13 }

```

해당 모델에 연관된 수정을 가하면 (`dyntickRCU-base-sl.spin`) 어려 없이 통과되는 661 개의 상태들을 통한 올바른 검증을 얻을 수 있습니다. 하지만, 첫번째 버전의 liveness 검증은 liveness 검증 자체의 버그로 인해서, 이 버그를 잡는데 실패했음은 알려둘 가치가 있습니다. 이 liveness 증명 버그는 `grace_period()` 프로세스 안에 무한루프를 넣어둠으로써 발생했습니다!

우린 이제 안전성과 liveness 조건을 모두 성공적으로 검증했습니다만, 동작하고 블락킹 되는 프로세스들에 대해서만 그렇습니다. 인터럽트들 역시 처리해야 할텐데, 이는 다음 섹션에서 처리하도록 하겠습니다.

12.1.6.4 Interrupts

Promela에서 인터럽트를 모델링하는 두가지 방법이 있습니다:

1. C 전처리기 트릭을 사용해서 모든 `dynticks_nohz()` 프로세스의 statement 사이에 인터럽트 핸들러를 넣거나
2. 인터럽트 핸들러를 별도의 프로세스로 모델링 하는 겁니다.

두번째 방법이 더 작은 상태 공간을 갖게 해줄거라 생각할 수 있습니다만, 이는 인터럽트 핸들러가 어떻게든 `dynticks_nohz()` 와는 어토믹하게 동작해야 하지만 `grace_period()` 와는 어토믹하지 않게 동작해야 할 것을 필요로 합니다.

다행히도, Promela는 어토믹 statement들을 분기할 수 있게 해줍니다. 이 트릭은 우리가 인터럽트 핸들러에서 플래그를 설정하고, `dynticks_nohz()` 가 어토믹하게 이 플래그를 체크한 후 그 플래그가 설정되지 않았을 때에만 실행되도록 코드를 수정할 수 있게

합니다. 이는 다음과 같이 라벨과 Promela statement들을 사용하는 C 전처리기 매크로를 사용해 이뤄질 수 있습니다:

```

1 #define EXECUTE_MAINLINE(label, stmt) \
2 label: skip; \
3     atomic { \
4         if \
5             :: in_dyntick_irq -> goto label; \
6         :: else -> stmt; \
7         fi; \
8     } \

```

이 매크로를 다음과 같이 사용할 수 있을 겁니다:

```

EXECUTE_MAINLINE(stmt1,
                  tmp = dynticks_progress_counter)

```

매크로의 line 2는 특정 statement 라벨을 만듭니다. Line 3-8은 `in_dyntick_irq` 변수를 테스트하는 어토믹 블락으로, 이 변수가 값이 설정되어 있다면(인터럽트 핸들러가 활성 상태임을 의미), 어토믹 블락의 수행을 라벨로 되돌립니다. 그렇지 않다면, line 6에서 요청된 statement를 수행합니다. 이로 인한 전체적인 효과는 요청된대로 인터럽트가 활성화 될 때마다 메인 수행이 공회전을 하게 되는 것입니다.

12.1.6.5 Validating Interrupt Handlers

첫번째 단계는 `dyntick_nohz()`를 다음과 같이 `EXECUTE_MAINLINE()`의 형태로 바꾸는 겁니다:

```

1 proctype dyntick_nohz()
2 {
3     byte tmp;
4     byte i = 0;
5     bit old_gp_idle;
6
7     do
8     :: i >= MAX_DYNTICK_LOOP_NOHZ -> break;
9     :: i < MAX_DYNTICK_LOOP_NOHZ ->
10        EXECUTE_MAINLINE(stmt1,
11                           tmp = dynticks_progress_counter)
12        EXECUTE_MAINLINE(stmt2,
13                           dynticks_progress_counter = tmp + 1;
14                           old_gp_idle = (gp_state == GP_IDLE);
15                           assert((dynticks_progress_counter & 1) == 1));
16        EXECUTE_MAINLINE(stmt3,
17                           tmp = dynticks_progress_counter;
18                           assert(!old_gp_idle ||
19                                 gp_state != GP_DONE))
20        EXECUTE_MAINLINE(stmt4,
21                           dynticks_progress_counter = tmp + 1;
22                           assert((dynticks_progress_counter & 1) == 0));
23        i++;
24    od;
25    dyntick_nohz_done = 1;
26 }

```

여러 statement의 그룹이 `EXECUTE_MAINLINE()`으로 전달될 때에는 line 12-15와 같이 해당 그룹 내의

모든 statement 가 어토믹하게 수행됨을 알아둘 필요가 있습니다.

Quick Quiz 12.16: 하지만 EXECUTE_MAINLINE() 내의 statement 들이 어토믹 하지 않게 수행되어야 하는 경우라면 어떻게 하겠습니까? ■

Quick Quiz 12.17: 하지만 dynticks_nohz() 프로세스가 “if” 나 “do” 문을 가지고 있는데 그 안의 조건절들이 그 분기 본체들은 어토믹하지 않게 수행되는 형태라면 어떻게 되죠? ■

다음 단계는 인터럽트 핸들러를 모델링 하기 위해 dyntick_irq() 프로세스를 작성하는 것입니다:

```

1 proctype dyntick_irq()
2 {
3     byte tmp;
4     byte i = 0;
5     bit old_gp_idle;
6
7     do
8     :: i >= MAX_DYNTICK_LOOP_IRQ -> break;
9     :: i < MAX_DYNTICK_LOOP_IRQ ->
10    in_dyntick_irq = 1;
11    if
12    :: rcu_update_flag > 0 ->
13        tmp = rcu_update_flag;
14        rcu_update_flag = tmp + 1;
15    :: else -> skip;
16    fi;
17    if
18    :: !in_interrupt &&
19        (dynticks_progress_counter & 1) == 0 ->
20        tmp = dynticks_progress_counter;
21        dynticks_progress_counter = tmp + 1;
22        tmp = rcu_update_flag;
23        rcu_update_flag = tmp + 1;
24    :: else -> skip;
25    fi;
26    tmp = in_interrupt;
27    in_interrupt = tmp + 1;
28    old_gp_idle = (gp_state == GP_IDLE);
29    assert(!old_gp_idle || gp_state != GP_DONE);
30    tmp = in_interrupt;
31    in_interrupt = tmp - 1;
32    if
33    :: rcu_update_flag != 0 ->
34        tmp = rcu_update_flag;
35        rcu_update_flag = tmp - 1;
36    if
37    :: rcu_update_flag == 0 ->
38        tmp = dynticks_progress_counter;
39        dynticks_progress_counter = tmp + 1;
40    :: else -> skip;
41    fi;
42    :: else -> skip;
43    fi;
44    atomic {
45        in_dyntick_irq = 0;
46        i++;
47    }
48    od;
49    dyntick_irq_done = 1;
50 }

```

Line 7-48 의 루프는 MAX_DYNTICK_LOOP_IRQ 까지의 인터럽트들을 모델링하는데, line 8 과 9는 루프 조건을 구성하고 line 46 은 제어 변수를 증가시킵니다. Line 10

은 dyntick_nohz() 에게 인터럽트 핸들러가 돌아가는 중이라고 이야기하고, line 45 는 dyntick_nohz()에게 이 핸들러가 완료되었다고 이야기합니다. Line 49는 dyntick_nohz() 의 관련된 라인과 같이 liveness 검증을 위해 사용됩니다.

Quick Quiz 12.18: Line 45 와 46(in_dyntick_irq = 0; 와 i++) 은 왜 어토믹하게 수행되는 건가요? ■

Line 11-25 는 rcu_irq_enter() 를 모델링하고, line 26 과 27 은 __irq_enter() 의 관련된 부분을 모델링 합니다. Line 28 과 29 는 dynticks_nohz() 의 관련된 부분과 거의 같은 방법으로 안전성을 검증합니다. Line 30 과 31 은 __irq_exit() 의 관련 부분을 모델링 하고, line 32-43 에서 rcu_irq_exit() 을 모델링 합니다.

Quick Quiz 12.19: ① dynticks_irq() 프로세스가 모델링할 수 없는 인터럽트들의 특성은 무엇이 있을까요? ■

이제 grace_period() 프로세스는 다음과 같이 됩니다:

```

1 proctype grace_period()
2 {
3     byte curr;
4     byte snap;
5     bit shouldexit;
6
7     gp_state = GP_IDLE;
8     atomic {
9         printf("MDLN = %d\n", MAX_DYNTICK_LOOP_NOHZ);
10        printf("MDLI = %d\n", MAX_DYNTICK_LOOP_IRQ);
11        shouldexit = 0;
12        snap = dynticks_progress_counter;
13        gp_state = GP_WAITING;
14    }
15    do
16    :: 1 ->
17    atomic {
18        assert(!shouldexit);
19        shouldexit = dyntick_nohz_done &&
20                    dyntick_irq_done;
21        curr = dynticks_progress_counter;
22        if
23            :: (curr - snap) >= 2 || (curr & 1) == 0 ->
24            break;
25        :: else -> skip;
26        fi;
27    }
28    od;
29    gp_state = GP_DONE;
30    gp_state = GP_IDLE;
31    atomic {
32        shouldexit = 0;
33        snap = dynticks_progress_counter;
34        gp_state = GP_WAITING;
35    }
36    do
37    :: 1 ->
38    atomic {
39        assert(!shouldexit);
40        shouldexit = dyntick_nohz_done &&
41                    dyntick_irq_done;
42        curr = dynticks_progress_counter;
43        if
44            :: (curr != snap) || ((curr & 1) == 0) ->
45            break;

```

```

46      :: else -> skip;
47      fi;
48  }
49  od;
50  gp_state = GP_DONE;
51 }

```

grace_period() 의 구현은 앞의 것과 매우 유사합니다. 변경점은 새로운 인터럽트 카운트 인자를 추가하기 위한 line 10 의 추가와 liveness 체크를 위한 새로운 dyntick_irq_done 변수를 추가하는 line 19 와 39 의 변경, 그리고 line 22 와 42 에서의 최적화 뿐입니다.

이 모델 (dyntickRCU-irqn-ssl.spin)은 대략 50만개의 상태를 에러 없이 성공적으로 검증합니다. 하지만, 이 버전의 모델링은 중첩된 인터럽트를 처리하지 않습니다. 이 주제는 다음 섹션에서 다루겠습니다.

12.1.6.6 Validating Nested Interrupt Handlers

중첩된 인터럽트 핸들러는 dyntick_irq() 의 루프의 몸체를 다음과 같이 분리시키는 것으로 모델링 될 수 있을 겁니다:

```

1 prootype dyntick_irq()
2 {
3     byte tmp;
4     byte i = 0;
5     byte j = 0;
6     bit old_gp_idle;
7     bit outermost;
8
9     do
10    :: i >= MAX_DYNTICK_LOOP_IRQ &&
11       j >= MAX_DYNTICK_LOOP_IRQ -> break;
12    :: i < MAX_DYNTICK_LOOP_IRQ ->
13        atomic {
14            outermost = (in_dyntick_irq == 0);
15            in_dyntick_irq = 1;
16        }
17        if
18        :: rcu_update_flag > 0 ->
19            tmp = rcu_update_flag;
20            rcu_update_flag = tmp + 1;
21        :: else -> skip;
22        fi;
23        if
24        :: !in_interrupt &&
25            (dynticks_progress_counter & 1) == 0 ->
26            tmp = dynticks_progress_counter;
27            dynticks_progress_counter = tmp + 1;
28            tmp = rcu_update_flag;
29            rcu_update_flag = tmp + 1;
30        :: else -> skip;
31        fi;
32        tmp = in_interrupt;
33        in_interrupt = tmp + 1;
34        atomic {
35            if
36            :: outermost ->
37                old_gp_idle = (gp_state == GP_IDLE);
38            :: else -> skip;
39            fi;
40        }
41        i++;
42        :: j < i ->
43        atomic {
44            if

```

```

45      :: j + 1 == i ->
46          assert(!old_gp_idle ||
47                  gp_state != GP_DONE);
48      :: else -> skip;
49      fi;
50  }
51  tmp = in_interrupt;
52  in_interrupt = tmp - 1;
53  if
54  :: rcu_update_flag != 0 ->
55      tmp = rcu_update_flag;
56      rcu_update_flag = tmp - 1;
57  if
58  :: rcu_update_flag == 0 ->
59      tmp = dynticks_progress_counter;
60      dynticks_progress_counter = tmp + 1;
61  :: else -> skip;
62  fi;
63  :: else -> skip;
64  fi;
65  atomic {
66      j++;
67      in_dyntick_irq = (i != j);
68  }
69  od;
70  dyntick_irq_done = 1;
71 }

```

이는 dynticks_irq() 프로세스와 유사합니다. 여기선 line 5 에서 두번째 카운터 변수 j 를 추가해서 i 는 인터럽트 핸들러들로의 진입을 셈하고 j 는 인터럽트 핸들러로부터 빠져나가는 횟수를 세게 합니다. Line 7에서의 outermost 변수는 안전성 검사를 위해 언제 gp_state 변수가 샘플링 되어야 하는지를 결정합니다. Line 10 과 11 에서의 루프 종료 체크는 명시된 수의 인터럽트 핸들러들이 진입된 만큼 빠져나와지기도 했음을 요청하기 위해 업데이트 되었고, i 의 값 증가는 인터럽트 진입 모델의 마지막인 line 41 로 옮겨졌습니다. Line 13-16 은 이게 중첩된 인터럽트들의 집합의 가능 바깥인지 여부를 알리기 위해 outermost 변수를 설정하고 dyntick_noz() 프로세스에 의해 사용되는 in_dyntick_irq 변수를 설정합니다. Line 34-40 에서는 gp_state 변수의 상태를 읽어오는데, 가장 바깥의 인터럽트 핸들러 내일 때에만 그렇습니다.

Line 42 는 인터럽트 종료 모델링을 위한 do 루프 조건절을 갖습니다: 우리가 진입한 것에 비해 적은 수의 인터럽트들만이 종료된 동안은, 다른 인터럽트를 빠져나가는게 합법적입니다. Line 43-50 은 안전성 기준을 체크합니다만, 가장 바깥의 인터럽트 단계에서 빠져나갈 때에만 그렇습니다. 마지막으로, line 65-68 은 인터럽트 종료 카운트 j 의 값을 증가시키고, 이게 가장 바깥의 인터럽트 단계라면, in_dyntick_irq 의 값을 지웁니다.

이 모델 (dyntickRCU-irq-ssl.spin)은 약 50만개가 조금 넘는 상태들에 대한 정확성 검사를 만들어내며, 모두 에러 없이 통과합니다. 하지만, 이 버전의 모델은 NMI 를 처리하지 않는데, 이에 대해선 다음 섹션에서 다루겠습니다.

12.1.6.7 Validating NMI Handlers

NMI 는 중첩되지 않는다는 점을 생각하면서 우리는 NMI 를 위해 인터럽트에 했던 것과 동일한 일반적 방법을 사용합니다. 이는 다음과 같은 dyntick_nmi() 프로세스를 만들어 내게 됩니다:

```

1 proctype dyntick_nmi()
2 {
3     byte tmp;
4     byte i = 0;
5     bit old_gp_idle;
6
7     do
8     :: i >= MAX_DYNTICK_LOOP_NMI -> break;
9     :: i < MAX_DYNTICK_LOOP_NMI ->
10    in_dyntick_nmi = 1;
11    if
12    :: rcu_update_flag > 0 ->
13        tmp = rcu_update_flag;
14        rcu_update_flag = tmp + 1;
15    :: else -> skip;
16    fi;
17    if
18    :: !in_interrupt &&
19        (dynticks_progress_counter & 1) == 0 ->
20        tmp = dynticks_progress_counter;
21        dynticks_progress_counter = tmp + 1;
22        tmp = rcu_update_flag;
23        rcu_update_flag = tmp + 1;
24    :: else -> skip;
25    fi;
26    tmp = in_interrupt;
27    in_interrupt = tmp + 1;
28    old_gp_idle = (gp_state == GP_IDLE);
29    assert(!old_gp_idle || gp_state != GP_DONE);
30    tmp = in_interrupt;
31    in_interrupt = tmp - 1;
32    if
33    :: rcu_update_flag != 0 ->
34        tmp = rcu_update_flag;
35        rcu_update_flag = tmp - 1;
36    if
37    :: rcu_update_flag == 0 ->
38        tmp = dynticks_progress_counter;
39        dynticks_progress_counter = tmp + 1;
40    :: else -> skip;
41    fi;
42    :: else -> skip;
43    fi;
44    atomic {
45        i++;
46        in_dyntick_nmi = 0;
47    }
48    od;
49    dyntick_nmi_done = 1;
50 }

```

물론, 우리가 NMI 를 갖는다는 사실은 다른 컴포넌트들에도 조정을 필요로 합니다. 예를 들어, EXECUTE_MAINLINE() 매크로는 이제 다음과 같이 dyntick_nmi_done 변수의 체크를 통해 NMI 핸들러 (in_dyntick_nmi) 는 물론 인터럽트 핸들러 (in_dyntick_irq) 에도 주의를 기울여야 합니다:

```

1 #define EXECUTE_MAINLINE(label, stmt) \
2 label: skip; \
3     atomic { \
4         if \
5             :: in_dyntick_irq || \
6                 in_dyntick_nmi -> goto label; \
7             :: else -> stmt; \
8             fi; \
9         } \

```

우리는 또한, dyntick_irq() 가 dyntick_nmi() 를 배척하도록 하기 위해 in_dyntick_nmi 를 체크하는 EXECUTE_IRQ() 매크로를 만들어야 합니다:

```

1 #define EXECUTE_IRQ(label, stmt) \
2 label: skip; \
3     atomic { \
4         if \
5             :: in_dyntick_nmi -> goto label; \
6             :: else -> stmt; \
7             fi; \
8         } \

```

더 나아가서 dyntick_irq() 를 다음과 같이 EXECUTE_IRQ() 로 변환시켜야 합니다:

```

1 proctype dyntick_irq()
2 {
3     byte tmp;
4     byte i = 0;
5     byte j = 0;
6     bit old_gp_idle;
7     bit outermost;
8
9     do
10    :: i >= MAX_DYNTICK_LOOP_IRQ &&
11        j >= MAX_DYNTICK_LOOP_IRQ -> break;
12    :: i < MAX_DYNTICK_LOOP_IRQ ->
13        atomic {
14            outermost = (in_dyntick_irq == 0);
15            in_dyntick_irq = 1;
16        }
17    stmt1: skip;
18    atomic {
19        if
20            :: in_dyntick_nmi -> goto stmt1;
21            :: !in_dyntick_nmi && rcu_update_flag ->
22                goto stmt1_then;
23            :: else -> goto stmt1_else;
24        fi;
25    }
26    stmt1_then: skip;
27    EXECUTE_IRQ(stmt1_1, tmp = rcu_update_flag)
28    EXECUTE_IRQ(stmt1_2, rcu_update_flag = tmp + 1)
29    stmt1_else: skip;
30    stmt2: skip; atomic {
31        if
32            :: in_dyntick_nmi -> goto stmt2;
33            :: !in_dyntick_nmi &&
34                !in_interrupt &&
35                (dynticks_progress_counter & 1) == 0 ->
36                    goto stmt2_then;
37                :: else -> goto stmt2_else;
38            fi;
39        }
40    stmt2_then: skip;
41    EXECUTE_IRQ(stmt2_1, tmp = dynticks_progress_counter)
42    EXECUTE_IRQ(stmt2_2,
43        dynticks_progress_counter = tmp + 1)
44    EXECUTE_IRQ(stmt2_3, tmp = rcu_update_flag)
45    EXECUTE_IRQ(stmt2_4, rcu_update_flag = tmp + 1)
46    stmt2_else: skip;
47    EXECUTE_IRQ(stmt3, tmp = in_interrupt)
48    EXECUTE_IRQ(stmt4, in_interrupt = tmp + 1)
49    stmt5: skip;

```

```

50     atomic {
51         if
52             :: in_dyntick_nmi -> goto stmt4;
53             :: !in_dyntick_nmi && outermost ->
54                 old_gp_idle = (gp_state == GP_IDLE);
55             :: else -> skip;
56             fi;
57     }
58     i++;
59     :: j < i ->
60 stmt6: skip;
61     atomic {
62         if
63             :: in_dyntick_nmi -> goto stmt6;
64             :: !in_dyntick_nmi && j + 1 == i ->
65                 assert(!old_gp_idle ||
66                     gp_state != GP_DONE);
67             :: else -> skip;
68             fi;
69     }
70     EXECUTE_IRQ(stmt7, tmp = in_interrupt);
71     EXECUTE_IRQ(stmt8, in_interrupt = tmp - 1);
72
73 stmt9: skip;
74     atomic {
75         if
76             :: in_dyntick_nmi -> goto stmt9;
77             :: !in_dyntick_nmi && rcu_update_flag != 0 ->
78                 goto stmt9_then;
79             :: else -> goto stmt9_else;
80             fi;
81     }
82 stmt9_then: skip;
83     EXECUTE_IRQ(stmt9_1, tmp = rcu_update_flag)
84     EXECUTE_IRQ(stmt9_2, rcu_update_flag = tmp - 1)
85 stmt9_3: skip;
86     atomic {
87         if
88             :: in_dyntick_nmi -> goto stmt9_3;
89             :: !in_dyntick_nmi && rcu_update_flag == 0 ->
90                 goto stmt9_3_then;
91             :: else -> goto stmt9_3_else;
92             fi;
93     }
94 stmt9_3_then: skip;
95     EXECUTE_IRQ(stmt9_3_1,
96                 tmp = dynticks_progress_counter)
97     EXECUTE_IRQ(stmt9_3_2,
98                 dynticks_progress_counter = tmp + 1)
99 stmt9_3_else:
100 stmt9_else: skip;
101     atomic {
102         j++;
103         in_dyntick_irq = (i != j);
104     }
105 od;
106 dyntick_irq_done = 1;
107 }

6     gp_state = GP_IDLE;
7     atomic {
8         printf("MDLN = %d\n", MAX_DYNTICK_LOOP_NOHZ);
9         printf("MDLI = %d\n", MAX_DYNTICK_LOOP_IRQ);
10        printf("MDLN = %d\n", MAX_DYNTICK_LOOP_NMI);
11        shouldexit = 0;
12        snap = dynticks_progress_counter;
13        gp_state = GP_WAITING;
14    }
15 }
16 do
17 :: 1 ->
18     atomic {
19         assert(!shouldexit);
20         shouldexit = dyntick_nohz_done &&
21             dyntick_irq_done &&
22             dyntick_nmi_done;
23         curr = dynticks_progress_counter;
24         if
25             :: (curr - snap) >= 2 || (curr & 1) == 0 ->
26                 break;
27             :: else -> skip;
28             fi;
29     }
30 od;
31 gp_state = GP_DONE;
32 gp_state = GP_IDLE;
33 atomic {
34     shouldexit = 0;
35     snap = dynticks_progress_counter;
36     gp_state = GP_WAITING;
37 }
38 do
39 :: 1 ->
40     atomic {
41         assert(!shouldexit);
42         shouldexit = dyntick_nohz_done &&
43             dyntick_irq_done &&
44             dyntick_nmi_done;
45         curr = dynticks_progress_counter;
46         if
47             :: (curr != snap) || ((curr & 1) == 0) ->
48                 break;
49             :: else -> skip;
50             fi;
51     }
52 od;
53 gp_state = GP_DONE;
54 }

```

우리는 line 11에 MAX_DYNTICK_LOOP_NMI 패러미터를 위한 새로운 printf()를 추가했고 dyntick_nmi_done을 line 22와 44의 shouldexit 할당에 추가했습니다.

이 모델(dyntickRCU-irq-nmi-ssl.spin)은 수억 개의 상태들과 함께 동작하는 정확한 검증을 만들어내며, 에러 없이 통과합니다.

Quick Quiz 12.20: Paul은 항상 그의 코드를 이렇게 고통스럽도록 점진적인 방법으로 작성하나요? ■

12.1.6.8 Lessons (Re)Learned

여기서는 몇가지 (다시) 배운 교훈들을 제공합니다:

1. Promela 와 spin 은 인터럽트/NMI-핸들러 와의 상호작용들을 검증할 수 있습니다.

```

1 proctype grace_period()
2 {
3     byte curr;
4     byte snap;
5     bit shouldexit;

```

Listing 12.16: Memory-Barrier Fix Patch

```

static inline void rcu_enter_nohz(void)
{
+    mb();
-    __get_cpu_var(dynticks_progress_counter)++;
-    mb();
}
static inline void rcu_exit_nohz(void)
{
-    mb();
+    __get_cpu_var(dynticks_progress_counter)++;
+    mb();
}

```

Listing 12.17: Variable-Name-Typo Fix Patch

```

-    if ((curr - snap) > 2 || (snap & 0x1) == 0)
+    if ((curr - snap) > 2 || (curr & 0x1) == 0)

```

2. 코드를 문서화 하는 것은 버그를 찾는데 도움을 줄 수 있습니다. 이 경우, 문서화는 Listing 12.16의 패치에 보여진 것처럼 `rcu_enter_nohz()` 와 `rcu_exit_nohz()` 에 있던 잘못 배치된 메모리 배리어들을 찾아냈습니다.
3. 코드를 빨리, 자주, 그리고 없어지기 전까지 검증 하십시오. 이런 노력은 Listing 12.17의 패치에서 보여진 것과 같이, `rcu_try_flip_waitack_needed()` 안의 테스트하거나 디버깅 하기에 상당히 어려울 수 있는 버그를 찾아냈습니다.
4. 항상 검증 코드를 검증하십시오. 이를 위한 일반적인 방법은 고의적인 버그를 집어넣고 검증 코드가 이를 잡아내는지 확인하는 것입니다. 물론, 그 검증 코드가 그 버그를 잡아내는데에 실패한다면, 그 버그 자체에 대해서도 검증을 할 필요가 있을 것이고, 그렇게 무한한 반복을 해야 할 수도 있습니다. 하지만, 당신 자신이 그런 무한한 반복에 빠져 있는 걸 깨닫게 된다면, 숙면을 취하는 게 효과적인 디버깅 테크닉이 될 수 있습니다. 그렇게 되면 분명한 검증을 검증하는 테크닉은 고의적으로 검증되는 코드에 버그를 집어넣는 것이라 걸 알게 될겁니다. 만약 검증 코드가 그것들을 찾는데 실패한다면, 그 검증은 분명히 버그로 가득차 있는 것입니다.
5. 어토믹 인스트럭션의 사용이 검증을 단순화 시킬 수 있습니다. 안타깝게도, `cmpxchg` 어토믹 명령어의 사용은 중요한 IRQ 빠른 수행 경로를 느리게 수행되도록 만들어서 이 경우에 적절치 못할 수도 있습니다.
6. 복잡한 정식 검증의 필요는 당신의 설계를 다시 한번 생각해 봄이 필요성을 의미합니다.

이 마지막 핵심에 이르러서, 다음 섹션에서 보여지게 될, dynticks 문제에 대한 훨씬 간단한 해결책이 있음이

Listing 12.18: Variables for Simple Dynticks Interface

```

1 struct rcu_dynticks {
2     int dynticks_nesting;
3     int dynticks;
4     int dynticks_nmi;
5 };
6
7 struct rcu_data {
8     ...
9     int dynticks_snap;
10    int dynticks_nmi_snap;
11 ...
12 };

```

드러났습니다.

12.1.6.9 Simplicity Avoids Formal Verification

Preemption 가능한 RCU의 dynticks 인터페이스의 복잡도는 주로 IRQ도 NMI도 같은 코드 수행 경로와 같은 상태 변수들을 사용한다는 사실에서 기인합니다. 이는 Manfred Spraul [Spr08b]에 의해 간접적으로 제안된대로 계층적 RCU [McK08a]의 경우처럼 별도의 코드 수행 경로와 변수를 제공하는 방법으로 결론지어집니다.

12.1.6.10 State Variables for Simplified Dynticks Interface

Listing 12.18은 새로운 per-CPU 상태 변수들을 보입니다. 이 변수들은 복수의 개별적인 RCU 구현들 (ex: `rcu` 와 `rcu_bh`)이 편하고 효과적으로 dynticks 상태를 공유할 수 있도록 하기 위해 구조체로 그룹지어졌습니다. 이어서 언급할 것들은 개별적인 per-CPU 변수들로 생각될 수도 있습니다.

`dynticks_nesting`, `dynticks`, 그리고 `dynticks_snap` 변수들은 IRQ 코드 수행 경로들을 위한 것이고, `dynticks_nmi` 와 `dynticks_nmi_snap` 변수는 NMI 코드 수행 경로를 위한 것입니다만, NMI 코드 수행 경로는 `dynticks_nesting` 변수 역시 레퍼런스할 (하지만 수정하지는 않을) 겁니다. 이 변수들은 다음과 같이 사용됩니다:

dynticks_nesting

이 변수는 연관된 CPU 가 RCU read-side 크리티컬 섹션들을 위해 모니터 되어야 하는 이유들의 수를 카운트 합니다. 만약 CPU 가 dynticks-idle 모드에 있다면, 이 변수는 IRQ 중첩 단계를 카운트하게 되고, 그렇지 않다면 IRQ 중첩 단계보다 1 큰 값을 갖게 됩니다.

dynticks

이 카운터의 값은 연관된 CPU 가 dynticks-idle 모드에 있고 현재 해당 CPU에서 수행중인 IRQ 핸들러가 없다면 짹수를, 그렇지 않다면 훌수의 값을

갖게 됩니다. 달리 말하자면, 이 카운터의 값이 훌수라면, 연관된 CPU는 RCU read-side 크리티컬 섹션 안에 있을 수 있습니다.

dynticks_nmi

이 카운터의 값은 연관된 CPU가 NMI 핸들러 안에 있다면 훌수가 되는데, 해당 NMI가 이 CPU가 현재 수행중인 IRQ 핸들러 없이 dyntick-idle 모드에 빠져 있을 때에만 그렇습니다. 그렇지 않다면, 해당 카운터의 값은 짹수가 됩니다.

dynticks_snap

이것은 dynticks 카운터의 스냅샷이 됩니다만, 현재 RCU grace period가 너무 긴 기간 동안 연장되었을 때에만 그렇습니다.

dynticks_nmi_snap

이것은 dynticks_nmi 카운터의 스냅샷이 됩니다만, 역시 현재 RCU grace period가 너무 오랜 기간 동안 연장되었을 때에만 그렇습니다.

주어진 기간 동안 dynticks 와 dynticks_nmi 가 모두 짹수를 가지고 있었다면, 연관된 CPU는 해당 기간 동안 quiescent 상태를 지나온 것입니다.

Quick Quiz 12.21: 하지만, 만약 NMI 핸들러가 IRQ 핸들러가 완료되기 전에 동작하기 시작하면, 그리고 그 NMI 핸들러가 두번째 IRQ 핸들러가 시작될 때까지 돌아가면 어떤 일이 발생할까요? ■

12.1.6.11 Entering and Leaving Dynticks-Idle Mode

Listing 12.19는 “nohz” 모드라고도 알려진 dynticks-idle 모드를 들어가고 빠져나오는 `rcu_enter_nohz()` 와 `rcu_exit_nohz()` 를 보이고 있습니다. 이 두 함수는 프로세스 컨텍스트에서 호출됩니다.

Line 6은 (RCU read-side 크리티컬 섹션들로부터의 액세스들을 포함할 수 있는) 앞의 모든 메모리 액세스들이 dynticks-idle 모드로의 진입을 표시하는 CPU들보다 앞서서 다른 CPU들에 보여질 것을 보장합니다. Line 7과 12는 IRQ를 각각 비활성화시키고 재활성화 시킵니다. Line 8은 현재 CPU의 `rcu_dynticks` 구조체로의 포인터를 얻어오고, line 9는 현재 CPU의 dynticks 카운터의 값을 증가시키는데, 우린 프로세스 컨텍스트에서 dynticks-idle 모드에 진입하고 있으므로 짹수가 되어야 할 겁니다. 마지막으로, line 10은 이제 0이 되어야 하는 `dynticks_nesting`의 값을 감소시킵니다.

`rcu_exit_nohz()` 함수는 이와 상당히 유사합니다만, `dynticks_nesting` 을 감소시키는게 아니라 증가시키며 dynticks의 반대 특성을 체크합니다.

Listing 12.19: Entering and Exiting Dynticks-Idle Mode

```

1 void rcu_enter_nohz(void)
2 {
3     unsigned long flags;
4     struct rcu_dynticks *rdtp;
5
6     smp_mb();
7     local_irq_save(flags);
8     rdtp = &__get_cpu_var(rcu_dynticks);
9     rdtp->dynticks++;
10    rdtp->dynticks_nesting--;
11    WARN_ON!(rdtp->dynticks & 0x1);
12    local_irq_restore(flags);
13 }
14
15 void rcu_exit_nohz(void)
16 {
17     unsigned long flags;
18     struct rcu_dynticks *rdtp;
19
20     local_irq_save(flags);
21     rdtp = &__get_cpu_var(rcu_dynticks);
22     rdtp->dynticks++;
23     rdtp->dynticks_nesting++;
24     WARN_ON!(rdtp->dynticks & 0x1);
25     local_irq_restore(flags);
26     smp_mb();
27 }
```

12.1.6.12 NMIs From Dynticks-Idle Mode

Listing 12.20는 dynticks-idle 모드로부터 NMI에 들어가는 것과 빠져나오는 것을 RCU에 알리는 `rcu_nmi_enter()` 와 `rcu_nmi_exit()` 함수를 보입니다. 하지만, 해당 NMI가 IRQ 핸들러 수행 중에 들어오게 되면, RCU는 이 CPU의 RCU read-side 크리티컬 섹션들을 탐색하고 있을 것이므로, `rcu_nmi_enter()` 의 line 6과 7과 `rcu_nmi_exit()` 의 line 18과 19는 dynticks가 훌수라면 아무것도 하지 않고 리턴합니다. 그렇지 않다면, 두 함수는 `dynticks_nmi`의 값을 증가시켜서 `rcu_nmi_enter()` 는 그 값을 훌수로, `rcu_nmi_exit()` 는 그 값을 짹수로 만들어둡니다. 두 함수 모두 line 10과 20에서 값 증가와 RCU read-side 크리티컬 섹션이 있을 수 있는 곳 사이에 메모리 배리어를 실행합니다.

12.1.6.13 Interrupts From Dynticks-Idle Mode

Listing 12.21은 IRQ 컨텍스트로의 진입과 IRQ 컨텍스트로부터의 빠져나음을 RCU에 알리는 `rcu_irq_enter()` 와 `rcu_irq_exit()` 함수들을 보입니다. `rcu_irq_enter()` 의 Line 6은 `dynticks_nesting`의 값을 증가시키고, 이 값이 0이 아니었다면, line 7에서 조용히 리턴합니다. 그렇지 않다면, line 8에서 dynticks의 값을 증가시켜서 그 값을 훌수로 만들어서 이 CPU가 이제 RCU read-side 크리티컬 섹션을 수행할 수 있다는 사실과 일관적이게 만듭니다. 따라서 line 10은 dynticks의 값 증가가 뒤따르는 irq 핸들러가 실행할 수도 있는 RCU read-side 크리티컬 섹션들보다 먼저 보

Listing 12.20: NMIs From Dynticks-Idle Mode

```

1 void rcu_nmi_enter(void)
2 {
3     struct rcu_dynticks *rdtp;
4
5     rdtp = &__get_cpu_var(rcu_dynticks);
6     if (rdtp->dynticks & 0x1)
7         return;
8     rdtp->dynticks_nmi++;
9     WARN_ON(!(rdtp->dynticks_nmi & 0x1));
10    smp_mb();
11 }
12
13 void rcu_nmi_exit(void)
14 {
15     struct rcu_dynticks *rdtp;
16
17     rdtp = &__get_cpu_var(rcu_dynticks);
18     if (rdtp->dynticks & 0x1)
19         return;
20     smp_mb();
21     rdtp->dynticks_nmi++;
22     WARN_ON(rdp->dynticks_nmi & 0x1);
23 }

```

Listing 12.21: Interrupts From Dynticks-Idle Mode

```

1 void rcu_irq_enter(void)
2 {
3     struct rcu_dynticks *rdtp;
4
5     rdtp = &__get_cpu_var(rcu_dynticks);
6     if (rdtp->dynticks_nesting++)
7         return;
8     rdtp->dynticks++;
9     WARN_ON!(rdtp->dynticks & 0x1));
10    smp_mb();
11 }
12
13 void rcu_irq_exit(void)
14 {
15     struct rcu_dynticks *rdtp;
16
17     rdtp = &__get_cpu_var(rcu_dynticks);
18     if (--rdtp->dynticks_nesting)
19         return;
20     smp_mb();
21     rdtp->dynticks++;
22     WARN_ON(rdp->dynticks & 0x1);
23     if (__get_cpu_var(rcu_data).nxtlist ||
24         __get_cpu_var(rcu_bh_data).nxtlist)
25         set_need_resched();
26 }

```

여지도록 보장하기 위해 메모리 배리어를 실행합니다.

`rcu_irq_exit()`의 line 18에서는 `dynticks_nesting`의 값을 감소시키고, 그 결과가 0이 아니라면, line 19에서 조용히 리턴합니다. 그렇지 않다면, line 21에서의 `dynticks`의 값 증가가 앞의 IRQ 핸들러가 실행했을 수도 있는 모든 RCU read-side 크리티컬 섹션들 뒤에 보여질 것을 보장하기 위해 메모리 배리어를 수행합니다. Line 22는 `dynticks`가 짹수임을 검증해서 어떤 RCU read-side 크리티컬 섹션들도 dynticks-idle 모드에서는 나타날 수 없다는 사실과 일관적이게 합니다. Line 23-25는 앞의 IRQ 핸들러들이 RCU 콜백들을

Listing 12.22: Saving Dyntick Progress Counters

```

1 static int
2 dyntick_save_progress_counter(struct rcu_data *rdp)
3 {
4     int ret;
5     int snap;
6     int snap_nmi;
7
8     snap = rdp->dynticks->dynticks;
9     snap_nmi = rdp->dynticks->dynticks_nmi;
10    smp_mb();
11    rdp->dynticks_snap = snap;
12    rdp->dynticks_nmi_snap = snap_nmi;
13    ret = ((snap & 0x1) == 0) &&
14        ((snap_nmi & 0x1) == 0);
15    if (ret)
16        rdp->dynticks_qs++;
17    return ret;
18 }

```

집어넣었는지 확인하고, 만약 그렇다면 재스케줄 API를 통해 이 CPU가 dynticks-idle 모드를 빠져나오도록 합니다.

12.1.6.14 Checking For Dynticks Quiescent States

Listing 12.22는 명시된 CPU의 `dynticks`와 `dynticks_nmi` 카운터들의 스냅샷을 가져오는 `dyntick_save_progress_counter()`를 보입니다. Line 8과 9는 이 두 개의 변수들의 스냅샷을 떠오르고, line 10은 Listing 12.19, 12.20, 그리고 12.21의 함수들의 메모리 배리어들과 짹을 맞추기 위해 메모리 배리어를 실행합니다. Line 11과 12는 나중의 `rcu_implicit_dynticks_qs` 호출을 위한 스냅샷을 기록해두고, line 13과 14는 dynticks-idle 모드의 이 CPU가 IRQ도 NMI도 진행중이 아니어서 (달리 말하자면, 두 스냅샷 모두 짹수를 가지고 있어서) 연장된 quiescent state 안에 있는 것인지 체크를 합니다. 만약 그렇다면, line 15와 16은 이 이벤트를 세고, 이 CPU가 quiescent state line 17에서 true를 리턴합니다.

Listing 12.23는 CPU가 `dynticks_save_progress_counter()` 호출에 이어서 dyntick-idle 모드에 들어갔는지 여부를 체크하는 `rcu_implicit_dynticks_qs()` 함수를 보입니다. Line 9와 11은 연관된 CPU의 `dynticks`와 `dynticks_nmi` 변수들의 새로운 스냅샷을 가져오고, line 10과 12는 기존에 `dynticks_save_progress_counter()`에 의해 저장된 스냅샷을 가져옵니다. Line 13은 이어서 Listing 12.19, 12.20, 그리고 12.21의 함수들의 메모리 배리어들과 짹을 맞추기 위해 메모리 배리어를 실행합니다. Line 14-16은 이어서 해당 CPU가 지금 (`curr`와 `curr_nmi`가 짹수를 가져서) quiescent state에 있거나 (`dynticks`와 `dynticks_nmi`의 값들이 이미 변해서) 마지막의 `dynticks_save_progress_counter()` 호출 후에 quiescent state를 지나왔는지를 체크합니다. 만약 이 체크가 이 CPU는 dyntick-idle quiescent state

Listing 12.23: Checking Dyntick Progress Counters

```

1 static int
2 rcu_implicit_dynticks_qs(struct rcu_data *rdp)
3 {
4     long curr;
5     long curr_nmi;
6     long snap;
7     long snap_nmi;
8
9     curr = rdp->dynticks->dynticks;
10    snap = rdp->dynticks_snap;
11    curr_nmi = rdp->dynticks->dynticks_nmi;
12    snap_nmi = rdp->dynticks_nmi_snap;
13    smp_mb();
14    if ((curr != snap || (curr & 0x1) == 0) &&
15        (curr_nmi != snap_nmi ||
16         (curr_nmi & 0x1) == 0)) {
17        rdp->dynticks_fqs++;
18        return 1;
19    }
20    return rcu_implicit_offline_qs(rdp);
21 }

```

를 지나왔다고 확인한다면, line 17 은 그 사실의 횟수를 세고 line 18 에서 이에 대한 사실을 알리는 값을 리턴 합니다. 어떻게 되었든, line 20 에서는 오프라인인 CPU 를 기다리고 있는 RCU 를 초래할 수 있는 경주 상황을 체크합니다.

Quick Quiz 12.22: 이건 여전히 상당히 복잡하네요. 왜 그냥 dyntick-idle 모드에 있는 각 CPU 들에 대해 bit 의 값이 설정되어 있는 cpumask_t 를 갖고 IRQ 나 NMI 핸들러에 들어갈 때에는 그 비트의 값을 지우고, 빠져나올 때에는 그 값을 설정하는 식으로 하지 않는거죠? ■

12.1.6.15 Discussion

약간의 시점 변경이 RCU 를 위한 dynticks 인터페이스의 상당한 단순화를 가져왔습니다. 이 단순화를 이끈 핵심 변경은 IRQ 와 NMI 컨텍스트 사이에 공유되는 것들의 최소화였습니다. 이 단순화된 인터페이스에서의 유일한 공유는 NMI 컨텍스트에서 IRQ 변수들로의 레퍼런스들 (dynticks 변수) 뿐입니다. NMI 함수들은 이 변수를 절대 업데이트 하지 않아서 그 값은 NMI 핸들러의 수명 동안 상수를 유지하므로 이런 종류의 공유는 친절한 편입니다. 이런 공유의 한계는 Section 12.1.5 에 그려진, NMI 가 IRQ 함수들의 수행 도중의 어느 시점에든 공유된 상태를 바꿀 수 있는 상황과는 반대로, 다행히도 개별적인 함수들이 한번에 하나씩 이해되는 걸 가능하게 합니다.

검증은 좋은 일이 될 수 있지만, 단순화는 그보다도 좋습니다.

12.2 Special-Purpose State-Space Search

Jack of all trades, master of none.

Unknown

Promela 와 spin 이 어떤 (작은) 알고리즘이든 굉장히 많은 부분을 검증할 수 있게 해주긴 하지만, 커다란 범용성이 어떨때에는 문제가 될수도 있습니다. 예를 들어, Promela 는 메모리 모델이나 재배치 개념을 이해하지 못합니다. 따라서 이 섹션은 제품화된 시스템들에서 사용되는 메모리 모델을 이해하고 있어서 완화된 순서 규칙의 코드 검증을 단순화 시켜주는 상태 공간 탐색 도구들을 소개합니다.

예를 들어, Section 12.1.4 는 완화된 메모리 순서 규칙을 처리하기 위해 Promela 를 어떻게 납득시켜야 하는지를 보았습니다. 이런 방법도 잘 동작할수 있지만, 이는 개발자가 해당 시스템의 메모리 모델을 이해하고 있을 것을 필요로 합니다. 안타깝게도, (존재한다 쳐도) 일부 개발자들만이 현대 CPU 들의 복잡한 메모리 모델을 완전하게 이해하고 있습니다.

따라서, 또 다른 방법은 Cambridge 대학의 Peter Sewell 과 Susmit Sarkar, INRIA 의 Luc Maranget, Francesco Zappa Nardelli, 그리고 Pankaj Pawan, 그리고 Oxford 대학의 Jade Alglave 가 IBM 의 Derek Williams 와 협력해서 만든 PPCMEM [AMP¹¹] 과 같은, 이미 이 메모리 순서 규칙을 이해하고 있는 도구들을 활용하는 것입니다. 이 그룹은 Power, ARM, x86 뿐만 아니라 C/C++11 표준 [Bec11] 의 메모리 모델을 형식화 시키고 Power 와 ARM 형식에 기초하여 PPCMEM 도구를 만들었습니다.

Quick Quiz 12.23: 하지만 x86 은 강한 메모리 순서 규칙을 가지고 있어요! 왜 이 메모리 모델을 정형화 시켜야 하는거죠? ■

PPCMEM 도구는 입력으로 리트머스 테스트를 받습니다. 예제 리트머스 테스트가 Section 12.2.1 에 있습니다. Section 12.2.2 는 이 리트머스 테스트를 동일한 C-언어 프로그램으로 관계지어 보고, Section 12.2.3 은 PPCMEM 을 이 리트머스 테스트에 어떻게 적용하는지를 설명하며, Section 12.2.4 에서는 이로부터의 의미를 이야기해 봅니다.

12.2.1 Anatomy of a Litmus Test

PPCMEM 을 위한 예제 PowerPC 리트머스 테스트가 Listing 12.24 에 보여져 있습니다. ARM 인터페이스도 정확히 같은 방식으로 동작합니다만, 그러기 위해선 첫줄의 “PPC” 가 “ARM” 으로 바뀌어야 하고 Power 인스트럭션(instruction) 이 ARM 인스트럭션으로 대체되어야 합니다. 뒤에서 이야기될 웹페이지의 “Change to

Listing 12.24: PPCMEM Litmus Test

```

1 PPC SB+lwsync-RMW-lwsync+isync-simple
2 ""
3 {
4 0:r2=x; 0:r3=2; 0:r4=y; 0:r10=0; 0:r11=0; 0:r12=z;
5 1:r2=y; 1:r4=x;
6 }
7 P0 | P1 ;
8 li r1,1 | li r1,1 ;
9 stw r1,0(r2) | stw r1,0(r2) ;
10 lwsync | sync ;
11 | lzw r3,0(r4) ;
12 lwarx r11,r10,r12 | ;
13 stwcx. r11,r10,r12 | ;
14 bne Fail1 | ;
15 isync | ;
16 lzw r3,0(r4) | ;
17 Fail1: | ;
18
19 exists
20 (0:r3=0 / \ 1:r3=0)

```

ARM model”을 클릭하는 것으로 ARM 인터페이스를 선택할 수 있습니다.

예제에서, line 1은 시스템의 종류 (“ARM” 또는 “PPC”)를 밝히고 모델의 이름을 갖습니다. Line 2는 테스트의 대안적 이름을 위한 공간을 제공하는데, 일반적으로는 앞의 예제에서 보인 것처럼 빈줄로 남겨두게 될 겁니다. 주석은 line 2와 3 사이에 Ocaml(또는 Pascal) 문법의 (* *)를 이용해 들어갈 수 있습니다.

Line 3-6은 모든 레지스터의 초기 값을 제공합니다; 각각 P:R=V의 형태로, P는 프로세스 식별자이고, R은 레지스터 식별자이며, V는 값입니다. 예를 들어, 프로세스 0의 레지스터 r3은 초기에 2라는 값을 담고 있습니다. 만약 값이 변수(예제의 x, y, 또는 z)라면 레지스터는 해당 변수의 주소로 초기화 됩니다. 변수의 값을 초기화시키는 것도 가능한데, 예를 들어 x=1은 x의 값을 1로 초기화 시킵니다. 초기화 되지 않은 변수들은 기본값으로 0을 갖게 되어서, 이 예제에서는 x, y, 그리고 z가 모두 초기에 0의 값을 갖습니다.

Line 7은 두 프로세스를 위한 식별자를 제공하므로, line 4의 0:r3=2는 P0:r3=2로 대신 쓰여질 수 있습니다. Line 7은 있어야만 하며, 식별자들은 Pn의 형태여야만 하며, n은 행 수로, 가장 왼쪽의 행을 0으로 세는 것부터 시작합니다. 이는 불필요하게 엄정한 것으로 보여질 수도 있겠습니다만, 실제 사용에 있어 많은 혼란을 방지해 줍니다.

Quick Quiz 12.24: Listing 12.24의 line 8은 왜 레지스터들을 초기화 시키죠? 왜 그것들을 line 4와 5에서 대신 초기화 시키지 않나요? ■

Line 8-17은 각각의 프로세스를 위한 코드들입니다. 프로세스는 P0의 line 11과 P1의 line 12-17처럼 빈줄을 가질 수도 있습니다. 라벨과 브랜치 역시 사용 가능한데, line 14의 브랜치와 line 17의 라벨로 사용이 보여져 있습니다. 그렇다면 하나, 너무 자유로운 브랜-

치 사용은 상태 공간의 크기를 폭증시킬 수 있습니다. 루프의 사용은 특히나 상태 공간의 크기를 폭증시키기 쉽습니다.

Line 19-20은 단정문을 보이는데, 이 경우에는 두 쓰레드가 모두 실행을 완료한 후에 P0의, 그리고 P1의 r3 레지스터들이 모두 0을 가지고 있을 수 있는지에 우리가 관심을 갖고 있음을 보입니다. 만약 P0와 P1이 모두 각각의 r3 레지스터에서 0을 보게 된다면 안타깝게도 실패할 수 있는 수많은 경우들이 존재할 수 있기에 이 단정문은 중요합니다.

이것만으로도 간단한 리트머스 테스트들을 만드는데 충분할 겁니다. 몇 가지 추가적인 문서화가 가능합니다만, 이런 추가적인 문서화들은 대부분 테스트를 실제 하드웨어 위에서 수행하기 위한 다른 연구용 도구를 위한 것입니다. 어쩌면 더 중요한 것은, 많은 수의 이미 존재하는 리트머스 테스트들은 온라인 도구를 통해서도 (“Select ARM Test”와 “Select POWER Test” 버튼을 통해서) 사용 가능하다는 것입니다. 이런 미리 존재하는 리트머스 테스트들 가운데 하나가 당신의 Power나 ARM 메모리 순서 규칙에 대한 질문의 답이 될 수도 있을 겁니다.

12.2.2 What Does This Litmus Test Mean?

P0의 line 8과 9는 C 언어의 x=1과 같은데, line 4에서 P0의 레지스터 r2가 x의 주소를 갖도록 정의했기 때문입니다. P0의 line 12와 13은 각각 load-linked(ARM 용어로는 “load register exclusive”이고 Power 용어로는 “load reserve”)와 store-conditional(ARM 용어로는 “store register exclusive”)입니다. 이것들이 함께 사용되면, x86에서는 lock; cmpxchq 인스트럭션으로 표현되는 compare-and-swap 시퀀스와 유사한 어도비 인스트럭션을 형성하게 됩니다. 더 높은 차원의 추상화 단계로 이야기 하면, line 10-15의 시퀀스는 리눅스 커널의 atomic_add_return(&z, 0)와 같습니다. 마지막으로, line 16은 C 언어의 r3=y와 같습니다.

P1의 line 8과 9는 C 언어의 y=1과 같으며, line 10은 리눅스 커널의 smp_mb()와 동일한 메모리 배리어이며, line 11은 C 언어의 r3=x와 같습니다.

Quick Quiz 12.25: Listing 12.24의 line 17의 Fail: 라벨에서는 무슨 일이 벌어지게 되는거죠? ■

이 모든 것들을 한자리에 모아서 만든, 전체 리트머스 테스트와 동일한 C-언어 코드가 Listing 12.25에 보여져 있습니다. 핵심은, atomic_add_return()이 (리눅스 커널의 요구사항이 그렇듯) 전체 메모리 배리어처럼 동작한다면, 실행이 완료된 후에 P0()의, 그리고 P1()의 r3가 모두 0일 수는 없다는 것입니다.

다음 섹션은 이 리트머스 테스트를 어떻게 수행할 수 있는지 설명합니다.

Listing 12.25: Meaning of PPCMEM Litmus Test

```

1 void P0(void)
2 {
3     int r3;
4
5     x = 1; /* Lines 8 and 9 */
6     atomic_add_return(&x, 0); /* Lines 10-15 */
7     r3 = y; /* Line 16 */
8 }
9
10 void P1(void)
11 {
12     int r3;
13
14     y = 1; /* Lines 8-9 */
15     smp_mb(); /* Line 10 */
16     r3 = x; /* Line 11 */
17 }

```

Listing 12.26: PPCMEM Detects an Error

```

./ppcmem -model lwsync_read_block \
          -model coherence_points filename.litmus
...
States 6
0:r3=0; 1:r3=0;
0:r3=0; 1:r3=1;
0:r3=1; 1:r3=0;
0:r3=1; 1:r3=1;
0:r3=2; 1:r3=0;
0:r3=2; 1:r3=1;
0k
Condition exists (0:r3=0 / 1:r3=0)
Hash=e2240ce2072a2610c034cc4fc964e77
Observation SB+lwsync-RMW-lwsync+isync Sometimes 1

```

12.2.3 Running a Litmus Test

리트머스 테스트들은 <http://www.cl.cam.ac.uk/~pes20/ppcmem/>를 통해서 대화형으로 수행되어 메모리 모델에 대한 이해를 도울 수 있습니다. 하지만, 이 방법에서는 사용자가 직접 전체 상태 공간 탐색을 해야 합니다. 모든 가능한 이벤트의 시퀀스를 체크했다고 자신하긴 어려우므로, 이런 경우를 위한 별개의 도구가 제공됩니다 [McK11c].

Listing 12.24에 보인 리트머스 테스트는 read-modify-write 인스트럭션들을 포함하고 있기 때문에, 커맨드 라인에 `-model` 인자를 추가해야만 합니다. 해당 리트머스 테스트가 `filename.litmus`에 저장되어 있다면, 이는 Listing 12.26에 보여진 것과 같은 결과를 보일텐데, 여기서 ...은 많은 양의 빌드 진행상의 출력을 대체하고 있습니다. 마지막 줄의 “Sometimes”는 이를 증명합니다: 해당 단정문의 조건은 항상 그런건 아니지만 일부 수행에서는 일어날 수 있습니다.

이 리눅스 커널 버그를 고치는 방법은 P0의 `isync`를 `sync`로 교체하는 것으로, 이렇게 수정된 테스트는 Listing 12.27에 보인 것과 같은 결과를 나오게 합니다. 볼 수 있듯, `0:r3=0; 1:r3=0;`는 상태들의 리스트에 나타나 있지 않고, 마지막 줄은 “Never”라고 이야기 합니다. 따라서, 해당 모델은 문제가 되는 실행 시퀀스가

Listing 12.27: PPCMEM on Repaired Litmus Test

```

./ppcmem -model lwsync_read_block \
          -model coherence_points filename.litmus
...
States 5
0:r3=0; 1:r3=1;
0:r3=1; 1:r3=0;
0:r3=1; 1:r3=1;
0:r3=2; 1:r3=0;
0:r3=2; 1:r3=1;
No (allowed not found)
Condition exists (0:r3=0 / 1:r3=0)
Hash=77dd723cd9981248ea4459fcdf6097d
Observation SB+lwsync-RMW-lwsync+sync Never 0 5

```

일어날 수 없음을 예측합니다.

Quick Quiz 12.26: ARM 리눅스 커널도 비슷한 버그를 가지고 있나요? ■

12.2.4 PPCMEM Discussion

이 도구들은 ARM과 Power에서 돌아가는 낮은 단계의 복잡 기능들을 사용하는 사람들에게 커다란 도움이 될 겁니다. 이 도구들은 일부 본질적인 한계점을 가지고 있습니다:

1. 이 도구들은 연구용 프로토타입이라, 어떤 것들은 지원하지 않습니다.
2. 이 도구들은 IBM이나 ARM으로부터의 CPU 아키텍쳐들에 대한 공식적 언급을 받은 바가 없습니다. 예를 들어, 두 회사 모두 언제든 이 도구들의 어떤 버전에 대해서도 버그가 있다고 이야기할 수 있습니다. 따라서 이 도구들은 실제 하드웨어에서의 중요한 스트레스 테스트의 대체제가 될수는 없습니다. 더구나, 이것들의 기반을 형성하고 있는 도구들도 모델들도 모두 활발히 개발되는 중이고 언제든 바뀔 수 있습니다. 한편, 이 모델은 적절한 하드웨어 전문가의 자문에 의해 개발되었기에, 이것은 해당 아키텍쳐들의 든든한 표현이라고 확신을 가져도 좋을 이유가 있는 셈입니다.
3. 이 도구들은 현재 인스트럭션 집합 중 한 부분만을 다루고 있습니다. 이 부분집합은 제 목적에 있어서는 충분했습니다만, 여러분의 목적은 다양할 수 있습니다. 구체적으로, 이 도구는 워드 크기 (32 bits)의 액세스들만을 다루며, 이렇게 액세스 되는 워드들은 올바르게 정렬되어 있어야만 합니다. 또한, 이 도구는 ARM 메모리 배리어 인스트럭션의 더 완화된 변종들도, 산술 인스트럭션들도 다루지 않습니다.
4. 이 도구들은 적은 수의 쓰레드에서 돌아가는, 작고 루프를 사용하지 않는 코드 조각들에서 사용될 것으로 제약되어 있습니다. 더 커다란 예제들은

Promela 와 spin 같은 비슷한 도구들과 같이 상태 공간의 폭증을 초래합니다.

5. 전체 상태 공간 탐색은 어떻게 각각의 문제되는 상태에 도달했는지를 알려주지 않습니다. 그렇다면 하나, 특정 상태가 정말로 도달할 수 있다는 사실을 깨닫게 되면, 대화형 도구를 사용해서 그 상태를 찾아나서는 것은 일반적으로 어렵지 않습니다.
6. 이 도구들은 복잡한 데이터 구조에는 그다지 좋지 않습니다만, 극단적으로 간단한 링크드 리스트를 “ $x=y$; $y=z$; $z=42$;” 와 같은 형태의 초기화 statement 들을 사용해서 생성하고 탐색하는 것은 가능 하긴 합니다.
7. 이 도구들은 memory mapped I/O 나 디바이스 레지스터들은 다루지 않습니다. 물론, 그런 것들을 처리하는 것은 그것들이 정형화 될 것을 필요로 하는데, 여기엔 존재하지 않습니다.
8. 이 도구들은 단정문을 통해 여러분이 코딩한 문제들에 대해서만 문제를 찾아줄 겁니다. 이 약점은 모든 정형적 방법들에 공통적인 것이고, 왜 테스트가 여전히 중요한지에 대한 또다른 이유입니다. 이 챕터의 시작에서 인용한 Donald Knuth 의 영원한 말처럼, “다음 코드의 버그들을 경계하세요; 전 그것이 올바르다는 걸 증명했을 뿐이지, 그걸 사용해 보진 않았습니다.”

그렇다면 하나, 이 도구들의 강점 가운데 하나는 해당 아키텍처에 의해서 허용되는, 합법적이지만 현재 하드웨어 구현이 부주의한 소프트웨어 개발자들에게 아직 가하지 않은 모든 동작들의 전체 범위를 모델링 하도록 설계되었다는 점입니다. 따라서, 이 도구들에서 테스트된 알고리즘은 실제 하드웨어에서 동작할 때에는 추가적인 안전성을 가질 수 있을 확률이 큽니다. 더 나아가서, 실제 하드웨어에서 테스트를 해보는 것은 버그를 찾을 수 있게 해줄 뿐입니다; 그런 테스트로 해당 사용이 올바른지에 대한 증명을 하는 것은 본질적으로 불가능 합니다. 이를 이해하기 위해, 연구자들이 그들의 모델의 검증을 위해 실제 하드웨어 위에서 천억개의 테스트를 일일이 수행하고 있는 것을 생각해 보세요. 어떤 경우에 있어서는, 아키텍처에 의해 허용되어 있는 행동이 1760 억 회의 테스트 수행에도 불구하고 나타나지 않은 적도 있었습니다 [AMP¹¹]. 반면에, 이 전체 상태 공간 탐색은 해당 도구가 코드 조각의 정확성을 증명할 수 있게 해줍니다.

정형적 방법들과 도구들은 테스트의 대체제가 아님을 다시 한번 이야기할 필요가 있습니다. 예를 들어 리눅스 커널과 같은 거대하고 안정적인 동시적 소프트웨어 작품을 만들어내는 것은 상당히 어려운 일입니다. 따라서 개발자들은 이 목표를 위해 모든 가능한 도구들을

Listing 12.28: IRIW Litmus Test

```

1 PPC IRIW.litmus
2 ""
3 (* Traditional IRIW. *)
4 {
5 0:r1=1; 0:r2=x;
6 1:r1=1;           1:r4=y;
7           2:r2=x; 2:r4=y;
8           3:r2=x; 3:r4=y;
9 }
10 P0      | P1      | P2      | P3      ;
11 stw r1,0(r2) | stw r1,0(r4) | lzw r3,0(r2) | lzw r3,0(r4) ;
12           |           | sync    | sync    ;
13           |           | lzw r5,0(r4) | lzw r5,0(r2) ;
14
15 exists
16 (2:r3=1  $\wedge$  2:r5=0  $\wedge$  3:r3=1  $\wedge$  3:r5=0)

```

적용할 준비가 되어 있어야 합니다. 이 챕터에서 보인 도구들은 테스트를 통해 발생시키기 (그리고 추적하기) 상당히 어려운 버그들을 찾아내는 것을 가능하게 해줍니다. 한편, 테스트는 이 챕터에서 소개된 도구들로 처리할 수 있는 것들보다 훨씬 커다란 몸집의 소프트웨어들에 적용될 수 있습니다. 항상 그렇듯이, 작업에 걸맞는 도구를 사용하세요!

물론, 여러분의 병렬 코드를 쉽게 분할될 수 있도록 설계하고 (락, 시퀀스 카운터, 어토믹 오퍼레이션, 그리고 RCU 같은) 고차원의 도구들을 사용해서 일을 더 간단하게 되도록 함으로써 이런 일을 할 필요 자체를 없애는 게 항상 최선입니다. 그리고 여러분의 일을 처리하기 위해 반드시 낮은 단계의 메모리 배리어들과 read-modify-write 인스트럭션들을 사용해야만 하는 경우라도 할지라도, 이 날카로운 도구들을 더 많이 보수적으로 사용할수록 여러분의 삶이 더 쉬워질 겁니다.

12.3 Axiomatic Approaches

Theory helps us to bear our ignorance of facts.

George Santayana

PPCMEM 도구가 Listing 12.28에 보여진, 유명한 “independent reads of independent writes” (IRIW) 리트머스 테스트를 해결할 수 있긴 합니다만, 그러기 위해선 14시간 이상의 CPU 시간과 10기가바이트 이상의 상태공간을 필요로 합니다. 그렇다면 하나, 이 상황은 이 문제를 풀기 위해선 커다란 레퍼런스 매뉴얼을 뒤져보고, 증명을 시도하고, 전문가와 토론을 하고, 마지막으로 내린 답에 대해서도 확신할 수 없었던, PPCMEM 이 나오기 전에 비하면 커다란 개선이 이뤄진 것입니다. 비록 14시간은 긴 시간처럼 보일 수 있겠지만, 이는 수주나 수개월에 비하면 너무나도 짧은 시간입니다.

하지만, 두개의 쓰레드가 두개의 별도의 변수에 값을

Listing 12.29: Expanded IRIW Litmus Test

```

1 PPC IRIW5.litmus
2 ""
3 (* Traditional IRIW, but with five stores instead of *)
4 (* just one. *)
5 {
6 0:r1=1; 0:r2=x;
7 1:r1=1; 1:r4=y;
8 2:r2=x; 2:r4=y;
9 3:r2=x; 3:r4=y;
10 }
11 P0 | P1 | P2 | P3 ;
12 stw r1,0(r2) | stw r1,0(r4) | lwz r3,0(r2) | lwz r3,0(r4) ;
13 addi r1,r1,1 | addi r1,r1,1 | sync | sync ;
14 stw r1,0(r2) | stw r1,0(r4) | lwz r5,0(r4) | lwz r5,0(r2) ;
15 addi r1,r1,1 | addi r1,r1,1 | | ;
16 stw r1,0(r2) | stw r1,0(r4) | | ;
17 addi r1,r1,1 | addi r1,r1,1 | | ;
18 stw r1,0(r2) | stw r1,0(r4) | | ;
19 addi r1,r1,1 | addi r1,r1,1 | | ;
20 stw r1,0(r2) | stw r1,0(r4) | | ;
21
22 exists
23 (2:r3=1 / 2:r5=0 / 3:r3=1 / 3:r5=0)

```

쓰고 두개의 다른 쓰레드가 이 두개의 변수로부터 반대 순서로 값을 읽어들일 뿐인 해당 리트머스 테스트의 단순성을 놓고 보면 요구되는 해당 시간은 조금 놀랍습니다. 단정문은 두개의 값을 읽어들이는 쓰레드들이 두개의 값 저장의 순서에 대해서 다른 의견을 갖는다면 발동됩니다. 이 리트머스 테스트는 긴단한데, 표준적 메모리 순서 리트머스 테스트들을 놓고 봐도 그렇습니다.

소모되는 시간과 공간의 양에 대한 한가지 이유는 PPCMEM 이 추적 기반의 전체 상태 공간 탐색을 한다는 것으로, 이는 아키텍처 단계에서 이벤트들의 모든 가능한 순서와 조합을 만들어내고 수행해 봐야 함을 의미합니다. 이 단계에서, 화려한 이벤트와 액션들의 시퀀스에 연관된 로드와 스토어는 모두 탐색되어야만 하는 매우 커다란 상태 공간을 초래하게 되고, 이는 커다란 메모리와 CPU 소모로 이어지게 됩니다.

물론, 그런 추적들 가운데 많은 것들은 다른 것들과 상당히 유사해서, 비슷한 추적들을 하나로 취급하는 것이 성능을 개선시킬 수도 있을 것임을 시사합니다. 그런 한 가지 방법이 Alglave 등의 공리적 집합론 방법 [AMT14]으로, 여기선 메모리 모델을 나타내기 위한 공리 집합을 만들어내고 리트머스 테스트들을 이 공리들의 집합으로 증명되거나 반증될 수 있는 정리로 변환시킵니다. 이렇게 만들어진, “herd” 라 불리는 도구는 편리하게 PPCMEM 에서와 같은 리트머스 테스트들을 입력으로 받는데, Listing 12.28 에 보인 IRIW 리트머스 테스트도 포함됩니다.

IRIW 를 푸는데에 PPCMEM 이 14 CPU 시간을 필요로 하는 반면, herd 는 17 밀리세컨드만에 IRIW 를 푸는데, 이는 백만배 이상의 속도 향상을 의미합니다. 그렇다면 하나, 문제는 근본적으로 기하급수적으로,

Listing 12.30: Locking Example

```

1 C Lock1
2 {
3 }
4
5 P0(int *x, spinlock_t *sp)
6 {
7  spin_lock(sp);
8  WRITE_ONCE(*x, 1);
9  WRITE_ONCE(*x, 0);
10 spin_unlock(sp);
11 }
12
13 P1(int *x, spinlock_t *sp)
14 {
15  int r1;
16
17  spin_lock(sp);
18  r1 = READ_ONCE(*x);
19  spin_unlock(sp);
20 }
21 exists (1:r1=1)

```

더 커다란 문제들에 있어서는 herd 역시 기하급수적으로 느려질 것을 예상해야 합니다. 그리고 이는 실제로 일어나는 일인데, 예를 들어 우리가 Listing 12.29 에 보여진 것처럼 쓰기를 하는 CPU마다 네개의 쓰기를 추가하면, herd 는 50,000 배 이상 느려져서 15 분 이상의 CPU 시간을 필요로하게 됩니다. 쓰레드를 추가하는 것 역시 기하급수적인 속도 저하를 초래합니다 [MS14].

이런 근본적 기하급수적 성질에도 불구하고, PPCMEM 과 herd 는 x86 시스템에서의 queued-lock handoff 를 포함해서 핵심적 병렬 알고리즘을 체크하는데에 상당히 유용한 것으로 증명되었습니다. Herd 의 약점은 Section 12.2.4 에서 이야기한 PPCMEM 의 그 것과 유사합니다. PPCMEM 과 herd 가 동의하지 않게 되는 불분명한 (하지만 매우 현실적인) 경우들이 존재하는데 2014년 말 현재까지는 이 이견문제를 해결하는 노력이 진행 중입니다.

리트머스 테스트가 어셈블리 (Listing 12.24 처럼) 어보다는 C 로 쓰인다면 (Listing 12.25 처럼) 더 좋을 겁니다. 이게 이제 가능한데, 다음 섹션에서 이야기 하겠습니다.

12.3.1 Axiomatic Approaches and Locking

공리적 접근법은 더 높은 수준의 언어들과 높은 수준의 동기화 기능들에도 적용될 수 있는데, Listing 12.30 에 턱킹 기반 리트머스 테스트가 예제로 보여져 있습니다. 예상대로, herd 툴의 결과는 Never 를 내포해서, P1() 은 x 가 값 1을 갖는 경우를 볼 수 없음을 올바르게 알립니다.¹

Quick Quiz 12.27: Listing 12.30 에 보인 것과 같은 리

¹ herd 툴의 결과는 PPCMEM 의 그것과 호환되므로, Listing 12.26 과 12.27 를 결과 포맷의 예로 보셔도 됩니다.

Listing 12.31: Broken Locking Example

```

1 C Lock2
2 {
3 }
4
5 P0(int *x, spinlock_t *sp1)
6 {
7     spin_lock(sp1);
8     WRITE_ONCE(*x, 1);
9     WRITE_ONCE(*x, 0);
10    spin_unlock(sp1);
11 }
12
13 P1(int *x, spinlock_t *sp2) // Buggy!
14 {
15     int r1;
16
17     spin_lock(sp2);
18     r1 = READ_ONCE(*x);
19     spin_unlock(sp2);
20 }
21 exists (1:r1=1)

```

Listing 12.32: Canonical RCU Removal Litmus Test

```

1 C C-RCU-remove
2 {
3     int z=1;
4     int y=2;
5     int *x=y;
6 }
7
8
9 P0(int **x, int *y, int *z)
10 {
11     rCU_assign_pointer(*x, z);
12     synchronize_rcu();
13     WRITE_ONCE(*y, 0);
14 }
15
16 P1(int **x, int *y, int *z)
17 {
18     int *r1;
19     int r2;
20
21     rCU_read_lock();
22     r1 = rCU_dereference(*x);
23     r2 = READ_ONCE(*r1);
24     rCU_read_unlock();
25 }
26
27 locations [1:r1; x; y; z]
28 exists (1:r2=0)

```

트머스 테스트를 *herd*로 돌려 보려면 뭘 해야 하나요?

물론, Listing 12.31에 보인 것처럼 *P0()*와 *P1()*이 다른 락을 사용하면 완전 망합니다. 이 경우에, *herd*의 출력은 *Sometimes*라는 문자열을 보여서, 다른 락을 사용하는건 *P1()*이 *x*의 값이 1인 경우를 볼 수 있게 됨을 올바르게 이야기 합니다.

12.3.2 Axiomatic Approaches and RCU

공리적 접근법은 RCU에 연관된 리트머스 테스트도 분석할 수 있습니다. 따라서, Listing 12.32은 RCU를

통한 링크드 리스트에서의 원소 제거에 관련된 리트머스 테스트를 보입니다. Line 6는 리스트 헤드인 *x*를 보이는데, 이 값은 초기에 *y*를 가리키고 있으며, *y*는 line 5에서 값 2로 초기화 되어 있습니다.

Line 9-14의 *P0()*는 리스트에서 *y*를 *z*로 바꿈으로써 (line 11) 리스트에서 제거하고, 하나의 그레이스 피리어드가 지나가길 기다리고 (line 12), 마지막으로 *y*의 값을 0으로 만들어 *free()*의 행동을 따라합니다 (line 13). Line 16-14의 *P1()*은 RCU read-side 크리티컬 섹션 내에서 (line 21-24), 리스트 헤드를 가져오고 (line 22) 다음 원소를 가져옵니다 (line 23). 이 다음 원소는 아직 메모리 해제되지 않은, 0이 아닌 값이어야 합니다 (line ??). 일부 다른 변수들은 디버깅 목적의 출력입니다 (line 27).

herd 툴에서 이 리트머스 테스트를 돌리면 그 결과는 *Never*로, *P0()*가 예상대로 결코 메모리 해제된 원소에 접근하지 않음을 알립니다. 역시 예상대로, line 12를 지우면 *P0()*가 메모리 해제된 원소를 접근할 수 있어서, *herd* 결과에 *Sometimes*로 보입니다.

Roman Penyaev [Pen18]에 의해 제안된 더 복잡한 예제를 위한 리트머스 테스트가 Listing 12.33으로 보여져 있습니다. 이 예제에서, line 12-35의 읽기 쓰레드들 (*P0()*로 모델됨)은 리스트의 마지막 원소로의 포인터를 변수 *c*로 “흘림”으로써 링크드 리스트를 라운드로빈 형태로 접근합니다. 업데이트 쓰레드들 (line 37-49의 *P1()*으로 모델됨)은 현재의 도는 미래의 읽기 쓰레드들을 방해하지 않도록 주의하면서 원소를 제거합니다.

Quick Quiz 12.28: 잠깐만요!!! 포인터를 RCU read-side 크리티컬 섹션 밖으로 흘리는건 심각한 버그가 아닌가요???

Line 4-8는 초기의 링크드 리스트를, tail 먼저 정의합니다. 리눅스 커널에서, 이는 양방향 순환 링크드 리스트가 되겠습니다만, *herd*는 현재 그런 걸 모델링 할 수 없습니다. 그대신 여기서의 전략은 끝까지 도달할 수 없을 정도로 무척 긴 단방향 링크드 리스트를 사용하는 겁니다. Line 9는 변수 *c*를 정의하는데, 이 변수는 성공적인 RCU read-side 크리티컬 섹션들 사이에서의 리스트 포인터를 캐싱하는데 사용됩니다.

다시, line 12-35는 읽기 쓰레드를 모델링 합니다. 이 프로세스는 리스트를 라운드로빈으로 순회하는 한상의 연속적인 읽기 쓰레드들을 모델링하는데, 첫번째 읽기 쓰레드가 line 19-26에, 두번째 읽기 쓰레드는 line 27-34에 있습니다. Line 20는 *c*에 캐시된 포인터를 가져오고, line 21가 이 포인터가 NULL인 걸 보게 되면, line 22에서 리스트의 처음부터 재시작합니다. 어느 경우든, line 24는 다음 리스트 원소로 진행하고, line 25는 이 원소로의 포인터를 변수 *c*에 다시 저장합니다. line 27-34는 이 과정을 반복합니다만, 레지스터 *r1*과

Listing 12.33: Complex RCU Litmus Test

```

1 C C-RomanPenyaev-list-rcu-rr
2
3 {
4     int *z=1;
5     int *y=z;
6     int *x=y;
7     int *w=x;
8     int *v=w;
9     int *c=w;
10 }
11
12 P0(int **c, int **v)
13 {
14     int *r1;
15     int *r2;
16     int *r3;
17     int *r4;
18
19     rcu_read_lock();
20     r1 = READ_ONCE(*c);
21     if (r1 == 0) {
22         r1 = READ_ONCE(*v);
23     }
24     r2 = rcu_dereference(*(int **)r1);
25     smp_store_release(c, r2);
26     rcu_read_unlock();
27     rcu_read_lock();
28     r3 = READ_ONCE(*c);
29     if (r3 == 0) {
30         r3 = READ_ONCE(*v);
31     }
32     r4 = rcu_dereference(*(int **)r3);
33     smp_store_release(c, r4);
34     rcu_read_unlock();
35 }
36
37 P1(int **c, int **v, int **w, int **x, int **y)
38 {
39     int *r1;
40
41     rcu_assign_pointer(*w, y);
42     synchronize_rcu();
43     r1 = READ_ONCE(*c);
44     if ((int **)r1 == x) {
45         WRITE_ONCE(*c, 0);
46         synchronize_rcu();
47     }
48     smp_store_release(x, 0);
49 }
50
51 locations [1:r1; c; v; w; x; y]
52 exists (0:r1=0 \ 0:r2=0 \ 0:r3=0 \ 0:r4=0)

```

r2 대신 r3 와 r4 를 사용합니다. Listing 12.32 에서와 같이, 이 리트머스 테스트는 free() 를 흉내내기 위해 0 을 저장하며, 따라서 라인 ?? 는 이 네개의 레지스터 중 어느 것이라도 NULL, 즉 0 이 되었는지 확인합니다.

P0() 가 RCU 로 보호되는 포인터를 첫번째 RCU read-side 크리티컬 섹션에서 두번째 것으로 유출시키기 때문에, P1() 은 그 업데이트 (x 의 제거) 를 매우 조심히 해야만 합니다. 라인 41 는 w 를 y 에 연결함으로써 x 를 제거합니다. 라인 42 은 뒤따르는 어떤 읽기 쓰레드도 링크드 리스트를 통한 x 로의 경로를 볼 수 없는 상태까지 기다립니다. 라인 43 는 c 를 가져오고, 만약 라인 44 가 c 가 이제 제거된 x 를 레퍼런스함을

알게 되면, 라인 45 가 c 를 NULL 로 만들고 라인 46 는 따르는 읽기 스레드들이 c 로부터 x 를 가져올 수 없는 상황까지 기다립니다. 어떤 경우든, 라인 48 는 x 에 0 을 저장해서 free() 를 흉내냅니다.

이 리트머스 테스트를 herd 도구로 돌렸을 때 결과는 Never 로, 예상대로 P0() 가 메모리 해제된 원소를 접근하지 못함을 알립니다. 역시 예상대로, synchronize_rcu() 를 제거하는건 P1() 이 메모리 해제된 원소에 접근할 수 있는 결과를 낳아, herd 결과에 Sometimes 가 나오게 합니다.

Quick Quiz 12.29: Listing 12.33 에서, 라인 48 바로 앞에서 synchronize_rcu() 를 한번만 호출하면 어떨까요? ■

Quick Quiz 12.30: Listing 12.33 에서도, 라인 48 가 smp_store_release() 대신에 WRITE_ONCE() 를 사용할 순 없나요? ■

이 섹션들은 어떻게 axiomatic 접근법들이 락킹과 RCU 같은 동기화 도구들을 C 언어 리트머스 테스트로 성공적으로 모델링 할 수 있는지 보였습니다. 장기적으로는, 이 axiomatic 접근법들이 더 높은 수준의 소프트웨어 작품들을 묘사할 수 있게 되길 바랍니다. 이는 axiomatic 검증이 훨씬 많은 소프트웨어 시스템들을 다룰 수 있게 할겁니다. 또 다른 대안은 boolena logic 의 axiom 들을 서비스에 넣는 것으로, 다음 섹션에서 다룹니다.

12.4 SAT Solvers

Live by the heuristic, die by the heuristic.

Unknown

제한된 횟수의 루프와 재귀를 갖는 모든 유한한 프로그램은 입력에 대한 그 프로그램의 단정들을 표현하는 논리 표현식으로 변환될 수 있습니다. 그런 논리 표현식이 있다면, 어떤 입력의 조합이 단정문 가운데 하나를 터지게 만들 수 있는지 알 수 있는지 여부를 아는 것은 매우 흥미로울 겁니다. 만약 입력이 이진 변수들의 조합으로 표시된다면, 이는 곧 satisfiability problem 이라고도 알려진 SAT 입니다. SAT solver 들은 하드웨어의 검증에 많이 사용되어져 왔으며, 여기서 커다란 진보의 동기를 주었습니다. 1990년대 초의 월드 클래스 SAT solver 는 100 개의 별개의 이진 변수들로 표현된 논리 표현식을 다룰 수 있습니다만, 2010년대 초에 와서는 백만개의 변수로 이루어진 SAT solver 들이 사용 가능합니다 [KS08].

또한, SAT solver 들을 위한 프론트엔드 프로그램들은 C 코드를 자동으로 논리 표현식으로 변환시킬 수 있으며, 이 때 단정문들을 취하기도 하고 배열 크기 침범

에러와 같은 에러 조건들을 위한 단정문을 생성하기도 합니다. 한가지 예는 C bounded model checker, 또는 cbmc 라 알려진 것으로, 많은 리눅스 배포판에 포함되어 있어서 사용 가능합니다. 이 도구는 사용하기가 상당히 간단해서, cbmc test.c 만으로도 test.c 를 검증하기에 충분합니다. 이런 사용상의 편의성은 회귀 테스트 프레임워크에 포함되고 있는 정형적 검증으로 의문을 열어주기 때문에 매우 중요합니다. 대조적으로, 특정 목적의 언어로의 사소하지 않은 변환을 필요로 하는 전통적인 도구들은 설계 시점에서의 검증으로만 국한되어졌습니다.

근래에 들어서, SAT solver 들은 병렬 코드를 처리하는 형태로도 나타났습니다. 이런 solver 들은 입력이 되는 코드를 single static assignment (SSA) 형태로 변환시키고는 여기서 생겨날 수 있는 모든 액세스 순서들을 생성합니다. 이 방법은 잘 동작할 듯 보입니다만, 실제 환경에서 얼마나 잘 동작할지는 볼 필요가 있습니다. 한 가지 좋은 징조는 2016년에 있었던 cbmc 를 리눅스 커널 RCU 에 적용하려 한 작업 [LMKM16, LMKM18, Roy17]입니다. 이 작업은 RCU 의 최소한의 구성과 작은 수의 쓰레드를 사용한 검증 시나리오를 사용하기 했습니다만, 리눅스 커널 C 코드를 수집하고 유용한 결과를 내놓았습니다. 이 C 코드에서 생성된 논리 표현식은 9천만개의 변수, 4만5천개의 절들을 가져서 이 SAT solver 가 올바른 결과를 내놓는데 수십기가바이트의 메모리 사용과 80시간의 CPU 시간을 필요로 했습니다.

그러나, 리눅스 커널 해커는 자신의 코드가 자동으로 검증되었다는 데 대해 회의감을 느낄 수도 있을 것이고, 그런 해커들은 수십년 전부터의 많은 그런 회의감을 찾을 겁니다 [DMLP79]. 그런 비판적 감정을 생산적으로 표현하는 한가지 방법은, 그렇게 검증된 코드의 버그가 삽입된 버전을 제공하는 겁니다. 만약 formal-verification tool 이 모든 버그를 찾는다면, 우리의 해커는 이 도구의 기능에 대해 더 만족할 수 있을 겁니다. 그리고 이게 바로 리눅스 커널 RCU 에 버그가 잠재적으로 삽입되어 있는 20개의 서로 다른 브랜치를 갖는 git 저장소 [McK17]를 가진 이유입니다.

현재, cbmc 는 여러개의 주입된 버그들을 찾을 수 있습니다만, RCU 의 메인테이너가 아직 알지 못한 버그를 찾지는 못했습니다. 그러나, SAT solver 들이 언젠가는 병렬 코드의 동시성 버그를 찾는데 유용해질 날이 올거라는 희망을 가질만 합니다.

12.5 Stateless Model Checkers

He's making a list, he's permuting it twice...

with apologies to Haven Gillespie and J. Fred Coots




Figure 12.2: Nidhugg Processing Flow

앞의 섹션에서 설명한 SAT-solver 방법은 상당히 편리하고 강력합니다만, 모든 가능한 수행 경우를 상태를 포함해서 모두 추적하는건 상당한 오버헤드를 일으킬 수 있습니다. 실제로, 메모리와 CPU-time 오버헤드는 적당하게 검증될 수 있는 프로그램의 크기를 제한하게 되는데, 이는 덜 정확한 방법들이 더 커다란 프로그램의 버그를 찾아낼 수 있을까 하는 질문을 품게 합니다.

이 질문에 대한 판정단은 아직 없지만, Nidhugg [LSLK14] 같은 stateless model checker 들은 Figure 12.2 에 보여진 것처럼 일부 경우에 더 큰 프로그램들을 사용하기 편하게 처리했습니다 [KS17b]. 또한, Nidhugg 는 일부 리눅스 커널 RCU 검증 시나리오에서 cbmc 보다 열배 넘게 빨랐습니다. 물론, Nidhugg 의 속도와 확장성의 장점은 데이터 비결정성을 처리하지 않는다는 사실과 연관되어 있습니다만, 이는 이 특정 검증 시나리오에서는 문제가 되지 않았습니다.

그러나, cbmc 에서와 같이, Nidhugg 는 아직 리눅스 커널 RCU 의 메인테이너가 알지 못한 버그를 찾지는 못했습니다. 하지만, 리눅스 커널 RCU 의 역사상의 버그가 메인테이너가 생각했던 것과 다른 커밋으로 수정되었음을 보일 수는 있었으며, 이는 Nidhugg 와 같은 stateless model checker 들이 언젠가는 병렬 코드의 동시성 버그를 찾는데 유용해지는 날이 올 것이란 희망을 품게 합니다.

12.6 Summary

Western thought has focused on True-False; it is high time to shift to Robust-Fragile.

summarized from Nassim Nicholas Taleb

이 챕터에서 설명한 정형적 검증 기술은 작은 병렬 알고리즘들을 검증하는데에는 매우 강력한 도구입니다만, 여러분의 도구상자에 그것만 있어선 안됩니다. 지난 수십년간의 정형적 검증에 대한 노력에도 불구하고, 테스트는 커다란 병렬 소프트웨어 시스템을 위한 대표적 검증 도구로 남아있습니다 [Cor06a, Jon11, McK15b].

물론 이는 항상 그렇지는 않을 수도 있는 것이 사실입니다. 이를 확실히 하기 위해, 2017년 기준으로 200억개가 넘는 리눅스 커널의 인스턴스가 존재한다고 추정된다는 점을 생각해 보세요. 리눅스 커널에 평균적으로 백만년의 수행 중 한번 발생할 수 있는 버그가 있다고 생각해 봅시다. 앞의 챕터의 마지막에서 설명했다시피, 이 버그는 이 전체 설치된 환경에서 하루에 50번씩 나타날 겁니다. 하지만 대부분의 형식적 검증 테크닉은 매우 작은 코드에 대해서만 사용될 수 있다는 사실도 여전합니다. 그런 상황에서 동시적 코드를 짜는 사람들은 뭘 해야 할까요?

한 가지 방법은 첫번째 버그, 첫번째로 관련 있는 버그, 마지막으로 관련 있는 버그, 그리고 마지막 버그를 찾는 것에 대해 생각해 보는 겁니다.

첫번째 버그는 코드 검사나 컴파일러의 진단 기능을 통해 발견되어집니다. 최신의 컴파일러에 의해 제공되며, 지속적으로 세련되어지고 있는 진단 기능이 가벼운 형태의 정형적 검증으로 여겨질 수도 있긴 하지만, 그것을 그런 용어로 부르는 건 흔하지 않습니다. 이는 부분적으로는 “내가 그걸 사용하고 있다면, 그것은 정형적 검증일 수 없다”라고 말하는, 이상한 실무자의 선입견 때문이기도 하고, 컴파일러 진단기능과 검증에 대한 연구 사이의 서로 다른 철학 때문이기도 합니다.

첫번째로 관련 있는 버그는 코드 검사나 컴파일러 진단 기능으로 발견되어질 수도 있지만, 이 두 단계가 오타와 거짓 양성 반응만을 찾게 되는 것도 흔하지 않은 일은 아닙니다. 어떤 방식으로든, 실제 제품에서 마주하게 될 버그들인 관련된 많은 버그들은 많은 경우 테스트를 통해 발견되어질 겁니다.

테스트가 예측된 사용 예에서 만들어졌든 진짜 사용 예에서 만들어졌든, 마지막 연관된 버그가 테스트를 통해 발견되어지는 것은 흔치 않은 일이 아닙니다. 이 상황은 형식적 검증에 대한 완전한 거부의 동기가 될 수도 있겠습니다만, 관계없는 버그들은 black-hat 공격 덕에 최소한의 알맞은 사이즈에 있어서는 갑자기 관계 있는 것이 되어버리는 안좋은 습관을 가지고 있습니다. 전체 소프트웨어 가운데 그 분포도를 지속적으로 높여가는

보안에 관련된 소프트웨어에 있어서는 마지막 버그를 찾아내고 고쳐내려는 강한 동기가 존재할 수 있습니다. 테스트는 마지막 버그를 찾아내는 것은 명백히 불가능하므로 정형적 검증에게만 가능한 역할이 존재합니다. 정형적 검증이 그 안으로 적용될 수 있다고만 하면 그런 역할이 있다는 이야기입니다. 이 챕터에서 보였듯이, 현재의 정형적 검증 시스템들은 상당히 제한적입니다.

Quick Quiz 12.31: 하지만 충분히 낫은 단계의 소프트웨어는 모든 의도와 목적에 있어 블랙햇으로부터의 공격에 내성이 있지 않나요? ■

또 다른 방법은 정형적 검증이 많은 경우 테스트보다 적용하기가 어렵다는 점을 고려하는 겁니다. 물론 이는 문화적인 측면에서의 이야기일 수 있고, 정형적 검증이 더 많은 사람들에게 친숙해질수록 더 쉽게 전파될 것이라는 희망을 가져볼 수도 있습니다. 그러나, 매우 간단한 테스트 사용은 임의의 거대한 소프트웨어 시스템에서 심각한 버그들을 찾아낼 수 있습니다. 반면에, 정형적 검증을 적용하기 위해 필요한 노력은 시스템의 크기가 증가할수록 극적으로 증가합니다.

전 20년이 넘도록 정형적 검증을 정형적 검증이 효력을 발휘하는 곳에서 필요할 때에만 사용했을 뿐인데, 설계 시점에서의, 무엇보다 중요한 소프트웨어 구성물의 작고 복잡한 부분의 검증에 있어 그랬습니다. 무엇보다 중요하지만 더 커다란 소프트웨어 구성물들은 물론 테스트로 검증했습니다.

Quick Quiz 12.32: L4 마이크로커널의 전체 검증을 생각해 보면, 이런 정형적 검증에 대한 제한적인 시각은 약간 시대에 뒤쳐진 것 아닌가요? ■

마지막 방법은 다음의 두개의 정의와 그것들이 암시하는 결론에 대해서 고려해 보는 것입니다:

정의: 버그가 없는 프로그램은 간단한 프로그램이다.

정의: 신뢰할 수 있는 프로그램은 알려진 버그가 없다.

결론: 모든 사소하지 않으며 신뢰할 수 있는 프로그램에는 최소 하나의 아직 알려지지 않은 버그가 있다.

이 시점에서 보면, 모든 검증 영역에서의 진보는 두 가지 영향을 가질 수밖에 없을 겁니다: (1) 간단한 프로그램의 증가 또는 (2) 신뢰할 수 있는 프로그램의 감소. 물론, 인류의 멀티코어 시스템과 소프트웨어에 대한 의존도의 증가는 간단한 프로그램들의 갯수의 가파른 증가에 대한 커다란 동기가 될겁니다!

하지만, 만약 여러분의 코드가 너무 복잡해서 여러분이 정형적 검증 도구에 너무 과하게 의존하고 있다는 점을 알게 된다면, 여러분은 여러분의 설계를 다시 세심하게 생각해 봐야 하는데, 당신의 정형적 검증 도구들이 당신의 코드가 특정 목적 언어로 순으로 변환해야

하게 되는 상황이라면 특히 그렇습니다. 예를 들어, Section 12.1.5에서 보인 preemption 가능한 RCU의 복잡한 dynticks 인터페이스 구현에 있어서는 Section 12.1.6.9에서 이야기한대로 훨씬 간단한 대안적 구현이 존재함이 드러났습니다. 다른게 모두 동일하다면, 복잡한 구현을 위한 올바름의 증명보다 간단한 구현이 훨씬 낫습니다!

그리고 정형적 검증 테크닉들과 시스템들에 대한 열려있는 도전은 이 요약 내용이 틀리다고 증명하는 것입니다! 이 일을 돋기 위해, Verification Challenge 6가 사용 가능합니다 [McK17]. 한번 보세요!!!

Chapter 13

You don't learn how to shoot and then learn how to launch and then learn to do a controlled spin—you learn to launch-shoot-spin.

“*Ender's Shadow*”, Orson Scott Card

Putting It All Together

이 챕터는 일부 동시적 프로그래밍의 퍼즐들을 처리하는데 대한 약간의 힌트를 제공하는데, Section 13.1에서 카운터의 난문제로 시작해서, Section 13.3에서 일부 RCU 구조로 이어지고, Section 13.4에서의 해싱 노력으로 마무리 합니다.

13.1 Counter Conundrums

이 섹션은 일부 카운터 문제에 대한 해결책들을 개략적으로 소개합니다.

13.1.1 Counting Updates

Schrödinger (Section 10.1를 참고하세요)가 각 동물의 업데이트 횟수를 카운트하고자 하고, 이 업데이트들은 데이터 원소별 락을 통해 동기화 된다고 해봅시다. 이 카운팅은 어떻게 해야 최선일까요?

물론, Chapter 5에서의 카운팅 알고리즘들 중 무엇이든 고려해 볼 수 있을 겁니다만, 이경우에 최적의 방법은 훨씬 간단합니다. 카운터를 각각의 데이터 원소에 위치시키고, 그 원소의 락으로 보호한 채로 카운터를 증가시키세요!

13.1.2 Counting Lookups

Schrödinger가 각 동물에의 검색의 횟수 역시 세고 싶어하며, 검색은 RCU를 통해 보호되고 있다고 생각해 봅시다. 이런 카운팅은 어떻게 하는게 최선일까요?

한 가지 방법은 Section 13.1.1에서 이야기한 원소별 락을 사용해서 검색 카운터를 보호하는 것일 겁니다. 불행히도, 이는 모든 검색이 락을 잡을 것을 필요로 해서, 커다란 시스템에서는 상당한 병목지점이 될겁니다.

또 다른 방법은 카운팅이 “안된다고 하기”로, `noatime` 마운트 옵션의 예를 따릅니다. 이 방법이 사용 가능한 경우라면, 이게 최고의 방법임이 분명합니다:

무엇보다, 아무것도 하지 않는것보다 빠른 것은 없습니다. 검색 카운트가 면제될 수 없다면, 마저 읽어주세요!

Chapter 5에 나온 모든 카운터들이 사용될 수 있는데, Section 5.2에서 설명한 통계적 카운터가 아마도 가장 흔한 선택이 될겁니다. 하지만, 이는 커다란 메모리 사용량을 초래합니다: 요구되는 카운터들의 갯수는 데이터 원소들의 갯수에 쓰레드의 갯수를 곱한 값이 됩니다.

이런 메모리 오버헤드가 지나치다면, CPU 별 카운터 대신 소켓별 카운터를 유지하고 Figure 10.3.에 보여진 것처럼 해시 테이블 성능 결과를 주목하는 방법이 있습니다. 이는 카운터 증가는 어토믹 오퍼레이션이 될 것을 필요로 할 것인데, 특히 특정 쓰레드가 언제든 다른 CPU로 옮겨갈 수 있는 사용자 모드 수행에서는 특히 그렇습니다.

만약 일부 원소들이 매우 자주 검색된다면, 쓰레드별 로그를 유지하며 특정 원소를 위한 여러 로그 항목들이 병합될 수 있는 식으로 업데이트들을 몰아서 처리하는 방법들이 있습니다. 특정 로그 항목이 충분히 많은 횟수 증가되었거나 충분히 많은 시간이 지났다면, 해당 로그 항목은 연관된 데이터 항목에 적용될 수 있을 겁니다. Silas Boyd-Wickizer는 이런 노선을 정형화 시켰습니다 [BW14].

13.2 Refurbish Reference Counting

레퍼런스 카운팅이 개념적으로는 간단한 테크닉이지만, 동시적 소프트웨어에 적용되면 그 디테일 안에 많은 악마들이 숨어있습니다. 무엇보다도, 오브젝트가 지나치게 일찍 폐기되는 일이 없는 오브젝트라면, 애초에 레퍼런스 카운터가 필요하지도 않았을 겁니다. 하지만 오브젝트가 폐기될 수 있다면, 레퍼런스를 얻어오는 프로세스 그 자체가 진행되는 동안 폐기되는 것을 무엇으로 막을 수 있을까요?

동시적 소프트웨어에서 사용되기 위해 레퍼런스 카운터를 재정비하는 몇가지 방법들이 있는데, 다음과 같

Table 13.1: Reference Counting and Synchronization Mechanisms

Acquisition Synchronization	Release Synchronization		
	Locking	Reference Counting	RCU
Locking	-	CAM	CA
Reference Counting	A	AM	A
RCU	CA	MCA	CA

은 것들이 포함됩니다:

1. 레퍼런스 카운트를 조정하는 동안에는 바깥에 존재하는 오브젝트의 락을 잡아야만 하기.
2. 오브젝트는 0이 아닌 레퍼런스 카운트와 함께 생성되고, 새로운 레퍼런스들은 레퍼런스 카운터의 현재 값이 0이 아닐 때에만 획득될 수 있게 하기. 어떤 레퍼런스가 특정 오브젝트로의 레퍼런스를 가지고 있지 않다면, 이미 레퍼런스를 가지고 있는 다른 쓰레드의 도움으로 해당 오브젝트로의 레퍼런스를 얻을 수 있음.
3. 해당 오브젝트를 위한 존재 보장이 제공되어서, 해당 오브젝트가 다른 무언가가 레퍼런스를 얻으려 시도하는 동안은 해제되지 않도록 하기. 존재 보장은 자동화된 *garbage collector*를 통해서, 또는 Section 9.5에서 보여지듯이 RCU를 통해서 제공되곤 합니다.
4. 오브젝트를 위한 탑업 안정성을 제공하기. 레퍼런스가 일단 획득되면 추가적인 아이덴티티 체크가 이뤄져야만 합니다. 탑업 안정성 보장은 예를 들어, Section 9.5에서 보여진 것과 같이 리눅스 커널 안에서 *SLAB_DESTROY_BY_RCU* 기능과 같이 특수 목적 메모리 할당자를 통해 제공될 수 있습니다.

물론, 존재 보장을 제공하는 모든 메커니즘은 그 정의에 의해 탑업 안정성 보장도 제공합니다. 따라서 이 섹션은 마지막의 두 단계를 RCU의 전례 하에 레퍼런스 획득 보호에 일반적으로 사용되는 세 가지 카테고리로 그룹지어 보겠습니다.: 레퍼런스 카운팅, 시퀀스 락킹, 그리고 RCU.

Quick Quiz 13.1: 레퍼런스 획득을 단순히 레퍼런스 카운터의 값이 0이 아닌 경우에만 레퍼런스를 획득하는 compare-and-swap 오퍼레이션으로 간단하게 만들지는 않는거죠? ■

레퍼런스 카운팅의 핵심 이슈는 레퍼런스의 획득과 오브젝트의 해제 사이의 동기화란 점을 놓고 보면, 우린 Table 13.1에 보인 것과 같은 아홉개의 메커니즘 조합들이 존재 가능합니다. 이 표는 레퍼런스 카운팅 메커니즘들을 다음과 같이 넓은 카테고리들로 나눕니다:

1. 어토믹 오퍼레이션, 메모리 배리어, 정렬 제약도 없는 간단한 카운팅 (“-”).
2. 메모리 배리어 없이 진행되는 어토믹 카운팅 (“A”).
3. 릴리즈 시에만 메모리 배리어를 사용하는 어토믹 카운팅 (“AM”).
4. 어토믹 획득 오퍼레이션과 릴리즈 시에만 필요시 되는 메모리 배리어들과 조합된 체크를 하는 어토믹 카운팅 (“CAM”).
5. 어토믹 획득 오퍼레이션과 조합된 체크를 하는 어토믹 카운팅 (“CA”).
6. 어토믹 획득 오퍼레이션과 레퍼런스 획득 때에도 필요시 되는 메모리 배리어들과 조합된 체크를 사용하는 어토믹 카운팅 (“MCA”).

하지만, 값을 리턴하는 모든 리눅스 커널 어토믹 오퍼레이션들은 메모리 배리어를 포함하도록 정의되어 있으므로,¹ 모든 릴리즈 오퍼레이션들은 메모리 배리어를 포함하고, 모든 체크되는 레퍼런스 획득 오퍼레이션들 또한 메모리 배리어를 포함하게 됩니다. 따라서, “CA”와 “MCA”는 “CAM”과 동일해서, 앞의 네개의 경우들을 위한 세션들만이 남게 됩니다: “-”, “A”, “AM”, 그리고 “CAM”. 레퍼런스 카운팅을 지원하는 리눅스의 기능들은 Section 13.2.2에 소개되어 있습니다. 뒤의 세션들은 레퍼런스 획득과 해제가 매우 빈번할 때, 그리고 레퍼런스 카운트가 매우 가끔씩만 0인지 여부를 체크해야 하는 경우에 대해 성능을 개선할 수 있는 최적화 방법들을 인용합니다.

13.2.1 Implementation of Reference-Counting Categories

락킹으로 보호되는 간단한 카운팅 (“-”)이 Section 13.2.1.1에 설명되고, 메모리 배리어 없이 수행되는 어토믹한 카운팅 (“A”)이 Section 13.2.1.2에 설명되고, 레퍼런스 획득 시의 메모리 배리어와 함께 수행되는 어토믹한 카운팅 (“AM”)이 Section 13.2.1.3에 설명되며, 레퍼런스 획득 시의 메모리 배리어와 체크와 함께 수행되는 어토믹한 카운팅 (“CAM”)이 Section 13.2.1.4에서 설명됩니다.

¹ *atomic_read()*와 *ATOMIC_INIT()*는 이 규칙에 예외가 됩니다.

Listing 13.1: Simple Reference-Count API

```

1 struct sref {
2     int refcount;
3 };
4
5 void sref_init(struct sref *sref)
6 {
7     sref->refcount = 1;
8 }
9
10 void sref_get(struct sref *sref)
11 {
12     sref->refcount++;
13 }
14
15 int sref_put(struct sref *sref,
16             void (*release)(struct sref *sref))
17 {
18     WARN_ON(release == NULL);
19     WARN_ON(release == (void (*) (struct sref *)) kfree);
20
21     if (--sref->refcount == 0) {
22         release(sref);
23         return 1;
24     }
25     return 0;
26 }

```

Listing 13.2: Linux Kernel kref API

```

1 struct kref {
2     atomic_t refcount;
3 };
4
5 void kref_init(struct kref *kref)
6 {
7     atomic_set(&kref->refcount, 1);
8 }
9
10 void kref_get(struct kref *kref)
11 {
12     WARN_ON(!atomic_read(&kref->refcount));
13     atomic_inc(&kref->refcount);
14 }
15
16 static inline int
17 kref_sub(struct kref *kref, unsigned int count,
18           void (*release)(struct kref *kref))
19 {
20     WARN_ON(release == NULL);
21
22     if (atomic_sub_and_test((int) count,
23                            &kref->refcount)) {
24         release(kref);
25         return 1;
26     }
27     return 0;
28 }

```

13.2.1.1 Simple Counting

어토믹 오퍼레이션도 메모리 배리어도 사용하지 않는 간단한 카운팅은 레퍼런스 카운터 획득과 해제가 모두 같은 락으로 보호될 때에 사용될 수 있습니다. 이 경우에 레퍼런스 카운터 자체는 어토믹하지 않게 조정될 것이란 점이 분명한데, 락은 모든 필요한 배타성, 메모리 배리어, 어토믹 인스트럭션, 그리고 컴파일러 최적화에 대한 방지를 제공하기 때문입니다. 이는 해당 락이 레퍼런스 카운트 만이 아니라 다른 오퍼레이션들도 보호해야 하지만 해당 오브젝트로의 레퍼런스가 해당 락을 해제한 후에 잡아야만 할 때에 선택될 수 있는 방법입니다. Listing 13.1은 간단한 어토믹하지 않은 레퍼런스 카운팅을 구현하는데 사용될 수 있는 간단한 API를 보입니다—간단한 레퍼런스 카운팅은 거의 항상 인터페이스 없이 곧바로 코딩되곤 하지만요.

13.2.1.2 Atomic Counting

간단한 어토믹 카운팅은 레퍼런스를 획득하는 모든 CPU는 레퍼런스를 이미 잡고 있어야 하는 경우에 사용될 수 있습니다. 이 스타일은 하나의 CPU가 자신의 사용을 위해 오브젝트를 생성하지만 나중에 태어난 다른 CPU, 테스크, 타이머 핸들러, 또는 I/O 완료 핸들러들이 그 오브젝트에 접근할 수 있도록 해야만 할 때 사용됩니다. 이 오브젝트를 넘겨주는 CPU는 받게 되는 오브젝트를 위해 새로운 레퍼런스를 먼저 획득해야만 합니다. 리눅스 커널에서는, kref 기능이 이런 스타일의 레퍼런스 카운팅을 구현하기 위해 사용되는데, Listing 13.2에 보여져 있습니다.

모든 레퍼런스 카운팅 오퍼레이션들이 락킹으로 보호되지는 않는데, 이는 두개의 다른 CPU들이 동시에 레퍼런스 카운트를 조정할 수 있음을 의미하기 때문에 어토믹 카운팅이 필요해집니다. 평범한 값 증가와 감소 오퍼레이션이 사용된다면, 한쌍의 CPU들이 둘 다 레퍼런스 카운트를 동시에 가져와서, “3”이라는 값을 읽을 수 있을 겁니다. 둘 다 그 값을 증가시키려 한다면, 이들은 모두 “4”를 얻게 될테고, 둘 다 이 값을 카운터에 다시 써넣을 겁니다. 카운터의 새로운 값은 “5”가 되었어야 하므로, 두개의 값 증가 오퍼레이션 중 하나는 없어진 셈입니다. 따라서, 카운터의 값 증가에도 값 감소에도 어토믹 오퍼레이션이 사용되어야만 합니다.

레퍼런스 릴리즈가 락킹이나 RCU로 보호된다면, 메모리 배리어는 필요하지 않을테지만, 다른 이유로 인해서입니다. 락킹의 경우, 락은 모든 필요한 메모리 배리어들을 제공하고 (그리고 컴파일러 최적화를 불능화시킵니다), 락들은 또한 두개의 레퍼런스 릴리즈가 동시에 수행되는 것을 막습니다. RCU의 경우, 현재 수행 중인 RCU read-side 크리티컬 섹션들이 모두 완료되기 전까지는 정리 작업이 유예되어야만 하고, 모든 필요한 메모리 배리어들이나 컴파일러 최적화의 불능화가 RCU 기능으로 제공될 겁니다. 따라서, 두개의 CPU들이 두개의 레퍼런스를 동시에 릴리즈 시킨다면, 실제 정리 작업은 두개의 CPU들이 모두 RCU read-side 크리티컬 섹션들을 빠져나갈 때까지 유예될 겁니다.

Quick Quiz 13.2: 한 CPU가 마지막 레퍼런스를 해제한 직후에 다른 CPU가 레퍼런스를 획득하는 경우에 대해서도 보호를 해줘야 하지 않나요? ■

`kref` 구조체 자체는 하나의 어토믹 데이터 아이템으로 구성되며, Listing 13.2 의 line 1-3 에 보여져 있습니다. Line 5-8 의 `kref_init()` 함수는 이 카운터를 값 “1”로 초기화 시킵니다. `atomic_set()` 기능은 단순한 값 할당으로, 그 이름은 `atomic_t` 의 데이터 타입에서 왔지, 그 동작에서 온것이 아님을 알아두시기 바랍니다. `kref_init()` 함수는 오브젝트 생성 때에, 해당 오브젝트가 어떤 다른 CPU 들에 의해 접근될 수 있게 되기 전에 실행되어야만 합니다.

Line 10-14 의 `kref_get()` 함수는 무조건적으로 카운터를 어토믹하게 증가시킵니다. `atomic_inc()` 기능은 모든 플랫폼에서 컴파일러 최적화를 명시적으로 불능화 시켜야만 하지는 않습니다만, `kref` 이 별개의 모듈에 존재하고 리눅스 커널 빌드 프로세스는 모듈간 최적화를 하지 않는다는 사실이 똑같은 효과를냅니다.

Line 16-28 의 `kref_sub()` 함수는 어토믹하게 카운터를 감소시키고, 만약 그 결과가 0이라면, line 24에서 명시된 `release()` 함수를 호출하고 line 25에서 호출자에게 `release()` 가 호출되었음을 알리면서 리턴합니다. 그렇지 않다면, `kref_sub()` 은 0을 리턴해서 호출자에게 `release()` 가 호출되지 않았음을 알립니다.

Quick Quiz 13.3: Listing 13.2 의 line 22에서 `atomic_sub_and_test()` 가 호출된 직후에, 어떤 다른 CPU 가 `kref_get()` 을 호출했다고 생각해 봅시다. 이는 다른 CPU 가 이제 비합법적으로 해제된 오브젝트로의 레퍼런스를 갖게 된 거 아닌가요? ■

Quick Quiz 13.4: `kref_sub()` 가 0을 리턴해서 `release()` 함수가 호출되지 않았음을 알렸다고 생각해 봅시다. 어떤 조건에서 호출자는 이 오브젝트의 존재의 지속에 의존할 수 있을까요? ■

Quick Quiz 13.5: 왜 그냥 해제 함수로 `kfree()` 를 넘기지 않는거죠? ■

13.2.1.3 Atomic Counting With Release Memory Barrier

이런 스타일의 레퍼런스는 리눅스 커널의 네트워킹 레이어에서 패킷 라우팅에 사용되는 목적지 캐시를 추적하는데에 사용됩니다. 실제 구현은 훨씬 더 관련되어 있습니다; 이 섹션은 이 사용예에 적합하며 Listing 13.3에 보인 `struct dst_entry` 레퍼런스 카운트 핸들링 부분에 집중하고 있습니다.

`dst_clone()` 함수는 호출자가 이미 명시된 `dst_entry` 에 대한 레퍼런스를 가지고 있을 때 사용될 수 있는데, 이는 커널 내의 다른 존재에게 넘겨줄 수도 있는 또 다른 레퍼런스를 획득하는 경우입니다. 호출자에 의해 이미 레퍼런스가 하나 잡혀 있기 때문에, `dst_clone()` 은 어떤 메모리 배리어도 실행할 필요가 없습니다. 어떤 다른 존재에게 `dst_entry` 를 넘겨주는

Listing 13.3: Linux Kernel `dst_clone` API

```

1 static inline
2 struct dst_entry * dst_clone(struct dst_entry * dst)
3 {
4     if (dst)
5         atomic_inc(&dst->__refcnt);
6     return dst;
7 }
8
9 static inline
10 void dst_release(struct dst_entry * dst)
11 {
12     if (dst) {
13         WARN_ON(atomic_read(&dst->__refcnt) < 1);
14         smp_mb__before_atomic_dec();
15         atomic_dec(&dst->__refcnt);
16     }
17 }

```

행위는 메모리 배리어를 필요로 할수도, 필요로 하지 않을 수도 있습니다만, 그런 메모리 배리어가 필요하다면, 그 메모리 배리어는 `dst_entry` 를 넘기는 메커니즘 내에 내장되어야 합니다.

`dst_release()` 함수는 어떤 환경에서도 호출될 수 있고, 호출자는 `dst_release()` 호출에 앞서 `dst_entry` 구조체의 원소들을 직접 참조할 수도 있습니다. 따라서 `dst_release()` 함수는 line 14에서 메모리 배리어를 포함해서 컴파일러나 CPU 가 접근 순서를 잘못 재배치하지 않도록 합니다.

`dst_clone()` 과 `dst_release()` 를 사용하는 프로그래머는 메모리 배리어에 대해서 신경쓸 필요가 없고, 단지 이 두개의 함수들의 사용규칙만을 알면 된다는 점을 알아 두시기 바랍니다.

13.2.1.4 Atomic Counting With Check and Release Memory Barrier

호출자가 현재는 레퍼런스를 가지고 있지 않은 오브젝트로의 레퍼런스를 획득해야만 하는 경우를 생각해 봅시다. 최초의 레퍼런스 카운트 획득은 레퍼런스 카운트 해제와 동시에 이뤄질 수 있다는 사실이 복잡도를 더욱 증가시킵니다. 레퍼런스 카운트 해제가 레퍼런스 카운트의 해제 후 값이 0이 되게 됨을 발견했고 그 레퍼런스에 연관된 오브젝트가 해제되어도 안전하다는 신호를 날렸다고 생각해 봅시다. 그런 해제작업이 개시된 후에 레퍼런스 카운트 획득을 허가할 수 있는 것은 분명하므로, 레퍼런스 획득은 레퍼런스 카운트가 0인지에 대한 검사를 포함해야만 합니다. 이런 검사는 다음에 보인 것과 같이 어토믹한 값 증가 오퍼레이션이 한 부분이 되어야만 합니다.

Quick Quiz 13.6: 레퍼런스 카운트의 값이 0인지에 대한 검사는 왜 간단히 어토믹 값 증가 오퍼레이션을 갖는 “if” 문의 “then” 절에 들어갈 수 없는거죠? ■

리눅스 커널의 `fget()` 과 `fput()` 기능들이 이런 스

Listing 13.4: Linux Kernel fget/fput API

```

1 struct file *fget(unsigned int fd)
2 {
3     struct file *file;
4     struct files_struct *files = current->files;
5
6     rCU_read_lock();
7     file = fcheck_files(files, fd);
8     if (file) {
9         if (!atomic_inc_not_zero(&file->f_count)) {
10             rCU_read_unlock();
11             return NULL;
12         }
13     }
14     rCU_read_unlock();
15     return file;
16 }
17
18 struct file *
19 fcheck_files(struct files_struct *files, unsigned int fd)
20 {
21     struct file * file = NULL;
22     struct fdtable *fdt = rCU_dereference((files)->fdt);
23
24     if (fd < fdt->max_fds)
25         file = rCU_dereference(fdt->fd[fd]);
26     return file;
27 }
28
29 void fput(struct file *file)
30 {
31     if (atomic_dec_and_test(&file->f_count))
32         call_rcu(&file->f_u.fu_rcuhead, file_free_rcu);
33 }
34
35 static void file_free_rcu(struct rcu_head *head)
36 {
37     struct file *f;
38
39     f = container_of(head, struct file, f_u.fu_rcuhead);
40     kmem_cache_free(filp_cachep, f);
41 }

```

타일의 레퍼런스 카운팅을 사용합니다. 이 함수들의 간단화된 버전이 Listing 13.4에 보여져 있습니다.

fget()의 Line 4는, 다른 프로세스들과 공유될 수도 있는 현재 프로세스의 file-descriptor 테이블을 가져옵니다. Line 6는 RCU read-side 크리티컬 섹션을 들어가는 rCU_read_lock()을 호출합니다. 뒤따르는 call_rcu()에 전달되는 콜백 함수의 수행은 매칭되는 rCU_read_unlock()이 호출될 때까지(이 경우 line 10 또는 14) 연기됩니다. Line 7은 fd 인자에 명시된 파일 디스크립터에 연관되는 file 구조체를 탐색하는데, 이에 대해서는 뒤에서 설명하겠습니다. 명시된 파일 디스크립터에 연관된 열린 파일이 존재한다면 line 9에서는 어토믹하게 레퍼런스 카운트를 획득하려 시도합니다. 만약 그렇게 하는데 실패한다면, line 10-11은 RCU read-side 크리티컬 섹션을 빠져나오고 실패했음을 알립니다. 그렇지 않고 시도가 성공했다면, line 14-15는 이 read-side 크리티컬 섹션을 빠져나오고 해당 file 구조체의 포인터를 리턴합니다.

fcheck_files() 기능은 fget()을 위한 도움을 주는 함수입니다. 해당 함수는 나중의 디레퍼런싱을 위해(이는 데이터 종속성이 메모리 순서 규칙을 강제하지

않는 DEC Alpha 와 같은 CPU 들에서는 메모리 배리어를 실행합니다) 안전하게 RCU로 보호되는 포인터를 가져오기 위해 사용됩니다. Line 22는 이 태스크의 현재 file-descriptor 테이블로의 포인터를 가져오기 위해 rCU_dereference()를 사용하고, line 24는 명시된 파일 디스크립터가 범위 안에 있는지 체크합니다. 만약 그렇다면 line 25는 해당 file 구조체로의 포인터를 가져오는데, 여기서도 rCU_dereference() 기능이 사용됩니다. 그리고나서 Line 26은 성공했다면 해당 file 구조체로의 포인터를 리턴하고, 실패했다면 NULL을 리턴하게 됩니다.

fput() 기능은 file 구조체로의 레퍼런스를 해제합니다. Line 31은 어토믹하게 레퍼런스 카운트를 감소시키고, 만약 그 감소 결과가 0이라면 line 32에서 해당 file 구조체를 모든 현재 수행중인 RCU read-side 크리티컬 섹션들이 완료된 후에 (call_rcu()의 두번째 인자로 전달되는 file_free_rcu()를 통해) 해제하기 위해 call_rcu() 기능을 실행시킵니다. 모든 현재 수행중인 RCU read-side 크리티컬 섹션들이 완료되기까지 필요한 시간은 “grace period”라고 불립니다. atomic_dec_and_test() 기능은 메모리 배리어를 포함하고 있음을 알아두시기 바랍니다. 이 메모리 배리어는 이 예제에서는 필요치 않은데, 이 구조체는 RCU read-side 크리티컬 섹션이 완료되기 전까지는 해제될 수 없기 때문입니다만 리눅스에서는 그 결과를 리턴하는 모든 어토믹 오퍼레이션들은 정의에 의해 메모리 배리어를 포함해야만 합니다.

일단 grace period 가 완료되면, file_free_rcu() 함수가 line 39에서 file 구조체로의 포인터를 가져오고 line 40에서 해제시킵니다.

이런 방법은 리눅스의 가장 메모리 시스템에서도 사용되는데, 페이지 구조체를 위해선 get_page_unless_zero()와 put_page_testzero()를, 메모리 맵 구조체를 위해서는 try_to_unuse()와 mmput()을 참고하시기 바랍니다.

13.2.2 Linux Primitives Supporting Reference Counting

앞의 예제들에서 사용된 리눅스 커널의 기능들이 다음의 리스트에 요약되어 있습니다.

atomic_t

어토믹하게 조정되는 32-bit 크기의 것을 위한 타입 정의.

void atomic_dec(atomic_t *var);

메모리 배리어를 요청하거나 컴파일러 최적화를 불능화시키지 않으며 참조된 변수의 값을 어토믹하게 감소.

```

int atomic_dec_and_test(atomic_t *var);
어토믹하게 참조된 변수의 값을 감소시키고 그 감
소 결과값이 0이라면 true (0 이 아닌 값) 을 리턴.
이 기능의 앞뒤로 메모리 참조가 옮겨가지 못하
도록 메모리 배리어와 컴파일러 최적화 불능화를
수행.

void atomic_inc(atomic_t *var);
메모리 배리어를 요청하거나 컴파일러 최적화를
불능화시키지 않으며 참조된 변수의 값을 어토믹
하게 증가.

int atomic_inc_not_zero(atomic_t *var);
참조된 변수의 값이 0이 아니라면 그 값을 어토믹
하게 증가시키고 값 증가가 수행되었다면 true (0
이 아닌 값) 을 리턴함. 이 기능의 앞뒤로 메모리
참조가 옮겨가지 못하도록 메모리 배리어와 컴파
일러 최적화 불능화를 수행.

int atomic_read(atomic_t *var);
참조된 변수의 정수 값을 리턴. 이는 어토믹 오퍼
레이션이어야 할 필요가 없고, 메모리 배리어 명
령어를 요청할 필요도 없음. “어토믹한 읽기” 라고
생각하기 보다는 “어토믹 변수로부터의 평범한 읽
기” 라고 생각할 것.

void atomic_set(atomic_t *var, int val);
참조된 어토믹 변수의 값을 “val” 로 설정. 이는
어토믹 오퍼레이션이어야 할 필요가 없으며, 메모
리 배리어나 컴파일러 최적화의 불능화를 수행할
필요도 없음. 이를 “어토믹한 값 설정”으로 생각하
기 보다는 “어토믹 변수에의 평범한 값 설정”으로
생각할 것.

void call_rcu(struct rcu_head *head, void
(*func)(struct rcu_head *head));
일부 시간이 지나서 현재 수행중인 RCU read-side
크리티컬 섹션들이 완료된 후에 func(head) 를
수행하되 call_rcu() 기능 자체는 즉시 리턴함.
head 는 일반적으로 RCU 로 보호되는 데이터
구조체이고, func 는 일반적으로 이 데이터 구조
체를 메모리에서 해제시키는 함수임을 알아둘 것.
call_rcu() 의 호출과 func 호출 사이의 시간
간격은 “grace period” 라 불리움. Grace period 를
포함하는 모든 시간 간격은 그 자체로 grace period
임.

type *container_of(p, type, f);
명시된 타입의 구조체의 필드 f 로의 포인터 p 를
받고 해당 구조체로의 포인터를 리턴.

void rcu_read_lock(void);
RCU read-side 크리티컬 섹션의 시작을 표시.

```

void rcu_read_unlock(void);
RCU read-side 크리티컬 섹션의 종료를 표시. RCU
read-side 크리티컬 섹션은 중첩될 수 있음.

void smp_mb_before_atomic_dec(void);
해당 플랫폼의 atomic_dec() 기능이 그러지 않
는다면 코드를 움직일 수 있는 컴파일러 최적화의
불능화와 메모리 배리어를 요청.

struct rcu_head
Grace period 를 기다리는 오브젝트들을 추적하기
위해 RCU 설비에서 사용되는 데이터 구조체. 일
반적으로 RCU 로 보호되는 데이터 구조체 내에
하나의 필드로 포함되어 있음.

Quick Quiz 13.7: 어토믹하지 않은 atomic_read()
와 atomic_set() 이라구요? 이건 또 무슨 농담이죠???

■

13.2.3 Counter Optimizations

카운터 증가와 감소가 흔하게 일어나지만 카운터 값이
0인지에 대한 검사는 가끔만 이뤄지는 일부 경우들에 있
어서는, Chapter 5 에서 이야기한 것처럼 per-CPU 또는
per-task 카운터들을 두는게 말이 될겁니다. 이런 테크
닉이 RCU 에 적용된 예를 보기 위해 sleepable read-copy
update (SRCU) 에 대한 논문 [McK06b] 을 참고하세요.
이 방법은 카운터 값 증가와 감소 기능들에서의 어토믹
명령어나 메모리 배리어의 사용의 필요를 없애줍니다
만, 코드의 위치를 움직이는 컴파일러 최적화의 제거는
여전히 필요합니다. 또한, 합산된 레퍼런스 카운트가
0이 되었는지를 체크하게 되는 synchronize_srcu()
와 같은 기능들은 상당히 느려집니다. 이는 이런 테크
닉들은 레퍼런스들이 빈번히 획득되고 해제되지만 레
퍼런스 카운트가 0이 되었는지에 대한 검사는 가끔만
일어나는 상황을 위해서 설계된 것이란 점을 강조합니
다.

하지만, 레퍼런스 카운트가 사용되지 않았다면 읽기
전용이었을 수 있는 데이터 구조에 레퍼런스 카운트의
사용은 (대부분의 경우 어토믹한) 쓰기를 필요로 한다
는 점이 문제인 경우가 많습니다. 이런 경우, 레퍼런스
카운트는 읽기를 하는 쓰레드들에게 비싼 캐시 미스를
부과합니다.

따라서 읽기를 하는 쓰레드들이 횡단하게 되는 데
이터 구조체에 쓰기를 하지 않아도 되게 하는 동기화
메커니즘들을 찾아볼 가치가 있습니다. 그런 것들 중 하
나는 Section 9.3 에서 다룬 해저드 포인터이고, 또 다른
하나는 Section 9.5 에서 다룬 RCU 입니다.

13.3 RCU Rescues

이 섹션은 이 책의 앞부분에서 이야기한 몇 가지 예제들에 RCU 를 어떻게 적용하는지를 보입니다. 일부 경우들에 있어서는 RCU 는 간단한 코드를 제공하고, 어떤 경우에는 더 나은 성능과 확장성을 제공하며, 또 다른 경우에는 두 가지를 모두 제공합니다.

13.3.1 RCU and Per-Thread-Variable-Based Statistical Counters

Section 5.2.4 는 대략적으로 평범한 값 증가 연산 (C++ 오퍼레이터) 과 같은—하지만 `inc_count()` 를 통해서만 값을 증가시키는—훌륭한 성능과 선형적 확장성을 보이는 통계적 카운터들의 구현을 설명했습니다. 불행히도, `read_count()` 를 통해 값을 읽어와야 하는 쓰레드들은 글로벌 락을 잡아야만 했고, 따라서 높은 오버헤드를 일으키고 낮은 확장성으로 고통받아야 합니다. 락 기반의 구현 코드는 Page 49 의 Listing 5.5 에 보여져 있습니다.

Quick Quiz 13.8: 대체 왜 그런 글로벌 락이 필요했던 거지요? ■

13.3.1.1 Design

원하는건 `inc_count()` 만이 아니라 `read_count()` 에서도 훌륭한 성능과 확장성을 얻기 위해 `read_count()` 의 쓰레드 횟단을 보호하는 데에 `final_mutex` 대신에 RCU 를 사용하는 것입니다. 하지만, 계산된 합계의 정확성을 포기하지도 않고 싶습니다. 자세히 말하자면, 특정 스레드가 종료될 때에, 우린 종료되는 쓰레드의 카운트를 읽어버릴 수도, 그걸 두번씩 세서도 안됩니다. 그런 에러는 결과의 전체 정확성과 동일한 정도의 비정확성을 초래할 수 있는데, 달리 말하자면 그런 에러는 결과값이 완전히 쓸모없게 만들 수 있습니다. 그리고 사실, `final_mutex` 의 목적들 중 하나는 쓰레드들이 `read_count()` 의 실행 사이에 들어왔다 나갔다 하지 않음을 분명히 하는 것입니다.

Quick Quiz 13.9: 어쨌든, `read_count()` 의 정확성을 대체 뭔가요? ■

따라서, 우리가 `final_mutex` 를 없애려 한다면, 우리는 일관성을 보장하기 위한 어떤 다른 방법을 사용해야 합니다. 한 가지 방법은 앞서 종료된 쓰레드들 전체를 위한 전체 카운트와 쓰레드별 카운터로의 포인터들의 배열을 하나의 구조체에 넣는 것입니다. `read_count()` 에 의해 접근될 수 있는 그런 구조체는 상수가 되므로, `read_count()` 가 일관적인 데이터를 보게 될 것을 보장합니다.

13.3.1.2 Implementation

Listing 13.5 의 line 1-4 는 `countarray` 구조체를 보이고 있는데, 이 구조체는 앞서 종료된 쓰레드들의 카운트를 위한 `->total` 필드와 현재 돌아가고 있는 각각의 쓰레드를 위한 per-thread counter 로의 포인터들의 배열인 `counterp[]` 를 갖습니다. 이 구조체는 `read_count()` 의 한 수행이 수행중인 쓰레드의 알려진 집합과 일관적인 전체값을 볼 수 있도록 합니다.

Line 6-8 은 per-thread counter 변수, 현재의 `countarray` 구조체를 가리키는 `countarrayp` 글로벌 포인터, 그리고 `final_mutex` 스피너의 정의를 담고 있습니다.

Line 10-13 은 Listing 5.5 로부터 달라지지 않은 `inc_count()` 를 보입니다.

Line 15-29 는 상당히 많이 바뀐 `read_count()` 를 보입니다. Line 21 과 27 은 `rcu_read_lock()` 과 `rcu_read_unlock()` 으로 `final_mutex` 의 획득과 해제를 대신합니다. Line 22 는 현재의 `countarray` 구조체를 로컬 변수 `cap` 으로 스냅샷을 뜨기 위해 `rcu_dereference()` 를 사용합니다. RCU 가 올바르게 사용된다면 이 `countarray` 구조체가 적어도 line 27 에서의 현재 RCU read-side 크리티컬 섹션의 종료까지는 유지될 것이 보장될 겁니다. Line 23 은 `sum` 을 `cap->total` 로 초기화 시키는데, 이는 앞서 종료된 쓰레드들의 카운트의 합입니다. Line 24-26 은 현재 수행중인 쓰레드들과 연관되어 있는 per-thread 카운터들을 합하고, 마지막으로 line 28 은 그 합을 리턴합니다.

`countarrayp` 의 초기값은 line 31-39 의 `count_init()` 에 의해 주어집니다. 이 함수는 첫번째 쓰레드가 생성되기 전에 수행되는데, 이 함수의 일은 초기의 구조체를 할당하고 그 값을 0 으로 세팅한 후에 `countarrayp` 를 할당하는 것입니다.

Line 41-48 은 `count_register_thread()` 함수를 보이는데, 이 함수는 각 쓰레드가 새로이 생성될 때마다 호출됩니다. Line 43 은 현재 쓰레드의 인덱스를 가져오고, line 45 는 `final_mutex` 를 획득하며, line 46 은 이 쓰레드의 `counter` 로의 포인터를 설치하며, line 47 에서 `final_mutex` 를 놓습니다.

Quick Quiz 13.10: 이봐요!!! Listing 13.5 의 line 46 은 앞서 존재한 `countarray` 구조체의 값을 수정하잖아요! 이 구조체는 일단 한번 `read_count()` 에 접근 가능하게 되면 상수로 남게 된다고 하지 않았어요???

Line 50-70 은 각 쓰레드가 종료하기 직전에 실행되는 `count_unregister_thread()` 를 보입니다. Line 56-60 은 새로운 `countarray` 구조체를 할당하고, line 61 에서 `final_mutex` 를 획득하며 line 67 에서 이를 해제합니다. Line 62 는 현재 `countarray` 의 내용을 새로 할당된 버전에 복사하고, line 63 은 종료되는 쓰레드의 `counter` 를 새로운 구조체의 `->total` 에 더하

Listing 13.5: RCU and Per-Thread Statistical Counters

```

1 struct countarray {
2     unsigned long total;
3     unsigned long *counterp[NR_THREADS];
4 };
5
6 long __thread counter = 0;
7 struct countarray *countarrayp = NULL;
8 DEFINE_SPINLOCK(final_mutex);
9
10 void inc_count(void)
11 {
12     counter++;
13 }
14
15 long read_count(void)
16 {
17     struct countarray *cap;
18     unsigned long sum;
19     int t;
20
21     rCU_read_lock();
22     cap = rCU_dereference(countarrayp);
23     sum = cap->total;
24     for_each_thread(t)
25         if (cap->counterp[t] != NULL)
26             sum += *cap->counterp[t];
27     rCU_read_unlock();
28     return sum;
29 }
30
31 void count_init(void)
32 {
33     countarrayp = malloc(sizeof(*countarrayp));
34     if (countarrayp == NULL) {
35         fprintf(stderr, "Out of memory\n");
36         exit(-1);
37     }
38     memset(countarrayp, '\0', sizeof(*countarrayp));
39 }
40
41 void count_register_thread(void)
42 {
43     int idx = smp_thread_id();
44
45     spin_lock(&final_mutex);
46     countarrayp->counterp[idx] = &counter;
47     spin_unlock(&final_mutex);
48 }
49
50 void count_unregister_thread(int nthreadsexpected)
51 {
52     struct countarray *cap;
53     struct countarray *capold;
54     int idx = smp_thread_id();
55
56     cap = malloc(sizeof(*countarrayp));
57     if (cap == NULL) {
58         fprintf(stderr, "Out of memory\n");
59         exit(-1);
60     }
61     spin_lock(&final_mutex);
62     *cap = *countarrayp;
63     cap->total += counter;
64     cap->counterp[idx] = NULL;
65     capold = countarrayp;
66     rCU_assign_pointer(countarrayp, cap);
67     spin_unlock(&final_mutex);
68     synchronize_rcu();
69     free(capold);
70 }

```

고, line 66 은 countarray 구조체의 새로운 버전을 설치하는데에 rCU_assign_pointer() 를 사용합니다. Line 68 은 동시적으로 read_count() 를 수행하고 있을 수 있는, 따라서 기존의 countarray 구조체로의 레퍼런스를 가지고 있을 수 있는 모든 쓰레드가 이들의 RCU read-side 크리티컬 섹션을 종료해서 그런 레퍼런스를 모두 버려버리도록 grace period 가 하나 지나가길 기다립니다. 그리고 나서 line 69 는 이제 기존의 countarray 구조체를 안전하게 해제시킬 수 있습니다.

13.3.1.3 Discussion

Quick Quiz 13.11: 우와! Listing 5.5 는 라인수가 42 밖에 되지 않는데 반해 Listing 13.5 는 69 라인이나 되는군요. 이 추가적인 복잡도가 정말로 가치가 있는 건가요? ■

RCU 의 사용은 종료되는 쓰레드가 다른 쓰레드들이 이 종료되는 쓰레드들의 __thread 변수들을 사용하는 것을 마칠 때까지 기다릴 수 있도록 해줍니다. 이는 read_count() 함수가 락킹을 필요 없게 해서 inc_count() 와 read_count() 함수들 다에 훌륭한 성능과 확장성을 제공합니다. 하지만, 이 성능과 확장성은 약간의 코드 복잡도의 증가를 비용으로 지불합니다. 컴파일러와 라이브러리를 작성하는 사람들이 안전한 쓰레드 간 __thread 변수들로의 접근을 제공하기 위해 유저 레벨 RCU [Des09b] 를 제공해서 __thread 변수들의 사용자간에 보여지게 되는 복잡도를 줄일 수 있게 된다면 좋을 겁니다.

13.3.2 RCU and Counters for Removable I/O Devices

Section 5.4.6 는 제거 가능한 디바이스들로의 I/O 액세스의 카운팅을 다루는 한쌍의 코드 조각을 보였습니다. 이 코드 조각들은 reader-writer 락을 잡아야 하는 필요로 인해 빠른 수행 경로 (I/O 를 시작하는 것) 에서의 높은 오버헤드로 힘들어했습니다.

이 섹션은 RCU 가 이 오버헤드를 어떻게 없앨 수 있는지 보입니다.

I/O 를 수행하는 코드는 원래의 것과 상당히 유사한데, RCU read-side 크리티컬 섹션이 원래 것의 reader-writer 락의 read-side 크리티컬 섹션을 대체합니다:

Listing 13.6: RCU-Protected Variable-Length Array

```

1 struct foo {
2     int length;
3     char *a;
4 };

```

```

1 rCU_read_lock();
2 if (removing) {
3     rCU_read_unlock();
4     cancel_io();
5 } else {
6     add_count(1);
7     rCU_read_unlock();
8     do_io();
9     sub_count(1);
10 }

```

RCU read-side 기능들은 최소한의 오버헤드만을 가지고 있으므로, 원했던대로 빠른 수행 경로의 속도를 높입니다.

디바이스 제거 부분의 업데이트된 코드 조각은 다음과 같습니다:

```

1 spin_lock(&mylock);
2 removing = 1;
3 sub_count(mybias);
4 spin_unlock(&mylock);
5 synchronize_rcu();
6 while (read_count() != 0) {
7     poll(NULL, 0, 1);
8 }
9 remove_device();

```

여기서 우린 reader-writer 락을 배타적 스피너로 바꾸고 모든 RCU read-side 크리티컬 섹션들이 완료되길 기다리기 위해 `synchronize_rcu()`를 추가했습니다. `synchronize_rcu()` 때문에, 일단 우리가 line 6에 도달한다면, 우린 모든 남아있는 I/O 들이 처리되었음을 알 수 있습니다.

물론, `synchronize_rcu()`의 오버헤드는 클 수 있습니다만, 디바이스의 제거는 상당히 드문 일임을 고려한다면 이는 괜찮은 트레이드오프입니다.

13.3.3 Array and Length

Listing 13.6에 보인 것과 같이 RCU로 보호되는 가변길이의 배열을 가지고 있다고 생각해 봅시다. 배열 `->a[]`의 길이는 동적으로 언제든 변할 수 있고, 그 길이는 `->length`를 통해 제공됩니다. 물론, 이는 다음과 같은 경주 조건을 만들어냅니다:

1. 배열의 길이가 초기에는 16 character 만큼의 길이이고, 따라서 `->length`는 16의 값을 갖습니다.

Listing 13.7: Improved RCU-Protected Variable-Length Array

```

1 struct foo_a {
2     int length;
3     char a[0];
4 };
5
6 struct foo {
7     struct foo_a *fa;
8 };

```

2. CPU 0 가 `->length`의 값을 읽어와서 16을 얻게 됩니다.
3. CPU 1 이 이 배열의 길이를 8로 줄이게 되고, 메모리의 8-character 블록 구간으로의 포인터를 `->a[]`에 할당합니다.
4. CPU 0 가 `->a[]`의 새로운 포인터를 가져오고, 그 12번째 원소에 새로운 값을 저장합니다. 이 배열은 8 개 character 만을 가지고 있으므로, 이는 SEGV 또는 (더 나쁜 경우인) 메모리 오염을 초래하게 됩니다.

이를 어떻게 막을 수 있을까요?

한가지 방법은 Chapter 15에서 소개된 메모리 배리어를 조심스럽게 사용하는 것입니다. 이는 제대로 동작합니다만, 읽는 쪽의 오버헤드를 초래하고, 아마도 더 나쁠 수도 있게도, 명시적인 메모리 배리어의 사용을 필요로 합니다.

더 나은 전략은 Listing 13.7에 보인 것과 같이 해당 배열과 값을 같은 구조체에 놓는 것입니다. 이제 새로운 배열 (`foo_a` 구조체)를 할당하는 일은 자동으로 배열 공간을 위한 새로운 공간을 제공합니다. 이는 어떤 CPU가 `->fa`로의 레퍼런스를 가져가면 `->length`는 `->a[]`의 길이와 들어맞을 것임을 보장합니다.

1. 배열의 길이가 초기에는 16 character 길이이고, 따라서 `->length`는 16의 값을 갖습니다.
2. CPU 0 이 `->fa`의 값을 읽어오게 되어서 값 16과 16-byte 배열을 담고 있는 구조체를 가져오게 됩니다.
3. CPU 0 가 `->fa->length`의 값을 읽어와서 16이라는 값을 얻게 됩니다.
4. CPU 1 이 배열의 길이를 8로 줄이고, 메모리의 8-character 블록 구간을 포함하는, 새로운 `foo_a` 구조체로의 포인터를 `->fa`에 할당합니다.
5. CPU 0 이 `->a[]`로부터 새로운 포인터를 가져가고 새로운 값을 12번째 원소에 저장합니다. 하지만 CPU 0 는 여전히 16-byte 배열을 담고 있는 기존의 `foo_a` 를 레퍼런스하고 있으므로, 모두 문제 없습니다.

Listing 13.8: Uncorrelated Measurement Fields

```

1 struct animal {
2     char name[40];
3     double age;
4     double meas_1;
5     double meas_2;
6     double meas_3;
7     char photo[0]; /* large bitmap. */
8 };

```

Listing 13.9: Correlated Measurement Fields

```

1 struct measurement {
2     double meas_1;
3     double meas_2;
4     double meas_3;
5 };
6
7 struct animal {
8     char name[40];
9     double age;
10    struct measurement *mp;
11    char photo[0]; /* large bitmap. */
12 };

```

물론, 두 경우 모두, CPU 1 은 기존의 배열을 메모리에서 해제하기 전에 하나의 grace period 를 기다려야만 합니다.

이 방법의 더 일반적인 버전이 다음 섹션에서 제공됩니다.

13.3.4 Correlated Fields

각각의 Schrödinger 의 동물들이 Listing 13.8 에 보여진 데이터 원소로 표현된다고 생각해 봅시다. `meas_1`, `meas_2`, 그리고 `meas_3` 필드는 주기적으로 업데이트되는 연관된 측정치의 집합입니다. 읽기를 하는 쓰레드들은 이 세개의 값들을 하나의 측정치 업데이트로부터 본다는 점이 특히 중요합니다: 만약 한 읽기 쓰레드가 `meas_1` 의 예전 값을 읽지만 `meas_2` 와 `meas_3` 의 새로운 값을 읽게 되다면, 그 읽기 쓰레드는 완전히 혼란에 빠질 겁니다. 읽기 쓰레드들이 이 세개의 값들의 통합된 집합을 볼 수 있도록 보장하려면 어떻게 해야 할까요?

한가지 방법은 새로운 `animal` 구조체를 할당하고, 기존 구조체를 새로운 구조체로 복사하고, 새로운 구조체의 `meas_1`, `meas_2`, 그리고 `meas_3` 필드들을 업데이트 한 후, 기존의 구조체를 새로운 구조체로 포인터를 업데이트하는 방법으로 교체하는 것입니다. 이는 모든 읽기 쓰레드들이 측정 값들의 통합된 집합을 볼 수 있을 것을 보장합니다만, 이는 `->photo[]` 필드 때문에 커다란 구조체의 복사를 필요로하게 됩니다. 이 복사 작업은 받아들일 수 없을 만큼 커다란 오버헤드를 일으킬 수 있습니다.

또 다른 방법은 하나의 간접적 단계를 추가하는 것으로, Listing 13.9 보여진 것과 같습니다. 새로운 측정이 취해진다면, 새로운 `measurement` 구조체를 할당하고,

이를 새로운 측정치로 채우고, `animal` 구조체의 `->mp` 필드가 이 새로운 `measurement` 구조체의 포인터를 가리키도록 `rcu_assign_pointer()` 를 사용해서 업데이트하는 것입니다. 하나의 grace period 가 지나간 후에, 기존의 `measurement` 구조체는 메모리에서 해제될 수 있습니다.

Quick Quiz 13.12: 하지만 Listing 13.9 에 보인 방법은 추가적인 캐시 미스를 초래할 수 있어서, 추가적인 읽기 쪽의 오버헤드를 초래할 수 있지 않나요? ■

이 방법은 읽기 쓰레드들이 선택된 필드들에 대해 연관된 값들을 최소한의 읽기 쪽 오버헤드만을 가지고 볼 수 있도록 해줍니다.

13.4 Hashing Hassles

이 섹션은 해시 테이블을 다룰 때에 나타날 수 있는 몇 가지 문제들을 알아봅니다. 이런 문제들은 많은 다른 탐색을 하는 구조체들에서도 역시 나타날 수 있음을 알아 두시기 바랍니다.

13.4.1 Correlated Data Elements

이 상황은 Section 13.3.4 에서의 것과 비슷합니다: 우린 두개 이상의 원소들의 연관된 시야를 필요로 하는 해시 테이블을 가지고 있습니다. 이 원소들은 함께 업데이트 되고, 첫번째 원소의 기존 버전과 함께 다른 원소들의 새로운 버전을 보지는 않고 싶습니다. 예를 들어, Schrödinger 는 그의 in-memory 데이터베이스에 그의 모든 동물들에 가족을 추가시키려 합니다. Schrödinger 는 결혼과 이혼이 순간적으로 일어나지는 않음을 알고 있지만, 그는 전통주의자이기도 합니다. 이와 같이, 그는 그의 데이터베이스가 신부는 이제 결혼했지만, 신랑은 그렇지 않은 경우, 또는 그 반대의 경우를 원하지 않습니다. 달리 말하자면, Schrödinger 는 그의 데이터베이스에 `wedlock` (역자 주: 결혼에 관련된 락) 에 일관적인 데이터 열람이 가능하기를 원합니다.

한가지 방법은 시퀀스 락 (Section 9.4 를 참고하세요) 을 사용해서 `wedlock` 에 관계된 `update` 들이 `write_seqlock()` 의 보호 아래 행해지도록 하고, `wedlock` 일관성을 필요로 하는 `read` 들은 `read_seqbegin()` / `read_seqretry()` 루프 아래 행해지도록 하는 겁니다. 시퀀스 락들은 RCU 보호의 대체품이 안미을 알아두시기 바랍니다: 시퀀스 락은 동시적인 수정들에 대해 데이터를 보호하지만, 동시적인 삭제들로부터 데이터를 보호하기 위해선 RCU 가 여전히 필요합니다.

이 방법은 연관된 원소들의 갯수가 작고, 이 원소들을 읽는 시간이 짧으며, 업데이트 되는 빈도가 적을 때 상당히 잘 동작합니다. 그렇지 않다면, 업데이트들은 읽기 쓰레드들이 결코 완료될 수 없을 정도로 업데이트들이

자주 일어날 수도 있을 겁니다. Schrödiger 는 그의 가장 덜 정상적인 동물들이라 해도 이런 문제가 생길 수 있을 정도로 빠르게 결혼과 이혼을 행하지는 않을 것으로 예상한다고 해도, 그는 이 문제가 다른 상황에서도 역시 일어날 수 있음을 깨닫고 있습니다. 이 읽기 쓰레드 starvation 문제를 없애는 한가지 방법은 읽기 쓰레드들이 너무 많은 재시도를 행하게 된다면 update-side 기능들을 사용하는 것입니다만, 이는 성능과 확장성을 떨어뜨릴 수 있습니다.

또한, 만약 update-side 기능들이 너무 자주 사용된다면, 락 경쟁으로 인해 낮은 성능과 확장성이 초래될 것입니다. 이를 막을 수 있는 한가지 방법은 per-element 시퀀스 락을 두고, 결혼 상태를 업데이트 할 때 두 배우자의 락을 모두 잡도록 하는 것입니다. 읽기 쓰레드들은 두 멤버에 연관된 결혼 상태의 모든 변경사항에 대한 안정적인 시야를 얻기 위해 두 배우자들의 락들에 대해 재시도 루프를 행할 수 있습니다. 이는 높은 결혼과 이혼 빈도에 의한 경쟁을 없앨 수 있습니다만, 데이터베이스에 대한 한번의 스캔 동안의 모든 결혼 상태들에 대한 안정적인 시야를 얻는 과정이 복잡해집니다.

원소 그룹짓기가 결혼 상태가 그렇기를 바라듯이 잘 정의되어 있고 영속적이라면, 데이터 원소에 주어진 그룹의 멤버들로의 링크를 가리키는 포인터를 추가하는 것도 한가지 방법입니다. 그렇게 되면 읽기 쓰레드들은 첫번째 멤버와 같은 그룹의 모든 데이터 원소들에 접근하기 위해서 이 포인터들을 따라가면 됩니다.

버전 넘버를 사용하는 다른 방법은 흥미있는 독자들을 위한 둑으로 남겨두겠습니다.

우아하게 지원합니다.

Quick Quiz 13.13: 하지만 이 스캐닝은 크기 재조정이 되고 있는 크기 재조정 가능한 해시 테이블에 대해서는 어떻게 동작하나요? 그런 경우, 기존의 해시 테이블도 새로운 해시 테이블도 해당 해시 테이블에 모든 원소들을 담고 있다고 보장될 수 없는데요! ■

13.4.2 Update-Friendly Hash-Table Traversal

해시 테이블의 모든 원소들에 대한 통계적 스캐닝이 필요하다고 생각해 봅시다. 예를 들어, Schrödinger 는 모든 동물들에 대해 평균적인 신장 대비 체중 비율을 구하고 싶어할 수 있습니다.² 더 나아가서 Schrödinger 가 이 통계를 위한 스캐닝이 진행되는 사이에 이 해시 테이블에 추가되고 삭제된 동물들로 인한 작은 에러 정도는 무시하고자 한다고 생각해 봅시다. Schrödinger 는 동시성을 제어하기 위해 무엇을 해야 할까요?

한가지 방법은 통계를 위한 스캐닝을 RCU read-side 크리티컬 섹션으로 감싸는 것입니다. 이는 업데이트들이 스캐닝에 과도하게 훼방을 놓지 않으면서 동시적으로 진행되는 것을 가능하게 합니다. 특히, 이 스캐닝은 업데이트를 가로막지 않고 그 반대 역시 마찬가지여서, 설령 매우 높은 업데이트 빈도가 있다 해도 매우 많은 양의 원소들을 담고 있는 해시 테이블들에 대한 스캐닝을

² 왜 그런 숫자가 필요하죠? 절 때리세요! 하지만 일반적인 그룹 통계는 유용한 경우가 많습니다.

Chapter 14

If a little knowledge is a dangerous thing, just imagine all the havoc you could wreak with a lot of knowledge!

Unknown

Advanced Synchronization

이 챕터는 고급 동기화의 두 카테고리, lockless 와 real-time 동기화에 대해 다룹니다.

Lockless 동기화는 극단적인 요구사항에 직면했을 때 상당히 도움될 수 있습니다만, 슬프게도, lockless 동기화는 만능해결책은 아닙니다. 예를 들어, Lockless 동기화를 생각하기 전에, Chapter 5 의 마지막에서 언급했듯, 여러분은 충분히 partitioning, batching, 그리고 잘 테스트되고 패키지화 된 완화된 API 들 (Chapter 8 와 9 를 참고하세요) 을 충분히 적용해야 합니다.

하지만 그걸 모두 한 뒤에도, 여러분은 이 챕터에서 이야기한 고급 기법들을 필요로 하고 있을 수도 있습니다. 따라서, Section 14.1 은 락들을 피하기 위해 사용되어온 기법들을 요약하고 Section 14.2 에서는 non-blocking 동기화의 간략한 개괄을 제공합니다. 메모리 순서 규칙은 상당히 중요하지만, 하나의 챕터, Chapter 15 를 필요로 할만큼 큰 분량입니다.

고급 동기화의 두번째 형태는 더 강력한 작업 진행 보장을 제공하는데 이는 병렬 real-time computing 에 필요한 것입니다. 따라서 real-time 동기화는 Section 14.3 의 주제입니다.

14.1 Avoiding Locks

락킹은 제품화 레벨의 병렬성에서 매우 많이 사용되는 방법이지만, 많은 상황에서 락을 사용하지 않는 (lockless) 테크닉을 사용하는 것으로 성능, 확장성, 그리고 실시간 반응성을 모두 크게 개선시킬 수 있습니다. 그런 lockless 테크닉의 한 예는 Section 5.2 에서 보인, 카운터 증가에 락은 물론 어토믹 오퍼레이션, 메모리 배리어, 그리고 심지어 캐시 미스 까지 없었던 통계적 카운터가 될 수 있을 것입니다. 그 외에 우리가 다뤘던 예들은 다음과 같습니다:

1. Chapter 5 에서 다른 다른 카운팅 알고리즘들의 빠른 수행 경로들.

2. Section 6.4.3 의 리소스 얼로케이터 캐시들의 빠른 수행 경로.
3. Section 6.5 의 미로 풀기 알고리즘.
4. Chapter 8 에서 설명한 데이터 소유권 (Data Ownership) 테크닉.
5. Chapter 9 에서 설명한 레퍼런스 카운팅과 RCU 테크닉들.
6. Chapter 10 에서 설명한 루업 코드 경로.
7. Chapter 13 에서 설명한 많은 테크닉들.

한마디로, lockless 테크닉들은 상당히 유용하고 많이 사용되고 있습니다.

하지만, lockless 테크닉들은 `inc_count()`, `memblock_alloc()`, `rcu_read_lock()` 등과 같은 잘 정의된 API 뒤에 숨겨져 있는게 제일 좋습니다. 과한 lockless 테크닉들의 사용은 어려운 버그를 만들어내기 쉽기 때문입니다. 그런 버그들을 생기지 않게 하는게 그것들을 찾아내고 고치는 것보다 쉽다는 것을 믿지 않는다면, Chapter 11 와 12 를 다시 한번 읽어보시기 바랍니다.

많은 lockless 테크닉들의 핵심 요소는 다음 섹션에서 설명할 메모리 배리어입니다.

14.2 Non-Blocking Synchronization

non-blocking synchronization (NBS) 라는 용어는 진행 보장사항 (*forward-progress guarantee*) 들을 달리 하는, 7개의 linearizable 알고리즘 클래스들을 말합니다. 이 진행 보장사항 들은 리얼타임 프로그래밍 (Real-time programming) 의 근간을 형성하는 그것들과는 직교적입니다:

- 리얼타임 진행 보장사항들은 그것들과 관련된 분명한 시간을 갖는데, 예를 들어, “스케줄링 대기시간은 100 마이크로세컨드 보다 작아야 한다.” 같은 것입니다. 반면, 가장 인기 있는 형태의 NBS는 분명한 최대 제한 없이 유한한 시간 내에 진행이 이뤄질 것만을 보장합니다.
- 리얼타임 진행 보장사항들은 간혹 확률적인데, 소프트 리얼타임 보장사항은 “최소 99.9%의 경우 스케줄링 대기시간은 100 마이크로세컨드 이내여야 한다.” 와 같은 식입니다. 반면, NBS의 진행 보장사항은 전통적으로 무조건적입니다.
- 리얼타임 진행 보장사항은 종종 환경 제약에 조건적인데, 예를 들어, 각 CPU가 최소한 어떤 특정한 양의 시간을 아무일도 하지 않고 보내거나, I/O의 비율이 특정 최대치 미만인 경우 가장 높은 우선순위의 작업들만이 그 보장을 받게 됩니다. 반면, NBS의 진행 보장사항은 보통 무조건적입니다.¹
- 리얼타임 진행 보장사항은 보통 소프트웨어 버그가 없을 때에만 적용됩니다. 반면, 대부분의 NBS 보장사항은 멈춰버리는 버그가 있더라도 적용 가능합니다.²
- NBS 진행 보장사항은 linearizability를 내포합니다. 반면, 리얼타임 진행 보장사항은 linearizability와 같은 순서 제약과 무관합니다.

이런 차이에도 불구하고, 여러 NBS 알고리즘들은 리얼타임 프로그램에 상당히 유용합니다.

현재 NBS 계층 [ACHS13]에는 7개의 단계가 있는데, 간략히 설명하자면 다음과 같습니다:

- Bounded wait-free synchronization*: 모든 쓰레드는 특정한 유한한 시간 내에 진행을 만들어낸다 [Her91]. (이 레벨은 대부분의 사람들로부터 불가능할 것으로 여겨지는데, Alitarh 등 [ACHS13]이 해내지 못한 이유일 수도 있습니다.)
- Wait-free synchronization*: 모든 쓰레드는 유한한 시간 내에 진행을 만들어낸다 [Her93].
- Lock-free synchronization*: 최소한 한 쓰레드는 유한한 시간 내에 진행을 만들어낸다 [Her93].
- Obstruction-free synchronization*: 경쟁이 없다면 모든 쓰레드가 유한한 시간 내에 진행을 만들어낸다 [HLM03].

¹ 아래에서 보게 되겠지만, 최근의 일부 NBS는 이 보장사항을 완화시켰습니다.

² 다시 말하지만, 최근의 일부 NBS는 이 보장사항을 완화했습니다.

- Clash-free synchronization*: 경쟁이 없다면 최소한 하나의 쓰레드는 유한한 시간 내에 진행을 만들어낸다 [ACHS13].
- Starvation-free synchronization*: 실패가 없다면 모든 쓰레드가 유한한 시간 내에 진행을 만들어낸다 [ACHS13].
- Deadlock-free synchronization*: 실패가 없다면 적어도 하나의 쓰레드는 유한한 시간 내에 진행을 만들어낸다 [ACHS13].

NBS 클래스 1, 2 그리고 3은 1990년대 초, 클래스 4는 2000년대 초, 그리고 클래스 5는 2013년에 처음 입안되었습니다. 마지막 두개의 클래스들은 수십년동안 비공식적으로 사용되어왔습니다만 2013년에 들어 다시 입안되었습니다.

이론적으로는 어떤 병렬 알고리즘도 wait-free 형태로 변형될 수 있습니다만, 흔히 사용되는 NBS 알고리즘들의 부분집합은 상대적으로 작은 편입니다. 이것들 중 일부가 다음 섹션에서 설명됩니다.

14.2.1 Simple NBS

아마도 가장 단순한 NBS 알고리즘은 fetch-and-add(`atomic_add_return()`) 기능을 이용한 정수 카운터의 어토믹한 업데이트일 것입니다.

또 다른 간단한 NBS 알고리즘은 한 배열 안의 정수들의 집합입니다. 여기서 배열 인덱스는 해당 집합의 멤버일 값을 가리키고 배열의 원소들은 해당 값이 실제로 집합의 멤버인지 아닌지를 알립니다. NBS 알고리즘을 위한 Linearizability 규범은 이 배열에의 읽기와 쓰기가 어토믹 인스트럭션을 사용하거나 메모리 배리어를 수반할 것을 요구합니다만 linearizability가 그다지 중요하지 않은, 그렇게 희귀하지도 않은 경우들에서는 간단한 volatile 로드와 스토어만으로도 충분한데, `ACCESS_ONCE()`의 사용이 한 예일 것입니다.

NBS 집합은 비트맵을 이용해 구현될 수도 있을 텐데, 해당 집합의 멤버인 값은 하나의 비트와 연관될 것입니다. 읽기와 업데이트는 일반적으로 어토믹한 비트 조작 인스트럭션들로 이루어져야만 합니다만 compare-and-swap (`cmpxchg()` 또는 CAS) 인스트럭션 또한 사용될 수 있습니다.

Section 5.2에서 이야기 되었던 통계적 카운터 알고리즘은 그 합이 정확하지는 않고 대략적이라는 분명한 트릭을 사용할 때라면 wait-free로 간주될 수 있습니다.³ `read_count()` 함수가 카운터들의 합을 구하는데 갖는 시간의 길이의 기능인 충분히 큰 여러 한계들을

³ 인용이 필요합니다. 전 이 트릭을 Mark Moir로부터 구두로 들었습니다.

Listing 14.1: NBS Enqueue Algorithm

```

1 static inline bool
2 __cds_wfcq_append(struct cds_wfcq_head *head,
3                     struct cds_wfcq_tail *tail,
4                     struct cds_wfcq_node *new_head,
5                     struct cds_wfcq_node *new_tail)
6 {
7     struct cds_wfcq_node *old_tail;
8
9     old_tail = uatomic_xchg(&tail->p, new_tail);
10    CMM_STORE_SHARED(old_tail->next, new_head);
11    return old_tail != &head->node;
12 }
13
14 static inline bool
15 __cds_wfcq_enqueue(struct cds_wfcq_head *head,
16                     struct cds_wfcq_tail *tail,
17                     struct cds_wfcq_node *new_tail)
18 {
19     return __cds_wfcq_append(head, tail,
20                             new_tail, new_tail);
21 }

```

감안하면, 어떤 linearizable 하지 않은 동작이 일어났음을 증명하는 것은 불가능합니다. 이는 분명히 (약간 인위적이라면) 이 통계적 카운터 알고리즘을 wait-free로 분류합니다. 다른 멋진 트릭들에도 불구하고, 이 알고리즘은 아마도 리눅스 커널에서 가장 많이 사용하는 NBS 알고리즘입니다.

또 다른 흔한 NBS 알고리즘은 하나의 어토믹한 큐로, 원소들의 추가는 어토믹한 교체 인스트럭션 [MS98b]을 사용하고, 이어서 새 원소의 \rightarrow next 포인터를 저장하는 데, 이는 유저스페이스-RCU 라이브러리 구현 [Des09b] 인 Listing 14.1에 나와 있습니다. Line 9는 tail 포인터가 새 원소를 가리키도록 업데이트하면서 그 앞의 것으로의 레퍼런스를 리턴하는데, 이 값은 로컬 변수 `old_tail`에 저장됩니다. Line 10은 이제 앞의 원소의 \rightarrow next 포인터가 새로 추가된 원소를 가리키도록 업데이트 하며, 마지막으로 line 11에서 해당 큐가 원래 비어있었는지 여부를 리턴합니다.

하나의 원소를 꺼내기 위해선 상호 배타성이 필요하지만 (따라서 꺼내기 작업은 블락됩니다), 큐의 전체 컨텐츠를 제거하는 일은 블락킹하지 않게도 할 수 있습니다. 불가능한 것은 어떤 주어진 원소를 블락킹하지 않는 방법으로 꺼내는 것입니다: 원소를 넣는 쪽은 line 9와 10에서 실패할 것이고, 따라서 요청된 원소는 부분적으로만 추가되었을 것입니다. 이로 인해 원소를 집어넣는 작업은 NBS지만 꺼내는 것은 블락킹되는 반면 NBS인 알고리즘으로 귀결됩니다. 하지만 이 알고리즘은 실제 상황에서 매우 많이 사용되는데, 대부분의 상품화된 소프트웨어는 임의의 fail-stop 에러들을 견뎌내도록 요구되지는 않는다는 것도 한 이유입니다.

14.2.2 NBS Discussion

완전히 블락킹 없는 큐 [MS96]를 만드는 건 가능합니다만, 그런 큐들은 앞의 반만 NBS인 알고리즘에 비해 훨씬 복잡합니다. 여기서 얻을 수 있는 교훈은 당신에게 정말로 요구되는 것이 무엇인지 주의깊게 생각해 봐야 한다는 것입니다. 무의미한 요구사항을 완화시키는 것은 단순성과 성능, 그리고 확장성에 큰 개선을 가져올 수 있습니다.

최근의 연구는 요구사항들을 완화시키기 위한 또 다른 중요한 방법을 이야기합니다. 공정한 (fair) 스케줄링을 제공하는 시스템들은 wait-free 동기화의 장점 대부분을 심지어 블락킹 하지 않는 동기화만 제공하는 알고리즘을 사용할 때에도 얻을 수 있다고 이론 [ACHS13]과 실제 [AB13]에서 모두 이야기 합니다. 상품화된 단계에서 사용되는 매우 많은 스케줄러들이 실제로 공정성 (fairness)을 제공하므로, wait-free 동기화를 제공하는 더 복잡한 알고리즘들은 일반적으로 더 간단하고 많은 경우 더 빠른 블락킹하지 않는 동기화 알고리즘들에 비해 실제 환경에서 더 나은 점을 제공하지 못하곤 합니다.

흥미롭게도, 공정한 스케줄링은 실제 상황에서 고려되는 이익적 제약들 중 하나일 뿐입니다. 다른 제약의 집합들은 블락킹 알고리즘들이 결정론적 리얼타임 반응을 달성할 수 있게 할 수 있습니다. 예를 들어, 그 획득이 주어진 우선순위에 따라 FIFO 순서로 이루어지게 하는 공정한 (fair) 락, (우선순위 상속 [TS95, WTS96]이나 우선순위 한도 문제와 같은) 우선순위 역전 문제를 회피하는 방법, 제한된 숫자의 쓰레드들, 제한된 크리티컬 섹션들, 제한된 부하량, 그리고 fail-stop 벤그들의 회피가 주어진다면, 락 기반의 어플리케이션들은 결정론적 반응 시간을 제공할 수 있습니다 [Bra11]. 물론 이런 시도는 블락킹과 wait-free 동기화 사이의 차이점을 흐리게 만드는데, 좋은 현상입니다. 이론적인 뼈대가 자랄수록, 소프트웨어가 실제로 현장에서 어떻게 구성되는지 설명하는 능력도 증가할 것입니다.

이론이 방법을 앞서야 한다고 생각하는 분들은 비길 데 없는 Peter Denning의 운영체제에 대한 이야기를 들어보시기 바랍니다: “Theory follows practice” [Den15].

Those who feel that theory should lead the way are referred to the inimitable Peter Denning, who said of operating systems: “Theory follows practice” [Den15].

14.3 Parallel Real-Time Computing

컴퓨팅에서 중요한 발전중인 영역은 병렬 리얼타임 컴퓨팅입니다. Section 14.3.1은 “리얼타임 컴퓨팅”에 대해서 흔한 발언들부터 도 의미있는 영역들까지의 다양한 정의를 알아봅니다. Section 14.3.2은 리얼타임 응답이 필요한 어플리케이션의 종류들에 대해서 알아

봅니다. Section 14.3.3 에서는 병렬 리얼타임 컴퓨팅이 우리에게 다가와 있음을 이야기하고, 언제, 그리고 왜 병렬 리얼타임 컴퓨팅이 유용하게 되는지에 대해서 이야기합니다. Section 14.3.4 에서는 어떻게 병렬 리얼타임 시스템들이 구현될 것인지에 대한 간략한 그림을 제공하며, 마지막으로 Section 14.3.7 에서는 여러분의 어플리케이션이 리얼타임 장비들을 필요로 하는지에 대한 결정을 어떻게 해야 하는지 간단히 설명합니다.

14.3.1 What is Real-Time Computing?

리얼타임 컴퓨팅을 분류하는 한가지 전통적인 방법은 *hard real time* 과 *soft real time* 의 카테고리로 나누는 것으로, 여기서 마초같은 *hard real-time* 어플리케이션들은 데드라인을 절대로 어기지 않지만, 약한 *soft real-time* 어플리케이션들은 데드라인을 자주, 그리고 종종 어길 수 있습니다.

14.3.1.1 Soft Real Time

Soft real time 에 대한 이 정의에 있어서 문제를 알아보기는 쉽습니다. 한가지 들어보면, 그 정의에 의해서, 모든 소프트웨어의 부분은 soft real-time 어플리케이션이라고 말할 수 있습니다: “제 어플리케이션은 백만개 점의 휴리에 변환을 0.5 피코세컨드 만에 계산합니다.” “말도 안돼요!!! 이 시스템의 클락 사이클은 300 피코세컨드보다 크다구요!” “아, 하지만 이건 soft real-time 어플리케이션이잖아요!” “Soft real time”이라는 용어가 어떻게든 사용된다면, 어떤 제한점이 분명하게 요구됩니다.

따라서 우리는 주어진 soft real-time 어플리케이션은 그 응답시간 요구사항이 최소한 얼마간의 시간 내여야만 한다고 말할 수 있을텐데, 예를 들어 우린 그 프로그램이 99.9% 의 경우는 20 마이크로세컨드 내에 수행되어야만 한다고 말할 수 있을겁니다.

물론 이는 그 어플리케이션이 그 자신의 응답시간 요구사항을 지키지 못했을 경우에는 어떤 일이 벌어지는지에 대한 의문을 생기게 만듭니다. 그에 대한 대답은 어플리케이션에 따라 다양할 수 있습니다만, 한가지 가능한 답은 제어되고 있는 그 시스템은 가끔의 느린 응답 동작을 문제없이 처리할 수 있을만큼 충분한 안정성과 관성을 갖는다는 것입니다. 또 다른 가능한 답은 해당 어플리케이션이 그 결과를 계산해내는데에 두가지 방법을 가지고 있어서, 하나는 빠르고 결정론적이지만 부정확한 방법이고 또 다른 하나는 매우 정확하지만 예측 불가능한 계산시간을 갖는 것입니다. 합리적인 한가지 방법은 두개지 방법을 병렬적으로 시작하고 정밀한 방법이 시간내에 완료되는데에 실패한다면, 그 수행을 중단하고 빠르지만 부정확한 방법의 결과를 답변으로



Figure 14.1: Real-Time Response Guarantee, Meet Hammer

사용하는 것입니다. 빠르지만 부정확한 방법으로 사용될 수 있는 한가지는 현재 시간 간격 동안 제어 동작을 취하지 않는 것이고, 또 다른 하나는 앞의 시간 간격동안 취해진 것과 똑같은 제어 동작을 취하는 것입니다.

짧게 말해서, 그것이 정확히 얼마나 soft 한지에 대한 어떤 측정을 제공하지 않은 채로는 soft real time 에 대해서 이야기 하는 것은 의미가 없습니다.

14.3.1.2 Hard Real Time

대조적으로, hard real time 의 정의는 상당히 명확합니다. 무엇보다, 주어진 시스템은 항상 그 데드라인을 지키거나 그렇지 않거나 둘 중 하나입니다. 불행하게도, 이 정의의 엄격한 응용은 어떤 hard real-time 쓰템도 존재할 수 없을 것을 의미합니다. 이에 대한 이유가 Figure 14.1 에 그려져 있습니다. 추가된 여분의 것을 포함해서도 더 튼튼한 시스템을 만들 수 있는게 사실입니다. 하지만 제가 항상 더 큰 망치를 가지고 올 수 있는 것도 사실이지요.

그렇다면 다시, 단순한 하드웨어 문제가 아니라 커다란 쇠로 된 하드웨어 문제가 분명한 데에서 소프트웨어를 문제시 하는건 공평치 않은 일일 수 있습니다.⁴ 이는 우리가 hard real-time 소프트웨어를 하드웨어의 고장이 없을 경우에 한정해서 항상 데드라인을 지키는 소프트웨어로 정의할 것을 제안합니다. 불행히도, Figure 14.2 에 보였듯이 고장이 항상 선택적일 수는 없습니다. 해당 그림에 그려진 불쌍한 신사가 우리가 “당신의 비극적인 죽음이 데드라인을 놓쳐서 초래된다면, 그건 소프트웨어 문제로 인한 것은 아닐 것이니 안심하십시오!” 라고

⁴ 또는, 근대의 망치를 놓고 보면, 커다란 강철 문제.




Figure 14.2: Real-Time Response: Hardware Matters

말하는데에 안심할 수는 없을 것임을 간단히 예상할 수 있습니다. Hard real-time 응답은 전체 시스템의 속성이지, 소프트웨어의 것만이 아닙니다.

하지만 우리가 완벽을 기할 수는 없다면, 앞서 언급한 soft real-time 방법에서와 비슷하게 공지를 해줄 수는 있을 겁니다. 그런 경우 Figure 14.2 의 Life-a-Tron 은 데드라인을 놓치게 될 것 같다면 병원 스텝에게 알림을 보낼 수 있을 겁니다.

안타깝게도, 이 방법은 Figure 14.3 에 보인 것과 같이 하찮은 해결책을 가지고 있습니다. 항상 즉각적으로 그 데드라인을 지킬 수 없을 것 같다고 알림을 내놓는 시스템은 법적으로는 문제가 없지만, 전혀 쓸모없습니다. 해당 시스템이 전체 시간중 어느 정도의 부분에 있어서는 데드라인을 지킨다거나, 또는 특정한 횟수의 연속된 오퍼레이션들에 대해서는 데드라인을 놓치지 않는다는 요구사항이 분명히 필요합니다.

Hard real time 에도 soft real time 에도 짧은 말로 설명되는 방법은 취할 수가 없습니다. 따라서 다음 섹션은 더 현실적인 접근방법을 취합니다.

14.3.1.3 Real-World Real Time

“Hard real-time 시스템들은 항상 데드라인을 지킵니다!” 와 같은 문장은 사람의 마음을 끌 수 있고 기억하기 쉬움에 의심의 여지가 없지만, 실제 세계의 real-time 시스템들을 위해선 뭔가 다른 것들이 필요합니다. 그렇게 이끌어진 명제는 기억하기에 더 어려울 수 있지만, 환경, 워크로드, 그리고 real-time 어플리케이션 자체에 대한 제약을 이끌어냄으로써 real-time 시스템의 구성을 간단화 시킬 수 있습니다.

Environmental Constraints 환경에의 제약은 “hard real time”에 의해 상정되는 응답시간에 대한 끝없는 약속에의 반론을 제기합니다. 이 제약은 허용 가능한 운영온도, 공기 청정도, 전자기파 방사량의 수준과 타입, 그리고, Figure 14.1 의 요점에 맞춰서, 충격과 진동의 수준을 명시할 수도 있습니다.

물론, 일부 제약들은 다른 것들보다 지켜지기가 더 쉽습니다. 수많은 사람들이 생필품처럼 팔리는 컴퓨터 컴포넌트들이 종종 얼음이 얼만한 온도에서는 동작하지 못한다는 점을 알고 있는데, 이는 일부 온도 조절 필요성을 제시합니다.

옛 대학교 친구 한명이 한번은 다소 격렬한 염소 화합물을 가진 대기에서 real-time 시스템을 운영해야 하는 어려움을 겪은 적이 있는데, 그는 이 어려움을 이해롭게 하드웨어 설계를 하게 되는 그의 학교 친구들에게 넘겨버렸습니다. 구체적으로, 제 대학교 친구는 컴퓨터를 곧바로 둘러싸는 환경에 대한 대기질 상의 화합물에 대한, 하드웨어 설계자들이 물리적 봉인을 사용함으로써 마주하게 되는 제약을 부과했습니다.

또 다른 옛 대학교 친구는 진공에서 강한 흐름을 그리며 티타늄 주괴를 뒤져대는 컴퓨터로 제어되는 시스템을 가지고 작업을 했습니다. 시간에 따라, 그 흐름은 티타늄의 주괴가 그리는 경로가 지겹다고 생각하고는 땅쪽으로 떨어지는 더 짧고 재미있는 경로를 선택할 수 있었습니다. 우리가 우리의 물리 수업 시간에 배웠듯이, 전자의 흐름의 급작스런 변화는 전자기파를 생성하고, 더 커다란 흐름에서의 더 커다란 변화는 강한 힘의 전자기파를 생성합니다. 그리고 이 경우에 초래된 전자기 파동은 400 미터 멀리 떨어진 작은 “러버덕 같은” 안테나의 전 위의 4분의 1을 유발할 수 있기에 충분했습니다. 이는 역제곱 법칙에 의해 근처의 전도체들은 큰 전압을 볼 수 있음을 의미합니다. 이는 이 뒤져대기 작업을 제어하는 컴퓨터를 구성하는 전도체를 포함했습니다. 구체적으로, 그 컴퓨터의 리셋 전선에 가해진 전압은 정말로 컴퓨터를 리셋시키기에, 관련된 모두를 놀래키기에 충분했습니다. 이 경우, 이 어려움은 또한 하드웨어로 처리되었는데, 정교한 봉인과 9600 baud 라는 제가 처음 들어볼 만큼 낮은 bitrate 의 광섬유 네트워크를 사용했습니다. 그렇다면 하나, 덜 화려한 전자기파 환경은 여러 감지와 수정 코드를 사용하는 소프트웨어를 통해 제어될 수 있습니다. 그렇다면 하나, 여러 감지와 수정 코드가 실패 확률을 줄일 수는 있지만, 그것들은 실패 확률을 아예 없애버릴 수는 없으므로 hard real-time 응답을 달성하는데에 또 다른 문제를 형성하게 됨을 기억해 두는 것이 중요합니다.

또한 최소한의 전력 수준이 필요로 되는 환경도 존재하는데, 예를 들면, 시스템을 이끄는 전력과 시스템이 모니터되거나 제어되려는 바깥 세계와 통신하게 되는



Figure 14.3: Real-Time Response: Notification Insufficient

기기의 것에의 전력이 되겠습니다.

Quick Quiz 14.1: 배터리로 동작하는 시스템의 경우에는 어떻죠? 그것들은 그 시스템으로 흘러들어오는 에너지를 전혀 필요로 하지 않아요. ■

많은 수의 시스템들이 상당한 수준의 충격과 진동에도 동작할 수 있도록 만들어지는데, 예를 들면 엔진 제어 시스템이 그렇습니다. 지속적인 진동과 급작스런 충격의 경우로 와보면 더 가혹한 요구사항이 발견될 수도 있습니다. 예를 들어, 제 학부시절의 연구중에, 저는 구식의 Athena 탄도학 컴퓨터를 보게 되었는데, 그 컴퓨터는 수류탄이 근처에 떨어지더라도 평범하게 동작을 계속할 수 있도록 설계되었습니다.⁵ 그리고 마침내, 비행기에 사용되는 “블랙 박스”들은 폭발 전에도, 폭발 중에도, 폭발 후에도 동작을 계속해야만 하게 되었습니다.

물론, 환경적 충격과 공격에 대해 더 안전하게 하드웨어를 만드는 것은 가능합니다. 여러개의 독창적인 기계적 충격 제거 기기들은 충격과 진동의 효과를 줄일 수 있고, 여러겹의 봉인은 낮은 전력의 전자기파의 효과를 줄일 수 있으며, 여러 수정 코딩은 높은 전력의 방사의 효과를 줄일 수 있고, 다양한 포장과 봉인 기술이 공기 청정 수준으로 인한 영향을 줄일 수 있고, 여러 온도 조절 장치 시스템들이 온도의 효과에 대응할 수 있습니다. 극단적인 경우에, 세개의 모듈 중복은 시스템의 하나의 부분의 실패 하나가 모든 시스템이 움직이지 않은 동작을 하는 결과를 초래할 확률을 낮출 수 있습니다. 하지만,

이 모든 방법들은 하나의 공통점을 갖습니다: 그것들이 실패의 확률을 낮출수는 있지만, 아예 그 확률을 0으로 만들 수는 없다는 것입니다.

이런 가혹한 환경적 조건들이 많은 경우에 더 강력하고 안정적인 하드웨어를 사용해서 처리되곤 하지만 다음 두개의 섹션에서의 워크로드와 어플리케이션 제약은 종종 소프트웨어로 해결되곤 합니다.

Workload Constraints 사람에게와 마찬가지로, real-time 시스템에 부담을 지나치게 주는 방법으로 데드라인을 지키지 못하게 하는 것이 가능한 경우가 종종 있습니다. 예를 들어, 만약 시스템이 너무 자주 인터럽트 당한다면, 이 시스템은 real-time 어플리케이션을 다른 기에 충분한 CPU 대역폭을 갖지 못할 수 있습니다. 이 문제에 대한 하드웨어를 통한 해결책은 시스템에 인터럽트가 전달되는 정도를 제한하는 것입니다. 가능한 소프트웨어를 통한 해결책은 인터럽트가 너무 자주 들어온다면 일정 시간동안 인터럽트를 불능화시키는 것, 너무 자주 인터럽트를 생성하는 디바이스를 리셋하는 것, 또는 심지어 인터럽트를 아예 금지시키고 폴링 방식을 사용하는 것 등이 있을 수 있습니다.

지나치게 부담을 주는 행위는 queueuing effect로 인해 응답시간을 나쁘게 만들 수 있어서, real-time 시스템들에 있어서 CPU 대역폭을 실제보다 많이 사용할 수 있도록 하는 것은 흔치 않은 일이며, 그로 인해 수행 중인 시스템은 (말해보자면) 80% 정도의 idle 시간을 갖습니다. 이 방법은 저장장치와 네트워킹 디바이스에도 역시 적용됩니다. 어떤 경우에 있어서는 real-time 어플리케이션의 높은 우선순위의 부분들만을 위한 별개의 저

⁵ 10여년 후, 일부 타입의 컴퓨터 시스템들에 대한 적합성 테스트는 커다란 폭발을 포함했고, 어떤 타입의 통신 네트워크들은 정확히 “탄도학 무선 통신 방해”라고 불리우는 것들을 다뤄야만 했습니다.

장장치와 네트워킹 하드웨어를 전용으로 갖춰 두기도 합니다. real-time 시스템에서는 처리량보다 응답시간이 더 중요하기 때문에, 이런 하드웨어가 대부분의 시간을 idle 상태로 유지하는 것은 물론 드문 일이 아닙니다.

Quick Quiz 14.2: 하지만 queueing theory에서의 결과를 놓고 생각해 보면, 낮은 리소스 활용률은 평균 응답시간만을 개선할 뿐이지 최악의 경우의 응답시간은 개선하지 못하지 않을까요? 그리고 최악의 경우에서의 응답시간이야말로 대부분의 real-time 시스템들이 정말로 신경쓰는 것이 아니던가요? ■

물론, 충분히 낮은 리소스 활용률을 유지하는 것은 설계와 구현 단계에서의 많은 연습을 필요로 합니다. 데드라인을 어기게 만들 수 있는 작은 기능적 잘못 같은 것은 없어야 합니다.

Application Constraints 최대 시간이 정해진 응답 시간을 제공하기는 일부 오피레이션이 다른 것에 비해 쉽습니다. 예를 들어, 인터럽트와 wake-up 오피레이션들에 대한 응답시간 명세서를 보는 일은 흔하지만, (예를 들어) 파일 시스템 unmount 오피레이션에 대한 응답시간 명세서는 상당히 드뭅니다. 이에 대한 이유 중 하나는 파일시스템 unmount 오피레이션은 파일시스템의 메모리 안에 있는 데이터를 모두 대용량 저장장치로 비워내려야만 하기 때문에, 해야 하는 일의 양을 제한하기는 상당히 어렵기 때문입니다.

이는 real-time 어플리케이션들이 제한된 대기 시간을 합리적으로 제공해줄 수 있는 오피레이션들의 사용만으로 국한되어야 함을 의미합니다. 다른 오피레이션들은 해당 어플리케이션의 real-time 이 아닌 영역으로 들어가거나 아예 사라져야만 합니다.

이 어플리케이션의 real-time 이 아닌 영역에 대해서도 제한이 있을 수 있습니다. 예를 들어, real-time 이 아닌 어플리케이션은 real-time 영역에 의해서 사용되는 CPU를 사용해도 되는 걸까요? 해당 어플리케이션의 real-time 부분이 일반적이지 않게도 바쁠 수 있는 시간이 존재할까요, 만약 그렇다면, 이 어플리케이션의 real-time 이 아닌 부분은 그런 시간 동안에도 계속 수행될 수 있을까요? 마지막으로, 해당 어플리케이션의 얼만큼의 real-time 부분까지는 real-time 이 아닌 부분의 처리량을 저하시켜도 좋은 것으로 허용되는 걸까요?

Real-World Real-Time Specifications 앞의 섹션들에서 보았듯이, 실제 세상에서의 real-time 명세는 환경, 워크로드 그리고 어플리케이션 자체에 있어서의 제약을 포함해야 합니다. 또한, 어플리케이션의 real-time 부분이 사용될 수 있는 경우를 위해선, 그런 오피레이션들을 구현하는 하드웨어와 소프트웨어에 제약이 존재해야만 합니다.

그런 오피레이션들에 있어서, 이런 제약들은 최대 응답시간 (그리고 최소 응답시간을 포함할 수도 있습니다)과 그 응답시간을 지킬 수 있는 확률을 포함할 수 있습니다. 100% 확률은 연관된 오피레이션이 hard real-time 서비스를 제공해야 함을 의미합니다.

어떤 경우들에 있어서는, 응답시간과 그것이 지켜질 확률에 대한 요구사항이 문제로 되는 오피레이션의 인자에 따라 다양하게 달라질 수도 있습니다. 예를 들어, 로컬 LAN을 통한 네트워크 오피레이션은 (대략) 100-마이크로세컨드 내에 완료될 확률이 대류간 WAN을 통한 네트워크 오피레이션이 100-마이크로세컨드 내에 완료될 확률보다는 훨씬 클 것입니다. 더 나아가서, 구리선이나 광섬유로 구성된 LAN에서의 네트워크 오피레이션은 시간을 소모하는 재전송 없이 완료될 확률이 매우 높은 반면, 취약한 WIFI 네트워크를 통한 네트워크 오피레이션은 데드라인을 놓칠 확률이 매우 클 것입니다. 유사하게, 밀접하게 엮인 solid-state disk (SSD)에서의 읽기 오피레이션은 구식의 USB로 연결된 녹슬은 disk drive에서의 같은 읽기에 비해 훨씬 빠를 것으로 예상할 수 있습니다.⁶

어떤 real-time 어플리케이션들은 다른 오피레이션 단계를 통해 수행될 수 있습니다. 예를 들어, 돌아가는 통나무로부터 (“베니어”라고 불리는) 얇은 나무판을 벗겨내는 합판 선반을 제어하는 real-time 시스템은 반드시: (1) 통나무를 선반에 가져오고, (2) 통나무에 있는 가장 큰 원기둥이 칼날에 노출되도록 통나무를 선반의 고정시키는 목재 위에 위치시키고, (3) 통나무를 돌리기 시작한 후, (4) 통나무로부터 베니어판을 벗겨낼 수 있도록 칼날의 위치를 지속적으로 조절하고, (5) 벗겨내기엔 너무 작게 된 통나무의 중심 부분을 제거하고, (6) 다음 통나무를 기다립니다. 이 여섯 단계의 오피레이션 각각은 역시 그 자체의 데드라인과 환경적 제약을 가질 수 있는데, 예를 들어 단계 4의 데드라인은 단계 6의 그것보다 훨씬 가혹해서 초단위가 아니라 밀리세컨드 단위일 것을 예상할 수 있을 겁니다. 따라서 낮은 우선순위의 작업은 단계 4에서 보다는 단계 6에서 수행될 것으로 예상할 수 있을 겁니다. 그렇다면 하나, 단계 4의 더 가혹한 요구사항을 지켜주기 위해선 세심한 하드웨어, 드라이버의 선택과 소프트웨어 구성이 더 필요할 겁니다.

이런 단계에 따른 단계 방법의 장점은 응답시간 예산이 나누어질 수 있어서, 어플리케이션의 다양한 컴포넌트들이 각각 자신의 응답시간 예산을 가진채로 독립적으로 개발될 수 있다는 점입니다. 물론, 모든 다른 종류의 예산과 마찬가지로, 어떤 컴포넌트가 전체 예산 중 얼만큼의 부분을 차지하게 될 것인지에 대해서는

⁶ 중요한 보안 팁: USB 디바이스에서의 최악의 경우의 응답시간은 극단적일 정도로 길 수 있습니다. 따라서 Real-time 시스템들은 critical path에서 USB 디바이스를 떨어뜨려 놓도록 신경써야 합니다.

가끔 충돌이 있을 수 있고, 다른 종류의 예산과 마찬가지로 강한 리더쉽과 공유된 목표에 대한 감이 이런 충돌을 빠르게 해결하는데에 도움이 될 수 있습니다. 그리고, 또다시 다른 종류의 기술적 예산과 마찬가지로, 응답시간에 대한 적절한 포커스를 보장하고 응답시간 문제에 대한 경고를 빨리 내기 위해서는 강력한 검증 노력이 필요합니다. 성공적인 검증 시도는 거의 항상, 이론가를 만족시킬수는 없을수도 있지만 실제 일이 수행되는데에 도움을 주는 덕목을 가진 훌륭한 테스트 모음을 포함할 것입니다. 실제로, 2015년 초에 있어서, 대부분의 실세계의 real-time 시스템은 형식적 검증보다는 적합한 테스트를 사용합니다.

그렇다고는 하나, real-time 시스템을 검증하기 위한 테스트 집합의 넓은 사용은 매우 현실적인 단점을 갖는다. real-time 소프트웨어는 특정 하드웨어와 소프트웨어 구성 위에서만 검증된다는 점입니다. 또다른 하드웨어와 환경구성을 추가하는 것은 추가적인 비용과 시간 소모를 요하는 테스트를 필요로 합니다. 형식적 검증이 이 상황을 바꿀 수 있기에 충분할 만큼 진보될 수도 있겠습니다만, 2015년 초에 있어서는, 더 많은 진보가 필요한 상황입니다.

Quick Quiz 14.3: 형식적 검증은 수십년간 집중된 연구로 인해 이미 상당히 실용 가능한 수준입니다. 추가적인 진보가 정말로 필요한 건가요, 아니면 이건 그저 실무자의 게으르기를 계속하고 형식적 검증의 대단한 위력을 무시하려는 변명일 뿐인가요? ■

어플리케이션의 real-time 부분에서의 응답시간 요구 사항에 더해서, 어플리케이션의 real-time 이 아닌 부분을 위한 성능과 확장성 요구사항도 있을 수 있습니다. 이런 추가적 요구사항들은 궁극의 real-time 응답시간들은 평균 성능과 확장성을 떨어뜨림으로써 얻어질 수 있다는 사실을 반영합니다.

소프트웨어 엔지니어링 요구사항 또한 중요할 수 있는데, 커다란 팀에 의해 개발되고 유지되어야 하는 커다란 어플리케이션에서는 특히나 그렇습니다. 이런 요구 사항들은 모듈성의 증가와 실패의 격리화를 선호하게 되는 경우가 많습니다.

이전 제품 단계의 real-time 시스템을 위한 데드라인과 환경적 제약들을 명세하기 위해 필요한 작업들의 간략한 개요에 지나지 않습니다. 이런 개요가 real-time 컴퓨팅에 대한 말로 듣기 좋은 이야기 기반의 접근법의 부적합성을 잘 보여주기를 바랍니다.

14.3.2 Who Needs Real-Time Computing?

모든 컴퓨팅이 사실은 real-time 컴퓨팅이라고 주장하는 것도 가능할 겁니다. 한 가지 적당히 극단적인 예를 들자면, 여러분이 생일선물을 온라인에서 구매한다면, 여러분은 그 선물이 받을 사람의 생일 전에 도착하기

를 바랄 겁니다. 그리고 사실 turn-of-the-millenium 웹 서비스들에서 조차도 1초 미만의 응답 제약이 관측되었고 [Boh01], 시간의 경과에 따라서 그 요구사항이 완화되지도 않았습니다 [DHJ⁺07]. real-time 이 아닌 시스템이나 어플리케이션에서 단순하게 응답시간 요구사항이 이뤄질 수는 없는 그런 real-time 어플리케이션들에 집중하는게 어느정도 유용할 겁니다. 물론, 하드웨어의 비용이 낮아지고 대역폭과 메모리 크기가 증가할수록 real-time 과 real-time 이 아닌 것 사이의 간격은 바뀌어 갈 것입니다만, 그런 진보는 결코는 나쁜 일이 아닙니다.

Quick Quiz 14.4: Real-time 과 real-time 이 아닌 것을 무엇이 “real-time 이 아닌 시스템과 어플리케이션에 대해서 간단히 이뤄질 수 있는지”로 구분하는 것은 우스운 일입니다! 그런 구별을 위한 이론적 기초는 전혀 존재치 않아요!!! 더 나은 것을 할 수는 없을까요??? ■

Real-time 컴퓨팅은 제조부터 항공 전자공학; 가장 스펙타클한 예를 들면 커다란, 지구에 달라붙어 있는 망원경이 별빛을 없애기 위해 사용되는 적용 제어 광학과 같은 과학 어플리케이션들; 앞서 언급된 항공 전자공학을 포함한 군사 어플리케이션; 그리고 기회를 인식하기 위한 첫번째 계산이 대부분의 초래되는 이익을 거둬들일 수 있는 금융 서비스 어플리케이션들까지 다양한 산업 제어 어플리케이션들에서 사용됩니다. 이 네가지 영역들은 “생산의 탐색”, “삶의 탐색”, “죽음의 탐색”, 그리고 “돈의 탐색”으로 성격지어질 수 있을 겁니다.

돈은 물질이 아니므로 계산 외의 반응속도는 상당히 작은 금융 서비스 어플리케이션은 다른 세개 카테고리의 어플리케이션들과 약간 다릅니다. 반대로, 다른 세개의 카테고리들에서 근본적으로 존재하는 기계적 자연들은 어플리케이션의 실시간 응답시간의 축소가 작은 이익 또는 이익을 아예 제공하지 않게 되는 수학체감지점을 제공합니다. 이 말은 금융 서비스 어플리케이션들은 다른 real-time 정보 처리 어플리케이션들과 달리 가장 낮은 응답시간을 갖는 어플리케이션이 일반적으로 승리하는 경주에 직면하게 됨을 의미합니다. 결과적으로 응답시간 요구사항은 여전히 Section 2 에 설명된 것과 같이 명시될 수 있으며, 이런 요구사항들의 일반적이지 않은 특성은 금융과 정보 처리 어플리케이션을 “real time” 보다는 “low latency” 어플리케이션으로 여겨지게 합니다.

우리가 그것을 정확히 뭐라 부를 것인지와는 관계 없이, real-time 컴퓨팅을 위한 상당한 필요가 존재합니다 [Pet06, Inm07].

14.3.3 Who Needs Parallel Real-Time Computing?

누가 별별 real-time 컴퓨팅을 정말 필요로 하는지는 덜 분명합니다만, 그와 상관 없이 낮은 비용의 멀티코어




Figure 14.4: Real-Time Reflexes

시스템의 진보가 그 자신을 전면에 대두시켰습니다. 안타깝게도, real-time 컴퓨팅을 위한 전통적인 수학적 기본 사항들은 그 규칙을 증명하는 일부 예외 [Bra11] 와 함께 단일 CPU 시스템을 가정하고 있습니다. 그렇다면 하지만, 최신 컴퓨팅 하드웨어가 real-time 수학적 사항들에 들어맞도록 하는 방법들이 두가지 존재하고, 일부 Linux 커널 해커들은 학계에서 이런 변환을 만들도록 장려해왔습니다 [Gle10].

한가지 방법은 Figure 14.4에 보여진 것처럼, real-time 응답으로부터 실시간이 아닌 전략짜기와 계획짜기까지 다양한 생물학적 신경 시스템을 많은 real-time 시스템들이 반영하고 있다는 사실을 깨닫는 것입니다. 센서들의 상태를 읽고 작동기를 제어하는 hard real-time 응답들은 하나의 CPU 위에서 real-time 으로 수행되는 동안, 어플리케이션의 real-time 이 아닌 전략짜기와 계획짜기 부분은 남아있는 여러 CPU에서 수행됩니다. 전략짜기와 계획짜기 활동은 통계적 분석, 주기적 교정, 사용자 인터페이스, 공급망 활동, 그리고 준비활동 등을 포함할 수 있습니다. 컴퓨팅 부하를 많이 주는 준비 활동의 한 예를 들어보자면, Section 2에서 이야기한 합판 깎아내기 어플리케이션을 다시 생각해 봅시다. 하나의 CPU 가 하나의 통나무를 깎아내는데 필요한 고속의 real-time 계산에 사용되고 있는 동안, 다른 CPU들은 고품질의 합판의 많은 수량을 얻기 위해서 다음 통나무를 어떻게 위치시켜야 할지를 결정하기 위해서 다음 통나무의 크기와 모양을 분석할 수 있을 겁니다. 많은 어플리케이션들이 real-time 과 real-time 이 아닌 컴포넌트들을 가지고 있음이 드러났으므로 [BMP08], 이 방법은 많은 경우에 전통적인 real-time 분석이 최신의 멀티코어 하드웨어와 결합될 수 있도록 하곤 합니다.

또 다른 사소한 방법은 하나의 하드웨어 쓰레드만을 켜고 나머지는 모두 꺼서 타협된 유니프로세서 real-time 컴퓨팅의 수학으로 되돌아가는 것입니다. 하지만, 이 방법은 잠재적 비용과 에너지 효율성의 장점들을 포기하게 됩니다. 그렇다면 하나, 이런 장점들을 취하는 것은 Chapter 3에서 다룬 병렬 성능 문제들을 극복해 낼 것을 필요로 하고, 평균적인 경우에만이 아니라 최악의 경우에 대해서 그렇습니다.

따라서 병렬 real-time 시스템을 구현하는 것은 상당히 어려운 일입니다. 이 어려운 목표를 달성하는 것은 다음 섹션에서 그 방법의 윤곽을 그려봅니다.




Figure 14.5: Real-Time Response Regimes

14.3.4 Implementing Parallel Real-Time Systems

우리는 event-driven 과 polling 이라는 real-time 시스템의 두가지 주요 스타일들을 알아보겠습니다. Event-driven real-time 시스템은 대부분의 시간을 idle 로 유지하고, 운영체제를 통해 어플리케이션으로 전달되어진 이벤트에 실시간으로 응답합니다. 대안적으로, 시스템은 idle 상태를 유지하는 대신 real-time 이 아닌 워크로드를 백그라운드로 수행시킬 수 있습니다. Polling real-time 시스템은 CPU에 성능이 결정되는 real-time 쓰레드를 갖고서, 이 쓰레드로 땀맞는 루프 내에서 입력이 있는지 알아보고 있을 경우 출력을 업데이트합니다. 이 땀맞는 입력 조사 루프는 사용자 모드 어플리케이션의 주소 공간에 매핑된 하드웨어 레지스터로부터 읽고 그 레지스터로 쓰기를 하는 방식으로 완전히 사용자 모드에서 수행되는 경우가 많습니다. 대안적으로, 일부 어플리케이션들은 입력 조사 루프를 커널에 넣어두는데, 예를 들면 로딩할 수 있는 커널 모듈을 사용하는 방식입니다.

어떤 스타일을 선택하는가와 상관 없이, real-time 시스템을 구현하는데 사용되는 방법은 예를 들면 Figure 14.5에 보인 것과 같이 데드라인에 종속적일 겁니다. 이 그림의 위에서부터 시작해 보자면, 여러분이 1초가 넘는 반응 시간을 가져도 괜찮다면, 여러분의 real-time 어플리케이션을 구현하는데에 스크립트 언어를 사용할 수도 있을 겁니다—그리고 스크립트 언어는 실제로 놀라울 만큼 자주 사용되는데, 제가 이 방법을 추천해야 할 정도는 아닙니다. 요구되는 응답시간이 수십 밀리세컨드를 넘는다면, 오래된 2.4 버전의 리눅스 커널이 사용될 수도 있을 텐데, 이 역시 제가 추천해야 할 정도는 아닙니다. 특수한 real-time Java 구현은 가비지 컬렉터의 사용에도 불구하고 수 밀리세컨드의 실시간 응답시간을 제공합니다. 리눅스 2.6.x 와 3.x 커널은 주의깊게 구성되고 튜닝되어서 real-time에 친화적인 하드웨어

서 수행된다면 수백 마이크로세컨드의 실시간 응답시간을 제공합니다. 특수한 real-time Java 구현은 가비지 콜렉터의 사용이 주의깊게 막아진다면 100 마이크로세컨드 아래의 실시간 응답시간을 제공할 수 있습니다. (하지만 가비지 콜렉터를 막는 행위는 Java의 많은 표준 라이브러리의 사용을 막게 되어서 Java의 생산성에서의 장점을 없애버린다는 점을 알아두시기 바랍니다.) -rt 패치셋을 포함한 리눅스 커널은 20 마이크로세컨드 아래의 응답시간을 제공하고, 메모리 변환 없이 동작하는 특수한 real-time 운영체제 (RTOSes)들은 10 마이크로세컨드 아래의 응답시간을 제공합니다. 마이크로세컨드 아래의 응답시간을 달성하는 것은 손으로 짜여진 어셈블리 코드나 심지어 특수 목적의 하드웨어를 사용할 것을 필요로 합니다.

물론, 이 스택의 전체에 걸쳐 주의깊은 구성과 튜닝이 필요합니다. 상세히 말하자면, 하드웨어나 펌웨어가 real-time 응답을 제공하는데에 실패한다면, 소프트웨어가 그 읽어버린 시간을 만회하기 위해 할 수 있는 일은 없습니다. 그리고 고성능 하드웨어는 가끔 더 나은 처리량을 얻기 위해 최악의 경우의 동작을 허생합니다. 실제로, 인터럽트가 불능화된 상태에서 돌아가는 짧은 루프에서의 타이밍은 고성능 무작위수 생성기의 기본을 제공할 수 있습니다 [MOZ09]. 더 나아가서, 일부 펌웨어는 다양한 필수 태스크들을 이끌어가기 위해 cycle-stealing을 하고, 일부 경우에는 희생자 CPU의 하드웨어 클락을 재프로그래밍 함으로써 그 궤도를 덮으려 시도합니다. 물론, cycle stealing은 가상 환경에서는 예상된 행동입니다만, 사람은 가상 환경에서 real-time 응답을 위해 일하지 않습니다 [Gle12, Kis14]. 따라서 여러분의 하드웨어의, 그리고 펌웨어의 real-time 기능을 평가하는게 상당히 중요합니다. 그런 평가를 진행해주는 기관들이 존재하는데, Open Source Automation Development Lab (OSADL)도 그 중 하나입니다.

하지만 주어진 유능한 real-time 하드웨어와 펌웨어를 두고서, 이 스택의 다음 위쪽 계층은 다음 섹션에서 다루어질 운영체제입니다.

14.3.5 Implementing Parallel Real-Time Operating Systems

Real-time 시스템을 구현하는데에 사용될 수 있는 여러가지 전략들이 있습니다. 한가지 방법은 Figure 14.6에 보인 것처럼 특수 목적 real-time 운영 체제 (RTOS) 위에 범용 real-time 이 아닌 OS를 포팅하는 것입니다. 초록색의 “Linux Process” 상자들은 리눅스 커널에서 돌아가는 real-time 이 아닌 프로세스들을 의미하며, 노란색의 “RTOS Process” 상자들은 RTOS 위에서 돌아가는 real-time 프로세스들을 의미합니다.

이 방법은 리눅스 커널이 real-time 기능을 얻게 되




Figure 14.6: Linux Ported to RTOS

기 전까지 매우 널리 사용되던 방법이고, 오늘날에도 여전히 사용되고 있습니다 [xen14, Yod04b]. 하지만, 이 방법은 어플리케이션이 RTOS에서 수행되는 부분과 리눅스에서 수행되는 또 다른 부분으로 나뉘어질 것을 필요로 합니다. 예를 들어 RTOS로부터의 POSIX 시스템 콜을 리눅스에서 수행되는 유ти리티 쓰레드로 포워딩시키거나 하는 식으로 이 두개의 환경이 비슷해 보이게 만드는게 가능하긴 하지만, 언제나 그러기 어려운 부분들이 존재합니다.

또한, 이 RTOS는 하드웨어와 리눅스 커널 둘 다와 연결되어야만 하고, 따라서 하드웨어와 커널 둘 다에서 발생되는 변경에 대해서 상당한 관리를 필요로 합니다. 더 나아가서, 이런 RTOS는 각각 그 스스로의 시스템 콜 인터페이스와 시스템 라이브러리 집합을 갖추고 있는 경우가 많아서 에코시스템과 개발자들을 분할해 놓을 수 있습니다. 실제로, 이런 문제들이 RTOS들과 리눅스의 조합을 이끌게 된 것으로 보이는데, 이 방법은 RTOS의 전체 real-time 기능으로의 접근을 허락하는 동시에 리눅스의 풍부하고 다양한 오픈 소스 생태계로의 어플리케이션의 real-time 이 아닌 완전한 접근을 가능하게 하기 때문입니다.

RTOS들을 리눅스 커널과 짹짓는 것은 리눅스 커널이 최소한의 real-time 기능들만을 가지고 있던 때에는 혁명하고 유용한 단기적 방법이었긴 합니다만, 이는 또한 리눅스 커널에 real-time 기능을 추가하는 동기가 되었습니다. 이 목표를 향한 진행이 Figure 14.7에 보여져 있습니다. 위쪽의 행은 preemption이 불능화 되어져서 핵심적으로는 real-time 기능을 가지고 있지 않은 상태의 리눅스 커널을 다이어그램으로 그리고 있습니다. 중간의 행은 preemption이 활성화 된 채로 메인라인 리눅




Figure 14.7: Linux-Kernel Real-Time Implementations

크너러의 real-time 기능들이 늘어나는 것을 보이는 다이어그램들을 보이고 있습니다. 마지막으로, 가장 아래의 행은 -rt 패치셋이 적용되어서 real-time 기능을 최대화 시킨 리눅스 커널의 다이어그램을 보이고 있습니다. -rt 패치셋으로부터의 기능들이 메인라인에 추가됨으로써, 메인라인 리눅스 커널의 기능들이 시간에 따라 증가되었습니다. 더도 아니고 덜도 아니고, 가장 큰 노력을 요하는 real-time 어플리케이션들은 -rt 패치셋을 사용하기 유지하고 있습니다.

Figure 14.7 의 꼭대기에 보여진 non-preemptible 커널은 CONFIG_PREEMPT=n 과 함께 빌드되어져서, 이 리눅스 커널에서의 수행은 preemption 당할 수 없습니다. 이는 곧 이 커널의 real-time 응답 시간의 최대 시간은 리눅스 커널의 가장 긴 코드 수행 경로에 따라 정해진다는 것을 의미하는데, 이 시간은 실제로깁니다. 하지만, 사용자 모드 수행은 preemption 당할 수 있고, 따라서 우상단에 보여진 real-time 리눅스 프로세스들 가운데 하나는 non-real-time 리눅스 프로세스들 가운데 어느 하나든 사용자 모드에서 수행 중일 때 해당 non-real-time 리눅스 프로세스를 preemption 할 수 있습니다.

Figure 14.7 의 가운데 행에 보여진 preemption 가능한 커널들은 CONFIG_PREEMPT=y 설정과 함께 빌드되어지며, 따라서 해당 리눅스 커널 내의 프로세스 수준 코드는 대부분 preemption 될 수 있습니다. 물론 이는 real-time 응답 시간을 상당히 개선시킵니다만, 이 그림의 가운데 행의 가장 왼쪽 다이어그램 안의 빨간색 박스로 보여지듯이 RCU read-side 크리티컬 섹션, 스핀락 크리티컬 섹션, 인터럽트 핸들러, 인터럽트가 불능화된 코드 영역, 그리고 preemption 불능화된 코드 영역에서는 여전히 preemption 이 불능화 되어 있습니다. Preemption 가능한 RCU 의 진화는 가운데 다이어그램에서 보여지듯이 RCU read-side 크리티컬 섹션의 preemption 될 수 있게 했고, 쓰레드화 된 인터럽트 핸들러들은 가장 오른쪽 다이어그램에 보여지듯이 디바이스 인터럽트 핸들러들이 플리엠션될 수 있게 만들었습니다. 물론, 이 시간 동안에 다른 real-time 기능들을 처리하는 기능들이 추가되었습니다만, 이는 이 다이어그램에 쉽게 표시될 수 없었습니다. 그에 대해서는 대신 Section 14.3.5.1 에서 이야기 하겠습니다.

마지막 방법은 Figure 14.8 에 보인 것처럼, real-time 프로세스로부터 모든 것을 차우는 것으로, 이 프로세스가 필요로 하는 모든 CPU로부터 모든 다른 프로세스 처리를 없애버리는 것입니다. 이는 3.10 리눅스 커널에서 CONFIG_NO_HZ_FULL Kconfig 인자로 구현되었습니다 [Wei12]. 이 방법은 예를 들면 수행중인 커널 daemon들과 같은 백그라운드 처리를 위해서 최소 하나의 최소 작업을 수행할 CPU 를 필요로 한다는 점을 알아둘 필요가 있습니다. 하지만, 최소 작업을 수행할 CPU 가 아닌 CPU 에 하나의 수행 가능한 task 만이 존재할 때에




Figure 14.8: CPU Isolation

는 해당 CPU에서 scheduling-clock 인터럽트가 꺼져서 간섭과 *OS jitter*의 중요 원인을 하나 없애버립니다.⁷ 몇 가지 예외와 함께, 이 커널은 해당의 최소 작업을 수행할 CPU로부터 다른 처리를 없애버리도록 강제하지는 않습니다만, 그대신 해당 CPU에 하나의 수행 가능한 task 만이 존재할 때 더 나은 성능을 제공합니다. 대체로 구성된다면, 간단하지 않은 일을 하는 CONFIG_NO_HZ_FULL은 real-time 쓰레드들에게 거의 bare-metal 시스템의 그것에 필적하는 것에 가까운 수준의 성능을 제공합니다.

이런 방법들 가운데 무엇이 real-time 시스템을 위해 최선인가에 대해서는 물론 상당한 언쟁이 있어왔습니다. 그리고, 이 언쟁은 상당한 시간동안 진행되어오고 있습니다 [Cor04a, Cor04c]. 대부분의 경우와 같이, 그에 대한 답은 다음 섹션들에서 이야기되듯이 “다른것에 종속적이다” 일 것으로 보입니다. Section 14.3.5.1 는 event-drive real-time 시스템들을 알아보고, Section 14.3.5.2 는 CPU에 성능이 국한되는 polling 루프를 사용하는 real-time 시스템을 알아봅니다.

14.3.5.1 Event-Driven Real-Time Support

Event-driven real-time 어플리케이션을 위해 필요한 운영 체제의 지원은 상당히 비용이 비쌉니다만, 이 섹션에서는 그 중 몇 가지 항목들에만 주목할텐데, 타이머, 쓰레드 인터럽트, 우선순위 상속, preemption 가능한 RCU, 그리고 preemption 가능한 스핀락이 그것입니다.

⁷ 1초에 한번 발생하는 잔여의 scheduling-clock 인터럽트는 프로세스 통계 등을 위해 남습니다. 나중에 할 일 목표에는 이런 것들을 처리하고 이 잔여의 인터럽트를 없애는 것을 포함합니다.

Timers 는 real-time 운영을 위해 상당히 중요한 계분명합니다. 무엇보다도, 무언가가 특정 시간 동안 되었음을 말할 수가 없다면, 어떻게 그 시간 내로 응답을 해줄 수 있겠습니까? Real-time 이 아닌 시스템에서조차도, 많은 수의 타이머들이 생성되고, 따라서 그것들은 상당히 효율적으로 다루어져야만 합니다. 사용 예로는 (거의 항상 그것들이 올릴 기회가 오기 전에 취소되어 버리는) TCP 연결을 위한 재전송 타이머,⁸ (드물게 취소되는 `sleep(1)` 과 같이) 시간이 지정된 딜레이, 그리고 (올릴 기회가 오기 전에 취소되는 경우가 자주 있는) `poll()` 시스템 콜을 위한 타임아웃 등이 있을 겁니다. 따라서 그런 타이머를 위한 좋은 데이터 구조는 추가 기능과 삭제 기능이 빠르고 예약이 걸린 타이머의 갯수에 대해 $O(1)$ 의 시간 비용을 갖는 우선순위 대기열이 될 겁니다.

이런 목적의 고전적인 데이터 구조는 리눅스 커널에서 *timer wheel* 이라 불리는 *calendar queue*입니다. 이 오래된 데이터 구조는 discrete-event 시뮬레이션에서 많이 사용되기도 합니다. 여기서의 아이디어는 시간이 양자화 된다는 것으로, 예를 들어 리눅스 커널에서는 시간 분량의 길이는 *scheduling-clock* 인터럽트의 기간입니다. 특정 시간은 정수로 표현될 수 있고, 어떤 양자화 기준으로 완전치 않은 시점에서 하나의 타이머를 등록하려는 모든 시도는 양자화된 완전한 시간 분량에 가깝도록 조정될 겁니다.

한가지 간단한 구현은 시간의 아래쪽 비트로 인덱스되는 하나의 배열을 할당하는 것이 될 겁니다. 이는 이론적으로는 동작하지만, 실제 시스템에서는 거의 항상 취소되어버리는 긴 시간의 타임아웃 (timeout)을 굉장히 많이 발생시킵니다 (예를 들어, TCP 세션들에서 45 분짜리의 *keepalive* 타임아웃). 이런 긴 시간을 필요로 하는 타임아웃은 대부분의 시간이 아직 만료되지 않은 타임아웃을 넘기는데에 소모되기 때문에 작은 크기의 배열에서는 문제를 일으킵니다. 한편으로는, 임의의 많은 수의 긴 시간의 타임아웃들을 수용할 수 있을 만큼 충분히 큰 배열은 너무 많은 양의 메모리를 소비하게 될 수 있는데, 특히 성능과 확장성을 고려하는 곳에서는 모든 CPU 각각에 대해 그런 배열을 필요로 한다는 점에서 특히 그렇습니다.

이런 충돌을 해결하는 한가지 일반적인 방법은 계층을 사용해서 여러개의 배열들을 제공하는 것입니다. 이 계층의 가장 낮은 단계에서는 각각의 배열 원소가 시간의 한 단위를 나타냅니다. 두 번째 단계에서, 각각의 배열 원소는 시간 단위 N 개를 나타내는데, N 은 각 배열의 원소의 갯수입니다. 세 번째 단계에서, 각각의 배열 원소는 시간 단위 N^2 개를 나타내고, 그런식으로 계층의 윗단계로 진행됩니다. 이 방법은 Figure 14.9에 그려진 것처럼 비현실적일 정도로 작은 8-비트 클락에 대해 개




Figure 14.9: Timer Wheel

별적인 배열들이 서로 다른 비트로 인덱스 될 수 있도록 합니다. 여기서, 각각의 배열은 16개의 원소를 가져서 시간의 아래쪽 네개의 비트 (현재 0xf)는 아래 단계의 (가장 오른쪽의) 배열을 인덱스하고, 다음의 네개의 비트 (현재 0x1)는 그 다음 위 단계를 인덱스하게 됩니다. 따라서, 각각 16 개의 원소를 가져서 총 32개의 원소를 갖는 두개의 배열을 가지게 되는데 이는 단일 배열을 사용한다면 256 개의 원소를 갖는 배열을 사용했어야 하는 것에 비하면 굉장히 작은 것입니다.

이 방법은 처리량 기반의 시스템에서는 상당히 잘 동작합니다. 각각의 타이머의 동작은 작은 수의 상수로 $O(1)$ 의 비용을 갖고, 각각의 타이머 원소는 최대 $m + 1$ 회 접근되는데, 여기서 m 는 단계의 수입니다.

안타깝게도, *time wheel*은 real-time 시스템에서는 두 가지 이유로 인해 잘 동작하지 못합니다. 첫 번째 이유는 타이머의 정확성과 타이머의 오버헤드 사이에 존재하는 가혹한 트레이드오프로, Figures 14.10 와 14.11에 그려져 있습니다. Figure 14.10에서, 타이머 처리는 1 밀리세컨드당 1회만 일어나는데, 이는 많은 (하지만 모든 것은 아닌!) 워크로드들에 대해 충분히 받아들여질 수 있을 만큼 낮은 오버헤드를 유지하게 됩니다만, 이는 또한 타임아웃이 1 밀리세컨드 단위보다 작은 단위로 설정될 수는 없음을 의미합니다. 다른 한편으로, Figure 14.11은 타이머 처리가 10 마이크로세컨드마다 발생하게 됨을 보이는데, 여기서는 대부분의 (하지만 모든 것은 아닌!) 워크로드에 대해 받아들여지기 충분할 만큼 세밀한 시간 단위를 제공하지만, 또한 시스템이

⁸ 합리적으로 낮은 패킷 로스 발생률을 가정한다면요!



Figure 14.10: Timer Wheel at 1 kHz



Figure 14.11: Timer Wheel at 100 kHz

타이머를 처리하는 것 이외에는 다른 일을 할 수가 없을 만큼 자주 타이머 처리가 이루어짐을 의미합니다.

두 번째 이유는 타이머를 위쪽 단계부터 아래쪽 단계까지 봐야 한다는 필요성입니다. Figure 14.9로 다시 돌아가서, 윗단계의 (왼쪽의) 배열의 1x 원소에 넣어진 모든 타이머는 아래 단계의 (오른쪽의) 배열로 이동되어서 그것들의 시간이 도착했을 때에 호출될 수도 있게 해야 합니다. 안타깝게도, 여기에는 아래 단계로 이동하기 위해 기다리고 있는 많은 수의 타임아웃들이 존재할 수 있는데, 특히 많은 수의 단계를 갖는 타이머에서는 더욱 그럴 것입니다. 통계의 힘은 이 단계 이동이 처리량 기반의 시스템에 있어서는 문제가 되지 않도록 합니다만, 단계 이동이 real-time 시스템에서는 응답시간의 저하라는 문제를 초래할 수 있습니다.

물론, real-time 시스템은 그냥 다른 데이터 구조를 선택할 수도 있는데, 예를 들면 추가와 삭제 오퍼레이션의 최대 성능 한계 $O(1)$ 이라는 조건을 포기하고 데이터 구조 관리 오퍼레이션에 대해서 $O(\log n)$ 한계를 얻을 수 있는 heap이나 tree의 형태가 될 수 있을 겁니다. 이는 특정 목적의 RTOS들에 대해서는 좋은 선택이 될 수 있습니다만, 주로 굉장히 많은 수의 타이머들을 지원해야 하는 리눅스와 같은 범용 목적의 시스템들에서는 비효율적입니다.

리눅스 커널의 -rt 패치셋에서 선택된 해결책은 나중의 동작을 스케줄하는 타이머와 TCP 패킷 로스와 같이 발생 확률이 낮은 에러의 처리를 스케줄하는데 사용되는 타이머를 서로 다르게 하는 것입니다. 여기서의 핵심적인 발견은 에러 처리는 일반적으로 특별히 시간이 중요하지 않고, 따라서 time wheel의 밀리세컨드 단위 관리도 충분하고 좋다는 것입니다. 또 다른 하나의 핵심 발견은 에러 처리용 타임아웃들은 일반적으로 매우 빨리 취소되는데, 그 빠른 정도는 아래 단계로의 전파적인 경우도 갖다는 것입니다. 마지막 발견은 시스템은 발생시키는 타이머 이벤트 보다도 훨씬 더 많은 에러 처리 타임아웃들을 가지고 있고, 따라서 $O(\log n)$ 데이터 구조는 타이머 이벤트에 받아들여질만한 성능을 제공해야 한다는 것입니다.

짧게 정리해서, 리눅스 커널의 -rt 패치셋은 에러 처리 타임아웃에 대해서는 timer wheel을 사용하고 타이머 이벤트에는 tree를 사용해서 각 카테고리에 필요시 되는 품질의 서비스를 제공합니다.

Thread interrupts는 Figure 14.12에 보여진 것과 같이 느려진 real-time 응답시간의 중요한 원인이 되는, 오래 수행되는 인터럽트 핸들러를 해결하기 위해 사용됩니다. 이런 응답시간들은 하나의 인터럽트에 많은 수의 이벤트를 전달할 수 있는 기기들에서 특히나 문제가 될 수 있는데, 이 인터럽트 핸들러는 이 이벤트들 전체를 처리하는 연장된 시간 기간동안 동작하게 될 것임을 의미합니다. 더 나쁜건 여전히 수행 중인 인터럽트 핸들러에 새로운 이벤트를 전달할 수 있는 기기들로, 그런 인터럽트 핸들러는 정해지지 않은 시간동안 수행될 수도 있고, 그로 인해 무한정 real-time 응답시간을 느리게 만들 수 있습니다.

이 문제를 해결하는 한가지 방법은 Figure 14.13에 보여진 쓰레드화 된 인터럽트의 사용입니다. 인터럽트 핸들러는 설정될 수 있는 우선순위로 수행되는, preemption 될 수 있는 IRQ 쓰레드의 컨텍스트에서 수행됩니다. 이렇게 되면 이 기기의 인터럽트 핸들러는 IRQ 쓰레드가 이 새로운 이벤트를 알아챌 수 있을 때까지의 짧은 시간동안만 수행됩니다. 그림에서 보였듯이, 쓰레드화된 인터럽트는 real-time 응답시간을 굉장히 개선할 수 있는데, IRQ 쓰레드의 컨텍스트에서 수행되는 인터럽트




Figure 14.12: Non-Threaded Interrupt Handler




Figure 14.13: Threaded Interrupt Handler

핸들러는 더 높은 우선순위의 real-time 쓰레드에 의해 preemption 당할 수 있기 때문인 게 한 부분적인 이유입니다.

하지만, 공짜 점심같은 건 없고, 쓰레드화된 인터럽트에도 단점이 존재합니다. 한 가지 단점은 길어진 인터럽트 응답시간입니다. 곧바로 인터럽트 핸들러를 수행하는 대신에, 핸들러의 수행은 IRQ 쓰레드가 수행될 수 있도록 되기까지 지연됩니다. 물론, 이는 인터럽트를 발생시키는 기기가 real-time 어플리케이션의 중요한 한 행정로에 있지 않다면 문제가 되지 않습니다.

또 다른 단점은 잘못 작성된 높은 우선순위의 real-time 코드가 인터럽트 핸들러를 starvation 상태에 빠뜨릴 수 있다는 것으로, 예를 들어 네트워킹 코드가 수행되지 못하게 만들어 버려서 이 문제를 디버깅하기 매우 어렵게 만들 수 있습니다. 따라서 개발자들은 높은 우선순위의 real-time 코드를 작성할 때에는 많은 주의를 기울여야 합니다. 이는 스파이더맨 철학을 떠올리게 합니다: With great power comes great responsibility.

Priority inheritance 는 다른 것들보다도 preemption 당할 수 있는 인터럽트 핸들러에 의해 락이 획득된다면 발생할 수 있는 우선순위 역전 문제를 해결하는데 사용됩니다 [SRL90b]. 낮은 우선순위의 쓰레드가 락

을 잡았지만, 최소 CPU 당 하나씩의 갯수를 갖는 중간 우선순위의 쓰레드들에게 preemption 당한다고 생각해 보세요. 만약 인터럽트가 발생한다면, 높은 우선순위의 IRQ 쓰레드는 중간 우선순위 쓰레드들 가운데 하나를 preemption 시킬 겁니다만, 낮은 우선순위의 쓰레드가 잡은 락을 잡기로 한 동안만 그렇습니다. 불행히도, 이 낮은 우선순위의 쓰레드는 수행이 시작되기 전까지는 락을 놓을 수가 없는데, 중간 우선순위 쓰레드들이 낮은 우선순위 쓰레드의 수행이 불가능하게 하고 있습니다. 따라서 높은 우선순위의 IRQ 쓰레드는 중간 우선순위 쓰레드들 가운데 하나가 자신의 CPU를 놓기 전까지는 그 락을 잡을 수가 없습니다. 짧게 말해서, 이 중간 우선순위 쓰레드가 간접적으로 높은 우선순위의 IRQ 쓰레드의 수행을 막고 있는 셈인데, 이는 고전적인 우선순위 역전의 한 예입니다.

쓰레드화된 인터럽트가 아닌 경우에는 낮은 우선순위의 쓰레드는 락을 잡고 있는 동안 인터럽트를 불능화 시켜야만 해서 중간 우선순위 쓰레드가 낮은 우선순위 쓰레드를 preemption 하는 일을 방지하므로, 이 우선순위 역전 현상은 발생하지 않음을 알아두세요.

이에 대한 우선순위 상속이라는 해결책에서, 락을 잡으려 하는 높은 우선순위 쓰레드는 자신의 우선순위를 락을 잡고 있는 낮은 우선순위의 쓰레드에게 그 락이 해



Figure 14.14: Priority Inversion and User Input

제될 때까지 넘겨주게 되고, 그런 식으로 긴 시간동안의 우선순위 역전을 방지합니다.

물론, 우선순위 상속은 나름대로의 한계를 가지고 있습니다. 예를 들어, 여러분이 여러분의 어플리케이션이 우선순위 역전 문제를 완전히 막을 수 있도록 설계할 수 있다면, 여러분은 어떤 더 나은 응답시간을 얻을 것입니다 [Yod04b]. 우선순위 상속이 최악의 경우의 응답시간에 두번의 컨텍스트 스위치를 추가한다는 점을 놓고 보면 이는 놀라운 일은 아닙니다. 그렇다면 하나, 우선순위 상속은 정해지지 않은 시간동안의 수행 연기를 제한된 응답시간의 증가와 교환할 수 있게 하고, 우선순위 상속의 소프트웨어 엔지니어링적 이득은 많은 어플리케이션에서 그 응답시간 비용보다 높을 겁니다.

또 다른 한계점은 특정 운영 체제의 컨텍스트 내에서, 락 기반의 우선순위 역전 문제만을 해결한다는 점입니다. 이런 이유로 해결할 수 없는 우선순위 역전 문제의 한 예는 높은 우선순위 쓰레드가 낮은 우선순위의 프로세스에 의해 만들어질 메세지를 소켓에서 받으려 기다리고 있는데, 이 낮은 우선순위 프로세스들은 중간 우선순위의 CPU를 많이 사용하는 프로세스들에게 preemption 당한 경우입니다. 또한, 사용자 입력에 우선순위 상속을 적용할 때의 또 다른 잠재적 단점이 Figure 14.14에 그려져 있습니다.

마지막 한계는 reader-writer 락킹과 관계되어 있습니다. 우리가 매우 많은 수의, 예를 들어 수천개의 낮은 우선순위 쓰레드들을 가지고 있으며, 각각의 쓰레드는 특정 reader-writer 락을 읽기 권한으로 잡고 있다고 생각해 봅시다. 이 쓰레드들이 모두 최소 CPU 당 하나의 중간 우선순위 쓰레드가 존재하며, 이 중간 우선순위 쓰레드들로 인해 preemption 당했다고 생각해 봅시다. 마지막으로, 높은 우선순위 쓰레드가 깨어나고 이 reader-writer 락을 쓰기 권한을 잡으려 한다고 생각해 봅시다. 우리가 읽기 권한으로 이 락을 잡고 있는 쓰레드들의 우선순위를 얼마나 필사적으로 올려주는가에 관계 없이, 이 높은 우선순위 쓰레드가 쓰기 권한을 얻게 되기까지는

긴 시간이 될 겁니다.

이 reader-writer 락 우선순위 역전 문제에 대해서는 몇 가지 가능한 해결책들이 존재합니다:

1. 해당 reader-writer 락에 대해 한번에 하나의 읽기 권한의 락 획득만을 가능하게 합니다. (이는 리눅스 커널의 -rt 패치셋에서 전통적으로 택해진 방법입니다.)
2. 해당 reader-writer 락에 대해서 한번에 N 개의 읽기 권한 락 획득만을 가능하게 하는데, 이 때 N 은 CPU의 갯수입니다.
3. 해당 reader-writer 락에 대해서 한번에 N 개의 읽기 권한 락 획득만을 가능하게 하는데, 이 때 N 은 어떤 방식으로든 개발자에 의해 선택된 숫자입니다. 리눅스 커널의 -rt 패치셋에서도 언젠가는 이 방법을 취하게 될 좋은 기회가 존재할 겁니다.
4. 높은 우선순위 쓰레드가 보다 낮은 우선순위로 수행되고 있는 쓰레드에 의해 읽기 권한으로 잡힌 reader-writer 락에 대해서 쓰기 권한을 획득하려는 것을 방지합니다. (이는 *priority ceiling* 프로토콜의 한 변종입니다 [SRL90b].)

Quick Quiz 14.5: 하지만 reader-writer 락에 대해서 한번에 하나의 read 권한 획득만을 허용한다면, 그건 배타적 락과 똑같은 거 아닌가요???

어떤 경우들에 있어, reader-writer 락 우선순위 역전 문제는 reader-writer 락을 RCU로 변환하는 것으로 방지하는 게 가능한데, 이는 다음 섹션에서 짧게 이야기 합니다.

Preemptible RCU 는 Section 9.5에서 이야기 된 것처럼, reader-writer 락킹의 대체로 사용될 수 있습니다 [MW07, MBWW12, McK14d]. Preemptible RCU가 사용될 수 있는 곳에서, preemptible RCU는 읽기 쓰레드들과 업데이트 쓰레드들이 동시에 수행될 수 있도록 해줌으로써, 낮은 웃너순위의 읽기 쓰레드들이 높은 우선순위의 업데이트 쓰레드들 위에 어떤 종류의 우선순위 역전 시나리오를 가하는 것을 막아줍니다. 하지만, 이게 유용하게 사용되려면, 오랫동안 이어지는 RCU read-side 크리티컬 섹션을 preempt하는게 가능하도록 할 필요가 있습니다 [GMTW08]. 그러지 않는다면, 길게 이어지는 RCU read-side 크리티컬 섹션들은 지나치게 긴 real-time 응답시간을 초래할 것입니다.

그래서 Preemptible RCU 구현 하나가 리눅스 커널에 추가되었습니다. 이 구현은 현재 RCU read-side 크리티컬 섹션 내에서 preemption 당한 태스크들의 리스트를 유지하면서 커널 내의 모든 각각의 task의 상태를 개별적으로 추적해야 하는 필요성을 막습니다. 하나의 grace

Listing 14.2: Preemptible Linux-Kernel RCU

```

1 void __rcu_read_lock(void)
2 {
3     current->rcu_read_lock_nesting++;
4     barrier();
5 }
6
7 void __rcu_read_unlock(void)
8 {
9     struct task_struct *t = current;
10
11    if (t->rcu_read_lock_nesting != 1) {
12        --t->rcu_read_lock_nesting;
13    } else {
14        barrier();
15        t->rcu_read_lock_nesting = INT_MIN;
16        barrier();
17        if (ACCESS_ONCE(t->rcu_read_unlock_special.s))
18            rCU_read_unlock_special(t);
19        barrier();
20        t->rcu_read_lock_nesting = 0;
21    }
22 }

```

period 는 다음과 같이 종료될 수 있습니다: (1) 일단 모든 CPU 들이 현재의 grace period 시작 전부터 효과를 발휘하고 있던 모든 RCU read-side 크리티컬 섹션들을 완료했을 때, 그리고 (2) 모든 그런 이전부터 존재했던 크리티컬 섹션의 중간에 preemption 당했던 모든 task 들이 그들의 리스트로부터 그 자신을 제거했을 때. 이 구현의 간단화된 버전이 Listing 14.2 에 보여져 있습니다. __rcu_read_lock() 함수는 line 1-5 에, 그리고 __rcu_read_unlock() 함수가 line 7-22 에 있습니다.

__rcu_read_lock() 의 line 3 은 rCU_read_lock() 함수의 중첩된 호출 횟수의 task 별 카운트를 증가시키며, line 4 는 컴파일러가 RCU read-side 크리티컬 섹션의 뒤따르는 코드가 앞의 rCU_read_lock() 보다 앞으로 컴파일러가 재배치 하는 것을 막습니다.

__rcu_read_unlock() 의 line 11 에서는 중첩 수준 카운트가 1인지 확인해보는데, 달리 말하자면, 이 함수 호출이 rCU_read_unlock() 호출의 중첩된 단계 중 가장 바깥의 단계인지를 확인합니다. 그렇지 않다면, line 12 에서는 이 카운트를 감소시키고, 제어는 호출자에게로 되돌아갑니다. 그렇지 않다면, 이게 rCU_read_unlock() 의 가장 바깥으로, line 14-20 을 통해 제어되는 크리티컬 섹션의 마무리를 필요로 합니다.

Line 14 는 컴파일러가 크리티컬 섹션 내의 코드가 rCU_read_unlock() 를 구성하는 코드와 재배치하는 것을 막습니다. Line 15 는 중첩 카운트를 인터럽트 핸들러 내에 포함된 RCU read-side 크리티컬 섹션들과의 경주 상태를 막기 위해 충분히 작은 음수로 설정하고 [McK11a], line 16 은 컴파일러가 이 할당문을 line 17 의 특수 경우 체크와 재배치 시키는 것을 막습니다. Line 17 이 특수 처리가 필요하다고 판단하면, line 18 은 이 특수 처리를 하기 위해 rCU_read_unlock_special() 를 수행시킵니다.

필요한 특수 처리에는 여러 종류가 있습니다만, 우리는 RCU read-side 크리티컬 섹션의 preemption 되었을 때에 필요한 것들에만 집중하도록 하겠습니다. 이 경우, 해당 task 는 자신의 RCU read-side 크리티컬 섹션 중에 처음 preemption 되었을 때에 자신이 추가되었던 리스트로부터 자신을 제거해야만 합니다. 하지만, 이런 리스트들은 lock 으로 보호된다는 점을 알 필요가 있는데, 이는 rCU_read_unlock() 이 더이상 lockless 하지 않음을 의미합니다. 하지만, 가장 높은 우선순위의 쓰레드는 preemption 당하지 않을 것이고, 따라서, 그런 가장 높은 우선순위의 쓰레드들의 rCU_read_unlock() 은 어떤 락도 잡지 않을 겁니다. 또한, 만약 조심스럽게 구현되었다면, 락킹은 real-time 소프트웨어의 동기화를 위해 사용될 수 있습니다 [Bra11].

특수 처리가 필요하든 그렇지 않든, line 19 는 컴파일러가 line 17 에서의 체크와 중첩 카운트를 0 으로 만드는 line 20 을 재배치 하는 것을 막습니다.

Quick Quiz 14.6: Listing 14.2 의 line 17 에서의 t-> rCU_read_unlock.special.s 의 로드 직후에 preemption 이 발생했다고 생각해 봅시다. 그렇게 되면 해당 task 가 rCU_read_unlock_special() 를 수행시키지 못하게 되어서, 자기 자신을 현재 grace period 를 막고 있는 task 들의 리스트로부터 삭제하는 것을 막아서, 그 grace period 가 무한정 길어질 수 있도록 할 수 있지 않을까요? ■

이 preemptible RCU 구현은 읽기가 대부분인 데이터 구조에게 많은 수의 읽기 쓰레드들의 우선순위 증가에 피할 수 없는 자연 없이 real-time 응답시간을 가능하게 합니다.

Preemptible spinlocks 는 리눅스 커널에서의 긴 시간 동안 잡히는 spinlock 기반의 크리티컬 섹션 때문에 -rt 패치셋에서의 중요한 부분입니다. 이 기능은 아직 메인라인에 들어가지는 못했습니다: 컨셉적으로 spinlock 을 위한 sleeplock 의 간단한 대체품이긴 하지만, 상대적으로 논란의 여지가 있는 것으로 증명되었습니다.⁹ 하지만, preemptible spinlock 은 real-time 응답시간을 수십 마이크로세컨드 아래로 내릴 필요가 있습니다.

물론, 예를 들면 최근에는 데드라인 스케줄링과 같은, 세계급의 real-time 응답시간을 이루는게 굉장히 중요한 다른 리눅스 커널 컴포넌트가 많이 존재합니다만, 이 섹션에서 언급된 것들은 -rt 패치셋과 합쳐진 리눅스 커널에서는 잘 동작하는 것처럼 보입니다.

⁹ 또한, -rt 패치셋의 개발은 최근 몇년간 느려졌는데, 아마도 이미 메인라인 리눅스 커널에 존재하는 real-time 기능들이 상당히 많은 사용에 있어 충분하기 때문일 수 있습니다 [Edg13, Edg14]. 하지만, OSADL (<http://osadl.org/>) 는 -rt 패치셋에 남아있는 코드를 메인라인으로 옮기기 위한 자금을 모으기 위해 일하고 있습니다.

14.3.5.2 Polling-Loop Real-Time Support

첫인상으로 보면, polling loop 의 사용은 모든 존재 가능한 운영 체제 간섭 문제들을 없앨 것처럼 보일 수 있습니다. 무엇보다도, 만약 주어진 CPU 가 커널에 들어가질 않는다면, 해당 커널은 완전히 그 그림 바깥에 있는 것이죠. 그리고 커널을 간섭하지 못하도록 두는 전통적인 방법은 단순히 커널을 갖지 않는 것이고, 많은 real-time 어플리케이션들이 실제로 bare metal (순수한 기계 그 자체)에서 수행되는데, 자세히 말해보자면 8-bit 마이크로컨트롤러 위에서 수행됩니다.

어떤 분은 하나의 CPU 에 성능이 종속적인 사용자 모드 쓰레드를 특정 CPU 위에서 수행하고 모든 간섭의 원인을 회피함으로써 현대의 운영체제 커널에서 bare-metal 성능을 얻기를 희망할 수 있을 겁니다. 비록 현실은 그보다 더 복잡하긴 하지만, Frederic Weisbecker 에 의해 진행되었고 3.10 버전의 리눅스 커널에 받아들여진 NO_HZ_FULL 구현 [Cor13b] 덕에 정말 그렇게 하는게 가능해지고 있습니다. 더도 아니고 덜도 아니고, 그런 환경을 올바르게 구성하기 위해서는 여러 OS jitter 의 가능한 원인들을 제어할 필요가 있으므로 상당한 주의가 필요합니다. 아래의 토론은 디바이스 인터럽트, 커널 쓰레드와 daemon들, 스케줄러 real-time throttling (이건 가능이지, 버그가 아닙니다!), 타이머, non-real-time 디바이스 드라이버, 커널 내의 global 동기화, scheduling-clock 인터럽트, 페이지 폴트, 그리고 non-real-time 하드웨어와 펌웨어 등을 포함하는 OS jitter 의 몇 가지 원인들의 제어를 다룹니다.

인터럽트는 OS jitter 의 많은 양의 대단한 원인입니다. 안타깝게도, 대부분의 경우에 인터럽트는 시스템이 바깥의 세계와 통신할 수 있도록 하기 위해 반드시 필요합니다. 이 OS jitter 와 바깥 세계와의 연락을 유지하는 사이에서의 충돌을 해결하는 한가지 방법은 작은 수의 최소한의 일을 처리할 CPU 를 예약해 두고, 모든 인터럽트를 그 CPU 들에서 처리하도록 강제하는 것입니다. 리눅스 소스 트리의 Documentation/IRQ-affinity.txt 파일은 어떻게 디바이스 인터럽트를 특정 CPU 로 향하도록 할 수 있는지 설명하는데, 현재 2015년 초에 있어서는 다음과 같이 됩니다:

```
echo 0f > /proc/irq/44/smp_affinity
```

이 커맨드는 인터럽트 #44 를 CPU 0-3 으로 몰아넣을 겁니다. Scheduling-clock 인터럽트는 특수한 처리를 필요로 하며, 이 섹션의 뒤쪽에서 그에 대해 설명할 것임을 알아두시기 바랍니다.

OS jitter 의 두번째 원인은 커널 쓰레드와 daemon 들입니다. RCU 의 grace-period kthread (rcu_bh, rcu_preempt, 그리고 rcu_sched) 와 같은 개별적인 커널 쓰레드는 taskset 커맨드, sched_setaffinity() 시

스템콜, 또는 cgroups 를 사용해 어떤 CPU 로든 원하는대로 수행되는 CPU 를 지정당할 수 있습니다.

Per-CPU kthread 들은 종종 더 어려운 과제가 되는데, 어떤 때에는 하드웨어 구성과 워크로드 구성을 강제합니다. 이런 kthread 들로부터의 OS jitter 를 방지하는 것은 특정한 타입의 하드웨어가 real-time 시스템으로 포함되지 않도록 해서 모든 인터럽트와 I/O 초기화가 최소한의 일만을 하는 CPU 에서 처리되도록 하거나, 일거리들을 일을 하는 CPU 로부터 다른 곳으로 넘겨지도록 하기 위해 특수한 커널 Kconfig 나 boot 패러미터가 선택되도록 하거나, 일하는 CPU 들이 커널에 들어가지 않도록 할 것을 필요로 합니다. 구체적인 per-kthread 에 대한 조언을 리눅스 커널 소스의 Documentation 디렉토리 내의 kernel-per-CPU-kthreads.txt 에서 찾을 수 있을 겁니다.

리눅스 커널에서 real-time 우선순위로 돌아가는 CPU 에 성능이 종속적인 쓰레드에 대한 OS jitter 의 세번째 원인은 스케줄러 자신입니다. 이것은 설령 여러분의 real-time 어플리케이션에 무한루프 버그가 존재한다고 할지라도 중요한 non-realtime 일이 매 초마다 최소한 50 밀리세컨드는 할당받을 수 있도록 보장할 수 있도록 설계된, 의도적인 디버깅 기능입니다. 하지만, 여러분이 polling-loop-style real-time 어플리케이션을 수행할 때에는, 이 디버깅 기능을 꺼버릴 필요가 있을 겁니다. 이는 다음과 같이 행해질 수 있습니다:

```
echo -1 > /proc/sys/kernel/sched_rt_runtime_us
```

이 커맨드를 수행시키기 위해서는 여러분은 물론 root 로 수행시켜야 하고, Spiderman 철학을 충분히 고려해야 할 필요가 있습니다. 위험을 최소화 시키기 위한 한가지 방법은 이 단락의 앞부분에서와 마찬가지로 인터럽트와 kernel thread/daemon 들을 수행중인, CPU 에 성능이 종속적인 real-time 쓰레드들이 수행중인 CPU 로부터 다른 곳으로 옮기는 것입니다. 또한, 여러분은 Documentation/scheduler 디렉토리 안의 것들을 충분히 읽어야 합니다. 구체적으로는 sched-rt-group.txt 파일 안의 것이 중요한데, 여러분이 CONFIG_RT_GROUP_SCHED Kconfig 패러미터로 활성화된 cgroups real-time 기능을 사용하고 있다면 특히 그런데, 그 경우에는 Documentation/cgroups 디렉토리 안의 것들도 역시 읽어야 합니다.

OS jitter 의 네번째 원인은 타이머들입니다. 대부분의 경우, 특정 CPU 를 커널 바깥에 있도록 유지시키는 것은 타이머가 해당 CPU 위에 스케줄 되는 것을 막습니다. 한가지 중요한 예외는 순환하는 타이머로, 특정 타이머 처리 부분이 같은 타이머의 다음 발생을 일으키는 경우입니다. 그런 타이머가 어떤 이유로든 특정 CPU 에서 시작되게 된다면, 그 타이머는 그 CPU 에서 주기적으로 수행되기를 계속할 것이어서 무기한적으로 OS jitter 를 일으킬 수 있습니다. 순환하는 타이머를

연기시키는 조합하지만 효율적인 방법은 CPU hotplug를 사용해서 CPU에 성능이 종속적인 real-time 어플리케이션 쓰레드들이 수행되는 CPU들을 모두 껐다가 다시 켜고 여러분의 real-time 어플리케이션을 시작하는 것입니다.

OS jitter의 다섯번째 원인은 real-time으로 사용될 것으로 의도되지 않은 디바이스 드라이버들로부터 제공됩니다. 오래된 규범적인 예제를 들어보자면, 2005년에 VGA 드라이버는 인터럽트를 불능화 시킨 채 프레임 버퍼를 0으로 가득채움으로써 화면을 빈 화면으로 만들 수 있었는데, 이는 수십 밀리세컨드의 OS jitter를 초래했습니다. 디바이스 드라이버가 포함시킨 OS jitter를 막는 한가지 방법은 real-time 시스템에서 많이 사용되는, 그리고 따라서 그것의 real-time 버그들이 고쳐진 디바이스를 조심스럽게 고르는 것입니다. 또 다른 방법은 그런 디바이스들의 인터럽트와 그 디바이스를 사용하는 모든 코드를 특정한 최소한의 일만 하는 CPU들에게 국한시키는 것입니다. 세번째 방법은 그 디바이스의 real-time 워크로드를 지원할 수 있는 능력을 테스트하고 모든 real-time 버그들을 고치는 것입니다.¹⁰

OS jitter의 여섯번째 원인은 커널 내부의 전체 시스템 동기화 알고리즘에 의해 제공되는데, 가장 명백한 건 글로벌 TBL-flush 알고리즘입니다. 이는 memory-unmapping 오퍼레이션을 막고, 명시적으로 커널 내에서의 unmapping 오퍼레이션들을 막는 것으로 막아질 수 있습니다. 2015년 초인 오늘날, 커널 내의 unmapping 오퍼레이션들을 막는 방법은 커널 모듈의 unloading을 막는 것입니다.

OS jitter의 일곱번째 원인은 scheduling-clock 인터럽트와 RCU 콜백 수행에서부터 제공되어집니다. 이것들은 여러분의 커널을 NO_HZ_FULL Kconfig 패러미터를 활성화 시킨채로 빌드하고, nohz_full= 패러미터가 real-time 쓰레드들을 수행하게 될 CPU들의 리스트를 명시하도록 한 채로 부팅함으로써 막아질 수 있습니다. 예를 들어, nohz_full=2-7은 CPU 2, 3, 4, 5, 6, 그리고 7을 일하는 CPU들로 만들어서, CPU 0과 1을 최소한의 일만 하는 CPU로 남겨둘 겁니다. 일하는 CPU들은 한 개가 넘는 runnable task가 각각의 CPU 위에 존재하지 않는 한은 scheduling-clock 인터럽트를 발생시키지 않을 것이고, 각각의 일하는 CPU의 RCU 콜백들은 최소한의 일만 하는 CPU들 가운데 하나에서 수행될 겁니다. CPU에 하나의 runnable task만이 존재한다는 이유로 scheduling-clock 인터럽트를 금지시킨 CPU는 *adaptive ticks mode*에 있다고 불리웁니다.

nohz_full= 부팅 패러미터에 대한 대안으로, 여러

¹⁰ 여러분께서 이 방법을 취한다면, 다른 사람들도 혜택을 얻을 수 있도록 그 수정사항을 업스트림으로 보내주시기 바랍니다. 여러분의 어플리케이션을 나중 버전의 리눅스 커널에 포팅해야 하게 된다면, 여러분이 그런 “다른 사람들”의 한명이 될 것이란 점을 명심해 주십시오.

Listing 14.3: Locating Sources of OS Jitter

```
1 cd /sys/kernel/debug/tracing
2 echo 1 > max_graph_depth
3 echo function_graph > current_tracer
4 # run workload
5 cat per_cpu/cpuN/trace
```

분은 여러분의 커널을 NO_HZ_FULL_ALL로 빌드할 수 있는데, 이는 CPU 0을 최소한의 일만 하는 CPU로 두고 모든 다른 CPU들을 일을 하는 CPU로 만들게 될 겁니다. 어떤 방식이던, 시스템의 나머지 부분드리 만들어내는 필수적인 최소한의 일들이 처리되기에 충분한 최소한의 일만 하는 CPU들이 할당되었을 수 있을 것을 보장할 필요가 있는데, 이는 충분한 벤치마크와 튜닝을 필요로 합니다.

물론, 공짜 점심은 없고, NO_HZ_FULL 역시 예외는 아닙니다. 앞서 언급되었듯이, NO_HZ_FULL은 kernel/user 전환의 비용을 더 비싸게 하는데, 다른 프로세스 처리의 필요성과 (RCU와 같은) 커널 서브시스템에게 전환을 알려야 하는 필요성 때문입니다. 이 방법은 또한 POSIX CPU 타이머가 활성화된 채 수행되고 있는 프로세스를 수행하는 CPU들이 adaptive-ticks 모드로 빠지는 것을 방지합니다. 추가적인 한계점, 트레이드오프, 그리고 설정에 대한 조언은 Documentation/timers/NO_HZ.txt에서 볼 수 있습니다.

OS jitter의 여덟번째 원인은 page fault입니다. 대부분의 리눅스 구현은 메모리 보호에 MMU를 사용하기 때문에, 이런 시스템 위에서 수행되는 real-time 어플리케이션들은 page fault를 일으킬 수 있습니다. 여러분의 어플리케이션의 페이지를 메모리에 둑아두기 위해서는 mlock()과 mlockall() 시스템 콜을 사용해서 major page fault를 막으세요. 물론, 너무 많은 메모리를 둑아두는 것은 시스템이 다른 일을 할 수 있도록 하는 것을 막을 수도 있기 때문에 Spiderman 철학이 여기에도 적용됩니다.

OS jitter의 아홉번째 원인은 불행하게도 하드웨어와 펌웨어입니다. 따라서 real-time에서의 사용을 위해 설계된 시스템을 사용하는게 중요합니다. OSADL은 시스템의 장시간 테스트를 수행하므로, 그들의 웹사이트 (<http://osadl.org/>)를 참고하는게 도움이 될 겁니다.

안타깝게도, 이 OS jitter 원인 리스트는 완벽할 수가 없는데, 이 리스트는 새로운 버전의 커널에 따라서 바뀔 것이기 때문입니다. CPU N이 CPU에 성능 종속적인 사용자 모드 쓰레드를 수행한다고 할 때, Listing 14.3에 보인 커맨드들이 이 CPU가 커널에 들어간 모든 시간의 리스트를 생성할 겁니다. 물론, line 5의 N은 정보를 얻고자 하는 CPU의 숫자로 대체되어야 하고, line 2의 1은 커널 내의 추가적인 함수 호출 수준을 보기 위해선 증가되어야 합니다. 결과로 나오는 기록은 OS jitter의 원인을 쫓아가는데에 도움이 될 수 있을 겁니다.

볼 수 있듯이, CPU에 성능 종속적인 real-time 쓰레드를 리눅스와 같은 범용 목적의 OS 위에서 수행하면서 bare-metal 성능을 얻는 것은 자세한 부분에 고통스럽게 정도로 신경쓸 것을 필요로 합니다. 물론 자동화가 도움이 될 수 있고, 일부 자동화가 적용되었습니다만, 상대적으로 적은 수의 사용자를 놓고 보면, 자동화는 상대적으로 느리게 나타날 것으로 예상될 수 있습니다. 더도 아니고 덜도 아니고, 범용 목적의 운영체제를 돌리면서 bare-metal에 가까운 성능을 얻는 능력은 real-time 시스템의 일부 타입의 구성을 더 쉽게 할 것을 약속합니다.

14.3.6 Implementing Parallel Real-Time Applications

Real-time 어플리케이션을 개발하는 것은 넓은 범위의 주제이고, 이 섹션은 그 중 일부 영역에 대해서만 다룹니다. 그렇게 되어서, Section 14.3.6.1은 real-time 어플리케이션에서 흔히 사용되는 일부 소프트웨어 컴포넌트들을 알아보고, Section 14.3.6.2는 polling-loop 기반 어플리케이션들이 어떻게 구현될 수 있는지에 대해서 간략한 개괄을 알아보고, Section 14.3.6.3는 스트리밍 어플리케이션들에 대해 비슷한 개관을 제공하며, Section 14.3.6.4은 이벤트 기반 어플리케이션을 간단히 다룹니다.

14.3.6.1 Real-Time Components

모든 엔지니어링의 영역들에서 그러하듯이, 생산성과 신뢰성에는 튼튼한 컴포넌트들이 필수적입니다. 이 섹션은 real-time 소프트웨어 컴포넌트들에 대한 전체 카탈로그는 아니고—그런 카탈로그는 한권의 책을 꽉 채울 겁니다—사용할 수 있는 컴포넌트들의 타입들에 대한 간략한 개관입니다.

Real-time 소프트웨어 컴포넌트들을 보기 위한 자연스런 장소는 wait-free 동기화 [Her91]를 제공하는 알고리즘들일 것이고, 실제로 lockless 알고리즘들은 real-time 컴퓨팅에 있어 매우 중요합니다. 하지만, wait-free 동기화는 한정된 시간 안에서의 진행을 보장할 뿐이고, real-time 컴퓨팅은 제한된 시간 내에서의 진행에 대한 훨씬 더 엄중한 보장을 제공하는 알고리즘을 필요로 합니다. 무엇보다도, 백년도 한정된 시간입니다만 여러분의 데드라인이 밀리세컨드 단위로 측정된다면 별도움이 되지 않을 겁니다.

더도 아니고 덜도 아니고, atomic test and set, atomic exchange, atomic fetch-and-add, 순환형 배열에 기반한 single-producer/single-consumer FIFO queues, 그리고 다양한 쓰레드별 분할 알고리즘 등을 포함하는, 제한된 응답 시간을 제공하는 중요한 wait-free 알고리즘들이 일부 존재합니다. 또한, 최근의 연구는 lock-free 보장을 포

함하는 알고리즘은¹¹ 확률적인 fair scheduler와 fail-stop 버그로부터 자유로울 것을 가정하는 실제 사례에서는 wait-free와 동일한 응답시간을 제공한다는 발견을 확인했습니다 [ACHS13].¹² 이는 곧 lock-free 스택과 큐들은 real-time 영역에의 사용이 적합함을 의미합니다.

Quick Quiz 14.7: 하지만 fail-stop 버그에도 불구하고 올바르게 동작하는게 가치있는 fault-tolerance 속성이 있는데 하나 아닌가요? ■

이론적으로는 그려함에도, 실전에서는 real-time 프로그램에 락킹이 자주 사용되곤 합니다. 하지만, 더 엄격한 제약 하에서는 락 기반의 알고리즘들 역시 제한된 응답시간을 제공할 수 있습니다 [Bra11]. 이런 제약들은 다음과 같은 것들을 포함합니다:

1. Fair scheduler. 고정된 우선순위 scheduler의 일반적인 경우에, 제한된 길이의 응답시간은 가장 높은 우선순위 쓰레드들에게만 제공됩니다.
2. 워크로드를 지원하기에 충분한 대역폭. 이 제약을 뒷받침하는 하나의 구현 상의 규칙 하나는 “평범한 운영 중에는 모든 CPU의 idle 시간이 최소한 50%는 된다.” 또는, 더 형식적으로 말하자면, “제시된 부하는 워크로드가 언제든 schedule 될 수 있기에 충분할 만큼 낮아야 한다” 일 것입니다.
3. Fail-stop 버그의 부재.
4. 제한된 획득, 이관, 해제 응답시간을 갖는 FIFO 락킹 기능들. 다시 말하지만, 같은 우선순위 내에서는 FIFO로 동작하는 일반적인 락킹 기능들에 있어서, 제한된 크기의 응답시간은 가장 높은 우선순위의 쓰레드에게만 제공됩니다.
5. 무제한적인 우선순위 역전 현상을 막을 수 있는 어떤 방법. 이 섹션의 앞에서 언급된 priority-ceiling과 priority-inheritance 방법으로도 충분할 겁니다.
6. 락 획득의 제한된 중첩 정도. 우린 무제한적인 수의 락을 가질 수 있습니다만, 하나의 쓰레드가 한번에 그 중 몇개의 것 (이상적으로는 딱 하나) 이상을 잡으려 하지는 않을 때에만 그렇습니다.
7. 제한된 수의 쓰레드. 앞의 제약들과의 조합으로, 이 제약은 어떤 락을 잡기 위해 기다리고 있는 쓰레드의 수는 제한되어질 것임을 의미합니다.

¹¹ Wait-free 알고리즘은 제한된 시간 안에 모든 쓰레드가 진행을 이를 것을 보장하는 반면, lock-free 알고리즘은 제한된 시간 안에 최소한 하나의 쓰레드는 진행을 이를 것을 보장합니다.

¹² 이 논문은 또한 real-time 실전을 향한 이론적 한단계 진보인 제한된 최소한의 진행의 개념을 소개합니다.

- 모든 크리티컬 섹션이든 제한된 시간을 가질 것. 어떤 락에든 제한된 수의 쓰레드만이 기다리고 있고 제한된 크리티컬 섹션 길이만이 존재한다고 하면, 대기 시간의 최대 길이는 제한될 겁니다.

Quick Quiz 14.8: 전 잘 모르겠지만 이 리스트 앞에 “포함한다”는 단어를 봤어요. 다른 제약도 존재하는 건가요? ■

이 결론은 real-time 소프트웨어에 사용되기 위한 상당히 많은 알고리즘과 데이터 구조들의 보고를 염니다—그리고 오랫동안의 real-time 관습을 검증합니다.

물론, 세심하고 간단한 어플리케이션 설계 역시 광장히 중요합니다. 세계 최고의 real-time 컴포넌트도 형편없이 만들어진 설계를 좋게 만들지는 못합니다. 병렬 real-time 어플리케이션을 위해서, 동기화 오버헤드는 설계의 핵심 컴포넌트가 되어야만 하는게 분명합니다.

14.3.6.2 Polling-Loop Applications

많은 real-time 어플리케이션들이 센서 데이터를 읽고 제어 법칙을 계산하고, 제어를 위한 출력을 내놓는 하나의 CPU에서 돌아가는 루프로 구성됩니다. 만약 센서 데이터를 제공하고 제어를 위한 출력을 받는 하드웨어 레지스터가 어플리케이션의 주소 공간으로 매핑된다면, 이 루프는 시스템콜로 접근, 조작될 수 있습니다. 하지만 Spiderman 철학을 기억하세요: 거대한 힘에는 거대한 책임이 따라오고, 이 경우에는 하드웨어 레지스터에 잘못된 참조를 함으로써 하드웨어를 벽돌로 만들어 버리는 걸 막을 책임이 따라옵니다.

이런 구성은 종종 bare metal 위에서 운영체제의 도움(또는 간섭) 없이 이루어집니다. 하지만, 하드웨어 기능을 늘리고 자동화 수준을 늘리는 것은 소프트웨어 기능을 늘리는 동기를 제공하는데, 예를 들어 사용자 인터페이스, 기록 남기기, 보고서 만들기, 모두 운영체제에 의해 도움받을 수 있습니다.

범용 목적 운영체제의 전체 기능과 능력으로의 접근을 가지면서도 bare metal에서 수행하는 것의 이득을 대부분 가져갈 수 있는 한가지 방법은 Section 14.3.5.2에서 설명한 리눅스 커널의 NO_HZ_FULL 기능을 사용하는 것입니다. 이 기능은 리눅스 커널의 버전 3.10에서부터 사용 가능해졌습니다.

14.3.6.3 Streaming Applications

비데이터 real-time 어플리케이션의 대중적인 것들은 다양한 출처로부터 입력을 받아들이고, 그것을 내부적으로 처리하고, 알림과 요약된 결과를 출력합니다. 이런 *streaming application*은 많은 경우 상당히 병렬적으로, 다른 출처로부터의 정보들을 동시적으로 처리합니다.

Streaming application을 구현하는 한가지 방법은 다른 처리 단계들을 연결하는데에 고밀도의 배열로 이루어진 순환형 FIFO를 사용하는 것입니다 [Sut13]. 그런 각각의 FIFO는 그대로 집어넣을 원소를 생성하는 하나의 생성자 쓰레드와 그로부터 원소를 꺼내서 소비하는(아마도 다른) 하나의 소비자 쓰레드만을 갖습니다. 합쳐지는 곳(fan-in)과 분산되는 곳(fan-out)은 자료구조보다는 쓰레드를 사용하며, 따라서 일부 FIFO들의 출력이 합쳐져야 한다면, 다른 쓰레드 하나가 그것들로부터 입력을 받아서 이 별개의 쓰레드가 단하나의 생산자가 되는 또다른 FIFO에 출력을 내보내게 됩니다. 유사하게, 만약 특정 FIFO의 출력이 나뉘어져야 한다면, 별개의 하나의 쓰레드가 이 FIFO로부터 입력을 받아와서 여러개의 FIFO에 필요한 대로 출력을 내보내게 됩니다.

이 방법은 제한적으로 보일 수도 있습니다만, 이 방법은 최소한의 동기화 오버헤드를 가지고 쓰레드간의 통신이 가능하게 하며, 빠빠한 응답시간 제약을 지켜야 할 때에 최소한의 동기화 오버헤드는 중요합니다. 이는 각각의 단계에서 처리해야 하는 일의 양이 작아서 동기화 오버헤드가 처리 오버헤드보다 중요할 때에 특히나 그러합니다.

각각의 개별적인 쓰레드는 CPU에 성능이 제한되어 있을 수 있는데, 이 경우 Section 14.3.6.2에서의 조언이 적용될 수 있을 겁니다. 반면에, 만약 각각의 개별적인 쓰레드가 각자의 입력 FIFO로부터의 데이터를 기다리면서 멈춰서 있다면, 다음 섹션의 조언이 적용될 수 있을 겁니다.

14.3.6.4 Event-Driven Applications

우린 중간 크기의 산업용 엔진으로의 연로 투입을 event-driven 어플리케이션의 한가지 간단한 예로 사용해 보도록 하겠습니다. 일반적인 운영 조건 상에서, 이 엔진은 연료가 상자점(엔진의 타이밍 측정이 만들어지는 기준점)을 둘러싼 1도의 간격 내에 투입될 것을 필요로 합니다. 우리가 1,500-RPM 회전율을 가정한다면, 우리는 초당 25 회의 회전, 초당 9,000 도의 회전을 갖게 되는 셈이며, 이는 곧 1도 회전당 111 마이크로세컨드로 이야기할 수 있습니다. 따라서 우리는 약 100 마이크로세컨드의 시간 간격 내에서 연료 투입을 스케줄 해야 합니다.

여러분이 엔진을 만들고 있긴 하지만, 연로 투입을 초기화하기 위해 시간 기준의 대기가 사용되었다고 생각해 보면, 전 여러분이 회전 센서를 제공하길 바랍니다. 우린 시간 기준의 대기 기능의 기능성을 테스트 해야하는데, 아마도 Listing 14.4에 보인 것과 같은 테스트 프로그램을 사용할 수 있을 겁니다. 안타깝게도, 이 프로그램을 돌리면, 설령 -rt 커널을 사용한다 해도 우린 받아들이기 어려운 timer jitter를 겪게 될 겁니다.

Listing 14.4: Timed-Wait Test Program

```

1 if (clock_gettime(CLOCK_REALTIME, &timestart) != 0) {
2     perror("clock_gettime 1");
3     exit(-1);
4 }
5 if (nanosleep(&timewait, NULL) != 0) {
6     perror("nanosleep");
7     exit(-1);
8 }
9 if (clock_gettime(CLOCK_REALTIME, &timeend) != 0) {
10    perror("clock_gettime 2");
11    exit(-1);
12 }

```

여기서의 한가지 문제는 CLOCK_REALTIME 이 충분히 이상하게도, real-time에서의 사용을 위한 의도로 만들 어진 게 아니라란 점입니다. 그게 아니라, 이는 프로세스나 쓰레드에 의해 소비된 CPU 시간의 양에 반대되는 의미로 써의 “realtime”을 의미합니다. Real-time에서의 사용을 위해서라면, 여러분은 이대신에 CLOCK_MONOTONIC 을 사용해야 합니다. 하지만, 이렇게 변경하더라도, 결과는 여전히 받아들일만하지 못할 겁니다.

또 다른 문제는 이 쓰레드는 sched_setscheduler() 시스템콜을 사용해서 real-time 우선순위로 격상되어야 한다는 점입니다. 하지만 이 변경을 하더라도 충분치 않은데, 여전히 우린 page fault를 만날 수 있기 때문입니다. 우린 또한 어플리케이션의 메모리를 고정시켜서 page fault를 막기 위해 mlockall() 시스템콜을 사용해야 합니다. 이 변경들을 모두 가하면, 그 결과는 드디어 받아들일만 할 겁니다.

다른 환경에서는 추가적인 조정이 필요할 수 있습니다. 시간에 민감한 쓰레드들을 각자의 CPU로 블록 만들어야 할 수도 있고, 인터럽트를 그런 CPU들로부터 떨어뜨려야 할 수도 있습니다. 조심스럽게 하드웨어와 드라이버를 골라야 할 수도 있고, 커널 설정을 잘 설정해야 할 가능성이 높습니다.

이 예제에서 볼 수 있듯이, real-time 컴퓨팅은 상당히 어려울 수 있습니다.

14.3.6.5 The Role of RCU

기온, 습도, 기압에 의해 변화될 수 있는 점진적 변화를 겪는 데이터에 접근할 필요가 있는 별별 real-time 프로그램을 작성하고 있다고 생각해 봅시다. 이 프로그램에서의 real-time 응답 제약은 매우 가혹해서 스핀ning을 하거나 블록되는 것을 허용할 수 없고, 따라서 락킹을 상호할 수도 없고, 재시도 루프를 사용하는 것도 허용될 수 없어서 시퀀스 락이나 해저드 포인터를 사용할 수도 없습니다. 다행히도, 기온과 기압은 일반적으로 제어되고, 따라서 기본의 하드 코딩 된 데이터 집합만으로도 보통은 충분합니다.

하지만, 온도, 습도, 그리고 기압은 때때로 기본값으로부터 너무 크게 변화되기도 하고, 그런 경우에는 기본

Listing 14.5: Real-Time Calibration Using RCU

```

1 struct calibration {
2     short a;
3     short b;
4     short c;
5 };
6 struct calibration default_cal = { 62, 33, 88 };
7 struct calibration cur_cal = &default_cal;
8
9 short calc_control(short t, short h, short press)
10 {
11     struct calibration *p;
12
13     p = rcu_dereference(cur_cal);
14     return do_control(t, h, press, p->a, p->b, p->c);
15 }
16
17 bool update_cal(short a, short b, short c)
18 {
19     struct calibration *p;
20     struct calibration *old_p;
21
22     old_p = rcu_dereference(cur_cal);
23     p = malloc(sizeof(*p));
24     if (!p)
25         return false;
26     p->a = a;
27     p->b = b;
28     p->c = c;
29     rcu_assign_pointer(cur_cal, p);
30     if (old_p == &default_cal)
31         return true;
32     synchronize_rcu();
33     free(p);
34     return true;
35 }

```

값들을 대체할 수 있는 데이터를 제공해야 합니다. 기온, 습도, 그리고 기압은 점진적으로 변화되기 때문에, 업데이트된 값을 제공하는 건 몇분 내로 이뤄져야만 하긴 하지만 긴급한 성격의 문제는 아닙니다. 해당 프로그램은 cur_cal 이라 가상으로 이름지어진, 평소에는 정적으로 할당되고 기본의 측정값들이 가상의 a, b, c 란 이름의 필드들에 초기값으로 저장되어 있는 default_cal 을 가리키는 글로벌 포인터를 사용할 겁니다. 그렇지 않다면, cur_cal 은 동적으로 할당되고 현재의 측정값들을 제공하는 구조체를 가리키게 됩니다.

Listing 14.5는 이 문제를 해결하는데 RCU 가 어떻게 사용될 수 있는지 보입니다. 탐색들은 line 9-15의 calc_control()로 보여진 것처럼 결정적이며, real-time 요구사항을 일관적으로 지킵니다. 업데이트들은 line 17-35의 update_cal()에 보여진 것처럼 좀 더 복잡합니다.

Quick Quiz 14.9: Real-time 시스템들은 많은 경우 safety-critical 어플리케이션들에 사용된다는 점을 놓고 보면, 그리고 수행시간 메모리 할당은 많은 safety-critical 상황에서 숨겨진다는 점을 생각해보면, malloc() 호출은 뭐때매 있는거죠???

Quick Quiz 14.10: update_cal()을 보호하기 위해 어떤 동기화가 필요하지 않나요?



Figure 14.15: The Dark Side of Real-Time Computing



Figure 14.16: The Dark Side of Real-Fast Computing

이 예는 RCU 가 어떻게 real-time 프로그램들에 결정론적 read-side 데이터 구조를 제공할 수 있는지를 보입니다.

14.3.7 Real Time vs. Real Fast: How to Choose?

Real-time 과 real-fast 컴퓨팅 사이에서의 선택은 어려울 수 있습니다. Real-time 시스템은 종종 real-time 이 아닌 컴퓨팅 쪽에 처리량을 떨어뜨릴 수 있기 때문에, 필요치 않은 곳에 real-time 을 사용하는 것은 Figure 14.15 에 보여진 것처럼 문제가 될 수 있습니다. 그 정도는 적어도 여러분의 상사에게 미안함을 느끼게 만들기에는 거의 충분합니다!

경험에 따른 한가지 규칙은 여러분의 선택을 돋기 위해 다음의 네가지 질문을 사용합니다:

1. 평균적인 긴 시간동안의 처리량만이 유일한 목표인가?
2. 커다란 부하가 응답시간을 악화시키는게 받아들일 만한가?
3. `mlockall()` 시스템콜의 사용을 필요로 할만큼 높은 메모리 부하가 존재하는가?
4. 여러분의 어플리케이션의 기본적인 일감 항목이 완료되는데에 100 밀리세컨드 이상을 필요로 하는가?

이 질문들에 대한 대답들 중 하나라도 “그렇다”라면, 여러분은 real-time 보다는 real-fast 를 선택해야 하고, 그렇지 않다면, real-time 이 필요할 겁니다.

현명한 선택을 하시고, real-time 을 선택했다면, 여러분의 하드웨어, 펌웨어, 그리고 운영체제가 그 일을 수행하기에 적당함을 분명히 하세요!

The art of progress is to preserve order amid change
and to preserve change amid order.

Alfred North Whitehead

Chapter 15

Advanced Synchronization: Memory Ordering

인과성과 순차적 순서는 상당히 직관적이며, 해커들은 일반인들에 비해 이런 개념들을 잘 이해하고 있는 경향을 띠는 경우가 많습니다. 이런 직관들은 순차적 코드와, 락킹과 같은 표준적 상호배타성 메커니즘을 사용하는 병렬 코드를 작성하고, 분석하고, 디버깅하는데 매우 강력한 도구가 될 수 있습니다. 불행히도, 표준적 메커니즘을 사용하지 않는 코드에서는 이런 직관들이 깨어지게 되는데, 그런 중요한 예 하나는 이런 표준 메커니즘들을 구현하는 코드이고, 또 다른 하나는 완화된 동기화를 사용하는 성능이 중요한 코드입니다. 사실, 일부는 이 완화성이 덕목이라고 주장했습니다 [Alg13]. 이 챕터는 동기화 도구들과 다른 성능이 중요한 코드를 구현하기 충분한 만큼 메모리의 순서 규칙에 대해 여러분이 이해 할 수 있도록 돕습니다.

Section 15.1은 실제 컴퓨터 시스템이 메모리 참조를 재배치 할 수 있음을 보이고, 왜 그러는지 이유를 보이며, 원치 않는 재배치를 어떻게 방지할 수 있는지에 대한 정보를 제공합니다. Section 15.2와 15.3은 하드웨어와 컴파일러들이 각각 병렬 프로그래머에게 해줄 수 있는 것들의 보다 완전한 리스트를 제공합니다. Section 15.4은 일부 대표적 하드웨어 플랫폼들에 대한 자세한 설명을 제공합니다. 마지막으로, Section 15.5은 경험으로부터의 법칙 일부를 제공합니다.

Quick Quiz 15.1: 이 글은 첫번째 버전 후 거의 완전히 다시 쓰여졌습니다. 메모리 순서 규칙은 2017년 후반에는 그렇게 많이 바뀌지 않았을 텐데, 뭘 다시 쓴 걸까요? ■

15.1 Ordering: Why and How?

메모리 순서규칙의 필요성이 첫눈에 보면 `exists` 절이 절대 발동되지 않을 것을 보장하는 것처럼 보일 수 있는, Listing 15.1 (C-SB+o-o+o-o.litmus) 으로

보이고 있습니다.¹ 무엇보다도, `exists` 절 안에서 `0:r2=0` 가 성립된다면,² 우린 Thread P0() 의 `x1` 로드가 Thread P1() 의 `x1` 스토어보다 먼저 일어났어야만 한다고 희망하게 되며, 이는 곧 Thread P1() 의 `x0` 의 로드가 Thread P0() 의 `x0` 스토어보다 나중에 일어나서 `1:r2=2` 이어서 `exists` 절이 trigger 되지 않게 되길 바라게 됩니다. 이 예제는 대칭적이므로, 비슷한 이유로 `1:r2=0` 는 `0:r2=2` 를 보장하길 기대하게 됩니다. 불행히도, 메모리 배리어의 부재는 이런 희망들을 없애 버립니다. CPU는 비교적 강한 순서 규칙을 갖는 x86과 같은 시스템에서조차도 Thread P0() 와 Thread P1() 모두 순서를 바꿀 권한을 가지고 있습니다.

Quick Quiz 15.2: 컴파일러도 Listing 15.1의 Thread P0() 와 Thread P1() 의 메모리 액세스 순서를 바꿀 수 있죠, 그렇죠? ■

이런 재배치에 대한 의지는 litmus7 [AMT14] 같은 도구를 통해 확인될 수 있는데, 이 도구는 제 x86 랩탑에서 100,000,000 번의 시도에서 314회 반직관적인 순서가 발생함을 찾아냈습니다. 이상하게 들리겠지만, 두 로드가 모두 값 2를 리턴하는 경우는 덜 빈번하게 발생했는데, 이 경우엔 167번만 발생했습니다.³ 여기서의 교훈은 분명합니다: 증가된 반직관성은 확률의 감소를 의미하지 않습니다!

다음 섹션들은 이 직관이 정확히 어디서 깨졌는지 보이며, 이어서 여러분이 이런 문제들을 피할 수 있게 도와주는 메모리 순서 규칙의 정신적 모델을 제공합니다.

¹ 순수주의자들은 이 `exists` 절이 절대 만족되지 않는다고 표현 하겠는데, 여기선 assertion 비유를 위해 “trigger”라는 표현을 사용하겠습니다.

² 즉, Thread P0() 의 로컬 변수 `r2` 의 인스턴스는 0 값을 갖습니다. 리트머스 테스트 명명법의 문서를 위해선 Section 12.2.1 을 참고하세요.

³ 이 결과는 실제 하드웨어 구성, 얼마나 시스템에 부하가 가해졌는지, 그외에도 많은 것들에 예민하게 달라질 수 있음을 알아두시기 바랍니다.

Listing 15.1: Memory Misordering: Store-Buffering Litmus Test

```

1 C C-SB+o-o+o-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     int r2;
8
9     WRITE_ONCE(*x0, 2);
10    r2 = READ_ONCE(*x1);
11 }
12
13
14 P1(int *x0, int *x1)
15 {
16     int r2;
17
18     WRITE_ONCE(*x1, 2);
19     r2 = READ_ONCE(*x0);
20 }
21
22 exists (1:r2=0 /\ 0:r2=0)

```

다.

Section 15.1.1 왜 하드웨어 가 메모리 액세스들의 순서를 잘못 잡는지에 대한 짧은 소개를 제공하고, 이어서 Section 15.1.2 에서는 어떻게 여러분이 악의 사악한 하드웨어의 순서를 잘못잡는 계획을 좌절시킬 수 있는지에 대해 마찬가지로 짧은 소개를 제공합니다. 마지막으로, Section 15.1.3 은 뒤의 섹션들에서 더 잘 다듬어질 경험으로부터의 법칙들을 보입니다.

15.1.1 Why Hardware Misordering?

하지만 대체 왜 메모리 가 순서를 이상하게 만드는 경우가 발생하는거죠? CPU는 스스로 순서를 기록하고 있을 수 없는 건가요? 일단 그게 바로 우리가 어떤 것들을 기록하고 있기 위해 컴퓨터를 갖는 이유이지 않던가요?

많은 사람들이 실제로 자신의 컴퓨터가 사물에 대해 기록을 가지고 있을 것이라 기대합니다만, 많은 사람들은 또한 그 기록을 빠르게 관리할 것을 요구합니다. 하지만, Chapter 3 에서 보였듯이, 메인 메모리는 메모리로부터 하나의 변수를 가져오는데 필요한 시간 동안 수백개의 명령어를 수행할 수 있는 근래의 CPU 의 속도를 따라갈 못합니다. 따라서 CPU 들은 Figure 3.9 에서 보인 것과 같이 갈수록 커다란 캐시들을 갖추는데, 이는 특정 CPU 의 특정 변수로부터의 첫번째 로드가 Section 3.1.5 에서 이야기한 값비싼 캐시 미스를 낸다 하더라도, 최초의 캐시 미스는 해당 변수가 해당 CPU 의 캐시에 올라오게 하기 때문에 해당 CPU로부터 해당 변수로의 뒤이은 반복된 로드들은 매우 빠르게 수행될 수도 있음을 의미합니다.

하지만, 여러 CPU 들로부터 공유된 변수들 집합으로 이루어지는 빈번한 동시적 스토어들을 잘 처리할 필요




Figure 15.1: System Architecture With Store Buffers




Figure 15.2: CPUs Can Do Things Out of Order

또한 있습니다. Cache-coherent 시스템에서, 캐시들이 특정 변수의 여러 복사본들을 가지고 있다면, 이 모든 복사본들은 같은 값을 가져야만 합니다. 이는 동시의 로드들에 대해서는 매우 잘 동작하지만, 동시의 스토어들에 대해서는 그렇지 못합니다: 각각의 스토어는 기존 값의 복사본들 모두에 대해서 어떤 일을 해줘야 하는데 (또 다른 캐시 미스!), 이는 빛의 제한된 속도와 원자적 물질의 원리를 놓고 보면, 성급한 소프트웨어 해커들이 좋아하지 않을 만큼 느릴 겁니다.

따라서 CPU 들은 Figure 15.1 에 보인 것처럼 스토어 버퍼를 장착합니다. 특정 CPU 가 특정 변수에 스토어를 수행하는데 해당 변수가 해당 CPU 의 캐시에 존재하지 않는다면, 이 새로운 값은 해당 CPU 의 스토어 버퍼에 저장됩니다. 이 CPU 는 이제 이 스토어가 다른 CPU 들의 캐시들에 있을 수 있는 이 변수의 기존 값에 뭔가 작업을 수행할 동안 기다리지 않고 곧바로 작업을 진행 할 수 있습니다.

스토어 버퍼들이 성능을 상당히 향상시킬 수 있지만,

이것들은 인스트럭션들과 메모리 참조들이 비순차적으로 수행되게 만들 수 있는데, 이는 곧 심각한 혼란을 가져오게 되는데, 이 상황이 Figure 15.2에 그려져 있습니다. 구체적으로는, 이런 스토어 버퍼들이 Listing 15.1에 보인 스토어 버퍼 리트머스 테스트에 보인 잘못된 메모리 순서를 가능하게 합니다.

Table 15.1은 이런 잘못된 메모리 접근 순서가 어떻게 일어날 수 있는지 보입니다. Row 1은 최초의 상태를 보이는데, 이 때 CPU 0은 x_1 을 자신의 캐시에 가지고 있고 CPU 1은 x_0 를 자기의 캐시에 가지고 있으며, 두 변수 모두 값 0을 가지고 있습니다. Row 2는 각 CPU의 스토어 (Listing 15.1의 line 9와 18)로 인한 상태 변화를 보입니다. 두 CPU 모두 스토어가 향한 변수를 자신의 캐시에 가지고 있지 않았기에, 두 CPU는 모두 각자의 스토어들을 자신의 스토어 버퍼들에서 처리합니다.

Quick Quiz 15.3: 하지만 잠시만요!!! Table 15.1의 row 2에서 x_0 와 x_1 모두 동시에 두개의 값, 0과 1을 가지고 있어요. 어떻게 이게 가능한거죠??? ■

Row 3는 두개의 로드 (Listing 15.1의 line 10과 19)를 보입니다. 각 CPU에 의해 읽혀지는 변수들은 각 CPU의 캐시에 있기 때문에, 각각의 로드는 곧바로 캐시의 값을 반환하는데, 이 경우 모두 0의 값입니다.

하지만 이 CPU들은 일이 다 끝나지 않았습니다: 금방 이든 나중이든, 각자의 스토어 버퍼를 비워야만 합니다. 캐시는 캐시라인 (cacheline)이라 불리는 상대적으로 커다란 블록 단위로 데이터를 옮기기 때문에, 그리고 각각의 캐시라인은 여러 변수들을 담고 있을 수 있기 때문에, 각 CPU는 자신의 스토어 버퍼 안의 변수에 해당하는 캐시라인의 해당 변수에 해당하지 않는 부분은 만지지 않으면서 해당 변수에 해당하는 부분만을 업데이트 할 수 있도록 해당 캐시라인을 자신의 캐시로 가져와야만 합니다. 각 CPU는 또한 해당 캐시라인이 어떤 다른 CPU의 캐시에도 존재하지 않는다는 점을 보장해야만 하는데, 이를 위해 read-invalidate 오퍼레이션이 사용됩니다. Row 4에서 보인 것처럼, 두개의 read-invalidate 오퍼레이션이 완료된 후, 이 두 CPU는 서로 넘겨받은 캐시라인들을 가지고 있게 되어서, CPU 0의 캐시는 이제 x_0 를 담고 있고 CPU 1의 캐시는 x_1 을 담고 있게 됩니다. 일단 이 두 변수들이 각자의 새로운 안식처에 위치하게 되면, 각 CPU는 자신의 스토어 버퍼를 연관된 캐시 라인으로 비워낼 수 있게 되어서, 각 변수의 값을 row 5에 보인 대로 마지막 값으로 설정합니다.

Quick Quiz 15.4: 하지만 이 값들은 또다시 캐시에서 메인 메모리로 비워져야 하는거 아닌가요? ■

요약하자면, 스토어 버퍼들은 CPUe 들이 스토어 명령을 효과적으로 처리할 수 있도록 하기 위해 필요합니다만, 이게 반 직관적인, 잘못된 메모리 접근 순서를 야기할 수 있습니다.

하지만 여러분의 알고리즘이 정말로 메모리 참조의

Listing 15.2: Memory Ordering: Store-Buffering Litmus Test

```

1 C C-SB+o-mb-o+o-mb-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     int r2;
8
9     WRITE_ONCE(*x0, 2);
10    smp_mb();
11    r2 = READ_ONCE(*x1);
12 }
13
14
15 P1(int *x0, int *x1)
16 {
17     int r2;
18
19     WRITE_ONCE(*x1, 2);
20     smp_mb();
21     r2 = READ_ONCE(*x0);
22 }
23
24 exists (1:r2=0 /\ 0:r2=0)

```

순서를 맞춰야 한다면 어떻게 해야 할까요? 예를 들어, 여러분이 어떤 드라이버와 하나는 이 드라이버가 동작 중인지 여부를 말하고 (driver-running flag) 하나는 이 드라이버에 처리되기를 기다리는 중인 요청이 있는지 여부를 말하는 (request-pending flag) 한쌍의 플래그를 사용해 통신하고 있다고 생각해 봅시다. 요청을 보내는 쪽은 request-pending flag의 bit을 채우고, driver-running flag의 bit을 검사한 후, 비어있다면 드라이버를 깨웁니다. 드라이버가 자신이 아는 모든 대기중인 요청들을 처리했다면, 드라이버는 자신의 driver-running flag의 bit을 없애고, 다시 일을 시작해야 하는지 여부를 보기 위해 request-pending flag를 체크해야 합니다. 이 매우 합리적인 접근법도 하드웨어가 여기서의 스토어들과 로드들을 순서대로 처리한다고 보장할 수 있는 방법이 없다면 제대로 동작하지 않을 겁니다. 이게 다음 섹션의 주제입니다.

15.1.2 How to Force Ordering?

메모리 배리어 (예를 들어, 리눅스 커널의 `smp_mb()`)를 사용해 순서 규칙의 환상을 지키는데 필요한 표준적 동기화 도구들 (락킹과 RCU 같은)과 컴파일러 지시어들이 존재합니다. 이런 메모리 배리어들은 ARM, POWER, Itanium, 그리고 Alpha에서처럼 명시적 인스트럭션이 될 수 있고, x86에서 종종 그런 것처럼 다른 인스트럭션들에 의해 내포될 수도 있습니다. 이런 표준적 동기화 도구들은 순서가 지켜진다는 환상을 지키기 때문에, 여러분이 가장 쉽게 적용할 수 있는 방법은 그냥 이 도구들을 사용해서, 이 섹션을 그만 읽는 겁니다.

하지만, 여러분 스스로 그런 동기화 도구들을 구현해야 한다면, 또는 그런 메모리 순서 규칙이 어떻게 동작하

Table 15.1: Memory Misordering: Store-Buffering Sequence of Events

CPU 0			CPU 1		
Instruction	Store Buffer	Cache	Instruction	Store Buffer	Cache
1 (Initial state)		x1==0	(Initial state)		x0==0
2 x0 = 2;	x0==2	x1==0	x1 = 2;	x1==2	x0==0
3 r2 = x1; (0)	x0==2	x1==0	r2 = x0; (0)	x1==2	x0==0
4 (Read-invalidate)	x0==2	x1==0	(Read-invalidate)	x1==2	x1==0
5 (Finish store)		x0==2	(Finish store)		x1==2

는지에 그저 흥미가 있는 거라면, 계속 읽어주세요! 이 여정에서의 첫번째 정류장은 Listing 15.2 (C-SB+o-mb-o+o-mb-o.litmus) 으로, `smp_mb()` 리눅스 커널 메모리 배리어가 P0() 와 P1() 의 스토어와 로드 사이에 위치했다는 점을 제외하고는 Listing 15.1 와 동일합니다. 이 배리어들은 제 x86 랩탑에서의 100,000,000 번의 시도에도 반직관적인 결과가 일어나는 것을 막았습니다. 흥미롭게도, 이 배리어들로 인해 추가된 오버헤드는 두 로드가 모두 값 2 를 반환하는 경우가 800,000 번이 넘게 일어나게 만들었는데, 이는 이 배리어가 없는 Listing 15.1 의 코드에서는 167 번밖에 일어나지 않았던 것과 대조적입니다.

이 배리어들은 Table 15.2 에 보인 것과 같이 순서규칙에 깊은 영향을 끼칩니다. 앞의 두 행은 Table 15.1 에 보인 것과 같고 row 3 의 `smp_mb()` 인스트럭션들은 직접적으로 상태를 바꾸지 않지만, 이 인스트럭션들은 스토어들이 (row 4 와 5) 로드 (row 6) 전에 완료되도록 만들어서, Table 15.1 에서 보인 반직관적인 결과가 나타나지 못하게 합니다. 변수 x0 와 x1 은 row 2 에서 여전히 두개의 값을 갖지만, 앞서 약속한대로, 이 `smp_mb()` 인스턴스들은 최종적으로는 일을 더 깐깐하게 처리했음을 알아두시기 바랍니다.

비록 `smp_mb()` 같은 완전한 배리어는 극단적으로 강력한 순서 보장을 갖지만, 그 강력함은 높은 가격과 함께 옵니다. 아주 많은 상황이 훨씬 약한 순서 보장으로 처리될 수 있는데, 이를 위해선 훨씬 낮은 비용의 메모리 순서 규칙 인스트럭션을 사용해도 되며, 어떤 경우에는 메모리 순서 규칙 인스트럭션을 아예 사용하지 않아도 됩니다.

Table 15.3 은 리눅스 커널의 순서 보장 도구들과 그 보장사항들을 보이는 커닝 페이퍼를 보입니다. 각 열은 순서 보장을 제공할 수도, 하지 않을 수도 있는 도구들 또는 도구들의 카테고리에 연관되며, “Prior Ordered Operation” 과 “Subsequent Ordered Operation” 으로 라벨링된 행들은 각 열의 도구에 의해 순서가 맞춰지는 (또는 맞춰지지 않는) 오퍼레이션들입니다. “Y” 를 담는 셀들은 무조건적으로 순서가 제공됨을 의미하며, 다른 문자들은 순서가 부분적으로 또는 조건적으로 제공됨

을 의미합니다. 빈 셀들은 어떤 순서 보장도 제공되지 않음을 의미합니다.

“Store” 행은 또한 어토믹 RMW 오퍼레이션의 스토어 부분도 포함합니다. 또한, “Load” 행은 성공한 경우의 값을 리턴하는 `_relaxed()` RMW 어토믹 오퍼레이션을 다룹니다만, 결합된 “`_relaxed()` RMW operation” 행은 값을 리턴하는 경우의 결합된 경우를 제공합니다. 성공하지 못한 값을 리턴하는 어토믹 RMW 오퍼레이션을 수행하는 CPU 는 연관된 변수를 모든 다른 CPU 의 캐시에서 무효화 시켜야 합니다. 따라서, 좀 이상 하겠지만, 성공하지 못한 값을 리턴하는 어토믹 RMW 오퍼레이션은 스토어의 특성을 많이 가지며, 이는 “`_relaxed()` RMW operation” 행이 성공하지 못한 값을 리턴하는 atomic RMW 오퍼레이션과도 관련되어 있음을 의미합니다.

*`_acquire` 열은 `smp_load_acquire()`, `cmpxchg_acquire()`, `xchg_release()`, 등을 포함합니다; *`_release` 열은 `smp_store_release()`, `cmpxchg_release()`, `xchg_release()`, 등을 포함합니다; 그리고 “Successful Non-Relaxed Non-void RMW” 열은 `atomic_add_return()`, `atomic_add_unless()`, `atomic_dec_and_test()`, `cmpxchg()`, `xchg()`, 등을 포함합니다. “Successful” 이라는 수식어는 앞의 “`_relaxed()` operation” 행에서도 가리키듯이, 실패했을 때에는 메모리에도 순서에도 어떤 영향을 끼치지 않는 `atomic_add_return()`, `cmpxchg_acquire()`, 그리고 `cmpxchg_release()` 같은 도구들에 적용됩니다.

“C” 행은 누적성과 전파성을 의미하는데, 이에 대해서는 Sections 15.2.7.1 과 15.2.7.2 에서 설명됩니다. 해당 섹션을 읽기 전까지는, 이 행은 최대 두개 쓰레드만이 돌아가는 상황에서는 대부분 무시될 수 있다는 정도만 알아두면 되겠습니다.

Quick Quiz 15.5: Table 15.3 의 열들은 상당히 무작위적이고 복잡해 보입니다. 이 표의 개념적 근본이 무엇인가 있나요? ■

Quick Quiz 15.6: Table 15.3 은 왜 `smp_mb_after_unlock_lock()` 과 `smp_mb_after_spinlock()` 을 빼먹고 있나요? ■

Table 15.2: Memory Ordering: Store-Buffering Sequence of Events

CPU 0			CPU 1		
Instruction	Store Buffer	Cache	Instruction	Store Buffer	Cache
1 (Initial state)		x1==0	(Initial state)		x0==0
2 x0 = 2; x0==2	x0==2	x1==0	x1 = 2; x1==2	x1==2	x0==0
3 smp_mb(); x0==2	x0==2	x1==0	smp_mb(); x1==2	x1==2	x0==0
4 (Read-invalidate) x0==2	x0==2	x0==0	(Read-invalidate) x1==2	x1==2	x1==0
5 (Finish store)		x0==2	(Finish store)		x1==2
6 r2 = x1; (2) x1==2	x1==2	r2 = x0; (2)			x0==2

이 표는 단지 컨닝 페이퍼에 불과하며, 따라서 메모리 순서 규칙에 대한 제대로 된 이해를 대체할 수는 없습니다. 그런 이해를 세우기 시작하기 위해, 다음 섹션은 일부 경험에 의거한 규칙들을 소개합니다.

15.1.3 Basic Rules of Thumb

이 섹션은 매우 많은 상황에 대해 “훌륭하고 충분한” 기본적인 경험으로부터의 법칙들을 소개합니다. 사실, 여러분은 이 경험으로부터의 법칙들 외에는 어떤 것도 필요치 않은 채 훌륭한 성능과 확장성을 갖는 동시성 코드를 대부분 작성할 수 있습니다.

Quick Quiz 15.7: 하지만 특정 프로젝트가 이 경험으로부터의 법칙들의 범위 내에서 설계되고 코딩 될 수 있다고 알 수 있죠? ■

A given thread sees its own accesses in order. 이 규칙은 공유된 변수에 대한 로드와 스토어가 각각 READ_ONCE() 와 WRITE_ONCE() 를 사용한다는 것을 가정합니다. 그러지 않는다면, 컴파일러가 여러분의 코드를 바닥부터 휘저을 수 있고⁴, 가끔은 CPU 역시 조금은 코드를 휘저을 수 있습니다.

Ordering has conditional if-then semantics. Figure 15.3는 메모리 배리어들을 위한 이 규칙을 보입니다. 두 메모리 배리어가 모두 충분히 강력하다 가정하고 (확신이 서지 않는다면, 언제든 smp_mb() 를 사용하세요), 만약 CPU 1 의 액세스 Y1 이 CPU 0 의 액세스 Y0 뒤에 일어났다면, CPU 1 의 액세스 X1 은 CPU 0 의 액세스 X1 뒤에 일어날 것이 보장됩니다.

Quick Quiz 15.8: 특정 상황에서 어떤 메모리 배리어들이 충분히 강력한지 어떻게 이야기 할 수 있나요? ■

Listing 15.2 은 이 점에서의 한 예입니다. Line 10 과 20에서의 smp_mb() 는 배리어들의 역할을, line 9에서의




Figure 15.3: Memory Barriers Provide Conditional If-Then Ordering

x0 스토어는 X0 역할을, line 11에서의 x1 으로부터의 로드는 Y0 를, line 19에서의 x1 스토어는 Y1, 그리고 x0 로부터의 로드는 X1 역할을 합니다. 이 if-then 규칙을 단계별로 적용해 보면, 만약 P0() 의 로컬 변수 r2 가 값 0 으로 설정되어 있다면 line 19에서의 x1 스토어는 line 11에서의 x1 로드 뒤에 일어났음을 알 수 있습니다. 그렇다면 이 if-then 규칙은 line 21에서의 x0 으로부터의 로드가 line 9의 x0 으로의 스토어 뒤에 일어났음을 이야기할 것입니다. 달리 말하자면, 만약 P0() 의 로컬 변수 r2 가 값 0 으로 끝난다면 P1() 의 로컬 변수 r2 는 값 2로 끝날 것이 보장됩니다. 이는 메모리 순서 보장이 조건적이지, 절대적이지 않다는 점의 중요성을 강조합니다.

비록 Figure 15.3 가 구체적으로 메모리 배리어들을

⁴ 컴파일러 개발자들은 종종 “최적화”라는 단어를 선호합니다.

Table 15.3: Linux-Kernel Memory-Ordering Cheat Sheet

Operation Providing Ordering	C	Prior Ordered Operation				Subsequent Ordered Operation					
		Self	R	W	RMW	Self	R	W	DR	DW	RMW
Store, for example, <code>WRITE_ONCE()</code>		Y									Y
Load, for example, <code>READ_ONCE()</code>		Y							Y	Y	Y
<code>_relaxed()</code> RMW operation		Y							Y	Y	Y
<code>smp_read_barrier_depends()</code>				Y					Y	Y	
<code>*_dereference()</code>		Y							Y	Y	Y
Successful <code>*_acquire()</code>		R					Y	Y	Y	Y	Y
Successful <code>*_release()</code>	C	Y	Y	Y	W						Y
<code>smp_rmb()</code>		Y		R		Y		Y			R
<code>smp_wmb()</code>			Y	W			Y		Y	W	
<code>smp_mb()</code> and <code>synchronize_rcu()</code>	CP	Y	Y	Y		Y	Y	Y	Y	Y	Y
Successful full-strength non-void RMW	CP	Y	Y	Y	Y	Y	Y	Y	Y	Y	Y
<code>smp_mb__before_atomic()</code>	CP	Y	Y	Y		a	a	a	a		Y
<code>smp_mb__after_atomic()</code>	CP	a	a	Y		Y	Y	Y	Y		Y

Key:	C: Ordering is cumulative
	P: Ordering propagates
	R: Read, for example, <code>READ_ONCE()</code> , or read portion of RMW
	W: Write, for example, <code>WRITE_ONCE()</code> , or write portion of RMW
	Y: Provides the specified ordering
	a: Provides specified ordering given intervening RMW atomic operation
	DR: Dependent read (address dependency, Section 15.2.3)
	DW: Dependent write (address, data, or control dependency, Sections 15.2.3–15.2.5)
	RMW: Atomic read-modify-write operation
	Self: Orders self, as opposed to accesses both before and after
	SV: Orders later accesses to the same variable
Applies to Linux kernel v4.15 and later.	

언급하지만, 리눅스 커널의 나머지 순서 보장 오퍼레이션들에도 같은 규칙이 적용됩니다.

Ordering operations must be paired. 여러분이 한 쓰레드에서의 오퍼레이션들의 순서는 주의깊게 맞췄지만, 다른 쓰레드에서는 그렇게 하는데 실패했다면, 순서가 없게 됩니다. 두 쓰레드 모두 앞의 if-then 규칙이 적용될 수 있도록 순서를 제공해야만 합니다.⁵

Ordering operations almost never speed things up. 앞의 스토어가 메모리에 더 빨리 적용될 수 있도록 강제하기 위해 메모리 배리어를 추가하려 하고 있다면, 참으세요! 순서 보장을 추가하는건 일반적으로 일을 느려지게 만듭니다. 물론, 인스트럭션들을 추가하는 것이 일을 더 빨리 처리되게 만드는 경우도 있습니다만, 그런 경우에는 주의깊은 벤치마킹이 필요합니다. 그리고

설령 그렇다 하더라도, 여러분이 여러분의 시스템에서 조금 속도를 높일 수 있었다 할지라도, 여러분의 사용자들의 시스템들에서는 상당히 속도가 떨어지는 경우가 있을 가능성도 있습니다. 또는 여러분의 미래의 시스템에요.

Ordering operations are not magic. 여러분의 프로그램이 어떤 레이스 컨디션으로 문제가 발생한다면, 여러분의 버그가 존재하지 않도록 하기 위해 몇가지 메모리 순서 보장 오퍼레이션들을 추가하고 싶어지는 경우가 많을 겁니다. 이보다 훨씬 나은 반응은 주의깊게 설계된 형태로 더 높은 단계의 기능들을 사용하는 것입니다. 동시성 프로그래밍에서, 여러분의 버그들을 존재하지 않게 설계하는게 존재하지 않도록 꼼수를 부리는 것보다 거의 항상 쉽습니다!

These are only rough rules of thumb. 비록 이 경험으로부터의 규칙들이 실제 현업에서 보여지는 대부분의

⁵ Section 15.2.7.2에서, 짹 맞추기는 사이클로 일반화 될겁니다.

상황들을 다룰 수 있긴 하지만, 모든 경험으로부터의 규칙들이 그러하듯이 이 규칙들 역시 한계가 있습니다. 다음 섹션은 여러분의 직관을 깨부수고 여러분의 이해를 높여줄 *trick-and-trap* 리트머스 테스트들을 소개함으로써 이 한계들을 일부 보이겠습니다. 이 리트머스 테스트들은 또한 Table 15.3로 보여진 리눅스 커널 메모리 순서규칙 커닝 페이퍼로 나타내어지는 개념들을 명확하게 할 것이고, 올바른 도구들을 통해 [AMM⁺18] 자동으로 해석될 수 있을 겁니다. Section 15.5은 모든 트릭들과 함정들로부터 배운 것들을 가지고 이 커닝 페이퍼를 다시 한번 들여다 볼 겁니다.

Quick Quiz 15.9: 잠깐만요!!! 자동으로 리트머스 테스트들을 분석하는 이 도구들은 어디서 찾을 수 있나요??? ■

15.2 Tricks and Traps

이제 하드웨어가 메모리 액세스 순서를 재배치 할 수 있고 여러분은 그걸 막을 수 있음을 알게 되었으니, 다음은 여러분이 여러분의 직관에 문제가 있음을 인정하도록 할 차례입니다. 이 고통스러운 작업은 scalar 변수들이 동시에 여러 값들을 가지고 있음을 보이는 코드를 소개하는 Section 15.2.1, 그리고 직관적으로 올바르지만 실제 하드웨어에서는 비참하게 실패하고 마는 코드들을 보이는 Sections 15.2.2부터 15.2.7까지를 통해 이루어질 겁니다. 이 비탄의 작업을 통해 일단 여러분의 직관이 만들어지면, 뒤의 섹션들에서 우리가 근간으로 삼게 될, 메모리 배리어들이 따르는 기본 규칙들을 제공합니다. 이 규칙들은 더 나아가

하지만 먼저, 한 순간에 하나의 변수가 얼마나 많은 값들을 가지고 있을 수 있는지 간단히 알아봅시다.

15.2.1 Variables With Multiple Values

하나의 변수는 잘 정의된 전역적 순서로 값들의 연속을 갖게 될 거라 생각하는건 자연스럽습니다. 불행히도, 이 여정의 다음 정류장은 이 편안한 거짓에 “작별”을 고하라 합니다. 바라건대, 여러분은 이미 Tables 15.1과 15.2의 row 2를 통해 “작별”을 고하기 시작했을 것이고 만약 그렇다면 이 섹션의 목적은 이 요점을 제대로 이끌어내는 것입니다.

그러기 위해, Listing 15.3에 보인 프로그램의 한 부분을 고려해 봅시다. 이 코드 조각은 여러 CPU들에서 병렬적으로 수행됩니다. Line 1은 하나의 공유 변수를 현재 CPU의 ID로 값을 할당하고, line 2에서는 모든 CPU를 가운데 동기화 되는 (불행히도, 모든 CPU 구조에서 가능한 일은 아닙니다!) 하드웨어 “timebase” 카운터의 값을 가져오는 `gettb()` 함수를 사용해 일부 변수들을 초기화시키고, line 3-8의 루프에서는 이 CPU

Listing 15.3: Software Logic Analyzer

```

1 state.variable = mycpu;
2 lasttb = oldtb = firsttb = gettb();
3 while (state.variable == mycpu) {
4     lasttb = oldtb;
5     oldtb = gettb();
6     if (lasttb - firsttb > 1000)
7         break;
8 }
```

가 할당한 값이 유지된 시간의 길이를 기록합니다. 물론, 이 CPU들 가운데 하나는 “승리” 할 것이고, 따라서 line 6-7의 검사가 아니라면 이 루프를 절대 빠져나오지 않을 겁니다.

Quick Quiz 15.10: Listing 15.3의 코드에서의 어떤 가정이 실제 하드웨어에서는 성립하지 않을까요? ■

루프를 빠져나오기 전, `firsttb`는 앞의 공유 변수에의 값 할당 후 곧바로 가져온 timestamp를 가지고 있을 것이고 `lasttb`는 여전히 할당된 값을 가지고 있을, 이 공유 변수의 마지막 샘플링 전에 가져온 timestamp를 가지고 있을 수도 있고, 만약 이 공유 변수가 루프에 들어오기 전에 바뀌었다면 `firsttb`와 같은 값을 가지고 있을 수도 있습니다. 이는 우리가 532-나노세컨드의 시간 간격 동안의 각 CPU의 `state.variable`의 값에 대한 관찰을 그려볼 수 있게 해주는데, Figure 15.4에 보여져 있습니다. 이 데이터는 2006년에 각각 두개의 하드웨어 쓰레드를 갖는 8개의 코어를 장착한 1.5 GHz POWER5 시스템에서 수집되었습니다. CPU 1, 2, 3, 그리고 4는 이 값을 기록했고, CPU 0은 이 테스트를 제어했습니다. Timebase 카운터의 시간 간격은 5.32 ns 정도였는데, 이는 중간의 캐시 상태들을 관찰하기에 충분히 작은 간격입니다.




Figure 15.4: A Variable With Multiple Simultaneous Values

각각의 수평의 막대는 해당 CPU의 관찰 결과를 시간별로 보여주는데, 왼쪽 검은 영역은 해당 CPU의 첫번째 관측 전까지의 시간을 나타냅니다. 처음 5 ns 동안, CPU 3 만이 이 변수의 값을 읽었습니다. 그 다음 10 ns 동안, CPU 2와 3은 이 변수의 값을 서로 다르게 이야기했는데, 그 후에는 최종적으로 동일한 값인 “2”라는 값에 합의했습니다. 하지만, CPU 1은 이 값이 “1”이라고 거의 300 ns 동안 믿었고, CPU 4는 거의 500 ns

동안이나 이 값이 “4”라고 믿었습니다.

Quick Quiz 15.11: 어떻게 CPU 들이 하나의 변수를 동시에 서로 다르게 볼 수가 있는거죠? ■

Quick Quiz 15.12: CPU 1 과 4 는 값을 동의하는데에 그렇게 오랜 시간이 걸렸는데, CPU 2 와 3 은 어떻게 그렇게 빨리 값에 동의하는 건가요? ■

그리고 네개의 CPU 에서의 상황이 재밌다고 생각한다면, 같은 상황을 15 CPU 들이 각각 시간 $t = 0$ 에 하나의 공유 변수에 각자의 숫자를 할당하는 경우를 보인 Figure 15.5 를 고려해 보세요. 해당 그림의 두 다이어그램은 모두 Figure 15.4 와 같은 방식으로 그려졌습니다. 유일한 차이점은 가로축의 단위가 timebase tick 으로, 각 tick 은 약 5.3 나노세컨드를 의미합니다. 따라서 여기서의 전체 연속된 값의 변화는 CPU 의 수의 증가에 일관되게 Figure 15.4 에서보다 긴 시간동안 유지되었습니다. 위의 다이어그램은 전체 그림을 보이며, 아래쪽의 것은 첫 50 timebase tick 만을 확대해서 보입니다.

여기서도, CPU 0 는 테스트를 제어했고, 따라서 어떤 값도 기록하지 않았습니다.

모든 CPU 들이 결국은 마지막 값 9 에 동의를 합니지만, 값 15 와 값 12 가 먼저 상황을 이끈 후입니다. 아래쪽 다이어그램의 수직선으로 나타내어진 time 21 시점에 변수의 값에 대한 14개의 서로 다른 의견들이 존재했음을 알아두시기 바랍니다. 또한 모든 CPU 들이 값들의 순서에 대해 Figure 15.6 에 보인 방향성 있는 그래프의 순서와 일관된 순서를 보았음을 알아두시기 바랍니다. 더도 아니고 덜도 아니고, 두 그림은 메모리 접근 순서에 신경 쓰는 코드에서의 메모리 배리어 같은 메모리 순서 보장 오퍼레이션들의 올바른 사용의 중요성을 강조합니다.

하나의 변수는 한 시점에 얼마나 많은 값을 가질 수 있을까요? 시스템에 존재하는 스토어 베퍼 하나당 하나씩입니다! 따라서 우리는 변수들의 값들과 시간의 흐름에 대한 편안한 직관에게 작별을 고해야만 하는 체제에 들어섰습니다. 이는 메모리 순서 보장 오퍼레이션들이 필요한 체제입니다.

이와 함께, Chapter 3 와 6 에서 배웠던 교훈들을 기억할 필요가 있습니다. 모든 CPU 들이 같은 변수에게 동시에 스토어를 하도록 하는 것은 병렬 프로그램을 설계하는 방법이 아닌데, 적어도 성능과 확장성이 여러분에게 전혀 중요하지 않은 게 아니라면 그렇습니다.

불행히도, 메모리 순서 규칙은 여러분의 직관을 망칠 수 있는 방법들을 이외에도 많이 가지고 있으며, 이런 방법들 모두가 성능과 확장성을 훼손하는 건 아닙니다. 다음 섹션은 관계없는 메모리 참조의 순서 재배치에 대한 소개를 제공합니다.

Listing 15.4: Message-Passing Litmus Test (No Ordering)

```

1 C C-MP+o-wmb-o+o-o
2
3 {
4 }
5
6
7 P0(int* x0, int* x1) {
8
9     WRITE_ONCE(*x0, 2);
10    smp_wmb();
11    WRITE_ONCE(*x1, 2);
12 }
13 }
14
15 P1(int* x0, int* x1) {
16
17     int r2;
18     int r3;
19
20     r2 = READ_ONCE(*x1);
21     r3 = READ_ONCE(*x0);
22
23 }
24
25 exists (1:r2=2 /\ 1:r3=0)

```

15.2.2 Memory-Reference Reordering

Section 15.1.1 에서는 x86 과 같이 상대적으로 강력한 순서 규칙의 시스템들도 앞의 스토어들을 뒤의 로드들과 만약 이 스토어와 로드가 서로 다른 변수들에 대해 행해진다면 재배치 시킬 수 있다는 것을 보였습니다. 이 섹션은 이 결과에 기반해서, 다른 로드와 스토어 조합을 봅니다.

15.2.2.1 Load Followed By Load

Listing 15.4 (C-MP+o-wmb-o+o-o.litmus) 는 고전적 *message-passing* 리트머스 테스트를 보이는데, 여기서 $x0$ 는 메세지이고 $x1$ 은 메세지가 존재하는지 여부를 알리는 플래그입니다. 이 테스트에서, `smp_wmb()` 는 `P0()` 의 스토어들이 순서대로 행해지게 강제하지만, 로드들에 대해서는 어떤 순서도 강제하지 않습니다. x86 과 같이 상대적으로 강력한 순서 규칙의 아키텍쳐들에서는 순서를 강제합니다. 하지만, 완화된 순서 규칙의 아키텍쳐들은 그렇지 않은 경우가 많습니다 [AMP¹¹]. 따라서, 이 listing 의 line 25 에서의 `exists` 절은 발동될 수 있습니다.

다른 위치로부터의 로드들을 재배치하는 한가지 이유는 그렇게 하는게 앞의 로드가 캐시 미스를 냈지만 뒤의 로드의 값은 존재하는 경우, 수행이 진행될 수 있게 해주기 때문입니다.

Quick Quiz 15.13: 하지만 왜 load-load 재배치를 사용자가 볼 수 있게 하나요? 겹치는 스토어가 없는 일반적인 경우에만 예측적 수행을 진행할 수 있게 해서 이 재배치가 보이지 않게 하는게 어떤가요? ■




Figure 15.5: A Variable With More Simultaneous Values




Figure 15.6: Possible Global Orders With More Simultaneous Values

따라서, 순서에 의존적이고 완화된 순서규칙의 아키텍쳐에도 이식될 수 있을 법한 코드에서는 명시적인 순서 규칙을 추가해야 하는데, 예를 들면 Listing 15.5 (C-MP+o-wmb-o+o-rmb-o.litmus)의 line 20에 보인, `exists` 절이 발동될 수 없게 하는 `smp_rmb()`를 추가하는 것입니다.

15.2.2.2 Load Followed By Store

Listing 15.6 (C-LB+o-o+o-o.litmus)은 고전적인 *load-buffering* 리트머스 테스트를 보입니다. x86이나 IBM Mainframe과 같이 비교적 강력한 순서규칙을 가진 시스템들은 앞의 로드들을 뒤따르는 스토어들과 재배치하지 않지만, 더 완화된 순서 규칙의 아키텍쳐들은 그런 재배치를 정말로 허용합니다 [AMP¹¹]. 따라서, line 22의 `exists` 절은 정말로 발동될 수 있습니다.

실제 하드웨어가 이런 재배치를 하는건 비교적 드문 일이긴 합니다만 [Mar17], 이런 재배치가 일어나기를 바랄만한 상황은 로드는 캐시 미스를 냈고, 스토어 베퍼는 거의 꽉 차있고, 뒤따르는 스토어를 위한 캐시 라인은 준비되어 있는 경우입니다. 따라서, 이식성 있는 코드는 더도 말고 덜도 말고 Listing 15.7 (C-LB+o-r+a-o.litmus)에 보인 것과 같이 모든 필요한 순서 규칙을 강제해야만 합니다. `smp_store_release()`와 `smp_load_acquire()`는 line 22의 `exists` 절이 절대 발동되지 않을 것을 보장합니다.

Listing 15.5: Enforcing Order of Message-Passing Litmus Test

```

1 C C-MP+o-wmb-o+o-rmb-o
2 {
3 }
4 }
5
6 P0(int* x0, int* x1) {
7
8     WRITE_ONCE(*x0, 2);
9     smp_wmb();
10    WRITE_ONCE(*x1, 2);
11
12 }
13
14 P1(int* x0, int* x1) {
15
16     int r2;
17     int r3;
18
19     r2 = READ_ONCE(*x1);
20     smp_rmb();
21     r3 = READ_ONCE(*x0);
22
23 }
24
25 exists (1:r2=2 /\ 1:r3=0)

```

Listing 15.6: Load-Buffering Litmus Test (No Ordering)

```

1 C C-LB+o-o+o-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     int r2;
8
9     r2 = READ_ONCE(*x1);
10    WRITE_ONCE(*x0, 2);
11 }
12
13
14 P1(int *x0, int *x1)
15 {
16     int r2;
17
18     r2 = READ_ONCE(*x0);
19     WRITE_ONCE(*x1, 2);
20 }
21
22 exists (1:r2=2 /\ 0:r2=2)

```

15.2.2.3 Store Followed By Store

Listing 15.8 (C-MP+o-o+o-rmb-o.litmus)은 다시 한번 고전적 메세지 패싱 리트머스 테스트를 보이는데, `smp_rmb()`가 P1()의 로드들의 순서를 지켜주지만, P0()의 스토어들에는 어떤 순서보장도 없습니다. 다시 한번 말하지만, 상대적으로 강력한 순서 규칙의 아키텍쳐들은 순서를 지켜주지만, 완화된 순서 규칙의 아키텍쳐들은 그러지 않기 때문에 [AMP¹¹], `exists` 절은 발동될 수 있습니다. 이런 재배치가 이득이 될 수 있는 경우는 스토어 베퍼가 꽉 차있고, 또 다른 스토어는 수행될 준비가 되었지만, 앞의 스토어에 필요한 캐시라인은 여전히 접근이 불가능한 경우입니다. 이 상황에서, 스

Listing 15.7: Enforcing Ordering of Load-Buffering Litmus Test

```

1 C C-LB+o-r+a-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     int r2;
8
9     r2 = READ_ONCE(*x1);
10    smp_store_release(x0, 2);
11 }
12
13
14 P1(int *x0, int *x1)
15 {
16     int r2;
17
18     r2 = smp_load_acquire(x0);
19     WRITE_ONCE(*x1, 2);
20 }
21
22 exists (1:r2=2 /\ 0:r2=2)

```

Listing 15.8: Message-Passing Litmus Test, No Writer Ordering (No Ordering)

```

1 C C-MP+o-o+o-rmb-o
2 {
3 }
4
5
6 P0(int* x0, int* x1) {
7
8     WRITE_ONCE(*x0, 2);
9     WRITE_ONCE(*x1, 2);
10 }
11
12
13 P1(int* x0, int* x1) {
14
15     int r2;
16     int r3;
17
18     r2 = READ_ONCE(*x1);
19     smp_rmb();
20     r3 = READ_ONCE(*x0);
21
22 }
23
24 exists (1:r2=2 /\ 1:r3=0)

```

토어들이 비순차적으로 완료될 수 있게 하는건 수행이 진행될 수 있게 해줄 겁니다. 따라서, 이식성 있는 코드는 Listing 15.5에서 보인 것과 같이 스토어들에도 명시적 순서를 부여해서 `exists` 절이 발동되지 않게 해야만 합니다.

Quick Quiz 15.14: 강력한 순서규칙의 시스템들은 불필요한 `smp_rmb()` 와 `smp_wmb()` 호출로 인한 성능 비용을 왜 지불해야 하죠? 완화된 순서규칙의 시스템들은 자신들의 순서를 지켜주지 않는 선택으로 인한 모든 비용을 책임져야 하지 않나요? ■

Listing 15.9: Message-Passing Address-Dependency Litmus Test (No Ordering Before v4.15)

```

1 C C-MP+o-wmb-o+o-addr-o
2 {
3 }
4 int y=1;
5 int *x1 = &y;
6 }
7
8 P0(int* x0, int** x1) {
9
10    WRITE_ONCE(*x0, 2);
11    smp_wmb();
12    WRITE_ONCE(*x1, x0);
13
14 }
15
16 P1(int** x1) {
17
18     int *r2;
19     int r3;
20
21     r2 = READ_ONCE(*x1);
22     r3 = READ_ONCE(*r2);
23
24 }
25
26 exists (1:r2=x0 /\ 1:r3=1)

```

15.2.3 Address Dependencies

*Address dependency*는 로드 인스트럭션에 의해 리턴된 값이 나중의 메모리 레퍼런스 인스트럭션에 의해 사용되는 주소의 계산에 사용될 때 발생합니다.

Listing 15.9 (`C-MP+o-wmb-o+o-addr-o.litmus`)은 message-passing 패턴의 링크 버전을 보입니다. 헤드 포인터는 `x1`으로, 최초에 `int` 변수 `y`를 가리키게 되며 (line 5), 변수 `y`는 초기값 1을 갖습니다 (line 4). `P0()`는 헤드 포인터 `x1`이 `x0`를 가리키도록 업데이트 (line 12)하는데 이는 `x0`가 2로 초기화 (line 10) 된 후로 순서지어집니다 (line 11). `P1()`은 헤드 포인터 `x1`을 가져오고 (line 21) 이를 통해 레퍼런스되는 값을 가져옵니다 (line 22). 따라서 line 21의 로드와 line 22의 로드 사이에는 address dependency가 존재합니다. 이 경우에, line 21에서 리턴되는 값은 line 22에서 사용되는 주소값 그 자체이지만, C-언어의 `->` 오퍼레이터를 사용한 필드 접근, 더하기, 빼기, 그리고 배열 인덱싱 등 많은 변종이 있을 수 있습니다.⁶

어떤 사람들은 line 21의 헤드 포인터 로드가 line 22의 dereference 전으로 순서 잡히길 바랄 텐데, 리눅스 v4.15 이후 버전에선 실제로 그렇습니다. 하지만, Section 15.4.1에서 설명할, 종속적 로드에 대한 예측된 값 사용을 할 수 있는 리눅스 v4.15 전 버전의 DEC Alpha에서는 그렇지 않을 겁니다. 따라서, Listing ??의 `exists` 절은 발동될 수 있습니다.

⁶ 하지만 리눅스 커널에서, address dependency는 배열로의 포인터를 통해 제공되어야지, 배열 인덱스를 통해서 제공되어선 안된다는 점을 알아두시기 바랍니다.

Listing 15.10: Enforced Ordering of Message-Passing Address-Dependency Litmus Test (Before v4.15)

```

1 C C-MP+o-wmb-o+ld-addr-o
2
3 {
4 int y=1;
5 int *x1 = &y;
6 }
7
8 P0(int* x0, int** x1) {
9
10    WRITE_ONCE(*x0, 2);
11    smp_wmb();
12    WRITE_ONCE(*x1, x0);
13
14 }
15
16 P1(int** x1) {
17
18    int *r2;
19    int r3;
20
21    r2 = lockless_dereference(*x1); // Obsolete
22    r3 = READ_ONCE(*r2);
23
24 }
25
26 exists (1:r2=x0 /\ 1:r3=1)

```

Listing 15.10 은 어떻게 하면 이걸 DEC Alpha 에서 돌아가는 v4.15 전의 리눅스 커널에서 안정적으로 동작하도록 할 수 있는지 보이는데, line 21 의 READ_ONCE() 를 lockless_dereference() 로 대체하는 것으로,⁷ lockless_dereference() 는 DEC Alpha 외의 모든 플랫폼에서 READ_ONCE() 와 동일하지만, DEC Alpha 에서는 READ_ONCE() 뒤에 smp_mb() 를 붙여 동작해서 모든 플랫폼에서 필요한 순서규칙을 강제하고, 결국 exists 절이 발동되지 않게 해줍니다.

하지만, 예를 들어, Listing 15.11 (C-S+o-wmb-o+o-addr-o.litmus) 에 보인 S 리트머스 테스트 [AMP⁺¹¹] 와 같이 종속적 오퍼레이션이 로드가 아니라 스토어라면 어떻게 될까요? 어떤 제품 품질의 플랫폼도 스토어를 예측적으로 하진 않기 때문에, line 10 의 WRITE_ONCE() 가 line 21 의 WRITE_ONCE() 를 덮어쓰기 할 수 없으며, 이는 DEC Alpha 에서 할지라도 종속적 로드의 경우에는 필요했던 lockless_dereference() 없이도 line 25 의 exists 절이 발동될 수 없음을 의미합니다.

Quick Quiz 15.15: 하지만 정말로 모든 플랫폼에서 Listing ?? 과 15.11 의 exists 절이 발동되지 않는다는 걸 어떻게 알 수 있죠? ■

Quick Quiz 15.16: SP, MP, LB, 그리고 이제는 S. 이 리트머스 테스트의 약어들은 모두 어디서 왔고 사람들은 이걸 어떻게 외우죠? ■

하지만, address dependency 는 Section 15.3.2 에서 이

⁷ lockless_dereference() 는 v4.15 이후 버전에서는 필요치 않고, 따라서 이 리눅스 커널들에서는 해당 기능이 존재치 않음을 알아 두시기 바랍니다.

Listing 15.11: S Address-Dependency Litmus Test

```

1 C C-S+o-wmb-o+o-addr-o
2
3 {
4 int y=1;
5 int *x1 = &y;
6 }
7
8 P0(int* x0, int** x1) {
9
10    WRITE_ONCE(*x0, 2);
11    smp_wmb();
12    WRITE_ONCE(*x1, x0);
13
14 }
15
16 P1(int** x1) {
17
18    int *r2;
19
20    r2 = READ_ONCE(*x1);
21    WRITE_ONCE(*r2, 3);
22
23 }
24
25 exists (1:r2=x0 /\ x0=2)

```

Listing 15.12: Load-Buffering Data-Dependency Litmus Test

```

1 C C-LB+o-r+o-data-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7    int r2;
8
9    r2 = READ_ONCE(*x1);
10   smp_store_release(x0, 2);
11 }
12
13
14 P1(int *x0, int *x1)
15 {
16    int r2;
17
18    r2 = READ_ONCE(*x0);
19    WRITE_ONCE(*x1, r2);
20
21 }
22 exists (1:r2=2 /\ 0:r2=2)

```

야기하듯 컴파일러 최적화에 의해 쉽게 깨질 수 있음을 알아두시기 바랍니다.

15.2.4 Data Dependencies

Data dependency 는 한 로드 인스트럭션에 의해 리턴된 값이 뒤의 스토어 인스트럭션에 의해 저장되는 데이터를 계산하는데 사용될 때 발생합니다. 앞의 “data”에 대해서 유념하시기 바랍니다: 로드에 의해 리턴된 값이 뒤의 스토어 인스트럭션에 의해 사용될 주소의 계산에 사용된다면, 그건 address dependency 입니다.

Listing 15.12 (C-LB+o-r+o-data-o.litmus) 은 P1() 의 line 18 과 19 사이의 순서 규칙이 acquire load 가

아니라 data dependency 로 강제된다는 점을 제외하고는 Listing 15.7 와 비슷합니다: Line 18 에서 로드된 값이 line 19 에서 저장하는 값입니다. 이 data dependency 에 의해 제공되는 순서는 `exists` 절이 발동되는 걸 막기에 충분합니다.

Address dependency 와 마찬가지로, data dependency 도 깨지기 쉽고 Section 15.3.2 에서 이야기 되듯이 컴파일러 최적화에 의해 쉽게 깨질 수 있습니다. 사실, data dependency 는 address dependency 보다도 취약할 수 있습니다. 그 이유는 address dependency 는 일반적으로 포인터 값에 과년되기 때문입니다. 반면에, Listing 15.12 에 보였듯이, 컴파일러가 존재치 않는 것으로 최적화 시 캐버릴 자유를 훨씬 많이 가지고 있는 완전한 값으로 data dependency 를 가져가고 싶게 됩니다. 한가지 예만 들어보자면, 만약 로드된 정수가 상수 0 으로 곱해진다면, 컴파일러는 그 결과가 0일 것을 알고, 따라서 로드된 값을 상수 0 으로 바꿔서, 이 종속성을 깨버릴 수 있습니다.

Quick Quiz 15.17: 잠깐만요!!! Listing 15.12 의 line 18 은 로드는 volatile 로 마킹하는 `READ_ONCE()` 를 사용하는데, 이 말은 컴파일러가 설명 그 값이 나중에 0 으로 곱해진다 해도 로드 인스트럭션을 만들어 내야 함을 의미합니다. 그런데도 컴파일러가 data dependency 를 깨지 못하도록 그렇게까지 고생을 해야 하나요? ■

요약하자면, 여러분은 data dependency 에 의존해도 되지만, 컴파일러가 그걸 깨버리는 걸 방지하기 위해 조심해야만 합니다.

15.2.5 Control Dependencies

Control dependency 는 로드 인스트럭션으로 리턴받은 값이 뒤의 스토어 인스트럭션이 수행되어야 할지 말아야 할지를 결정하는 테스트에 사용될 때 발생합니다. “뒤의 스토어 인스트럭션”에 주의하시기 바랍니다: 많은 플랫폼들이 load-to-load control dependency 는 무시합니다.

Listing 15.13 (C-LB+o-r+o-ctrl-o.litmus) 은 또 다른 load-buffering 예를 보이는데, 이번에는 line 18 의 로드와 line 20 의 스토어 사이의 순서를 맞추는데 control dependency (line 19) 를 사용하고 있습니다. 이렇게 지켜진 순서는 `exists` 절이 발동하는 걸 막기에 충분합니다.

하지만, control dependency 는 data dependency 보다도 최적화 과정에서 제거되기가 더 쉽고, Section ?? 은 여러분의 컴파일러가 control dependency 를 깨는 걸 막기 위해 따라야만 하는 규칙들을 일부 설명합니다.

Control dependency 는 로드에서 스토어로의 순서에 대해서만 지켜진다는 걸 다시 반복할 필요가 있습니다. 따라서, Listing 15.14 (C-MP+o-r+o-ctrl-o.litmus)

Listing 15.13: Load-Buffering Control-Dependency Litmus Test

```

1 C C-LB+o-r+o-ctrl-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     int r2;
8
9     r2 = READ_ONCE(*x1);
10    smp_store_release(x0, 2);
11 }
12
13
14 P1(int *x0, int *x1)
15 {
16     int r2;
17
18     r2 = READ_ONCE(*x0);
19     if (r2 >= 0)
20         WRITE_ONCE(*x1, 2);
21 }
22
23 exists (1:r2=2 /\ 0:r2=2)

```

Listing 15.14: Message-Passing Control-Dependency Litmus Test (No Ordering)

```

1 C C-MP+o-r+o-ctrl-o
2 {
3 }
4
5
6 P0(int* x0, int* x1) {
7
8     WRITE_ONCE(*x0, 2);
9     smp_store_release(x1, 2);
10 }
11
12
13 P1(int* x0, int* x1) {
14     int r2;
15     int r3 = 0;
16
17     r2 = READ_ONCE(*x1);
18     if (r2 >= 0)
19         r3 = READ_ONCE(*x0);
20
21 }
22
23 exists (1:r2=2 /\ 1:r3=0)

```

의 line 17-19 에 보인 load-to-load control dependency 는 순서를 제공하지 않으며, 따라서 `exists` 절이 발동되는 걸 막지 않습니다.

요약하자면, control dependency 는 유용할 수 있지만, 상당한 관리가 필요한 항목입니다. 따라서 여러분은 성능에 대한 고려가 다른 해법은 허용치 않을 때에만 이걸 사용하셔야 합니다.

Quick Quiz 15.18: 프로그래밍 언어 표준에 지켜진다고 되어있으면, control dependency 는 더 믿을만 하지 않을까요??? ■

Listing 15.15: Cache-Coherent IRIW Litmus Test

```

1 C C-CCIRIW+o+o+o-o+o-o-
2
3 {
4 int x = 0;
5 }
6
7 P0(int *x)
8 {
9     WRITE_ONCE(*x, 1);
10 }
11
12 P1(int *x)
13 {
14     WRITE_ONCE(*x, 2);
15 }
16
17 P2(int *x)
18 {
19     int r1;
20     int r2;
21
22     r1 = READ_ONCE(*x);
23     r2 = READ_ONCE(*x);
24 }
25
26 P3(int *x)
27 {
28     int r3;
29     int r4;
30
31     r3 = READ_ONCE(*x);
32     r4 = READ_ONCE(*x);
33 }
34
35 exists(2:r1=1 /\ 2:r2=2 /\ 3:r3=2 /\ 3:r4=1)

```

15.2.6 Cache Coherence

Cache-coherent 플랫폼에서는, 모든 CPU 들이 특정 변수로의 로드와 스토어들의 순서에 대해 동의를 합니다. 다행히도, `READ_ONCE()` 와 `WRITE_ONCE()` 가 사용된 경우라면 Table 15.3에 보인 컨닝 페이퍼의 “SV” 열이나 타내듯이 거의 모든 플랫폼들이 cache-coherent 합니다. 불행히도, 이 특성은 너무 유명해서 여러 이름을 갖는데, “single-variable SC”,⁸ “single-copy atomic” [SF95], 그리고 그냥 “coherence” [AMP+11] 라고도 불렸습니다. 이 개념에 대해 또 다른 용어를 만들어 붙여서 혼란을 가중시키기보다는, 이 책에서는 “cache coherence” 와 “coherence” 라는 용어를 사용하겠습니다.

Listing 15.15 (`C-CCIRIW+o+o+o-o+o-o.litmus`) 은 cache coherence 를 테스트 하는 리트머스 테스트를 보이는데, 여기서 “IRIW” 는 “independent reads of independent writes” 의 약자입니다. 이 리트머스 테스트는 하나의 변수만 사용하므로, `P2()` 와 `P3()` 는 `P0()` 와 `P1()` 의 스토어 순서에 동의해야만 합니다. 달리 말해, `P2()` 가 `P0()` 의 스토어가 먼저 행해졌다고 믿는 결과가 나온다면, `P3()` `P1()` 의 스토어가 먼저 행해졌다고 믿는 결과는 없어야 합니다. 그리고 그런 없어야 할 상




Figure 15.7: Global System Bus And Multi-Copy Atomicity

황이 일어난다면 line 35의 `exists` 절은 발동할 겁니다.

Quick Quiz 15.19: 하지만 Listing 15.15에서, `P2()` 의 `r1` 과 `r2` 가 값 2 와 1 을 각각 얻고, `P3()` 의 `r1` 과 `r2` 가 값 1과 2 를 각각 얻게 되는것 역시 만만치 않게 나쁘지 않을까요? ■

하나의 메모리 영역에 대한 다른 크기의 겹치는 로드와 스토어들은 (C-언어의 `union` 키워드를 통해 이뤄질 수 있을 겁니다) 비슷한 순서 보장을 제공할거라 생각하고 싶을 겁니다. 하지만, Flur 등은 이런 보장들이 실제 하드웨어 위에서 위배될 수 있다는 것을 보이는 놀랍도록 간단한 리트머스 테스트를 발견했습니다 [FSP+17]. 따라서 하나의 변수에 대해서는 겹치지 않는 같은 크기의 정렬된 액세스만 행하도록 코드를 제한할 필요가 있는데, 적어도 이식성이 중요하다면 그렇습니다.⁹

더 많은 변수와 쓰레드를 추가하면 재배치와 다른 반직관적인 행동을 일으킬 범위가 커질텐데, 이에 대해 다음 섹션에서 설명합니다.

15.2.7 Multicopy Atomicity

완전한 *Multicopy atomic* [SF95] 플랫폼에서 돌아가는 쓰레드들은 스토어들의 순서에 대해서는 심지어 서로 다른 변수들에 대한 것조차도 동의를 할 것이 보장됩니다. 그런 시스템에 대한 유용한 상상의 모델은 Figure 15.7에 보인 싱글 버스 아키텍쳐 같은 시스템입니다. 각각의 스토어가 버스로의 메세지를 낸다면, 그리고 이 버스가 한번에 하나의 스토어만 처리할 수 있다면, 모든 CPU 들은 모든 스토어에 대해 각각 관측한 순서가 동일할 겁니다. 불행히도, 그럼에 보인 것처럼 스토어 버퍼나 캐시조차 없이 컴퓨터 시스템을 만드는건 병하고 같은 계산속도가 나오게 할겁니다. 따라서 multicopy atomicity 를 제공하는데 흥미를 갖는 대부분의 CPU 제조사들은 그대신 약간 더 완화된 *other-multicopy atomicity* [ARM17, Section B2.3] 를 제공하고자 하게 되는데, 여기선 특정 스토어를 수행하는 CPU 는 모든 스토어들의 순서에 대한 CPU 들의 동의로부터 배제될 수 있게

⁸ SC 는 sequentially consistent 의 약자입니다.

⁹ 어토믹 RMW 오퍼레이션들 (예를 들면, `xchg()`) 을 모든 스토어들에 사용하는 것이 순차적으로 일관적인 순서를 제공할거라 믿을 수도 있겠습니다만, 이는 어떤 방식으로도 증명된 바 없습니다.

Listing 15.16: WRC Litmus Test With Dependencies (No Ordering)

```

1 C C-WRC+o+o-data-o+o-rmb-o
2
3 {
4 }
5
6 P0(int *x)
7 {
8     WRITE_ONCE(*x, 1);
9 }
10
11 P1(int *x, int* y)
12 {
13     int r1;
14
15     r1 = READ_ONCE(*x);
16     WRITE_ONCE(*y, r1);
17 }
18
19 P2(int *x, int* y)
20 {
21     int r2;
22     int r3;
23
24     r2 = READ_ONCE(*y);
25     smp_rmb();
26     r3 = READ_ONCE(*x);
27 }
28
29 exists (1:r1=1 /& 2:r2=1 /& 2:r3=0)

```

해줍니다. 이는 CPU 들 중 일부만 스토어를 수행한다면, 다른 CPU 들은 스토어들의 순서에 동의함을 의미하는데, 따라서 “other-multicopy atomicity” 의 “other” 가 존재하는 겁니다. Multicopy-atomic 플랫폼들과 달리, other-multicopy-atomic 플랫폼에서는, 스토어를 수행하는 CPU는 자신의 스토어를 더 빨리 관측할 수 있어서, 나중의 로드가 새로 스토어된 값을 스토어 버퍼로부터 곧바로 얻어올 수 있음을 의미합니다. 이는 끔찍한 플랫폼은 피할 수 있게 해줍니다.

Quick Quiz 15.20: Multicopy atomic 와 다른 multicopy atomic 사이의 다른 동작에 대한 특정한 예를 들어볼 수 있겠습니까? ■

모든 플랫폼이 어떤 형태의 multi-copy atomicity 를 제공하는 시대가 올수도 있겠습니다만, 그 사이에는 multicopy-atomic 이 아닌 플랫폼이 존재할 것이고, 따라서 소프트웨어는 그걸 잘 다뤄야만 합니다.

Listing 15.16 (C-WRC+o+o-data-o+o-rmb-o.litmus) 은 multicopy atomicity 를 보이고 있는데, multicopy-atomic 플랫폼 위에서라면 line 29 의 exists 절은 발동될 수 없습니다. 반면에, multicopy-atomic 이 아닌 플랫폼에서 이 exists 절은 P1() 의 액세스들은 data dependency 로 순서잡혀지고 P2() 의 액세스들은 smp_rmb() 로 순서잡혀짐에도 발동될 수 있습니다. Multicopy atomicity 의 정의는 모든 쓰레드가 스토어의 순서에 동의할 것을, 즉 모든 스토어가 모든 쓰레드에 같은 시간에 도착하는 것으로 생각될 수도 있을 것을




Figure 15.8: Shared Store Buffers And Multi-Copy Atomicity

요구함을 다시 이야기 드립니다. 따라서, multicopy-atomic 이 아닌 플랫폼은 다른 쓰레드에 다른 시간에 도착하는 스토어가 있을 수 있습니다. 특히, P0() 의 스토어는 P2() 에 도착하기 훨씬 전에 P1() 에 도착할 수도 있는데, 이는 P1() 의 스토어가 P0() 의 스토어보다 먼저 P2() 에 도착할 확률을 높입니다.

이는 왜 일반적인 물리 법칙의 제한을 받는 실제 시스템이 Listing 15.16 의 exists 절을 발동시키는지에 대한 의문을 낳습니다. 그런 실제 시스템에 대한 그림이 Figure 15.8 에 그려져 있습니다. CPU 0 와 CPU 1 은 스토어 버퍼를 공유하며, CPU 2 와 3 도 그렇습니다. 이는 CPU 1 은 이 스토어 버퍼로부터 값을 로드할 수 있으며, 따라서 CPU 0 가 스토어한 값을 곧바로 볼 가능성이 있습니다. 반면에, CPU 2 와 3 은 연관된 캐시 라인이 새로운 값을 자신에게 가져올 때까지 기다려야 합니다.

Quick Quiz 15.21: 대체 누가 공유된 스토어 버퍼를 갖는 시스템을 설계할 생각 따위를 하겠어요??? ■

Table 15.4 은 Listing 15.16 의 exists 절이 발동될 수 있는 일련의 이벤트를 보입니다. 이 일련의 이벤트는 P0() 와 P1() 이 Figure 15.8 에 보인 방식으로 캐시와 스토어 버퍼를 공유한다는 점에 상당히 의존적입니다.

Quick Quiz 15.22: 하지만 P0() 와 P1() 은 스토어 버퍼와 캐시를 공유해야 하는데 P2() 는 자기만의 캐시와 스토어 버퍼를 갖는다는게 공평한가요??? ■

Row 1 은 최초의 상태를 보이는데, y 는 P0() 와 P1() 의 공유된 캐시에, x 의 최초 값은 P2() 의 캐시에 있습니다.

Row 2 는 P0() 의 line 8 에서의 스토어가 수행된 직후의 효과를 보입니다. x 를 담고 있는 캐시라인은 P0() 와 P1() 의 공유 캐시에 있지 않으므로, 새로운 값 (1) 은 해당 CPU 들의 공유 스토어 버퍼에 저장됩니다.

Row 3 는 두개의 사건을 보입니다. 먼저, P0() 는 x 의 새로운 값을 공유 스토어 버퍼에서 내려보낼 수 있게끔 x 를 담고 있는 캐시라인을 얻어오기 위해 read-invalidate 오퍼레이션을 날립니다. 이어서, P1() 은 x 를 읽어오는데 (line 15), 이 오퍼레이션은 x 의 새로운 값을 공유 스토어 버퍼에서 곧바로 얻어올 수 있기 때문에

Table 15.4: Memory Ordering: WRC Sequence of Events

P0()		P0() & P1()		P1()		P2()		
Instruction		Store Buffer	Cache	Instruction		Instruction	Store Buffer	Cache
1	(Initial state)		y==0	(Initial state)		(Initial state)		x==0
2	x = 1;	x==1	y==0					x==0
3	(Read-Invalidate x)	x==1	y==0	r1 = x (1)				x==0
4		x==1 y==1	y==0	y = r1	r2 = y			x==0
5		x==1	y==1	(Finish store)	(Read y)			x==0
6	(Respond y)	x==1	y==1		(r2==1)			x==0 y==1
7		x==1	y==1		smp_rmb()			x==0 y==1
8		x==1	y==1		r3 = x (0)			x==0 y==1
9		x==1	x==0 y==1		(Respond x)			y==1
10	(Finish store)	x==1 y==1						y==1

즉각적으로 완료됩니다.

Row 4 또한 두개의 사건을 보입니다. 먼저, P1() 이 y로의 스토어 (line 16) 을 수행한 직후의 효과로, 이 새로운 값은 공유 스토어 버퍼에 저장됨을 보입니다. 이어서, P2() 의 y로부터의 로드 (line 24) 를 보입니다.

Row 5 는 두개의 사건의 이후 흐름을 보입니다. 먼저, P1() 은 y로의 스토어를 완료하고, 공유 스토어 버퍼에서 캐시로 값을 내림을 보입니다. 또한, P2() 의 y를 담고 있는 캐시라인으로의 요청을 보입니다.

Row 6 는 P2() 가 y를 담고 있는 캐시라인을 받아서 r2로의 로드를 마칠 수 있게 해주는데, 이 로드는 1의 값을 가져오게 됩니다.

Row 7 은 P2() 가 smp_rmb() 를 수행해서 (line 25), 두 로드의 순서를 강제하는 것을 보입니다.

Row 8 은 P2() 가 x로부터의 로드를 수행하는 것을 보이는데, 이는 P2() 의 캐시로부터 값 0 을 곧바로 가져올 겁니다.

Row 9 은 마침내 P2() 가 P0() 의, row 3에서 보내졌던, x를 담고 있는 캐시라인에 대한 요청에 응답하게 되는 것을 보입니다.

마지막으로, row 10 은 P0() 가 자신의 스토어를 끝내서, x에 대한 값을 자신의 공유 스토어 버퍼에서 공유된 캐시로 내리는 것을 보입니다.

Line 29의 exists 절이 발동됨 역시 알아두시기 바랍니다. r1과 r2의 값들은 모두 값 1을 갖고, r3의 마지막 값은 값 0입니다. 이 이상한 결과는 P0() 의 x에 대한 새로운 값이 P2() 와 이야기하기 전에 P1() 에게 전달되었기 때문에 발생했습니다.

Quick Quiz 15.23: Table 15.4 대로라면, P1() 의 스토어는 그렇게 빨리 끝나는데 P0() 의 스토어는 왜 그렇게 오래 걸리나요? 달리 말하자면, Listing 15.16의 line 32에 있는 exists 절은 정말로 실제 시스템에서도 발동되는건가요? ■

의존성이 순서를 제공하긴 하지만, 각자의 쓰레드 스스로에 대해서만 제공하기 때문에 이 반직관적인 결과가 일어납니다. 이 세개 쓰레드 예제는 더 강한 순서 규칙을 필요로 하는데, Section 15.2.7.1 부터 15.2.7.4 까지의 주제가 이를 다룹니다.

15.2.7.1 Cumulativity

Listing 15.16에 보인 세개 쓰레드의 예제는 *cumulative* 순서 규칙, 또는 *cumulativity* 라 불리는 순서 규칙을 필요로 합니다. Cumulative 메모리 순서 강제 오퍼레이션은 그 앞의 액세스들만이 아니라 같은 변수에 대한 모든 쓰레드의 이전 액세스들까지 순서를 강제해줍니다.

의존성은 *cumulativity*를 제공하지 않는데, Table 15.3의 `smp_read_barrier_depends()` 와 `READ_ONCE()` 행이 모두 “C” 열을 비워둔 이유입니다. 하지만, `release` 오퍼레이션들은 “C” 열의 “C” 가 알리듯이, *cumulativity*를 제공합니다. 따라서, Listing 15.17 (`C-WWC+o+o-r+o-addr-o.litmus`)은 Listing 15.16의 data dependency를 위한 `release` 오퍼레이션을 대체합니다. `Release` 오퍼레이션은 *cumulative* 하기 때문에, 그 순서 강제는 Listing 15.17의 line 15에서의 P1()에 의한 x로부터의 로드만이 아니라 line 8의 P0()에 의한 x로의 스토어에도 적용됩니다—하지만 그 로드가 스토어된 값을 리턴할 경우만으로, line 28의 exists 절 안의 `1:r1=1`이 맞을 경우만 그렇습니다. 이는 P2()의 `load-acquire`는 line 25에서의 x로부터의 로드가 line 8의 스토어 뒤에 일어난 것으로 강제하기 충분해서, 리턴되는 값은 1로, `2:r3=0` 는 맞지 않게 되어서, 결국 exists 절이 발동되지 않게 함을 의미합니다.

이런 순서 규칙은 Figure 15.9에 그려져 있습니다. *Cumulativity*는 한단계 이전의 시간으로만 제한되는게 아님을 알아두시기 바랍니다. 어떤 쓰레드에서건 line 13




Figure 15.9: Cumulativity

Listing 15.17: WRC Litmus Test With Release

```

1 C C-WRC+o+o-r+a-o
2
3 {
4 }
5
6 P0(int **x)
7 {
8     WRITE_ONCE(*x, 1);
9 }
10
11 P1(int **x, int* y)
12 {
13     int r1;
14
15     r1 = READ_ONCE(*x);
16     smp_store_release(y, r1);
17 }
18
19 P2(int **x, int* y)
20 {
21     int r2;
22     int r3;
23
24     r2 = smp_load_acquire(y);
25     r3 = READ_ONCE(*x);
26 }
27
28 exists (1:r1=1 / 2:r2=1 / 2:r3=0)

```

수 있습니다. 그렇다고 해도 Cumulativity 는 한계가 있는데, 이에 대해 다음 섹션에서 알아봅니다.

15.2.7.2 Propagation

Listing 15.18 (C-W+RWC+o-r+a-o+o-mb-o.litmus) 은 cumulativity 와 store-release 가 전체 메모리 배리어에도 불구하고 갖는 한계를 보입니다. 문제는, line 12에서의 `smp_store_release()` 가 cumulativity 를 가짐에도 불구하고 갖는 한계를 보입니다. 문제는, line 12에서의 `smp_store_release()` 가 cumulativity 를 가짐에도 불구하고 갖는 한계를 보입니다. 그리고 이 cumulativity 가 line 30에서의 P2() 의 로드를 순서잡음에도 불구하고, `smp_store_release()` 의 순서규칙은 P1() 의 로드 (line 21) 와 P2() 의 스토어 (line 28) 에 전파될 수 없다는 것입니다. 이는 line 33에서의 `exitst` 절이 발동될 수 있음을 의미합니다.

Quick Quiz 15.24: 하지만 이 리트머스 테스트에 최소 세개의 쓰레드가 존재하지 않는다면 전파에 대해서는 걱정할 필요가 없을 거예요, 그렇죠? ■




Figure 15.10: Load-to-Store is Counter-Temporal

에서의 스토어 전에 x 로의 스토어 또는 x 로부터의 로드가 있었다면, r1 과 r2 가 모두 x 의 주소를 갖게 되는 경우에 한해서이긴 하지만 그 앞의 로드나 스토어 역시 line 32에서의 스토어 전으로 순서잡음하게 됩니다.

정리해보면, cumulative 순서 강제 오퍼레이션의 사용은 일부 상황에서의 non-multicopy-atomic 동작을 막을

이 상황은 완전히 반직관적으로 보일 수도 있겠습

Listing 15.18: W+RWC Litmus Test With Release (No Ordering)

```

1 C C-W+RWC+o-r+a-o+o-mb-o
2
3 {
4 int x = 0;
5 int y = 0;
6 int z = 0;
7 }
8
9 P0(int *x, int *y)
10 {
11     WRITE_ONCE(*x, 1);
12     smp_store_release(y, 1);
13 }
14
15 P1(int *y, int *z)
16 {
17     int r1;
18     int r2;
19
20     r1 = smp_load_acquire(y);
21     r2 = READ_ONCE(*z);
22 }
23
24 P2(int *z, int *x)
25 {
26     int r3;
27
28     WRITE_ONCE(*z, 1);
29     smp_mb();
30     r3 = READ_ONCE(*x);
31 }
32
33 exists(1:r1=1 /\ 1:r2=0 /\ 2:r3=0)

```

Listing 15.19: W+RWC Litmus Test With More Barriers

```

1 C C-W+RWC+o-mb-o+a-o+o-mb-o
2
3 {
4 int x = 0;
5 int y = 0;
6 int z = 0;
7 }
8
9 P0(int *x, int *y)
10 {
11     WRITE_ONCE(*x, 1);
12     smp_mb();
13     WRITE_ONCE(*y, 1);
14 }
15
16 P1(int *y, int *z)
17 {
18     int r1;
19     int r2;
20
21     r1 = smp_load_acquire(y);
22     r2 = READ_ONCE(*z);
23 }
24
25 P2(int *z, int *x)
26 {
27     int r3;
28
29     WRITE_ONCE(*z, 1);
30     smp_mb();
31     r3 = READ_ONCE(*x);
32 }
33
34 exists(1:r1=1 /\ 1:r2=0 /\ 2:r3=0)

```

니다만, 빛의 속도는 제한되어 있고 컴퓨터는 크기가 존재함을 기억하시기 바랍니다. 따라서 P2()의 z로의 스토어가 P1()에게 전달되기까지는 시간을 필요로하고, 이는 결국 P1()의 z로부터의 읽기가 시간상으로 훨씬 뒤에 일어날 수 있지만, 예전 값인 0을 읽을 수 있습니다. 이 상황은 Figure 15.10에 그려져 있습니다: 어떤 로드가 기존 값을 본다는 것은 이 로드가 새로운 값에 대한 스토어보다 먼저 수행되었음을 의미하지는 않습니다.

Listing 15.18 또한, 두개가 아니라 세개의 프로세스가 있음으로 인해 메모리 배리어 짹 맞추기의 한계를 보이고 있음을 알아두시기 바랍니다. 이런 보다 복잡한 리트머스 테스트들은 사이클을 가지고 있다고 말할 수도 있는데, 메모리 배리어 짹 맞추기는 두개 쓰레드 사이클이 있는 특별한 경우입니다. Listing 15.18의 사이클은 P0() (line 11과 12), P1() (line 20과 21), P2() (line 28, 29, 그리고 30), 그리고 다시 P0() (line 11)로 이어집니다. 여기서의 exists 절은 이 사이클을 설명합니다: 1:r1=1은 line 20에서의 smp_load_acquire()가 line 12에서 smp_store_release()가 저장한 값을 리턴했음을 의미하고, 1:r2=0는 line 28에서의 WRITE_ONCE()가 line 21에서의 READ_ONCE()에 의해 리턴되는 값에 영향을 끼치기에는 너무 늦게 도달했음을 의미하며, 마지막으로 2:r3=0는 line 11에서의 WRITE_

ONCE()가 line 30에서의 READ_ONCE()에 의해 리턴되는 값에 영향을 끼치기에는 너무 늦게 도착했음을 의미합니다. 이 경우, exists 절이 발동될 수 있다는 사실은 이 사이클이 허용된 것이라고 이야기 됩니다. 반대로, exists 절이 발동될 수 없는 경우라면, 이 사이클이 금지된 것이라고 이야기 됩니다.

하지만 우리가 Listing 15.18의 line 33에 있는 exists 절을 유지해야 한다면 어떡해야 할까요? 한 가지 해결책은 P0()의 smp_store_release()를 Table 15.3이 보이듯 cumulativity 만이 아니라 propagation도 갖는 smp_mb()로 교체하는 것입니다. 그렇게 한 결과가 Listing 15.19 (C-W+RWC+o-mb-o+a-o+o-mb-o.litmus)에 보여져 있습니다.

Quick Quiz 15.25: smp_mb()가 propagation 속성을 갖는다면, Listing 15.18 line 29의 smp_mb()는 왜 exists 절이 발동되는 걸 막지 못하는 거죠? ■

완전함을 기하기 위해, Figure 15.11는 같은 변수를 향한 여러 스토어들 가운데 “승리하는” 스토어는 가장 마지막에 행해진 스토어가 아닐 수 있음을 보이고 있습니다. Figure 15.5를 주의깊게 이해한 사람에게 이는 그다지 놀라운 일이 아닐 겁니다.

Quick Quiz 15.26: 하지만 Listing 15.20 (C-2+2W+o-wmb-o+o-wmb-o.litmus)에 보인 것과 같이 순서잡힌 스토어만을 사용하는 리트머스 테스트에서, 한 연구는




Figure 15.11: Store-to-Store is Counter-Temporal

Listing 15.20: 2+2W Litmus Test With Write Barriers

```

1 C C-2+2W+o-wmb-o+o-wmb-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     WRITE_ONCE(*x0, 1);
8     smp_wmb();
9     WRITE_ONCE(*x1, 2);
10 }
11
12
13 P1(int *x0, int *x1)
14 {
15     WRITE_ONCE(*x1, 1);
16     smp_wmb();
17     WRITE_ONCE(*x0, 2);
18 }
19
20 exists (x0=1 /\ x1=1)

```




Figure 15.12: Store-to-Load is Temporal

ARM 과 Power 같은 완화된 순서규칙의 시스템에서 조차도 사이클이 사라짐을 보였습니다 [SSA¹¹]. 이를 놓고 보면, store-to-store 는 정말로 항상 반 임시적인가요??? ■

하지만 가끔 시간은 실제로 우리 편입니다. 계속 읽어보세요!

15.2.7.3 Happens-Before

Figure 15.12 에 보인 것과 같이, 사용자에게 보여지는 예측적 수행이 없는 플랫폼에서는, 어떤 로드가 특정 스토어로부터의 값을 리턴한다면, 빛의 유한한 속도와 크기가 존재하는 근래의 컴퓨팅 시스템 덕분에, 해당 스토어는 분명 로드보다 먼저 수행되었다고 확신할 수 있습니다. 이는 주의깊게 짜여진 프로그램은 시간의 흐름 자체를 메모리 순서 강제 오퍼레이션처럼 생각하고

Listing 15.21: LB Litmus Test With One Acquire

```

1 C C-LB+a-o+o-data-o+o-data-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     int r2;
8
9     r2 = smp_load_acquire(x0);
10    WRITE_ONCE(*x1, 2);
11 }
12
13
14 P1(int *x1, int *x2)
15 {
16     int r2;
17
18     r2 = READ_ONCE(*x1);
19     WRITE_ONCE(*x2, r2);
20 }
21
22 P2(int *x2, int *x0)
23 {
24     int r2;
25
26     r2 = READ_ONCE(*x2);
27     WRITE_ONCE(*x0, r2);
28 }
29
30 exists (0:r2=2 /\ 1:r2=2 /\ 2:r2=2)

```

의존할 수 있다는 뜻입니다.

물론, Listing 15.6 에서 store-to-load 연결만을 가지고 있지만 여전히 exists 절을 발동시킬 수 있듯이 시간의 흐름 그 자체만으로는 충분치 않습니다. 하지만, 각 쓰레드가 가장 약한 순서 규칙만이라도 제공한다면, exists 절은 발동될 수 없습니다. 예를 들어, Listing 15.21 (C-LB+a-o+o-data-o+o-data-o.litmus) 은 P0() 가 smp_load_acquire() 로 순서지어지고 P1() 과 P2() 는 data dependency 로 순서지어지는 것을 보입니다. Table 15.3 의 꼭대기에 있는 이런 순서 규칙들은 이 exists 절이 발동되는 것을 막는데 충분합니다.

Quick Quiz 15.27: 의존성 만을 사용하는, Listing 15.21 와 비슷한 리트머스 테스트를 짤 수 있나요? ■

중요한, 더 유용하다고 말할만한, 메모리 액세스 순서를 위한 시간의 사용은 다음 섹션에서 다루어집니다.

15.2.7.4 Release-Acquire Chains

최소한의 release-acquire 체인을 Listing 15.7 (C-LB+a-r+a-r+a-r+a-r.litmus) 에 보였습니다만, 이 체인들은 Listing 15.22 에 보인 것처럼 훨씬 더 길어질 수 있습니다. 이 release-acquire 체인이 길어질수록, 시간의 흐름으로부터 얻어지는 이득이 많아져서, 얼마나 많은 쓰레드가 연관되어 있는가와 관계 없이 관련된 exists 절이 발동되지 않게 할 수 있습니다.

release-acquire 체인이 본질적으로 store-to-load 이

Listing 15.22: Long LB Release-Acquire Chain

```

1 C C-LB+a-r+a-r+a-r+a-r
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     int r2;
8
9     r2 = smp_load_acquire(x0);
10    smp_store_release(x1, 2);
11 }
12
13
14 P1(int *x1, int *x2)
15 {
16     int r2;
17
18     r2 = smp_load_acquire(x1);
19     smp_store_release(x2, 2);
20 }
21
22 P2(int *x2, int *x3)
23 {
24     int r2;
25
26     r2 = smp_load_acquire(x2);
27     smp_store_release(x3, 2);
28 }
29
30 P3(int *x3, int *x0)
31 {
32     int r2;
33
34     r2 = smp_load_acquire(x3);
35     smp_store_release(x0, 2);
36 }
37
38 exists (0:r2=2 / 1:r2=2 / 2:r2=2 / 3:r2=2)

```

긴 하지만, 이것들은 Figure 15.10에 보인 것처럼 반 임시적이긴 하지만 하나의 load-to-store 단계를 처리할 수 있는 것으로 밝혀졌습니다. 예를 들어, Listing 15.23 (C-ISA2+o-r+a-r+a-r+a-o.litmus)은 세 단계의 release-acquire 체인을 보입니다만, P3()의 마지막 액세스는 P0()에 의해 WRITE_ONCE() 된 x0로부터의 READ_ONCE()여서, 임시적이지 않은 load-to-store 링크를 두 프로세스 사이에 형성합니다. 하지만, P0()의 smp_store_release() (line 8)는 cumulativity를 가지므로, P3()의 READ_ONCE()가 0을 리턴한다면, 이 cumulativity는 이 READ_ONCE()가 P0()의 smp_store_release() 앞으로 순서지어지게 강제할 겁니다. 또한, 이 release-acquire 체인 (line 8, 16, 17, 24, 25, 그리고 33)은 P3()의 READ_ONCE()가 P0()의 smp_store_release() 뒤로 순서지어지게 강제합니다. P3()의 READ_ONCE()는 P0()의 smp_store_release() 앞뒤에 있을 수 없으므로, 다음 두가지 중 하나 또는 모두가 진실이어야만 합니다:

1. P3()의 READ_ONCE()가 P0()의 WRITE_ONCE() 뒤에 와서, READ_ONCE()가 값 2를 리턴해서, exists 절의 3:r2=0는 거짓이 됨.

Listing 15.23: Long ISA2 Release-Acquire Chain

```

1 C C-ISA2+o-r+a-r+a-r+a-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     WRITE_ONCE(*x0, 2);
8     smp_store_release(x1, 2);
9 }
10
11
12 P1(int *x1, int *x2)
13 {
14     int r2;
15
16     r2 = smp_load_acquire(x1);
17     smp_store_release(x2, 2);
18 }
19
20 P2(int *x2, int *x3)
21 {
22     int r2;
23
24     r2 = smp_load_acquire(x2);
25     smp_store_release(x3, 2);
26 }
27
28 P3(int *x3, int *x0)
29 {
30     int r1;
31     int r2;
32
33     r1 = smp_load_acquire(x3);
34     r2 = READ_ONCE(*x0);
35 }
36
37 exists (1:r2=2 / 2:r2=2 / 3:r1=2 / 3:r2=0)

```

2. o] release-acquire 체인이 형성되지 않아서, exists 절의 1:r2=2, 2:r2=2, 3:r1=2 가운데 하나 이상이 거짓이 됨.

어느 쪽이던, 이 리트머스 테스트는 P3()와 P0() 사이에 악명높은 load-to-store 링크를 가지고 있음에도, exists 절은 발동되지 못합니다. 하지만 Listing 15.18에서 보였듯이 release-acquire 체인은 하나의 load-to-store 링크만 처리할 수 있음을 절대 잊지 마시기 바랍니다.

Release-acquire 체인들은 또한 store-to-store 단계를 처리할 수 있는데, Listing 15.24 (C-Z6.2+o-r+a-r+a-r+a-o.litmus)에 이 모습이 보여져 있습니다. 앞의 예에서와 같이, smp_store_release()의 cumulativity는 release-acquire 체인의 임시적 성질과 결합되어서 line 36의 exists 절이 발동되는 것을 막습니다. 하지만 주의하세요: 두번째 store-to-store 단계를 추가하게 되면, 그에 맞춰 업데이트된 exists 절은 발동될 수도 있습니다.

Quick Quiz 15.28: Listing 15.25에 보인 것과 같이 하나의 load-to-store 링크와 하나의 store-to-store 링크와 함께 짧은 release-acquire 체인이 있다고 해봅시다.

Listing 15.24: Long Z6.2 Release-Acquire Chain

```

1 C C-Z6.2+o-r+a-r+a-r+a-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     WRITE_ONCE(*x0, 2);
8     smp_store_release(x1, 2);
9 }
10
11
12 P1(int *x1, int *x2)
13 {
14     int r2;
15
16     r2 = smp_load_acquire(x1);
17     smp_store_release(x2, 2);
18 }
19
20 P2(int *x2, int *x3)
21 {
22     int r2;
23
24     r2 = smp_load_acquire(x2);
25     smp_store_release(x3, 2);
26 }
27
28 P3(int *x3, int *x0)
29 {
30     int r2;
31
32     r2 = smp_load_acquire(x3);
33     WRITE_ONCE(*x0, 3);
34 }
35
36 exists (1:r2=2 /\ 2:r2=2 /\ 3:r2=2 /\ x0=2)

```

Listing 15.25: Z6.0 Release-Acquire Chain (Ordering?)

```

1 C C-Z6.2+o-r+a-o+o-mb-o
2 {
3 }
4 int x = 0;
5 int y = 0;
6 int z = 0;
7 }
8
9 P0(int *x, int *y)
10 {
11     WRITE_ONCE(*x, 1);
12     smp_store_release(y, 1);
13 }
14
15 P1(int *y, int *z)
16 {
17     int r1;
18
19     r1 = smp_load_acquire(y);
20     WRITE_ONCE(*z, 1);
21 }
22
23 P2(int *z, int *x)
24 {
25     int r2;
26
27     WRITE_ONCE(*z, 2);
28     smp_mb();
29     r2 = READ_ONCE(*x);
30 }
31
32 exists(1:r1=1 /\ 2:r2=0 /\ z=2)

```

각 non-store-to-load 링크가 하나씩만 있으므로, `exists` 절은 발동되지 않을 겁니다, 그렇죠? ■

Quick Quiz 15.29: Store-to-load 링크, load-to-store 링크, 그리고 store-to-store 링크를 이야기 했군요. Load-to-load 링크에 대해선 어떻죠? ■

요약해보면, 제대로 구성된 release-acquire 체인은 직관적 환희의 평화로운 섬을 훨씬 복잡한 메모리 순서 규칙의 강력한 반직관적 바다 가운데에 형성해 줍니다.

15.3 Compile-Time Conternation

C를 포함해서 대부분의 언어는 병렬 프로그래밍에 대한 경험이 적거나 아예 없는 사람들에 의해 단일 프로세서 시스템에서 개발되었습니다. 그 결과, 명시적으로 달리 이야기되지 않는다면, 이 언어들은 현재의 CPU가 메모리를 읽거나 쓰는 유일한 존재라고 가정합니다. 이는 결국 이런 언어들의 컴파일러들의 최적화 도구들은 여러분의 프로그램이 수행하는 메모리 참조들의 순서, 갯수, 그리고 크기를 극적으로 바꿀 준비도 되어있고, 의지도 있고, 그럴 능력을 가지고 있습니다. 사실, 하드웨어에 의해 만들어지는 재배치는 이에 비하면 상당히 온순해 보입니다.

이 섹션은 여러분이 여러분의 컴파일러를 길들여서 컴파일 시점의 경악을 없앨 수 있게 돋습니다. Section 15.3.1은 컴파일러가 여러분의 코드의 메모리 참조를 파괴적으로 최적화 하지 않게 할 수 있는지 설명하고, Section 15.3.2에서는 address dependency 와 data dependency 를 어떻게 보호하는지 설명하며, 마지막으로 Section ?? 에서는 복잡한 control dependency 를 보호하는 방법을 설명합니다.

15.3.1 Memory-Reference Restrictions

다시 말하지만, 달리 이야기 해주지 않으면, 컴파일러는 생성된 코드에 의해 접근되는 변수들에 영향을 끼치는 다른 존재는 없다고 가정합니다. 이 가정은 단순한 설계상의 에러가 아니고, 다양한 표준에서 소중히 지켜지는 것입니다.¹⁰ 이 가정은 컴파일러는 다음의 코드에 대해 컴파일러가 `do_something()` 은 `a`를 수정하지 않음을 증명할 수 있는 경우라면 `a`로부터의 로드를 루프 바깥으로 끄집어 내는 최적화를 수행할 (표준에 정의된) 권리를 가짐을 의미합니다:

```

1 while (a)
2     do_something();

```

최적화된 코드는 아래와 같이, 임의의 거대한 횟수의 의도된 로드들을 하나의 실제 로드로 합쳐버린 모습으로 될 수 있을 겁니다:

¹⁰ 또는, 어찌면 표준화된 설계상의 에러일 수도 있겠습니다.

```

1 if (a)
2   for (;;)
3     do_something();

```

이 최적화는 a에 값 0을 저장함으로써 이 루프를 종료시킬 것이라고 예상한 다른 곳의 코드에 놀라움으로다가올 겁니다. 다행히도, 이 문제를 막을 수 있는 여러 방법들이 있습니다:

1. Volatile 액세스.
2. 어토믹 변수들.
3. 데이터 레이스를 가져오는 걸 막는 것.

`volatile` 제약은 믿을 수 있는 디바이스 드라이버를 작성하는데 필요하고, 어토믹 변수들과 데이터 레이스를 가져오는 걸 막는 것은 믿을 수 있는 동시적 코드를 작성하는데 필요합니다.

다음 코드는 `READ_ONCE()`의 무한루프 최적화를 막을 수 있도록 `volatile` 캐스팅을 사용합니다:

```

1 while (READ_ONCE(a))
2   do_something();

```

`READ_ONCE()`는 이 로드를 `volatile` 캐스팅으로 표시합니다. `volatile`은 원래 일반적인 메모리에 접근할 때 사용되는 것과 동일한 로드와 스토어 인스트럭션을 사용해 접근되는 memory-mapped I/O (MMIO) 레지스터로의 접근을 위해 설계되었습니다. 하지만, MMIO 레지스터는 일반적 메모리처럼 동작해야 할 필요가 없습니다. MMIO 레지스터에 값을 저장하는 행위는 해당 레지스터로부터의 이어지는 로드가 지금 저장한 값을 리턴함을 의미할 이유가 없습니다. MMIO 레지스터로부터의 로드는 부가 작용을 가질 수 있는데, 예를 들면 디바이스의 상태를 바꾸거나 다른 MMIO 레지스터에 연관된, 뒤이어지는 로드와 스토어의 응답에 영향을 끼치거나 하는 것입니다. 같은 MMIO 주소로의 다른 크기의 로드와 스토어는 서로 다른 영향을 끼칠 수도 있습니다.

이는, 설령 단일 프로세서 시스템이라 할지라도, MMIO 액세스의 순서, 갯수, 또는 크기를 바꾸는 것은 엄격히 금지되어야만 함을 의미합니다. 그리고 이게 정확히 C-언어의 `volatile` 키워드의 목적으로, 컴파일러가 안정적인 디바이스 드라이버를 구현할 수 있게 해주는 것입니다.

이는 왜 `READ_ONCE()`가 a로부터의 로드를 루프 바깥으로 끄집어 내는 행위를 막아주는지 설명합니다: 그렇게 하는 것은 a로부터의 `volatile` 로드들의 수를 바꾸는 것으로, 그런 최적화는 허용되지 않습니다. 하지만, `volatile`은 하드웨어에 제약을 거는 일은 아무것도 하지 않음 역시 알아두시기 바랍니다. 따라서, 루프를 뒤따르는 코드가 이 루프를 종료시키는 0 값의 저장을

앞지르는 메모리 레퍼런스의 결과를 봐야 한다면, 여러분은 값 0을 저장하는데에 `smp_store_release()` 같은 것을, 그리고 루프 조건에는 `smp_load_acquire()` 같은 것을 사용해야만 합니다. 하지만 여러분에게 필요한게 루프의 안정적인 제어 뿐이고 다른 순서는 필요치 않다면, `READ_ONCE()`가 그 일을 해줄 수 있습니다.

컴파일러는 로드를 복사할 수도 있습니다. 예를 들어, 다음의 현실적인 코드를 보시기 바랍니다:

```

1 tmp = p;
2 if (tmp != NULL && tmp <= q)
3   do_something(tmp);

```

여기서의 의도는 `do_something()` 함수가 NULL 포인터나 q보다 큰 포인터를 받지 않는 것입니다. 하지만, 컴파일러는 이를 다음과 같이 바꿀 수 있는 권한이 있습니다:

```

1 if (p != NULL && p <= q)
2   do_something(p);

```

이렇게 바뀐 코드에서, p의 값은 세개의 서로 다른 시점에서 로드됩니다. 이 변환은 처음엔 우습게 보일 수도 있겠지만, 이를 둘러싼 코드가 기계의 모든 레지스터를 사용하고 있는 경우라면 매우 유용할 겁니다. p의 현재 값이 line 1에서의 테스트를 통과하지만, line 2가 수행되기 전에 어떤 다른 쓰레드가 p에 NULL을 저장해서, 결국 `do_something()`은 놀랍게도 NULL 포인터를 받아올 수 있습니다.¹¹ 컴파일러가 로드를 복제하는 걸 막기 위해선, `READ_ONCE()`를 아래 예제처럼 사용하세요:

```

1 tmp = READ_ONCE(p);
2 if (tmp != NULL && tmp <= q)
3   do_something(tmp);

```

또는, 변수 p가 `volatile`로 선언될 수도 있습니다.

컴파일러는 스토어들을 결합시킬 수도 있습니다. 그런 가장 유명한 예는 아마도 아래에 보인 프로그레스바 예제일 겁니다:

```

1 while (!am_done()) {
2   do_something(p);
3   progress++;
4 }

```

컴파일러가 feedback 기반 최적화를 사용한다면, 공유 변수 `progress`로의 스토어가 상당히 비용이 비싸다는 걸 알게 되어서, 다음과 같이 의도되지 않은 최적화를 만들어 낼 수도 있을 겁니다:

¹¹ 이 책의 편집자는 1990년대 초에 DYNIX/ptx 커널의 메모리 할당자에서 정확히 이와 같은 실수를 한 적이 있습니다. 이 버그를 찾아내기 위해 이 책의 편집자만이 아니라 그의 여러 동료들까지 휴일 주말을 반납해야 했습니다. 짧게 말해서, 이건 새로운 문제가 아닙니다.

```

1 while (!am_done()) {
2     do_something(p);
3     tmp++;
4 }
5 progress = tmp;

```

이는 성능을 약간 높일 수도 있겠지만, 프로그래스바를 바라보는 불쌍한 사용자는 이 최적화로 인해 종종 잊혀져 버립니다. 프로그래스바는 계속 0에 오랜시간 멈춰있다가, 마지막에 와서야 갑자기 커질 겁니다. 다음 코드는 이런 일반적으로 이런 문제를 막아줍니다:

```

1 while (!am_done()) {
2     do_something(p);
3     WRITE_ONCE(progress, progress + 1);
4 }

```

컴파일러가 `do_something()` 을 분석해서 어토믹, 또는 `volatile` 변수로의 액세스가 없다는 것을 알아낼 수 있다면 예외가 있을 수 있습니다. 이런 경우에 컴파일러는 `do_something()` 을 호출하는 루프와 `progress` 를 증가시키는 루프 두개의 루프를 만들어낼 수 있습니다. 그런 일이 일어날 수 있는 희박한 확률의 상황에는 `WRITE_ONCE()` 를 `smp_store_release()` 같은 것으로 바꿔야 할 겁니다. 컴파일러가 `volatile` 액세스의 횟수, 크기, 순서를 바꿀 수는 없게 되어 있지만, `volatile` 액세스들과 관계 없는 평범한 액세스들은 순서를 바꿀 권한을 가지고 있음을 알아두는게 중요합니다.

이상하게 들릴 수 있지만, 컴파일러는 어떤 변수에의 일반적 스토어 직전에 그 변수를 임시 저장소로 사용할 수 있어서, 해당 변수로의 스토어를 만들어 낼 수 있습니다. 다행히도, 대부분의 컴파일러는 적어도 스택 변수 외에서는 이런 종류의 일을 하지 않습니다. 어떤 경우에에는, `WRITE_ONCE()` 를 사용하는 것, 변수를 `volatile` 로 선언하는 것, 또는 (어토믹을 지원하는 최신 C 와 C++ 컴파일러에서) 해당 변수를 어토믹으로 선언하는 것은 이런 일을 막아줄 겁니다.

Quick Quiz 15.30: 왜 컴파일러는 일반적 변수에의 스토어를 아무때나 만들 수 없는거죠? ■

앞의 예는 액세스의 횟수를 바꾸는 컴파일러 최적화에 관련된 것이었습니다. 이제, 아래쪽에 있는 하드웨어는 액세스 순서를 바꿀 수 있다는 걸 놓고 보면 컴파일러가 액세스 순서를 바꾸는 걸 막는건 무의미한 행위라고 보일 수도 있을 겁니다. 하지만, 근래의 기계들은 *exact exception* 과 *exact interrupt* 를 갖는데, 이는 모든 인터럽트나 익셉션은 인스트럭션의 흐름 가운데 특정 위치에서 발생한 것을 보외하게 되어서, 이것들의 핸들러는 앞의 인스트럭션들의 효과를 모두 보게 되지만, 뒤따르는 인스트럭션들의 효과는 보지 못하게 됨을 의미합니다. 따라서 `READ_ONCE()` 와 `WRITE_ONCE()` 는 인터럽트된 코드와 인터럽트 핸들러 사이의 통신을 제어하기 위해 사용될 수 있습니다.¹²

¹² 하지만, 다양한 표준의 위원회들은 여러분이 이전에 `sig`

실제 액세스되는 크기가 요청된 것보다 작을 경우에 *load tearing* 과 *store tearing* 이라 알려진, 액세스의 크기의 변화에 대해선 이야기 되지 않았습니다. 예를 들어, 상수 0x00010002 를 32-bit 변수에 저장하는 것은 안전하게 보일 겁니다. 하지만, 작은 즉석값 (immediate value) 을 곧바로 메모리에 저장할 수 있는 CPU 들이 존재하고, 그런 CPU 에서는, 명시적으로 32-bit 상수를 만드는 오버헤드를 없애기 위해 이를 두개의 16-bit 스토어로 쪼갤 거라 예상할 수 있습니다. 이는 이 변수의 값을 동시에 읽어들이는 다른 쓰레드 입장에서는 절반만 완료된 스토어의 결과는 예상치 못했기에 커다란 놀라움이 됩니다. `READ_ONCE()` 와 `WRITE_ONCE()` 의 사용은 컴파일러가 *load tearing* 과 *store tearing* 을 활용하는 것을 각각 막아줍니다.

요약해서, `READ_ONCE()`, `WRITE_ONCE()`, 그리고 `volatile` 의 사용은 컴파일러가 여러분의 병렬 알고리즘을 존재하는 것과 다르게 최적화 하는 것을 막는데 효과적인 도구들입니다. 컴파일러는 예를 들면 `memory_order_relaxed` 어토믹 로드와 스토어 같은, *load* 와 *store tearing* 을 막기 위한 다른 메커니즘들을 제공하기 시작했습니다만, 액세스들을 합치고 쪼개는 것을 막기 위해선 `volatile` 이 여전히 필요합니다.

하지만, `READ_ONCE()` 와 `WRITE_ONCE()` 를 과용할 수도 있습니다. 예를 들어, 여러분이 특정 변수가 변화하는 것을 막았다면 (해당 변수에 대한 모든 업데이트를 락으로 지킨다던지 하는식으로), `READ_ONCE()` 를 사용할 필요가 없습니다. 비슷하게, 여러분이 모든 다른 CPU 나 쓰레드가 특정 변수를 읽는 것을 막았다면 (여러분이 해당 변수를 모든 다른 CPU 나 쓰레드가 접근하기 전에 초기화 한다던지 해서), `WRITE_ONCE()` 를 사용할 필요가 없습니다. 하지만, 제 경험으로는 개발자들은 그들이 생각하는 것보다 더 자주 `READ_ONCE()` 와 `WRITE_ONCE()` 같은 걸 사용해야 하고, 불필요한 사용으로 인한 오버헤드는 상당히 낮습니다. 더 나아가서, 필요한 곳에 이것들을 사용하지 않음으로써 생기는 문제는 상당히 큽니다.

15.3.2 Address- and Data-Dependency Difficulties

컴파일러는 address dependency 도 data dependency 도 이해하지 못하지만, 그걸 가르치려 하고, 최근에는 그런 가르치는 방법을 표준화 하려는 노력들이 있습니다 [MWB⁺17, MRP⁺17]. 그 전까지는, 여러분의 컴파일러가 여러분의 의존성을 깨부실 기회를 갖길 막기 위해 매우 조심스러울 필요가 있습니다.

`atomic_t` 타입의 변수들이나 어토믹 기능들을 대신 사용하길 권장합니다.

1. 컴파일러는 control dependency 를 이해하지 못하므로, 컴파일러가 여러분의 코드를 망가뜨리지 않도록 하는건 여러분의 일입니다.
2. Control dependency 는 앞의 로드를 뒤의 스토어에 대해 순서 지을 수 있습니다. 하지만, 이는 다른 종류의 순서는 어떤 것도 보장하지 않습니다. 앞의 로드는 뒤의 로드와 순서지어지지 않고, 앞의 스토어는 뒤의 어떤 것과도 순서지어지지 않습니다. 이런 다른 종류의 순서가 필요하다면, `smp_rmb()`, `smp_wmb()`, 또는, 앞의 스토어와 뒤의 로드 사이의 순서가 필요하다면 `smp_mb()` 를 사용해야 합니다.
3. “if” 문의 양 브랜치가 동일한 변수에 대한 동일한 스토어로 시작한다면, 이 스토어들은 각각의 앞에 `smp_mb()` 를 위치시키거나 `smp_store_release()` 를 통해 스토어를 행하든 해서 순서가 보장되어져야만 합니다. “if” 문의 양 브랜치의 시작에 `barrier()` 를 사용하는 것만으로는 충분치 않은데, 이는 앞의 예제로 보여졌듯, 컴파일러 최적화는 `barrier()` 의 규칙을 지키면서도 control dependency 를 깰 수 있기 때문이란 걸 알아두시기 바랍니다.
4. Control dependency 는 앞의 로드와 뒤따르는 스토어 사이에 최소 한번의 실행시간의 조건을 필요로 하며, 이 조건은 앞의 로드와 관계되어야만 합니다. 만약 컴파일러가 이 조건을 최적화를 통해 없애버릴 수 있다면, 컴파일러는 이 안의 순서 역시 최적화를 통해 없애버릴 수 있습니다. `READ_ONCE()` 와 `WRITE_ONCE()` 의 조심스러운 사용은 필요한 조건을 지키는데 도움을 줄 수 있습니다.
5. Control dependency 는 컴파일러가 의존성을 존재치 않게 재배치 해버리는 걸 막을 것을 필요로 합니다. `READ_ONCE()`, `atomic_read()`, 또는 `atomic64_read()` 의 조심스러운 사용은 여러분의 control dependency 를 지키는 걸 도울 수 있습니다.
6. Control dependency 는 “if” 절의 “then” 과 “else” 와 이 두 절 내에서의 호출된 함수까지만 적용됩니다. control dependency 는 control dependency 를 담은 “if” 를 뒤따르는 코드에는 적용되지 않습니다.
7. Control dependency 는 일반적으로 다른 종류의 메모리 순서 강제 오퍼레이션들과 짹을 이룹니다.
8. Control dependency 는 cumulativity 를 제공하지 않습니다. Cumulativity 가 필요하다면, `smp_mb()` 를 사용하세요.

짧게 말해서, 많은 유명한 언어들이 주로 싱글 쓰레드 환경만 고려한 채 만들어졌습니다. 이런 언어들을 멀티쓰레드 소프트웨어를 구축하는데 성공적으로 사용하려면 여러분이 메모리 레퍼런스와 의존성에 특별한 관심을 기울여야 합니다.

15.4 Hardware Specifics

각 CPU 는 메모리 순서 규칙을 위한 각자의 특수한 방법을 가지고 있는데, 이는 Table 15.5 에 보여진 것과 같이 호환성을 지키기를 어렵게 만듭니다. 사실, 일부 소프트웨어 환경은 프로그래머가 필요로 하는 정도를 받아들이게 해주는 상호 배타적 기능들만을 사용할 수 있도록 제한하고 메모리 순서 보장 오퍼레이션들의 직접적 사용을 금지하는 단순한 방법을 취하기도 합니다. 이 섹션은 각 CPU 제품군의 모든 (또는 대부분의) 영역을 다루는 레퍼런스 매뉴얼이라기보다는, 개략적 비교를 제공하는 높은 수준의 개론으로 의도되어졌음을 알아두시기 바랍니다. 상세한 내용을 원한다면, 해당 CPU 의 레퍼런스 매뉴얼을 보시기 바랍니다.

Table 15.5 로 돌아가서, 첫번째 행들은 메모리 순서 보장 속성들을 보이고 두번째 행들은 인스트럭션 속성들을 보입니다.

첫번째 세개의 행은 특정 CPU 가 네개의 있을 수 있는 로드와 스토어 조합이 Section 15.1 와 15.2.2.1-15.2.2.3. 에서 이야기했듯 재배치 될 수 있는지를 보입니다. 그 다음 줄 (“Atomic Instructions Reordered With Loads or Stores?”) 은 특정 CPU 가 로드와 스토어를 어토믹 인스트럭션들과 재배치 될 수 있게 허용하는지 여부를 보입니다.

다섯번째와 여섯번째 줄은 재배치와 의존성을 이야기하는데, 이는 Section 15.2.3-15.2.5 에서 다루어졌으며 Section 15.4.1 에서 더 자세히 다루어질 겁니다. 짧게 이야기해 보자면 Alpha 는 연결된 자료 구조의 읽기를 하는 쓰레드는 물론이고 업데이트를 하는 쓰레드에게도 메모리 배리어를 필요로 합니다.

다음 줄, “Non-Sequentially Consistent” 는 CPU 의 로드와 스토어 인스트럭션이 sequential consistency 로 제약이 되는지를 보입니다. 대부분은 성능상의 이유로 이런 제약을 갖지 않습니다.

다음의 두 줄은 Section 15.2.7 에서 정의된 multicopy atomicity 를 다룹니다. 첫번째 줄은 전체 (그리고 희귀한) multicopy atomicity 를 가리키고, 두번째 줄은 약화된 other-multicopy atomicity 입니다.

다음 줄, “Non-Cache Coherent” 는 여러 쓰레드로부터 하나의 변수로의 접근을 다루는데, Section 15.2.6 에서 이야기 된 바 있습니다.

마지막 세줄은 인스트럭션 수준에서의 선택들과 문제들을 다룹니다. 첫번째 줄은 각 CPU 가 어떻게 load-

Table 15.5: Summary of Memory Ordering

Property		CPU Family								
		Alpha	ARMv7-A/R	ARMv8	Itanium	MIPS	POWER	SPARC TSO	x86	z Systems
Memory Ordering	Loads Reordered After Loads or Stores?	Y	Y	Y	Y	Y	Y			
	Stores Reordered After Stores?	Y	Y	Y	Y	Y	Y			
	Stores Reordered After Loads?	Y	Y	Y	Y	Y	Y	Y	Y	Y
	Atomic Instructions Reordered With Loads or Stores?	Y	Y	Y		Y	Y			
	Dependent Loads Reordered?		Y							
	Dependent Stores Reordered?									
	Non-Sequentially Consistent?	Y	Y	Y	Y	Y	Y	Y	Y	Y
	Non-Multiplication Atomic?	Y	Y	Y	Y	Y	Y	Y	Y	
	Non-Other-Multiplication Atomic?	Y	Y		Y	Y	Y			
Instructions	Non-Cache Coherent?				Y					
	Load-Acquire/Store-Release?	F	F	i	I	F	b			
	Atomic RMW Instruction Type?	L	L	L	C	L	L	C	C	C
	Incoherent Instruction Cache/Pipeline?	Y	Y	Y	Y	Y	Y	Y	Y	Y

Key:

- b: Load-Acquire/Store-Release?
- F: Full memory barrier
- i: Instruction with lightweight ordering
- I: Instruction with heavyweight ordering
- Atomic RMW Instruction Type?
- C: Compare-and-exchange instruction
- L: Load-linked/store-conditional instruction

acquire 와 store-release 를 구현했는지 보이고, 두번째 줄은 CPU 들을 atomic-instruction 타입으로 구분하고, 세번째와 마지막 줄은 각 CPU 가 비일관적인 인스트럭션 캐시와 파이프라인을 갖는지 보입니다. 그런 CPU 들은 스스로를 수정하는 코드의 경우 특수한 인스트럭션을 수행할 것을 필요로 합니다.

괄호로 둘러싸인 CPU 이름은 아키텍쳐상으로는 허용되었지만 실제로는 잘 사용되지 않는 모드를 의미합니다.

흔한, 메모리 순서 보장 오퍼레이션에 대해 “그냥 안 된다고 말하기” 접근법은 적용되는 곳에서는 상당히 알맞습니다만, 리눅스 커널과 같이 메모리 순서 보장 오퍼레이션을 직접 사용해야 하는 환경이 존재합니다. 따라서, 리눅스는 주의깊게 선택된, 메모리 순서 보장 오퍼레이션들의 최소 공통 분모 들의 집합을 제공하는데, 이것들은 다음과 같습니다:

`smp_mb()` 로드와 스토어를 모두 순서지음 (full memory barrier). 이는 특정 메모리 배리어를 앞서는 로드와 스토어들은 해당 메모리 배리어를 뒤따는 로드와 스토어보다 먼저 메모리에 던져질 것을 의미합니다.

`smp_rmb()` 로드들만을 순서지음 (read memory barrier).

`smp_wmb()` 스토어들만을 순서지음 (write memory barrier).

`smp_read_barrier_depends()` 앞의 오퍼레이션들에 의존적인 뒤따르는 오퍼레이션들을 순서지음. 이 기능은 Alpha 를 제외한 모든 플랫폼에서 no-op입니다만, 직접적으로는 잘 사용되지 않고, `READ_ONCE()` 나 `rcu_dereference()` 같은 것들 안에서 사용됩니다.

`smp_mb__before_atomic()` `smp_mb__before_atomic()` 를 앞서는 액세스들을 뒤의 RMW 어토믹 오퍼레이션에 대해 순서짓도록 강제함. 이는 어토믹 RMW 오퍼레이션들에 대해 순서를 완전히 제공하는 시스템들에서는 noop 이 됩니다.

`smp_mb__after_atomic()` 앞의 RMW atomic 오퍼레이션을 앞지르는 액세스들을 `smp_mb__after_atomic()` 을 뒤따르는 오퍼레이션에 대해 순서 지음. 이 또한 atomic RMW 오퍼레이션에 완전한 순서를 보장하는 시스템들에서는 noop 이 됩니다.

`mmiowb()` 글로벌 스픬락으로 보호되는 MMIO 쓰기에 대해 순서를 강제하며, MMIO에 대한 2016년 LWN 기사 [MDR16a] 에 더 자세히 설명되어 있음.

`smp_mb()`, `smp_rmb()`, 그리고 `smp_wmb()` 기능들은 배리어를 가로지르는 메모리 오퍼레이션들을 재배치 하는 컴파일러 최적화 또한 막습니다. `smp_read_barrier_depends()` 기능 또한 비슷한 효과를 갖지만, 그건 Alpha CPU 에서만 그렇습니다.

이런 기능들은 SMP 커널에서만 코드를 생성합니다만, 각각은 유니프로세서 환경으로 빌드된 커널에서 조차도 메모리 배리어를 생성하는, 유니프로세서 환경에서의 버전들 (`mb()`, `rmb()`, `wmb()`, 그리고 `read_barrier_depends()` 가각에 대응됩니다) 또한 가지고 있습니다. `smp_` 버전은 대부분의 경우에 사용되어야 합니다. 하지만, 유니프로세서 버전은 드라이버를 작성할 때 유용한데, MMIO 액세스들은 UP 커널에서도 순서를 지켜야 하기 때문입니다. 메모리 순서 보장 오퍼레이션이 없다면, CPU 와 컴파일러는 이런 액세스들을 재배치해서, 기기가 이상하게 동작하거나, 심지어 여러분의 커널을, 또는 심지어 여러분의 하드웨어에 손상을 입힐 수도 있습니다.

따라서 대부분의 커널 프로그래머들은 이 인터페이스들을 사용하는한, 각 CPU 의 메모리 순서 규칙의 특이성을 알 필요가 없습니다. 여러분이 특정 CPU 의 구조에 깊숙이 특화된 코드를 가지고 일하고 있다면, 물론 그렇지 않습니다.

더 나아가서, 모든 리눅스의 락킹 도구들 (spinlock, reader-writer lock, semaphore, RCU, ...) 은 모든 필요한 순서 보장 기능을 담고 있습니다. 따라서 이런 도구들을 올바르게 사용하는 코드를 가지고 일하고 있다면, 여러분은 리눅스의 메모리 순서 보장 기능들에 대해서는 걱정할 필요 없습니다.

그렇다고는 하나, 각 CPU 의 메모리 일관성 모델에 대한 깊은 이해는 디버깅을 할 때 매우 도움이 될 수 있으며, 아키텍쳐에 특화된 코드나 동기화 도구를 작성할 때에 대해서는 말할 것도 없습니다.

한편, 얇은 지식은 매우 위험한 것이라고도 이야기합니다. 여러분이 많은 지식을 가지고 만들 수 있는 위험

Listing 15.26: Insert and Lock-Free Search (No Ordering)

```

1 struct el *insert(long key, long data)
2 {
3     struct el *p;
4     p = kmalloc(sizeof(*p), GFP_ATOMIC);
5     spin_lock(&mutex);
6     p->next = head.next;
7     p->key = key;
8     p->data = data;
9     smp_wmb();
10    head.next = p;
11    spin_unlock(&mutex);
12 }
13
14 struct el *search(long key)
15 {
16     struct el *p;
17     p = READ_ONCE(head.next);
18     while (p != &head) {
19         /* Prior to v4.15, BUG ON ALPHA!!! */
20         if (p->key == key) {
21             return (p);
22         }
23         p = READ_ONCE(p->next);
24     };
25     return (NULL);
26 }

```

을 생각해 보세요! 각 CPU 들의 메모리 일관성 모델에 대한 이해를 원하는 분들을 위해, 다음 섹션들은 가장 유명하고 두드러진 CPU 들을 설명합니다. 해당 CPU 의 문서를 읽는 것을 대신할 수는 없겠지만, 이 섹션들은 좋은 개발이 될 겁니다.

15.4.1 Alpha

수명이 다한지 오래된 CPU 에 대해 뭔가 이야기하는건 좀 이상하게 보일수도 있겠습니다만, Alpha 는 의존적 로드들을 재배치하는 유일한 주류 CPU이고, 따라서 리눅스를 포함한 동시성 API 에 많은 영향을 끼쳤기에 흥미롭습니다. 따라서 Alpha 를 이해하는 것은 리눅스 커널 해커에게 매우 중요합니다.

Alpha 와 다른 CPU 사이의 의존적 로드에 대한 차이점이 Listing 15.26 의 코드에 보여져 있습니다. 이 그림의 line 9 에서의 `smp_wmb()` 는 line 6-8 의 원소 초기화가 line 10 에서 원소가 추가되기 전에 수행될 것을 보장해서 이 lock-free 탐색이 제대로 동작할 겁니다. 정확히 말하면, Alpha 를 제외한 모든 CPU 에서 이 보장이 지켜집니다.¹³

Alpha 는 실제로 Listing ?? 의 line 20 에서의 코드가 line 6-8 의 초기화 전의 쓰레기 값을 보게 할 수 있습니다.

Figure 15.13 는 분리된 캐시를 가져서 분리된 캐시 사이를 웠다갔다 하는 캐시라인이 다른 캐시에서 처리

¹³ 하지만 리눅스 커널 버전 v4.15 이후에서는 `READ_ONCE()` 가 Alpha 에서는 메모리 배리어를 만들도록 하며, 따라서 이 이야기는 그보다 오래된 버전의 리눅스 커널들에만 적용됩니다.




Figure 15.13: Why `smp_read_barrier_depends()` is Required

될 수 있는 상당히 복잡적인 기계에서 어떻게 이런 일이 일어날 수 있는지 보입니다. 예를 들어, Listing 15.26의 line 17에서의 `head.next`의 로드는 캐시 뱅크 0에 액세스 했고, line 20에서의 `p->key`의 로드와 line 23에서의 `p->next`의 로드는 캐시 뱅크 1에 액세스 했을 수 있습니다. Alpha에서, `smp_wmb()`는 Listing 15.26의 line 6-8에 의해 일어난 (`p->next`, `p->key`, `p->next`) 캐시 무효화가 (`head.next`) line 10전에 접합부에 도달할 것을 보장합니다만, 읽기를 하는 CPU의 캐시 뱅크로의 전파의 순서에 대해서는 어떤 보장도 하지 않습니다. 예를 들어, 읽기를 하는 CPU의 캐시 뱅크 1이 매우 바쁜 사이, 캐시 뱅크 0는 한가할 수 있습니다. 이는 새로운 원소를 위한 (`p->next`, `p->key`, 그리고 `p->data`) 캐시 무효화가 지연되어서, 읽기를 하는 CPU가 `head.next`의 새로운 값을 읽지만 `p->key`와 `p->next`의 예전 값을 읽을 수 있게 하는 결과를 만들 수 있습니다. 그렇습니다. 이는 Alpha가 포인터를 가져오기 전에 포인터로 가리켜지는 데이터를 가져올 수 있음을 의미합니다. 이상하지만 사실입니다. 더 많은 정보를 원하시거나 제가 이 모든걸 꾸며냈다고 생각하신다면 앞서 작성된 문서 [Com01, Pug00]를 참고하시기 바랍니다.¹⁴ 이런 일반적이지 않은 순서규칙에 대한 접근법의 장점은 Alpha가 더 간단한 캐시 하드웨어를 가질 수 있어서 Alpha의 전성기의 보다 높은 클럭 주파수가 가능하게 했다는 것입니다.

어떤 사람은 Alpha가 포인터의 로드를 뒤따르는 의존적 로드에 대해 순서지키도록 강제하기 위해 포인터 로드와 디레퍼런스 사이에 `smp_rmb()`를 위치시킬 수도 있을 겁니다. 하지만, 이는 읽기에 대해 data dependency를 지키는 시스템들 (ARM, Itanium, PPC, 그리고 SPARC)에는 불필요한 오버헤드를 가져올 수 있

¹⁴ 물론, 빈틈없는 독자분들은 Alpha가 불쾌하고 추잡한 만큼이나 근처에서는 볼 수 없고, Section C.6.1의 (감사하게도) 미신적 아키텍쳐가 이 경우임을 이미 알아차렸을 겁니다.

Listing 15.27: Safe Insert and Lock-Free Search

```

1 struct el *insert(long key, long data)
2 {
3     struct el *p;
4     p = kmalloc(sizeof(*p), GFP_ATOMIC);
5     spin_lock(&mutex);
6     p->next = head.next;
7     p->key = key;
8     p->data = data;
9     smp_wmb();
10    head.next = p;
11    spin_unlock(&mutex);
12 }
13
14 struct el *search(long key)
15 {
16     struct el *p;
17     p = rcu_dereference(head.next);
18     while (p != &head) {
19         if (p->key == key) {
20             return (p);
21         }
22         p = rcu_dereference(p->next);
23     };
24     return (NULL);
25 }
  
```

습니다. 그래서 이런 시스템에서의 오버헤드를 없애기 위해 `smp_read_barrier_depends()` 기능이 리눅스 커널에 추가되었으며, 또한 리눅스 커널 v4.15에서 핵심 커널 코드가 더이상 이런 DEC Alpha의 측면을 신경쓰지 않아도 되게끔 `READ_ONCE()`에 추가되었습니다. 이 `smp_read_barrier_depends()` 기능이 Listing 15.26의 line 19에 추가될 수 있습니다만, Listing 15.27의 line 17과 22에 보여진 것처럼 `rcu_dereference()` 래퍼 매크로를 사용하는게 낫습니다.

`smp_wmb()` 자리에 모든 읽기를 하는 CPU들이 쓰기를 하는 CPU의 쓰기를 순서대로 읽게 강제하는 소프트웨어 메커니즘을 구현할 수도 있을 겁니다. 이 소프트웨어 배리어는 모든 다른 CPU에 inter-processor interrupt (IPI)들을 보내는 것으로 구현될 수 있습니다. 그런 IPI가 도착하면, CPU는 리눅스 커널의 `sys_membarrier()` 시스템 콜로 제공되는 것과 비슷한 메모리 배리어 `shootdown`을 구현하는 인스트럭션을 수행할 겁니다. 데드락을 막기 위해선 추가적인 로직이 필요합니다. 물론, data dependency를 지켜주는 CPU에서는 그런 배리어를 단순히 `smp_wmb()`로 정의할 수 있을 겁니다. 하지만, 이 방법은 상당한 오버헤드를 가하고, 더 나아가서 시스템이 강력한 real-time 응답 요구사항을 지켜야만 하는 사람들에게는 비합리적이라고 여겨지기에 리눅스 커뮤니티에서는 사용되지 않습니다.

리눅스 메모리 배리어 기능들은 그 이름을 Alpha의 인스트럭션들에서 따왔는데, `smp_mb()`는 mb로부터, `smp_rmb()`는 rmb로부터, 그리고 `smp_wmb()`는 wmb로부터 왔습니다. Alpha는 `smp_read_barrier_depends()`가 no-op이 아니라 `smp_mb()`인 유일한

CPU 입니다.

Quick Quiz 15.31: Alpha 의 `smp_read_barrier_depends()` 는 왜 `smp_rmb()` 가 아니라 `smp_mb()`죠?

Quick Quiz 15.32: DEC Alpha 는 가장 완화된 메모리 순서 규칙을 갖는 만큼 중요하지 않나요?

Alpha 에 대한 더 자세한 정보를 위해선, 레퍼런스 매뉴얼 [Cor02] 을 참고하시기 바랍니다.

15.4.2 ARMv7-A/R

ARM 제품군의 CPU 는 임베디드 응용에서, 특히 휴대폰과 같이 전력 제한이 있는 응용 분야에서 굉장히 대중적으로 사용됩니다. 그 메모리 모델은 POWER(Section 15.4.6 을 참고하세요) 와 비슷합니다만, ARM 은 다른 메모리 배리어 인스트럭션 집합을 사용합니다 [ARM10]:

DMB (data memory barrier) 는 특정 타입의 오퍼레이션들이 같은 타입의 뒤따르는 모든 오퍼레이션들보다 먼저 완료된 것으로 보이게 합니다. 오퍼레이션들의 “타입”은 모든 오퍼레이션들이거나 쓰기만으로 제한될 수 있습니다 (Alpha `wmb` 와 POWER `eieio` 인스트럭션과 유사합니다). 또한, ARM 은 캐시 일관성이 세가지 범위 중 하나를 가질 수 있게 합니다: 싱글 프로세서, 프로세서들 중 일부 (“inner”) 그리고 글로벌 (“outer”).

DSB (data synchronization barrier) 는 특정 타입의 오퍼레이션들이 뒤따르는 (모든 타입의) 오퍼레이션들이 수행되기 전에 정말로 완료되도록 만듭니다. 오퍼레이션들의 “타입”은 DMB 에서와 같습니다. DSB 인스트럭션은 ARM 아키텍처의 초기 버전에서는 DWB (drain write buffer 또는 data write barrier) 라고 불렸습니다.

ISB (instruction synchronization barrier) 는 CPU 파이프라인을 비워서, ISB 를 뒤따르는 모든 인스트럭션들은 ISB 가 완료된 후에야 불러들여집니다. 예를 들어, 여러분이 (JIT 와 같은) 스스로를 수정하는 프로그램을 만들었다면, 여러분은 해당 코드를 만들고 수행하기 전에 ISB 를 수행해야만 합니다.

이 인스트럭션들 가운데 어떤 것도 리눅스의 `rmb()` 기능의 의미와 맞아떨어지지 않아서, 리눅스에서의 `rmb()` 는 완전한 DMB 로 구현되어집니다. DMB 와 DSB 인스트럭션은 배리어의 앞과 뒤로 순서지어지는 액세스들의 재귀적 정의를 가지고 있는데, 이는 POWER 의 `cumulativity` 와 비슷한 효과를 가지고, 이는 모두 Section 15.2.7.1 의 `cumulativity` 의 변종보다 강력합니다.




Figure 15.14: Half Memory Barrier

ARM 은 또한 control dependency 를 구현하고 있어서, 조건적 브랜치가 어떤 로드에 의존적이라면, 이 조건적 브랜치 뒤에 수행되는 모든 스토어는 이 로드 뒤로 순서지어집니다. 하지만, 조건적 브랜치를 뒤따르는 로드는 이 브랜치와 이 로드 사이에 ISB 인스트럭션이 있지 않다면 순서가 보장되지 않습니다. 다음과 같은 예를 생각해 봅시다:

```
1 r1 = x;
2 if (r1 == 0)
3     nop();
4 y = 1;
5 r2 = z;
6 ISB();
7 r3 = z;
```

이 예에서, load-store control dependency 순서 규칙이 line 1에서의 x 의 로드가 line 4에서의 y 로의 스토어 앞으로 순서지어지게 합니다. 하지만, ARM 은 load-load control dependency 는 지켜주지 않으므로, line 1에서의 로드는 line 5에서의 로드 뒤에 수행될 수도 있습니다. 다른 한편, line 2에서의 조건적 브랜치는 line 6에서의 ISB 인스트럭션과 결합되어 line 7에서의 로드가 line 1에서의 로드 뒤에 수행될 것을 보장합니다. ISB 인스트럭션을 line 3과 4 사이에 추가하면 line 1과 5 사이의 순서가 강제될 것임을 알아두시기 바랍니다.

15.4.3 ARMv8

ARMv8 은 ARM 의 새로운 CPU 제품군 [ARM17] 으로, Section 15.4.2 에서 설명된 32-bit 만 지원하는 CPU 와 달리 64-bit 기능을 갖고 있습니다. ARMv8 의 메모리 모델은 ARMv7 에서의 것들과 비슷합니다만, load-

acquire (LDLARB, LDLARH, 그리고 LDLAR) 와 store-release (STLLRB, STLLRH, 그리고 STLLR) 인스트럭션들을 갖습니다. 이 인스트럭션들은 “반쪽 메모리 배리어”로 동작해서, Figure 15.14 로 그려진 것처럼 ARMv8 CPU 는 앞의 액세스들은 뒤의 LDLAR 인스트럭션과 재배치 할 수 있지만, 앞의 LDLAR 을 뒤의 액세스들과 재배치 하는건 금지되어 있습니다. 비슷하게, ARMv8 CPU 는 앞의 STLLR 인스트럭션을 뒤따르는 액세스들과 재배치 하는건 가능하지만, 앞의 액세스들을 뒤따르는 STLLR 인스트럭션과 재배치하는건 금지되어 있습니다. 누군가는 예상했겠지만, 이는 이 인스트럭션들이 C11 의 load-acquire 와 store-release 를 바로 지원함을 의미합니다.

하지만, ARMv8 은 많은 환경에서 store-release 와 load-acquire 가 완전한 배리어로 동작하도록 조합할 것을 필수로 함으로써 C11 메모리 모델 이상의 것을 할 수도 있습니다. 예를 들어, ARMv8 에서, 스토어 뒤에 store-release, load-acquire, 로드가 모두 서로 다른 변수들에 대해 모두 하나의 CPU 에서 행해지며 순서대로 뒤따른다면, 모든 CPU 들은 최초의 스토어가 마지막의 로드를 앞선다는데에 동의하게 됩니다. 흥미롭게도, 대부분의 (x86 과 mainframe 을 포함해서) TSO 아키텍처들은 이 보장을 갖지 않아서, 두개의 로드가 두개의 스토어 앞으로 재배치 될 수 있게 합니다.

ARMv8 은 `smp_mb__after_spinlock()` 이 전체 배리어를 가져야 하는 두 아키텍처 중 하나인데, 이는 리눅스 커널의 상대적으로 약한 락 획득 구현 때문입니다.

ARMv8 은 또한 제조사가 공개적으로 수행 가능한 정형적 모델을 통해 그 메모리 순서 규칙을 정의한 첫번째 CPU 의 영예를 가졌습니다.

15.4.4 Itanium

Itanium 은 완화된 일관성 모델을 제공해서, 명시적인 메모리 배리어 인스트럭션이 없으면, Itanium 은 임의적으로 메모리 레퍼런스들을 재배치 할 수 있습니다 [Int02]. Itanium 은 `mf` 라는 이름의 memory-fence 인스트럭션을 갖습니다만, 또한 로드, 스토어, 그리고 일부 어토믹 인스트럭션들을 “반쪽짜리 memory fence”로 변환하는 변경자 또한 갖습니다 [Int02]. `acq` 변경자는 뒤따르는 메모리 레퍼런스 인스트럭션들이 `acq` 앞으로 재배치 되는 것을 막습니다만, 앞의 메모리 레퍼런스 인스트럭션들이 `acq` 뒤로 재배치 되는건 허용하는데, 이는 ARMv8 의 load-acquire 인스트럭션과 유사합니다. 비슷하게, `rel` 변경자는 앞의 메모리 레퍼런스 인스트럭션들이 `rel` 뒤로 재배치 되는걸 막습니다만, 뒤따르는 메모리 레퍼런스 인스트럭션들이 `rel` 앞으로 재배치 되는건 허용합니다.

이런 반쪽짜리 memory fence 들은 크리티컬 섹션에

유용한데, 오퍼레이션들을 크리티컬 섹션 안으로 들어 보내는건 안전하지만 크리티컬 섹션 밖으로 보내는건 치명적일 수 있기 때문입니다. 하지만, 이 기능을 가진 CPU 가운데 하나로써,¹⁵ Itanium 은 한때 리눅스의 락 획득과 해제에 관련된 메모리 순서 규칙을 정의했습니다. 이상하게 들릴 수 있지만, 실제 Itanium 하드웨어는 load-acquire 와 store-release 인스트럭션들을 완전한 배리어로 구현했다는 소문이 있습니다. 어쨌든, Itanium 은 load-acquire 와 store-release 의 (소문이 사실이어서 실제가 아니라면) 개념을 인스트럭션 집합에 추가한 첫번째 주류 CPU 였습니다.

Itanium `mf` 인스트럭션은 리눅스 커널의 `smp_rmb()`, `smp_mb()`, 그리고 `smp_wmb()` 기능에 사용됩니다. 아, 그리고 반대의 루머가 있긴 하지만, “`mf`” 는 “memory fence” 의 약자가 맞습니다.

마지막으로, Itanium 은 “`mf`” 인스트럭션을 포함해 “release” 오퍼레이션들에 글로벌하고 완전한 순서를 제공합니다. 이는 *transitivity* 를 제공하는데, 이는 특정 코드 조각이 특정 액세스가 일어난 것으로 파악했다면, 뒤따르는 모든 코드 조각은 역시 이 액세스가 이미 일어난 것으로 보게 됩니다. 다시 말하지만, 모든 관련된 코드 조각들이 올바르게 메모리 배리어를 사용했다는 가정 하의 이야기입니다.

마지막으로, Itanium 은 리눅스 커널이 지원하는, 같은 변수에의 평범한 로드들을 재배치 할 수 있는 유일한 아키텍처입니다. 리눅스 커널은 `READ_ONCE()` 가 `ld,acq` 인스트럭션으로 컴파일되는 `volatile` 로드를 만들어서 모든 해당 CPU 에서의, 그리고 같은 변수로의 `READ_ONCE()` 호출이 순서를 갖게 강제해서 이 문제를 막습니다.

Finally, Itanium is the only architecture supporting the Linux kernel that can reorder normal loads to the same variable. The Linux kernel avoids this issue because `READ_ONCE()` emits a `volatile` load, which is compiled as a `ld,acq` instruction, which forces ordering of all `READ_ONCE()` invocations by a given CPU, including those to the same variable.

15.4.5 MIPS

MIPS 메모리 모델 [Ima17, page 479] 은 ARM, Itanium, 그리고 POWER 를 닮아서, 기본적으로는 완화된 순서를 갖지만, 의존성은 지켜줍니다. MIPS 는 다양한 메모리 배리어 인스트럭션을 갖습니다만, 하드웨어 상의 필요에 매여있기보다는 ARMv8 에 추가된 것들과 비슷하게, 리눅스 커널과 C++11 표준 [Smi15] 에서 존재하는 사용상의 경우에 연결되어 있습니다:

¹⁵ 이제는 PowerPC 가 이 모호한 특권을 갖는 아키텍처입니다.

SYNC

메모리 레퍼런스 외에도 여러 하드웨어 오퍼레이션들을 위한 완전한 배리어로, v4.13 리눅스 커널의 OCTEON 시스템들을 위한 `smp_mb()` 를 구현함.

SYNC_WMB

쓰기 메모리 배리어로, OCTEON 시스템들에서 v4.13 리눅스 커널의 `smp_wmb()` 기능을 `syncw` mnemonic 을 통해 구현함. 다른 시스템들에서는 그냥 `sync` 만 사용함.

SYNC_MB

메모리 오퍼레이션들에만 작동하는 완전한 메모리 배리어. 이는 `smp_mb()` 와 C++ `atomic_thread_fence(memory_order_seq_cst)` 의 구현에 사용될 수 있습니다.

SYNC_ACQUIRE

C++ 의 `atomic_thread_fence(memory_order_acquire)` 의 구현에 사용될 수 있는 `acquire` 메모리 배리어. 이론상으로는, 이 인스트럭션은 v4.13 리눅스 커널의 `smp_load_acquire()` 기능의 구현에도 사용될 수 있지만, 실제 코드는 `sync` 를 대신 사용합니다.

SYNC_RELEASE

C++ 의 `atomic_thread_fence(memory_order_release)` 의 구현에 사용될 수 있는 `release` 메모리 배리어. 이론상으로는, v4.13 리눅스 커널의 `smp_store_release()` 기능 구현에도 사용될 수 있습니다만, 실제 코드에서는 `sync` 가 대신 사용됩니다.

SYNC_RMB

이론상으로는 리눅스 커널의 `smp_rmb()` 기능을 구현하는데 사용될 수 있는 읽기 메모리 배리어이나, v4.13 리눅스 커널에서 지원하는 현재의 MIPS 구현에서는 순서 규칙을 위한 명시적 인스트럭션이 필요없습니다. 따라서, `smp_rmb()` 는 단순히 컴파일러에 대한 강제만 가합니다.

SYNCI

Just-in-time (JIT) 컴파일러들에서 사용될 수 있는, 스스로를 수정하는 코드가 사용될 수 있게 해주는 인스트럭션들과 함께 사용되는 인스트럭션 캐시 동기화 기능.

MIPS 설계자들과의 비공식적 토론은 MIPS 가 ARM 과 POWER 의 것과 유사한 *transitivity* 또는 *cumulativity* 에 대한 정의를 가짐을 암시합니다. 하지만, 서로 다른 MIPS 구현들은 서로 다른 메모리 순서 규칙을 가질 수 있으며, 따라서 여러분이 사용하고 있는 특정 MIPS 구현의 문서를 확인하는게 중요합니다.

15.4.6 POWER / PowerPC

POWER 와 PowerPC CPU 제품군은 다양한 메모리 배리어 인스트럭션을 갖습니다 [IBM94, LHF05]:

sync 는 모든 앞서는 오퍼레이션들이 뒤따르는 오퍼레이션들이 시작하기 전에 완료된 것으로 보이게 합니다. 따라서 이 인스트럭션은 상당히 비용이 비쌉니다.

lwsync (light-weight sync) 는 로드를 뒤의 로드와 스토어에 대해, 그리고 스토어를 뒤의 스토어에 대해 순서 맞춥니다. 하지만, 이 인스트럭션은 스토어를 뒤따르는 로드에 대해 순서맞추지는 않습니다. **lwsync** 인스트럭션은 load-acquire 와 store-release 오퍼레이션들을 구현하는데 사용될 수 있습니다. 흥미롭게도, **lwsync** 인스트럭션은 x86, z Systems, 그리고 우연히도, SPARC TSO 와 동일한 CPU 내에서의 순서 규칙을 강제합니다. 하지만, **lwsync** 인스트럭션을 각 메모리 레퍼런스 인스트럭션 쌍 사이에 위치시키는 것으로는 x86, z Systems, 또는 SPARC TSO 메모리 순서규칙을 이끌어내지 못합니다. 이런 시스템들에서는, CPU 들의 한 쌍이 독립적으로 다른 변수들에 대한 스토어를 수행한다면, 모든 다른 CPU 들이 이 스토어들의 순서에 동의할겁니다. PowerPC 에서는 **lwsync** 인스트럭션이 각 메모리 레퍼런스 인스트럭션 사이에 있다 해도 그렇지 않은데, PowerPC 는 non-multicopy atomic 하기 때문입니다.

eieio (enforce in-order execution of I/O) 는 모든 앞의 캐시 가능한 스토어들을 뒤따르는 스토어보다 먼저 완료된 것으로 보이게 합니다. 하지만, 캐시 가능한 메모리로의 스토어들은 캐시 가능하지 않은 메모리로의 스토어들과 따로 순서지어져서, **eieio** 는 MMIO 스토어가 스팬락 해제보다 앞서게 강제하지는 않을 겁니다.

isync 는 모든 앞의 인스트럭션들이 뒤따르는 인스트럭션들이 수행을 시작하기 전에 완료된 것으로 보이게 합니다. 이는 앞의 인스트럭션들은 그들이 만들어낼 수 있는 모든 trap 들은 이미 일어났거나 일어나지 않을 것이 보장될 정도로, 그리고 이 인스트럭션들의 부가적 효과들 (예를 들면, page-table 의 변경) 은 뒤따르는 인스트럭션들에게 보일 정도로 많이 진행되었어야 함을 의미합니다.

불행히도 이 인스트럭션들 중 어느 것도 모든 스토어들이 순서지어져야 하지만, **sync** 인스트럭션의 높은 오버헤드를 갖는 동작을 필요로 하지는 않는 리눅스의 `wmb()` 기능에 정확히 맞아떨어지지 않습니다. 하지만 선택의 여지가 없습니다: ppc64 버전의 `wmb()` 와 `mb()`

는 무거운 sync 인스트럭션으로 정의되어 있습니다. 하지만, 리눅스의 `smp_wmb()` 인스트럭션은 (드라이버는 SMP 커널에서는 물론이고 UP에서도 MMIO들의 순서를 세심히 지켜줘야 하기 때문에) MMIO에 절대 사용되지 않으므로, 더 가벼운 `eieio` 또는 `lwsync` 인스트럭션으로 정의되어 있습니다 [MDR16b]. 이 인스트럭션은 다섯개의 모음으로 구성된 약자를 가진다는 점에서도 독특합니다. `smp_mb()` 인스트럭션 또한 sync 인스트럭션으로 정의되어 있습니다만, `smp_rmb()` 와 `rmb()` 모두 더 가벼운 `lwsync` 인스트럭션으로 정의되어 있습니다.

POWER는 transitivity를 얻는데 사용될 수 있는 “cumulativity”를 갖추고 있습니다. 제대로 사용되면, 앞의 코드 조각의 결과를 보는 모든 코드는 이 앞의 코드 조각들이 스스로 본 액세스를 역시 볼 것입니다. 더 많은 자세한 내용은 McKenney와 Silvera의 글 [MS09]에서 볼 수 있습니다.

POWER는 ARM과 같은 방식으로 control dependency를 지키는데, ARM ISB 인스트럭션이 POWER `isync` 인스트럭션으로 바뀌어야 한다는 점은 예외입니다.

ARMv8과 같이, POWER는 `smp_mb__after_spinlock()`이 전체 메모리 배리어일 것을 필요로 합니다. 또한, POWER는 `smp_mb__after_unlock_lock()`이 전체 메모리 배리어일 것을 필요로 하는 유일한 아키텍쳐입니다. 두 경우 모두 POWER의 락킹 도구들의, 획득과 해제 모두에 순서를 제공하기 위해 `lwsync`를 사용해서 생기는 완화된 순서 속성 때문입니다.

POWER 아키텍처의 많은 멤버들이 일관적이지 않은 인스트럭션 캐시를 가져서, 메모리로의 스토어는 인스트럭션 캐시에는 반영되지 않을 수도 있습니다. 고맙게도, 오늘날엔 적은 사람들만이 스스로를 수정하는 코드를 작성합니다만, JIT과 컴파일러는 항상 이 일을 합니다. 더 나아가서, 최근에 수행된 프로그램을 다시 컴파일하는 행위는 CPU의 관점에서는 스스로를 수정하는 코드처럼 보입니다. `icbi` 인스트럭션 (instruction cache block invalidate)은 인스트럭션 캐시로부터 특정 캐시 라인을 무효화 시키고, 이런 상황에서 사용될 수 있습니다.

15.4.7 SPARC TSO

SPARC의 TSO (total-store order)는 리눅스와 Solaris 모두에서 사용되었으며, 이 아키텍처는 또한 PSO (partial store order)와 RMO (relaxed-memory order)를 정의합니다. RMO에서 돌아가는 모든 프로그램은 PSO나 TSO에서도 돌아갈 수 있으며, 비슷하게, PSO에서 돌아가는 프로그램은 TSO에서도 돌아갑니다. 공유 메모리 병렬 프로그램을 다른 방향으로 옮겨 수행하는 것은 메모리

배리어의 주의 깊은 추가를 필요로 합니다.

SPARC의 PSO와 RMO 모드는 오늘날엔 잘 사용되지 않긴 합니다만, 해당 모드들은 세세한 수준의 규칙 보장 제어를 가능하게 하는, 매우 유연한 메모리 배리어 인스트럭션 [SPA94]을 생겨나게 했습니다.

StoreStore는 앞의 스토어들을 뒤따르는 스토어들에 대해 순서지어줍니다. (이 옵션은 리눅스 `smp_wmb()` 기능에서 사용됩니다.)

LoadStore는 앞의 로드를 뒤따르는 스토어에 대해 순서지어줍니다.

StoreLoad는 앞의 스토어들을 뒤따르는 로드들에 대해 순서지어줍니다. (이 옵션은 리눅스 `smp_rmb()` 기능에 의해 사용됩니다.)

sync는 모든 앞의 오퍼레이션들을 뒤따르는 오퍼레이션들 전에 완료되도록 합니다.

MemIssue는 진행중인 메모리 오퍼레이션들이 뒤따르는 메모리 오퍼레이션들 전에 완료되도록 하는데, memory-mapped I/O의 일부 경우에 중요합니다.

Lookaside는 MemIssue와 동일하지만, 앞의 스토어들과 뒤따르는 로드들에만 적용되며, 같은 메모리 영역에 접근하는 스토어와 로드에만 적용됩니다.

그런데, “`membar #MemIssue`”는 왜 필요할까요? “`membar #StoreLoad`”는 뒤따르는 로드가 그 값을 스토어 버퍼에서 가져올 수 있게 해서, 해당 쓰기가 MMIO 레지스터로 향하는 것이어서 읽히는 값에 따라 부가작용을 일으킬 수 있는 것이라면 문제가 될 수 있습니다. 반면에, “`membar #MemIssue`”는 이 로드가 수행되기 전에 스토어 버퍼들이 비워지게 해서, 이 로드는 이 값을 실제로 MMIO 레지스터로부터 얻어오게 할 겁니다. 드라이버는 이대신 “`membar #Sync`”를 사용할 수 있습니다만, 더 비싼 “`membar #Sync`”의 추가적인 동작이 필요없는 경우엔 더 가벼운 편인 “`membar #MemIssue`”가 낫습니다.

“`membar #Lookaside`”는 “`membar #MemIssue`”의 경량 버전으로, 특정 MMIO 레지스터에 쓰기를 하는 행위가 해당 레지스터로부터 다음에 읽힐 값에 영향을 주는 경우에 유용합니다. 하지만, 더 무거운 “`membar #MemIssue`”는 해당 MMIO 레지스터의 쓰기가 나중에 다른 MMIO 레지스터로부터의 읽기에 영향을 끼치는 경우에는 반드시 사용되어야만 합니다.

SPARC는 `flush` 인스트럭션이 인스트럭션이 스토어된 시점과 수행되는 시점 사이에서 사용될 것을 필요로

합니다 [SPA94]. 이는 SPARC 의 인스트럭션 캐시로부터 해당 지역의 기존 값을 비우기 위해 필요합니다. `flush` 는 주소를 받아서, 인스트럭션 캐시로부터 해당 위치의 값만을 지운다는 것을 알아두시기 바랍니다. SMP 시스템에서는 모든 CPU 의 캐시가 비워지지만, 언제 모든 CPU 의 플러시가 완료되었는지를 알아낼 간편한 방법은 없습니다만, 구현상의 레퍼런스는 있습니다.

하지만 다시 말하건대, 리눅스 커널은 SPARC 를 TSO 모드로 수행하므로, 앞의 모든 `membar` 변종들은 역사적 관점에서만 흥미로울 것입니다. 특히, `smp_mb()` 기능은 `#StoreLoad` 의 사용만을 필요로 할텐데 다른 세개의 재배치들은 TSO 에서 금지되어 있기 때문입니다.

15.4.8 x86

역사적으로, x86 CPU 들은 “process ordering” 을 제공해서 모든 CPU 들이 특정 CPU 의 메모리로의 쓰기 순서에 동의하게 했습니다. 이는 `smp_wmb()` 가 해당 CPU 에서는 no-op 일 수 있게 했습니다 [Int04b]. 물론, `smp_wmb()` 기능 앞뒤로 재배치를 하는 최적화를 막기 위해 컴파일러 지시어 또한 필요했습니다. 과거에는, 특정 x86 CPU 들은 로드들에는 순서 보장을 제공하지 않아서, `smp_mb()` 와 `smp_rmb()` 기능들이 `lock; addl` 로 확장되었습니다. 이 어토믹 인스트럭션은 로드와 스트어 모두에 대한 배리어로 동작합니다.

하지만 그건 과거의 일입니다. 최근에, Intel 은 x86 을 위한 메모리 모델을 공개했습니다 [Int07]. 이로 인해 Intel 의 실제 CPU 들은 기존의 명세서들에서 이야기 하던 것보다 더 빠른 순서 규칙을 강제한다는 것이 드러났으며, 따라서 이 모델은 단순히 기존의 실질적 표준의 행동을 의무화 합니다. 더 최근에, Intel 은 x86 을 위한 개정된 메모리 모델 [Int11, Section 8.2] 를 공개 했는데, 여기선 스토어에 대해선 완전한 전역적 순서를 의무화합니다만, 개별 CPU 는 여전히 스스로의 스토어들을 이 완전한 전역적 순서보다 빠르게 발생한 것으로 볼 수 있게 합니다. 완전한 순서 보장을 대한 이 예외는 스토어 버퍼들에 관련된 중요한 하드웨어 최적화를 허용하기 위해 필요합니다. 또한, x86 은 또 다른 `multicopy atomicity` 를 제공하는데, 예를 들면, CPU 0 가 CPU 1 에 의한 스토어를 봤다면, CPU 0 는 CPU 1 이 해당 스토어 전에 본 모든 스토어들 역시 볼 수 있을 것을 보장합니다. 소프트웨어는 이 하드웨어 최적화들을 무시하기 위해 어토믹 오퍼레이션들을 사용할 수도 있는데, 이는 어토믹 오퍼레이션들이 어토믹하지 않은 비슷한 것들에 비해 더 비싼 경향을 갖는 이유입니다.

특정 메모리 위치에 행해지는 어토믹 인스트럭션들은 모두 같은 크기여야 함 [Int11, Section 8.1.2.2] 을 알아둘 필요가 있습니다. 예를 들어, 여러분이 한 CPU

가 한 바이트의 값을 증가시키는 동안 다른 CPU 가 같은 위치에 4-바이트 어토믹 값 증가 오퍼레이션을 수행한다면, 여러분이 알아서 해야 합니다.

하지만, 일부 SSE 인스트럭션들은 완화된 순서 규칙을 가짐을 알아두시기 바랍니다 (`clflush` 와 `non-temporal move` 인스트럭션들 [Int04a]). 이런 임시적이지 않은 move 인스트럭션들을 사용하는 코드는 `smp_mb()` 를 위해 `mfence` 를, `smp_rmb()` 를 위해 `lfence`, 그리고 `smp_wmb()` 를 위해 `sfence` 를 수행할 수 있습니다.

x86 CPU 의 일부 오래된 버전들은 out-of-order 스토어들을 가능하게 하는 모드 비트를 갖고 있으며, 이 CPU 들에서는, `smp_wmb()` 역시 `lock; addl` 로 정의됩니다.

보다 최신의 x86 구현들은 스스로를 수정하는 코드를 특수한 인스트럭션들 없이 받아들이지만, 기존과 잠재적인 미래의 x86 구현들에 대해서도 완전히 호환성을 가지려면, CPU 는 코드를 수정하고 이를 수행하는 사이에 `jump` 인스트럭션이나 `serializing` 인스트럭션 (e.g. `cpuid`) 을 수행해야만 합니다 [Int11, Section 8.1.3].

15.4.9 z Systems

z Systems 는 기존에 360, 370, 390, 그리고 zSeries [Int04c] 라 알려진 IBM™ 메인프레임 제품군을 만드는데 사용되었습니다. 병렬성은 z Systems 에 늦게 도입되었습니다만, 이 메인프레임들은 1960년대 중반에 출고되기 시작한 걸 생각해 보면, 그렇게 늦은 건 아닙니다. 리눅스 `smp_mb()` 기능에 “`bcr 15,0`” 인스트럭션이 사용됩니다만, `smp_rmb()` 와 `smp_wmb()` 기능에는 컴파일러 제약만으로도 충분합니다. 이 아키텍쳐는 또한 Table 15.5 에 보인 것처럼 상대적으로 강력한 메모리 순서 보장을 갖습니다. 특히, 모든 CPU 들은 다른 CPU 들로부터의 관계없는 스토어들의 순서에 동의를 하게 되는데, 즉, z Systems 는 완전한 `multicopy atomic` 을 제공합니다.

대부분의 CPU 들과 같이, z Systems 아키텍처는 캐시 일관적 인스트럭션 흐름을 제공하지 않아서, 스스로를 수정하는 코드는 인스트럭션들을 업데이트 하는 시점과 수행하는 시점 사이에 직렬화 인스트럭션을 수행해야만 합니다. 그렇다고는 하나, 많은 실제 z Systems 기계들은 사실 스스로를 수정하는 코드를 직렬화 인스트럭션 없이 수행하고 있습니다. z Systems 인스트럭션 집합은 많은 직렬화 인스트럭션들을 제공하는데, `compare-and-swap`, 일부 종류의 브랜치 (예를 들어, 앞서 이야기한 “`bcr 15,0`” 인스트럭션), 그리고 `test-and-set` 등 외에도 많은 것들을 제공합니다.

15.5 Where is Memory Ordering Needed?

이 섹션은 Table 15.3 과 Section 15.1.3 을 다시 살펴보고, 더 세련된 경험적 법칙을 가지고 그 사이의 토론을 요약합니다.

첫번째 경험적 법칙은 메모리 순서 오퍼레이션들은 최소 두개의 쓰레드 사이에 최소 두개의 변수가 관여하는 상호작용이 존재할 가능성이 있을 때에만 필요하다는 것입니다. 관계되는 것들에 비춰보면, 이 하나의 문장은 Section 15.1.3 의 기본 경험적 규칙을 무척 내포하는데, 예를 들어, “메모리 배리어 짹짓기”는 “사이클”의 두개 쓰레드에서의 특수 경우임을 생각해 보세요. 또한, 항상 그렇듯, 싱글 쓰레드 프로그램이 충분한 성능을 제공한다면, 뭐하려 병렬성을 고려하겠습니까?¹⁶ 무엇보다도, 병렬성을 제거하는건 메모리 순서 보장 오퍼레이션의 추가적 비용을 제거합니다.

두번째 경험적 법칙은 load-buffering 상황에 관계됩니다: 한 사이클 내에서의 모든 쓰레드간의 통신이 store-to-load 연결 (즉, 다음 쓰레드의 로드가 앞의 쓰레드가 스토어한 값을 리턴하는것)을 사용한다면, 최소한의 순서보장으로 충분합니다. 최소한의 순서 보장은 의존성, acquire, 그리고 모든 더 강력한 순서 보장 오퍼레이션들을 포함합니다.

세번째 경험적 법칙은 release-acquire 체인에 관계됩니다: 해당 사이클 내에서의 하나를 제외한 모든 연결들이 store-to-load 연결이라면, Listing 15.23 와 15.24 에 보인 것처럼 각각의 store-to-load 링크들에 release-acquire 쌍을 사용하는 것으로 충분합니다. 여러분은 acquire 를 의존성으로 교체할 수도 있지만 이는 이를 허용하는 환경에서만 가능하며, C11 표준의 메모리 모델은 종속성을 모두 지키지는 않음을 명심하시기 바랍니다. 따라서, 로드로 시작되는 종속성은 READ_ONCE() 나 rcu_dereference() 로 시작되어야만 함 역시 알아두시기 바랍니다: 평범한 C 언어의 로드 기능은 충분치 않습니다. 여러분의 컴파일러에 의해 망가진 의존성은 아무짝에도 도움이 되지 않으니, Section 15.3.2 과 ?? 를 주의깊게 다시 볼 것을 잊지 마세요! 하나의 non-store-to-load 링크를 공유하는 두 쓰레드는 일반적으로 WRITE_ONCE() 더하기 smp_wmb() 를 smp_store_release() 로 교체할 수 있고, READ_ONCE() 더하기 smp_rmb() 를 smp_load_acquire() 로 교체할 수 있습니다. 하지만, 지혜로운 개발자는 예를 들면 Section 12.3 에서 설명한 herd 툴을 사용하거나 해서 그런 교체를 주의 깊게 체크할 겁니다.

Quick Quiz 15.33: Load-to-store 와 store-to-store 링크에는 더 무거운 순서 규칙이 필요하지만 store-to-load

링크에는 그렇지 않죠? 대체 뭐가 store-to-load 링크를 그렇게 특별하게 하는 건가요??? ■

마지막 네번째 경험적 법칙은 어디에 완전한 메모리 배리어 (또는 그보다 강력한 것) 이 필요한지를 식별하게 합니다: 해당 사이클이 두개 이상의 non-store-to-load 연결을 갖는다면 (즉, 두개 이상의 load-to-store 와 store-to-store 링크), Listing 15.19 와 Quick Quiz 15.24 의 답에서 설명한 것과 같이 각 non-store-to-load 연결 사이에 최소 하나의 완전한 배리어를 필요로 하게 됩니다. 완전한 배리어는 smp_mb(), 성공적으로 수행된 full-strength non-void atomic RMW 오퍼레이션들, 그리고 smp_mb__before_atomic() 이나 smp_mb__after_atomic() 과 결합된 원자적 RMW 오퍼레이션들을 포함합니다. RCU 의 grace-period-wait 기능들 (synchronize_rcu() 와 그 외의 비슷한 것들) 역시 완전한 배리어로 동작합니다만, smp_mb() 보다도 많이 비쌉니다. 강력함에는 비용이 따라옵니다만, 완전한 배리어의 오버헤드는 일반적으로 확장성을 해치는 것 보다는 성능을 해칩니다.

이 네개의 경험적 법칙은 최소한의 보장만을 내포함을 알아두시기 바랍니다. 서로 다른 아키텍쳐들은 Section 15.4 에서 이야기한 것처럼 더 강력한 보장을 제공할 수도 있습니다만 이는 해당 아키텍쳐에서의 수행만을 위해 설계된 코드 외의 부분에서는 이에 의존하지 말아야 합니다. 또한, 더 관여된 메모리 모델은 일부 커진 복잡도를 대가로 해서 더 강한 보장 사항을 제공할 겁니다 [AMM¹⁸].

마지막 충고의 말입니다: 낮은 수준의 메모리 순서 보장 기능의 사용은 마지막 수단입니다. 락킹이나 RCU 같이 여러분을 위해 메모리 순서 보장을 고려하는, 존재하는 기능들을 사용하는게 거의 항상 더 낫습니다.

¹⁶ 취미로 사는 사람들과 연구자들은 물론 이것 등의 경고들을 무시해도 좋을 겁니다.

Chapter 16

Ease of Use

16.1 What is Easy?

“쉽다”는 건 상대적인 용어입니다. 예를 들어, 많은 사람들은 15시간의 비행을 약간 괴로운 체험일 것이라 여깁니다—그들이 대체할 수 있는 이동수단, 특히 수영과 같은 것을 고려하는 것을 면추지 않는다면 말이죠. 이는 사용하기 편리한 API를 만드는 것은 여러분의 의도된 사용자들을 상당히 잘 알아야 함을 의미합니다.

다음의 질문은 이 지점을 잘 설명합니다: “오늘날 살아가는 사람들 가운데 무작위적으로 선택된 사람을 하나 놓고 생각할 때, 어떤 변경이 그의 또는 그녀의 삶을 개선시킬까요?”

모든 사람의 삶을 도울 것이라 보장되는 하나의 변화는 존재하지 않습니다. 무엇보다도, 굉장히 다양한 부류의 사람들이 연관된 다양한 범위의 필요, 원하는 것, 소망, 그리고 열망을 가지고 존재하고 있습니다. 굶어 죽어가고 있는 사람은 음식을 필요로 할 것입니다만, 병적으로 비만인 사람에게 음식을 더 주는 것은 그의 죽음을 앞당길 수도 있습니다. 많은 젊은 사람들에 의해서 열광적으로 소망되는 높은 수준의 짜릿함은 심장마비로부터 회복되고 있는 누군가에게는 치명적일 수 있습니다. 한 사람의 성공에 중요한 정보는 너무 많은 정보의 부하로 고통받고 있는 누군가에게는 실패를 줄 수도 있습니다. 짧게 말해서, 여러분이 전혀 모르는 누군가를 돋기 위한 목적의 소프트웨어 프로젝트를 위해 일하고 있다면, 여러분은 그 누군가가 여러분의 노력에 덜 감명 받더라도 놀라지 않아야 합니다.

여러분이 정말로 어떤 집단의 사람들을 돋고자 한다면, 그들과 일정한 기간의 시간동안 그들과 가까이 작업을 하는 것을 대체할 수는 없습니다. 더도 아니고 덜도 아니고, 여러분의 사용자들이 여러분의 소프트웨어로 인해 행복해지는 정도를 늘리기 위해서 여러분이 할 수 있는 몇 가지 간단한 것들이 존재하고, 그 중 일부는 다음 섹션에서 다뤄집니다.

Creating a perfect API is like committing the perfect crime. There are at least fifty things that can go wrong, and if you are a genius, you might be able to anticipate twenty-five of them.

With apologies to any Kathleen Turner fans who might still be alive.

16.2 Rusty Scale for API Design

이 섹션은 Rusty Russell의 2003 Ottawa Linux Symposium 키노트 [Rus03, Slides 39-57]에서 가져와졌습니다. Rusty의 주장의 핵심은 목표는 API를 단순히 사용하기 편하게 만드는 게 아니라, API가 잘못 사용되기 어렵게 해야 한다는 것입니다. 그런 결론 하에서, Rusty는 잘못 사용하기 어렵게 하는 속성을 중요한 순서로 내림차순으로 정리한 “Rusty Scale”을 제안했습니다.

다음의 리스트는 Rusty Scale을 리눅스 커널에 일반화 시킵니다:

1. 잘못 사용되는 것은 불가능합니다. 이건 모든 API 디자이너들이 노력해야 할 표준이긴 합니다만, 가상의 `dwim()`¹ 커맨드가 이를 안지킨, 잘못된 예에 가깝습니다.
2. 컴파일러나 링커는 여러분을 잘못되게 두지 않습니다.
3. 컴파일러나 링커는 여러분이 잘못한 경우에는 경고를 합니다.
4. 가장 간단한 사용법이 올바른 사용법입니다.
5. 이름은 여러분이 그걸 어떻게 사용해야 하는지 알려줘야 합니다.
6. 올바르게 사용하지 않는다면 그것은 수행시간에 항상 깨져야 합니다.
7. 일반적인 관례를 따라야 하며, 그렇게 하면 여러분은 올바른 동작을 얻게 될겁니다. 메모리 할당을 잘못하기는 쉽지만, 수많은 프로젝트들이 적어도 대부분의 경우에는 메모리 할당을 올바르게 관리합니다. `malloc()`을 Valgrind [The11]와 함께

¹ `dwim()` 함수는 “do what I mean (내가 의미하는 걸 하라)”의 약자입니다.

- 사용하는 행위는 `malloc()` 을 거의 “올바르게 사용해야 하며, 그러지 않는다면 수행시간에 항상 깨지는” 지점까지 옮겨 놓을 겁니다.
8. 문서를 읽으면 여러분은 올바른 동작을 얻을 것입니다.
 9. 구현을 들여다보면 여러분은 올바른 동작을 얻을 것입니다.
 10. 올바른 메일링 리스트 기록을 읽으면 여러분은 올바른 동작을 얻을 것입니다.
 11. 올바른 메일링 리스트 기록을 읽으면 여러분은 잘못된 동작을 얻을 것입니다.
 12. 구현을 들여다보면 여러분은 잘못된 동작을 얻을 것입니다. `rcu_read_lock()` 의 `CONFIG_PREEMPT` 없을 때의 원래 구현 [McK07a] 은 이 요점의 유명하지 않은, 하나의 예입니다.
 13. 문서를 읽으면 여러분은 잘못된 동작을 얻을 것입니다. 예를 들어, DEC Alpha `wmb` 인스트럭션의 문서 [SW95] 는 이 인스트럭션이 실제로 하는 것에 비해 더 많이 엄격한 메모리 순서 의미를 갖는다고 개발자들이 생각하게끔 만들었습니다. 나중의 문서는 이 점에 대해서 설명해서 [Com01, Pug00], `wmb` 인스트럭션을 “문서를 읽으면 여러분은 올바른 동작을 얻을 것입니다” 지점으로 옮겼습니다.
 14. 일반적인 관계를 따르면 여러분은 잘못된 동작을 얻을 것입니다. `printf()` 명령은 이런 요점의 한 예인데, 개발자들은 거의 항상 `printf()` 의 여러 리턴을 체크하지 않기 때문입니다.
 15. 올바르게 수행한다면 그것은 항상 수행시점에서 깨질 겁니다.
 16. 이름은 여러분이 그것을 어떻게 사용해선 안되는지 설명해 줘야 합니다.
 17. 분명한 사용은 잘못된 것입니다. 리눅스 커널의 `smp_mb()` 함수는 이 요점의 한 예입니다. 많은 개발자들이 이 함수는 실제로 그것이 가지고 있는 것에 비해 강한 순서 규칙을 가지고 있을 것이라 가정합니다. Chapter 15 는 이런 실수를 막기 위해 필요한 정보를 담고 있으며, 리눅스 커널 소스 트리의 Documentation 디렉토리 역시 그런 정보를 담고 있습니다.
 18. 컴파일러나 링커는 여러분이 올바른 일을 한다면 경고를 해줄 겁니다.
 19. 컴파일러나 링커는 여러분이 올바른 일을 하도록 놔두지 않을 겁니다.
 20. 올바른 일을 하는 것은 중요합니다. `gets()` 함수는 이 요점의 하나의 유명한 예입니다. 실제로, `gets()` 는 무조건적인 버퍼 오버플로우 보안 구멍으로 설명될 수 있을 겁니다.

16.3 Shaving the Mandelbrot Set

유용한 프로그램들은 (Figure 16.1 에 보인) Mandelbrot 집합과 깔끔하게 떨어지는 부드러운 외곽을 갖지 않는다는 점에서 닮았습니다—만약 그런 외곽을 갖는다면, halting problem 이 풀릴 수 있을 겁니다. 하지만 우린 진짜 사람이 사용할 수 있는 API 가 필요하지, 각각의 모든 잠재적 사용에 Ph.D. 학위 논문이 필요한 것들을 원하는게 아닙니다. 따라서, 우리는 “Mandelbrot 집합을 깎아내서”,² API 의 사용을 잠재적 사용의 전체 집합 중 쉽게 설명될 수 있는 부분집합으로 제한시켜야 합니다.




Figure 16.1: Mandelbrot Set (Courtesy of Wikipedia)

그런 깎아냄은 비생산적으로 보일 수도 있습니다. 무엇보다, 한 알고리즘이 동작한다면, 왜 그걸 사용하지 말아야 할까요?

최소한 일부의 깎아내기는 분명히 필요한 이유를 보기 위해서, 데드락을 예방하는, 하지만 가능한 가장 나쁜 방법을 사용하는 락킹 설계를 생각해 봅시다. 이 설계는 순환식 이중 링크드 리스트를 사용하는데, 이 리스트는 시스템 상의 각각의 쓰레드를 위해 하나의 헤더 원소와 함께 하나의 원소를 유지합니다. 새로운 쓰레드가 시작되면, 그 부모 쓰레드는 이 리스트에 새로운 원소를 집어넣어야만 하는데, 이는 어떠한 종류의 동기화를 필요로 합니다.

² Josh Triplett 덕에.

이 리스트를 보호하는 한가지 방법은 글로벌 락을 사용하는 것입니다. 하지만, 이는 쓰레드들이 빈번하게 생성되고 소멸된다면 병목지점이 될 수도 있습니다.³ 또 다른 방법은 해시 테이블을 사용하고 개별적인 hash bucket 들을 락으로 관리하는 것입니다만, 이는 리스트를 원소 순서대로 스캔할 때에는 나쁜 성능으로 동작할 겁니다.

세번째 방법은 개별의 리스트 원소들을 락으로 보호하고, 원소의 삽입 시에 해당 원소의 앞쪽 원소와 뒤쪽 원소 둘 다의 락을 잡는 겁니다. 두 락이 모두 잡혀야 하므로, 그것들을 어떤 순서로 잡을 것인지를 우리는 결정해야 합니다. 그런 두개의 일반적인 방법은 락들을 주소순서로 잡거나 그것들이 리스트에 보여지는 순서대로 잡아서, 락으로 잡겨지는 두개의 원소 중 하나가 잡겨질 때 그 헤더가 항상 먼저 얻어지도록 하는 것입니다. 하지만, 이 방법들 모두 특별한 경우 검사와 분기를 필요로 합니다.

여기서 깎아내져야 하는 해결책은 락들을 무조건적으로 리스트 순서로 잡는 것입니다. 하지만 데드락은 어떡하죠?

데드락은 일어날 수 없습니다.

이를 알아보기 위해, 리스트의 원소를 헤더를 0으로, (순환형 리스트이므로, 헤더의 앞쪽 원소인) 리스트의 마지막 원소를 N 으로 하는식으로 번호를 매깁시다. 비슷하게, 쓰레드들을 0부터 $N - 1$ 까지로 번호매깁시다. 만약 각각의 쓰레드가 원소들 가운데 연속적인 두개의 원소들의 락을 잡으려 한다면, 최소한 하나의 쓰레드는 두 락들을 모두 잡을 수 있도록 보장될 겁니다.

왜죠?

리스트의 모든 것들에 닿을 만큼 쓰레드들의 수가 충분히 많지 않기 때문입니다. 쓰레드 0 가 원소 0 의 락을 잡는다고 생각해 봅시다. 이 쓰레드가 블락되기 위해서는, 어떤 다른 쓰레드가 이미 원소 1 의 락을 잡았어야 하는데, 쓰레드 1이 그러고 있다고 가정해 봅시다. 비슷하게, 쓰레드 1 이 블락되기 위해서는 어떤 다른 쓰레드가 원소 2 의 락을 잡고 있어야 하는데, 이런식으로 쓰레드 $N - 1$ 까지 연속되는데, 이 쓰레드는 원소 $N - 1$ 의 락을 획득합니다. 쓰레드 $N - 1$ 이 블락되기 위해서는 어떤 다른 쓰레드가 원소 N 의 락을 잡고 있어야 합니다. 하지만 더이상 쓰레드가 존재하지 않고, 따라서 쓰레드 $N - 1$ 은 블락될 수가 없습니다. 따라서, 데드락은 일어나지 않습니다.

그러니 우리가 왜 이 마음에 드는 작은 알고리즘의 사용을 막아야 합니까?

여러분이 정말로 그걸 사용하고자 한다면, 우리는 여러분을 막을 수 없는게 사실입니다. 하지만, 우리는

³ 운영체제에 대한 많은 배경지식을 가지고 있는 여러분이라면, 이 말을 불신하는 걸 잠시 멈춰주세요. 이 말에 대한 불신을 잠시 멈추는게 불가능하다면, 우리에게 이보다 더 나은 예를 보내주세요.

우리가 신경쓰는 어떤 프로젝트에도 그런 코드가 들어오지 못하도록 추천할 수 있습니다.

하지만, 여러분이 이 알고리즘을 사용하기 전에, 다음의 Quick Quiz 를 한번 생각해 주시기 바랍니다.

Quick Quiz 16.1: 원소를 지울 때에도 비슷한 알고리즘을 사용할 수 있습니까? ■

이 알고리즘은 극도로 특수화 되어 있으며 (이 알고리즘은 특수한 크기의 리스트에 대해서만 동작합니다), 또한 상당히 취약한 게 사실입니다. 리스트에 노드를 하나 추가하는데 의도치 않게 실패하게 하는 어떤 버그든 데드락을 초래할 수 있습니다. 사실, 노드를 약간이라도 너무 늦게 추가하는 것만으로도 데드락을 초래할 수 있습니다.

또한, 앞에서 설명한 다른 알고리즘들이 “좋고 충분합니다”. 예를 들어, 단순히 락들을 주소 순서대로 잡는 것은 상당히 간단하고 빠르면서도 어떤 크기의 리스트든 사용할 수 있게 합니다. 다만 비어있는 리스트와 하나의 원소만을 포함하고 있는 리스트의 특수한 경우들에 대해서만 조심하세요!

Quick Quiz 16.2: 그러면 깎여져나갈 가치가 있는 알고리즘을 가지고 나타난 누군가를 포용해 본 적 있나요??? ■

정리하자면, 우린 그저 동작한다는 이유만으로 알고리즘을 사용하지는 않습니다. 그대신에 우리는 배울 가치가 충분한 알고리즘들만 사용하도록 우리 자신을 제한합니다. 더 어렵고 더 복잡한 알고리즘일수록, 그걸 배우고 그 버그를 고치는데 드는 고통이 가치가 있을 수 있도록 더 일반적으로 유용해야만 합니다.

Quick Quiz 16.3: 이 규칙에 대한 예외를 대 보세요. ■

예외는 차치하고, 우리는 우리의 프로그램들이 Figure 16.2 에 보여진 것처럼 유지가능한 상태를 유지할 수 있도록 소프트웨어를 깎아내기를 계속해야만 합니다.



Figure 16.2: Shaving the Mandelbrot Set

Prediction is very difficult, especially about the future.

Niels Bohr

Chapter 17

Conflicting Visions of the Future

이 챕터는 병렬 프로그래밍의 미래에 대한 일부 서로 다른 전망들을 소개합니다. 이 전망들 가운데 어느것이 현실이 될지, 사실 이것들 중 하나라도 현실이 될지는 명확치가 않습니다. 그러나 이것들은 각 전망을 좋아하는 지지자들이 있기 때문에 중요하며, 충분히 많은 사람들이 무언가를 열렬하게 믿는다면, 여러분은 그 지지자들의 생각, 말, 그리고 행위에서의 영향의 형태를 통한 그 존재함의 그림자만이라도 다루게 될 겁니다. 그와는 별개로, 이 전망들 중 두개 이상의 것들이 실제 현실이 될 수도 있습니다. 하지만 대부분은 가짜입니다. 뭐가 진짜고 뭐가 가짜일지 말할 수 있다면 여러분은 부자가 될겁니다 [Spi77]!

따라서, 뒤의 섹션들은 트랜잭션 메모리, 하드웨어 트랜잭션 메모리, 그리고 병렬 함수형 프로그래밍에 대한 개괄을 제공합니다. 하지만 먼저, 예언에 대한 경고적인 이야기를 2000년대 초로부터 가져와 봅니다.

17.1 The Future of CPU Technology Ain't What it Used to Be

많은 기간의 경험을 가진 렌즈를 통해 보면 과거는 항상 무척 간단하고 순수해 보입니다. 그리고 2000년대 초는 당시에는 전통적이었던, Moore's Law 가 CPU를 끌 주파수의 증가를 가져오던 현상이 깨지기 시작하는 시점에 임박한, 순수했던 시대였습니다. 아, 그때도 기술의 한계에 대한 경고가 때때로 있었습니다만 그런 경고들은 수십년째 이어져 오고 있었습니다. 이를 명심한 채로, 다음의 시나리오들을 고려해 봅시다:

1. 유니프로세서 Über Alles (역주: Über Alles 는 '모든 것보다 위대한'이라는 뜻의 독일어 관용구입니다.) (Figure 17.1),
2. 멀티쓰레드 매니아 (Figure 17.2),
3. 더 많은 같은것들 (Figure 17.3), 그리고




Figure 17.1: Uniprocessor Über Alles

4. 메모리 장벽에 부딪치는 것들 (Figure 17.4).

이 각각의 시나리오를 뒤따르는 섹션들에서 다릅니다.

17.1.1 Uniprocessor Über Alles

2004년에 이야기 되었던 것 [McK04] 처럼:

이 시나리오에서, CPU 를 끌 속도에 있어서의 Moore's-Law 의 증가와 수평적으로 확장되는 컴퓨팅의 계속된 발전의 조합은 SMP 시스템들을 무의미하게 만듭니다. 따라서 이 시나리오는 “Uniprocessor Über Alles”, 말 그대로 다른 모든것보다 나은 유니프로세서라고 불립니다.




Figure 17.2: Multithreaded Mania




Figure 17.3: More of the Same

이런 유니프로세서 시스템들은 인스트럭션 오버헤드만이 문제가 될텐데, 메모리 배리어, cache thrashing, 그리고 cache contention은 단일 CPU 시스템에서는 문제가 없기 때문입니다. 이 시나리오 상에서, RCU는 NMI들과의 상호작용과 같은 간단한 부분에서만 유용할 것입니다. 이미 RCU를 구현한 운영체제는 계속 RCU를 사용하면 되겠지만, RCU가 존재하지 않는 운영체제가 RCU를 적용해야 할지는 분명치 않습니다.

하지만, 최근의 멀티쓰레드 CPU의 발전은 이 시나리오가 이뤄질 가능성이 적을 것을 시사합니다.

실제로 그렇게 되진 않을 겁니다! 하지만 한 커다란 소프트웨어 커뮤니티는 그들이 병렬성을 포용해야 한다는 사실을 받아들이기를 꺼려했는데, 이는 이 커뮤니티가 Moore's-Law로 인한 CPU 코어 클럭 주파수 상승의 “공짜 점심”이 정말로 끝났다는 결론을 내리기 전이었습니다. 잊지 마세요: 믿음은 감정이므로, 이성적이고 기술적인 사고 과정의 결과가 아닐 수 있습니다!

17.1.2 Multithreaded Mania

역시 2004년의 이야기 [McK04]에서:

Uniprocessor Über Alles의 덜 극단적인 변종은 하드웨어 멀티쓰레딩을 제공하는 유니프로세서들로, 멀티쓰레딩 기능을 제공하는

CPU는 오늘날의 많은 데스크탑과 랩탑 컴퓨터 시스템에 표준이 되어있습니다. 멀티쓰레드 기능을 가장 적극적으로 제공하는 CPU들은 모든 레벨의 캐시 구조를 공유하고, 그로 인해 CPU에서 CPU로의 메모리 접근 응답시간을 없애버려, 전통적인 동기화 메커니즘에서의 성능 페널티를 거의 없애버립니다. 하지만, 멀티쓰레딩 기능을 제공하는 CPU는 메모리 배리어로 인해 발생하는 경쟁과 파이프라인 stall들로 인한 오버헤드로 여전히 부담을 겪을 겁니다. 더 나아가서, 모든 하드웨어 쓰레드가 모든 단계의 캐시를 공유하기 때문에, 특정 하드웨어 쓰레드에서 사용 가능한 캐시는 단일 쓰레드 CPU라면 가질 수 있는 캐시의 일부분만이 될 것이어서, 많은 캐시 사용량을 갖는 어플리케이션은 성능이 떨어질 수 있을 겁니다. 또한, 제한된 양의 캐시만이 사용 가능하다는 사실은 RCU 기반 알고리즘들이 RCU의 grace-period가 가져오는 추가적 메모리 소모로 인한 성능 하락을 겪게 할 가능성도 있습니다.

하지만, 그런 성능 저하를 막기 위해서, 많은 멀티쓰레드 CPU들과 multi-CPU 칩들이 하드웨어 쓰레드 별로 최소 일부 단계 캐시를 분할해 사용하게 하고 있습니다. 이는 각각의



Figure 17.4: Crash Dummies Slamming into the Memory Wall

하드웨어 쓰레드가 사용 가능한 캐시의 양은 증가시킵니다만, 하나의 하드웨어 쓰레드에서 다른 쓰레드로 전달되는 캐시라인을 위한 메모리 응답시간의 증가를 다시금 가져옵니다.

그리고 우리 모두 이 이야기가 하나의 소켓에 꽂혀진 하나의 다이 위의 멀티쓰레드 기능을 제공하는 여러개의 코어의 형태로 진행되었다는 걸 압니다. 이제 질문은 미래의 공유 메모리 시스템들은 하나의 소켓에 들어맞을 것인가 됩니다.

17.1.3 More of the Same

다시 한번 2004년의 이야기 [McK04]로부터:

More-of-the-Same 시나리오는 메모리 응답시간이 지금과 거의 같은 수준으로 머물 것이라는 가정 하에 세워집니다.

이 시나리오는 실제로는 변화를 의미하는데, 더 많은 같은 것들을 가지려면 접합부의 성능이 접합부의 성능이 Moore's-Law로 인한 CPU 코어 성능의 향상과 함께 유지되어야만 하기 때문입니다. 이 시나리오에서, 파이프라인 stall, 메모리 응답시간, 그리고 경쟁으로 인한 오버헤드는 여전히 심각한 수준으로 남아있고, RCU는 오늘날 그런 것처럼 높은 수준의 응용력을 유지하게 됩니다.

그리고 그 변화는 Moore's Law 가 여전히 제공하고 있는대로, 높아지는 수준의 집적도입니다. 하지만 더




Figure 17.5: Instructions per Local Memory Reference for Sequent Computers

긴 시간의 관점에서 본다면, 무엇이 될까요? 더 많은 디이당 CPU의 갯수? 아니면 더 많은 I/O, 캐시, 그리고 메모리?

서버들은 앞의 것들을 선택한 것 같고, 하나의 칩 위에 올라가는 임베디드 시스템들 (SoCs)은 뒤의 것을 계속 선택해 갈 것 같습니다.

17.1.4 Crash Dummies Slamming into the Memory Wall

그리고 2004년의 이야기 [McK04]로부터 하나 더 인용 해서:

Figure 17.5에 보인 메모리 응답시간 트렌드가 계속된다면, 메모리 응답시간은 인스트럭션 수행 오버헤드에 비해 커지기를 계속할 것입니다. RCU를 많이 사용하는 리눅스와 같은 시스템들은 RCU의 추가적인 사용이 Figure 17.6에 보인 것처럼 더 이득이 될 것을 알게 될겁니다. 이 그림에서 볼 수 있는 것처럼, RCU가 많이 사용된다면, 증가되는 메모리 응답시간은 RCU에게 다른 동기화 메커니즘 대비 더 나은 이득을 주게 될겁니다. 반면에, RCU를 적게 사용하는 시스템들은 Figure 17.7에 보인 것처럼 더 많은 읽기 비율을 필요로하게 될겁니다. 이 그림에서 볼 수 있듯이, RCU가 적게 사용된다면, 증가되는 메모리 응답시간 비율은 RCU를 다른 동기화 메커니즘들 대비 단점이 많아지게 합니다. 리눅스는 높은




Figure 17.6: Breakevens vs. r , λ Large, Four CPUs




Figure 17.7: Breakevens vs. r , λ Small, Four CPUs

부하 아래에서 grace period 당 1,600 개가 넘는 콜백들을 보았기 때문에, 리눅스는 앞의 카테고리에 속한다고 말하기 충분할 것 같습니다.

한편, 이 구절은 RCU 가 상당한 업데이트 위주의 워크로드에서 겪을 수 있는 cache warmth 문제를 설명하지 못하는데, 한편으로는 그런 워크로드에서 RCU 가 사용되지는 않을 것이기 때문입니다. 결과적으로, 이런 cache-warmth 문제가 문제로 되는 경우에는 시퀀스 락킹이 그렇듯이 SLAB_DESTROY_BY_RCU 가 사용되도록 되었습니다. 한편으로는, 이 구절은 또한 RCU 가 스케줄링 응답시간을 줄이거나 보안 기능을 위해 사용

되지는 못할 것인 점을 설명하지도 않습니다.

짧게 말해서, 이 챕터의 뒷부분에서 설명하는 것들을 포함해 전조들에 주의하시기 바랍니다.

17.2 Transactional Memory

데이터베이스 바깥의 영역에서 트랜잭션을 사용하자는 아이디어는 수십년 전으로 거슬러 오르는데 [Lom77], 이 아이디어는 데이터베이스에서와 데이터베이스 외에서의 트랜잭션에 대해 데이터베이스 외에서의 트랜잭션은 데이터베이스 트랜잭션을 정의하는 성질인 “ACID”에서 “D”를 빼냅니다. 하드웨어에서 메모리 기반의 트랜잭션, 또는 “트랜잭션 메모리” (TM) 을 지원하려는 아이디어는 최근의 것입니다만 [HM93], 안타깝게도 실제 많이 사용되는 하드웨어에서의 그런 트랜잭션의 지원은 그와 비슷한 것들에 대한 제안은 계속 있어왔지만 [SSHT93], 곧바로 이루어지지는 않았습니다. 그로부터 그렇게 오래지 않아, Shavit 과 Touitou 는 일반적으로 사용되는 하드웨어에서 동작할 수 있는, 메모리 접근 순서를 조정해서 소프트웨어만으로 이루어진 트랜잭션 메모리 구현 (STM) 을 제안했습니다 [ST95]. 이 제안은 여러 해동안 질질 끌려졌는데, 어쩌면 연구자 커뮤니티들의 관심은 non-blocking 동기화 (Section 14.2 을 참고하세요) 에 열중되었기 때문일 수도 있습니다.

하지만 세기가 변하면서, TM 은 일부 주의의 목소리를 받기 시작했고 [BLM05, MMW07], 2000년부터 2009년 사이의 중반쯤에는 몇 가지 경고의 목소리에도 불구하고 [Her05, Gro07], 그 관심의 수준이 “열광적”이라 할 수 있게 되었습니다.

TM에 대한 기본 아이디어는 한 셱션의 코드를 자동으로 수행해서 다른 쓰레드가 그 중간의 상태를 볼 수 없게 하자는 것입니다. 그렇게, TM의 의미는 간단히 각각의 트랜잭션을 반복적으로 획득할 수 있는 글로벌 렉의 획득과 해제로 감싸는 것으로, 성능과 확장성이 치참해지길 하겠지만, 구현될 수 있습니다. 하드웨어에서든 소프트웨어에서든 TM 구현에서는 피할 수 없는 복잡성은 동시적인 트랜잭션들이 안전하게 병렬적으로 수행될 수 있는지에 대한 파악입니다. 이 파악은 동적으로 이루어지기 때문에, 충돌하는 트랜잭션들은 취소되거나 “롤백”될 수 있고, 일부 구현에서는, 이 실패한 모드가 프로그래머에게 보여질 수 있습니다.

트랜잭션 롤백은 트랜잭션 크기가 줄어들에 따라 발생률이 줄어들 것이기 때문에, TM은 스택, 큐, 해시 테이블, 탐색 트리들과 같은 데에 사용되는 링크드 리스트 제어와 같이 작은 크기의 메모리 기반 오퍼레이션들에 매력적일 수 있습니다. 하지만, I/O 와 프로세스 생성과 같은 메모리 기반이 아닌 오퍼레이션들을 포함하는 것들과 같은, 커다란 트랜잭션들에 TM을 적용하기는 어렵습니다. 다음 셱션들은 “Transactional Memory Ev-

everywhere” [McK09d] 의 커다란 비전을 위해 존재하는 현재의 극복해야 할 사항들을 알아봅니다. Section 17.2.1 은 바깥의 것들과 상호동작하는 데에 나타나는 문제점을 알아보고, Section 17.2.2 는 프로세스 수정 기능들과의 상호동작을 보며, Section 17.2.3 는 다른 동기화 기능들과의 상호 동작들을 살펴보며, 마지막으로 Section 17.2.4 에서 일부 토의와 함께 마무리 합니다.

17.2.1 Outside World

Donald Knuth 의 말을 인용하면:

많은 컴퓨터 사용자들이 입력과 출력은 “진짜 프로그래밍”의 실제 부분은 아니고, 그것들은 그저 기계로 정보를 넣고 그로부터 정보를 뽑아내기 위해 (불행히도) 반드시 해야만 하는 것들이라고 느낍니다.

우리가 입력과 출력이 “진짜 프로그래밍”이라 믿든 아니라 믿든, 대부분의 컴퓨터 시스템들에 있어서, 바깥 세상과의 상호작용이 첫번째 중요도의 요구사항임은 사실입니다. 따라서 이 섹션은 트랜잭션의, I/O 오퍼레이션을 통해서든, 시간 딜레이를 통해서든, 또는 영구적 저장장치를 이용해서든 이루어지는, 상호작용을 위한 기능들에 대해 비평해 봅니다.

17.2.1.1 I/O Operations

누군가는 I/O 오퍼레이션을 락 기반의 크리티컬 섹션 안에서 할 수도, 적어도 원칙적으로는, userspace-RCU read-side 크리티컬 섹션 안에서 할 수도 있습니다. 트랜잭션 안에서 I/O 오퍼레이션을 수행하려 하면 어떻게 될까요?

여기 내포된 문제는 트랜잭션은 롤백될 수 있는데, 예를 들어 *conflict* 이거나 하는 경우입니다. 대략적으로 말해서, 이는 특정 트랜잭션 내에서 일어날 수 있는 모든 오퍼레이션들이 복구될 수 있어서 해당 오퍼레이션을 두번 행하는 것은 한번만 행한 것과 똑같은 효과를 내야 할 것을 필요로 합니다. 안타깝게도, I/O 는 일반적으로는 근본적으로 돌이킬 수 없는 오퍼레이션이어서, 일반적인 I/O 오퍼레이션을 트랜잭션 내에 넣기는 어렵게 합니다. 사실, 일반적인 I/O 는 돌이킬 수 없습니다: 일단 여러분이 핵탄두를 발사시키는 버튼을 눌렀다면, 되돌릴 수는 없습니다.

여기 트랜잭션 안에서 I/O 를 다루기 위한 몇 가지 선택사항들이 있습니다:

1. 트랜잭션 내에서의 I/O 를 메모리 상의 버퍼에 버퍼링 되는 I/O 로 제약시킵니다. 이렇게 되면 이 버퍼들은 다른 메모리 위치들이 포함될 수 있는 것과 같은 방식으로 트랜잭션 내에 포함되어질 수

있을 겁니다. 이는 선택될 수 있는 메커니즘으로 보이며, 이는 실제로 stream I/O 나 대용량 I/O 와 같은, 많은 혼란 상황들에서 잘 동작합니다. 하지만, 복수의 레코드에 기반한 출력 스트림들이 복수의 프로세스들로부터 하나의 파일에 합쳐지는, 예컨대 “a+” 옵션과 함께 사용된 *fclose()* 이나 *O_APPEND* 플래그와 함께 사용된 *open()* 과 같은 경우에는 특수한 처리가 필요합니다. 또한, 다음 섹션에서 보게 되겠지만, 일반적인 네트워킹 오퍼레이션들은 버퍼링을 통해 처리될 수 없습니다.

2. 트랜잭션 안에서의 I/O 를 금지시켜서 I/O 오퍼레이션을 행하려는 모든 시도는 그를 둘러싼 트랜잭션을 *abort* 시키게 만듭니다(그리고 복수의 중첩된 트랜잭션들까지도요). 이 방법은 버퍼링 되지 않은 I/O 를 위한 관습적인 TM 전략처럼 보이지만, TM 이 I/O 를 허용할 수 있는 다른 동기화 기능들을 포함할 것을 필요로 합니다.
3. 트랜잭션 안에서의 I/O 를 금지시키지만, 이 금지를 강제시키는데에 컴파일러의 협조를 받습니다.
4. 한번에 단 하나의 되돌려질 수 있는 트랜잭션 [SMS08] 만이 수행될 수 있게 허가해서, 되돌려질 수 있는 트랜잭션들은 I/O 오퍼레이션을 포함할 수 있도록 허가합니다.¹ 이는 일반적으로 동작합니다만, I/O 오퍼레이션들의 성능과 확장성을 상당히 제한합니다. 확장성과 성능이 병렬화의 첫 번째 목표라는 점을 놓고 보면, 이 방법의 일반성은 약간 스스로를 제한시키는 것으로 보입니다. 더 나쁜 것은, 되돌릴 수 있는 성질을 I/O 오퍼레이션을 막는데에 사용하는 것은 직접적인 트랜잭션 *abort* 오퍼레이션의 사용을 금지하는 것으로 보입니다.² 마지막으로, 특정 데이터 아이템을 조정하는 도돌려질 수 있는 트랜잭션이 존재한다면, 똑같은 데이터 아이템을 조정하는 다른 모든 트랜잭션들은 non-blocking semantic 을 가질 수가 없습니다.
5. I/O 오퍼레이션들이 트랜잭션의 하층에 들어가질 수 있는 새로운 하드웨어와 프로토콜을 만듭니다. 인풋 오퍼레이션의 경우, 하드웨어는 그 오퍼레이션의 결과를 올바르게 예측할 수 있어야 할 것이고, 그 예측이 틀렸을 경우에는 그 트랜잭션을 *abort* 시킬 수 있어야 할 겁니다.

I/O 오퍼레이션은 TM 의 잘 알려진 약한 부분들이고, 트랜잭션에서 I/O 를 지원하기 위한 이 문제가 합리적이고 일반적인 해결책을 가지고 있는지는 확실치 않은데,

¹ 이전의 문헌에서, 되돌려질 수 있는 트랜잭션들은 *inevitable* 트랜잭션이라 칭해졌습니다.

² 이 문제는 Michael Factor 에 의해 지적되었습니다.

적어도 “합리적” 이란 말이 사용 가능한 성능과 확장성을 포함한다면 그렇습니다. 더도 아니고 덜도 아니고, 이 문제에 대한 계속된 시간과 관심이 이 문제에 대한 추가적인 진보를 만들어낼 겁니다.

17.2.1.2 RPC Operations

누군가는 RPC 들을 락 기반의 크리티컬 섹션에서도, userspace-RCU read-side 크리티컬 섹션 내에서도 수행할 수 있습니다. 여러분이 RPC 를 트랜잭션 내에서 수행하려 하면 어떻게 될까요?

RPC 요청과 그에 대한 응답이 해당 트랜잭션 내에 포함된다면, 그리고 트랜잭션의 일부 부분이 그 응답으로 리턴되는 결과에 의존적이라면, 베퍼링을 사용하는 I/O 의 경우에 사용되었던 메모리 베퍼를 사용한 트릭은 사용할 수 없습니다. 이런 베퍼링 전략을 사용하려는 모든 시도는 트랜잭션을 deadlock 에 바지게 할 것인데, 요청은 그 트랜잭션이 성공할 것이라 보장되기 전까지는 보내질 수가 없지만, 트랜잭션의 성공 여부는 응답이 도착하기 전까지는 알 수 없을 것이기 때문에, 다음과 같은 경우가 그 예가 됩니다:

```

1 begin_trans();
2 rpc_request();
3 i = rpc_response();
4 a[i]++;
5 end_trans();

```

이 트랜잭션의 메모리 사용량은 RPC 응답이 도착하기 전까지는 결정될 수 없고, 이 트랜잭션의 메모리 사용량이 결정되기 전까지는, 이 트랜잭션이 커밋되어도 되는지 여부를 결정할 수가 없습니다. 따라서 트랜잭션의 의미론에 있어 일관적인 유일한 동작은 무조건적으로 이 트랜잭션을 abort 시키는 것으로, 이 말은, 곧 도움이 되지 않는다는 말입니다.

여기 TM 에서 사용할 수 있는 몇가지 선택들이 있습니다:

1. 트랜잭션 내에서의 RPC 를 금지시켜서, RPC 오퍼레이션을 수행하려 하는 모든 시도는 그를 둘러싼 트랜잭션을 (그리고 아마도 복수개의 중첩된 트랜잭션들도) abort 시키도록 합니다. 대안적으로, 컴파일러가 RPC 없는 트랜잭션들을 강제하도록 도움을 줄 수 있게 합니다. 이 방법은 동작합니다만, TM 이 다른 동기화 도구들과 상호작용할 것을 필요로 합니다.
2. 한번에 하나의 되돌려질 수 있는 특수한 트랜잭션 [SMS08] 만을 허용해서, 이 되돌려질 수 있는 트랜잭션은 RPC 오퍼레이션을 포함할 수 있도록 합니다. 이 방법은 일반적으로 동작합니다만, RPC 오퍼레이션들의 확장성과 성능을 상당히 제한하게

됩니다. 확장성과 성능이 병렬화의 첫번째 목표임을 상기해보면, 이 방법의 일반성은 약간 제한적인 것으로 보입니다. 더 나아가서, RPC 오퍼레이션을 받아들일 수 있는, 되돌려질 수 있는 트랜잭션들의 사용은 일단 RPC 오퍼레이션이 시작되면 손으로 작성된 트랜잭션 abort 오퍼레이션들을 배제시킵니다. 마지막으로, 특정 데이터 아이템을 조정하는 되돌려질 수 있는 트랜잭션이 존재한다면, 같은 데이터 아이템을 조정하는 모든 다른 트랜잭션들은 non-blocking semantic 을 가질 수 없습니다.

3. 트랜잭션의 성공이 RPC 응답이 도착하기 전에 결정될 수 있는 특수한 경우를 정의하고, RPC 요청이 보내지기 직전에 이것들을 자동적으로 되돌려질 수 있는 트랜잭션들로 변환시킵니다. 물론, 만약 여러 동시적 트랜잭션들이 이 방식으로 RPC 호출을 시도한다면, 이것들 중 하나만을 제외하고는 모두 롤백시켜야 할 것으로, 결과적으로 성능과 확장성이 떨어질 겁니다. 이 방법은 더도 아니고 덜도 아니고, RPC 로 마무리되는, 오랫동안 수행되는 트랜잭션들이 있을 때에는 가치가 있을 겁니다. 이 방법은 여전히 손으로 직접 하는 트랜잭션 abort 오퍼레이션들과의 문제가 존재합니다.
4. RPC 응답이 트랜잭션의 바깥으로 옮겨질 수 있는 특수한 경우들을 정의하고, 베퍼링을 사용한 I/O 에서 사용된 것과 비슷한 기법을 사용합니다.
5. 트랜잭션적인 구조가 RPC 클라이언트만이 아니라 서버도 포함하도록 확장합니다. 이건 이론적으로는 가능하며, 분산 데이터베이스들을 통해 보여졌습니다. 하지만, 분산 데이터베이스 기법을 통해 요구되는 성능과 확장성 요구사항들이 맞춰질 수 있을지는 불명확한데, 메모리 기반의 TM 은 느린 디스크 드라이브에서 나오는 느린 응답시간을 감출 수 없을 것이기 때문입니다. 물론, 솔리드 스테이트 디스크 (SSD) 의 발전과 함께, 데이터 베이스들이 그 자신의 응답시간들을 디스크 드라이브의 응답시간들에 숨겨둘 수 있을지도 불명확해지고 있습니다.

앞의 섹션에서 이야기 된 것처럼, I/O 는 TM 의 알려진 약점이고, RPC 는 그저 I/O 의 특별히 문제가 되는 경우일 뿐입니다.

17.2.1.3 Time Delays

트랜잭션 턱한 접근과의 상호작용에 관련된 중요한 특수 케이스 하나는 트랜잭션 내에서의 명시적인 시간 딜레이와 관련됩니다. 물론, 트랜잭션 내에서의 시간 딜레이이라는 이 생각은 TM 의 원자성에 위배됩니다만, 어떤

사람들은 이런 종류의 일은 완화된 원자성이 모두 그려한 것이라고 주장할 수 있습니다. 나아가서, memory-mapped I/O와의 올바른 상호작용은 가끔 주의 깊게 제어되는 타이밍을 필요로 하며, 어플리케이션들은 다양한 목적을 위해 시간 딜레이를 자주 사용합니다.

그러니, TM은 트랜잭션 내에서의 시간 딜레이에 대해 뭘 해야 할까요?

1. 트랜잭션 내에서의 시간 딜레이를 무시합니다. 이 방법은 우아한 모습으로 보이지만, 다른 너무 많은 “우아한” 해결책들처럼, 기존 코드에 사용되는 순간 실패하게 됩니다. 크리티컬 섹션 내에서 중요한 시간 딜레이를 가지고 있을 수도 있는 그런 코드는 트랜잭션화 되는 과정에서 실패할 겁니다.
2. 시간 딜레이 오퍼레이션을 마주하는 순간 트랜잭션을 `abort` 시킵니다. 이 방법은 매력적이지만, 안타깝게도 시간 딜레이 오퍼레이션을 자동적으로 탐지하는게 항상 가능하지는 않습니다. 어떤 짧은 루프는 정말 중요한 무언가를 계산하는 루프일까요, 아니면 그저 시간이 지나가길 기다리는 걸까요?
3. 트랜잭션 내에서의 시간 딜레이를 금지시키기 위해 컴파일러의 도움을 받습니다.
4. 시간 딜레이가 평범하게 수행되도록 합니다. 안타깝게도, 일부 TM 구현은 커밋 시점에서야 수정사항을 외부에 노출시켜서, 많은 경우에는 시간 딜레이의 목적을 달성 불가능하게 할겁니다.

단 하나의 올바른 답이 있는지 여부는 분명치 않습니다. 완화된 원자성을 갖춰서 변경 사항을 트랜잭션 내에서 곧바로 외부에 노출시키는 (`abort` 시에는 이 변경들을 되돌리는) TM 구현은 마지막 대안에 의해 잘 처리될 수 있을 겁니다. 이런 경우라 하더라도, 트랜잭션의 다른 끝의 (또는, 심지어 하드웨어의) 코드는 `abort`된 트랜잭션을 처리하기 위해 상당한 재설계가 필요할 겁니다. 이런 재설계의 필요성은 트랜잭션 메모리를 기존 코드에 적용하기를 더 어렵게 할겁니다.

17.2.1.4 Persistence

락킹 기능들에는 많은 다른 타입들이 존재합니다. 한 가지 흥미로운 차이는 지속성으로, 달리 말하자면, 락이 그 락을 사용하는 프로세스의 주소 공간에 대한 의존성이 없이 존재할 수 있는가 여부입니다.

지속성 없는 락은 `pthread_mutex_lock()`, `pthread_rwlock_rdlock()`, 그리고 대부분의 커널 레벨 락킹 기능들을 포함합니다. 만약 지속성 없는 락의 데이터 구조를 담고 있는 메모리 위치가 사라지면, 락 역시 그렇게 됩니다. `pthread_mutex_lock()`의 일반적인 사용에 있어, 이는 프로세스가 종료될 때, 그것의

모든 락들이 사라짐을 의미합니다. 이 속성은 프로그램 종료 시점에 락 정리를 대수롭지 않게 하기 위해 사용될 수도 있습니다만, 관계없는 어플리케이션들 사이에서 락을 공유하기는, 그런 공유를 위해선 어플리케이션 사이에 메모리를 공유할 것을 필요로 하기에, 어렵게 합니다.

지속성 있는 락들은 관련없는 어플리케이션들 사이에 메모리를 공유해야 할 필요를 없앱니다. 지속성 있는 락킹 API들은 `flock` 계열인 `lockf()`, System V 세마포어, `open()`에 사용되는 `O_CREAT` 플래그 등을 포함합니다. 이 지속성 있는 API들은 다양한 어플리케이션들을 구축하는 커다란 규모의 오퍼레이션들을 보호하는데에 사용될 수 있고, `O_CREAT`의 경우에는 심지어 운영체제 리부팅 뒤에도 살아남습니다. 필요하다면, 락들은 분산된 락 매니저와 분산 파일 시스템들을 통해서 여러 컴퓨터 시스템들에까지 미칠 수 있습니다—그리고 이 컴퓨터 시스템들의 어떤 모든 것들의 리부팅 전후에도 지속됩니다.

지속성 있는 락들은 어떤 어플리케이션을 통해서도 사용될 수 있는데, 복수의 언어와 소프트웨어 환경을 사용해 작성된 어플리케이션도 포함됩니다. 사실, 하나의 지속성 있는 락이 C 언어로 쓰여진 어플리케이션에 의해 획득되고는 Python으로 쓰여진 어플리케이션에 의해 해제될 수도 있는 것입니다.

TM에는 이와 비슷한 지속성 있는 기능들이 어떻게 주어질 수 있을까요?

1. 지속성 있는 트랜잭션들을 그것들을 지원하기 위해 설계된, SQL과 같은 특수 목적 환경으로 제한 시킵니다. 이는 데이터베이스 시스템의 수십년의 역사를 보건대 분명히 잘 동작합니다만, 지속성 있는 락들에 의해 제공되는 것만큼의 유연성을 제공하지는 않습니다.
2. 일부 저장 장치나 파일시스템들에서 제공되는 스냅샷 기능들을 사용합니다. 안타깝게도, 이는 네트워크 통신을 처리하지도, 스냅샷 기능을 제공하지 않는, 예를 들어 메모리 스택과 같은 장치로의 I/O는 처리하지도 못합니다.
3. 타임머신을 만듭니다.

물론, 이것이 트랜잭션 메모리라 불린다는 사실이 한숨을 돌리게 할텐데, 이 이름 자체가 지속성 있는 트랜잭션의 컨셉과 들어맞지 않기 때문입니다. 이는 가능성을 트랜잭션 메모리의 피할 수 없는 한계점을 보이는 중요한 테스트 케이스로 고려할 만큼, 딱 그만큼의 가치만 있습니다.

17.2.2 Process Modification

프로세스들은 영원하지 않습니다: 프로세스들은 생성되고 소멸되며, 메모리 매핑은 수정되고, 동적 라이브러리들과 링크되고, 디버깅 됩니다. 이 세션들은 어떻게 트랜잭션을 메모리가 항상 변화되는 실행 환경을 처리할 수 있는지 알아봅니다.

17.2.2.1 Multithreaded Transactions

락을 친채, 또는, 필요하다면 userspace-RCU read-side 크리티컬 섹션 내에서 프로세스나 쓰레드를 생성하는 것은 완전히 합법적인 일입니다. 이건 합법적일 뿐만 아니라, 다음 코드 조각에서 볼 수 있듯이 상당히 간단하기도 합니다.

```

1 pthread_mutex_lock(...);
2 for (i = 0; i < ncpus; i++)
3   pthread_create(&tid[i], ...);
4 for (i = 0; i < ncpus; i++)
5   pthread_join(tid[i], ...);
6 pthread_mutex_unlock(...);

```

이 슈도코드는 CPU 당 하나의 쓰레드를 생성하기 위해 `pthread_create()`를 사용하고, 각각의 쓰레드가 완료되기를 기다리기 위해 `pthread_join()`을 사용하는데, 모두 `pthread_mutex_lock()`의 보호 아래에서 행해집니다. 원하는 결과는 락 기반의 크리티컬 섹션을 병렬적으로 수행하는 것이고, `fork()` 와 `wait()`를 사용해서도 비슷한 효과를 얻을 수 있을 겁니다. 물론, 이 크리티컬 섹션은 쓰레드 생성 오버헤드를 정당화하기 충분할 만큼 커야 할 것입니다만, 제품 소프트웨어에서 커다란 크리티컬 섹션들의 예는 많이 존재합니다.

TM은 트랜잭션 내에서의 쓰레드 생성에 대해서 무엇을 해줄까요?

1. 트랜잭션 내에서의 `pthread_create()`를 불법적인 것으로 규정해서, `pthread_create()` 사용의 경우 트랜잭션이 `abort` 되거나 (이게 선호됩니다) 정해지지 않은 동작을 하도록 만듭니다. 대안적으로는, 컴파일러가 `pthread_create()` 가 없는 트랜잭션만을 강제하도록 도움을 받습니다.
2. 트랜잭션 내에서 `pthread_create()` 가 수행될 수 있도록 하되, 그 부모 쓰레드만이 트랜잭션의 일부로 여겨지도록 합니다. 이 방법은 이미 존재하는 TM 구현들과 합리적으로 호환될 수 있을 것처럼 보입니다만, 부주의한 사람에게는 함정이 될 것으로 보입니다. 이 방법은 몇 가지 더 질문을 떠오르게 하는데, 자식 쓰레드로의 접근의 충돌을 어떻게 처리할 것인가와 같은 것들입니다.

3. `pthread_create()` 를 함수 호출로 변환시킵니다. 이 방법 역시 매력적인 골칫거리가 되는데, 자식 쓰레드들이 서로 통신하는 드물지 않은 경우들을 처리하지 않기 때문입니다. 이 방법은 또한 부모 쓰레드가 트랜잭션을 커밋하기 전에 자식 쓰레드들을 기다리지 않는다면 어떤 일이 일어나게 될것인지와 같은 흥미로운 질문 역시 물려일으킵니다. 더 흥미롭게도, 부모가 트랜잭션 내에 포함되어 있는 변수의 값에 기초해서 조건적으로 `pthread_join()` 을 수행한다면 무슨 일이 일어날까요? 이 질문들에 대한 답은 락킹의 경우에는 꽤 간단합니다. TM에서의 이 질문들에 대한 답은 독자 여러분의 몫으로 남겨두겠습니다.

데이터베이스 쪽에서 트랜잭션들의 병렬적 수행은 일반적이기 때문에, 현재의 TM 제안들은 그것들을 위해 제공되며 아니란 점은 놀라울 수도 있습니다. 한편으로는, 앞의 예제들은 간단한 교재에서의 예제에서는 일반적으로 찾을 수 없는, 락킹의 복잡한 사용 예여서, 그것들의 부작위함이 예상될 수도 있습니다. 그렇다면 하나, 일부 TM 연구자들이 트랜잭션 내에서의 `fork/join` 병렬성을 위해 노력하고 있다는 소문이 돌리고 있으므로, 이 주제는 조만간 더 완벽하게 다루어질 수도 있습니다.

17.2.2.2 The `exec()` System Call

락을 잡은채로, 또는 RCU read-side 크리티컬 섹션 내에서도 `exec()` 시스템 콜을 호출할 수 있습니다. 그 호출의 정확한 의미는 기능의 타입에 따라 정해집니다.

지속성 없는 기능들 (`pthread_mutex_lock()`, `pthread_rwlock_rdlock()`, 그리고 userspace-RCU 등)의 경우에는, `exec()` 가 성공한다면, 모든 잡혀 있던 락들을 포함해서 전체주소 공간이 사라집니다. 물론, `exec()` 가 실패한다면, 이 주소 공간은 여전히 살아있게 되어서, 모든 연관된 락들 역시 여전히 살아 있게 됩니다. 약간 이상할 수 있겠지만, 합리적으로 잘 정의된 의미입니다.

다른 한편, 지속성이 있는 기능들 (`flock` 부류들, `lockf()`, System V 세마포어, `O_CREAT` 플래그와 함께 수행되는 `open()` 등)은 `exec()` 의 성공이나 실패 여부와 관계 없이 살아남아서, `exec()` 된 프로그램은 그것들을 놓아줘야 할 겁니다.

Quick Quiz 17.1: 메모리의 `mmap()` 리전 내의 데이터 구조체로 표현되는 지속성 없는 기능들은 어떤까요? 그런 기능들로 만들어진 크리티컬 섹션 내에서의 `exec()` 가 존재한다면 어떤 일이 벌어질까요? ■

트랜잭션 안에서 `exec()` 시스템 콜을 수행하려 한다면 어떤 일이 벌어질까요?

1. 트랜잭션 내에서의 `exec()` 를 금지시켜서, `exec()` 가 호출되면 그를 둘렀나 트랜잭션들이 `abort` 되게 합니다. 이는 괜찮은 정의입니다만, TM 외의 동기화 기능들이 `exec()` 와의 관계 안에서도 잘 동작할 수 있을 것을 필요로 합니다.
2. 트랜잭션 내에서의 `exec()` 를 금지시키며, 컴파일러가 이 금지를 강제하도록 합니다. 이 방법을 취해서, 함수들이 `transaction_safe` 와 `transaction_unsafe` attribute 로 장식되도록 하는, C++ 에서의 TM 에 대한 작성중인 명세가 있습니다.³ 이 방법은 실행시간 중에 트랜잭션을 `abort` 하는 것에 비해 몇가지 장점이 있습니다만, 역시 `exec()` 와 관련해서 사용되어야 하는 TM 이 아닌 동기화 기능들을 필요로 합니다.
3. 트랜잭션을 지속성 없는 락킹 기능들과 비슷한 방식을 취급해서, `exec()` 가 실패한다면 트랜잭션이 성공하고, `exec()` 가 성공하면 말없이 트랜잭션을 커밋해 버립니다. 일부 변수들이 `mmap()` 으로 매핑된 메모리에 존재하는 경우에 대해서는 (따라서 성공적인 `exec()` 시스템 콜 뒤에는 살아남는 변수들) 독자 여러분의 뜻으로 남겨두겠습니다.
4. `exec()` 시스템 콜이 성공할 것 같다면 트랜잭션을 (그리고 `exec()` 시스템 콜을) `abort` 시키고, `exec()` 시스템 콜이 실패할 것 같다면 트랜잭션을 지속시킵니다. 이는 어떤 의미에서는 “올바른” 방법입니다만, 성이 차지 않는 결과를 위해서는 상당한 작업을 필요로 할 겁니다.

아마도 `exec()` 시스템 콜은 보편적인 TM 적용성에 대한 가장 이상한 반론의 예 중 하나일 텐데, 어떤 방법이 말이 되는지가 전혀 명시치 않고, 누구가는 이건 그저 실제 삶에서 중역들과 일하는 위험의 반영일 뿐이라고 주장할 수도 있을 겁니다. 그렇다고 하나, 트랜잭션 내에서의 `exec()` 를 금지시키는 두가지 방법은 그나마 가장 논리적일 겁니다.

비슷한 문제들이 `exit()` 과 `kill()` 시스템 콜, `longjmp()` 나 트랜잭션 밖으로 빠져나갈 수 있는 `exception` 들에 대해서도 존재합니다. (`longjmp()` 나 `exception` 은 어디서 올까요?)

17.2.2.3 Dynamic Linking and Loading

락 기반의 크리티컬 섹션과 userspace-RCU read-side 크리티컬 섹션 모두 C/C++ 공유 라이브러리나 Java 클래스 라이브러리와 같은, 동적으로 링크되고 로드되는 함수들을 수행시키는 코드를 합법적으로 담고 있을 수

³ 이 명세서를 짚어준 Mark Moir 와, 그보다 앞의 버전을 알려준 Michael Wong 에게 감사를 드립니다.

있습니다. 물론, 이 라이브러리에 들어있는 코드에 대해서는 그 정의에 따라, 컴파일 타임에는 알 수 없습니다. 그러나, 동적으로 로드된 함수가 트랜잭션 안에서 수행된다면 어떤 일이 벌어질까요?

이 질문은 두개의 부분으로 구성됩니다: (1) 트랜잭션 안에서 어떻게 함수를 동적으로 링크하고 로드하는지와 (b) 이 함수 안의 알 수 없는 코드에 대해서 무엇을 해야 할까요? 공정해지기 위해, 항목 (b)는 적어도 이론상으로는 락킹과 userspace-RCU 모두에게 일부 도전적 과제를 갖게 합니다. 예를 들어서, 동적으로 링크된 함수는 락킹에 있어 데드락을 가져올 수도 있고 (에러에 의해) userspace-RCU read-side 크리티컬 섹션 안에 `quiescent state` 를 가져올 수도 있습니다. 차이점은, 락킹과 RCU 크리티컬 섹션 안에서 허용되는 오퍼레이션들의 클래스는 여전히 잘 이해되어 있지만, TM 의 경우에 대해서는 상당한 불확실성이 존재한다는 점입니다. 사실, 서로 다른 구현의 TM 은 서로 다른 제한을 갖게 될 것으로 보입니다.

그러니 동적으로 링크되고 로드되는 라이브러리 함수에 대해서 TM 은 무엇을 해야 할까요? 실제 코드를 로드하는 (a) 부분의 선택사항은 다음과 같은 것들을 포함합니다:

1. 동적 링킹과 로딩을 페이지 폴트와 비슷한 형태로 취급해서, 함수가 로드되고 링크되면 해당 프로세스의 트랜잭션을 `abort` 시킵니다. 만약 그 트랜잭션이 `abort` 되면, 재시도는 그 함수가 이미 존재함을 보게 될거고, 해당 트랜잭션은 이제 정상적으로 진행될 것으로 예상될 수 있습니다.
2. 트랜잭션 안에서의 함수의 동적 링킹과 로딩을 금지시킵니다.

아직 로드되지 않은 함수 안에서의 TM 에 친화적이지 않은 오퍼레이션들을 파악해낼 수 없는 특성에 대한 (b) 부분에 대한 선택 사항은 다음과 같은 것들이 있을 수 있습니다:

1. 그냥 코드를 수행합니다: 해당 함수 안에 TM 에 친화적이지 않은 오퍼레이션들이 존재한다면, 그냥 트랜잭션을 `abort` 시킵니다. 불행히도, 이 방법은 컴파일러가 특정 트랜잭션들이 안전하게 구성되어 있는지 여부를 알 수 없게 합니다. 그에 상관없이 조합이 가능하게 할 수 있는 방법 한가지는 되돌이킬 수 있는 트랜잭션의 사용입니다만, 현재의 구현들은 한번에 하나의 되돌이킬 수 있는 트랜잭션의 수행만을 허용해서, 성능과 확장성을 상당히 떨어뜨릴 수 있습니다. 되돌이킬 수 있는 트랜잭션들은 직접적인 트랜잭션 `abort` 오퍼레이션의 사용을 제외시킬 것으로 보여집니다. 마지막으로, 특정

- 데이터 아이템을 조정하는 되돌이킬 수 있는 트랜잭션이 하나 존재한다면, 똑같은 데이터 아이템을 조정하는 모든 다른 트랜잭션은 non-blocking 시맨틱을 가질 수 없습니다.
2. 함수 선언 부분을 어떤 함수들이 TM 친화적인지 알리도록 장식합니다. 이렇게 되면, 이 장식들은 컴파일러의 타입 시스템에 의해 강제될 수 있습니다. 물론, 많은 언어들에 있어서, 이는 연관된 시간 딜레이와 함께 언어의 확장이 제시되고, 표준화되고, 구현될 것을 필요로 합니다. 그렇다고는 하나, 그런 표준화를 위한 노력이 이미 진행 중입니다 [ATS09].
 3. 앞에서와 같이, 트랜잭션 안에서의 함수의 동적 링킹과 로딩을 불허합니다.

물론 I/O 오퍼레이션은 TM의 알려진 약점이고, 동적 링킹과 로딩은 I/O의 또 다른 특수 케이스 중 하나로 여겨질 수 있습니다. 더도 아니고 덜도 아니고, TM의 제안자들은 이 문제를 해결하거나, TM이 병렬 프로그래머의 도구상자의 여러 도구들 가운데 하나일 뿐이라고 스스로를 인정하게 해야 합니다.(공평을 위해 말하자면, 많은 수의 TM 제안자들이 그들 스스로는 TM 외의 것들도 갖춘 세계에 존재하는 존재 가운데 하나일 뿐임을 인정해 왔습니다.)

17.2.2.4 Memory-Mapping Operations

락 기반의 크리티컬 섹션 내에서 `(mmap()`, `shmat()`, 그리고 `munmap()` [Gro01]과 같은) 메모리 매핑 오퍼레이션들을 사용하는건 완전히 합법적이고, 적어도 원칙적으로는, userspace-RCU read-side 크리티컬 섹션 내에서의 사용도 드립습니다. 그런 오퍼레이션을 트랜잭션 내에서 수행하려 시도하면 무슨 일이 벌어질까요? 더 나아가서, 다시 매핑된 메모리 영역이 현재 쓰레드의 트랜잭션에 사용되는 변수를 담고 있다면 어떻게 될까요? 그리고 이 메모리 영역이 다른 스레드의 트랜잭션에 사용되는 변수를 담고 있다면 어떻게 될까요?

대부분의 락킹 기능들이 락 변수들을 다시 매핑하는 행위의 결과를 정의하지 않는다는 점을 놓고 보면 TM 시스템의 메타데이터가 다시 매핑되는 케이스의 경우는 고려하지 않아도 될 것입니다.

TM에서 사용 가능한 메모리 매핑에서의 선택지들이 여기 있습니다:

1. 트랜잭션 안에서의 메모리 재 매핑은 불법으로 간주되어서, 모든 메모리 재 매핑을 둘러싼 트랜잭션이 abort 됩니다. 이는 일을 단순화 시킵니다만, TM이 크리티컬 섹션 내에서 재 매핑을 처리할 수 있는 동기화 기능들과 상호작용할 수 있을 것을 필요로 합니다.

2. 트랜잭션 안에서의 메모리 재 매핑은 불법으로 간주되고, 컴파일러가 이 금지사항을 강제할 수 있도록 돋습니다.
3. 트랜잭션 내에서의 메모리 매핑은 합법입니다만, 매핑된 영역 안에 변수를 가지고 있는 모든 다른 트랜잭션들은 abort 됩니다.
4. 트랜잭션 내에서의 메모리 매핑은 합법입니다만, 매핑되는 영역이 현재 트랜잭션의 메모리 사용 영역과 겹친다면 그 매핑 오퍼레이션은 실패합니다.
5. 트랜잭션 안에서든 밖에서든 행해지는 모든 메모리 매핑 오퍼레이션은 시스템의 모든 트랜잭션의 메모리 사용 범위와 겹쳐지는지를 체크합니다. 만약 겹친다면, 해당 메모리 매핑 오퍼레이션은 실패합니다.
6. 시스템의 어떤 트랜잭션의 메모리 사용 영역과 겹치는 메모리 매핑 오퍼레이션의 영향은 TM conflict manager에 의해 결정되는데, 메모리 매핑 오퍼레이션을 실패시킬지 모든 충돌하는 트랜잭션들을 abort 시킬지를 동적으로 결정합니다.

`munmap()`은 메모리의 관련된 영역을 매핑되지 않은 채로 놔두어서, 추가적인 재미있는 영향을 가질 수 있음을 알아둘만 합니다.⁴

17.2.2.5 Debugging

브레이크포인트와 같은 일반적인 디버깅 오퍼레이션들은 락 기반의 크리티컬 섹션과 userspace-RCU read-side 크리티컬 섹션 안에서는 평범하게 동작합니다. 하지만, 초기의 트랜잭션에서 메모리 하드웨어 구현 [DLMN09]에서는 트랜잭션 안에서의 exception은 그 트랜잭션을 abort 시켰는데, 이는 브레이크포인트는 그를 둘러싼 트랜잭션들을 abort 시켰음을 의미합니다.

트랜잭션은 어떻게 디버깅 될 수 있을까요?

1. 브레이크포인트를 담고 있는 트랜잭션에 대해서 소프트웨어 에뮬레이션 테크닉을 사용합니다. 물론, 모든 트랜잭션의 범위 내에서 브레이크포인트가 설정될 때마다 모든 트랜잭션을 에뮬레이션 해야 할 필요가 있을 겁니다. 만약 런타임 시스템이 특정 브레이크포인트가 트랜잭션의 범위 안에 있는지 아닌지 여부를 결정할 수가 없다면, 안전한 쪽으로 있기 위해 모든 트랜잭션을 에뮬레이션 해야 할 필요가 있을 겁니다. 하지만, 이 방법은 상당한 오버헤드를 가져오게 될 것이어서, 쫓고 있는 버그를 찾기 어렵게 만들 겁니다.

⁴ 매핑과 매핑 해제 사이의 이 차이점은 Josh Triplett에 의해 이야기 되었습니다.

2. 브레이크포인트 exception 을 처리할 수 있는 하드웨어 TM 구현만을 사용합니다. 불행히도, 지금 (2008년 9월) 글을 쓰는 시점에서는, 모든 그런 구현들은 연구용 프로토타입들 뿐입니다.
3. 하드웨어 TM 구현들의 더 간단한 것들보다는 (매우 간략히 말해서) 더 exception 을 잘 처리해주는 소프트웨어 TM 구현만을 사용합니다. 물론, 소프트웨어 TM은 하드웨어 TM 보다 높은 오버헤드를 갖는 경향이 있으므로, 이 방법이 모든 상황에서 적합하지는 않을 겁니다.
4. 더 주의깊게 프로그램을 짜서, 트랜잭션 안에서는 버그가 존재하지 않는 것을 첫번째 목적으로 합니다. 이걸 어떻게 할 수 있는지 알아낸다면, 부디 모두에게 그 비밀을 공유해 주세요!

트랜잭션 메모리가 다른 동기화 메커니즘들에 비해서 더 나은 생산성을 가져다 줄 것임을 믿을 만한 몇가지 이유가 있습니다만, 전통적인 디버깅 테크닉들이 트랜잭션에 적용될 수가 없다면 이런 개선점들은 사라질 수도 있을 듯 합니다. 특히나 트랜잭션 메모리에 익숙지 않은 사람이 커다란 트랜잭션을 트랜잭션 메모리로 사용하려 한다면 특히나 그렇게 될 가능성이 큽니다. 대조적으로, 거친 “탑 클래스의” 프로그래머들은, 특히나 작은 트랜잭션에 대해서는 그런 디버깅의 필요 자체가 없게 할 수도 있을 겁니다.

따라서, 트랜잭션 메모리가 익숙지 않은 프로그래머들에게도 생산성을 약속해 줄 수 있으려면, 디버깅 문제는 풀릴 필요가 있습니다.

17.2.3 Synchronization

어느날 트랜잭션 메모리가 모두에게의 모든 것이 된다면, 다른 동기화 메커니즘을 사용할 필요가 없어질 겁니다. 그렇게 되기 전까지는, 트랜잭션 메모리가 할 수 없는 것을 할 수 있거나 주어진 상황에서 보다 자유롭게 동작할 수 있는 동기화 메커니즘과 함께 사용되어야 할 겁니다. 다음 섹션들은 이 영역에 존재하는 현재의 challenge 들을 정리해 봅니다.

17.2.3.1 Locking

락을 잡은채로 다른 락을 잡는 것은 일반적인 일인데, 최소한, 데드락을 막기 위해 일반적으로 잘 알려진 소프트웨어 엔지니어링 테크닉이 사용된다면 이는 잘 동작 합니다. RCU read-side 크리티컬 섹션 안에서 락을 잡는 것은 흔하지 않는데, RCU read-side 기능들은 락 기반의 데드락 사이클에 포함될 수가 없기 때문에 이는 데드락에 대한 고려를 줄여줍니다. 하지만 트랜잭션 안에서 락을 잡으려 한다면 무슨 일이 일어날까요?

이론적으로, 그에 대한 답은 간단합니다: 해당 락을 나타내는 데이터 구조를 트랜잭션의 한 부분으로 잡으면, 모든 것이 잘 동작합니다. 실제로는, TM 시스템의 상세한 구현에 따라서 여러개의 명확치 않은 복잡한 문제 [VGS08] 가 존재할 수 있습니다. 이런 복잡한 문제들은 해결될 수 있긴 하지만, 트랜잭션의 바깥에서 잡는 락들에 대해서는 45 %의 오버헤드 증가, 트랜잭션 안에서 잡는 락들에 대해서는 300 %의 오버헤드 증가를 그 비용으로 갖게 됩니다. 적은 양의 락킹을 포함하고 있는 트랜잭션을 사용하는 프로그램에서 이런 오버헤드는 받아들일 만도 하게지만, 때때로 트랜잭션을 사용하고자 하는 락 기반의 제품 수준 프로그램에서는 받아들여질 수 없을 겁니다.

1. 락킹에 친화적인 TM 구현만을 사용합니다. 불행히도, 락킹에 친화적이지 않은 구현들은 성공적인 트랜잭션을 위한 낮은 오버헤드와 극단적으로 큰 트랜잭션을 수용할 수 있는 능력과 같은 장점을 일부 갖습니다.
2. TM 을 락 기반의 프로그램에 사용할 때 “조금만” TM 을 사용해서 락킹에 친화적인 TM 구현의 한계 점들을 받아들입니다.
3. 락킹 기반의 기존 시스템을 전부 무시해서, 모든 것을 트랜잭션 기준으로 다시 구현합니다. 이 방법은 지지하는 사람이 부족하지 않습니다만, 이는 이 시리즈에서 이야기된 모든 문제들이 해결되기를 필요로 합니다. 이 문제들을 해결하는데 걸리는 시간 동안, 경쟁상대인 동기화 메커니즘들 역시 개선될 수 있을 겁니다.
4. TxLinux [RHP+07] 그룹에 의해서 행해진 것처럼, TM 을 락킹 기반의 시스템에서의 최적화로만 사용합니다. 이 방법은 잘 동작할 듯 들리지만, (데드락을 막기 위한 필요와 같은) 락킹 설계 문제들을 그대로 남겨둡니다.
5. 락킹 기능들로 추가되는 오버헤드를 줄이려 노력합니다.

많은 사람에게 놀랄 수 있는 TM 과 락킹 사이를 잇는 문제가 존재할 수 있다는 사실은 실제 제품 소프트웨어에서 새로운 메커니즘과 기능들을 사용해야 함을 강조합니다. 다행히도, 오픈 소스의 진보는 연구자들을 포함해서 모두에게 많은 그런 소프트웨어가 사용 가능함을 의미합니다.

17.2.3.2 Reader-Writer Locking

락을 잡은 채로 reader-writer 락의 읽기 권한 획득을 하는 것은 잘 동작하며, 적어도 데드락을 막기 위해 잘

알려진 소프트웨어 엔지니어링 테크닉이 사용되는 곳에서는 흔한 일입니다. RCU read-side 크리티컬 섹션 아นำเสนอ reader-writer 락의 읽기 권한 획득을 하는 것 역시 동작하며, RCU read-side 기능들은 락 기반의 데드락 사이클에 포함될 수가 없기 때문에 데드락에 대한 주의를 완화시켜줍니다. 하지만 트랜잭션 안에서 reader-writer 락의 읽기 권한을 획득하려 하면 무슨 일이 벌어질까요?

안타깝게도, 트랜잭션 안에서 전통적인 카운터 기반의 reader-writer 락의 읽기 권한을 획득하려는 시도는 reader-writer 락의 목적을 왜해시킬 수 있습니다. 이를 보기 위해, 같은 reader-writer 락의 읽기 권한을 동시에 획득하려 하는 한쌍의 트랜잭션을 생각해 봅시다. 읽기 권한 획득은 reader-writer 락의 데이터 구조의 수정에 연관되기 때문에, 충돌이 날 것이고, 이는 두 트랜잭션 가운데 하나를 roll back 시킬 겁니다. 이 동작은 reader-writer 락의 목적인 동시적인 읽기 쓰레드들을 허용하는 것과 전혀 일관적이지 못합니다.

TM에서 해볼 수 있는 선택사항 몇 가지가 다음과 같습니다:

1. Per-CPU 또는 per-thread reader-writer 락킹 [HW92]을 사용해서, 특정 CPU (또는, 쓰레드) 가 락의 읽기 권한 획득 시에 로컬 데이터만을 조정하도록 합니다. 이는 동시에 락의 읽기 권한을 획득하려는 두개의 트랜잭션이 충돌하는 현상을 막아서 원래 의도대로 동시에 둘 다 진행되도록 합니다. 안타깝게도, (1) per-CPU/thread 락킹에서의 쓰기 권한 획득 오버헤드는 상당히 크며, (2) per-CPU/thread 락킹의 메모리 오버헤드가 금지될 수 있으며, (3) 이 변환은 여러분이 문제가 되는 소스 코드에 접근 권한이 있을 때에만 사용할 수 있는 방법입니다. 더 최근의, 다른 확장성 있는 reader-writer 락 [LLO09]은 이런 문제들을 일부 또는 전부 없앨 수도 있습니다.
2. TM을 락 기반의 프로그램에 접목할 때 “작은 부분”에서만 TM을 사용해서 트랜잭션 안에서 reader-writer 락의 일기 권한 획득을 막습니다.
3. 락킹 기반의 기존 시스템을 완전히 분리시켜서, 모든 것을 트랜잭션으로 다시 구현합니다. 이 방법은 지지자가 부족하지는 않지만, 이는 이 글에서 설명된 모든 문제들이 해결될 것을 필요로 합니다. 이 문제들을 해결하는 시간이 지나는 동안, 다른 경쟁상대 동기화 메커니즘들이 더 나아질 가능성도 물론 존재합니다.
4. TxLinux [RHP+07] 그룹에 의해서 그랬던 것처럼 TM을 완전히 락 기반의 시스템의 최적화에만 사용합니다. 이 방법은 잘 동작할 듯 들리지만, 락킹

설계의 (데드락 방지 등과 같은) 제약점들을 그대로 둡니다. 더 나아가서, 이 방법은 여러 트랜잭션들이 같은 락에 대해 읽기 권한을 획득하려 할 때에 불필요한 트랜잭션 롤백을 초래할 수 있습니다.

물론, 배타적 락킹에 대해서도 그랬던 것처럼, TM을 reader-writer 락킹에 조합하는 것을 둘러싼 또 다른 명확치 않은 이슈들이 있을 수 있습니다.

17.2.3.3 Deferred Reclamation

이 섹션은 RCU에 주로 집중합니다. TM을 레퍼런스 카운터나 해저드 포인터 같은 다른 deferred-reclamation 메커니즘과 조합할 때에도 비슷한 문제나 해결책이 존재합니다. 아래에서, 알려진 차이점은 명시적으로 이야기될 겁니다.

Read-copy update (RCU)는 리눅스 커널에서 주로 사용되기 때문에, RCU와 TM을 조합하려는 학계에서의 시도는 없었을 거라고 생각할 수 있을 겁니다.⁵ 하지만, 오스틴 텍사스 대학교의 TxLinux 그룹은 다른 선택이 없었습니다 [RHP+07]. 그들은 RCU를 사용하는 리눅스 2.6 커널에 TM을 적용했기 때문에 TM이 RCU 업데이트를 위한 락킹의 자리를 대신하는 방식으로 TM과 RCU를 조합해야만 했습니다. 해당 논문은 RCU 구현의 락들 (예: `rcu_ctrlblk.lock`)이 트랜잭션으로 변환되었다고 이야기 하긴 했지만, 안타깝게도 RCU 기반의 업데이트에 사용된 락들 (예: `dcache_lock`)에는 무슨 일이 있었는지는 이야기 되지 않았습니다.

RCU는 읽기 쓰레드들과 업데이트 쓰레드들이 동시에 수행될 수 있게 하며, 더 나아가서 RCU 읽기 쓰레드들은 업데이트가 진행되고 있는 데이터에도 접근할 수 있도록 한다는 점을 알아두는게 중요합니다. 물론, 성능, 확장성, real-time 응답성에서의 이득이 될 수 있는, 이런 RCU의 속성은 TM의 원자성 속성을 무시하고 동작합니다.

그러니 TM 기반의 업데이트가 동시에 RCU 읽기 쓰레드들과 상호작용할 때에는 어떻게 해야 할까요? 몇 가지 가능한 것들은 다음과 같습니다:

1. RCU 읽기 쓰레드들이 충돌하는 동시에 TM 업데이트들을 abort 시킵니다. 이는 실제로 TxLinux 프로젝트에서 취해진 방법입니다. 이 방법은 RCU semantic을 유지하고, 또한 RCU의 read-side 성능, 확장성, 그리고 real-time 응답 속성을 유지합니다만, 불행히도, 불필요하게 충돌되는 업데이트들을 abort 시키는 부작용을 갖게 됩니다. 최악의 경우에는 길게 유지되는 RCU 읽기 쓰레드들은 모든

⁵ 하지만, user-space RCU [Des09b, DMS+12]의 발전으로 커널 안에서만 사용될 것이라는 변명은 힘을 잃습니다.

업데이트 쓰레드들을 진행하지 못하게 만들 잠재성을 가지고 있어서 이는 이론적으로 시스템이 멎게 되는 결과를 초래할 수 있습니다. 또한, 모든 TM 구현이 이런 방법에 필요한 강한 원자성을 제공하는 것은 아닙니다.

2. 충돌하는 TM 업데이트들과 동시에 수행되는 RCU 읽기 쓰레드들은 충돌하는 어떤 RCU load로부터 든 과거의 (이전 트랜잭션의) 값을 가져오도록 합니다. 이는 RCU semantic과 성능을 유지하며, RCU 업데이트 쪽의 starvation을 방지합니다. 하지만, 모든 TM 구현이 수행중인 트랜잭션에 의해 임시적으로 업데이트된 변수들의 기존 값들에 대한 빠른 접근을 제공할 수 있는 건 아닙니다. 구체적으로, 기존 값을 로그에 유지하는 (그렇게 함으로써 훌륭한 TM 커밋 성능을 제공하는) 로그 기반의 TM 구현은 이런 방법에 대해서는 즐거울 수 없을 겁니다. RCU 가 커다란 길이의 트랜잭션 구현 안에서 기존 값을 접근하는 것을 가능하게 하기 위해 아마도 `rcu_dereference()` 기능이 사용될 수 있을 겁니다만, 성능은 여전히 문제가 될 수 있을 겁니다. 더도 아니고 털도 아니고, 이런 방법으로 쉽고 효율적으로 RCU 와 조합될 수 있는 유명한 TM 구현들이 존재합니다 [PW07, HW11, HW13].
3. RCU 읽기 쓰레드가 현재 수행중인 트랜잭션과 충돌하는 액세스를 수행한다면, 그 RCU 액세스는 충돌하는 트랜잭션이 커밋하거나 abort 되기 전까지 딜레이 되도록 합니다. 이 방법은 RCU semantic을 유지합니다만, RCU의 성능이나 real-time 응답은 유지하지 않으며, 특히나 긴시간 수행되는 트랜잭션의 존재 시에는 더욱 그렇습니다. 또한, 모든 TM 구현에서 충돌되는 액세스들을 딜레이 시키는게 가능하지는 않습니다. 그렇다고는 하나, 이 방법은 작은 트랜잭션들만을 지원하는 하드웨어 TM 구현들에는 확실히 합리적일 것으로 보입니다.
4. RCU 읽기 쓰레드들을 트랜잭션으로 변환시킵니다. 이 방법은 RCU 가 모든 TM 구현과 완전히 호환될 것을 보장합니다만, RCU read-side 크리티컬 섹션에서의 TM의 롤백이 가능해서 RCU의 real-time 응답 보장을 지켜지지 못하게 하고, 따라서 RCU의 read-side 성능을 떨어뜨립니다. 더 나아가서, 이 방법은 RCU read-side 크리티컬 섹션들 가운데 하나라도 사용되는 TM 구현이 처리할 수 없는 오퍼레이션들을 포함하고 있는 경우에 대해서는 적절치 못합니다. 이 방법은 읽기 쓰레드의 코드 섹션을 명시적으로 정의하지 않는 해저드 포인터에 적용하기에는 더 어렵습니다.
5. RCU의 많은 update-side 사용들이 새로운 데이터

구조를 공개하기 위해 하나의 포인터를 수정합니다. 이런 일부 경우들에 있어서, RCU는 이어서 롤백될 트랜잭션에 의한 포인터 업데이트를 안전하게 볼 수 있는데, 해당 트랜잭션이 메모리 순서 규칙을 지켜주는 한, 그리고 이 롤백 프로세스가 연관된 구조체를 메모리에서 해제시키는데에 `call_rcu()`를 사용하는 한은 그렇습니다. 안타깝게도, 모든 TM 구현들이 트랜잭션 안에서의 메모리 배리어를 따르지는 않습니다. 명백하게, 이 생각은 트랜잭션들은 원자적일 것으로 여겨지기 때문에, 트랜잭션 안에서의 액세스들의 순서는 문제가 되지 않을 것으로 여겨진다는 것입니다.

6. RCU 업데이트에서의 TM의 사용을 금지시킵니다. 이는 잘 동작할 것으로 보장됩니다만, 약간 제한적일 것으로 보입니다.

추가적인 방법들 역시 모습을 드러내게 될 것으로 보이는데, 특히나 user-level RCU 와 해저드 포인터의 구현의 발전에 따라서 특히 그렇습니다.⁶

17.2.3.4 Extra-Transactional Accesses

락 기반의 크리티컬 섹션 내에서, 동시에 액세스 되는 변수를 조정하는 것은 완전히 합법적이며, 심지어 그락의 크리티컬 밖에서 수정되고 있는 변수에 액세스 하는 것도 합법적인데, 그런 흔한 예 중 하나는 통계적 카운터일 것입니다. 같은 일이 RCU read-side 크리티컬 섹션 안에서도 비슷하며, 이는 흔한 일입니다.

제품화된 데이터베이스 시스템에서도 흔한 “dirty reads” 라 불리는 이런 메커니즘을 놓고 보면, TM의 제안자로부터 extra-transactional access들이 상당한 관심을 받은 것은 놀랄만한 일이 아닌데, 완화된, 그리고 강화된 원자성 [BLM06] 이 이런 의미에서의 하나의 케이스입니다.

여기 extra-transactional 선택 사항들이 몇가지 있습니다:

1. Extra-transactional 액세스로 인한 충돌은 항상 트랜잭션을 abort 시킵니다. 이는 강한 원자성입니다.
2. Extra-transactional 액세스로 인한 충돌은 무시되어서, 트랜잭션 끼리의 충돌만이 트랜잭션들을 abort 시킵니다. 이는 완화된 원자성입니다.
3. 트랜잭션은 메모리를 할당할 때나 락 기반의 크리티컬 섹션과 상호작용할 때와 같이 특수한 경우에 트랜잭션에서 할 수 없는 동작도 할 수 있도록 허용됩니다.

⁶ 여려개의 앞의 대안들을 가져와준 TxLinux 그룹, Maged Michael, 그리고 Josh Triplett에게 감사를.

4. 복수개의 트랜잭션에 의해 하나의 변수에 동시에 수행될 수 있는 일부 오퍼레이션 (예를 들면, 더하기)이 가능하게 하는 하드웨어 확장장치를 만듭니다.
5. 트랜잭션 메모리에 완화된 semantic 을 가져옵니다. 한가지 방법은 Section 17.2.3.3 에서 설명된 RCU 와의 조합으로, Gramoli 와 Guerraoui 가 예를 들면 커다란 “신축성 있는” 트랜잭션들을 작은 트랜잭션들로의 제한적 분할로 (맥빠지는 성능과 확장성에도 불구하고) 충돌 가능성을 줄이는 식의 많은 수의 완화된 트랜잭션 방법을 연구했습니다 [GG14].

트랜잭션들은 어떤 다른 동기화 메커니즘과의 상호 작용의 필요 없이 혼자 존재할 수 있도록 만들어진 것으로 보입니다. 만약 그렇다면, 트랜잭션들을 트랜잭션으로 인한 것이 아닌 액세스와 조합할 때에 많은 혼란과 복잡성이 등장하는 것은 놀라운 일이 아닙니다. 하지만 트랜잭션들이 격리된 데이터 구조로의 적은 업데이트로만 국한되어 있는 것이 아니라면, 또는 기존에 존재 하던 커다란 병렬 코드와 상호작용하지 않는 새로운 프로그램에만 국한되어 있는 게 아니라면, 트랜잭션은 커다란 수준의 실용적인 효과를 내기 위해서는 트랜잭션이 아닌 액세스와 조합되어야만 합니다.

17.2.4 Discussion

보편적인 TM 적용에 대한 문제들은 다음과 같은 결론을 이끌어냅니다:

1. TM 의 흥미로운 속성 가운데 하나는 트랜잭션들은 룰백과 재시도에 걸리기 쉽다는 사실입니다. 이 속성은 버퍼링 되지 않는 I/O, RPC, 메모리 매핑 오퍼레이션, 시간 딜레이, 그리고 exec() 시스템콜과 같이 되돌이킬 수 없는 오퍼레이션들에 대한 TM 의 어려움을 암시합니다. 이 속성은 또한 안타깝게도, 개발자에게 보여질 수 있는 형태로 존재하는, 실패의 가능성으로 인해 존재하는 동기화 도구들에 내재된 복잡성을 가져오는 결론을 이끌어냅니다.
2. Shpeisman 등 [SATG⁺09] 에 의해 이야기된 TM 의 또 다른 흥미로운 속성은, TM 은 자신이 보호하는 데이터와 동기화가 뒤엉켜진다는 것입니다. 이 속성은 I/O, 메모리 매핑 오퍼레이션들, 트랜잭션 이외의 접근들, 그리고 디버깅 브레이크포인트들과 연관되는 TM 의 문제들을 암시합니다. 대조적으로, 락킹과 RCU 를 포함하는 전통적인 동기화 기능들은 동기화 기능들과 그들이 보호하는 데이터 사이의 분명한 구분을 유지합니다.




Figure 17.8: The STM Vision

3. TM 분야의 많은 사용자들의 이야기된 목표들 가운데 하나는 커다란 순차적 프로그램의 병렬화를 쉽게 하는 것입니다. 그렇게 되면, 개별적인 트랜잭션들은 흔히 순차적으로 수행될 것으로 기대되어서, TM 의 멀티쓰레드로 수행되는 트랜잭션들에 대한 문제들을 상당수 설명할 수도 있을 겁니다.

TM 연구자들과 개발자들은 이런 모든 것에 대해 무엇을 해야 할까요?

한가지 방법은 TM 에 대한 집중은 작게 하고, 다른 동기화 기능들에 대비해 상당한 장점을 잠재적으로 하드웨어가 줄 수 있는 상황에 집중하는 것입니다. 이는 실제로 Sun 이 Rock 연구용 CPU 에서 취한 방법입니다 [DLMN09]. 일부 TM 연구자들은 이 방법에 동의하는 것으로 보입니다만, 다른 사람들은 TM 에 그보다 훨씬 많은 기대를 갖고 있습니다.

물론, TM 이 커다란 문제들에서 취해질 수 있게 되는 것도 상당히 가능할 것이고, 이 셋션은 TM 이 이 높은 목표를 달성하기 위해서는 해결해야 할 문제들을 일부 나열했습니다.

물론, 관련된 모든 사람들은 이를 배우는 경험으로 다뤄야 합니다. TM 연구자들은 커다란 소프트웨어 시스템을 전통적인 동기화 기능들로 성공적으로 만들어낸 실무자들로부터 배우기 위해 많은 거래를 하게 될 것으로 보입니다.

그리고 반대도 마찬가지죠.

하지만, STM 의 현재 상황은 일련의 만화로 요약될 수 있을 것 같습니다. 먼저, Figure 17.8 는 STM 의 전망



Figure 17.9: The STM Reality: Conflicts




Figure 17.10: The STM Reality: Irrevocable Operations

을 보이고 있습니다. 항상 그렇듯, 실제는 Figures 17.9, 17.10, 그리고 17.11에 그려진 것처럼 좀 더 미묘한 차이가 있습니다.

최근의 구할 수 있는 하드웨어에서의 발전은 뒤의 섹션에서 설명될 HTM의 변종으로의 문을 열었습니다.

17.3 Hardware Transactional Memory

2017년에 이르러, 하드웨어 트랜잭션 메모리 (HTM)이 상품으로 구입할 수 있는 흔한 컴퓨터 시스템들 일부에도 도입되기 시작하고 있습니다 [YHLR13, Mer11, JSG12].. 이 섹션은 병렬 프로그래머의 도구상자에 이 하드웨어 트랜잭션 메모리가 위치할 자리를 알아보기 위한 시도를 해 봅니다.

개념적 관점에서, HTM은 명시된 명령문의 그룹 (하나의 “트랜잭션”)을 다른 프로세서에서 수행되는 모든 다른 트랜잭션들의 시야에 원자적으로 보이도록 그 효과를 만들기 위해 프로세서 캐시와 예측적 수행을 사용합니다. 이 트랜잭션은 begin-transaction 기계 인스트럭션을 통해 초기화 되고 commit-transaction 기계 인스트럭션을 통해 완료됩니다. 일반적으로 abort-transaction 기계 인스트럭션도 존재하는데, 이는 (begin-transaction 인스트럭션과 그를 뒤따른 인스트럭션들이 수행되지 않은 것처럼) 예측적 수행 내용을 짓이기고 failure handler의 수행을 시작합니다. 이 failure handler의 위치는

begin-transaction 인스트럭션에 의해서 명시적인 failure-handler의 주소를 통해서든 또는 해당 인스트럭션 자체의 조건적 코드에 의해서든 주어집니다. 각각의 트랜잭션은 모든 다른 트랜잭션에 대해 어토믹하게 수행됩니다.

HTM은 여러가지 중요한 장점을 갖는데, 데이터 구조의 자동적인 동적 분할, 동기화 기능의 캐시 미스의 감소, 그리고 상당수의 실용적 어플리케이션의 지원 등이 이런 장점에 포함됩니다.

하지만, 항상 작은 문자로 인쇄된 부분을 읽어야 하고, HTM 역시 예외가 아닙니다. 이 섹션의 중요한 요점은 어떤 조건 하에서 HTM의 장점들이 그것의 작은 문자로 인쇄된 내용에 감추어져 있는 복잡성을 앞서는가를 결정하는 것입니다. 이런 결론 아래, Section 17.3.1은 HTM의 장점을 설명하고 Section 17.3.2은 그 단점을 설명합니다. 이는 이전의 논문들 [MMW07, MMTW10]에서 취해진 것과 같은 방법입니다만, 전체적으로 TM보다는 HTM에 초점을 맞춥니다.⁷

이어서 Section 17.3.3은 리눅스 커널에서 (그리고 일부 user-space 어플리케이션에서) 사용되는 동기화 도구들의 조합과 관련해서 HTM의 단점을 설명합니다. Section 17.3.4은 병렬 프로그래머의 도구상자에서 어디에 HTM이 가장 잘 어울릴지를 알아보고, Section 17.3.5은 HTM의 범위와 매력을 상당히 증가시킬 수 있을 몇

⁷ 그리고 저는 다른 저자들인 Maged Michael, Josh Triplett, Jonathan Walpole, 그리고 Andi Kleen과의 자극적인 토론들에 기꺼이 감사를 드립니다.



Figure 17.11: The STM Reality: Realtime Response

가지 사건들을 나열합니다. 마지막으로, Section 17.3.6에서는 결론을 내립니다.

17.3.1 HTM Benefits WRT to Locking

HTM의 주된 장점들은 (1) 다른 동기화 기능들에 의해 종종 일어나는 캐시 미스의 제거, (2) 동적으로 데이터 구조를 파티셔닝하는 능력, (3) 상당한 수의 실용적 어플리케이션이 존재한다는 사실입니다. 저는 두 가지 이유로 TM의 전통과 달리 사용의 편의성을 별도로 열거하지 않습니다. 첫째로, 사용의 편의성은 이 섹션이 초점을 맞추고 있는 HTM의 주요 장점으로부터 기인합니다. 둘째, 날 프로그래밍 재능을 위한 테스트를 하려는 시도를 둘러싼 [Bor06, DBA09], 그리고 심지어 취직을 위한 면접에서의 작은 프로그래밍 연습문제의 사용을 둘러싼 [Bra07] 상당한 논쟁이 존재했습니다. 이는 우리가 무엇이 프로그래밍을 쉽게 하고 어렵게 하는지에 대한 진정한 이해를 가지고 있지 못함을 의미합니다. 따라서, 이 섹션은 앞서 나열한 세 개의 장점에 대해서만, 각각 뒤의 섹션들에서 초점을 맞추도록 하겠습니다.

17.3.1.1 Avoiding Synchronization Cache Misses

대부분의 동기화 메커니즘들은 어토믹 인스트럭션으로 조정되는 데이터 구조에 기반합니다. 일반적으로 이 어토믹 인스트럭션들은 먼저 연관된 캐시 라인이 수행되고 있는 CPU에 의해 소유되도록 하기 때문에, 다른 CPU에서 같은 동기화 기능 인스턴스의 수행을 뒤따라 하게 되면, 캐시 미스를 초래하게 됩니다. 이러한 통신으로 인한 캐시 미스 이벤트들은 전통적인 동기화

메커니즘들의 성능과 확장성을 상당히 떠어뜨립니다 [ABD⁺97, Section 4.2.3].

반면에, HTM은 CPU의 캐시를 사용해서 동기화를 하므로 동기화 데이터 구조의 필요와 그로 말미암은 캐시 미스가 없습니다. HTM의 장점은 락 데이터 구조가 별개의 캐시 라인에 위치해 있을 때에 극대화 되는데, 크리티컬 섹션을 HTM 트랜잭션으로 변환함으로써 전체 캐시 미스로 인한 크리티컬 섹션의 오버헤드를 줄여주는 경우가 그런 경우입니다. 이런 이득은 짧은 크리티컬 섹션을 갖는 흔한 경우에 특히 큼 수 있으며, 최소한 생략된 락이 그 락에 의해 보호되는, 자주 쓰여지는 변수와 캐시 라인을 공유하지 않을 때의 상황에서는 그렇습니다.

Quick Quiz 17.2: 해당 락 변수와 캐시 라인을 공유하는, 자주 쓰여지는 변수가 왜 문제가 될까요? ■

17.3.1.2 Dynamic Partitioning of Data Structures

일부 전통적 동기화 메커니즘의 사용에 대한 주요한 방해는 정적으로 데이터 구조를 분할해야 하는 필요성입니다. 간단하게 분할될 수 있는 데이터 구조들이 여럿 존재하는데, 유명한 예로 해시 테이블이 존재하는데, 여기서는 각각의 해시 체인이 하나의 파티션을 구성하게 됩니다. 각각의 해시 체인을 위한 락을 할당하는 것으로 해시 테이블을 해당 체인에 국한된 오퍼레이션들로 병렬화 시키게 됩니다.⁸ 배열, radix tree, 그리고 일부 다른 데이터 구조들에 대해서도 파티셔닝은 비슷하게 간단합니다.

하지만, 많은 종류의 tree와 graph에 있어 파티셔닝은 상당히 어렵고, 그 결과는 종종 복잡합니다 [Ell80]. 일반적인 데이터 구조를 파티셔닝 하는데에 two-phased 락킹과 해시된 락 배열들을 사용하는 것도 가능하지만, 다른 방법들이 더 선호되었는데 [Mil06]. 이것들은 Section 17.3.3에서 논의될 겁니다. 동기화 캐시 미스의 제거를 놓고 볼 때, HTM은 최소한 상대적으로 적은 업데이트를 가정하면 커다란 파티셔닝 불가능한 데이터 구조를 위한 그럴싸한 방법입니다.

Quick Quiz 17.3: HTM 성능과 확장성에 상대적으로 적은 업데이트가 중요한 이유가 뭐죠? ■

17.3.1.3 Practical Value

HTM의 실질적 가치에 대한 몇몇 증거들이 Sun Rock [DLMN09]와 Azul Vega [Cli09]을 포함한 여러 하드웨어 플랫폼들에서 보여졌습니다. 실질적 이점들이 더 최신의 IBM Blue Gene/Q, Intel Haswell TSX,

⁸ 그리고 이 방법을 여러 해시 체인에 접근하는 오퍼레이션들로 그런 오퍼레이션들이 연관된 체인들을 위한 락들을 해시 순서대로 모두 잡도록 하는 것으로 쉽게 확장할 수 있습니다.

그리고 AMD ASF 시스템들에서도 나올 것이라 가정하는 것은 합리적입니다.

예상되는 실질적 이점들은 다음과 같습니다:

1. In-memory 데이터 액세스와 업데이트를 위한 락 생략 [MT01, RG02].
2. 커다란 파티셔닝 불가능한 데이터 구조로의 동시적인 액세스와 약간의 무작위적 업데이트들.

하지만, HTM은 또한 실질적인 한계점들도 가지고 있는데, 이에 대해서는 다음 섹션에서 이야기 하겠습니다.

17.3.2 HTM Weaknesses WRT Locking

HTM의 컨셉은 상당히 간단합니다: 메모리로의 액세스와 업데이트가 그룹 단위로 어토믹하게 일어난다는 것입니다. 하지만, 많은 간단한 아이디어들이 그러하듯이, 이를 실제 세계의 실제 시스템에 적용할 때에서야 복잡성이 나타납니다. 이 복잡성들은 다음과 같은 것들입니다:

1. 트랜잭션 크기 한계.
2. Conflict 처리.
3. Abort 와 롤백.
4. 진행 보장의 부재.
5. 되돌이킬 수 없는 오퍼레이션들.
6. Semantic 상의 차이점들.

이 각각의 복잡성들은 다음의 섹션들에서 다루어지고, 그 뒤를 이어 요약을 합니다.

17.3.2.1 Transaction-Size Limitations

현재 HTM 구현들의 트랜잭션 크기 한계점은 그 트랜잭션에 영향받는 데이터를 쥐고 있기 위해 프로세서의 캐시를 사용한다는 데서 나옵니다. 이는 특정 CPU가 트랜잭션을 자신의 캐시 안에 국한된 채로 수행시켜서 해당 트랜잭션이 다른 CPU들에게 어토믹하게 보이도록 하는 것을 가능하게 하지만, 이는 또한 캐시에 들어가지 않는 모든 트랜잭션은 abort 될것을 의미하기도 합니다. 더 나아가서, 인터럽트, 시스템 콜, exception, trap, 그리고 컨텍스트 스위치와 같이 수행 문맥을 바꾸는 이벤트들은 해당 CPU에서 수행중인 트랜잭션을 모두 abort 시키거나 다른 수행 컨텍스트에 의한 캐시 사용으로 인해 트랜잭션의 크기를 제한해야만 합니다.

물론, 최신 CPU들은 커다란 캐시를 갖는 경향이 있고, 많은 트랜잭션들에 필요한 데이터는 1 메가바이트 캐시 안에도 잘 들어갈 겁니다. 불행히도, 캐시에 있어서, 크기만이 모든 문제는 아닙니다. 문제는, 대부분의 캐시들은 하드웨어로 구현된 해시 테이블로 생각될 수 있다는 것입니다. 하지만, 하드웨어 캐시는 (일반적으로 *set*이라 불리는) 베킷들을 연결시키지 않고, *set* 당 고정된 수의 캐시라인들을 제공합니다. 특정 캐시에서 각각의 *set*에 제공되는 원소들의 수는 해당 캐시의 *associativity*라고 불립니다.

Cache associativity는 다양하지만, 제가 지금 타자를 치고 있는 랩탑의 8-way associativity level-0 캐시는 흔하지 않습니다. 이게 의미하는바는 특정 트랜잭션이 9개의 캐시 라인을 견드리게 되고, 그 9개의 캐시 라인들이 모두 같은 *set*으로 매핑된다면, 그 트랜잭션은 해당 캐시에 얼마나 많은 메가바이트의 용량들이 남아있는가에 관계없이 성공할 수 없다는 것입니다. 그렇습니다, 특정 데이터 구조에서 무작위적으로 골라진 데이터 원소들에 있어서, 그 트랜잭션이 커밋에 성공할 확률은 매우 높진 않습니다만, 어떤 보장사항도 없습니다.

이 한계점을 경감시키기 위한 일부 연구들이 있습니다. Fully associative *victim cache*는 associativity 한계를 경감시킬 수 있습니다만, *victim cache*의 성능과 에너지 효율성에 대한 많은 한계가 현재 존재합니다. 그렇다고는 하나, 수정되지 않은 캐시 라인들을 위한 HTM *victim cache*는 주소만을 가지고 있을 수도 있으므로, 상당히 작을 수 있습니다: 데이터 주소 자체는 충돌되는 쓰기를 파악하기에 충분하며 [RD12] 데이터 자체는 메모리에 쓰여지거나 다른 캐시에 shadow 될 수 있습니다.

Unbounded transactional memory (UTM) 방법 [AAKL06, MBM⁺06]은 DRAM을 극단적으로 커다란 *victim cache*로 사용합니다만, 그런 방법을 제품 품질의 캐시 일관성 메커니즘과 결합하는 것은 여전히 해결되지 않은 문제입니다. 또한, DRAM을 *victim cache*로 사용하는 것은 성능과 에너지 효율성의 저하를 가져올 수 있는데, *victim cache*가 fully associative 하다면 특히 그렇습니다. 마지막으로, UTM의 “unbounded”라는 측면은 DRAM이 모두 *victim cache*로 사용될 수 있다는 가정을 합니다만, 실제로는 커다랗긴 하지만 고정된 양의, 해당 CPU에 주어진 DRAM의 용량만으로 해당 CPU의 트랜잭션의 크기가 제한될 겁니다. 다른 방법들은 하드웨어 트랜잭션 메모리와 소프트웨어 트랜잭션 메모리의 조합을 사용하고 [KCH⁺06], HTM의 fallback 메커니즘으로 STM을 사용하는 방법을 생각해 볼 수도 있을 겁니다.

하지만, 제가 알기로는, 현재로써 사용 가능한 시스템들은 이런 연구 아이디어들을 구현한 바가 없습니다.

17.3.2.2 Conflict Handling

첫번째 문제는 *conflict* 의 가능성입니다. 예를 들어, transaction A 와 B 가 다음과 같이 정의되었다고 생각해 봅시다:

Transaction A	Transaction B
$x = 1;$	$y = 2;$
$y = 3;$	$x = 4;$

각각의 트랜잭션이 각자의 프로세서 위에서 동시에 수행된다고 생각해 봅시다. 만약 transaction A 가 x 에 쓰기를 하는 동시에 transaction B 가 y 에 쓰기를 한다면, 두 트랜잭션 모두 진행될 수 없습니다. 이를 보기 위해, transaction A 가 y 로의 쓰기를 수행한다고 생각해 봅시다. 그럼 transaction A 는 transaction B 와 섞여들어가게 되는데, 이는 트랜잭션이 상대방의 시점에 어토믹하게 수행되어야 한다는 트랜잭션의 요구사항을 위반하는 것입니다. Transaction B 가 x 로의 저장을 수행하게 허락한다면, 이는 비슷하게 어토믹 수행 요구 사항을 위반하는 것입니다. 이 상황은 *conflict* 라 명명되는데, 두개의 동시에 수행되는 트랜잭션들이 똑같은 변수에 접근하게 되며 그 접근들 가운데 최소한 하나는 쓰기인 경우에 발생합니다. 따라서 시스템은 수행이 진행될 수 있도록 하기 위해 이 트랜잭션들 가운데 하나나 두개 모두를 *abort* 시킬 의무를 갖습니다. 정확히 어떤 트랜잭션을 *abort* 시킬 것인가에 대한 선택은 Ph.D. 학위 논문을 만들 능력이 있을 만큼 흥미로운 주제인데, 그런 예 [ATC⁺11]도 있으니, 보시기 바랍니다.⁹ 이 섹션의 목적을 위해서, 우린 시스템이 무작위적 선택을 한다고 가정하겠습니다.

또하나의 문제는 *conflict* 파악으로, 적어도 가장 간단한 경우에 있어서는 비교적 간단한 편입니다. 프로세서가 트랜잭션을 수행할 때, 프로세서는 그 트랜잭션에 의해 접근되는 모든 캐시라인을 표시해 둡니다. 만약 이 프로세서의 캐시가 현재 트랜잭션에 의해 접근된 것으로 표시된 캐시라인에 대한 요청을 받게 되면, 잠재적 *conflict* 이 일어난 것입니다. 더 세련된 시스템들은 현재 프로세서의 트랜잭션이 그 요청을 보낸 프로세서의 트랜잭션을 앞서도록 순서잡을 것이고, 이 프로세스의 최적화는 또한 Ph.D. 학위논문을 쓰기 위한 능력을 얻을 수 있게 해줄 겁니다. 하지만 이 섹션은 매우 간단한 *conflict* 파악 전략을 가정합니다.

하지만, HTM 이 효율적으로 동작하려면 *conflict* 의 가능성이 충분히 낮아야 하는데, 이는 데이터 구조가 충분히 낮은 *conflict* 가능성을 유지하도록 구성되어야 할 것을 필요로 합니다. 예를 들어, 간단한 삽입, 삭제,

그리고 탐색 오퍼레이션을 제공하는 red-black 트리는 이런 경우에 적합합니다만, 트리의 모든 원소의 정확한 수를 유지해야 하는 red-black 트리는 그렇지 않습니다.¹⁰ 또 다른 예로, 트리의 모든 원소를 하나의 트랜잭션에서 열거하는 red-black 트리는 높은 *conflict* 확률을 가질 것이고, 성능과 확장성을 떨어뜨릴 겁니다. 결과적으로, 많은 순차적 프로그램들은 HTM 이 효과적으로 동작하도록 하기 위해 일부 재구성을 필요로 할 겁니다. 몇몇 경우에 있어서, 실무자들은 그런 추가적 단계를 취하거나 (red-black 트리의 경우에 있어서, radix 트리나 해시 테이블과 같은 파티셔닝 가능한 데이터 구조로의 전환 같은) 그냥 랙킹을 사용하는 것을 선호할 수 있는데, HTM 이 모든 관련된 구조에서 사용 가능하기 충분한 시간이 오기 전까지는 특히 그럴 수 있습니다 [Cli09].

Quick Quiz 17.4: 동기화 메커니즘의 선택에 관계 없이 어떻게 red-black 트리가 트리 내의 모든 원소의 열거를 효율적으로 할 수 있을까요???

더 나아가서, *conflict* 이 일어날 수 있다는 사실은 다음 섹션에 이야기되는 것처럼 *failure* 처리를 어떻게 할 것인지 그림을 가져올 수 있게 해줍니다.

17.3.2.3 Aborts and Rollbacks

모든 트랜잭션이 언제든 *abort* 될 수 있으므로, 트랜잭션은 롤백될 수 없는 명령을 포함해선 안된다는 점이 중요합니다. 이 말은 트랜잭션은 I/O, 시스템콜, 또는 디버깅 브레이크포인트 (HTM 트랜잭션에서의 디버거에서의 single step 수행이 안됩니다!!!!) 를 가질 수 없음을 의미합니다. 대신, 트랜잭션은 스스로를 평범한 캐시된 메모리에만 접근하도록 국한시켜야만 합니다. 더 나아가서, 일부 시스템에서는, 인터럽트, exception, trap, TLB 미스, 그리고 다른 이벤트들 역시 트랜잭션을 *abort* 시킵니다. 잘못된 에러 조건의 처리로 초래된 많은 수의 버그들을 생각해보면, 사용성을 위해 *abort* 와 *rollback* 이 어떤 효과를 갖는지 알아보는게 좋을 겁니다.

Quick Quiz 17.5: 하지만 왜 디버거는 트랜잭션의 앞의 인스턴스의 스텝들을 다시 추적하기 위해 재시도에 의존하면서 브레이크포인트를 트랜잭션의 성공되는 명령문 줄에 설정해 두는 것으로 single stepping 을 흉내낼 수 없나요?

물론, *abort* 와 롤백은 HTM 이 real-time 시스템에 유용할 수 있는 것인지를 질문을 떠올리게 합니다. HTM 의 성능적 이득이 *abort* 와 롤백의 비용을 넘을까요, 그리고 그렇다면 어떤 조건 하에서 그럴까요? 트랜잭션은 우선순위 향상 기능을 사용할 수 있을까요? 아니면 높은 우선순위 쓰레드를 위한 트랜잭션은 낮은 우선순위

⁹ “Toxic Transactions” 라는 제목의 Liu 와 Spear 의 논문 [LS11]은 이런 면에서 특히 유명합니다.

¹⁰ 이 수를 업데이트 해야할 필요성이 트리로의 삽입과 트리로부터의 삭제가 서로 *conflict* 를 발생시키게 해서 strong non-commutativity 를 초래할 겁니다 [AGH⁺11a, AGH⁺11b, McK11b].

쓰레드들을 우선적으로 *abort* 시켜야 할까요? 만약 그렇다면, 하드웨어는 어떻게 효율적으로 우선순위를 알 수 있을까요? 실제 세계에서의 HTM의 사용에 대한 환경은 협소한데, 연구자들이 트랜잭션들이 비 *real-time* 환경에서 잘 동작하기에는 충분한 것들보다도 더 많은 문제들을 찾고 있기 때문일 수도 있습니다.

현재의 HTM 구현들은 결정론적으로 특정 트랜잭션을 *abort* 시킬 수도 있기 때문에, 소프트웨어는 *fallback* 코드를 제공해야만 합니다. 이 *fallback* 코드는 예를 들면 락킹과 같은, 어떤 다른 형태의 동기화를 사용해야만 합니다. 만약 이 *fallback*이 빈번하게 사용된다면, 데드락의 가능성을 포함한 모든 락킹의 제한점들이 다시 나타납니다. 물론, 이 *fallback*이 자주 사용되지 않아서 더 간단하고 디드락이 나타나기 쉽지 않은 설계가 사용될 수 있게 되기를 바랄 수 있습니다. 하지만 이는 시스템은 락 기반의 *fallback*에서 트랜잭션으로 어떻게 전환할 것인지를 대한 질문을 떠올리게 합니다.¹¹ 한 가지 방법은 *test-and-test-and-set* 방법 [MT02]의 사용으로, 모두가 락이 해제될 때까지 기다림으로써 시스템이 트랜잭션적으로 깨끗한 백지 상태에서 시작할 수 있도록 하는 것입니다. 하지만, 이는 상당한 *spinning*을 초래할 수 있는데, 이는 락을쥔 쓰레드가 블락되어 있거나 *preemption* 당했다면 현명하지 못한 행위일 수 있습니다. 또 다른 방법은 트랜잭션이 락을쥔 쓰레드와 병렬적으로 수행될 수 있도록 하는 것 [MT02]입니다만, 이 방법은 원자성을 유지하는데에 어려움을 낳으며, 특히 그 쓰레드가 락을 잡고 있는 이유가 연관된 트랜잭션이 캐시에 들어가지 않기 때문이라면 더 그렇습니다.

마지막으로, *abort*와 룰백 가능성을 처리하는 것은 개발자에게 모든 가능한 여러 조건들의 조합을 올바르게 처리해야 한다는 추가적인 부담을 지우는 것으로 보일 수 있습니다.

HTM의 사용자들이 *fallback* 코드 수행경로와 *fallback*에서 트랜잭션 코드로의 전환 모두에 상당한 검증을 위한 노력을 기울여야 함은 분명합니다.

17.3.2.4 Lack of Forward-Progress Guarantees

트랜잭션 크기, *conflict*, 그리고 *abort/rollback*이 모두 트랜잭션을 *abort*되게 만들 수 있다고는 하지만, 충분히 작고 짧은 기간동안 수행되는 트랜잭션은 결국은 성공할 것이라 보장된다고 희망할 수 있을 것입니다. 이는 *compare-and-swap* (CAS)와 *load-linked/store-conditional* (LL/SC) 오퍼레이션들이 이 인스트럭션들을 어토믹 오퍼레이션을 구현하는데에 사용하는 코드에서 무조건적으로 재시도 되는 것과 똑같이 트랜잭션이 무

¹¹ 어플리케이션이 *fallback* 모드에서 멈춰서게 되는 가능성은 Dave Dice가 만드는데 기여한, “lemming effect”라고 명명되었습니다.

조건적으로 재시도 되도록 허용하도록 할 수 있을 것입니다.

불행히도, 대부분의 현재 사용 가능한 HTM 구현들은 어떤 종류의 진행 보장도 제공하지 않는데, 이는 HTM은 시스템의 데드락을 막는데에 사용될 수 없음을 의미합니다.¹² 미래의 HTM 구현은 어떤 진행 보장을 제공할 수도 있을 겁니다. 그러기 전까지는, HTM은 *real-time* 어플리케이션은 상당한 주의 아래 사용되어야만 합니다.¹³

2013년에 있어 이 우울한 그림에 대한 한가지 예외는 특수한 제약된 트랜잭션 [JSG12]을 시작하는데 사용되는 별도의 인스트럭션을 제공하는 IBM 메인프레임의 차기 버전들입니다. 이름에서 추측할 수 있듯이, 그런 트랜잭션은 다음과 같은 제약 아래에 살아남을 수 있어야만 합니다:

1. 각각의 트랜잭션의 데이터 사용량은 4개의 32-byte 메모리 블락 안에 들어갈 수 있어야만 합니다.
2. 각각의 트랜잭션은 최대 32개의 어셈블러 인스트럭션을 수행하도록 허용됩니다.
3. 트랜잭션은 뒤로 돌아가는 브랜치 (e.x: 루프를 가질 수 없음)를 가질 수 없습니다.
4. 각각의 트랜잭션의 코드는 256 바이트의 메모리로 제한됩니다.
5. 특정 트랜잭션의 데이터 사용량의 한 부분이 4K 페이지 안에 위치한다면, 그 4K 페이지는 트랜잭션의 인스트럭션을 담을 수 없습니다.

이런 제약은 가혹합니다만, 이는 더도 아니고 덜도 아니고 스택, 큐, 해시 테이블, 등을 포함해서 다양한 데이터 구조의 업데이트가 구현될 수 있도록 합니다. 이런 오퍼레이션들은 결국은 완료될 것이 보장되고, 따라서 데드락과 라이브락 조건으로부터 자유롭습니다.

시간의 흐름에 따라 하드웨어의 진행 보장이 얼마나 지우너될 것인지 보는 것은 꽤 흥미로울 것입니다.

17.3.2.5 Irrevocable Operations

*Abort*와 룰백의 또 다른 결론은 HTM 트랜잭션은 되돌이켜질 수 없는 오퍼레이션들을 담을 수 없다는 것입니다. 현재의 HTM 구현들은 일반적으로 트랜잭션 안에서의 모든 액세스가 캐시될 수 있는 메모리 안으로만 국한되도록 하고 (따라서 MMIO 액세스를 금지하고) 인터럽트,

¹² HTM은 데드락의 가능성을 줄이는데 사용될 수는 있습니다만, *fallback* 코드가 수행될 가능성이 존재하는 한, 데드락의 가능성은 존재합니다.

¹³ 2012년 중반까지는, 트랜잭션의 메모리의 *real-time* 특성에 대해서는 놀라만큼 적은 작업만이 있었습니다.

trap, 그리고 exception 시에는 트랜잭션을 어보팅 시키는 것으로 (따라서 시스템콜을 금지시키는 것으로) 이제한을 강제합니다.

HTM 트랜잭션은 buffered I/O 역시 버퍼의 fill/flush 오퍼레이션이 트랜잭션 외에서 일어나는 한은 담겨질 수 있음을 알아두시기 바랍니다. 이게 동작하는 이유는 버퍼에 데이터를 넣고 빼는 것은 되돌이켜질 수 있기 때문입니다: 실제 버퍼 fill/flush 오퍼레이션들만이 되돌이켜질 수 없습니다. 물론, 이 buffered-I/O 방법은 I/O 를 트랜잭션의 흔적에 포함시키는 효과를 내서, 트랜잭션의 크기를 키우고 그로 인해 트랜잭션 실패 확률을 증가시킵니다.

17.3.2.6 Semantic Differences

HTM 이 많은 경우에 락킹의 대체제로 사용될 수 있는 하지만 (그래서 transactional lock elision [DHL⁺08] 이란 명칭이 있습니다), semantic 상에 약간의 차이가 있습니다. 트랜잭션으로 수행되면 deadlock이나 livelock을 초래할 수 있는 락 기반의 크리티컬 섹션과 연관된 특히 골치아픈 예가 Blundell에 의해 알려졌습니다만 [BLM06], 훨씬 간단한 예는 텅 빈 크리티컬 섹션입니다.

락 기반의 프로그램에서, 텅 빈 크리티컬 섹션은 기준에 그 락을 쥐고 있던 모든 프로세스들이 지금은 그것을 해제한 상태일 것을 보장합니다. 이 idiom은 2.4 리눅스 커널의 네트워킹 스택에서 설정 변경을 조정하기 위해 사용되었습니다. 하지만 이 텅 빈 크리티컬 섹션이 트랜잭션으로 변환된다면, 그 결과는 no-op입니다. 모든 앞의 크리티컬 섹션들이 종료되었을 것이라는 보장은 사라집니다. 달리 말해서, transactional lock elision은 락킹의 데이터 보호 semantic을 유지하지만 락킹의 시간에 기반한 메세지 semantic은 잊어버립니다.

Quick Quiz 17.6: 하지만 누가 텅 빈 락 기반의 크리티컬 섹션을 필요로 하나요???

Quick Quiz 17.7: 락 기반의 텅 빈 크리티컬 섹션들을 생략하지 않는 방법으로 간단하게 락킹의 시간 기반 메세지 semantic을 transactional lock elision에서 처리할 수는 없을까요?

Quick Quiz 17.8: 최신 하드웨어 [MOZ09]에서, 누가 병렬 소프트웨어가 타이밍에 의존해서 동작할 거라고 기대할 수 있겠습니까?

락킹과 트랜잭션 사이의 중요한 semantic 상의 차이 하나는 락 기반의 real-time 프로그램에서 우선순위 역전을 막기 위해 상요되는 priority boosting입니다. 우선순위 역전이 일어날 수 있는 한가지 경우는 락을 쥐고 있는 낮은 우선순위의 쓰레드가 중간 우선순위의 CPU를 많이 사용하는 쓰레드에 의해 preemption 당하는 경우입니다. 만약 CPU마다 그런 중간 우선순위 쓰레드가 최소 하나씩은 있다면, 낮은 우선순위 쓰레드는 수행될 기회를 결코 얻지 못할 겁니다. 만약 높은 우선순위

Listing 17.1: Exploiting Priority Boosting

```

1 void boostee(void)
2 {
3     int i = 0;
4
5     acquire_lock(&boost_lock[i]);
6     for (;;) {
7         acquire_lock(&boost_lock[!i]);
8         release_lock(&boost_lock[i]);
9         i = i ^ 1;
10        do_something();
11    }
12 }
13
14 void booster(void)
15 {
16     int i = 0;
17
18     for (;;) {
19         usleep(1000); /* sleep 1 ms. */
20         acquire_lock(&boost_lock[i]);
21         release_lock(&boost_lock[i]);
22         i = i ^ 1;
23     }
24 }
```

쓰레드가 이제 그 락을 얻으려 시도하면, 이 쓰레드는 블록될 겁니다. 이 쓰레드는 낮은 우선순위 쓰레드가 락을 놓기 전까지는 그 락을 얻지 못할 것이고, 이 낮은 우선순위 쓰레드는 수행될 기회를 얻기 전까지는 그 락을 해제하지를 못할 것이며, 낮은 우선순위 쓰레드는 중간 우선순위 쓰레드가 CPU를 놓기 전까지는 수행될 기회를 얻지를 못할 겁니다. 따라서, 중간 우선순위 쓰레드는 실질적으로 높은 우선순위 프로세스를 블록하고 있는 셈인데, 이게 바로 “우선순위 역전”이라 불리는 이유입니다.

우선순위 역전을 막기 위한 한가지 방법은 *priority inheritance*로, 락에 의해 블록된 높은 우선순위 쓰레드가 임시적으로 자신의 우선순위를 락을 쥔 쓰레드에게 넘겨주는 것인데, *priority boosting*이라고도 불립니다. 하지만, *priority boosting*은 우선순위 역전을 막는 것 외에도 Listing 17.1에 보여진 것처럼도 사용될 수 있습니다. 이 그림의 line 1-12는 매 밀리세컨드마다 수행되어야 하는 낮은 우선순위 프로세스를 보이고 있고, line 14-24는 *boostee()*가 주기적으로 필요한 만큼 수행되는 것을 보장하기 위해 *priority boosting*을 사용하는 높은 우선순위 프로세스를 보입니다.

boostee() 함수는 두개의 *boost_lock[]* 락들 가운데 하나를 항상 쥐고 있어서 *booster()*의 line 20-21이 우선순위를 필요로 만큼 증폭시킬 수 있게 함으로써 이를 가능하게 합니다.

Quick Quiz 17.9: 하지만 Listing 17.1의 *boostee()* 함수는 그 락을 반대 순서로 잡고 있어요! 이는 deadlock을 초래할 수 있지 않을까요?

이 구조는 *boostee()*가 시스템이 바빠지기 전에 line 5에서 첫번째 락을 잡을 것을 필요로 합니다만,

이는 최신 하드웨어에서 조차도 쉽게 가능합니다.

안타깝게도, 이 구조는 transactional lock elision의 존재 하에서는 깨질 수 있습니다. `boostee()` 함수의 겹쳐지는 크리티컬 섹션들은 잠시 후든 나중이든 `abort` 될 하나의 무한한 트랜잭션이 되어버리는데, 예를 들면 `boostee()` 함수를 수행하는 쓰레드가 `preemption` 당하는 첫 번째 시점이 되겠습니다. 이 시점에서, `boostee()`는 락킹으로 물러나게 됩니다만, 그 낮은 우선순위와 초기화 단계가 완료되었다는 사실 때문에 (이게 바로 `boostee()`가 `preemption`을 당한 이유입니다), 이 쓰레드는 다시 수행될 기회를 얻지 못하게 됩니다.

그리고 만약 `boostee()` 쓰레드가 락을 잡고 있지 않다면, `booster()` 쓰레드의 Listing 17.1 line 20 과 21에서의 텅빈 크리티컬 섹션은 아무런 효과를 갖지 못하는 텅빈 트랜잭션이 되어서, `boostee()`는 결코 수행되지 않을 겁니다. 이 예는 트랜잭션 메모리의 `rollback-and-retry` 시맨틱의 미묘한 결론을 그리고 있습니다.

경험이 추가적인 묘한 semantic 상의 차이를 더 드러낼 것인데, HTM 기반의 lock elision의 커다란 프로그램으로의 적용은 주의 하에 이루어져야 합니다. 그렇다면 하나, 적용이 되는 곳이라면, HTM 기반 lock elision은 해당 락 변수에 연관된 캐시 미스들을 제거할 수 있어서 2015년 초에 있어서 실제 세계의 커다란 소프트웨어 시스템들에서는 수십 퍼센트의 성능 향상을 가져옵니다. 따라서 우리는 이 기술을 지원하는 하드웨어에서의 이 테크닉의 상당한 사용을 기대합니다.

Quick Quiz 17.10: 그래서 많은 사람들이 락킹을 대신하는 작업을 시작하고는 대부분은 락킹을 최적화하는 것으로 결론을 내리나요???

17.3.2.7 Summary

HTM이 강력한 사용 예들을 갖는 것처럼 보이긴 하지만, 현재의 구현들은 주의 깊은 처리를 필요로 하는, 트랜잭션 크기, conflict 처리의 복잡성, `abort-and-rollback` 이슈, 그리고 semantic 상의 차이와 같은 심각한 한계들을 가지고 있습니다. HTM의 현재 상황이 락킹과 비교해서 Table 17.1에 요약되어 있습니다. 보여지듯이, HTM의 현재 상황이 락킹의 일부 심각한 단점을 경감시키긴 하지만,¹⁴ HTM 역시 그 자체의 상당히 많은 단점을 포함하고 있습니다. 이러한 단점들은 TM 커뮤니티의

리더들에 의해서도 인정된 바 있습니다 [MS12].¹⁵

또한, 이게 전부가 아닙니다. 락킹은 일반적으로 그 자체만으로 사용되지 않고, 보통 레퍼런스 카운팅, 어토믹 오퍼레이션, non-blocking 데이터 구조, 해저드 포인터 [Mic04, HLM02], 그리고 read-copy update (RCU) [MS98a, MAK⁺01, HMBW07, McK12a] 등과 같은 다른 동기화 메커니즘들과 결합되어 사용됩니다. 다음 섹션은 그러한 결합이 이 수식을 어떻게 바꾸어놓는지 봅니다.

17.3.3 HTM Weaknesses WRT to Locking When Augmented

실무자들은 락킹의 일부 단점을 막기 위해 오랫동안 레퍼런스 카운팅, 어토믹 오퍼레이션, non-blocking 데이터 구조, 해저드 포인터, 그리고 RCU를 사용해 왔습니다. 예를 들어, deadlock은 많은 경우에 레퍼런스 카운트, 해저드 포인터, 또는 RCU를 데이터 구조를 보호하는데 사용함으로써 막아질 수 있고, 특히나 read-only 크리티컬 섹션에서는 그렇습니다 [Mic04, HLM02, DMS⁺12, GMTW08, HMBW07]. 이 방법은 또한 Chapter 10에서 봤던 것처럼 데이터 구조를 분할할 필요를 줄여줍니다. RCU는 더 나아가서 contention에서 자유로운 wait-free read-side 기능들을 제공합니다 [DMS⁺12]. 이런 점을 Table 17.1에 추가하면 Table 17.2에 보인, augmented locking과 HTM 사이의 업데이트된 비교가 나옵니다. 두 개의 표간의 차이점을 요약해보면 다음과 같습니다:

1. Non-blocking read-side 메커니즘의 사용은 deadlock 문제를 줄여줍니다.
2. 해저드 포인터와 RCU와 같은 Read-side 메커니즘들은 분할이 불가능한 데이터에서 효과적으로 동작할 수 있습니다.
3. 해저드 포인터와 RCU는 서로간에 또는 업데이트 쓰레드와 충돌하지 않아서, 읽기가 대부분인 워크로드에서는 훌륭한 성능과 확장성을 제공합니다.
4. 해저드 포인터와 RCU는 진행 보장을 제공합니다 (각각 lock freedom과 wait-freedom을 제공합니다).
5. 해저드 포인터와 RCU에서의 privatization 오퍼레이션들은 간단합니다.

시력이 좋은 분들을 위해, Table 17.3은 Table 17.1과 17.2를 조합합니다.

¹⁴ 공정성을 위해 말해두자면, 락킹의 단점들은 잘 알려져 있고 널리 사용되고 있는 deadlock detector [Cor06a], 락킹에 적용된 데이터 구조의 풍부함, 그리고 Section 17.3.3에서 이야기한 것과 같이 결합되어 사용되어온 긴 역사를 포함한, 엔지니어링 단계에서의 해결책들이 있음을 강조해둘 필요가 있습니다. 한가지 더 말하자면, 락킹이 정말로 많은 학계의 논문들을 살짝만 보아도 믿어질 만큼 끔찍한 것 이었다면, 그 수많은 락 기반의 (FOSS와 독점의) 병렬 프로그램들은 대체 어디서 나왔을까요?

¹⁵ 또한, 2011년 초에, 저는 트랜잭션 메모리를 둘러싼 일부 가정에 대한 비평을 하도록 초대된 바 있습니다 [McK11d]. 제가 발표를 하기 위해 시차에 매우 시달렸기 때문에 저를 편하게 해주기 위해서 였을지는 몰라도, 청중은 놀라우리만큼 적대적이지 않았습니다.

Table 17.1: Comparison of Locking and HTM (**Advantage** , **Disadvantage** , **Strong Disadvantage**)

	Locking	Hardware Transactional Memory
Basic Idea	Allow only one thread at a time to access a given set of objects.	Cause a given operation over a set of objects to execute atomically.
Scope	Handles all operations.	Handles revocable operations. Irrevocable operations force fallback (typically to locking).
Composability	Limited by deadlock.	Limited by irrevocable operations, transaction size, and deadlock (assuming lock-based fallback code).
Scalability & Performance	Data must be partitionable to avoid lock contention.	Data must be partitionable to avoid conflicts.
	Partitioning must typically be fixed at design time.	Dynamic adjustment of partitioning carried out automatically down to cacheline boundaries. Partitioning required for fallbacks (less important for rare fallbacks).
	Locking primitives typically result in expensive cache misses and memory-barrier instructions.	Transactions begin/end instructions typically do not result in cache misses, but do have memory-ordering consequences.
	Contention effects are focused on acquisition and release, so that the critical section runs at full speed.	Contention aborts conflicting transactions, even if they have been running for a long time.
	Privatization operations are simple, intuitive, performant, and scalable.	Privatized data contributes to transaction size.
Hardware Support	Commodity hardware suffices.	New hardware required (and is starting to become available).
	Performance is insensitive to cache-geometry details.	Performance depends critically on cache geometry.
Software Support	APIs exist, large body of code and experience, debuggers operate naturally.	APIs emerging, little experience outside of DBMS, breakpoints mid-transaction can be problematic.
Interaction With Other Mechanisms	Long experience of successful interaction.	Just beginning investigation of interaction.
Practical Apps	Yes.	Yes.
Wide Applicability	Yes.	Jury still out, but likely to win significant use.

Table 17.2: Comparison of Locking (Augmented by RCU or Hazard Pointers) and HTM (**Advantage** , **Disadvantage** , **Strong Disadvantage**)

	Locking with Userspace RCU or Hazard Pointers	Hardware Transactional Memory
Basic Idea	Allow only one thread at a time to access a given set of objects.	Cause a given operation over a set of objects to execute atomically.
Scope	Handles all operations.	Handles revocable operations. Irrevocable operations force fallback (typically to locking).
Composability	Readers limited only by grace-period-wait operations. Updaters limited by deadlock. Readers reduce deadlock.	Limited by irrevocable operations, transaction size, and deadlock. (Assuming lock-based fallback code.)
Scalability & Performance	Data must be partitionable to avoid lock contention among updaters. Partitioning not needed for readers. Partitioning for updaters must typically be fixed at design time. Partitioning not needed for readers. Updater locking primitives typically result in expensive cache misses and memory-barrier instructions. Update-side contention effects are focused on acquisition and release, so that the critical section runs at full speed. Readers do not contend with updaters or with each other. Read-side primitives are typically wait-free with low overhead. (Lock-free for hazard pointers.) Privatization operations are simple, intuitive, performant, and scalable when data is visible only to updaters. Privatization operations are expensive (though still intuitive and scalable) for reader-visible data.	Data must be partitionable to avoid conflicts. Dynamic adjustment of partitioning carried out automatically down to cacheline boundaries. Partitioning required for fallbacks (less important for rare fallbacks). Transactions begin/end instructions typically do not result in cache misses, but do have memory-ordering consequences. Contention aborts conflicting transactions, even if they have been running for a long time. Read-only transactions subject to conflicts and rollbacks. No forward-progress guarantees other than those supplied by fallback code. Privatized data contributes to transaction size.
Hardware Support	Commodity hardware suffices. Performance is insensitive to cache-geometry details.	New hardware required (and is starting to become available). Performance depends critically on cache geometry.
Software Support	APIs exist, large body of code and experience, debuggers operate naturally.	APIs emerging, little experience outside of DBMS, breakpoints mid-transaction can be problematic.
Interaction With Other Mechanisms	Long experience of successful interaction.	Just beginning investigation of interaction.
Practical Apps	Yes.	Yes.
Wide Applicability	Yes.	Jury still out, but likely to win significant use.

Table 17.3: Comparison of Locking (Plain and Augmented) and HTM (Advantage, Disadvantage, Strong Disadvantage)

	Locking	Locking with Userspace RCU or Hazard Pointers	Hardware Transactional Memory
Basic Idea	Allow only one thread at a time to access a given set of objects.	Allow only one thread at a time to access a given set of objects.	Cause a given operation over a set of objects to execute atomically.
Scope	Handles all operations.	Handles all operations.	Handles revocable operations.
Composability	Limited by deadlock.	Readers limited only by grace-period-wait operations.	Limited by irrevocable operations, transaction size, and deadlock. (Assuming lock-based fallback code.)
Scalability & Performance	Data must be partitionable to avoid lock contention.	Data must be partitionable to avoid conflicts.	Irrevocable operations force fallback (typically to locking).
Partitioning	Partitioning must typically be fixed at design time.	Partitioning for updaters must typically be fixed at design time.	Partitioning required for fallbacks (less important for rare fallbacks).
	Locking primitives typically result in expensive cache misses and memory-barrier instructions.	Updater locking primitives typically result in expensive cache misses and memory-barrier instructions.	Transactions begin/end instructions typically do not result in cache misses, but do have memory-ordering consequences.
	Contention effects are focused on acquisition and release, so that the critical section runs at full speed.	Update-side contention effects are focused on acquisition and release, so that the critical section runs at full speed.	Contention aborts conflicting transactions, even if they have been running for a long time.
	Readers do not contend with updaters or with each other.	Readers do not contend with updaters or with each other.	
	Read-side primitives are typically wait-free with low overhead. (Lock-free for hazard pointers.)	Read-only transactions subject to conflicts and rollbacks. No forward-progress guarantees other than those supplied by fallback code.	
Privatization	Privatization operations are simple, intuitive, performant, and scalable.	Privatization operations are simple, intuitive, performant, and scalable when data is visible only to updaters.	Privatized data contributes to transaction size.
	Privatization operations are expensive (though still intuitive and scalable) for reader-visible data.	Privatization operations are expensive (though still intuitive and scalable) for reader-visible data.	
Hardware Support	Commodity hardware suffices.	Commodity hardware suffices.	New hardware required (and is starting to become available).
Performance	Performance is insensitive to cache-geometry details.	Performance is insensitive to cache-geometry details.	Performance depends critically on cache geometry.
Software Support	APIs exist, large body of code and experience, debuggers operate naturally.	APIs exist, large body of code and experience, debuggers operate naturally.	APIs emerging, little experience outside of DBMS, breakpoints mid-transaction can be problematic.
Interaction With Other Mechanisms	Long experience of successful interaction.	Long experience of successful interaction.	Just beginning investigation of interaction.
Practical Apps	Yes.	Yes.	Yes.
Wide Applicability	Yes.	Yes.	Jury still out, but likely to win significant use.

물론, 다음 섹션에서 논의하듯이 HTM 을 다른 기능들과 결합하는 것도 가능합니다.

17.3.4 Where Does HTM Best Fit In?

HTM 의 적용 영역이 page 145 의 Figure 9.23 에 보여진 RCU 처럼 그려지기 전인 것 같긴 하지만, 그런 방향으로 움직이기 시작하지 않을 이유는 없습니다.

HTM 은 커다란 멀티프로세서에서 돌아가는 상대적으로 커다란 in-memory 데이터 구조의 겹치지 않는 영역에 대한 상대적으로 작은 변경에 연관된 업데이트 위주의 워크로드에 들어맞을 텐데, 이런 워크로드는 현재 HTM 구현의 크기 제약을 맞출 수 있고 conflict 과 그로인한 abort 와 롤백의 확률을 최소화 시켜줄 것이기 때문입니다. 이 시나리오는 현재의 동기화 도구들을 가지고는 처리하기가 상대적으로 어려운 시나리오이기도 합니다.

HTM 과 함께 락킹을 사용하는 것은 돌이킬 수 없는 오퍼레이션들에 대한 HTM 의 어려움을 극복해줄 수 있을 것으로 보이며, RCU 나 해저드 포인터의 사용은 데이터 구조의 커다란 부분을 횡단하는, read-only 오퍼레이션들에 대해서 HTM 의 트랜잭션 크기 제한을 해결해 줄 수 있을 것입니다. 현재의 HTM 구현들은 RCU 나 해저드 포인터 읽기 쓰레드와 conflict 나는 업데이트 트랜잭션을 무조건적으로 abort 시키고 있지만, 미래의 HTM 구현들은 이런 동기화 메커니즘들과 더 부드럽게 작용할 것입니다. 그전까지는, 커다란 RCU 나 해저드 포인터 read-side 크리티컬 섹션과 conflict 나는 업데이트의 확률은 동일한 read-only 트랜잭션과 conflict 날 확률에 비해 훨씬 작아야 합니다.¹⁶ 더도 아니고 덜도 아니고, RCU 나 해저드 포인터 읽기 쓰레드들의 느린 흐름이 연관된 conflict 의 느린 흐름으로 인해 업데이트 쓰레드를 starve 시킬 수도 있습니다. 이런 취약점은 앞의 트랜잭션의 로드된 메모리 로케이션의 복사본에 대한 트랜잭션 외적인 읽기 방법을 제공하는 것으로 (상당한 하드웨어 비용과 복잡성을 요하겠지만) 제거될 수도 있습니다.

HTM 트랜잭션들이 fallback 을 가져야만 한다는 사실로 인해 어떤 경우에는 데이터 구조들의 정적 분할 가능성을 강제해야만 할 수도 있습니다. 이 제약점은 미래의 HTM 구현들이 진행 보장을 제공한다면 어떤 경우에는 fallback 코드의 필요성을 제거할 것이므로 없어질 수 있을 것인데, 이는 HTM 이 높은 conflict 확률 아래의 환경에서도 효과적으로 사용될 수 있을 것입니다.

¹⁶ NoSQL 데이터베이스들이 데이터베이스 어플리케이션의 엄격한 트랜잭션에의 의존도를 완화시키고 있는 상황에서 shared-memory 시스템에서는 엄격한 트랜잭션 메커니즘이 떠오르는 것은 상당히 아이라고 합니다. 하지만, HTM 은 리눅스 커널의 address-space randomization 방어 메커니즘으로의 black-hat 공격 덕분에 [JLK16a, JLK16b] HTM 이 쓰기 쉽다는게 확실해졌습니다.

요약하자면, HTM 이 중요한 사용과 응용 분야를 가질 수 있을 것이지만, 병렬 프로그래머의 도구상자의 또 다른 도구일 뿐이지, 도구상자 전체의 대체제는 아닙니다.

17.3.5 Potential Game Changers

HTM 의 필요성을 상당히 증가시킬 Game changer 들은 다음과 같은 것들이 있습니다:

1. 진행 보장.
2. 트랜잭션 크기 증가.
3. 개선된 디버깅 지원.
4. 완화된 원자성.

이것들은 다음 섹션들에서 확장되어 설명됩니다.

17.3.5.1 Forward-Progress Guarantees

Section 17.3.2.4 에서 논의한 것과 같이, 현재의 HTM 구현들은 진행 보장을 갖지 않아서 HTM 의 실패된 트랜잭션을 처리하기 위한 fallback 소프트웨어를 필요로 합니다. 물론, 보장을 추가하는 건 쉽습니다만, 그걸 제공하는건 항상 쉽지는 않습니다. HTM 의 경우에, 보장을 제공하는데 걸리는 문제는 캐시 크기와 캐시 associativity, TLB 크기와 TLB associativity, 트랜잭션의 시간적 길이와 인터럽트 빈도, 그리고 스케줄러 구현 등이 포함됩니다.

캐시 크기와 캐시 associativity 는 Section 17.3.2.1 에서 현재의 한계점들을 우회하기 위한 일부 연구 작업들과 함께 논의된 바 있습니다. 하지만, HTM 의 진행 보장은 크기에 대해 한계와 함께 제공될 겁니다. 그런데 현재의 HTM 구현들은, 예를 들자면 캐시의 associativity 의 한계에 맞춰진 작은 트랜잭션들에 대해서는 진행 보장을 제공하지 않는 걸까요? 한가지 잠재적인 이유는 하드웨어 failure 를 처리해야 하는 필요성일 수 있습니다. 예를 들어, 문제가 생긴 캐시의 SRAM 셀은 해당 문제가 생긴 셀을 비활성화 시키는 것으로 처리될 수 있는데, 이는 캐시의 associativity 를 줄이게 되고 따라서 진행 보장이 제공될 수 있느니 트랜잭션의 최대 크기 역시 줄이게 됩니다. 이는 단순히 보장된 트랜잭션 크기를 줄일 뿐이란 점을 생각해 보면, 실제로는 다른 이유들도 있을 것으로 보입니다. 제품 수준의 하드웨어에서 진행 보장을 제공하는 것은 아마도 소프트웨어에서 진행 보장을 제공하는데 걸리는 어려움보다도 더 어려울 수 있습니다. 따라서 문제를 더 쉽게 풀기 위해, 문제를 소프트웨어에서 하드웨어로 옮기는 게 필요합니다.

물리적으로 tag 되고 index 되는 캐시에 있어서는 트랜잭션이 캐시 안에 들어간다는 것만으로는 충분치 않습니다. 여기서는 주소변환이 TLB에 들어 맞기도 해야 합니다. 따라서 모든 진행 보장은 TLB 크기와 TLB associativity도 신경을 써야 합니다.

현재의 HTM 구현들에서는 인터럽트, trap, 그리고 exception이 트랜잭션을 abort 시킨다는 점을 생각해 보면, 특정 트랜잭션의 수행 시간 길이가 인터럽트 간의 예상되는 시간 간격보다 짧아야 할 필요가 있습니다. 특정 트랜잭션이 얼마나 적은 데이터만 건드리는가와는 관계 없이, 너무 오랫동안 수행된다면, 해당 트랜잭션은 abort 될겁니다. 따라서, 모든 진행 보장은 트랜잭션 크기만이 아니라 트랜잭션 수행시간에 대해서도 조정되어야만 합니다.

진행 보장은 conflict 되는 여러개의 트랜잭션들 가운데 어떤 트랜잭션이 aobrt 되어야 하는지 결정하는 능력에도 특히 의존적입니다. 각각 앞의 트랜잭션을 aobrt시키고 자기 자신도 뒤의 트랜잭션에 대해서 aobrt 되어서 어떤 트랜잭션도 실질적으로 커밋하지 못하는 무한한 트랜잭션의 연속을 쉽게 생각해 볼 수 있습니다. Conflict 처리의 복잡성은 제안된 바 있는 많은 수의 HTM conflict 해결 정책들 [ATC⁺11, LS11]로 알 수 있습니다. 트랜잭션 외적인 액세스들로 인해 추가적인 복잡성들이 나타나는데, Blundell에 의해 알려졌습니다 [BLM06]. 이런 모든 문제들에 대해서 트랜잭션 외적인 액세스들을 탓하기는 쉽습니다만, 이런 생각의 어리석음은 각각의 트랜잭션 외적인 액세스를 그 자신만의 하나의 액세스로 구성된 트랜잭션으로 교체함으로써 쉽게 드러납니다. 이는 그 자체로 문제인 액세스 패턴이지, 그것들이 트랜잭션 안에서 일어나느냐 아니냐의 문제가 아닙니다.

마지막으로, 트랜잭션을 위한 모든 진행 보장은 해당 트랜잭션을 수행하는 쓰레드가 커밋을 성공하기에 충분할 만큼 길게 수행될 수 있도록 해줄 수 있는 스케줄러에 의존적입니다.

따라서 진행 보장을 제공하는 HTM 제작사들에게는 상당한 문제가 존재합니다. 하지만, 그것들을 해결하면 얻을 수 있는 효과는 대단합니다. 그렇게 되면 HTM 트랜잭션은 소프트웨어 fallback이 더이상 필요없어지는 데, 이는 HTM은 마침내 TM의 deadlock 제거의 약속을 선사하게 됨을 의미합니다.

그리고 2012년 말, IBM Mainframe은 일반적인 최선의 HTM 구현에 대해서 *constrained transaction*을 포함하는 HTM 구현을 발표했습니다 [JSG12]. *constrained transaction*은 best-effort 트랜잭션을 시작하는데 사용되는 `tbegin` 명령과 달리 `tbegininc` 명령으로 시작됩니다. *Constrained transaction*은 항상 (결국은) 성공할 것이 보장되어 있으며, 따라서 만약 어떤 트랜잭션이 abort된다면, (best-effort 트랜잭션이 그렇듯이) fallback path로

분기되기보다는 하드웨어가 그 트랜잭션을 `tbegininc` 명령으로부터 재시작 시킵니다.

이 Mainframe 구조는 이 진행 보장을 위해서 상당한 측정을 해야 했습니다. 특정 constrained transaction이 반복적으로 실패한다면, 이 CPU는 branch prediction을 비활성화하고, in-order execution을 강제하고, 심지어 pipelining을 비활성화 시킬 수도 있습니다. 만약 반복된 failure가 높은 contention 때문이라면, CPU는 speculative fetch를 비활성화하고, 무작위적 delay를 집어넣고, 심지어 충돌하는 CPU들의 수행을 직렬화 시킬 수조차 있습니다. “흥미로운” 진행 보장 시나리오는 두개의 CPU만이 관여될 수도, 백개의 CPU들이 관여될 수도 있습니다. 아마도 이런 상당한 측정은 왜 다른 CPU들이 constrained transaction을 제공하는 것을 그렇게도 자제했는지에 대한 이해를 일부 제공합니다.

그 이름이 이야기 하듯이, constrained transaction은 실제로 상당히 제약되어 있습니다:

1. 최대 데이터 사용량은 메모리의 4개 블럭으로 제한되는데, 각각의 블럭은 32 바이트 이상이 될 수 없습니다.
2. 최대 코드 크기는 256 바이트입니다.
3. 만약 특정 4K 페이지가 constrained transaction의 코드를 담고 있다면, 해당 페이지는 그 트랜잭션의 데이터를 담고 있을 수 없습니다.
4. 실행될 수 있는 assembly 인스트럭션의 최대 갯수는 32입니다.
5. 뒤 방향으로의 분기는 금지됩니다.

더도 아니고 덜도 아니고, 이러한 제약들은 링크드리스트, 스택, 큐, 그리고 배열과 같은 여러개의 중요한 데이터 구조들을 지원합니다. 따라서 constrained HTM은 병렬 프로그래머의 도구상자에서 중요한 도구가 될 수 있을 것으로 보입니다.

이런 진행 보장성은 절대적일 필요는 없다는 것을 알 아두시기 바랍니다. 예를 들어, HTM의 사용이 fallback으로 global lock을 사용한다고 생각해 봅시다. 이 fallback 메커니즘이 Section 17.3.2.3에서 이야기된 “lemming effect”를 피할 수 있도록 잘 설계되었다고 하면, HTM 롤백들이 충분히 드물게 일어난다면, 이 global lock은 병목이 되지 않을 겁니다. 그렇다면 하나, 시스템이 커질수록, 크리티컬 섹션이 길어질수록, “lemming effect”로부터 회복되는데 필요한 시간이 길어질수록, 더욱 드문 “충분한 드물음”이 필요해질 겁니다.

17.3.5.2 Transaction-Size Increases

진행 보장은 중요하지만, 우리가 봤듯이, 트랜잭션 크기와 시간에 기반한 조건적 보장이 될 겁니다. 작은 크기의

트랜잭션에 대한 보장도 상당히 유용함을 알아둘 것이 필요합니다. 예를 들어, 두개의 캐시 라인 크기에 대한 보장은 스택, 큐, `dequeue`에 충분합니다. 하지만, 더 큰 데이터 구조는 더 큰 트랜잭션에 대한 보장을 필요로 하는데, 예를 들어 `tree` 를 순서대로 횡단하는데에는 `tree`의 노드의 수만큼의 크기에 대한 보장이 필요합니다.

따라서, 보장의 크기를 늘리는 것은 HTM 의 유용성 역시 늘려주고, 따라서 CPU 들이 HTM 을 제공하거나 훌륭하고 충분한 우회적 해결방법을 제공할 필요를 증가시킵니다.

17.3.5.3 Improved Debugging Support

트랜잭션 크기에 대한 또 다른 억제 요소는 트랜잭션을 디버깅 해야할 필요입니다. 현재 메커니즘에서의 문제는 *single-step exception* 이 자신을 둘러싼 트랜잭션을 `abort` 시킨다는 것입니다. 이 문제를 위한 우회적 해결 방법으로 프로세서 애뮬레이션 (느려요!), HTM 을 STM 으로의 대체 (느리고 시맨틱이 약간 다릅니다!), 진행을 애뮬레이션 하기 위한 반복적 재시도를 사용한 *playback* 테크닉 (이상한 *failure* 모드가 존재합니다!), 그리고 HTM 트랜잭션에서의 디버깅 지원 (복잡해요!) 등의 여러가지 방법들이 있습니다.

HTM 제조사들 가운데 누군가는 브레이크포인트, *single stepping*, 그리고 *print* 명령을 포함한 고전적인 디버깅 방법을 트랜잭션 안에서 사용할 수 있는 간단한 방법을 가능하게 하는 HTM 시스템을 제공해야 하며, 이는 HTM 을 더욱 강력하게 만들어줄 겁니다. 2013년에 이르러, 일부 트랜잭션 메모리 연구자들은 이 문제를 인식하고 있으며 하드웨어가 돋는 디버깅 기능들에 관한 제안도 있습니다 [GKP13]. 물론, 이 제안은 그런 기능들을 실제로 가지고 있고 사용할 수 있는 하드웨어에 의존적입니다.

17.3.5.4 Weak Atomicity

HTM 이 가까운 미래에 어떤 종류의 크기 제한을 갖게 될 것이라는 점을 놓고 보면, HTM 은 다른 메커니즘들과 부드럽게 연동될 수 있어야 할겁니다. 해저드 포인터와 RCU 같은 읽기가 대부분인 경우를 위한 메커니즘들과 HTM 의 연동 능력은 트랜잭션 외적인 읽기가 같은 목적이에 쓰기를 하는 트랜잭션을 무조건적으로 `abort` 시키지 않는다면 개선될 수 있을 겁니다—대신, 해당 읽기는 간단히 해당 트랜잭션 전의 값을 얻어올 수 있을 겁니다. 이런 방식으로, 해저드 포인터와 RCU 는 HTM 이 커다란 데이터 구조를 처리하고 *conflict* 확률을 줄이는데 사용될 수 있을 겁니다.

하지만, 이는 간단하지가 않습니다. 이 방법을 구현하는 가장 간단한 방법은 각각의 캐시라인과 bus 에 추가적인 상태를 가질 것을 필요로 하는데, 이는 추가적

비용을 필요로 합니다. 이 비용과 함께 생기는 장점은 커다란 영역을 접근하는 읽기 쓰레드들이 연속된 *conflict*로 인해 업데이트 쓰레드들이 *starve*하게 되는 문제 없이 수행될 수 있게 해준다는 것입니다. Binary search tree 에 큰 효과를 가져다준 Siakvaras 등의 대안적인 방법 [SNGK17]은 *read-only traversal* 에만 RCU 를 사용하고 실제 업데이트에는 HTM 만 사용합니다. 이 조합은 다른 *transactional-memory* 기법들을 220 % 가량 상회하는 성능을 보이는데, Howard 와 Walpole [HW11] 이 RCU 와 STM 을 조합해서 보인 것과 비슷한 성능 향상입니다. 두 경우 모두, 이 완화된 *atomicity* 는 하드웨어가 아니라 소프트웨어로 구현되었습니다. 하지만 완화된 *atomicity* 를 하드웨어와 소프트웨어 모두로 구현해서 추가적인 성능 향상을 보는 것도 흥미로울 겁니다.

17.3.6 Conclusions

현재의 HTM 구현들이 일부 경우에 대해서는 실질적인 이득을 가져다 주긴 했지만, 또한 상당한 단점들을 가지고 있기도 합니다. 가장 심각한 단점은 제한적인 트랜잭션 사이즈, *conflict* 처리, `abort` 와 룰백의 필요, 진행 보장의 부재, 되돌이켜질 수 없는 오퍼레이션들의 처리 불가능성, 그리고 락킹과의 미묘한 semantic 상의 차이입니다.

이러한 단점들 가운데 일부는 미래의 구현들에서는 줄어들 수 있겠습니다만, 기존에 언급된 바 [MMW07, MMTW10] 와 같이 많은 다른 종류의 동기화 메커니즘들과 함께 동작할 수 있어야 할 필요성은 계속될 것으로 보입니다.

요약해서, 현재의 HTM 구현들은 병렬 프로그래머의 도구박스에 들어오면 좋은, 그리고 유용한 추가적 도구가 되겠고, 그것들을 사용하기 위해서는 많은 흥미롭고 도전적인 작업들을 필요로 합니다. 하지만, 그것들은 모든 병렬 프로그래밍에서의 문제들을 모두 한번에 처리해줄 마법봉으로 여겨질 수는 없습니다.

17.4 Formal Regression Testing?

Formal verification 은 일부 경우에 유용한 것으로 증명되었습니다만, hard-core formal verification 이 리눅스 커널과 같이 복잡한 동시성을 가진 코드를 위한 자동화된 regression-test 도구에 포함될 수 있을 것인지에 대한 질문이 많습니다. 리눅스 커널 SRCU를 위한 이론적 증명은 이미 있지만 [Roy17], 이 테스트는 가장 간단한 RCU 구현들 가운데 하나의 작은 부분을 위한 테스트이고, 이걸 계속 변화하는 리눅스 커널에 맞춰 유지하기는 어려움이 증명되었습니다. 따라서 formal verification 을 리눅스 커널의 regression test 에 첫번째 멤버로 추가하기 위해 뭐가 필요할지 물어볼 가치가 있습니다.

다음은 좋은 시작이 될 수 있을 겁니다 [McK15a, slide 34]:

1. 모든 필요한 변환은 자동화 되어야만 합니다.
2. 환경 (메모리 순서 규칙 포함) 은 올바르게 처리되어야만 합니다.
3. 메모리와 CPU 오버헤드는 받아들일 수 있을 만큼 적어야만 합니다.
4. 버그의 위치를 알려주는 정보가 제공되어야만 합니다.
5. 소스코드와 입력 이외의 정보는 너무 범위가 크지 않아야만 합니다.
6. 발견되는 버그는 해당 코드의 사용자들에 관련되어 있어야만 합니다.

이 목록은 만들어져가는 중입니다만 Richard Bornat의 격언에 비하면 간단합니다: “Formal-verification 연구자들은 개발자들이 작성하는 코드를 그들이 작성한 언어로, 그들이 수행하는 환경에서 검증해야 한다.” 다음 섹션들은 앞의 요구사항들 각각에 대해 논해보고, 이어서 몇가지 도구들이 이 요구사항들을 얼마나 만족시키고 있는지 점수를 매겨봅니다.

17.4.1 Automatic Translation

Promela 와 spin 이 설계에는 도움이 되지만, 여러분이 정형적으로 C-언어 프로그램을 regression-test 하려면, 여러분은 여러분의 코드를 다시 검증하고 싶을 때마다 Promela 로 일일이 손으로 변환시켜야만 합니다. 여러분의 코드가 매 60-90일마다 릴리즈되는 리눅스 커널 안에 있다면, 여러분은 매년 네번에서 여섯번씩 수작업으로 변환을 해야 할겁니다. 시간이 흐름에 따라, 사람의 실수가 생겨날 텐데, 이는 해당 검증이 소스 코드에 들어 맞지 않음을 의미해서, 해당 검증이 쓸모없게 만듭니다. 반복된 검증은 해당 formal-verification 도구가 여러분의 코드를 직접 입력받을 수 있거나, 여러분의 코드를 검증에 필요한 형태로 자동으로 변환해주는 도구가 있을 것을 필요로 합니다.

PPCMEM 과 herd 는 이론적으로 어셈블리 언어와 C++ 코드를 직접 입력받을 수 있습니다만, 이 도구들은 매우 작은 리트머스 테스트에서만 동작하여서, 일반적으로는 여러분의 메커니즘의 핵심을 수작업으로 추출해 내야만 함을 의미합니다. Promela 와 spin 만큼, PPCMEM 과 herd 는 매우 유용합니다만, regression suite 에 적합하지는 않습니다.

반면, cbmc 와 Nidhugg 는 합리적인 (여전히 매우 제한되어 있긴 하지만) 크기의 C 프로그램을 입력받을

수 있고, 그 기능이 계속 발전한다면, regression test에 훌륭한 추가물이 될 수도 있을 겁니다.

C 코드를 입력으로 받는 것의 한가지 단점은, 해당 컴파일러가 올바르다고 가정한다는 겁니다. 한가지 대안적인 접근법은 C 컴파일러가 만들어낸 바이너리를 입력으로 받음으로써, 관련된 컴파일러 버그들을 모두 파악해내는 겁니다. 이 방법은 여러 검증 시도에서 사용되었는데, SEL4 프로젝트 [SM13] 가 특히 그했습니다.

Quick Quiz 17.11: SEL4 프로젝트에서 사용된 다양한 검증기들의 획기적인 성격이 있는데, 이 챕터는 왜 이걸 더 깊게 다루지 않나요? ■

하지만, 소스나 바이너리로부터 직접 검증을 하는게 모두 사람의 변환 과정에서의 에러를 제거하는, 안정적인 regression test에 매우 중요한 장점을 갖습니다.

특수 목적 언어를 사용하는 도구들이 쓸모없다는 이야기를 하려는게 아닙니다. 반대로, 그런 것들은 설계 시점에서의 검증에 Chapter 12에서 이야기된 것처럼 매우 도움될 수 있습니다. 하지만, 그런 도구들은 자동화된 리그레션 테스트에 특별히 도움되지는 않습니다.

17.4.2 Environment

Formal-verification 도구들이 각자의 환경을 올바르게 모델링 하는 것은 매우 중요합니다. 모두에게 너무나 흔한 생략은 메모리 모델로, Promela/spin 을 포함한 매우 많은 formal-verification 도구들이 순차적 일관성에 국한되어 있습니다. Section 12.1.4.6 에 연관된 QRCU의 경험은 중요한 교훈적 이야기입니다.

Promela 와 spin 은 순차적 일관성을 가정하는데, 이는 Chapter 15에서 볼 수 있듯이 최근의 컴퓨터 시스템에서는 좋은 맞춤이 아닙니다. 대조적으로, PPCMEM 과 herd 의 큰 강점 중 하나는 x86, ARM, Power, 그리고, herd 의 경우에는 리눅스 커널 v4.17에서 받아들여진 리눅스 커널 메모리 모델 [AMM⁺18] 을 포함해 다양한 CPU 제품군들의 메모리 모델에 대한 모델링입니다.

cbmc 와 Nidhugg 도구들은 메모리 모델을 선택할 수 있는 기능을 일부 제공합니다만, PPCMEM 과 herd 만큼 다양한 기능은 아닙니다. 하지만, 시간이 흐름에 따라 더 커다란 규모의 도구들이 더 많은 메모리 모델을 받아들일 가능성이 있습니다.

장기적으로 보면, formal-verification 도구들이 I/O 를 포함하는게 도움이 될겁니다 [MDR16a]만, 그렇게 되기전에 많은 시간이 필요할 겁니다.

그러나, 환경에 맞지 않는 도구들도 유용할 수 있습니다. 예를 들어, 매우 많은 동시성 버그들이 신화적인 순차적 일관성 시스템에서도 버그일 수 있고, 이 버그들은 시스템의 메모리 모델을 순차적 일관성으로 과하게 가정한 도구들에 의해서도 파악될 수도 있습니다. 그러나, Section 12.1.4.6 의 끝부분에서 앞서 언급되었듯이,

이런 도구들은 메모리 순서규칙 지시어를 놓쳐서 발생하는 버그들을 찾지는 못할 겁니다.

17.4.3 Overhead

거의 모든 하드코어 formal-verification 도구들이 기본적으로 기하급수적으로 증가하는 오버헤드를 가져서, 많은 흥미로운 소프트웨어 질문들은 실제로 논증 불능이란 걸 여러분이 고려하기 전까지는 사용하고 싶지 않게 보일 겁니다. 하지만, 그 기하급수적 단계 사이에도 그 정도에는 차이가 있습니다.

PPCMEM은 설계적으로 최적화되어 있지 않은데, 관심의 메모리 모델이 실제로 정확하게 표현되었음에 대한 확증을 주기 위해서입니다. *herd*는 더 적극적으로 최적화를 하며, 따라서 Section 12.3에서 설명한대로, PPCMEM 보다 열배 이상 빠릅니다. 그러나, PPCMEM과 *herd* 모두 커다란 코드보다는 매우 작은 리트머스 테스트를 목표로 삼습니다.

반면에, Promela/spin, cbmc, 그리고 Nidhugg는 더 커다란 코드(무언가)를 위해 설계되었습니다. Promela/spin은 Curiosity rover의 파일시스템 [GHH⁺14]을 검증하기 위해 사용되었고, 앞에서도 이야기되었듯 cbmc와 Nidhugg는 모두 리눅스 커널 RCU에 적용되었습니다.

휴리스틱의 발전이 지난 25년간의 속도로 지속된다면, 우리는 formal verification의 오버헤드의 많은 감소를 예상할 수 있습니다. 그렇다고는 해도, 오버헤드의 조합적인 증가는 여전히 조합적 증가인데, 이는 휴리스틱의 개선이 지속되든 안되든 검증될 수 있는 프로그램의 크기는 여전히 대폭 제한할 겁니다.

하지만, 조합적 폭증의 반대면은 Macedon의 Philip II의 영원한 충고입니다: “분할하고 지배하라.” 커다란 프로그램이 분할될 수 있고 그 조각들이 검증될 수 있다면, 그 결과는 조합적 폭발 [McK11d]일 겁니다. 분할을 할 자연스러운 장소는 API 경계인데, 예를 들어, 락킹 기능들의 그것입니다. 그러면 하나의 검증 패스는 락킹 구현이 올바른지 검증하고, 추가적인 검증 패스들은 락킹 API들의 올바른 사용을 검증할 수 있을 겁니다.

Table 17.4: Emulating Locking: Performance (s)

# Threads	Locking	cmpxchg_acquire
2	0.004	0.022
3	0.041	0.743
4	0.374	59.565
5	4.905	

이 접근법의 성능 이득은 리눅스 커널 메모리 모델 [AMM⁺17a, AMM⁺17b]을 통해 보여질 수 있습니다.

Listing 17.2: Emulating Locking with cmpxchg_acquire()

```

1 C C-SB+1-o-o-u+l-o-o-u-C
2
3 {
4 }
5
6 P0(int *sl, int *x0, int *x1)
7 {
8     int r2;
9     int r1;
10
11     r2 = cmpxchg_acquire(sl, 0, 1);
12     WRITE_ONCE(*x0, 1);
13     r1 = READ_ONCE(*x1);
14     smp_store_release(sl, 0);
15 }
16
17 P1(int *sl, int *x0, int *x1)
18 {
19     int r2;
20     int r1;
21
22     r2 = cmpxchg_acquire(sl, 0, 1);
23     WRITE_ONCE(*x1, 1);
24     r1 = READ_ONCE(*x0);
25     smp_store_release(sl, 0);
26 }
27
28 filter (0:r2=0 /& 1:r2=0)
29 exists (0:r1=0 /& 1:r1=0)

```

이 모델은 *spin_lock()*과 *spin_unlock()* 기능을 제공하지만, 이 기능들은 또한 Listing 17.2 (C-SB+1-o-o-u+l-o-o-*u.litmus와 C-SB+1-o-o-u+l-o-o-u*-C.litmus)에 보인대로 *cmpxchg_acquire()*와 *smp_store_release()*를 사용해서도 에뮬레이션 될 수 있습니다. Table 17.4은 이 모델의 *spin_lock()*과 *spin_unlock()*을 사용할 때의 성능과 확장성을 이 기능들을 앞의 리스트에 보인대로 에뮬레이션 했을 때와 비교합니다. 이 차이는 무의미하지 않습니다: 네개 프로세스에서, 이 모델은 에뮬레이션보다 백배 이상 빠릅니다!

Quick Quiz 17.12: Listing 17.2의 line 28에서 해당 컨디션을 그냥 *exists* 절에 넣는 대신 왜 별개의 *filter* 커맨드를 사용하나요? 그리고 *cmpxchg_acquire()* 대신 *xchg_acquire()*를 사용하는게 더 간단하지 않겠어요? ■

도구들이 자동으로 커다란 프로그램들을 쪼개고, 그 조각들을 검증하고, 그 조각들의 조합을 검증한다면 물론 매우 유용할 겁니다. 그렇게 되기 전까지는, 커다란 프로그램의 검증은 상당한 수작업을 필요로 할 겁니다. 이 작업은 매 릴리즈마다 반복된 검증을 안정적으로 해내기에 낫고 결국 continuous integration에 잘 맞는 방식인 스크립팅으로 중개를 하는게 바람직할 겁니다.

어떤 경우든, 우린 formal-verification 기능이 시간에 따라 증가하길 계속할 것을 기대할 수 있고, 모든 그런 증가는 결국 formal verification을 리그레션 테스트에 사용할 수 있는 가능성을 증가시킬 겁니다.

17.4.4 Locate Bugs

어떤 크기의 소프트웨어 제품이든 모두 버그를 갖고 있습니다. 따라서, 버그의 존재 여부만 알려주는 formal-verification 도구는 딱히 유용하지 않습니다. 필요한건 최소한 버그가 어디에 있고 그 버그의 특성이 무엇인지에 대한 어떤 정보를 제공해 주는 도구입니다.

cbmc의 출력은 소스 코드로 매핑되는 기록을 포함하며, Promela/spin의 것과 유사하고, Nidhugg도 그려합니다. 물론, 이런 기록은 매우 길수도 있고, 그걸 분석하는건 상당히 지루할 수 있습니다. 하지만, 그러는 게 과거의 방식으로 버그를 찾는것보다는 일반적으로 훨씬 빠르고 즐겁습니다.

또한, 가장 간단한 formal-verification 도구들의 테스트 중 하나는 버그 추가입니다. 무엇보다도, 우리 중 누구도 `printf("VERIFIED\n")`을 쓸 수는 없습니다만, 평범한 사실 하나는 formal-verification 도구의 개발자들은 우리들만큼이나 버그를 만들기 쉽다는 것입니다. 따라서, 버그가 존재한다고 주장하기만 하는 formal-verification 도구들은 기본적으로 신뢰하기가 어려운데 이는 실제 세계에서 코딩된 그것들을 검증하기는 더 어렵기 때문입니다.

하지만, formal-verification 도구들을 작성하는 사람들은 존재하는 도구들에 의존할 수 있습니다. 예를 들어, 심각하지만 흔하지 않은 버그의 존재 또는 부재만을 판단하도록 설계된 도구는 bisection에 의존할 수 있을 겁니다. 테스트되는 프로그램의 옛날 버전이 버그를 가지고 있지 않지만 새 버전은 가지고 있다면, bisection은 해당 버그를 만들어낸 커밋을 빨리 찾아내는데 사용될 수 있을 것인데, 이는 버그를 찾고 고치기에 충분한 정보가 될 수 있을 겁니다. 물론, 이런 종류의 전략은 일반적인 버그들에 대해서는 잘 동작하지 않을 수 있는데 이 경우에 bisection은 일반적 버그 하나라도 가지고 있는 모든 커밋들에 의해 실패할 것이기 때문입니다.

따라서, 많은 formal-verification 도구들에 의해 제공되는 수행 기록은 계속해서 가치있을 것이고, 복잡하고 이해하기 어려운 버그들에 대해서는 특히 그럴 겁니다.

17.4.5 Minimal Scaffolding

과거, formal-verification 연구자들은 어떤 소프트웨어가 검증될 것인지에 대한 완전한 명세를 원했습니다. 불행히도, 수학적으로 엄격한 명세는 실제 코드보다도 클 수 있고, 명세의 각 줄은 코드의 각 줄이 그런것처럼 버그를 포함하고 있을 수 있습니다. 코드가 해당 명세를 차실히 구현하고 있는지를 증명하는 formal verification 노력은 둘 사이의 버그를 위한 버그의 호환성에 대한 증명이 될 수 있는데, 이는 큰 도움이 되진 않을 수도 있습니다.

이게 다가 아니라, 리눅스 커널 RCU를 포함한 여러 소프트웨어 제품들을 위한 요구사항은 근본적으로

경험적입니다 [McK15e, McK15c, McK15d].¹⁷ 이런 흔한 종류의 소프트웨어에게, 완전한 명세는 환상입니다. 하드웨어에게 완전한 명세는 더이상 환상만이 아닙니다, 2017년 말의 Meltdown과 Spectre side-channel 공격 [Hor18]을 통해 분명해졌습니다.

이런 상황은 사람들이 실제 세상의 소프트웨어와 하드웨어 제품에 대한 formal verification의 희망을 포기하게 할 수도 있지만, 명세될 수 있는게 꽤 있다는 게 드러났습니다. 예를 들어, 설계와 코딩 규칙, 코드내에 포함된 단정문은 부분적 명세로 동작될 수 있습니다. 그리고 실제로 cbmc와 Nidhugg와 같은 formal-verification 도구들은 발동될 수 있는 단정문들을 검사하는데, 암묵적으로 이 단정문들을 명세의 부분으로 취급하는 것입니다. 하지만, 이 단정문들은 또한 코드의 부분인데, 이는 이 단정문들이 폐용되지 않을 것이며, 특히 이 코드가 스트레스 테스트를 위한 것이라면 그러할 것입니다.¹⁸ cbmc 도구는 또한 배열 범위를 벗어난 래퍼런스를 검사하는데, 이 역시 암묵적으로 이 명세에 추가하는 것입니다.

이 암묵적 명세 접근법은 상당히 말이 되는데, 여러분이 formal verification을 올바름에 대한 완전한 증명으로 보기보다는 일반적으로 사용되는, 테스트와 다른 강점과 약점을 가진 하나의 대안적 형태의 검증이라고 생각하고 있다면 특히 그렇습니다. 이 관점에서, 소프트웨어는 항상 버그를 가지고 있고, 따라서 이런 버그를 찾아주는 모든 종류의 도구는 실제로 매우 좋은 물건입니다.

17.4.6 Relevant Bugs

버그를 찾는것—그리고 그걸 고치는것—은 물론 모든 검증의 완전한 목적입니다. 분명히, 거짓 양성반응은 없어야 합니다. 하지만 거짓 양성반응이 없다 해도, 버그는 존재하고 존재합니다.

예를 들어, 어떤 소프트웨어 제품이 정확히 100개의 남아있는 버그가 있고, 그 버그 각각은 평균적으로 백만년의 수행시간에 한번 나타난다고 가정해 봅시다. 더 나아가서 어떤 전지전능한 formal-verification 도구가 모든 100개의 버그를 찾아내서 개발자가 이를 수정했다고 해봅시다. 이 소프트웨어 제품의 안정성에는 어떤 일이 벌어질까요?

아마도 그 놀랄만한 답은 안정성이 하락한다는 것일 겁니다.

이를 이해하기 위해, 약 7%의 수정은 새로운 버그를 만들어냈다는 역사적 경험 [BJ12]을 명심하기 바랍니다. 따라서, 발생하기까지 조합된 평균 시간 (MTBF:

¹⁷ 또는, formal-verification 용어로, 리눅스 커널 RCU는 불완전한 명세를 가지고 있습니다.

¹⁸ 그리고 여러분은 여러분의 코드에 대해 스트레스 테스트를 하죠, 그렇죠?

Mean Time Between Failure) 10,000년을 갖는 100개의 버그를 고치는 것은 7개의 추가적 버그를 만들어냅니다. 역사적 통계는 각각의 이 새로운 버그가 70,000년보다 훨씬 적은 MTBF를 가질 것을 이야기 합니다. 이는 결국 이 7개의 새로운 버그의 조합된 MTBF가 10,000년보다 훨씬 적을 것을 이야기하는데, 이는 결국 원래의 100개 버그의 잘 의도된 수정은 전체 소프트웨어의 안정성을 실제로 하락시켰음을 의미합니다.

Quick Quiz 17.13: 알려진 버그들의 MTBF들이 아직 발견되지 않은 버그들의 MTBF에 대한 좋은 추측이 될 수 있음을 어떻게 아나요? ■

Quick Quiz 17.14: 하지만 formal-verification 도구들은 이 수정으로 만들어지는 모든 버그들을 곧바로 발견해 낼텐데, 이게 왜 문제죠? ■

아직 끝이 아닌게, 평균적으로 하루에 한번 발견되는 버그와 매 100만년마다 발견되는 99개의 버그를 갖는 소프트웨어 제품을 생각해 봅시다. 어떤 formal-verification 도구가 이 99개의 백만년짜리 버그를 발견하지만, 하루짜리 버그는 발견하지 못한다고 생각해 봅시다. 이 99개의 버그를 고치는 것은 시간과 노력을 필요로 할텐데, 약간 안정성을 떨어뜨릴 테고, 훨씬 부끄럽고 훨씬 나쁠, 매일 발견되는 버그에 대해서는 아무일도 하지 않게 될겁니다.

따라서, 대부분의 문제가 되는 버그들을 우선적으로 찾아내는 검증 도구를 갖는게 좋을 겁니다. 하지만, Section 17.4.4에서 이야기 되었듯, 추가적인 도구들을 활용하는 것도 가능합니다. 강력한 도구 가운데 하나는 평범한 기존 테스트입니다. 버그에 대해 알고 있다면, 이를 위한 특정 테스트를 만드는게 가능할 것이고, 이 버그의 발현 확률을 증가시키기 위해 Section 11.6.4에서 이야기된 기법들을 사용하는 것도 가능할 겁니다. 이런 기법들은 버그의 기본 실패 확률에 대한 대략적 예측 계산을 가능하게 해야하는데, 이는 결국 버그 수정을 위한 노력의 가치를 높여줄 겁니다.

Quick Quiz 17.15: 하지만 많은 formal-verification 도구들이 한번에 하나의 버그만 찾을 수 있어서, 이 도구가 다음 버그를 찾기 전에 버그 각각을 먼저 고쳐야만 합니다. 그런 도구를 가지고 어떻게 버그 수정 노력의 가치가 높아질 수 있겠습니까? ■

연관된 버그들을 파악해 낸다는데 대해 물어보고 싶은게 많겠지만, 이는 우리가 정말로 소프트웨어 안정성을 개선하고자 한다면 필요한 것입니다.

17.4.7 Formal Regression Scorecard

Table 17.5는 이 챕터에서 다른 formal-verification 도구들의 대략적인 점수를 보입니다. 더 짧은 파장이 긴 파장보다 나은 것입니다.

Promela는 수작업 변환을 필요로 하고 sequential con-

sistency 만을 지원하므로, 이것의 처음 두개 셀은 빨강습니다. 이 도구는 합리적인 오버헤드 (formal verification에 대해서는요, 어쨌든)를 갖고 traceback 기능을 제공하므로, 다음 두개 셀은 노란색입니다. 수작업 변환을 필요로 하긴 하나, Promela는 단정문을 자연적인 방법으로 처리하며, 따라서 다섯번째 셀은 초록색입니다.

PPCMEM은 지원하는 리트머스 테스트의 작은 크기 때문에 일반적으로 수작업을 필요로 하며, 따라서 첫번째 셀은 오렌지색입니다. 이 도구의 오버헤드는 상당히 높아서, 세번째 셀은 빨간색입니다. 이 도구는 오퍼레이션들간의 관계를 그림으로 보여주는데, 이는 traceback 만큼이나 유용하면서 상당히 유용하므로, 네번째 셀은 노란색입니다. 이 도구는 `exists` 절을 만들 것을 필요로 하고 프로세스간 단정문은 받지 못하기 때문에, 그다섯번째 셀 역시 노란색입니다.

`herd` 도구는 PPCMEM과 유사하게 검증되는 코드의 크기에 제한이 있으며, 따라서 `herd`의 첫번째 셀은 오렌지색입니다. 이 도구는 다양한 종류의 메모리 모델을 지원하므로, 두번째 셀은 파란색입니다. 합리적인 오버헤드를 가지고 있으므로, 세번째 셀은 노란색입니다. 버그 파악과 단정문 기능은 PPCMEM의 그것과 상당히 유사해서, `herd` 또한 그 다음 두개 셀은 노란색입니다.

`cbmc` 도구는 C 코드를 직접 입력받고, 따라서 첫번째 셀은 파란색입니다. 이 도구는 몇가지 메모리 모델을 지원하며, 따라서 두번째 셀은 노란색입니다. 합리적인 오버헤드를 가지고 있으므로, 세번째 셀은 노란색입니다만, SAT-solver 성능은 계속해서 증가할 수 있습니다. 이 도구는 traceback을 제공하므로, 네번째 셀은 초록색입니다. 이 도구는 C 코드로부터 단정문을 곧바로 가져오므로, 다섯번째 셀은 파란색입니다.

`Nidhugg` 또한 C 코드를 직접 입력받으므로 첫번째 셀은 파란색입니다. 이 도구는 두가지 메모리 모델만을 지원하므로, 두번째 셀은 오렌지색입니다. 오버헤드는 상당히 낮으므로 (formal-verification에 대해서), 세번째 셀은 초록색입니다. Traceback을 지원하므로, 네번째 셀은 초록색입니다. 단정문을 C 코드로부터 곧바로 받으므로, 다섯번째 셀은 파란색입니다.

그런데 여섯번째 마지막 줄은 뭐죠? 이 중 어떤 도구가 올바른 버그를 찾는지 이야기하기엔 너무 이르므로, 이것들은 모두 물음표와 함께 노란색으로 칠해져 있습니다.

Quick Quiz 17.16: Table 17.5에 보인 점수표에 테스트는 어떻게 올라갈까요? ■

Quick Quiz 17.17: 하지만 Table 17.5에 보인 것들 외에도 상당히 많은 formal-verification 시스템들이 존재하지 않나요? ■

다시 말하건대, 이 표는 이 도구들을 regression testing에 사용할 경우에 대한 채점임을 알아두시기 바랍니다. 이것들중 많은 것들이 regression testing에 전혀 적합

Table 17.5: Formal Regression Scorecard

	Promela	PPCMEM	herd	cbmc	Nidhugg
(1) Automated	Red	Orange	Orange	Blue	Blue
(2) Environment	(MM)	Green	Blue	(MM)	(MM)
(3) Overhead	Yellow	Red	Yellow	(SAT)	Green
(4) Locate Bugs	Yellow	Yellow	Yellow	Green	Green
(5) Minimal Scaffolding	Green	Yellow	Yellow	Blue	Blue
(6) Relevant Bugs	???	???	???	???	???

하지 않다는 것은 이게 쓸모없음을 의미하지는 않으며, 사실, 이것들 중 많은 것들이 지난 시간동안 가치있음을 증명했습니다.¹⁹ 단지 regression testing 을 위한 건 아니란 거죠.

하지만, 이는 바뀔 수 있습니다. 무엇보다, formal verification 도구들은 2010년대에 인상적인 활보들을 보였습니다. 이 발전이 지속된다면, formal verification 은 병렬 프로그래머의 검증 도구상자에 없을 수 없는 도구가 될 수도 있을 겁니다.

17.5 Functional Programming for Parallelism

1980년대 초에 제가 처음으로 함수형 프로그래밍 수업을 들었을 때, 교수님은 side-effect-free 한 함수형 프로그래밍 스타일은 사소한 병렬화와 분석에 잘 맞는다고 이야기했습니다. 30년이 지나서도 이 말은 여전히 남아 있습니다만, 프로그램은 상태도 I/O 도 갖지 않아야만 한다고 이야기한 이 교수님의 또하나의 말과는 달리 병렬 함수형 언어를 사용하는 주류 업체는 적습니다. Erlang 과 같은 함수형 언어들의 템파 사용 예가 존재하고, 일부 다른 함수형 언어들에 멀티쓰레드 지원이 추가되었습니다만, 주류 업체의 언어 사용은 (일반적으로 OpenMP, MPI, 또는 Fortran 의 경우, coarrays 와 연동되는) C, C++, Java, 그리고 Fortran 과 같은 절차형 언어의 것으로 남아있습니다.

이 상황은 기본적으로 “분석이 목표라면, 분석을 하기 전에 절차형 언어를 함수형 언어로 변환하는게 어떨까?” 하는 질문을 이끌어냅니다. 이 접근방법에 대해서는 물론 여러가지 반대의견들이 있는데, 여기선 세개만 나열해 보자면 다음과 같습니다:

1. 절차적 언어들은 종종 글로벌 변수들을 많이 사용 하곤 하는데, 이 변수들은 다른 함수들, 또는, 더

¹⁹ 다만 한가지 예를 들면, Promela 는 다른 것도 아니고 Curiosity Rover 의 파일 시스템을 검증하는데 사용되었습니다. 여러분의 formal verification 도구는 Mars 탐사선에 사용되었나요?

나쁘게도, 여러 쓰레드들에서 접근될 수 있습니다. Haskell 의 monad 는 단일 쓰레드의 글로벌 상태를 다루기 위해 만들어졌고, 글로벌 상태로의 복수 쓰레드에서의 접근은 함수적 모델에 대한 추가적 위반을 필요로 함을 알아두세요.

2. 멀티쓰레드를 지원하는 절차적 언어들은 종종 락, 어토믹 오퍼레이션, 트랜잭션과 같은, 함수형 모델에 대한 위반을 추가하는 동기화 기능들을 종종 사용합니다.
3. 절차적 언어들은, 예를 들면 하나의 함수에의 같은 호출에 두개의 서로 다른 인자에 같은 구조체로의 포인터를 넘김으로써 함수 인자들을 alias 할 수 있습니다. 이는 함수가 알지 못한채로 그 구조체를 두개의 서로 다른 (그리고 겹칠 수 있는) 코드 흐름을 통해 수정하는 결과를 초래할 수 있는데, 이는 분석을 상당히 복잡하게 만들니다.

물론, 글로벌 상태, 동기화 기능들, aliasing 의 중요성으로 인해, 영리한 함수형 프로그래밍 전문가들은 함수형 프로그래밍 모델을 그것들에 조화시키기 위한 방법들을 여럿 제안했고, monads 는 그런 것들 중 하나에 불과합니다.

또 다른 접근방법은 병렬 절차적 프로그램을 함수형 프로그램으로 변환하고, 그 결과 나온 프로그램을 분석하는데에 함수형 프로그래밍 도구들을 사용하는 것입니다. 하지만 모든 실제 컴퓨팅은 유한한 시간 간격동안 유한한 입력과 함께 동작하는 커다란 finite-state machine 이라는 점을 놓고 보면, 이보다 훨씬 잘 할 수 있을 법 합니다. 이는, 모든 실제 프로그램은 비록 실용적이지 못할 만큼 커다란 것이라 할지라도 하나의 수식으로 변환될 수 있음을 의미합니다 [DHK12].

하지만, 여러개의 병렬 알고리즘의 낮은 단계의 알맞이들이 현대의 컴퓨터들의 메모리에 들어가기에 알맞을 만큼 충분히 작은 크기의 수식으로 변환될 수 있습니다. 만약 그런 수식이 단정문과 결합된다면, 해당 단정문이 들어맞는지 알아보는 것은 충족 가능성 문제가 됩니다. 충족 가능성 문제는 NP-complete 하긴 하지만,

이 문제들은 전체 상태 공간을 만들어내는데 필요한 것 보다는 훨씬 적은 시간 안에 풀이될 수 있는 경우가 많습니다. 또한, 이 풀이에 걸리는 시간은 그 아래 깔려있는 메모리 모델과는 조금만 의존적인 것으로 나타나서, 완화된 순서 규칙의 시스템에서 수행되는 알고리즘 역시 검사될 수 있습니다 [AKT13].

일반적인 접근방법은 프로그램을 single-static-assignment (SSA) 형태로 변환시켜서 하나의 변수로의 각각의 값 할당이 그 변수의 별개의 버전을 만들도록 하는 것입니다. 이는 모든 동작중인 쓰레드로부터의 값 할당에 적용되어서, 그로부터 말미암은 표현은 검사하고자 하는 코드의 모든 가능한 수행경로를 담고 있게 됩니다. 단정문의 추가는 입력과 초기 값들의 어떤 조합이든 단정문이 틀리게 되는 경우를 만들 수 있는지에 대한 질문, 즉 앞에서 이야기한 충족 가능성 여부에 대한 질문을 수반 합니다.

여기서 있을법한 반대의견 중 하나는, 임의의 루프 구조에 대해서는 제대로 처리를 하지 못한다는 점입니다. 하지만, 많은 경우에 이는 루프를 유한한 횟수만큼 풀어놓는 것으로 처리될 수 있습니다. 또한, 아마도 일부 루프는 귀납법으로는 비난을 면치 못하게 될것이 증명될 겁니다.

또하나의 있을법한 반대의견은 스피너은 임의의 긴 루프에 관계되고, 유한 횟수 루프를 풀어놓는 방법은 해당 스피너의 모든 동작을 담지는 못할 것이라는 점입니다. 이 반대의견은 쉽게 극복될 수 있음이 드러났습니다. 전체 스피너을 모델링하는 대신에, 락을 얻으려 시도하며, 만약 즉시 락을 얻지 못한다면 abort 하도록 하는 trylock을 모델링 하는 것입니다. 이렇게 되면 단정문은 락이 곧바로 얻을 수 없어서 abort 되는 스피너에 대해서는 단정문 실패가 되지 않도록 수정되어야 합니다. 논리 수식은 시간과는 무관하기 때문에, 모든 가능한 동시성 동작들은 이 방법을 통해 담아질 수 있을 겁니다.

마지막 반대의견은 이 테크닉은 리눅스 커널을 만드는 수백만 줄의 코드로 이루어진 것과 같은 실제 전체 크기의 소프트웨어 작품을 다루기에는 적합치 않을 것이라는 것입니다. 이건 그럴 수도 있습니다만, 리눅스 커널 내의 그보다 훨씬 작은 병렬 기능들 각각을 제대로 검증하는 것도 상당히 가치있는 것이라는 사실은 그대로 남아있습니다. 그리고 실제로 연구자들은 이 방법을 리눅스 커널의 Tree RCU 구현을 포함한 (RCU의 덜 심오한 속성들 중 하나를 검증하는 것이기는 하지만) 단순하지 않은 실제 세계의 코드에 적용했습니다 [LMKM16, KS17a].

이 테크닉이 얼마나 넓게 적용될 수 있을 것인지를 볼 필요가 있습니다만, 이는 formal verification 분야의 흥미로운 혁신들 중 하나입니다. 함수형 프로그래밍 대변자들이 이야기하는, 피할 수 없는 함수형 프로그래밍의 지배 시대가 올수도 있겠지만, 이 오래도록 끌려온

방법론이 formal-verification에서의 신뢰성 있는 경쟁이 보이기 시작하는 것은 분명한 사건입니다. 따라서 피할 수 없는 함수형 프로그래밍의 지배 시대에 대해 의심을 가질 이유는 있습니다.

Ask me no questions, and I'll tell you no fibs.

“She Stoops to Conquer”, Oliver Goldsmith

Appendix A

Important Questions

다음 섹션들은 SMP 프로그래밍에 관련된 몇 가지 중요한 질문들에 대해 논합니다. 또한, 각각의 섹션은 여러분의 목표가 여러분의 SMP 코드가 가능한한 빠르고 문제 없이 돌아가기 일 뿐—그건 그렇고, 훌륭한 목표죠!—이라면, 관련된 질문들에 대해 걱정하는 것을 어떻게 방지하는지를 보입니다.

이 질문들에 대한 대답들은 비록 많은 경우 싱글 쓰레드 환경에서에 비해 상당히 덜 직관적인 경우가 많습니다만, 이해하기에 어렵지는 않습니다. 여러분이 귀납법을 깨우쳤다면, 압도적일 만큼 어려운 것은 없을 겁니다.

A.1 What Does “After” Mean?

“After”는 직관적이지만 놀라우리만큼 어려운 개념입니다. 한가지 중요한 반직관적 문제는 코드가 언제든 열만큼이든 지연되어서 수행될 수 있다는 점입니다. 타임스탬프 “t”와 정수 필드 “a”, “b”, 그리고 “c”를 포함하는 글로벌 구조체를 이용해서 통신을 하는 생산자와 소비자 구조를 생각해 봅시다. 생산자는 Listing A.1에 보여진 것처럼 (1970년으로부터의 현재 시각까지 지난 초를 10진수로 나타내는) 현재 시각을 기록하고 “a”, “b”, 그리고 “c”를 업데이트 하는 루프를 돋립니다. 소비자는 Listing A.2에 보여진 것처럼 역시 현재 시각을 기록하지만 생성자의 타임스탬프와 “a”, “b”, 그리고 “c” 필드의 값을 복사해옵니다. 프로그램 수행 종료 시점에서, 소비자는 이례적인 기록들을 출력하는데, 예를 들면 시간이 뒤로 돌아간 것으로 보이는 경우입니다.

Quick Quiz A.1: 이 예제에서 어떤 SMP 코딩 에러가 보이거나요? 전체 코드를 보기 위해선 `time.c` 파일을 보세요. ■

생성자가 타임스탬프나 값을 저장하는데에 그렇게 많은 시간이 걸리지 않을 것이기에 생성자와 소비자 타임스탬프 간의 차이는 상당히 작을 것이라고 예상하는 사람들이 있겠습니다. 듀얼코어 1GHz x86에서의 출

Listing A.1: “After” Producer Function

```
1 /* WARNING: BUGGY CODE. */
2 void *producer(void *ignored)
3 {
4     int i = 0;
5
6     producer_ready = 1;
7     while (!goflag)
8         sched_yield();
9     while (goflag) {
10         ss.t = dgettimeofday();
11         ss.a = ss.c + 1;
12         ss.b = ss.a + 1;
13         ss.c = ss.b + 1;
14         i++;
15     }
16     printf("producer exiting: %d samples\n", i);
17     producer_done = 1;
18     return (NULL);
19 }
```

력 결과가 Table A.1에 보여져 있습니다. 여기서, “seq” 행은 루프를 수행한 횟수이고, “time” 행은 변칙적 행위가 나타난 시각을 초로 나타낸 것이고, “delta” 행은 소비자의 타임스탬프가 생성자의 것보다 얼마나 뒤의 것이었는지(즉, 이 값이 음수라면 소비자가 생성자보다 타임스탬프를 먼저 받았음을 말합니다), 그리고 “a”, “b”, 그리고 “c”로 나타내어진 행들은 이 변수들이 소비자에 의해 수집된 앞의 스냅샷에 비해 얼마나 증가되었는지를 보입니다.

Table A.1: “After” Program Sample Output

seq	time (seconds)	delta	a	b	c
17563:	1152396.251585	(-16.928)	27	27	27
18004:	1152396.252581	(-12.875)	24	24	24
18163:	1152396.252955	(-19.073)	18	18	18
18765:	1152396.254449	(-148.773)	216	216	216
19863:	1152396.256960	(-6.914)	18	18	18
21644:	1152396.260959	(-5.960)	18	18	18
23408:	1152396.264957	(-20.027)	15	15	15

왜 시간이 거꾸로 가는 걸까요? 팔호 안의 숫자는

Listing A.2: “After” Consumer Function

```

1 /* WARNING: BUGGY CODE. */
2 void *consumer(void *ignored)
3 {
4     struct snapshot_consumer curssc;
5     int i = 0;
6     int j = 0;
7
8     consumer_ready = 1;
9     while (ss.t == 0.0) {
10         sched_yield();
11     }
12     while (goflag) {
13         curssc.tc = dgettimeofday();
14         curssc.t = ss.t;
15         curssc.a = ss.a;
16         curssc.b = ss.b;
17         curssc.c = ss.c;
18         curssc.sequence = curseq;
19         curssc.iserror = 0;
20         if ((curssc.t > curssc.tc) ||
21             modgreater(ssc[i].a, curssc.a) ||
22             modgreater(ssc[i].b, curssc.b) ||
23             modgreater(ssc[i].c, curssc.c) ||
24             modgreater(curssc.a, ssc[i].a + maxdelta) ||
25             modgreater(curssc.b, ssc[i].b + maxdelta) ||
26             modgreater(curssc.c, ssc[i].c + maxdelta)) {
27             i++;
28             curssc.iserror = 1;
29         } else if (ssc[i].iserror)
30             i++;
31         ssc[i] = curssc;
32         curseq++;
33         if (i + 1 >= NSNAPS)
34             break;
35     }
36     printf("consumer exited, collected %d items of %d\n",
37           i, curseq);
38     if (ssc[0].iserror)
39         printf("0/%d: %.6f %.6f (%.3f) %d %d %d\n",
40               ssc[0].sequence, ssc[j].t, ssc[j].tc,
41               (ssc[j].tc - ssc[j].t) * 1000000,
42               ssc[j].a, ssc[j].b, ssc[j].c);
43     for (j = 0; j <= i; j++)
44         if (ssc[j].iserror)
45             printf("%d: %.6f (%.3f) %d %d %d\n",
46                   ssc[j].sequence,
47                   ssc[j].t, (ssc[j].tc - ssc[j].t) * 1000000,
48                   ssc[j].a - ssc[j - 1].a,
49                   ssc[j].b - ssc[j - 1].b,
50                   ssc[j].c - ssc[j - 1].c);
51     consumer_done = 1;
52 }

```

마이크로세컨드 단위의 차이로써, 큰 수는 10 마이크로세컨드를 넘기고, 한번은 100 마이크로세컨드를 넘기기 조차 했습니다! 이 CPU는 그동안 100,000 개의 인스트럭션을 수행할 수도 있음을 알아두시기 바랍니다.

한가지 가능한 이유는 다음과 같은 이벤트 시퀀스로 설명됩니다:

1. 소비자가 타임스탬프를 얻어옵니다 (Listing A.2, line 13).
2. 소비자가 `preemption` 당합니다.
3. 임의의 시간이 흐릅니다.

4. 생성자가 타임스탬프를 얻어옵니다 (Listing A.1, line 10).
5. 소비자가 수행을 다시 재개하고, 생성자의 타임스탬프를 얻어옵니다 (Listing A.2, line 14).

이 시나리오 상에서, 생성자의 타임스탬프는 소비자의 타임스탬프보다 일만큼이든 뒤의 것일 수 있습니다.

여러분은 여러분의 SMP 코드가 “after”의 의미로 고민하는 것을 어떻게 막으시나요?

그냥 SMP 기능들을 설계된 대로 사용하세요.

이 예제에서, 가장 간단한 수정방법은 락킹을 사용하는 것으로, 예를 들어 생성자는 Listing A.1의 line 10 앞에서 락을 잡고 소비자는 Listing A.2의 line 13 앞에서 락을 잡도록 합니다. 또한, 이 락은 Listing A.1의 line 13 뒤에서 해제되고 Listing A.2의 line 17 뒤에서 해제되어야만 합니다. 이 락들은 Listing A.1의 line 10-13과 Listing A.2의 line 13-17의 코드 조각들이 서로를 배제하도록 해주는데, 달리 말하자면 서로에 대해서 어토믹하게 수행되게 된다는 말입니다. 이는 Figure A.1로 표현되어 있습니다: 이 락킹은 모든 상자 안의 코드가 시간상으로 겹쳐지는 것을 방지해 줘서, 소비자의 타임스탬프는 앞의 생성자의 타임스탬프 뒤에 수집될 수 있도록 해줍니다. 이 그림에 있는 각각의 상자 안의 코드 조각들은 “크리티컬 섹션”이라 명명됩니다; 한 시점에는 오로지 하나의 크리티컬 섹션만이 수행됩니다.

Time

Producer

```

ss.t = dgettimeofday();
ss.a = ss.c + 1;
ss.b = ss.a + 1;
ss.c = ss.b + 1;

```

Consumer

```

curssc.tc = gettimeofday();
curssc.t = ss.t;
curssc.a = ss.a;
curssc.b = ss.b;
curssc.c = ss.c;

```

Producer

```

ss.t = dgettimeofday();
ss.a = ss.c + 1;
ss.b = ss.a + 1;
ss.c = ss.b + 1;

```

Figure A.1: Effect of Locking on Snapshot Collection

이렇게 락킹을 추가하면 Table A.2에 보여진 것과 같은 출력 결과가 나옵니다. 여기선 시간이 뒤로 간 경우는 없었고, 그대신 소비자에 의해 읽어진 연속된 읽기로

읽혀진 값들 사이에는 1,000 카운트 이상의 차이들이 생겼습니다.

Table A.2: Locked “After” Program Sample Output

seq	time (seconds)	delta	a	b	c
58597:	1156521.556296	(3.815)	1485	1485	1485
403927:	1156523.446636	(2.146)	2583	2583	2583

Quick Quiz A.2: 소비자의 연속적인 읽기들 사이에 어떻게 그렇게 큰 간격이 존재하게 된걸까요? 전체 코드를 위해선 `timelocked.c` 파일을 보세요. ■

요약하자면, 여러분이 배타적 락을 획득한다면, 여러분은 그 락을 잡은채 하는 모든 일이 그 락을 앞서 잡고서 행한 모든 것보다 뒤에 행해진 것으로 나타남을 알게 됩니다. 어떤 CPU가 메모리 배리어를 수행했는지 안했는가로 걱정할 필요가 없고, CPU나 캠파일러가 오퍼레이션들을 재배치 했는지에 대해 걱정하지 않아도 됩니다—삶은 간단합니다. 물론, 이 락킹이 이 두개의 코드 조각을 동시적으로 수행되지 못하도록 막는 것은 프로그램이 멀티프로세서에서 성능을 높일 가능성을 막는데, 즉 “안전하지만 느린” 상황을 초래할 수도 있는 것입니다. Chapter 6는 많은 상황에서 성능과 확장성을 높일 수 있는 방법들을 설명합니다.

하지만, 대부분의 경우에 있어서, 어떤 주어진 코드 조각의 전과 후에 어떤 일이 일어나는지 걱정된다면, 표준 기능들의 사용을 더 잘 하기 위해 이를 힌트로 삼아야 합니다. 이 기능들이 여러분이 걱정을 하지 않아도 되도록 하도록 해주세요.

A.2 What is the Difference Between “Concurrent” and “Parallel”?

고전적 컴퓨팅 관점에서, “concurrent” 와 “parallel”은 분명한 유의어입니다. 하지만, 많은 사람들이 이 두개의 단어 사이의 차이점을 이야기 하는 것을 멈추지 않았고, 이제 이 차이점들은 두개의 서로 다른 관점에서 이해될 수 있음이 들어났습니다.

첫번째 관점은 “parallel” 을 “data parallel”의 약자로 취급하고, “concurrent” 를 그 외의 대부분의 것으로 취급합니다. 이 관점에서, parallel computing 에서는 전체 문제의 각각의 조각이 서로 다른 조각 사이의 통신 없이 완전히 독립적으로 진행될 수 있습니다. 이 경우, 조각들 사이의 협동은 거의 필요없거나 아예 필요 없습니다. 반면에, concurrent computing 은 경쟁되는 락, 트랜잭션, 또는 다른 형태의 동기화 메커니즘들과 같은 형태의 강한 상호 작용성을 가질 수 있습니다.

Quick Quiz A.3: RCU read-side 기능만을 유일한 동기화 수단으로 사용하는 프로그램의 한 부분을 생각해

봅시다. 이는 parallelism 또는 concurrency 인가요? ■

이는 물론, 그런 차이점이 뭐가 문제인가 하는 질문을 떠오르게 하는데, 이 질문은 스케줄러에 대한 두번째 관점을 가져올 수 있게 해줍니다. 스케줄러는 상당한 복잡성과 가능성을 갖는데, 경험에 의거한 법칙으로 이야기하자면, 병렬의 프로세스들이 더 긴밀하고 불규칙하게 통신할수록 스케줄러에게 더 높은 수준의 세련됨이 필요해집니다. 따라서, parallel computing 의 상호 의존성의 제거는 parallel-computing 프로그램들은 최소한의 기능만 갖춘 스케줄러에서도 잘 동작함을 의미합니다. 실제로, 완전한 parallel-computing 프로그램은 임의의 단위로 분할되고 하나의 유니프로세서에 배치된 채로도 성공적으로 동작합니다.¹ 반면에, concurrent-computing 프로그램은 스케줄러에 상당히 미묘한 점들을 필요로 할겁니다.

우린 그저 스케줄러로부터의 합리적인 수준의 사항만을 알려주도록 요구해서, parallelism 과 concurrency 사이의 차이점을 무시할 수 있어야 한다는 반론이 있을 수 있을 겁니다. 이는 많은 경우에 좋은 전략이지만, 스케줄러가 합리적으로 제공할 수 있는 정보의 수준을 효율성, 성능, 그리고 확장성이 크게 제한하는 중요한 경우들이 존재합니다. 그런 중요한 예제 가운데 하나는 스케줄러가 하드웨어로 구현된 경우로, SIMD 나 GPGPU 가 대부분 그렇습니다. 또 다른 예는 일의 단위가 상당히 짧은 워크로드로, 소프트웨어 기반의 스케줄러라 하더라도 간단함과 효율성 사이에서 어려운 선택을 해야만 하는 경우가 생깁니다.

이제, 이 두번째 관점은 워크로드가 현재 사용 가능한 스케줄러와 들어맞도록, 즉 parallel 워크로드는 간단한 스케줄러에서 동작할 수 있고 concurrent 워크로드는 더 세련된 스케줄러를 필요로 하도록 만드는 것으로 생각될 수 있습니다.

불행히도, 이 관점은 첫번째 관점으로부터 나온 의존성 기반의 차이점과 항상 들어맞지는 않습니다. 예를 들어, 상당히 독립적인 락 기반의, CPU 당 쓰레드 하나의 워크로드는 스케줄러의 결정이 필요치 않기 때문에 간단한 스케줄러 위에서도 돌아갈 수 있습니다. 실제로, 이런 종류의 일부 워크로드는 순차적 기계 위에서 조차도 한 부분 다음 다른 부분이 돌아가는 식으로 수행될 수 있습니다. 따라서, 그러한 워크로드는 첫번째 관점에 의해서는 “concurrent” 라 표시되지만 두번째 관점을 취하면 “parallel” 이라 표시될 수 있을 것입니다.

Quick Quiz A.4: 두번째 (스케줄러 기반의) 관점의 어떤 부분에서 락 기반의 CPU 당 하나의 쓰레드를 사용하는 워크로드가 “concurrent” 로 여겨질 수 있을까요? ■

이는 문제가 되지 않습니다. 인류가 만든 어떤 규칙

¹ 그렇습니다, 이는 parallel-computing 프로그램들은 순차적 수행에 잘 어울림을 의미합니다. 왜 물어보셨죠?

도 객관적 진실성에 대한 중요성을 갖지 않는데, 이는 멀티프로세서 프로그램을 “concurrent” 와 “parallel”로 카테고리를 나누는 것에 대해서도 마찬가지입니다.

이 카테고리화에서의 실패는 그런 규칙들이 쓸모없음을 의미하지 않으며, 오히려 여러분이 그것들을 새로운 상황에 적용하려 할때에는 충분히 비판적인 프레임을 취해야 함을 의미합니다. 항상 그렇듯이, 그런 규칙은 적용될 수 있을 때에만 사용하고 그렇지 않을 때에는 무시하세요.

실제로, parallel, concurrent, map-reduce, task-based, 기타 등등 외에도 추가적인 카테고리들이 생겨날 수 있습니다. 누군가는 시간의 평가를 기다리고 있을 수도 있을텐데, 올바른 예측이길 바랍니다!

A.3 What Time Is It?




Figure A.2: What Time Is It?

멀티코어 컴퓨터에서 시간을 관리하는데 있어서의 핵심 문제가 Figure A.2에 그려져 있습니다. 한가지 문제는 시간을 읽는데에도 시간이 걸린다는 점입니다. 하나의 인스트럭션을 통해 하드웨어 시계를 읽을 것이고, 이 읽기 오퍼레이션을 완료하기 위해서 코어 바깥으로 (더 나쁜 경우라면, socket 바깥으로) 나가야 할 겁니다. 또한, 읽어온 값에 대해서 어떤 계산을 해야 할 수도 있는데, 예를 들어, 요구된 형태로 변환을 하기 위해, 또는 네트워크 타임 프로토콜 (NTP)을 통한 조정을 하기 위해, 등등의 이유로 인해서입니다. 그러니 최종적으로 리턴되는 시간은, 시간을 얻어도기 위해 걸린 시간의 시작점에서의 시각일까요, 끝에서의 시각일까요, 또는 그사이 어딘가일까요?

더 나쁜건, 시간을 읽는 쓰레드가 인터럽트 당하거나 preemption 당할 수도 있습니다. 더 나아가서, 시간을 읽어오고 나서 실제로 그렇게 읽어온 시간을 사용하기 전에 또 다른 계산 과정이 들어갈 수도 있습니다. 이런 가능성들이 불확실한 시간 간격을 더 늘립니다.

이에 대한 한가지 방법은 시간을 두번 읽고, 이렇게 읽어온 두가지 값의 평균을 사용하는 것입니다. 두번의 읽어온 값 사이의 차이는 사이에 낸 오퍼레이션이 발생시킨 시간의 불확실성의 정도입니다.

물론, 많은 경우에, 정확한 시각이 필요치는 않습니다. 예를 들어, 사람이 사용하기 위한 시각을 프린트 하는 경우에 있어서는, 우리는 내부 하드웨어와 소프트웨어의 비규칙적인 딜레이를 처리하는데에 있어, 사람의 느린 반응성에 의존할 수 있습니다. 비슷하게, 어떤 서버가 클라이언트로의 응답 시간을 측정해야 한다면, 요청의 도착 시각과 응답의 전송 사이의 시각은 똑같이 괜찮을 겁니다.

Appendix B

“Toy” RCU Implementations

이 부록의 장난감 RCU 구현은 높은 성능, 실용성, 또는 어떤 종류의 상품에의 사용을 위해 설계되지 않았고¹ 그저 분명함을 위해 설계되었습니다. 이 장난감 RCU 구현을 쉽게 이해하기 위해서는 더도 아니고 덜도 아니고, Chapter 2, 3, 4, 그리고 6는 물론이고 Chapter 9의 앞부분들에 대해서도 깊이 이해하고 있어야 합니다.

이 부록은 존재 보장 문제를 풀어가는 관점에서 세련됨을 증가시켜가는 방향으로 일련의 RCU 구현들을 제공합니다. Section B.1은 간단한 락킹에 기반한 초보적인 RCU 구현을 보이고, Sections B.2에서 B.9까지는 락킹, 레퍼런스 카운터, 그리고 free-running 카운터들에 기반한 간단한 RCU 구현을 보입니다. 마지막으로, Section B.2부터 B.9까지는 요약과 바래봄직한 RCU 속성들의 리스트를 제공합니다.

B.1 Lock-Based RCU

아마도 가장 간단한 RCU 구현은 Listing B.1 (`rcu_lock.h` 와 `rcu_lock.c`)에 보여진 것처럼 락킹을 사용할 겁니다. 이 구현에서 `rcu_read_lock()`은 글로벌 스핀락을 잡고, `rcu_read_unlock()`은 그걸 놓으며, `synchronize_rcu()`는 그걸 잡고는 바로 놓습니다.

`synchronize_rcu()`는 그 락을 잡기 (그리고 놓기) 전까지는 리턴하지 않기 때문에, 모든 앞의 RCU read-side 크리티컬 섹션들이 완료되기 전까지는 리턴할 수 없어서, RCU 시맨틱을 모두 구현하고 있습니다. 물론, 한번에 하나의 RCU 읽기 쓰레드만이 자신의 read-side 크리티컬 섹션을 수행할 수 있어서 RCU의 목적 중 거의 모든 것을 이루지 못합니다. 또한, `rcu_read_lock()`과 `rcu_read_unlock()`에서의 락 오퍼레이션들은 매우 무거운 일이어서, 하나의 POWER5 CPU에서 100 나노세컨드 정도의 read-side 오버헤드는 64-CPU 시스템에서는 17 마이크로세컨드 까지 증가합니다. 더 나쁜건,

이것과 같은 락 오퍼레이션들은 `rcu_read_lock()`이 데드락 사이클에 연관될 수 있게 한다는 것입니다. 더 나아가서, 재귀적인 락이 없다 해도, RCU read-side 크리티컬 섹션들은 중첩될수가 없고, 마지막으로, 동시의 RCU 업데이트들이 공통의 grace period에 의해 원론적으로는 가능하지만, 이 구현은 grace period들을 직렬화 시켜서 grace-period 공유를 불가능하게 합니다.

Quick Quiz B.1: Listing B.1에서의 RCU 구현의 데드락이 다른 RCU 구현에서의 데드락이 될 수 없는 이유는 뭘까요? ■

Quick Quiz B.2: 왜 Listing B.1의 RCU 구현에서는 RCU 읽기 쓰레드들이 병렬로 수행될 수 있도록 간단하게 reader-writer 락을 사용하지 않았나요? ■

이 구현이 실제 상품 구성에서 유용할 거라 생각하기는 어렵습니다만, 거의 모든 사용자 레벨 어플리케이션들에 구현할 수 있다는 장점을 가지고 있습니다. 나아가서, CPU 별로 하나의 락을 갖거나 reader-writer 락을 사용하는 비슷한 구현들은 2.4 리눅스 커널이라는 제품에서 사용된 바 있습니다.

이런 CPU 별로 하나의 락을 사용하는 전략의 수정된, 쓰레드별로 락을 하나씩 갖는 버전은 다음 섹션에서 설명됩니다.

B.2 Per-Thread Lock-Based RCU

Listing B.2 (`rcu_lock_percpu.h` 와 `rcu_lock_percpu.c`)는 쓰레드별로 하나의 락 두기에 기반한 구현을 보입니다. `rcu_read_lock()`과 `rcu_read_unlock()` 함수들은 각각 현재 쓰레드의 락을 잡고 풁니다. `synchronize_rcu()` 함수는 각 쓰레드의 락들을 한번에 모두 잡고 풁니다. 따라서, `synchronize_rcu()`가 시작될 때 수행중인 모든 RCU read-side 크리티컬 섹션들은 `synchronize_rcu()`가 리턴하기 전에 완료되어야만 합니다.

이 구현은 동시의 RCU 읽기 쓰레드들을 가능하게

¹ 하지만, 상품 품질의 사용자 레벨 RCU 구현은 구할 수 있습니다 [Des09b].

하고 하나의 글로벌 락을 사용할 때 생길 수 있는 데드락 조건을 예방하는 장점을 갖습니다. 더 나아가서, read-side 오버헤드는 비록 대략 140 나노세컨드 정도로 높긴 하지만 CPU들의 수에 관계 없이 140 나노세컨드 정도로 유지됩니다. 하지만, 업데이트 쪽의 오버헤드는 하나의 POWER5 CPU에서 600 나노세컨드부터 64 CPU에서의 100 마이크로세컨드 정도까지 움직입니다.

Quick Quiz B.3: Figure B.2 의 line 15-18 의 루프에서는 락들을 일단 모두 다 잡고나서는 한번에 모두 풀어주는게 더 깔끔하지 않나요? 무엇보다, 이렇게 바꾸면 어떤 읽기 쓰레드도 존재하지 않는 시점이 생기게 되어서 모든 것들이 매우 간단해질 겁니다. ■

Quick Quiz B.4: Figure B.2 에 보여진 구현은 deadlock 으로부터 자유로울까요? 그렇다면, 또는 그렇지 않다면, 왜죠? ■

Quick Quiz B.5: Figure B.2 에 보인 RCU 알고리즘의 예를 들어 POSIX pthread 처럼 여러곳에서 사용 가능한 기능들만을 사용하고 있는 점도 장점 아닌가요? ■

이 방법은 일부 환경에서는 유용할 수 있는데, 리눅스 2.4 커널에서도 비슷한 방법이 사용되었습니다 [MM00].

이어서 소개될 카운터 기반의 RCU 구현은 락 기반 구현의 일부 한계들을 해결합니다.

B.3 Simple Counter-Based RCU

약간 더 세련된 RCU 구현이 Figure B.3 (rcu_rcg.h 와 rcu_rcg.c)에 보여져 있습니다. 이 구현은 line 1에 정의된 글로벌 레퍼런스 카운터 rcu_refcnt를 사용합니다. rcu_read_lock() 기능은 어토믹하게 이 카운터를 증가시키고, RCU read-side 크리티컬 섹션이 이 어토믹 값 증가 뒤로 순서지어지는 것을 보장시킵니다. 유사하게, rcu_read_unlock()은 RCU read-side 크리티컬 섹션을 가두기 위해 메모리 배리어를 실행하고 어토믹하게 그 카운터를 감소시킵니다. synchronize_rcu() 기능은 레퍼런스 카운터에 감싸인 채 이 레퍼런스 카운

Listing B.1: Lock-Based RCU Implementation

```

1 static void rcu_read_lock(void)
2 {
3     spin_lock(&rcu_gp_lock);
4 }
5
6 static void rcu_read_unlock(void)
7 {
8     spin_unlock(&rcu_gp_lock);
9 }
10
11 void synchronize_rcu(void)
12 {
13     spin_lock(&rcu_gp_lock);
14     spin_unlock(&rcu_gp_lock);
15 }
```

Listing B.2: Per-Thread Lock-Based RCU Implementation

```

1 static void rcu_read_lock(void)
2 {
3     spin_lock(&__get_thread_var(rcu_gp_lock));
4 }
5
6 static void rcu_read_unlock(void)
7 {
8     spin_unlock(&__get_thread_var(rcu_gp_lock));
9 }
10
11 void synchronize_rcu(void)
12 {
13     int t;
14
15     for_each_running_thread(t) {
16         spin_lock(&per_thread(rcu_gp_lock, t));
17         spin_unlock(&per_thread(rcu_gp_lock, t));
18     }
19 }
```

Listing B.3: RCU Implementation Using Single Global Reference Counter

```

1 atomic_t rcu_refcnt;
2
3 static void rcu_read_lock(void)
4 {
5     atomic_inc(&rcu_refcnt);
6     smp_mb();
7 }
8
9 static void rcu_read_unlock(void)
10 {
11     smp_mb();
12     atomic_dec(&rcu_refcnt);
13 }
14
15 void synchronize_rcu(void)
16 {
17     smp_mb();
18     while (atomic_read(&rcu_refcnt) != 0) {
19         poll(NULL, 0, 10);
20     }
21     smp_mb();
22 }
```

터가 0이 되기를 기다립니다. Line 19의 poll()은 단순히 순수한 지연을 제공하고, 순수한 RCU 시맨틱의 관점에서는 허용될 수 있습니다. 다시, 일단 synchronize_rcu()가 리턴하면 모든 앞의 RCU read-side 크리티컬 섹션들은 완료되었을 것이 보장됩니다.

Section B.1에서 보여진 락 기반의 구현과 상반되는 장점으로, 이 구현은 RCU read-side 크리티컬 섹션들의 병렬 수행을 가능하게 합니다. Section B.2에서 보여진 쓰레드별 락 기반의 구현과 상반되는 장점으로, 이 구현은 또한 그것들이 중첩될 수 있게 합니다. 또한, rcu_read_lock() 기능은 결코 스핀하지도 블록하지도 않기 때문에 데드락 사이클에 연관될 수 없습니다.

Quick Quiz B.6: 하지만 synchronize_rcu()을 감싸고 락을 잡고 같은 락을 RCU read-side 크리티컬 섹션 내에서 잡으면 어떻게 되죠? ■

하지만, 이 구현은 여전히 일부 심각한 한계점을

Listing B.4: RCU Global Reference-Count Pair Data

```

1 DEFINE_SPINLOCK(rcu_gp_lock);
2 atomic_t rcu_refcnt[2];
3 atomic_t rcu_idx;
4 DEFINE_PER_THREAD(int, rcu_nesting);
5 DEFINE_PER_THREAD(int, rcu_read_idx);

```

가지고 있습니다. 첫째로, `rcu_read_lock()` 과 `rcu_read_unlock()` 안의 어토믹 오퍼레이션들은 여전히 상당히 무겁고, read-side 오버헤드는 하나의 POWER5 CPU에서의 100 나노세컨드부터 64-CPU 시스템에서의 약 40 마이크로세컨드의 범위를 갖습니다. 이는 RCU read-side 크리티컬 섹션들은 실제 read-side 병렬성을 갖기 위해서는 상당히 길어야 함을 의미합니다. 반면에 읽기 쓰레드들이 존재하지 않는다면 grace period는 40 나노세컨드 만에 끝나는데, 이는 리눅스 커널의 제품 품질의 구현보다 수십 수백배는 빠른 겁니다.

Quick Quiz B.7: `synchronize_rcu()` 가 10-밀리세컨드 지연을 포함하고 있는데 어떻게 grace period가 40 나노세컨드 만에 끝날수가 있나요? ■

둘째로, 많은 동시의 `rcu_read_lock()` 과 `rcu_read_unlock()` 오퍼레이션들이 있다면, `rcu_refcnt`에 굉장한 메모리 경쟁이 발생할 거고, 이는 비싼 캐시 미스를 유발할 겁니다. 이 두개의 한계점들은 RCU의 주 목적인 read-side 동기화 기능에 낮은 오버헤드 제공하기를 매우 어렵게 만듭니다.

마지막으로, 긴 read-side 크리티컬 섹션들을 갖는 많은 수의 RCU 읽기 쓰레드들은 글로벌 카운터가 결코 0이 되지 못하게 해서 `synchronize_rcu()` 가 영원히 완료되지 못하게 만들 수도 있습니다. 이는 RCU 업데이트의 starvation을 유발할 수 있는데 이는 당연하게도 제품 환경에서는 받아들여질 수 없는 특성입니다.

Quick Quiz B.8: Figure B.3 의 RCU 구현은 동시의 `synchronize_rcu()` 가 너무 오래 기다리고 있을 때에는 왜 간단히 `rcu_read_lock()` 을 기다리게 만들지 않는 거죠? 그렇게 하면 `synchronize_rcu()` 의 starvation을 막을 수 있지 않나요? ■

따라서, 이 구현은 락 기반의 메커니즘보다는 예를 들어 고도의 스트레스 디버깅 환경에서 적합한 RCU 구현과 같은 잠재성이 약간 있긴 하지만, 제품 환경에서 유용할 거라고 생각하기는 여전히 어렵습니다. 다음 섹션은 쓰기 쓰레드들에 좀 더 신경쓴 레퍼런스 카운팅 방법들을 설명합니다.

B.4 Starvation-Free Counter-Based RCU

Listing B.5 (`rcu_rcgp.h`) 는 Listing B.4에 보여진 한쌍의 레퍼런스 카운터 (`rcu_refcnt[]`) 와 그 한쌍 중 하

Listing B.5: RCU Read-Side Using Global Reference-Count Pair

```

1 static void rcu_read_lock(void)
2 {
3     int i;
4     int n;
5
6     n = __get_thread_var(rcu_nesting);
7     if (n == 0) {
8         i = atomic_read(&rcu_idx);
9         __get_thread_var(rcu_read_idx) = i;
10        atomic_inc(&rcu_refcnt[i]);
11    }
12    __get_thread_var(rcu_nesting) = n + 1;
13    smp_mb();
14 }
15
16 static void rcu_read_unlock(void)
17 {
18     int i;
19     int n;
20
21     smp_mb();
22     n = __get_thread_var(rcu_nesting);
23     if (n == 1) {
24         i = __get_thread_var(rcu_read_idx);
25         atomic_dec(&rcu_refcnt[i]);
26     }
27     __get_thread_var(rcu_nesting) = n - 1;
28 }

```

나의 카운터를 고르는데 사용되는 글로벌 인덱스 (`rcu_idx`), 쓰레드별 중첩 수준 카운터 `rcu_nesting`, 쓰레드별 글로벌 인덱스의 스냅샷 (`rcu_read_idx`), 그리고 하나의 글로벌 락을 사용하는 RCU 구현의 read-side 기능들을 보이고 있습니다.

Design 두개의 원소를 갖는 `rcu_refcnt[]` 배열이야 말로 starvation으로부터 자유를 가져다 주는 그 무엇입니다. 핵심은 `synchronize_rcu()` 는 앞서 존재한 읽기 쓰레드들을 기다리는 것만이 요구된다는 점입니다. 만약 새로운 읽기 쓰레드가 이미 수행을 시작한 특정 `synchronize_rcu()` 인스턴스 뒤에 시작된다면, 그 `synchronize_rcu()` 인스턴스는 이 새로운 읽기 쓰레드를 기다려야 할 필요가 없습니다. 어떤 시점이든, 특정 읽기 쓰레드가 `rcu_read_lock()` 을 통해 자신의 RCU read-side 크리티컬 섹션을 들어갈 때에, 이 읽기 쓰레드는 `rcu_idx` 변수로 가리키는 `rcu_refcnt[]` 배열의 원소의 값을 증가시킵니다. 같은 읽기 쓰레드가 `rcu_read_unlock()` 을 통해 자신의 RCU read-side 크리티컬 섹션을 나갈 때에는 이 읽기 쓰레드는 `rcu_idx` 값에 대해 값을 있는 모든 뒤의 변경들을 무시한 채 자신이 증가시켰던 원소의 값을 감소시킵니다.

이 구성을 `synchronize_rcu()` 가 `rcu_idx` 의 값을 `rcu_idx = !rcu_idx` 식으로 보정함으로써 starvation을 막을 수 있음을 의미합니다. `rcu_idx`의 예전 값이 0이었고, 따라서 새로운 값은 1이 될 것이라고 가정해 봅시다. 이 값 보정 오퍼레이션 후에 도착하는 새로운

읽기 쓰레드들은 `rcu_idx[1]` 을 증가시킬 것이고, 그 동안 앞서 `rcu_idx[0]` 를 증가시켰던 과거의 읽기 쓰레드들은 각자의 RCU read-side 크리티컬 섹션들을 나갈 때마다 `rcu_idx[0]`을 감소시킬 겁니다. 이는 `rcu_idx[0]` 의 값은 더이상 증가하지 않을것이고, 따라서 단조롭게 감소를 하게 될것이라는 의미입니다.² 이는 모든 `synchronize_rcu()` 가 해야할 일은 `rcu_refcnt[0]` 가 0이 될 때까지 기다려야 하는 것 뿐이란 의미입니다.

이 배경지식과 함께라면, 실제 기능들의 구현을 들여다 볼 준비가 되었습니다.

Implementation `rcu_read_lock()` 기능은 `rcu_idx` 로 인덱스되는 `rcu_refcnt[]` 배열의 멤버의 값을 어 토믹하게 증가시키고, 이 인덱스의 스냅샷을 쓰레드별 변수인 `rcu_read_idx` 안에 보관합니다. `rcu_read_unlock()` 함수는 연관된 `rcu_read_lock()` 에서 값을 증가시켰던 카운터의 값을 어토믹하게 감소시킵니다. 하지만, `rcu_idx` 의 하나의 값만이 쓰레드별로 기억되기 때문에 read-side 크리티컬 섹션의 중첩을 허용하게 위해서는 추가적인 방법들이 필요합니다. 이런 추가적인 방법들은 중첩 정보를 쫓아가는데에 쓰레드별 `rcu_nesting` 변수를 사용합니다.

이것들이 모두 동작하도록 하기 위해, Listing B.5 의 `rcu_read_lock()` 의 line 6 에서는 현재 쓰레드의 `rcu_nesting` 인스턴스를 가져오고 line 7 에서는 지금 중첩된 `rcu_read_lock()` 중 가장 바깥에 있음을 확인한 후 line 8-10 에서는 `rcu_idx` 의 현재 값을 가져오고 이 값을 이 쓰레드의 `rcu_read_idx` 에 저장한 후 `rcu_refcnt` 의 선택된 원소의 값을 어토믹하게 증가시킵니다. `rcu_nesting` 의 값과는 무관하게 line 12 에서는 그 값을 증가시킵니다. Line 13 에서는 메모리 배리어를 실행해서 RCU read-side 크리티컬 섹션이 `rcu_read_lock()` 코드 앞으로 튀어나오지 않게 막아줍니다.

비슷하게, `rcu_read_unlock()` 함수는 RCU read-side 크리티컬 섹션이 `rcu_read_unlock()` 코드 뒤로 빠져나가지 않도록 line 21 에서 메모리 배리어를 실행합니다. Line 22 에서는 이 쓰레드의 `rcu_nesting` 인스턴스를 가져오고 line 23 에서 지금 중첩된 `rcu_read_unlock()` 가운데 가장 바깥임을 확인하고, line 24 와 25 에서 이 쓰레드의 (중첩된 `rcu_read_lock()` 중 가장 바깥의 것에서 저장된) `rcu_read_idx` 인스턴스를 가져온 후 `rcu_refcnt` 의 선택된 원소의 값을 감소시킵니다. 중첩 단계와 관계없이, line 27 에서는 이 쓰레드의 `rcu_nesting` 인스턴스의 값을 감소시킵니다.

Listing B.6 (`rcu_rcpg.c`) 는 이에 연관되는 `synchronize_rcu()` 구현을 보입니다. Line 6 과 19

² 이 “단조로운 감소” 문장이 무시하는 race condition 이 있습니다. 이 race condition 은 `synchronize_rcu()` 코드와 함께 다루겠습니다. 그전까지는, 의심을 면줘주시길 바랍니다.

Listing B.6: RCU Update Using Global Reference-Count Pair

```

1 void synchronize_rcu(void)
2 {
3     int i;
4
5     smp_mb();
6     spin_lock(&rcu_gp_lock);
7     i = atomic_read(&rcu_idx);
8     atomic_set(&rcu_idx, !i);
9     smp_mb();
10    while (atomic_read(&rcu_refcnt[i]) != 0) {
11        poll(NULL, 0, 10);
12    }
13    smp_mb();
14    atomic_set(&rcu_idx, i);
15    smp_mb();
16    while (atomic_read(&rcu_refcnt[!i]) != 0) {
17        poll(NULL, 0, 10);
18    }
19    spin_unlock(&rcu_gp_lock);
20    smp_mb();
21 }
```

는 두개 이상의 `synchronize_rcu()` 인스턴스가 동시에 수행되는 것을 막기 위해 `rcu_gp_lock` 을 각각 잡고 풁니다. Line 7-8 은 각각 `rcu_idx` 의 값을 가져오고 뒤따르는 `rcu_read_lock()` 이 앞의 인스턴스들과 다른 `rcu_idx` 원소를 사용하도록 보정합니다. Line 10-12 는 `rcu_idx` 로 가리켜지는 원소의 값이 0이 될때까지 기다리는데 앞서 line 9 에서의 메모리 배리어를 통해 `rcu_idx` 의 체크가 `rcu_idx` 의 보정 앞으로 튀어오르지 않게 합니다. Line 13-18 은 이 과정을 반복하고, line 20 은 어떤 뒤따르는 오퍼레이션들이 `rcu_refcnt` 의 검사를 앞질러 튀어오르지 않게 합니다.

Quick Quiz B.9: Listing B.6 의 `synchronize_rcu()` 의 line 5 의 메모리 배리어는 바로 뒤에 스판락 획득이 있는데도 왜 필요한거죠? ■

Quick Quiz B.10: Listing B.6 에서 카운터는 왜 두번 뒤집히는 거죠? 한번의 뒤집고 기다리는 사이를만으로도 충분하지 않나요? ■

This implementation avoids the update-starvation issues that could occur in the single-counter implementation shown in Listing B.3.

Discussion 여전히 심각한 한계점들이 있습니다. 첫째로, `rcu_read_lock()` 과 `rcu_read_unlock()` 의 어 토믹 오퍼레이션들은 여전히 상당히 무겁습니다. 사실, 이것들은 Listing B.3 의 하나의 카운터 사용 버전보다 더 복잡해서 read-side 기능들은 하나의 POWER5 CPU 에서 약 150 나노세컨드를, 그리고 64-CPU 시스템에서는 약 40 마이크로세컨드를 소모합니다. 업데이트 쪽의 `synchronize_rcu()` 기능은 이보다도 비싸서, 하나의 POWER5 CPU 에서는 200 나노세컨드 정도, 64-CPU 시스템에서는 40 마이크로세컨드 정도를 소모합니다. 이 말은 정말 read-side 병렬성을 얻기 위해서는 RCU

Listing B.7: RCU Per-Thread Reference-Count Pair Data

```

1 DEFINE_SPINLOCK(rcu_gp_lock);
2 DEFINE_PER_THREAD(int [2], rcu_refcnt);
3 atomic_t rcu_idx;
4 DEFINE_PER_THREAD(int, rcu_nesting);
5 DEFINE_PER_THREAD(int, rcu_read_idx);

```

read-side 크리티컬 섹션들이 매우 길어야만 한다는 뜻입니다.

둘째로, 많은 동시적인 `rcu_read_lock()` 과 `rcu_read_unlock()` 오퍼레이션들이 존재한다면, `rcu_refcnt` 원소들에의 극심한 경쟁이 만들어질 것이고, 이는 비싼 캐시 미스들을 유발할 것입니다. 이것은 더 나아가 병렬적인 read-side 액세스를 위해 필요시되는 RCU read-side 크리티컬 섹션 길이를 더욱 늘릴 겁니다. 이 두가지 한계점들은 대부분의 상황에서 RCU의 목적을 달성하기 어렵게 합니다.

셋째로, `rcu_idx` 를 두번이나 뒤집어야 하는 필요성은 업데이트 쪽에 상당한 오버헤드를 의미하는데, 특히 쓰레드의 수가 클 때에 더욱 그러합니다.

마지막으로, 동시의 RCU 업데이트들이 동일한 grace period로 처리될 수 있음에도 불구하고 이 구현은 grace period들을 직렬화 시켜서 grace-period 공유를 불가능하게 합니다.

Quick Quiz B.11: 어토믹 값 증가와 값 감소가 그렇게 비싸다고 하면, Listing B.5 의 line 10 에서는 어토믹하지 않은 값 증가를, line 25 에서는 어토믹하지 않은 값 감소를 하지 그래요? ■

이런 한계점들에도 불구하고, 누군가는 이 RCU 변종이 적은 수의 타이트하게 연결된 CPU 들 위에서는 더 복잡한 구현들과의 API 호환성을 유지하는 메모리 절약 구현으로는 사용될 수도 있을 거라 생각할 겁니다. 하지만, 그건 적은 CPU 들 위로는 확장되지 못할 겁니다.

다음 섹션은 훨씬 개선된 read-side 성능과 확장성을 제공하는 또 다른 레퍼런스 카운팅 기반 방법을 설명합니다.

B.5 Scalable Counter-Based RCU

Listing B.8 (`rcu_rcpl.h`) 는 쓰레드별 레퍼런스 카운터 한쌍을 사용하는 RCU 구현의 read-side 기능들을 보입니다. 이 구현은 Listing B.5 에서 보인 구현과 상당히 비슷한데, 차이점은 `rcu_refcnt` 가 (Listing B.7 에 보인 것과 같이) 쓰레드별 배열이라는 것 뿐입니다. 앞 섹션에서의 알고리즘처럼, 이 두개의 배열의 원소를 사용하는 것은 읽기 쓰레드들이 업데이트 쓰레드들을 starvation 에 빠뜨리는 것을 막습니다. 쓰레드별 `rcu_refcnt` [] 배열의 한가지 장점은 `rcu_read_lock()` 과 `rcu_read_unlock()` 기능들이 더 이상 어토믹 오퍼레이션들을 사용하지 않는다는 것입니다.

Listing B.8: RCU Read-Side Using Per-Thread Reference-Count Pair

```

1 static void rcu_read_lock(void)
2 {
3     int i;
4     int n;
5
6     n = __get_thread_var(rcu_nesting);
7     if (n == 0) {
8         i = atomic_read(&rcu_idx);
9         __get_thread_var(rcu_read_idx) = i;
10        __get_thread_var(rcu_refcnt)[i]++;
11    }
12    __get_thread_var(rcu_nesting) = n + 1;
13    smp_mb();
14 }
15
16 static void rcu_read_unlock(void)
17 {
18     int i;
19     int n;
20
21     smp_mb();
22     n = __get_thread_var(rcu_nesting);
23     if (n == 1) {
24         i = __get_thread_var(rcu_read_idx);
25         __get_thread_var(rcu_refcnt)[i]--;
26     }
27     __get_thread_var(rcu_nesting) = n - 1;
28 }

```

이션들을 사용하지 않는다는 것입니다.

Quick Quiz B.12: 집어쳐요! `rcu_read_lock()` 안에 `atomic_read()` 가 빼히 보인다구요!!! 왜 `rcu_read_lock()` 이 어토믹 오퍼레이션을 포함하고 있지 않은 척하시는거죠??? ■

Listing B.9 (`rcu_rcpl.c`) 는 `synchronize_rcu()` 의 구현을 `flip_counter_and_wait()` 라 이름지어진 함수와 함께 보이고 있습니다. `synchronize_rcu()` 함수는 Listing B.6 에 보인 것과 유사합니다만, 반복된 카운터 뒤집기는 line 22 와 23 에서의 새로운 함수로의 호출 두개로 뒤바뀌었습니다.

이 새로운 `flip_counter_and_wait()` 함수는 `rcu_idx` 변수를 line 5 에서 업데이트하고 line 6 에서 메모리 배리어를 실행한 후 line 7-11 에서 각 쓰레드의 기존 `rcu_refcnt` 원소가 0이 되기를 기다리며 스핀하게 됩니다. 일단 모든 그런 원소들이 0이 된다면, 이 함수는 line 12 에서 또 다른 메모리 배리어를 치고 리턴합니다.

이 RCU 구현은 그 소프트웨어 환경에 중요한 새로운 요구사항을 내포하고 있는데, 이는 (1) 쓰레드별 변수를 선언할 수 있어야 하고, (2) 이 쓰레드별 변수들은 다른 쓰레드들에서도 접근할 수 있어야 하며, (3) 모든 쓰레드의 것들을 하나하나 열거하기가 가능해야 한다는 것입니다. 이런 요구사항들은 거의 모든 소프트웨어 환경에서 충족됩니다만 종종 전체 쓰레드의 갯수의 상한선이 고정되는 결과가 나오곤 합니다. 더 복잡한 구현은 그런 상한선을 제거할 수 있는데, 예를 들면 확장 가능한 해시 테이블을 사용하거나 하는 형태입니다. 그런

Listing B.9: RCU Update Using Per-Thread Reference-Count Pair

```

1 static void flip_counter_and_wait(int i)
2 {
3     int t;
4
5     atomic_set(&rcu_idx, !i);
6     smp_mb();
7     for_each_thread(t) {
8         while (per_thread(rcu_refcnt, t)[i] != 0) {
9             poll(NULL, 0, 10);
10        }
11    }
12    smp_mb();
13 }
14
15 void synchronize_rcu(void)
16 {
17     int i;
18
19     smp_mb();
20     spin_lock(&rcu_gp_lock);
21     i = atomic_read(&rcu_idx);
22     flip_counter_and_wait(i);
23     flip_counter_and_wait(!i);
24     spin_unlock(&rcu_gp_lock);
25     smp_mb();
26 }

```

구현은 동적으로 쓰레드들의 정보를 추적할 수 있을텐데, 예를들면 각 쓰레드들의 정보를 `rcu_read_lock()` 호출 시에 추가하는 형태일 겁니다.

Quick Quiz B.13: 좋아요, 우리가 N 쓰레드들을 가지고 있다면 우리는 $2N$ 10밀리세컨드의 기다리는 호출 (`flip_counter_and_wait()` 당 한 세트) 을 할 수 있을텐데, 우리가 각 쓰레드를 위해 오직 한번 기다린다고 가정해도 그렇습니다. ■

이 구현은 여전히 일부 한계점들을 가지고 있습니다. 먼저, `rcu_idx`를 두번 뒤집어야 하는 필요성은 업데이트 쪽에 상당한 오버헤드를 내포하고 있는데, 특히 많은 수의 쓰레드가 있을때 그렇습니다.

두번째로 `synchronize_rcu()` 는 이제 쓰레드들의 수가 늘어남에 따라 선형적으로 늘어나는 여러 변수들을 조사해야 하는데, 이는 쓰레드의 수가 많은 어플리케이션에 상당한 오버헤드가 있을 것을 암시합니다.

세번째로, 앞에서와 마찬가지로 동시의 RCU 업데이트들은 원론적으로는 공통의 grace period 를 사용할 수 있음에도 이 구현은 grace period 들을 직렬화 시켜서 grace period 공유를 막고 있습니다.

마지막으로, 글에서 이야기했듯, 쓰레드별 변수의 필요성과 쓰레드들을 모두 봐야 한다는 필요성은 일부 소프트웨어 환경에서는 문제가 될 수 있습니다.

그렇다고는 하나, read-side 기능들은 매우 잘 확장되는데, 단일 CPU에서 돌아가든 64-CPU POWER5 시스템에서 돌아가든 상관없이 약 115 나노세컨드를 필요로 합니다. 앞에서 이야기한 바와 같이, `synchronize_rcu()` 기능은 확장되지 못하는데, 그 오버헤드는 단일

Listing B.10: RCU Read-Side Using Per-Thread Reference-Count Pair and Shared Update Data

```

1 DEFINE_SPINLOCK(rcu_gp_lock);
2 DEFINE_PER_THREAD(int [2], rcu_refcnt);
3 long rcu_idx;
4 DEFINE_PER_THREAD(int, rcu_nesting);
5 DEFINE_PER_THREAD(int, rcu_read_idx);

```

Listing B.11: RCU Read-Side Using Per-Thread Reference-Count Pair and Shared Update

```

1 static void rcu_read_lock(void)
2 {
3     int i;
4     int n;
5
6     n = __get_thread_var(rcu_nesting);
7     if (n == 0) {
8         i = READ_ONCE(rcu_idx) & 0x1;
9         __get_thread_var(rcu_read_idx) = i;
10        __get_thread_var(rcu_refcnt)[i]++;
11    }
12    __get_thread_var(rcu_nesting) = n + 1;
13    smp_mb();
14 }
15
16 static void rcu_read_unlock(void)
17 {
18     int i;
19     int n;
20
21     smp_mb();
22     n = __get_thread_var(rcu_nesting);
23     if (n == 1) {
24         i = __get_thread_var(rcu_read_idx);
25         __get_thread_var(rcu_refcnt)[i]--;
26     }
27     __get_thread_var(rcu_nesting) = n - 1;
28 }

```

POWER5 CPU에서의 약 1 마이크로세컨드를, 그리고 64-CPU 시스템에서는 200 마이크로세컨드를 보입니다. 이 구현은 생각건대 제품 품질의 사용자 수준 RCU 구현에 대한 토대가 될 수도 있을 것입니다.

다음 섹션에서는 더 효과적인 동시의 RCU 업데이트들을 가능하게 하는 알고리즘 하나를 설명합니다.

B.6 Scalable Counter-Based RCU With Shared Grace Periods

Listing B.11 (`rcu_rcpls.h`) 는 기존과 같이 쓰레드별 레퍼런스 카운트 쌍을 사용하는, 하지만 업데이트들이 grace period 들을 공유할 수 있게 하는 RCU 구현을 위해 read-side 쪽의 기능들을 보입니다. Listing B.8로 보인 앞의 구현과 주요한 차이점은 `rcu_idx`가 이제는 자유롭게 수를 셀 수 있는 `long` 이어서, Listing B.11의 line 8은 아래쪽의 비트만을 집어내서 사용해야만 합니다. 또한 `atomic_read()` 와 `atomic_set()` 의 사용에서 `ACCESS_ONCE()`로 바꿨습니다. Listing B.10에

Listing B.12: RCU Shared Update Using Per-Thread Reference-Count Pair

```

1 static void flip_counter_and_wait(int ctr)
2 {
3     int i;
4     int t;
5
6     WRITE_ONCE(rcu_idx, ctr + 1);
7     i = ctr & 0x1;
8     smp_mb();
9     for_each_thread(t) {
10         while (per_thread(rcu_refcnt, t)[i] != 0) {
11             poll(NULL, 0, 10);
12         }
13     }
14     smp_mb();
15 }
16
17 void synchronize_rcu(void)
18 {
19     int ctr;
20     int oldctr;
21
22     smp_mb();
23     oldctr = READ_ONCE(rcu_idx);
24     smp_mb();
25     spin_lock(&rcu_gp_lock);
26     ctr = READ_ONCE(rcu_idx);
27     if (ctr - oldctr >= 3) {
28         spin_unlock(&rcu_gp_lock);
29         smp_mb();
30         return;
31     }
32     flip_counter_and_wait(ctr);
33     if (ctr - oldctr < 2)
34         flip_counter_and_wait(ctr + 1);
35     spin_unlock(&rcu_gp_lock);
36     smp_mb();
37 }

```

보인 것처럼, 데이터 또한 상당히 비슷한데 `rcu_idx`는 `atomic_t`가 아니라 `long`으로 바뀌었습니다.

Listing B.12(`rcu_rcpls.c`)는 `synchronize_rcu()`와 거기에 도움을 주는 `flip_counter_and_wait()` 함수를 보입니다. 이것들은 Listing B.9에 있던 것들과 비슷합니다. `flip_counter_and_wait()`의 차이점에는 다음과 같은 것들이 있습니다:

1. Line 6는 `atomic_set()` 대신 `ACCESS_ONCE()`를 사용하고 보정을 하는 대신 값 증가를 시킵니다.
2. 새로운 line 7은 카운터의 가장 아래 비트를 꺼내서 사용합니다.

`synchronize_rcu()`의 변경은 더 많습니다:

1. 락을 잡기 전의 `rcu_idx`의 값을 Line 23에서 저장해 두는, 새로운 로컬 변수 `oldctr`이 존재합니다.
2. Line 26에서는 `atomic_read()` 대신에 `ACCESS_ONCE()`를 사용합니다.
3. Line 27-30은 락을 잡는 동안 다른 쓰레드에 의해 카운터 뒤집기가 최소 세번 이상 이루어졌는지를

확인해보고, 만약 그렇다면 락을 놓고 메모리 배리어를 수행한 후 리턴합니다. 이 경우, 카운터가 0이 될때까지 두번의 완전한 기다림이 있었던 것이고, 따라서 다른 쓰레드들은 이미 모든 필요한 일들을 했습니다.

4. Line 33-34에서, `flip_counter_and_wait()`는 락이 잡히는 동안 두번 미만의 카운터 뒤집기가 이루어졌을 때에만 `flip_counter_and_wait()`를 수행합니다. 한편으로는, 두번의 카운터 뒤집기가 있었다면, 일부 다른 쓰레드는 모든 카운터가 0으로 갈 때까지 완전한 기다림을 수행했으므로, 한번만 더 하면 됩니다.

이 방법에서는 임의의 많은 수의 쓰레드들이 각 쓰레드별로 CPU 하나를 가지고 `synchronize_rcu()`를 동시에 수행하게 되면, 카운터가 0이 되기를 총 세번만 기다리게 될 것입니다.

이 개선에도 불구하고, 이 RCU 구현은 여전히 몇 가지 한계점을 가지고 있습니다. 첫째로, 앞에서와 같이 `rcu_idx`를 두번 뒤집어야 하는 필요성은 업데이트 쪽에 상당한 오버헤드를 암시하는데, 많은 수의 쓰레드들이 존재할 때 특히 그렇습니다.

둘째로, 각 업데이트 쓰레드는 여전히 `rcu_gp_lock`을 잡는데, 할 일이 없을 때조차도 그렇습니다. 이는 수 많은 동시의 업데이트들이 존재한다면 상당한 확장성 한계점으로 작용할 수 있습니다. 리눅스 커널의 제품 품질의 RCU 리얼타임 구현 [McK07a]에서 사용되었던 것처럼, 이 문제를 막는 방법들은 존재합니다.

세번째로, 이 구현은 쓰레드별 변수와 쓰레드들을 모두 돌아봐야 하는 기능을 필요로하는데, 이는 역시 일부 소프트웨어 환경에서는 문제가 될 수 있습니다.

마지막으로, 32-bit 머신에서는 특정 업데이트 쓰레드가 `rcu_idx` 카운터가 오버헤드 되도록 긴 시간동안 preemption 당할 수 있습니다. 이는 그런 쓰레드가 불필요한 카운터 뒤집기를 하도록 하게 만들 수도 있습니다. 하지만, 각각의 grace period 가 1 마이크로세컨드 만을 가진다 하더라도, 문제의 쓰레드는 한시간 이상을 preemption 당할 수 있어서 추가적인 카운터 뒤집기만 걱정해도 될 가능성이 큽니다.

Section B.3에서 설명한 구현에서와 같이, 이 read-side 기능들은 상당히 잘 확장되는데, CPU의 수에 관계없이 대략 115 나노세컨드의 오버헤드를 갖습니다. `synchronize_rcu()` 기능은 여전히 비싼 편인데, 1 마이크로세컨드에서 16 마이크로세컨드 사이의 오버헤드를 갖습니다. 이는 Section B.5의 구현에서 가졌던 대략 200 마이크로세컨드의 오버헤드에 비하면 더도 덜도 아니고 훨씬 저렴한 비용입니다. 따라서, 그 제한점들에도 불구하고, 이 RCU 구현은 실제 삶에서 접하는 활용처의 제품에서 사용될 수도 있을 거라고 생각될 수 있을

Listing B.13: Data for Free-Running Counter Using RCU

```

1 DEFINE_SPINLOCK(rcu_gp_lock);
2 long rcu_gp_ctr = 0;
3 DEFINE_PER_THREAD(long, rcu_reader_gp);
4 DEFINE_PER_THREAD(long, rcu_reader_gp_snap);

```

겁니다.

Quick Quiz B.14: 이 모든 장난감 RCU 구현들은 `rcu_read_lock()` 과 `rcu_read_unlock()` 안에 어토믹 오퍼레이션들을 가지고 있거나 쓰레드의 수에 따라 선형적으로 증가하는 `synchronize_rcu()` 의 오버헤드를 갖습니다. 어떤 환경에서라면 RCU 구현이 이 세 개의 기능들이 모두 결정적인 ($O(1)$) 의 오버헤드와 대기시간을 갖는 가벼운 구현을 가질 수 있을까요? ■

Listing B.11로 돌아가서, 우리는 하나의 전역 변수 접근과 thread-local 변수들로의 네번보다 적지 않은 액세스들이 존재함을 볼 수 있습니다. POSIX 쓰레드를 구현하는 시스템에서의 상대적으로 비싼 비용의 thread-local 액세스들을 놓고 보면, 이 세개의 thread-local 변수들을 하나의 구조체로 만들어서 `rcu_read_lock()` 과 `rcu_read_unlock()` 의 thread-local 데이터로의 접근을 하나의 thread-local-storage로의 접근으로 바꾸고 싶을 수 있을 겁니다. 하지만, 그보다도 더 나은 접근은 다음 섹션에서 하듯이, thread-local 액세스의 수를 하나로 바꾸는 것일 겁니다.

B.7 RCU Based on Free-Running Counter

Listing B.14 (`rcu.h` and `rcu.c`)는 Listing B.13에 보여진 데이터와 함께 짹수 값만을 갖는 글로벌한 자유롭게 동작하는 카운터에 기반한 RCU 구현을 보입니다. 이렇게 만들어진 `rcu_read_lock()` 구현은 상당히 단순합니다. Line 3과 4에서는 단순히 글로벌한 자유롭게 동작하는 `rcu_gp_ctr` 변수에 1을 더한 값으로 만들어진 훌수를 쓰레드별 변수인 `rcu_reader_gp`에 저장합니다. Line 5는 뒤따르는 RCU read-side 크리티컬 섹션의 내용이 “빼져나오는 것”을 방지하기 위해 메모리 배리어를 실행합니다.

`rcu_read_unlock()` 구현 역시 비슷합니다. Line 10에서는 이번에도 앞의 RCU read-side 크리티컬 섹션이 “빼져나오는 것”을 방지하기 위해 메모리 배리어를 실행합니다. Line 11과 12는 `rcu_gp_ctr` 글로벌 변수의 값을 쓰레드별 변수인 `rcu_reader_gp`에 복사해서 이 쓰레드별 변수의 값을 짹수로 만들도록 인해 동시에 `synchronize_rcu()` 인스턴스가 이를 무시해도 좋을 것임을 알립니다.

Quick Quiz B.15: 짹수만으로도 해당 태스크를 무시해도 좋다고 `synchronize_rcu()`에 말하기에 충분하

Listing B.14: Free-Running Counter Using RCU

```

1 static void rcu_read_lock(void)
2 {
3     __get_thread_var(rcu_reader_gp) =
4         ACCESS_ONCE(rcu_gp_ctr) + 1;
5     smp_mb();
6 }
7
8 static void rcu_read_unlock(void)
9 {
10    smp_mb();
11    __get_thread_var(rcu_reader_gp) =
12        ACCESS_ONCE(rcu_gp_ctr);
13 }
14
15 void synchronize_rcu(void)
16 {
17     int t;
18
19     smp_mb();
20     spin_lock(&rcu_gp_lock);
21     ACCESS_ONCE(rcu_gp_ctr) += 2;
22     smp_mb();
23     for_each_thread(t) {
24         while ((per_thread(rcu_reader_gp, t) & 0x1) &&
25                ((per_thread(rcu_reader_gp, t) -
26                  ACCESS_ONCE(rcu_gp_ctr)) < 0)) {
27             poll(NULL, 0, 10);
28         }
29     }
30     spin_unlock(&rcu_gp_lock);
31     smp_mb();
32 }

```

다면 Listing B.14의 line 10과 11은 왜 단순히 `rcu_reader_gp`에 0을 할당하지 않나요? ■

따라서, `synchronize_rcu()`는 이 모든 쓰레드별 `rcu_reader_gp` 변수들이 짹수를 가지게 될때까지 기다릴 수도 있습니다. 하지만, 그보다 훨씬 나은 방법이 있는데 `synchronize_rcu()`는 전부터 존재한 RCU read-side 크리티컬 섹션들만 기다리면 그만이기 때문입니다. Line 19에서는 앞의 RCU로 보호되는 데이터 구조체의 조정이 line 21의 값 증가 뒤로 (CPU에 의해 서든 컴파일러에 의해서든) 재배치 되는 것을 막기 위해 메모리 배리어를 실행합니다. Line 20에서는 여러개의 `synchronize_rcu()` 인스턴스들이 동시에 수행되는 것을 막기 위해 `rcu_gp_lock`을 획득합니다 (그리고 line 30에서 이를 해제합니다). Line 21은 글로벌 변수인 `rcu_gp_ctr`의 값을 2 만큼 증가시켜서 모든 전부터 존재해온 RCU read-side 크리티컬 섹션들이 갖는 그들과 연관된 쓰레드별 변수 `rcu_reader_gp`는 `rcu_gp_ctr`보다 작은 값을 가지게 될 것입니다. 짹수 값의 `rcu_reader_gp`를 갖는 쓰레드들은 RCU read-side 크리티컬 섹션에 들어가 있지않다는 점을 다시 상기해서, line 23-29는 `rcu_reader_gp` 값을 그 모든 것들이 짹수이거나 (line 24) 글로벌한 `rcu_gp_ctr` 보다 큰 동안 (line 25-26) 스캔합니다. Line 27에서는 앞서 존재해온 RCU read-side 크리티컬 섹션을 기다리기 위해 짧은 시간동안 블록하지만 만약 grace-period 대기시간이 중

Listing B.15: Data for Nestable RCU Using a Free-Running Counter

```

1 #define _SPINLOCK(rcu_gp_lock);
2 #define RCU_GP_CTR_SHIFT 7
3 #define RCU_GP_CTR_BOTTOM_BIT (1 << RCU_GP_CTR_SHIFT)
4 #define RCU_GP_CTR_NEST_MASK (RCU_GP_CTR_BOTTOM_BIT - 1)
5 long rcu_gp_ctr = 0;
6 #define _PER_THREAD(long, rcu_reader_gp);

```

요하다면 스펀 루프로 교체될 수 있습니다. 마지막으로, line 31에서의 메모리 배리어는 뒤따르는 모든 오브젝트 해체가 루프의 앞으로 재배치 되지 않도록 보장합니다.

Quick Quiz B.16: Listing B.14 의 line 19 와 31에서의 메모리 배리어들은 왜 필요한 건가요? line 20 과 30에서의 락킹이 충분한데 메모리 배리어는 피할 수 있지 않나요? ■

이 전략은 훨씬 나은 read-side 성능을 달성할 수 있게 하는데, POWER5 CPU 들의 숫자에 관계 없이 대략 63 나노세컨드의 오버헤드를 갖습니다. 업데이트는 더 많은 오버헤드를 갖는데, 하나의 POWER5 CPU에서 500 나노세컨드로부터 64 개의 CPU에서 100 마이크로 세컨드 까지 같습니다.

Quick Quiz B.17: Section B.6에서 설명한 update-side batching 이 Listing B.14 에 보인 구현에 적용될 수도 있지 않을까요? ■

이 구현은 앞서 언급한 많은 update-side 오버헤드 외에도 몇가지 심각한 한계점들로 인해 문제가 될 수 있습니다. 먼저, 더이상 중첩된 RCU read-side 크리티컬 섹션들이 불가능한데, 이에 대해선 다음 섹션에서 다루도록 합니다. 둘째로, 읽기 쓰레드가 rCU_gp_ctr에서 값을 읽어왔지만 rCU_reader_gp에 값을 저장하기 전에 Listing B.14 의 line 3에서 preemption 당하고 rCU_gp_ctr 카운터가 가질 수 있는 값들보다는 적게, 하지만 그 절반보다는 많게 값 증가를 반복한다면, synchronize_rcu() 는 이 뒤의 RCU read-side 크리티컬 섹션을 무시하게 될겁니다. 마지막으로, 이 구현은 쓰레드별 변수들을 유지할 수 있고 모든 쓰레드들을 검사할 수 있는 소프트웨어 환경에 들어가 있을 것을 필요로 합니다.

Quick Quiz B.18: Listing B.14 의 line 3-4에서 읽기 쓰레드들이 preemption 당할 수 있다는 사실은 진짜 문제일까요? 달리 말하자면, 정말 실패를 만들 수 있는 실제의 이벤트들이 존재하나요? 그렇지 않다면, 왜죠? 그렇다면, 그 이벤트들은 어떤 것이고, 그 실패는 어떻게 해결될 수 있을까요? ■

Listing B.16: Nestable RCU Using a Free-Running Counter

```

1 static void rCU_read_lock(void)
2 {
3     long tmp;
4     long *rrgp;
5
6     rrgp = &_get_thread_var(rcu_reader_gp);
7     tmp = *rrgp;
8     if ((tmp & RCU_GP_CTR_NEST_MASK) == 0)
9         tmp = ACCESS_ONCE(rcu_gp_ctr);
10    tmp++;
11    *rrgp = tmp;
12    smp_mb();
13 }
14
15 static void rCU_read_unlock(void)
16 {
17     long tmp;
18
19     smp_mb();
20     _get_thread_var(rcu_reader_gp)--;
21 }
22
23 void synchronize_rcu(void)
24 {
25     int t;
26
27     smp_mb();
28     spin_lock(&rcu_gp_lock);
29     ACCESS_ONCE(rcu_gp_ctr) += RCU_GP_CTR_BOTTOM_BIT;
30     smp_mb();
31     for_each_thread(t) {
32         while (rcu_gp_onGoing(t) &&
33                ((per_thread(rcu_reader_gp, t) -
34                  rCU_gp_ctr) < 0)) {
35             poll(NULL, 0, 10);
36         }
37     }
38 }
39 spin_unlock(&rcu_gp_lock);
40 smp_mb();
41 }

```

B.8 Nestable RCU Based on Free-Running Counter

Listing B.16 (rcu_nest.h and rcu_nest.c) 는 하나의 글로벌한 자유롭게 동작하는 카운터에 기반하지만 RCU read-side 크리티컬 섹션들의 중첩을 허용하는 RCU 구현을 보입니다. 이 중첩 가능성은 Listing B.15 에 보인 정의들을 사용해서 글로벌한 rCU_gp_ctr의 아래쪽 비트들을 중첩을 세는데 사용하도록 전용화 함으로써 이루어집니다. 이는 Section B.7에서 보인, 아래쪽의 하나의 비트를 중첩 단계를 세는데에 사용한 것으로 생각될 수 있는 방법의 일반화된 방법입니다. 이를 위해 두개의 C 프리프로세서 매크로인 RCU_GP_CTR_NEST_MASK 와 RCU_GP_CTR_BOTTOM_BIT 이 사용됩니다. 이 매크로들은 연관되어 있습니다: RCU_GP_CTR_NEST_MASK=RCU_GP_CTR_BOTTOM_BIT-1. RCU_GP_CTR_BOTTOM_BIT 매크로는 중첩 단계를 세기 위해 전용화된 비트들의 바로 앞에 자리잡은 하나의 비트를 가지고 있으며, RCU_GP_CTR_

NEST_MASK는 `rcu_gp_ctrl`에서 중첩 단계를 세기 위해 사용되는 지역에 모두 1 비트를 채워 가지고 있습니다. 분명하게, 두개의 C 프리프로세서 매크로들은 요구되는 최대의 RCU read-side 크리티컬 섹션들의 중첩을 허용하기 충분한 만큼의 카운터의 아래쪽 비트들을 가지고 있어야 하고, 이 구현은 대부분의 어플리케이션들에서 충분할 만한 크기인 최대 127 단계의 RCU read-side 크리티컬 섹션 중첩을 위해 일곱개의 비트를 준비해 두고 있습니다.

그렇게 해서 만들어진 `rcu_read_lock()` 구현은 여전히 합리적인 수준으로 간단합니다. Line 6에서는 이 쓰레드의 `rcu_reader_gp` 인스턴스로의 포인터를 지역 변수인 `rrgp`로 가져와서 비싼 pthreads thread-local-state API의 호출 횟수를 최소화 합니다. Line 7에서는 `rcu_reader_gp`의 현재 값을 또 다른 지역 변수인 `tmp`에 기록하고, line 8에서 그 아래쪽 비트들이 0인지 확인하는데, 이는 이 쓰레드가 가장 바깥의 `rcu_read_lock()`을 수행중인지 확인하게 됩니다. 만약 그렇다면, line 9에서는 line 7에서 앞서 가져왔던 현재의 값은 더이상 유효하지 않을 수 있으므로 글로벌 변수인 `rcu_gp_ctrl`를 `tmp`에 넣습니다. 어떤 경우든, line 10에서는 중첩 단계를 증가시키는데, 이는 카운터의 아래쪽 7개의 비트들에 저장됩니다. Line 11에서는 업데이트된 카운터를 이 쓰레드의 `rcu_reader_gp` 인스턴스에 업데이트하고, 마지막으로 line 12에서는 RCU read-side 크리티컬 섹션이 앞의 `rcu_read_lock()` 안으로 빠져 나오지 않도록 메모리 배리어를 실행합니다.

달리 말하면, 이 `rcu_read_lock()` 구현은 현재의 `rcu_read_lock()`의 실행이 RCU read-side 크리티컬 섹션 안에서 중첩되어 있지 않다면 글로벌 변수 `rcu_gp_ctrl`의 복사본을 가져오고, 그렇지 않다면 현재 쓰레드의 `rcu_reader_gp`의 값을 가져옵니다. 어떤 경우든, 추가적인 중첩 단계를 기록하기 위해 뭐가 가져와졌든 가져온 값을 증가시키고 그 결과를 현재 쓰레드의 `rcu_reader_gp` 인스턴스에 저장합니다.

흥미롭게도, 이 `rcu_read_lock()`의 차이점에도 불구하고, `rcu_read_unlock()`의 구현은 Section B.7에 보인 것과 상당히 유사합니다. Line 19에서는 RCU read-side 크리티컬 섹션이 뒤따르는 `rcu_read_unlock()`으로 빠져나오는 걸 막기 위해 메모리 배리어를 실행하고, line 20에서 이 쓰레드의 `rcu_reader_gp`의 인스턴스를 값 감소시키는데, 이는 `rcu_reader_gp`의 아래쪽 비트들에 저장되어 있는 중첩 단계 카운트를 감소시키는 효과를 갖습니다. 이 기능의 디버깅 버전은 (값을 감소시키기 전에!) 이 아래쪽 비트들이 0이 아닌지 검사할 수도 있을 겁니다.

`synchronize_rcu()`의 구현은 Section B.7에 보인 것과 상당히 유사합니다. 그 사이엔 두 가지 차이가 있습니다. 첫번째는 line 29 와 30에서 상수 “2”가 아

Listing B.17: Data for Quiescent-State-Based RCU

```
1 DEFINE_SPINLOCK(rcu_gp_lock);
2 long rcu_gp_ctrl = 0;
3 DEFINE_PER_THREAD(long, rcu_reader_qs_gp);
```

나라 `RCU_GP_CTR_BOTTOM_BIT` 을 `rcu_gp_ctrl`에 더 한다는 것이고, 두번째는 line 33에서의 비교가 조건에 관계없이 아래쪽 비트를 검사하는게 아니라 `RCU_GP_CTR_BOTTOM_BIT`을 검사하는 별도의 함수로 추상화 되었다는 점입니다.

이 방법은 Section B.7에 보인 것과 거의 유사한 read-side 성능을 달성하는데, POWER5 CPU의 수와 관계 없이 대략 65 나노세컨드의 오버헤드를 보입니다. 업데이트는 이번에도 더 많은 오버헤드를 갖는데, 하나의 POWER5 CPU에서 약 600 나노세컨드부터 64 CPU에서 약 100 마이크로세컨드를 갖습니다.

Quick Quiz B.19: 이 복잡한 비트 조정을 하는 대신에 앞의 섹션에서 그랬듯이 별도의 쓰레드별 중첩 수준 변수를 갖지 않는 건가요? ■

이 구현은 RCU read-side 크리티컬 섹션들의 중첩이 이제는 가능하다는 점을 제외하고는 Section B.7에서의 것과 동일한 한계점들로 문제가 될 수 있습니다. 또한, 32비트 시스템에서라면, 이 전략은 global `rcu_gp_ctrl` 변수를 오버플로우 시키는데 필요한 시간을 더 줄여버릴 수 있습니다. 다음 섹션은 오버플로우가 일어나는데 필요한 시간을 훨씬 증가시키면서도 read-side 오버헤드는 훨씬 줄이는 한가지 방법을 보입니다.

Quick Quiz B.20: Listing B.16에 보여진 알고리즘에서, 어떻게 하면 전역 변수인 `rcu_gp_ctrl`가 오버플로우 되는데 걸리는 시간을 두배로 늘릴 수 있을까요? ■

Quick Quiz B.21: 다시, Listing B.16에 보여진 알고리즘에서, 카운터 오버플로우는 치명적인가요? 그 이유는 무엇이죠? 만약 치명적이라면, 그걸 고치기 위해 뭘 할 수 있을까요? ■

B.9 RCU Based on Quiescent States

Listing B.18 (`rcu_qs.h`)는 조용한 상태에 기반한 사용자 레벨 RCU 구현을 만드는데에 Listing B.17에 보인 데이터와 함께 사용되는 read-side 기능들을 보입니다. 그림의 line 1-7에서 볼 수 있듯이, `rcu_read_lock()`과 `rcu_read_unlock()` 기능들은 아무일도 하지 않고, 따라서 인라인 함수로 바뀌고 최적화 단계에서 아예 사라져서 버릴 거라 예상할 수 있고, 리눅스 커널의 서버 빌드에서는 그렇습니다. 이는 조용한-상태-기반의 RCU 구현들은 RCU read-side 크리티컬 섹션들의 양을 앞서 언급한 조용한 상태들을 사용해서 어림잡는다는 사실 때문입니다. 이러한 각각의 조용한 상태

Listing B.18: Quiescent-State-Based RCU Read Side

```

1 static void rcu_read_lock(void)
2 {
3 }
4
5 static void rcu_read_unlock(void)
6 {
7 }
8
9 rcu_quiescent_state(void)
10 {
11     smp_mb();
12     __get_thread_var(rcu_reader_qs_gp) =
13         ACCESS_ONCE(rcu_gp_ctrl) + 1;
14     smp_mb();
15 }
16
17 static void rcu_thread_offline(void)
18 {
19     smp_mb();
20     __get_thread_var(rcu_reader_qs_gp) =
21         ACCESS_ONCE(rcu_gp_ctrl);
22     smp_mb();
23 }
24
25 static void rcu_thread_online(void)
26 {
27     rcu_quiescent_state();
28 }

```

들은 `rcu_quiescent_state()` 호출을 포함하는데, 이 함수는 이 그림의 line 9-15에 보여져 있습니다. 확장된 조용한 상태에 들어가는 쓰레드는 (예를 들어, 블록되었을 때) 대신 `rcu_thread_offline()` (line 17-23)을 호출하고 그로부터 빠져나올 때에는 `rcu_thread_online()` (line 25-28)을 호출할 수 있습니다. 그런 식으로, `rcu_quiescent_state()`는 `rcu_read_lock()`과 유사하고 `rcu_thread_offline()`은 `rcu_read_unlock()`과 유사합니다. 또한, `rcu_quiescent_state()`는 `rcu_thread_online()` 뒤에 곧바로 `rcu_thread_offline()`이 이어지는 것으로 생각될 수 있습니다.³ RCU read-side 크리티컬 섹션 내에서 `rcu_quiescent_state()`, `rcu_thread_offline()`, 또는 `rcu_thread_online()`을 호출하는 건 금지된 행위입니다.

`rcu_quiescent_state()`에서, line 11에서는 이 quiescent state (조용한 상태) 앞의 (RCU read-side 크리티컬 섹션들을 포함해서) 어떤 코드가 quiescent state 앞으로 재배치 되는 것을 막기 위해 메모리 배리어를 칩니다. Line 12-13에서는 글로벌 변수 `rcu_gp_ctrl`의 복사본을 가져오는데, `rcu_gp_ctrl`가 두번 이상 가져와지는 최적화가 만들어지거나 하지 않게 `ACCESS_ONCE()`를 사용합니다. 그리고 나서 가져온 값에 1을 더하고 쓰레드별 변수인 `rcu_reader_qs_gp`에 저장해서 모든 동시에 수행되는 `synchronize_rcu()` 인스턴스들은 훌

³ 비록 이 그림의 코드가 `rcu_quiescent_state()`가 `rcu_thread_online()` 뒤에 곧바로 `rcu_thread_offline()`이 따라오는 것과 같지만, 이 관계는 성능 최적화로 인해 불투명해집니다.

Listing B.19: RCU Update Side Using Quiescent States

```

1 void synchronize_rcu(void)
2 {
3     int t;
4
5     smp_mb();
6     spin_lock(&rcu_gp_lock);
7     rcu_gp_ctrl += 2;
8     smp_mb();
9     for_each_thread(t) {
10         while (rcu_gp_ongoing(t) &&
11                ((per_thread(rcu_reader_qs_gp, t) -
12                  rcu_gp_ctrl) < 0)) {
13             poll(NULL, 0, 10);
14         }
15     }
16     spin_unlock(&rcu_gp_lock);
17     smp_mb();
18 }

```

수를 볼 수 있게 해서, 새로운 RCU read-side 크리티컬 섹션이 시작되었음을 알 수 있게 합니다. 예전의 RCU read-side 크리티컬 섹션들을 기다리는 `synchronize_rcu()`의 인스턴스들은 따라서 이것을 무시해도 좋을 것임을 알 수 있게 됩니다. 마지막으로, line 14에서는 메모리 배리어를 실행해서 (RCU read-side 크리티컬 섹션을 포함해서) 뒤따르는 코드가 line 12-13과 재배치되는 일을 방지합니다.

Quick Quiz B.22: Listing B.18의 line 14에 보인 추가적인 메모리 배리어는 `rcu_quiescent_state`의 오버헤드를 많이 늘리지 않을까요? ■

어떤 어플리케이션들은 RCU를 가끔씩만 쓰지만, 사용할 때에는 매우 자주 사용할 수도 있습니다. 그런 어플리케이션들은 RCU를 사용하기 시작할 때 `rcu_thread_online()`을 사용하고 더이상 RCU를 사용하지 않을 때에 `rcu_thread_offline()`을 사용할 수 있을 겁니다. `rcu_thread_offline()` 호출과 뒤따르는 `rcu_thread_online()` 사이의 시간은 하나의 확장된 quiescent state 여서, RCU는 이 시간동안 명시적으로 quiescent state가 등록되지는 않을 것이라고 예상할 수 있습니다.

`rcu_thread_offline()` 함수는 쓰레드별 변수 `rcu_reader_qs_gp` 변수를 `rcu_gp_ctrl`의 현재 값으로 설정하는데, 이 값은 짹수 값을 가질 겁니다. 따라서 동시에 수행되는 `synchronize_rcu()` 인스턴스들은 이 쓰레드를 무시해도 됨을 알 것입니다.

Quick Quiz B.23: Listing B.18의 line 19와 22의 메모리 배리어들은 왜 필요한 건가요? ■

`rcu_thread_online()`은 단순히 `rcu_quiescent_state()`를 호출해서 연장된 quiescent state의 종료를 표시합니다.

Listing B.19 (`rcu_qs.c`)는 `synchronize_rcu()`의 구현을 보이는데, 이는 앞 섹션들에서의 것과 상당히 유사합니다.

이 구현은 `rcu_read_lock()`-`rcu_read_unlock()` 왕복에 대략 50 피코세컨드 라는 엄청나게 빠른 read-side 기능들을 갖습니다. `synchronize_rcu()` 의 오버헤드는 단일 CPU 의 POWER5 시스템에서 600 나노세컨드부터 64-CPU 시스템에서 100 마이크로세컨드 까지의 오버헤드를 갖습니다.

Quick Quiz B.24: 분명히 해두겠는데, 2008 년의 POWER 시스템들의 클락 주파수는 상당히 높았지만, 5GHz 클락 주파수도 루프가 50 피코세컨드만에 실행되게 하는데에는 부족해요! 무슨 일이 벌어진 거죠? ■

하지만, 이 구현은 각 쓰레드가 주기적으로 `rcu_quiescent_state()` 를 호출하거나 연장된 quiescent state 를 위해 `rcu_thread_offline()` 을 호출해 줄것을 필요로 합니다. 이 함수들을 주기적으로 실행해야 하는 필요성은 이 구현을 특정 타입의 라이브러리 함수들과 같은 일부 환경에서는 사용하기 어렵게 할 수 있습니다.

Quick Quiz B.25: 코드가 라이브러리에 있다는 사실이 왜 Listing B.18 와 B.19 에 보여진 RCU 구현의 사용에 어려움을 가져올 수 있는 건가요? ■

Quick Quiz B.26: 하지만 락을 `synchronize_rcu()` 전후에 걸쳐 잡고, 같은 락을 RCU read-side 크리티컬 섹션에서 잡으면 어떻게 되나요? 이건 데드락이 되어야 할텐데, 하지만 어떻게 어떤 코드도 만들지 않는 기능이 데드락 사이클에 참여될 수가 있죠? ■

또한, 이 구현은 동시의 `synchronize_rcu()` 호출이 grace period 를 공유할 수 있도록 허용하지 않습니다. 그렇다고 하나, 이 버전의 RCU 에 기초해서 제품 품질의 RCU 구현을 쉽게 생각해 볼 수 있을 겁니다.

B.10 Summary of Toy RCU Implementations

여기까지 잘 도착했다면, 축하합니다! 이제 독자 여러분은 RCU 자체에 대해서만이 아니라 그걸 둘러싸고 있는 소프트웨어 환경들과 어플리케이션들의 요구 사항들에 대해서도 분명한 이해를 가지게 되었을 겁니다. 이보다도 더 깊은 이해를 원하는 분들은 제품 품질의 RCU 구현에 대한 설명을 읽어보시기 바랍니다 [DMS⁺12, McK07a, McK08a, McK09c].

앞의 섹션들에서는 다양한 RCU 기능들의 바랄법한 속성들을 열거해 보았습니다. 새로운 RCU 구현을 만들고자 하는 분들이 쉽게 참조해 볼 수 있도록 다음의 리스트를 제공합니다.

1. Read-side 기능들 (`rcu_read_lock()` 과 `rcu_read_unlock()` 과 같은 것들) 과 grace-period 기능들 (`synchronize_rcu()` 와 `call_rcu()` 와 같은 것들) 이 반드시 있어야만 하는데, 그것들은

grace period 의 시작 시점에 존재한 read-side 크리티컬 섹션은 모두 그 grace period 의 종료 전까지는 완료되어야 합니다.

2. RCU read-side 기능들은 최소한의 오버헤드만을 가져야 합니다. 구체적으로는, 캐시 미스, 어토믹 인스트럭션, 메모리 배리어, 그리고 브랜칭과 같은 비싼 오퍼레이션들은 방지되어야 합니다.
3. 리얼타임 쪽에서의 사용을 위해선 RCU read-side 기능들은 $O(1)$ 의 계산 복잡도를 가져야 합니다. (이는 읽기 쓰레드들은 업데이트 쓰레드들과 동사에 수행됨을 암시합니다.)
4. RCU read-side 기능들은 모든 컨텍스트에서 사용이 가능해야 합니다 (리눅스 커널에서는, idle 루프를 제외한 모든 곳에서 사용이 가능합니다). 중요한 특수 케이스는 RCU read-side 기능들이 RCU read-side 크리티컬 섹션 내부에서 사용되는 것으로, 달리 말하면, RCU read-side 크리티컬 섹션들은 중첩될 수 있어야 합니다.
5. RCU read-side 기능들은 무조건적으로 수행되어서 실패를 리턴하거나 하지 않아야 합니다. 이 속성은 굉장히 중요한데, 실패여부 검사는 복잡성을 증가시키고 테스트와 검증을 번거롭게 만들기 때문입니다.
6. Quiescent state (그리고 grace period) 를 제외한 모든 오퍼레이션은 RCU read-side 크리티컬 섹션 내에서 사용 가능해야 합니다. 구체적으로는, I/O 와 같이 최소 불가능한 오퍼레이션들이 사용 가능해야 합니다.
7. RCU 로 보호되는 데이터 구조체는 RCU read-side 크리티컬 섹션에서 실행 중일 때에도 업데이트 할 수 있어야 합니다.
8. RCU read-side 기능들도 update-side 기능들도 메모리 할당자 설계와 구현과는 독립적이어야 하는데, 달리 말해서, 같은 RCU 구현은 특정 데이터 구조에 대해 그 데이터 원소들이 어떻게 할당되고 해제되는가에 관계없이 그 데이터 구조를 보호할 수 있어야 합니다.
9. RCU grace period 는 RCU read-side 크리티컬 섹션들 바깥에서 종료되는 쓰레드들에 의해 블록되지 않아야 합니다. (하지만 대부분의 quiescent-state 기반의 구현은 이 필요성을 위반합니다.)

Quick Quiz B.27: Grace period 가 RCU read-side 크리티컬 섹션들로 통제된다면, RCU로 보호되는 데이터 구조체는 어떻게 RCU read-side 크리티컬 섹션 내에서 업데이트 될 수 있을까요? ■

Appendix C

Why Memory Barriers?

그래서 무엇이 CPU 설계자들을 불쌍하고 의심할 줄 모르는 SMP 소프트웨어 설계자들에게 메모리 배리어를 주게 만들었을까요?

한마디로, 메모리 참조 순서 재배치는 성능을 훨씬 좋게 만들고, 따라서 올바른 동작 여부가 메모리 참조 순서에 의존적인 동기화와 같은 작업에는 순서를 강제하기 위해 메모리 배리어가 필요해졌습니다.

이 질문에 더 자세한 답변을 얻기 위해선 어떻게 CPU 캐시들이 동작하는지, 특히 캐시가 정말 잘 동작하게 하기 위해 필요한게 무엇인지에 대한 깊은 이해가 필요합니다. 다음의 섹션들은:

1. 캐시의 구조를 보이고,
2. 캐시 일관성 프로토콜이 어떻게 CPU 들이 메모리의 각 위치의 값들에 대해 합의하며, 마지막으로,
3. 어떻게 스토어 베퍼들과 인밸리데이트 큐들이 캐시와 캐시 일관성 프로토콜이 높은 성능을 얻을 수 있게 돋는지 알아봅니다.

우린 메모리 배리어들이 좋은 성능과 확장성을 위한 필 요약이고, CPU 들이 그들 사이의 접합부보다도, 그들이 접근하려 시도하는 메모리 보다도 훨씬 빠르다는 사실로부터 기인했음을 보게 될 것입니다.

C.1 Cache Structure

현대의 CPU 들은 현대의 메모리 시스템들보다 훨씬 빠릅니다. 2006 년의 CPU 는 나노세컨드당 열개의 인스트리션들을 수행할 수 있습니다만, 메인 메모리에서 데이터 아이템 하나를 가져오는데엔 수십 나노세컨드를 필요로 할겁니다. 이 속도의 간극 — 100 배가 넘는 — 이 현대 CPU 에서 볼 수 있는 수 메가바이트의 캐시를 있게 했습니다. 이런 캐시들은 Figure C.1 에 보여졌듯,

CPU 들과 연관되어지고 수 사이클만에 접근될 수 있습니다.¹




Figure C.1: Modern Computer System Cache Structure

CPU 의 캐시와 메모리 사이의 데이터 흐름은 “캐시 라인” 이라 불리는, 일반적으로 16 과 256 사이의 2의 거듭제곱 바이트 크기인, 고정된 길이의 블록 단위로 이루어집니다. 한 데이터 아이템이 한 CPU 에 의해 처음 액세스 되면, 그 아이템은 해당 CPU 의 캐시에 없을 것이고, 이는 곧 “캐시 미스”(또는, 보다 분명히 말하면, “스타트업” 또는 “웜업” 캐시 미스)를 의미합니다. 이 캐시 미스는 CPU 는 해당 아이템이 메모리로부터 얻어져 오는 동안 수백 사이클을 기다려야(또는 “스톨” 되어야) 함을 의미합니다. 하지만, 해당 아이템은 해당 CPU 의 캐시 위에 로드될 것이고, 따라서 다음의 액세스는 해당 아이템을 캐시에서 찾아낼 것이고, 따라서 최대 속도로 처리될 것입니다.

시간이 지난 후, 이 CPU 의 캐시는 꽉 찰 것이고,

¹ CPU 에 가깝게 작고 한 사이클의 액세스 타임을 갖는 1단계 캐시를, 그 다음엔 더 크고, 약 10 사이클 정도의 긴 액세스 타임을 갖는 2단계 캐시를 두는 식으로 여러 단계의 캐시를 사용하는건 표준적인 일입니다. 고성능 CPU 는 종종 세단계 또는 네단계까지도 캐시를 둡니다.

	Way 0	Way 1
0x0	0x12345000	
0x1	0x12345100	
0x2	0x12345200	
0x3	0x12345300	
0x4	0x12345400	
0x5	0x12345500	
0x6	0x12345600	
0x7	0x12345700	
0x8	0x12345800	
0x9	0x12345900	
0xA	0x12345A00	
0xB	0x12345B00	
0xC	0x12345C00	
0xD	0x12345D00	
0xE	0x12345E00	0x43210E00
0xF		

Figure C.2: CPU Cache Structure

이후의 미스들은 새로 가져온 아이템들을 위한 공간을 만들기 위해 캐시로부터 아이템을 비울 것을 필요로 할 수 있습니다. 그런 캐시 미스는 캐시의 제한된 용량으로 인해 발생하기 때문에 “용량 미스”라고 불리웁니다. 하지만, 대부분의 캐시들은 아직 용량이 꽉 차지 않았다 해도 새 아이템의 공간을 만들기 위해 오래된 아이템을 비우도록 강제되기도 합니다. 이는 커다란 캐시들은 Figure C.2 체이닝 없이 고정된 크기의 해시 베켓(CPU 설계자들이 부르는 용어로는 “set”)들을 사용하는 하드웨어 해시 테이블로 구현되어 있기 때문입니다.

이 캐시는 16개의 “set”들과 두개의 “way”를 가져서 총 32개의 “라인”을 가지며, 각 엔트리는 256 바이트의 “캐시 라인” 하나를 담는, 256 바이트 정렬 블록의 메모리입니다. 이 캐시 라인 크기는 좀 작지만, 16진수 계산을 훨씬 간단하게 해줄 겁니다. 하드웨어 용어로, 이것은 two-way set-associative 캐시라고 불리우며, 16개의 베켓을 가지고, 각 베켓은 최대 두개의 원소를 가질 수 있는 해시 체인인 소프트웨어 해시 테이블로 비유될 수 있습니다. 사이즈(이 경우 32 개의 캐시 라인들)와 associativity(이 경우 2)는 함께 캐시의 “기하 도형적 배열(geometry)”이라 불립니다. 이 캐시는 하드웨어로 구현되었기 때문에, 해시 함수는 엄청 간단합니다: 메모리 어드레스에서 네개의 비트를 뽑아냅니다.

Figure C.2에서 각 박스는 256 바이트 캐시 라인을 담는 캐시 엔트리를 나타냅니다. 하지만, 캐시 엔트리는 그림의 빈 박스처럼 비어있을 수도 있습니다. 그 외의 박스들은 각 엔트리가 담고 있는 캐시 라인의 메모리 주소들을 표시하고 있습니다. 캐시 라인들은 256 바이트로 정렬되어야 하기 때문에, 각 주소의 하위 8 비트는 0입니다, 그리고 하드웨어 해시 함수는 그 다음 4개 상위 비트를 해시 라인 넘버로 매치시킵니다.

그럼에 그려진 상황은 프로그램의 코드가 메모리 주

소로 0x43210E00부터 0x43210EFF 사이에 위치하고, 이 프로그램이 0x12345000부터 0x12345EFF까지의 데이터를 순차적으로 접근했다면 나타날 것입니다. 이 프로그램이 이제 0x12345F00을 접근하려 한다고 생각해 봅시다. 이 위치는 0xF 열로 해시되고, 이 라인의 두 way는 모두 비어있으므로, 이로 인한 256 바이트 라인은 캐시에 들어올 수 있습니다. 만약 프로그램이 0x1233000 위치를 액세스 하려 한다면, 0x0 열로 해시되고, 이로 인한 256 바이트 캐시 라인은 way 1에 들어올 수 있습니다. 하지만, 만약 프로그램이 0x1233E00 위치에 액세스 한다면, 0xE 열로 해시되는데, 여기 존재하는 것들 중 하나는 새로 들어올 캐시 라인을 위한 공간을 만들기 위해 비워져야 합니다. 만약 이렇게 비워진 캐시 라인이 나중에 액세스 된다면, 캐시 미스가 날겁니다. 그러한 캐시 미스를 “associativity miss”라고 합니다.

지금까지는 CPU가 데이터 아이템을 읽는 경우만 생각해봤습니다. 쓰기를 하면 어떻게 될까요? 주어진 데이터 아이템의 값에 대해 모든 CPU가 동의를 하는 것이 중요하기에, CPU는 어떤 데이터 아이템에 값을 쓰기 전에, 먼저 그 아이템을 다른 CPU의 캐시에서 삭제하거나, “무효화(invalidate)” 시켜야만 합니다. 무효화 작업이 완료되면, 이 CPU는 안전하게 해당 데이터 아이템을 수정할 수 있습니다. 만약 해당 데이터 아이템이 이 CPU의 캐시에 존재했다면, 그러나 읽기 전용이었다면, 이 작업은 “write miss”라고 합니다. CPU가 주어진 데이터 아이템을 다른 CPU의 캐시들로부터 무효화시키는데 성공하면, 이 CPU는 해당 데이터 아이템을 반복적으로 쓸 수(그리고 읽을 수도) 있습니다.

나중에, 다른 CPU가 해당 데이터 아이템에 접근하려 하면, 이번엔 첫번째 CPU가 그 아이템에 쓰기를 하려고 그 아이템을 무효화 시켰기 때문에 캐시 미스가 납니다. 이런 캐시 미스는 일반적으로 일부 CPU들이 데이터 아이템을 커뮤니케이션에 사용하려 해서(예를 들어, 락은 CPU들 사이에서 상호 배제적 알고리즘을 위한 커뮤니케이션에 사용되는 데이터 아이템입니다) 발생하기 때문에, “커뮤니케이션 미스”라고 합니다.

분명히, 모든 CPU들이 해당 데이터에 일관된 시야를 유지하도록 보장하는데 많은 주의를 기울여야만 합니다. 이 데이터 가져오기, 무효화 하기, 쓰기 작업을 통해, 데이터를 잃어버리거나(더 나쁘게도) 다른 CPU들이 같은 데이터 아이템에 대해 각자의 캐시에 다른 값을 갖게 되는 경우를 상상해 볼 수 있습니다. 이런 문제는 다음 섹션에서 다루는 “캐시 일관성 프로토콜”에 의해 방지됩니다.

C.2 Cache-Coherence Protocols

캐시 일관성 프로토콜은 비일관적인 상황이나 데이터 유실을 막기 위해 캐시 라인 상태를 관리합니다. 이런

프로토콜은 열개 이상의 상태를 가져서 매우 복잡할 수 있습니다만,² 우리의 목적을 위해서는 MESI 캐시 일관성 프로토콜의 네가지 상태에 대해서만 신경쓰면 됩니다.

C.2.1 MESI States

MESI 는 한 캐시 라인이 이 프로토콜을 통해 가질 수 있는 네가지 상태인 “modified”, “exclusive”, “shared”, 그리고 “invalid” 의 약자입니다. 따라서 이 프로토콜을 사용하는 캐시는 캐시라인마다 해당 라인의 물리 주소와 데이터 이외에도 두 비트의 상태 “tag” 를 갖습니다.

“modified” 상태의 라인은 연관된 CPU 가 최근에 메모리 스토어를 했고, 연관된 메모리는 다른 CPU 의 캐시에 존재하지 않음이 보장됩니다. 따라서 “modified” 상태의 캐시 라인들은 해당 CPU 에 의해 “소유된 상태” 라고도 이야기 합니다. 이 캐시는 최신 상태의 데이터 카피만을 가지고 있으므로, 이 캐시는 메모리의 예전 데이터를 최신 데이터로 갱신하거나 다른 캐시에게 넘기거나 할 의무를 가지고 있으며, 그 의무는 이 라인이 다른 데이터를 가지게 되기 전에 반드시 수행되어야만 합니다.

“exclusive” 상태는 “modified” 상태와 유사합니다만, 해당 캐시 라인은 연관된 CPU 에 의해 수정되지 않은 상태라는 점이 유일한 차이점으로, 메모리에 있는 캐시 라인의 데이터의 복사본이 최신 버전이란 뜻입니다. 하지만, CPU 는 다른 CPU 의 눈치를 보지 않고 언제든 이 라인에 언제든 스토어를 할 수 있으므로, “exclusive” 상태의 라인은 연관된 CPU 에 소유되어 있다고 이야기 할 수 있습니다. 그렇다면 하나, 메모리에 있는 값이 최신 상태이므로, 이 캐시는 데이터를 메모리에 다시 돌려넣거나 다른 CPU 에게 넘기지 않고 버릴 수 있습니다.

“shared” 상태의 라인은 적어도 한개의 다른 CPU 의 캐시에는 복사되어 있으며, 따라서 이 PU 는 먼저 다른 CPU 에게 이야기를 하지 않고서는 해당 라인에 스토어를 할 수 없습니다. “exclusive” 상태처럼, 메모리에 있는 값은 최신 버전이므로, 이 캐시는 메모리에 값을 다시 돌려놓거나 다른 CPU 에게 넘기지 않고 그 데이터를 버릴 수 있습니다.

“invalid” 상태의 라인은 비어있는데, 달리 말하자면, 아무 값도 들고 있지 않습니다. 새로운 데이터는 캐시에 들어올 때, 가능하다면 “invalid” 상태의 캐시 라인에 위치합니다. 다른 상태에 있는 라인을 교체하는 것은 교체된 라인이 미래에 다시 참조될 때 비싼 캐시 미스가 발생할 수 있기 때문에 이런 방법이 선호됩니다.

캐시 라인의 데이터에 대해 모든 CPU 가 일관적인

² SGI Origin2000 의 9개 상태, Sequent (이제는 IBM) NUMA-Q 의 26개 상태 그림을 보기 위해 Culler et al. [CS99] 670 페이지와 671 페이지를 참고하세요. 두 그림 모두 실제보다는 단순합니다.

뷰를 유지해야 하기 때문에, 이 캐시 일관성 프로토콜은 시스템 사이의 캐시 라인의 이동을 조정하기 위해 메세지를 제공합니다.

C.2.2 MESI Protocol Messages

앞 섹션에서 이야기한 많은 작업들은 CPU 간의 통신을 필요로 합니다. 만약 CPU 들이 하나의 공유된 버스만을 사용한다면, 다음과 같은 메세지를 만으로도 충분합니다:

Read

: “Read” 메세지는 읽혀질 캐시 라인의 물리 주소를 담습니다.

Read Response:

“Read response” 메세지는 앞의 “read” 메세지에서 요청받은 데이터를 담습니다. 이 “read response” 메세지는 메모리에서 또는 캐시들 중 하나에서 얻어와질 수도 있습니다. 예를 들어, 캐시들 가운데 하나가 현재 필요로 하는 데이터를 “modified” 상태로 가지고 있다면, 그 캐시가 “read response” 메세지를 보내야 합니다.

Invalidate:

“Invalidate” 메세지는 무효화할 캐시 라인의 물리 주소를 담습니다. 모든 다른 캐시들은 그 데이터를 각자의 캐시에서 제거하고 답장을 해야 합니다.

Invalidate Acknowledge:

“Invalidate” 메세지를 받은 CPU 는 반드시 요청된 데이터를 자신의 CPU 로부터 제거한 후 “invalidate acknowledge” 메세지를 보내야 합니다.

Read Invalidate:

“Read Invalidate” 메세지는 읽음과 동시에 다른 캐시들로부터는 제거할 캐시 라인의 물리 주소를 담습니다. 따라서, 이름으로부터 알 수 있듯 이것은 “read” 와 “invalidate” 의 조합인 셈입니다. “read invalidate” 메세지는 “read response” 와 “invalidate acknowledge” 메세지 둘 다 응답으로 받습니다.

Writeback:

“writeback” 메세지는 메모리에 도로 쓰여질 (그리고 그 과정에서 다른 CPU 의 캐시에 “snooped” 를 보낼 수 있을 겁니다) 데이터와 주소를 모두 담습니다. 이 메세지는 캐시들이 “modified” 상태의 라인을 다른 데이터를 위한 공간을 만들어야 하거나 할 때 제거할 수 있도록 합니다.

Quick Quiz C.1: Writeback 메세지는 어디서 와서 어디로 가나요? ■

흥미롭게도, 공유 메모리 멀티프로세서 시스템은 내부적으로는, 실제로 메세지 전달 컴퓨터입니다. 이는 분산 공유 메모리를 사용하는 SMP 머신 클러스터들은 두개의 서로 다른 단계의 시스템 구조 간에 메세지 패싱을 구현하고 있다는 의미입니다.

Quick Quiz C.2: 두개의 CPU 들이 같은 캐시 라인을 동시에 무효화 하려고 하면 어떻게 되나요? ■

Quick Quiz C.3: 커다란 멀티프로세서에서 “invalidate” 메세지가 생기면, 모든 CPU 가 “invalidatge acknowledge” 응답을 보내야만 합니다. 그로 인한 “invalidate acknowledge” 의 “폭풍우” 가 시스템 버스를 완전히 뒤덮지 않을까요? ■

Quick Quiz C.4: SMP 머신들이 실제로 메세지 전달을 어떻게든 사용한다면, 애초에 왜 SMP 에 신경을 쓰는거죠? ■

C.2.3 MESI State Diagram

캐시 라인은 Figure C.3 에 보여진 것처럼 프로토콜 메세지가 보내지고 받아짐에 따라 그 상태가 바뀝니다.




Figure C.3: MESI Cache-Coherency State Diagram

이 그림의 상태 변화들은 다음과 같습니다:

상태 변화(a)

: 캐시 라인이 메모리로 메모리에 writeback 되지만, 해당 CPU 는 그 데이터를 자신의 캐시에 유지하고 더나아가 그 데이터를 수정할 권리도 유지합니다. 이 상태 변경은 “writeback” 메세지를 필요로 합니다.

상태 변화(b)

: CPU 가 이미 독점적 액세스 권한을 이미 가지고 있는 캐시 라인에 값을 씁니다. 이 상태 변경은 어떤 메세지의 전송이나 수신을 필요로 하지 않습니다.

상태 변화 (c)

: 자신이 수정한 캐시 라인으로의 “read invalidate” 메세지를 CPU 가 받습니다. 메세지를 받은 CPU 는 자신의 복사본을 무효화 시키고, “read response” 와 “invalidate acknowledge” 메세지 둘 다를 보내서 메세지를 보내온 CPU 에게 데이터를 전송하고 자신이 더이상 그 복사본을 들고 있지 않음을 알려야 합니다.

상태 변화 (d)

: CPU 가 자신의 캐시에 존재하지 않는 한 데이터 아이템에 어토믹 read-modify-write 오퍼레이션을 수행합니다. 이 CPU 는 “read invalidate” 메세지를 보내서 “read response” 를 받습니다. CPU 가 “invalidate acknowledge” 메세지까지 받으면 그 상태 변화가 완료됩니다.

상태 변화 (e)

: CPU 가 자신의 캐시에 read-only 상태로 존재하던 데이터 아이템에 어토믹 read-modify-write 오퍼레이션을 수행합니다. 상태 변환을 완료하기 위해 CPU 는 “invalidate” 메세지들을 보내고, “invalidate acknowledge” 응답이 모두 도착하길 기다려야 합니다.

상태 변화 (f)

: 어떤 다른 CPU 가 해당 캐시라인을 읽고, 그 오퍼레이션은 메모리에 writeback 중일 수도 있는 read-only 상태의 복사본을 가지고 있는 CPU 의 캐시에서 값을 얻어갑니다. 이 상태 변화는 “read” 메세지의 수신으로 시작되고 이 CPU 는 요청된 데이터를 담고 있는 “read response” 메세지로 응답을 보냅니다.

상태 변화 (g)

: 어떤 다른 CPU 가 이 캐시 라인의 데이터 아이템을 읽고, 그 오퍼레이션이 해당 CPU 의 캐시나 메모리에서 그 값을 얻어갑니다. 어떤 경우든, 이 CPU 는 read-only 복사본을 가지고 있습니다. 이 상태 변화는 “read” 메세지의 수신과 함께 시작되고, 이 CPU 는 요청된 데이터를 담고 있는 “read response” 메세지로 응답을 보냅니다.

상태 변화 (h)

: 이 CPU 는 자신이 곧 이 캐시 라인에 어떤 데이터를 쓰게 될 것임을 깨닫고, 따라서 “invalidate” 메세지를 보냅니다. 해당 CPU 는 모든 “invalidate acknowledge” 응답을 모두 받기 전까지 상태 변화를 마무리 할 수 없습니다. 또 다른 경우로, 모든 다른 CPU 들이 이 캐시 라인을 각자의 캐시에서 (다른 캐시라인을 위한 공간을 만들기 위해) “writeback”

메세지로 비워버려서 이 CPU 가 그 캐시 라인을 캐시하고 있는 마지막 CPU 가 될수도 있습니다.

상태 변화 (i)

: 어떤 다른 CPU 가 이 CPU 의 캐시에만 있는 캐시 라인의 데이터 아이템에 어토믹 read-modify-write 오퍼레이션을 수행합니다. 이 상태 변경은 “read invalidate” 메세지를 수신하는 것으로 시작되고, 이 CPU 는 응답으로 “read response” 와 “invalidate acknowledge” 메세지를 모두 보냅니다.

상태 변화 (j)

: 이 CPU 가 자신의 캐시에 존재하지 않는 캐시 라인에 데이터 아이템을 저장하고, 따라서 “read invalidate” 메세지를 보냅니다. 이 CPU 는 “read response” 와 모든 “invalidate acknowledge” 메세지들을 받기 전까지 상태 변환은 끝나지 않습니다. 이 캐시라인은 이후 실제 저장이 완료되는대로 transition (b) 를 통해 “modified” 상태로 변경될 것입니다.

상태 변화 (k)

: 이 CPU 는 자신의 캐시에 존재하지 않는 캐시라인에 데이터 아이템을 읽습니다. 이 CPU 는 “read” 메세지를 보내고, 그에 상응하는 “read response” 를 받는대로 상태 변화를 완료 합니다.

상태 변화 (l)

: 어떤 다른 CPU 가 이 캐시 라인의 데이터 아이템에 쓰기를 합니다만, 이 캐시라인은 (예를 들어 현재 CPU 의 캐시 같은) 다른 CPU 의 캐시에도 존재하기 때문에 read-only 상태입니다. 이 상태 변경은 “invalidate” 메세지의 수신과 함께 시작되고, 이 CPU 는 “invalidate acknowledge” 메세지로 응답을 보냅니다.

Quick Quiz C.5: 앞에 설명된 지연되는 상태 변경들은 하드웨어에서 어떻게 처리하나요? ■

C.2.4 MESI Protocol Example

이제 네 개의 CPU 시스템의 한개짜리 라인을 가지는 각 캐시 사이에 이동하게 될, 최초에는 메모리 어드레스 0 에 존재하는 캐시 라인의 데이터의 시각에서 바라봐 봅시다. Table C.1 이 첫째 행은 오퍼레이션들의 시퀀스를, 두번째 행은 그 오퍼레이션을 수행하는 CPU 를 그리고 세번째 행은 수행되고 있는 오퍼레이션을, 네번째 행은 각 CPU 의 캐시 라인(MESI 상태에 의해 따라오는 메모리 주소)의 상태를, 그리고 마지막의 두 행은 연관된 메모리 내용이 최신인지(“V”) 아닌지(“I”) 표시하면서 이런 데이터 흐름을 보입니다.

최초에, 해당 데이터가 위치하게 될 CPU 캐시 라인은 “invalid” 상태로, 데이터는 메모리에 유효한채로 존재합니다. CPU 0 가 이 주소 0 의 데이터를 읽어오면, 캐시라인은 CPU 0 의 캐시 안에서 “shared” 상태가 되고 메모리에의 값도 여전히 유효합니다. CPU 3 역시 주소 0 의 이 데이터를 읽어오고, 이로 인해 캐시 라인은 두 CPU 의 캐시 안에서 모두 “shared” 상태가 되며, 여전히 메모리의 값도 유효합니다. 다음으로 CPU 0 가 다른 캐시 라인(주소 8) 의 데이터를 읽어오면, 주소 0 의 데이터는 캐시에서 무효화가 되도록 할 것이고, 그 공간을 주소 8 의 데이터가 차지하게 됩니다. CPU 2 가 이제 주소 0 을 읽게 되는데, 이 CPU 는 곧 거기에 쓰기를 해야 함을 깨닫고, 따라서 독점적 복사본을 얻기 위해 “read invalidate” 메세지를 날려서 (메모리의 값은 여전히 최신 버전이지만) CPU 3 의 캐시에서 해당 캐시라인을 무효화 시킵니다. 다음으로 CPU 2 는 예상했던 쓰기를 하게 되어, 상태를 “modified” 로 바꿉니다. 메모리에 있는 해당 데이터의 복사본은 이제 과거의 것이 되었습니다. CPU 1 은 어토믹한 증가를 시키기 위해 CPU 2 의 캐시에 있는 데이터를 얻어오고 무효화 시키도록 “read invalidate” 를 이용하게 되는데, 이로 인해 CPU 1 의 복사본은 “modified” 상태가 됩니다 (그리고 메모리의 복사본은 여전히 과거 값입니다). 마지막으로 CPU 1 이 주소 8 의 캐시 라인을 읽게 되는데, 여기선 주소 0 의 데이터를 메모리에 되돌려 놓기 위해 “writeback” 메세지를 사용하게 됩니다.

몇몇 다른 CPU 의 캐시에 값을 남겨둔 채라는 것을 기억해 두세요.

Quick Quiz C.6: 어떤 오퍼레이션들의 시퀀스가 CPU 의 캐시를 모두 “invalid” 상태로 돌려 놓을까요? ■

C.3 Stores Result in Unnecessary Stalls

Figure C.1 에 보인 캐시 구조는 하나의 CPU 로부터 하나의 데이터 아이템으로의 반복적인 읽기와 쓰기에는 좋은 성능을 보이지만, 하나의 캐시 라인에의 첫번째 쓰기 성능은 매우 떨어집니다. 이를 분명히 하기 위해, CPU 0 에서 CPU 1 의 캐시에 있는 캐시라인으로의 쓰기 상황을 보여주는 Figure C.4 를 생각해 보세요. CPU 0 는 쓰기를 하기 전에, 해당 캐시 라인이 도착하기를 기다려야만 하기 때문에, CPU 0 는 더 긴 시간을 멈춰 있어야만 합니다.³

하지만 CPU 0 를 그렇게나 길게 멈춰있게 둘 진정한 이유는 없습니다—무엇보다, CPU 1 이 보내는 캐시라

³ 캐시 라인을 하나의 CPU 의 캐시에서 다른 CPU 의 캐시로 전달하는데 필요한 시간은 일반적으로 간단한 레지스터에서 레지스터로 행해지는 인스트럭션에 요구되는 시간의 수십배는 됩니다.

Table C.1: Cache Coherence Example

Sequence #	CPU #	Operation	CPU Cache				Memory	
			0	1	2	3	0	8
0		Initial State	-/I	-/I	-/I	-/I	V	V
1	0	Load	0/S	-/I	-/I	-/I	V	V
2	3	Load	0/S	-/I	-/I	0/S	V	V
3	0	Invalidation	8/S	-/I	-/I	0/S	V	V
4	2	RMW	8/S	-/I	0/E	-/I	V	V
5	2	Store	8/S	-/I	0/M	-/I	I	V
6	1	Atomic Inc	8/S	0/M	-/I	-/I	I	V
7	1	Writeback	8/S	8/S	-/I	-/I	V	V




Figure C.4: Writes See Unnecessary Stalls

인에 어떤 값이 들어있을지와는 관계 없이, CPU 0 는 어떤 조건 없이 그걸 덮어써 버릴테니까요.

C.3.1 Store Buffers

이런 불필요한 쓰기 지연을 예방하는 한가지 방법은 각 CPU 와 각 CPU 의 캐시 사이에 Figure C.5 에 보이이는 것처럼 “스토어 버퍼”를 추가하는 것입니다. 이렇게 스토어 버퍼가 추가되면, CPU 0 는 단순히 자신의 쓰기를 자신의 스托어 버퍼에 저장해 두고 실행을 계속할 수 있습니다. 해당 캐시 라인이 마침내 CPU 1 에서 CPU 0 으로 이동하면, 해당 데이터는 스托어 버퍼에서 해당 캐시 라인으로 이동하게 될겁니다.

Quick Quiz C.7: 하지만 스托어 버퍼의 주목적이 멀티프로세서 캐시 일관성 프로토콜의 응답 지연시간을 숨기기 위해서라면, 왜 유니프로세서들도 스托어 버퍼

를 가지고 있는거죠? ■




Figure C.5: Caches With Store Buffers

이런 스托어 버퍼는 한 CPU 에 지역적이거나, 하드웨어 멀티쓰레딩을 지원하는 시스템에서는 한 코어에 지역적입니다. 어떤 방식이든, 한 CPU 는 자신에게 할당된 스托어 버퍼에만 액세스 할 수 있습니다. 예를 들어, Figure C.5 에서 CPU 0 는 CPU 1 의 스托어 버퍼에 액세스 할 수 없고 반대도 마찬가지입니다. 이 제약이 고려사항들을 분리시킴으로써 하드웨어를 단순화 시킵니다: 스托어 버퍼는 반복적인 쓰기에 대해 성능을 향상시키며, CPU 들 (또는 코어들) 사이의 통신에 대한 책임은 캐시 일관성 프로토콜이 완전히 가지고 있습니다. 하지만, 이런 제약이 있다고 해도, 다음 두 섹션에서 이야기할, 여전히 처리되어야만 하는 복잡한 문제들이 존재합니다.

C.3.2 Store Forwarding

첫번째 문제인 스스로에 대한 일관성의 파괴 문제를 보기 위해, 변수 “a” 와 “b” 는 0 값을 가지며, 변수 “a” 를 담는 캐시 라인은 CPU 1 에 소유되어 있고 “b” 를 담는 캐시라인은 CPU 0 이 가지고 있는 초기 상태를 가정해 두고 다음의 코드를 생각해 봅시다.

```
1  a = 1;
2  b = a + 1;
3  assert(b == 2);
```

누군가는 이 단정은 실패하지 않을 거라고 생각할 겁니다. 하지만, Figure C.5 에서 보여진 매우 단순한 구조를 사용할 만큼 명청하다면 깜짝 놀랄 겁니다. 그런 시스템은 다음과 같은 이벤트의 시퀀스를 발생시킬 가능성이 있습니다:

1. CPU 0 는 $a = 1$ 을 수행하기 시작합니다.
2. CPU 0 는 “a” 가 캐시에 있는지 보고, 자신의 캐시에 없음을 깨닫습니다.
3. 따라서 CPU 0 는 “a” 를 담고 있는 캐시 라인에 배타적 소유권을 얻기 위해 “read invalidate” 메세지를 보냅니다.
4. CPU 0 는 “a” 로의 스토어를 자신의 스토어 버퍼에 기록합니다.
5. CPU 1 은 “read invalidate” 메세지를 받고, 해당 캐시라인을 보내고 해당 캐시라인을 자신의 캐시에서 지우는 것으로 응답합니다.
6. CPU 0 는 $b = a + 1$ 을 수행합니다.
7. CPU 0 는 CPU 1 으로부터 여전히 “a” 의 값이 0인 해당 캐시 라인을 받습니다.
8. CPU 0 는 자신의 캐시로부터 “a” 를 읽어내고 값 0 을 얻습니다.
9. CPU 0 는 자신의 스토어 버퍼의 항목을 새로 도착한 캐시 라인에 적용해서, 자신의 캐시에 있는 “a” 의 값을 1로 만듭니다.
10. CPU 0 는 앞서 읽혀진 “a” 의 값 0에 1을 더하고, 이를 “b” 를 담고 있는 캐시 라인(우리는 이게 이미 CPU 0 에 소유되어 있다 가정했습니다) 에 저장합니다.
11. CPU 0 는 `assert(b == 2)` 를 수행하고, 실패합니다.

문제는 우리가 “a” 의 두개의 복사본을 하나는 캐시에, 다른 하나는 스토어 버퍼에 가지고 있다는 것입니다.

이 예를 각각의 CPU 는 항상 그것들이 프로그램 순서대로 행하는 것처럼 각자의 오퍼레이션들을 바라봐야 한다는 매우 중요한 보장사항을 깨뜨렸습니다. 이 보장사항을 깨뜨리는 것은 소프트웨어에게 매우 비직관적인 일이어서 하드웨어 쪽 사람들은 연민을 가지게 되었고 각 CPU 가 로드 오퍼레이션을 수행할 때 Figure C.6 에 보여지는 것처럼 자신의 캐시만이 아니라 스토어 버퍼 역시 참고(또는 “기웃거리개(snoop)”) 하는 “store forwarding” 을 구현했습니다. 달리 말하자면, 주어진 CPU 의 스토어는 이후에 이어지는 자신의 로드에 캐시를 통하지 않고 곧바로 포워딩 됩니다.




Figure C.6: Caches With Store Forwarding

스토어 포워딩이 존재하면, 앞의 시퀀스에서의 아이템 8 은 “a” 의 올바른 값 1을 스토어 버퍼에서 찾고, 따라서 “b” 의 최종값은 우리가 원했던 대로 2가 될 것입니다.

C.3.3 Store Buffers and Memory Barriers

글로벌 메모리 순서의 위반이라는 두번째 문제를 보기 위해, 변수 “a” 와 “b” 가 초기값 0을 가지고 있다는 가정 하에 다음의 코드를 봅시다:

```

1 void foo(void)
2 {
3     a = 1;
4     b = 1;
5 }
6
7 void bar(void)
8 {
9     while (b == 0) continue;
10    assert(a == 1);
11 }

```

CPU 0 는 foo() 를, 그리고 CPU 1 은 bar() 를 수행한다고 해봅시다. 그리고 “a” 를 담는 캐시라인은 CPU 1 의 캐시에, 그리고 “b” 를 담는 캐시라인은 CPU 0 에 소유되어 있습니다. 그러면 다음과 같은 오퍼레이션들의 시퀀스가 생길 수 있습니다:

1. CPU 0 는 a = 1 을 실행합니다. 해당 캐시 라인은 CPU 0 의 캐시에 없으므로, CPU 0 는 “a” 의 새로운 값을 스토어 버퍼에 넣고 “read invalidate” 메세지를 던집니다.
2. CPU 1 은 while (b == 0) continue 를 수행합니다만, “b” 를 담는 캐시 라인이 자신의 캐시에 없습니다. 따라서 이 CPU 는 “read” 메세지를 보냅니다.
3. CPU 0 이 b = 1 을 수행합니다. 이 CPU 는 이 캐시 라인을 이미 가지고 있으므로(달리 말하자면, 해당 캐시 라인은 이미 “modified” 또는 “exclusive” 상태입니다), “b” 의 새 값을 캐시 라인에 저장합니다.
4. CPU 0 이 “read” 메세지를 받고, CPU 1 에게 업데이트 되어 있는 “b” 값을 담은 캐시 라인을 보내며, 또한 자신의 캐시 위의 해당 라인을 “shared” 로 표시합니다.
5. CPU 1 은 “b” 를 담고 있는 캐시라인을 받고 자신의 캐시에 집어넣습니다.
6. CPU 1 은 이제 “b” 의 값이 1임을 확인했으나 while (b == 0) continue 의 수행을 끝낼 수 있게 되었고, 다음 문장을 수행합니다.
7. CPU 1 은 assert(a == 1) 을 수행하게 되는데, CPU 1 은 “a” 의 예전 값을 들고 있으므로, 이 단정문은 실패합니다.
8. CPU 0 은 “a” 를 담는 캐시 라인을 받고 바로 이때에서야 스토어 버퍼에 머물러 있던 스토어 오퍼레이션을 행해서 CPU 1 의 실패한 단정문이 가능하게 합니다.

Quick Quiz C.8: 앞의 step 1 에서, 왜 CPU 0 는 그냥 “invalidate” 가 아니라 “read invalidate” 를 보내는거죠?

■ 하드웨어 설계자들은 이 문제를 직접 도와줄 수는 없는데, CPU 들은 어떤 변수들이 연관되어 있는지, 어떻게 변수들이 연관될 수 있을지 알수가 없기 때문입니다. 따라서, 하드웨어 설계자들은 소프트웨어가 CPU 에게 그런 연관관계를 알려줄 수 있도록 메모리 배리어 인스트럭션들을 제공합니다. 앞의 프로그램 조각은 다음과 같이 메모리 배리어를 포함하도록 수정되어야 합니다:

```

1 void foo(void)
2 {
3     a = 1;
4     smp_mb();
5     b = 1;
6 }
7
8 void bar(void)
9 {
10    while (b == 0) continue;
11    assert(a == 1);
12 }

```

메모리 배리어 smp_mb() 는 해당 CPU 가 자신의 스토어 버퍼를 이후의 스토어 오퍼레이션이 대상 변수의 캐시 라인에 값을 써넣기 전에 비우도록 합니다. 해당 CPU 는 단순히 이어서 진행을 하기 전에 스토어 버퍼가 비워질 때까지 멈춰 있을 수도 있고, 다음의 스토어 오퍼레이션들을 이미 스토어 버퍼에 채워져 있던 내용들이 모두 적용될 때까지 스토어 버퍼 안에 들고 있을 수도 있습니다.

이 두번째 방법을 사용하게 되면 오퍼레이션들의 시퀀스는 다음과 같아질 겁니다:

1. CPU 0 는 a = 1 을 실행합니다. 해당 캐시 라인은 CPU 0 의 캐시에 없으므로, CPU 0 는 “a” 의 새로운 값을 스토어 버퍼에 넣고 “read invalidate” 메세지를 던집니다.
2. CPU 1 은 while (b == 0) continue 를 수행합니다만, “b” 를 담는 캐시 라인이 자신의 캐시에 없습니다. 따라서 이 CPU 는 “read” 메세지를 보냅니다.
3. CPU 0 가 smp_mb() 를 수행하고, 현재 스토어 버퍼에 있는 모든 항목(구체적으로는, a = 1)을 마크해둡니다.
4. CPU 0 가 b = 1 을 수행합니다. 이 CPU 는 이 캐시 라인을 이미 가지고 있습니다만(달리 말하자면, 해당 캐시 라인은 이미 “modified” 또는 “exclusive”

- 상태입니다), 스토어 버퍼에 마크된 항목들이 있습니다. 따라서, “b”의 새 값을 해당 캐시 라인에 저장하는 대신, CPU 0은 이 동작을 스토어 버퍼에 (하지만 마크되지 않은 자리에) 집어넣습니다.
5. CPU 0은 “read” 메세지를 받고, “b”의 원래 값을 저장되어 있는 캐시 라인을 CPU 1에게 보냅니다. 또한 자신의 이 캐시라인의 복사본을 “shared”로 바꿔줍니다.
 6. CPU 1은 “b”를 담고 있는 캐시 라인을 받고 자신의 캐시에 집어넣습니다.
 7. CPU 1은 이제 “b”的 값을 읽을 수 있습니다만, “b”的 값이 여전히 0임을 확인하므로, 해당 while 문을 계속 반복 수행하게 됩니다. “b”的 새 값은 안전하게 CPU 0의 스토어 버퍼 안에 숨겨져 있습니다.
 8. CPU 1은 “read invalidate” 메세지를 받고, “a”를 담고 있는 해당 캐시 라인을 CPU 0에게 보내고 자신의 캐시에서 해당 캐시 라인을 무효화 시킵니다.
 9. CPU 0은 “a”를 담고 있는 캐시 라인을 받고 스토어 버퍼에 들어가 있던 스토어 오퍼레이션을 행하고 이 캐시 라인을 “modified” 상태로 바꿉니다.
 10. “a”로의 스토어는 스토어 버퍼 내에 `smp_mb()`에 의해 마크되어 있던 유일한 항목이므로, CPU 0은 “b”的 새 값의 저장도 할 수 있습니다 — “b”를 담고 있는 캐시 라인이 이제는 “shared” 상태라는 사실은 제외하고.
 11. 따라서 CPU 0은 CPU 1에게 “invalidate” 메세지를 보냅니다.
 12. CPU 1은 “invalidate” 메세지를 받고, 자신의 캐시로부터 “b”를 담고 있는 캐시 라인을 무효화시키고, “acknowledgement” 메세지를 CPU 0에게 보냅니다.
 13. CPU 1은 `while (b == 0) continue`를 수행합니다만, “b”를 담고 있는 캐시 라인이 자신의 캐시에 없습니다. 따라서 “read” 메세지를 CPU 0에게 보냅니다.
 14. CPU 0은 “read” 메세지를 받고, “b”的 새 값을 담고 있는 캐시 라인을 CPU 1에게 보냅니다. 또한 자신이 가지고 있는 이 캐시 라인의 복사본을 “shared” 상태로 바꿉니다.
 15. CPU 1이 “b”를 담고 있는 캐시 라인을 받고 자신의 캐시에 올려놓습니다.
 16. CPU 1은 이제 “b”的 값을 읽을 수 있고, “b”的 값이 1임을 확인하기 되므로 `while` 루프를 종료하고 다음 문장으로 실행을 넘깁니다.
 17. CPU 1은 `assert(a == 1)`을 수행하는데, “a”를 담는 캐시 라인이 자신의 캐시에 없습니다. 이 캐시 라인을 CPU 0로부터 다시 받으면, 최신 버전의 값을 갖는 “a”를 가지고 동작하게 되므로, 단정문은 통과됩니다.
- 볼 수 있듯, 이 작업은 적지 않은 양의 부기 (bookkeeping)를 필요로 합니다. 몇몇 내용은 직관적으로 간단해 보이겠지만, “a의 값을 로드하기”와 같은 명령도 실리콘에서는 수많은 복잡한 단계를 야기할 수 있습니다.

C.4 Store Sequences Result in Unnecessary Stalls

불행히도, 각각의 스토어 버퍼는 비교적 작아야 해서, 적당한 스토어들만 수행하는 CPU 도 스토어 버퍼를 가득 채울 수 있습니다 (예를 들어, 그 모든 것들이 캐시 미스를 초래한다면). 이렇게 되면, CPU는 계속해서 수행을 하기 전에 스토어 버퍼가 비워지도록 또다시 무효화가 완료되길 기다려야만 합니다. 메모리 배리어 이후에도, 모든 뒤이어 요청되는 스토어 인스트럭션들이 해당 스토어들이 캐시 미스를 내는지 안내는지와 관계 없이 무효화가 완료되길 기다리는 똑같은 경우가 발생할 수 있습니다.

이런 상황은 무효화 응답 메세지가 좀 더 빨리 도착하게 함으로써 개선될 수 있습니다. 이를 가능하게 하는 한 가지 방법은 CPU 별 무효화 메세지의 큐, “invalidate queue”를 사용하는 것입니다.

C.4.1 Invalidate Queues

무효화 응답 메세지가 그렇게 오랜 시간을 소모하는 한 가지 이유는 응답 메세지들은 연관된 캐시 라인이 실제로 무효화 되었음을 보장해야 하는데, 예를 들어 CPU가 해당 캐시에 있는 데이터의 로드와 스토어를 열심히 하고 있거나 해서 캐시가 바빠 무효화가 지연될 수도 있다는 것입니다. 또한, 짧은 시간 동안 많은 무효화 메세지가 도착하면, 해당 CPU는 이것들을 처리하는데 바빠서, 다른 CPU들을 모조리 멈춰있게 만들 수도 있습니다.

하지만, 해당 CPU는 응답을 보내기 전에 정말로 캐시 라인들을 무효화 해야만 할 필요는 없습니다. 대신 CPU가 나중에 해당 캐시 라인과 관련된 메세지를 보내기 전까지는 그 메세지가 처리되어야만 한다는 점만 기억해두고 무효화 메세지를 큐에 집어넣어 둘 수도 있습니다.

C.4.2 Invalidate Queues and Invalidate Acknowledge

Figure C.7 는 무효화 큐를 가진 시스템을 그리고 있습니다. 무효화 큐를 가진 CPU 는 관련된 캐시 라인에 실제로 무효화 되는 걸 기다리지 않고 무효화 메세지를 큐에 넣자마자 응답 메세지를 보낼 수 있습니다. 물론, 해당 CPU 는 무효화 메세지들을 보낼 준비를 할 때 자신의 무효화 큐를 확인해 봄아 합니다 — 관련된 캐시 라인을 위한 항목이 무효화 큐에 존재한다면, 해당 CPU 는 무효화 메세지를 곧바로 보낼 수 없습니다; 대신 무효화 큐의 해당 항목이 처리되길 기다려야 합니다.




Figure C.7: Caches With Invalidate Queues

한 항목을 무효화 큐에 집어넣는 것은 결국은 해당 CPU 가 해당 항목과 관련된 캐시 라인에 대한 어떤 MESI 프로토콜 메세지를 나중에 보내기 전까지는 해당 항목을 처리하겠다는 약속입니다. 관련된 데이터 구조에 너무 많은 요청이 들어오지 않는다면 해당 CPU 가 그 약속으로 인해 어려움을 겪는 일은 거의 없을 겁니다.

하지만, 무효화 메세지가 무효화 큐에 들어가 있을 수 있다는 사실은 다음 섹션에서 이야기할 추가적인 메모리 오퍼레이션의 잘못된 재배치 문제를 야기합니다.

C.4.3 Invalidate Queues and Memory Barriers

CPU 들이 무효화 요청을 큐에 집어넣기만 하고 곧바로 응답하는 경우를 생각해 봅시다. 이 방법은 스토어를 하

는 CPU 들에게 보이는 캐시 무효화 대기시간을 최소화 해주지만, 다음의 예에서 보여지듯이 메모리 배리어들을 패배시킬 수가 있습니다.

“a” 와 “b” 가 초기값 0을 가지고, “a” 는 read-only 로 복사되어 있고 (MESI “shared” 상태), “b” 는 CPU 0 에 의해 소유되어 있는 (MESI “exclusive” 또는 “modified” 상태) 라고 가정합시다. 그리고 CPU 0 는 다음의 코드에서 `foo()` 함수를 실행하고, 그동안 CPU 1 은 `bar()` 함수를 실행하고 있다고 생각해 봅시다:

```

1 void foo(void)
2 {
3     a = 1;
4     smp_mb();
5     b = 1;
6 }
7
8 void bar(void)
9 {
10    while (b == 0) continue;
11    assert(a == 1);
12 }
```

그럼 다음과 같은 오퍼레이션들의 시퀀스가 가능합니다:

1. CPU 0 이 `a = 1` 을 실행합니다. 관련된 캐시 라인 이 CPU 0 의 캐시에 read-only 상태이므로, CPU 0 는 “a” 의 새 값을 스토어 버퍼에 넣고 해당 캐시 라인을 CPU 1 의 캐시로부터 없애기 위해 “invalidate” 메세지를 전송합니다.
2. CPU 1 이 `while (b == 0) continue` 를 실행합니다만, “b” 를 담고 있는 캐시라인이 자신의 캐시에 없습니다. 따라서 “read” 메세지를 보냅니다.
3. CPU 1 이 CPU 0 의 “invalidate” 메세지를 받고, 큐에 넣은 후, 곧바로 그에 응답합니다.
4. CPU 0 은 CPU 1 로부터 응답을 받고, 따라서 line 4 의 `smp_mb()` 를 수행할 수 있게 되어 “a” 의 값을 스토어 버퍼에서 자신의 캐시 라인으로 옮깁니다.
5. CPU 0 가 `b = 1` 을 수행합니다. 이미 이 캐시 라인을 소유하고 있으므로 (달리 말하자면, 해당 캐시 라인은 이미 “modified” 또는 “exclusive” 상태입니다), “b” 의 새 값을 자신의 캐시 라인에 써넣습니다.
6. CPU 0 는 “read” 메세지를 받고, 이제 막 업데이트된 “b” 의 값을 담고 있는 캐시 라인을 CPU 1 에게 전송하고, 자신의 캐시에서 해당 캐시 라인을 “shared” 로 표시합니다.
7. CPU 1 이 “b” 의 값을 포함하는 캐시 라인을 받고 자신의 캐시에 올립니다.

8. CPU 1 은 이제 `while (b == 0) continue` 의 수행을 끝내고, “b” 의 값이 1임을 확인하므로, 다음 문장으로 수행을 넘깁니다.
9. CPU 1 은 `assert(a == 1)` 을 수행하지만, “a” 의 이전 값이 여전히 CPU 1 의 캐시에 있으므로, 이 단정문은 실패합니다.
10. 단정문이 실패했음에도, CPU 1 은 큐에 들어가 있는 “invalidate” 메세지를 처리하고, (뻔뻔스럽게) 자신의 캐시에서 “a” 를 담고 있는 캐시 라인을 무효화 시킵니다.

Quick Quiz C.9: Section C.4.3 의 첫번째 시나리오의 스텝 1에서, 왜 “read invalidate” 가 아니라 “invalidate” 를 보내는 거죠? CPU 0 는 “a” 외에도 이 캐시 라인을 공유하는 다른 변수들의 값을 필요로 할수도 있지 않나요?

■ 메모리 배리어를 무시되게 한다면 무효화 응답을 빠르게 하는 것은 별 의미가 없어집니다. 하지만, 메모리 배리어 인스트럭션은 한 CPU 가 메모리 배리어를 수행할 때, 무효화 큐에 있는 모든 항목을 표시해 두고 다음에 요청되는 로드 오퍼레이션들은 모든 표시된 항목들이 해당 CPU 의 캐시에 적용될 때까지 기다리게 하도록 무효화 큐와 상호작용 할 수 있습니다. 따라서, 우린 `bar` 함수에 다음과 같이 메모리 배리어를 추가할 수 있습니다:

```

1 void foo(void)
2 {
3     a = 1;
4     smp_mb();
5     b = 1;
6 }
7
8 void bar(void)
9 {
10    while (b == 0) continue;
11    smp_mb();
12    assert(a == 1);
13 }
```

Quick Quiz C.10: 뭐라구요??? CPU 는 `while` 루프가 끝나기 전까지는 `assert()` 를 수행할 수 없는데 왜 여기에 메모리 배리어가 필요해요? ■

변경된 코드에서 오퍼레이션들의 시퀀스는 다음과 같이 될겁니다:

1. CPU 0 이 `a = 1` 을 실행합니다. 관련된 캐시 라인 이 CPU 0 의 캐시에 read-only 상태이므로, CPU 0 는 “a” 의 새 값을 스토어 버퍼에 넣고 해당 캐시 라인을 CPU 1 의 캐시로부터 없애기 위해 “invalidate” 메세지를 전송합니다.

2. CPU 1 이 `while (b == 0) continue` 를 실행합니다. 다만, “b” 를 담고 있는 캐시라인이 자신의 캐시에 없습니다. 따라서 “read” 메세지를 보냅니다.
3. CPU 1 이 CPU 0 의 “invalidate” 메세지를 받고, 큐에 넣은 후, 곧바로 그에 응답합니다.
4. CPU 0 은 CPU 1 로부터 응답을 받고, 따라서 line 4 의 `smp_mb()` 를 수행할 수 있게 되어 “a” 의 값을 스토어 버퍼에서 자신의 캐시 라인으로 옮깁니다.
5. CPU 0 가 `b = 1` 을 수행합니다. 이미 이 캐시 라인을 소유하고 있으므로 (달리 말하자면, 해당 캐시 라인은 이미 “modified” 또는 “exclusive” 상태입니다), “b” 의 새 값을 자신의 캐시 라인에 써넣습니다.
6. CPU 0 는 “read” 메세지를 받고, 이제 막 업데이트된 “b” 의 값을 담고 있는 캐시 라인을 CPU 1 에게 전송하고, 자신의 캐시에서 해당 캐시 라인을 “shared” 로 표시합니다.
7. CPU 1 이 “b” 의 값을 포함하는 캐시 라인을 받고 자신의 캐시에 올립니다.
8. CPU 1 은 이제 `while (b == 0) continue` 의 수행을 끝내고, “b” 의 값이 1임을 확인하므로, 다음 문장의, 메모리 배리어를 수행하게 됩니다.
9. CPU 1 은 이제 모든 무효화 큐에 들어가 있던 메세지들이 처리될 때까지 기다려야만 합니다.
10. CPU 1 은 이제 큐에 들어가 있던 “invalidate” 메세지를 수행하게 되어, 자신의 캐시에서 “a” 를 담고 있는 캐시 라인을 무효화 시킵니다.
11. CPU 1 은 `assert(a == 1)` 을 수행하는데, “a” 를 담고 있는 캐시 라인이 더이상 CPU 1 의 캐시에 존재하지 않으므로, “read” 메세지를 보냅니다.
12. CPU 0 는 이 “read” 메세지에 “a” 의 새로운 값을 담고 있는 캐시 라인으로 응답합니다.
13. CPU 1 은 “a” 의 값 1을 담고 있는 이 캐시 라인을 받고, 따라서 단정문은 성공합니다.

훨씬 많이 주고받게 된 MESI 메세지들과 함께, CPU 을바른답에도 달했습니다. 이 섹션은 왜 CPU 설계자들이 캐시 일관성 최적화에 매우 조심스러워야만 하는지 이야기 했습니다.

C.5 Read and Write Memory Barriers

앞의 섹션에서, 메모리 배리어들은 스토어 버퍼와 무효화 큐 둘 다의 항목들을 표시하는데 사용되었습니다. 하지만 우리의 코드에서, `foo()` 는 무효화 큐에 대해 별다른 일을 할 이유가 없었고, `bar()` 는 스토어 버퍼에 추가적인 일을 할 이유가 없었습니다.

따라서 많은 CPU 들이 이 두가지 일 중 하나만 하느 좀 더 약한 메모리 배리어 인스트럭션을 제공합니다. 간단히 말해서, “읽기 메모리 배리어”는 무효화 큐만 을, 그리고 “쓰기 메모리 배리어”는 스토어 버퍼만을 막킹하며, 전체 메모리 배리어는 둘 다 합니다.

이로 인해 읽기 메모리 배리어는 자신을 수행한 CPU에서의 로드 오퍼레이션들에 대해서만 순서를 맞춰줘서, 읽기 메모리 배리어 앞에 있었던 로드 오퍼레이션들은 읽기 메모리 배리어 뒤에 따라오는 로드 오퍼레이션들이 이전에 완료된 것으로 보이게 하는 효과를 냅니다. 유사하게, 쓰기 메모리 배리어는 자신을 수행한 CPU에서 스토어 오퍼레이션들만을 순서를 맞춰줘서, 쓰기 메모리 배리어 앞의 모든 스토어 오퍼레이션들이 쓰기 메모리 배리어를 뒤따르는 스토어 오퍼레이션들 이전에 끝난 것처럼 보이게 합니다. 전체 메모리 배리어는 로드와 스토어 둘 다를 순서세웁니다만, 아까도 이야기 했듯 메모리 배리어를 실행하는 CPU 위에서만 그렇습니다.

`foo` 와 `bar` 를 읽기 메모리 배리어와 쓰기 메모리 배리어를 사용하도록 바꾸면 다음과 같을 것입니다:

```

1 void foo(void)
2 {
3     a = 1;
4     smp_wmb();
5     b = 1;
6 }
7
8 void bar(void)
9 {
10    while (b == 0) continue;
11    smp_rmb();
12    assert(a == 1);
13 }

```

일부 컴퓨터는 이보다도 다양한 메모리 배리어를 가지고 있기도 합니다만, 이 세개의 변종만 이해해도 일반적인 메모리 배리어에 대해 잘 소개 할 수 있을 것입니다.

C.6 Example Memory-Barrier Sequences

이 섹션은 괜찮아 보이지만 약간씩 잘못된 메모리 배리어의 사용 예를 제공합니다. 대부분은 많은 상황에서 올바르게 동작할 것이고, 일부는 특정 CPU에서라면 항상 잘 동작하겠지만, 모든 CPU에서 안정적으로 동작하는 코드를 만들고자 한다면 이런 잘못된 사용은 없어야만 합니다. 이 약간씩 잘못된 부분을 잘 보기 위해, 먼저 순서세우기에 적대적인 아키텍쳐에 집중을 해 볼 필요가 있습니다.

C.6.1 Ordering-Hostile Architecture

지난 수십년간 여러개의 순서세우기에 적대적인 컴퓨터 시스템들이 만들어졌습니다만, 적대성의 본질은 항상 매우 교묘해서 그것을 이해하는데에는 특정 하드웨어에 대한 자세한 지식이 필요했습니다. 특정 하드웨어 벤더를 고르고 독자 여러분을 자세한 기술 사양으로 끌어들이는 대신, 실존하지는 않지만 최대한 메모리 순서에 적대적인 컴퓨터 아키텍쳐를 설계해 봅시다.⁴

이 하드웨어는 다음과 같은 순서 규칙 [McK05a, McK05b]을 지켜야만 합니다:

1. 각 CPU 는 항상 자기 자신의 메모리 액세스를 프로그램 순서로 이루어진 것으로 인지해야 합니다.
2. CPU 들은 스토어 오퍼레이션들만으로 구성된 오펠에시녀들을 두 오퍼레이션들이 서로 다른 위치에 대해 행해진다면 순서를 바꿀 것입니다.
3. 읽기 메모리 배리어 (`smp_rmb()`) 앞에 있는 한 CPU 의 모든 로드 오퍼레이션들은 모든 CPU 들에 그 읽기 메모리 배리어 뒤에 따라오는 로드 오퍼레이션들보다 앞서 수행된 것으로 인지될 것입니다.
4. 쓰기 메모리 배리어 (`smp_wmb()`)를 앞서는 한 CPU 의 모든 스토어 오퍼레이션들은 모든 CPU 들에 그 쓰기 메모리 배리어 뒤에 따라오는 스토어 오퍼레이션들보다 앞서 수행된 것으로 인지될 것입니다.
5. 전체 메모리 배리어 (`smp_mb()`)를 앞서는 한 CPU 의 모든 액세스들 (로드 오퍼레이션들과 스토어 오퍼레이션들) 은 그 메모리 배리어를 뒤따르는 어떤 다른 액세스들보다도 먼저 수행된 것으로 모든 CPU 들에 인지될 것입니다.

⁴ 실제 하드웨어 아키텍쳐를 자세히 알아보는 것을 선호하는 독자 여러분들은 CPU 벤더들의 매뉴얼들 [SW95, Adv02, Int02, IBM94, LHF05, SPA94, Int04b, Int04a, Int04c], Gharachorloo 의 박사 학위 논문 [Gha95], Peter Sewell 의 작업물 [Sew], 또는 Sorin, Hill, 그리고 Wood 의 훌륭한 하드웨어에 기반한 초급 독본 [SHW11] 을 참고해 보시기 바랍니다.

Quick Quiz C.11: 각 CPU 는 자신의 메모리 액세스를 순서대로 보게 된다는 보장 사항은 각 유저 레벨 쓰레드 역시 자신의 메모리 액세스를 순서대로 볼 것이라고 보장하나요? 그렇다면 왜 그렇고, 아니라면 왜 아니죠? ■

주어진 노드의 CPU 들에게 interconnect 밴드위쓰를 공정하게 할당해 줄 수 있도록 각 노드의 interconnect interface 마다 CPU 별 큐를 제공하는, Figure C.8 와 같이 커다란 non-uniform 캐시 아키텍쳐 (NUCA) 시스템을 생각해 보세요. 한 CPU 의 액세스들은 그 CPU 에서 수행한 메모리 배리어에 의해 의도한대로 순서가 세워지지만, 두 개의 CPU 째의 액세스들의 상대적인 순서는 이후 보게 되듯 상당히 자유롭게 재배치 될 수 있습니다.⁵




Figure C.8: Example Ordering-Hostile Architecture

C.6.2 Example 1

Listing C.1 는 각각 CPU 0, 1, 2 에서 동시에 수행되는 코드를 보이고 있습니다. “a”, “b”, “c” 는 처음엔 0 값을 갖습니다.

CPU 0 가 최근에 많은 캐시 미스를 겪었고, 따라서 메세지 큐가 꽉 찼지만, CPU 1 은 캐시 안에서 대부분의 수행을 마무리 지었고, 따라서 메세지 큐가 비어 있다고 생각해 봅시다. 이제 CPU 0 의 “a” 와 “b” 에의 값 대입은 Node 0 의 캐시에 곧바로 이루어질 (따라서 CPU 1 에게 곧바로 보일 것이고) 테지만, CPU 0 의 메세지 큐는 이미 꽉 차 있으므로 바깥에 그 현상이 보여지려면 큐에

⁵ 진짜 하드웨어 아키텍트들이나 디자이너들은 여기에 강력하게 반발할텐데, 두 CPU 가 모두 액세스 하는 캐시 라인에 관한 메세지를 어떤 큐가 처리해야 하는지에 대한 가능성에 대해, 이 예가 포함하고 있을 수 있는 많은 레이스 상황에 대해 아무것도 말할 수 없기 때문에, 좀 화가 날 수 있기 때문입니다. 제가 말 할 수 있는 건 “더 나은 예를 주세요.” 뿐입니다.

Listing C.1: Memory Barrier Example 1

CPU 0	CPU 1	CPU 2
<pre>a = 1; smp_wmb(); b = 1;</pre>	<pre>while (b == 0); c = 1;</pre>	<pre>z = c; smp_rmb(); x = a; assert(z == 0 x == 1);</pre>

차 있는 작업들이 처리되길 기다려야 할 겁니다. 반면, CPU 1 의 “c” 에의 값 대입은 CPU 1 의 비어있는 큐를 통해 곧바로 이루어질 것입니다. 따라서, CPU 2 는 CPU 1 의 “c” 에의 값 대입을 CPU 0 의 “a” 에의 값 대입 이전에 보게 될 것이고, 메모리 배리어에도 불구하고 단정문이 실패하게 만들 것입니다.

따라서, 컴파일러와 CPU 모두 코드가 단정문을 실패 하도록 만들 수 있으므로, 다양한 환경에 포팅을 해야 하는 코드라면 이 단정문 통과에 기대선 안됩니다.

Quick Quiz C.12: CPU 1 의 “while” 과 “c” 값 대입문 사이에 메모리 배리어를 넣는 것으로 이 코드를 고칠 수 있지 않을까요? 고칠 수 있다면 왜이고 고칠 수 없다면 그건 또 왜죠? ■

C.6.3 Example 2

Listing C.2 는 각각 CPU 0, 1, 2 에서 동시에 수행되는 코드를 보이고 있습니다. “a”, “b”, “c” 는 처음엔 0 값을 갖습니다.

Listing C.2: Memory Barrier Example 2

CPU 0	CPU 1	CPU 2
<pre>a = 1;</pre>	<pre>while (a == 0); smp_mb(); b = 1;</pre>	<pre>y = b; smp_rmb(); x = a; assert(y == 0 x == 1);</pre>

이번에도, CPU 0 는 최근 많은 캐시 미스를 겪었어서 메세지 큐가 꽉 차 있고, CPU 1 은 캐시 안에서만 수행을 마무리 해왔기에 CPU 1 의 메세지 큐는 비어 있는 상황을 생각해 봅시다. CPU 0 의 “a” 에의 값 대입은 Node 0 의 캐시에 곧바로 반영될 (따라서 곧바로 CPU 1 에게 보이게 됩니다) 것이지만, CPU 0 의 메세지 큐가 가득 차 있으므로 곧바로 외부에 보이지는 못할 것입니다. 반면, CPU 1 의 “b” 에의 값 대입은 CPU 1 의 비어있는 메세지 큐를 곧바로 넘어갑니다. 따라서, CPU 2 는 CPU 1 의 “b” 에의 값 대입을 CPU 0 의 “a” 에의 값 대입 이전에 보게 되고, 메모리 배리어에도 불구하고 단정문의 실패를 야기하게 됩니다.

이론적으로, 포터블한 코드는 이 예제의 코드를 사용해선 안됩니다만, 실제로는 앞에서와 같이 대부분의 주류 컴퓨터 시스템에서 이 코드도 잘 동작합니다.

C.6.4 Example 3

Listing C.2 는 각각 CPU 0, 1, 2에서 동시에 수행되는 코드를 보이고 있습니다. 모든 변수는 처음엔 0 값을 갖습니다.

CPU 1 도 CPU 2 도 CPU 0 의 line 3에서의 “b”에의 값 할당을 보기 전까지는 line 5로 넘어갈 수 없음을 알아 둡시다. CPU 1과 2가 line 4의 메모리 배리어를 실행한다면, 둘 다 CPU 0의 line 2의 메모리 배리어 앞의 값 할당을 볼 수 있도록 보장됩니다. 비슷하게, line 8의 CPU 0의 메모리 배리어는 line 4의, CPU 1과 2에 의한 메모리 배리어와 짹을 이루므로 CPU 0은 line 9의 “e”의 값 할당을 자신의 “a”에의 값 할당이 다른 CPU 둘 다에게 보이기 전까지는 수행할 수 없을 것입니다. 따라서, CPU 2의 line 9에서의 단정문은 실패하지 않을 것이 보장됩니다.

Quick Quiz C.13: Listing C.3에서 CPU 1과 2의 line 3-5가 인터럽트 핸들러 안에서 수행되고, CPU 2의 line 9는 프로세스 레벨에서 수행된다고 생각해 봅시다. 달리 말하자면, 이 표의 세개의 열 모두의 코드가 같은 CPU에서 수행되지만, 앞의 두개의 열의 코드는 인터럽트 핸들러에서 수행되고, 세번째 열의 것은 프로세스 레벨에서 수행되어서, 세번째 열의 코드는 앞의 두 열에 의해 인터럽트 당할 수 있다고 생각해 봅시다. 코드가 정확히 동작하도록 하는데, 달리 말하자면 단정문이 실패하지 않도록 하는데 어떤 변경이 필요할까요? 필요하다면 무엇일까요? ■

Quick Quiz C.14: Listing C.3의 예에서 CPU 2가 `assert(e==0 || c==1)`을 수행하면 단정문은 실패할 수 있을까요? ■

리눅스 커널의 `synchronize_rcu()`는 이 예에서 보인 것과 유사한 알고리즘을 사용합니다.

C.7 Are Memory Barriers Forever?

최근의 시스템들 중에는 일반적으로 순서 외 (out-of-order) 실행에, 그리고 특히 메모리 참조 재배치에 상당히 덜 과감한 경우가 여럿 있었습니다. 이런 경향은 메모리 배리어가 과거의 것이 되게 하는 지점까지 이어질까요?

긍정적으로 생각하는 측에서는 제안된, 매우 많은 멀티 쓰레드를 지원해서 각 쓰레드는 메모리가 준비되기까지 기다리게 되고, 그 사이 수십, 수백, 심지어 수천개의 다른 쓰레드들이 진전을 이루게 되는 하드웨어 아키텍쳐를 인용할 수 있을 겁니다. 그런 아키텍쳐에서 쓰레드는 다음 인스트럭션을 수행하기 전, 나머지 오퍼레이션들이 모두 완료될 때까지 그저 기다릴 것이기 때문에 메모리 배리어들이 필요 없을 겁니다. 수천개의 다른 쓰레드가 존재하고 있을 것이기 때문에, 해당 CPU

는 완전히 활용되고 있을 것이고, 따라서 CPU는 시간을 허비하지 않습니다.

반대하는 측에서는 극단적으로 적은, 1000개 쓰레드 까지 확장이 가능한 어플리케이션의 수와 일부 어플리케이션에서는 수십 마이크로세컨드에 불과할 정도로 가혹한 실시간 요구사항을 인용할 수 있을 겁니다. 앞서 이야기한 거대한 멀티 쓰레드 시나리오대로라면 실시간 반응성 요구사항은 달성되기 어려우며, 극단적으로 적은 싱글 쓰레드 처리량을 생각하면 더더욱 어려울 것입니다.

또 다른 찬성 의견 측에서는 갈수록 늘어나는, 여전히 순서와 실행의 성능 이점을 거의 다 제공하면서도 완전히 순차적 일관성 (sequential consistency)을 제공하는 것 같은 환상을 제공하는 CPU를 구현하는 정교한, 대기시간을 줄기는 하드웨어 구현 기술들을 인용할 수도 있을 것입니다. 반대 측에서는 갈수록 가혹해져 가는, 배터리 기반 디바이스와 환경적 요구사항 둘 다에서 발생하는 전력 효율성 요구사항을 인용할 수 있을 것입니다.

누가 맞을까요? 딱히 단서가 없으니, 두 시나리오 모두에 대비해서 살아야 합니다.

C.8 Advice to Hardware Designers

하드웨어 설계자들이 소프트웨어쪽 사람들의 삶을 고통스럽게 하기 위해 할 수 있는 여러가지 일들이 있습니다. 여기 우리가 과거에 마주했던 그런 것들 중 몇개를 미래에는 그런 문제가 없어지도록 도움을 주기 위한 바램으로 나열해 봅니다:

1. 캐시 일관성을 무시하는 I/O 디바이스들.

이 유혹적인 잘못된 기능은 메모리로부터의 DMA가 아웃풋 버퍼에 만들어진 최근의 변경을 놓치거나, 인풋 버퍼가 CPU 캐시에 의해 DMA 완료 직후에야 덮어써지게 만들 수 있습니다. 그런 잘못된 동작에서도 시스템이 정상적으로 동작하게 만들려면, 조심스럽게 모든 DMA 버퍼 위치의 CPU 캐시를 그 버퍼가 I/O 디바이스에 넘어가기 전에 비워야만 합니다. 비슷하게, 모든 DMA 버퍼 위치의 CPU 캐시를 해당 버퍼로의 DMA가 완료된 직후 비워야 합니다. 그리고 나서도, 잘못 만들어진 인풋 버퍼로의 읽기 작업조차도 해당 데이터 입력을 망가뜨릴 수 있기 때문에, 포인터 버그를 매우 조심스럽게 방지해야 합니다!

2. 캐시 일관성 데이터를 전달하는데 실패할 수 있는 외부 버스.

이전 앞의 문제보다도 더 심각한 문제로, 여러 디바이스 그룹들—그리고 심지어 메모리 자신도—을

Listing C.3: Memory Barrier Example 3

	CPU 0	CPU 1	CPU 2
1	a = 1;		
2	smp_wmb();		
3	b = 1;	while (b == 0);	
4		smp_mb();	
5		c = 1;	
6	while (c == 0);		
7	while (d == 0);		
8	smp_mb();		
9	e = 1;		assert(e == 0 a == 1);

캐시 일관성과 관련해 실패하게 만듭니다. 이야기하기 고통스러운 말이지만, 임베디드 시스템들이 멀티코어 아키텍쳐로 옮겨감에 따라 이런 문제들이 여럿 나타나게 될 것입니다. 부디 이 문제들이 2015년에는 해결되길 바랍니다.

3. 캐시 일관성을 무시하는 디바이스 인터럽트들.

이건 문제 없어 보일 수 있습니다 — 일단, 인터럽트들은 메모리 참조가 아니지 않습니까? 하지만 분할된 캐시를 갖는 CPU에서 인풋 버퍼의 마지막 캐시라인을 매우 바쁜 뱅크 하나가 가지고 있는 상황을 생각해 봅시다. 만약 관련된 I/O 완료 인터럽트가 이 CPU에 도착하면, 이 CPU의 해당 버퍼의 마지막 캐시라인으로의 메모리 참조는 예전 데이터를 반환할 수 있고, 이로 인해 데이터가 망가질 수 있으며, 이 망가진 데이터는 뒤에 만들어질 크래시 덤프에는 보이지도 않을 겁니다. 시스템이 문제가 된 입력 버퍼를 덤프 뜨려 해는 시점에서는 DMA는 완료됐을 것이기 때문입니다.

4. 캐시 일관성을 무시하는 프로세서간 인터럽트 (IPS).

IPI가 그 목표지에 연관된 메세지 버퍼의 캐시 라인들이 모두 메모리에 반영되기 전에 도달한다면 문제가 될 수 있습니다.

5. 캐시 일관성을 추월하는 컨텍스트 스위치.

메모리 액세스들이 너무 비순차적으로 완료될 수 있다면, 컨텍스트 스위치가 문제가 될 수 있습니다. 태스크가 원래 있던 CPU에 보이는 모든 메모리 액세스들이 넘어갈 CPU에 보여지게 되기 전에 이동하게 된다면, 해당 태스크에게는 관련된 변수들이 이전의 값으로 보이게 되어, 대부분의 알고리즘을 혼란스럽게 만들 것입니다.

6. 지나치게 친절한 시뮬레이터들과 에뮬레이터들.

메모리 순서 재배치를 강제하는 시뮬레이터나 에뮬레이터를 만들기는 어려운 관계로, 이런 환경에서 잘 동작하던 소프트웨어는 실제 하드웨어에서

수행되면 불쾌한 놀림을 받을 수 있습니다. 불행히도, 하드웨어는 시뮬레이터나 에뮬레이터보다 일탈적이라는게 여전히 진실입니다만, 이런 상황이 바꿔질 바랍니다.

다시 말하지만, 하드웨어 설계자들이 이런 것들을 좀 바꿔주길 바랍니다!

Appendix D

Read-Copy Update Implementations

이 부록은 완전한 기능을 갖춘 제품 수준의 RCU 구현들 몇 가지를 설명합니다. 이 구현들에 대한 이해를 위해서는 Chapter 2 와 9 에 대한 깊은 이해는 물론이고 리눅스 커널에 대한 충분한 이해를 필요로 하는데, 뒤의 것은 여러 책들과 웹사이트를 통해 얻을 수 있을 겁니다 [BC05, CRKH05, Cor08, Lov05].

RCU 구현들을 처음 접한다면, 아마도 Appendix B에서 찾을 수 있을, 더 간단한 “toy” RCU 구현부터 시작해야 할 겁니다.

Section D.1 에서는 “Sleepable RCU” 또는 SRCU 라 불리는 것을 설명하는데, 이는 SRCU 읽기 쓰레드들이 임의적으로 sleep 상태에 빠지는 것을 가능하게 합니다. 이는 제품 수준의 RCU 구현들이 그렇듯이 간단한 구현이며, 그런 구현들에 대해 공부를 시작하기에 좋은 부분입니다.

Section D.2 은 수천개의 CPU 들을 갖춘 SMP 시스템을 위해 설계된, Classic RCU 의 높은 확장성을 갖춘 구현에 대한 개괄을 제공합니다. Section D.3 는 이 구현에 대한 (2008년 경의) 코드의 walkthrough 를 취해봅니다.

마지막으로, Section D.4 에서는 real-time 시스템에서 사용되는 preemptible RCU 구현에 대해 자세히 살펴봅니다.

D.1 Sleepable RCU Implementation

Classic RCU 는 read-side 크리티컬 섹션들이 순수한 스핀락들의 크리티컬 섹션들에 의해 지켜지는 것과 똑같은 규칙을 지킬 것을 필요로 합니다: 블락되거나 sleep 상태에 빠지는 어떠한 종류의 것들도 엄격히 금지됩니다. 이는 많은 경우 RCU 의 사용에 문제가 되었고, Paul 은 RCU read-side 크리티컬 섹션 안에서 임의적으로 잠드는 (또는 블록되는) 것을 허용하는 “sleepable RCU” (SRCU) 를 위한 요청을 많이 받았습니다. Paul 은 기존에는 그런 요청들을 모두 작업할 수 없다고 거부했는데,




Figure D.1: Sleeping While RCU Reading Considered Harmful

RCU read-side 안에서 임의로 sleep 상태에 빠지는 것은 grace period 를 불명확하게 연장시킬 수 있는데, 이는 임의의 커다란 양의 메모리가 하나의 grace period 의 종료를 기다리는 결과를 초래할 것이고, 이는 결국 Figure D.1 에 그려진 것처럼 대부분의 경우 메모리 부족으로 인한 시스템 몇몇 상태의 재앙이 되어버릴 수 있을 것이기 때문이었습니다. 무엇보다도, 시스템 몇몇 상태를 초래할 수 있는—심지어 올바르게 사용되었음에도—모든 동시성 제어 기능은 존재할 가치가 없습니다.

하지만, 스핀락 크리티컬 섹션들이 preemption 될 수 있을 것을 필요로 하는 realtime 커널들 [Mol05] 또한 RCU read-side 크리티컬 섹션들이 preemption 될 수 있을 것을 필요로 했습니다 [MS05]. Preemptible 크리티컬 섹션들은 데드락이 방지될 수 있도록 하기 위해 lock-acquisition 기능이 블록될 수 있을 것을 필요로 했고, 이는 곧 RCU 의, 그리고 스핀락의 크리티컬 섹션들이 락을 기다리며 블록될 수 있음을 의미하게 됩니다. 하지만, 이 두 가지 형태의 sleeping 은 이 잠든 task 들을 짧은 시간 내에 깨우기 위해 사용될 수 있는 priority boosting 과 priority inheritance 라는 특수한 속성을 갖습니다.

하지만, realtime 커널들에서의 RCU의 사용은 “RCU read-side 크리티컬 섹션들은 결코 잠들 수 없다”라고 새겨져 있는 석판에 생겨난 첫번째 흡집이었습니다. 그렇다고는 하나, 들어오는 TCP 연결을 기다리면서 블록되는 것과 같은 불명확한 시간동안의 잠듦은 realtime 커널들에서조차도 엄격히 금지되어 있습니다.

Quick Quiz D.1: Classic RCU read-side 크리티컬 섹션 안에서는 왜 잠드는 행위가 금지되어 있었나요? ■

Quick Quiz D.2: quiescent state에서 컨텍스트 스 위치를 제거해버리고, user-mode 수행과 idle loop를 quiescent state로 남겨둠으로써 Classic RCU read-side 크리티컬 섹션에서의 잠드는 행위를 허용하는 건 어때습니까? ■

D.1.1 SRCU Implementation Strategy

SRCU를 설계하는데 있어서의 주요한 도전점은 RCU read-side 크리티컬 섹션 내에서 잠드는 task가 무한히 많은 RCU callback들을 블록하는 것을 방지하는 것입니다. SRCU는 이 목표를 달성하기 위해 두개의 전략을 사용합니다:

1. Classic RCU의 `call_rcu()` API와 같은 비동기적인 grace-period 인터페이스를 제공하지 않습니다, 그리고
2. grace-period 탐지를 각각의 SRCU를 사용하는 subsystem 내로 격리시킵니다.

이런 전략들의 근본적 이유는 다음 섹션들에서 다루어집니다.

D.1.1.1 Abolish Asynchronous Grace-Period APIs

`call_rcu()` API에서의 문제는 다음에 표현된 것처럼 하나의 쓰레드가 grace period를 기다리는 무한히 큰 수의 메모리 블록들을 만들 수 있다는 겁니다:

```
1 while (p = kmalloc(sizeof(*p), GFP_ATOMIC))
2     call_rcu(&p->rcu, f);
```

반대로, `synchronize_rcu()`를 사용하는 비슷한 코드는 쓰레드당 grace period를 기다리는 메모리 블록은 단 하나까지만 만들 수 있습니다:

```
1 while (p = kmalloc(sizeof(*p),
2                     GFP_ATOMIC)) {
3     synchronize_rcu();
4     kfree(&p->rcu, f);
5 }
```

따라서, SRCU는 `synchronize_rcu()`와 동일한 기능은 제공하지만 `call_rcu()`에 대해서는 동일한 기능을 제공하지 않습니다.

D.1.1.2 Isolate Grace-Period Detection

Classic RCU에서는 단일 read-side 크리티컬 섹션이 무한하게 모든 RCU callback들을 지연시킬 수 있는데, 예를 들면 다음과 같습니다:

```
1 /* BUGGY: Do not use!! */
2 rCU_read_lock();
3 schedule_timeout_interruptible(longdelay);
4 rCU_read_unlock();
```

이런 부류의 동작은 만약 RCU가 grace period의 긴 시간동안의 지연에도 돌아갈 수 있도록 주의깊게 설계된 하나의 subsystem 안에서만 사용되었다면 해결될 수도 있었을 겁니다. 이 긴 시간동안의 RCU read-side 지연이 사라지도록 강제한 RCU의 모든 사용자를 하나의 격리된 subsystem 안에서의 하나의 RCU read-side 버그가 지연시킬 수 있다는게 사실입니다.

이 문제를 우회할 수 있는 한가지 방법은 grace-period 탐지가 subsystem-by-subsystem 기반으로 이루어지도록 해서, 혼수상태의 RCU 읽기 쓰레드는 grace period를 해당 읽기 쓰레드의 subsystem 내에서만 지연시키도록 하는 것입니다. 각각의 subsystem은 grace period를 기다리는 메모리 블록들을 제한된 숫자까지만 가질 수 있고, subsystem의 수 역시 짐작컨대 제한되어 있으므로, grace period를 기다리는 메모리의 양 역시 제한될 겁니다. 특정 subsystem의 설계자는 반드시: (1) SRCU read-side sleeping이 제한되어 있음을 분명히 보장하고 (2) `synchronize_srcu()`를 기다리는 메모리의 양을 제한해야만 합니다.¹

이게 정확히 SRCU가 취한 방법으로, 다음 섹션에서 설명됩니다.

D.1.2 SRCU API and Usage

SRCU API가 Figure D.2에 보여져 있습니다. 다음 섹션은 이걸 어떻게 사용하는지 설명합니다.

```
int init_srcu_struct(struct srcu_struct *sp);
void cleanup_srcu_struct(struct srcu_struct *sp);
int srcu_read_lock(struct srcu_struct *sp);
void srcu_read_unlock(struct srcu_struct *sp, int idx);
void synchronize_srcu(struct srcu_struct *sp);
long srcu_batches_completed(struct srcu_struct *sp);
```

Figure D.2: SRCU API

¹ 예를 들어, SRCU로 보호되는 해시 테이블은 hash chain 당 하나의 락을 가질 수 있어서, hash chain 당 최대 하나의 블록이 `synchronize_srcu()`를 기다리도록 할 수 있습니다.

D.1.2.1 Initialization and Cleanup

SRCU 를 사용하는 subsystem 각각은 `struct srcu_struct` 를 이 타입의 변수를 선언하는 것으로, 또는, 예를 들면 `kamllloc()` 등을 사용해서 동적으로 메모리를 할당하는 것으로 생성해야만 합니다. 일단 이 구조체가 만들어지면, 이 구조체는 `init_srcu_struct()` 로 초기화 되어야 하는데, 이 함수는 성공 시에는 0 을, (예를 들어, 메모리 부족 같은 이유로 인한) 실패 시에는 에러 코드를 리턴합니다.

만약 `struct srcu_struct` 가 동적으로 할당되었다면, 메모리에서 해제되기 전에 `cleanup_srcu_struct()` 가 반드시 호출되어야 합니다. 비슷하게, `struct srcu_struct` 가 리눅스 커널 모듈 내에서 선언된 변수라면, `cleanup_srcu_struct()` 는 해당 모듈이 언로드 되기 전에 호출되어야만 합니다. 어떤 방식으로든, 호출자는 `cleanup_srcu_struct()` 의 호출 전에 모든 SRCU read-side 크리티컬 섹션이 완료되었음을 (그리고 더이상 시작되지 않을 것을) 보장해야 합니다. 이를 달성하기 위한 방법 중 한가지가 Section D.1.2.4에서 설명됩니다.

D.1.2.2 Read-Side Primitives

Read-side `srcu_read_lock()` 과 `srcu_read_unlock()` 기능들은 다음과 같이 사용됩니다:

```
1 idx = srcu_read_lock(&ss);
2 /* read-side critical section. */
3 srcu_read_unlock(&ss, idx);
```

`ss` 변수는 그 초기화가 Section D.1.2.1에서 설명된 `struct srcu_struct` 이고 `idx` 변수는 `srcu_read_unlock()` 에게 시작된 `srcu_read_lock()` 이 연관된 grace period 를 이야기 하는 정수입니다.

이렇게 정수를 가져가는 것은 RCU API로부터의 이별로써, 이는, 필요시 된다면, 똑같은 정보를 task 구조체에 저장할 겁니다. 하지만, 주어진 task 는 잠재적으로 무한하게 커다란 수의 중첩된 SRCU read-side 크리티컬 섹션을 독점할 수 있기에, SRCU 는 이 index 를 task structure 에 저장할 수 없습니다.

D.1.2.3 Update-Side Primitives

`synchronize_srcu()` 기능은 아래에 보여진 것처럼 사용될 수 있습니다:

```
1 list_del_rcu(p);
2 synchronize_srcu(&ss);
3 kfree(p);
```

Classic RCU 와의 유사점으로부터 유추할 수 있듯이, 이 기능은 Table D.1에 보여진 것처럼 이 `synchronize_src()` 가 시작하기 전에 시작된 모든 SRCU read-side

크리티컬 섹션들이 완료될 때까지 블록됩니다. 여기서, CPU 1 은 CPU 0 의 SRCU read-side 크리티컬 섹션의 완료까지만 기다리면 됩니다. CPU 2 의 SRCU read-side 크리티컬 섹션의 완료를 기다릴 필요는 없는데, CPU 2 는 CPU 1 이 `synchronize_src()` 의 수행을 시작하기까지는 이 크리티컬 섹션을 시작하지 않았기 때문입니다. 마지막으로, CPU 1 의 `synchronize_srcu()` 는 CPU 3 의 SRCU read-side 크리티컬 섹션을 기다릴 필요가 없는데, CPU 3 는 자신의 `struct srcu_struct` 로 `s1` 이 아니라 `s2` 를 사용하기 때문입니다. 따라서 CPU 3 의 SRCU read-side 크리티컬 섹션은 CPU 0 과 2 와는 다른 grace period 집합에 연관됩니다.

특정 `struct srcu_struct` 의 grace period 의 진행을 모니터 하기 위해 `srcu_batches_completed()` 기능을 사용할 수 있을 겁니다. 이 기능은 SRCU 의 동작을 검증하는 “torture tests”에서 사용됩니다.

D.1.2.4 Cleaning Up Safely

SRCU 를 안전하게 정리하기 (cleanning up) 는 하나의 도전이 될수 있습니다만, 다행히도 많은 사용의 경우 그럴 필요가 없습니다. 예를 들어, boot time 에 초기화를 하는 운영체제 커널에서의 사용의 경우 정리 작업이 필요없습니다. 하지만, load 할 수 있는 모듈 내에서의 사용은 연관된 모듈이 안전하게 unload 되어야 한다면 정리 작업이 필요합니다.

RCU torture 모듈과 같은 일부 경우에 있어서는, 알려진 작은 수의 쓰레드들만이 특정한 `struct srcu_struct` 에 대해 SRCU read-side 기능들을 사용합니다. 이런 경우에 있어서는 module 종료 코드는 해당 쓰레드들을 종료시키고, 그것들이 종료되길 기다린 후, 정리 작업을 진행하면 됩니다.

예를 들면 디바이스 드라이버들과 같은 다른 경우에 있어서는 시스템의 어떤 쓰레드이건 해당 SRCU 의 read-side 기능들을 사용하고 있을 수 있습니다. 앞의 문단에서의 방법을 적용할 수도 있겠지만, 이는 결국 전체 reboot 과 같은 결과를 나오게 할텐데, 이는 별로 매력적인 방법이 아닙니다. Figure D.3 는 reboot 없이 정리 작업이 이뤄질 수 있는 방법 한가지를 보입니다.

`readside()` 함수는 line 5-11 의 RCU 와 line 10-13 의 SRCU read-side 크리티컬 섹션을 겹치게 합니다. 이 RCU read-side 크리티컬 섹션은 `nomoresrcu` 변수의 값을 지키기 위해 순수한 RCU [McK04] 를 사용합니다. 만약 이 변수에 값이 할당되면, 우린 정리작업을 하고 있는 것이고, 따라서 뒤의 SRCU read-side 크리티컬 섹션을 들어가지 않아야 하므로, 그대신 `-EINVAL` 을 리턴합니다. 한편, 우리가 아직 정리작업 중이 아니라면, 우린 SRCU read-side 크리티컬 섹션 안으로 진입합니다.

`cleanup()` 함수는 먼저 line 19에서 `nomoresrcu` 변수에 값을 할당하지만, 그러고나서는 모든 현재 존재하

Table D.1: Ssrcu Update and Read-Side Critical Sections

	CPU 0	CPU 1	CPU 2	CPU 3
1	i0 = srcu_read_lock(&s1)			i3 = srcu_read_lock(&s2)
2		synchronize_srcu(&s1)enter		
3			i2 = srcu_read_lock(&s1)	
4	srcu_read_unlock(&s1, i0)			
5		synchronize_srcu(&s1)exit		
6			srcu_read_unlock(&s1, i2)	

```

1 int readside(void)
2 {
3     int idx;
4
5     rCU_read_lock();
6     if (nomoresrcu) {
7         rCU_read_unlock();
8         return -EINVAL;
9     }
10    idx = srcu_read_lock(&ss);
11    rCU_read_unlock();
12    /* Ssrcu read-side critical section. */
13    srcu_read_unlock(&ss, idx);
14    return 0;
15 }
16
17 void cleanup(void)
18 {
19     nomoresrcu = 1;
20     synchronize_rcu();
21     synchronize_srcu(&ss);
22     cleanup_srcu_struct(&ss);
23 }

```

Figure D.3: Ssrcu Safe Cleanup

는 RCU read-side 크리티컬 섹션이 완료되기를 line 20에서의 synchronize_rcu() 기능을 통해 기다립니다. 일단 cleanup() 함수가 line 21에 다다르면, nomoresrcu의 값이 0인 것을 봤을 수 있는 모든 readside() 실행 쓰레드들은 이미 line 11에 이르렀을 것이고, 따라서 이미 각각의 Ssrcu read-side 크리티컬 섹션에 들어갔어야 합니다. 모든 이후의 readside() 호출은 line 8에서 종료될 것이고, 따라서 read-side 크리티컬 섹션에 들어가지 않을 것입니다.

따라서, 일단 cleanup()이 line 21에서의 synchronize_srcu() 호출을 완료한다면, 모든 Ssrcu read-side 크리티컬 섹션들은 이미 완료되었을 것이고, 새로운 크리티컬 섹션의 시작은 없을 겁니다. 따라서 line 22에서의 cleanup_srcu_struct() 호출을 통한 정리작업은 안전합니다.

D.1.3 Implementation

이 섹션은 Ssrcu의 데이터 구조, 초기화와 정리 기능들, read-side 기능들, 그리고 update-side 기능들을 설명합니다.

D.1.3.1 Data Structures

Figure D.4에 Ssrcu의 데이터 구조가 보여져 있고, Figure D.5에 그 개략적 구조가 설명되어 있습니다. completed 필드는 struct srcu가 초기화된 이후의 grace period들의 횟수를 세고, 다이어그램에 보여진 것처럼, 그 아래쪽 비트는 struct srcu_struct_array를 가리키는데에 사용됩니다. per_cpu_ref 필드는 이 배열을 가리키고, mutex 필드는 한번에 하나의 synchronize_src() 만이 진행될 수 있도록 하는데에 사용됩니다.

```

1 struct srcu_struct_array {
2     int c[2];
3 };
4 struct srcu_struct {
5     int completed;
6     struct srcu_struct_array *per_cpu_ref;
7     struct mutex mutex;
8 };

```

Figure D.4: Ssrcu Data Structures




Figure D.5: Ssrcu Data-Structure Diagram

D.1.3.2 Initialization Implementation

Ssrcu의 초기화 함수, init_srcu_struct()가 Figure D.6에 보여져 있습니다. 이 함수는 단순히 struct

`srcu_struct`의 필드들을 초기화 할 뿐이며, 초기화가 성공하면 0을 리턴하고 그렇지 않으면 `-ENOMEM`을 리턴합니다.

```

1 int init_srcu_struct(struct srcu_struct *sp)
2 {
3     sp->completed = 0;
4     mutex_init(&sp->mutex);
5     sp->per_cpu_ref =
6         alloc_percpu(struct srcu_struct_array);
7     return (sp->per_cpu_ref ? 0 : -ENOMEM);
8 }
```

Figure D.6: SRCU Initialization

SRCU의 cleanup 함수들이 Figure D.7에 보여져 있습니다. 주요 cleanup 함수인 `cleanup_srcu_struct()`가 그림의 line 19-29에 보여져 있는데, 이 함수는 `srcut_srcu_struct`를 사용하는 읽기 쓰레드들이 현재 존재하지 않음을 검증하기 위해 이 그림의 line 13-17에 보여져 있는 `srcu_readers_active()`를 곧바로 호출합니다.

`srcu_readers_active()` 함수는 단순히 각 노드의 `srcu_readers_active_idx()`의 값의 합을 리턴할 뿐이며, `srcu_readers_active_idx()`는 line 1-11에 보여진 것과 같이 해당 인덱스에 연관된 per-CPU 카운터들의 값의 합을 구해서 그 결과를 리턴합니다.

`srcu_readers_active()`로부터 리턴받은 값이 0이 아니라면, `cleanup_srcu_struct()`는 line 24에서 경고를 내고는 단순히 line 25와 26에서 리턴해서 여전히 사용중인 `srcut_srcu_struct`의 해제 작업을 하지 않습니다. 그런 경고는 항상 버그에 연관되어 있으며, 버그가 레포트 되었으므로, 있을 법한 메모리 오염을 알리기보다는 약간의 메모리 누수와 함께 시스템이 지속되도록 하는게 낫습니다.

그렇지 않다면, `cleanup_srcu_struct()`는 line 27과 28에서 per-CPU 카운터들의 배열을 해제하고 포인터들의 값을 NULL로 만듭니다.

D.1.3.3 Read-Side Implementation

`srcu_read_lock()`을 구현하는 코드가 Figure D.8에 보여져 있습니다. 이 함수는 메모리 배리어와 어토믹 인스트럭션을 사용하지 않도록 주의깊게 만들어졌습니다.

Line 5와 11은 코드가 `preemption` 당하지 않은 채 하나의 CPU 위에서 수행되도록 강제하기 위해 `preemption`을 불가능하게 만들었다가 다시 가능하게 만듭니다. Line 6는 `grace-period` 카운터의 가장 아래 bit을 가져오는데, 이 bit은 이 Ssrcu read-side 크리티컬 섹션을 위해 per-CPU 카운터들의 어떤 rank가 선택될 것인지 결정하는데 사용됩니다. Line 7에서의 `barrier()`

```

1 int srcu_readers_active_idx(struct srcu_struct *sp,
2                               int idx)
3 {
4     int cpu;
5     int sum;
6
7     sum = 0;
8     for_each_possible_cpu(cpu)
9         sum += per_cpu_ptr(sp->per_cpu_ref, cpu)->c[idx];
10    return sum;
11 }
12
13 int srcu_readers_active(struct srcu_struct *sp)
14 {
15     return srcu_readers_active_idx(sp, 0) +
16         srcu_readers_active_idx(sp, 1);
17 }
18
19 void cleanup_srcu_struct(struct srcu_struct *sp)
20 {
21     int sum;
22
23     sum = srcu_readers_active(sp);
24     WARN_ON(sum);
25     if (sum != 0)
26         return;
27     free_percpu(sp->per_cpu_ref);
28     sp->per_cpu_ref = NULL;
29 }
```

Figure D.7: Ssrcu Cleanup

호출은 이 인덱스가 최소 한번은 가져와 질 것을² 강제하는 컴파일러에의 지시어로, 이로 인해 line 9에서 사용되는 인덱스가 line 12에서 리턴하는 값과 동일하게 합니다. Line 8-9는 현재 CPU의 선택된 카운터를 증가시킵니다.³ Line 10은 non-`CONFIG_PREEMPT` 빌드의 어떠한 코드도 잘못 순서잡히는 것을 막기 위해, 뒤따르는 코드 수행이 line 8-9 뒤에 수행되도록 강제합니다. 하지만, `CONFIG_PREEMPT` 커널에서는 여기 필요했던 `barrier()` 호출이 line 11의 `preempt_enable()` 안에 내장되어 있으므로, 이 경우에 있어 `srcu_barrier()`는 no-op이 됩니다. 마지막으로, line 12는 인덱스를 리턴해서 이게 연관된 `srcu_read_unlock()`에 사용될 수 있도록 합니다.

`srcu_read_unlock()`의 코드가 Figure D.9에 보여져 있습니다. 다시 한번, line 3과 7은 전체 코드가 `preemption` 되지 않은 하나의 CPU 위에서 수행될 수 있도록 `preemption`을 불능화 / 재가능화 시킵니다. `CONFIG_PREEMPT` 커널들에서는, line 3의 `preempt_disable()` 이 `barrier()` 기능을 내장하고 있으며, 그

² 이 이름에도 불구하고, `barrier()`는 CPU가 코드와 메모리 액세스의 수행을 재조합할 수 있는 능력에는 어떠한 영향도 끼치지 않음을 알아두시기 바랍니다.

³ `smp_processor_id()` 기능은 `preemption`이 불능화 되었을 때에만 장기적 의미를 가짐을 알아 두시기 바랍니다. `Preemption`이 불능화 되어 있지 않다면, 이 기능을 곧바로 뒤따르는 `preemption`이 뒤따르는 코드들은 다른 CPU에서 수행되는 결과를 초래할 수 있습니다.

```

1 int srcu_read_lock(struct srcu_struct *sp)
2 {
3     int idx;
4
5     preempt_disable();
6     idx = sp->completed & 0x1;
7     barrier();
8     per_cpu_ptr(sp->per_cpu_ref,
9                  smp_processor_id())->c[idx]++;
10    srcu_barrier();
11    preempt_enable();
12    return idx;
13 }

```

Figure D.8: SRCU Read-Side Acquisition

령지 않은 경우에는 line 4에서 `barrier()` 가 제공됩니다. 다시 한번, 이 지시어는 뒤따르는 코드가 겹쳐지는 인터럽트 핸들러들의 관점에서 이 크리티컬 섹션 뒤에 수행되도록 강제합니다. Line 5 와 6은 이 CPU를 위한 카운터의 값을 감소시키는데, 이 때 사용되는 인덱스는 연관된 `srcu_read_lock()`에서 사용된 것과 동일한 것입니다.

```

1 void srcu_read_unlock(struct srcu_struct *sp, int idx)
2 {
3     preempt_disable();
4     srcu_barrier();
5     per_cpu_ptr(sp->per_cpu_ref,
6                  smp_processor_id())->c[idx]--;
7     preempt_enable();
8 }

```

Figure D.9: SRCU Read-Side Release

핵심은, 특정 CPU의 카운터들은 다른 CPU들에 의해 해당 CPU의 인터럽트 핸들러들과의 협동을 통해서만 보여질 수 있다는 점입니다. 이런 인터럽트 핸들러들은 카운터를 보게 되기 전에 모든 필요한 메모리 배리어들을 사용했음을 분명히 할 책임을 갖습니다.

D.1.3.4 Update-Side Implementation

SRCU의 핵심 포인트는 `synchronize_sched()` 는 현재 수행중인 `preemption` 불능화된 영역의 코드가 완료될 때까지 블록된다는 것입니다. `synchronize_srcu()` 기능은 Figure D.10에 보여진 것처럼 이 효과를 많이 사용합니다.

Line 5는 grace-period 카운터의 스냅샷을 얻어옵니다. Line 6는 mutex를 획득하고, line 7-10은 스냅샷을 얻어온 후 최소 두개의 grace period가 지났는지 체크해보고, 만약 그렇다면, 락을 해제하고 리턴합니다—이 경우, 다른 누군가가 우리가 해야 할 일을 대신 해준 셈입니다. 그렇지 않다면, line 11에서 `srcu_read_lock()`에서 grace period 카운터의 증가된 값을 보는 다른 CPU는 `synchronize_srcu()`에 진입하기 전에 이 CPU에

의해 만들어진 변경도 역시 볼 수 있을 것을 보장합니다. 이 보장은 다음 grace period를 블록하고 있지 않은 모든 Ssrcu read-side 크리티컬 섹션들이 모든 이전의 변경들을 보았음을 분명히 하기 위해 필요합니다.

Line 12는 grace-period 카운터의 밑바닥의 bit을 하나 나중에 per-CPU 카운터 배열로의 인덱스로 사용하기 위해 가져오고, 이후 line 13에서 grace-period 카운터의 값을 증가시킵니다. Line 14는 이제 모든 현재 수행중인 `srcu_read_lock()`이 완료되길 기다리고, 이로 인해 우리가 line 15에 다다랐을 때에는, 모든 `srcu_read_lock()`의 현존하는 인스턴스들은 `sp->completed`의 업데이트된 값을 사용하고 있게 됩니다. 따라서, line 15에서 `srcu_readers_active_idx()`로 얻어와지는 카운터들은 단조적으로 그 값이 감소되는 것이 보장되어서, 일단 그 합이 0에 다다르면, 거기에 도달했음을 보장됩니다.

하지만, `srcu_read_unlock()` 기능에는 메모리 배리어가 없으므로, CPU는 카운터 값 감소를 Ssrcu 크리티컬 섹션 안으로 재배열 할 수 있고, 따라서 Ssrcu로 보호되는 데이터 구조로의 레퍼런스가 Ssrcu 크리티컬 섹션 바깥으로 “새어나올” 수도 있습니다. 이 시나리오는 line 17의 `synchronize_sched()`에 의해서 해결되어지는데, 이 기능은 `preempt_disable()` 코드(`srcu_read_unlock()`과 같은) 내에서 수행되고 있는 모든 CPU들이 그 코드 수행을 완료할 때까지 블록되도록 합니다. 특정 `preempt_disable()` 코드의 완료는 그 코드를 수행중인 CPU에 의해 보여지므로, 이 코드의 완료는 모든 앞의 Ssrcu read-side 크리티컬 섹션의 완료를 의미합니다. 필요한 모든 메모리 배리어들은 이 완료의 발견을 하는 코드에 의해 제공되어집니다.

따라서, 이 시점에서는 line 18에서와 같이 mutex를 해제하고 호출자에게 리턴하기에 안전하며, 호출자는 같은 `struct srcu_struct`를 공유하고 있는 모든 Ssrcu read-side 크리티컬 섹션들이 `synchronize_srcu()` 호출 전에 만든 모든 업데이트를 볼 수 있을 것임을 확신할 수 있습니다.

Quick Quiz D.3: `synchronize_sched()`에 의해 구분되는 업데이트들이 순서대로 수행될 것이라고 가정해도 되는 이유가 무엇이죠? ■

Quick Quiz D.4: `synchronize_srcu()` (Figure D.10)의 line 17은 왜 line 18의 mutex 해제보다 앞서야 하죠? 이 두 라인이 서로 바꿔게 하려면 어떤 변경이 있어야 할까요? 그런 변경은 의미가 있을까요? 왜 그럴까요? ■

D.1.4 Ssrcu Summary

Ssrcu는 Ssrcu read-side 크리티컬 섹션 안에서의 일반적인 sleeping을 허용하는 RCU 같은 기능들을 제공

```

1 void synchronize_srcu(struct srcu_struct *sp)
2 {
3     int idx;
4
5     idx = sp->completed;
6     mutex_lock(&sp->mutex);
7     if ((sp->completed - idx) >= 2) {
8         mutex_unlock(&sp->mutex);
9         return;
10    }
11    synchronize_sched();
12    idx = sp->completed & 0x1;
13    sp->completed++;
14    synchronize_sched();
15    while (srcu_readers_active_idx(sp, idx))
16        schedule_timeout_interruptible(1);
17    synchronize_sched();
18    mutex_unlock(&sp->mutex);
19 }

```

Figure D.10: SRCU Update-Side Implementation

합니다. 하지만, SRCU 는 프로토타입 코드에서만 사용되어왔음을 알아두실 필요가 있습니다. RCU torture 테스트를 통과하긴 하지만요. 미래에는 SRCU 가 어디에 사용되는지 보는 것도 흥미로울 것입니다.

D.2 Hierarchical RCU Overview

Classic RCU 의 read-side 기능들은 훌륭한 성능과 확장성을 갖긴 합니다만, 언제 이전부터 존재한 read-side 크리티컬 섹션들이 완료되었는지를 결정하는데 사용되는 update-side 기능들은 수십개의 CPU 들만을 고려한 채 설계되었습니다. 이것들의 확장성은 각 grace period 마다 최소 한번은 각 CPU 에 의해 획득되어야 하는 global lock 에 의해 제한됩니다. Classic RCU 는 실제로는 수백개의 CPU 들까지도 확장성을 갖고, 대략 천개의 CPU 들까지도 확장성을 갖도록 (더 길어지는 grace period 를 대가로) 꼼수를 부릴 수 있지만, 발전되는 중인 멀티코어 시스템들은 더 높은 확장성을 필요로 할겁니다.

또한, Classic RCU 는 최적화 되지 않은 dynticks 인터페이스를 가지고 있어서, Classic RCU 는 매 grace period 마다 최소 한번씩은 깨어나게 할겁니다. 이 문제를 자세히 보려면, 4개의 CPU 만이 바쁘게 유지되고 있을 정도로 적은 부하만을 가지고 있는 16-CPU 시스템을 생각해 보세요. 완벽한 세계에서는, 나머지 열두개의 CPU 들은 에너지를 아끼기 위해 깊은 sleep 모드로 빠져 있을 수 있을 겁니다. 불행히도, 네개의 바쁜 CPU 들이 자주 RCU update 동작을 수행한다면, 이 열두개의 idle CPU 들은 자주 깨어나서 상당한 전력을 소모할 겁니다. 따라서, Classic RCU 에의 주요 변경 사항들은 항상 잠들어있는 CPU 들을 놔두어야 합니다.

Classic 과 hierarchical 구현들 둘 다 Classic RCU 의 semantic 과 동일한 API 들을 가지고 있습니다만, 기

존의 구현은 “classic RCU” 로 불리울 것이고, 새로운 구현은 “hierarchical RCU” 라 불릴 겁니다.

Section D.2.1 은 RCU 의 기본에 대한 짧은 개괄을 제공하고 Section D.2.2 은 기존의 “Classic RCU” 구현에 대한 전반적인 개괄을 제공합니다. Section D.2.3 은 RCU 에서 일어나지 않을 것 같은 일들을 나열해보고, Section D.2.4 과 D.2.5 에서는 확장성과 전력 효율성을 위한 설계상의 고려할 점들을 각각 알아보고, Section D.2.6 에서 hierarchical RCU state machine 을 설명합니다. Section D.2.7, Section D.2.8 는 테스트를 다루고, 마지막으로 Section D.2.9 에서 결론을 내립니다.

D.2.1 Review of RCU Fundamentals

가장 기본적 형태에 있어, RCU 는 일이 끝나길 기다리는 방법입니다. 물론, 일이 끝나길 기다리는 방법은 레퍼런스 카운트, reader-writer 락, 이벤트, 등등 매우 많이 존재합니다. RCU 의 커다란 장점은 (대략) 20,000 개의 서로 다른 일들을 명시적으로 하나하나 다 정보를 추적할 필요 없이, 그리고 명시적 추적에서는 피할 수 없는 성능의 하락, 확장성의 제약, 복잡한 데드락 시나리오, 메모리 누수 문제 없이 각각 기다릴 수 있다는 겁니다.

RCU 의 경우, 기다리는 것들은 “RCU read-side 크리티컬 섹션” 이라 불리웁니다. 하나의 RCU read-side 크리티컬 섹션은 `rcu_read_lock()` 기능으로 시작하고, 연관된 `rcu_read_unlock()` 기능으로 종료됩니다. RCU read-side 크리티컬 섹션들은 중첩될 수 있고, 명시적으로 블록되거나 잠들지 않는다면, 상당히 많은 양의 임의적 코드를 포함할 수 있습니다 (Section D.1 에서 설명한 SRCU 라 불리는 특수한 형태의 RCU 는 SRCU read-side 크리티컬 섹션 내에서의 일반적인 sleeping 을 허용하긴 하지만요). 여러분이 이러한 표준을 준수한다면, 여러분은 모든 코드 조각에 대해 완료되길 기다리는데에 RCU 를 사용할 수 있습니다.

RCU 는 언제 이것들이 끝나는지를 간접적으로 판단함으로써 이 기능을 구현하는데, classic RCU 의 경우 다른 곳 [MS98a] 에서, preemptible RCU 의 경우 Section D.4 에서 자세히 설명합니다.

자세히 말하자면, page 132 의 Figure 9.12 에서 보인 바와 같이, RCU 는 앞서 존재하기 시작한 RCU read-side 크리티컬 섹션들과 그것들에 의해 수행된 메모리 오포레이션들이 완전히 종료되기를 기다리는 방법입니다.

하지만, 특정 grace period 가 시작한 후에 시작된 RCU read-side 크리티컬 섹션들은 해당 grace period 종료 뒤 까지도 연장될 수 있음을 알아두시기 바랍니다.

다음 섹션은 Classic RCU 구현이 어떻게 동작하는지에 대한 높은 수준에서의 개관을 제공합니다.

D.2.2 Brief Overview of Classic RCU Implementation

Classic RCU 구현 아래의 핵심 컨셉은, Classic RCU read-side 크리티컬 섹션은 커널 코드에 국한되어 있고 블록이 허용되어 있지 않다는 것입니다. 이 말은 언제든 어떤 CPU 가 블록되어 있는 중으로 보이거나, idle loop 을 돌고 있거나, 커널 모드를 빠져나가 있다면, 우리는 해당 CPU 에서 앞서 수행중이던 RCU read-side 크리티컬 섹션이 모두 완료되었어야 함을 알 수 있다는 것입니다. 그런 상태는 “quiescent states” 라 불리며, 각각의 CPU 가 적어도 하나의 quiescent state 를 거쳤다면, 해당 RCU grace period 는 끝납니다.




Figure D.11: Flat Classic RCU State

Classic RCU 의 가장 중요한 데이터 구조는 `rcu_ctrlblk` 구조체로, Figure D.11 에 보인 것처럼 CPU 당 하나의 bit 을 담고 있는 `->cpumask` 필드를 가지고 있습니다. 각각의 CPU 의 bit 은 각각의 grace period 의 시작지점에서 1로 설정되고, 각각의 CPU 는 quiescent state 를 지날 때마다 자신의 bit 의 값을 해제합니다. 여러 개의 CPU 들이 각자의 bit 을 동시적으로 값 해제하고자 할 수 있으며 이는 `->cpumask` 필드를 오염시킬 수 있기 때문에, 그런 문제를 방지하기 위해 `->cpumask` 필드를 보호하는데에 `->lock` 스피너를 사용됩니다. 안타깝게도, 멀티코어 트렌드가 지속된다면 곧 흔한 경우가 될 수 밖에 넘는 CPU 가 존재한다면 이 스피너 또한 상당한 경쟁상태로 성능에 악영향을 줄 수 있습니다. 더 나쁜건, 모든 CPU 들이 각자의 bit 을 값 해제해야 한다는 사실은 CPU 들이 grace period 동안은 잠들지 않아야 함을 말하는데, 이는 Linux 의 전력 소모 감소 능력이 제한됨을 말합니다.

다음 섹션은 새로운 real-time 이 아닌 RCU 구현에서 필요한 것들을 나열합니다.

D.2.3 RCU Desiderata

Real-time RCU 의 요구사항 [MS05] 을 나열해 보는게 좋은 시작점이 될겁니다:

1. 하나의 RCU grace period 는 모든 이전부터 존재한 RCU read-side 크리티컬 섹션들이 완료될 때까지 끝날 수 없도록 하는 지연된 해체.
2. 일년 365일 24시간 지속되는 동작을 지원할 수 있는 신뢰성.
3. IRQ 핸들러에서 호출할 수 있을 것.
4. 너무 많은 콜백들이 존재한다면 grace period 들을 신속히 처리할 수 있는 메커니즘이 존재할 수 있도록 하는, 억제된 메모리 사용량 (LCA2005 리스트로 효율이 약화되었습니다.)
5. RCU 가 어떤 있음직한 메모리 할당자와도 동작할 수 있도록 해주는 메모리 블락들의 독립성.
6. CPU 나 태스크의 지역적 메모리에서의 평범한, 어토믹하지 않은 인스트럭션 동작이 허용될 수 있도록 하는 동기화에 자유로운 read side (이건 LCA2005 리스트에서 강화되었습니다).
7. Update-side 락이 RCU read-side 크리티컬 섹션 내에서 획득되어지는, 리눅스 커널의 여러곳에서 사용되는 무조건적인 read-to-write 업그레이드.
8. 호환성 있는 API.
9. 이건 real-time RCU 가 될 것은 아니기에, preemption 가능한 RCU read-side 크리티컬 섹션에 대한 요구사항은 빼겠습니다. 하지만, 과거 수년동안의 변경사항들을 처리하기 위해 다음의 새로운 요구 사항들을 추가할 필요가 있습니다.
10. 극단적으로 낮은 internal-to-RCU 락 경쟁상황을 갖는 확장성. RCU 는 최소 1,024 개, 가능하면 최소 4,096 개의 CPU 들을 지원해야 합니다.
11. 전력 효율성: RCU 는 저전력 상태의 dynticks-idle CPU 들을 깨우지 않으면서도 언제 현재의 grace period 가 종료되는지를 알 수 있어야 합니다. 이는 real-time RCU 에서 구현되었습니다만, 상당한 단순화를 필요로 합니다.
12. RCU read-side 크리티컬 섹션들은 irq 핸들러는 물론이고 NMI 핸들러 내에서도 사용이 가능해야 합니다. Preemptible RCU 의 경우에는 별도로 구현된 `synchronize_sched()` 덕분에 이 필요성이 없었음을 알아두시기 바랍니다.

13. RCU 는 반복되는 CPU-hotplug 오퍼레이션들의 상황에서도 잘 동작해야 합니다. 이는 classic RCU 와 real-time RCU 에서의 필요사항들을 가져올 뿐입니다.
14. 앞서 등록된 모든 RCU 콜백들이 완료되길 기다릴 수 있어야만 하는데, 이는 이미 `rcu_barrier()`의 형태로 제공되길 합니다.
15. RCU 와 다양한 무한 루프 버그들, 그리고 RCU grace period 가 종료되기를 막는 하드웨어 상의 문제들을 진단하는데 도움이 될 수 있도록, 응답을 하는데 실패하는 CPU 들을 파악할 수 있다면 좋습니다.
16. 하나의 RCU grace period 가 마지막 연관된 RCU read-side 크리티컬 섹션이 완료되는데에 수백 마이크로세컨드 만이 걸릴 수 있도록 하는 RCU grace period 의 극단적인 속도 촉진이 가능하면 좋습니다. 하지만, 그런 동작은 상당한 CPU 오버헤드를 가져올 거라 예상되어지며, 각각의 RCU grace period 를 기다려야 하는 긴 일련의 오퍼레이션들을 처리해야 할 때 유용할 겁니다.

새로운 요구사항들 가운데 가장 압박이 되는 건 첫 번째 항목인 확장성입니다. 따라서 다음 섹션은 RCU 의 내부 락들의 경쟁 상황을 수십 배 줄여주는지 설명합니다.

D.2.4 Towards a More Scalable RCU Implementation




Figure D.12: Hierarchical RCU State

락 경쟁을 줄여주는 효과적인 방법 가운데 하나는 Figure D.12 에 보인 것처럼 계층을 만드는 것입니다. 여기서, 각각의 네개의 `rcu_node` 구조체는 자신의 락을 가지고 있어서, CPU 0 과 1 만이 좌하단의 `rcu_node` 의 락을 획득하며, CPU 2 와 3 만이 중하단의 `rcu_node` 의 락을 획득하고, CPU 4 와 5 만이 우하단의 `rcu_node` 의 락을 획득합니다. 어떤 특정 grace period 동안에도, 아래쪽 `rcu_node` 구조체들에 접근하는 CPU 들 가운데 하나만이 위의 `rcu_node` 에 접근하게 되어서, 각각의 CPU 짝 들 가운데 마지막 하나만이 연관된 grace period에 대한 quiescent state 를 기록하게 됩니다.

이는 락 경쟁의 상당한 감소를 초래합니다: 여섯개의 CPU 들이 하나의 락을 위해 매 grace period 마다 경쟁하는 대신, 위쪽 `rcu_node` 락에 세개의 CPU 만이 경쟁하고 (50% 경쟁 감소) 아래쪽 `rcu_node` 의 락에 대해서는 각각 두개의 CPU 만이 경쟁을 합니다 (67% 경쟁 감소).




Figure D.13: Mapping `rcu_node` Hierarchy Into Array

`rcu_node` 구조체들의 트리는 `rcu_state` 구조체 안의 선형적 배열로 트리의 루트를 0번 원소로 저장하는 식으로 내장되는데, Figure D.13 에 여덟개의 CPU 를 갖는 시스템에서 세 단계를 갖는 계층으로 구성했을 때를 보이고 있습니다. 각각의 화살표는 특정 `rcu_node` 구조체를 그 부모로 연결시키는데, `rcu_node` 의 `->parent` 필드를 나타냅니다. 각각의 `rcu_node` 는 자신이 관리하는 CPU 들의 범위를 나타내는데, 루트 노드는 모든 CPU 들을 관리하고, leaf 레벨의 각각의 노드는 한쌍의 CPU 들을 관리합니다. 이 배열은 컴파일 시점에 `NR_CPUS` 값에 따라 정적으로 할당됩니다.

Figure D.14 안의 다이어그램들의 시퀀스는 어떻게 grace period 들이 파악되는지를 보입니다. 첫번째 그림에서는 어떤 CPU 도 빨간 네모로 표시되었듯이 quiescent state 에 이르지 못했습니다. 모든 여섯개의 CPU 들이 동시에 RCU 에게 자신이 quiescent state 에 이르렀노라고 이야기하고자 한다고 생각해 봅시다. 각각의 짝 안의 CPU 들 중 하나만이 연관된 아래쪽 `rcu_node` 의 락을 획득할 수 있을 것이고, 따라서 두번째 그림은 그런 운좋은 CPU 들이 0, 3, 그리고 5 라고 초록색 네모로 나타내고 있습니다. 이 운좋은 CPU 들이 일단 마무리 되면, 다른 CPU 들이 락을 획득할 것인데, 세 번째 그림으로 보인 바와 같습니다. 이 CPU 들 각각은 자신들이 자신의 그룹 내에서는 마지막에 이르렀음을




Figure D.14: Hierarchical RCU Grace Period

보게 되고, 따라서 모든 세개의 CPU 들은 위쪽의 `rcu_node`로 이동하려 시도하게 됩니다. 한번에 하나만이 위쪽 `rcu_node` 구조체의 락을 얻을 수 있고, 네번째, 다섯번째, 그리고 여섯번째 그림은 CPU 1, CPU 2, 그리고 CPU 4가 순서대로 그 락을 잡는다는 가정 하에 상태의 흐름을 보입니다. 마지막 여섯번째 그림은 모든 CPU 들이 `quiescent state`를 지난, 그래서 grace period 가 끝난 경우를 보이고 있습니다.




Figure D.15: Hierarchical RCU State 4,096 CPUs

앞의 예에서, Classic RCU 에서라면 여섯개의 CPU 들이 경쟁하게 될 터인 것을 어떤 하나의 락에 대해서는 세개가 넘는 CPU 들이 경쟁하지 않았습니다. 하지만, 더 많은 수의 CPU 들에서라면 이보다도 극적인 락

경쟁의 감소가 가능합니다. 64 개의 아래쪽 구조체와 $64 \times 64 = 4,096$ CPU 들로 구성된, Figure D.15 에 보인 것과 같은 `rcu_node` 구조체들의 계층을 생각해 보세요.

여기서 각각의 아래쪽 `rcu_node` 구조체의 락들은 64 개의 CPU 들에 의해 획득되어지는데, 이는 Classic RCU 의 하나의 글로벌 락에 4,096 개의 CPU 들이 경쟁하는 것에 비해 64배의 감소입니다. 비슷하게, 특정 grace period 동안에, 아래쪽 `rcu_node` 구조체의 CPU 들 가운데 하나만이 위쪽 `rcu_node` 구조체의 락을 잡을 것이므로, 이는 또다시 4,096 개의 CPU 로 구성된 시스템에서 동작하는 Classic RCU 가 겪게 되는 경쟁의 64x 감소입니다.

Quick Quiz D.5: 잠깐만요! 이 새로운 락들을 가지고, 데드락은 어떻게 막나요? ■

Quick Quiz D.6: 왜 64-배 감소에서 멈추는 거죠? 왜 그이상 가서 수백배까지 줄이지 않는거예요? ■

Quick Quiz D.7: 하지만 전 McKenney 의 Quick Quiz 2 에의 게으른 변명 따위 신경쓰지 않아요!!! 저는 하나의 락에 경쟁하는 CPU 들의 수를 16이나 그정도 쯤까지 더 합리적인 수준으로 낮추고 싶어요!!! ■




Figure D.16: Hierarchical RCU State With BH

실제 구현은 RCU 콜백의 리스트와 같은 per-CPU 테이터를 유지하도록 되어 있으며, 이는 `rcu_data` 구조체에 정리되어 있습니다. 또한, `rcu` (`call_rcu()` 에서의) 와 `rcu_bh` (`call_rcu_bh()` 에서의)는 각각 Figure D.16

에 보인 것과 같이 각각의 계층을 유지합니다.

Quick Quiz D.8: 좋아요, 근데 색깔은 뭘 의미하나요?

■ 다음 섹션은 에너지 소모 감소에 대해 이야기 해봅니다.

D.2.5 Towards a Greener RCU Implementation

앞서 언급되었듯이, 이러한 노력의 중요한 목표는 전력 소모를 방지하기 위해 잠자는 CPU들을 깨우지 않는 것입니다. 반면에, Classic RCU는 잠들어 있는 CPU들을 어떤 겨울에 있어서는 매 grace period마다 한번씩은 깨울 것인데, 이는 적은 수의 CPU들만이 바쁘게 일을 하면서 RCU update를 하고 있고 나머지 대부분의 CPU들은 idle 상태일 때에 비효율적입니다. 이 상황은 peak load를 위해 맞춰진 시스템들에서 자주 발생하며, 우린 이런 상황을 잘 대처할 필요가 있습니다. 더 나아가서, 우린 긴시간 동작하는 RCU read-side 크리티컬 섹션을 담고 있으며 인터럽트를 처리하는 dynticks-idle CPU가 RCU grace period가 끝나는 것을 막는데 실패하는, Classic RCU의 오랫동안 있어왔던 버그를 고칠 필요가 있습니다.

Quick Quiz D.9: 그런 어처구니 없는 버그가 있다면, Linux는 대체 어떻게 동작하고 있는거죠? ■

이는 모든 CPU들이 per-CPU `rcu_dynticks` 구조체 안에 위치한 카운터들을 조정하도록 함으로써 이루어집니다. 간단히 말해서, 이 카운터들은 연관된 CPU가 dynticks idle 모드에 있을 경우에는 짹수의 값을 가지고, 그렇지 않을 때에는 훌수의 값을 갖습니다. 따라서 RCU는 이 `rcu_dynticks` 카운터들이 훌수인 CPU들에 대해서만 quiescent state를 기다리면 되고, 그 카운터의 값이 짹수인 잠들어있는 CPU들은 깨울 필요가 없습니다. Figure D.17에 보여진 것처럼, 각각의 per-CPU `rcu_dynticks` 구조체는 “rcu”와 “rcu_bh” 구현에 의해 공유됩니다.

다음 섹션은 높은 레벨에서의 RCU state machine에 대한 개요를 보입니다.

D.2.6 State Machine

충분히 높은 단계에서 보면, 리눅스 커널 RCU 구현은 Figure D.18에 보인 state machine으로 볼 수 있습니다. 바쁘게 동작하는 시스템에서의 이 state machine의 일반적인 경우의 수행경로는 가장 위쪽 두개의 루프로—각각의 grace period (GP)의 시작으로 초기화되어서, quiescent state (QS)를 기다리고, 각 CPU가 grace period 동안 첫번째 quiescent state를 지나가는 경로입니다. 그런 시스템에서는, quiescent state는 각 컨택




Figure D.17: Hierarchical RCU State With Dynticks

스트 스위치마다 발생할 수도 있고, idle 이거나 user-mode 코드를 수행중인 CPU에서는 각 scheduling-clock 인터럽트마다 발생할 수 있습니다. CPU-hotplug 이벤트는 state machine을 “CPU Offline” 상자로 가져가게 되며, quiescent state로의 빠른 전환을 실패하게 하는 “holdout” CPU들의 존재 시에는 “Send resched IPIs to Holdout CPUs” 상자로의 전환을 일으킬 겁니다. 불필요하게 dyntick-idle CPU들을 불필요하게 깨우는 것을 막는 RCU 구현은 그런 CPU들을 연장된 quiescent state에 있는 것으로 표시해 둘 것이고 “CPUs in dyntick-idle Mode?” 결정 마름모꼴의 “Y” 브랜치를 취하게 될 것입니다 (하지만 dyntick-idle 모드의 CPU들은 resched IPI들을 보내지 않을 것임을 알아두세요). 마지막으로, CONFIG_RCU_CPU_STALL_DETECTOR가 켜져있다면, quiescent state에 이르기까지의 정말로 너무 긴 딜레이에는 “Complain About Holdout CPUs” 경로를 수행하게 만들겁니다.

Quick Quiz D.10: 하지만 이 state diagram은 dyntick-idle CPU들이 reschedule IPI들을 맞게 될 것을 보이고

있지 않나요? 그게 그것들을 깨워버리지 않을까요? ■




Figure D.18: Generic RCU State Machine




Figure D.19: RCU State Machine and Hierarchical RCU Data Structures

앞의 state machine 의 내용은 또 다른 데이터 구조와 상호작용하게 되는데, Figure D.19 에 보인 것과 같습니다. 하지만, 이 state machine 의 내용은 어떤 RCU 구현에 있어서도 그대로 C 코드로 변환되어지지는 않습니다. 그보다는, 이 구현들은 커널 내에 event-driven 코드로 만들어져 있습니다. 따라서, 다음 섹션은 일부 “사용 예”, 또는 RCU 알고리즘이 앞의 state machine 의 내용을 진행하는 방법은 물론이고 관련된 데이터 구조를 알아봅니다.

D.2.7 Use Cases

이 섹션은 사용되는 데이터 구조들과 호출되는 함수들을 나열하며 RCU 구현 내에서의 몇 가지 “사용 예” 들에

대한 개요를 제공합니다. 이 사용 예들은 다음과 같습니다:

1. 새로운 Grace Period 의 시작 (Section D.2.7.1)
2. Quiescent State 의 통과 (Section D.2.7.2)
3. RCU 에게 Quiescent State 를 알리기 (Section D.2.7.3)
4. Dynticks Idle Mode 의 진입과 빠져나오기 (Section D.2.7.4)
5. Dynticks Idle Mode로부터의 인터럽트 (Section D.2.7.5)
6. Dynticks Idle Mode로부터의 NMI (Section D.2.7.6)
7. CPU 가 Dynticks Idle Mode 에 있음을 알기 (Section D.2.7.7)
8. CPU 를 끄기 (Section D.2.7.8)
9. CPU 를 켜기 (Section D.2.7.9)
10. 너무 긴 Grace Period 를 감지하기 (Section D.2.7.10)

이 사용 예들 각각은 다음 섹션들에서 설명됩니다.

D.2.7.1 Start a New Grace Period

`rcu_start_gp()` 함수는 새로운 grace period 를 시작합니다. 이 함수는 CPU 가 grace period 를 기다리는 콜백을 가지고 있는 CPU 가 어떤 grace period 도 진행 중이 아니란 것을 알릴 때에 호출됩니다.

`rcu_start_gp()` 함수는 새로이 시작된 grace period 를 알리기 위해 `rcu_state` 와 `rcu_data` 구조체의 상태를 업데이트 하는데, 동시에 CPU-hotplug 오퍼레이션들을 배제하기 위해 `->onoff` 락을 잡고 (그리고 irq 들을 불능화 시키고), (이 CPU 를 포함해) 모든 CPU 들은 quiescent state 를 지나야만 함을 알리기 위해 모든 `rcu_node` 구조체의 bit 들의 값을 설정하고, 마지막으로 `->onoff` 락을 해제합니다.

이 bit 값 설정 동작은 두개의 페이즈로 진행됩니다. 먼저, non-leaf `rcu_node` 구조체의 bit 들은 어떤 락도 더이상 잡지 않은 채 설정되고, 이후엔 각각의 leaf `rcu_node` 구조체들의 bit 들이 해당 구조체의 `->lock` 을 잡은 채 설정되어집니다.

Quick Quiz D.11: 하지만 한 CPU 가 bit 값 설정하는 CPU 가 종료되기 전에 (자신의 bit 의 값을 해제하면서) quiescent state 를 지나감을 이야기 하려 하면 어떻게 되나요? ■

Quick Quiz D.12: Bit 값 설정 CPU 가 종료되기 전에 모든 CPU 들이 quiescent state 를 지나감을 보고하려고

해서 새로운 grace period 를 시작도 하기 전에 종료해 버리면 무슨 일이 일어나나요? ■

D.2.7.2 Pass Through a Quiescent State

RCU 의 `rcu` 와 `rcu_bh` 향은 서로 다른 quiescent state 집합을 갖습니다. Quiescent state 는 `rcu` 에 있어서는 컨텍스트 스위치, idle (dynticks 또는 idle 루프), 그리고 user-mode 수행인 반면, `rcu_bh` 에 있어서는 interrupt 가 활성화 된 채의 softirq 바깥 모든 코드입니다. RCU 를 위한 quiescent state 는 곧 `rcu_bh` 를 위한 quiescent state 이기도 하다는 점을 알아 두시기 바랍니다. RCU 를 위한 quiescent state 들은 `rcu_qsctr_inc()` 를 호출하는 것으로 기록되고, `rcu_bh` 를 위한 quiescent state 들은 `rcu_bh_qsctr_inc()` 를 호출함으로써 기록되어집니다. 이 두개의 함수들은 각자의 상태를 현재 CPU 의 `rcu_data` 구조체 안에 기록합니다.

이 함수들은 스케줄러에서 호출되어지는데, `__do_softirq()` 와 `rcu_check_callbacks()` 에서입니다. 뒤의 함수는 scheduling-clock 인터럽트에 의해서 호출되어지며, 이 인터럽트가 `rcu_qsctr_inc()` 또는 `rcu_bh_qsctr_inc()` 를 호출한 quiescent state 에서 발생한 것인지를 판단하기 위해 상태를 분석합니다. 이 함수는 또한 RCU_SOFTIRQ 에 의해서도 호출되는데, 나중에 softirq 컨텍스트에서 현재 CPU 에서 `rcu_process_callbacks()` 를 호출되게 합니다.

D.2.7.3 Announce a Quiescent State to RCU

앞에서 언급된 `rcu_process_callbacks()` 함수는 몇 가지 의무를 가지고 있습니다:

1. 언제 너무 오래 유지된 grace period 를 (`force_quiescent_state()` 를 통해) 끝낼지 판단하는 것.
2. 다른 CPU 가 grace period 의 끝을 파악했을 때 (`rcu_process_gp_end()` 를 통해) 적절한 행동을 취하는 것. “적절한 행동”은 이 CPU 의 콜백들을 수행하고 새로운 grace period 를 기록하는 것을 포함합니다. 이 똑같은 함수는 다른 CPU 가 새로운 grace period 를 시작하는 것에 대한 응답으로 상태를 업데이트 합니다.
3. 현재 CPU 의 quiescent state 들을 (결국은 `cpu_quiet()` 를 호출하는 `rcu_check_quiescent_state()` 를 통해) RCU 메커니즘의 핵심에 알리는 것. 이는 물론 현재 grace period 의 끝을 표시합니다.
4. 진행중인 grace period 가 없고 이 CPU 가 여전히 grace period 를 기다리고 있는 RCU 콜백들을 가

지고 있다면 (`cpu_needs_another_gp()` 와 `rcu_start_gp()` 를 통해) 새로운 grace period 를 시작하는 것.

- Grace period 가 끝난 이 CPU 의 콜백들을 (`rcu_do_batch()` 를 통해) 호출하는 것.

이 동작들은 앞의 grace period 로부터의 quiescent state 를 현재의 grace period 에게 보고한다던가 하는 것과 같은 버그를 막기 위해 매우 조심스럽게 짜여져 동작합니다.

D.2.7.4 Enter and Leave Dynticks Idle Mode

스케줄러는 dynticks-idle 모드에 들어가기 위해 `rcu_enter_nohz()` 를 호출하고, 거기서 나오기 위해 `rcu_exit_nohz()` 를 호출합니다. `rcu_enter_nohz()` 함수는 per-CPU `dynticks_nesting` 변수와 per-CPU `dynticks` 변수의 값을 증가시키는데, `dynticks` 는 따라서 짹수의 값을 가져야만 합니다. `rcu_exit_nohz()` 함수는 같은 per-CPU `dynticks_nesting` 변수의 값을 감소시키고 per-CPU `dynticks` 카운터의 값을 증가시킵니다, 따라서 `dynticks` 는 훌수 값을 갖게 됩니다.

`dynticks` 카운터는 다른 CPU 에 의해 보여질 수 있습니다. 만약 그 값이 짹수라면, 첫번째 CPU 는 연장된 quiescent state 안에 있는 것입니다. 비슷하게, 만약 그 카운터의 값이 grace period 동안 바뀌었다면, 첫번째 CPU 는 grace period 동안의 언젠가에 연장된 quiescent state 안에 있었던 셈입니다. 하지만, 또한 보여져야만 하는 `dynticks_nmi` per-CPU 변수가 하나 더 있는데, 이에 대해 아래에서 설명합니다.

D.2.7.5 Interrupt from Dynticks Idle Mode

Dynticks idle 모드로부터의 인터럽트는 `rcu_irq_enter()` 와 `rcu_irq_exit()` 에서 처리되어집니다. `rcu_irq_enter()` 함수는 per-CPU `dynticks_nesting` 변수의 값을 증가시키고, 만약 기존 값이 0 이었다면, `dynticks` per-CPU 변수의 값 또한 증가시킵니다 (이제 훌수 값을 갖게 될겁니다).

`rcu_irq_exit()` 함수는 per-CPU `dynticks_nesting` 변수의 값을 감소시키고, 새로운 값이 0이라면, `dynticks` per-CPU 변수의 값을 증가시킵니다 (이제 짹수 값을 갖게 될겁니다).

Irq 핸들러에 들어가게 되면 dynticks idle 모드를 빠져나가는 것이고 그 반대도 성립됨을 알아두시기 바랍니다. 이렇게 들어가고 빠져나오는게 서로 일치하지 못하는 것은 상당한 혼란을 가져올 수 있습니다. 경고 드렸습니다.

D.2.7.6 NMI from Dynticks Idle Mode

Dynticks idle 모드로부터의 NMI 들은 `rcu_nmi_enter()` 와 `rcu_nmi_exit()` 에서 처리됩니다. 이 함수들은 둘 다 `dynticks_nmi` 카운터의 값을 증가시키는데, 다만 앞서 이야기한 `dynticks` 카운터의 값이 짹수일 때에만 그렇습니다. 달리 말하자면, NMI 가 dynticks-idle 모드가 아닐 때에 또는 인터럽트 핸들러 안에서 발생했다면 `dynticks_nmi` 카운터를 조정하지 않습니다.

두 함수간의 유일한 차이점은 여러 체크로, `rcu_nmi_enter()` 는 `dynticks_nmi` 카운터를 그 값을 훌수로 한 채 끝나야 하고, `rcu_nmi_exit()` 는 이 카운터의 값이 짹수가 되게 하고 끝나야 하기 때문입니다.

D.2.7.7 Note That a CPU is in Dynticks Idle Mode

`force_quiescent_state()` 함수는 세 단계의 state machine 을 구현합니다. 첫번째 단계 (RCU_INITIALIZING) 은 `rcu_start_gp()` 가 grace-period 초기화를 완료하기를 기다립니다. 이 상태는 `force_quiescent_state()` 에 의해서가 아니라 `rcu_start_gp()` 에 의해 종료됩니다.

두번째 단계 (RCU_SAVE_DYNTICK) 에서는 `dyntick_save_progress_counter()` 함수가 아직 quiescent state 를 보고하지 않은 CPU 들을 스캔하면서 각각의 per-CPU `dynticks` 와 `dynticks_nmi` 카운터들의 값을 기록합니다. 만약 이 카운터들이 모두 짹수 값을 갖는다면, 연관된 CPU 는 dynticks-idle 상태에 있는 것으로, 따라서 extended quiescent state 로 알려지는 겁니다 (`cpu_quiet_msk()` 로 보고됩니다).

세번째 단계 (RCU_FORCE_QS) 에서는 `rcu_implicit_dynticks_qs()` 함수가 다시 (명시적으로든 RCU_SAVE_DYNTICK) 단계를 통해 묵시적으로든) 아직 quiescent state 를 보고하지 않은 CPU 들을 스캔하면서, per-CPU `dynticks` 와 `dynticks_nmi` 카운터들을 스캔합니다. 이것들 각각이 그 값을 바꿨거나 이제 짹수라면, 거기에 연관된 CPU 는 dynticks idle 을 지나왔거나 아직 그 안에 있는 것으로, 앞에서와 같이 extended quiescent state 에 있는 것을 알리는 겁니다.

`rcu_implicit_dynticks_qs()` 가 특정 CPU 가 dynticks idle 모드에 들어가 있지도 않고 quiescent state 를 보고하지도 않았음을 알게 되면, 이 함수는 `rcu_implicit_offline_qs()` 를 호출하는데, 이 함수는 해당 CPU 가 offline 인지 확인하는데, offline 임은 또한 extended quiescent state 로 보고되어 있습니다. 만약 해당 CPU 가 online 상태라면, `rcu_implicit_offline_qs()` 는 여기에 RCU 로 quiescent state 를 보고할 의무를 다시 한번 알리기 위해 reschedule IPI 를 날립니다.

`force_quiescent_state()` 는 지겹적으로 `dyntick_save_progress_counter()` 도 `rcu`-

`implicit_dynticks_qs()` 도 호출하지 않고, 대신 이 함수들을 CPU 들을 스캔하고 extended quiescent state 를 보고하는데에 연관된 공통된 코드들을 추상화 시킨 함수인, `rcu_process_dyntick()` 함수에게 넘김을 알아두시기 바랍니다.

Quick Quiz D.13: 한 CPU 가 dyntick-idle 모드에서 빠져나오고선 다른 CPU 가 첫번째 CPU 가 dyntick-idle 모드에 있었음을 알게 되자마자 quiescent state 를 지나가버리면 어떻게 되나요? 두 CPU 모두 동시에 quiescent state 를 보고하려 해서, 혼란이 생기지 않을까요? ■

Quick Quiz D.14: 하지만 모든 CPU 들이 dyntick-idle 모드에 있으면 어떻게 되죠? 이게 현재의 RCU grace period 가 영원히 끝나지 못하게 하지는 않을까요? ■

Quick Quiz D.15: `force_quiescent_state()` 가 세단계 state machine 이란 것을 놓고 보면, 모든 CPU 들을 스캐닝 하는 것 때문에 스케줄링 응답시간을 세배로 늘리는 것 아닌가요? ■

D.2.7.8 Offline a CPU

CPU-offline 이벤트는 `rcu_cpu_notify()` 가 `rcu_offline_cpu()` 를 호출하게 하며, 이 함수는 결국 해당 데이터 구조의 `rcu` 와 `rcu_bh` 인스턴스 모두에서 `_rcu_offline_cpu()` 를 호출하게 됩니다. 이 함수는 꺼지는 CPU 의 bit 들의 값을 지워서 나중의 grace period 가 이 CPU 가 quiescent state 를 발표할 것이라 기대하지 않게끔 하고, 나아가서는 offline 으로 발생한 extended quiescent state 를 알리기 위해 `cpu_quiet()` 를 호출합니다. 이 작업은 동시의 grace-period 초기화와의 상호 간섭을 막기 위해 잡혀지는, 전역적인 `->onofflock` 과 함께 수행됩니다.

Quick Quiz D.16: 하지만 `->onofflock` 을 잡는 또 다른 이유는 여러개의 동시적인 online/offline 오퍼레이션들을 방지하기 위함이 맞지요? ■

D.2.7.9 Online a CPU

CPU-online 이벤트는 `rcu_cpu_notify()` 가 `rcu_online_cpu()` 를 호출하게 하는데, 이 함수는 새로 켜지는 CPU 의 dynticks state 를 초기화 하며, 이어서 새로 들어온 CPU 의 `rcu_data` 구조체를 초기화 하고 이 CPU 의 (global 한 `->onofflock` 으로 보호되는) bit 들을 나중의 grace period 들이 이 CPU 의 quiescent state 를 기다리도록 하게 설정하는 `rcu_init_percpu_data()` 를 호출합니다. 마지막으로, `rcu_online_cpu()` 는 이 CPU 를 위한 RCU softirq vector 를 설정합니다.

Quick Quiz D.17: Global 한 `->onofflock` 의 획득을 위한 동작들을 모두 보면, 수천개의 CPU 들이 동작하는 경우에는 이게 상당한 락 경쟁이 되지 않을까요? ■

Quick Quiz D.18: Dyntick-idle CPU 탐지와 offline

CPU 탐지를 합쳐서 코드를 단순화 시키는 건 어떤가요? ■

D.2.7.10 Detect a Too-Long Grace Period

`CONFIG_RCU_CPU_STALL_DETECTOR` 커널 퍼미터가 정의된 경우, `record_gp_stall_check_time()` 함수는 시간과 이후의 3초간의 타임스탬프를 기록합니다. 현재의 grace period 가 그 시간까지 종료되지 않았다면, `check_cpu_stall()` 함수는 문제가 있는 부분을 체크해보고, 현재 CPU 가 붙잡고 있다면 `check_cpu_stall()` 을 호출하고, 다른 CPU 가 그러고 있다면 `print_cpu_stall()` 을 호출합니다. 두개의 jiffie 오프셋은 CPU 들이 각자를 보고할 것을 보장하고, CPU 는 일반적으로 다른 CPU 의 스택을 추적하는 것보다 자신의 스택을 추적하는데에 더 나은 일을 할 수 있다는 사실의 장점을 취합니다.

D.2.8 Testing

RCU는 기본적인 동기화 코드이므로, RCU 에서의 모든 실패는 무작위적이고 디버깅 하기 어려운 메모리 오류를 초래합니다. 따라서 RCU 는 매우 안정적일 필요가 매우 중요합니다. 이 안정성 중 일부는 조심스런 설계에서 기인하지만, 최종적으로는 고문이라고도 알려진 상당한 스트레스 테스팅에 의존해야만 합니다.

다행히도, Geneva Convention 이 어떤 인종들에게 적용되는지에 대한 일부 논쟁이 있긴 했지만, 소프트웨어에는 여전히 적용되지 않습니다. 따라서, 소프트웨어를 고문하는건 여전히 합법입니다. 실제로, 여러분이 여러분의 소프트웨어를 고문하지 않는다면 상상할 수 있는 가장 불편한 시점에 소프트웨어가 꺼짐으로써 여러분을 고문하는 결과가 나올겁니다.

따라서, 우리는 `rcutorture` 모듈을 사용해 RCU 를 매우 고통스럽게 고문합니다.

하지만, RCU 의 흔한 사용 경우에 대해서만 고문을 가하는걸로는 충분하지 않습니다. 예를 들어 CPU 들이 동시적으로 online 되고 offline 되는 경우와 CPU 들이 동시적으로 dynticks idle 모드를 들어오고 나가는 것과 같이 일반적이지 않은 상황에 대해서도 고문을 할 필요가 있습니다. 저는 `rcutorture` 모듈과 동시에 수행되는 CPU 들을 online 시키고 offline 시키는 간단한 스크립트를 사용합니다. 이 모듈은 dynticks idle 모드를 스트레스 테스트 하기 위해 `test_no_idle_hz` 모듈 패러미터를 받습니다. 완벽해지기 위해, 저는 가끔 여기에 병렬적으로 `kernbench` 를 돌리기도 합니다. 128-way 머신에서 열시간동안 이런 종류의 고문을 돌리는 건 대부분의 버그들을 잡기에 충분합니다.

이것조차도 완전한 이야기는 아닙니다. Alexey Dobriya 과 Nick Piggie 이 2008 년 초에 보였듯이, RCU 를

연관된 커널 패러미터들의 모든 조합들과 고문할 필요가 있습니다. 연관된 커널 패러미터들은 또 다른 간단한 스크립트로 규정될 수 있는데, 다음과 같습니다:

1. CONFIG_CLASSIC_RCU: Classic RCU.
2. CONFIG_PREEMPT_RCU: Preemptible (real-time) RCU.
3. CONFIG_TREE_RCU: 거대한 SMP 시스템에서의 Classic RCU.
4. CONFIG_RCU_FANOUT: 각 rCU_node 의 자식의 수.
5. CONFIG_RCU_FANOUT_EXACT: rCU_node 트리의 뱐런스를 맞춤.
6. CONFIG_HOTPLUG_CPU: CPU 들이 offline 되고 online 되는 것을 허용.
7. CONFIG_NO_HZ: dyntick-idle 모드를 활성화.
8. CONFIG_SMP: multi-CPU 오퍼레이션을 활성화.
9. CONFIG_RCU_CPU_STALL_DETECTOR: RCU 가 CPU 들이 언제 extended quiescent-state 를 들어 가는지 파악할 수 있게 함.
10. CONFIG_RCU_TRACE: Debugfs 안에 RCU trace 파일을 생성함.

우리는 hierarchical RCU 는 잘못된 lockdep 을 갖지는 않을 것이라는 아마도 자연스러운 가정 하에 CONFIG_DEBUG_LOCK_ALLOC 설정은 무시합니다. 10개의 환경 구성 변수들이 있는데, 이것들이 비의존적인 boolean 변수들이라면 1,024 개의 조합을 만들 겁니다. 다행히도 앞의 세개는 상호 배타적이어서 조합의 수를 384 개로 줄입니다만, CONFIG_RCU_FANOUT 은 그 값을 2 부터 64 까지 가질 수 있어서, 조합의 수를 12,096 까지 늘립니다. 이건 상당한 수의 조합입니다.

주요한 발견 중 하나는 CONFIG_NO_HZ 와 CONFIG_PREEMPT 는 CONFIG_CLASSIC_RCU 나 CONFIG_PREEMPT_RCU 가 켜져 있다면 변경된 동작을 취할 수 있다는 것으로, 이 두개의 기존부터 존재한 RCU 구현들만이 앞의 두개의 환경구성 구현과 함께 변경되었기 때문입니다. 이는 가능한 조합 가운데 거의 3분의 2를 제거합니다.

더 나아가서, CONFIG_RCU_FANOUT 의 모든 설정 가능한 값이 상당히 다른 결과를 내놓지는 않고, 실제로 몇개의 경우들만이 따로 테스트 되면 됩니다:

1. 싱글 노드 “트리”.
2. 2단계 뱐런스 잡힌 트리.

3. 3단계 뱐런스 잡힌 트리.

4. CONFIG_RCU_FANOUT 은 뱐런스 잡하지 않은 트리 를 명시하지만 CONFIG_RCU_FANOUT_EXACT 없이는 자동으로 뱐런스 잡하게 되는 자동으로 뱐런스 잡힌 트리.

5. 뱐런스 잡하지 않은 트리.

더 보자면, CONFIG_HOTPLUG_CPU 는 CONFIG_SMP 가 주어졌을 때에만 의미를 갖고, CONFIG_RCU_CPU_STALL_DETECTOR 는 의존성이 없으며, 한번만 테스트 되면 됩니다 (저보다 더 편집증적인 누군가는 이것도 CONFIG_SMP 를 켰을때와 꺼었을 때에 대해 모두 테스트 할 수도 있겠습니다). 비슷하게, CONFIG_RCU_TRACE 는 한번만 테스트 되면 됩니다만, (저처럼) 정말로 편집증에 걸린 사람은 CONFIG_NO_HZ 를 켰을때와 꺼었을 때에 대해 모두 테스트 할 수 있을 겁니다.

이건 15개의 테스트 케이스만을 가지고도 RCU 의 상당한 부분을 커버할 수 있게 해줍니다. 모든 테스트 케이스들은 rcutorture 를 돌리기 위해, 그리고 CONFIG_HOTPLUG_CPU=n 이 실제로 영향을 끼치게 하기 위해 다음과 같은 환경 구성 패러미터들을 명시하게 됩니다.

```
CONFIG_RCU_TORTURE_TEST=m
CONFIG_MODULE_UNLOAD=y
CONFIG_SUSPEND=n
CONFIG_HIBERNATION=n
```

이 15 개의 테스트 케이스들은 다음과 같습니다:

1. 작은 시스템들을 위한 싱글 노드 “트리”를 강제:

```
CONFIG_NR_CPUS=8
CONFIG_RCU_FANOUT=8
CONFIG_RCU_FANOUT_EXACT=n
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=y
```

2. 커다란 시스템을 위해 2단계 트리를 강제:

```
CONFIG_NR_CPUS=8
CONFIG_RCU_FANOUT=4
CONFIG_RCU_FANOUT_EXACT=n
CONFIG_RCU_TRACE=n
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=y
```

3. 거대한 시스템들을 위한 3단계 트리를 강제:

```
CONFIG_NR_CPUS=8
CONFIG_RCU_FANOUT=2
CONFIG_RCU_FANOUT_EXACT=n
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=y
```

4. 밸런스 잡힌 트리를 향한 자동 밸런스 잡기를 테스트:

```
CONFIG_NR_CPUS=8
CONFIG_RCU_FANOUT=6
CONFIG_RCU_FANOUT_EXACT=n
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=y
```

5. 밸런스 잡히지 않은 트리를 테스트

```
CONFIG_NR_CPUS=8
CONFIG_RCU_FANOUT=6
CONFIG_RCU_FANOUT_EXACT=y
CONFIG_RCU_CPU_STALL_DETECTOR=y
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=y
```

6. CPU-stall 탐지를 비활성화:

```
CONFIG_SMP=y
CONFIG_NO_HZ=y
CONFIG_RCU_CPU_STALL_DETECTOR=n
CONFIG_HOTPLUG_CPU=y
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=y
```

7. CPU-stall 탐지와 dyntick idle 모드를 비활성화:

```
CONFIG_SMP=y
CONFIG_NO_HZ=n
CONFIG_RCU_CPU_STALL_DETECTOR=n
CONFIG_HOTPLUG_CPU=y
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=y
```

8. CPU-stall 탐지와 CPU hotplug 를 비활성화:

```
CONFIG_SMP=y
CONFIG_NO_HZ=y
CONFIG_RCU_CPU_STALL_DETECTOR=n
CONFIG_HOTPLUG_CPU=n
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=y
```

9. CPU-stall 탐지, dyntick idle 모드, 그리고 CPU hotplug 를 비활성화:

```
CONFIG_SMP=y
CONFIG_NO_HZ=n
CONFIG_RCU_CPU_STALL_DETECTOR=n
CONFIG_HOTPLUG_CPU=n
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=y
```

10. SMP, CPU-stall 탐지, dyntick idle 모드, 그리고 CPU hotplug 를 비활성화:

```
CONFIG_SMP=n
CONFIG_NO_HZ=n
CONFIG_RCU_CPU_STALL_DETECTOR=n
CONFIG_HOTPLUG_CPU=n
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=y
```

이 조합은 수많은 컴파일러 경고들을 나오게 했습니다.

11. SMP 와 CPU hotplug 를 비활성화:

```
CONFIG_SMP=n
CONFIG_NO_HZ=y
CONFIG_RCU_CPU_STALL_DETECTOR=y
CONFIG_HOTPLUG_CPU=n
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=y
```

12. Classic RCU 를 preemption 없이 dynticks idle 과 테스트:

```
CONFIG_NO_HZ=y
CONFIG_PREEMPT=n
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=y
CONFIG_TREE_RCU=n
```

13. Classic RCU 를 dynticks idle 없이 preemption 과 함께 테스트:

```
CONFIG_NO_HZ=n
CONFIG_PREEMPT=y
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=n
CONFIG_CLASSIC_RCU=y
CONFIG_TREE_RCU=n
```

14. Preemptible RCU 를 dynticks idle 과 함께 테스트:

```
CONFIG_NO_HZ=y
CONFIG_PREEMPT=y
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=y
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=n
```

15. Preemptible RCU 를 dynticks idle 없이 테스트:

```
CONFIG_NO_HZ=n
CONFIG_PREEMPT=y
CONFIG_RCU_TRACE=y
CONFIG_PREEMPT_RCU=y
CONFIG_CLASSIC_RCU=n
CONFIG_TREE_RCU=n
```

RCU 핵심 코드에 대한 커다란 변경에 대해서는 앞의 조합 각각에 대해, 그리고 CONFIG_HOTPLUG_CPU 의 경우를 위해 CPU offlining 과 onlining 과 함께 rcutorture 를 돌려봐야 합니다. 작은 변경에 대해서는 각각의 경우에 kernbench 를 돌리는 것으로 충분할 겁니다. 물론, 이 변경이 특정한 환경구성 패러미터의 조합의 부분집합에 국한되어 있다면, 테스트 케이스의 수를 줄일 수도 있을 겁니다.

소프트웨어 고문: Geneva Convection 은 (아직은) 이를 금지하지 않고 있으며, 전 이걸 강력히 추천합니다!

D.2.9 Conclusion

이 RCU 의 계층형 구현은 락 경쟁을 줄이고, 불필요하게 dyntick-idle 상태에서 잠자는 CPU 들을 깨우지 않으면서 리눅스의 hotplug-CPU 코드 경로를 디버깅 하는 것을 돋습니다. 이 구현은 수천개의 CPU 를 가진 단일 시스템을 다루기 위해 설계되었는데, 64-bit 시스템들은 25만개 CPU 로 구조적 한계를 가지고 있으므로, 제가 예상한 한계점은 차후 몇년동안은 충분할 겁니다.

이 RCU 구현은 물론 몇가지 한계점도 가지고 있습니다:

1. `force_quiescent_state()` 는 irq 가 비활성화된 채로 모든 CPU 들을 스캔할 수 있습니다. 이는 real-time RCU 구현에서는 치명적일 수 있으며, 따라서 preemptible RCU 에 계층이 도입될 필요가 있다면, 다른 방법이 필요할 겁니다. 이는 4,096-CPU 시스템에서는 문제가 될 수 있습니다만, 이 방법을 따라야 할지 다른 방법을 찾아야 할지를 증명하려면 그런 시스템에서의 실제 테스트가 필요합니다.

바쁘게 돌아가는 시스템에서는 `force_quiescent_state()` 의 스캔은 일어나지 않을 것이라 예측될 수 있는데, CPU 들은 quiescent state 를 quiescent state 의 시작으로부터 3 jiffies 안에 지나가야 하기 때문입니다. 적당히 바쁘게 돌아가는 시스템에서는 dynticks-idle 모드의 CPU 들만이 스캔되어야 할 겁니다. 예를 들어 dynticks-idle CPU 가 스캔 중간에 인터럽트를 처리하는 것과 같은 일부 경우에는 뒤따르는 스캔이 필요합니다. 하지만, 그런 스캔 각각은 개별적으로

수행되고, 따라서 스케줄링 응답시간은 그런 스캔 하나의 오버헤드 만큼만 나빠질 겁니다.

이 스캔이 문제라고 증명된다면, 한가지 직선적인 해결책은 이 스캔을 점진적으로 하는 겁니다. 이는 약간 코드 복잡도를 높일 수 있고 grace period 를 종료하는데 걸리는 시간을 늘릴 수 있습니다만, 그럼에도 해결책이 될 수 있을 겁니다.

2. `rcu_node` 구조는 컴파일 시점에 만들어지며, 따라서 최악의 경우인 NR_CPUS 갯수의 CPU 들을 가정해 크기가 정해집니다. 하지만, 4,096 개의 CPU 들에서도, `rcu_node` 구조는 64-bit 머신에서 65개의 캐시라인만을 사용합니다 (그리고 32-bit 머신에서 4,096 개 CPU 를 넣어보세요!). 물론, 16-CPU 머신에서 NR_CPUS=4096 으로 빌드된 커널을 수행시키면 단일 노드 트리로도 잘 돌아갈 곳에 2단계 트리를 사용하게 될 겁니다. 이 구성이 추가적인 락킹 오버헤드를 가져오긴 하겠지만, hot-path read-side 코드에는 영향을 끼치지 않으므로, 실제로는 문제가 되지 않을 겁니다.

3. 이 패치는 커널 text 와 data 를 약간 증가시킵니다: NR_CPUS=4 시스템에서 기존의 Classic RCU 구현은 1,757 바이트의 커널 text 와 456 바이트의 커널 data 로 총 2,213 바이트만을 사용했습니다만, 새로운 계층적 RCU 구현은 4,006 바이트의 커널 text 와 624 바이트의 커널 data 를 사용해 총 4,630 바이트를 사용합니다. 이는 수백 메가바이트의 메인 메모리만을 갖는 대부분의 임베디드 시스템에서 조차도 문제가 될 정도는 아닙니다. 하지만, 아주 작은 임베디드 시스템에서 이게 문제가 된다면, RCU 의 “scale up” 과 “scale down” 구현을 모두 제공할 필요가 있을 수 있습니다.

이 계층적 RCU 구현은 어쨌거나 수백개의 CPU 들에서는 Classic RCU 를 넘어서 커다란 개선입니다. 무엇보다도, Classic RCU 는 16-32 개 CPU 의 시스템들만을 위해 설계되었습니다.

언젠가는, preemptible RCU 구현에도 계층을 적용할 필요가 있을 수 있습니다. 이는 per-CPU 카운터 쌍에 사용된 modular 연산으로 인해 좀 더 전적인 일이 될 수 있습니다만, 불가능한 일은 아닐 겁니다.

D.3 Hierarchical RCU Code Walk-through

이 섹션은 리눅스 커널 hierarchical RCU 코드의 일부 부분들을 분석합니다. 이 섹션은 hierarchical RCU 를 매우 낮은 단계에서 이해하기를 바라는 hard-core 해커들을

위해 지어졌으며, 그런 해커들이라면 먼저 Section D.2를 읽어야 합니다. 하드코어 매저키스트들 역시 이 섹션을 읽어볼 흥미가 생길겁니다. 물론 진짜 하드코어 매저키스트들은 Section D.2를 읽기 전에 이 섹션을 읽을 겁니다.

Section D.3.1은 데이터 구조와 커널 패러미터들을 설명하고, Section D.3.2은 외부로의 함수 인터페이스를 다루며, Section D.3.3은 초기화 프로세스를 서술하고, Section D.3.4는 CPU-hotplug 인터페이스를 설명하고, Section D.3.5는 그외의 유털리티 함수들을 다루고, Section D.3.6은 grace-period 탐지 메커니즘을 설명하고, Section D.3.7은 dynticks-idle 인터페이스를 보고, Section D.3.8은 (offline과 dynticks-idle CPU들을 포함해) holdout CPU들을 다루는 함수들을 알아보고, Section D.3.9는 stall 된 CPU, 즉 커널 모드에서 수초 동안을 spinning 하는 CPU들을 알리는 함수를 보입니다. 마지막으로, Section D.3.10은 있을법한 설계상의 흥결과 수정사항들을 이야기합니다.

D.3.1 Data Structures and Kernel Parameters

Hierarchical RCU 데이터 구조의 완전한 이해는 이 알고리즘의 이해에 매우 중요합니다. 따라서, Section D.3.1.1은 각 CPU의 dyntick-idle state를 추적하는데 사용되는 데이터 구조들을 설명하고, Section D.3.1.2는 rcu_node 계층을 만드는데 사용되는 per-node 데이터 구조의 필드들을 설명하며, Section D.3.1.3은 per-CPU rcu_data 구조체를 설명하고, Section D.3.1.4에서는 global rcu_state 구조체의 필드를 설명하며 Section D.3.1.5에서는 Hierarchical RCU의 동작을 조절하는 커널 패러미터들을 설명합니다.

Page 385의 Figure D.17와 Page 403의 Figure D.26가 다음의 데이터 구조 설명들을 따라가는데에 많은 도움이 될 수 있습니다.

D.3.1.1 Tracking Dyntick State

Per-CPU rcu_dynticks 구조체는 다음 필드들을 이용해 dynticks state를 추적합니다:

- **dynticks_nesting:** 이 int는 연관된 CPU가 RCU read-side 크리티컬 섹션들을 모니터 되어야 하는 이유의 수를 셉니다. 만약 이 CPU가 dynticks-idle 모드에 있다면, 이 필드는 irq가 감싸진 횟수를 세고, 그렇지 않다면 irq 감싸진 횟수보다 하나 큰 값을 갖습니다.
- **dynticks:** 이 int 카운터의 값은 연관된 CPU가 dynticks-idle 모드에 있고 현재 해당 CPU에서 수행

중인 irq 핸들러가 없다면 짹수의 값을 갖고, 그렇지 않다면 홀수의 값을 갖습니다. 달리 말하자면, 이 카운터의 값이 홀수라면, 연관된 CPU는 RCU read-side 크리티컬 섹션에 있을 수 있습니다.

- **dynticks_nmi:** 이 int 카운터의 값은 연관된 CPU가 NMI 핸들러 수행중이라면 홀수인데, 이 CPU가 irq 핸들러 수행중이지 않은 채로 dyntick-idle 모드에 있는 동안 NMI를 받았을 때에만입니다. 그렇지 않다면, 이 카운터의 값은 짹수입니다.

이 상태는 rcu와 rcu_bh 구현 사이에서 공유됩니다.

D.3.1.2 Nodes in the Hierarchy

앞서 언급했듯이, rcu_node 계층은 page 383의 Figure D.13에 보인 것처럼 rcu_state 구조체 안에 평면화 되어 존재합니다. 이 계층 안의 rcu_node 각각은 다음과 같은 필드들을 갖습니다:

- **lock:** 이 스핀락은 이 구조체의 상수가 아닌 필드들을 보호합니다. 이 락은 softirq 컨텍스트에서 얻어지고, 따라서 irq들을 비활성화 시켜야 합니다.

Quick Quiz D.19: rcu_data 구조체의 lock을 회득할 때 그냥 bottom halves (softirq)를 비활성화시키는게 어떤가요? 그게 더 빠르지 않겠어요?

■

루트 rcu_node의 lock 필드는 추가적인 의무를 갖습니다:

1. CPU-stall 검사를 직렬화 시켜서, 하나의 stall이 하나의 CPU에 의해서만 보고될 수 있도록 합니다. 이는 수천개의 CPU들이 존재하는 시스템에서는 중요합니다!
2. 새로운 grace period를 시작하는 것을 직렬화 시켜서, 여러 CPU들이 grace period들을 동시에 시작하지 않도록 합니다.
3. 새로운 grace period들이 하나의 grace period에 국한되어서 시작되어야 할 필요를 없앱니다.
4. Reschedule IPI들의 갯수를 너무 지나치지 않도록 유지하기 위해 (force_quiescent_state()의) state machine forcing quiescent state들을 직렬화 시킵니다.

- **qsmask:** 이 bitmask는 현재의 grace period가 끝나기 위해 지나가야 하는 quiescent state를 여전히 통과해야 하는 CPU들 (leaf rcu_node 구조체들을 위해)이나 CPU들의 그룹들 (leaf가 아닌 rcu_node 구조체들을 위해)을 추적합니다.

- **qsmaskinit:** 이 bitmask 는 어떤 CPU 들이나 CPU 들의 그룹들이 다음 grace period 들이 끝나기 위해 quiescent state 를 지나가야 하는지를 추적합니다. Online/offline 코드는 qsmaskinit 필드들을 조정하는데, 각 grace period 의 시작 때 qsmask 필드들이 복사되어집니다. 이 복사 작업은 왜 grace period 초기화가 online/offline 오퍼레이션들과 배타적으로 수행되어야 하는지에 대한 이유 중 하나입니다.
- **grpmask:** 이 bitmask 는 하나의 bit set 을 가지며, 이는 부모 `rcu_node` 구조체의 `qsmask` 와 `qsmaskinit` 필드들에서의 이 `rcu_node` 구조체의 위치에 연관되어 있습니다. 이 필드의 사용은 Manfred Spraul 이 제안한대로 quiescent-state 처리를 단순화 시킵니다.

Quick Quiz D.20: Leaf `rcu_node` 구조체의 `qsmask` 와 `qsmaskinit` 필드들은 어떤가요? 이 필드들의 어떤 bit 들이 이 `rcu_node` 구조체에 의해 처리되는 각 CPU 들에 연관되는지를 알기 위한 어떤 방법이 필요하지 않나요? ■

- **grplo:** 이 필드는 이 `rcu_node` 구조체에 의해 처리되는 CPU 들 중 가장 낮은 숫자의 CPU 의 숫자를 담고 있습니다.
- **grphi:** 이 필드는 이 `rcu_node` 구조체에 의해 처리되는 CPU 들 중 가장 높은 숫자의 CPU 의 숫자를 담고 있습니다.
- **grpnum:** 이 필드는 부모 `rcu_node` 구조체의, 이 `rcu_node` 구조체가 연관되어 있는 `qsmask` 와 `qsmaskinit` 필드들의 bit 수를 담고 있습니다. 달리 말하자면, 특정 `rcu_node` 구조체로의 포인터 `rnp` 가 있다면, `1UL << rnp->grpnum == rnp->grpmask` 가 될 겁니다. 이 `grpnum` 필드는 tracing 출력을 위해서만 사용됩니다.
- **level:** 이 필드는 루트 `rcu_node` 구조체에서는 0 이 되고, 루트의 자식인 `rcu_node` 구조체에서는 1 의 값을, 그리고 계층의 아래로 가면서 이런식으로 값을 갖게 됩니다.
- **parent:** 이 필드는 부모 `rcu_node` 구조체로의 포인터이며, 루트 `rcu_node` 구조체에 있어서는 NULL 입니다.

D.3.1.3 Per-CPU Data

`rcu_data` 구조체는 RCU 의 per-CPU 상태를 담고 있습니다. 이 상태는 grace period 와 quiescent state 들을 관리하는 조정을 위한 변수들을 담고 있습니다 (`completed`, `gignum`, `passed_quiesc_completed`, `passed_quiesc`,

`qs_pending`, `beenonline`, `mynode`, 그리고 `grpmask`). `rcu_data` 구조체는 또한 RCU 콜백들로 관련되는 조정을 위한 변수들 또한 담고 있습니다 (`nxtlist`, `nxttail`, `qlen`, 그리고 `blimit`). Dynticks 가 활성화된 커널들은 관련된 조정을 위한 변수들을 `rcu_data` 구조체 안에 가지고 있습니다 (`dynticks`, `dynticks_snap`, 그리고 `dynticks_nmi_snap`). `rcu_data` 구조체는 tracing에서 사용되는 이벤트 카운터들을 담고 있습니다 (`dynticks_fqs` given `dynticks`, `offline_fqs`, 그리고 `resched_ipi`). 마지막으로, 한 쌍의 필드들은 언제 quiescent state 를 강제해야 하는지 판단하기 위해 `rcu_pending()` 호출 횟수를 세고 있고 (`n_rcu_pending` 그리고 `n_rcu_pending_force_qs`), cpu 필드는 해당 `rcu_data` 구조체가 어떤 CPU 에 연관되어 있는지를 알립니다.

이 필드들 각각에 대해 아래에서 설명합니다.

- **completed:** 이 필드는 이 CPU 가 끝나길 기다리고 있는 최근의 grace period 들의 수를 담습니다.
- **gignum:** 이 필드는 이 CPU 가 시작되길 신경쓰고 있는 최근의 grace period 들의 수를 담습니다.
- **passed_quiesc_completed:** 이 필드는 이 CPU 가 마지막으로 quiescent state 를 지났을 때 가장 최근에 완료된 grace period 의 수를 담습니다. “가장 최근에 완료된” 이란 말은 quiescent state 를 지나는 CPU 의 관점에서입니다: 만약 이 CPU 가 아직 (말하자면) 42 번 grace period 가 완료되길 신경쓰고 있지 않다면, 여전히 값 41 을 기록하고 있게 될겁니다. 이 CPU 가 이미 quiescent state 를 지나갔는가 여부가 grace period 가 완료될 수 있는 유일한 방법이기 때문에 이건 괜찮습니다. 이 필드는 부팅할 때와 CPU 를 online 화 시킬 때의 race condition 을 없애기 위해 (미신적일 수 있는) 과거의 grace period 수로 초기화 됩니다.
- **passed_quiesc:** 이 필드는 이 CPU 가 `passed_quiesc_completed`에 저장된 수의 grace period 가 완료된 아래로 quiescent state 를 지난적이 있는지를 가리킵니다. 이 필드는 연관된 CPU 가 새로운 grace period 의 시작을 신경쓰게 될때마다 지워집니다.
- **qs_pending:** 이 필드는 이 CPU 가 코어 RCU 메커니즘이 자신이 quiescent state 를 지나길 기다리고 있음을 알고 있음을 알립니다. 이 필드는 이 CPU 가 새로운 grace period 를 파악하거나 한 CPU 가 online 이 될 때 값이 채워집니다.

Quick Quiz D.21: Offline 이 되는 건 모든 진행중인 grace period 를 처리해야 할 extended quiescent state

인데도 왜 CPU 가 online 이 될 때 qs_pending 의 값을 1 로 설정하는 거죠? ■

Quick Quiz D.22: 왜 passed_quiesc_completed 에 마지막으로 완료된 grace period 의 수를 기록하는거죠? 그건 어떤 grace period 도 진행중이지 않을 때에 보여진 quiescent state 들이 올바르지 않게 다음에 시작되는 grace period 에 적용되는 것에 이 RCU 구현이 취약해 지게 하지 않나요? ■

- **beenonline:** 초기값 0을 갖는 이 필드는 연관된 CPU 가 online 이 될 때마다 값이 설정됩니다. 이 필드는 online 이 된 적 없는 CPU 들을 위한 불필요한 tracing 출력이 생성되는 것을 막기 위해 사용되며, 실제 CPU 들의 수보다 과하게 많은 NR_CPUS 를 가는 커널들에서 유용합니다.

Quick Quiz D.23: 실제 CPU 들의 수보다 많은 NR_CPUS 를 갖는 시스템을 운영하는 이유가 뭐죠? ■

- **mynode:** 이 필드는 이 연관된 CPU 를 처리하는 leaf rCU_node 구조체로의 포인터입니다.
- **grpmask:** 이 필드는 mynode->qsmask 의 어떤 bit 이 연관된 CPU 를 나타내는지를 알리는 하나의 bit 이 set 되어있는 bitmask입니다.
- **nxtlist:** 이 필드는 이 CPU 에 위치한 가장 오래된 RCU 콜백 (rcu_head 구조체) 으로의 포인터이고, 이 CPU 가 현재 콜백을 가지고 있지 않다면 NULL입니다. 추가적인 콜백들은 next 포인터들을 통해 연결될 수 있습니다.
- **nxttail:** 이 필드는 nxtlist 콜백 리스트로의 double-indirect tail 포인터들의 배열입니다. 만약 nxtlist 가 비어있다면, 모든 nxttail 포인터들은 이 nxtlist 필드를 가리키게 됩니다. nxttail 배열의 각 원소들은 다음과 같은 의미를 갖습니다:
 - RCU_DONE_TAIL=0: 이 원소는 자신의 grace period 를 지나와서 호출될 준비가 된 마지막 콜백의 ->next 필드를 가리키거나 그런 콜백이 없다면 nxtlist 필드를 가리킵니다.
 - RCU_WAIT_TAIL=1: 이 원소는 현재의 grace period 가 끝나길 기다리고 있는 마지막 콜백의 next 필드를 가리키고 있지만, 그런 콜백이 존재하지 않는다면 RCU_DONE_TAIL 원소와 같습니다.
 - RCU_WAIT_TAIL=2: 이 원소는 다음 grace period 를 기다릴 준비가 된 마지막 콜백의 next 필드를 가리키고 있으며, 그런 콜백이 없다면 RCU_WAIT_TAIL 원소와 같습니다.

- RCU_WAIT_TAIL=3: 이 원소는 이 리스트의 마지막 콜백의 next 필드를 가리키고 있으며, 이 리스트가 비어있다면 nxtlist 필드를 가리킵니다.

Quick Quiz D.24: 이 웃기는 여러 꼬리를 가진 리스트 보다는 여러개의 리스트를 그냥 유지하는 게 어때요? ■

- **qlen:** 이 필드는 nxtlist 에 들어가 있는 콜백들의 수를 담습니다.
 - **blimit:** 이 필드는 한번에 호출될 수 있는 콜백들의 최대 갯수를 담습니다. 이 한계는 많은 부하 아래에서의 시스템의 반응성을 개선합니다.
 - **dynticks:** 이 필드는 Section D.3.1.1 에서 이야기 한대로 연관된 CPU 의 rCU_dynticks 구조체를 참조합니다.
 - **dynticks_snap:** 이 필드는 dynticks->dynticks 의 예전 값을 담고 있는데, force_quiescent_state() 가 체크하는, 이 CPU 가 irq 핸들러에 있을 때마다 언제 CPU 가 dynticks idle state 를 지나가는지 판단하는데에 사용됩니다.
 - **dynticks_nmi_snap:** 이 필드는 dynticks->dynticks_nmi 의 예전 값을 갖는데, force_quiescent_state() 가 체크하는, 이 CPU 가 NMI 핸들러에 있을 때마다 언제 CPU 가 dynticks idle state 를 지나가는지 판단하는데에 사용됩니다.
 - **dynticks_fqs:** 이 필드는 dynticks-idle 모드로 인해 이 rCU_data 구조체에 연관된 CPU 의 아래에서 다른 CPU 가 몇번이나 quiescent state 를 알렸는지 그 횟수를 셹니다.
 - **offline_fqs:** 이 필드는 offline 이 되는 일로 인해 이 rCU_data 구조체에 연관된 CPU 의 아래에서 다른 CPU 가 몇번이나 quiescent state 를 알렸는지 그 횟수를 셹니다.
- Quick Quiz D.25:** 그래서 일부 불쌍한 CPU 는 모든 각각의 offline CPU 아래에서도 quiescent state 들을 알려야 한다는 건가요? 으웩! 그건 적은 수의 CPU 를 가지고 있지만 큰 값의 NR_CPUS 를 가진, 흔하지 않은 시스템에서는 지나친 오버헤드가 되지 않을까요? ■
- **resched_ipi:** 이 필드는 reschedule IPI 가 연관된 CPU 로 보내어진 횟수를 셹니다. 이런 IPI 들은 offline 인것도 dynticks idle state 에 있는 것도 아니면서 시간 내에 quiescent state 를 지나지 못한 CPU 들에게 보내어집니다.

- `n_rcu_pending`: 이 필드는 non-dynticks-idle CPU 들에게 jiffy 마다 호출되는 `rcu_pending()` 을 호출한 횟수를 셉니다.
- `n_rcu_pending_force_qs`: 이 필드는 `n_rcu_pending` 의 값의 threshold 를 갖습니다. 만약 `n_rcu_pending` 이 이 threshold 에 닿는다면, 이는 현재의 grace period 가 너무 길게 이어졌음을 의미하며, 따라서 이걸 신속화 시키기 위해 `force_quiescent_state()` 가 호출됩니다.

D.3.1.4 RCU Global State

`rcu_state` 구조체는 RCU (`rcu` 와 `rcu_bh`) 인스턴스 각각을 위한 RCU 의 global state 를 담고 있습니다. 이는 `rcu_node` 구조체의 계층과 관련된 필드들도 있고, `node` 배열 자체, 계층의 각 단계들을 향한 포인터들을 담는 `level` 배열, 이 계층 상의 각 단계의 노드의 갯수를 담는 `levelcnt` 배열, 이 계층의 각 단계의 노드별 자식의 갯수를 담는 `levels` 배열, 그리고 각 CPU 의 `rcu_data` 구조체로의 포인터의 `rda` 배열을 포함합니다. `rcu_state` 구조체 또한 다양한 현재 grace period 의 자세한 내용들과 다른 메커니즘들 (signaled, gpnum, completed, onofflock, fqslock, jiffies_force_qs, n_force_qs, n_force_qs_lh, n_force_qs_ngp, gp_start, jiffies_stall, 그리고 dynticks_completed) 과의 상호작용을 조정하는 다양한 필드들을 갖고 있습니다.

이 필드들 각각에 대해 아래에서 설명합니다.

- `node`: 이 필드는 `rcu_node` 구조체의 배열로, 계층 상의 루트 노드는 `->node[0]` 에 위치합니다. 이 배열의 크기는 `NUM_RCU_NODES` C 전처리기 매크로로 명시되는데, Section D.3.1.5 에서 설명되듯이 `NR_CPUS` 와 `CONFIG_RCU_FANOUT` 을 가지고 계산됩니다. 첫번째 원소부터 시작해서 `->node` 배열을 순회하는 것은 `rcu_node` 계층을 breadth-first 탐색하는 것과 같은 효과를 냅니다.
- `level`: 이 필드는 `node` 배열로의 포인터들의 배열입니다. 해당 계층의 루트 노드는 `->level[0]` 를 통해 참조되며, 계층상 두번째 단계의 (존재한다면) 첫번째 노드는 `->level[1]` 로 참조되며, 나머지도 그렇게 구성됩니다. 첫번째 leaf 노드는 `->level[NUM_RCU_LVLS-1]` 로 참조되며, 따라서 `level` 배열의 크기는 `NUM_RCU_LVLS` 로 명시되는데, Section D.3.1.5 에서 설명된대로 계산됩니다. `->level` 필드는 `rcu_node` 계층의 한 단계를, 예를 들면 leaf 노드들을 스캔하기 위해 `->node` 와 함께 조합되어 사용됩니다. `->level` 의 원소들은

부팅 시점에 `rcu_init_one()` 함수에 의해 채워집니다.

- `levelcnt`: 이 필드는 `rcu_node` 계층의 각 단계의 노드의 갯수들을 담고 있는 배열로, leaf `rcu_node` 구조체를 참조하는 `rcu_data` 구조체의 갯수를 포함해서, 이 배열은 `->level` 배열보다 원소를 하나 더 많이 갖게 됩니다. `->levelcnt[0]` 는 이 계층의 꼭대기에 있는 하나의 루트 `rcu_node` 에 연관되어서 1의 값을 항상 가질 겁니다. 이 배열은 C 전처리기 매크로로 Section D.3.1.5 에서 설명된대로 계산되는 `NUM_RCU_LVL_0`, `NUM_RCU_LVL_1`, `NUM_RCU_LVL_2`, 그리고 `NUM_RCU_LVL_3`, 의 값으로 초기화 됩니다. `->levelcnt` 필드는 디버깅 목적으로 이 계층의 다른 부분들을 초기화하는데에 사용됩니다.
- `levels`: 이 필드의 각 원소는 `rcu_node` 계층의 연관된 각 단계의 희망되는 자식들의 갯수를 담습니다. 이 배열의 원소들의 값들은 실행시점에 `CONFIG_RCU_FANOUT_EXACT` 커널 퍼러미터로 선택되는 두개의 `rcu_init_levels()` 함수들 중 하나로 계산됩니다.
- `rda`: 이 필드의 각 원소는 연관된 CPU 의 `rcu_data` 구조체로의 포인터를 담고 있습니다. 이 배열은 부팅 시점에 `RCU_DATA_PTR_INIT()` 매크로로 초기화 됩니다.
- `signaled`: 이 필드는 Section D.3.8 에서 설명된 것처럼 `force_quiescent_state()` 함수에 의해 사용되는 상태를 유지하기 위해 사용됩니다. 이 필드는 다음의 값을 중 하나를 취합니다:
 - `RCU_GP_INIT`: 이 값은 현재의 grace period 가 초기화 되어가는 과정이 진행 중이어서 `force_quiescent_state()` 는 아무 동작도 하지 말아야 함을 알립니다. 물론, 이런 상황이 발생하기 위해선 grace-period 초기화가 세개의 jiffy 만큼이나 길게 수행될 필요가 있겠지만, 여러분이 매우 많은 수의 CPU 를 사용한다면 이 race 는 실제로 일어날 수 있습니다. 일단 grace-period 초기화가 완료된다면, 이 값은 (`CONFIG_NO_HZ` 라면) `RCU_SAVE_DYNTICK` 이나 `RCU_FORCE_QS` 로 설정됩니다.
 - `RCU_SAVE_DYNTICK`: 이 값은 현재의 grace period 를 위한 quiescent state 를 아직 보고하지 않은 모든 CPU 에 대해 `force_quiescent_state()` 가 dynticks state 를 체크해야 함을

알립니다. Quiescent state 는 dyntick-idle 모드에 있는 모든 CPU 를 아래에서 보고될 겁니다.

- RCU_FORCE_QS: 이 값은 현재의 grace period 를 위한 quiescent state 를 아직 보고하지 않은 모든 CPU 에 대해 force_quiescent_state() 가 dynticks state 와 online/offline 상태를 다시 체크해야 함을 알립니다. 다시 dynticks state 를 체크하는 것은 이 구현이 dynticks-idle state 에 있지만, 그게 체크될 때 irq 나 NMI 핸들러에 있었던 CPU 의 경우에 대해서도 처리할 수 있게 해줍니다. 이외에 모두 실패한다면, 이 꾸물거리는 CPU 에게 reschedule IPI 가 날아갈 겁니다.

이 필드는 루트 rcu_node 구조체의 락으로 보호됩니다.

Quick Quiz D.26: 그럼 이 앞에서 이야기된 이 구조체의 필드들은 뭘로 보호되나요? ■

- gpnum: 이 필드는 현재 grace period 의 수를, 또는 현재 grace period 가 없다면 마지막 grace period 의 수를 갖습니다. 이 필드는 루트 rcu_node 구조체의 락으로 보호됩니다만, 이 락을 잡지 않은 채로도 빈번히 액세스 됩니다 (하지만 수정되진 않습니다).
- completed: 이 필드는 마지막으로 완료된 grace period 의 수를 갖습니다. 현재 진행중인 grace period 가 없다면 이는 ->gpnum 과 동일하고, 현재 진행중인 grace period 가 있다면 ->gpnum 보다 1 작습니다. 원론적으로, 이 두개의 필드들을 하나의 boolean 으로 바꿀 수도 있을 텐데, 일부 버전의 Linux 에서의 Classic RCU 가 그러합니다만, 실제로는 두개의 숫자를 갖는 편이 race 처리에 훨씬 간단합니다. 이 필드는 루트 rcu_node 구조체의 락으로 보호됩니다만, 이 락을 잡지 않은 채로도 빈번히 액세스 됩니다 (하지만 수정되진 않습니다).
- onofflock: 이 필드는 grace-period 초기화와 동시에 online/offline 처리가 수행되는 것을 막습니다. 여기엔 하나의 예외가 있습니다: 만약 rcu_node 계층이 하나의 구조체로만 이루어져 있다면, 이 하나의 구조체의 ->lock 필드가 이 일을 대신 처리할 겁니다.
- fqslock: 이 필드는 두개 이상의 task 가 force_quiescent_state() 로 quiescent state 를 강제하는 것을 막습니다.
- jiffies_force_qs: 이 필드는 CPU 를 quiescent state 로 강제하기 위해, 그리고/또는 extended quiescent state 를 보고하기 위해 언제
- force_quiescent_state() 가 호출되어야 하는지를 jiffy 단위로 기록하고 있습니다. 이 필드는 루트 rcu_node 구조체의 락으로 보호됩니다만, 이 락 없이도 자주 액세스 됩니다 (하지만 수정은 되지 않습니다).
- n_force_qs: 이 필드는 force_quiescent_state() 가 grace period 가 이미 완료되었거나, 동시에 다른 CPU 가 있거나, force_quiescent_state() 가 너무 최근에 수행된 적이 있거나 하지 않고 실제로 일을 수행한 횟수를 셹니다. 이 필드는 tracing 과 디버깅에 사용되며, ->fqslock 으로 보호됩니다.
- n_force_qs_lh: 이 필드는 force_quiescent_state() 가 ->fqslock 이 다른 CPU 에 의해 잡혀 있었던 관계로 곧바로 리턴한 대략적 횟수를 셹니다. 이 필드는 tracing 과 debugging에 사용되며 대략적인 수인 만큼 어떤 락으로도 보호되지 않습니다.
- n_force_qs_ngp: 이 필드는 성공적으로 ->fqslock 을 잡았지만 진행중인 grace period 가 없다는 것을 알아차리게 된 force_quiescent_state() 수행 횟수를 셹니다. 이 필드는 tracing 과 debugging 을 위해 사용되며, ->fqslock 으로 보호됩니다.
- gp_start: 이 필드는 가장 최근의 grace period 가 시작한 시간을 jiffy 단위로 기록합니다. 이는 stalled CPU 들의 파악에 사용됩니다만, CONFIG_RCU_CPU_STALL_DETECTOR 커널 패러미터가 선택되었을 때만의 이야기입니다. 이 필드는 루트 rcu_node 의 ->lock 으로 보호됩니다만, 가끔은 이 락을 잡지 않고도 액세스 됩니다 (하지만 수정되진 않습니다).
- jiffies_stall: 이 필드는 현재의 grace period 가 연장될 시간을 jiffy 단위로 기록하며, CPU stall 을 체크하기 위해 사용되기 적합할 겁니다. ->gp_start 와 같이, 이 필드는 CONFIG_RCU_CPU_STALL_DETECTOR 커널 패러미터가 선택되었을 때에만 존재합니다. 이 필드는 루트 rcu_node 의 ->lock 으로 보호됩니다만, 가끔은 이 락을 잡지 않은 채 액세스 됩니다 (하지만 수정되지는 않습니다).
- dynticks_completed: 이 필드는 force_quiescent_state() 가 dyntick state 의 스냅샷을 찍을 때의 ->completed 의 값을 기록합니다만, 또한 매 grace period 의 시작 때마다 기존 grace period 로 초기화 됩니다. 이 필드는 기존 grace

period로부터의 dyntick-idle quiescent state 가 현재 grace period 에 적용되는 것을 막는데에 사용됩니다. 이 필드는 CONFIG_NO_HZ 커널 패러미터가 선택되었을 때에만 존재합니다. 이 필드는 루트 `rcu_node` 의 `->lock` 으로 보호됩니다만, 가끔은 이 락을 잡지 않은 채로 액세스 됩니다 (하지만 수정되지는 않습니다).

D.3.1.5 Kernel Parameters

다음의 커널 패러미터들이 이 RCU 변종에 영향을 끼칩니다:

- NR_CPUS, 시스템의 CPU 의 최대 갯수.
- CONFIG_RCU_FANOUT, `rcu_node` 계층의 각 노드의 바람직한 자식 노드의 수.
- CONFIG_RCU_FANOUT_EXACT, `rcu_node` 계층의 rebalancing 을 막는 boolean 값.
- CONFIG_HOTPLUG_CPU, CPU 들이 online 이 되고 offline 이 될 수 있도록 허용.
- CONFIG_NO_HZ, dynticks-idle 모드가 지원되는지 여부를 알림.
- CONFIG_SMP, 복수개의 CPU 들이 존재할 수 있음을 알림.
- CONFIG_RCU_CPU_STALL_DETECTOR, RCU grace period 가 너무 길게 연장된다면 RCU 는 stalled CPU 를 체크해야 함을 알림.
- CONFIG_RCU_TRACE, RCU 가 debugfs 에 tracing 정보를 제공해야 함을 알림.

CONFIG_RCU_FANOUT 과 NR_CPUS 패러미터들은 Figure D.20 에 보인 것처럼 컴파일 시점에 `rcu_node` 계층의 모습을 결정하는데에 사용됩니다. Line 1 은 `rcu_node` 계층의 최대 depth 를 정하는데, 여기선 3 입니다. 최대 허용된 depth 를 늘리는 행위는 여기저기 변경을 필요로 하는데, 예를 들면 line 6-26 의 #if 문에 또 다른 경우를 추가합니다. Line 2-4 는 각각 fanout, fanout 의 제곱, 그리고 fanout 의 세제곱을 계산합니다.

이후에 이 값들은 `rcu_node` 계층의 요구되는 depth 를 결정하기 위해 NR_CPUS 와 비교되어지며, 이 depth 는 NUM_RCU_LVLS 에 저장되는데 이는 `rcu_state` 구조체의 여러 배열들의 크기를 정하는데 사용되어집니다. 루트 단계에는 항상 하나의 노드가 존재하며, leaf 단계 아래에는 NUM_CPUS 갯수의 `rcu_data` 구조체가 존재합니다. 루트 단계 이상의 단계가 존재한다면, leaf 단계에서의 노드의 갯수는 NR_CPUS 를 RCU_FANOUT_SQ

로 나누고 반올림 한 값으로 계산됩니다. 다른 단계에서의 노드들의 갯수는 (예를 들면) RCU_FANOUT_SQ 대신 RCU_FANOUT 을 사용하는 식으로 비슷하지만 약간 다르게 계산됩니다.

이어서 Line 28 은 이 모든 단계의 수들을 더해서 `rcu_node` 구조체들의 수와 `rcu_data` 구조체의 수를 더한 값을 구합니다. 마지막으로, line 29 는 이 합으로 부터 (`rcu_data` 구조체들의 갯수인) NR_CPUS 를 빼서 `rcu_node` 구조체의 갯수를 구해서 NUM_RCU_NODES 안에 저장합니다. 이 값은 `rcu_state` 구조체의 `->nodes` 배열의 크기를 정하는데에 사용됩니다.

D.3.2 External Interfaces

RCU 의 외부로의 인터페이스는 표준 RCU API 만이 아니라 RCU 구현 자체에 필요한 커널의 나머지 부분들로의 내부적 인터페이스도 포함됩니다. 이 인터페이스들은 `rcu_read_lock()`, `rcu_read_unlock()`, `rcu_read_lock_bh()`, `rcu_read_unlock_bh()`, (`_call_rcu()` 의 wrapper 인) `call_rcu()`, (마찬가지 인) `call_rcu_bh()`, `rcu_check_callbacks()`, (`_rcu_process_callbacks()` 의 wrapper 인) `rcu_process_callbacks()`, (`_rcu_pending()` 의 wrapper 인) `rcu_pending()`, `rcu_needs_cpu()`, `rcu_cpu_notify()`, 그리고 `_rcu_init()` 입니다. `synchronize_rcu()` 와 `rcu_barrier()` 는 모든 RCU 구현에 공통되며, `call_rcu()` 규모에서 정의되어 있음을 알아두시기 바랍니다. 비슷하게, `rcu_barrier_bh()` 는 모든 RCU 구현에 공통되며, `call_rcu_bh()` 규모에서 정의되어 있습니다.

이런 외부로의 API 들 각각을 다음 섹션들에서 설명합니다.

D.3.2.1 Read-Side Critical Sections

Figure D.21 는 RCU read-side 크리티컬 섹션들을 표시하는 함수들을 보입니다. Line 1-6 은 “rcu” read-side 크리티컬 섹션을 시작하는 `_rcu_read_lock()` 을 보입니다. Line 3 은 preemption 을 불능화 하고, line 4 는 RCU read-side 크리티컬 섹션의 시작을 알리는 가벼운 표시이고, line 5 는 lockdep 상태를 업데이트 합니다. Line 8-13 은 `_rcu_read_lock()` 의 반대 역할인 `_rcu_read_unlock()` 을 보입니다. Line 15-20 은 `_rcu_read_lock_bh()` 를 보이고 line 22-27 은 `_rcu_read_unlock_bh()` 을 보이는데, 앞의 두개와 비슷한 함수입니다만, preemption 이 아니라 bottom-half 처리를 불능화하고 활성화 합니다.

Quick Quiz D.27: 전 RCU read-side 처리가 빠를 거라고 생각했는데요! Figure D.21 에 보인 함수들은 너무

```

1 #define MAX_RCU_LVLS 3
2 #define RCU_FANOUT (CONFIG_RCU_FANOUT)
3 #define RCU_FANOUT_SQ (RCU_FANOUT * RCU_FANOUT)
4 #define RCU_FANOUT_CUBE (RCU_FANOUT_SQ * RCU_FANOUT)
5
6 #if NR_CPUS <= RCU_FANOUT
7 # define NUM_RCU_LVLS 1
8 # define NUM_RCU_LVL_0 1
9 # define NUM_RCU_LVL_1 (NR_CPUS)
10 # define NUM_RCU_LVL_2 0
11 # define NUM_RCU_LVL_3 0
12 #elif NR_CPUS <= RCU_FANOUT_SQ
13 # define NUM_RCU_LVLS 2
14 # define NUM_RCU_LVL_0 1
15 # define NUM_RCU_LVL_1 (((NR_CPUS) + RCU_FANOUT - 1) / RCU_FANOUT)
16 # define NUM_RCU_LVL_2 (NR_CPUS)
17 # define NUM_RCU_LVL_3 0
18 #elif NR_CPUS <= RCU_FANOUT_CUBE
19 # define NUM_RCU_LVLS 3
20 # define NUM_RCU_LVL_0 1
21 # define NUM_RCU_LVL_1 (((NR_CPUS) + RCU_FANOUT_SQ - 1) / RCU_FANOUT_SQ)
22 # define NUM_RCU_LVL_2 (((NR_CPUS) + (RCU_FANOUT) - 1) / (RCU_FANOUT))
23 # define NUM_RCU_LVL_3 NR_CPUS
24 #else
25 # error "CONFIG_RCU_FANOUT insufficient for NR_CPUS"
26 #endif /* #if (NR_CPUS) <= RCU_FANOUT */
27
28 #define RCU_SUM (NUM_RCU_LVL_0 + NUM_RCU_LVL_1 + NUM_RCU_LVL_2 + NUM_RCU_LVL_3)
29 #define NUM_RCU_NODES (RCU_SUM - NR_CPUS)

```

Figure D.20: Determining Shape of RCU Hierarchy

쓰레기가 많이 들어있어서 이건 느릴 수밖에 없겠는걸요! 이게 뭡니까? ■

```

1 void __rcu_read_lock(void)
2 {
3     preempt_disable();
4     __acquire(RCU);
5     rCU_read_acquire();
6 }
7
8 void __rcu_read_unlock(void)
9 {
10    rCU_read_release();
11    __release(RCU);
12    preempt_enable();
13 }
14
15 void __rcu_read_lock_bh(void)
16 {
17    local_bh_disable();
18    __acquire(RCU_BH);
19    rCU_read_acquire();
20 }
21
22 void __rcu_read_unlock_bh(void)
23 {
24    rCU_read_release();
25    __release(RCU_BH);
26    local_bh_enable();
27 }

```

Figure D.21: RCU Read-Side Critical Sections

D.3.2.2 call_rcu()

Figure D.22 는 __call_rcu(), call_rcu(), 그리고 call_rcu_bh() 의 코드를 보입니다. call_rcu() 와 call_rcu_bh() 는 __call_rcu() 의 wrapper 일 뿐임을 알아주시기 바라며, 따라서 여기서는 더이상 다루지 않습니다.

관심을 __call_rcu() 로 돌려보면, line 9-10 은 명시된 rCU_head 를 초기화하고, line 11 은 __call_rcu() 가 호출되기 전에 수행된 RCU 로 보호되는 데이터 구조로의 업데이트가 콜백 등록 전에 된것으로 보여질 것을 보장합니다. Line 12 와 34 는 인터럽트 핸들러로부터의 __call_rcu() 호출에 의한 파괴적 간섭을 막기 위해 인터럽트를 비활성화하고 재활성화 합니다. Line 13 은 현재 CPU 의 rCU_data 구조체로의 레퍼런스를 얻어오고, line 14 는 현재 grace period 가 끝나지 않았다면 콜백들을 진행시키기 위해 rCU_process_gp_end() 를 수행하고, line 15 는 새로운 grace period 가 시작되면 상태를 기록하기 위해 check_for_new_grace_period() 를 호출합니다.

Quick Quiz D.28: Figure D.22 의 line 13 에서 현재 CPU 의 rCU_data 구조체로의 레퍼런스를 가져오는데에 간단히 __get_cpu_var() 를 사용하는게 어떤가요?

```

1 static void
2 __call_rcu(struct rCU_head *head,
3           void (*func)(struct rCU_head *rcu),
4           struct rCU_state *rsp)
5 {
6     unsigned long flags;
7     struct rCU_data *rdp;
8
9     head->func = func;
10    head->next = NULL;
11    smp_mb();
12    local_irq_save(flags);
13    rdp = rsp->rda[smp_processor_id()];
14    rCU_process_gp_end(rsp, rdp);
15    check_for_new_grace_period(rsp, rdp);
16    *rdp->nxttail[RCU_NEXT_TAIL] = head;
17    rdp->nxttail[RCU_NEXT_TAIL] = &head->next;
18    if (ACCESS_ONCE(rsp->completed) ==
19        ACCESS_ONCE(rsp->gpnum)) {
20        unsigned long nestflag;
21        struct rCU_node *rnp_root = rCU_get_root(rsp);
22
23        spin_lock_irqsave(&rnp_root->lock, nestflag);
24        rCU_start_gp(rsp, nestflag);
25    }
26    if (unlikely(++rdp->qlen > qhimark)) {
27        rdp->blimit = LONG_MAX;
28        force_quiescent_state(rsp, 0);
29    } else if (((long)(ACCESS_ONCE(rsp->jiffies_force_qs) -
30                      jiffies) < 0 ||
31                (rdp->n_rcu_pending_force_qs -
32                 rdp->n_rcu_pending) < 0))
33        force_quiescent_state(rsp, 1);
34    local_irq_restore(flags);
35 }
36
37 void call_rcu(struct rCU_head *head,
38               void (*func)(struct rCU_head *rcu))
39 {
40     __call_rcu(head, func, &rcu_state);
41 }
42
43 void call_rcu_bh(struct rCU_head *head,
44                   void (*func)(struct rCU_head *rcu))
45 {
46     __call_rcu(head, func, &rcu_bh_state);
47 }

```

Figure D.22: call_rcu() Code



Line 16과 17은 새로운 콜백을 집어넣습니다. Line 18과 19는 진행중인 grace period가 있는지 체크해보며, 그렇지 않다면 line 23에서 루트 rCU_node 구조체의 락을 얻어오고 line 24에서 새로운 grace period를 시작하기 위해 (그리고 얻어온 락을 내려놓기 위해) rCU_start_gp()를 실행합니다.

Line 26은 이 CPU를 너무 많은 RCU 콜백들이 기다리고 있지 않은지 확인해보고, 만약 그렇다면 line 27에서 콜백들이 수행되는 비율을 증가시키기 위해 ->blimit을 증가시키며, line 28에서는 제공된 CPU들이 quiescent state를 지나도록 시도하기 위해 급히 force_quiescent_state()를 호출합니다. 그렇지 않다면, line 29-32에서 grace period가 시작된 이후로 (또는

```

1 static int __rcu_pending(struct rCU_state *rsp,
2                           struct rCU_data *rdp)
3 {
4     rdp->n_rcu_pending++;
5
6     check_cpu_stall(rsp, rdp);
7     if (rdp->qs_pending)
8         return 1;
9     if (cpu_has_callbacks_ready_to_invoke(rdp))
10        return 1;
11    if (cpu_needs_another_gp(rsp, rdp))
12        return 1;
13    if (ACCESS_ONCE(rsp->completed) != rdp->completed)
14        return 1;
15    if (ACCESS_ONCE(rsp->gpnum) != rdp->gpnum)
16        return 1;
17    if (ACCESS_ONCE(rsp->completed) !=
18        ACCESS_ONCE(rsp->gpnum) &&
19        ((long)(ACCESS_ONCE(rsp->jiffies_force_qs) -
20                jiffies) < 0 ||
21         (rdp->n_rcu_pending_force_qs -
22          rdp->n_rcu_pending) < 0))
23        return 1;
24    return 0;
25 }
26
27 int rCU_pending(int cpu)
28 {
29     return __rcu_pending(&rcu_state,
30                          &per_cpu(rcu_data, cpu)) ||
31            __rcu_pending(&rcu_bh_state,
32                          &per_cpu(rcu_bh_data, cpu));
33 }
34
35 void rCU_check_callbacks(int cpu, int user)
36 {
37     if (user ||
38         (idle_cpu(cpu) && !in_softirq() &&
39          hardirq_count() <= (1 << HARDIRQ_SHIFT))) {
40         rCU_qsctr_inc(cpu);
41         rCU_bh_qsctr_inc(cpu);
42     } else if (!in_softirq()) {
43         rCU_bh_qsctr_inc(cpu);
44     }
45     raise_softirq(RCU_SOFTIRQ);
46 }

```

Figure D.23: rCU_check_callbacks() Code

지난번의 force_quiescent_state() 호출 아래로) 너무 오래되었는지 확인하고, 만약 그렇다면 line 33에서 다시한번 제공된 CPU들이 quiescent state를 지나도록 시도하기 위해 force_quiescent_state()를 급히 하지 않게 호출합니다.

D.3.2.3 rCU_check_callbacks()

Figure D.23는 각 CPU에서 jiffy마다 한번씩 scheduling-clock 인터럽트 핸들러에서 호출되는 코드를 보입니다. rCU_pending() 함수 (__rcu_pending()의 wrapper입니다)가 실행되고, 이게 0이 아닌 값을 리턴하면, rCU_check_callbacks()가 호출됩니다. (rCU_pending()을 rCU_check_callbacks() 안으로 합칠 생각도 있었음을 알아두시기 바랍니다.)

`__rcu_pending()`의 시작과 함께, line 4는 이 `rcu_pending()`의 호출 횟수를 세는데, 언제 quiescent state를 강제할지 결정하는데 사용하기 위해서입니다. Line 6은 `CONFIG_RCU_CPU_STALL_DETECTOR`가 선택되어 있다면 커널 내에서 spinning하고 있거나, 또는 하드웨어 문제를 겪고 있는 CPU들을 보고하기 위해 `check_cpu_stall()`을 호출합니다. Line 7-23은 여러 검사를 하고, RCU가 현재 CPU가 다른 일을 하도록 해야 한다면 0이 아닌 값을 리턴합니다. Line 7은 현재 CPU가 현재의 grace period를 위해 quiescent state를 빛지고 있는지 검사하고, line 9는 현재 CPU가 끝난 grace period를 위한, 따라서 호출될 준비가 된 콜백을 가지고 있는지 검사하며, line 11은 현재 CPU가 다른 RCU grace period가 지나가길 기다려야 하는 콜백을 가지고 있는지 보기 위해 `cpu_needs_another_gp()`를 호출하며, line 13은 현재 grace period가 끝났는지 체크하고, line 15는 새로운 grace period가 시작되었는지 검사하며, 마지막으로 line 17-22에서는 제공된 CPU들이 quiescent state를 지나도록 강제해야 할 시간인지 체크합니다. 이 마지막 검사는 다음과 같이 나뉘어집니다: (1) line 17-18은 진행중인 grace period가 있는지 체크하고, 만약 그렇다면 line 19-22에서 `force_quiescent_state()`가 호출되기에 충분할 정도로 jiffy들 (line 19-20) 또는 `rcu_pending()` 호출 (line 21-22)이 지나갔는지 체크합니다. 이 검사들 중 어느것도 해당하지 않는다면, line 24에서 0을 리턴하여 `rcu_check_callbacks()`가 호출될 필요가 없음을 알립니다.

Line 27-33은 단순히 `__rcu_pending()`을 두번, 한번은 “rcu”를 위해 그다음은 “rcu_bh”를 위해 호출하는 `rcu_pending()`을 보입니다.

Quick Quiz D.29: Figure D.23의 line 29-32에서 `rcu_pending()`이 항상 두번 호출된다는 점을 생각해 보면 이 두개의 구조체들에 대한 검사들을 하나로 합칠 방법이 있어야 하는거 아닌가요? ■

Line 35-48은 `rcu_check_callbacks()` 함수를 보는데, 이 함수는 scheduling-clock 인터럽트가 연장된 quiescent state를 인터럽트 했는지 검사하고, 만약 그렇다면 RCU의 softirq 처리를 시작 (`rcu_process_callbacks()`) 합니다. Line 37-41은 “rcu”를 위한 이 검사를 수행하고 line 42-43은 “rcu_bh”를 위한 이 검사를 수행합니다.

Line 37-39는 이 scheduling clock 인터럽트가 사용자 모드 수행으로부터 들어왔는지 (line 37) 또는 idle 루프로부터 곧바로 들어왔는지 (line 38의 `idle_cpu()` 수행)를 인터럽트의 단계를 건드리지 않고 들어왔는지 (line 38의 뒷부분과 line 39) 검사합니다. 이 검사에 걸린다면, 즉 scheduling clock 인터럽트가 연장된 quiescent state로부터 왔다면, “rcu”를 위한 모든 quiescent state는 또한 “rcu_bh”를 위한 quiescent state이기도 하므로,

```

1 static void
2 __rcu_process_callbacks(struct rcu_state *rsp,
3                         struct rcu_data *rdp)
4 {
5     unsigned long flags;
6
7     if ((long)(ACCESS_ONCE(rsp->jiffies_force_qs) -
8             jiffies) < 0 ||
9         (rdp->n_rcu_pending_force_qs -
10          rdp->n_rcu_pending) < 0)
11         force_quiescent_state(rsp, 1);
12     rCU_process_gp_end(rsp, rdp);
13     rCU_check_quiescent_state(rsp, rdp);
14     if (cpu_needs_another_gp(rsp, rdp)) {
15         spin_lock_irqsave(&rcu_get_root(rsp)->lock, flags);
16         rCU_start_gp(rsp, flags);
17     }
18     rCU_do_batch(rdp);
19 }
20
21 static void
22 rCU_process_callbacks(struct softirq_action *unused)
23 {
24     smp_mb();
25     __rcu_process_callbacks(&rcu_state,
26                            &__get_cpu_var(rcu_data));
27     __rcu_process_callbacks(&rcu_bh_state,
28                            &__get_cpu_var(rcu_bh_data));
29     smp_mb();
30 }

```

Figure D.24: `rcu_process_callbacks()` Code

line 40과 41은 이 quiescent state를 두 종류의 RCU 모두를 위한 것으로 보고합니다.

비슷하게 “rcu_bh”를 위해서도 line 42에서 이 scheduling-clock 인터럽트가 softirq가 활성화된 코드 영역에서 온 것인지 검사하고 만약 그렇다면 line 43에서 이 quiescent state를 “rcu_bh”만을 위한 것으로 보고합니다.

Quick Quiz D.30: Figure D.23의 line 42는 `in_hardirq()` 검사도 해야하지 않습니까? ■

어느 경우든, line 45는 RCU softirq를 수행하는데, 이는 이 CPU에서 (인터럽트가 현재의 scheduler-clock 인터럽트 후에 재활성화 되거나 하는) 미래에 `rcu_process_callbacks()`가 호출되게 할겁니다.

D.3.2.4 `rcu_process_callbacks()`

Figure D.24는 `__rcu_process_callbacks()`의 wrapper인 `rcu_process_callbacks()`의 코드를 보입니다. 이 함수들은 예를 들면 RCU 코어는 이 CPU가 뭘가 할 필요가 있다고 생각할 이유가 있다면 일반적으로 행해지는, Figure D.23의 line 47과 같이 `raise_softirq(RCU_SOFTIRQ)` 호출의 결과로 실행됩니다.

Line 7-10은 현재의 grace period가 시작된지 한참이 지났는지 체크하고, 만약 그렇다면 line 11에서 제공된 CPU들이 이 grace period를 위해 quiescent state를 지나도록 설득하기 위해 `force_quiescent_state()`

를 호출합니다.

Quick Quiz D.31: 하지만 Figure D.24 의 `__rcu_process_callbacks`에서 grace period 가 실제로 진행 중인지도 체크해 봐야 하지 않을까요? ■

어떤 경우든, line 12 는 `rcu_process_gp_end()` 를 호출하는데, 이 함수는 어떤 다른 CPU 가 이 CPU 가 신경쓰고 있던 grace period 를 끝내버리진 않았는지 검사하고, 만약 그렇다면 해당 grace period 의 종료를 알아채고 그에 맞춰 이 CPU 의 RCU 콜백들을 진행시킵니다. Line 13 은 `rcu_check_quiescent_state()` 를 호출하는데, 이 함수는 어떤 다른 CPU 가 새로운 grace period 를 시작했는지, 또한 현재의 CPU 가 현재의 grace period 를 위한 quiescent state 를 지났는지 검사하고, 만약 그렇다면 상태를 올바르게 업데이트 합니다. Line 14 는 진행중인 grace period 가 존재치 않는지 검사하고 현재 CPU 가 다른 grace period 를 필요로 하는 콜백들을 가지고 있지 않은지 검사합니다. 만약 그렇다면, line 15 는 루트 `rcu_node` 구조체의 락을 획득하고, line 17 에서 새로운 grace period 를 시작하는 `rcu_start_gp()` 를 호출합니다 (그리고 루트 `rcu_node` 구조체의 락을 해제합니다). 어떤 경우든, line 18 은 이 CPU 의 콜백들 가운데 grace period 가 완료된 것들을 모두 실행합니다.

Quick Quiz D.32: Figure D.24 에서 두개의 CPU 들이 새로운 grace period 를 동시에 시작하여 시도하면 어떻게 되나요? ■

Line 21-30 은 `rcu_process_callbacks()` 로, `__rcu_process_callbacks()` 의 wrapper 입니다. Line 24 는 모든 앞의 RCU read-side 크리티컬 섹션들이 뒤따르는 RCU 처리에 앞서 완료된 것으로 보일 것을 보장하기 위해 메모리 배리어를 실행합니다. Line 25-26 과 27-28 은 각각 “rcu” 와 “rcu_bh” 를 위해 `__rcu_process_callbacks()` 를 호출하고, 마지막으로 line 29 에서 `__rcu_process_callbacks()` 에 의해 진행된 모든 RCU 처리 과정이 뒤따르는 RCU read-side 크리티컬 섹션들 전에 보일 수 있도록 보장하기 위해 메모리 배리어를 수행합니다.

D.3.2.5 `rcu_needs_cpu()` and `rcu_cpu_notify()`

Figure D.25 는 `rcu_needs_cpu()` 와 `rcu_cpu_notify()` 함수의 코드를 보이는데, 이것들은 리눅스 커널에서 각각 dynticks-idle 모드로의 전환을 체크하고 CPU hotplug 를 처리하기 위해 호출됩니다.

Line 1-5 는 `rcu_needs_cpu()` 를 보이는데, 이 함수는 단순히 명시된 CPU 가 “rcu” (line 3) 또는 “rcu_bh” (line 4) 콜백을 가지고 있는지 체크합니다.

Line 7-28 은 `rcu_cpu_notify()` 를 보이는데, 이 함수는 일반적인 `switch` 구문을 사용하는 매우 일반적인 CPU-hotplug notifier 함수입니다. Line 16 은 명시된 CPU 가 online 이 되려 한다면 `rcu_online_cpu()` 를

```

1 int rcu_needs_cpu(int cpu)
2 {
3     return per_cpu(rcu_data, cpu).nxtlist ||
4            per_cpu(rcu_bh_data, cpu).nxtlist;
5 }
6
7 static int __cpuinit
8 rcu_cpu_notify(struct notifier_block *self,
9                 unsigned long action, void *hcpu)
10 {
11     long cpu = (long)hcpu;
12
13     switch (action) {
14     case CPU_UP_PREPARE:
15     case CPU_UP_PREPARE_FROZEN:
16         rcu_online_cpu(cpu);
17         break;
18     case CPU_DEAD:
19     case CPU_DEAD_FROZEN:
20     case CPU_UP_CANCELED:
21     case CPU_UP_CANCELED_FROZEN:
22         rcu_offline_cpu(cpu);
23         break;
24     default:
25         break;
26     }
27     return NOTIFY_OK;
28 }
```

Figure D.25: `rcu_needs_cpu()` and `rcu_cpu_notify` Code

호출하고, line 22 는 명시된 CPU 가 offline 으로 가려 한다면 `rcu_offline_cpu()` 를 호출합니다. CPU-hotplug 오퍼레이션은 atomic 하지 않으며, 여러 grace period 를 거칠 정도로 길어질 수 있음을 알아두어야 합니다. 따라서 RCU 는 들어오거나 나가는 과정 상의 CPU 들을 우아하게 처리해야만 합니다.

D.3.3 Initialization

이 섹션은 주요한 데이터 구조체들을 Figure D.26 에 보인 것처럼 연결시키는 초기화 코드를 살펴보겠습니다. 노란 영역은 `rcu_state` 데이터 구조체의 필드들을 가리키는데, \rightarrow node 배열, 핑크색으로 보여진 각각의 원소들을 포함하며, Section D.2 에서 사용된 규칙을 지킵니다. 파란 네모들은 각각 하나의 `rcu_data` 구조체를 가리키며, 파란 네모들의 그룹은 per-CPU `rcu_data` 구조체의 집합을 구성합니다.

\rightarrow levelcnt [] 배열은 \rightarrow level [0] 가 그렇듯이 컴파일 타임에 초기화 됩니다만 나머지 값들과 포인터들은 뒤의 섹션들에서 설명할 함수들에 의해 내용이 채워집니다. 이 그림은 두단계의 계층을 보이고 있습니다만, 한개의 단계도 세개의 단계로 구성된 계층도 만들어 질 수 있습니다. \rightarrow levels[] 배열의 각 원소는 이 계층상의 연관된 단계에서의 노드당 자식의 갯수를 갖습니다. 따라서, 이 그림상에서 root 노드는 두개의 자식을 갖고 leaf 단계의 노드들은 각각 세개의 자식을




Figure D.26: Initialized RCU Data Layout

갖습니다. `levelcnt[]` 배열의 각 원소는 이 계층의 연관된 단계에 얼마나 많은 노드들이 존재하는지 알립니다: root 단계에선 1, leaf 단계에선 2, 그리고 `rcu_data` 단계에선 6입니다—그리고 그외의 모든 원소들은 사용되지 않으므로 0의 값을 갖습니다. `->level[]` 배열의 각 원소는 `rcu_node` 계층상의 연관된 단계의 첫번째 노드를 가리키며, `->rda[]` 배열의 각 원소는 연관된 CPU의 `rcu_data` 구조체를 가리킵니다. 각 `rcu_node` 구조체의 `->parent` 필드는 그 부모를 가리키는데, NULL `->parent` 포인터를 갖는 root `rcu_node` 구조체는 예외입니다. 마지막으로, `rcu_data` 구조체의 `->mynode` 필드는 부모 `rcu_node` 구조체를 가리킵니다.

Quick Quiz D.33: 해당 코드는 `rcu_node` 계층의 root부터 leaf 까지를 어떻게 횡단하나요? ■

다시 말해컨대, 다음 섹션들은 이 구조체를 만드는 코드를 들여다 봅니다.

D.3.3.1 `rcu_init_levelsread()`

Figure D.27는 `rcu_node` 계층 안의 fanout, 즉 부모당 자식의 갯수를 조절하는 `rcu_init_levelsread()` 함수의 코드를 보입니다. 이 함수의 두가지 버전이 있는데, 하나는 (`CONFIG_RCU_FANOUT`으로 명시된) 정확한 fanout을 강제하는 line 2-9에 보여져 있고, 다른 하나는 자식 노드의 갯수를 명시된 fanout에 간접적으로 기반해서 정하지만 이후 트리를 균형잡는 형태의 line 11-25

```

1 #ifdef CONFIG_RCU_FANOUT_EXACT
2 static void __init
3 rcu_init_levelsread(struct rcu_state *rsp)
4 {
5     int i;
6
7     for (i = NUM_RCU_LVLS - 1; i >= 0; i--)
8         rsp->levelsread[i] = CONFIG_RCU_FANOUT;
9 }
10 #else
11 static void __init
12 rcu_init_levelsread(struct rcu_state *rsp)
13 {
14     int ccur;
15     int cprv;
16     int i;
17
18     cprv = NR_CPUS;
19     for (i = NUM_RCU_LVLS - 1; i >= 0; i--) {
20         ccur = rsp->levelcnt[i];
21         rsp->levelsread[i] = (cprv + ccur - 1) / ccur;
22         cprv = ccur;
23     }
24 }
25 #endif

```

Figure D.27: `rcu_init_levelsread()` Code

에 보여져 있습니다. `CONFIG_RCU_FANOUT_EXACT` 커널 패러미터는 해당 커널 빌드에서 어떤 버전을 사용할지 선택합니다.

Exact-fanout 버전은 line 7과 9의 루프에 보인 것처럼 단순히 명시된 `rcu_state` 구조체의 `->levelsread`

```

1 static void __init rcu_init_one(struct rcu_state *rsp)
2 {
3     int cpustride = 1;
4     int i;
5     int j;
6     struct rcu_node *rnp;
7
8     for (i = 1; i < NUM_RCU_LVLS; i++)
9         rsp->level[i] = rsp->level[i - 1] +
10            rsp->levelcnt[i - 1];
11     rcpu_init_levelspread(rsp);
12     for (i = NUM_RCU_LVLS - 1; i >= 0; i--) {
13         cpustride *= rsp->levelsprad[i];
14         rnp = rsp->level[i];
15         for (j = 0; j < rsp->levelcnt[i]; j++, rnp++) {
16             spin_lock_init(&rnp->lock);
17             rnp->qsmask = 0;
18             rnp->qsmaskinit = 0;
19             rnp->grplo = j * cpustride;
20             rnp->grphi = (j + 1) * cpustride - 1;
21             if (rnp->grphi >= NR_CPUS)
22                 rnp->grphi = NR_CPUS - 1;
23             if (i == 0) {
24                 rnp->grpnum = 0;
25                 rnp->grpmask = 0;
26                 rnp->parent = NULL;
27             } else {
28                 rnp->grpnum = j % rsp->levelsprad[i - 1];
29                 rnp->grpmask = 1UL << rnp->grpnum;
30                 rnp->parent = rsp->level[i - 1] +
31                     j / rsp->levelsprad[i - 1];
32             }
33             rnp->level = i;
34         }
35     }
36 }

```

Figure D.28: rcu_init_one() Code

배열의 모든 원소들을 CONFIG_RCU_FANOUT 커널 패러미터로 값 할당합니다.

Line 11-24의 계층의 균형을 잡는 버전은 한쌍의 지역 변수 `ccur` 와 `cprv` 를 사용하는데 이것들은 현재와 앞 단계의 `rcu_node` 구조체의 갯수를 각각 추적합니다. 이 함수는 leaf 단계부터 계층의 위쪽으로 동작하는데, 따라서 `cprv` 의 값은 line 18에서 `NR_CPUS` 로 초기화 되며, 이는 leaf 단계에 들어가는 `rcu_data` 구조체의 갯수에 연관됩니다. Line 19-23은 leaf 부터 루트까지 반복합니다. 이 루프 안에서, line 20에서는 현재 단계의 `rcu_node` 구조체의 갯수를 `ccur` 에 넣습니다. 이어서 line 21은 앞의 (아래의) 단계의 노드의 갯수의 현재 단계의 `rcu_node` 구조체의 갯수에 대한 비율을 반올림해서 명시된 `rcu_state` 구조체의 `->levelsprad` 배열에 집어넣습니다. 이후 line 22에서는 이 루프의 다음 반복을 위한 환경 구성을 합니다.

어떤 쪽이든 이 함수들에 대한 호출 후에는 `->levelsprad` 배열은 `rcu_node` 계층의 각 단계별 자식 노드의 갯수를 담고 있게 됩니다.

D.3.3.2 rcu_init_one()

Figure D.28는 명시된 `rcu_state` 구조체에 대해 브트 타임 초기화를 행하는 `rcu_init_one()` 코드를 보입니다.

Section D.3.1.4에서 이야기했듯 `rcu_state` 구조체의 `->levelcnt[]` 배열은 root 부터 시작하는 계층의 각 단계의 노드들의 수로 컴파일 시점에 초기화 되며, 이 배열의 하나의 추가적인 원소는 있을 수 있는 최대한의 CPU의 갯수인 `NR_CPUS`로 초기화 됩니다. 여기에 더해서, `->level[]` 배열의 첫번째 원소는 root `rcu_node` 구조체로의 레퍼런스로 초기화 되는데, 이는 결국 `rcu_state` 구조체의 `->node[]` 배열의 첫번째 원소입니다. 이 뱅려은 더 나아가서 breadth-first 순서로 위치됩니다. 이 모든 것을 명심하고, line 8-10의 루프는 `->level[]` 배열의 나머지들을 `rcu_node` 구조체의 각 단계의 첫번째 `rcu_node` 구조체를 레퍼런스 하도록 초기화 합니다.

이어서 line 11은 `rcu_init_levelsprad()` 를 호출하는데, 이 함수는 Section D.3.3.1에서 설명한대로 `->levelsprad[]` 배열을 초기화 합니다. 이어서 예비의 배열들이 완전히 초기화되고, 따라서 line 15-35의 루프가 돌아갈 준비가 되는데, 이 루프의 각 단계는 `rcu_node` 구조체의 각 단계를 leaf 부터 시작해서 초기화 해나갑니다.

Line 13은 이 계층의 현재 단계를 위한 `rcu_node` 구조체 당 CPU의 갯수를 계산하고, line 14는 이 계층의 현재 단계의 첫번째 `rcu_node` 구조체로의 포인터를 얻어오는데, line 15-34의, 하나의 `rcu_node` 구조체의 초기화를 매번 해나가는 루프를 위한 준비단계입니다.

Line 16-18은 `rcu_node` 구조체의 스픬락과 그 CPU mask 들을 초기화합니다. `qsmaskinit` 필드는 나중에 부팅 시점 중에 CPU들이 online 이 될 때 설정되고, `qsmask` 필드는 첫번째 grace period 가 시작될 때 설정됩니다. Line 19는 `->grplo` 필드를 이 `rcu_node` 구조체의 첫번째 CPU의 숫자로 설정하고 line 20은 `->grphi` 를 이 `rcu_node` 구조체의 마지막 CPU의 숫자로 설정합니다. 만약 이 계층의 주어진 단계의 마지막 `rcu_node` 구조체가 부분적으로만 차 있다면, line 21과 22는 그것의 `->grphi` 필드가 시스템의 마지막 존재할 수 있는 CPU의 숫자가 되도록 만듭니다.

Line 24-26은 root `rcu_node` 구조체의 `->grpnum`, `->grpmask`, 그리고 `->parent` 필드를 초기화하는데, 이 구조체는 부모가 없으므로, 모두 zero 와 NULL 이 됩니다. Line 28-31은 이 계층의 나머지 `rcu_node` 구조체들의 같은 필드들을 초기화 합니다. Line 28은 `->grpnum` 필드를 같은 부모를 가진 집합 내에서의 이 `rcu_node` 구조체로의 인덱스로 계산하고, line 29는 `->grpmask` 필드의 연관된 bit의 값을 1로 설정합니다. 마지막으로, line 30-31은 `->parent` 필드에 부모 노드로의 포인터를 넣습니다. 이 세개의 필드는 quiescent state 를 계층의

```

1 #define RCU_DATA_PTR_INIT(rsp, rcu_data) \
2 do { \
3     rnp = (rsp)->level[NUM_RCU_LVLS - 1]; \
4     j = 0; \
5     for_each_possible_cpu(i) { \
6         if (i > rnp[j].grphi) \
7             j++; \
8         per_cpu(rcu_data, i).mynode = &rnp[j]; \
9         (rsp)->rda[i] = &per_cpu(rcu_data, i); \
10    } \
11 } while (0)
12
13 void __init __rcu_init(void)
14 {
15     int i;
16     int j;
17     struct rcu_node *rnp;
18
19     rcpu_init_one(&rcu_state);
20     RCU_DATA_PTR_INIT(&rcu_state, rcpu_data);
21     rcpu_init_one(&rcu_bh_state);
22     RCU_DATA_PTR_INIT(&rcu_bh_state, rcpu_bh_data);
23
24     for_each_online_cpu(i)
25         rcpu_cpu_notify(&rcpuc_nb, CPU_UP_PREPARE,
26                         (void *)(long)i);
27     register_cpu_notifier(&rcpuc_nb);
28 }

```

Figure D.29: __rcu_init() Code

윗단계로 넘기는데에 사용됩니다.

마지막으로, line 33 은 이 계층의 단계를 ->level에 기록하는데, 이는 전체 계층을 횡단할 때 tracing에 사용됩니다.

D.3.3.3 __rcu_init()

Figure D.29 는 __rcu_init() 함수와 그것의 helper macro인 RCU_DATA_PTR_INIT()를 보입니다. __rcu_init() 함수는 부팅 초기에 스케줄러가 초기화 되기 전에, 그리고 하나 이상의 CPU가 동작하기 전에 호출됩니다.

RCU_DATA_PTR_INIT() 매크로는 rcpu_state 구조체로의 포인터와 rcpu_data per-CPU 변수의 집합의 이름을 인자로 받습니다. 이 매크로는 per-CPU rcpu_data 구조체들을 스캔하고, 각 rcpu_data 구조체의 ->mynode 포인터가 연관된 leaf rcpu_node 구조체를 가리키도록 값을 할당합니다. 이 매크로는 또한 명시된 rcpu_state 구조체의 ->rda[] 배열을 그 원소들이 각각 연관된 rcpu_data 구조체를 가리키도록 값을 채웁니다. Line 3 은 첫번째 leaf rcpu_node 구조체로의 포인터를 (이 매크로의 호출자에 의해 선언되어야만 하는) 지역 변수 rnp에 넣고, line 4 는 연관된 leaf-node 숫자인 지역 변수 j를 0으로 할당합니다. Line 5-10 으로 구성되는 루프의 각 단계에서는 연관된 (NR_CPUS로 명시된) 잠재적 CPU들의 초기화를 수행합니다. 이 루프 안에서, line 6 는 우리가 현재 leaf rcpu_node 구조체의

한계를 넘어 움직였는지 체크하고, 만약 그렇다면 line 7에서 다음 구조체로 진행합니다. 그리고 나서는, 여전히 루프 안에서, line 8 은 현재 CPU의 rcpu_data 구조체의 ->mynode 포인터가 현재 leaf rcpu_node 구조체를 가리키도록 만들고, line 9 는 현재 CPU의 (rcpup_state 구조체 안의) ->rda[] 원소가 현재 CPU의 rcpu_data 구조체를 가리키도록 만듭니다.

Quick Quiz D.34: C-preprocessor 매크로는 너무 1990년대 스러워요! 왜 요즘 시대에 걸맞게 Figure D.29의 RCU_DATA_PTR_INIT()을 함수로 바꾸지 않는거죠?

■
 __rcu_init() 함수는 먼저 line 19에서 rcpup_state 구조체를 가지고 rcpu_init_one()을 호출하고, 이어서 이 rcpup_state 구조체와 per-CPU 변수들의 rcpu_data 집합을 가지고 RCU_DATA_PTR_INIT()을 호출합니다. Line 21-22에서는 이를 rcpu_bh_state 와 rcpu_bh_data에 대해 반복합니다. Line 24-26에 걸쳐진 루프는 현재 online인 각 CPU에 대해 rcpu_cpu_notify()를 호출하고, line 27 은 CPU가 online이 될 때마다, RCU에게 그 존재를 알리기 위해 rcpu_cpu_notify()가 호출되도록 알림을 설정합니다.

Quick Quiz D.35: Figure D.29의 line 25-26에서 online CPU가 마지막으로 알려졌을 때와 line 27에서 register_cpu_notifier()가 호출된 시점 사이에서 어떤 CPU가 online이 되면 어떤 일이 벌어지나요? ■

rcpup_cpu_notify() 과 연관된 함수들은 뒤의 Section D.3.4에서 더 이야기 하겠습니다.

D.3.4 CPU Hotplug

다음 섹션들에서 설명하는 CPU-hotplug 함수들은 어떤 CPU들이 현재 존재하고 어떤 CPU들은 존재하지 않는지를 RCU가 추적할 수 있게 해주면서, 또한 각 CPU가 online이 될 때 각 CPU의 rcpu_data 구조체를 초기화합니다.

D.3.4.1 rcpu_init_percpu_data()

Figure D.30 는 rcpu_init_percpu_data()의 코드를 보이는데, 이 함수는 부팅 때 또는 특정 CPU가 online이 될 때 특정 CPU의 rcpu_data 구조체를 초기화 합니다. 이 함수는 또한 이 CPU가 다음 grace period에 참여할 수 있도록 rcpu_node 계층을 설정합니다.

Line 8은 명시된 rcpup_state 구조체를 기반으로 이 CPU의 rcpu_data 구조체로의 포인터를 가져오고, 이 포인터를 로컬 변수 rdp에 넣습니다. Line 9는 명시된 rcpup_state 구조체를 위한 루트 rcpu_node 구조체로의 포인터를 가져와서 로컬 변수 rnp에 넣습니다.

Line 11-29는 rcpu_data 구조체의 필드들을 일관성 있는 값을 보장하기 위해 루트 rcpu_node 구조체의 락을

```

1 static void
2 rcu_init_percpu_data(int cpu, struct rcu_state *rsp)
3 {
4     unsigned long flags;
5     int i;
6     long lastcomp;
7     unsigned long mask;
8     struct rcu_data *rdp = rsp->rda[cpu];
9     struct rcu_node *rnp = rcu_get_root(rsp);
10
11    spin_lock_irqsave(&rnp->lock, flags);
12    lastcomp = rdp->completed;
13    rdp->completed = lastcomp;
14    rdp->gpnun = lastcomp;
15    rdp->passed_quiesc = 0;
16    rdp->qs_pending = 1;
17    rdp->beenonline = 1;
18    rdp->passed_quiesc_completed = lastcomp - 1;
19    rdp->grpmask = 1UL << (cpu - rdp->mynode->grplo);
20    rdp->nxtlist = NULL;
21    for (i = 0; i < RCU_NEXT_SIZE; i++)
22        rdp->nxttail[i] = &rdp->nxtlist;
23    rdp->qlen = 0;
24    rdp->blimit = blimit;
25 #ifdef CONFIG_NO_HZ
26    rdp->dynticks = &per_cpu(rcu_dynticks, cpu);
27 #endif /* #ifdef CONFIG_NO_HZ */
28    rdp->cpu = cpu;
29    spin_unlock(&rnp->lock);
30    spin_lock(&rsp->onofflock);
31    rnp = rdp->mynode;
32    mask = rdp->grpmask;
33    do {
34        spin_lock(&rnp->lock);
35        rnp->qsmaskinit |= mask;
36        mask = rnp->grpmask;
37        spin_unlock(&rnp->lock);
38        rnp = rnp->parent;
39    } while (rnp != NULL && !(rnp->qsmaskinit & mask));
40    spin_unlock(&rsp->onofflock);
41    cpu_quiet(cpu, rsp, rdp, lastcomp);
42    local_irq_restore(flags);
43 }

```

Figure D.30: rcu_init_percpu_data() Code

로 보호하면서 초기화 합니다. Line 17은 tracing을 위해 중요한데, 많은 리눅스 배포판들이 NR_CPUS를 매우 큰 수로 설정해서 rcu_data 구조체를 trace 할 때 지나치게 많은 출력력을 초래할 수 있기 때문입니다. 이 문제를 해결하기 위해 ->beenonline 필드가 사용되는데, 이 필드는 이미 online이 된 CPU에 rcu_data 구조체가 연관될 때 값을 1로 설정하고, 그 외의 모든 다른 rcu_data 구조체들을 위한 부분은 0으로 설정됩니다. 이는 tracing 코드가 불필요한 CPU들을 쉽게 무시할 수 있도록 해줍니다.

Line 30-40은 online이 되는 CPU의 bit을 rcu_node 계층으로 전파하는데, 루트 rcu_node에 도달하거나 연관된 bit이 이미 값 설정되어 있거나 할 때까지 전파됩니다. 이 bit-setting은 새로운 grace period의 초기화를 배제하기 위해 ->onofflock의 보호 아래 이루어지고, 추가적으로, 각 rcu_node 구조체도 이 락의 보호 아래 초기화 됩니다. 이어서 line 41은 RCU에게 이 CPU가

```

1 static void __cpuinit rcu_online_cpu(int cpu)
2 {
3 #ifdef CONFIG_NO_HZ
4     struct rcu_dynticks *rdtp;
5
6     rdtp = &per_cpu(rcu_dynticks, cpu);
7     rdtp->dynticks_nesting = 1;
8     rdtp->dynticks |= 1;
9     rdtp->dynticks_nmi = (rdtp->dynticks_nmi + 1) & ~0x1;
10 #endif /* #ifdef CONFIG_NO_HZ */
11    rcu_init_percpu_data(cpu, &rcu_state);
12    rcu_init_percpu_data(cpu, &rcu_bh_state);
13    open_softirq(RCU_SOFTIRQ, rcu_process_callbacks);
14 }

```

Figure D.31: rcu_online_cpu() Code

extended quiescent state에 있었음을 알리는 신호를 주기 위해 cpu_quiet()를 호출하고 마지막으로 line 42에서 irq들을 다시 활성화 시킵니다.

Quick Quiz D.36: Figure D.30의 line 41에서는, 우리가 다양한 락들을 사용해 grace period들을 배제시켰음에도, 그리고 모든 앞서 존재한 grace period들은 이 기준에 offline이 된 CPU들을 기다리지 않을 것임에도, 왜 cpu_quiet()를 호출하는거죠? ■

rcu_init_percpu_data()가 부팅될 때만 호출되는데 아니라, 특정 CPU가 online이 될 때마다 매번 호출된다는 점을 기억해 두시기 바랍니다.

D.3.4.2 rcu_online_cpu()

Figure D.31은 RCU에게 특정 CPU가 online이 되는 것을 알리는 rcu_online_cpu()의 코드를 보이고 있습니다.

Dynticks (CONFIG_NO_HZ)가 활성화 되어 있으면, line 6은 명시된 CPU의 rcu_dynticks 구조체로의 레퍼런스를 얻어오는데, 이 구조체는 RCU의 “rcu”와 “rcu_bh” 구현 사이에 공유됩니다. Line 7은 ->dynticks_nesting 필드의 값을 1로 설정해서 새로 online이 되는 CPU가 dynticks-idle 모드에 있지 않다는 사실을 반영시킵니다 (다시 말하건대 ->dynticks_nesting 필드는 연관된 CPU가 RCU read-side 크리티컬 섹션들을 추적해야 하는 필요의 이유들의 수를 추적하며, 이 경우에는 process-level 코드를 수행할 수 있기 때문입니다). Line 8은 ->dynticks 필드는 허수의 값으로 강제하는데, 이 값은 최소한 기준에 online이었을 때의 마지막 값만큼은 커야 하는데, 역시 새로 online이 된 CPU들이 dynticks-idle 모드에 있지 않다는 사실을 반영하는 것이며, line 9는 ->dynticks_nmi 필드를 짹수의 값으로 강제하는데, 이 값은 기준에 online이었을 때 가졌던 마지막 값만큼은 큰 값으로, 이 CPU가 현재 NMI 핸들러 안에서 실행되고 있다는 사실을 반영합니다.

```

1 static void
2 __rcu_offline_cpu(int cpu, struct rcu_state *rsp)
3 {
4     int i;
5     unsigned long flags;
6     long lastcomp;
7     unsigned long mask;
8     struct rcu_data *rdp = rsp->rda[cpu];
9     struct rcu_data *rdp_me;
10    struct rcu_node *rnp;
11
12    spin_lock_irqsave(&rsp->onofflock, flags);
13    rnp = rdp->mynode;
14    mask = rdp->grpmask;
15    do {
16        spin_lock(&rnp->lock);
17        rnp->qsmaskinit &= ~mask;
18        if (rnp->qsmaskinit != 0) {
19            spin_unlock(&rnp->lock);
20            break;
21        }
22        mask = rnp->grpmask;
23        spin_unlock(&rnp->lock);
24        rnp = rnp->parent;
25    } while (rnp != NULL);
26    lastcomp = rdp->completed;
27    spin_unlock(&rsp->onofflock);
28    cpu_quiet(cpu, rsp, rdp, lastcomp);
29    rdp_me = rdp->rda[smp_processor_id()];
30    if (rdp->nxtlist != NULL) {
31        *rdp_me->nxttail[RCU_NEXT_TAIL] = rdp->nxtlist;
32        rdp_me->nxttail[RCU_NEXT_TAIL] =
33            rdp->nxttail[RCU_NEXT_TAIL];
34        rdp->nxtlist = NULL;
35        for (i = 0; i < RCU_NEXT_SIZE; i++)
36            rdp->nxttail[i] = &rdp->nxtlist;
37        rdp_me->qlen += rdp->qlen;
38        rdp->qlen = 0;
39    }
40    local_irq_restore(flags);
41 }
42
43 static void rcu_offline_cpu(int cpu)
44 {
45     __rcu_offline_cpu(cpu, &rcu_state);
46     __rcu_offline_cpu(cpu, &rcu_bh_state);
47 }

```

Figure D.32: `rcu_offline_cpu()` Code

Line 11-13 은 CONFIG_NO_HZ 커널 패러미터의 값과 관계 없이 수행됩니다. Line 11은 명시된 CPU의 “rcu”를 위한 `rcu_data` 구조체를 초기화 하며, line 12는 “rcu_bh”를 위해 같은 일을 행합니다. 마지막으로, line 13은 이 CPU의 뒤따르는 `raise_softirq()` 호출에 의해 `rcu_process_callbacks()` 가 호출되도록 등록합니다.

D.3.4.3 `rcu_offline_cpu()`

Figure D.32는 `__rcu_offline_cpu()` 와 그 wrapper 함수인 `rcu_offline_cpu()`의 코드를 보입니다. 이 (그림의 line 43-47에 보인) wrapper 함수의 목적은 단순히 `__rcu_offline_cpu()` 를 두번, 한번은 “rcu”를

위해 그리고 “rcu_bh”를 위해 호출하는 것 뿐입니다. `__rcu_offline_cpu()` 함수의 목적은 미래의 grace period 가 offline 이 된 CPU를 기다리는 것을 방지하는 것, extended quiescent state 를 알리는 것, 그리고 이 CPU에서 처리중인 모든 RCU callback 이 새로 위치해야 할 곳을 찾는 것입니다.

그림의 line 1-41에 보여진 `__rcu_offline_cpu()`로 돌아가서, line 12는 명시된 `rcu_state`의 `->onofflock`을 획득해서 여러 `rcu_node` 계층을 위한 grace-period 초기화를 배제시킵니다.

Quick Quiz D.37: 하지만 작은 시스템이어서 `rcu_node` 계층이 하나의 구조체만을 갖는다면 어떻게 되나요? Figure D.32의 코드에서, 이 경우에 무엇이 동시의 grace-period 초기화를 방지하나요? ■

Line 13은 이 CPU의 `rcu_data` 구조체의 `->mynode` 포인터를 사용해서 이 CPU에 연관된 leaf `rcu_node` 구조체로의 포인터를 가져옵니다 (Figure D.26를 참고하세요). Line 14는 이 CPU의 leaf `rcu_node` 구조체의 `qsmask` 필드에 사용할 `mask`를 가져옵니다.

이어서 line 15-25의 루프는 이 CPU의 bit들을 이 CPU의 leaf `rcu_node` 구조체부터 시작해서 `rcu_node` 계층을 위로 따라가며 지워갑니다. Line 16은 현재 `rcu_node` 구조체의 `->lock` 필드를 획득하고, line 17에서는 이 CPU에 (또는, 계층의 위로 가면 그룹에) 연관된 bit을 `->qsmaskinit` 필드로부터 지워서 미래의 grace period를 이 CPU로부터의 quiescent state를 기다리지 않도록 만듭니다. 그 결과 `->qsmaskinit`의 값이 line 18에서 체크되는 것처럼 0이 아니라면, 현재 `rcu_node` 구조체는 추적해야만 하는 online CPU들을 갖고 있다는 것이고, 따라서 line 19에서 현재 `rcu_node` 구조체의 `->lock`을 해제하고 line 20에서 루프를 빠져나갑니다. 그렇지 않다면, 우리는 `rcu_node` 계층을 따라 진행해야 합니다. 이 경우, line 22는 다음 단계에 적용할 `mask`를 가져오고 line 23에서 현재 `rcu_node` 구조체의 `->lock`을 해제한 후, line 24에서 이 계층의 다음 레벨로 넘어갑니다. Line 25는 루프를 나가는 데, 이 계층의 꼭대기에서 일 겁니다.

Quick Quiz D.38: 하지만 Figure D.32의 line 25가 정말로 이 루프를 끝낼까요? 그렇다면, 또는 그렇지 않다면 왜죠? ■

Line 26은 명시된 `rcu_state` 구조체의 `->completed` 필드를 로컬 변수 `lastcomp`로 가져오고, line 27은 `->onofflock`을 해제하고 (하지만 irq는 비활성화 된 채로 됩니다), line 28은 offline 이 되는 CPU가 이제 extended quiescent state에 있음을 알리고, 이 quiescent state를 자신이 시작된 곳이 아니라 다른 grace period에게 보고하는 것을 막기 위해 `lastcomp`를 넘기는 `cpu_quiet()` 함수를 호출합니다.

Quick Quiz D.39: Figure D.32의 line 26이 상당히

비순차적으로 수행되어서 `lastcomp`는 어떤 앞의 grace period로 설정되어 있지만 현재 grace period는 여전히 이제 offline이 된 CPU를 기다리고 있다고 생각해 봅시다. 이런 경우, `cpu_quiet()` 호출은 이 quiescent state를 보고하는데 실패하고, 따라서 이 grace period가 이 이제는 offline이 된 CPU를 영원히 기다리게 되지 않을까요? ■

Quick Quiz D.40: Offline CPU가 extended quiescent state에 있음에도, 왜 Figure D.32의 line 28은 자신이 어떤 grace period를 처리하고 있는지 신경써야 하는거죠? ■

Line 29-39는 offline이 되는 CPU의 모든 RCU 콜백들을 현재 돌아가는 CPU로 옮깁니다. 이 작업은 옮겨지는 콜백들의 순서를 재배치하는 걸 막아야 하는데, 그러지 않는다면 `rcu_barrier()`가 올바르게 동작하지 못할 것이기 때문입니다. Line 29는 현재 동작 중인 CPU의 `rcu_data` 구조체로의 포인터를 로컬 변수 `rdp_me`로 가져옵니다. Line 30은 이어서 offline이 되는 CPU가 어떤 RCU 콜백들을 가지고 있는지 체크해 봅니다. 만약 그렇다면, line 31-38에서 그것들을 옮깁니다. Line 31은 콜백들의 리스트를 수행중인 CPU의 리스트의 끝에 이어붙입니다. Line 32-33은 수행중인 CPU의 콜백 tail 포인터를 offline이 되는 CPU의 그것으로 바꿔치기하고, 이어서 line 34-36에서 offline이 되는 CPU의 리스트를 텅비도록 초기화 합니다. Line 37은 offline이 되는 CPU의 콜백 리스트의 길이를 현재 수행중인 CPU의 그것에 더하고, 마지막으로 line 38에서 offline이 되는 CPU의 리스트의 길이를 0으로 설정합니다.

Quick Quiz D.41: 하지만 Figure D.32의 이 리스트 이동은 모든 offline이 되는 CPU의 콜백들이 설령 호출될 준비가 되어 있는 상태였을지라도 다른 grace period로 가도록 만듭니다. 이건 비효율적이지 않나요? 뿐만 아니라, offline이 되고는 online으로 돌아오는 CPU들의 불행한 패턴은 특정 콜백이 영원히 호출되지 않게 할 수 있지 않나요? ■

마지막으로, line 40은 irq들을 재활성화 시킵니다.

D.3.5 Miscellaneous Functions

이 섹션은 다음의 기타 기능을 제공하는 함수들을 설명합니다:

1. `rcu_batches_completed`
2. `rcu_batches_completed_bh`
3. `cpu_has_callbacks_ready_to_invoke`
4. `cpu_needs_another_gp`
5. `rcu_get_root`

```

1 long rcu_batches_completed(void)
2 {
3     return rcu_state.completed;
4 }
5
6 long rcu_batches_completed_bh(void)
7 {
8     return rcu_bh_state.completed;
9 }
10
11 static int
12 cpu_has_callbacks_ready_to_invoke(struct rcu_data *rdp)
13 {
14     return &rdp->nxtlist != rdp->nxttail[RCU_DONE_TAIL];
15 }
16
17 static int
18 cpu_needs_another_gp(struct rcu_state *rsp,
19                         struct rcu_data *rdp)
20 {
21     return *rdp->nxttail[RCU_DONE_TAIL] &&
22            ACCESS_ONCE(rsp->completed) ==
23            ACCESS_ONCE(rsp->gpnum);
24 }
25
26 static struct rcu_node
27 *rcu_get_root(struct rcu_state *rsp)
28 {
29     return &rsp->node[0];
30 }

```

Figure D.33: Miscellaneous Functions

Figure D.33는 몇가지 기타 함수들을 보이고 있습니다. Line 1-9는 `rcu_batches_completed()`와 `rcu_batches_completed_bh()`를 보이는데, 이 함수들은 rcutorture test suite에 의해 사용됩니다. Line 11-15는 `cpu_has_callbacks_ready_to_invoke()` 함수를 보이는데, 이 함수는 명시된 `rcu_data` 구조체가 grace period가 지난 RCU 콜백들을 가지고 있는지를 알리는 데, 이는 리스트의 헤드를 더이상 향하지 않는 “done” tail 포인터에 의해 알려집니다. Line 17-24는 명시된 `rcu_data` 구조체에 연관된 CPU가 어떤 grace period도 진행중이지 않은 시간 동안 추가적인 grace period를 필요로 하는지 알리는 `cpu_needs_another_gp()` 함수를 보이고 있습니다. 이 명시된 `rcu_data` 구조체는 명시된 `rcu_state` 구조체와 연관되어 있어야 한다는 점을 알아두시기 바랍니다. 마지막으로, line 26-30은 명시된 `rcu_state` 구조체에 연관된 root `rcu_node` 구조체를 리턴하는 `rcu_get_root()` 함수를 보입니다.

D.3.6 Grace-Period-Detection Functions

이 섹션은 grace period들의 시작과 끝을 탐지하는데 직접적으로 관계된 함수들을 다룹니다. 물론 이는 grace period들을 실제로 시작하고 끝내는 것이 포함되며, 다른 CPU들이 grace period들을 시작하고 끝낸 시점을 알리는 것도 포함됩니다.

```

1 static void note_new_gpnum(struct rcu_state *rsp,
2                             struct rcu_data *rdp)
3 {
4     rdp->qs_pending = 1;
5     rdp->passed_quiesc = 0;
6     rdp->gpnum = rsp->gpnum;
7     rdp->n_rcu_pending_force_qs = rdp->n_rcu_pending +
8         RCU_JIFFIES_TILL_FORCE_QS;
9 }
10
11 static int
12 check_for_new_grace_period(struct rcu_state *rsp,
13                             struct rcu_data *rdp)
14 {
15     unsigned long flags;
16     int ret = 0;
17
18     local_irq_save(flags);
19     if (rdp->gpnum != rsp->gpnum) {
20         note_new_gpnum(rsp, rdp);
21         ret = 1;
22     }
23     local_irq_restore(flags);
24     return ret;
25 }

```

Figure D.34: Noting New Grace Periods

D.3.6.1 Noting New Grace Periods

Hierarchical RCU 의 주요 목적은 grace period 들을 탐지하는 것이고, 이 작업에 더 직접적으로 관련된 함수들이 이 섹션에서 설명되어집니다. Section D.3.6.1 은 CPU 들이 새로운 grace period 가 시작되었음을 CPU 들이 알 수 있게 해주는 함수를 다루고, Section D.3.6.2 은 새로운 grace period 를 시작하는 `rcu_start_gp()` 를 다루며, Section D.3.6.4 에서는 CPU 의 quiescent state 를 RCU core 에 알리는데 관련된 함수들을 다룹니다.

Figure D.34 는 `note_new_gpnum()` 함수를 보이고 있는데, 이 함수는 새로운 grace period 를 반영하기 위한 상태 업데이트를 행합니다. 또한 `check_for_new_grace_period()` 함수를 보이는데, 이 함수는 언제 다른 CPU 들이 새로운 grace period 를 시작했는지 파악하는데에 사용됩니다.

`note_new_gpnum()` 의 Line 4 는 RCU 가 이 CPU 의 quiescent state 를 필요로 함을 알리기 위해 현재 CPU 의 `rcu_data` 구조체의 `->qs_pending` 플래그의 값을 1로 세우고, line 5 는 이 CPU 가 그런 quiescent state 를 아직 지나지 않았다는 것을 알리기 위해 `->passed_quiesc` 플래그의 값을 0으로 설정하며, line 6 는 grace-period 숫자를 global `rcu_state` 구조체로부터 이 CPU 의 `rcu_data` 구조체로 복사해서 이 CPU 가 이 새로운 grace period 의 시작을 알렸음을 기억할 수 있게 합니다. 마지막으로, line 7-8 은 이 CPU 가 치연되어있는 CPU 들이 quiescent state 들을 지나도록 강제하려 시도할 시간을 jiffies 로 기록하는데 (이 시간에 또는 이 시간 후에 `force_quiescent_state()` 를 호출함으로써 강제할

```

1 static void
2 rcu_process_gp_end(struct rcu_state *rsp,
3                     struct rcu_data *rdp)
4 {
5     long completed_snap;
6     unsigned long flags;
7
8     local_irq_save(flags);
9     completed_snap = ACCESS_ONCE(rsp->completed);
10    if (rdp->completed != completed_snap) {
11        rdp->nxttail[RCU_DONE_TAIL] =
12            rdp->nxttail[RCU_WAIT_TAIL];
13        rdp->nxttail[RCU_WAIT_TAIL] =
14            rdp->nxttail[RCU_NEXT_READY_TAIL];
15        rdp->nxttail[RCU_NEXT_READY_TAIL] =
16            rdp->nxttail[RCU_NEXT_TAIL];
17        rdp->completed = completed_snap;
18    }
19    local_irq_restore(flags);
20 }

```

Figure D.35: Noting End of Old Grace Periods

겁니다) 이 전에 grace period 가 끝나지 않는 가정 하에 그렇습니다.

`check_for_new_grace_period()` 의 line 18 과 23 은 각각 인터럽트를 비활성화 하고 재활성화 합니다. Line 19 는 현재 CPU 가 알지 못한 새로운 grace period 가 존재하는지 보고, 만약 그렇다면 line 20 은 이 새로운 grace period 를 알리기 위해 `note_new_gpnum()` 을 호출하고, line 21 은 적절하게 리턴 값 을 설정합니다. 어느 쪽이든, line 24 는 상태를 리턴합니다: 새로운 grace period 가 시작했다면 0이 아닌 값을, 그렇지 않으면 0 입니다.

Quick Quiz D.42: Figure D.34 의 `check_for_new_grace_period()` 안에 `note_new_gpnum()` 을 그대로 집어넣지 않나요? ■

D.3.6.2 Noting End of Old Grace Periods

Figure D.35 는 CPU 가 하나의 grace period 가 끝났을 거라 의심할 때에 (해당 CPU 가 실제로 grace period 를 끝냈거나 해서) 호출되는 `rcu_process_gp_end()` 함수가 보여져 있습니다. 만약 하나의 grace period 가 정말로 끝났다면, 이 함수는 현재 CPU 의 RCU 콜백들을 진행시키는데, 이 콜백들은 Figure D.36 에 보여진 것처럼 여러개의 tail 포인터들을 가진 singly linked list 로 관리되어집니다. 이 여러개의 tail pointer 형태는 Lai Jiangshan 에 의해 이루어졌으며 리스트 관리를 단순화 시킵니다 [Jia08]. 이 그림에서, 파란 네모는 한 CPU 의 `rcu_data` 구조체를 나타내며, 다이어그램 바닥의 여섯개의 하얀 네모는 여섯개의 RCU 콜백들 (`rcu_head` 구조체) 의 리스트를 나타냅니다. 이 리스트에서, 앞의 세개의 콜백들은 각자의 grace period 를 이미 지났고 따라서 수행되어지길 기다리고 있으며, 네번째 콜백(두




Figure D.36: RCU Callback List

번재 줄의 첫번째 것)은 현재 grace period 가 완료되고 기다리고 있으며, 마지막 두개의 콜백은 다음 grace period 를 기다리고 있습니다. 마지막 두개의 tail pointer 들은 마지막 원소를 가리키며, 따라서 아직 특정 grace period 에 관계되지 않은 콜백들을 가지고 있는 마지막 sublist 는 비어있습니다.

Figure D.35 의 line 8 과 19 는 각각 인터럽트를 비활성화 / 재활성화 시킵니다. Line 9 는 rCU_state 구조체의 ->completed 필드를 가져오고, 그걸로컬 변수 completed_snap 에 저장해 둡니다. Line 10 은 현재 CPU 가 grace period 의 끝을 알고 있지 못한지 체크해 보고, 만약 알고 있지 못하다면, line 11-16 은 이 CPU 의 RCU 콜백들을 tail 포인터들을 조정해서 진행시킵니다. 이어서 Line 17 은 가장 최근에 완료된 grace period 의 숫자를 ->completed 필드의 이 CPU 의 rCU_data 구조체에 기록합니다.

D.3.6.3 Starting a Grace Period

Figure D.37 는 새로운 grace period 를 시작하고, 호출자에 의해 획득되어져 있어야만 하는 root rCU_node 구조체의 락을 해제하는 rCU_start_gp() 함수를 보입니다.

Line 3 는 sparse 도구를 위한 주석으로, rCU_start_gp() 가 root rCU_node 구조체의 락을 해제한다는 것을 알립니다. 지역변수 rdp 는 수행중인 CPU 의 rCU_data 구조체를 가리키고, rnp 는 root rCU_node 구조체를 가리키며, rnp_cur 와 rnp_end 는 rCU_node 계층을 획단하는데 커서로 사용됩니다.

Line 10 은 이 CPU 가 정말로 또다른 grace period

```

1 static void
2 rCU_start_gp(struct rCU_state *rsp, unsigned long flags)
3   __releases(rCU_get_root(rsp)->lock)
4 {
5   struct rCU_data *rdp = rsp->rda[smp_processor_id()];
6   struct rCU_node *rnp = rCU_get_root(rsp);
7   struct rCU_node *rnp_cur;
8   struct rCU_node *rnp_end;
9
10  if (!cpu_needs_another_gp(rsp, rdp)) {
11    spin_unlock_irqrestore(&rnp->lock, flags);
12    return;
13  }
14  rsp->gpnnum++;
15  rsp->signaled = RCU_GP_INIT;
16  rsp->jiffies_force_qs = jiffies +
17    RCU_JIFFIES_TILL_FORCE_QS;
18  rdp->n_rcu_pending_force_qs = rdp->n_rcu_pending +
19    RCU_JIFFIES_TILL_FORCE_QS;
20  record_gp_stall_check_time(rsp);
21  dyntick_record_completed(rsp, rsp->completed - 1);
22  note_new_gpnnum(rsp, rdp);
23  rdp->nxttail[RCU_NEXT_READY_TAIL] =
24    rdp->nxttail[RCU_NEXT_TAIL];
25  rdp->nxttail[RCU_WAIT_TAIL] =
26    rdp->nxttail[RCU_NEXT_TAIL];
27  if (NUM_RCU_NODES == 1) {
28    rnp->qsmask = rnp->qsmaskinit;
29    spin_unlock_irqrestore(&rnp->lock, flags);
30    return;
31  }
32  spin_unlock(&rnp->lock);
33  spin_lock(&rsp->onofflock);
34  rnp_end = rsp->level[NUMBER_RCU_LVLS - 1];
35  rnp_cur = &rsp->node[0];
36  for (; rnp_cur < rnp_end; rnp_cur++) {
37    rnp_cur->qsmask = rnp_cur->qsmaskinit;
38    rnp_end = &rsp->node[NUMBER_RCU_NODES];
39    rnp_cur = rsp->level[NUMBER_RCU_LVLS - 1];
40    for (; rnp_cur < rnp_end; rnp_cur++) {
41      spin_lock(&rnp_cur->lock);
42      rnp_cur->qsmask = rnp_cur->qsmaskinit;
43      spin_unlock(&rnp_cur->lock);
44    }
45  rsp->signaled = RCU_SIGNAL_INIT;
46  spin_unlock_irqrestore(&rsp->onofflock, flags);
47 }

```

Figure D.37: Starting a Grace Period

를 시작할 필요가 있는지 알아보고, 만약 그렇지 않다면 line 11 에서 root rCU_node 구조체의 락을 해제하고 line 12 에서 리턴합니다. 이 코드 경로는 여러 CPU 들이 동시에 grace period 를 시작하려 시도해서 실행될 수도 있습니다. 이 경우에, 승리자인 하나의 CPU 만이 grace period 를 시작하고, 나머지들은 이 코드 경로를 통해 빠져나갑니다.

그렇지 않다면, line 14 에서 명시된 rCU_state 구조체의 ->gpnnum 필드의 값을 증가시켜서 새로운 grace period 의 시작을 공식적으로 표시합니다.

Quick Quiz D.43: 하지만 Figure D.37 의 line 15 까지는 초기화가 없었어요! 만약 CPU 가 새로운 grace period 를 알게 되었지만 곧바로 quiescent state 를 보고하려 하면 어떻게 되죠? 이러면 좀 혼란스러워지지 않을까요?

Line 15 는 다른 CPU 가 이 새로운 grace period 에 그 초기화가 완료되기 전에 종률로 강제하는 것을 막기 위해 `->signaled` 필드를 `RCU_GP_INIT` 으로 설정합니다. Line 16-18 은 이 새로운 grace period 에 종료를 강제할 다음 시도를 위한 스케줄을 잡는데, 첫번째는 jiffies 단위로 그리고 두번째는 `rcu_pending` 호출의 횟수 단위로입니다. 물론, 만약 그 시간 전에 이 grace period 가 자연스럽게 종료된다면, 그런 종료를 강제할 시도를 할 필요가 없어집니다. Line 20 은 더 긴 단위의 진행 체크를 위한 스케줄을 위해 `record_gp_stall_check_time()` 을 호출합니다—만약 이 grace period 가 이 시간 뒤로까지 연장된다면, 이는 에러로 취급될 겁니다. Line 22 는 이 CPU 의 `rcu_data` 구조체가 새로운 grace period 를 관리하도록 초기화 하기 위해 `note_new_gpnum()` 을 호출합니다.

Line 23-26 은 이 CPU 의 모든 콜백들을 진행시켜서 이 새로운 grace period 의 종료 시에 모두 호출될 수 있게 만듭니다. 이는 콜백들의 가속화를 표시하는데, 다른 CPU 들은 `RCU_NEXT_READY_TAIL` 배치만을 옮겨서 현재 grace period 에 의해 처리될 수 있게 합니다; `RCU_NEXT_TAIL` 은 그대신에 `RCU_NEXT_READY_TAIL` 배치로 진척되어야 할 필요가 있을 겁니다. 이 CPU 가 `RCU_NEXT_TAIL` 배치를 진척시킬 수 있는 이유는 이 CPU 가 정확히 언제 이 새로운 grace period 가 시작되는지 알기 때문입니다. 반면에, 다른 CPU 들은 새로운 grace period 의 시작과 새로운 RCU z콜백의 도착 사이의 race 를 올바르게 해결할 수 없을 겁니다.

Line 27 은 계층 상에 하나의 `rcu_node` 구조체만이 존재하는지 체크해보고, 만약 그렇다면 line 28 에서 `->qsmask` bit 들을 연관된 모든 online CPU 들, 달리 말하자면 새로운 grace period 가 종료되기 위해서는 quiescent state 를 지나야 하는 모든 CPU 들로 설정합니다. Line 29 는 root `rcu_node` 구조체의 락을 해제하고 line 30 에서 리턴합니다. 이 경우, gcc 의 dead-code elimination 이 line 32-46 에 제공될 것입니다.

그렇지 않다면, `rcu_node` 계층은 여러 구조체를 가지고 있어서 더 관여된 초기화 계획을 필요로 합니다. Line 32 는 root `rcu_node` 구조체의 락을 해제하지만, 인터럽트가 비활성화 된 채로 유지하고, 이어서 line 33 에서 명시된 `rcu_state` 구조체의 `->onofflock` 을 획득하여서 다른 동시에 수행중인 CPU-hotplug 오퍼레이션들이 RCU 에 관계된 state 를 조정하는 것을 막습니다.

Line 34 는 `rnp_end` 지역변수가 첫번째 leaf `rcu_node` 구조체를 가리키도록 설정하는데, 이 구조체는 `->node` 배열에서 마지막 non-leaf `rcu_node` 구조체를 곧바로 뒤따르는 `rcu_node` 구조체가 될수도 있습니다. Line 35 는 `rnp_cur` 지역 변수가 root `rcu_node` 구조체를 가리키도록 만드는데, 이 구조체는 `->node` 배열의

첫번째 구조체가 될수도 있습니다. Line 36 과 37 d은 이어서 모든 non-leaf `rcu_node` 구조체들을 획단하며, 이 새로운 grace period 가 종료되기 위해서는 quiescent state 들을 지나가야만 하는 CPU 들을 갖는 더 낮은 단계의 `rcu_node` 구조체들에 연관된 bit 들을 설정합니다.

Quick Quiz D.44: 이봐요! Figure D.37 의 line 37 의 non-leaf `rcu_node` 구조체의 상태 분배 시에 그 락들을 잡아야 하지 않나요??? ■

Line 38 은 지역 변수 `rnp_end` 를 마지막 leaf `rcu_node` 구조체로 설정하고, line 39 는 지역 변수 `rnp_cur` 가 첫번째 leaf `rcu_node` 구조체를 가리키도록 해서 line 40-44 의 루프가 `rcu_node` 계층의 모든 leaf 들을 획단하도록 만듭니다. 이 루프의 각 단계마다 line 41 은 현재 leaf `rcu_node` 구조체의 락을 잡고, line 42 는 (이 새로운 grace period 가 종료될 수 있기 전에 quiescent state 를 지나가야 만 하는) online CPU 들에 연관된 bit 들을 설정하고, line 43 에서 이 락을 놓습니다.

Quick Quiz D.45: Figure D.37 의 line 36-37 의 루프를 line 40-44 에 합치는 건 어떤가요? ■

이어서 line 45 는 명시된 `rcu_state` 구조체의 `->signaled` 필드를 quiescent state 강제를 허용할 수 있도록 설정하고, line 46 에서 CPU-hotplug 오퍼레이션들이 RCU 상태를 조정할 수 있도록 하기 위해 `->onofflock` 을 해제합니다.

D.3.6.4 Reporting Quiescent States

이 계층적 RCU 구현은 quiescent state 들을 보고하는데에 다음의 함수들을 사용해서 계층화된 방법을 구현합니다:

- 특정 CPU 가 quiescent state 를 지날 때마다 “rcu” 와 “rcu_bh” 를 위해 각각 `rcu_qsctr_inc()` 와 `rcu_bh_qsctr_inc()` 가 호출됩니다. Dynticks-idle 과 CPU-offline quiescent state 는 특별하게 처리되는데, 그런 CPU 는 수행 중이지 않고, 따라서 스스로가 quiescent state 에 있다고 보고할 수 없기 때문이란 걸 알아두시기 바랍니다.
- `rcu_check_quiescent_state()` 는 현재의 CPU 가 quiescent state 를 지났는지 알아보고, 만약 그렇다면 `cpu_quiet()` 를 호출합니다.
- `cpu_quiet()` 는 명시된 CPU 가 quiescent state 를 지났음을 보고하기 위해 `cpu_quiet_msk()` 를 호출합니다. 이 명시된 CPU 는 현재의 CPU 이거나 offline CPU 여야만 합니다.
- `cpu_quiet_msk()` 는 명시된 CPU 들이 quiescent state 를 지났음을 보고합니다. 이 CPU 들은 현재의 CPU 여야만 하지도, offline 이어야만 하지도 않습니다.

```

1 void rcu_qsctr_inc(int cpu)
2 {
3     struct rcu_data *rdp = &per_cpu(rcu_data, cpu);
4     rdp->passed_quiesc = 1;
5     rdp->passed_quiesc_completed = rdp->completed;
6 }
7
8 void rcu_bh_qsctr_inc(int cpu)
9 {
10    struct rcu_data *rdp = &per_cpu(rcu_bh_data, cpu);
11    rdp->passed_quiesc = 1;
12    rdp->passed_quiesc_completed = rdp->completed;
13 }

```

Figure D.38: Code for Recording Quiescent States

```

1 static void
2 rcu_check_quiescent_state(struct rcu_state *rsp,
3                             struct rcu_data *rdp)
4 {
5     if (check_for_new_grace_period(rsp, rdp))
6         return;
7     if (!rdp->qs_pending)
8         return;
9     if (!rdp->passed_quiesc)
10    return;
11    cpu_quiet(rdp->cpu, rsp, rdp,
12              rdp->passed_quiesc_completed);
13 }

```

Figure D.39: Code for rcu_check_quiescent_state()

이 함수들은 아래에 설명됩니다.

Figure D.38 는 rcu_qsctr_inc() 와 rcu_bh_qsctr_inc() 함수의 코드를 보이는데, 이 함수들은 현재 CPU 의 quiescent state 통과를 알립니다.

rcu_qsctr_inc() 의 line 3 는 명시된 CPU 의 rcu_data 구조체 (“rcu_bh”에 반대되는 “rcu”에 연관된) 로의 포인터를 얻어옵니다. Line 4 는 ->passed_quiesc 필드에 값을 할당해서 이 quiescent state 를 기록합니다. Line 5 는 ->passed_quiesc_completed 필드의 값을 이 CPU 가 알고 있는 마지막으로 완료된 grace period (rcu_data 구조체의 ->completed 필드에 저장되어 있는) 의 숫자로 할당합니다.

rcu_bh_qsctr_inc() 함수는 같은 방식으로 동작하는데, 유일한 차이점은 line 10 에서 rcu_data 포인터를 rcu_data per-CPU 변수가 아니라 rcu_bh_data per-CPU 변수로부터 가져온다는 점입니다.

Figure D.39 는 언제 다른 CPU 들이 새로운 grace period 를 시작했는지 파악하고 RCU 에게 이 CPU 를 위한 최근의 quiescent state 들을 알리기 위해 (Section D.3.2.4 에서 설명된) rcu_process_callbacks() 에서 호출되는 rcu_check_quiescent_state() 함수의 코드를 보이고 있습니다.

Line 5 는 새로운 grace period 가 어떤 다른 CPU 에 의해 시작된 것을 체크하기 위해 check_for_new_

```

1 static void
2 cpu_quiet(int cpu, struct rcu_state *rsp,
3            struct rcu_data *rdp, long lastcomp)
4 {
5     unsigned long flags;
6     unsigned long mask;
7     struct rcu_node *rnp;
8
9     rnp = rdp->mynode;
10    spin_lock_irqsave(&rnp->lock, flags);
11    if (lastcomp != ACCESS_ONCE(rsp->completed)) {
12        rdp->passed_quiesc = 0;
13        spin_unlock_irqrestore(&rnp->lock, flags);
14        return;
15    }
16    mask = rdp->grpmask;
17    if ((rnp->qsmask & mask) == 0) {
18        spin_unlock_irqrestore(&rnp->lock, flags);
19    } else {
20        rdp->qs_pending = 0;
21        rdp = rsp->rda[smp_processor_id()];
22        rdp->nxttail[RCU_NEXT_READY_TAIL] =
23            rdp->nxttail[RCU_NEXT_TAIL];
24        cpu_quiet_msk(mask, rsp, rnp, flags);
25    }
26 }

```

Figure D.40: Code for cpu_quiet()

grace_period() 를 호출하고, 또한 이 CPU 의 지역 상태를 그 새로운 grace period 를 처리할 수 있도록 업데이트 합니다. 만약 새로운 grace period 가 막 시작되었다면, line 6 는 리턴합니다. Line 7 은 RCU rk duwjsql guswo CPU 로부터의 quiescent state 를 기대하고 있는지 검사하고, 만약 그렇지 않다면 line 8 에서 리턴합니다. Line 9 는 이 CPU 가 현재 grace period 의 시작 아래로 quiescent state 를 지났는지 (달리 말하면, rcu_qsctr_inc() 또는 rcu_bh_qsctr_inc() 가 각각 “rcu” 와 “rcu_bh” 를 위해 호출되었는지) 체크하고, 만약 그렇지 않다면 line 10 에서 리턴합니다.

따라서, 앞서 알려진 grace period 가 여전히 효과를 발휘하고 있고, 이 CPU 가 이 grace period 를 끝나게 하기 위해서는 quiescent state 를 지나야 하며, 이 CPU 가 그런 quiescent state 를 지났을 경우에만 line 11 로 실행 흐름이 넘어옵니다. 이 경우, line 11-12 는 이 quiescent state 를 RCU 에 보고하기 위해 cpu_quiet() 를 호출합니다.

Quick Quiz D.46: Figure D.39 의 line 11-12 가 앞의 grace period 로부터의 quiescent state 를 현재의 grace period 에게 보고하는 것을 방지하는 건 무엇인가요? ■

Figure D.40 는 특정 CPU 를 위한 quiescent state 를 보고하는 데에 사용되는 cpu_quiet() 를 보입니다. 앞에서도 이야기 되었듯이, 이는 현재 수행중인 CPU 또는 계속해서 offline 으로 상태가 유지될 것이 보장되는 CPU 여야만 합니다.

Line 9 는 이 CPU 에 책임을 갖는 leaf rcu_node 구조체로의 포인터를 가져옵니다. Line 10 은 이 leaf rcu_node 구조체의 락을 획득하고 인터럽트를 비활성

```

1 static void
2 cpu_quiet_msk(unsigned long mask, struct rcu_state *rsp,
3                  struct rcu_node *rnp, unsigned long flags)
4  __releases(rnp->lock)
5 {
6  for (;;) {
7    if (!(rnp->qsmask & mask)) {
8      spin_unlock_irqrestore(&rnp->lock, flags);
9      return;
10   }
11   rnp->qsmask &= ~mask;
12   if (rnp->qsmask != 0) {
13     spin_unlock_irqrestore(&rnp->lock, flags);
14     return;
15   }
16   mask = rnp->grpmask;
17   if (rnp->parent == NULL) {
18     break;
19   }
20   spin_unlock_irqrestore(&rnp->lock, flags);
21   rnp = rnp->parent;
22   spin_lock_irqsave(&rnp->lock, flags);
23 }
24 rsp->completed = rsp->gpnum;
25 rcu_process_gp_end(rsp, rsp->rda[smp_processor_id()]);
26 rcu_start_gp(rsp, flags);
27 }

```

Figure D.41: Code for `cpu_quiet_msk()`

화시킵니다. Line 11은 이 명시된 grace period 가 여전히 효력을 발휘하고 있음을 분명히 하고, 만약 그렇지 않다면 line 11은 이 CPU 가 quiescent state 를 지나왔다는 알림을 제거해 버리고 (이미 효력이 없는 grace period 에 속해 있기 때문이죠), line 13은 이 락을 해제하고 인터럽트를 재활성화 시킨 후, line 14에서 호출자에게 리턴합니다.

그렇지 않다면, line 16에서 명시된 CPU 의 bit set 을 가지고 mask 를 만듭니다. Line 17에서 이 bit 이 여전히 leaf rcu_node 구조체에 있는지 확인하고, 만약 그렇지 않다면 line 18에서 락을 해제하고 인터럽트를 재활성화 시킵니다.

반면에, 만약 이 CPU 의 bit 이 여전히 존재한다면, line 20에서 `->qs_pending` 의 bit 들을 제거함으로써 이 CPU 가 이 grace period 를 위한 quiescent state 를 지났음을 반영시킵니다. Line 21에서는 지역 변수 `rdp` 를 수행중인 CPU 의 `rcu_data` 구조체로의 포인터로 덮어쓰고, line 22-23에서는 이 수행중인 CPU 의 RCU 콜백들을 업데이트해서 모든 콜백들이 다음 grace period 에 연관되지 않게 합니다. 마지막으로, line 24에서는 `rcu_node` 계층의 bit 들을 제거해서, 적절하다면 심지어 새로 시작하는 것이라도 현재의 grace period 를 종료시킵니다. `cpu_quiet()` 는 락을 해제하고 인터럽트를 재활성화 시킴을 알아두시기 바랍니다.

Quick Quiz D.47: Figure D.40 의 line 22-23 은 수행중인 CPU 의 RCU 콜백들을 촉진시켜도 안전함을 아는 거죠? ■

Figure D.41 는 CPU 들의 quiescent state 동안의, 인자 `mask` 에 의해 알려지는 통과를 `rcu_node` 계층에 반영시키는 `cpu_quiet_msk()` 를 보이고 있습니다. 인자 `rnp` 는 명시된 CPU 들에 연관된 leaf `rcu_node` 구조체임을 알아 두시기 바랍니다.

Quick Quiz D.48: Figure D.41 의 line 2 의 인자 `mask` 는 `unisgned long` 인데, 이게 어떻게 64 개 이상의 CPU 들을 갖는 시스템들을 다룰 수 있겠습니까? ■

Line 4는 `sparse` 를 위한 주석으로, `cpu_quiet_msk()` 가 leaf `rcu_node` 구조체의 락을 해제함을 알립니다.

Line 6-23의 루프의 각 단계는 `rcu_node` 계층의 한 단계씩을 처리하는데, Figure D.42의 파란 화살표로 보여진 것처럼 데이터 구조체들을 횡단합니다.

Line 7은 `mask` 의 모든 bit 들이 현재 `rcu_node` 구조체의 `->qsmask` 필드에 지워져 있는지 확인하고, 만약 그렇다면, line 8에서 이 락을 해제하고 인터럽트를 재활성화 시킨 후, line 9에서 호출자에게 리턴합니다. 만약 그렇지 않다면, line 11은 `mask` 로 명시된 bit 들을 현재의 `rcu_node` 구조체의 `qsmask` 필드로부터 지웁니다. Line 12는 이어서 `->qsmask` 에 더 남아 있는 bit 이 있는지 보고, 만약 그렇다면 line 13에서 그 락을 해제하고 인터럽트를 재활성화 한 후, line 14에서 호출자에게 리턴합니다.

그렇지 않다면, `rcu_node` 계층의 다음 단계로 넘어갈 필요가 있습니다. 이 다음 단계로 가기 위한 준비 단계로, line 16에서는 현재의 `rcu_node` 구조체에 그 부모로부터 연관되는 하나의 bit 을 설정한 `mask` 를 준비합니다. Line 17은 실제로 현재 `rcu_node` 구조체의 부모가 존재하는지 알아보고, 만약 그렇지 않다면, line 18은 이 루프를 깨고 나갑니다. 반대로, 부모 `rcu_node` 구조체가 존재한다면 line 20에서는 현재 `rcu_node` 구조체의 락을 해제하고 line 21에서 `rnp` 지역 변수를 부모로 전환시키고, line 22에서 부모의 락을 잡습니다. 실행 흐름은 이어서 line 7의 루프의 시작점으로 돌아갑니다.

Line 18이 루프를 깬다면, 우린 현재의 grace period 가 끝났음을 알게 되는데, root `rcu_node` 구조체의 모든 bit 들이 지워질 수 있는 유일한 방법은 모든 CPU 들이 quiescent state 를 지났을 때이기 때문입니다. 이 경우에, line 24는 `rcu_state` 구조체의 `->complted` 필드를 새로이 끝난 grace period 의 숫자에 맞도록 업데이트해서, 해당 grace period 가 실제로 끝났음을 알립니다. Line 24는 이어서 수행중인 CPU 의 RCU 콜백들을 전행시키기 위해 `rcu_process_gp_end()` 를 실행하고, 마지막으로 line 26은 새로운 grace period 를 시작하기 위해 `rcu_start_gp()` 를 실행합니다.

Figure D.43는 grace period 가 끝난 RCU 콜백들을 호출하는 `rcu_do_batch()` 함수를 보입니다. 수행중인 CPU 위에서의 콜백들만이 호출됩니다—다른 CPU

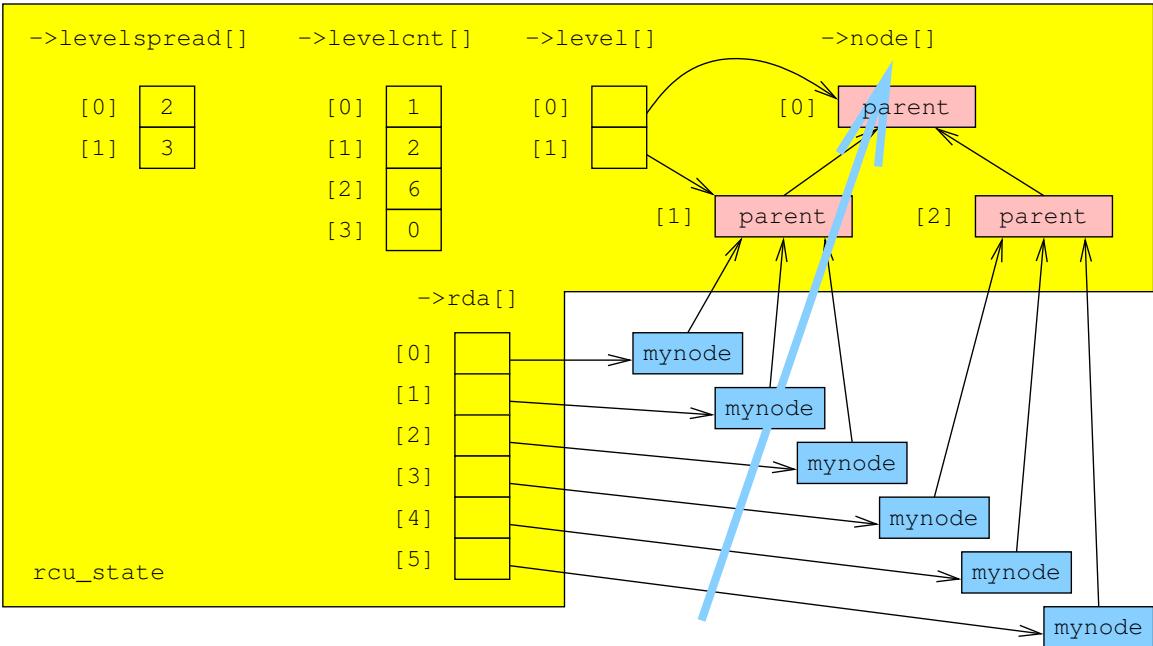


Figure D.42: Scanning `rcu_node` Structures When Applying Quiescent States

들은 각자의 콜백들을 호출해야만 합니다.

Quick Quiz D.49: Dynticks-idle이나 offline CPU들에 있는 RCU 콜백들은 어떻게 호출되나요? ■

Line 7은 이 CPU가 grace period가 종료된 RCU 콜백들을 가지고 있는지 보기 위해 `cpu_has_callbacks_ready_to_invoke()`을 호출하고, 만약 그렇지 않다면 line 8에서 리턴합니다. Line 9와 18은 인터럽트를 각각 비활성화시키고 재활성화 시킵니다. Line 11-13은 호출될 준비가 된 콜백들을 `->nxtlist`에서 제거하고, line 14-17은 tail 포인터에 모든 필요한 조정을 가합니다.

Quick Quiz D.50: Figure D.43의 line 14-17은 왜 tail 포인터를 조정하는 거죠? ■

Line 19는 실제로 호출될 콜백의 수를 셀 준비를 위해 `count`로 `cnt` 변수를 0으로 초기화 합니다. Line 20-27의 루프의 각 단계는 콜백을 수행하고 그 수를 세는데, line 25-26은 너무 많은 콜백들이 한번에 호출될 예정이면 이 루프를 빠져나갑니다(이렇게 함으로써 반응성을 지킵니다). 이 함수의 나머지 부분은 이 한계로 인해 실행될 수 없는 모든 콜백들을 대기열에 다시 집어넣습니다.

Line 28과 41은 각각 인터럽트를 비활성화시키고 재활성화 시킵니다. Line 29는 이 CPU의 RCU 콜백들의 전체 갯수를 갖는 `->qlen` 필드를 업데이트 합니다. Line 30은 원래 수행될 수 있었으나 그때에 수행될 수 있는 콜백 갯수의 제한 문제로 수행되지 못한, 호출될

준비가 된 콜백들의 갯수를 체크합니다. 만약 그런 콜백들이 있다면, line 30-38은 그것들을 다시 대기열에 넣고, 다시 tail 포인터들을 필요한대로 조정합니다. Line 39-40은 만약 한번에 수행할 콜백 개수의 한계가 지나친 콜백 backlog로 증가했다면 다시 복구하고, line 42-43은 남아있는 호출될 준비가 된 콜백들이 존재한다면 스케줄 될 추가적인 RCU 처리를 행합니다.

D.3.7 Dyntick-Idle Functions

이 섹션의 함수들은 리눅스 커널의 `CONFIG_NO_HZ` 빌드에서만 정의되는데, 일부 경우에는 `extended-no-op` 버전들이 존재하긴 합니다. 이 함수들은 RCU가 특정 CPU에게 관심을 기울일지 안기울일지를 조정합니다. Dynticks-idle 모드의 CPU들은 무시됩니다만, 그것들이 현재 인터럽트나 NMI 핸들러 안에 있지 않을 때 뛰어옵니다. 이 섹션의 함수들은 이 CPU의 RCU로의 상태를 소통합니다.

이 함수들의 집합은 Preemptible RCU에서 사용되었던 것들에 비해 상당히 단순화되어 있는데, 앞의 더 복잡한 모델에 대한 설명을 위해선 Section 12.1.5를 참고하시기 바랍니다. Manfred Spraul은 이 단순화된 인터페이스를 위한 아이디어를 그의 상태 기반 RCU 패치들 중 하나로 제공했습니다 [Spr08b, Spr08a].

Section D.3.7.1은 프로세스 컨텍스트로부터 dynticks-idle 모드에 들어가고 빠져나오는 함수들을 설명하고,

```

1 static void rcu_do_batch(struct rcu_data *rdp)
2 {
3     unsigned long flags;
4     struct rcu_head *next, *list, **tail;
5     int count;
6
7     if (!cpu_has_callbacks_ready_to_invoke(rdp))
8         return;
9     local_irq_save(flags);
10    list = rdp->nxtlist;
11    rdp->nxtlist = *rdp->nxttail[RCU_DONE_TAIL];
12    *rdp->nxttail[RCU_DONE_TAIL] = NULL;
13    tail = rdp->nxttail[RCU_DONE_TAIL];
14    for (count = RCU_NEXT_SIZE - 1; count >= 0; count--)
15        if (rdp->nxttail[count] ===
16            rdp->nxttail[RCU_DONE_TAIL])
17            rdp->nxttail[count] = &rdp->nxtlist;
18    local_irq_restore(flags);
19    count = 0;
20    while (list) {
21        next = list->next;
22        prefetch(next);
23        list->func(list);
24        list = next;
25        if (++count >= rdp->blimit)
26            break;
27    }
28    local_irq_save(flags);
29    rdp->qlen -= count;
30    if (list != NULL) {
31        *tail = rdp->nxtlist;
32        rdp->nxtlist = list;
33        for (count = 0; count < RCU_NEXT_SIZE; count++)
34            if (&rdp->nxtlist == rdp->nxttail[count])
35                rdp->nxttail[count] = tail;
36            else
37                break;
38    }
39    if (rdp->blimit == LONG_MAX && rdp->qlen <= qlowmark)
40        rdp->blimit = blimit;
41    local_irq_restore(flags);
42    if (cpu_has_callbacks_ready_to_invoke(rdp))
43        raise_softirq(RCU_SOFTIRQ);
44 }

```

Figure D.43: Code for rcu_do_batch()

Section D.3.7.2 은 dynticks-idle 모드로부터의 NMI 처리를 설명하며, Section D.3.7.3 은 dynticks-idle 모드로부터의 인터럽트 처리를 다루고, Section D.3.7.4 은 어떤 다른 CPU 가 현재 dynticks-idle 모드에 있는지 체크하는 함수들을 보입니다.

D.3.7.1 Entering and Exiting Dyntick-Idle Mode

Figure D.44 는 스케줄러가 dynticks-idle 모드로 들어가고 그로부터 나오는 걸 가능하게 하는 rcu_enter_nohz() 와 rcu_exit_nohz() 함수들을 보입니다. 따라서, rcu_enter_nohz() 함수가 호출된 뒤에는, RCU 는 적어도 다음 rcu_exit_nohz(), 다음 인터럽트, 또는 다음 NMI 전까지는 이 CPU 를 무시할 겁니다.

rcu_enter_nohz() 의 line 6 는 모든 앞의 RCU read-side 크리티컬 섹션들은 RCU 이에게 이 CPU 를 무시하라

```

1 void rcu_enter_nohz(void)
2 {
3     unsigned long flags;
4     struct rcu_dynticks *rdtp;
5
6     smp_mb();
7     local_irq_save(flags);
8     rdtp = &__get_cpu_var(rcu_dynticks);
9     rdtp->dynticks++;
10    rdtp->dynticks_nesting--;
11    local_irq_restore(flags);
12 }
13
14 void rcu_exit_nohz(void)
15 {
16     unsigned long flags;
17     struct rcu_dynticks *rdtp;
18
19     local_irq_save(flags);
20     rdtp = &__get_cpu_var(rcu_dynticks);
21     rdtp->dynticks++;
22     rdtp->dynticks_nesting++;
23     local_irq_restore(flags);
24     smp_mb();
25 }

```

Figure D.44: Entering and Exiting Dyntick-Idle Mode

고 말하는, 뒤따르는 코드 전에 일어난 것으로 보이도록 보장하기 위해 메모리 배리어를 실행합니다. Line 7 과 11 은 상태 변경과의 간섭을 막기 위해 인터럽트를 비활성화하고 재활성화 합니다. Line 8 은 수행중인 CPU 의 rcu_dynticks 구조체로의 포인터를 가져오고, line 9 는 (이제는 이 CPU 가 무시될 수 있다는 걸 알리는 짝수여야 하는) ->dynticks 필드의 값을 증가시키고, 마지막으로 line 10 에서는 (이 CPU 에 관심을 줄 필요가 없다는 걸 알리는 값 0 을 가져야 하는) ->dynticks_nesting 필드의 값을 감소시킵니다.

rcu_exit_nohz() 의 line 19 와 23 은 역시 간섭을 막기 위해 인터럽트를 비활성화하고 재활성화 합니다. Line 20 은 이 CPU 의 rcu_dynticks 구조체로의 포인터를 가져오고, line 21 은 (이제 RCU 에게 이 CPU 에 다시 관심을 기울여야 함을 알리기 위해 허수 값을 가져야 하는) ->dynticks 필드의 값을 증가시키고, line 22 는 (이제 이 CPU 에 관심을 기울여야 할 하나의 이유가 있음을 알리도록 값 1 을 가져야 하는) ->dynticks_nesting 필드의 값을 증가시킵니다.

D.3.7.2 NMIs from Dyntick-Idle Mode

Figure D.45 는 각각 NMI 에 들어가는 것과 그로부터 나오는 것을 처리하는 rcu_nmi_enter() 와 rcu_nmi_exit() 을 보입니다. NMI 핸들러에 들어가는 것은 dyntick-idle 모드를 나오게 된다는 점과 그 반대도 마찬가지라는 점을 알아둘 필요가 있는데, 달리 말하면 RCU 는 NMI 핸들러를 수행 중인 동안 dyntick-idle 모드로 들어가려 시도하는 CPU 들에 관심을 기울일 필요가

```

1 void rCU_nmi_enter(void)
2 {
3     struct rCU_dynticks *rdtp;
4
5     rdtp = &__get_cpu_var(rCU_dynticks);
6     if (rdtp->dynticks & 0x1)
7         return;
8     rdtp->dynticks_nmi++;
9     smp_mb();
10 }
11
12 void rCU_nmi_exit(void)
13 {
14     struct rCU_dynticks *rdtp;
15
16     rdtp = &__get_cpu_var(rCU_dynticks);
17     if (rdtp->dynticks & 0x1)
18         return;
19     smp_mb();
20     rdtp->dynticks_nmi++;

```

Figure D.45: NMIs from Dyntick-Idle Mode

있다는 이야기로, NMI 핸들러는 RCU read-side 크리티컬 섹션을 가질 수 있기 때문입니다. 이 반대적인 역할은 상당히 헛갈릴 수 있습니다: 경고 드렸습니다.

`rcu_nmi_enter()`의 line 5는 이 CPU의 `rcu_dynticks` 구조체로의 포인터를 얻어오고, line 6는 이 CPU가 이미 RCU에 의해 `srcutiny` 아래 있는지 확인해보고, 만약 그렇다면 line 7에서 조용히 리턴합니다. 그렇지 않다면, line 8에서 `->dynticks_nmi` 필드의 값을 증가시키는데, 이 필드는 이제 훌수 값을 가져야만 합니다. 마지막으로, line 9는 앞의 `->dynticks_nmi` 값의 증가가 다른 모든 CPU들에게 뒤따르는 모든 RCU read-side 크리티컬 섹션보다 먼저 일어난 것으로 보이게끔 메모리 배리어를 실행합니다.

`rcu_nmi_exit()`의 line 16은 다시 이 CPU의 `rcu_dynticks` 구조체로의 포인터를 가져오고, line 17은 이 CPU가 NMI 아래 있정낳았다 하더라도 RCU가 관심을 가질 것인지 체크하고 만약 그렇다면 line 18에서 조용히 리턴합니다. 그렇지 않다면, line 19에서 이 핸들러 안의 모든 RCU read-side 크리티컬 섹션들이 모든 CPU들에게 line 20에서의 `->dynticks_nmi` 필드의 값 증가 전에 일어난 것으로 보이게끔 메모리 배리어를 실행합니다. 이 필드의 새로운 값은 이제 짹수가 되어야만 합니다.

Quick Quiz D.51: Figure D.45의 코드는 어떻게 중첩된 NMI들을 처리하나요? ■

D.3.7.3 Interrupts from Dyntick-Idle Mode

Figure D.46는 각각 인터럽트에 들어가는 것과 그로부터 나오는 걸 처리하는 `rcu_irq_enter()`와 `rcu_irq_exit()`를 보입니다. NMI에서와 같이, 인터럽트 핸들러에 들어가는 것은 dyntick-idle 모드를 빠져나오

```

1 void rCU_irq_enter(void)
2 {
3     struct rCU_dynticks *rdtp;
4
5     rdtp = &__get_cpu_var(rCU_dynticks);
6     if (rdtp->dynticks_nesting++)
7         return;
8     rdtp->dynticks++;
9     smp_mb();
10 }
11
12 void rCU_irq_exit(void)
13 {
14     struct rCU_dynticks *rdtp;
15
16     rdtp = &__get_cpu_var(rCU_dynticks);
17     if (--rdtp->dynticks_nesting)
18         return;
19     smp_mb();
20     rdtp->dynticks++;
21     if (__get_cpu_var(rCU_data).nxtlist ||
22         __get_cpu_var(rCU_bh_data).nxtlist)
23         set_need_resched();
24 }

```

Figure D.46: Interrupts from Dyntick-Idle Mode

는 것이 되고 그 반대로 마찬가지인데, 인터럽트 핸들러 안에 RCU read-side 크리티컬 섹션이 있을 수 있다는 사실 때문입니다.

`rcu_irq_enter()`의 line 5는 현재 CPU의 `rcu_dynticks` 구조체로의 레퍼런스를 얻어옵니다. Line 6는 `->dynticks_nesting` 필드의 값을 증가시키고, 만약 그 원래 값이 이미 0이 아니었다면(달리 말해서, RCU가 이미 이 CPU에 관심을 기울이고 있었다면), line 7에서 조용히 리턴합니다. 그렇지 않다면, line 8에서 `->dynticks` 필드의 그 뱃을 증가시키는데, 이 값은 이제 훌수 값을 가져야만 합니다. 마지막으로, line 9는 이 값 증가가 모든 CPU들에게 인터럽트 핸들러 안에 있을 수 있는 모든 RCU read-side 크리티컬 섹션들보다 먼저 일어난 것으로 보일 수 있도록 메모리 배리어를 실행합니다.

`rcu_irq_exit()`의 line 16은 이제는 전통적인 현재 수행중인 CPU의 `rcu_dynticks` 구조체로의 레퍼런스 얻어오기를 수행합니다. Line 17은 `->dynticks_nesting` 필드의 값을 감소시키고, 만약 그 결과가 0이 아니라면(달리 말해서, RCU가 이 인터럽트 핸들러를 빠져나감에도 불구하고 이 CPU에 관심을 기울여야만 한다면), line 18에서 조용히 리턴합니다. 그렇지 않다면, line 19에서 이 인터럽트 핸들러 안에 있을 수 있는 모든 RCU read-side 크리티컬 섹션들이 모든 CPU들에 line 20에서의 `->dynticks` 필드의 값 증가(이제는 짹수의 값을 가져야만 합니다)보다 먼저 일어난 것으로 보일 수 있게끔 메모리 배리어를 실행합니다. Line 21과 22는 이 인터럽트 핸들러가 어떤 “rcu”나 “rcu_bh” 콜백들을 신청했는지 확인해보고, 만약 그렇다면 line 23에서 이

```

1 static int
2 dyntick_save_progress_counter(struct rcu_data *rdp)
3 {
4     int ret;
5     int snap;
6     int snap_nmi;
7
8     snap = rdp->dynticks->dynticks;
9     snap_nmi = rdp->dynticks->dynticks_nmi;
10    smp_mb();
11    rdp->dynticks_snap = snap;
12    rdp->dynticks_nmi_snap = snap_nmi;
13    ret = ((snap & 0x1) == 0) && ((snap_nmi & 0x1) == 0);
14    if (ret)
15        rdp->dynticks_fqs++;
16    return ret;
17 }

```

Figure D.47: Code for `dyntick_save_progress_counter()`

CPU 가 dynticks-idle 모드로부터 강제로 나가게 되는 side-effect 를 가진, schedule 재실행을 강제하는데, 이는 RCU 가 이 콜백들에 의해 필요시 되는 grace period 를 처리할 수 있도록 하는데 필요한 대로입니다.

D.3.7.4 Checking for Dyntick-Idle Mode

CPU 가 dynticks-idle 모드에 있는지를 체크하는데 `dyntick_save_progress_counter()` 와 `rcu_implicit_dynticks_qs()` 함수들이 사용됩니다. `dyntick_save_progress_counter()` 함수가 먼저 호출되고, 해당 CPU 가 현재 dynticks-idle 모드에 있다면 0이 아닌 값을 리턴합니다. 만약 해당 CPU 가 예를 들어 현재 인터럽트나 NMI 를 처리하고 있거나 해서 dynticks-idle 모드에 있지 않다면, 몇 jiffy 후에 `rcu_implicit_dynticks_qs()` 함수가 호출됩니다. 이 함수는 앞의 `dyntick_save_progress_counter()` 호출로 저장되어 있는 상태와 함께 현재 상태를 살펴보고, 해당 CPU 가 dynticks-idle 모드에 있거나 그 사이에 dynticks-idle 모드에 있었던 적이 있다면 0이 아닌 값을 리턴합니다. `rcu_implicit_dynticks_qs()` 함수는 필요하다면 true 를 리턴할 때까지 반복적으로 호출될 수 있습니다.

Figure D.47 는 특정 CPU-rcu_state 짹의 `rcu_data` 구조체를 전달받는 `dyntick_save_progress_counter()` 의 코드를 보입니다. Line 8 과 9 는 해당 CPU 의 `rcu_dynticks` 구조체의 `->dynticks` 와 `->dynticks_nmi` 필드의 값을 얻어오고, 이어서 line 10 에서는 이 얻어온 값이 모든 CPU 들에게 이 값에 의존적으로 행해지는 모든 처리들보다 먼저 보여진 것으로 보이게끔 메모리 배리어를 실행합니다. 이 메모리 배리어는 `rcu_enter_nohz()`, `rcu_exit_nohz()`, `rcu_nmi_enter()`, `rcu_nmi_exit()`, `rcu_irq_enter()`, 그리고 `rcu_irq_exit()` 의 것들과 짹을 이룹니다. 이어서 line 14-15 는 이 CPU 가 dynticks-idle 모드 (`(curr & 0x1) == 0` 이고 `curr_nmi & 0x1 == 0`) 이거나 지난번의 `dyntick_save_progress_counter()` 호출 후에 dynticks-idle 모드를 지났거나 (`curr != snap` 이고

```

1 static int
2 rcu_implicit_dynticks_qs(struct rcu_data *rdp)
3 {
4     long curr;
5     long curr_nmi;
6     long snap;
7     long snap_nmi;
8
9     curr = rdp->dynticks->dynticks;
10    snap = rdp->dynticks_snap;
11    curr_nmi = rdp->dynticks->dynticks_nmi;
12    snap_nmi = rdp->dynticks_nmi_snap;
13    smp_mb();
14    if ((curr != snap || (curr & 0x1) == 0) &&
15        (curr_nmi != snap_nmi || (curr_nmi & 0x1) == 0)) {
16        rdp->dynticks_fqs++;
17    }
18    return 1;
19    return rcu_implicit_offline_qs(rdp);
20 }

```

Figure D.48: Code for `rcu_implicit_dynticks_qs()`

고 `rcu_irq_exit()` 의 것들과 짹을 이룹니다. Line 11 과 12 는 이 두개의 값들을 저장해 두어서 이것들이 나중의 `rcu_implicit_dynticks_qs()` 호출에서 접근할 수 있도록 만듭니다. Line 13 은 두개의 값들이 모두 짹수 값을 가져서 이 CPU 가 non-idle process 상태에도, 인터럽트 핸들러에도, NMI 핸들러에도 있지 않았음을 알리는지 체크합니다. 만약 그렇다면, line 14 와 15 에서 tracing 에만 사용되는 통계적 카운터인 `->dynticks_fqs` 의 값을 증가시킵니다. 어느 쪽이든, line 16 은 해당 CPU 가 dynticks-idle 모드에 있었는지 여부를 알리는 리턴을 합니다.

Quick Quiz D.52: Figure D.47 의 line 8 과 9 사이에는 왜 메모리 배리어가 없죠? 이는 `->dynticks` 와 `->dynticks_nmi` 필드의 두 값이 동시에 0이었던 적이 없는데도 짹수 값을 가져오도록 할 수 있지 않나요?

Figure D.48 는 `rcu_implicit_dynticks_qs()` 의 코드를 보입니다. Line 9-12 는 해당 CPU 의 `rcu_dynticks` 구조체의 `->dynticks` 와 `->dynticks_nmi` 필드의 새 값을 가져오고, 또한 최근의 `dyntick_save_progress_counter()` 호출로부터 얻어온 스냅샷도 얻어옵니다. Line 13 은 이어서 이 값들이 다른 CPU 들에 뒤따르는 RCU 처리보다 먼저 얻어온 것으로 보이게끔 메모리 배리어를 실행합니다. `dyntick_save_progress_counter()` 에서와 같이, 이 메모리 배리어는 `rcu_enter_nohz()`, `rcu_exit_nohz()`, `rcu_nmi_enter()`, `rcu_nmi_exit()`, `rcu_irq_enter()`, 그리고 `rcu_irq_exit()` 의 것들과 짹을 이룹니다. 이어서 line 14-15 는 이 CPU 가 dynticks-idle 모드 (`(curr & 0x1) == 0` 이고 `curr_nmi & 0x1 == 0`) 이거나 지난번의 `dyntick_save_progress_counter()` 호출 후에 dynticks-idle 모드를 지났거나 (`curr != snap` 이고

`curr_nmi != snap_nmi` 인지를 체크합니다. 만약 그렇다면, line 16에서 `->dynticks_fqs` 통계적 카운터 (이번에도, tracing을 위해서만 사용됩니다)를 증가시키고 line 17에서 0이 아닌 값을 리턴해 해당 CPU가 quiescent state를 지났음을 알립니다. 그렇지 않다면, line 19에서 (Section D.3.8에서 설명된) `rcu_implicit_offline_qs()`를 호출해서 해당 CPU가 현재 offline 인지 체크합니다.

D.3.8 Forcing Quiescent States

일반적으로, CPU들은 적절히 기록되는 quiescent state들을 지나감으로써 grace period들이 시간에 맞춰 끝날 수 있게 합니다. 하지만, 다음의 세가지 조건은 모두 CPU들이 quiescent state를 지나는 것을 방지할 수 있습니다:

1. CPU가 dyntick-idle 상태에 있고, 저전력 모드에서 잠들어 있는 경우. 그런 CPU는 공식적으로 extended quiescent state에 있는 것이긴 하지만, 명령어를 수행하고 있지 않기 때문에, 스스로는 어떤일도 할 수 없습니다.
2. CPU가 online이 되는 과정 중에 있고, RCU는 해당 CPU가 online이라고 알림을 받았지만, 이 CPU는 아직 실제로 코드를 수행하고 있지는 않을 뿐더러, `cpu_online_map`에 online이라고 표시되지 않은 경우. 따라서 현재의 grace period는 이 CPU를 기다리게 되지만, 이 CPU는 스스로는 quiescent state를 지나지 못합니다.
3. CPU가 유저 레벨 코드를 수행하고 있지만, 긴 시간 동안 스케줄러에 들어가는 것을 막아놓은 경우.

이 각각의 경우에 대해, RCU는 이 응답 없는 CPU에 대해 뭔가 행동을 취해야 합니다. 다음의 섹션들은 그런 행동을 취하는 함수들을 설명합니다. Section D.3.8.1은 dynticks-idle grace-period 수를 (올바르지 않게) dynticks-idle quiescent state를 잘못된 grace period에 적용하는 것을 막기 위해 기록하고 회수하는 함수들을 설명하고, Section D.3.8.2은 offline과 holdout CPU들을 탐지하는 함수들을 설명하며, Section D.3.8.3에서는 holdout CPU들을 스캔하는 `rcu_process_dyntick()`을 다루고, Section D.3.8.4에서는 extended quiescent state를 파악하고 holdout CPU들에 quiescent state를 강제하는 프로세스가 동작하게 하는 `force_quiescent_state()`를 설명합니다.

```

1 static void
2 dyntick_record_completed(struct rcu_state *rsp,
3                           long comp)
4 {
5     rsp->dynticks_completed = comp;
6 }
7
8 static long
9 dyntick_recall_completed(struct rcu_state *rsp)
10 {
11     return rsp->dynticks_completed;
12 }

```

Figure D.49: Recording and Recalling Dynticks-Idle Grace Period

```

1 static int rcu_implicit_offline_qs(struct rcu_data *rdp)
2 {
3     if (cpu_is_offline(rdp->cpu)) {
4         rdp->offline_fqs++;
5         return 1;
6     }
7     if (rdp->cpu != smp_processor_id())
8         smp_send_reschedule(rdp->cpu);
9     else
10        set_need_resched();
11     rdp->resched_ipi++;
12     return 0;
13 }

```

Figure D.50: Handling Offline and Holdout CPUs

D.3.8.1 Recording and Recalling Dynticks-Idle Grace Period

Figure D.49는 `dyntick_record_completed()`와 `dyntick_recall_completed()`의 코드를 보입니다. 이 함수들은 dynticks가 활성화된 경우 (달리 말해서, `CONFIG_NO_HZ` 커널 패러미터가 선택된 경우)에만 보여진대로 정의되고, 그렇지 않은 경우에는 no-op 뿐입니다. 이 함수들의 목표는 dynticks-idle 모드에 있는 특정 CPU의 발견이 이 dynticks-idle 모드의 CPU의 보고와 이 CPU가 dynticks-idle 모드로부터 나가는 것과 그 스스로의 quiescent state를 보고하는 것 사이의 race condition에도 불구하고 올바른 grace period에 조합되도록 보장하는 것입니다.

Line 1-6은 `dyntick_record_completed()` 함수로, `comp` 인자로 명시된 값을 명시된 `rcu_state` 구조체의 `->dynticks_completed` 필드에 저장합니다. Line 8-12는 `dyntick_recall_completed()` 함수로, 가장 최근의 `dyntick_record_completed()` 호출로 이 CPU와 `rcu_state` 구조체의 조합으로 저장된 값을 리턴합니다.

D.3.8.2 Handling Offline and Holdout CPUs

Figure D.50 는 offline CPU 들을 체크하고 online holdout CPU 들을 quiescent state 에 들어가도록 강제하는 `rcu_implicit_offline_qs()` 의 코드를 보입니다.

Line 3 는 명시된 CPU 가 offline 인지 체크하고, 만약 그렇다면 line 4 에서 통계적 카운터인 `->offline_fqs` (tracing 을 위해서만 사용됩니다) 의 값을 증가시키고, line 5 에서 해당 CPU 가 extended quiescent state 에 있다는 것을 알리기 위해 0이 아닌 값을 리턴합니다.

그렇지 않다면, 해당 CPU 는 online 이고 dynticks-idle 모드가 아니며(만약 그렇지 않다면 일단 이 함수가 호출되지도 않았을 겁니다), 이 grace period 를 위한 quiescent state 를 아직 지나지 않은 겁니다. Line 7 은 이 holdout CPU 가 현재 수행중인 CPU 인지 체크하고, 만약 그렇지 않다면 line 8 에서 이 holdout CPU 에게 reschedule IPI 를 날립니다. 그렇지 않다면, line 10 에서 현재의 task 를 위해 TIF_NEED_RESCHED 플래그를 세워서 현재 CPU 가 scheduler 에 들어가도록 강제합니다. 어느 경우든, 이 CPU 는 이제 빨리 quiescent state 에 들어가야 합니다. Line 11 은 tracing 을 위해서만 사용되는 통계적 카운터인 `resched_ipi` 의 값을 증가시킵니다. 마지막으로, line 12 는 이 holdout CPU 가 여전히 quiescent state 를 지나가길 거부하고 있다는 걸 알리기 위해 0을 리턴합니다.

D.3.8.3 Scanning for Holdout CPUs

Figure D.51 는 Figure D.52 에 파란 화살표로 그려진대로 holdout CPU 들을 탐색하기 위해 leaf `rcu_node` 구조체들을 스캔하는 `rcu_process_dyntick()` 의 코드를 보입니다. 이 함수는 각각의 CPU 의 `rcu_data` 구조체에 대해 인자로 받은 함수 `f` 를 실행하고, `lastcomp` 인자로 명시된 grace period 가 종료되었다면 0이 아닌 값을 리턴합니다.

Line 13 과 14 는 첫번째와 마지막 leaf `rcu_node` 구조체로의 레퍼런스를 각각 얻어옵니다. Line 15-38 의 루프의 각 단계는 leaf `rcu_node` 구조체들 중 하나를 처리합니다.

Line 16 은 지역 변수 `mask` 를 0 으로 값 설정합니다. 이 변수는 현재 leaf `rcu_node` 구조체의 extended quiescent state 에 있는 CPU 들을 모으는데 사용됩니다. Line 17 은 현재 leaf `rcu_node` 구조체의 락을 얻어오고, line 18 은 현재의 grace period 가 완료되었는지 확인하며, 만약 그렇다면 line 19 에서 이 락을 해제하고 line 20 에서 0이 아닌 값을 리턴합니다. 그렇지 않다면, line 22 에서 이 `rcu_node` 구조체에 연관된 holdout CPU 들을 체크하고, 그런게 하나도 없다면, line 23 에서 이 락을 해제하고 line 24 에서 루프를 다음 leaf `rcu_node` 구조체부터 시작하도록 재시작 시킵니다.

```

1 static int
2 rcu_process_dyntick(struct rcu_state *rsp,
3                      long lastcomp,
4                      int (*f)(struct rcu_data *))
5 {
6     unsigned long bit;
7     int cpu;
8     unsigned long flags;
9     unsigned long mask;
10    struct rcu_node *rnp_cur;
11    struct rcu_node *rnp_end;
12
13    rnp_cur = rsp->level[NUM_RCU_LVLS - 1];
14    rnp_end = &rsp->node[NUM_RCU_NODES];
15    for (; rnp_cur < rnp_end; rnp_cur++) {
16        mask = 0;
17        spin_lock_irqsave(&rnp_cur->lock, flags);
18        if (rsp->completed != lastcomp) {
19            spin_unlock_irqrestore(&rnp_cur->lock, flags);
20            return 1;
21        }
22        if (rnp_cur->qsmask == 0) {
23            spin_unlock_irqrestore(&rnp_cur->lock, flags);
24            continue;
25        }
26        cpu = rnp_cur->grplo;
27        bit = 1;
28        for (; cpu <= rnp_cur->grphi; cpu++, bit <= 1) {
29            if ((rnp_cur->qsmask & bit) != 0 &&
30                f(rsp->rda[cpu]))
31                mask |= bit;
32        }
33        if (mask != 0 && rsp->completed == lastcomp) {
34            cpu_quiet_msk(mask, rsp, rnp_cur, flags);
35            continue;
36        }
37        spin_unlock_irqrestore(&rnp_cur->lock, flags);
38    }
39    return 0;
40 }

```

Figure D.51: Scanning for Holdout CPUs

이 `rcu_node` 구조체에 연관된 holdout CPU 가 최소 하나라도 있다면 실행은 line 26 에 도달합니다. Line 26 과 27 은 지역 변수 `cpu` 와 `bit` 을 이 `rcu_node` 구조체에 연관된 가장 낮은 숫자의 CPU 를 가리키도록 설정합니다. Line 28-32 의 루프의 각 단계는 현재의 `rcu_node` 구조체에 연관된 CPU 들 중 하나씩을 체크합니다. Line 29 는 이 CPU 가 여전히 유지되고 있는지 아니면 이미 quiescent state 를 지나갔는지 확인합니다. 만약 여전히 유지되고 있다면, line 30 에서 명시된 함수 (`dyntick_save_progress_counter()` 또는 `rcu_implicit_dynticks_qs()`) 를 호출하고, 그 함수가 0이 아닌 값을 리턴한다면 (현재 CPU 가 extended quiescent state 에 있음을 의미함), line 31 에서 `mask` 내의 현재 CPU 의 `bit` 의 값을 1로 세팅합니다.

이어서 Line 33 은 어떤 CPU 가 extended quiescent state 에 있었던 걸로 구분되었는지 그리고 현재의 grace period 가 여전히 강제되어 있는지 체크하고, 만약 그렇다면 line 34 에서 이 grace period 는 더이상 그런 CPU

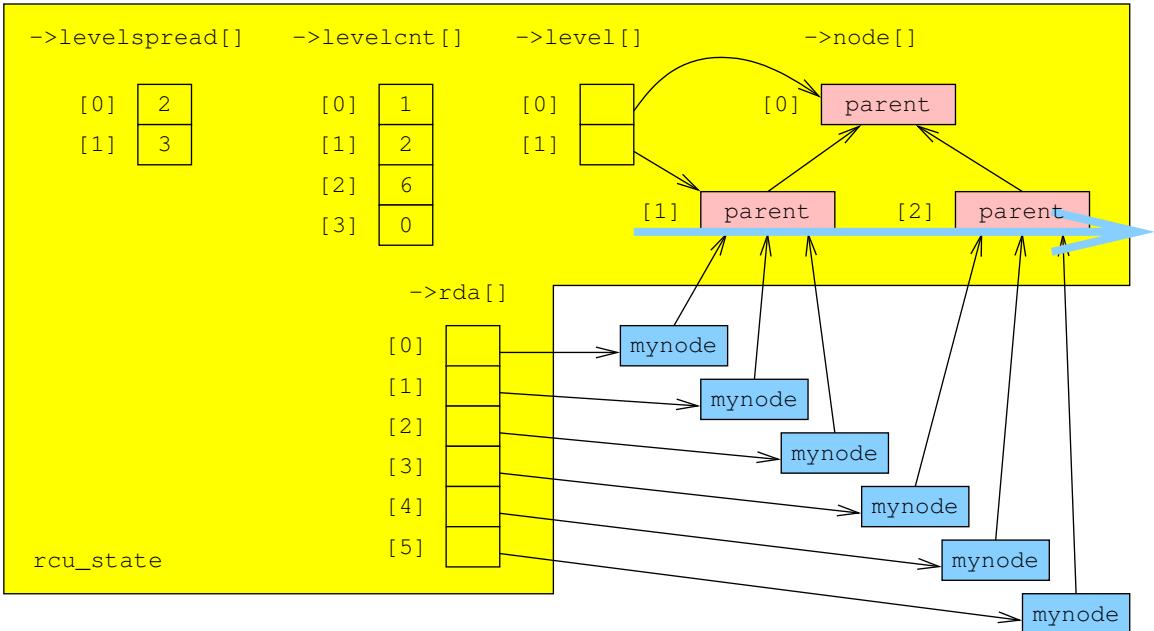


Figure D.52: Scanning Leaf rCU_node Structures

들을 기다릴 필요가 없단 걸 알리기 위해 `cpu_quiet_msk()`를 호출하고 line 35에서 다음 `rcu_node` 구조체를 가지로 루프를 재시작합니다. (`cpu_quiet_msk()`는 현재 `rcu_node` 구조체의 락을 해제하며, 현재 grace period를 끝낼 수도 있음을 알아두시기 바랍니다.) 그렇지 않다면, 만약 모든 holdout CPU들이 여전히 진짜로 holdout 상태라면, line 37에서 현재 `rcu_node` 구조체의 락을 해제합니다.

일단 모든 leaf `rcu_node` 구조체들이 처리되었다면, 루프를 빠져나가고 line 39에서 현재의 grace period는 여전히 진행되어야 함을 알리기 위해 0을 리턴합니다. (line 20은 현재 grace period가 끝났음을 알리기 위해 0이 아닌 값을 리턴함을 다시 말해둡니다.)

D.3.8.4 Code for `force_quiescent_state()`

Figure D.53는 `CONFIG_SMP`를 위한 `force_quiescent_state()`의 코드를 보이는데⁴, 이 함수는 RCU가 현재 grace period를 CPU들을 quiescent state 너머로 진척시키고자 하는 필요를 느낄 때 호출됩니다. RCU는 다음 중 한 상태일 때 이 필요를 느낍니다:

1. 현재의 grace period가 3 jiffy(또는 compile-time의 `RCU_JIFFIES_TILL_FORCE_QS` 값으로 명시된 만큼) 이상 진행되었거나,

⁴ non-`CONFIG_SMP`에서는 `force_quiescent_state()`는 `set_need_resched()`의 wrapper일 뿐입니다.

2. `call_rcu()` 또는 `call_rcu_bh()`를 통해 RCU 콜백을 집어넣는 CPU가 10,000개(또는 boot-time 패러미터인 `qhimark`로 명시된 양) 이상의 콜백이 넣어져 있음을 보았을 때.

Line 10-12는 진행중인 grace period가 존재하는지 보고, 존재하지 않는다면 그냥 조용히 종료합니다. Line 13-16은 하나의 grace period를 진척시키려는 동시적 시도를 방지해주는 `->fqslck`을 획득하려 시도합니다. `->n_force_qs_1h` 카운터는 이 락이 이미 잡혀 있을 때 그 값이 증가되며, `CONFIG_RCU_TRACE` 커널 패러미터가 활성화되어 있으면 `rcuhier` debugfs 파일의 `fqlh` 필드로 그 값을 볼 수 있습니다. Line 17-21은 현재의 grace period가 정말로 진척될 필요가 있는지 확인해보는데, 달리 말하자면 (1) 현재의 CPU가 10,000개의 대기중인 RCU 콜백들을 가지고 있는지, 또는 (2) 현재 grace period의 시작으로부터 또는 현재 grace period를 진척시키려는 마지막 시도로부터 `jiffies` 카운터 또는 `rcu_pending` 호출 횟수로 측정해서 3 jiffy 이상이 지났는지를 봅니다. Line 22는 이어서 grace period들을 진척시키려 시도한 횟수를 셹니다.

Line 23-36은 현재의 grace period가 그것을 진척시키려 시도하자마자 종료되었을 때의 혼란을 막기 위해 root `rcu_node` 구조체의 락을 잡은 채로 실행됩니다. Line 24와 25는 `->completed`과 `->signaled` 필드의 스냅샷을 뜯고, line 26-30에서는 뒤따르는 non-relaxed `force_quiescent_state()`가 실제로 어떤 진척을 행할 수

```

1 static void
2 force_quiescent_state(struct rcu_state *rsp, int relaxed)
3 {
4     unsigned long flags;
5     long lastcomp;
6     struct rcu_data *rdp = rsp->rda[smp_processor_id()];
7     struct rcu_node *rnp = rcu_get_root(rsp);
8     u8 signaled;
9
10    if (ACCESS_ONCE(rsp->completed) ==
11        ACCESS_ONCE(rsp->gpnum))
12        return;
13    if (!spin_trylock_irqsave(&rsp->fqslck, flags)) {
14        rdp->n_force_qs_lh++;
15        return;
16    }
17    if (relaxed &&
18        (long)(rsp->jiffies_force_qs - jiffies) >= 0 &&
19        (rdp->n_rcu_pending_force_qs -
20         rdp->n_rcu_pending) >= 0)
21        goto unlock_ret;
22    rdp->n_force_qs++;
23    spin_lock(&rnp->lock);
24    lastcomp = rsp->completed;
25    signaled = rsp->signaled;
26    rdp->jiffies_force_qs =
27        jiffies + RCU_JIFFIES_TILL_FORCE_QS;
28    rdp->n_rcu_pending_force_qs =
29        rdp->n_rcu_pending +
30        RCU_JIFFIES_TILL_FORCE_QS;
31    if (lastcomp == rsp->gpnum) {
32        rdp->n_force_qs_ngp++;
33        spin_unlock(&rnp->lock);
34        goto unlock_ret;
35    }
36    spin_unlock(&rnp->lock);
37    switch (signaled) {
38    case RCU_GP_INIT:
39        break;
40    case RCU_SAVE_DYNTICK:
41        if (RCU_SIGNAL_INIT != RCU_SAVE_DYNTICK)
42            break;
43        if (rcu_process_dyntick(rsp, lastcomp,
44                               dyntick_save_progress_counter))
45            goto unlock_ret;
46        spin_lock(&rnp->lock);
47        if (lastcomp == rsp->completed) {
48            rdp->signaled = RCU_FORCE_QS;
49            dyntick_record_completed(rsp, lastcomp);
50        }
51        spin_unlock(&rnp->lock);
52        break;
53    case RCU_FORCE_QS:
54        if (rcu_process_dyntick(rsp,
55                               dyntick_recall_completed(rsp),
56                               rcu_implicit_dynticks_qs))
57            goto unlock_ret;
58        break;
59    }
60 unlock_ret:
61     spin_unlock_irqrestore(&rsp->fqslck, flags);
62 }

```

Figure D.53: force_quiescent_state() Code

있게 되기까지의 가장 빠른 시간을 설정하고, line 31-35는 이 grace period 가 우리가 이 rcu_node 구조체의 락을 잡는 사이에 종료되었는지 확인하고, 만약 그렇다면 이 락을 해제하고 리턴합니다.

Line 37-59는 force_quiescent_state()의 state machine을 이릅니다. 해당 grace period 가 아직 초기화 중이라면, line 41과 42 dptj rmsid flxjsgotj force_quiescent_state() 가 아마도 초기화가 끝난 나중에 다시 호출될 수 있게 합니다. 만약 dynticks 가 (CONFIG_NO_HZ 커널 패러미터를 통해) 활성화되어 있다면, 해당 grace period의 초기화 뒤의 첫번째 force_quiescent_state() 호출은 line 40-52를 실행하고, 두번째와 그 이후의 호출들은 line 53-59를 실행하게 됩니다. 반면에, dynticks 가 활성화되어 있지 않다면, 모든 초기화 뒤의 force_quiescent_state() 호출은 line 53-59를 실행하게 될겁니다.

Line 40-52의 목적은 아직 quiescent state를 지나지 않은 모든 CPU들의 현재 dynticks-idle state를 기록하고, 현재 dynticks-idle 상태에 있는(하지만 irq나 NMI 핸들러에 있지 않은) 모든 quiescent state를 기록하는 것입니다. Line 41-42는 gcc에게 이 switch문의 branch가 non-CONFIG_NO_HZ 커널에서는 사용되지 않는 코드임을 알리는 역할을 합니다. Line 43-45는 현재의 grace period를 위한 quiescent state를 아직 지나지 않은 각각의 CPU를 위해 dyntick_save_progress_counter()를 호출하고(아직 quiescent state를 지나지 않은 모든 CPU들이 dyntick-idle 모드에서 잠들어 있었음을 발견하거나 함으로써) 이 grace period가 그 사이 종료되었다면 force_quiescent_state()를 빠져나가기 위해 rCU_process_dyntick()을 호출합니다. Line 46과 51은 현재 grace period의 동시적 종료와의 혼란을 막기 위해 root rcu_node 구조체의 락을 잡고 해제합니다. Line 47은 현재의 grace period가 여전히 진행 중인지 체크하고, 만약 그렇다면 line 48에서 이 상태를 RCU_FORCE_QS 상태로 진척시키고 line 49에서 현재의 grace-period 숫자를 다음 force_quiescent_state() 호출 때를 위해 저장해둡니다. 현재 grace-peirod 숫자를 저장하는 이유는 현재의 grace period가 다음의 force_quiescent_state()의 호출과 동시에 종료되는 경우의 race condition을 올바르게 처리하기 위함입니다.

앞에서 이야기했듯, line 53-58은 CONFIG_NO_HZ 커널에서의 두번째 이후 force_quiescent_state() 호출, 그리고 non-CONFIG_NO_HZ 커널에서의 모든 호출에 대해서 수행됩니다. Line 54와 58은 아직 quiescent state를 지나지 않은 CPU들 사이를 지나며 그것들에 대해(CONFIG_NO_HZ 가 활성화되어 있다면) 이 CPU들 중 하나라도 dyntick-idle state를 지났는지 체크하고, offline CPU들을 기다리고 있진 않은지 확인하고, 마지막으로 앞의 두 그룹에 속하지 않은 모든 CPU들에 대해선

```

1 static void
2 record_gp_stall_check_time(struct rcu_state *rsp)
3 {
4     rsp->gp_start = jiffies;
5     rsp->jiffies_stall =
6         jiffies + RCU_SECONDS_TILL_STALL_CHECK;
7 }

```

Figure D.54: record_gp_stall_check_time() Code

```

1 static void
2 check_cpu_stall(struct rcu_state *rsp,
3                  struct rcu_data *rdp)
4 {
5     long delta;
6     struct rcu_node *rnp;
7
8     delta = jiffies - rsp->jiffies_stall;
9     rnp = rdp->mynode;
10    if ((rnp->gsmask & rdp->grpmask) && delta >= 0) {
11        print_cpu_stall(rsp);
12    } else if (rsp->gpnum != rsp->completed &&
13               delta >= RCU_STALL_RAT_DELAY) {
14        print_other_cpu_stall(rsp);
15    }
16 }

```

Figure D.55: check_cpu_stall() Code

reschedule IPI 를 날려주는 `rcu_implicit_dynticks_qs()` 를 호출하는 `rcu_process_dyntick()` 을 호출합니다.

D.3.9 CPU-Stall Detection

RCU 는 `CONFIG_RCU_STALL_DETECTOR` 커널 패러미터가 선택되어 있는 경우에는 stall 되어있는 CPU 들을 검사합니다. “Stall 되어있는 CPU 들”은 커널에서 preemption 이 불능화 되어있는 채로 spin 하고 있어서 응답시간을 나쁘게 만드는 것들입니다. 이것들은 `record_gp_stall_check_time()`, `check_cpu_stall()`, `print_cpu_stall()`, 그리고 `print_other_cpu_stall()` 함수의 구현을 통해 검사되며, 이것들 각각이 아래에 설명됩니다. 이 함수들은 `CONFIG_RCU_CPU_STALL_DETECTOR` 커널 패러미터가 선택되어 있지 않은 경우에는 모두 no-op 이 됩니다.

Figure D.54 는 `record_gp_stall_check_time()` 의 코드를 보입니다. Line 4 는 jiffy 로 (이) grace period 의 시작) 현재 시간을 기록하고, line 5-6 는 stall 된 CPU 가 채크되어야 할 시간을 기록합니다.

Figure D.55 는 grace period 가 너무 길게 늘어졌는지 체크하고, 그럴 경우 CPU-stall 경고 메세지를 출력하기 위해 `print_cpu_stall()` 이나 `print_other_cpu_stall()` 을 호출하는 `check_cpu_stall()` 의 코드를 보입니다.

Line 8 은 stall 경고가 출력되어야 하는 시간으로부

```

1 static void print_cpu_stall(struct rcu_state *rsp)
2 {
3     unsigned long flags;
4     struct rcu_node *rnp = rcu_get_root(rsp);
5
6     printk(KERN_ERR
7           "INFO: RCU detected CPU %d stall "
8           "(t=%lu jiffies)\n",
9           smp_processor_id(),
10          jiffies - rsp->gp_start);
11    dump_stack();
12    spin_lock_irqsave(&rnp->lock, flags);
13    if ((long)(jiffies - rsp->jiffies_stall) >= 0)
14        rsp->jiffies_stall =
15            jiffies + RCU_SECONDS_TILL_STALL_RECHECK;
16    spin_unlock_irqrestore(&rnp->lock, flags);
17    set_need_resched();
18 }

```

Figure D.56: print_cpu_stall() Code

터의 jiffy 의 수를 계산하는데, 이는 아직 warning 을 출력할 시간이 아니라면 음수가 됩니다. Line 9 는 현재의 CPU 에 연관된 leaf `rcu_node` 구조체로의 포인터를 가져오고, line 10 은 현재의 CPU 가 아직 quiescent state 를 지나지 않았는지, 그리고 이 grace period 가 너무 길게 연장되지 않았는지 (달리 말해서, 현재 CPU 가 stall 되었는지) 검사하고, 만약 그렇다면 line 11 에서 `print_cpu_stall()` 을 호출합니다.

그렇지 않다면, line 12-13 에서 이 grace period 가 아직 효력을 발휘하고 있는지, 그리고 이게 CPU-stall 경고 기간을 지나 두 jiffy 만큼 연자오디었는지 검사하고, 만약 그렇다면 line 14 에서 `print_other_cpu_stall()` 을 호출합니다.

Quick Quiz D.53: Figure D.55 의 line 12-13 에서는 왜 두 jiffy 를 더 기다리는 거죠? ■

Figure D.56 는 `print_cpu_stall()` 코드를 보입니다.

Line 6-11 은 콘솔 메세지를 출력하고 현재 CPU 의 스택의 dump 를 행하며, line 12-17 은 다음 CPU stall 경고를 할 시간을 계산하는데, grace period 가 그만큼 길어지면 경고를 하게 됩니다.

Quick Quiz D.54: Figure D.56 에서 stall 경고가 출력되게 전에 grace period 가 종료되는 건 누가 막나요? ■

Figure D.57 는 현재 수행중인 CPU 외의 CPU 들을 위한 stall 경고를 출력하는 `print_other_cpu_stall()` 의 코드를 보입니다.

Line 10 과 11 은 첫번째 leaf `rcu_node` 구조체와 마지막 leaf `rcu_node` 구조체 다음 것의 레퍼런스를 가져옵니다. Line 12 는 root `rcu_node` 구조체의 락을 잡고, 또한 인터럽트를 불능화 시킵니다. Line 13 은 얼마나 오래 전에 CPU-stall 경고 시간 (아직 있지 않았다면 음수가 됩니다) 이 있었는지 계산하고, line 14 와 15 는 이

```

1 static void print_other_cpu_stall(struct rcu_state *rsp)
2 {
3     int cpu;
4     long delta;
5     unsigned long flags;
6     struct rcu_node *rnp = rcu_get_root(rsp);
7     struct rcu_node *rnp_cur;
8     struct rcu_node *rnp_end;
9
10    rnp_cur = rsp->level[0] - 1;
11    rnp_end = &rsp->node[0];
12    spin_lock_irqsave(&rnp->lock, flags);
13    delta = jiffies - rsp->jiffies_stall;
14    if (delta < RCU_STALL_RAT_DELAY || !!
15        rsp->gpnum == rsp->completed) {
16        spin_unlock_irqrestore(&rnp->lock, flags);
17        return;
18    }
19    rsp->jiffies_stall = jiffies +
20        RCU_SECONDS_TILL_STALL_RECHECK;
21    spin_unlock_irqrestore(&rnp->lock, flags);
22    printk(KERN_ERR "INFO: RCU detected CPU stalls:");
23    for (; rnp_cur < rnp_end; rnp_cur++) {
24        if (rnp_cur->qsmask == 0)
25            continue;
26        cpu = 0;
27        for (; cpu <= rnp_cur->grphi - rnp_cur->grplo; cpu++)
28            if (rnp_cur->qsmask & (1UL << cpu))
29                printk("%d", rnp_cur->grplo + cpu);
30    }
31    printk(" (detected by %d, t=%ld jiffies)\n",
32          smp_processor_id(),
33          (long)(jiffies - rsp->gp_start));
34    force_quiescent_state(rsp, 0);
35 }

```

Figure D.57: print_other_cpu_stall() Code

CPU-stall 경고 시간이 지났는지 보고 이 grace period 가 아직 끝나지 않았는지 검사하며, 만약 그렇다면 line 16에서 이 락을 해제하고 (또 인터럽트를 재활성화 시키고) line 17에서 리턴합니다.

Quick Quiz D.55: print_cpu_stall() 은 안그러는데 Figure D.57 의 print_other_cpu_stall() 은 왜 grace period 의 종료를 검사해야 하나요? ■

그렇지 않다면, line 19 와 20 은 (그만큼 grace period 가 길어진다면) CPU stall 경고가 출력되어야 할 다음 시간을 계산하고 line 21에서 락을 해제하고 인터럽트를 재활성화 시킵니다. Line 23-33 은 stall 된 CPU 들의 목록을 출력하고, 마지막으로 line 34에서 문제의 CPU 들을 quiescent state 를 지날 수 있도록 살짝 찔러주기 위해 force_quiescent_state() 를 호출합니다.

D.3.10 Possible Flaws and Changes

이 글을 쓰는 시점까지에 있어 Hierarchical RCU 의 있을 수 있는 가장 큰 문제는 force_quiescent_state() 는 잠재적으로 모든 CPU 의 rcu_data 구조체들을 돌아봐야 할 수 있다는 겁니다. 이 스캔 작업이 인터럽트가 불능화 된 채 이루어지기 때문에 수천개의 CPU 들을 가

진 기계에서는, 이는 잠재적으로 스케줄링 반응시간에 큰 영향을 끼칠 수 있습니다.

이게 실제로 문제가 될 수 있는데, 한가지 해결책은 현재의 per_rcu_state ->signaled 상태 변수처럼 per_leaf_rcu_node 기반으로 force_quiescent_state() 시퀀스를 분리시켜 유지하는 겁니다. 이는 per_leaf_rcu_node 기반으로 quiescent state 진행을 가능하게 할 것이어서 최악의 경우의 스케줄링 응답시간의 최악의 경우의 문제를 크게 줄일 겁니다.

그런 수정이 가해지기 전까지는 스케줄링 응답시간에 민감한 분들은 시스템의 CPU 갯수를 제한하거나 preemptible RCU 구현을 사용하시기 바랍니다.

D.4 Preemptible RCU

Preemptible RCU 구현은 read-side 크리티컬 섹션의 preemption 당하고 락들을 오래도록 기다리게 만들 수 있다는 점에서 일반적이지 않습니다. 하지만, 이 구현은 (예를 들어, wait_event() 기능을 통해) 일반적인 블록킹을 처리하지 않습니다: 여러분이 이게 필요하다면, 여러분은 Appendix D.1에서 소개한 SRCU를 대신 사용해야 합니다. Ssrcu 와 대조적으로, preemptible RCU 는 non-CONFIG_PREEMPT 커널에서 우선순위 상속과 non-blocking 에 모두 해당하는 기능들 안에서만 블록킹을 허용합니다. 블락되어 있는 락을 획득하고 RCU read-side 크리티컬 섹션 내에서 preemption 당할 수 있는 능력은 Ingo Molnar 의 -rt 패치셋에서 제공된 강한 real-time 기능성을 위해 필요합니다. 하지만, 최초의 preemptible RCU 구현 [McK05c] 은 일부 한계가 있는데, 다음과 같습니다:

1. Read-side 기능들은 non-maskable 인터럽트 (NMI) 나 system 관리 인터럽트 핸들러 내에서 호출될 수 없습니다.
2. Read-side 기능들은 어토믹 인스트럭션들과 메모리 배리어를 모두 사용하는데, 이것들은 모두 상당한 오버헤드를 갖습니다.
3. RCU read-side 크리티컬 섹션의 priority boosting [McK07e] 을 하지 않습니다.

2.6.26 리눅스 커널에 받아들여진 새로운 preemptible RCU 구현은 이 한계점을 제거했고, 이 부록은 그 설계에 대한 LWN 기사 [McK07a] 에 대한 업데이트 역할을 합니다. 하지만, 이 구현은 더 빠르고 간단한 2.6.32 리눅스 커널에서의 구현으로 교체되었다는 점을 알아두시기 바랍니다. 이 설명은 다만 기존에 고안되었던 RCU 구현들 중 가장 복잡한 것에 대한 증언일 뿐입니다.

Quick Quiz D.56: Preemptible-RCU read-side 크리티컬 섹션 내에서 호출되는 블록킹 기능들이 우선순위

상속에 걸리기 쉬워야 한다는 점이 중요한 이유가 뭐죠?

Quick Quiz D.57: Non-CONFIG_PREEMPT 커널 내에서 블록될 수 있는 기능들을 사용할 수 있게 하는 게 가능할까요, 그리고 만약 그렇다면, 어떤 조건 하에서 가능할까요?

D.4.1 Conceptual RCU

가장 낮은 단계에서의 RCU에 대한 이해를 놓고 보면 RCU 구현에 대한 이해와 겸중은 훨씬 쉬워집니다. 이 섹션은 RCU 구현이 반드시 지원해야 하는 가장 기본적인 동시성에 대한 요구사항에 대한 간단한 개요를 제공합니다. 더 자세한 내용을 위해선, Section 9.5.2을 보세요.

RCU 구현은 다음 규칙을 준수해야만 합니다: 특정 RCU read-side 크리티컬 섹션의 명령이 어떤 grace period를 앞선다면, 해당 RCU read-side 크리티컬 섹션의 모든 명령은 해당 grace period가 끝나기 전에 완료되어야만 합니다.




Figure D.58: Buggy Grace Period From Broken RCU

Figure D.58에 시간축을 왼쪽에서 오른쪽으로 표현하면서 이를 표현했습니다. 빨간색 “Removal” 박스는 RCU로 보호되는 데이터 구조를 예를 들면 `list_del_rcu()`를 사용하는 식으로 수정하는 update-side 크리티컬 섹션을 표현합니다; 커다란 노란색의 “Grace Period” 박스는 `synchronize_rcu()`를 통해 호출될 수 있는 grace period를 의미하며, 초록색의 “Reclamation” 박스는 `kfree()` 등을 통한, 영향 받은 데이터 원소의 해제를 의미합니다. 파란색의 “Reader” 박스들은 각각 RCU read-side 크리티컬 섹션을 표현하는데, 예를 들면 `rcu_read_lock()`으로 시작되고 `rcu_read_unlock()`으로 종료됩니다. 빨간색으로 테두리 쳐진 “Reader” 박스는 비합법적인 상황에 대한 예입니다: Read-side 크리티컬 섹션이 grace period에 겹칠 수 있도록 하는 RCU 구현이라 불리는 것들은 버그가 존재하는 것으로, update 쓰래드가 이 읽기 쓰래드가 여전히 사용하고

있는 메모리 영역을 해제해 버릴 수 있기 때문입니다.

그럼, 이 상황에서 RCU 구현이 해야 할 건 무엇일까요?




Figure D.59: Good Grace Period From Correct RCU

RCU 구현은 이 grace period를 연장해야 하는데, Figure D.59에 보여진 것과 같은 형태가 될 수 있겠습니다. 짧게 말해서, 이 RCU 구현은 특정 grace period의 시작 시점에서 진행 중이던 모든 RCU read-side 크리티컬 섹션은 해당 grace period가 완료되기 전에 메모리 오퍼레이션들 등의 모든 것이 완전히 종료되었음을 보장해야 합니다. 이 점은 RCU 겸중이 집중될 수 있게 해줍니다: 컴파일러나 CPU가 RCU 구현이 한 일을 무효화 시키는 것을 막도록 충분히 배리어를 써서 하나의 grace period의 시작 시점에 진행 중이던 RCU read-side 크리티컬 섹션은 모두 해당 grace period가 종료되기 전에 끝나는 것을 보이는 겁니다.

D.4.2 Overview of Preemptible RCU Algorithm

이 섹션은 preemptible RCU의 특정 구현에 집중합니다. 많은 다른 구현들이 있을 수 있겠지만, 그에 대해선 다른 곳 [MSMB06, MS05]에서 다루어졌습니다. 이 글은 이 특정 구현의 일반적인 방법들과 데이터 구조, grace-period state machine, 그리고 read-side 기능들에 대한 파악에 집중합니다.

D.4.2.1 General Approach

이 preemptible RCU 구현은 `rcu_read_lock()`과 `rcu_read_unlock()`에 메모리 배리어를 필요로 하지 않기 때문에, 다단계 grace-period 탐지 알고리즘이 필요합니다. 콜백들을 위한 (기존의 RCU 구현들을 위해선 충분했던) 하나의 `wait queue`를 사용하는 대신에, 이 구현은 `wait 큐`들의 배열을 사용해서 RCU 콜백들이 이 배열의 각 원소에 차례차례 enqueue될 수 있게 합니다. 콜백의




Figure D.60: Classic vs. Preemptible RCU Callback Processing

흐름에 있어서의 이 차이가 Figure D.60에 grace period 당 두개의 waitlist stage들을 갖는(반면, 2007년 9월 10일의 -rt로의 패치 [McK07d]는 네개의 waitlist stage를 사용합니다) preemptible RCU 구현에 대해 그려져 있습니다.

Grace period 당 두개의 stage를 갖기 때문에, 한쌍의 stage들은 하나의 완전한 grace period를 구성합니다. 비슷하게, grace period 당 네개의 stage를 갖는 구현에서는 네개의 stage의 연속이 하나의 완전한 grace period를 구성합니다.

언제 하나의 grace-period stage가 끝날 수 있는지 판단하기 위해, preemptible RCU는 진행중인 RCU read-side 크리티컬 섹션들을 추적하는 두개의 원소로 구성된 per-CPU `rcu_flipctr` 배열을 사용합니다. 특정 CPU의 `rcu_flipctr` 배열의 하나의 원소는 오래된 RCU read-side 크리티컬 섹션들, 달리 말하자면 현재의 grace-period stage보다 먼저 시작된 크리티컬 섹션들을 추적합니다. 다른 원소는 새로운 RCU read-side 크리티컬 섹션들을 추적하는데, 이것들은 현재 grace-period stage 중간에 시작된 것들입니다. 이 배열의 원소들은 새로운 grace-period stage 각각의 시작 때마다 그 역할을 바꾸는데, Figure D.61에 그 모습이 그려져 있습니다.

앞의 그림의 왼쪽의 첫번째 stage 동안, `rcu_flipctr[0]`은 새로운 RCU read-side 크리티컬 섹션들을 추적하고, 따라서 `rcu_read_lock()`에 의해 그




Figure D.61: Preemptible RCU Counter Flip Operation

값이 증가하고 `rcu_read_unlock()`에 의해 그 값이 감소합니다. 비슷하게, `rcu_flipctr[1]`은 오래된(앞의 stage 동안 시작된) RCU read-side 크리티컬 섹션들을 추적하고, 따라서 `rcu_read_unlock()`에 의해 그 값이 감소되고 결코 그 값이 증가하지 않습니다.

각 CPU의 `rcu_flipctr[1]` 원소는 결코 그 값이 증가되지 않기 때문에, 모든 CPU들의 그 원소의 값의 합은 결국은 0이 됩니다. RCU read-side 크리티컬 섹션 중간의 preemption은 개별적 카운터가 0이 아니게 놔두거나 심지어 음수를 만들 수도 있겠지만 말입니다. 예를 들어, 하나의 task가 한 CPU 위에서 `rcu_read_lock()`을 호출했고, preemption 당한 후, 다른 CPU에서 다시 시작되어서 `rcu_read_unlock()`을 호출했다고 생각해 보세요. 첫번째 CPU의 카운터는 +1 될것이고 두번째 CPU의 카운터는 -1 됩니다만, 그 합은 0이 됩니다. Preemption의 가능성에 관계 없이, 이 카운터 원소들의 합이 0이 된다면, 앞의 그림의 오른쪽에 보여진 것처럼 다음 grace-period stage로 넘어가도 안전합니다.

이 두번째 stage에서, 각 CPU의 `rcu_flipctr` 카운터 배열의 원소들은 그 역할을 서로 바꿉니다. `rcu_flipctr[0]` 카운터는 이제 오래된 RCU read-side 크리티컬 섹션, 달리 말해 grace period stage 0 동안 시작된 것들을 추적합니다. 비슷하게, `rcu_flipctr[1]` 카운터는 이제 grace period stage 1 안에서 시작된 새로운 RCU read-side 크리티컬 섹션들을 추적합니다. 따라서, `rcu_read_lock()`은 이제 `rcu_flipctr[1]`의 값을 증가시키며, `rcu_read_unlock()`은 여전히 각 카운터의 값을 감소시킵니다. 특히, `rcu_read_lock()`이 grace-period stage 0(이 시점에선 과거의 stage) 동안 수행되었다면, `rcu_read_unlock()`은 `rcu_flipctr[0]`의 값을 감소시키지만, `rcu_read_lock()`이 grace-period stage 1(새로운 stage) 동안 수행되었다면, `rcu_read_`

`unlock()` 은 `rcu_flipctr[1]` 의 값을 감소시켜야 합니다.

여기서의 핵심은 과거의 RCU read-side 크리티컬 섹션들을 추적하는 모든 `rcu_flipctr` 원소들이 확실히 감소되어야 한다는 겁니다. 따라서, 일단 이 과거의 것들에 대한 카운터의 합이 0이 된다면, 이는 바뀔 수 없습니다.

`rcu_read_lock()` 기능은 `rcu_flipctr` 배열을 인덱스 하기 위해 현재 grace-period 카운터의 가장 바닥 bit (`rcu_ctrlblk.completed & 0x1`)을 사용하고, 이 인덱스를 task 구조체 안에 기록해 둡니다. 여기 짹을 맞추는 `rcu_read_unlock()`은 이 기록된 값을 `rcu_read_lock()` 이 값을 증가시킨 것에 걸맞는 카운터의 값을 감소시킨다는 것을 보장하기 위해 사용합니다. 물론, 이 RCU read-side 크리티컬 섹션이 `preemption` 당했다면, `rcu_read_unlock()`은 짹이 맞는 `rcu_read_lock()` 이 값을 증가시킨 카운터가 아니라, 다른 CPU에 속한 카운터의 값을 감소시킬 수도 있습니다.

각각의 CPU는 또한 `rcu_flip_flag` 와 `rcu_mb_flag` per-CPU 변수들을 갖고 있습니다. `rcu_flip_flag` 변수는 각 grace-period stage의 시작을 동기화 시키는 데에 사용됩니다: 일단 특정 CPU가 `rcu_flip_flag`에 응답했다면, 이제 과거의 grace-period stage에 연관된 `rcu_flip` 배열의 원소의 값을 증가시키는 걸 중단해야 합니다. 이 카운터의 값 (`rcu_ctrlblk.completed`)을 증가시키는 CPU는 각 CPU의 `rcu_mb_flag`의 값을 `rcu_flipped`로 바꿉니다만, 특정 `rcu_mb_flag`는 연관된 CPU에 의해서만 `rcu_flip_seen`으로 되바뀔 겁니다.

`rcu_mb_flag` 변수는 각 CPU가 각 grace-period stage의 끝에서 메모리 바리어를 실행하도록 강제하는데에 사용됩니다. 이런 메모리 바리어들은 주어진 grace-period stage에서 끝나는 RCU read-side 크리티컬 섹션들로부터의 메모리 접근이 이 stage의 종료 전으로 순서잡힐 것을 보장하는데 필요합니다. 이 방법은 RCU read-side 크리티컬 섹션의 시작과 끝에 비싼 메모리 배리어를 실제로 수행하지 않고도 수행한 것과 같은 효과를 얻게 해줍니다. `rcu_mb_flag`는 과거의 것들의 카운터의 합이 0이 되는 것을 파악하는 CPU에 의해 `rcu_mb_needed`로 설정됩니다만, 해당 `rcu_mb_flag`는 연관된 CPU에 의해서만, 메모리 배리어를 수행한 후에만 `rcu_mb_done`으로 되돌려집니다.

D.4.2.2 Data Structures

이 섹션은 preemptible RCU의 주요 데이터 구조인 `rcu_ctrlblk`, `rcu_data`, `rcu_flipctr`, `rcu_try_flip_state`, `rcu_try_flip_flag`, 그리고 `rcu_mb_flag`를 설명합니다.

`rcu_ctrlblk` `rcu_ctrlblk` 구조체는 전역적으로, grace-period 처리를 보호하는 락 (`filplock`)과 global grace-period 카운터 (`completed`)를 보호하는 락을 잡고 수정됩니다. `completed`의 가장 아래쪽 bit은 `rcu_read_lock()`이 어떤 카운터 집합의 값을 증가시킬지 결정하는데 사용됩니다.

`rcu_data` `rcu_data` 구조체는 per-CPU 구조체로, 다음과 같은 필드들을 갖습니다:

- `lock`은 이 구조체의 나머지 필드들을 보호합니다.
- `completed`은 CPU-local 한 활동들을 `rcu_ctrlblk`의 글로벌 카운터들과 동기화 시키는데에 사용됩니다.
- `waitlistcount`는 비어있지 않은 wait-list의 수를 세는데에 사용됩니다. 이 필드는 이 CPU가 처리해야 할 RCU에 관련된 일을 가지고 있는지 파악하는 걸 돋는데에 `rcu_pending()`에 의해 사용됩니다.
- `nextlist`, `nextail`, `waitlist`, `waittail`, `donelist`, 그리고 `donetail`은 grace period의 종료 시점에 호출되기를 기다리고 있는 RCU 콜백들로 구성된 리스트들을 형성합니다. 각각의 리스트는 tail 포인터를 가지고 있어서, $O(1)$ 삽입을 허용합니다. 이 RCU 콜백들은 이 리스트들을 통해 아래에 보여진 것처럼 훌려갑니다.
- `rcupreempt_trace`는 통계를 누적합니다.

Figure D.62는 RCU 콜백들이 `rcu_data` 구조체의 리스트들을 `call_rcu()`를 통한 생성부터 `rcu_process_callbacks()`를 통한 호출까지 어떻게 훌려가는지 보입니다. 파란색 화살표는 각각 grace-period state machine을 통한 이동을 나타내는데, 뒤의 섹션에서 이에 대해 설명합니다.

`rcu_flipctr` 앞에서도 이야기했듯이, `rcu_flipctr` per-CPU 카운터 배열은 RCU read-side 크리티컬 섹션들을 추적하는 카운터 쌍들을 담습니다. 이 배열의 어떤 카운터든 음수가 될 수 있는데, 예를 들면 한 task가 RCU read-side 크리티컬 섹션 내에서 다른 CPU로 옮겨가거나 하는 경우입니다. 하지만, 이 카운터들의 값의 합은 연관된 grace period 동안은 양수로 유지될 것이며, 이 grace period의 종료 시점에서는 0이 될겁니다.

`rcu_try_flip_state` `rcu_try_flip_state` 변수는 다음 섹션에서 설명하는대로 grace-period state machine의 현재 상태를 추적합니다.




Figure D.62: Preemptible RCU Callback Flow

`rcu_try_flip_flag` `rcu_try_flip_flag` per-CPU 변수는 grace-period 카운터가 최근에 그 값을 증가시킨데 연관된 CPU를 알리며 해당 CPU의 확인을 기록하기도 합니다. 일단 어떤 CPU가 카운터 뒤집기를 확인하면, 해당 CPU에서 `rcu_read_lock()`에 의해 취해지는 후속의 동작들은 해당 grace-period 카운터의 새로운 값을 가져야 하는데, 특히 `rcu_read_lock()` 내에서 `rcu_flipctr`의 값을 증가시킬 때가 그렇습니다.

`rcu_mb_flag` `rcu_mb_flag` per-CPU 변수는 grace-period state machine이 진행될 수 있도록 하기 위해 메모리 배리어를 반드시 수행해야 하는, 연관된 CPU를 알리며, 또한 해당 CPU의 확인을 기록합니다. 일단 어떤 CPU가 메모리 배리어를 수행하면, RCU read-side 크리티컬 섹션 앞의 모든 메모리 오퍼레이션들은 연관된 grace period 뒤의 코드에 보여질 겁니다.

D.4.2.3 Grace-Period State Machine

이 섹션은 grace-period state machine에 의해 수행되는 state 들에 대한 개괄을 제공하고 관련된 코드들을 살펴봅니다.

Grace-Period State Machine Overview의 상태 (`rcu_try_flip_state`에 기록되어짐)는 다음과 같은 값을 가질 수 있습니다:

- `rcu_try_flip_idle_state`: 어떤 RCU grace-period 활동도 없기에 Grace-period state machine이 idle 상태에 있음. `rcu_ctrlblk.completed_grace-period` 카운터는 이 상태로부터 빠져나갈 때마다 값이 증가되고, 모든 per-CPU `rcu_flip_flag` 변수들은 `rcu_flipped`로 설정됩니다.
- `rcu_try_flip_waitack_state`: 모든 CPU들이 각자의 `rcu_flip_fflag` 변수를 `rcu_flip_seen`으로 설정함으로써 기존 state의 증가를 보았음을 보고하기를 기다리는 상태. 일단 모든 CPU들이 이렇게 보고를 하게 되면, 우린 과거의 카운터 집합은 더이상 값 증가할 수 없음을 알게 됩니다.
- `rcu_try_flip_waitack_state`: 기존 카운터들의 값의 합이 0이 되길 기다리는 상태. 일단 카운터들의 값의 합이 0이 되면, 모든 per-CPU `rcu_mb_flag` 변수들은 `rcu_mb_needed`로 설정됩니다.
- `rcu_try_flip_waitmb_state`: 모든 CPU들이 각자의 `rcu_mb_flag` 변수의 값을 `rcu_mb_done`으로 설정함으로써 메모리 배리어 인스트럭션을 수행했음을 알리기를 기다리는 상태. 일단 모든 CPU들이 메모리 배리어 인스트럭션을 수행하면, 연관된 grace period의 시작 전에 시작된 read-side 크리티컬 섹션에 의해 만들어진 변경사항은 모든 CPU들이 볼 수 있을 것임이 완화된 순서규칙의 기계에서도 보장됩니다.

Grace period state machine은 Figure D.63에 보여진 것처럼 상태들을 순차적으로 돌아갑니다.

Figure D.64는 이 state machine이 어떻게 시간의 흐름에 따라 동작하는지 보입니다. 상태들은 이 그림의 왼쪽에 보여져 있고 연관된 이벤트들이 시간의 흐름에 따라 보여져 있는데, 시간은 아래쪽으로 흐르고 있습니다. 우리는 뒤의 섹션에서 이 알고리즘을 검증할 때에 이 그림을 상세히 설명할 겁니다.

그 전까지는, 여기에 알아둘 중요한 사항들이 있으니 알아두시기 바랍니다:

1. `rcu_ctrlblk.completed` 카운터의 값 증가는 파란 타원으로 표시된 것처럼 다른 시간에 다른 CPU들에 의해 관측되어질 수 있습니다. 하지만, 해당 CPU가 이 값 증가를 알아챈 다음에는, 새로운 카운터를 사용해야 합니다. 따라서, 일단 모든 CPU들이 알아챘음을 알린다면, 과거의 카운터의 값은 감소만 될 수 있습니다.
2. 특정 CPU는 이 카운터의 값 증가를 알기 전까지만 콜백 리스트들을 진행시킬 수 있습니다.




Figure D.63: Preemptible RCU State Machine

3. 파란 타원은 메모리 오퍼레이션 재배치가 다른 CPU 들이 값 증가를 다른 시간에 볼 수 있음을 알립니다. 이는 특정 CPU 는 어떤 다른 CPU 가 이 카운터의 새로운 값을 해당 카운터가 진짜로 증가하기 전에 사용해서 이 구간을 건너뛰었다고 믿을 수도 있음을 의미합니다. 실제로, 이론상으로는, 특정 CPU 는 `rcu_ctrlblk.completed` 카운터의 다음의 값 증가를 기존의 메모리 배리어가 쳐진 시점만큼 빠른 시간에 볼 수도 있습니다. (이 문장은 매우 부정확함을 알아두시기 바랍니다. 메모리 배리어에 대한 올바름의 증명을 하고자 한다면, Appendix D.4.3.3 를 보기 바랍니다.)
4. `rcu_read_lock()` 은 어떤 메모리 배리어도 포함하고 있지 않기 때문에, 연관된 RCU read-side 크리티컬 섹션들은 해당 CPU 에 의해 `rcu_read_unlock()` 을 뒤따르도록 재배치 될 수도 있습니다. 따라서, 이 RCU read-side 크리티컬 섹션들의 행동들이 실제로 완료되었음을 보장하기 위해 메모리 배리어가 필요합니다.
5. 이어서 보게 되겠지만, 서로 다른 CPU 들이 카운터의 flip 을 서로 다른 시간에 볼 수 있다는 사실은 state machine 을 통한 한 번의 횡단은 grace period




Figure D.64: Preemptible RCU State Machine Timeline

```

1 void rcu_check_callbacks(int cpu, int user)
2 {
3     unsigned long flags;
4     struct rcu_data *rdp = RCU_DATA_CPU(cpu);
5
6     rcu_check_mb(cpu);
7     if (rcu_ctrlblk.completed == rdp->completed)
8         rcu_try_flip();
9     spin_lock_irqsave(&rdp->lock, flags);
10    RCU_TRACE_RDP(rcupreempt_trace_check_callbacks, rdp);
11    __rcu_advance_callbacks(rdp);
12    spin_unlock_irqrestore(&rdp->lock, flags);
13 }
  
```

Figure D.65: `rcu_check_callbacks()` Implementation

에 충분치 않음을 의미합니다: 여러번의 횡단이 필요합니다.

Grace-Period State Machine Walkthrough 이 섹션은 scheduling-clock 인터럽트에서 irq (그리고 preemption) 가 비활성화된 채로 `rcu_check_callbacks()` 를 호출하는, RCU grace-period state machine 을 구현하는 C 코드를 살펴봅니다. 이 함수는 Figure D.65 에 보여지는 것처럼 구현되어 있습니다. Line 4 는 현재의 CPU 에 연관된 `rcu_data` 구조체를 골라내고 line 6 는 이 CPU 가 state machine 을 `rcu_try_flip_waitmb_state` 상

```

1 static void rcu_check_mb(int cpu)
2 {
3     if (per_cpu(rcu_mb_flag, cpu) == rcu_mb_needed) {
4         smp_mb();
5         per_cpu(rcu_mb_flag, cpu) = rcu_mb_done;
6     }
7 }

```

Figure D.66: rcu_check_mb() Implementation

```

1 static void rcu_try_flip(void)
2 {
3     unsigned long flags;
4
5     RCU_TRACE_ME(rcupreempt_trace_try_flip_1);
6     if (!spin_trylock_irqsave(&rcu_ctrlblk.fliplock, flags)) {
7         RCU_TRACE_ME(rcupreempt_trace_try_flip_e1);
8         return;
9     }
10    switch (rcu_try_flip_state) {
11        case rcu_try_flip_idle_state:
12            if (rcu_try_flip_idle())
13                rcu_try_flip_state = rcu_try_flip_waitack_state;
14            break;
15        case rcu_try_flip_waitack_state:
16            if (rcu_try_flip_waitack())
17                rcu_try_flip_state = rcu_try_flip_waitzero_state;
18            break;
19        case rcu_try_flip_waitzero_state:
20            if (rcu_try_flip_waitzero())
21                rcu_try_flip_state = rcu_try_flip_waitmb_state;
22            break;
23        case rcu_try_flip_waitmb_state:
24            if (rcu_try_flip_waitmb())
25                rcu_try_flip_state = rcu_try_flip_idle_state;
26    }
27    spin_unlock_irqrestore(&rcu_ctrlblk.fliplock, flags);
28 }

```

Figure D.67: rcu_try_flip() Implementation

태에서 진행시키기 위해 메모리 배리어를 실행해야 하는지를 체크합니다. Line 7은 이 CPU가 이미 현재 grace-period stage number를 알고 있는지 보고, 그렇다면 line 8에서 이 state machine을 진행시킵니다. Line 9와 12는 rcu_data의 락을 잡고, line 11에서는 적절하다면 콜백들을 수행시킵니다. Line 10에서는 CONFIG_RCU_TRACE가 활성화되어 있다면 RCU tracing을 위한 통계들을 업데이트합니다.

rcu_check_mb() 함수는 Figure D.66에 보여진 것처럼 필요하면 메모리 배리어를 수행합니다. Line 3은 이 CPU가 메모리 배리어를 수행해야 하는지 체크하고, 만약 그렇다면 line 4에서 메모리 배리어를 실행하고 line 5에서 state machine을 알립니다. 이 메모리 배리어는 rcu_mb_flag의 새로운 값을 보는 모든 CPU는 이 CPU에 의해 앞의 RCU read-side 크리티컬 섹션 안에서 수행된 메모리 오퍼레이션들을 보게 될 것을 보장함을 알아두시기 바랍니다.

rcu_try_flip() 함수는 Figure D.67에 보인 것처럼 RCU grace-period state machine의 최고단계 구현을

```

1 static int rcu_try_flip_idle(void)
2 {
3     int cpu;
4
5     RCU_TRACE_ME(rcupreempt_trace_try_flip_i1);
6     if (!rcu_pending(smp_processor_id())) {
7         RCU_TRACE_ME(rcupreempt_trace_try_flip_ie1);
8         return 0;
9     }
10    RCU_TRACE_ME(rcupreempt_trace_try_flip_g1);
11    rcu_ctrlblk.completed++;
12    smp_mb();
13    for_each_cpu_mask(cpu, rcu_cpu_online_map)
14        per_cpu(rcu_flip_flag, cpu) = rcu_flipped;
15    return 1;
16 }

```

Figure D.68: rcu_try_flip_idle() Implementation

합니다. Line 6는 global RCU state-machine lock을 획득하려 시도하고, 실패하면 리턴합니다. Line 5와 7은 (CONFIG_RCU_TRACE가 활성화되어 있다면) RCU-tracing 통계를 조작합니다. Line 10부터 26은 state machine을 수행하는데, 각각 해당 state에 맞는 함수를 수행시킵니다. 그런 함수 각각은 해당 state가 진행되야 한다면 1을, 그렇지 않다면 0을 리턴합니다. 원칙적으로, 다음 state를 곧바로 수행될 수 있지만, 실제로는 응답시간을 줄이기 위해 그렇게 하지 않습니다. 마지막으로, line 27에서는 line 6에서 획득했던 global RCU state-machine lock을 해제합니다.

rcu_try_flip_idle() 함수는 RCU grace-period state machine이 idle 상태일 때 호출되며, 따라서 이 state machine이 필요할 때 시작되도록 해줘야 하는 책임이 있습니다. 그 코드는 Figure D.68에 보여져 있습니다. Line 6는 이 CPU에 남아있는 RCU grace-period 작업이 있는지 체크하고, 그렇지 않다면 top-level state machine에게 idle 상태로 남아있으라고 이야기한채 line 8에서 빠져나옵니다. 그렇지 않고 할 일이 있다면, line 11에서 grace-period stage 카운터의 값을 증가시키고, line 12에서 CPU들이 새로운 카운터를 보아달라는 요청을 받기 전에 그 카운터를 봄을 보장하기 위해 메모리 배리어를 수행하고, line 13과 14에서 모든 online CPU의 rcu_flip_flag를 설정합니다. 마지막으로, line 15에서 top-level state machine에게 다음 state로 넘어가라고 이야기를 합니다.

Figure D.69에 보인 rcu_try_flip_waitack() 함수는 모든 online CPU들이 카운터 뒤집기(“값증가”라고도 말할 수 있지만 rcu_read_lock()은 rcu_flipctr 배열을 인덱스하는데에 사용하는 아래쪽 bit을 실제로 뒤집기에 “뒤집기”라고 불립니다)를 보았는지 체크합니다. 만약 그렇다면, top-level grace-period state machine에게 다음 state로 넘어가라고 이야기합니다.

Line 6는 모든 online CPU들을 보고, line 7은 현재의 CPU가 마지막 카운터 뒤집기를 알아차렸는지 봅니다.

```

1 static int rcu_try_flip_waitack(void)
2 {
3     int cpu;
4
5     RCU_TRACE_ME(rcupreempt_trace_try_flip_a1);
6     for_each_cpu_mask(cpu, rCU_cpu_online_map)
7         if (per_cpu(rcu_flip_flag, cpu) != rCU_flip_seen) {
8             RCU_TRACE_ME(rcupreempt_trace_try_flip_ae1);
9             return 0;
10        }
11    smp_mb();
12    RCU_TRACE_ME(rcupreempt_trace_try_flip_a2);
13    return 1;
14 }

```

Figure D.69: `rcu_try_flip_waitack()` Implementation

```

1 static int rcu_try_flip_waitzero(void)
2 {
3     int cpu;
4     int lastidx = !(rcu_ctrlblk.completed & 0x1);
5     int sum = 0;
6
7     RCU_TRACE_ME(rcupreempt_trace_try_flip_z1);
8     for_each_possible_cpu(cpu)
9         sum += per_cpu(rcu_flipctr, cpu)[lastidx];
10    if (sum != 0) {
11        RCU_TRACE_ME(rcupreempt_trace_try_flip_ze1);
12        return 0;
13    }
14    smp_mb();
15    for_each_cpu_mask(cpu, rCU_cpu_online_map)
16        per_cpu(rcu_mb_flag, cpu) = rCU_mb_needed;
17    RCU_TRACE_ME(rcupreempt_trace_try_flip_z2);
18    return 1;
19 }

```

Figure D.70: `rcu_try_flip_waitzero()` Implementation

그렇지 않다면, line 9에서 top-level grace-period state machine에게 이 state에 남아있으라고 이야기합니다. 그렇지 않고, 모든 online CPU들이 알아차렸다면, line 11에서 마지막 CPU가 알아차렸음을 이야기하기 전에 0을 체크하지 않을 것을 보장하기 위해 메모리 배리어를 칩니다. 이는 의심스럽게 보일 수 있습니다만, CPU 설계자들은 가끔 이상한 짓거리를 하기도 합니다. 마지막으로, line 13은 top-level grace-period state machine에게 다음 state로 넘어가라고 이야기합니다.

Figure D.70에 보인 `rcu_try_flip_waitzero()` 함수는 모든 이전부터 존재한 RCU read-side 크리티컬 섹션들이 완료되었는지 체크하고, 만약 그렇다면 state machine에게 진행하라고 이야기합니다. Line 8과 9는 카운터들의 값의 합을 구하고, line 10은 그 결과가 0인지 확인하고, 만약 그렇지 않다면 line 12에서 state machine에게 현재 상태 그대로 유지하라고 이야기합니다. 그렇지 않다면, line 14에서 어떤 CPU도 자신이 마지막 RCU read-side 크리티컬 섹션을 빠져나오기

```

1 static int rcu_try_flip_waitmb(void)
2 {
3     int cpu;
4
5     RCU_TRACE_ME(rcupreempt_trace_try_flip_m1);
6     for_each_cpu_mask(cpu, rCU_cpu_online_map)
7         if (per_cpu(rcu_mb_flag, cpu) != rCU_mb_done) {
8             RCU_TRACE_ME(rcupreempt_trace_try_flip_me1);
9             return 0;
10        }
11    smp_mb();
12    RCU_TRACE_ME(rcupreempt_trace_try_flip_m2);
13    return 1;
14 }

```

Figure D.71: `rcu_try_flip_waitmb()` Implementation

전에 뒤따르는 메모리 배리어 호출을 볼 수 없을 것을 보장하기 위해 메모리 배리어를 호출합니다. 그런 일이 있을 가능성이 희박해 보이겠지만, 다시 말하건대 CPU 설계자들은 좀 이상한 짓을 해왔고, 사실 그것이 빠른 수행 방법입니다. Line 15와 16은 모든 online CPU의 `rcu_mb_flag` 변수의 값을 설정하고, line 18에서 state machine에게 다음 상태로 진행하라고 이야기합니다.

Figure D.71에 보인 `rcu_try_flip_waitmb()` 함수는 모든 online CPU들이 요청된 메모리 배리어를 수행했는지 체크하고, 만약 그렇다면 state machine에게 진행하라고 이야기합니다. Line 6과 7은 각각의 online CPU에 대해 각각 필요한 메모리 배리어를 쳤는지 확인하고, 만약 그렇지 않다면 line 9에서 state machine에게 진행하지 말라고 이야기합니다. 그렇지 않고, 모든 CPU들이 메모리 배리어를 수행했다면, line 11에서 모든 RCU 콜백 호출이 모든 메모리 배리어들을 뒤따른다는 걸 보장하기 위해 메모리 배리어를 실행하고, line 13은 state machine에게 진행하라고 이야기합니다.

Figure D.72에 보인 `__rcu_advance_callbacks()` 함수는 콜백들을 진행하고 카운터 뒤집기를 확인해줍니다. Line 7은 글로벌한 `rcu_ctrlblk.completed` 카운터가 마지막의 현재 CPU에 의한 이 함수의 호출 이후로 값이 증가되었는지 체크합니다. 그렇지 않다면, 콜백들은 진행될 수 (line 8-37) 없습니다. 그렇다면, line 8부터 37은 리스트의 콜백들을 진행시킵니다 (비어있지 않은 리스트의 갯수를 `w1c` 변수에 관리하면서). 어떤 경우든, line 38부터 43은 필요한 경우 카운터 뒤집기를 확인해줍니다.

Quick Quiz D.58: `__rcu_advance_callbacks()`의 line 38-43은 line 7-37이 수행되지 않음에도 수행될 수가 있다는 거죠? 둘 다 카운터 뒤집기 직후에 수행되는데, 다른 시간이 아니지 않아요? ■

```

1 static void __rcu_advance_callbacks(struct rcu_data *rdp)
2 {
3     int cpu;
4     int i;
5     int wlc = 0;
6
7     if (rdp->completed != rcu_ctrlblk.completed) {
8         if (rdp->waitlist[GP_STAGES - 1] != NULL) {
9             *rdp->donetail = rdp->waitlist[GP_STAGES - 1];
10            rdp->donetail = rdp->waittail[GP_STAGES - 1];
11            RCU_TRACE_RDP(rcupreempt_trace_move2done, rdp);
12        }
13        for (i = GP_STAGES - 2; i >= 0; i--) {
14            if (rdp->waitlist[i] != NULL) {
15                rdp->waitlist[i + 1] = rdp->waitlist[i];
16                rdp->waittail[i + 1] = rdp->waittail[i];
17                wlc++;
18            } else {
19                rdp->waitlist[i + 1] = NULL;
20                rdp->waittail[i + 1] =
21                    &rdp->waitlist[i + 1];
22            }
23        }
24        if (rdp->nextlist != NULL) {
25            rdp->waitlist[0] = rdp->nextlist;
26            rdp->waittail[0] = rdp->nexttail;
27            wlc++;
28            rdp->nextlist = NULL;
29            rdp->nexttail = &rdp->nextlist;
30            RCU_TRACE_RDP(rcupreempt_trace_move2wait, rdp);
31        } else {
32            rdp->waitlist[0] = NULL;
33            rdp->waittail[0] = &rdp->waitlist[0];
34        }
35        rdp->waitlistcount = wlc;
36        rdp->completed = rcu_ctrlblk.completed;
37    }
38    cpu = raw_smp_processor_id();
39    if (per_cpu(rcu_flip_flag, cpu) == rcu_flipped) {
40        smp_mb();
41        per_cpu(rcu_flip_flag, cpu) = rcu_flip_seen;
42        smp_mb();
43    }
44 }

```

Figure D.72: __rcu_advance_callbacks() Implementation

D.4.2.4 Read-Side Primitives

이 섹션은 `rcu_read_lock()` 과 `rcu_read_unlock()` 기능을 살펴보고, 이어서 어떻게 이 구현이 이 두 기능들이 메모리 배리어를 포함하지 않는다는 점을 어떻게 가능하게 했는지 이야기합니다.

`rcu_read_lock()` `rcu_read_lock()`의 구현은 Figure D.73에 보여져 있습니다. Line 7은 이 task의 RCU read-side 크리티컬 섹션 중첩 카운터를 가져옵니다. Line 8에서 이 카운터의 값이 0이 아니란 점이 밝혀지면, 우린 이미 바깥의 `rcu_read_lock()`으로 보호되고 있는 것으로, 이 경우에는 line 9에서 그냥 이 카운터의 값을 증가시킵니다.

하지만, 이게 가장 바깥의 `rcu_read_lock()`이라면,

```

1 void __rcu_read_lock(void)
2 {
3     int idx;
4     struct task_struct *t = current;
5     int nesting;
6
7     nesting = ACCESS_ONCE(t->rcu_read_lock_nesting);
8     if (nesting != 0) {
9         t->rcu_read_lock_nesting = nesting + 1;
10    } else {
11        unsigned long flags;
12
13        local_irq_save(flags);
14        idx = ACCESS_ONCE(rcu_ctrlblk.completed) & 0x1;
15        ACCESS_ONCE(__get_cpu_var(rcu_flipctr)[idx])++;
16        ACCESS_ONCE(t->rcu_read_lock_nesting) = nesting + 1;
17        ACCESS_ONCE(t->rcu_flipctr_idx) = idx;
18        local_irq_restore(flags);
19    }
20 }

```

Figure D.73: __rcu_read_lock() Implementation

더 많은 작업이 필요합니다. Line 13과 18은 그 사이의 코드가 preemption 되지도 않고 (grace period state machine을 수행시키는) scheduling-clock 인터럽트로 인터럽트 당하지도 않았다는 것을 보장하기 위해 irq들을 막고 다시 풀어줍니다. Line 14는 grace-period 카운터를 얻어오고, line 15에서 이 CPU를 위한 현재 카운터의 값을 증가시키고, line 16에서 중첩 카운터의 값을 증가시킨 후, line 17에서 `rcu_read_unlock()`이 연관된 카운터의 값을 감소시킬 수 있도록 기존/새로운 카운터 인덱스를 기록합니다.

`ACCESS_ONCE()` 매크로들은 컴파일러가 순서대로 액세스 코드를 만들어 내도록 강제합니다. 비록 이게 CPU가 액세스들을 다른 CPU의 관점으로부터 다르게 재배치하는 것을 막지는 못하지만, 이 CPU에서 수행되는 NMI와 SMI 핸들러들은 이 액세스들을 순서대로 볼 것을 보장해 줍니다. 이는 상당히 중요합니다:

1. idx로의 값 할당에 `ACCESS_ONCE()`가 없다면, 컴파일러는: (a) 로컬 변수 idx를 삭제하고 (b) line 16에서의 값 증가를 fetch-increment-store로 컴파일해서 `rcu_ctrlblk.completed`에서 값을 읽어오고 다시 쓰는 두번의 별개의 액세스로 만들어버릴 수 있는 권리를 갖습니다. 만약 그 사이에 `rcu_ctrlblk.completed`의 값이 바뀌었다면, 이는 `rcu_flipctr` 값을 잘못되게 만들 수 있습니다.
2. `rcu_read_lock_nesting`으로의 값 할당 (line 17)이 `rcu_flipctr`의 값 할당 (line 16) 앞으로 재배치된다면, 그리고 NMI가 이 두 이벤트 사이에 발생했다면, 해당 NMI 핸들러 안에서의 `rcu_read_lock()`은 자신이 이미 `rcu_read_lock()`의 보호 아래 있다고 잘못된 결론을 내릴 겁니다.
3. 만약 `rcu_read_lock_nesting`으로의 값 할당

(line 17) 이 `rcu_flipctr_idx` 에의 값 할당 (line 18) 뒤로 재배치된다면, 그리고 NMI 가 이 두 이벤트 사이에 발생한다면, 해당 NMI 핸들러 안에서의 `rcu_read_lock()` 은 `rcu_flipctr_idx` 를 망쳐버려서, 짹을 이루는 `rcu_read_unlock()` 이 잘못된 카운터의 값을 감소시키도록 만들 수 있습니다. 이는 결국 grace period 가 너무 빨리 끝나거나 grace period 를 무기한 연장시킬 수도, 두 사건이 모두 일어날 수도 있습니다.

`nesting` 에의 값 할당 (line 7) 에 `ACCESS_ONCE` 가 필요한가는 명확치 않습니다. 또한 `smp_read_barrier_depends()` (line 15) 이 필요한지도 명확치 않습니다. 이것들은 인덱스와 값의 변경이 순서가 유지되도록 추가되었습니다.

Line 13 부터 line 19 사이에 irq 가 비활성화 되어야 하는 이유는 다음과 같습니다:

1. 한 CPU 가 `rcu_ctrlblk.completed` 를 읽어왔고 (line 14), 이어서 두번째 CPU 가 이 카운터의 값을 증가시켰으며, 이어서 첫번째 CPU 가 `scheduling-clock` 인터럽트를 받았다고 생각해 봅시다. 첫번째 CPU 는 이제 이 카운터 뒤집기를 확인해 줘야 함을 보게 되며, 그렇게 할겁니다. 이 확인 행위는 새로이 과거의 것이 되는 카운터의 값을 증가시키는 것을 막을 것이라는 약속인데, 이 CPU 는 이 약속을 깨게 될겁니다. 더 나쁜건, 이 CPU 가 `scheduling-clock` 인터럽트로부터의 리턴 직후에 `preemption` 당할 수 있고, 따라서 미래의 무작위한 어느 시점에 카운터의 값을 증가시킬 수 있다는 겁니다. 두 상황 모두 `grace-period` 텀지를 망칠 수 있습니다.
2. IRQ 들을 비활성화 시키는 것은 `preemption` 을 비활성화 시키는 side effect 를 갖습니다. 만약 이 코드가 `rcu_ctrlblk.completed` 를 읽어들이는 것 (line 14) 과 `rcu_flipctr` 의 값을 증기시키는 것 (line 16) 사이에서 `preemption` 될 수 있다면, 다른 CPU 에서 동작을 재개할 수 있을 겁니다. 이는 이 카운터를 다른 CPU 로부터 가져와서는 atomic 하지 않게 값 증가를 시키는 결과를 낳을 수 있습니다. 이 CPU 가 바로 그 시점에서 `rcu_read_lock()` 또는 `rcu_read_unlock()` 을 수행 중이었다면 하나의 값 증가 또는 감소가 없던게 되어버려서, 역시 `grace-period` 텀지를 망칩니다. RISC 머신에서는 값 증가 사이에 (기존 카운터의 값 읽기 후 새로이 증가된 값의 저장 전에) `preemption` 이 발생하면 같은 결과가 이뤄질 수 있을 겁니다.
3. line 16 의 중간에, 현재 CPU 의 `rcu_flipctr` 배열의 복사본을 고르는 것과 `rcu_flipctr_idx` 로 선택된 원소의 값을 증가시키는 사이에 `preemption`

을 허용하는 것은 비슷한 문제를 일으킬 수 있습니다. 실행은 이번에도 역시 다른 CPU 에서 재개될 수 있습니다. 이 실행 재개가 원래 CPU 에서 수행 중인 `rcu_read_lock()` 또는 `rcu_read_unlock()` 과 동시에 발생한다면, 하나의 값 증가 또는 값 감소가 사라질 수 있어서 `grace period` 의 너무 빠른 종료 또는 무기한 연장, 또는, 심지어 둘 다를 일으킬 수 있습니다.

4. Preemption 비활성화를 못하게 되는 것 역시 특정 task 가 언제 RCU read-side 크리티컬 섹션에 있는지 파악하는데 `rcu_read_lock_nesting` 을 사용하는 RCU priority boosting 을 망칠 수 있습니다. 따라서, 예를 들어, 어떤 task 가 `rcu_flipctr` 를 증가시킨 후, `rcu_read_lock_nesting` 의 값을 업데이트 하기 전에 `preemption` 당한다면, `preemption` 당한 동안 RCU grace period 를 멈춰둘 수 있을 겁니다. 하지만, `rcu_read_lock_nesting` 은 아직 값이 증가되지 않았으므로, RCU priority booster 는 이 boosting 이 필요하다고 말할 수 없습니다. 따라서, CPU-bound realtime thread 가 존재한다면 이 `preemption` 당한 task 는 무기한적으로 `grace period` 를 멈춰버릴 수 있어서 결국 OOM 이벤트를 일으킬 겁니다.

마지막 세개의 이유는 물론 irq 를 비활성화 하는게 아니라 `preemption` 만 비활성화 하는 것으로도 해결될 수 있습니다만, 첫번째 이유는 irq 를 비활성화 할 것을 필요로 하기에, 굳이 구분해서 `preemption` 만 비활성화 할 이유는 없습니다. 첫번째 이유는 추가적인 `grace-period stage` 를 두어서 해결하는 것도 확실히 가능합니다만, 최근의 CPU 들에서 `preemption` 을 비활성화 하는 것이 인터럽트를 비활성화 하는것보다 엄청 빠른가는 확실치 않습니다.

`rcu_read_unlock()` Figure D.74 에 `rcu_read_unlock()` 의 구현이 보여 있습니다. Line 7 은 `rcu_read_lock_nesting` 카운터를 읽어오고, line 8 은 우리가 우리를 둘러싼 `rcu_read_lock()` 의 보호 아래 있는지 확인합니다. 만약 그렇다면, line 9 에서 그냥 카운터의 값을 감소시킵니다.

하지만, `rcu_read_lock()` 에서와 같이, 그렇지 않다면 더 많은 일을 해야 합니다. Line 13 과 17 은 `rcu_read_unlock()` 처리 과정 중에 `scheduling-clock` 인터럽트가 `grace-period state machine` 을 일깨우는 것을 막기 위해 irq 들을 막고 재활성화 시킵니다. Line 14 는 짹을 맞추는 `rcu_read_lock()` 에서 저장된 `rcu_flipctr_idx` 를 가져오고, line 15 는 irq 와 NMI/SMI 핸들러들이 앞으로 `rcu_flipctr` 를 업데이트 할 수 있도록 `rcu_read_lock_nesting` 의 값을 감소시키고, line 16 은

```

1 void __rcu_read_unlock(void)
2 {
3     int idx;
4     struct task_struct *t = current;
5     int nesting;
6
7     nesting = ACCESS_ONCE(t->rcu_read_lock_nesting);
8     if (nesting > 1) {
9         t->rcu_read_lock_nesting = nesting - 1;
10    } else {
11        unsigned long flags;
12
13        local_irq_save(flags);
14        idx = ACCESS_ONCE(t->rcu_flipctr_idx);
15        ACCESS_ONCE(t->rcu_read_lock_nesting) = nesting - 1;
16        ACCESS_ONCE(__get_cpu_var(rcu_flipctr)[idx])--;
17        local_irq_restore(flags);
18    }
19 }

```

Figure D.74: __rcu_read_unlock() Implementation

카운터의 값을 감소시킵니다.

ACCESS_ONCE() 매크로와 irq 비활성화는 rCU_read_lock()에서와 비슷한 이유로 필요합니다.

Quick Quiz D.59: rCU_read_unlock()의 ACCESS_ONCE()가 컴파일러에 의해 재배치된다면 어떤 문제가 발생할 수 있나요? ■

Quick Quiz D.60: rCU_read_unlock() 내의 ACCESS_ONCE()를 포함한 코드가 CPU에 의해 재배치되면 어떤 문제가 일어날 수 있을까요? ■

Quick Quiz D.61: irq들이 비활성화되어 있지 않다면 rCU_read_unlock()에 어떤 문제가 있을 수 있나요? ■

Memory-Barrier Considerations 이 두개의 기능들은 메모리 배리어들을 포함하고 있지 않으며, 따라서 rCU_read_lock()을 실행하기 전 또는 rCU_read_unlock()을 수행한 후에 크리티컬 섹션을 CPU가 수행하는 것을 막을 방법이 없다는 것을 알아두시기 바랍니다. rCU_try_flip_waitmb_state의 목적은 이런 가능한 재배치를 처리하기 위한 것입니다만, grace period의 시작과 끝에서만 그렇습니다. 왜 이 방법이 좋은지 알아보려면, 메모리 배리어를 RCU read-side 크리티컬 섹션의 시작과 끝에 위치시키는 것의 낭비 [MSMB06]를 보여주는 Figure D.75를 보시기 바랍니다.

“MB”들은 메모리 배리어들을 의미하며, 굵게 표시된 배리어들만이 필요한데, 각 CPU의 각 grace period의 시작과 끝에서의 것들입니다. 따라서 이 peremptible RCU 구현은 Figure D.76에 보인 것처럼 grace period에 메모리 배리어를 연관시킵니다.

리눅스 커널은 말그대로 수백만의 RCU read-side 크리티컬 섹션들을 grace period 당 수행할 수 있다는 점을 놓고 보면, 이 방법은 read-side 비용의 상당한 절감을 가능하게 하는데, 메모리 배리어의 비용을 grace period




Figure D.75: Preemptible RCU with Read-Side Memory Barriers

내의 모든 read-side 크리티컬 섹션들로 청산하기 때문입니다.

D.4.3 Validation of Preemptible RCU

D.4.3.1 Testing

Preemptible RCU는 2단계 grace period와 함께 완화된 순서 규칙의 POWER4와 POWER5 CPU에서 각각 24시간씩 15백만, 2천만 grace period를 각각 가지고 rcutorture로 테스트되었으며 어떤 에러도 없었습니다. 물론, 이것만으로는 이 알고리즘이 옳다고 증명하지 못합니다. 여기서 최대한 이야기 할 수 있는건, 이 결과가 이 두개의 기계들은 굉장히 운이 좋았거나 preemptible RCU에 남아 있는 버그들은 매우 낮은 발생 확률을 가지고 있다는 것입니다. 따라서 우리는 이 알고리즘이 동작한다는 확신이, 또는, 남아있는 버그의 확인이 필요합니다.

이 작업은 개념적 접근방법을 필요로 하는데, 이에 대해 다음 섹션에서 설명합니다.




Figure D.76: Preemptible RCU with Grace-Period Memory Barriers




Figure D.77: Preemptible RCU Worst-Case Scenario

D.4.3.2 Conceptual Validation

`rcu_read_lock()` 도 `rcu_read_unlock()` 도 메모리 배리어를 포함하고 있지 않기 때문에, RCU read-side 크리티컬 섹션은 완화된 순서규칙의 기계에선 빠져나올 수가 있습니다. 또한, 이 RCU 구현의 상대적으로 완화된 결합은 CPU들이 언제 특정 grace period가 시작하고 끝났는지에 대해 다르게 생각할 수 있게 합니다. 이는 특정 RCU read-side 크리티컬 섹션이 grace-period state machine에 상대적으로 얼마나 길게 연장될 수 있는지 질문을 떠올리게 합니다.

최악의 경우가 Figure D.77에 보여져 있습니다. 여기서, CPU 0은 가장 짧은 객체 제거와 메모리에서의 해제 처리를 진행하고, 그 사이 CPU 1은 가장 긴 RCU read-side 크리티컬 섹션을 수행합니다. 콜백 대기열들은 카운터 뒤집기를 알리기 직전에 진행되므로, CPU 0이 `list_del_rcu()` 와 `call_rcu()`를 수행할 수 있는 가장 최신의 순간은 카운터 뒤집기를 알리는 scheduling clock 인터럽트 직전입니다. `call_rcu()` 호출은 콜백을 CPU 0의 `next` 리스트에 놓고, 이 인터럽트는 이 콜백을 `next` 리스트에서 `wait[0]` 리스트로 옮길 겁니다. 이 콜백은 다음 카운터 뒤집기를 뒤따르는 첫번째 scheduling-clock 인터럽트 때에 다시 (`wait[0]` 리스트에서 `wait[1]` 리스트로) 옮겨집니다. 비슷하게, 이 콜백은 값 3을 되게 하는 카운터 뒤집기를 뒤따르는 CPU 0의 첫번째 scheduling-clock 인터럽트 때에 `wait[1]`에서 `done` 리스트로 옮겨질 겁니다.

그 사이, CPU 1은 RCU read-side 크리티컬 섹션을 수행하고 있습니다. 여기서의 `rcu_read_lock()`이 (값을 1이 되게 하는) 첫번째 카운터 뒤집기를 뒤따라서, 이 `rcu_read_lock()`이 CPU 1의 `rcu_flipctr[1]` 카운터의 값을 증가시킨다고 가정해 봅시다. `rcu_read_lock()`은 어떤 메모리 배리어도 포함하지 않기 때문에, 이 크리티컬 섹션의 내용은 이 CPU에 의해 더 먼저 수행될 수 있다는 점을 기억하세요. 하지만, 그림에 보인 것처럼, 이 더 빠른 수행은 CPU 1에 의해 수행되는 앞의 메모리 배리어를 앞설 수는 없습니다. 그러나 이는 `rcu_dereference()`가 CPU 0의 `list_del_rcu()`에 의해 지워지는 항목을 읽어올 수 있기에 충분할 만큼 빠릅니다.

이 `rcu_read_lock()`은 index-1 카운터의 값을 증가켰으므로, 연관된 `rcu_read_unlock()`은 인덱스 1을 위한 “기존 카운터들이 0이 되는” 이벤트를 앞서 야만 합니다. 하지만, `rcu_read_unlock()`은 메모리 배리어를 포함하고 있지 않기에, 연관된 RCU read-side 크리티컬 섹션의 (CPU 0에 의해 삭제된 항목을 레퍼런스하고 있을 수도 있는) 내용물은 CPU 1에 의해 더 나중에 수행될 수 있습니다. 하지만, 그림에도 보여져 있듯 이는 CPU 1의 다음 메모리 배리어보다 나중에 수행될 수는 없습니다. CPU 1에 의한 가능한 마지막

참조는 가장 빠른 있을 수 있는 CPU 0 의 콜백 수행을 앞서기에, grace-period state machine 을 통한 두 경로들은 완전한 grace period 를 구성하기에 충분하며, 따라서 다음의 코드가 수행되기에 안전합니다:

```
#define GP_STAGES 2
```

Quick Quiz D.62: `rcu_read_lock()` 의 irq 비활성화가 preemption 비활성화로 대체되었다고 생각해 봅시다. `GP_STAGES` 에 어떤 영향이 있을 수 있을까요? ■

Quick Quiz D.63: 왜 `rcu_dereference()` 가 메모리 배리어를 앞설 수 없나요? ■

D.4.3.3 Formal Validation

이 알고리즘의 형식적 검증은 상당히 중요합니다만, 미래에 할 일로 남겨뒀습니다. 이 검증을 하는 도구 가운데 하나는 Chapter 12 에 설명되어 있습니다.

Quick Quiz D.64: ‘CPU 0 는 CPU 1 의 값 증가를 CPU 1 의 앞선 마지막 메모리 배리어 만큼 빠른 시점에 볼 수도 있다’ 를 더 정확히 말하려면 어떻게 말해야 할까요? ■

Appendix E

Read-Copy Update in Linux

이 챕터에서는 2008년 중반 이후부터의 리눅스 커널에서의 RCU의 역사를 설명합니다. 그 전의 RCU의 역사를 대해서는 다른 곳 [McK04, MW08]을 찾아 보시기 바랍니다. Section E.1은 리눅스에서의 RCU 사용의 증가를 개괄적으로 알아보고 Section E.2는 최근의 RCU의 진화에 대한 자세한 설명을 제공합니다.

E.1 RCU Usage Within Linux

리눅스 커널의 RCU 사용은 Figure E.1 [McK06a]를 통해 볼 수 있듯이 시간에 따라 증가되었습니다. RCU는 코드 내에 존재하는 다른 동기화 메커니즘(예를 들면, 네트워킹 프로토콜 스택의 `brlock` [MM00, Tor03a, Tor03b])들을 대체했으며, 새로운 기능을 구현하는 코드(예를 들면, SELinux [Mor04]에서의 audit 시스템)와 함께 나타나기도 했습니다. 하지만, RCU는 Figure E.2에 보여지듯이 락킹에 비해서 틈새에만 사용되는 기술로 남아있습니다. 락킹이 커널 해커의 동시성 도구상자의 망치라면, RCU는 아마도 스크류드라이버입니다. 만약 그렇다면, Figure E.3를 통해 볼 수 있듯 매우 급격히 성장하는 스크류드라이버입니다.

E.2 RCU Evolution

이 섹션은 2008년 중반 이후 계속 진행중인 RCU에 대한 경험을 제공합니다.

E.2.1 2.6.27 Linux Kernel

이 릴리즈는 `call_rcu_sched()`, `rcu_barrier_sched()`, 그리고 `rcu_barrier_bh()` RCU API 멤버를 추가했습니다.

E.2.2 2.6.28 Linux Kernel

RCU API의 크기를 실제로 줄이는데에 관련된 변경 사항으로 `list_for_each_rcu()` 기능의 제거가 있었습니다. 이 기능은 `list_head` 구조체를 구성하는 포인터쌍을 따라가기보다는 (헷갈릴 수 있지만, 리스트 헤더뿐 아니라 리스트 원소로 동작하는) 구조체들을 따라가는 장점을 가진 `list_for_each_entry_rcu()`로 대체되었습니다. 이 변경은 2.6.28 리눅스 커널에 받아들여졌습니다.

안타깝게도, 2.6.28 리눅스 커널은 또한 `rcu_read_lock_sched()`과 `rcu_read_unlock_sched()` RCU API 멤버들을 추가했습니다. 이 API들은 가독성을 올리기 위해 추가되었습니다. 과거에는, `synchronize_sched()`에 연관된 RCU read-side 크리티컬 섹션들을 표시하기 위해 인터럽트나 `preemption`을 불능화 시키는데 사용되는 기능들을 사용했습니다. 하지만, 이는 개발자들이 `preemption`이나 인터럽트를 불능화 시킬 필요가 없어졌지만 RCU 보호를 위한 필요를 알지 못할 때에 버그가 생기도록 이끌었습니다. `rcu_read_lock_sched()`의 사용은 그런 버그를 예방하는데 도움이 될 것입니다.

E.2.3 2.6.29 Linux Kernel

새로운 더욱 확장성 있는 구현, “Tree RCU”가 `bitmap`을 `combining tree`로 대체하면서 2.6.29 리눅스 커널에 받아들여졌습니다. 이 구현은 근래의 멀티프로세서들의 계속해서 증가하는 코어의 갯수에서 영감을 받아서 수백개의 CPU 환경을 위해 설계되었습니다. 현재의 구조상의 한계는 262,144 개 CPU 인데, 이는 개발자들이(순진한 것일 수도 있지만) 한동안은 충분할 것이라 믿는 숫자입니다. 이 구현은 또한 `preemptible RCU`의 개선된 `dynamic-tick` 인터페이스 인터페이스를 받아들였습니다.

Mathieu Desnoyers는 리눅스 커널의 tracing code가 RCU를 사용하도록 하는데 필요한




Figure E.1: RCU API Usage in the Linux Kernel




Figure E.2: RCU API Usage in the Linux Kernel vs. Locking




Figure E.3: RCU API Growth Over Time

`rcu_read_lock_sched_notrace()` 와 `rcu_read_unlock_sched_notrace()` 를 추가했습니다. 이 API 들 없이는, RCU read-side 크리티컬 섹션을 추적하려는 시도는 무한 재귀 문제를 일으킵니다.

Eric Dumazet 은 리스트 포인터에 단일 비트 마커들이 저장될 수 있도록 하는 새로운 종류의 RCU로 보호되는 리스트를 추가했습니다. 이 종류의 리스트는 여러개의 락이 없는 알고리즘들을 가능하게 하는데, Maged Michael 에 의해 보고된 것 [Mic04] 등을 포함합니다. Eric 의 작업은 `hlist_nulls_add_head_rcu()`, `hlist_nulls_del_rcu()`, `hlist_nulls_del_init_rcu()`, 그리고 `hlist_nulls_for_each_entry_rcu()` 를 추가합니다. 이는 또한 `hlist_nulls_node` 라는 이름의 새로운 구조체를 추가합니다.

또한, 이건 엄격히 말해서 리눅스 커널의 부분은 아니긴 하지만, 동시에 Mathieu Desnoyers 는 그의 유저 스페이스 RCU 구현 [Des09b] 을 발표했습니다. 이는 real-time user-level RCU 구현을 향한 중요한 첫걸음입니다.

E.2.4 2.6.31 Linux Kernel

Jiri Pirko 는 RCU-subscription 기능인 `rcu_dereference()` 를 더 높은 수준의 리스트 접근 기능에 포함시킨 `list_entry_rcu` 와 `list_first_entry_rcu()` 기능을 추가했는데, 이 기능들은 일련의 버그들을 제거해줄 수 있을 겁니다.

또한, “Tree RCU” 구현은 “experimental” 상태로부터

업그레이드 되었습니다.

E.2.5 2.6.32 Linux Kernel

리눅스 커널의 이 버전에서의 가장 큰 변경은 “Classic RCU” 구현의 제거일 것입니다. 이 구현은 “Tree RCU” 구현으로 대체되었습니다.

이 버전은 그 외에도 여러 변경을 가졌는데, 다음과 같은 것들이 포함됩니다:

1. `synchronize_rcu_expedited()`, `synchronize_sched_expedited()`, 그리고 `synchronize_rcu_bh_expedited()` RCU API 멤버들의 추가. 이 기능들은 grace period 를 신속히 처리하기 위해 측정을 한다는 점을 제외하고는 non-expedited 버전의 것들과 동일합니다.
2. “Tree RCU” 구현에 preemptible-RCU 기능들을 추가함으로써 리눅스로 돌아가는 커다란 멀티프로세서 머신에서의 real-time response 에 대한 문제를 해결.
3. 이 새로운 “Tree Preemptible RCU” 구현은 기존의 preemptible RCU 구현을 구형으로 만들어서 리눅스 커널에서 사라지게 했습니다.

E.2.6 2.6.33 Linux Kernel

이 릴리즈에서의 가장 극적인 추가사항은 Tree RCU 에서의 day-one 버그 [McK09a] 였을 겁니다. 다른 변경 사항들은 다음과 같습니다:

1. “RCU: The Bloatwatch Edition” [McK09b] 라고도 알려진 “Tiny RCU”.
2. `synchronize_srcu_expedited()` 의 형태의 expedited SRCU.
3. 앞서 이야기된 버그에 의해 촉발된 Tree RCU 동기화의 정리.
4. Tree Preemptible RCU 의 expedited 구현의 추가 (이전의 릴리즈에서, “expedited” 지원은 단순히 `synchronize_rcu()` 로 매팅되었는데, 이는 의미적으로는 옳은 동작이지만 성능 관점에서는 별로 도움이 되지 않았습니다.)
5. 스트레스 테스트를 항상시킨 네번째 수준의 Tree RCU 추가. 이로 인해, 누군가가 16,777,216 개의 CPU 를 가진 시스템에서 리눅스를 돌리고자 한다면, RCU 를 그런 환경에도 준비가 되었습니다! 대략 1600 만개의 per-CPU 데이터 원소들을 스캐닝 하는 것에 대한 응답시간 의미 ...

E.2.7 2.6.34 Linux Kernel

이 릴리즈에서 가장 눈에 띠는 추가사항은 `rcu_dereference()` 가 올바른 락킹 조건을 체크하도록 하는 `CONFIG_PROVE_RCU` [McK10] 였습니다. 다른 변경들은 다음과 같습니다:

1. 기존 grace period 를 강제하고 새로운 grace period 를 시작하는 사이의 Tree RCU 의 상호작용의 간소화.
2. Free-running 카운터들이 부호 없게 되도록 카운터들을 재작업. (C-컴파일러 해커들이 부호 있는 정수를 오버플로우 시킴으로써 코드를 깨먹을 수 있는 최적화를 이야기하면서 얼굴에 띠웠던 즐거운 표정을 여러분은 상상하지도 못할겁니다!!!!)
3. RCU read-side 크리티컬 섹션 안에서 지나치게 많은 시간 동안 preemption 당한 모든 태스크들을 출력하기 위한 Tree Preemptible RCU 의 stall 파악 기능 업데이트.
4. Tree RCU 의 CPU-stall-detection 코드의 다른 버그 수정과 개선. 이 코드는, 예를 들어, 인터럽트가 불능화 된채 무한루프를 돌거나 하는, 락업된 CPU 들을 체크합니다.
5. 배터리로 동작하는 멀티프로세서 시스템에서 마지막 CPU 가 idle 상태로 빠질 때 grace period 를 가속화 시키기 위한 일부 코드를 프로토타입. 시스템이 모든 CPU 들이 꺼질 수 있는 상태로 넘어가는데에 추가적인 몇 밀리세컨드를 RCU 가 가져가는데 대해서 상당히 불쾌해 했던 사람들이 존재합니다!

E.2.8 2.6.35 Linux Kernel

이 릴리즈는 여러개의 버그 수정과 코드 정리를 추가합니다. 여기서의 주요 변경 사항은 Mathieu Desnoyers 의 RCU 콜백의 오용을 위한 검사로, 예를 들면 하나의 grace period 안에서 `rcu_head` 구조체를 `call_rcu()` 에 두번 보내거나 하는 경우입니다.

E.2.9 2.6.36 Linux Kernel

Mathieu Desnoyers 의 디버그 목적의 작업물의 핵심은 2.6.36 에 나타났는데, 일부 코드 정리 작업은 다른 maintainer 트리들에 나오는 커밋들과의 종속성 때문에 2.6.37 로 미뤄졌습니다. Arnd Bergmann 의 sparse RCU 검사의 한 핵심적 부분이 2.6.36 에 나타났는데, 나머지는 역시 다른 maintainer 트리에 나오는 커밋과의 종속성 때문에 2.6.37 로 미뤄졌습니다. 마지막으로, Eric Dumazet 으로부터의 패치는 `rcu_dereference_bh()` 의 여러 검사에서의 에러를 고쳤습니다.

E.2.10 2.6.37 Linux Kernel

Mathieu Desnoyers 의 디버그 목적 작업의 마지막 정리 작업이 2.6.37 에 Arnd Bergmann 의 sparse 기반 검사 작업과 함께 나타났습니다. Lai Jiangshan 은 rcutorture 에 preemption 에 의한 문제 상황을 추가했고 Tree RCU 의 per-CPU 데이터 처리를 일부 간단화 시켰습니다. Tetsuo Handa 는 RCU lockdep 으로 나온 문제 하나를 고쳤고, Christian Dietrich 는 불필요하게 반복된 #ifdef 를 제거했으며, Dongdong Deng 은 일부 Tree RCU 제어 데이터로의 락 없는 액세스를 가능하게 하도록 ACCESS_ONCE() 를 추가했습니다.

Paul 의 preemptible Tiny RCU 의 구현 또한 RCU CPU stall-warning 코드, docbook 수정, 중복 코드의 합체, Tree RCU 속도 향상, RCU callback flow 에의 queuing 모델 지원에 대한 tracing 추가, 그리고 몇가지 기타 수정과 정리 작업과 함께 2.6.37 에서 나타났습니다.

E.2.11 2.6.38 Linux Kernel

Lai Jiangshan 은 synchronize_sched_expedited() 를 kernel/sched.c 에서 그것이 유래한 kernel/rcutree.c 와 kernel/rcu_tiny.c 로 옮겼습니다. 그는 또한 orphan_cbs_list 를 제거함으로써 CPU-hotplug 오퍼레이션 동안의 RCU-callback 처리를 단순화 해서, offline 이 되는 CPU 에 의해 고아가 되는 RCU 콜백들이 곧바로 해당 offline 화 시키는 동작을 함께 돋는 CPU 들에 의해 곧바로 처리될 수 있도록 했습니다. Tejun Heo 는 synchronize_sched_expedited() 의 batching 기능을 개선했는데, 이는 결국 많은 동시적 synchronize_sched_expedited 오퍼레이션들을 갖는 워크로드들의 성능과 확장성을 개선했습니다. Frédéric Weisbecker 는 RCU 를 idle 상태일 때 더욱 전력에 효율적이도록 만들어주는 RCU 핵심 코드상의 일부 변경을 제공했습니다. Mariusz Kozlowski 는 __list_for_each_rcu() 상의 문법상 에러를 고쳐졌고, 곧 사라졌습니다. (하지만 이 고쳐진 버전은 필요한 경우를 위해 git tree 상에 존재합니다.) Nick Piggin 은 RCU 로 보호되는 bit-locked doubly-linked list 들을 위해 hlist_bh_set_first_rcu(), hlist_bh_first_rcu(), hlist_bh_del_init_rcu(), hlist_bh_del_rcu(), hlist_bh_add_head_rcu(), 그리고 hlist_bh_for_each_entry_rcu() 기능을 추가했습니다. Christoph Lameter 는 변수가 곧바로 접근되는 경우에 사용 되기 위한 __get_cpu_var() 의 최적화된 변종인 __this_cpu_read() 를 구현했습니다.

또한, TINY_RCU 는 priority boosting 을 얻었고, synchronize_srcu_expedited() 의 race condition 이 고쳐졌고, synchronize_srcu_expedited() 가

동시적인 읽기 쓰레드들이 존재할 때에 expedited 본성을 얻을 수 있도록 수정되었으며, grace-period 시작/종료 검사가 개선되었고, TREE_RCU 의 leaf-level fanout 이 lock-contention 문제들을 고치기 위해 16 으로 제한되었습니다. 이 마지막 변경은 TREE_RCU 와 TREE_PREEMPT_RCU 가 지원할 수 있는 CPU 들의 최대 갯수를 4,194,304 로 줄였는데, 이는 (다시 말하지만, 어쩌면 순진하게도) 충분할 것으로 여겨집니다.

E.2.12 2.6.39 Linux Kernel

Lai Jiangshan 은 task 가 RCU read-side 크리티컬 섹션 내에서 종료되는 경우에 디버깅 상태를 보존하기 위해 exit_rcu() 가 rCU_read_unlock() 대신 __rcu_read_unlock() 을 호출하도록 만들었으며, Jesper Juhl 은 rcutorture 내의 중복된 sched.h 포함을 제거했고, Amerigo Wang 은 rCU_fixup_free() 로부터 의미없는 코드들을 일부 제거했습니다.

또한, MCE 서비스에서의 사용을 위해 새로운 rCU_access_index() 가 만들어졌습니다.

E.2.13 3.0 Linux Kernel

많은 사람들이 2.6.40 릴리즈가 될 것이라 예상했던 것은 3.0 릴리즈가 되었습니다. 여기서 가장 중요한 RCU 기능은 Tree RCU 를 위한 priority boosting 의 추가였습니다: 계획했던 것보다 여려면에서 중요해서 [McK11a], 3.0-rc7 뒤의 RCU 수정이 되었습니다. Shaohua Li, Peter Zijlstra, Steven Rostedt 의 RCU, 스케줄러, 그리고 thread 로 돌아가는 인터럽트들 사이의 충돌의 fallout 처리에 대한 많은 도움에 감사 드리는 바입니다. 또한, RCU CPU stall warning 들은, 여전히 커널 부트 패러미터나 sysfs 로 조정될 수 있는 rCU_cpu_stall_suppress 모듈 패러미터로 불능화 될 수 있긴 하지만, 이제 무조건적으로 Tree RCU 안으로 컴파일 됩니다.

Mathieu Desnoyers 는 non-preemptible RCU 구현에 들어오게 되는 DEBUG_OBJECTS_RCU_HEAD 체크를 활성화 시켰습니다. Lai Jiangshan 은 fire-and-forget kfree_rcu() 를 만들었고 (그리고 이를 커널을 통해 적용했습니다), 또한 exit_rcu() 가 task 가 RCU read-side 크리티컬 섹션 내에서 끝나는 경우에 디버깅 상태를 유지할 수 있도록 하기 위해 rCU_read_unlock() 대신 __rcu_read_unlock() 을 호출하도록 만들었습니다. Eric Dumazet 는 더 나아가서 TINY_RCU 를 감소시켰고 Gleb Natapov 는 가상화가 guest OS 와의 문맥 전환 시에 일어나는 quiescent state 들 사이에 RCU 가 신경을 쓸 수 있도록 RCU hook 들을 추가했습니다. Peter Zijlstra 는 RCU kthread 블록킹과 wakeup 을 streamline 시켰습니다.

E.2.14 3.1 Linux Kernel

3.1 버전은 Arun Sharma, Jiri Kosina, Michal Hocko, Peter Zijlstra, 그리고 Jan H. Schönherr로부터의 마이너한 수정들과 코드 정리들을 포함한, RCU에 있어서는 조용한 시간이었습니다.

E.2.15 3.2 Linux Kernel

3.2 리눅스 커널은 RCU의 코드의 꼭대기부터 바닥까지의 검사 첫번째 단계에서 발견된 문제들에 대한 여러 수정사항들을 담고 있습니다. 이 검사의 결과물 가운데 하나는 코드의 irq 불능화된 구간이 preemptible RCU read-side 크리티컬 섹션의 시작이 아니라 끝과 겹치게 되면 데드락이 일어날 수 있다는 것입니다. 따라서, 부분적으로 irq 불능화된 코드 구간과 겹칠 수 있는 RCU read-side 크리티컬 섹션들을 만들지 마세요: 대신에, irq 불능화된 코드 섹션을 주어진 RCU read-side 크리티컬 섹션 안에 완전히 집어넣거나 그 반대로 하거나 하세요.

이 릴리즈는 RCU 이벤트 추적 기능을 처음으로 보였습니다. Eric Dumazet는 RCU의 kthread들이 NUMA 시스템에 최적화된 방식으로 위치된 메모리를 가지게 됨을 보장하는 `kthread_create_on_node()` 기능을 적용했습니다. 그는 또한 `rcu_assign_pointer()` 가 무조건적으로 메모리 배리어를 삽입하도록 했는데, 특정 환경에서는 이 메모리 배리어가 생략되게 했던 기존의 컴파일러의 마술이 그보다 최신의 버전의 컴파일러에서는 통하지 않았기 때문입니다. 따라서, RCU로 보호되는 포인터에 NULL을 할당할 때에는, `rcu_assign_pointer()` 보다는 `RCU_INIT_POINTER()`를 사용하세요.

Shaohua Li는 RCU의 per-CPU kthread들의 불필요한 self-wakeup을 제거했고, Andi Kleen은 일부 충돌되는 변수 선언들을 정리했습니다. Mike Galbraith는 RCU가 `RCU_BOOST_PRIO` 커널 패러미터를 무시하게 하는 버그를 잡았고, 마지막으로, 계속해서 확장되는 RCU의 기능들을 잡을 수 있도록 `rcutorture`가 진척을 만들었습니다.

E.2.16 3.3 Linux Kernel

3.3 리눅스 커널은 RCU의 idle CPU가 아니라면 `scheduling-clock ticks`를 위한 필요를 줄여주는 에너지 효율성 개선, `uprobes`에 의해 필요시되는 새로운 `srcu_read_lock_raw()` 기능, 여전히 진행중인 RCU 전체 검사로 찾아내어진 문제들에 대한 수정사항들, 그리고 스크립트로 짜여진, 타입이나 `userspace` 레이아웃의 존재에 의존적이지 않은 KVM 기반의 RCU 테스트를 가능하게 하는 `rcutorture` 개선사항이 포함되었습니다.

또한 Thomas Gleixner로부터의 `-rt` RCU 패치를 포함했고, 또한 dyntick-idle 모드부터 usermode 수행 까지의 응용을 지원하는 Frédéric Weisbecker로부터의 RCU 기반시설 관련 여러 패치들을 포함했습니다.

비록 일부 초기 작업들은 RCU-preempt의 `__rcu_read_lock()`과 `__rcu_read_unlock()`가 inline 될 수 있도록 했지만, 그보다 훨씬 많은 작업이 다양한 include 파일 문제들을 푸는데 필요했습니다. 마지막으로, Rusty Russell로부터의 잡다한 수정들이 있었습니다.

`rcu_barrier_expedited()`에 대한 초기 요청이 있었습니다만, 그 요청을 한 사람은 이 문제를 풀기 위한 다른 방법을 찾았기에, 이는 상대적으로 낮은 우선순위를 가졌습니다.

E.2.17 3.4 Linux Kernel

3.4 커널은 전력 효율성을 위해 급격한 idle 진입/종료 워크로드에 대한 단점을 줄이는 작업을 포함했습니다. 여기서 관리된 트레이드오프는 긴 idle 시간에 대비해서 idle 진입에 대한 작업의 증가이고, 따라서 이 릴리즈에서의 변경사항들은 추가적인 노력이 의미없을 때를 인식하는 데 대해 더 나은 일을 하는데, 예를 들어 CPU가 워크로드 때문에 idle을 급격하게 진입했다가 빠져나간다면 CPU가 더 오래 sleep 상태에 머무르게 하는 idle-entry 동작을 취하는데에 약간의 이점이 있습니다.

이 릴리즈는 또한 계속해서 증가하는 사용예인 idle CPU들에서 RCU를 호출하는 행위를 처리하는데 사용되기 위한 `RCU_NOIDLE()`을 추가했습니다. RCU는 idle CPU들을 무시하기 때문에, 이런 행위는 상당히 위험합니다. 따라서 이 새로운 `RCU_NOIDLE()` 매크로는 RCU read-side 크리티컬 섹션이 그 일을 할 수 있도록 idle로부터 급격하게 빠져나가도록 합니다.

RCU의 CPU hotplug 처리가 개선되었고, `rcutorture`는 RCU CPU stall 경고를 테스트하기 위한 기본적 기능을 일부 얻었으며, 이 stall 경고 자체는 더 많은 정보를 추가하고 `sysfs`를 통해 타임아웃을 제어할 수 있는 기능을 추가함으로써 개선되었습니다. `TREE_RCU`는 `CONFIG_SMP=n` 커널에서는 더이상 사용되지 않습니다; `TINY_RCU`가 그대신 사용됩니다. 이 릴리즈는 또한, non-preemptible-RCU read-side 크리티컬 섹션 내에서의 잠자는 행위와 RCU read-side 크리티컬 섹션 내에서의 idle loop 진입을 위한 `lockdep-RCU` 체크의 추가를 포함합니다.

`TINY_RCU`는 v3.0-rc7 RCU trainwreck [McK11a]을 위한 `TREE_RCU` 수정사항들을 상속받았습니다. Grace-period 초기화 프로세스는 기존의 single-node 최적화를 제거했으며, offline이 된 CPU들에 남아있는 콜백들은 더이상 두번째의 grace period 전체를 거치지 않아도 되게 되었습니다. 더 나아가서, offline CPU들은 더이상

RCU 콜백들을 호출할 수 없게 되었습니다.

이 외에도 더 많은 전력 효율성 코드의 수정사항들이 idle CPU 위에서 비참하게 살아있을 수도 있는 Time lazy 콜백들의 양을 제한했습니다. 마지막으로, Frédéric Weisbecker, Heiko Carstens, Julia Lawall, Hugh Dickins, Jan Beulich, 그리고 Paul Gortmaker에 의해서 다수의 수정사항들이 추가되었습니다.

E.2.18 3.5 Linux Kernel

3.5 리눅스 커널은 CONFIG_RCU_FAST_NO_HZ 전력 효율성 코드에 타이머 처리와 RCU_NOIDLE()에 의한 idle로부터의 정지에 대한 올바른 처리 등을 포함한, 더 많은 변화를 가져왔습니다.

이는 또한 `rcu_barrier()` 와 그 비슷한 것들에 의한 분열을 콜백들을 아무것도 갖지 않은 CPU에 넣는 것을 막음으로써 줄였습니다. 이 작업은 또한 `rcu_barrier()` 와 offline이 된 CPU들에 의하고아가 된 콜백들 사이의 상호작용을 보다 명시적이게 만들었는데, 이는 일부 교묘한 race condition들을 막는데에 필요했던 것입니다. `__rcu_read_unlock()` 을 inline 하려다 실패한 시도는 그러나 RCU의 task 종료 처리의 오버헤드를 줄이고 격리화 시키는 효과를 남겼습니다.

이 릴리즈는 Lai Jiangshan에 의한 SRCU의 완전한 재작성, 그 외에도 Jan Engelhardt, Michel Machado, 그리고 Dave Jones에 의한 수정사항들을 포함했습니다.

E.2.19 3.6 Linux Kernel

3.6 리눅스 커널은 `rcu_node` 트리의 leaf 단계 fanout을 boot-time 패러미터를 통해 제어 가능하게 함으로써 수천개의 CPU들을 갖는 시스템에서의 RCU의 스케줄링 응답시간 효과를 줄이기 위한 변경 사항들 중 첫번째 것들을 포함했습니다. 이 변경은 grace-period 초기화 동안 만져져야 하는 메모리의 양을 4배 줄였고, 그로 인해 응답시간의 효과를 200 마이크로세컨드에서 60-70 마이크로세컨드로 줄였습니다. 이 릴리즈는 또한 `rcu_barrier()` 동시성을 증가시켰습니다.

전통을 따라서, 이 릴리즈는 또한 CONFIG_RCU_FAST_NO_HZ 기능을 위한 전력 효율성 상의 변경 사항을 포함했습니다. 마지막으로, 이 릴리즈는 Carsten Emde로부터의 초기화되지 않은 문자열에 대한 수정을 포함해서 여러개의 수정 사항들을 포함했습니다.

E.2.20 3.7 Linux Kernel

3.7 리눅스 커널은 grace-period 초기화 작업을 별개의 kthread로 옮겼는데, 이 쓰레드는 preemptible 해서, 커다란 시스템에서의 grace-period 초기화 응답시간 문제를

제거할 수 있을 것입니다. 이 릴리즈는 또한, 기존의 `_rcu_barrier()` 의 악성의 `__stop_machine()` 로의 종속성을 제거했습니다. 이는 또한 Frédéric Weisbecker의 CONFIG_NO_HZ_FULL bare-metal 기반기능 [Cor13b]에 의해 필요한 RCU 기반시설을 일부 포함했으며, 이 RCU 기반시설의 대부분은 실제로 Frédéric에 의해 작성되었습니다. 마지막으로, 이 릴리즈는 Tejun Heo, Thomas Gleixner, Li Zhong, 그리고 Dimiti Sivanich로부터의 수정사항들과 최적화들을 포함했습니다.

E.2.21 3.8 Linux Kernel

3.8 리눅스 커널은 새로운 CONFIG_RCU_NOCB_CPU Kconfig 패러미터 [Cor12b]의 형태로 RCU 콜백 오프로딩의 프로토타입 구현을 추가했으며, Paul Gortmaker는 필요한 수정사항들을 몇 가지 제공했습니다. 이 프로토타입 구현은 CPU 0가 offload 되지 않을 것을, 결국은 모든 콜백들이 CPU 0로 처리될 것을 필요로 했습니다. 이는 분명 scalable 하지 않으며, 따라서 더 나은 구현이 나중에 나올 겁니다. RCU CPU stall-warning 메세지는 한번 더 업그레이드 되었고, RCU의 CPU-hotplug 코드로의 일부 개선이 추가되었습니다.

Lai Jiangshan은 Ssrcu로의 static definition 기능을 추가했고 Michael Wang은 RCU의 오래된 debugfs 추적 기능을 재작업했습니다. Antti P. Miettinen은 모든 RCU synchronous grace-period 기능들이 expedited 모드에서 동작하도록 강제하는 커널 부트 패러미터를 추가했으며, Eric Dumazet은 RCU 콜백 batch-limit 문제를 수정했습니다.

E.2.22 3.9 Linux Kernel

3.9 리눅스 커널은 콜백들의 그룹들을 연관된 숫자로 태그하는데, 이는 RCU가 콜백들을 지나치게 promote시키는 것에 대한 걱정 없이 그들을 최대한 적극적으로 promote 시킬 수 있도록 해줍니다. 또한, 이 릴리즈는 TINY_RCU를 위한 RCU CPU stall warning들을 추가했습니다.

Lai Jiangshan은 일부 Ssrcu 업데이트를 제공했는데, 이는 Ssrcu read-side 기능들이 idle과 offline CPU들에서 수행될 수 있게 해주었으며, 그외에도 일부 추가적인 수정사항들이 있었습니다. 추가적인 수정사항들이 Sasha Levin, Steven Rostedt, Li Zhong, Cody P. Schafer, 그리고 Josh Triplett에 의해 제공되었습니다.

E.2.23 3.10 Linux Kernel

3.10 리눅스 커널로, RCU는 마침내 시스템 레벨에서 측정될 수 있는 전력 효율 향상을 가져다주는 전력 효율성 메커니즘을 갖게 되었습니다 [MER13]. 여기서의

트릭은 CONFIG_RCU_FAST_NO_HZ 가 3.9 에서 추가된 callback 태깅 기능을 사용하도록 한겁니다. 이는 idle 로 빠지는 CPU 들이 자기만의 콜백들을 분류하고 숫자를 매기는것만을 필요로 하게 됨을 의미하는데, 이는 기존의 RCU state machine 이 진행되게 하던 시도에 비해서 상당히 저렴한 비용만을 필요로 합니다. 또한, 이 callback 태깅 기능은 CPU 들이 미래의 grace period 에 대한 필요를 알리는 것을 가능하게 하는 개선이 있었는데, 이는 요청을 한 CPU 가 전체 과정 동안 잠들어 있었다는 사실에도 불구하고 CPU 들이 grace period 에 대한 필요를 알릴 수 있도록 했습니다.

또한, CONFIG_RCU_NOCB_CPU 기반기능들은 CPU 0 로의 종속성을 제거하도록 개선되어서, RCU 콜백들이 모든 CPU 들로 offload 될 수 있도록 했습니다.

이 릴리즈는 또한 Steven Rostedt, Eric Dumazet, Sasha Levin, Frédéric Weisbecker, Al Viro, Steven Whitehouse, Srivatsa S. Bhat, Jiang Fang, 그리고 Akinobu Mita 로부터의 수정사항들을 포함했습니다.

E.2.24 3.11 Linux Kernel

3.11 리눅스 커널은 3.9 와 3.10 에서의 callback 태깅 작업의 정리 작업 겨로가를 추가했고 유니프로세서 모드에서는 TREE_PREEMPT_RCU 를 수행하도록 TINY_PREEMPT_RCU 를 제거했습니다. 이 릴리즈는 또한 Paul Gortmaker 와 Kees Cook 으로부터의 수정사항들을 포함했습니다.

E.2.25 3.12 Linux Kernel

3.12 커널은 CONFIG_NO_HZ_FULL 이 효율적으로 언제 전체 시스템이 idle 인지를 판단할 수 있도록 하는데 필요한 기반기능을 제공하는 CONFIG_NO_HZ_FULL_SYSIDLE Kconfig 패러미터를 추가했습니다. CONFIG_NO_HZ_FULL 이 전체 시스템이 idle 상태임을 증명할 수 없다면, CPU 0 가 scheduling-clock 인터럽트를 active 상태로 유지해야 하는데, 이는 배터리 수명에 좋은 일이 아니기 때문에 [Cor13a] 이는 중요합니다.

이는 또한 rcutorture 의 테스트 범위를 synchronous, asynchronous, 그리고 expedited grace-period 기능들을 병렬적으로 테스트 할 수 있게 함으로써 rcutorture 를 개선시켰습니다. 또한 duplicate-callback 테스트를 추가했고 rcutorture 가 CPU-online 오퍼레이션이 실패했을 때 더 많은 정보를 제공하도록 만들었습니다. 마지막으로, 이 릴리즈는 Steven Rostedt, Tejun Heo, 그리고 Borislav Petkov 으로부터의 수정사항들을 포함했습니다.

E.2.26 3.13 Linux Kernel

3.13 커널은 CONFIG_RCU_FAST_NOHZ 수행에서의 일부 향상점들을 포함하는데, 그가운데는 콜백들을 강화시키려는 너무 빈번한 시도를 막는 것도 있습니다. 그런 변화가 필요한 이유는, 그와 같이 콜백들이 강화될 수 있도록 허용하는 이벤트들은 일반적으로 수 밀리세컨드에 한번 정도만 발생해서, jiffy 마다 한번 이상의 빈도로 콜백들을 강화하려는 시도는 성능과 전력의 낭비 외에는 아무일도 하지 않는다는 것입니다. 따라서 3.13 커널은 현재 jiffy 내에 이미 콜백을 강화시키려 시도한 적이 없을 경우에만 시도를 합니다.

새로 추가된 `rcu_is_watching()` 함수는 호출자가 RCU read-side 크리티컬 섹션에 진입하기에 안전한가 그렇지 않은가를 판단할 수 있도록 해줍니다. 달리 말하자면, `rcu_is_watching()` 은 해당 CPU 가 idle 이거나 offline 상태가 아니라면 `true` 를 리턴합니다. 또한, 새로 추가된 (Michael S. Tsirkin 에 의해 제공된) `smp_mb__after_srcu_read_unlock()` 인터페이스는 `srcu_read_unlock()` 에서 전체 메모리 배리어를 칠 것을 보장합니다. 비록 `srcu_read_unlock()` 이 현재로써는 이미 전체 메모리 배리어를 제공하지만, 기존의 구현들은 그리하지 않았고 미래의 구현들은 또다시 그리하지 않게 될수도 있다는 점을 알아두시기 바랍니다.

RCU 의 소스 파일들은 3.13 부터 새로운 장소로 옮겨졌는데, `kernel` 디렉토리로부터 `kernel/rcu` 디렉토리로 옮겨졌습니다.

마지막으로, Christoph Lameter 는 RCU 의 per-CPU 변수 API 사용을 업데이트 하는 패치를 하나 제공했고 Kirill Tkhai 는 CONFIG_RCU_NOCB_CPU_ALL 과 함께 만들어진 커널들이 중간중간 비어있는 CPU 숫자 규칙을 가진 시스템에서 돌아가는 경우 부팅 중에 panic 을 발생시킬 수 있던 문제의 수정을 제공했습니다.

E.2.27 3.14 Linux Kernel

3.14 에서 추가된 주요한 내용들은 커널 내의 rcutorture 테스트 스크립트의 개선사항들인데, 이는 테스트 케이스들의 long-overdue 리팩토링을 포함합니다. 이 릴리즈는 또한, 불필요하게 NO_HZ_FULL CPU 들에서 처리되고 있는 코어를 떠맡은 RCU 에 의해 이루어진 OS jitter 의 원인을 제거했습니다. 이 릴리즈는 또한 Fengguang Wu 에 의한 Coccinelle warning 의 수정사항, Lai Jiangshan 에 의한 `rcu_read_unlock_special()` 체크 제거를 위한 첫번째 단계, Chen Gang 으로부터의 일부 버퍼 오버플로우 방지, Teodora Baluta 에 의한 불필요한 extern 태그들의 제거, Josh Triplett 에 의한 `rcu_assign_pointer()` 로직의 개선을 포함했습니다.

Appendix F

Style Guide

This appendix is a collection of style guides which is intended as a reference to improve consistency in perfbook. It also contains several suggestions and their experimental examples.

Section F.1 describes basic punctuation and spelling rules. Section F.2 explains rules related to unit symbols. Section F.3 summarizes \LaTeX -specific conventions.

F.1 Paul’s Conventions

Following is the list of Paul’s conventions assembled from his answers to Akira’s questions regarding perfbook’s punctuation policy.

- (On punctuations and quotations) Despite being American myself, for this sort of book, the UK approach is better because it removes ambiguities like the following:

Type “`ls -a`,” look for the file “`.`,” and file a bug if you don’t see it.

The following is much more clear:

Type “`ls -a`”, look for the file “`.`”, and file a bug if you don’t see it.

- American English spelling: “color” rather than “colour”.
- Oxford comma: “a, b, and c” rather than “a, b and c”. This is arbitrary. Cases where the Oxford comma results in ambiguity should be reworded, for example, by introducing numbering: “a, b, and c and d” should be “(1) a, (2) b, and (3) c and d”.
- Italic for emphasis. Use sparingly.

- `\co{}` for identifiers, `\url{}` for URLs, `\path{}` for filenames.
- Dates should use an unambiguous format. Never “mm/dd/yy” or “dd/mm/yy”, but rather “July 26, 2016” or “26 July 2016” or “26-Jul-2016” or “2016/07/26”. I tend to use `yyyy.mm.ddA` for filenames, for example.
- North American rules on periods and abbreviations. For example neither of the following can reasonably be interpreted as two sentences:

- Say hello, to Mr. Jones.
- If it looks like she sprained her ankle, call Dr. Smith and then tell her to keep the ankle iced and elevated.

An ambiguous example:

If I take the cow, the pig, the horse, etc.
George will be upset.

can be written with more words:

If I take the cow, the pig, the horse, or
much of anything else, George will be
upset.

or:

If I take the cow, the pig, the horse, etc.,
George will be upset.

- I don’t like ampersand (“&”) in headings, but will sometimes use it if doing so prevents a line break in that heading.
- When mentioning words, I use quotations. When introducing a new word, I use `\emph{}`.

F.2 NIST Style Guide

F.2.1 Unit Symbol

F.2.1.1 SI Unit Symbol

NIST style guide¹ states the following rules (rephrased for perfbook).

- When SI unit symbols such as “ns”, “MHz”, and “K” (kelvin) are used behind numerical values, narrow spaces should be placed between the values and the symbols.

A narrow space can be coded in L^AT_EX by the sequence of “\,.”. For example,

“2.4 GHz”, rather than “2.4GHz”.

- Even when the value is used in adjectival sense, a narrow space should be placed. For example,

“a 10 ms interval”, rather than “a 10-ms interval” nor “a 10ms interval”.

The symbol of micro ($\mu:10^{-6}$) can be typeset easily by the help of “gensymb” L^AT_EX package. A macro “\micro” can be used in both text and math modes. To typeset the symbol of “microsecond”, you can do so by “\micro s”. For example,

10 μ s

Note that math mode “\mu” is italic by default and should not be used as a prefix. An improper example:

10 μ s (math mode “\mu”)

F.2.1.2 Non-SI Unit Symbol

Although NIST style guide does not cover non-SI unit symbols such as “KB”, “MB”, and “GB”, the same rule should be followed.

Example:

“A 240 GB hard drive”, rather than “a 240-GB hard drive” nor “a 240GB hard drive”.

Strictly speaking, NIST guide requires us to use the binary prefixes “Ki”, “Mi”, or “Gi” to represent powers of 2^{10} . However, we accept the JEDEC conventions to

¹ <https://www.nist.gov/pml/nist-guide-si-chapter-7-rules-and-style-conventions-expressing-values-quantities>

use “K”, “M”, and “G” as binary prefixes in describing memory capacity.²

An acceptable example:

“8 GB of main memory”, meaning “8 GiB of main memory”.

Also, it is acceptable to use just “K”, “M”, or “G” as abbreviations appended to a numerical value, e.g., “4K entries”. In such cases, no space before an abbreviation is required. For example,

“8K entries”, rather than “8 K entries”.

If you put a space in between, the symbol looks like a unit symbol and is confusing. Note that “K” and “k” represent 2^{10} and 10^3 , respectively. “M” can represent either 2^{20} or 10^6 , and “G” can represent either 2^{30} or 10^9 . These ambiguities should not be confusing in discussing approximate order.

F.2.1.3 Degree Symbol

The angular-degree symbol (°) does not require any space in front of it. NIST style guide clearly states so.

The symbol of degree can also be typeset easily by the help of gensymb package. A macro “\degree” can be used in both text and math modes.

Example:

45°, rather than 45 °.

F.2.1.4 Percent Symbol

NIST style guide treats the percent symbol (%) as the same as SI unit symbols.

50 % possibility, rather than 50% possibility.

F.2.1.5 Font Style

Quote from NIST check list:³

Variables and quantity symbols are in italic type. Unit symbols are in roman type. Numbers should generally be written in roman type. These rules apply irrespective of the typeface used in the surrounding text.

² <https://www.jedec.org/standards-documents/dictionary/terms/mega-m-prefix-units-semiconductor-storage-capacity>

³ #6 in <https://physics.nist.gov/cuu/Units/checklist.html>

For example,

e (elementary charge)

On the other hand, mathematical constants such as the base of natural logarithms should be roman.⁴ For example,

e^x

F.2.2 NIST Guide Yet To Be Followed

There are a few cases where NIST style guide is not followed. Other English conventions are followed in such cases.

F.2.2.1 Digit Grouping

Quote from NIST check list:⁵

The digits of numerical values having more than four digits on either side of the decimal marker are separated into groups of three using a thin, fixed space counting from both the left and right of the decimal marker. Commas are not used to separate digits into groups of three.

NIST Example: 15 739.012 53 ms

Our convention: 15,739.01253 ms

In LATEX coding, it is cumbersome to place thin spaces as are recommended in NIST guide. The `\num{}` command provided by the “siunitx” package would be of help for us to follow this rule. It would also help us overcome different conventions. We can select a specific digit-grouping style as a default in preamble, or specify an option to each `\num{}` command as is shown in Table F.1.

Table F.1: Digit-Grouping Style

Style	Outputs of <code>\num{}</code>		
NIST/SI (English)	12 345	12.345	1 234 567.89
SI (French)	12 345	12,345	1 234 567,89
English	12,345	12.345	1,234,567.89
French	12 345	12,345	1 234 567,89
Other Europe	12.345	12,345	1.234.567,89

As are evident in Table F.1, periods and commas used as other than decimal markers are confusing and should

be avoided, especially in documents expecting global audiences.

By marking up constant decimal values by `\num{}` commands, the LATEX source would be exempted from any particular conventions.

Because of its open-source policy, this approach should give more “portability” to perfbook.

F.3 LATEX Conventions

Good looking LATEX documents require further considerations on proper use of font styles, line break exceptions, etc. This section summarizes guidelines specific to LATEX.

F.3.1 Monospace Font

Monospace font (or typewriter font) is heavily used in this textbook. First policy regarding monospace font in perfbook is to avoid directly using “`\texttt{}`” or “`\tt`” macro. It is highly recommended to use a macro or an environment indicating the reason why you want the font.

This section explains the use cases of such macros and environments.

F.3.1.1 Code Snippet

Because the “`verbatim`” environment is a primitive way to include listings, we are transitioning to a new scheme which uses the “`fancyvrb`” package for code snippets.

The goal of the new scheme is to extract LATEX sources of code snippets directly from code samples under `CodeSamples` directory. It also makes it possible to embed line labels in the code samples, which can be referred from the text. This reduces the burden of keeping line numbers in the text consistent with those in code snippets.

Code-snippet extraction is handled by a couple of perl scripts and recipes in `Makefile`. We use the `fancyvrb` package’s escaping feature to embed line labels in comments.

We used to use the “`verbbox`” environment provided by the “`verbatimbox`” package. Section F.3.1.2 describes how `verbbox` can automatically generate line numbers, but these line numbers cannot be referenced from the text.

Let’s start by looking at how code snippets are coded in the new scheme. There are three customized environments of “`Verbatim`”. “`VerbatimL`” is for floating snippets within the “`listing`” environment. “`VerbatimN`” is for inline snippets with line count enabled. “`VerbatimU`” is

⁴ <https://physics.nist.gov/cuu/pdf/typefaces.pdf>

⁵ #16 in <http://physics.nist.gov/cuu/Units/checklist.html>.

Listing F.1: L^AT_EX Source of Sample Code Snippet (Current)

```

1 \begin{listing}[tbl]
2 \begin{linelabel}[ln:base1]
3 \begin{VerbatimL}[commandchars=\$\[\]]
4 /*
5 * Sample Code Snippet
6 */
7 #include <stdio.h>
8 int main(void)
9 {
10     printf("Hello world!\n");      $lnlbl[printf]
11     return 0;                      $lnlbl[return]
12 }
13 \end{VerbatimL}
14 \end{linelabel}
15 \caption{Sample Code Snippet}
16 \label{lst:app:styleguide:Sample Code Snippet}
17 \end{listing}

```

Listing F.2: Sample Code Snippet

```

1 /*
2 * Sample Code Snippet
3 */
4 #include <stdio.h>
5 int main(void)
6 {
7     printf("Hello world!\n");
8     return 0;
9 }

```

for inline snippets without line count. They are defined in the preamble as shown below:

```

\DefineVerbatimEnvironment{VerbatimL}{Verbatim}%
  {fontsize=\scriptsize,numbers=left,numberssep=5pt,%
   xleftmargin=9pt,obeytabs=true,tabsize=2}%
\AfterEndEnvironment{VerbatimL}{\vspace*{-9pt}}%
\DefineVerbatimEnvironment{VerbatimN}{Verbatim}%
  {fontsize=\scriptsize,numbers=left,numberssep=3pt,%
   xleftmargin=5pt,xrightmargin=5pt,obeytabs=true,%
   tabsize=2,frame=single}%
\DefineVerbatimEnvironment{VerbatimU}{Verbatim}%
  {fontsize=\scriptsize,numbers=none,xleftmargin=5pt,%
   xrightmargin=5pt,obeytabs=true,tabsize=2,%
   samepage=true,frame=single}

```

The L^AT_EX source of a sample code snippet is shown in Listing F.1 and is typeset as shown in Listing F.2.

Labels to lines are specified in “\$lnlbl[]” command. The characters specified by “commandchars” option to VerbatimL environment are used by the fancyvrb package to substitute “\lnlbl{}” for “\$lnlbl[]”. Those characters should be selected so that they don’t appear elsewhere in the code snippet.

Labels “printf” and “return” in Listing F.2 can be referred to as shown below:

```

\begin{lineref}[ln:base1]
Lines-\lnref{printf} and-\lnref{return} can be referred
to from text.
\end{lineref}

```

Listing F.3: Source of Code Sample with “snippet” meta command

```

1 //\begin{snippet}[labelbase=ln:base1,commandchars=\$\[\]]
2 /*
3 * Sample Code Snippet
4 */
5 #include <stdio.h>
6 int main(void)
7 {
8     printf("Hello world!\n");      //\lnlbl{printf}
9     return 0;                      //\lnlbl{return}
10 }
11 //\end{snippet}

```

Above code results in the paragraph below:

Lines 7 and 8 can be referred to from text.

Macros “\lnlbl{}” and “\lnref{}” are defined in the preamble as follows:

```

\newcommand{\lnlblbase}{}%
\newcommand{\lnlbl}[1]{%
  \phantomsection\label{\lnlblbase:#1}%
\newcommand{\lnrefbase}{}%
\newcommand{\lnref}[1]{\ref{\lnrefbase:#1}}

```

Environments “linelabel” and “lineref” are defined as shown below:

```

\newenvironment{linelabel}[1][]{%
  \renewcommand{\lnlblbase}{#1}%
  \ignorespaces\ignorespacesafterend}%
\newenvironment{lineref}[1]{%
  \renewcommand{\lnrefbase}{#1}%
  \ignorespaces\ignorespacesafterend}%

```

The main part of L^AT_EX source shown on Lines 2-14 in Listing F.1 can be extracted from a code sample of Listing F.3 by a perl script *utilities/fcvextract.pl*. All the relevant rules of extraction are described as recipes in the top level *Makefile* and a script to generate dependencies (*utilities/gen_snippet_d.pl*).

As you can see, Listing F.3 has meta commands in comments of C (C++ style). Those meta commands are interpreted by *utilities/fcvextract.pl*, which distinguishes the type of comment style by the suffix of code sample’s file name.

Meta commands which can be used in code samples are shown below:

```

\begin{snippet}[option]
\end{snippet}
\lnlbl{<label string>}

```

Options to the \begin{snippet} meta command are as the following:

```
labelbase=<label base string>
commandchars=\X\Y\Z
```

The string given to “labelbase” will be passed to “`\begin{linelabel}[<label base string>]`” command as shown on line 2 of Listing F.1. “commandchars” option is given to the `VerbatimL` environment as is. Other types of options, if any, are also passed to the `VerbatimL` environment. The “`\lnlbl`” commands are converted along the way to reflect the escape-character choice.⁶

There can be multiple pairs of `\begin{snippet}` and `\end{snippet}` as long as they have unique “labelbase” strings.

Our naming scheme of “labelbase” for unique name space is as follows:

```
ln:<Chapter/Subdirectory>:<File Name>:<Function Name>
```

Litmus tests, which are handled by “`herdtools7`” commands such as “`litmus7`” and “`herd7`”, were problematic for this scheme. Those commands have particular rules of where comments can be placed and restriction on characters in comments. They also forbid a couple of tokens to appear in comments. (Tokens in comments might sound strange, but they do have such restriction.)

For example, the first token in a litmus test must be one of “C”, “PPC”, “X86”, “LISA”, etc., which indicates the flavour of the test. This means no comment is allowed at the beginning of a litmus test.

Similarly, several tokens such as “exists”, “filter”, and “locations” indicate the end of litmus test’s body. Once one of them appears in a litmus test, comments should be ocaml style (“`(* ... *)`”). Those tokens keep the same meaning even when they appear in comments!

The pair of characters “{” and “}” also have special meaning in the C flavour tests. They are used to separate portions in a litmus test.

First pair of “{” and “}” encloses initialization part. Comments in this part should also be in the ocaml form.

You can’t use “{” and “}” in comments in litmus tests, either.

Examples of disallowed comments in a litmus test are shown below:

```
1 // Comment at first
2 C C-sample
3 // Comment with { and } characters
4 {
5 x=2; // C style comment in initialization
```

```
6 }
7
8 P0(int *x)
9 {
10     int r1;
11     r1 = READ_ONCE(*x); // Comment with "exists"
12 }
13 [...]
14
15 exists (0:r1=0) // C++ style comment after test body
```

To avoid parse errors, meta commands in litmus tests (C flavour) are embedded in the following way.

```
1 C C-SB+o-o+o-o
2 //\begin{snippet}[labelbase=ln:base,commandchars=\%@\$]
3
4 {
5 1:r2=0           (*\lnlbl{inatr2}*)
6 }
7
8 P0(int *x0, int *x1)           //\lnlbl{P0:b}
9 {
10     int r2;
11     WRITE_ONCE(*x0, 2);
12     r2 = READ_ONCE(*x1);
13 }                                //\lnlbl{P0:e}
14
15 P1(int *x0, int *x1)
16 {
17     int r2;
18     WRITE_ONCE(*x1, 2);
19     r2 = READ_ONCE(*x0);
20 }
21
22 //\end{snippet}
23 exists (1:r2=0 /\ 0:r2=0) (* \lnlbl{exists_} *)
```

Example above is converted to the following intermediate code by a script `utilities/reorder_ltms.pl`.⁷ The intermediate code can be handled by the common script `utilities/fcvextract.pl`.

```
1 // Do not edit!
2 // Generated by utilities/reorder_ltms.pl
3 //\begin{snippet}[labelbase=ln:base,commandchars=\%@\$]
4 C C-SB+o-o+o-o
5
6 {
7 1:r2=0           //\lnlbl{inatr2}
8 }
9
10 P0(int *x0, int *x1)           //\lnlbl{P0:b}
11 {
12     int r2;
13     WRITE_ONCE(*x0, 2);
14     r2 = READ_ONCE(*x1);
15 }                                //\lnlbl{P0:e}
16
17 P1(int *x0, int *x1)
18 {
19 }
```

⁶ Characters forming comments are also gobbled up.

⁷ Currently, only C flavour litmus tests are supported.

Listing F.4: L^AT_EX Source of Sample Code Snippet (Obsolete)

```

1 \begin{listing}[tb]
2 { \scriptsize
3 \begin{verbbox}[\LstLineNo]
4 /*
5 * Sample Code Snippet
6 */
7 #include <stdio.h>
8 int main(void)
9 {
10 printf("Hello world!\n");
11 return 0;
12 }
13 \end{verbbox}
14 }
15 \centering
16 \theverbbox
17 \caption{Sample Code Snippet (Obsolete)}
18 \label{lst:app:styleguide:Sample Code Snippet (Obsolete)}
19 \end{listing}

```

Listing F.5: Sample Code Snippet (Obsolete)

```

1 /*
2 * Sample Code Snippet
3 */
4 #include <stdio.h>
5 int main(void)
6 {
7 printf("Hello world!\n");
8 return 0;
9 }

```

```

20 int r2;
21 WRITE_ONCE(*x1, 2);
22 r2 = READ_ONCE(*x0);
23 }
24 }
25 exists (1:r2=0 /\ 0:r2=0) \lnlbl{exists_}
26 //\end{snippet}

```

Note that each litmus test's source file can contain at most one pair of `\begin{snippet}` and `\end{snippet}` because of the restriction of comments.

F.3.1.2 Code Snippet (Obsolete)

Sample L^AT_EX source of a code snippet coded using the “`verbbox`” package is shown in Listing F.4 and is typeset as shown in Listing F.5.

The auto-numbering feature of `verbbox` is enabled by the “`\LstLineNo`” macro specified in the option to `verbbox` (line 3 in Listing F.4). The macro is defined in the preamble of `perfbook.tex` as follows:

```
\newcommand{\LstLineNo}
{\makebox[5ex][r]{\arabic{VerbboxLineNo}\hspace{2ex}}}
```

The “`verbbox`” environment is used for listings with too many lines to fit in a column. It is also used to avoid

overwhelming L^AT_EX with a lot of floating objects. They are being converted to the scheme using the `Verbatim` environment.

F.3.1.3 Identifier

We use “`\co{}`” macro for inline identifiers. (“`co`” stands for “code”.)

By putting them into `\co{}`, underscore characters in their names are free of escaping in L^AT_EX source. It is convenient to search them in source files. Also, `\co{}` macro has a capability to permit line breaks at particular sequences of letters. Current definition permits a line break at an underscore (`_`), two consecutive underscores (`__`), a white space, or an operator `->`.

F.3.1.4 Identifier inside Table and Heading

Although `\co{}` command is convenient for inlining within text, it is fragile because of its capability of line break. When it is used inside a “`tabular`” environment or its derivative such as “`tabularx`”, it confuses column width estimation of those environments. Furthermore, `\co{}` can not be safely used in section headings nor description headings.

As a workaround, we use “`\tco{}`” command inside tables and headings. It has no capability of line break at particular sequences, but still frees us from escaping underscores.

When used in text, `\tco{}` permits line breaks at white spaces.

F.3.1.5 Other Use Cases of Monospace Font

For URLs, we use “`\url{}`” command provided by the “`hyperref`” package. It will generate hyper references to the URLs.

For path names, we use “`\path{}`” command. It won't generate hyper references.

Both `\url{}` and `\path{}` permit line breaks at “`/`”, “`-`”, and “`..`”.⁸

For short monospace statements not to be line broken, we use the “`\nbco{}`” (non-breakable co) macro.

F.3.1.6 Limitations

There are a few cases where macros introduced in this section do not work as expected. Table F.2 lists such

⁸ Overfill can be a problem if the URL or the path name contains long runs of unbreakable characters.

limitations.

Table F.2: Limitation of Monospace Macro

Macro	Need Escape	Should Avoid
\co, \nbc	\, %, {, }	
\tco	#	%, {, }, \

While \co{} requires some characters to be escaped, it can contain any character.

On the other hand, \tco{} can not handle “%”, “{”, “}”, nor “\” properly. If they are escaped by a “\”, they appear in the end result with the escape character. The “\verb” macro can be used in running text if you need to use monospace font for a string which contains many characters to escape.⁹

F.3.2 Non Breakable Spaces

In LATEX conventions, proper use of non-breakable white spaces is highly recommended. They can prevent widow and orphaning of single digit numbers or short variable names, which would cause the text to be confusing at first glance.

The thin space mentioned earlier to be placed in front of a unit symbol is non breakable.

Other cases to use a non-breakable space (“~” in LATEX source, often referred to as “nbsp”) are the following (inexhaustive).

- Reference to a Chapter or a Section:

Please refer to Section F.2.

- Calling out CPU number or Thread name:

After they load the pointer, CPUs 1 and 2 will see the stored value.

- Short variable name:

The results will be stored in variables a and b.

⁹ \verb macro is not almighty though. For example, you can't use it within a footnote. If you do so, you will see a fatal LATEX error. The “fancyvrb” package provides a workaround by the name of \VerbatimFootnotes macro. This footnote contains \verb macro.

F.3.3 Hyphenation and Dashes

F.3.3.1 Hyphenation in Compound Word

In plain LATEX, compound words such as “high-frequency” can be hyphenated only at the hyphen. This sometimes results in poor typesetting. For example:

High-frequency radio wave, high-frequency radio wave.

By using a shortcut “\-/” provided by the “extdash” package, hyphenation in elements of compound words is enabled in perfbook.¹⁰

Example with “\-/”:

High-frequency radio wave, high-frequency radio wave.

F.3.3.2 Non Breakable Hyphen

We want hyphenated compound terms such as “x-coordinate”, “y-coordinate”, etc. not to be broken at the hyphen following a single letter.

To make a hyphen unbreakable, we can use a short cut “\=/” also provided by the “extdash” package.

Example without a shortcut:

x-, y-, and z-coordinates; x-, y-, and z-coordinates; x-, y-, and z-coordinates; x-, y-, and z-coordinates; x-, y-, and z-coordinates;

Example with “\-/”:

x-, y-, and z-coordinates; x-, y-, and z-coordinates; x-, y-, and z-coordinates; x-, y-, and z-coordinates; x-, y-, and z-coordinates;

Example with “\=/”:

¹⁰ In exchange for enabling the shortcut, we can't use plain LATEX's shortcut “\-” to specify hyphenation points. Use `pfhyphex.tex` to add such exceptions.

x-, y-, and z-coordinates; x-, y-, and z-coordinates;

Note that “\=/” enables hyphenation in elements of compound words as the same as “\-/” does.

F.3.3.3 Em Dash

Em dashes are used to indicate parenthetical expression. In *perfbook*, em dashes are placed without spaces around it. In *L^AT_EX* source, an em dash is represented by “---”.

Example (quote from Section C.1):

This disparity in speed—more than two orders of magnitude—has resulted in the multi-megabyte caches found on modern CPUs.

F.3.3.4 En Dash

In *L^AT_EX* convention, en dashes (–) are used for a range of (mostly) numbers. However, this is not followed in *perfbook* at all. Because of the heavy use of dashes (–) for such cases in plain-text communication, to make the *L^AT_EX* sources compatible with them, plain dashes are kept unmodified in the sources.

As a compromise, for those who are accustomed to en dashes representing ranges, there is a script to substitute en dashes for plain dashes.

If you have the git repository of *perfbook*, by using a script `utilities/dohyphen2endash.sh`, you can do the substitutions. The script works only when you are in a clean git repository. Otherwise it will just abort to prevent you from losing local changes.

Example with a simple dash:

Lines 4-12 in Listing F.4 are the contents of the `verbbox` environment. The box is output by the `\theverbbox` macro on line 16.

Example with an en dash:

Lines 4–12 in Listing F.4 are the contents of the `verbbox` environment. The box is output by the `\theverbbox` macro on line 16.

F.3.3.5 Numerical Minus Sign

Numerical minus signs should be coded as math mode minus signs, namely “\$-\$”.¹¹ For example,

–30, rather than -30.

F.3.4 Punctuation

F.3.4.1 Ellipsis

In monospace fonts, ellipses can be expressed by series of periods. For example:

Great ... So how do I fix it?

However, in proportional fonts, the series of periods is printed with tight spaces as follows:

Great ... So how do I fix it?

Standard *L^AT_EX* defines the `\dots` macro for this purpose. However, it has a kludge in the evenness of spaces. The “ellipsis” package redefines the `\dots` macro to fix the issue.¹² By using `\dots`, the above example is typeset as the following:

Great ... So how do I fix it?

Note that the “*xspace*” option specified to the “ellipsis” package adjusts the spaces after ellipses depending on what follows them.

For example:

- He said, “I ... really don’t remember ...”
- Sequence A: (one, two, three, ...)
- Sequence B: (4, 5, ..., *n*)

As you can see, extra space is placed before the comma. `\dots` macro can also be used in math mode:

- Sequence C: (1, 2, 3, 5, 8, ...)
- Sequence D: (10, 12, ..., 20)

The `\ldots` macro behaves the same as the `\dots` macro.

¹¹ This rule assumes that math mode uses the same upright glyph as text mode. Our default font choice meets the assumption.

¹² To be exact, it is the `\textellipsis` macro that is redefined. The behavior of `\dots` macro in math mode is not affected. The “*amsmath*” package has another definition of `\dots`. It is not used in *perfbook* at the moment.

F.3.5 Floating Object Format

F.3.5.1 Ruled Line in Table

They say that tables drawn by using ruled lines of plain LATEX look ugly.¹³ Vertical lines should be avoided and horizontal lines should be used sparingly, especially in tables of simple structure.

Table F.3 (corresponding to a table from a now-deleted section) is drawn by using the features of “booktabs” and “xcolor” packages. Note that ruled lines of booktabs can not be mixed with vertical lines in a table.¹⁴

Table F.3: Refrigeration Power Consumption

Situation	T (K)	C_P	Power per watt waste heat (W)
Dry Ice	195	1.990	0.5
Liquid N ₂	77	0.356	2.8
Liquid H ₂	20	0.073	13.7
Liquid He	4	0.0138	72.3
IBM Q	0.015	0.000051	19,500.0

F.3.5.2 Position of Caption

In LATEX conventions, captions of tables are usually placed above them. The reason is the flow of your eye movement when you look at them. Most tables have a row of heading at the top. You naturally look at the top of a table at first. Captions at the bottom of tables disturb this flow. The same can be said of code snippets, which are read from top to bottom.

For code snippets, the “ruled” style chosen for listing environment places the caption at the top. See Listing F.2 for an example.

As for tables, the position of caption is tweaked by `\floatstyle{}` and `\restylefloat{}` macros in preamble.

Vertical skips below captions are reduced by setting a smaller value to the `\abovecaptionskip` variable, which would also affect captions to figures.

In the tables which use horizontal rules of “booktabs” package, the vertical skips between captions and tables are further reduced by setting a negative value to the

`\abovetopsep` variable, which controls the behavior of `\toprule`.

F.3.6 Improvement Candidates

There are a few areas yet to be attempted in `perfbook` which would further improve its appearance. This section lists such candidates.

F.3.6.1 Grouping Related Figures/Listings

To prevent a pair of closely related figures or listings from being placed in different pages, it is desirable to group them into a single floating object. The “subfig” package provides the features to do so.¹⁵

Two floating objects can be placed side by side by using `\parbox` or `minipage`. For example, Figures 14.10 and 14.11 can be grouped together by using a pair of `minipages` as shown in Figures F.1 and F.2.

By using `subfig` package, Listings 15.4 and 15.5 can be grouped together as shown in Listing F.6 with sub-captions (with a minor change of blank line).

Note that they can not be grouped in the same way as Figures F.1 and F.2 because the “ruled” style prevents their captions from being properly typeset.

The sub-caption can be cited by combining a `\ref{}` macro and a `\subref{}` macro, for example, “Listing F.6(a)”.

It can also be cited by a `\ref{}` macro, for example, “Listing F.6b”. Note the difference in the resulting format. For the citing by a `\ref{}` to work, you need to place the `\label{}` macro of the combined floating object ahead of the definition of subfloats. Otherwise, the resulting caption number would be off by one from the actual number.

F.3.6.2 Table Layout Experiment

This section presents some experimental tables using booktabs, xcolors, and arydshln packages. The corresponding tables in the text have been converted using one of the format shown here. The source of this section can be regarded as a reference to be consulted when new tables are added in the text.

In Table F.4 (corresponding to Table 3.1), the “S” column specifiers provided by the “siunitx” package are used to align numbers.

Table F.5 (corresponding to Table 13.1) is an example of table with a complex header. In Table F.5, the gap in the

¹³ <https://www.inf.ethz.ch/personal/markusp/teaching/guides/guide-tables.pdf>

¹⁴ There is another package named “arydshln” which provides dashed lines to be used in tables. A couple of experimental examples are presented in Section F.3.6.2.

¹⁵ One problem of grouping figures might be the complexity in LATEX source.



Figure F.1: Timer Wheel at 1 kHz



Figure F.2: Timer Wheel at 100 kHz

Listing F.6: Message-Passing Litmus Test (by subfig)

(a) Not Enforcing Order

```

1 C C-MP+o-wmb-o+o-o.litmus
2
3 {
4 }
5
6 P0(int* x0, int* x1) {
7
8     WRITE_ONCE(*x0, 2);
9     smp_wmb();
10    WRITE_ONCE(*x1, 2);
11
12 }
13
14 P1(int* x0, int* x1) {
15
16     int r2;
17     int r3;
18
19     r2 = READ_ONCE(*x1);
20     r3 = READ_ONCE(*x0);
21
22 }
23
24
25 exists (1:r2=2 /\ 1:r3=0)

```

(b) Enforcing Order

```

1 C C-MP+o-wmb-o+o-rmb-o.litmus
2
3 {
4 }
5
6 P0(int* x0, int* x1) {
7
8     WRITE_ONCE(*x0, 2);
9     smp_wmb();
10    WRITE_ONCE(*x1, 2);
11
12 }
13
14 P1(int* x0, int* x1) {
15
16     int r2;
17     int r3;
18
19     r2 = READ_ONCE(*x1);
20     smp_rmb();
21     r3 = READ_ONCE(*x0);
22
23 }
24
25 exists (1:r2=2 /\ 1:r3=0)

```

mid-rule corresponds to the distinction which had been represented by double vertical rules before the conversion. The legends in the frame box appended here explain the abbreviations used in the matrix. Two types of memory barrier are denoted by subscripts here. The legends and subscripts are not present in Table 13.1 since they are redundant there.

Table F.6 (corresponding to Table C.1) is a sequence diagram drawn as a table.

Table F.7 is a tweaked version of Table 9.4. Here, the “Category” column in the original is removed and the categories are indicated in rows of bold-face font just below the mid-rules. This change makes it easier for `\rowcolors{}` command of “xcolor” package to work

properly.

Table F.8 is another version which keeps original columns and colors rows only where a category has multiple rows. This is done by combining `\rowcolors{}` of “xcolor” and `\cellcolor{}` commands of the “colortbl” package (`\cellcolor{}` overrides `\rowcolors{}`).

In Table 9.4, the latter layout without partial row coloring has been chosen for simplicity.

Table F.9 (corresponding to Table 15.1) is also a sequence diagram drawn as a tabular object.

Table F.10 shows another version of Table F.3 with dashed horizontal and vertical rules of the `arydshln` package.

Table F.4: Performance of Synchronization Mechanisms of 4-CPU 1.8 GHz AMD Opteron 844 System

Operation	Cost (ns)	Ratio (cost/clock)
Clock period	0.6	1.0
Best-case CAS	37.9	63.2
Best-case lock	65.6	109.3
Single cache miss	139.5	232.5
CAS cache miss	306.0	510.0
Comms Fabric	5,000	8,330
Global Comms	195,000,000	325,000,000

Table F.5: Reference Counting and Synchronization Mechanisms

Acquisition Synchronization	Release Synchronization		
	Locking	Reference Counting	RCU
Locking	—	CAM _R	CA
Reference Counting	A	AM _R	A
RCU	CA	M _A CA	CA

Key: A: Atomic counting
 C: Check combined with the atomic acquisition operation
 M_R: Memory barriers required only on release
 M_A: Memory barriers required on acquire

Table F.10: Refrigeration Power Consumption

Situation	T (K)	C _P	Power per watt waste heat (W)
Dry Ice	195	1.990	0.5
Liquid N ₂	77	0.356	2.8
Liquid H ₂	20	0.073	13.7
Liquid He	4	0.0138	72.3
IBM Q	0.015	0.000051	19,500.0

In this case, the vertical dashed rules seems unnecessary. The one without the vertical rules is shown in Table F.11.

Table F.11: Refrigeration Power Consumption

Situation	T (K)	C _P	Power per watt waste heat (W)
Dry Ice	195	1.990	0.5
Liquid N ₂	77	0.356	2.8
Liquid H ₂	20	0.073	13.7
Liquid He	4	0.0138	72.3
IBM Q	0.015	0.000051	19,500.0

F.3.6.3 Miscellaneous Candidates

Other improvement candidates are listed in the source of this section as comments.

Table F.6: Cache Coherence Example

Sequence #	CPU #	Operation	CPU Cache				Memory	
			0	1	2	3	0	8
0		Initial State	-/I	-/I	-/I	-/I	V	V
1	0	Load	0/S	-/I	-/I	-/I	V	V
2	3	Load	0/S	-/I	-/I	0/S	V	V
3	0	Invalidation	8/S	-/I	-/I	0/S	V	V
4	2	RMW	8/S	-/I	0/E	-/I	V	V
5	2	Store	8/S	-/I	0/M	-/I	I	V
6	1	Atomic Inc	8/S	0/M	-/I	-/I	I	V
7	1	Writeback	8/S	8/S	-/I	-/I	V	V

Table F.7: RCU Publish-Subscribe and Version Maintenance APIs

Primitives	Availability	Overhead
List traversal		
<code>list_for_each_entry_rcu()</code>	2.5.59	Simple instructions (memory barrier on Alpha)
List update		
<code>list_add_rcu()</code>	2.5.44	Memory barrier
<code>list_add_tail_rcu()</code>	2.5.44	Memory barrier
<code>list_del_rcu()</code>	2.5.44	Simple instructions
<code>list_replace_rcu()</code>	2.6.9	Memory barrier
<code>list_splice_init_rcu()</code>	2.6.21	Grace-period latency
Hlist traversal		
<code>hlist_for_each_entry_rcu()</code>	2.6.8	Simple instructions (memory barrier on Alpha)
Hlist update		
<code>hlist_add_after_rcu()</code>	2.6.14	Memory barrier
<code>hlist_add_before_rcu()</code>	2.6.14	Memory barrier
<code>hlist_add_head_rcu()</code>	2.5.64	Memory barrier
<code>hlist_del_rcu()</code>	2.5.64	Simple instructions
<code>hlist_replace_rcu()</code>	2.6.15	Memory barrier
Pointer traversal		
<code>rcu_dereference()</code>	2.6.9	Simple instructions (memory barrier on Alpha)
Pointer update		
<code>rcu_assign_pointer()</code>	2.6.10	Memory barrier

Table F.8: RCU Publish-Subscribe and Version Maintenance APIs

Category	Primitives	Availability	Overhead
List traversal	<code>list_for_each_entry_rcu()</code>	2.5.59	Simple instructions (memory barrier on Alpha)
List update	<code>list_add_rcu()</code>	2.5.44	Memory barrier
	<code>list_add_tail_rcu()</code>	2.5.44	Memory barrier
	<code>list_del_rcu()</code>	2.5.44	Simple instructions
	<code>list_replace_rcu()</code>	2.6.9	Memory barrier
	<code>list_splice_init_rcu()</code>	2.6.21	Grace-period latency
Hlist traversal	<code>hlist_for_each_entry_rcu()</code>	2.6.8	Simple instructions (memory barrier on Alpha)
Hlist update	<code>hlist_add_after_rcu()</code>	2.6.14	Memory barrier
	<code>hlist_add_before_rcu()</code>	2.6.14	Memory barrier
	<code>hlist_add_head_rcu()</code>	2.5.64	Memory barrier
	<code>hlist_del_rcu()</code>	2.5.64	Simple instructions
	<code>hlist_replace_rcu()</code>	2.6.15	Memory barrier
Pointer traversal	<code>rcu_dereference()</code>	2.6.9	Simple instructions (memory barrier on Alpha)
Pointer update	<code>rcu_assign_pointer()</code>	2.6.10	Memory barrier

Table F.9: Memory Misordering: Store-Buffering Sequence of Events

CPU 0			CPU 1		
Instruction	Store Buffer	Cache	Instruction	Store Buffer	Cache
1 (Initial state)		$x1==0$	(Initial state)		$x0==0$
2 $x0 = 2;$	$x0==2$	$x1==0$	$x1 = 2;$	$x1==2$	$x0==0$
3 $r2 = x1; (0)$	$x0==2$	$x1==0$	$r2 = x0; (0)$	$x1==2$	$x0==0$
4 (Read-invalidate)	$x0==2$	$x0==0$	(Read-invalidate)	$x1==2$	$x1==0$
5 (Finish store)		$x0==2$	(Finish store)		$x1==2$

The Answer to the Ultimate Question of Life, The Universe, and Everything.

*“The Hitchhikers Guide to the Galaxy”,
Douglas Adams*

Appendix G

Answers to Quick Quizzes

G.1 How To Use This Book

Quick Quiz 1.1:

이 Quick Quiz 들의 답은 어디에 있나요? ■

Answer:

Page 459에서 시작하는 Appendix G에 있습니다.
쉽죠? □

Quick Quiz 1.2:

몇몇 퀴즈는 저자의 입장이 아니라 독자의 입장에서 쓰인 것 같은데요. 의도적으로 그렇게 한 건가요? ■

Answer:

실제로 그렇답니다! 많은 질문들은 Paul E. Mckenny 가 이 내용들을 다루는 수업을 듣는 학생이었다면 질문했을 법한 것들입니다. Paul은 이 내용들을 교수님들로부터가 아니라 병렬 하드웨어와 소프트웨어로부터 배웠다는 내용도 짚어둬야 할 것 같네요. Paul의 경험에 의하면, 교수님들은 Watson 같은 실제 병렬 시스템과는 달리 말로 이야기되는 문제에 대한 답을 주려 하는 경향이 있습니다. 물론, 이런 종류의 문제들에 대해 어떤 교수님들이나 어떤 병렬 시스템들이 가장 유용한 답을 주는지에 대해서는 길디 긴 토론이 가능하겠습니까만, 지금은 일단 실제 교수님들과 병렬 시스템들에 따라 그들이 주는 답의 유용성이 다를 수 있다는 점만 동의하고 넘어갑시다.

그 외의 퀴즈들은 컨퍼런스 발표 중에, 그리고 이 책에서 다루는 내용을 다루는 수업 중에 받은 실제 질문과 유사합니다. 그리고 일부 퀴즈는 저자의 관점에서 쓰이기도 했습니다. □

Quick Quiz 1.3:

이 Quick Quizzes 는 제 취향이 아니예요. 어떡하죠? ■

Answer:

여기 몇가지 전략이 있습니다:

1. 그냥 Quick Quizzes 를 무시하고 책을 읽으세요. 퀴즈 퀴즈의 흥미로운 내용들을 놓치게 되겠지만 이 책의 퀴즈를 제외한 부분도 훌륭한 내용을 많이 담고 있습니다. 만약 당신의 핵심 목표가 이 주제에 대한 일반적인 이해를 얻는 것이거나 이 책을 통해 특정 문제에 대한 해결책을 찾는 것이라면 충분히 합리적인 접근법입니다.
2. Quick Quizzes 가 집중을 방해하지만 무시하기엔 중요하다고 생각한다면, 언제든 이 책의 소스를 git 저장소에서 클론할 수 있음을 기억하세요. 그렇게 하면 Makefile 과 qqz.sty 를 수정해서 퀴즈 퀴즈가 PDF에서 사라지게 할 수 있습니다. 또는, 해당 파일들을 수정해서 답변이 문제 바로 아래 나오도록 수정할 수도 있습니다.
3. 당신의 답을 구하느라 너무 많은 시간을 보내지 말고 곧바로 답을 보세요. 현재 퀴즈 퀴즈의 답이 당신이 해결하려는 문제의 핵심을 쥐고 있는 게 아니라면 이것도 합리적인 접근법입니다. 또한, 당신이 원하는게 해당 내용에 대한 깊은 이해이지, 새로운 병렬성을 활용한 해결책을 맨바닥부터 만들려 하는게 아닌 경우에도 이는 합리적인 접근법입니다.

2016년 중반부터 이 Quick Quizzes 는 답으로, 답은 퀴즈로 링크가 되어 있습니다. 답으로 이동하기 위해서는 “Quick Quiz” 시작점이나 작은 검정 네모를 클릭하세요. 답에서 퀴즈의 시작으로 가기 위해서는 답의 시작점이나 작은 검정 네모를, 퀴즈의 끝으로 가려면 작은 하얀 네모를 클릭하세요. □

G.2 Introduction

Quick Quiz 2.1:

이봐요!!! 병렬 프로그래밍은 수십년간 엄청나게 어렵다고 알려졌다구요. 근데 당신은 그게 그렇게 어렵지

않다고 슬쩍 이야기하는 것 같네요. 뭔가 사기치는 거 아닌가요? ■

Answer:

정말 병렬 프로그래밍이 엄청나게 어렵다고 믿는다면, “왜 병렬 프로그래밍이 어려운가?”라는 질문에 대답 할 준비가 되어 있을 겁니다. 누군가는 여러 이유를 댈 수 있겠죠, 데드락부터 레이스 컨디션, 테스팅 커버리지 등등. 하지만 진짜 답은 그건 그렇게까지 어렵지는 않다입니다. 무엇보다도, 만약 병렬 프로그래밍이 정말로 그렇게 소름끼치도록 어렵다면, Apache나 MySQL, 리눅스 커널 같은 많은 오픈 소스 프로젝트들은 어떻게 그걸 잘 사용하고 있겠어요?

보다 나은 질문은 아마도 이렇겠죠: “왜 병렬 프로그래밍은 그렇게 어렵다고 알려져 있을까요?” 답을 알기 위해, 1991년으로 돌아가 봅시다. Paul McKenney는 6개의 dual-80486 Sequent Symmetry CPU 보드를 들고 Sequent의 벤치마킹 센터 주차장을 지나가던 중, 문득 자신이 집 몇채 가격의 물건을 들고 있음을 깨달았습니다.¹ 이렇게 엄청난 병렬 시스템의 가격은 병렬 프로그래밍이 병렬 시스템을 직접 제작하거나—1991년의 미국 달러로—\$100,000 이상의 가격의 기계를 구매할 수 있는 회사에서 일하는 일부 제한된 특권층에게만 가능했음을 의미합니다.

하지만, 2006년, Paul은 자신이 이 글을 dual-core x86 노트북에서 쓰고 있음을 발견합니다. 앞서 이야기한 dual-80486 CPU 보드와 달리, 이 노트북은 2GB 메인 메모리, 60GB 디스크 드라이브, 모니터, 이더넷, USB 포트, 무선랜, 그리고 블루투스까지 달려 있습니다. 그리고 그 노트북은 그간의 인플레이션을 고려하지 않더라도 dual-80486 CPU 보드보다 열배가 넘게 싹니다.

병렬 시스템이 정말로 세상에 도래했습니다. 병렬 시스템은 더이상 일부 특권층의 소유물이 아니라 거의 모든 사람에게 가능한 물건입니다.

기존의 제한적이었던 병렬 하드웨어로의 접근성이 야말로 병렬 프로그래밍이 그렇게 어렵다고 여겨지게 만들었던 진짜 이유입니다. 무엇보다, 아무리 단순한 기계라도 직접 만져볼 수가 없다면 프로그램 하는 법을 배우는건 매우 어렵습니다. 찾기 어렵고 비싼 병렬 머신들의 시대는 갔으니 병렬 프로그래밍이 미치도록 어렵다고 생각하던 시대는 곧 지나갈 겁니다.² □

Quick Quiz 2.2:

어떻게 병렬 프로그래밍이 순차적 프로그래밍만큼 쉬운게 가능한가요? ■

¹ 그래요, 이 갑작스런 깨달음은 그가 좀 더 조심히 걸게 만들었습니다. 왜 그런걸 물어요?

² 병렬 프로그래밍은 순차적 프로그래밍보다는 어렵습니다. 예를 들어, 병렬적으로 validation을 하는 것은 더 어렵습니다. 하지만 더이상 미질듯이 어렵진 않아요.

Answer:

그건 프로그래밍 환경에 달려 있습니다. SQL [Int92]는 잘 알려지지 않은 성공 사례인데요, 병렬성에 대해 잘 모르는 프로그래머도 거대한 병렬 시스템을 바삐 동작하게 만들 수 있도록 해주기 때문이죠. 병렬 컴퓨터는 갈수록 싸고 어디서나 접할 수 있게 되어가고 있기 때문에 이런 류의 다양한 예를 볼 수 있을 겁니다. 예를 들어, 과학 / 기술 컴퓨팅 쪽에서의 가능할 법한 경쟁자는 일반적인 행렬 연산을 자동으로 병렬화 시켜주는 MATLAB*P입니다.

마지막으로, 리눅스와 유닉스 시스템에서의 다음 셀 커맨드를 생각해 보세요:

```
get_input | grep "interesting" | sort
```

이 셀 파이프라인은 get_input, grep, 그리고 sort를 병렬적으로 처리합니다. 어때요, 어렵지 않았죠, 그렇죠?

요약하자면, 병렬 프로그래밍은 순차적 프로그래밍 만큼이나 쉽습니다. 적어도 병렬성을 사용자로부터 숨겨주는 환경에서는요! □

Quick Quiz 2.3:

헐, 진짜요? 정확성, 관리성, 내구성이 같은 것들은요? ■

Answer:

그것들도 중요한 목표들이죠, 하지만 그런 목표들의 중요도는 순차적 프로그램에서나 병렬 프로그램에서나 똑같습니다. 따라서, 그것들은 중요한 목표들이긴 하지만 병렬 프로그래밍만의 목표에는 속하지 않습니다. □

Quick Quiz 2.4:

그리고 정확성, 관리성, 내구성이 해당되지 않는데 왜 생산성과 Generality는 해당되는거죠? ■

Answer:

병렬 프로그래밍이 순차적 프로그래밍보다 훨씬 어렵다고 인식되고 있는 만큼, 생산성도 달성하기 어려운 목표로 여겨지고 있고, 따라서 반드시 이 목표를 이뤄야 합니다. 또한, SQL과 같이 높은 생산성을 갖는 병렬 프로그래밍 환경은 특정한 용도에만 사용 가능하기 때문에, Generality도 반드시 목표에 들어가야 합니다. □

Quick Quiz 2.5:

병렬 프로그램은 정확성을 증명하기가 어렵다고 알고 있는데, 정말 정확성도 그 목록에 올라갈 수 없는 건가요? ■

Answer:

공학적 관점에서, 형식적이든 비형식적이든, 정확성을 증명하는데 있어서의 어려움은 생산성의 주요 목표에

영향을 끼치는 만큼 중요합니다. 따라서, 정확성 증명이 중요한 경우라면 “생산성” 아래 포함된다고 볼 수 있겠죠. □

Quick Quiz 2.6:

그냥 재미를 목표로 하는건 어떤가요? ■

Answer:

재미도 물론 중요하죠, 하지만 당신이 이걸 취미로 하는 사람이 아니라면 재미가 당신의 최우선 목표는 아닐 겁니다. 거꾸로 말하자면, 당신이 취미로 이걸 하는 사람이 맞다면 좋은 자세입니다! □

Quick Quiz 2.7:

성능 이외의 이유로 병렬 프로그래밍을 하는 경우는 없나요? ■

Answer:

풀어야 하는 문제가 본질적으로 병렬적인 경우가 있는데, 예를 들면 Monte Carlo method들과 일부 숫자 계산들입니다. 하지만, 이런 경우에조차도 병렬성을 관리하기 위해 많은 추가작업이 필요합니다.

병렬성은 가끔 신뢰성(reliability)을 위해 사용되기도 합니다. 일단 예를 하나들자면, triple-modulo redundancy는 병렬로 동작하는 세개의 시스템을 가지고 결과에 대해 투표를 합니다. 극단적 경우에는 세개의 시스템이 서로 다른 알고리즘과 기술을 가지고 독립적으로 구현될 수도 있습니다. □

Quick Quiz 2.8:

왜 이런 비기술적인 주제를 이야기하는거죠??? 그저 비기술적일 뿐 아니라, 심지어 생산성이라니요? 누가 그런걸 신경써요? ■

Answer:

여러분이 순수히 취미로만 이 일을 하는 사람이라면 신경쓰지 않아도 될겁니다. 하지만 설령 그렇다 해도 얼마나 빨리 그리고 얼마나 많이 일을 할 수 있는지는 종종 신경쓰일 겁니다. 무엇보다, 가장 유명한 취미가용 도구는 보통 그 목적에 가장 적합한 도구이고, “가장 적합한” 이란 말의 정의의 가장 중요한 부분은 생산성과 연결되어 있죠. 그리고 만약 누군가가 당신에게 병렬 코드를 작성하라고 돈을 준다면, 그들은 당신의 생산성에 대해 매우 신경쓸겁니다. 그리고 그 고용주가 뭔가에 신경쓴다면, 당신은 거기에 적어도 관심을 가져야겠죠!

논외지만, 만약 여러분이 정말로 생산성에 신경쓰지 않는다면, 애초에 컴퓨터를 사용하지 않고 손으로 일을 했겠죠! □

Quick Quiz 2.9:

병렬 시스템이 그렇게 싼 가격이 되었다면, 어떤 사람이 그걸 프로그램 하라고 월급을 줘가며 프로그래머를 고용하겠어요? ■

Answer:

이 질문에는 여러개의 답이 있습니다:

1. 거대한, 여러 병렬머신들로 구성된 클러스터가 있다고 하면, 이 클러스터의 전체 비용은 상당한 개발 비용을 정당화하는데, 개발 비용이 이 수많은 머신들 전체에 분산 적용될 수 있기 때문입니다.
2. 수천만명이 넘는 사용자들이 존재하는 유명한 소프트웨어라면 그 개발 비용은 수천만 사용자들에게 분산 적용될 수 있으므로 상당한 개발 비용이 정당화 됩니다. 커널이나 시스템 라이브러리 같은 것들도 이 경우에 들어감을 참고하세요.
3. 낮은 가격의 병렬 머신이 중요한 어떤 장비의 운영에 사용되고 있다면 그 장비의 가격 일부분이 상당한 개발 비용을 정당화 할 수 있습니다.
4. 낮은 가격의 병렬 머신을 위한 소프트웨어가 상당히 가치있는 결과 (예: 광산의 탐사)를 만들어 낸다면 이 가치있는 결과는 역시 상당한 개발 비용을 정당화 할 수 있을 겁니다.
5. 안전을 위해 사용되는 주요 시스템은 사람의 목숨을 보호합니다. 따라서 이 경우에는 매우 큰 개발 비용을 정당화 하죠.
6. 취미가와 연구자들은 돈보다는 지식, 경험, 재미, 그리고 명예를 추구합니다.

그리니까 하락하는 하드웨어 가격은 소프트웨어를 의미없게 만들지 않고, 오히려 소프트웨어 개발 비용을 하드웨어 가격에 “숨기는” 것이 불가능해진 겁니다. 엄청나게 많은 수의 하드웨어를 사용하는 경우가 아니라면요. □

Quick Quiz 2.10:

이건 달성 불가한 이상에 불과해요! 현실적으로 달성 가능한 무언가에 집중하는게 어때요? ■

Answer:

이건 분명 달성 가능합니다. 휴대폰은 프로그래밍이나 환경구성 없이 최종 사용자가 전화 통화를 하고 텍스트 메세지를 주고 받을 수 있게 해주는 컴퓨터입니다.

일견 사소한 예처럼 보일 수 있겠지만, 천천히 생각해보면 이건 간단하기도 하고 심오하기도 한 이야기입니다. generality를 희생하면 우리는 놀랍도록 높은 생산성 향상을 얻을 수 있습니다. 과한 generality에 빠진

사람들은 그래서 소프트웨어 스택의 최대치까지 성능을 끌어올리는데 실패하곤 합니다. 이 삶의 진리는 그에 대한 약자도 가지고 있죠: YAGNI, 즉 “You Ain’t Gonna Need It.” □

Quick Quiz 2.11:

잠깐만요! 이런 접근법은 개발을 위한 노력을 당신으로부터 이미 존재하는 병렬 소프트웨어를 만드는 사람인 누군가에게 전가할 뿐인 거 아닌가요? ■

Answer:

바로 그겁니다! 그리고 그게 바로 이미 존재하는 소프트웨어를 쓰는 것의 요점이죠. 한 팀의 작업물이 많은 다른 팀에 의해 재사용되어서 모든 팀이 불필요하게 바퀴를 재발명하는 것에 비해 전체적인 노력을 크게 줄이게 되는것이요. □

Quick Quiz 2.12:

어떤 다른 병목지점들이 CPU를 추가해도 성능이 개선되지 않게 할 수 있을까요? ■

Answer:

그런 잠재적 병목지점이 얼마든지 있습니다:

1. 메인 메모리. 싱글 쓰레드가 모든 가용한 메모리를 사용하고 있다면, 추가된 쓰레드는 명청하게 자신을 페이지 아웃 시킬 뿐이겠죠.
2. 캐시. 싱글 쓰레드의 캐시 사용량이 모든 공유된 CPU 캐시(들)을 꽉 채운다면, 쓰레드를 추가하는 것은 그저 영향받는 캐시들을 압박 하기만 할겁니다.
3. 메모리 대역폭. 싱글 쓰레드가 모든 메모리 대역폭을 소모한다면, 추가된 쓰레드들은 메모리로와 시스템 사이에 줄 서 있기만 할겁니다.
4. I/O 대역폭. 싱글 쓰레드가 I/O에 바운드 되어 있다면, 쓰레드를 추가하는 것은 쓰레드들이 모두 관련된 I/O 자원에 줄을 서서 기다리고만 있게 할겁니다.

특정 하드웨어 시스템들은 얼마든지 추가적인 병목지점을 가지고 있을 수 있습니다. 다만 분명한 건 여러 CPU들이나 쓰레드들 간에 공유되고 있는 모든 자원은 잠재적 병목지점입니다. □

Quick Quiz 2.13:

CPU 캐시 용량 외에, 동시에 수행되는 쓰레드들의 갯수를 제한해야 하는 요인이 또 뭐가 있을 수 있을까요? ■

Answer:

쓰레드 갯수에 영향을 끼치는 여러 잠재적 요소들이 있습니다:

1. 메인 메모리. 각 쓰레드는 (최소한 스택을 위해) 메모리를 일부 사용하므로, 너무 많은 쓰레드는 메모리를 모조리 사용해버려서 과도한 페이징이나 메모리 할당 실패를 일으킬 수 있습니다.
2. I/O 대역폭. 각 쓰레드가 많은 스토리지 I/O나 네트워크 트래픽을 만든다면 너무 많은 수의 쓰레드는 과도한 I/O 큐잉 딜레이를 일으키고, 결국 성능이 저하될 겁니다. 일부 네트워킹 프로토콜은 너무 많은 쓰레드가 존재해 네트워킹 이벤트에 대한 응답을 시간 내에 받지 못할 경우 타임아웃이나 다른 문제상황을 낼 수 있습니다.
3. 동기화 오버헤드. 많은 동기화 프로토콜에서 과도한 수의 쓰레드는 지나친 스피닝 (spinning), 블락킹 (blocking), 또는 롤백을 일으켜서 성능을 떨어뜨릴 수 있습니다.

특정한 어플리케이션이나 플랫폼에 따라서는 이외에도 추가적인 요소가 얼마든지 있을 수 있습니다. □

Quick Quiz 2.14:

“명시적 타이밍”이란 무엇인가요???. ■

Answer:

특정 쓰레드가 동의된 시간 동안 자원들의 일부 집합에 접근하는 것. 예를 들어, 여덟개의 쓰레드를 갖는 병렬 프로그램은 8-밀리세컨드 시간 간격으로 구성되어서, 첫번째 쓰레드가 각 간격의 첫번째 밀리세컨드 동안 접근을 한다면, 두번째 쓰레드는 두번째 밀리세컨드 동안 접근하고 나머지도 그런 식으로 접근을 하게 되는 경우입니다. 이 방법은 주의깊게 동기화된 시계와 주의깊은 수행시간의 제어를 필요로 하며, 따라서 상당한 주의를 가지고 사용되어야만 합니다.

사실, hard realtime 환경 외에서는, 여러분은 대부분의 경우 이와 다른 것을 원할 겁니다. 그러나 명시적 타이밍은 언급될 가치가 있는데, 여러분이 필요로 할 때에는 사용할 수 있기 때문입니다. □

Quick Quiz 2.15:

병렬 프로그래밍에 다른 어려움은 없나요? ■

Answer:

병렬 프로그래밍에의 수많은 잠재적 문제들이 존재합니다. 여기 그 중 일부를 이야기 해보죠:

- 주어진 프로젝트의 하나 뿐인 알고리즘이 본질적으로 순차적일 수 있습니다. 이 경우에는 (당신의 프로젝트가 반드시 병렬로 돌아야 한다는 규칙이 없다면) 병렬 프로그래밍을 관두거나 새로운 병렬 알고리즘을 고안해내야 합니다.
- 프로젝트가 동일한 주소 공간을 사용하지만 바이너리로만 제공되는 플러그인을 허용해서 어떤 개발자도 해당 프로젝트의 모든 소스 코드에 접근할 수는 없는 경우가 있을 수 있습니다. 데드락을 포함해 많은 병렬성에 기인한 버그들이 여기저기 있을 수 있기 때문에, 그런 바이너리로만 제공되는 플러그인은 현재의 소프트웨어 개발 방법 하에서는 상당한 어려움을 안겨줄 수 있습니다. 이 역시 시간이 흐름에 따라 바뀔 수도 있겠지만, 현재로써는, 특정 주소 공간을 공유하는 병렬 코드의 개발자는 모두 해당 주소 공간에서 돌아가는 모든 코드를 들여다 볼 수 있어야 합니다.
- 프로젝트가 병렬성을 고려하지 않은 채 설계된 API [AGH^{11a}, CKZ¹³] 를 엄청나게 사용하는 경우. System V 메세지 큐 API의 매우 화려한 기능들이 이 경우에 속합니다. 물론, 당신의 프로젝트가 수십년 넘게 존속되었다면, 그리고 그 개발자들이 병렬 하드웨어를 접해본 적 없었다면 그 프로젝트는 분명 그런 API 들을 최소한 사용은 하고 있을 겁니다.
- 프로젝트가 병렬성에 대한 고려 없이 구현된 경우. 순차적 환경에서는 매우 잘 동작하지만 병렬 환경에서는 차참하게 동작하는 기술이 많이 있기 때문에, 만약 여러분의 프로젝트가 순차적 하드웨어에서만 그동안 사용되어왔다면 당신의 프로젝트는 분명 병렬성에 친화적이지 못한 코드를 최소한 사용은 하고 있을 겁니다.
- 프로젝트가 좋은 소프트웨어 개발 관습을 따르지 않고 구현된 경우. 잔혹한 사실은 많은 경우에 있어 공유 메모리 병렬 환경은 순차적 환경에 비해 대충 만들어진 개발 관습에 더욱 엄혹하다는 것입니다. 이 경우에는 병렬성을 도입하기 전에 먼저 기존의 설계와 코드를 재정리 해야할 겁니다.
- 프로젝트를 처음 개발한 사람들이 여전히 관리 권한을 쥐고 있거나 작은 기능 정도는 추가할 수 있는 기능을 가지고 있지만 “커다란” 변경은 할 수 없는 경우. 이런 경우에는 여러분이 매우 간단하게 당신의 프로젝트를 병렬화 할 수 있다 해도, 순차적인 채로 놔두는게 최선일 수 있습니다. 그렇지만 여러 인스턴스를 수행시킨다던지, 많이 사용하는 라이브러리의 병렬적 구현체를 사용한다던지, 데이터베이스와 같은 다른 병렬 프로젝트의 사용을

하도록 한다던지 하는 방법들로 프로젝트를 간단히 병렬화 시킬 수 있는 방법이 있습니다.

이런 문제들은 비기술적인 요소들이라고 말할 수도 있겠습니다만, 그렇다고 이것들이 비현실적이지도 않습니다. 요약하자면, 커다란 코드의 병렬화는 크고 복잡한 노력을 필요로 할 수 있습니다. 그리고 크고 복잡한 노력이 필요하다면, 그 속제를 가능한 빨리 해결하는 게 낫겠죠. □

G.3 Hardware and its Habits

Quick Quiz 3.1:

왜 병렬 프로그래머가 하드웨어의 로우 레벨 요소들까지 배워야 하죠? 하이 레벨의 추상 계층만 보는게 더 쉽고, 낫고, 일반적이지 않겠어요? ■

Answer:

하드웨어의 세세한 내용들은 무시하는게 더 쉬울 수 있을 겁니다만, 많은 경우 그건 바보같은 짓일 수 있습니다. 병렬성의 모든 목적이 성능 향상일 뿐이란걸 인정하신다면, 그리고 성능은 하드웨어의 디테일한 부분들에 의존적인 걸 인정하신다면, 논리적으로 병렬 프로그래머들은 하드웨어에 대해 최소 조금은 알아야 한다는 결론을 얻을 수 있을 겁니다.

이건 대부분의 엔지니어링 교훈에서 나오는 이야기입니다. 당신이라면 콘크리트와 철강에 대해 이해하지 못하는 엔지니어가 설계한 다리를 사용하시겠습니까? 아니라면, 왜 병렬 프로그래머가 최소한 조금의 하드웨어에 대한 이해 없이 훌륭한 병렬 소프트웨어를 만들 수 있을 거라고 생각하시나요? ■

Quick Quiz 3.2:

어떤 기계가 복수 데이터 요소에 대한 어토믹 오퍼레이션을 허용하겠어요? ■

Answer:

이 질문에 대한 한가지 답은 종종 복수개의 데이터 요소를 어토믹하게 다뤄질 수 있는, 단일 머신 워드 안에 모아넣을 수 있다는 겁니다.

좀 더 트렌디한 답은 트랜잭션 메모리 [Lom77] 를 지원하는 기계가 되겠습니다. 2014년 초에 이르러서는 일부 주요 시스템들이 제한되긴 했지만 하드웨어 트랜잭션 메모리 구현을 제공합니다. 더 자세한 내용은 Section 17.3 에서 다루고 있습니다. 소프트웨어 트랜잭션 메모리 [MMW07, PW07, RHP⁰⁷, CBM⁰⁸, DFGG11, MS12] 에 대해서는 아직 적합하지 않다는 평가입니다. 소프트웨어 트랜잭션 메모리에 대한 더 많은 내용은 Section 17.2 에서 볼 수 있을 겁니다. □

Quick Quiz 3.3:

그래서, CPU 설계자들은 캐시 미스 오버헤드 역시 많이 개선 했나요? ■

Answer:

안타깝지만, 그렇게 많은 개선은 하지 못했습니다. 약간 오버헤드를 줄인 CPU들도 있습니다만, 빛의 속도의 한계와 물질의 원자성의 자연 법칙이 큰 시스템에서 캐시 미스 오버헤드를 줄일 수 있는 방법을 제한하고 있습니다. Section 3.3에서 가능할 법한 미래의 개선 방법들을 논의해 봅니다. □

Quick Quiz 3.4:

이게 간략히 표현한 거라구요? 이것보다 더 복잡한게 어떻게 가능하죠? ■

Answer:

이 예는 다음을 포함해 몇가지 있을법한 복잡한 경우를 뺏습니다:

1. 해당 캐시라인에 대해 다른 CPU들도 동시에 CAS 오퍼레이션을 수행하려 하고 있을 수 있습니다.
2. 해당 캐시라인은 리드 온리로 다른 CPU들의 캐시들에 복사되어 있을 수 있는데, 이 경우엔 그 캐시들도 비워야 합니다.
3. CPU 7은 해당 요청이 도착했을 때 해당 캐시라인에 뭔가 연산을 수행하고 있었을 수 있고, 이 경우 CPU 7은 자신의 연산이 끝날 때까지 해당 요청을 잠시 대기하고 있게 해야 합니다.
4. CPU 7은 (예를 들어, 다른 데이터를 위한 공간을 만들기 위해) 해당 캐시라인을 캐시에서 없앴을 수 있고, 이로 인해 요청이 도착한 시점에서는 캐시라인이 메모리에 있을 수 있습니다.
5. 캐시라인에서 고칠 수 있는 에러가 났을 수 있는데, 그렇다면 해당 데이터가 사용되기 전에 그 에러는 고쳐져야 합니다.

제품 품질의 캐시 일관성 메커니즘들은 이런 종류의 여러 복잡한 경우 [HP95, CSG99, MHS12, SHW11] 때문에 엄청나게 복잡합니다. □

Quick Quiz 3.5:

왜 CPU 7의 캐시에서 해당 캐시라인을 비워야 하죠? ■

Answer:

만약 해당 캐시라인이 CPU 7의 캐시에서 비워지지 않는다면, CPU 0과 CPU 7은 같은 변수에 대해 서로 다른

Table G.1: Performance of Synchronization Mechanisms on 16-CPU 2.8 GHz Intel X5550 (Nehalem) System

Operation	Cost (ns)	Ratio (cost/clock)
Clock period	0.4	1.0
“Best-case” CAS	12.2	33.8
Best-case lock	25.6	71.2
Single cache miss	12.9	35.8
CAS cache miss	7.0	19.4
Off-Core		
Single cache miss	31.2	86.6
CAS cache miss	31.2	86.5
Off-Socket		
Single cache miss	92.4	256.7
CAS cache miss	95.9	266.4
Comms Fabric	2,600	7,220
Global Comms	195,000,000	542,000,000

값을 보게 될 겁니다. 이런 종류의 비일관성은 병렬 소프트웨어를 매우 복잡하게 만들 수 있고, 때문에 하드웨어 설계자들은 그런 문제를 없애려 노력해 왔습니다. □

Quick Quiz 3.6:

하드웨어 설계자들은 분명 이 상황을 개선하려 노력할 수 있었을 거예요! 왜 그들은 이 단일 인스트럭션 오퍼레이션들의 끔찍한 성능을 만족하고 있는거죠? ■

Answer:

하드웨어 설계자들은 이 문제를 해결하려 노력했었습니다만, 물리학자 스티븐 호킹 정도의 권위자에게만 조언을 얻었습니다. 호킹은 하드웨어 설계자들이 두개의 기본 문제 [Gar07]를 가지고 있음을 발견했습니다:

1. 빛의 한계 속도, 그리고
2. 물질의 원자적 본성.

첫번째 문제는 기본 속도를 제한하고, 두번째 문제는 동작의 소형화를 제한하여 결과적으로 단위시간당 가능한 오퍼레이션의 갯수를 제한합니다. 그리고 이 문제는, 설령 현재 상품화된 CPU들의 속도를 10 GHz 아래로 제한하고 있는 에너지 소비 문제를 피해간다 해도 존재합니다.

Table G.1과 페이지 22의 Table 3.1를 비교해 보면 알 수 있겠지만, 분명 개선은 이루어지고 있습니다. 하드웨어 쓰레드들을 단일 코어에 집어 넣고 복수의 코어들을 하나의 다이에 넣는 것은 적어도 싱글 코어내에서 또는 단일 다이 내에서의 반응속도는 엄청나게

개선했습니다. 전체 시스템 응답시간에도 일부 개선이 있었습니다만, 겨우 대략 두배 정도입니다. 안타깝지만, 지난 몇년간 빛의 속도도 물질의 원자적 본성도 크게 변하지 않았습니다 [Har16].

Section 3.3에서는 병렬 프로그래머들의 곤경을 완화시키기 위해 어떤 일을 해줄 수 있을지 알아봅니다. □

Quick Quiz 3.7:

숫자가 미친듯이 크군요! 어떡해야 제 머리로 이걸 이해할 수 있을까요? ■

Answer:

휴지 한 룰을 가져오세요. 미제 휴지라면, 한 룰의 휴지는 약 350-500 조각의 휴지로 구성됩니다. 휴지의 조각 하나가 하나의 클락 사이클이라고 생각하고 한조각을 찢어 보세요. 이제 나머지를 모두 풀어 보세요.

그게 하나의 CAS 캐시 미스를 의미한다고 보면 됩니다.

더 비싼 시스템간 커뮤니케이션 대기시간을 보려면, 몇개의 휴지 룰 (또는 여러 휴지 케이스들)이 필요할 겁니다.

중요한 팁 하나: 당신이 살아가면서 필요한 휴지가 얼마나 되는지도 생각해보세요! □

Quick Quiz 3.8:

하지만 개별의 전자들은 컨덕터 내에서조차도 그렇게 빠르지 않아요!!! 반도체에서 발견된 저전압 컨덕터 안에서의 전자 이동 속도는 초당 겨우 1 밀리미터 정도라구요. 뭘까요??? ■

Answer:

전자 이동 속도는 긴 시간동안의 개별 전자들의 이동을 추적합니다. 개별 전자들은 꽤 무작위적으로 튀어나녀서 그들의 순간 속도는 매우 빠르지만 긴 시간으로 보게 되면 그렇게 멀리 이동하지는 않습니다. 여기서, 전자들은 대부분의 시간을 고속으로 이동하는데 소모하지만 긴 시간으로 보면 어디에도 가지 않는 통근자와도 같습니다. 이런 통근자들의 속도는 시속 70 마일(시속 113 킬로미터) 정도지만, 지구의 표면에 비교해 보는 긴 시간동안의 이동 속도는 제로에 가까울 겁니다.

따라서, 우리는 전자의 이동속도가 아니라 순간적 속도에 주의를 기울여야 합니다. 하지만, 전자의 순간적 속도라 하더라도 빛의 속도에는 발끝도 따라가지 못합니다. 그러나, 컨덕터에서 측정된 전자파의 속도는 빛의 속도의 발끝은 따라가고 있는데, 이 때문에 여전히 미스테리는 풀리지 않습니다.

또 다른 트릭은 전자는 그 음극의 성질로 인해 다른 전자와 상당히(원자적 관점에서요) 상호작용 한다는 것입니다. 이 상호작용은 광자에 의해 이끌어지는데, 광자는 바로 빛의 속도로 움직입니다. 따라서 전기학에서의 전자라 해도, 대부분의 일을 하는건 광자입니다.

통근자 비유를 이어가 보자면, 운전자는 다른 운전자에게 사고나 교통 혼잡들을 알리는데 스마트폰을 사용할 수 있고, 이로 인해 교통 상황의 변화를 개별 차들의 순간 속도보다 훨씬 빠르게 전파할 수 있는 겁니다. 이 전기학과 교통상황 사이의 비유를 요약하자면 다음과 같습니다:

1. 전자의 (매우 낮은) 이동 속도는 통근자의 장시간 속도와 비슷해서, 둘 다 제로에 가깝습니다.
2. 전자의 (여전히 낮은) 순간 속도는 통행 중인 차의 순간 속도와 비슷합니다. 둘 다 이동 속도에 비해선 높지만, 변화가 전달되는 속도에 비교하면 굉장히 작습니다.
3. 전자파의 (훨씬 높은) 전달 속도는 대부분 전자들 사이에서 전자기력을 전달하는 광자의 덕분입니다. 유사하게, 교통 상황은 운전자 사이의 커뮤니케이션으로 인해 훨씬 빠르게 바뀔 수 있습니다. 이것은 이미 교통 혼잡에 빠져 있는 운전자에겐 큰 도움이 되지 않듯이, 이미 주어진 캐퍼시티에 잡혀 있는 전자들에겐 큰 도움이 되지 않습니다.

물론, 이 주제를 완전히 이해하려면 전자기학을 공부해야 할겁니다. □

Quick Quiz 3.9:

분산 시스템에서 통신이 그렇게까지 비싸다면 누가, 그리고 왜 그런 시스템을 쓰려 하는 건가요? ■

Answer:

몇가지 이유가 있지요:

1. 공유 메모리 멀티 프로세서 시스템은 크기 제한이 있습니다. 수천개 이상의 CPU가 필요하다면, 분산 시스템을 사용하는 것밖에 선택지가 없습니다.
2. 극단적으로 거대한 공유 메모리 시스템은 매우 비싸고, Table 3.1에 나타난 것처럼 작은 네개 CPU로 구성된 시스템에서보다도 긴 캐시 미스 대기시간을 갖는 경향을 보입니다..
3. 분산 시스템에서의 통신 대기시간은 CPU를 사용하지 않고, 따라서 메세지가 전달되는 동안 컴퓨팅 연산을 병렬적으로 수행할 수 있습니다.

4. 많은 중요한 문제들은 “당황스럽도록 병렬적” 이라서 극단적일 정도로 거대한 연산 단위들이 매우 작은 수의 메세지만으로 가능해 질수도 있습니다. SETI@HOME [Uni08b] 은 그런 어플리케이션의 한 예입니다. 이런 부류의 어플리케이션들은 극단적으로 긴 통신 대기시간에도 불구하고 컴퓨터 네트워크를 훌륭하게 사용할 수 있습니다.

병렬 어플리케이션에서의 향후 노력은 긴 통신 대기 시간을 가진 기계와, 또는 클러스터에서 잘돌아갈 수 있는 당황스럽도록 병렬적인 어플리케이션의 수를 늘려가는 것을 계속할 것입니다. 그렇다면 해도, 하드웨어 대기시간을 크게 줄이는 것은 개발에 크게 도움이 될겁니다. □

Quick Quiz 3.10:

좋아요, 우리가 분산 프로그래밍 기법들을 공유 메모리 병렬 프로그램에 적용하려 한다면, 항상 이런 분산 기법들을 사용하고 공유 메모리 없이 살면 안되나요? ■

Answer:

많은 경우 프로그램의 작은 부분만이 성능에 민감하기 때문입니다. 공유 메모리 병렬성은 우리가 그 작은 부분에의 분산 프로그래밍에 집중하고, 성능에 민감하지 않은 프로램의 대부분의 영역은 간단한 공유 메모리 기법을 사용하도록 해줍니다. □

간단한 것을 잊지 않도록 하는 것입니다! 무엇보다, 당신이 그 어려운 병렬 프로그래밍을 하기로 선택했다면, 당신의 선택이니, 당신 자신 외의 누구에게도 불평 할 수 없습니다. □

G.4 Tools of the Trade

Quick Quiz 4.1:

이것들을 도구라고 하셨나요??? 제게 이것들은 도구라기보다는 낮은 단계의 동기화 기능들처럼 보이는데요!

■

Answer:

그것들은 실제로 낮은 단계의 동기화 기능들이기 때문에 그렇게 보입니다. 하지만 또한, 그것들은 실제로 낮은 단계의 동시성 있는 소프트웨어를 만드는데 사용되는 기본적인 도구들입니다. □

Quick Quiz 4.2:

하지만 이 간단한 셸 스크립트는 진짜 병렬 프로그램이 아니잖아요! 왜 이런 별거아닌 걸 신경쓰는거죠??? ■

Answer:

당신은 결코 이 간단한 것을 잊지 않아야 하기 때문입니다!

이 책의 제목이 “Is Parallel Programming Hard, And, If So, What Can You Do About It?” 이런 걸 마음에 새겨 두십시오. 당신이 할 수 있는 가장 효과적인 일은 그

Quick Quiz 4.3:

병렬 셸 스크립트를 작성하는 좀 더 간단한 방법은 없나요? 만약 있다면, 어떻게 하나요? 없다면, 왜 없죠?

■

Answer:

가장 직관적인 방법은 셸 파이프라인입니다:

```

grep $pattern1 | sed -e 's/a/b/' | sort
\end{verbatim}
}

충분히 커다란 입력 파일에 대해서, \co{grep} 의 패턴 매칭, \co{sed} 수정과 \co{sort} 의 입력을 처리는 병렬적으로 수행될 겁니다.
\path{parallel.sh} 파일에 셀 스크립트 병렬성과 파이프라인에 있습니다.
\iffalse

For a sufficiently large input file,
\co{grep} will pattern-match in parallel with \co{sed}
editing and with the input processing of \co{sort}.
See the file \path{parallel.sh} for a demonstration of
shell-script parallelism and pipelining.
\fi

\QuickE{}
\QuickQ{}

하지만 스크립트 기반 병렬 프로그래밍이 그렇게 쉽다면, 왜 다른 것들을 바로 동작하는 가장 빠른 방법 아닐까요? ■

\iffalse

But if script-based parallel programming is so easy, why
bother with anything else?
\fi

\QuickA{}

사실 오늘날 사용되는 병렬 프로그램들의 매우 많은 부분들이 스크립트에 기반합니다.
하지만, 스크립트 기반 병렬성은 한계점도 지니고 있습니다:
\iffalse

In fact, it is quite likely that a very large fraction of
parallel programs in use today are script-based.
However, script-based parallelism does have its limitations:
\fi

\begin{enumerate}
\item 새 프로세스의 생성은 보통 비싼 시스템콜인 \co{fork()} 와 \co{exec()} 를 포함하기 때문에 상당히 무거운 작업입니다.
\item 파일라이닝을 포함해서 데이터의 공유는 일반적으로 비싼 file I/O 를 포함합니다.
\item 스크립트에서 믿고 쓸 수 있는 동기화 기본 도구들 역시 일반적으로 비싼 file I/O 를 포함합니다.
\item 스크립트 언어들은 많은 경우 너무 느립니다만, 더 낮은 단계의 프로그래밍 언어로 쓰여진, 오랫동안 수행되는 프로그램의 수행을 조정할 때에는 많은 경우 상당히 유용합니다.
\iffalse
\item Creation of new processes is usually quite heavyweight,
involving the expensive \co{fork()} and \co{exec()}
system calls.
\item Sharing of data, including pipelining, typically involves
expensive file I/O.
\item The reliable synchronization primitives available to
scripts also typically involve expensive file I/O.
\item Scripting languages are often too slow, but are often
quite useful when coordinating execution of long-running
programs written in lower-level programming languages.
\fi
\end{enumerate}
\iffalse

이런 제한점들은 스크립트 기반 병렬성이 coarse-grained 병렬성을 사용하는 편이 훨씬 쉽습니다. 리눅스 커널 내에서 실행되는 모든 태그 일의 단위들은 최소 수십 밀리세컨드, 그리고 가능하다면 그보다도 훨씬 긴 시간을 가질 것을 요구합니다.
\iffalse
These limitations require that script-based parallelism use
coarse-grained parallelism, with each unit of work having
execution time of at least tens of milliseconds, and preferably
much longer.
\fi
\fi

finer-grained 병렬성을 필요로 하는 작업들은 그 작업의 문제가 coarse-grained 형태로 표현될 수는 없을지 좀 고민해 보도록 추천됩니다.
만약 불가능하다면, Section-\ref{sec:toolsoftrade:POSIX Multiprocessing}에서 다른 것과 같은 다른 병렬 프로그래밍 환경을 고려해 봐야 합니다.
\iffalse
Those requiring finer-grained parallelism are well advised to
think hard about their problem to see if it can be expressed
in a coarse-grained form.
If not, they should consider using other parallel-programming
environments, such as those discussed in
Section-\ref{sec:toolsoftrade:POSIX Multiprocessing}.
\fi
\QuickE{}
\QuickQ{}

```

비슷하게 `__sync_fetch_and_add()`, `__sync_fetch_and_sub()`, 그리고 `__sync_fetch_and_xor()` 를 그들의 나중값 리턴하는 대응 함수들을 대한 대보가 이용해 구현하는 것도 가능합니다.

하지만, 이를 대신해주는 기능이 있는 게 프로그래머에게도 컴파일러/라이브러리를 구현하는 사람에게도 편리할 것입니다. ■

Quick Quiz 4.4:

이 어토믹 오퍼레이션들이 인스트럭션 집합에서 곧바로 지원하는 인스트럭션들을 만들어낼 수 있다면, 그게 바로 동작하는 가장 빠른 방법 아닐까요? ■

Answer:

불행히도, 아닙니다. 극명한 반례를 위해 Chapter 5 을 참고하시기 바랍니다. ■

Quick Quiz 4.5:

ACCESS_ONCE() 에 무슨 일이 벌어진거죠? ■

Answer:

2018년 초 기준으로, 리눅스 커널의 ACCESS_ONCE() 는 읽기와 쓰기를 위한 목적으로 각각 READ_ONCE() 와 WRITE_ONCE() 로 교체되었습니다 [Cor12a, Cor14a, Rut17]. ACCESS_ONCE() 는 RCU 코드에 도움을 주는 역할로 소개되었지만, 그후에 core API 로 격상되었습니다 [McK07b, Tor08]. 리눅스 커널의 READ_ONCE() 와 WRITE_ONCE() 는 커다란 구조체에 access-once 의미를 제공하면서도 이 구조체가 하나의 기계 인스트럭션으로 로드되고 스托어 될 수 없을 경우에는 load-store tearing 이 일어날 수 있게 하기 위해 원래의 ACCESS_ONCE() 와는 상당히 다르게 보이는 복잡한 형태로 진화했습니다. ■

Quick Quiz 4.6:

리눅스 커널의 fork() 와 wait() 대체물은 어디갔죠? ■

Answer:

리눅스 커널 내에서 실행되는 모든 태그들은 메모리를 공유합니다. 당신이 거대한 메모리 매핑을 손으로 일일히 할 생각이 아니라면 말이죠. ■

Quick Quiz 4.7:

변수 counter 의 값이 mutex 의 보호 없이 증가된다면 어떤 문제가 있을 수 있나요? ■

Answer:

만약 불가능하다면, Section-\ref{sec:toolsoftrade:POSIX Multiprocessing}에서 다른 것과 같은 다른 병렬 프로그래밍 환경을 고려해 봐야 합니다. Load-store 아키텍처의 CPU 들에서라면, counter 의 값 증가 연산은 다음과 같은 형태로 컴파일 될 수 있습니다:

```

Those requiring finer-grained parallelism are well advised to
think hard about their problem to see if it can be expressed
in a coarse-grained form.
If not, they should consider using other parallel-programming
environments, such as those discussed in
Section-\ref{sec:toolsoftrade:POSIX Multiprocessing}.
\fi
\QuickE{}
\QuickQ{}

```

```
LOAD counter,r0
INC r0
STORE r0,counter
```

그런 기계에서라면, 두개의 쓰레드가 동시에 `counter`의 값을 읽어오고, 각자 그 값을 증가시킨 후, 각각 그 결과를 저장할 수 있습니다. 그렇게 되면 `counter`의 새로운 값은 두개의 쓰레드가 각각 그 값을 증가시켰음에도 기존에 비해 1만큼만 클 것입니다. □

Quick Quiz 4.8:

`Listing 4.14`의 `global_ptr`를 최대 세번까지 로드하게 된게 뭐가 문제죠? ■

Answer:

`global_ptr`이 최초에는 `NULL`이 아니었지만, 어떤 다른 쓰레드가 `global_ptr`를 `NULL`로 바꾼다고 생각해 보세요. 더 나아가서 변경된 코드 (`Listing 4.15`)의 라인 1이 `global_ptr`이 `NULL`로 쓰여지기 직전에 쓰여지고 이어서 라인 2가 수행된다고 생각해 보세요. 라인 1은 `global_ptr`가 `NULL`이 아니라고 생각하고, 라인 2는 그 값이 `high_address` 보다 작다고 결론내릴 겁니다. 따라서 라인 3은 `do_low()`에 `NULL` 포인터를 넘길텐데, 이 인자는 `do_low()`가 처리할 준비가 되지 않은 값입니다. □

Quick Quiz 4.9:

`Listing ??`의 `do_something()`과 `do_something_else()`가 인라인 함수인게 왜 문제되죠? ■

Answer:

`gp`는 `static` 변수가 아니므로, `do_something()`이나 `do_something_else()`가 별도로 컴파일 되었다면, 컴파일러는 이 두 함수가 `gp`의 값을 바꿀 수 있다고 가정하게 됩니다. 이 가능성은 컴파일러가 라인 `??`에서 `gp`를 다시 읽어오는 걸 방지해서, `NULL` 포인터 디레퍼런스 문제를 막을 겁니다. □

Quick Quiz 4.10:

하지만 전체 메모리 배리어를 너무 무겁지 않나요? `Listing 4.25`의 순서 규칙을 강제하는데에 더 비용이 적은 방법도 있지 않아요? ■

Answer:

대부분의 경우 그렇듯이, 답은 “상황에 종속적이다”입니다. 하지만, 두개의 쓰레드만이 `status`와 `other_task_ready`를 접근하고 있는 상황이라면, `Section 4.3.5`의 `smp_store_release()`와 `smp_load_acquire()` 함수들만으로도 충분할 겁니다. □

Quick Quiz 4.11:

특정 인터럽트나 시그널 핸들러가 그 스스로 인터럽트 되면 어떻게 되나요? ■

Answer:

그렇다면 그 인터럽트 가능한 핸들러는 인터럽트를 처리하는 핸들러가 접근할 수 있는 모든 변수로의 접근에 `READ_ONCE()`와 `WRITE_ONCE()` 또는 그보다 강한 것을 사용해야 합니다. 그 스스로는 인터럽트 당할 수 없거나 인터럽트 하는 핸들러와 어떤 변수도 공유하지 않는 코드만이 평범한 액세스를 사용할 수 있고, 그렇다 하더라도 다른 CPU 또는 스레드에서 동시에 그 변수들을 접근하지 않아야 합니다. □

Quick Quiz 4.12:

Per-thread-variable API를 제공하지 않는 시스템에서는 어떻게 이를 우회할 수 있을까요? ■

Answer:

한가지 방법은 `smp_thread_id()`로 인덱스 되는 배열을 생성하는 방법이 있겠고, 또 다른 방법은 `smp_thread_id()`를 배열 인덱스로 매핑하는 해시 테이블을 사용하는 방법이 있겠습니다—이 API들이 `pthread` 환경에서 실제로 동작하는 방법입니다.

또 다른 방법은 부모가 각각의 per-thread 변수를 담는 필드로 구성된 구조체를 할당하고, 이를 쓰레드 생성 시에 자식 쓰레드에게 넘겨주는 방법입니다. 하지만, 이 방법은 커다란 시스템에서는 큰 소프트웨어 엔지니어링 비용을 야기할 수 있습니다. 이를 자세히 알아보기 위해선, 커다란 시스템의 모든 전역 변수들이, 그것들이 `C static` 변수들인지 아닌지에 관계없이 하나의 파일에 선언되어야 하는 경우를 떠올려보세요! □

Quick Quiz 4.13:

셸은 기본적으로 `fork()`가 아니라 `vfork()`를 사용하지 않나요? ■

Answer:

아마 그럴겁니다만, 확인해보는건 독자의 몫으로 두겠습니다. 다만, `vfork()`는 `fork()`의 변종일 뿐이고, 따라서 둘 다를 이야기하는 일반적 용어로 `fork()`를 사용해도 된다는데 우리가 합의했으면 합니다. □

G.5 Counting

Quick Quiz 5.1:

대체 왜 효과적이고 확장성 있는 카운팅이 어려운가요?
무엇보다, 컴퓨터들은 카운팅, 더하기, 빼기, 그 외에도 여러가지를 위한 전용 하드웨어도 가지고 있는데, 그걸 못하나요??? ■

Answer:

예컨대 공유된 카운터에 대한 어토믹 오퍼레이션과 같은 기본적인 카운팅 알고리즘들은 Section 5.1에서 이야기하듯 느리고 확장성이 나쁘거나 정확도가 떨어지기 때문입니다. ■

Quick Quiz 5.2:

네트워크 패킷 카운팅 문제. 당신이 송수신된 네트워크 패킷의 갯수에 대한 통계를 구해야 한다고 생각해 봅시다. 패킷들은 시스템의 어떤 CPU를 통해서든 송신/수신될 수 있을 겁니다. 더 나아가서 이 시스템이 CPU 당 초당 백만개의 패킷을 다룰 수 있고, 그 갯수를 매 5초마다 읽어내야 하는 시스템 모니터링 패키지가 있다고 가정해 봅시다. 당신이라면 이 통계 카운터를 어떻게 구현하시겠어요? ■

Answer:

힌트: 카운터의 업데이트는 엄청 빨라야 합니다만, 카운터는 500만번의 업데이트마다 한번만 읽히기 때문에, 카운터를 읽어내는 행동은 꽤 느려도 될 겁니다. 또한, 일반적으로 읽어지는 값은 완전히 정교하진 않아도 될 겁니다—어쨌든, 카운터는 1밀리세컨드당 1000번 업데이트되기 때문에, 우린 “진짜 값”에서 수천정도는 오차값을 가질 수밖에 없을 겁니다. “진짜 값”이란게 이 문맥에서 뭘 의미하던지요. 하지만, 읽혀지는 값은 어느정도는 절대적인 오차를 유지해야 할겁니다. 예를 들어, 카운트가 수백만 정도일 때 1% 오차는 문제없지만, 조단위가 된다면 문제가 있겠죠. Section 5.2를 참고하세요. ■

Quick Quiz 5.3:

대략적 구조체 할당 한계 문제. 할당된 구조체의 갯수가 어떤 한계(한 10,000 정도)를 넘어가면 추가 할당을 막기 위해 할당된 구조체의 갯수를 유지해야 한다고 생각해 봅시다. 또, 이 구조체들은 할당되고 나서 곧바로 해제되고, 한계치를 넘기는 일은 매우 드물고, “대략적인” 한계치 설정이 가능하다고 생각해 봅시다. ■

Answer:

힌트: 카운터의 업데이트 동작은 여기서도 매우 빨라야 합니다만, 카운터는 값이 증가될 때마다 읽혀야 합니다.

하지만, 읽혀지는 값은 그 값이 한계치 아래인지 위인지 를 대략적으로는 구분해 내야 한다는 점을 제외하고는 정교하지 않아도 됩니다. ■

Quick Quiz 5.4:

정교한 구조체 할당 한계 문제. 할당된 구조체의 갯수가 어떤 정확한 한계(여기서도, 한 10,000 정도)를 넘어가면 추가 할당을 막기 위해 할당된 구조체의 갯수를 유지해야 한다고 생각해 봅시다. 이 구조체들은 할당되고 얼마 안되 해제되고, 그 한계는 드물게 초과되며, 거의 항상 최소 한개의 구조체는 사용중이 됩니다. 또한 예를 들어, 하나의 구조체도 사용되지 않고 있다면 해제 할 수 있는 어떤 메모리를 위해 카운터가 0이 되는 시점을 정확히 알 필요가 있습니다. ■

Answer:

힌트: 카운터의 업데이트 동작은 역시 엄청 빨라야 합니다만, 카운터의 값이 증가될 때마다 그 값 역시 읽혀야 합니다. 하지만, 그 값은 한계치 경계를 넘어서는지와 0인지를 분명하게 체크해야 한다는 점을 제외하고는 정교할 필요가 없습니다. Section 5.4를 참고하세요. ■

Quick Quiz 5.5:

제거될 수 있는 I/O 디바이스 접속 카운트 문제. 매우 빈번하게 사용되는 제거 가능한 대용량 디바이스에 대해 사용자에게 해당 디바이스를 제거해도 안전한지 알려주기 위해 그 참조 횟수를 관리해야 한다고 가정해 봅시다. 사용자는 디바이스를 제거하고 싶을 때 그 의사를 알려주며, 시스템은 사용자에게 언제 디바이스를 제거해도 안전한지 알려주는 일반적 디바이스 제거 절차를 따릅니다. ■

Answer:

힌트: 여기서도 카운터의 업데이트 동작은 I/O 오퍼레이션이 느려지지 않게 매우 빠르고 확장성 있어야 합니다. 하지만 카운터는 사용자가 디바이스를 제거하고자 할 때에만 읽혀지기 때문에, 카운터의 읽기 동작은 매우 느려도 됩니다. 또한, 사용자가 디바이스를 제거하고자 하는 의사를 밝히지 않았다면 그 카운터는 읽혀질 필요가 아예 없습니다. 또한, 그 값은 디바이스가 제거를 위한 절차 중일 때로 한정해서 0인지 0이 아닌지만 분명히 구분할 수 있어야 한다는 점을 제외하고는 정교할 필요가 없습니다. 하지만, 한번 0이라는 값을 읽었다면, 차후에 다른 쓰레드가 제거중인 해당 디바이스에 접근을 하거나 하는 일을 막기 위해 해당 값을 0으로 유지해야 합니다. Section 5.4.6를 참고하세요. ■

Quick Quiz 5.6:

하지만 영리한 컴파일러는 Listing 5.1의 라인 5 이 ++

연산자와 동일함을 증명하고 x86 add-to-memory 인스터러션을 만들어 낼 수 있지 않나요? ■

Answer:

++ 연산자는 어토믹할 수도 있지만, 그래야만 한다는 규칙은 없습니다. 그리고 실제로, GCC는 값을 레지스터에 읽어오고, 레지스터의 값을 증가시킨 후, 메모리에 그 값을 저장하는, 분명 어토믹하지 않은 방법을 종종 택합니다.

더 나아가서, READ_ONCE() 와 WRITE_ONCE() 안의 volatile 캐스팅을 알아두시기 바라는데, 이는 해당 위치가 MMIO 장치 레지스터로도 사용될 수 있음을 컴파일러에게 이야기 합니다. MMIO 레지스터는 캐시되지 않기 때문에, 증가 연산자가 실제로 어토믹할 거라 컴파일러가 생각하는건 현명하지 못한 일일 겁니다. □

Quick Quiz 5.7:

실패 횟수의 8-figure 정확도는 당신이 진짜로 이 테스트를 한 것을 보여주는군요. 왜 이런 사소한 프로그램을, 특히나 버그가 이렇게 쉽게 직관적으로 보이는데도 굳이 테스트 해야 하나요? ■

Answer:

사소한 병렬 프로그램 일부만이 아니라, 순차적 프로그램에도 마찬가지라고 저는 생각합니다.

프로그램이 얼마나 작거나 간단한지와는 상관 없이, 여러분이 테스트 해보지 않았다면, 그건 동작하지 않는 것입니다. 그리고 설령 테스트 해봤다 해도, 머피의 법칙에 의하면 여전히 숨어있는 버그가 몇개는 있을 수 있을 수 있습니다.

또한, 정확성의 증명은 분명 그 의미를 갖지만, 여기 사용된 counttorture.h 테스트를 포함해 테스트를 대체하는 일은 결코 없을 겁니다. 무엇보다, 증명은 그것이 바닥에 깔고 있는 가정에 국한됩니다. 게다가, 증명은 프로그램만큼이나 버그를 가지고 있기 쉽습니다! □

Quick Quiz 5.8:

왜 x 축의 점선은 $x = 1$ 에서 대각선의 선과 만나지 않죠? ■

Answer:

어토믹 오퍼레이션의 오버헤드 때문입니다. x 축의 점선은 어토믹하지 않은 증가 연산의 싱글쓰레드 수행에서의 오버헤드를 나타냅니다. 이상적인 알고리즘은 선형적으로 확장될 뿐만 아니라, 싱글 쓰레드 코드에 비해서도 성능 하락이 없어야 할 것입니다.

이런 수준의 이상론은 좀 지나쳐 보일 수 있습니다. 다만 리눅스 토발즈에게 충분하다면, 당신에게도 충분할 겁니다. □

Quick Quiz 5.9:

하지만 어토믹 증가 연산은 여전히 꽤 빠릅니다. 그리고 빠빠한 루프에서 하나의 변수를 증가시키는 건 제겐 꽤 비현실적인 것 같아 보이구요, 무엇보다, 프로그램의 실행은 실제로 일을 하는데 쓰여야지, 자기가 한 일을 세는데 쓰여야 하는게 아니라구요! 왜 제가 이걸 빠르게 하는 걸 고민해야 하나요? ■

Answer:

많은 경우에 어토믹 증가 연산은 분명히 당신에겐 충분히 빠를 겁니다. 그런 경우에 당신은 당연히 어토믹 증가 연산을 사용해야죠. 그렇지만, 더 나은 카운팅 알고리즘이 필요한 실제 상황도 상당히 많이 존재합니다. 그런 상황의 예는 고도로 최적화된 네트워킹 스택에서의 패킷과 용량 카운팅으로, 이런 예에서는, 특히나 커다란 멀티프로세서에서는 대부분의 실행시간을 이런류의 카운팅 작업에 보내게 됩니다.

게다가, 이 챕터의 시작에서 이야기했듯, 카운팅은 공유 메모리 병렬 프로그램에서 마주칠 수 있는 문제들을 보여줍니다. □

Quick Quiz 5.10:

그런데 왜 CPU 설계자들은 단순히 데이터에의 증가 연산을 추가함으로써 데이터를 담고 있는 캐시 라인의 순환이 증가하는 걸 막지 못한 거죠? ■

Answer:

어떤 경우에는 그런 방법도 가능하겠죠. 하지만, 그러면 좀 복잡합니다:

1. 만약 어떤 변수의 값이 필요하다면, 값을 필요로 하는 쓰레드는 해당 오퍼레이션이 그 데이터로 향할 때까지 기다리고, 그리고나선 돌아오기까지 기다려야 합니다.
2. 그 어토믹 증가 오퍼레이션이 이전의, 그리고 이후의 오퍼레이션들과 순서를 맞춰야 한다면, 해당 쓰레드는 오퍼레이션이 데이터까지 가고, 돌아올 준비가 완료될 때까지 기다려야 합니다.
3. 오퍼레이션들을 CPU들 사이에서 보내게 되면 시스템 접속부를 지나야 하고, 이는 더 많은 다이 공간과 전력을 소모하게 될 겁니다.

하지만 앞의 두가지 조건이 없다면? 그럼 여러분은 Section 5.2에서 논의되는, 실제 상용화된 하드웨어에서 이상적 상황에 근접하는 성능을 보이는 알고리즘을 잘 고려해 봐야 할 겁니다.

앞의 두개 조건이 모두, 또는 하나라도 걸려 있다면, 개선된 하드웨어에 약간의 희망이 있습니다. 캠바이닝 트리(combining tree)를 하드웨어에서 구현해서, 여러




Figure G.1: Data Flow For Global Combining-Tree Atomic Increment

CPU에서의 증가 요청이 하드웨어에 의해 결합되어 하나의 더하기 연산으로 변환되는 방법을 생각해 볼 수 있을 것입니다. 해당 하드웨어는 또한 요청들에 순서를 잡아줄 수도 있으므로, 각 CPU에게 각자의 어토믹 증가에 의한 값의 반환도 가능할 겁니다. Figure G.1에서 보여지듯, 이는 인스트럭션의 대기시간을 $O(\log N)$ 로 만들어 줍니다. 여기서 N 은 CPU의 갯수입니다. 그리고 이런 하드웨어 최적화를 포함하는 CPU는 2011년부터 나오기 시작했습니다.

Figure 5.2에 보여진 현재 하드웨어의 $O(N)$ 성능에 비하면 엄청난 향상이고, 3차원 제조 공정이 현실화되면 하드웨어 응답시간은 더욱 낮아질 수 있을 겁니다. 물론, 일부 중요한 특수 케이스에서는 소프트웨어가 훨씬 나은 일을 할 수 있을 것입니다. □

Quick Quiz 5.11:

하지만 C의 “정수들”의 제한된 크기가 일을 복잡하게 만들지는 않나요? ■

Answer:

아닙니다, 모듈로 더하기도 역시 상호성과 결합성을 가지니까요. 부호 없는 정수형을 사용한다면 말입니다. 오버플로우가 났을 때 넘쳐난 값을 감추는 것 외에 별다른 일을 하는 기계들은 요즘 거의 없지만, C 표준에 의하면 부호를 갖는 정수형의 오버플로우는 예상외 동작을 유발할 수 있으므로, 요즘 기계들은 대부분 안전하다는 사실은 무시하십시오. 불행히도, 컴파일러들은 종종 부호 있는 정수형들은 오버플로우 나지 않을 것이라는 가정 하에 최적화를 하기 때문에, 당신의 코드가 부호 있는 정수형을 오버플로우 나게 한다면, 2의 보수를 사용하는 하드웨어를 사용하고 있다 해도 문제에 직면할 수 있습니다.

그렇다면 해도, 32-비트 쓰레드별 카운터에서 (대략) 64-비트 합을 모으는데에도 추가적인 복잡한 일이 숨어 있습니다. 이걸 처리하는 것은 독자 여러분의 연습문제로 남겨두겠습니다만, 이 챕터의 뒤에 소개될 기법들이 큰 도움이 될 수도 있습니다. □

Quick Quiz 5.12:

배열이요??? 하지만 그럼 쓰레드의 갯수가 제한되지 않나요? ■

Answer:

그럴 수 있고, 이 간단한 구현에서는 그렇습니다. 하지만 임의의 갯수의 쓰레드를 지원하는 구현을 만드는 건 그렇게 어렵지 않은데, 예를 들면, Section 5.2.4 GCC의 `_thread`를 사용하는 거죠. □

Quick Quiz 5.13:

이거 말고도 GCC가 할 수 있는 이상한 최적화는 어떤게 있나요? ■

Answer:

C 표준에 따르면, 다른 쓰레드에 의해 동시에 읽혀질 수 있는 변수에 평범하게 쓰기를 하는 행동이 일으킬 효과는 정의되어 있지 않습니다. C는 어토믹하게 `long`을 읽어들일 수가 없는 (예를 들어) 8비트 아키텍쳐를 지원해야만 했기에, C 표준은 그럴 수밖에 없었습니다. C 표준의 최신 버전은 이 간극을 채우기 위한 어토믹 기능들을 도입했습니다. 하지만 이걸 리눅스 커널에 적용하려던 시도는 엉갈린 결과를 가져왔는데 [Cor16], 어토믹 기능을 위해 컴파일러가 만들어내는 코드의 품질이 나빴던 게 한 이유였습니다. 또한, 리눅스 커널은 C11 어토믹 기능이 제공하는 것보다 더 많은 기능을 자신의 메모리 모델에 바라고 있는데, 컨트롤 의존성, 완전한 배리어/펜스, 낮은 비용의 주소/데이터 의존성 [MWP18b]이 여기에 포함됩니다.

언젠가는 C11 어토믹 기능이 이 간극을 메우겠지만, 그 때가 오기 전까지 리눅스 커널은 `volatile` 접근, `inline` 어셈블리, 컴파일러 지시어, 그리고 코딩 표준의 조합을 사용해 공유 변수들에 안전한 접근을 할 겁니다. 이 방법은 리눅스 커널이 훌륭한 성능을 유지하고 C11 어토믹 기능을 지원하지 않는 오래된 컴파일러도 사용할 수 있게 해줍니다만, 리눅스 커널을 새로운 CPU 아키텍쳐로 포팅하려 할 때 노력을 필요로하게 합니다. 그러나, C11 어토믹 기능이 바로 사용된다고 해도 컨텍스트 스위치, 인터럽트, 익셉션, MMU, 전력 효율을 위한 전력 관리, 그 외에도 여러가지를 다루기 위해 상당한 노력이 필요할 겁니다. 따라서 리눅스 커널의 C11 어토믹 기능 적용은 점진적인 쪼步骤입니다.

그러니 평범한 기존의 C-언어 할당문을 사용해 공유 변수에 접근하는게 어떻습니까? 문제는 컴파일러가

다른 쓰레드가 해당 변수에 접근하고 있지 않을 거라고 가정해도 될 권리를 가지고 있다는 겁니다. 따라서, 컴파일러는 평범한 기존의 C-언어 로드 명령을 가지고 한번에 한 바이트씩 읽기를 하거나 (“로드 티어링”), 읽기 동작을 반복하거나(레지스터가 부족할 때 많이 사용되는 방법입니다), 같은 변수로부터의 연속적 로드를 합쳐버릴 수 있습니다. 이런 동작들 각각은 싱글 쓰레드 알고리즘의 정확성을 지키겠지만, 이것들 모두 동시성 있는 알고리즘의 정확성을 쉽게 망가트릴 수 있습니다. 공유 메모리 동시성의 주요한 주의사항은 그런 충돌하는 접근들을 지원하기 위한 것으로, 다른 쓰레드에 의해 동시에 업데이트 될 수 있는 변수들을 평범한 C-언어 로드와 스토어를 사용해 접근하는 것은 매우 현명치 못한 것입니다. 더 나아가서, 현재의 C11 어토믹 기능들은 (여전히?) 리눅스 커널에 적절치 않으므로, 뭔가 다른게 필요합니다.

한가지 접근법은 락킹과 같은 블록킹 동기화 기능(Chapter 7 를 참고하세요)을 사용해서 동시의 업데이트를 막는 겁니다. 대안적으로, 하드웨어가 하나의 메모리 레퍼런스 명령어로 그 값을 접근할 수 있는 경우라면 `READ_ONCE()` 와 `WRITE_ONCE()` 로 제공되는 `volatile` 접근이³ 사용될 수 있습니다. 하지만, `volatile` 액세스는 그것 자체만으로는 고성능과 안정성 있는 동기화 메커니즘에 충분치 않습니다. 따라서 리눅스 커널은 `volatile` 액세스를 앞서 언급된 `inline` 어셈블리, 컴파일러 지시어, 그리고 코딩 표준과 조합해 사용하고 있습니다. □

Quick Quiz 5.14:

`Listing 5.3` 의 쓰레드별 `counter` 변수는 어떻게 초기화되나요? ■

Answer:

C 표준은 전역 변수의 초기값은 명시적으로 초기화되지 않는 이상 0이라고 명시합니다. 따라서 `counter`의 모든 인스턴스의 초기값은 0이 될 겁니다. 그리고, 사용자가 통계적 카운터들의 연속적으로 읽어들이는 값 사이의 차이에만 관심있는 일반적인 경우에는 초기값은 의미가 없습니다. □

Quick Quiz 5.15:

`Listing 5.3` 의 코드가 어떻게 복수의 카운터를 가능하게 할 수 있죠? ■

Answer:

실제로, 이 예제는 한개 이상의 카운터는 지원하지 않습니다. 이 예제를 수정해서 복수의 카운터를 제공하게 하는건 독자 여러분에게 과제로 남겨 두겠습니다. □

³ `READ_ONCE()` 와 `WRITE_ONCE()` 에 대한 간단한 정의가 `Listing 4.9` 에 보여져 있습니다.

Quick Quiz 5.16:

읽기 오퍼레이션은 쓰레드별 값은 모두 더하는 시간을 가져야 할 것이고, 그동안에도 카운터는 값이 변할 수 있어요. 이는, `Listing 5.3` 의 `read_count()` 는 정확하지 않다는 것을 의미합니다. 이 카운터는 단위시간당 r 만큼 값이 증가되고 `read_count()` 는 Δ 단위시간을 소모한다고 해봅시다. 반환되는 값의 예상 오류값은 얼마입니까? ■

Answer:

최악의 경우에 대한 분석부터 해보고, 좀 나은 경우들을 보죠.

최악의 경우는, 읽기 오퍼레이션이 실제 동작은 금방 끝냈지만 리턴하기 전에 Δ 단위시간동안 대기를 하는 경우로, 이 경우의 오류값은 간단히 $r\Delta$ 입니다.

이 최악의 경우 동작은 별로 현실성이 없으니 각 N 카운터들에 대한 각 읽기 동작이 시간 간격 Δ 안에 동일한 간격으로 일어나는 경우를 생각해보죠. N 회의 읽기 사이에 $\frac{\Delta}{N+1}$ 길이의 $N+1$ 개 간격이 존재할 겁니다. 마지막 쓰레드의 카운터에서의 읽기 이후로의 지연으로 발생하는 에러치는 $\frac{r\Delta}{N(N+1)}$ 이므로, 두번째에서 마지막 쓰레드 사이의 카운터는 $\frac{2r\Delta}{N(N+1)}$, 세번째에서 마지막 사이는 $\frac{3r\Delta}{N(N+1)}$, 그리고 그렇게 계속 진행됩니다. 전체 오류값은 각 쓰레드의 카운터에서의 읽기로 발생한 에러의 총 합으로 주어지는데, 다음과 같습니다:

$$\frac{r\Delta}{N(N+1)} \sum_{i=1}^N i \quad (G.1)$$

합 부분은 다음과 같이 표현 가능하구요:

$$\frac{r\Delta}{N(N+1)} \frac{N(N+1)}{2} \quad (G.2)$$

불필요한 부분을 제거하면 다음과 같이 직관적인 결과가 나옵니다:

$$\frac{r\Delta}{2} \quad (G.3)$$

읽기 오퍼레이션 호출자가 해당 오퍼레이션으로 리턴받은 수를 가지고 어떤 일을 하는 코드를 수행하는 중에도 오류는 쌓여감을 기억해둘 필요가 있습니다. 예를 들어, 읽기 오퍼레이션 호출자가 리턴받은 값을 가지고 어떤 계산을 하는데 t 시간을 사용한다면, 최악의 경우 오류치는 $r(\Delta + t)$ 로 늘어날 겁니다.

예상 오류치도 비슷하게 늘어나겠죠:

$$r \left(\frac{\Delta}{2} + t \right) \quad (G.4)$$

물론, 읽기 중에 카운터가 계속 증가하는건 용납될 수 없는 경우도 있겠습니다. Section 5.4.6 에서는 이런 상황을 해결하는 방법을 알아봅니다.

이렇게, 우리는 감소는 없고 증가만 이루어지는 카운터를 알아보았습니다. 만약 카운터 값이 단위시간당 r 만큼 감소되든 증가되든 바뀐다면, 오류값은 줄어들 거라고 예상할 수 있을 겁니다. 하지만, 카운터가 어느 쪽으로든 움직일 수 있을지 몰라도 최악의 경우는 해당 읽기 오퍼레이션이 금방 끝났지만 Δ 단위 시간동안 기다려야 하는데, 그 시간 동안 카운터의 값은 같은 방향으로만 이동하는 경우이므로 여전히 $r\Delta$ 오류값을 내므로 차이가 없습니다.

평균 에러치를 계산하는데는 값의 증감 패턴에 대한 다양한 가정을 바탕으로 하는 여러가지 방법이 있습니다. 일단은 간단하게, 오퍼레이션들 중 f 만큼이 감소 오퍼레이션이고, 관심있는 오류값은 카운터의 장시간 추세선에서의 굴곡이라고 가정해 봅시다. 이 가정 하에서는 f 가 0.5 이하라면, 각 감소는 증가에 의해 무효화되고, 따라서 $2f$ 오퍼레이션은 서로를 무효화시키고, $1-2f$ 의 오퍼레이션들은 무효화되지 않은 증가가 됩니다. 반면, f 가 0.5 보다 크다면, $1-f$ 의 감소는 증가에 의해 무효화되고, 카운터는 음의 방향으로 $-1+2(1-f)$ 만큼 이동하는데, 이는 $1-2f$ 로 정리되고, 따라서 카운터는 평균적으로 오퍼레이션당 $1-2f$ 만큼씩 어느 경우든 이동하게 됩니다. 따라서, 긴 시점에서의 카운터의 변화는 $(1-2f)r$ 로 주어집니다. 이걸 Equation G.3에 대입하면:

$$\frac{(1-2f)r\Delta}{2} \quad (G.5)$$

그렇지만, 대부분의 통계적 카운터 사용에서 `read_count()` 에 의해 리턴되는 값의 오류치는 별 의미가 없습니다. `read_count()` 가 수행하는데 필요한 시간은 일반적으로 `read_count()` 호출 사이의 시간에 비하면 극단적으로 작기 때문입니다. □

Quick Quiz 5.17:

Listing 5.4 의 `inc_count()` 는 왜 어토믹 명령을 사용하지 않죠? 쓰레드별 카운터를 여러 쓰레드에서 접근하고 있잖아요! ■

Answer:

두 쓰레드 중 하나는 읽기만 하고 있고, 변수는 정렬되어 있으며 기계가 지원하는 워드 크기이기에, 어토믹하지 않은 명령들만으로도 충분합니다. 다만, 카운터 업데이트가 `eventual()` 에게 보여지지 않게 할 수도 있는 컴파일러 최적화를 막기 위해 `READ_ONCE()` 매크로가 사용되었습니다.⁴

⁴ `READ_ONCE()` 의 간단한 정의가 Listing 4.9 에 표시되어 있습니다.

이 알고리즘의 예전 버전은 실제로 어토믹 명령을 사용했었습니다만, 감사하게도 Ersoy Bayramoglu 가 그것들이 필요 없다는 것을 지적해 줬습니다. 그렇다면 하나, 쓰레드별 `counter` 변수가 `global_counter` 보다 작았다면 어토믹 명령이 필요했을 겁니다. 하지만, 32-bit 시스템에서 쓰레드별 `counter` 변수는 정확하게 합을 구하기 위해 32 비트로 제한되어야 하고 오버플로를 막기 위해 `global_count` 변수는 64-bit 이 되어야 할 겁니다. 이 경우엔, 오버플로를 막기 위해 쓰레드별 `counter` 변수를 주기적으로 0으로 초기화 시켜줘야 할 겁니다. 0으로의 주기적 초기화가 너무 오래 지연되면 쓰레드별 변수의 오버플로가 가능하단 것을 반드시 기억해 둬야만 합니다. 따라서 이 방법은 프로그램이 돌아가는 시스템이 리얼-타임 속성을 가지고 있어야 하며, 매우 조심스럽게 사용되어야 함을 의미합니다.

대조적으로, 모든 변수가 같은 크기이면 어떤 변수에 오버플로가 나더라도 최종적 합은 워드 크기로 절삭될테니 별 문제 없습니다. □

Quick Quiz 5.18:

Listing 5.4 의 단일 글로벌 쓰레드인 `eventual()` 함수는 글로벌 락처럼 큰 병목이 되거나 하진 않나요? ■

Answer:

이 경우엔, 아닙니다. 그 대신 쓰레드의 갯수가 늘어나면 `read_count()` 에 리턴되는 카운터 값이 더 부정확해질 겁니다. □

Quick Quiz 5.19:

Listing 5.4 의 `read_count()` 에서 리턴하는 추정값은 쓰레드의 갯수가 늘어날수록 부정확해져 가지 않을까요? ■

Answer:

맞습니다. 이게 문제가 된다면, 여러 `eventual()` 쓰레드를 만들고, 각 쓰레드가 일을 나눠서 해야 하는게 한가지 해결책이 될 수 있습니다. 더 극단적인 경우에는, `tree` 같은 구조의 `eventual()` 쓰레드 계층 관리가 필요할 수도 있습니다. □

Quick Quiz 5.20:

Listing 5.4 의 최종적 일관성 알고리즘은 읽기에도 쓰기에도 매우 적은 오버헤드와 극단적인 확장성을 보이는데, 과연 누가 Section 5.2.2 같이 읽기 쪽이 비싼 구현을 사용하겠습니까? ■

Answer:

`eventual()` 쓰레드를 돌리는 것은 CPU 시간을 소모합니다. 이런 최종적으로 일관적인 카운터의 갯수가 늘어나면 언젠가는 `eventual()` 쓰레드들이 모든 CPU 를 차지할 겁니다. 따라서 이 구현은 쓰레드나 CPU 의

갯수가 아니라 최종적으로 일관적인 카운터의 갯수에 확장성이 제한되는, 또 다른 종류의 확장성 한계 문제를 갖습니다.

물론, 다른 트레이드오프를 갖는 것도 가능합니다. 예를 들어, 하나의 싱글쓰레드가 모든 최종적으로 일관적인 카운터들을 처리하도록 만들어질 수도 있는데, 이는 오버헤드를 하나의 CPU로 제한시킵니다만, 카운터들의 수가 늘어남에 따라 update-to-read 대기시간을 증가시키는 결과를 초래할 겁니다. 대안으로, 해당 싱글 쓰레드는 자주 업데이트 되는 카운터들을 더 자주 방문하는 식으로 카운터들의 업데이트 비율을 추적할 수 있습니다. 또한, 카운터들을 쥐고 있는 쓰레드들의 수는 전체 CPU 갯수의 일부로 설정될 수도 있으며, 이는 실행시간 도중에 정해질 수도 있습니다. 마지막으로, 각 카운터는 자신의 대기시간을 명시할 수 있고, 각 카운터에 요구된 대기시간을 지켜주기 위해 deadline-scheduling 테크닉이 사용될 수도 있습니다.

이외에도 얼마든지 더 많은 트레이드오프를 만들 수 있음이 분명합니다. □

Quick Quiz 5.21:

다른 쓰레드의 카운터를 찾는데 왜 별개의 배열이 필요하죠? 왜 GCC는 리눅스 커널이 `per_cpu()`를 통해 쓰레드들이 다른 쓰레드의 쓰레드별 변수를 쉽게 접근할 수 있도록 하는 것처럼 `per_thread()` 같은 인터페이스를 제공하지 않나요? ■

Answer:

정말 왜일까요?

공정을 기하기 위해 말해두건대, 리눅스 커널은 무시할 수 있는 몇 가지 문제들이 GCC에는 존재합니다. 유저 레벨 쓰레드가 종료될 때, 그 쓰레드의 쓰레드별 변수는 모두 사라지는데, 이로 인해, 적어도 유저 레벨 RCU (Section 9.5를 참고하세요) 가 충분히 개선되기 전까지는, 쓰레드별 변수에의 액세스 문제는 복잡해집니다. 반면, 리눅스 커널에서는 한 CPU가 오프라인이 되더라도 그 CPU의 CPU 별 변수는 여전히 매핑 되어 있고 액세스 가능한 상태로 남습니다.

비슷하게, 새 유저 레벨 쓰레드가 생성되면, 그 쓰레드의 쓰레드별 변수는 갑자기 생겨나야 합니다. 반면, 리눅스 커널에서는 특정 CPU가 아직 존재하지 않거나 나중에도 존재하게 되는 일이 없더라도 부팅 과정에서 모든 CPU 별 변수의 매핑과 초기화를 합니다.

리눅스 커널이 가지고 있는 중요 제약은 컴파일 시간의 길이가 CPU 갯수인 `CONFIG_NR_CPUS`에 바운드되며, 부팅 타임의 길이 역시 `nr_cpu_ids`에 바운드된다는 점입니다. 반면, 유저 스페이스에서는 쓰레드의 갯수에 의한, 하드코딩된 제약이 존재하지 않습니다.

물론, 두 환경 모두 다이나믹하게 로드되는 코드 (유저 스페이스라면 동적 라이브러리, 리눅스 커널에서는

커널 모듈) 가 쓰레드별 변수의 복잡도를 증가시키므로 해당 경우도 처리해야 합니다.

이런 복잡성이 유저 스페이스 환경에서 다른 쓰레드의 쓰레드별 변수에의 접근을 제공하기 어렵게 합니다. 하지만 분명한건, 그런 접근은 상당히 유용하고, 따라서 언젠가는 그런 인터페이스가 생겨나면 좋겠죠. □

Quick Quiz 5.22:

Listing 5.5의 라인 19에서의 NULL 체크는 브랜치 예측 실패를 가져오지 않나요? 항상 0인 변수 집합을 두고 더이상 사용되지 않는 카운터로의 포인터를 NULL로 만드는 대신 그 변수로 향하게 하는게 어떤가요? ■

Answer:

말 되는 이야기입니다. 다만 성능이 어떻게 달라지는지 확인하는 건 독자 여러분의 몫으로 남겨두겠습니다. 다만, 여기서 빠르게 수행되도록 만들어야 하는 곳은 `read_count()`가 아니라 `inc_count()` 임을 기억해두시기 바랍니다. □

Quick Quiz 5.23:

도대체 왜 Listing 5.5의 `read_count()` 함수의 합을 계산하는 곳에서 무거운 `lock`을 사용하는거죠? ■

Answer:

기억하세요, 쓰레드가 종료될 때, 그 쓰레드의 쓰레드별 변수는 사라집니다. 따라서, 어떤 쓰레드가 종료된 후에 그 쓰레드의 쓰레드별 변수를 접근하려 하면 세그먼테이션 폴트가 날 겁니다. 이 락은 합 계산 작업과 쓰레드 종료 작업을 조정해서 그런 일이 발생하지 않게 해줍니다.

물론, 대신 reader-writer 락을 사용해 읽기 락을 획득할 수도 있겠습니다만 Chapter 9에서 이 중재작업을 그보다도 가볍게 해줄 수 있는 매커니즘을 소개할 겁니다.

다른 방법으로는 쓰레드별 변수 대신 배열을 사용하는 방법이 있겠는데요, Alexey Roystman이 이야기한대로 NULL 테스트를 없앨 수 있겠죠. 하지만, 배열에의 접근은 대부분의 경우 쓰레드별 변수보다 느리고, 쓰레드의 갯수의 최대값에 대한 제한을 가져올 겁니다. 또한, 우리가 빠르게 수행되도록 하고자 하는 부분인 `inc_count()`에서는 테스트도 락도 필요치 않음을 기억하세요. □

Quick Quiz 5.24:

대체 왜 Listing 5.5의 `count_register_thread()` 함수에서 락을 잡아야 하는거죠? 여기서 사용하는건 다른 쓰레드가 접근하지 않는, 제대로 정렬된 기계의 워드 사이즈 데이터에 대한 스토어 오퍼레이션이니 어토믹할 거잖아요, 아닌가요? ■

Listing G.1: Per-Thread Statistical Counters With Lockless Summation

```

1 unsigned long __thread counter = 0;
2 unsigned long *counterp[NR_THREADS] = { NULL };
3 int finalthreadcount = 0;
4 DEFINE_SPINLOCK(final_mutex);
5
6 static __inline__ void inc_count(void)
7 {
8     WRITE_ONCE(counter, counter + 1);
9 }
10
11 static __inline__ unsigned long read_count(void)
12     /* need to tweak counttorture! */
13 {
14     int t;
15     unsigned long sum = 0;
16
17     for_each_thread(t)
18         if (READ_ONCE(counterp[t]) != NULL)
19             sum += READ_ONCE(*counterp[t]);
20     return sum;
21 }
22
23 void count_register_thread(unsigned long *p)
24 {
25     WRITE_ONCE(counterp[smp_thread_id()], &counter);
26 }
27
28 void count_unregister_thread(int nthreadsexpected)
29 {
30     spin_lock(&final_mutex);
31     finalthreadcount++;
32     spin_unlock(&final_mutex);
33     while (READ_ONCE(finalthreadcount) < nthreadsexpected)
34         poll(NULL, 0, 1);
35 }

```

Answer:

이 락은 실제로 없앨 수도 있습니다만, 특히 이 함수가 쓰레드 시작 시점에서만 실행되므로, 성능에 중요한 영역이 아닌만큼 좀 더 안전에 치중했습니다. 만약 우리가 이 코드를 수천개의 CPU를 가진 기계에서 테스트 한다면 이 락을 없애야 할 수도 있습니다만 “겨우” 수백개 CPU의 기계라면 굳이 그렇게 할 필요 없겠죠. □

Quick Quiz 5.25:

좋아요, 하지만 리눅스 커널은 CPU 별 카운터의 값을 합칠 때 락을 잡지 않아요. 유저 스페이스 코드에선 왜 이게 필요한거죠??? ■

Answer:

기억해보세요, 리눅스 커널의 CPU 별 변수들은 항상, 심지어 해당 CPU가 꺼져 있다 해도 접근 가능해요—심지어 해당 CPU가 한번도 켜졌던 적 없고 앞으로도 켜질 일이 없다 해도요.

이 문제를 회피하는 한가지 방법은 Listing G.1 (`count_tstat.c`)에 나온 것처럼 각 쓰레드가 모든 쓰레드가 끝날 때까지 종료하지 않게 하는 겁니다. 이 코드의 분석은 독자 여러분의 돋으로 남겨두겠습니다만 이건 `counttorture.h`의 카운터 성능 평가 방법과는

맞지 않음을 알아 두세요.(왜일까요?) Chapter 9에서는 이 상황을 훨씬 우아한 방법으로 해결하는 동기화 메커니즘을 소개합니다. □

Quick Quiz 5.26:

패킷의 사이즈가 다양하다면 패킷의 갯수를 세는 것과 패킷의 전체 바이트 수를 세는 것에 어떤 기본적 차이가 있나요? ■

Answer:

패킷의 갯수를 셀 때, 카운터는 한번에 1씩 증가합니다. 반면, 바이트를 셀 때에는, 카운터는 한번에 크게 증가할 수도 있습니다.

왜 이걸 신경써야 할까요? 1씩 증가하는 경우에 리턴되는 값은 비록 그 값이 이루어진 시점이 언제인지는 알 수 없더라도 분명히 어떤 시점의 값인 것은 분명하기 때문입니다. 반면, 바이트를 세는 경우에는 두개의 서로 다른 쓰레드는 오퍼레이션들의 순서에 따라 비일관적인 값을 리턴할 수도 있습니다.

쓰레드 0이 자신의 카운터에 3을, 쓰레드 1이 자신의 카운터에 5를 더하고, 쓰레드 2와 쓰레드 3이 카운터 전체 값을 구하는 경우를 생각해 봅시다. 만약 시스템이 “완화된 순서 규칙”을 갖거나 컴파일러가 강력한 최적화를 사용한다면, 쓰레드 2는 합이 3이고 쓰레드 3은 합이 5라고 볼 수 있습니다. 일관적인 시스템이라면 값이 변하는 순서는 0,3,8 또는 0,5,8만 가능하므로 이 예에서 쓰레드들이 발견한 결과는 일관적이지 못합니다.

이걸 깜박했다 해도, 당신만 그런게 아닙니다. Michael Scott은 Paul E. McKenney의 박사 학위 심사 과정에서 이 질문을 했습니다. □

Quick Quiz 5.27:

읽기 쓰레드는 쓰레드들의 카운터를 모두 더해야 하므로, 쓰레드의 갯수가 늘어나면 더 많은 시간을 쓰게 될겁니다. 읽기 쓰레드에게도 쓸만한 성능과 확장성을 주면서 쓰기 작업도 여전히 빠르고 확장성 있게 하는 방법은 없을까요? ■

Answer:

전역적인 추정값을 두는 게 한 방법이 될겁니다. 업데이트 쓰레드는 각자의 쓰레드별 변수만 증가시키되 쓰레드별 변수의 값이 미리 지정된 한계에 도달했을 때에는 그 값을 글로벌 변수에 어토믹하게 더하고, 쓰레드별 변수를 0으로 초기화 시키는 겁니다. 이 방법은 평균적 쓰기 오버헤드와 읽혀지는 값의 정확성 사이의 협상을 가능하게 할겁니다.

독자분들은 다른 방법들, 예를 들어 Combining tree와 같은 것들을 생각해보고 시도해보는 것도 좋을 겁니다. □

Quick Quiz 5.28:

어째서 Listing 5.7 는 Section 5.2 에서 나왔던 `inc_count()` 와 `dec_count()` 인터페이스 대신에 `add_count()` 와 `sub_count()` 를 제공하나요? ■

Answer:

서로 다른 크기의 구조체들이 할당 요청되기 때문입니다. 물론, 특정 크기의 구조체에만 사용되는 한계치 카운터는 여전히 `inc_count()` 와 `dec_count()` 를 사용할 수 있을 겁니다. □

Quick Quiz 5.29:

Listing 5.7 line 3 의 저 이상한 조건문은 뭔가요? 왜 다음과 같이 더 직관적인 형태의 빠른 수행경로를 사용하지 않는거죠?

```
3 if (counter + delta <= countermax) {
4     counter += delta;
5     return 1;
6 }
```

Answer:

두단어로 설명하죠. “인티저 오버플로우 (Integer overflow).”

앞의 코드를 10의 값을 갖는 `counter` 와 `ULONG_MAX` 값을 갖는 `delta` 에 대해 수행해 보세요. 그리고 나서 Listing 5.7 의 코드로 한번 더 해보세요.

이 예제의 뒷부분은 인티저 오버플로우에 대한 깊은 이해를 필요로 하므로, 인티저 오버플로우 문제를 한번도 겪어본 적 없다면, 몇몇 예제를 가지고 이해해 보려 노력해보세요. 일부 경우에 있어서는 인티저 오버플로우가 별별 알고리즘보다도 제대로 처리하기가 어렵습니다! □

Quick Quiz 5.30:

Listing 5.7 에서 왜 `globalize_count()` 는 나중에 `balance_count()` 가 쓰레드별 변수를 다시 채우도록 쓰레드별 변수를 0으로 바꾸나요? 왜 그냥 쓰레드별 변수를 0이 아닌 채로 놔두질 않는거죠? ■

Answer:

사실 이 코드의 이전 버전에서는 그렇게 했습니다. 하지만 더하기와 빼기는 매우 비용이 싼 동작이고, 모든 특수 케이스를 처리하는건 상당히 복잡합니다. 다시 말하지만, 직접 한번 해보세요, 다만 인티저 오버플로우를 조심하구요! □

Quick Quiz 5.31:

Listing 5.7 에서 `globalreserve` 는 `add_count()` 에서 값이 구해지는데, 왜 `sub_count()` 에서 값을 구하지 않나요? ■

Answer:

`globalreserve` 변수는 모든 쓰레드의 `countermax` 변수의 합을 따라갑니다. 이 쓰레드의 `counter` 변수들의 합은 0 부터 `globalreserve` 사이 어딘가일 것입니다. 따라서 우리는 모든 쓰레드의 `counter` 변수가 `add_count()` 에서 꽉 차고 `sub_count()` 에서 비어버린다 가정하는, 보수적 방법을 취합니다.

하지만 나중에 다시 한번 이야기할테니, 이 질문을 기억해 두세요. □

Quick Quiz 5.32:

한 쓰레드가 Listing 5.7 의 `add_count()` 를 호출하고, 다른 쓰레드가 `sub_count()` 를 호출한다고 해봅시다. `sub_count()` 는 카운터의 값이 0이 아님에도 실패하지 않겠습니까? ■

Answer:

실제로 그럴 것입니다! 많은 경우에, 이것은 Section 5.3.3 에서 이야기되는 것처럼 문제가 될 것이고, 그런 경우에는 Section 5.4 에서 다른 알고리즘을 사용하는게 좋을 겁니다. □

Quick Quiz 5.33:

Listing 5.7 에서는 왜 `add_count()` 와 `sub_count()` 를 모두 가지고 있는 거죠? 그냥 `add_count()` 에 음수를 넘기면 되지 않나요? ■

Answer:

`add_count()` 는 `unsigned long` 타입을 인자로 받기 때문에, 음수를 넘기는건 조금 어려울 겁니다. 그리고 설명 반물질 메모리를 가지고 있다 해도, 사용중인 구조체의 수를 세는데에 음수를 넘긴다는건 좀 말이 이상하죠! □

Quick Quiz 5.34:

Listing 5.8 의 라인 15 에서는 왜 `counter` 를 `countermax / 2` 로 만들죠? 그냥 `countermax` 값을 가져오는게 더 간단하지 않나요? ■

Answer:

첫째로, `countermax` 카운트는 이미 예약되어 있긴 합니다만 (라인 14 를 참고하세요), 이 코드는 해당 순간에 해당 쓰레드에 의해서 실제로는 그 반만 사용하고 있다고 알리는 것입니다. 이렇게 함으로써 해당 쓰레드는 `globalcount` 까지 찾아가지 않고도 최소 `countermax / 2` 만큼까지는 증가 또는 감소 작업을 할 수 있게 합니다.

`globalcount` 의 수는 라인 18 에서의 조정 덕에 여전히 정확함을 참고하세요. □

Quick Quiz 5.35:

Figure 5.6에서 보면, 가운데와 오른쪽 구성은 뒤쪽의 점선을 보면 알 수 있듯이, 한계까지 남은 카운트의 4분의 1이 쓰레드 0에게 주어졌음에도, 8분의 1 만이 사용되었습니다. 왜 그런건가요? ■

Answer:

쓰레드 0의 `counter`가 `countermax`의 절반으로 책정되었기 때문입니다. 따라서, 쓰레드 0에 할당된 4분의 1 중 절반(8분의 1)은 `globalcount`에서 오고, 나머지 절반(역시 8분의 1)은 남은 카운트에서 오도록 남겨두는 것이죠.

이런 방법을 취하는데에는 두가지 목적이 있습니다: (1) 쓰레드 0가 증가만이 아니라 감소에서도 빠른 수행 경로를 사용할 수 있도록 하는 것, 그리고 (2) 모든 쓰레드가 단조적으로 한계점을 향해 증가만 하고 있다면 비정확성을 줄이기 위해서입니다. 마지막 이야기를 이해하려면, 알고리즘에 한발 더 다가가 자세히 살펴보세요. □

Quick Quiz 5.36:

쓰레드의 `counter`와 `countermax` 변수를 한번에 어토믹하게 수정해야 하는 이유가 뭐죠? 각 변수를 개별적으로 어토믹하게 수정해도 충분하지 않나요? ■

Answer:

그렇게도 할 수 있겠지만, 각별한 주의가 필요합니다. `countermax`를 먼저 0으로 하지 않고 `counter`를 없애는 것은 `counter`를 0이 된 직후 증가시키는 같은 쓰레드가 카운터를 0으로 만든 효과를 없애버리게 만듭니다.

반대로, `countermax`를 0으로 만들고 `counter`를 없애는 것 역시 0이 아닌 `counter`를 만들 수 있습니다. 이걸 자세히 보기 위해 다음의 이벤트 시퀀스를 봅시다:

1. Thread A가 자신의 `countermax`를 가져오고, 0이 아님을 확인합니다.
2. Thread B가 Thread A의 `countermax`를 0으로 만듭니다.
3. Thread B가 Thread A의 `counter`를 제거합니다.
4. 자신의 `countermax`가 0이 아님을 확인했던 Thread A는 `counter`에 값을 더하고, 이로 인해 `counter`는 0이 아닌 값을 갖습니다.

다시 말하지만, `countermax`와 `counter`를 별개의 변수로 두고서 어토믹하게 조정하는 것도 가능하긴 합니다만, 많은 주의가 필요할 것임은 분명합니다. 또한 그렇게 하는 것은 빠른 수행경로를 느리게 만들 확률이 큽니다.

이런 가능성을 더 알아보는 건 독자 여러분의 숙제로 남겨두겠습니다. □

Quick Quiz 5.37:

Listing 5.11의 line 7에서는 C 표준을 어기는 거 아닌가요? ■

Answer:

해당 코드는 바이트당 비트가 8개라 가정합니다. 이 가정은 공유 메모리 멀티프로세서에 쉽게 장착될 수 있는 현재의 모든 상용화된 마이크로프로세서에 성립합니다만, 물론 C 코드가 돌아갈 수 있는 모든 컴퓨터 시스템에 성립하진 않습니다. (C 표준에 맞추려면 대신 어떻게 할 수 있을까요? 그리고 그 때의 단점은 무엇일까요?) □

Quick Quiz 5.38:

`ctrandmax` 변수는 하나 뿐인데, Listing 5.11의 라인 18에서는 왜 굳이 포인터로 받는 거죠? ■

Answer:

`ctrandmax` 변수는 쓰레드당 한개씩만 있습니다. 뒤에서 우리는 다른 쓰레드의 `ctrandmax` 변수를 `split_crandmax()`에 넘기는 코드도 보게 될 겁니다. □

Quick Quiz 5.39:

Why does `merge_counterandmax()` in Listing 5.11 return an `int` rather than storing directly into an `atomic_t`? ■

Answer:

나중에, `atomic_cmpxchg()` 함수에 넘기기 위해 `int` 리턴이 필요한 부분을 보게 될 겁니다. □

Quick Quiz 5.40:

우웩! Listing 5.12 라인 11의 저 더러운 `goto`는 웬 건가요? `break` 모르시나요??? ■

Answer:

해당 `goto`를 `break`로 대체하려면 라인 15에서 리턴해야 할지 말아야 할지를 결정하기 위한 플래그를 하나 더 만들어야 할텐데, 이건 빠른 수행 경로에서 하고자 하는 일은 아닐 겁니다. 정말로 `goto`를 그렇게나 싫어한다면, 이 빠른 수행 경로를 별도의 함수로 집어넣고 그 함수에서 성공인지 실패인지를 리턴하게 하고 “실패”는 느린 수행 경로의 수행 필요를 나타내도록 하는 게 최선일 겁니다. 이건 `goto`를 싫어하는 독자분들의 연습 문제로 남겨두겠습니다. □

Quick Quiz 5.41:

Listing 5.12의 라인 ??-14의 `atomic_cmpxchg()` 함수는 어떻게 실패할 수 있죠? 우린 이전 값을 라인 9에서 가져오고 나서 바꾼 적 없잖아요! ■

Answer:

나중에, Listing 5.14 의 `flush_local_count()` 함수에서 어떻게 이 쓰레드의 `ctrandmax` 변수를 Listing 5.12의 라인 8-14 의 빠른 수행 경로 실행과 동시에 수정할 수 있는지 알아볼 겁니다. □

Quick Quiz 5.42:

Listing 5.14 의 라인 14에서 `flush_local_count()` 가 `ctrandmax` 변수를 0 으로 만든 후 그냥 다시 값을 넣을 수 없는 이유는 뭐죠? ■

Answer:

이 다른 쓰레드는 `flush_local_count()` 를 호출한 쪽에서 `gblcnt_mutex` 를 해제하기 전까지는 자신의 `ctrandmax` 를 재설정 할 수 없습니다. `gblcnt_mutex` 가 해제되는 시점에선, `flush_local_count()` 호출자 쪽에서는 카운트 값의 사용을 이미 끝냈을 거고, 따라서 재설정에 문제는 없습니다 — `globalcount` 가 재설정을 허용할 만큼 충분히 크다는 가정 하에서요. □

Quick Quiz 5.43:

Listing 5.14 의 라인 27에서 `flush_local_count()` 가 `ctrandmax` 변수를 비우는 동안 `add_count()` 나 `sub_count()` 의 빠른 수행경로가 `ctrandmax` 를 함께 사용하면서 동시에 수행되지 못하는 이유는 뭐죠? ■

Answer:

그런 이유는 없습니다. 다음의 세가지 경우를 생각해보죠:

- 만약 `flush_local_count()` 의 `atomic_xchg()` 가 이야기된 빠른 수행경로 두개의 `split_crandmax()` 이전에 수행된다면, 빠른 수행경로에서는 0 이 된 `counter` 와 `countermax` 를 보게 될거고, 따라서 (물론 `delta` 가 0 이 아니라면) 그냥 느린 수행경로로 넘어갈 겁니다.
- 만약 `flush_local_count()` 의 `atomic_xchg()` 가 두 빠른 수행경로의 `split_crandmax()` 뒤에, 그러나 빠른 수행경로의 `atomic_cmpxchg()` 보단 앞에 수행된다면, `atomic_cmpxchg()` 를 실패할 거고, 빠른 수행경로를 재시작해서 앞의 case 1 의 상황으로 돌아갈 겁니다.
- 만약 `flush_local_count()` 의 `atomic_xchg()` 가 두 빠른 수행경로의 `atomic_cmpxchg()` 뒤에 수행된다면, 빠른 수행경로는 `flush_local_count()` 가 해당 쓰레드의 `ctrandmax` 변수를 0 으로 만들기 이전에 이미 성공적으로 완료될 겁니다.

어느쪽이든, 경주는 올바르게 마무리 됩니다. □

Quick Quiz 5.44:

`atomic_set()` 은 주어진 `atomic_t` 에 단순히 스토어를 할 뿐인데, 어떻게 Listing 5.15 의 라인 21에서의 `balance_count()` 는 `flush_local_count()` 의 해당 변수에 동시에 가해지는 업데이트에도 불구하고 올바르게 동작할 수 있는 거죠? ■

Answer:

`balance_count()` 와 `flush_local_count()` 의 호출자 모두 `gblcnt_mutex` 를 잡고 있으므로, 한번에 한쪽만 수행될 수 있습니다. □

Quick Quiz 5.45:

하지만 시그널 핸들러는 수행 중에 다른 CPU 로 옮겨져서 수행될 수도 있잖아요. 이런 가능성은 쓰레드와 해당 쓰레드를 인터럽트 하는 시그널 핸들러 사이의 안정적인 통신을 위해 어토믹 인스트럭션과 메모리 배리어를 필요로 하게 만들지 않을까요? ■

Answer:

아니요. 시그널 핸들러가 다른 CPU 로 옮겨가면, 인터럽트된 쓰레드 역시 그리로 옮겨집니다. □

Quick Quiz 5.46:

Figure 5.7에서 REQ theft 상태는 왜 빨간색으로 칠해졌나요? ■

Answer:

빠른 수행 경로만이 `theft` 상태를 바꿀 수 있음과 해당 쓰레드가 이 상태에 너무 오래 머무르면, 느린 수행 경로를 수행하고 있는 쓰레드는 POSIX 시그널을 다시 보낼 것임을 알리기 위해서입니다. □

Quick Quiz 5.47:

Figure 5.7에서, 두개의 분리된 REQ 와 ACK theft 상태를 갖는 이유가 뭐죠? 왜 그 두 상태를 하나의 REQACK 상태로 만들어서 스테이트 머신을 간단하게 만들지 않는 거예요? 만약 그렇게 하면 그 상태에 먼저 도달하는 시그널 핸들러나 빠른 수행 경로가 상태를 READY 로 바꿀 수 있을 텐데요. ■

Answer:

REQ 와 ACK 상태를 합치는게 나쁜 이유를 들어보자면:

- 해당 느린 수행 경로는 REQ 와 ACK 상태를 사용해 언제 시그널이 다시 보내져야 할지 결정합니다. 만약 해당 상태들이 합쳐진다면, 해당 느린 수행 경로는 반복적으로 시그널을 보내는 수밖에 없고, 빠른 수행경로를 불필요하게 느리게 만드는 효과를 만들 겁니다.

2. 다음과 같은 레이스가 일어날 수 있습니다:

- (a) 느린 수행 경로가 주어진 쓰레드의 상태를 REQACK 으로 만듭니다.
- (b) 해당 쓰레드는 방금 빠른 수행 경로를 끝낸 참이었고, REQACK 상태임을 확인합니다.
- (c) 해당 쓰레드는 시그널을 받고, 여기서도 REQACK 상태임을 확인합니다만, 빠른 수행 경로는 아무 효과를 발휘하지 못한 채이므로, 상태를 READY 로 바꿉니다.
- (d) 느린 수행 경로는 READY 상태를 확인하고, 카운트를 가져가고 상태를 IDLE 로 돌려놓고 완료됩니다.
- (e) 빠른 수행 경로는 상태를 READY 로 바꾸고, 이 쓰레드에서의 다음 빠른 수행 경로 수행을 막아버립니다.

여기서의 기본적 문제는 합쳐진 REQACK 상태는 시그널 핸들러와 빠른 수행 경로 둘 다 볼 수 있다 는 겁니다. 네개의 상태로 관리되는 명확한 분리 상태는 순서화된 상태 전환을 분명히 보장합니다.

그렇다곤 하지만, 세개의 상태만으로도 제대로 동작하도록 할 수 있을 수도 있습니다. 만약 성공하면 네개 상태 버전과 잘 비교해 보세요. 세개 상태 버전이 정말 더 낫나요, 그리고 왜죠 또는 왜 아니죠? □

Quick Quiz 5.48:

Listing 5.17 의 flush_local_count_sig() 함수에서 왜 theft 쓰레드별 변수의 사용을 ACCESS_ONCE() 로 감싼거죠? ■

Answer:

The first one (on line 11) can be argued to be unnecessary. The last two (lines 14 and 16) are important. If these are removed, the compiler would be within its rights to rewrite lines 14-16 as follows:

```

14 theft = THEFT_READY;
15 if (counting) {
16     theft = THEFT_ACK;
17 }
```

This would be fatal, as the slowpath might see the transient value of THEFT_READY, and start stealing before the corresponding thread was ready. □

Quick Quiz 5.49:

Listing 5.17에서 왜 다른 쓰레드의 countermax 변수를 바로 접근해도 안전한 거죠? ■

Answer:

그 다른 쓰레드는 자신의 countermax 변수의 값을 gblcnt_mutex 락을 쥐지 않은 한 수정할 수 없기 때문입니다. 하지만 이 함수 호출 코드는 락을 잡고 함수를 호출하기 때문에, 그 다른 쓰레드는 해당 락을 잡을 수가 없고, 따라서 그 다른 쓰레드는 countermax 변수를 수정할 수 없습니다. 따라서 바로 접근해도 안전합니다—하지만 바꾸진 않습니다. □

Quick Quiz 5.50:

Listing 5.17에서, 왜 라인 33 은 현재 쓰레드가 자기 자신에게 시그널을 보내는지 체크하지 않나요? ■

Answer:

또한번 체크할 필요가 없습니다. flush_local_count() 는 이미 globalize_count() 를 호출했으니, 라인 28에서의 체크가 성공해서 뒤의 pthread_kill() 은 스킵될 겁니다. □

Quick Quiz 5.51:

Listing 5.17 의 코드는 GCC 와 POSIX 에서 동작합니다. ISO C 표준에서 동작하게 하려면 뭐가 필요할까요? ■

Answer:

theft 변수는 안전하게 시그널 핸들러와 시그널에 인터럽트되는 코드 사이에서 안전하게 공유될 수 있도록 sig_atomic_t 타입이어야만 합니다. □

Quick Quiz 5.52:

In Listing 5.17, why does line 41 resend the signal? ■

Answer:

지난 수십년간 많은 운영 체제는 갑자기 시그널을 끊어 버리는 특성을 가졌기 때문입니다. 이게 가능인지 버그인지는 논쟁거리이지만, 그건 무의미합니다. 사용자가 보기에 분명한 증상은 커널 버그가 아니라 사용자 어플리케이션의 문제입니다.

당신의 어플리케이션의 문제입니다! □

Quick Quiz 5.53:

POSIX 시그널만 느린게 아니라, 시그널을 각 쓰레드에 보내는 행위 자체가 확장성이 없어요. 만약 10,000 개의 쓰레드가 있고 읽는 쪽도 빨라야 한다면 어떻게 하시겠어요? ■

Answer:

한가지 방법은 Section 5.2.3 에서 보였던, 한개의 카운터 변수에 추정치를 합하는 방법입니다. 또 다른 방법으로는 각각 업데이트를 하는 쓰레드의 일부와 상호작용하면서 읽기 작업을 함께 하는 복수의 쓰레드를 사용하는 방법도 있겠습니다. □

Quick Quiz 5.54:

아래쪽 한계는 명확하게 지키지만 위쪽 한계는 좀 정확하지 않아도 되는 한계 카운터를 원한다면 어떻게 하면 될까요? ■

Answer:

한가지 간단한 해결책은 위쪽 한계를 원하는 만큼 더 높게 잡아주는 것입니다. 그렇게 더 높게 리미트를 잡아주는 것의 한계는 카운터가 표현할 수 있는 최대의 값을 될 것입니다. □

Quick Quiz 5.55:

바이어스된 카운터를 사용할 때 그 외에 뭘 하면 좋을까요? ■

Answer:

카운터가 액세스의 수가 최대값에 가까울 때에도 효과적으로 동작할 수 있도록 위쪽 리미트를 바이어스, 예상되는 최대 액세스 수, 그리고 충분한 “출렁거림”을 수용하기 충분하도록 크게 잡는게 좋을 겁니다. □

Quick Quiz 5.56:

이거 참 웃기네요! 카운터를 업데이트 하기 위해 리더-라이터 락의 읽기 권한 획득을 한다니요? 뭐하는거예요??? ■

Answer:

이상해 보일 수 있겠죠, 하지만 진짜예요! “리더-라이터 락”이라는 이름은 사실 완벽하게 의미를 설명하지 못한다는 점을 상기하면 이해가 될 거예요, 그렇죠? □

Quick Quiz 5.57:

실제 시스템에 적용하려면 해결해야 할 문제들이 또 뭐가 있을 수 있을까요? ■

Answer:

엄청나게 많습니다!

일단 몇가지 생각을 시작할 것들은:

1. 디바이스는 여러개가 있을 수 있으니, 전역 변수는 적절치 못하고, `do_io()`에 인자가 없는 것도 마찬가지죠.
2. 풀링하는 루프는 실제 시스템에서는 CPU 시간과 전력을 낭비하는 문제가 있을 수 있습니다. 많은 경우, 이벤트 기반 설계가 훨씬 나은데, 예를들면 마지막으로 I/O를 완료하는 쪽에서 디바이스 제거 쓰레드를 깨우는 식입니다.
3. I/O는 실패할 수 있으므로, `do_io()`는 리턴 값을 가져야 할 겁니다.

4. 디바이스가 고장나면, 마지막 I/O는 성공하지 못할 것입니다. 이런 경우, 에러 복구를 위한 어떤 타임아웃 같은 것이 필요할 것입니다.

5. `add_count()`와 `sub_count()` 모두 실패할 수 있는데 리턴값을 체크하지 않았습니다.

6. 리더-라이터 락은 확장성이 그다지 좋지 않습니다. 리더-라이터 락의 읽기 권한 획득의 높은 비용을 회피하는 방법 한가지가 Chapter 7 와 9 에 소개되어 있습니다.

□

Quick Quiz 5.58:

Table 5.1 의 `count_stat.c` 열에 보면 읽기 성능이 쓰레드 수에 따라 선형적으로 확장되는데요. 쓰레드 수가 늘어나면 더 많은 쓰레드별 카운터의 합이 이루어져야 하는데 어떻게 그게 가능하죠? ■

Answer:

읽는 쪽의 코드는 쓰레드의 수와 상관 없이 고정된 크기의 배열 전체를 읽어야 하기 때문에 성능에 차이가 없습니다. 반면, 뒤의 두개 알고리즘의 경우 쓰레드가 늘어나면 더 많은 일을 하게 됩니다. 더불어, 뒤의 두개 알고리즘은 쓰레드 ID 와 연관된 `__thread` 변수 사이의 매팅을 유지하는 추가적인 계층을 갖습니다. □

Quick Quiz 5.59:

Table 5.1 의 마지막 열을 보더라도 통계적 카운터 구현의 읽기쪽 성능은 매우 나쁘군요. 왜 이렇게 성능 나쁜 알고리즘을 신경쓰는거죠? ■

Answer:

“해야할 일에 걸맞는 도구를 사용하세요.”

Figure ?? 에서 볼 수 있듯이, 하나의 변수에 어토믹 값 증가 오퍼레이션을 사용하는 방법은 상당한 양의 병렬적 업데이트가 있는 작업에 사용되어선 안됩니다. 반면, Table 5.1 에 보인 알고리즘들은 업데이트가 많은 상황에서 일을 훌륭하게 처리할 것입니다. 물론, 읽기가 대부분인 상황이라면, 다른걸 사용해야 합니다. 예를들자면, Section 5.2.3에 사용된 것과 비슷하게 한번의 로드 오퍼레이션으로 읽어낼 수 있는, 어토믹하게 증가되는 변수를 사용하는 결과적 일관성 설계와 같은 것을요. □

Quick Quiz 5.60:

Table 5.2 에 보여진 성능 데이터를 놓고 보자면, 우리는 항상 어토믹 오퍼레이션보다는 시그널을 사용해야겠군요, 그렇죠? ■

Answer:

그건 워크로드에 따라 달라집니다. 64-코어 시스템이라면, 단지 한개의 시그널 (약 40-나노세컨드 성능 향상)을 만들기 위해 100 개가 넘는 어토믹하지 않은 오퍼레이션들의 실행 (약 5-마이크로세컨드 성능 저하)이 필요합니다. 더욱 읽기 위주인 워크로드는 여전히 존재하지만, 현재 처리해야하는 특정 워크로드에 신경쓸 필요가 있습니다.

또한, 역사적으로 메모리 배리어는 일반 인스트럭션들에 비해 비용이 비쌌지만, 당신이 운용하게 될 특정 하드웨어에서도 그러한지 확인해 봐야 합니다. 컴퓨터 하드웨어의 특성은 시간에 따라 변하고, 알고리즘도 그에 맞춰 변해야만 합니다. □

Quick Quiz 5.61:

Table 5.2에 보여진 읽는 쓰레드간의 락 컨텐션을 해결하기 위해 고급 테크닉들이 사용될 수 있을까요? ■

Answer:

한가지 해결책은 scalable non-zero indicators(SNZI) [ELLM07]처럼 업데이트 쪽 성능을 약간 포기하는 겁니다. SNZI 외에도 이 해결책을 구현하는 여러 방법이 있겠지만, 그건 독자 여러분의 몫으로 남겨두겠습니다. 자주 획득이 요청되는 글로벌 락을 낮은 계층의 로컬 락의 획득들로 대체하는 계층적 방법들도 이 문제를 잘 해결할 겁니다. □

Quick Quiz 5.62:

++ 오퍼레이터는 1,000 자리 숫자에도 잘 동작해요! 연산자 오버로딩이라고 못들어봤어요??? ■

Answer:

C++ 언어에서라면 그런 수를 구현하는 클래스에 액세스가 가능하다는 가정 하에 1,000 자리 숫자에도 ++를 사용할 수 있겠죠. 하지만 최소 2010년 까지는 C 언어는 오퍼레이터 오버로딩을 허용하지 않습니다. □

Quick Quiz 5.63:

하지만 우리가 모든 것을 분할할 거라면, 왜 공유 메모리 멀티쓰레딩을 신경쓰죠? 그냥 문제를 완벽하게 분할해 버리고 각 분할된 조각들을 여러 프로세스들로, 각자의 어드레스 스페이스에서 처리하도록 돌리지 않는건가요? ■

Answer:

사실, 별도의 어드레스 스페이스를 갖는 여러 프로세스들은 병렬성을 보일 수 있는 훌륭한 방법으로, 포크-조인 방법론의 지지자들과 Erlang 언어가 그 사실을 잘 입증합니다. 하지만, 공유 메모리 병렬성만의 장점 역시 일부 있습니다:




Figure G.2: Dining Philosophers Problem, Fully Partitioned

1. 어플리케이션의 성능에 치명적인 부분만이 분할되어야 하고, 그런 성능에 치명적인 부분은 일반적으로 어플리케이션의 작은 부분입니다.
2. 캐시 미스는 레지스터에서 레지스터로 값을 옮기는 인스트럭션들에 비하면 매우 느리지만, TCP/IP 네트워킹과 같은 것들보다 빠른 프로세스간 통신 (inter-process-communication) 기능들에 비해서도 상당히 빠릅니다.
3. 공유 메모리 멀티프로세서들은 이미 시장에 나와 있고 상당히 저렴하므로, 1990년대와는 정반대로, 공유 메모리 병렬성을 사용하는데 비용 문제는 거의 없습니다.

항상 말하듯이, 처리해야 하는 일에 걸맞는 도구를 사용하세요! □

G.6 Partitioning and Synchronization Design

Quick Quiz 6.1:

식사하는 철학자들 문제를 위한 더 나은 해결책은 없을까요? ■

Answer:

그런 개선된 해결책이 Figure G.2에 보여져 있는데, 철학자들에게 추가로 다섯개의 포크를 주는 것입니다. 이제 모든 다섯명의 철학자들이 동시에 식사를 할 수 있고,

따라서 철학자들이 남을 기다려야 할 필요가 없습니다. 또한, 이 방법은 질병 확산 제어를 크게 개선시킵니다. 이 해결책은 누군가에겐 사기처럼 보이겠지만, 그런 “사기”가 많은 동시성 문제에 좋은 해결책을 찾는 핵심입니다. □

Quick Quiz 6.2:

그리고 어떤 관점에서 이 “수평적 병렬성”은 “수평적”이라 이야기 될 수 있는 걸까요? ■

Answer:

Inamn은 프로토콜 스택에 대한 작업을 했는데, 이 프로토콜 스택은 일반적으로는 어플리케이션을 꼭 대기해 두고 하드웨어 연결을 바닥에 두는 식으로 수직적으로 그림 그려집니다. 데이터는 이 스택의 위아래로 흐르게 됩니다. “수평적 병렬성”은 다른 네트워크로부터의 패킷들을 병렬적으로 처리하게 되는데, 반면 “수직적 병렬성”은 각 패킷들에게 서로 다른 프로토콜 처리 단계를 병렬적으로 줍니다.

“수직적 병렬성”은 또한 “파이프라인”이라고도 불립니다. □

Quick Quiz 6.3:

이 compound double-ended 큐 구현에서, 비어있던 큐가 락을 놓고 다시 잡는 과정 사이에 더이상 비어있지 않게 된다면 어떻게 해야 할까요? ■

Answer:

이 경우, 단순히 더이상 비어있지 않은 그 큐의 원소를 디큐하고, 락들을 풀고, 리턴하면 그만입니다. □

Quick Quiz 6.4:

해시를 사용한 double-ended 큐는 좋은 해결책인가요? 그렇다면 왜 그렇고 그렇지 않다면 또 왜 그렇죠? ■

Answer:

이 질문에 답을 하는 가장 좋은 방법은 `lockhdeq.c`를 여러개의 멀티프로세서 시스템들 위에서 돌려보는 것이고, 가능한한 그렇게 해보시기를 권장합니다. 주의해야 하는 한가지 이유는, 이 구현에서 각 오퍼레이션은 한개가 아니라 두개의 락들을 획득해야 한다는 점입니다.

일단은 잘 설계된 성능 연구를 보는 것으로 시작을 해야 할 겁니다.⁵ 순차적 구현과 비교해 보는 것을 잊지 마세요! □

⁵ Dalessandro 등의 연구 [DCW⁺11] 와 Dice 등의 연구 [DLM⁺10] 가 좋은 시작점이 될 것입니다.

Quick Quiz 6.5:

비어진 큐로 모든 원소들을 옮긴다구요? 대체 어떤 세상에서는 이런 정신나간 방법이 어떤 이유로든 최적인 거죠??? ■

Answer:

데이터의 흐름이 아주 가끔만 그 방향을 바꿀 때에 최적입니다. 물론 double-ended 큐가 양쪽에서 동시에 비워진다면 매우 잘못된 선택일 겁니다. 이는 당연하게도 또 다른 질문을 일으키는데, 대체 어떤 세상에서는 양쪽에서 동시에 큐를 비게 만드는게 합당한 일이 되냐는 것이죠. Work-stealing 큐들이 이 질문에의 가능한 답 중 하나일 것입니다. □

Quick Quiz 6.6:

왜 compound parallel double-ended queue 구현은 대칭적으로 만들어질 수 없는거죠? ■

Answer:

식사하는 철학자들 문제에 대한 해결책에서 포크에 솟자를 매기는 것이 그랬듯이, 락 계층구조를 사용해 데드락을 예방해야 하는 관계로 비대칭성이 필요해집니다 (Section 6.1.1를 참고하세요). □

Quick Quiz 6.7:

Listing 6.3 의 line 28에서 왜 오른쪽 디큐를 또 시도하는거죠? ■

Answer:

이 쓰레드가 `d->rlock` 을 line 25에서 놓고 나서 line 27에서 다시 잡는 사이에 다른 쓰레드가 원소를 집어넣었을 수도 있기 때문에 필요합니다. □

Quick Quiz 6.8:

왼쪽 락은 언젠가는 사용 가능할 겁니다!!! 그런데 Figure 6.3 의 line 25에서는 왜 오른쪽 락을 무조건적으로 놔버려야 하는거죠? ■

Answer:

왼쪽 락이 획득 가능할 때에 그걸 얻기 위해 `spin_trylock()` 을 사용할 수도 있을 겁니다. 하지만, 실패할 경우에는 여전히 오른쪽 락을 잠시 내려놓고 두 락을 순서대로 다시 잡아야만 할 겁니다. 이런 변경을 이해하는건 (그리고 그게 가치있는 것인지 결정하는 것은) 독자 여러분의 몫으로 남겨두겠습니다. □

Quick Quiz 6.9:

하지만 데이터가 한방향으로만 흐르는 경우에는, Listing 6.3에 보인 알고리즘은 디큐를 하는쪽 끝이 그 아래에 있는 double-ended queue 를 비워버리게 되면 두 끝단이 모두 같은 락을 획득하려 시도할 겁니다. 이는 이 알고리즘이 어떤 경우에 있어서는 큐가 임의의 많은

수의 원소들을 가지고 있을 때조차도 큐의 양끝에 동시의 액세스를 제공하는데 실패한다는 의미가 아닌가요?

■

Answer:

실제로 그렇습니다!

하지만 이 속성을 주장하는 다른 알고리즘들에 있어 서도 같습니다. 예를 들어, 소프트웨어 트랜잭션 메모리 메커니즘을 사용하는 해결책들은 락들의 해시된 배열에 기반하는데, 가장 왼쪽과 가장 오른쪽 원소들의 주소들은 간혹 같은 락으로 해시됩니다. 이 해시 충돌 역시 동시의 액세스를 막을 겁니다. 또 다른 예를 들어보면, 하드웨어 트랜잭션 메모리를 소프트웨어 폴백(fallback)과 함께 사용하는 해결책들 [YHLR13, Mer11, JSG12]은 종종 이 소프트웨어 폴백 내에서 락킹을 사용하며, 따라서 (흔히 않을 테지만) 이 락킹 솔루션이 겪는 동시성의 제약으로 고통을 받게 됩니다.

따라서, 2017년 말 기준, compound double-ended queue를 포함해 동시성을 갖는 double-ended queue 문제에 대한 모든 현실적 해결책들은 최소 일부 환경에서는 완전한 동시성을 제공하는데 실패합니다. □

Quick Quiz 6.10:

double-ended 큐 문제에 왜 한개가 아니라 두개나 해결책이 있는 거죠?

■

Answer:

실은 최소한 세개입니다. Dominik Dingel의 세번째 것은 reader-writer 락킹을 사용하는데, lockrwdeq.c에서 보실 수 있을 겁니다. □

Quick Quiz 6.11:

직렬화된 double-ended 큐는 해시 기반 double-ended 큐보다 두배나 빠른데, 이런 현상은 제가 해시 테이블의 크기를 미친듯이 크게 만들어줘도 그렇습니다. 왜 그런거죠?

■

Answer:

해시 기반 double-ended 큐의 락킹 디자인은 각 끝에서 한번에 하나의 쓰레드만을 허용하고, 또한 각 오퍼레이션을 위해 두개의 락 획득을 필요로 합니다. 직렬화된 double-ended 큐 또한 각 끝에서 한번에 하나의 쓰레드만을 허용하지만, 일반적인 경우에는 오퍼레이션당 하나의 락 획득만을 필요로 합니다. 따라서, 직렬화된 double-ended 큐는 해시 기반 double-ended 큐보다 성능이 나을 것으로 예상될 수 있습니다.

여러개의 동시적 오퍼레이션들을 가능하게 하는 double-ended 큐를 만들 수 있을 것 같나요? 그렇다면, 어떻게요? 불가능하다면, 왜죠?

□

Quick Quiz 6.12:

double-ended 큐들을 위한 동시성 제어에 대한 훨씬 나은 방법이 있나요?

■

Answer:

한가지 방법은 풀어야 하는 문제를 여러개의 double-ended 큐들을 별별로 이용할 수 있게 바꾸는 것으로, 더 간단한 단일 락 기반 double-ended 큐를 사용하고, 각 double-ended 큐를 일반적인 single-ended 큐의 쌍으로 바꾸는 것이 가능해집니다. 그런 “수평적 확장” 없이는, 성능 향상은 2.0으로 제한됩니다. 반면, 수평적 확장 설계들은 매우 커다란 성능 향상을 가질 수 있고, 큐의 각 끝에서 일하는 여러 쓰레드들이 있다면 특히 매력적인데, 여러 쓰레드가 있는 경우 디큐는 엄격한 순서 보장을 하지 않아도 되기 때문입니다. 무엇보다, 한 쓰레드가 어떤 아이템을 처음으로 제거했다는 사실은 그 아이템을 처음으로 처리할 것이라는 의미를 갖지는 않습니다 [HKLP12]. 그리고 그런 보장이 없다면, 이런 보장을 제공하지 않는데서 오는 성능 이득을 얻을 수도 있을 겁니다.

문제가 여러 큐를 사용하는 형태로 바뀔 수 있느냐 없느냐와 관계없이, 일이 몰아서 처리될 수 있어서 각 enqueue와 dequeue 오퍼레이션이 더 큰 단위의 일에 연관될 수 있는지 알아보는 것도 해볼 가치가 있습니다. 이 배칭(batching) 전략은 큐 데이터 구조체들로의 경쟁을 줄여줘서, 성능과 확장성 둘 다를 증가시켜주는데, Section 6.3에서 알아볼 것입니다. 무엇보다, 높은 동기화 오버헤드를 겪어야만 한다면, 돈을 가치있게 쓰고 있는지 분명히 해두기 바랍니다.

다른 연구자들은 큐에서의 제한된 순서 보장의 이점을 살리는 다른 방법들을 연구하고 있습니다 [KLP12].

□

Quick Quiz 6.13:

크리티컬 섹션과 관련한 이 모든 문제들은 우리가 크리티컬 섹션에 아예 없는 non-blocking 동기화 [Her90]를 사용해야 한다는 의미는 아닌가요?

■

Answer:

Non-blocking 동기화는 일부 상황에서는 매우 유용할 수 있지만, 만병통치약은 아닙니다. 또한, non-blocking 동기화는 Josh Triplett에 의해 이야기되었듯 실제로는 크리티컬 섹션을 갖습니다. 예를 들어, compare-and-swap 오퍼레이션에 기반한 한 non-blocking 알고리즘에서, 최초의 로드로 시작해 compare-and-swap으로 이어지는 코드는 여러면에서 락 기반의 크리티컬 섹션과 유사합니다. □

Quick Quiz 6.14:

자신의 락이 잡혀 있는 동안은 구조체가 메모리 해제 되지 않도록 할 수 있는 방법들은 어떤 것들이 있을까요?

■

Answer:

여기 존재 보장 문제를 위한 해결책 몇가지가 있습니다:

1. 구조체별 락이 잡혀 있는 동안 유지되는 정적으로 할당된 락을 두는 것으로, 계층적 락킹의 한 예입니다 (Section 6.4.2 을 참고하세요). 물론, 이런 목적으로 하나의 글로벌 락을 사용하는 것은 허용불가능할 정도로 높은 락 경쟁 상황을 가져와서 성능과 확장성의 드라마틱한 하락을 가져올 수 있습니다.
2. 정적으로 할당된 락들의 배열을 두어서, 구조체의 어드레스를 해싱해서 잡아야 할 락을 고르는 것으로, Chapter 7 에서 설명된 방식입니다. 주어진 해시 함수가 충분히 높은 성능을 갖는다면, 이 방법은 하나의 글로벌 락이 갖는 확장성의 한계를 해결할 수 있습니다만, 읽기가 대부분인 상황에서는 락 획득 오버헤드가 수용불가할 정도로 성능을 떨어뜨릴 수 있습니다.
3. 가비지 컬렉터를 제공하는 소프트웨어 환경이라면 가비지 컬렉터를 사용해서, 구조체가 참조되어 있는 동안은 메모리 해제되지 않도록 하는 것입니다. 이 방법은 잘 동작하고, 존재 보장의 짐을 (그리고 그외의 것들을) 개발자의 어깨에서 내려놓게 하지만, 프로그램의 가비지 컬렉션 오버헤드를 갖습니다. 가비지 컬렉션 기술은 지난 수십년간 상당히 진보했지만, 그 오버헤드는 일부 어플리케이션에서는 수용하기 어려울 만큼 높을 수 있습니다. 또한, 일부 어플리케이션들은 데이터 구조체의 배치와 위치 조정에 대해 대부분의 가비지 컬렉션 환경에 비해 개발자에게 많은 연습을 필요로 할 수도 있습니다.
4. 가비지 컬렉터의 특수한 경우로, 글로벌 레퍼런스 카운터를 두거나 레퍼런스 카운터들의 글로벌한 배열을 두는 방법이 있습니다.
5. 안에서-밖으로의 참조 카운트라 생각할 수 있는, 해저드 포인터 [Mic04] 를 사용하는 방법이 있습니다. 해저드 포인터 기반의 알고리즘들은 쓰레드별 포인터들의 리스트를 두어서, 이 리스트들에 있는 포인터의 존재가 연관된 구조체로의 참조처럼 동작하게 합니다. 해저드 포인터들은 흥미로운 연구 방향입니다만, 상품화 단계 (2008년도 시점에선) 에선 아직 잘 쓰여지지 않고 있습니다.

6. 트랜잭션 메모리(TM) [HM93, Lom77, ST95] 를 사용해서 데이터 구조체로 요청되는 각각의 참조와 수정이 어토믹하게 수행되도록 하는 방법이 있습니다. TM 은 최근의 수년간 대단한 흥분을 일으켰고 상품 단계 소프트웨어에서 일부 사용될 것처럼 보였지만, 개발자들은 몇가지 주의를 기울여야 하며 [BLM05, BLM06, MMW07] 이는 특히 성능에 영향을 주는 코드에선 더욱 그렇습니다. 특히, 존재 보장은 트랜잭션이 글로벌 레퍼런스부터 업데이트되는 데이터 원소들에 이르기까지 전체를 감쌀 것을 필요로 합니다.

7. 극단적으로 가벼운 가비지 컬렉터의 추상화로 생각될 수 있는, RCU 를 사용하는 것입니다. 업데이트를 하는 쪽은 RCU 로 보호되는 데이터 구조체를 RCU 로 보호되는 데이터를 읽는쪽이 여전히 참조를 하고 있는 동안은 메모리에서 해제시킬 수 없습니다. RCU 는 읽기가 대부분인 데이터 구조체에서 상당히 많이 사용되고 있고, Chapter 9 에서 이야기될 것입니다.

존재 보장에 대해 더 많은 내용을 위해선 Chapter 7 과 9 을 참고하세요. □

Quick Quiz 6.15:

싱글쓰레드로 동작하는 64 행 64 열 행렬 곱셈이 어떻게 1.0보다 낮은 효율성을 가질 수 있죠? Figure 6.17 의 모든 조합에서의 결과들이 한 쓰레드에서만 돌아갈 때에는 정확히 1.0 의 효율성을 보여야 하는 거 아닌가요?

■

Answer:

matmul.c 프로그램은 명시된 수의 워커 쓰레드들을 생성하므로, 하나의 워커 쓰레드만을 생성한 경우에도 쓰레드 생성 오버헤드는 발생할 수 있습니다. 하나의 워커 쓰레드의 경우에 쓰레드 생성 오버헤드를 없애기 위한 수정은 독자 여러분의 연습문제로 남겨두겠습니다. □

Quick Quiz 6.16:

행렬 곱셈에서 데이터 병렬화 기법이 어떻게 도움이 될 수 있나요? 그건 이미 병렬적인 데이터잖아요!!! ■

Answer:

주의를 기울이고 있으신 것 같아 기쁩니다! 이 예는 데이터 병렬성은 매우 좋은 것이긴 하지만, 모든 비효율성의 원인을 자동으로 제거하는 마술봉은 아니란 것을 보이기 위한 것임을 보이기 위한 것입니다. 64 쓰레드에게 “한정적인” 상황에서조차도 전체 성능을 가지고 선형적으로 성능을 확장하는 데에는 설계와 구현의 모든 단계에서의 세심한 주의가 필요합니다.

특히, 분할된 조각의 크기에 매우 세심한 관심을 기울여야만 합니다. 예를 들어, 64 행 64 열 행렬 곱셈 문제를 64 쓰레드에게 조금다면, 각 쓰레드는 64 개의 부동소수점 곱셈 연산만을 하게 될 것입니다. 부동소수점 곱셈 연산의 비용은 쓰레드 생성의 오버헤드에 비하면 매우 작습니다.

교훈: 변화무쌍한 입력을 받을 수 있는 병렬 프로그램을 가지고 있다면, 항상 입력의 크기를 체크하는 과정을 포함시켜서 병렬화 시킬 가치가 없을 정도로 너무 작은 입력 사이즈에 대응하도록 하십시오. 그리고 병렬화에 도움이 되지 않을 정도라면, 쓰레드를 생성하는데 필요한 오버헤드를 감내하기에도 도움이 되지 않을 정도입니다. 그렇죠? ■

Quick Quiz 6.17:

계층적 락킹이 잘 동작할 만한 상황은 뭐가 있을까요?
■

Answer:

Listing 6.8 의 라인 31에서의 비교 연산이 훨씬 무거운 연산으로 교체된다면, `bp->bucket_lock` 을 놓는 작업은 아마도 락 경쟁을 충분히 줄여줘서 그로부터 얻는 이익이 추가적인 `cur->node_lock` 의 획득과 해제에 드는 오버헤드보다 커질 수도 있을 것입니다. ■

Quick Quiz 6.18:

이 자원 할당자 설계는 Section 5.3에서 다룬 대략적 한계 카운터의 것과 닮지 않았나요? ■

Answer:

실제로 그렇습니다! 우리는 메모리를 할당하고 해제하는 것을 생각했습니다만, Section 5.3에서의 그 알고리즘은 “카운트”를 할당하고 해제하는 매우 비슷한 액션을 위해 만들어졌습니다. ■

Quick Quiz 6.19:

Figure 6.21에서, 세개의 샘플들마다 할당 수행 시간 길이가 증가함에 따라 성능이 따라 증가하는 패턴이 존재하는데, 예를 들어, 할당 수행 시간 길이 10, 11, 12의 경우입니다. 왜 그런거죠? ■

Answer:

이는 per-CPU 타겟 값이 3이기 때문입니다. 할당 수행 시간 길이 12의 경우는 글로벌 풀 락을 두번 잡아야 하는 반면, 할당 수행 시간 길이 13은 글로벌 풀 락을 세번 잡아야 합니다. ■

Quick Quiz 6.20:

두개 쓰레드를 사용한 테스트에서 할당 수행 길이가 19 이상일 때 할당 실패가 발견되었습니다. 글로벌 풀 사이즈가 40이고 per-thread 타겟 풀 사이즈 s 가 3이고,

쓰레드의 갯수 n 가 2이며, per-thread 풀들은 초기에 비어있고 메모리를 아무도 사용하고 있지 않다고 가정하는 조건 하에서, 할당 실패가 발생할 수 있는 최소의 할당 수행 시간 길이 m 은 무엇일까요? (각 쓰레드는 메모리의 m 블럭을 할당받고 m 블럭의 메모리를 해제하는 것을 반복함을 다시 이야기 드립니다.) 그 대신에, n 개 쓰레드가 각각 풀 사이즈 s 를 갖는다면, 그리고 각 쓰레드가 먼저 메모리의 m 개 블럭을 할당받고 그 m 개 블럭을 해제하는 것을 반복한다고 하는 조건이라면, 글로벌 풀 사이즈는 얼마나 커야 할까요? Note: 올바른 답을 얻기 위해서는 `smpalloc.c` 소스 코드를 자세히 들여다보고, 한단계 한단계씩 들여다봐야 할 겁니다. 분명 경고했어요! ■

Answer:

이 답안은 Alexey Roystman 이 제출한 것으로부터 받아들여졌습니다. 이는 다음의 정의에 기초합니다:

g 전역적으로 사용 가능한 블럭들의 갯수

i 초기화 쓰레드의 per-thread 풀에 남아 있는 블럭들의 수. (이게 코드를 들여다봐야 하는 이유 중 하나입니다!)

m 할당/해제 수행 시간 길이.

n 초기화 쓰레드를 제외한 쓰레드의 수.

p 실제로 할당된 블럭들과 per-thread 풀에 남아 있는 블럭들을 포함해서 쓰레드 당 최대 블럭 소비량.

g, m , 그리고 n 의 값은 문제에서 이미 주어졌습니다. p 의 값은 m 을 s 의 배수로 반올림된 값으로, 다음과 같습니다:

$$p = s \left\lceil \frac{m}{s} \right\rceil \quad (G.6)$$

i 의 값은 다음과 같습니다:

$$i = \begin{cases} g & (mod \ 2s) = 0 : 2s \\ g & (mod \ 2s) \neq 0 : g \pmod{2s} \end{cases} \quad (G.7)$$

이 값들 사이의 관계는 Figure G.3에 보여진 것과 같습니다. 글로벌 풀은 이 그림의 꼭대기에 그려져 있고, “나머지” 초기화 쓰레드의 쓰레드별 풀과 쓰레드별 할당은 가장 왼쪽의 두개의 박스로 그려져 있습니다. 이 초기화 쓰레드는 할당된 블럭을 가지고 있지 않습니다만, i 개의 블럭들이 초기화 쓰레드의 쓰레드별 풀에 고립되어 있습니다. 가장 오른쪽의 두개의 박스는 최대 가능한 수의 블럭을 쥐고 있는 쓰레드들의 쓰레드별 풀들과 쓰레드별 할당들이고, 왼쪽에서 두번째의 박스들은 현재 할당을 시도하고 있는 쓰레드를 가리킵니다.




Figure G.3: Allocator Cache Run-Length Analysis

블럭 전체의 갯수는 g 이고, 쓰레드별 할당과 쓰레드별 풀들을 함께 고려해보면, 우리는 글로벌 풀이 $g - i - p(n - 1)$ 블럭들을 가지고 있음을 알 수 있습니다. 할당을 하는 쓰레드가 할당에 성공하려면, 글로벌 풀에는 최소한 m 개의 블럭들은 남아 있어야 하는데, 달리 말하자면 다음과 같습니다:

$$g - i - p(n - 1) \geq m \quad (\text{G.8})$$

문제에서 $g = 40$, $s = 3$, $n = 2$ 였습니다. Equation G.7에 따라 $i = 4$ 이고 Equation G.6에 따라 $m = 18$ 이면 $p = 18$ 이고 $m = 19$ 이면 $p = 21$ 입니다. 이것들을 Equation G.8에 대입해 보면 $m = 18$ 은 넘치지 않는 반면, $m = 19$ 는 넘칠 것을 알 수 있습니다.

i 의 존재는 버그로 여겨질 수도 있을 것입니다. 무엇보다도, 왜 메모리를 초기화 쓰레드의 캐시에 고립된 채로 남겨둡니까? 이를 고치는 한가지 방법은 현재 쓰레드의 풀을 글로벌 풀로 비워버리는 `memblock_flush()` 함수를 제공하는 것이 될 것입니다. 그렇게 되면 이 초기화 쓰레드는 블럭들을 모두 해제한 이후에 이 함수를 호출할 수 있을 것입니다. □

G.7 Locking

Quick Quiz 7.1:

희생양 역할을 한계 어떻게 명예로운 것으로 여겨질 수가 있나요??? ■

Answer:

락킹이 연구 논문에서의 희생양 역할을 맡게 된 이유는 그것이 실제로 상당히 많이 사용되기 때문입니다. 그렇지 않고 아무도 락킹에 신경쓰지 않는다면, 대부분의 연구 논문들은 그것에 대해 언급하는 것조차도 고려하지 않을 것입니다. □

Quick Quiz 7.2:

하지만 데드락의 정의는 단지 각 쓰레드가 최소 하나

이상의 락을 잡고 일부 쓰레드에 의해 잡혀 있는 또 다른 락을 기다리고 있는 것이잖아요. 어떻게 거기에 사이클이 존재하는지 알 수 있죠? ■

Answer:

그래프에 사이클이 존재하지 않는다고 생각해 봅시다. 만약 그렇다면 우리는 방향성 비순환 그래프 (DAG: directed acyclic graph)를 가지게 될텐데, 이 그래프는 최소한 하나의 잎사귀 노드 (leaf node)를 가질 겁니다.

이 잎사귀 노드가 락이라면, 우린 어떤 쓰레드에도 잡혀 있지 않은 락을 기다리고 있는 한 쓰레드를 가지고 있다는 이야기가 됩니다 (그리고 이 경우 해당 쓰레드는 즉시 해당 락을 얻게 되겠죠.)

반면에, 만약 이 잎사귀 노드가 쓰레드였다면, 어떤 락도 기다리고 있지 않은 쓰레드가 하나 존재한다는 이야기가 되는데, 이것 역시 데드락의 정의를 위반합니다. (그리고 이 경우, 해당 쓰레드는 수행중이거나 락이 아닌 무언가에 의해 블락되어 있거나 하는 상태일 것입니다.)

따라서, 이 데드락의 정의에 기반하면, 앞서 설명한 데드락 상태를 나타내는 그래프에는 사이클이 존재해 야만 합니다. □

Quick Quiz 7.3:

이 규칙에 대한 어떤 예외가 존재해서, 라이브러리 코드가 호출자의 어떤 함수도 실행하지 않는다는 조건 하에서도 라이브러리와 호출자 둘 다의 락을 포함하는 데드락 사이클이 실제로는 존재할 수도 있을 수 있나요? ■

Answer:

실제로 존재합니다! 여기 그런 예외들 중 일부가 있습니다:

1. 라이브러리 함수의 인자 가운데 하나가 이 라이브러리 함수가 획득하는 락으로의 포인터라면, 그리고 만약 그 라이브러리 함수가 그 호출자의 락을 잡은 상태로 자신의 락들을 잡는다면, 호출자의 락과 라이브러리 락들이 함께 들어간 데드락 사이클을 가질 수도 있게 됩니다.
2. 라이브러리 함수들 가운데 하나가 호출자에 의해 잡힌 락으로의 포인터를 리턴하게 된다면, 그리고 만약 그 호출자가 라이브러리의 락을 잡은 채로 자신의 락을 잡는다면, 이번에도 호출자의 락과 라이브러리의 락들이 함께 들어간 데드락 사이클을 가질 수도 있게 됩니다.
3. 라이브러리 함수들 가운데 하나가 락을 하나 잡고 그걸 잡은 채로 리턴하게 된다면, 그리고 만약 그 호출자가 자신의 락들 가운데 하나를 잡게 된다면, 또다시 호출자의 락과 라이브러리의 락이 모두 연관된 데드락 사이클을 생성하는 방법이 됩니다.

4. 호출자가 락을 잡는 시그널 핸들러를 가지고 있다면, 호출자의 락과 라이브러리의 락이 모두 연관된 데드락 사이클이 있을 수 있습니다. 하지만, 이 경우에 라이브러리의 락들은 데드락 사이클에 죄가 없는 방관자일 뿐입니다. 그렇다면 하나, 시그널 핸들러 안에서 락을 획득하는 것은 대부분의 환경에서 하지 말아야 할 일임을 알아두시기 바랍니다—그건 그냥 나쁜 생각일 뿐 아니라, 지지받지 못할 일입니다. □

Quick Quiz 7.4:

하지만 `qsort()` 가 비교 함수를 실행하기 전에 그 자신의 락들을 모두 해제해버리면, 다른 `qsort()` 쓰레드들과의 경주 문제로부터 안전성을 어떻게 지킬 수 있나요? ■

Answer:

비교되는 데이터 원소들을 사유화 시켜버리거나 (Chapter 8에서 설명한 것과 같이) 레퍼런스 카운팅과 같은 뒤로 미루기 메커니즘을 사용하는 것 (Chapter 9에서 설명한 것과 같이) 으로 가능합니다. □

Quick Quiz 7.5:

락으로의 포인터를 함수에 넘기는 게 완벽하게 합리적인 예외를 하나만 들어 보세요. ■

Answer:

락킹 기능들이죠, 당연히! □

Quick Quiz 7.6:

`pthread_cond_wait()` 함수가 먼저 그 뮤텍스를 해제하고 나서 다시 획득한다는 사실은 데드락의 가능성은 제거하는 거 아닌가요? ■

Answer:

전혀 그렇지 않습니다!

`mutex_a`를 획득하고, 그 후엔 `mutex_b`를 획득하고 나서는 `mutex_a`를 `pthread_cond_wait`에 넘겨버리는 한 프로그램을 생각해 보세요. 이제 `pthread_cond_wait`는 `mutex_a`를 해제합니다만, 리턴하기 전에 그걸 다시 잡습니다. 만약 그 사이에 다른 쓰레드가 `mutex_a`를 잡고서 `mutex_b`를 사용해 블락된다면, 이 프로그램은 데드락에 빠지고 맙니다. □

Quick Quiz 7.7:

Listing 7.3에서 Listing 7.4로의 변경이 어디서나 적용될 수 있는 걸까요? ■

Answer:

절대 그렇지 않습니다!

이 변경은 `layer_2_processing()` 함수가 같은 입력에 대해선 항상 같은 출력을 내놓는다는 가정을 가지고 있는데, `layer_1()`의 라우팅 결정이 변화되면 같은 패킷에 대해 이 함수가 여러번 수행될 수도 있기 때문입니다. 따라서, 실제 세상에서 이런 변경을 적용하기는 상당히 복잡해질 수 있습니다. □

Quick Quiz 7.8:

그렇지만 Listing 7.4에서의 추가된 복잡도는 그게 데드락을 막는다는 점을 생각하면 꽤 가치있는 거예요, 맞죠? ■

Answer:

아마도요.

만약 `layer_1()`에서의 라우팅 결정이 충분히 자주 바뀐다면, 해당 코드는 항상 재시도만 할테고, 진전은 전혀 이루지 못할 겁니다. 이런 현상을 가리켜 어떤 쓰레드도 진행을 못하고 있을 때에는 “livelock”이라 하고, 일부 쓰레드는 진행을 이루고 있지만 다른 것들은 못하고 있을 때에는 “starvation”이라 합니다 (Section 7.1.2을 참고하세요). □

Quick Quiz 7.9:

Section 7.1.1.6에서 이야기한 “필요한 락들을 먼저 획득하기” 방법을 사용할 때에, 어떻게 하면 livelock을 막을 수 있을까요? ■

Answer:

추가적인 글로벌 락을 제공하는 겁니다. 어떤 쓰레드가 반복적으로 필요한 락들을 획득하려 노력하고 실패했다면 그 쓰레드는 조건 없이 새로운 글로벌 락을 획득하도록 하고 조건 없이 모든 필요한 락들을 획득하게 하는 겁니다. (Doug Lea.에 의해 제안된 방법입니다.) □

Quick Quiz 7.10:

시그널 핸들러 안에서 획득되는 Lock B를 잡은 채로 시그널들을 블락시키지 않고 시그널 핸들러 밖에서 획득되는 Lock A를 잡는 행위가 해선 안되는 행위인 이유가 뭐죠? ■

Answer:

데드락을 유발할 수 있기 때문입니다. Lock A가 시그널들을 블락시키지 않은 상태로 시그널 핸들러의 밖에서 잡혔다면, 이 락을 잡고 있는 상태로 어떤 시그널은 처리될 수 있을 겁니다. 이제 그 시그널에 연관된 시그널 핸들러는 Lock B를 잡으려 할텐데, 따라서 Lock B는 Lock A를 잡은 채로 획득될 것입니다. 따라서, 질문에서 이야기한 것처럼 우리가 Lock B를 잡은 채로 Lock A를 잡으려 한다면 데드락 사이클이 생기게 되는 것입니다.

따라서, 시그널 핸들러 안에서 획득하는 락을 잡고서 시그널들을 블락시키지 않은채로 시그널 핸들러 밖에서 획득되는 락을 잡는 행위는 금지된 행위입니다. □

Quick Quiz 7.11:

시그널 핸들러 안에서 어떻게 시그널들을 블락시킬 수가 있죠? ■

Answer:

그렇게 할 수 있는 가장 간단하고 가장 빠른 방법은 시그널을 설정할 때 `sigaction()` 함수에 전달하는 `struct sigaction` 객체의 `sa_mask` 필드를 사용하는 겁니다. □

Quick Quiz 7.12:

시그널 핸들러들 안에서 락을 잡는 행위가 그렇게 나쁜 생각이라면, 그걸 안전하게 해내기 위한 생각 자체는 대체 왜 하는거죠? ■

Answer:

똑같은 규칙이 운영체제 커널들과 일부 임베디드 어플리케이션들에서 사용되는 인터럽트 핸들러들에도 적용되기 때문입니다.

많은 어플리케이션 환경에서, 시그널 핸들러 안에서 락을 잡으려 하는 행위는 해로운 행위로 여겨져 왔습니다 [Ope97]. 하지만, 그런 분위기가 똑똑한 개발자들이 (보통은 현명하지 못한 짓이지만) 어토믹 오퍼레이션들을 사용해서 직접 만든 락들을 사용해대는 것을 면추게 하자는 않았습니다. 그리고 어토믹 오퍼레이션들은 많은 경우 시그널 핸들러 안에서 사용되어도 전혀 문제가 되지 않습니다. □

Quick Quiz 7.13:

다양한 객체들 사이로 실행 제어가 완전 자유롭게 오가는 객체 지향 어플리케이션이어서 직관적인 락킹 계층, 레이어, 또는 다른 것들이 존재하지 않는 경우⁶라면 그 어플리케이션은 어떻게 병렬화 시켜야 할까요? ■

Answer:

다양한 방법이 있습니다:

- 예를 들면 기계적인 또는 전기적인 기기를 위한 좋은 설계를 찾아내기 위한 시뮬레이션을 통한 모수 검색과 같이 많은 수의 시뮬레이션을 수행하게 되는 경우라면, 그 시뮬레이션을 단일 쓰레드로 수행되도록 두되, 많은 수의 시뮬레이션을 병렬로 수행시키는 겁니다. 이 방법은 객체 지향적 설계를 유지하고, 높은 수준으로 병렬성을 끌어올리며, 또한 동기화 오버헤드 역시 없앱니다.

⁶ “객체 지향 스파게티 코드”라고도 알려져 있죠.

2. 객체들을 여러 그룹들로 분류하는데, 한번에 그룹과 그룹 사이의 객체들 사이의 수행은 없도록 분류를 합니다. 그리고 각 그룹별로 락을 사용하도록 연관시킵니다. 이는 Section 7.1.1.7에서 알아본 한번에 한 락만 잡기 전략의 한 예라고 볼 수 있습니다.

3. 객체들을 여러 그룹들로 분류하는데, 쓰레드들은 모두 한 그룹의 객체들에 대해 어떤 그룹 단위의 순서로만 수행을 할 수 있도록 분류합니다. 그리고 각 그룹별로 락을 하나씩 연관시키고, 그룹들 단위의 락킹 계층을 적용시킵니다.

4. 임의로 선택된 계층을 락들에 적용하고 락을 비순서적으로 획득해야 하는 경우에는 Section 7.1.1.5에서 이야기 했던 조건적 락킹을 적용합니다.

5. 일련의 오퍼레이션들을 수행하기 전에, 그 오퍼레이션들의 수행을 위해 어떤 락들이 획득되어야 할지 예측하고, 그것들을 정말로 어떤 업데이트를 가하기 전에 획득합니다. 그 예측이 틀렸던 것으로 드러난다면, 모든 락들을 내려놓고 경험으로부터 얻은 정보를 바탕으로 수정된 예측을 가지고 다시 락 획득을 시도합니다. 이런 접근법은 Section 7.1.1.6에서 이야기 되었습니다.

6. 트랜잭션 메모리를 사용합니다. 이 접근법은 많은 장점과 단점을 가지고 있는데, Section 17.2에서 다루어질 겁니다.

7. 어플리케이션 자체가 좀 더 동시성에 친화적이라도 될 수성을 합니다. 이는 심지어 어플리케이션이 단일 쓰레드로 수행될 때조차도 빠르게 동작하는 부가적 효과를 만들어낼 수도 있습니다만 어플리케이션 수정을 좀 더 어렵게 만들어 버릴 수도 있습니다.

8. 락킹 이외에 뒤의 챕터들에서 설명할 기법들을 적용해 봅니다. □

Quick Quiz 7.14:

Listing 7.5에 보여진 livelock은 어떻게 예방할 수 있나요? ■

Answer:

Listing 7.4는 몇가지 좋은 힌트를 제공합니다. 많은 경우, livelock들은 락킹 설계를 다시 한번 들여다 봐야 한다는 힌트 역할을 하곤 합니다. 또는, 락킹 설계가 “성장했다면” 첫번째로 들여다봐야 하는 영역이기도 합니다.

그렇다고는 하나, Doug Lea에 의하면 훌륭하고 충분한 접근법은 Section 7.1.1.5에서 설명된 것처럼 조건적

락킹을 하되, Section 7.1.1.6에서 설명된 대로 공유되어 있는 데이터를 수정하기 전에 모든 필요한 락들을 먼저 획득하는 방법과 조합해서 쓰는 것입니다. 특정 크리티컬 섹션 수행이 너무 많이 재시도 되면, 조건 없이 글로벌 락을 잡아버리고, 조건 없이 모든 필요한 락들을 잡아버리는 방법입니다. 이 방법은 deadlock과 livelock 두 가지 모두를 예방할 뿐더러, 이야기한 글로벌 락이 너무 자주 잡혀지지는 않는다는 가정 하에서는 합리적인 수준의 확장성을 갖습니다. □

Quick Quiz 7.15:

Listing 7.6에서 어떤 문제를 발견할 수 있나요? ■

Answer:

여기 두 가지가 있습니다:

1. 대부분의 경우에 대기시간 1초는 너무나 긴 시간입니다. 대기 간격은 대략 해당 크리티컬 섹션을 수행하는데 걸리는 시간 정도에서부터 시작해야 하는데, 이는 일반적으로 마이크로세컨드나 밀리세컨드 영역에 있을 것입니다.
2. 해당 코드는 오버플로우를 체크하지 않고 있습니다. 반면에, 이 버그는 앞서 이야기한 버그에 의해 무효가 됩니다: 32비트로 나타낼 수 있는 최대의 초는 50년이 넘습니다.

□

Quick Quiz 7.16:

락 경쟁정도가 충분히 낮아서 비공정성을 예방할 수 있을 정도가 되는 좋은 병렬 설계를 사용하는 편이 더 낫지 않을까요? ■

Answer:

어떤 면에서는 그렇게 하는게 낫겠습니다만, 가끔은 높은 락 경쟁률을 갖게 되어버리는 설계를 사용하는 편이 더 적합한 상황도 존재합니다.

예를 들어, 매우 드물게 발생하는 에러 조건을 처리하는 시스템을 생각해 봅시다. 이렇게 매우 드물게 발생하는 에러 조건에 대해서는 매우 낮은 성능과 확장성을 갖지만 간단한 에러 처리 설계를 사용하는 게 그런 매우 드물게 발생하는 에러 조건들 가운데 하나가 실제로 발생했을 때에만 효과를 볼하는 복잡하고 디버깅 하기 어려운 설계를 사용하는 것에 비해 최선일 수 있습니다.

그렇다고는 하나, 간단할 뿐만 아니라 에러 조건에 대해서도 효과적인 설계를 만들어내는데 노력은 기울일 가치가 있는데, 문제를 조개는 것이 한 예입니다. □

Quick Quiz 7.17:

락을 잡은 쓰레드는 어떻게 다른 쓰레드로부터 간섭을 받을 수도 있을까요? ■

Answer:

만약 어떤 락에 의해 보호되는 데이터가 그 락과 같은 캐시 라인 위에 위치해 있다면, 다른 CPU들이 그 락을 잡으려 시도하는 행위는 그 락을 잡고 있는 CPU 쪽에 비용이 높은 캐시 미스를 초래시킬 수 있을 겁니다. 이건 false sharing의 특별한 경우라 할 수 있는데, 다른 락들로 보호되는 두개의 변수가 같은 캐시 라인을 공유하고 있으면 벌어지는 현상이기도 합니다. 반대로, 어떤 락이 그 락을 통해 보호되는 데이터와 다른 캐시 라인에 위치해 있다면, 그 락을 잡은 CPU는 그 변수에의 첫번째 접근 때에만 캐시 미스를 겪게 될 것입니다.

물론, 락과 데이터를 별도의 캐시 라인에 위치시키는 것의 단점은, 그렇게 설계된 코드로 변경될 경우 락을 잡기 위한 경쟁이 가열차지 않은 경우에는 단 한번이었을 캐시 미스가 두번의 캐시 미스로 바뀌게 된다는 점입니다. □

Quick Quiz 7.18:

배타적 락을 잡고나서 곧바로 풀어버리는, 즉, 텅 빈 크리티컬 섹션과 같은 것을 갖는 행위가 어떤 의미를 가질 수 있을까요? ■

Answer:

텅 빈 크리티컬 섹션의 사용은 드물긴 하지만, 분명히 존재합니다. 배타적 락의 의미적 기능은 두개의 부분으로 나뉘어진다는게 핵심입니다: (1) 모두가 잘 알고 있는 데이터 보호의 기능과 (2) 주어진 락을 놓는 것으로 같은 락을 획득하기 위해 기다리고 있는 쓰레드에게 던져주는 공지와 같은 메세지 전달의 기능입니다. 텅 빈 크리티컬 섹션은 데이터 보호의 기능 없이 메세지 전달의 기능만을 사용합니다.

이 답의 나머지 부분에서는 텅 빈 크리티컬 섹션의 사용 예를 몇가지 보여 드릴 겁니다만, 이 예제들은 백마법이나 흑마법이 아닌, “회색 마법”으로 여겨져야만 합니다.⁷ 텅 빈 크리티컬 섹션은 그 자체로는 실전에서는 거의 항상 사용되지 않습니다. 하지만, 이 회색 영역 안으로 들어가 봅시다...

텅 빈 크리티컬 섹션이 사용된 역사적 사례 가운데 하나는 리눅스 커널 2.4 버전에서의 네트워킹 스택에서 발견됩니다. 이 사용 패턴은 Section 9.5에서 다뤄지게 될 read-copy update (RCU)의 효과를 비슷하게 따라하기 위한 방법 중 하나라고 이해될 수 있겠습니다.

텅 빈 크리티컬 섹션이라는 관용적 코드는 일부 상황에서 락 경쟁정도를 줄이기 위해 사용될 수도 있습니다. 예를 들어, 멀티쓰레드로 동작하는 사용자 레벨 어플리케이션으로, 각 쓰레드가 전체 일 중에서 쓰레드별 리스트에 매달려서 관리되는 한 단위의 조각을 처리하게 되며, 쓰레드는 다른 쓰레드의 리스트를 건드릴 수

⁷ 이 설명을 위해 도움 준 Alexey Roystan에게 감사를 드립니다.

없는 경우를 생각해 봅시다. 이런 상황에서는 스케줄된 일의 조각들이 모두 완료된 후에 진행되어야 하는 업데이트가 존재할 수 있을 겁니다. 이런 상황을 처리하는 한가지 방법은 일의 조각들을 각 쓰레드에 스케줄 해서, 이 일의 조각들이 모두 완료되면, 업데이트가 진행되도록 하는 것입니다.

일부 어플리케이션에서 쓰레드는 나타났다가 사라졌다가 할 수 있습니다. 예를 들어, 개별 쓰레드는 어플리케이션의 한 사용자에 연관될 수도 있고, 따라서 그 사용자가 로그아웃 하거나 어떤 다른 방법으로 연결이 끊기거나 하게 되면 그 쓰레드 역시 사라질 겁니다. 많은 어플리케이션에서, 쓰레드는 어토믹하게 사라질 수 없습니다: 쓰레드가 사라지기 위해서는 쓰레드 자신 스스로를 특정한 일련의 동작들을 하는 어플리케이션의 다양한 영역들로부터 명시적으로 떨어져야만 합니다. 그런 동작들 중 한 예로는 다른 쓰레드들로부터 들어올 수 있는 이후의 작업 요청을 거절하는 것이 될 수 있겠고, 또 하나 더 그런 동작의 예를 들어보면 쓰레드 자신의 리스트에 아직 남아있는 일거리들을 처분하는 것이 되겠는데, 예를 들면, 이런 남아있는 일거리들을 글로벌한 일거리 처분 리스트에 집어넣어 다른 남아있는 쓰레드들 가운데 하나에 의해 처분되도록 할 수 있겠습니다. (남아있는 일들 각각을 그냥 처리함으로써 그 쓰레드의 일거리 리스트를 비워버리는 건 어떨까요? 주어진 일거리들은 또 다른 일거리를 만들어낼 수도 있기 때문에, 일거리 보관 리스트는 적당한 시간 내에 비워지지 못할 수도 있습니다.)

이런 어플리케이션이 좋은 확장성과 성능을 가지기 위해선, 좋은 락킹 설계가 필요합니다. 흔하게 사용되는 해결책 중 하나는 쓰레드의 정리 과정을 전부 보호하는 하나의 글로벌 락 (이걸 G라고 해보죠) 을 두고 개별적인 정리 동작들을 보호하는 더 잘게 쪼개진 크리티컬 섹션을 위한 락을 또 두는 것입니다.

이제, 사라지려 하는 쓰레드는 자신의 일거리 리스트에 있는 일거리들을 처분하기에 앞서서 향후의 작업 요청들을 분명하게 거절해야 하는데, 그러지 않으면 남아있는 일거리들을 처분한 이후에도 추가적인 일거리들이 들어닥쳐서 일거리 처분 과정이 무효가 되게 만들 것이기 때문입니다. 그런 점을 고려해 쓰레드가 사라지는 과정을 간략히 슈도코드로 표현해 보면 다음과 같을 것입니다:

1. 락 G를 잡습니다.
2. 커뮤니케이션을 보호하는 락을 잡습니다.
3. 다른 쓰레드로부터의 향후의 커뮤니케이션을 거절합니다.
4. 커뮤니케이션을 보호하는 락을 풀어줍니다.

5. 글로벌 일거리 처분 리스트를 보호하는 락을 잡습니다.

6. 해당 쓰레드의 일거리 리스트에 남아 있는 모든 일거리들을 글로벌한 처분될 일거리 리스트에 옮깁니다.

7. 글로벌한 처분될 일거리 리스트를 보호하는 락을 풀어줍니다.

8. 락 G를 풀어줍니다.

물론, 먼저 스케줄된 일거리들이 모두 처리되기를 기다리는 쓰레드는 사라지는 쓰레드 역시 염두해 두어야 합니다. 이 상황을 보기 위해서, 어떤 사라지려 하는 쓰레드가 다른 쓰레드들과의 이후의 커뮤니케이션을 거절한 직후에 모든 앞서 스케줄된 일거리들이 완료되기를 기다리고 있는 쓰레드를 생각해 봅시다. 쓰레드들은 다른 쓰레드의 일거리 리스트에 접근할 수 없다는 점을 생각해보면, 이 쓰레드는 사라지려 하는 쓰레드의 일거리들이 완료되기를 어떻게 기다릴 수 있을까요?

간단한 방법 가운데 하나는 이 쓰레드가 G를 획득하고 글로벌한 처분될 일거리 리스트를 지키는 락을 잡고 나서, 그 리스트의 일거리들을 자신의 리스트로 가져오는 것입니다. 그리고 나서는 두 락을 모두 놓아주고, 자신의 일거리 리스트의 끝에 일거리 하나를 집어넣고, 각 쓰레드의 일거리 리스트 (자신의 것을 포함해) 안에 들어있는 일거리들이 완료되기를 기다리는 겁니다.

이 방법은 많은 경우에 잘 동작합니다만, 글로벌한 처분될 일거리 리스트로부터 가져오는 각각의 일거리에 대해 가져올 때마다 특별한 처리가 필요하다면 G에의 경쟁도가 지나치게 될 겁니다. 그런 지나친 경쟁을 막기 위한 한가지 방법은 G를 획득한 직후에 놔버리는 겁니다. 그렇게 되면 앞서 스케줄된 모든 일거리들이 완료되길 기다리는 과정은 다음과 같이 될 것입니다:

1. 글로벌 카운터의 값을 1로 두고 조건 변수의 값을 0으로 초기화 시킵니다.
2. 모든 쓰레드들에 메세지를 보내서 쓰레드들이 어토믹하게 글로벌 카운터의 값을 증가시키고 일거리를 대기열에 집어넣게 합니다. 그 일거리는 어토믹하게 글로벌 카운터의 값을 감소시키고 그 감소된 결과값이 0이라면 조건 변수의 값을 1로 만듭니다.
3. G를 잡는데, 이로 인해 사라지려 하는 쓰레드가 있다면 사라지는 작업이 끝날 때까지 기다리게 될 것입니다. 한번에 하나의 쓰레드만 사라질 수 있기 때문에, 모든 남아있는 쓰레드들은 이미 앞의 단계에서 보낸 메세지를 받았을 것입니다.

4. G 를 놓습니다.
5. 글로벌한 치분할 일거리 리스트를 보호하는 락을 잡습니다.
6. 글로벌한 치분할 일거리 리스트의 일거리들을 이 쓰레드의 리스트로 옮기고, 옮기는데 필요한 일이 있다면 합니다.
7. 글로벌한 치분할 일거리 리스트를 보호하는 락을 놓아줍니다.
8. 이 쓰레드의 리스트에 추가적으로 일거리 하나를 넣습니다. (앞에서와 마찬가지로, 이 일거리는 자동적으로 글로벌 카운터의 값을 어토믹하게 감소 시킬 것이고, 그 결과가 0이라면 조건 변수의 값을 1로 만듭니다.)
9. 조건 변수가 1이 되기를 기다립니다.

이 과정이 완료되면, 모든 앞서 스케줄된 일거리들은 완료되어 있을 것이 보장됩니다. 이와 같이, 텅 빈 크리티컬 섹션들은 락킹을 데이터 보호만이 아니라 메세지 보내는 용도로 사용하는 것입니다. □

Quick Quiz 7.19:

VAX/VMS DLM 0] reader-writer 락을 다른 방법으로 모방해낼 수도 있을까요? □

Answer:

실제로 여러가지 방법이 있습니다. 한가지 방법은 null, protected-read, 그리고 exclusive 모드를 사용하는 것이겠습니다. 또 다른 방법은 null, protected-read, 그리고 concurrent-write 모드를 사용하는 것일 테고요. 세번째 방법은 null, concurrent-read, 그리고 exclusive 모드를 사용하는 것이겠지요. □

Quick Quiz 7.20:

Listing 7.7 의 코드는 황당할 정도로 복잡하군요! 왜 그냥 조건적으로 하나의 글로벌 락을 잡지 않나요? □

Answer:

조건적으로 하나의 글로벌 락을 잡는 방법은 실제로 잘 동작합니다만, 비교적 작은 수의 CPU 들을 사용할 때만 그렇습니다. 수백개의 CPU 를 가진 시스템에서 이게 왜 문제가 될 수 있는지 보려면, Figure ?? 를 보시고 8개에서 1,000 개로 CPU 들이 늘어나면 그 딜레이가 어떻게 될지 한번 생각해 보세요. □

Quick Quiz 7.21:

잠깐만요! Listing 7.7 의 line 16 에서 토너먼트에 “승리” 했다면, do_force_quiescent_state() 의 모든 일을

해야만 하잖아요. 어떻게 이걸 승리라고 할 수 있어요, 진짜로? □

Answer:

어떻게 그러냐구요? 이건 그저 동시성에 있어서, 삶이 그러하듯이, 게임을 진행하기 전에 승리함이 의미하는 바가 정확히 무엇인지 알기 위해 주의를 기울여야 한다는 걸 보여줄 뿐입니다. □

Quick Quiz 7.22:

왜 C 언어에서 기본적으로 제공하는 0으로의 초기화 메커니즘을 사용하지 않고 Listing 7.8 의 line 2 에 보여진 것처럼 명시적으로 초기화를 하는 거죠? □

Answer:

이 기본적인 초기화 메커니즘은 어떤 함수의 범위 안의 auto 변수로 할당된 락에 대해서는 적용되지 않을 것이기 때문입니다. □

Quick Quiz 7.23:

왜 Listing 7.8 의 line 7-8 의 안쪽 루프를 귀찮게 수행해야 하나요? 왜 그냥 간단하게 line 6 에서 계속해서 어토믹한 값 교환 오퍼레이션을 수행하지 않는거죠? □

Answer:

락이 잡혀 있고 여러 쓰레드들이 그 락을 잡으려 시도한다고 생각해봅시다. 이런 상황에서, 이 쓰레드들이 모두 어토믹 값 교환 오퍼레이션을 하면서 루프를 반복한다면, 이들은 그 락을 포함하고 있는 캐시 라인을 쓰레드들 사이에서 계속 주고받을 것이고, 이는 곧 CPU 사이의 로드를 의미합니다. 반면에, 이 쓰레드들이 line 7-8 의 안쪽 루프에서 루프를 돌게 되면 각자의 캐시만을 가지고 루프를 돌게 되어서 CPU 사이의 로드는 위협이 되지 않을 정도가 될 것입니다. □

Quick Quiz 7.24:

Listing 7.8 의 line 14 에서는 왜 그냥 간단하게 락에 0 값을 저장하지 않는거죠?

Quick Quiz 7.25:

■

Answer:

그렇게 하는 것도 문제 없는 구현이긴 합니다만, 그 저장 작업에 ACCESS_ONCE() 가 사용되고, 그 뒤에 메모리 배리어가 놓여질 때에만 그렇습니다. 메모리 배리어는 xchg() 오퍼레이션이 사용될 경우에는 필요치 않은데 이 오퍼레이션은 전의 값을 리턴해야 한다는 사실 때문에 자체적으로 전체 메모리 배리어를 내포하고 있기 때문입니다. □

Quick Quiz 7.26:

카운터의 값이 오버플로우 되어 초기화 되는 경우를 고려하면서 어떻게 하나의 카운터가 다른 카운터보다 큰지를 판단할 수 있나요? ■

Answer:

C 언어에서는 다음과 같은 macro를 사용해서 이 문제를 정확하게 처리할 수 있습니다:

```
#define ULONG_CMP_LT(a, b) \
(ULONG_MAX / 2 < (a) - (b))
```

부호를 갖는 정수들을 간단히 빼기 연산하는게 나을 것 같아 보일 수 있지만, C 언어에서 부호를 갖는 것들의 오버플로우에 대한 결과는 정의되어 있지 않기 때문에 그 방법은 피해져야만 합니다. 예를 들어, 만약 컴파일러가 하나의 값은 양수이고 다른 하나는 음수란 것을 안다면, 컴파일러는 단순히 양수가 음수보다 크다고 판단할 권리를 갖고 있는데, 양수에서 음수를 빼는 결과가 오버플로우를 일으키고 따라서 음수가 나올 수 있더라도 그려합니다.

컴파일러가 어떻게 두 숫자의 부호를 알 수 있을까요? 앞의 값 할당과의 비교로부터 추론해 낼 수 있습니다. 이 경우, CPU 별 카운터들이 부호가 존재한다면, 컴파일러는 항상 그것들이 값을 증가시킨다는 것을 추론할 수 있고, 그렇게 되면 이 값들은 결코 음수가 되지 않는다고 가정할 수 있습니다. 이런 가정은 컴파일러가 유감스러운 코드를 생성하는 결과를 이끌어 낼 수 있을 겁니다 [McK12c, Reg10]. ■

Quick Quiz 7.27:

카운터 사용과 플래그 사용 중 뭐가 더 나을까요? ■

Answer:

플래그를 사용하는 방법이 일반적으로 더 적은 캐시 미스를 낼 겁니다만, 더 나은 방법은 두 가지 모두 시도해 보고 당장 적용해야 하는 특정한 워크로드에서 뭐가 더 잘 동작하는지 보는 것입니다. ■

Quick Quiz 7.28:

어떻게 비명시적인 존재 보장에 의존하는게 버그를 만들어낼 수 있나요? ■

Answer:

비명시적 존재 보장의 잘못된 사용에 의해 초래될 수 있는 일부 버그들이 여기 있습니다:

1. 어떤 프로그램이 한 글로벌 변수의 주소를 한 파일에 쓰고, 그 후에 똑같은 프로그램의 새로운 실행 흐름이 그 주소를 읽고는 그 주소의 값을 읽어보려 시도합니다. 이는 그 프로그램의 기존 수행에서의 내용을 기반으로 다음 수행에서의 구성을 예측할 수 없게 하는 주소 공간 임의 추출 (address space randomization) 기법으로 인해 실패할 수 있습니다.

2. 어떤 모듈은 자신의 변수들 가운데 하나의 주소를 다른 모듈에 위치해 있는 한 포인터에 기록해 두고는 그 포인터가 가리키는 값을 모듈이 내려간 (unloaded) 다음에 읽어보려 시도할 수 있습니다.

3. 어떤 함수는 자신의 스택 위에 할당된 변수들 가운데 하나의 주소를 어떤 글로벌 포인터에 기록해 두고는 그 함수가 리턴한 후에 어떤 다른 함수가 그 포인터가 가리키는 값을 읽어보려 시도할 수 있습니다.

그 외에도 여러가지 추가적인 가능성이 있을 수 있다고 확신합니다. ■

Quick Quiz 7.29:

우리가 삭제해야 하는 원소가 Listing 7.9 의 line 8 의 리스트의 첫번째 원소가 아니면 어떻게 하죠? ■

Answer:

이건 체이닝을 사용하지 않는 매우 간단한 해시 테이블이므로, 주어진 bucket 의 원소는 첫번째 원소 뿐입니다. 독자 여러분은 이 간단한 예제 해시 테이블에 체이닝을 적용해 보셔도 좋을 겁니다. ■

Quick Quiz 7.30:

Listing 7.9 에서 어떤 경쟁 조건이 발생할 수 있나요? ■

Answer:

다음과 같은 일련의 이벤트들을 생각해 봅시다:

1. Thread 0 이 `delete(0)` 을 호출하고, 그림의 line 10에 도달해서 락을 얻습니다.
2. Thread 1 이 동시적으로 `delete(0)` 를 호출하고, line 10에도착합니다만 Thread 0 이 이미 락을 잡고 있으니 그 락을 기다리며 루프를 돋습니다.
3. Thread 0 이 line 11-14 를 수행하고 해시테이블에서 그 원소를 삭제하고 락을 해제하고, 그 원소를 메모리 해제시킵니다.
4. Thread 0 는 수행을 계속해서 메모리를 할당받는데 이 때 정확히 방금 해제한 메모리 블락을 받습니다.
5. Thread 0 는 이제 이 메모리 블락을 어떤 다른 타입의 구조체로 초기화 시킵니다.

6. Thread 1 의 `spin_lock()` 은 스핀락이라 생각했던 `p->lock` 이 더이상 스핀락이 아니기 때문에 실패 합니다.

존재에 대한 보장이 없기 때문에 해당 데이터 원소의 정체성은 어떤 쓰레드가 line 10에서 그 원소의 락을 얻기 위해 시도중인 상황 중에도 바뀔 수가 있는 겁니다! □

G.8 Data Ownership

Quick Quiz 8.1:

어떤 형태의 데이터 소유권이 C 나 C++ 를 사용해서 (예를 들어, `pthreads` 를 사용해서) 공유 메모리 병렬 프로그램을 만들 때 방지하기가 극단적으로 어려울까요? ■

Answer:

함수 안에서의 `auto` 변수들의 사용입니다. 기본적으로, 이것들은 현재 함수를 수행하고 있는 쓰레드에 소유됩니다. □

Quick Quiz 8.2:

Section 8.1에서 보인 예제에 남아있는 동기화 작업은 무엇이 있을까요? ■

Answer:

`sh` 의 & 오퍼레이터를 통한 쓰레드들의 생성과 `sh` 의 `wait` 명령을 통한 쓰레드 종료 기다리기입니다.

물론, 프로세스들이 예를 들어 `shmget()`이나 `mmap()` 시스템 콜을 이용해 명시적으로 메모리를 공유한다면 이 공유 메모리 영역을 접근하거나 업데이트하는 데에는 명시적인 동기화가 필요할 겁니다. 프로세스들은 또한 다음의 프로세스간 통신 메커니즘들 중 어떤 것이든 사용할 수도 있을 겁니다.

1. System V 세마포어.
2. System V 메세지 큐.
3. UNIX-domain 소켓.
4. TCP/IP, UDP, 그리고 모든 다른 것들의 호스트를 포함한 네트워킹 프로토콜.
5. 파일 락킹.
6. `O_CREAT` 과 `O_EXCL` 플래그와 함께 사용되는 `open()` 시스템콜.
7. `rename()` 시스템콜의 사용.

사용 가능한 동기화 메커니즘 전체의 리스트를 만드는 건 독자의 몫으로 둘텐데, 이는 굉장히 긴 리스트가 될 겁니다. 놀랍도록 많은 수의 예상치 못한 시스템콜들이 동기화 메커니즘으로 나타날 수 있습니다. □

Quick Quiz 8.3:

Section 8.1에서 보여진 예제에 어떤 공유된 데이터가 있나요? ■

Answer:

이건 철학적인 질문입니다.

“아니오”라는 답을 원하는 사람들은 프로세스들이 정의에 의해 메모리를 공유하지 않는다고 주장할 수도 있을 겁니다.

“예”라고 대답하고 싶은 사람들은 공유 메모리를 필요로 하지 않는 많은 동기화 메커니즘들의 리스트를 나열하고 커널은 공유된 상태를 가질 것임을 이야기 할 수 있고, 아마도 심지어는 프로세스 ID (PID) 의 할당은 공유된 데이터에 해당된다고 주장할 수도 있습니다.

그런 주장들은 매우 지적인 행위이고 불행한 학교 친구나 동료들에게서 점수를 따고 지적이라는 느낌을 받을 수 있는 훌륭한 방법이기도 하며, (특히!) 유용한 일이 이루어지기를 막아버리는 행위입니다. □

Quick Quiz 8.4:

각각의 쓰레드가 자신의 쓰레드별 변수만을 읽을 수 있지만 다른 쓰레드의 인스턴스들에는 쓰기를 할 수도 있는 부분적 데이터 소유권도 말이 될까요? ■

Answer:

놀랍게도, 그렇습니다. 한가지 예는 쓰레드들이 다른 쓰레드의 메일함에 메세지를 보내고, 각 쓰레드는 자신이 보낸 메세지를 일단 그 메세지가 읽혀졌다면 지워야 할 책임을 갖는 간단한 메세지 전달 시스템입니다. 그런 알고리즘의 구현은 다른 알고리즘들을 비슷한 소유권 패턴으로 구분해 보는 일과 함께 독자의 몫으로 남겨두겠습니다. □

Quick Quiz 8.5:

함수를 전달하는데 POSIX 시그널 외에 어떤 다른 메커니즘이 사용될 수 있을까요? ■

Answer:

그런 메커니즘에는 상당히 많은 것들이 있는데, 다음의 것들을 포함합니다:

1. System V 메세지 큐.
2. 공유 메모리 디큐 (Section 6.1.2 를 참고하세요).
3. 공유 메모리 메일함.

4. UNIX-domain 소켓.
5. RPC, HTTP, XML, SOAP, 그 외 여러가지 높은 레벨의 프로토콜들과 결합되어 사용될 수도 있는 TCP/IP 또는 UDP.

전체 리스트의 완성은 성실한 독자들의 몫으로 남겨둘 텐데, 그 리스트는 굉장히 길 수 있다는 점을 경고해 듭니다. □

Quick Quiz 8.6:

하지만 Listing 5.4 의 line 15-32 에 보여진 `eventual()` 함수의 어떤 데이터도 실제로는 `eventual()` 쓰레드에게 소유되어 있지 않습니다! 이게 어떻게 데이터 소유권인가요??? ■

Answer:

핵심 문구는 “데이터로의 권한을 소유한다”입니다. 이 경우, 질문되는 권한은 해당 그림의 line 1에 정의된 쓰레드별 `counter` 변수에 접근할 수 있는 권한을 말합니다. 이 상황은 Section 8.2에서 설명된 것과 비슷한 상황입니다.

하지만, 정말로 `eventual()` 쓰레드에 의해 소유되는 데이터도 존재하는데, 해당 그림의 line 17과 18에 정의되어 있는 `t`와 `sum` 변수들입니다.

정해진 쓰레드의 다른 예를 보려면, 리눅스 커널의 커널 쓰레드들을 보면 되는데, 예컨대 `kthread_create()` 와 `kthread_run()` 으로 생성되는 것들을 보시기 바랍니다. □

Quick Quiz 8.7:

쓰레드별 데이터의 완전한 사유화를 유지하면서 좋은 정확도를 얻을 수도 있을까요? ■

Answer:

네. 한가지 방법은 `read_count()` 가 자신의 쓰레드별 변수를 더하도록 하는 것입니다. 이렇게 되면 완전한 소유권과 성능을 유지하지만 정확도에 있어서는 아주 조금 개선이 될텐데, 특히나 매우 많은 수의 쓰레드들이 존재하는 시스템에서 그럴 겁니다.

또 다른 방법은 `read_count()` 가 함수 전달을 사용하는 것으로, 예를 들면 쓰레드별 시그널과 같은 형태가 되겠습니다. 이 방법은 정확도를 매우 많이 개선시킬 것입니다만, `read_count()` 의 성능에 대해선 상당한 비용을 갖게 될겁니다.

하지만, 이런 방법들 모두 카운터 업데이트의 일반적인 경우에 있어서의 캐시 라인 바운싱 (cache-line bouncing) 을 제거해주는 이점을 가질 겁니다. □

G.9 Deferred Processing

Quick Quiz 9.1:

해제 후 사용 체크를 왜 신경쓰죠? ■

Answer:

버그 발견 가능성을 크게 늘리기 위해서입니다. 하나의 타입의 구조체를 할당받고 해제할 뿐인 작은 `torture-test` 프로그램 (`routetorture.h`) 은 놀랍도록 많은 양의 해제 후 사용 실수들을 제어할 수 있습니다. Page 186의 Figure 11.4 를 한번 보시고, 버그를 찾을 확률을 높이는 것의 중요성을 더 알기 위해서 Page 188 부터 시작하는 Section 11.6.4에서의 토론을 살펴보시기 바랍니다. □

Quick Quiz 9.2:

Listing 9.3 의 `route_del()` 은 해제될 원소를 찾는 과정을 보호하기 위해 레퍼런스 카운트를 사용하지 않는 이유가 뭐죠? ■

Answer:

그 과정은 이미 락으로 보호되고 있기 때문에, 추가적인 보호는 필요하지 않기 때문입니다. □

Quick Quiz 9.3:

Figure 9.2에서 “ideal” 선은 왜 똑바로 증가하지 않고 계단 형태로 증가하죠? ■

Answer:

하이퍼쓰레딩 때문입니다. 이 시스템에서, 코어 위에서의 하드웨어 쓰레드들은 연속되는 CPU 번호를 갖습니다. 또한, 이 특정한 포인터를 따라가는, 낮은 캐시 미스 확률의 워크로드는 하나의 하드웨어 쓰레드가 자신의 코어의 거의 모든 자원을 소모할 수 있도록 하는 것으로 보입니다. 더 많은 계산 작업을 갖는 워크로드는 각 코어의 두번째 하드웨어 쓰레드로부터 더 많은 이득을 얻을 것이라 예상할 수 있을 겁니다. □

Quick Quiz 9.4:

요즘과 같은 시대에, Figure 9.2 는 왜 겨우 여덟개의 CPU 까지만 사용하는 거죠??? ■

Answer:

레퍼런스 카운팅의 끔찍한 확장성을 고려해보면, 누가 여덟개보다 많은 CPU 를 필요로 하겠어요? CPU 네개 까지만 해도 요점을 이야기하는데 충분합니다! 하지만, 더 많은 CPU 를 원하는 분들은 Chapter 10 를 참고하시기 바랍니다. □

Quick Quiz 9.5:

동시성이 “레퍼런스 카운팅의 유용성을 분명히 저하시켰다”면, 리눅스 커널은 왜 그렇게 레퍼런스 카운터를 많이 사용하는거죠? ■

Answer:

그 문장은 “유용성을 저하시켰다”고 했지, “유용성을 없앴다”고는 하지 않았습니다. 그렇죠?

리눅스 커널이 높은 동시성이 존재하는 환경에서 레퍼런스 카운팅의 장점을 가져오기 위해 사용하는 방법들을 이야기하는 Section 13.2를 보기 바랍니다. □

Quick Quiz 9.6:

Figure 9.4의 `hp_store()`는 왜 데이터 원소로의 접근을 두번이나 간접적으로 하는거죠? 왜 `void *`가 아니라 `void **`인 건가요? ■

Answer:

`hp_store()`는 동시의 수정에 대해서 체크를 해봐야 하기 때문입니다. 이 일을 하기 위해서는 그 원소로의 포인터로의 포인터가 필요한데, 그게 있으면 해당 원소로의 포인터로의 수정이 있었는지 검사할 수 있기 때문입니다. □

Quick Quiz 9.7:

`hp_store()`의 호출자는 실패했을 때 왜 데이터 접근을 처음부터 다시 시작해야 하는거죠? 데이터 구조체가 매우 크다면 좀 비효율적이지 않나요? ■

Answer:

어떻게 보면 좀 비효율적일 수도 있겠습니다만 분명한 사실은 정확성을 위해 그런 처음부터의 재시작이 반드시 필요하다는 점입니다. 이를 확실히 보기 위해, 원소 A, B, 그리고 C를 가지고 있는 해저드 포인터로 보호되는 링크드 리스트가 다음의 일련의 이벤트들을 겪는다고 생각해 봅시다:

1. 쓰레드 0 가 원소 B로의 해저드 포인터를 저장합니다 (아마도 원소 A를 거쳐 원소 B를 찾아왔을 겁니다).
2. 쓰레드 1 이 리스트로부터 원소 B를 삭제하는데, 이를 위해 원소 B에서 원소 C로의 포인터를 이 삭제 작업을 표시하기 위해 특수한 `HAZPTR_POISON` 값으로 설정합니다. Thread 0은 원소 B로의 해저드 포인터를 가지고 있으므로, 아직 정리될 수 없습니다.
3. 쓰레드 1 이 리스트에서 원소 C를 삭제합니다. 원소 C를 레퍼런스 하는 해저드 포인터들이 존재하지 않으므로, 원소 C는 곧바로 메모리 해제될 수 있습니다.

4. 쓰레드 0 이 이제 없어진 원소 B의 다음 원소로의 해저드 포인터를 얻으려 합니다만, `HAZPTR_POISON` 값을 보게 되고, 따라서 0을 리턴해서, 호출자가 리스트의 시작점부터 탐색을 다시 시작하도록 강제합니다.

따라서 처음부터 다시 탐색하는게 좋은 방법인데, 이렇게 하지 않는다면 쓰레드 0은 이제는 제거된 원소 C에 액세스를 시도할 수 있으며, 이는 임의의 끔찍한 메모리 오염을 일으키는 결과를 만들어낼 수 있는데, 특히나 원소 C를 위해 사용되던 메모리가 어떤 다른 목적으로 재할당 되었다면 특히 그럴 것이기 때문입니다.

그와는 별개로, 해저드 포인터의 재시작은 최소한의 메모리 사용량을 유지할 수 있도록 함을 이해하시기 바랍니다. 현재 해저드 포인터로 레퍼런스 되고 있지 않은 오브젝트는 곧바로 해제될 수 있습니다. 대조적으로, Section 9.5에서는 `read-side` 재시도를 방지하지만 (`read-side` 오버헤드도 최소화 시킵니다), 훨씬 큰 메모리 사용량을 갖는 메커니즘을 이야기할 겁니다. □

Quick Quiz 9.8:

해저드 포인터들에 대한 논문들은 각각의 포인터의 아래 비트들을 지워진 원소들을 마크하기 위해 사용한다고 하는데, `HAZPTR_POISON`은 뭔가요? ■

Answer:

출간된 논문의 해저드 포인터 구현들은 그 삽입과 삭제를 위해 `non-blocking` 동기화 기법들을 사용했습니다. 이런 기법들은 데이터 구조체를 가로지르며 읽기를 하는 쓰레드들이 업데이트를 하는 쓰레드들이 그들의 업데이트를 완료하도록 “도움”을 줄 것을 필요로 하는데, 이 말은 읽기를 하는 쓰레드들은 삭제된 원소의 다음 원소를 봐야만 한다는 뜻입니다.

반면에, 우리는 업데이트 작업들을 동기화 시키는데 락킹을 사용할 것인데, 이렇게 되면 읽기를 하는 쓰레드들이 업데이트를 하는 쓰레드들이 그들의 업데이트를 완료할 수 있도록 돋는 일을 해줄 필요가 없어져서 포인터들의 아래쪽 비트들을 놔둘 수 있게 해줍니다. 이 방법은 읽기를 하는쪽 코드를 좀 더 간단하고 빠르게 해줍니다. □

Quick Quiz 9.9:

하지만 해저드 포인터에 있는 이런 제약사항들은 다른 형태의 레퍼런스 카운팅에도 똑같이 적용되는 거 아닌가요? ■

Answer:

이런 제약사항은 레퍼런스 획득이 실패할 수 있는 레퍼런스 카운팅 메커니즘들에만 적용됩니다. □

Quick Quiz 9.10:

논문 “Structured Deferral: Synchronization via Procrastination” [McK13] 은 해저드 포인터가 이상적인 경우에 가까운 성능을 보인다는 걸 보였습니다. Figure 9.3 에선 무슨 일이 일어난거죠???

Answer:

첫째로, Figure 9.3 는 1차원적 y-축을 갖는데 반해 “Structured Deferral” 논문에서의 그래프는 로그스케일 y-축을 갖습니다. 다음으로, 그 논문은 가벼운 일을 하는 해시 테이블을 사용했고, Figure 9.3 의 수행은 10개 원소의 간단한 링크드 리스트를 사용했는데, 이는, 해저드 포인터가 이 워크로드에서 “Structured Deferral” 논문에서의 것보다 더 큰 메모리 배리어 페널티를 받았다는 뜻입니다. 마지막으로, 그 논문은 더 커다랗고 오래된 x86 시스템을 쓴 반면, Figure 9.3 의 결과를 만드는데 사용된 시스템은 더 신형이고 더 작은 시스템이었습니다.

또한, 비대칭적 배리어 쌍의 사용 [Mic08, Cor10b, Cor18] 이 가능한 시스템에서는 읽기 쪽 해저드 포인터 메모리 배리어를 없애기 위해 사용될 것이 제안되었는데 [Gol18], 이렇게 되면 해저드 포인터의 성능을 이 그림에서 보인 것보다 더 향상시킬 수 있을 겁니다.

항상 그렇듯, 비용은 경우에 따라 다를 수 있습니다. 이 성능의 차이를 놓고 보면, 해저드 포인터가 (메모리 배리어 오버헤드가 최소한 캐시 미스 페널티와 겹칠만큼) 매우 커다란 데이터 구조체에서나 해시 테이블과 같이 탐색 작업이 최소한의 해저드 포인터만을 필요로 하는 경우에는 가장 이상적인 성능을 줄 것임이 분명합니다. □

Quick Quiz 9.11:

왜 이 시퀀스 락에 대한 토론은 Chapter 7 에서, *locking* 의 하나로써 다루어지지 않았던 거죠???

Answer:

시퀀스 락 메커니즘은 실제로는 시퀀스 카운트와 락킹이라는 두개의 별개의 동기화 메커니즘들의 조합입니다. 사실, 시퀀스 카운트 메커니즘은 리눅스 커널에서 `write_seqcount_begin()` 과 `write_seqcount_end()` 기능들을 사용해 별개로 사용될 수도 있습니다.

하지만, `write_seqlock()` 과 `write_sequnlock()` 기능의 조합은 리눅스 커널에서 훨씬 많이 사용됩니다. 더 중요한건, 더 많은 사람들이 “시퀀스 카운트” 라고 말하는 것보다는 “시퀀스 락”이라고 말하는 걸 더 쉽게 이해할 것이라는 점입니다.

그래서 이 섹션은 사람들이 제목으로부터 이게 뭐에 대한 것인지를 이해할 수 있도록 “Sequence Locks” 라고 이름지어졌고, “Deferred Processing” 으로 표현한 이유는 (1) “시퀀스 락”에서 “시퀀스 카운트”의 강조를 위함과 (2) “시퀀스 락”은 단순한 락보다는 더 많은 의미를 갖기 때문입니다. □

Quick Quiz 9.12:

Listing 9.9 의 `read_seqbegin()` 은 왜 내부적으로 가장 낮은 자리의 비트를 검사하고 재시도를 하지 않고 어차피 망할 읽기를 시작하는 건가요???

Answer:

그렇게 하는 것도 합법적인 구현이 될겁니다. 하지만, 워크로드에 읽기가 대부분이라면, 일반적인 경우의 성공적인 읽기의 오버헤드가 증가할 것인데, 이는 생산적이지 못한 일입니다. 하지만, 충분히 많은 업데이트가 존재하고 충분히 높은 읽기의 오버헤드가 존재한다면, 그런 검사를 `read_seqbegin()` 내부에서 하는 것도 괜찮을 겁니다. □

Quick Quiz 9.13:

Listing 9.9 의 line 26 에서의 `smp_mb()` 는 왜 필요한 건가요???

Answer:

만약 그게 없다면, 컴파일러 또는 CPU 가 이 `read_seqretry()` 함수 호출 전의 크리티컬 섹션을 이 함수 뒤로 옮겨버릴 수도 있기 때문입니다. 그렇게 되면 시퀀스 락이 크리티컬 섹션을 보호하지 못하게 만들어 버릴 겁니다. `smp_mb()` 기능은 그런 재배치를 막아줍니다. □

Quick Quiz 9.14:

Listing 9.9 의 코드는 완화된 형태의 메모리 배리어를 사용할 수는 없을까요???

Answer:

리눅스 커널의 오래된 버전들에서라면, 안됩니다.

최신의 리눅스 커널에서는, line 16 은 `READ_ONCE()` 대신에 `smp_load_acquire()` 를 사용할 수 있고, 그렇게 되면 line 17 에서의 `smp_mb()` 는 없어질 수 있을 겁니다. 비슷하게, line 41 은 `smp_store_release()` 를 사용할 수 있는데, 예를 들면 다음과 같은 겁니다:

```
smp_store_release(&slp->seq, READ_ONCE(slp->seq) + 1);
```

이는 line 40 의 `smp_mb()` 를 없앨 수 있게 해줄 겁니다. □

Quick Quiz 9.15:

시퀀스 락킹을 사용하는 경우, 업데이트 쓰레드들이 읽기 쓰레드들이 진행 못하게 하는 걸 막는 건 무엇일까요??

Answer:

그런 건 없습니다. 이것은 시퀀스 락킹의 약점들 가운데 하나이고, 그 결과로, 시퀀스 락킹은 읽기가 대부분인 환경에서만 사용되어야 합니다. 만약 읽기를 하는 쪽이

스타베이션에 빠지는 것도 괜찮은 상황이라면, 시퀀스 락킹 업데이트들을 가지고 더 폭넓게 사용해도 좋을 겁니다! □

Quick Quiz 9.16:

다른 뭔가 쓰기 쓰레드들을 직렬화 시켜서 락이 필요치 않다면 어떻게 되죠? ■

Answer:

그런 경우라면, 리눅스 커널의 `seqcount_t` 가 그렇듯이 `->lock` 필드가 사라질 수 있을 겁니다. □

Quick Quiz 9.17:

Listing 9.9 의 line 2 의 `seq` 는 왜 `unsigned` 가 아니라 `unsigned long` 인가요? 무엇보다, `unsigned` 가 리눅스 커널에서 충분히 좋은 것이라면 모두에게도 충분히 좋지 않을까요? ■

Answer:

전혀 그렇지 않습니다. 리눅스 커널은 다음과 같은 일련의 이벤트들을 무시하는 것을 가능하게 하는 특별한 속성들을 가지고 있습니다:

1. Thread 0 가 `read_seqbegin()` 을 실행하고, line 16에서 `->seq` 를 얻어오는데, 그 값은 짹수여서, 호출자에게 리턴합니다.
2. Thread 0 가 자신의 `read-side` 크리티컬 섹션을 실행하기 시작합니다만, 곧 오랫동안 cpu 를 빼앗깁니다.
3. 다른 쓰레드들이 반복적으로 `write_seqlock()` 과 `write_sequnlock()` 을 호출하는데, `->seq` 의 값이 오버플로우 되어서 Thread 0 가 얻어온 값과 같아질 때까지 반복합니다.
4. Thread 0 가 실행을 재개하고, 자신의 `read-side` 크리티컬 섹션을 이제 비일관적인 데이터와 함께 마무리짓습니다.
5. Thread 0 는 `read_seqretry()` 를 호출하는데, 부정확하게도 Thread 0 가 이 시퀀스 락으로 보호되는 데이터의 일관적인 모습만 보았다고 결론내리게 됩니다.

리눅스 커널은 매우 드물게 업데이트 되는 것들에 대해서만 시퀀스 락킹을 사용하는데, 하루의 시각 정보가 그런 경우입니다. 이 정보는 아무리 잣아도 1 밀리세컨드에 한번 업데이트 되며, 따라서 카운터를 오버플로우 시키는데에는 7주일이 필요할 겁니다. 만약 어떤 커널 쓰레드가 7주일간 cpu 를 빼앗겼다면, 이 리눅스 커널의 soft-lockup 코드가 그동안 2분에 한번씩 경고를 띠웠을 겁니다.

반면, 64-bit 카운터를 사용한다면 설령 업데이트가 매 나노세컨드마다 일어난다고 해도 오버플로우를 하는데 500년 이상이 필요합니다. 따라서, 이 구현은 `->seq` 의 타입에 64 비트 시스템에서는 64 비트인 타입을 사용합니다. □

Quick Quiz 9.18:

이 버그는 고쳐질 수 있을까요? 달리 말해서, 동시의 삽입, 삭제, 탐색을 지원하는 링크드 리스트를 보호하는 동기화 메커니즘으로 시퀀스 락 하나만 사용할 수 있을까요? ■

Answer:

이를 가능하게 하는 한가지 방법은 `read-only` 액세스를 포함해 모든 액세스들을 `write_seqlock()` 과 `write_sequnlock()` 으로 감싸버리는 것입니다. 물론, 이 방법은 모든 `read-side` 병렬성을 없애버릴 것이고, 커다란 락 컨텐션을 초래하며, 더 나아가서 간단한 락킹처럼 쉽게 구현될 수 있을 겁니다.

`Read-side` 액세스를 보호하는데 `read_seqbegin()` 과 `read_seqretry()` 를 사용하는 방법을 찾아낸다면, 그 방법이 다음의 이벤트 시퀀스도 잘 처리할 수 있는지 확인해 보시기 바랍니다:

1. CPU 0 가 링크드 리스트를 순회하고, 리스트 원소 A로의 포인터를 집어냅니다.
2. CPU 1 이 원소 A 를 리스트에서 제거하고 해제합니다.
3. CPU 2 가 관계없는 데이터 구조체를 하나 할당하는데, 이 과정에서 원소 A 가 사용하고 있던 메모리를 받아오게 됩니다. 원소 A 의 `->next` 포인터를 저장하는데 사용되던 영역은 이제 이 관계없는 데이터 구조 내에서 floating-point 수를 저장하는데 사용됩니다.
4. CPU 0 가 원소 A 의 `->next` 포인터였던 것을 보게 되는데, 무작위적인 비트를 보게 되고, 따라서 `segmentation fault` 가 날 겁니다.

이런 종류의 문제를 해결하기 위해서는 “타입-안전 메모리”가 필요한데, 이에 대해서는 Section 9.5.3.7 에서 다루도록 하겠습니다. 하지만 이 경우, 시퀀스 락에 대해서 또 다른 동기화 메커니즘을 사용해야 할 겁니다! □

Quick Quiz 9.19:

하지만 Section 9.4 의 시퀀스 락 역시 읽기 쓰레드들과 업데이트 쓰레드들이 동시에 일을 할 수 있도록 하지 않던가요? ■

Answer:

맞는 말이고 아닌 말이기도 합니다. 시퀀스 락의 읽기 쓰레드들은 쓰기 쓰레드들과 동시에 수행될 수 있지만, 이런 상황이 발생할 때마다, `read_seqretry()` 기능이 읽기 쓰레드는 다시 수행을 시도하도록 강제할 겁니다. 이는 시퀀스 락을 사용하면서 업데이트 쓰레드와 동시에 수행되는 읽기 쓰레드가 하는 일은 모두 취소되고 다시 수행될 것을 의미합니다. 따라서 시퀀스 락을 사용하는 읽기 작업은 업데이트 작업과 동시에 수행 될 수 있지만, 그런 경우에 실제로는 어떤 일도 만들어내지 못합니다.

반면에, RCU 읽기 쓰레드는 동시에 RCU 업데이트 쓰레드가 존재하더라도 의미있는 일을 처리해낼 수 있습니다. □

Quick Quiz 9.20:

`list_add_rcu()` 와 정확히 똑같은 시간에 `list_for_each_entry_rcu()` 이 수행되면 segfault 가 날 수 있을 것 같은데, 이걸 무엇이 방지해 주나요? ■

Answer:

리눅스가 돌아가는 모든 시스템에서 포인터로의 로드와 스토어는 모두 어토믹한데, 즉, 포인터로의 스토어가 같은 포인터로부터의 로드와 같은 시점에 일어난다면, 이 로드는 초기값이나 저장된 값을 가져오지, 그 두 값이 섞여진 값을 가져오는 일은 결코 없습니다. 또한, `list_for_each_entry_rcu()` 는 항상 리스트를 앞으로만 움직이지, 결코 뒤로 움직이지는 않습니다. 따라서, `list_for_each_entry_rcu()` 는 `list_add_rcu()` 를 통해 들어온 원소를 보거나 보지 않을 뿐이지 만 어떤 경우든 적합하게 잘 형성된 리스트를 볼 겁니다. □

Quick Quiz 9.21:

리스트의 버전이 두개보다 많을 수 있도록 하기 위해서는 삭제 예제를 어떻게 수정해야 할까요? ■

Answer:

이를 가능하게 하는 한가지 방법은 Listing G.2 에 보인 것처럼 하는 것입니다.

Listing G.2: Concurrent RCU Deletion

```

1 spin_lock(&mylock);
2 p = search(head, key);
3 if (p == NULL)
4   spin_unlock(&mylock);
5 else {
6   list_del_rcu(&p->list);
7   spin_unlock(&mylock);
8   synchronize_rcu();
9   kfree(p);
10 }
```

이 코드는 여러개의 동시에 수행되는 삭제 작업들이 `synchronize_rcu()` 에서 기다리게 될수도 있음을 의미합니다. □

Quick Quiz 9.22:

하나의 리스트는 한 순간에 RCU 버전들을 몇개까지 가질 수 있을까요? ■

Answer:

동기화 설계에 따라 달라집니다. 업데이트를 보호하는 세마포어가 grace period 에 걸쳐 잡혀 있다면, 옛날 버전과 새로운 버전, 최대 두개의 버전이 있을 수 있을 겁니다.

하지만, 검색, 업데이트, 그리고 `list_replace_rcu()` 만이 락으로 보호되고 있어서 Listing G.2 보인 코드에서처럼 `synchronize_rcu()` 가 락의 바깥에 있다고 생각해 봅시다. 더 나아가서 수많은 쓰레드들이 거의 동시에 RCU 교체 기능을 수행했고, 이 읽기 쓰레드들은 또한 데이터 구조를 계속해서 지나다니고 있다고 생각해 봅시다.

그러면 다음과 같은 일련의 이벤트들이 Figure 9.14의 마지막 상태로부터 발생할 수 있습니다.

1. 쓰레드 A 가 리스트를 횡단하면서 5,2,3 원소로의 레퍼런스를 얻습니다.
2. 쓰레드 B 가 5,2,3 원소를 새로운 5,2,4 원소로 교체하고, 자신의 `synchronize_rcu()` 호출이 리턴하길 기다립니다.
3. 쓰레드 C 가 리스트를 횡단하면서 5,2,4 원소로의 레퍼런스를 얻습니다.
4. 쓰레드 D 가 5,2,4 원소를 새로운 5,2,5 원소로 교체하고, 자신의 `synchronize_rcu()` 호출이 리턴하길 기다립니다.
5. 쓰레드 E 가 리스트를 횡단하면서 5,2,5 원소로의 레퍼런스를 얻습니다.
6. 쓰레드 F 가 5,2,5 원소를 새로운 5,2,6 원소로 교체하고, 자신의 `synchronize_rcu()` 호출이 리턴하길 기다립니다.
7. 쓰레드 G 가 리스트를 횡단하면서 5,2,6 원소로의 레퍼런스를 얻습니다.
8. 그리고 앞의 두 스텝들이 빠르게 계속해서 반복되어서 모든 쓰레드들이 `synchronize_rcu()` 호출이 리턴하길 기다립니다.

따라서, 얼마든지 많은 버전들이 존재할 수 있습니다만, 메모리 크기와 얼마나 많은 업데이트들이 하나의 grace period 안에 완료될 수 있느냐에 그 수가 제한됩니다. 하지만 그렇게 자주 업데이트 되는 데이터 구조체들은 RCU 를 사용하기에 적합한 후보가 아닐 수 있음을 알아두시기 바랍니다. 그렇다면 해도, RCU 는 필요할 때에는 높은 비율의 업데이트를 처리할 수 있습니다. □

Quick Quiz 9.23:

`rcu_read_lock()` 과 `rcu_read_unlock()` 함수는 스픈하지도 블락하지도 않는데 어떻게 RCU 업데이트 쓰레드들이 RCU 읽기 쓰레드들을 대기시킬 수가 있나요? ■

Answer:

특정 RCU 업데이트 쓰레드에 의해 가해진 수정사항은 연관된 CPU 가 해당 데이터를 포함하는 캐시 라인들을 무효화 하도록 만들 것이고, 동시에 수행중인 RCU 읽기 쓰레드들을 수행중인 해당 CPU 들이 비싼 캐시 미스를 마주하게 만들 겁니다. (동시에 수행중인 읽기 쓰레드에게 비싼 캐시 미스를 만들지 않고 데이터 구조에 변경을 가할 수 있는 알고리즘을 설계할 수 있을까요? 또는 뒤 따르는 읽기 쓰레드들에게?) □

Quick Quiz 9.24:

RCU QSBR 은 왜 이상적 결과와 동일한 결과를 보이지 않는 거죠? ■

Answer:

`rcu_dereference()` 는 컴파일러의 최적화를 조금 제약할 수 있어서, 아주 약간 느린 코드를 만들어낼 수 있습니다. 이 영향은 일반적으로는 별로 심각하지 않을 것입니다만, 각각의 탐색이 약 13 나노세컨드를 더 필요로 하게 되는데, 이는 코드 생성의 작은 차이가 느껴지지도 못할 만큼 충분히 짧은 시간입니다. 이 차이는 약 1.5 % 부터 약 11.1 % 까지 나오는데, RCU QSBR 코드가 “이상적인” 코드는 할 수 없는 동시의 업데이트도 처리할 수 있다는 점을 생각하면 상당히 작은 차이입니다.

C11 `memory_order_consume` 로드 [Smi15] 가 언젠가는 `rcu_dereference()` 에게 더 낮은 비용에 필요한 보호를 해주는 날이 올 것을 기대하고 있습니다. □

Quick Quiz 9.25:

RCU QSBR 의 read-side 성능이 이렇게 좋은데, 왜 다른 종류의 userspace RCU 를 신경써야 하죠? ■

Answer:

RCU QSBR 은 어플리케이션에게 경우에 따라서는 불가능한 제약을 강제하는데, 예를 들어 어플리케이션 내의

각각의 모든 쓰레드가 quiescent state 를 정규적으로 통과해야 하는 식입니다. 무엇보다도, 이는 RCU QSBR 이 라이브러리를 만드는 사람에게는 도움이 될 수 없음을 의미하는데, 그런 사람들은 다른 종류의 userspace RCU 를 사용하는게 좋을 겁니다 [MDJ13c]. □

Quick Quiz 9.26:

이게 뭐죠? 3GHz 에서 클락 시간은 300 피코세컨드 가 넘는데 대체 어떻게 RCU 는 100 펫토세컨드의 오버헤드를 갖는다고 제가 믿을 수 있을 거라고 생각하세요? ■

Answer:

먼저, 이 측정을 위해 사용된 내부의 루프가 다음과 같다고 생각해 보세요:

```
1 for (i = 0; i < CSCOUNT_SCALE; i++) {
2     rCU_read_lock();
3     rCU_read_unlock();
4 }
```

다음으로, `rcu_read_lock()` 과 `rcu_read_unlock()` 이 실질적으로 수행하는 코드가 다음과 같다고 생각해 봅시다:

```
1 #define rCU_read_lock() do { } while (0)
2 #define rCU_read_unlock() do { } while (0)
```

그리고 컴파일러가 이 루프를 다음과 같이 바꿔게 하는 간단한 최적화를 한다고 생각해 보세요:

```
1 i = CSCOUNT_SCALE;
```

따라서 100 펫토세컨드의 “측정”은 단순히 고정된 시간 측정 오버헤드를 `rcu_read_lock()` 과 `rcu_read_unlock()` 호출을 담고 있는 루프의 수행 횟수로 나눈 값일 뿐입니다. 그리고 따라서, 이 측정은 실제로 애러인데, 실제로 수십수백배의 애러율입니다. 앞의 `rcu_read_lock()` 와 `rcu_read_unlock()` 의 정의에서 알 수 있듯이, 실제 오버헤드는 정확히 제로입니다.

언제까지나 100 펫토세컨드의 시간 측정이 과하게 추측된 걸로 판명되는 건 아닐 것이 분명합니다! □

Quick Quiz 9.27:

크리티컬 섹션 오버헤드가 늘어나면 왜 `rwlock` 의 오버헤드와 가변성이 모두 줄어드는 거죠? ■

Answer:

크리티컬 섹션 오버헤드가 증가하면 그 아래에 위치한 `rwlock_t` 를 얻기 위한 경쟁이 줄어들기 때문입니다. 하지만, 이 `rwlock` 오버헤드는 단일 CPU 에서는 캐시

쓰래싱 오버헤드 때문에 그렇게 크게 떨어지지는 않을 겁니다. □

Quick Quiz 9.28:

이 데드락 내성에 어떤 예외가 있을까요, 그리고 만약 그렇다면, 어떤 일련의 이벤트들이 데드락을 이끌어 낼 수 있을까요? ■

Answer:

RCU read-side 기능들이 연관된 데드락 사이클을 만들 어내는 한가지 방법은 다음과 같은 (불법적인) 일련의 코드들을 통해 가능합니다:

```
rcu_read_lock();
synchronize_rcu();
rcu_read_unlock();
```

여기서의 `synchronize_srcu()` 는 전부터 존재한 모든 RCU read-side 크리티컬 섹션이 완료되기 전까지 리턴할 수 없습니다만, 이 자체가 RCU read-side 크리티컬 섹션 안에 들어가 있고 그 크리티컬 섹션은 `synchronize_rcu()` 가 리턴하기 전까지 끝날 수 없습니다. 결국 이건 고전적인 self-deadlock 의 결과를 이끌어냅니다—읽기 모드로 reader-writer 락을 잡은채로 쓰기 모드로 락을 잡으려 하면 똑같은 효과가 나타날 겁니다.

이 self-deadlock 시나리오는 RCU QSRB 에는 적용되지 않는다는 점을 알아두셔야 하는데, 이는 `synchronize_rcu()` 에 의해 수행되는 컨텍스트 스위치는 이 CPU에 정지한 상태처럼 행동할 것이어서 grace period 가 완료되게 할 것이기 때문입니다. 하지만, 이는 오히려 더 안좋은 케이스로, 이 RCU read-side 크리티컬 섹션에 의해 사용되던 데이터가 해당 grace period 의 완료로 인해 메모리에서 해제될 수 있기 때문입니다.

짧게 말하자면, RCU read-side 크리티컬 섹션 내에서 동기적인 RCU update-side 기능들을 실행하지 마세요. □

Quick Quiz 9.29:

데드락과 우선순위 역전 모두에 내성이 있다고요??? 사실이라기엔 너무 좋은 이야기 같은데요. 제가 이게 가능하다는걸 어떻게 믿을 수 있을까요? ■

Answer:

정말로 잘 동작합니다. 무엇보다, 이게 동작하지 않는다면, 리눅스 커널은 동작하지 못하겠죠. □

Quick Quiz 9.30:

근데 잠깐만요! 이건 RCU 를 reader-writer 락킹 대용으로 하려 할 때 쓸법한 코드와 완전 똑같잖아요! 뭐가 새로운 거죠? ■

Answer:

이는 장난감 예제의 법칙의 효과입니다: 어떤 특정 포인트 이후로는 해당 코드는 똑같아 보일 겁니다. 이 코드를 어떻게 생각하느냐가 단 하나의 차이입니다. 하지만, 이 차이점은 매우 중요할 수 있습니다. 이 중요성에 대해 한가지만 예를 들어 보자면, RCU 를 제한적인 레퍼런스 카운팅 방법으로 생각하고 있다면, 업데이트가 RCU read-side 크리티컬 섹션들과 배타적으로 수행될 거라 생각하는 실수를 하지 않을 겁니다.

하지만 RCU 를 reader-writer 락킹의 대체제로 생각하는 건 종종 쓸모 있는데, 예를 들면 reader-writer 락킹을 RCU 로 대체할 때입니다. □

Quick Quiz 9.31:

6 CPU 근처에서 refcnt 오버헤드의 증가도가 확 떨어지는건 왜그렇죠? ■

Answer:

NUMA 효과 때문일 겁니다. 하지만, 여러 바들로 보여진 것처럼, refcnt 선을 측정하는데 사용된 값들은 상당한 편차를 가지고 있습니다. 사실, 일부 케이스에 있어서 표준편차는 측정된 값의 10 %를 초과합니다. 따라서 해당 오버헤드의 큰 차이는 통계적 탈선일 수도 있습니다. □

Quick Quiz 9.32:

우리가 삭제하려는 원소가 Listing 9.21 의 line 9 의 리스트의 첫번째 원소가 아니라면 어떡하죠? ■

Answer:

Listing 7.9 에서와 마찬가지로, 이건 체이닝을 하지 않는 매우 간단한 해시 테이블이어서 하나의 버킷에 들어갈 수 있는 원소는 첫번째 원소 뿐입니다. 이 해시 테이블을 완전한 체이닝을 사용하도록 바꿔보는 건 독자 여러분의 몫으로 두겠습니다. □

Quick Quiz 9.33:

Listing 9.21 의 line 17 에서 락을 놓기 전에 line 15 에서 RCU read-side 크리티컬 섹션을 빠지는게 왜 안전한거죠? ■

Answer:

첫째로, line 14 에서의 두번째 체크는 어떤 다른 CPU 가 이 원소를 우리가 락을 잡는 동안 삭제했을 수 있기 때문에 필요합니다. 하지만, 우리가 이 락을 잡는 동안 RCU read-side 크리티컬 섹션에 들어와 있다는 사실은 이 원소가 재할당되고 이 해시 테이블에 다시 삽입되지는 못함을 보장합니다. 더 나아가서, 일단 우리가 락을 잡았다면, 그 락 자체는 이 원소의 존재를 보장하게 되고, 따라서 우리는 더이상 RCU read-side 크리티컬 섹션 안에 머무를 필요가 없습니다.

원소의 키를 다시 체크해 볼 필요가 있을까라는 질문에 대한 답은 독자 여러분의 뜻으로 남겨두겠습니다. □

Quick Quiz 9.34:

Listing 9.21 의 line 23 에서 RCU read-side 크리티컬 섹션을 빠져나가는 건 왜 line 22 에서 락을 내려놓기 전에 될 수 없나요? ■

Answer:

우리가 이 두 라인의 순서를 뒤집는다고 생각해 봅시다. 그러면 이 코드는 다음의 일련의 이벤트들에 취약해집니다:

1. CPU 0 가 `delete()` 를 실행하고, 삭제될 원소를 찾아낸 후 line 15 를 수행합니다. 아직 항목의 삭제를 실제로 하지는 않았고, 이제 곧 할 참입니다.
2. CPU 1 이 동시에 `delete()` 를 실행하고 같은 원소를 삭제하려 합니다. 하지만, CPU 0 는 아직 락을 잡고 있으므로, CPU 1 은 line 13 에서 기다립니다.
3. CPU 0 이 line 16 과 17 을 수행하고 line 18 에서 CPU 1 이 RCU read-side 크리티컬 섹션을 나오기를 기다립니다.
4. CPU 1 은 이제 락을 획득하지만 CPU 0 가 이미 해당 원소를 삭제했으므로 line 14 에서의 테스트가 실패합니다. CPU 1 은 이제 line 22 (line 23 과 이 Quick Quiz 를 위해 바꾼) 를 수행해서 RCU read-side 크리티컬 섹션을 나옵니다.
5. CPU 0 는 이제 `synchronize_rcu()` 로부터 리턴하고 따라서 line 19 를 수행해서 이 항목을 메모리 해제하고 재사용 가능 리스트로 옮깁니다.
6. CPU 1 이 이제 이미 재사용이 가능한 다른 종류의 데이터 구조체에 사용되기 위해 재할당 될 수도 있는 항목을 위한 락을 놓으려 합니다. 이건 치명적인 메모리 오염 에러입니다.

□

Quick Quiz 9.35:

하지만 여러 쓰레드에 상당히 긴 RCU read-side 크리티컬 섹션이 존재해서 어떤 특정한 시점에든 시스템의 최소 하나의 쓰레드는 RCU read-side 크리티컬 섹션을 수행하고 있으면 어떡하죠? 그게 어떤 데이터가 `SLAB_DESTROY_BY_RCU` 슬랩에서 시스템으로 반환되는 걸 막아서 OOM 이벤트를 유발하지는 않을까요? ■

Answer:

분명, 최소 하나의 쓰레드는 항상 RCU read-side 크리티컬 섹션에 존재하는, 굉장히 긴 기간이 존재할 수 있습니다. 하지만, Section 9.5.3.7 의 설명에서의 키워드는 “사용중인”과 “전부터 존재한”입니다. 특정 RCU read-side 크리티컬 섹션은 컨셉적으로 그 크리티컬 섹션의 시작 시점에 사용된 데이터에 한해서만 레퍼런스를 가질 수 있도록 됨을 명심하기 바랍니다. 더 나아가서, 슬랩은 자신의 데이터 원소들이 모두 해제되기 전까지는 시스템에 반환될 수 없고, 사실, RCU grace period 는 그것들이 모두 해제되기 전까지는 시작할 수가 없습니다.

따라서, 슬랩 캐시는 그 슬랩의 마지막 원소가 해제되기 전에 시작한 RCU read-side 크리티컬 섹션들이 완료될 때까지만 기다리면 됩니다. 이 말은 마지막 원소가 해제된 뒤에 시작된 어떤 RCU grace period 도 수행을 계속한다는 뜻입니다—그 슬랩은 그 grace period 가 끝난 후에 시스템에 반환될 것입니다. □

Quick Quiz 9.36:

`nmi_profile()` 함수가 preemption 당할 수 있다고 해 봅시다. 이 예제가 제대로 동작하도록 하기 위해 뭘 바꿔야 할까요? ■

Answer:

한가지 가능한 방법은 `rcu_read_lock()` 과 `rcu_read_unlock()` 을 `nmi_profile()` 내에서 사용하고, `synchronize_sched()` 를 `synchronize_rcu()` 로 바꾸는 것으로, 아마도 Listing G.3 와 같은 모습이 될겁니다.

□

Quick Quiz 9.37:

Table 9.3 의 일부 셀들은 왜 느낌표 (“!”) 를 가지고 있나요? ■

Answer:

느낌표와 함께 표시된 API 멤버 (`rcu_read_lock()`, `rcu_read_unlock()`, 그리고 `call_rcu()`) 만이 과거 90년대 중반에 Paul E. McKenney 가 신경썼던 리눅스 RCU API 의 멤버입니다. 이 시절에, 그는 그가 RCU 에 대해 알아야 할 것들을 모두 알고 있다는 잘못된 인상을 가지고 있었습니다. □

Quick Quiz 9.38:

많은 수의 RCU read-side 크리티컬 섹션들이 `synchronize_rcu()` 실행을 무기한 블록시키는 걸 어떻게 막을 수 있나요? ■

Listing G.3: Using RCU to Wait for Mythical Preemptible NMIs to Finish

```

1 struct profile_buffer {
2     long size;
3     atomic_t entry[0];
4 };
5 static struct profile_buffer *buf = NULL;
6
7 void nmi_profile(unsigned long pcvalue)
8 {
9     struct profile_buffer *p;
10
11     rCU_read_lock();
12     p = rCU_dereference(buf);
13     if (p == NULL) {
14         rCU_read_unlock();
15         return;
16     }
17     if (pcvalue >= p->size) {
18         rCU_read_unlock();
19         return;
20     }
21     atomic_inc(&p->entry[pcvalue]);
22     rCU_read_unlock();
23 }
24
25 void nmi_stop(void)
26 {
27     struct profile_buffer *p = buf;
28
29     if (p == NULL)
30         return;
31     rCU_assign_pointer(buf, NULL);
32     synchronize_rcu();
33     kfree(p);
34 }

```

Answer:

RCU read-side 크리티컬 섹션들이 synchronize_rcu() 실행을 무기한 블록하는 걸 막을 필요가 전혀 없는데, synchronize_rcu() 실행은 전부터 존재한 RCU read-side 크리티컬 섹션들만 기다리면 되기 때문입니다. 따라서 각 RCU read-side 크리티컬 섹션이 한정된 길이를 갖는다면, 아무 문제가 없습니다. □

Quick Quiz 9.39:

synchronize_rcu() API 는 전부터 존재한 인터럽트 핸들러들이 모두 완료되길 기다리죠, 맞죠? □

Answer:

전혀 그렇지 않아요! 그리고 preemption 가능한 RCU를 사용하고 있다면 특허나 그렇지 않습니다! 그리고 싶다면 synchronize_irq()를 사용해야 합니다. 또는, 대안적으로 synchronize_rcu()가 기다리기를 바라는 인터럽트 핸들러 안에 rCU_read_lock()과 rCU_read_unlock()를 위치시킬 수 있겠습니다. □

Quick Quiz 9.40:

이것들을 섞어서 활용하면 어떻게 되나요? 예를 들어, rCU_read_lock()과 rCU_read_unlock()을 RCU read-side 크리티컬 섹션을 구분하는데 사용하지만

call_rcu_bh() 를 RCU callback 을 위해 사용한다고 하면요? □

Answer:

call_rcu_bh() 가 실행되는 시점에 rCU_read_lock_bh() 와 rCU_read_unlock_bh()로 구분된 RCU read-side 크리티컬 섹션들이 존재하지 않는다면 RCU는 이 콜백을 곧바로 수행해도 되는 권한을 갖게 되어서, 해당 RCU read-side 크리티컬 섹션이 사용중인 데이터 구조체를 메모리에서 해제해버릴 수도 있습니다! 이건 단순히 이론적인 가능성입니다: rCU_read_lock()과 rCU_read_unlock()으로 구분지어졌고 오랫동안 동작중인 RCU read-side 크리티컬 섹션은 이런 실패에 취약합니다.

하지만, rCU_dereference() 함수들은 모든 RCU 변종들에 적용됩니다. (변종별 rCU_dereference()를 만들려는 시도도 있었지만, 그건 너무 혼란스러웠습니다.) □

Quick Quiz 9.41:

하드웨어 인터럽트 핸들러들은 묵시적인 rCU_read_lock_bh() 의 보호 아래 있다고 생각되어도 되겠죠? □

Answer:

전혀 그렇지 않아요! 그리고 preemption 가능한 RCU를 사용중일 때에는 특허나 그렇지 않습니다! “rcu_bh”로 보호되는 데이터 구조체를 인터럽트 핸들러 내에서 접근하려 한다면, 명시적으로 rCU_read_lock_bh() 와 rCU_read_unlock_bh()를 사용해야 합니다. □

Quick Quiz 9.42:

RCU Classic 과 RCU Sched 를 섞어서 사용하면 어떻게 되나요? □

Answer:

Non-PREEMPT 나 PREEMPT 커널에서는 이 두개의 일은 우연히 섞이게 되는데, 그런 커널 빌드에서 RCU Classic 과 RCU Sched 는 같은 구현으로 매핑되기 때문입니다. 하지만, 이런 조합은 -rt 패치셋을 사용하는 PREEMPT_RT 빌드에서는 치명적인데 Realtime RCU의 read-side 크리티컬 섹션들은 preemption 당할 수 있어서 synchronize_sched() 가 RCU read-side 크리티컬 섹션이 rCU_read_unlock() 호출을 하기 전에 리턴할 수 있기 때문입니다. 이는 데이터 구조체가 그 구조체를 사용하는 read-side 크리티컬 섹션이 끝나기 전에 메모리 해제될 수 있게 해서 커널의 보험 통계적 리스크를 무척 증가시킬 수 있습니다.

실제로, RCU Classic 과 RCU Sched 의 분리는 preemption 가능해야 하는 RCU read-side 크리티컬 섹션들로부터 영감을 받았습니다. □

Quick Quiz 9.43:

일반적으로, 모든 전부터 존재한 인터럽트 핸들러들을 기다리는데에 `synchronize_sched()`에 의존해선 안 됩니다, 맞죠? □

Answer:

맞습니다! -rt 리눅스는 쓰레드로 도는 인터럽트 핸들러를 사용하기 때문에, 인터럽트 핸들러 내부에서의 컨텍스트 스위치가 있을 수 있습니다. `synchronize_sched()`는 각 CPU가 컨텍스트 스위치를 할 때까지만 기다리기 때문에, 특정 인터럽트 핸들러가 완료되기 전에 리턴을 할 수도 있습니다.

특정 인터럽트 핸들러가 완료되기까지 기다려야 한다면, 그대신 `synchronize_irq()`를 사용하거나 기다리기 원하는 인터럽트 핸들러 안에 명시적으로 RCU read-side 크리티컬 섹션을 넣어야 합니다. □

Quick Quiz 9.44:

`call_srcu()` 사용을 조심해야 하는 이유는 무엇일까요? □

Answer:

하나의 태스크는 SRCU 콜백들을 매우 빠르게 등록할 수 있습니다. SRCU가 읽기 쓰레드들이 임의의 기간동안 블록될 수 있도록 허용함을 생각하면, 이는 임의의 커다란 양의 메모리를 소모할 것을 알 수 있습니다. 반대로, 동기적인 `synchronize_srcu()` 인터페이스에서는 주어진 태스크는 다음 grace period를 기다리는 걸 시작하기 전에 주어진 grace period를 기다리는 것을 마무리해야만 합니다. □

Quick Quiz 9.45:

어떤 조건에서 `synchronize_srcu()`가 SRCU read-side 크리티컬 섹션 내에서 안전하게 사용될 수 있을까요? □

Answer:

원론적으로, 특정 `srcu_struct` 와 함께, `synchronize_srcu()`는 어떤 다른 `srcu_struct`를 사용하는 SRCU read-side 크리티컬 섹션 안에서 사용될 수 있습니다. 하지만, 실제에서는 이런 짓을 하는건 거의 분명하게 나쁜 생각입니다. 세부적으로는 Figure ??에 보인 코드가 여전히 데드락을 일으킬 수 있을 것입니다. □

Quick Quiz 9.46:

`list_del_rcu()`는 왜 `next` 와 `prev` 두 포인터를 모두 파괴하지 않는거죠? □

Answer:

`next` 포인터를 파괴하는 행위는 이 포인터를 사용해야

Listing G.4: Multistage SRCU Deadlocks

```

1 idx = srcu_read_lock(&ssa);
2 synchronize_srcu(&ssb);
3 srcu_read_unlock(&ssa, idx);
4
5 /* . . . */
6
7 idx = srcu_read_lock(&ssb);
8 synchronize_srcu(&ssa);
9 srcu_read_unlock(&ssb, idx);

```

하는 동시의 RCU 읽기 쓰레드들과 간섭될 수 있습니다. 하지만, RCU 읽기 쓰레드들은 `prev` 포인터의 사용으로부터 숨겨져 있으므로 이건 안전하게 파괴될 수 있습니다. □

Quick Quiz 9.47:

일반적으로, `rcu_dereference()`에 사용되는 모든 포인터는 반드시 항상 `rcu_assign_pointer()`로 업데이트 되어야만 합니다. 이 규칙에 예외는 뭐가 있을까요? □

Answer:

그런 예외 가운데 하나는 여러 원소가 연결된 데이터 구조체가 다른 CPU들에서 접근할 수 없는 상태에서 하나의 유닛으로써 초기화되었고 하나의 `rcu_assign_pointer()`가 이 데이터 구조체로의 글로벌 포인터를 설정하는데 사용된 경우입니다. 비록 그 구조체가 글로벌하게 보여진 후에 일어나는 그런 할당들은 반드시 `rcu_assign_pointer()`를 사용해야 하지만, 초기화 시점의 포인터 할당은 `rcu_assign_pointer()`를 사용할 필요가 없습니다.

하지만, 이 초기화 코드가 매우 자주 실행되는 코드 수행경로에 있는게 아니라면, 이론적으로는 불필요할지라도 `rcu_assign_pointer()`를 사용하는게 현명할 것입니다. 어떤 “사소한” 변경이 그 초기화는 혼자서 행하게 된다는 소중한 가정을 무효화 시키기는 매우 쉽습니다. □

Quick Quiz 9.48:

이런 횡단과 업데이트 기능들이 어떤 RCU API 패밀리 멤버들과 함께 사용된다 하더라도 어떤 문제는 없나요? □

Answer:

어떤 경우에는 “sparse” 와 같은 자동화된 코드 검사기 (또는 사람이)가 어떤 종류의 RCU read-side 크리티컬 섹션이 어떤 RCU 횡단 기능들과 연관되어 있는지 알기 어려울 수 있습니다. 예를 들어, Listing G.5에 보여진 것과 같은 코드를 생각해 봅시다.

`rcu_dereference()` 기능은 RCU Classic 크리티컬 섹션 안에 있을까요? RCU Sched 크리티컬 섹션 안에 있을까요? 이걸 알아내려면 어떻게 해야할까요? □

Listing G.5: Diverse RCU Read-Side Nesting

```

1 rCU_read_lock();
2 preempt_disable();
3 p = rCU_dereference(global_pointer);
4
5 /* . . . */
6
7 preempt_enable();
8 rCU_read_unlock();

```

Quick Quiz 9.49:

Grace period 를 기다리기 전에 락을 내려놓거나 grace period 를 기다리는 대신에 `call_rcu()` 같은 걸 사용하는 게 어떤가요? ■

Answer:

이 저자들은 linearizable tree 오퍼레이션들을 지원하고자 했고, 따라서 동시의 트리에 대한 추가, 삭제, 그리고 탐색은 전체적으로 동의된 순서로 수행된 것으로 나타나야 했습니다. 이들의 탐색 트리에서는, 이 grace period 들 사이로 락을 잡을 것을 필요로 했습니다. (대부분의 경우에는 linearizability 를 버리는게 낫겠습니다만, linearizability 는 놀랍도록 대중적인 (그리고 비싼!) 요구사항입니다.) □

Quick Quiz 9.50:

Listing 5.5 (`count_end.c`) 에 보인 통계적 카운터의 구현은 `read_count()` 안에서 합계를 구하는 것을 보호하기 위해 글로벌 락을 사용했는데 이게 부족한 성능과 음의 확장성을 일으켰습니다. `read_count()` 가 훌륭한 성능과 좋은 확장성을 제공할 수 있게 하기 위해 RCU 를 어떻게 적용해 볼 수 있을까요. (`read_count()` 의 확장성은 모든 쓰레드의 카운터들을 스캔해야 한다는 필요성으로 인해 제한되어진다는 점을 명심하세요.) ■

Answer:

힌트: 글로벌 변수 `finalcount` 와 배열 `counterp[]` 를 하나의 RCU 로 보호되는 구조체 안에 넣으세요. 초기화 때, 이 구조체는 할당되고 모두 0과 NULL 로 설정될 겁니다.

`inc_count()` 함수는 바뀔 필요가 없을 겁니다.

`read_count()` 함수는 `final_mutex` 를 잡는 대신에 `rcu_read_lock()` 를 사용할 것이고, 현재 구조체로의 레퍼런스를 얻어오는데 `rcu_dereference()` 를 사용해야 할 겁니다.

`count_register_thread()` 함수는 이 새로 생성된 쓰레드와 연관된 배열 원소를 그 쓰레드의 쓰레드별 counter 변수로의 레퍼런스로 설정할 겁니다.

`count_unregister_thread()` 함수는 새로운 구조체를 할당받고, `final_mutex` 를 잡은 후, 기존의 구조체를 새로운 것으로 복사하고, 나가는 쓰레드의 counter

변수를 전체 값에 더하고, 이 counter 변수로의 포인터를 NULL 로 만든 후, 이 새로운 구조체를 과거의 것의 자리에 설치하기 위해 `rcu_assign_pointer()` 를 사용한 후, `final_mutex` 를 풀고, grace period 를 기다린 후, 마지막으로 기존의 구조체 메모리를 반환해야 합니다.

이게 정말 동작할까요? 그 이유는 무엇이죠?

더 자세한 내용을 위해서는 page 241 의 Section 13.3.1 를 참고하세요. □

Quick Quiz 9.51:

Section 5.4.6 는 디바이스들을 제거하기 위해 I/O 액세스를 카운트하는 일을 처리하는 한쌍의 코드 조각을 보였습니다. 이 코드 조각은 reader-writer 락을 잡아야 하는 이유로 (I/O 를 시작하는) 빠른 수행 경로의 높은 오버헤드 문제를 겪었습니다. 여기에 훌륭한 성능과 확장성을 가져오기 위해 RCU 를 어떻게 사용할 수 있을까요? (I/O 액세스를 하는 일반적인 경우의 첫번째 코드 조각의 성능이 디바이스 제거 코드 조각의 것보다 훨씬 더 중요함을 명심하세요.) ■

Answer:

힌트: 이 reader-writer 락의 read 권한 획득을 RCU read-side 크리티컬 섹션들로 바꾸고, device 제거 코드를 이에 맞게 조정하세요. 이 문제에 대한 하나의 해결책을 위해선 Page 242 의 Section 13.3.2 를 참고하세요. □

G.10 Data Structures

Quick Quiz 10.1:

하지만 많은 종류의 해시 테이블들이 존재하고, 여기 설명된 체인 기반 (chained) 해시 테이블은 그 중 하나의 종류일 뿐입니다. 왜 체인 사용 해시 테이블에 집중하는 걸까요? ■

Answer:

체인 사용 해시 테이블은 완전히 파티셔닝 적용 가능하고, 따라서 동시적 사용에 잘 맞습니다. 다른 완전히 파티셔닝 적용 가능한 해시 테이블들도 존재하는데, 예를 들면 split-ordered list [SS06] 가 있습니다만, 그런 것들은 훨씬 더 복잡합니다. 따라서 우리는 체인 사용 해시 테이블부터 시작하겠습니다. □

Quick Quiz 10.2:

하지만 Listing 10.3 의 line 15-18 에서의 두번의 비교는 키가 unsigned long 에 들어맞는 경우라면 비효율적이지 않나요? ■

Answer:

실제로 그렇습니다! 하지만, 해시 테이블들은 상당히 자주 키에 `unsigned long`에 들어맞아야 할 이유가 없는 문자열과 같은 정보를 저장하기도 합니다. 해시 테이블 구현을 키가 항상 `unsigned long`에 들어맞는 경우에 맞춰 간소화 시키는 것은 독자 여러분의 연습으로 두겠습니다. □

Quick Quiz 10.3:

단순히 bucket 들의 수를 늘리는 대신에 이미 있는 bucket 들을 캐시에 정렬 시키는게 더 낫지 않을까요? ■

Answer:

이에 대한 답은 상당히 많은 것들에 의존적입니다. 만약 해시 테이블이 bucket 마다 많은 수의 원소를 가지고 있었다면, bucket 들의 수를 늘리는게 분명 나을 겁니다. 한편으로는, 만약 해시 테이블에 가해지는 로드가 적었다면, 이에 대한 답은 하드웨어, 해시 함수의 효율성, 그리고 워크로드에 의존적일 겁니다. 관심있는 독자들은 실험을 해보시기 바랍니다. □

Quick Quiz 10.4:

Schrödinger 의 동물원 어플리케이션의 소켓을 넘어가면서 보이는 음의 확장성을 가지고 생각해보면, 어플리케이션의 복사본을 여럿 만들어서 각각의 복사본이 전체 동물의 부분집합만을 가지고 하나의 소켓 위에서만 각자 돌도록 하는 건 어떨까요? ■

Answer:

그렇게 해볼 수 있습니다! 사실, 이 아이디어를 커다란 클러스터 시스템으로 확장할 수도 있는데, 각 어플리케이션 복사본을 클러스터의 각 노드에 수행시키는 형식으로 말입니다. 이 방법은 “sharding”이라 불리며, 실제로 커다란 웹 기반의 상점에서 상당히 많이 사용되는 방법입니다 [DHJ⁺07].

하지만, 멀티소켓 시스템에서 소켓별로 분할을 하려 한다면, 별개의 더 작고 짠 단일 소켓 시스템들을 사용 각각의 데이터베이스 조각을 그 각각의 시스템에서 수행시키는게 어렵겠어요? □

Quick Quiz 10.5:

하지만 해시 테이블의 원소가 검색과 동시에 삭제될 수가 있다면, 그 말은 검색 기능은 검색된 직후에 삭제된 원소로의 레퍼런스를 리턴할 수도 있다는 의미 아닌가요? ■

Answer:

네, 그럴 수 있습니다! 이게 왜 `hashtab_lookup()`이 RCU read-side 크리티컬 섹션 안에서 호출되어야만 하는지에 대한 이유이고, 왜 `hashtab_add()` 와

`hashtab_del()` 역시 RCU를 신경쓰는 리스트 조작 기능을 사용해야 하는가에 대한 이유입니다. 마지막으로, 이게 바로 `hashtab_del()` 가 삭제한 원소를 메모리에서 해제시키기 전에 (ex: `synchronize_rcu()`를 호출해서) grace period를 기다려야 하는지에 대한 이유입니다. □

Quick Quiz 10.6:

8개 CPU에서 60 CPU 상황을 쓰레드 수를 늘리는 것으로 시뮬레이션 해보는건 상당히 위험함이 Section 10.2.3에서 드러났었습니다. 하지만 60 CPU를 가지고 더 많은 CPU 상황을 시뮬레이션 해보는건 보다 안전할 수 있을까요? ■

Answer:

그건 보다 안전하지 않고, 유용한 방법은 이 프로그램들을 더 큰 시스템에서 돌리는 것입니다. 하지만, 다른 테스트는 RCU read-side 기능들은 1024 쓰레드까지도 일관된 성능과 확장성을 제공하는 것을 보였습니다. □

Quick Quiz 10.7:

Listing 10.10의 코드는 해시 값을 두번 계산하네요! 왜 이렇게 비효율적이죠? ■

Answer:

기존의 해시 테이블과 새로운 해시 테이블은 전혀 다른 해시 함수를 사용할 수도 있고, 따라서 기존의 테이블을 위해 계산된 해시 값을 새로운 테이블에서는 적절치 않을 수 있기 때문입니다. □

Quick Quiz 10.8:

Listing 10.10의 코드는 선택된 bucket에서 진행중일 수도 있는 크기 재조정 프로세스로부터의 보호는 어떻게 하나요? ■

Answer:

그런 보호는 전혀 이루어지지 않고 있습니다. 그건 뒤에서 설명될 업데이트 쪽 동시성 제어 함수에서 할 일입니다. □

Quick Quiz 10.9:

Listing 10.10 와 10.11의 코드는 업데이트를 위해 해시 값을 계산하고 bucket 선택 로직을 두번 수행하네요! 왜 이렇게 비효율적인거죠? ■

Answer:

이 방법은 `hashtorture.h` 테스트 도구가 재사용될 수 있게 합니다. 그렇다고는 하지만, 제품 품질의 크기 재조정 가능한 해시 테이블은 이런 두번의 계산이 없도록 최적화 되어야 할겁니다. 그런 최적화를 하는건 독자 여러분의 몫으로 넘겨둡니다. □

Quick Quiz 10.10:

크기 재조정 작업이 이루어지는 사이에 한 쓰레드가 새로운 해시 테이블에 원소를 넣는다고 생각해 봅시다. 뒤따르는 크기 재조정 작업이 이 삽입 작업 전에 완료됨으로 인해 이 삽입 작업이 없던 것처럼 되어버리는 문제는 어떻게 방지되고 있나요? ■

Answer:

두번째 크기 재조정 작업은 해당 bucket에서 삽입 작업이 이루어지고 있는 장소로 움직일 수 없을텐데, 삽입 작업이 새로운 해시 테이블(이 예에서의 세개의 해시 테이블 중 두번째)의 bucket 중 하나의 락을 잡고 있기 때문입니다. 더 나아가서, 이 삽입 작업은 RCU read-side 크리티컬 섹션 안에 위치하고 있습니다. `hashtab_resize()` 함수에서 봤듯이, 이 말은 첫번째 크기 재조정 작업이 삽입의 read-side 크리티컬 섹션이 완료되기 를 `synchronize_rcu()`를 이용해 기다리고 있을 것을 의미합니다. □

Quick Quiz 10.11:

Listing 10.12의 `hashtab_lookup()` 함수에서, 코드는 탐색될 원소가 이미 동시의 크기 재조정 작업에 의해 분산되었다면 새로운 해시 테이블에 있는 올바른 bucket을 찾아옵니다. 이건 RCU로 보호되는 탐색에서는 좀 낭비가 있는 것 같은데요. 이 경우에는 왜 그냥 기존 해시 테이블에서 작업을 끝내지 않는 거죠? ■

Answer:

크기 재조정 작업이 시작되었고 기존 테이블의 bucket들 중 절반만 새로운 테이블로 분산했다고 생각해 보세요. 더 나아가서 한 쓰레드가 이미 분산된 bucket 안에 원소를 하나 넣었고, 이 쓰레드가 이제 방금 새로 추가한 원소를 탐색한다고 생각해 봅시다. 탐색이 무조건적으로 기존 해시 테이블을 탐색한다고 하면, 이 쓰레드는 자신이 집어넣은 원소를 찾는데 실패할텐데, 이는 저한테는 분명한 버그처럼 들리는군요! □

Quick Quiz 10.12:

Listing 10.12의 `hashtab_del()` 함수는 원소를 항상 기존 해시 테이블에서 제거하지는 않는데요. 이 말은 읽기 쓰레드들이 이 새로 제거된 원소를 해제된 후에도 볼 수 있다는 의미 아닌가요? ■

Answer:

아닙니다. `hashtab_del()` 함수는 이제 제거된 원소를 담고 있는 bucket에 대해 크기 재조정 작업이 이미 완료되었을 때에만 기존 해시 테이블에서 제거합니다. 하지만 이는 새로운 `hashtab_lookup()` 오퍼레이션은 해당 원소를 탐색할 때 새로운 해시 테이블을 사용할 것을 의미합니다. 따라서, `hashtab_del()` 보다 먼저 시작된 `hashtab_lookup()` 오퍼레이션들만이 이번에 제거된

원소를 만날 수 있을 겁니다. 이는 `hashtab_del()`는 이 불편한 `hashtab_lookup()`을 막기 위해 하나의 RCU grace period 만 기다리면 된다는 것을 의미합니다. □

Quick Quiz 10.13:

Listing 10.12의 `hashtab_resize()` 함수에서, line 29에서의 `->ht_new`로의 업데이트가 line 36에서의 `->ht_resize_cur`로의 업데이트 전에 일어난 것으로 `hashtab_lookup()`, `hashtab_add()`, 그리고 `hashtab_del()`의 관점에 보일 것을 무엇이 보장하죠? ■

Answer:

Listing 10.12의 line 30에서의 `synchronize_rcu()`는 전부터 존재한 RCU 읽기 쓰레드들이 line 29에서 새로운 해시 테이블로의 레퍼런스를 설치한 시점과 line 36에서 `->ht_resize_cur`를 업데이트한 시점 사이에서 완료되었을 것을 보장합니다. 이 말은 `->ht_resize_cur`의 음이 아닌 값을 본 모든 읽기 쓰레드들은 `->ht_new` 할당 전에 시작되었을 수 없고, 따라서 새로운 해시 테이블로의 레퍼런스를 볼 수 있어야 합니다. □

Quick Quiz 10.14:

Listing 10.10의 `ht_get_bucket()`과 Listing 10.13의 `hashtab_resize()`의 메모리 배리어는 왜 존재하는 건가요? ■

Answer:

`ht_get_bucket()`은 업데이트 쪽 락을 잡지 않은 채로 호출될 수 있어서, 상호 배제가 없을 것이기 때문입니다. 이는 `ht_get_bucket()`이 새로운 해시 테이블을 지금 접근하고자 하는 데이터 원소가 아직 그쪽 테이블에 나타나지지 않았을 때 문제가 될 수 있고, 따라서 이 두개의 메모리 배리어가 그런 일의 발생을 막습니다. 즉, `hashtab_resize()`는 기존 bucket의 데이터 원소를 `->ht_resize_cur`의 업데이트 전에 완전히 옮겼고, `ht_get_bucket()`은 `->ht_resize_cur`로부터 값이 업데이트 된 것을 보기 전까지는 새 해시 테이블에 접근하지 않을 겁니다. □

Quick Quiz 10.15:

`hashtorture.h`의 코드는 `hashtab_lock_mode()`가 `ht_get_bucket()`의 기능을 포섭하도록 수정될 수 없나요? ■

Answer:

그럴 수도 있을테고, 그렇게 하는게 이 챕터에 선보여진 bucket 별 락킹을 사용하는 해시 테이블에 이득을 가져다 줄 수 있을 겁니다. 이런 변경을 만드는 건 독자 여러분의 몫으로 두겠습니다. □

Quick Quiz 10.16:

이런 특수화는 정말로 얼마나 성능을 구하나요? 이게 정말 가치가 있나요? ■

Answer:

첫번째 질문에 대한 답은 독자의 뜻으로 남겨져 있습니다. 크기 재조정 가능한 해시 테이블을 특수화 시켜보고 그 결과로 성능이 얼마나 개선되는지 살펴보세요. 두번째 질문은 일반적으로는 답변될 수가 없습니다만, 대신 특수한 사용 예에 맞춰서 답변될 수 있을 겁니다. 일부 사용 케이스는 성능과 확장성에 극단적으로 민감하고 다른 것들은 그보다 덜할 수 있습니다. □

G.11 Validation

Quick Quiz 11.1:

컴퓨팅에 있어서 단편적 계획을 따르는게 특히 중요한 건 언제인가요? ■

Answer:

얼마든지 많은 상황이 존재할 수 있습니다만, 가장 중요한 상황은 그 프로그램을 개발하기 위해 조립해야 할 것들을 아무도 만든게 없는 상황이 되겠습니다. 이런 경우, 믿을만한 계획을 만들어내는 유일한 방법은 그 프로그램을 구현하고, 계획을 만들고, 이걸 또다시 두번째로 구현하는 것 뿐입니다. 하지만 누가 됐든 처음으로 그 프로그램을 구현하는 사람은 단편적 계획을 따르는 것밖에 다른 선택이 없는데 현실을 알지 못하고 만들어진 자세한 계획은 실제 세계에서는 살아남을 수가 없기 때문입니다.

그리고 아마도 이게 단편적 계획을 따를 수 있을만큼 미친듯이 낙관적인 인류를 진화가 선택한 이유 가운데 하나일 겁니다. □

Quick Quiz 11.2:

다음과 같은 `time` 커맨드의 출력을 처리하는 스크립트를 작성하고 있다고 해봅시다:

```
real      0m0.132s
user      0m0.040s
sys       0m0.008s
```

해당 스크립트는 에러를 처리하고 에러일 수 있는 `time` 출력을 받았을 경우 적절한 진단 내용을 제공하기 위해 자신에게 주어진 입력을 체크해야 합니다. 싱글 쓰레드 프로그램들로 생성된 `time` 출력의 사용에 대해 이 프로그램을 테스트 하기 위해 어떠한 입력의 테스트를 제공해야 할까요? ■

Answer:

- 모든 시간이 CPU-bound 프로그램에 의해 user 모드에서 소비되는 경우를 위한 테스트 케이스가 있습니까?
- 모든 시간이 CPU-bound 프로그램에 의해 system 모드에서 소비되는 경우를 위한 테스트 케이스가 있습니까?
- 세개의 시간이 모두 0인 경우를 위한 테스트 케이스가 있습니까?
- “user” 와 “sys” 시간의 합이 “real” 시간보다 큰 경우를 위한 테스트 케이스가 있습니까?(멀티쓰레드 프로그램에 있어서 이건 물론 완전히 합법적인 결과입니다.)
- 시간들 중 하나가 1초 이상인 경우를 위한 테스트 케이스 집합이 있습니까?
- 시간들 중 하나가 10초 이상인 경우를 위한 테스트 케이스 집합이 있습니까?
- 시간들 중 하나가 0이 아닌 분을 갖는 시간을 갖는 경우를 위한 테스트 케이스 집합이 있습니까?(예를 들어, “15m36.342s”.)
- 시간들 중 하나가 60보다 큰 두번째 값을 갖는 경우를 위한 테스트 케이스 집합이 있습니까?
- 시간들 중 하나가 밀리세컨드에 있어 32 비트를 오버플로우 하는 경우를 위한 테스트 케이스 집합이 있습니까? 64 비트의 밀리세컨드는요?
- 시간들 중 하나가 음수인 경우를 위한 테스트 케이스 집합이 있습니까?
- 시간들 중 하나가 양수의 분 값을 갖지만 음수의 두번째 값을 갖는 경우를 위한 테스트 케이스 집합이 있습니까?
- 시간들 중 하나가 “m”이나 “s”를 누락하고 있는 경우를 위한 테스트 케이스 집합이 있습니까?
- 시간들 중 하나가 숫자가 아닌 경우를 위한 테스트 케이스 집합이 있습니까?(예를 들어, “Go Fish”.)
- 입력의 열들 중 하나가 누락된 경우를 위한 테스트 케이스 집합이 있습니까?(예를 들어, “real” 값과 “sys” 값은 있지만 “user” 값은 없는 경우.)
- 입력의 열들 중 하나가 중복된 경우를 위한 테스트 케이스 집합이 있습니까? 또는 중복되었지만 그 중복된 내용은 다른 시간 값을 갖는 경우를 위한?

16. 입력의 특정 열이 하나 이상의 시간 값을 갖는 경우를 위한 테스트 케이스 집합이 있습니까? (예를 들어, “real 0m0.132s 0m0.008s”.)
17. 무작위적 문자를 담고 있는 경우를 위한 테스트 케이스 집합이 있습니까?
18. 잘못된 입력에 관련된 모든 테스트 케이스들은 모든 순열을 생성합니까?
19. 각각의 테스트 케이스에 대해서 그 테스트에 예상되는 결과를 가지고 있습니까?

위의 상당한 수의 테스트 케이스들을 위한 테스트 데이터를 만들지 않았다면, 여러분은 더 높은 품질의 테스트를 만들 수 있는 기회를 갖기 위해서 더 분해적인 자세를 가져야 합니다.

물론, 분해를 효율적으로 하는 한가지 방법은 테스트되어야 하는 소스 코드와 함께 테스트를 생성하는 것인데, 이는 white-box 테스트라고 불립니다 (black-box 테스트와 반대되는 개념입니다). 하지만, 이게 만병통치는 아닙니다: 당신의 생각이 그 프로그램이 뭘 다룰 수 있는지에만 제한되어 있어서 정말로 분해적인 입력을 생성하는데 실패하게 되는 경우를 발견하기는 매우 쉽다는 걸 알게 될겁니다. □

Quick Quiz 11.3:

지금 저에게 코딩을 시작하기도 전에 검증을 시작하고 말씀하시는 거예요??? 그건 마치 아무것도 시작하지 않는 훌륭한 방법처럼 들리네요!!! ■

Answer:

그게 당신의 프로젝트라면, 예를 들어 취미라면, 원하는 대로 하세요. 당신이 낭비하는 모든 시간은 당신만의 것이고, 그걸 신경쓸 어떤 사람도 존재하지 않습니다. 그리고 시간이 전혀 낭비되지 않을 수 있는 좋은 기회도 있지요. 예를 들어, 당신이 세상에 없던 최초의 종류의 프로젝트에 착수했다면, 요구사항들은 어떤 방법으로도 알 수 없는 것들일 겁니다. 이 경우, 최선의 방법은 빠르게 간단한 해결책의 여러 프로토타입들을 만들어보고, 그걸 사용해 보고, 뭐가 가장 잘 동작하는지 보는 겁니다.

다른 한편으로, 당신이 이미 존재하는 시스템과 전체적으로 유사한 시스템을 만들도록 돈을 받았다면, 당신은 당신의 사용자인 고용인에게, 그리고 일찍부터 자주 검증을 하는 스스로의 미래에 빛을 지고 있는 셈입니다. □

Quick Quiz 11.4:

WARN_ON_ONCE() 는 어떻게 구현할 수 있을까요? ■

Answer:

가끔은 두번이나 세번까지는 경고를 날릴 수 있는 WARN_ON_ONCE() 여도 문제가 없다면, 간단히 초기값 0을 갖는 static 변수를 사용하세요. 조건이 만족된다면, 이 static 변수를 체크하고, 만약 0이 아니라면, 그냥 리턴합니다. 그렇지 않다면, 그 값을 1으로 설정하고, 메세지를 출력한 후, 리턴하세요.

경고 메세지가 굉장히 커다랗거나 해서 메세지가 절대로 두번 이상 나타나선 안된다면 앞의 “그 값을 1로 설정” 부분을 어토믹 교환 오퍼레이션을 사용할 수 있습니다. 경고 메세지는 이 어토믹 교환 오퍼레이션이 0을 리턴한 경우에만 프린트하도록 합니다. □

Quick Quiz 11.5:

어떤 사람이 존재하는 코드를 종이에 펜으로 사본을 만들려 하겠어요??? 그건 그냥 필사 과정에서의 에러의 가능성만 증가시키는 거 아닌가요? ■

Answer:

필사 과정에서의 에러가 걱정된다면, 제가 당신에게 diff라는 이름의 정말 멋진 도구를 처음으로 소개해줄 수 있게 해주세요. 또한, 필사 과정을 진행하는건 상당히 가치있을 수 있습니다:

1. 많은 코드를 복사하게 된다면 당신은 추상화를 함으로써 얻을 수 있는 이득을 얻을 수 없을 겁니다. 코드를 필사하는 행위는 추상화를 위한 커다란 동기 부여를 줄 수 있습니다.
2. 코드를 필사하는 행위는 코드가 정말로 새로운 환경에서도 잘 동작할 것인지 생각해볼 기회를 줍니다. 인터럽트를 불가능하게 해야 한다거나 어떤 락을 잡아야 한다거나와 같은, 명확치 않은 제약이 있나요?
3. 코드를 필사하는 행위는 또한 그 일을 하게 하는 데 어떤 더 나은 방법이 있을지 고민해 볼 시간을 줍니다.

그러니까, 그래요, 코드를 필사하세요! □

Quick Quiz 11.6:

이 과정은 우스꽝스러울 정도로 지나치게 공업화 되어 있어요! 어떻게 당신은 소프트웨어의 충분한 부분이 이런 방식으로 작성되었을 거라고 생각할 수 있는거죠? ■

Answer:

실제로, 코드를 손으로 복사하는 행위를 반복하는 것은 노동집약적이고 느립니다. 하지만, 상당한 스트레스 테스트와 정확성 검증과 조합되어진다면, 궁극적인 성능과 안정성이 필요하고 디버깅이 어려운 복잡한 병렬

코드에 있어서는 이 또한 상당히 효과적입니다. 리눅스 커널 RCU 구현이 그런 케이스입니다.

한편으로는, 당신이 어떤 데이터를 조작하기 위해 간단한 싱글 쓰레드 셀 스크립트를 작성하고 있다면, 다른 방법론이 당신을 가장 잘 도와줄 겁니다. 예를 들어, 당신이 원하는 대로 동작하고 있음을 확신할 수 있도록 하는 테스트 테이터와 함께 커맨드 하나 하나를 하나씩 대화형 셀에 입력하고, 그리고 나서 성공한 커맨드들을 스크립트 안에 복사해서 붙여넣을 수 있을 겁니다. 마지막으로, 전체 스크립트를 테스트하세요.

도움을 주려 하는 친구나 동료가 있다면, 페어 프로그래밍이 잘 될 수 있을 텐데, 정식적인 디자인 리뷰와 코드리뷰 프로세스에 있어서도 마찬가지입니다.

그리고 당신이 취미로 코드를 작성하고 있다면, 뭐가 됐든 하고 싶은대로 하세요.

짧게 요약해서, 다른 종류의 소프트웨어는 다른 개발 방법론을 필요로 합니다. □

Quick Quiz 11.7:

당신의 쓰레기 봉투에 굉장히 많은 시스템이 있다고 생각해 봅시다. 예를 들어, 현재의 클라우드 가격 정책대로라면, 당신은 충분히 낮은 가격에 수많은 CPU 시간을 구입할 수 있습니다. 모든 실용적인 목적에 있어서의 정확성을 충분히 가져가기 위해서 이 전략을 사용하는 건 어떤가요? ■

Answer:

이 방법은 당신의 검증 무기고에 가치 있는 추가 물품이 될 수도 있을 겁니다. 하지만 이 방법은 몇 가지 한계점을 가지고 있습니다:

1. 일부 버그는 극단적으로 낮은 발생 가능성을 가지고 있지만, 그래도 고쳐져야 합니다. 예를 들어, 리눅스 커널의 RCU 구현이 평균적으로 100년의 CPU 시간에 딱 한번 발생하는 버그를 가지고 있다고 생각해 봅시다. 100년의 CPU 시간은 가장 싼 클라우드 플랫폼에서라고 해도 상당히 비싼 가격입니다만, 2011년 기준으로 세계에 1억 개 이상의 리눅스 인스턴스가 존재하므로, 이 버그는 하루에도 2,000 회 이상의 문제를 일으킬 수 있을 것으로 예상할 수도 있습니다.
2. 이 버그는 당신의 테스트 환경에서는 발생 가능성이 없을 수 있는데, 이는 당신이 테스트를 하는데에 얼마나 많은 시간을 쏟아붓는가와 관계없이 당신은 그 버그를 볼 수 없을 것이란 것을 의미합니다.

물론, 당신의 코드가 충분히 작다면 Section 12 에서와 같이, 정형적 검증 절차가 도움이 될 수 있을 겁니다. 하지만 주의하세요: 당신의 코드의 정형적 검증은 당신의 가정, 요구사항에 대한 잘못된 이해, 당신이 사용하는 소프트웨어나 하드웨어에 대한 잘못된 이해, 또는 당신이 증명을 할 생각을 하지 못한 에러에 대해서는 문제를 찾아내지 못할 겁니다. □

Quick Quiz 11.8:

뭐라구요??? 제가 앞에서 이야기한 각각 10% 실패 확률을 갖는 다섯 번의 테스트의 예를 이 공식에 집어넣어 보면 59,050%를 얻게 되는데 이건 말이 안되잖아요!!! ■

Answer:

당신 말이 맞아요, 전혀 말이 안되죠.

확률은 0과 1 사이의 숫자여서 당신은 확률을 구하기 위해서는 퍼센티지를 100으로 나눠야 함을 기억하세요. 따라서 10%의 확률은 0.1로, 공식에 대입한 확률은 0.4095 값을 얻게 되는데, 이는 반올림하면 41%가 되는데, 이렇게 되면 앞의 결과와 상당히 일관적이지요. □

Quick Quiz 11.9:

Equation 11.6에서, 로그의 밑은 10인가요, 2인가요, 또는 e인가요? ■

Answer:

그건 상관 없습니다. 어떤 밑의 로그를 취하는가에 관계없이 똑같은 답을 얻을 수 있을 텐데 그 결과는 로그 값들 간의 비율이기 때문입니다. 유일한 제약은 분모와 분자에 둘다 같은 밑을 사용해야 한다는 점입니다. □

Quick Quiz 11.10:

어떤 버그가 평균적으로 시간당 세 번의 테스트 실패를 유발한다고 생각해 봅시다. 수정사항이 실패의 확률을 상당히 줄였음을 99.9% 증명할 수 있는 증거를 위해서 테스트는 에러 없이 얼마나 오래 돌아가야 할까요? ■

Answer:

Equation 11.11에서 n 은 3으로, 그리고 P 를 99.9로 놓으면, 결과는 다음과 같습니다:

$$T = -\frac{1}{3} \ln \frac{100 - 99.9}{100} = 2.3 \quad (\text{G.9})$$

테스트가 실패하지 않은 채 2.3 시간동안 돌아간다면, 우린 해당 수정사항이 실패 가능성을 줄였음을 99.9% 확신할 수 있습니다. □

Quick Quiz 11.11:

이 모든 계승식 (factorial)들과 지수식 (exponential)들을 더하고 있는건 진짜 고통스럽습니다. 좀 더 편한 길은 없나요? ■

Answer:

한가지 방법은 “maxiam”라는 이름의 오픈 소스 기호 논리학 조작 프로그램을 사용하는 것입니다. 많은 Debian 기반 리눅스 배포본의 일부분이 이 프로그램을 일단 설치하면, 이걸 수행하고 `load(distrib)`; 커맨드를 넣고 이어서 `bfloat(cdf_poisson(m,1))`; 커맨드들의 숫자들을 아무거나 넣을 수 있는데, 여기서 `m`은 m 을 위한 원하는 값으로 바꾸고 (실제 테스트에서의 실제 failure 횟수) 1은 원하는 λ 값으로 (실제 테스트에서 기대된 failure 횟수) 바꿔야 할 겁니다.

구체적으로는, `bfloat(cdf_poisson(2,24))`; 커맨드는 1.181617112359357b-8을 내놓는데, 이는 Equation 11.13로 구해진 값과 맞아 떨어집니다.

대안적으로는, Section 11.6.2에서 설명하는 rough-and-ready 방법을 사용할 수 있습니다. □

Quick Quiz 11.12:

하지만 잠시만요!!! 실패의 어떤 횟수가 있어야 한다는 (실패가 없을 수 있다는 가능성은 포함해서) 점을 놓고 보면, Equation 11.13에 보여진 더하기는 m 을 1로 놓으면 무한대가 되지 않나요? ■

Answer:

실제로 그래야 합니다. 그리고 그렇지요.

이를 알아보기 위해, $e^{-\lambda}$ 는 i 에 의존되지 않는데, 이는 다음과 같이 더하기에서 빠져나올 수 있음을 의미함을 보세요:

$$e^{-\lambda} \sum_{i=0}^{\infty} \frac{\lambda^i}{i!} \quad (G.10)$$

남은 더하기는 정확히 e^{λ} 를 위한 Taylor 시리즈로, 다음과 같이 됩니다:

$$e^{-\lambda} e^{\lambda} \quad (G.11)$$

이 두개의 지수식들은 서로 상반되므로 무시되어서 정확히 요구된 대로 1이 됩니다. □

Quick Quiz 11.13:

만약 그 오염이 어떤 관계없는 포인터에 영향을 끼쳐서 그 포인터를 따라가서 오염을 일으키는 경우에 이 방법은 어떻게 도움을 줄 수 있을까요??? ■

Answer:

실제로, 그런 상황이 일어날 수 있습니다. 많은 CPU가 그런 관계없는 포인터를 찾아내는 것을 도울 수 있는

하드웨어 디버깅 기능을 가지고 있습니다. 뿐만 아니라, core dump를 가지고 있다면, 메모리의 오염된 영역을 가리키는 포인터들을 위해 core dump를 조사할 수 있습니다. 또한 오염의 데이터 구조를 살펴보고, 그 구조와 맞아떨어지는 포인터들을 체크해 볼 수도 있습니다.

또한 한발자국 떨어져서 프로그램을 구성하는 모듈들을 더 혹독하게 테스트 해볼 수 있는데, 이는 오염을 그에 책임이 있는 모듈로 국한시킬 겁니다. 만약 이게 오염을 사라지게 한다면, 각각의 모듈에서 노출된 함수들의 인자 체크를 더 추가해 보는 걸 고려해 보세요.

하지만, 이건 어려운 문제인데, 그게 제가 “약간 어둠의 예술”이라는 말을 사용한 이유입니다. □

Quick Quiz 11.14:

하지만 제가 그렇게 이등분을 통한 탐색을 해봤는데, 결국 나온 범인은 거대한 커밋이었어요. 이제 뭘 해야 하죠? ■

Answer:

커다란 커밋이요? 그건 참 부끄러운 일입니다! 이건 왜 당신이 커밋들을 작게 유지할 것이라 기대되는지에 대한 한가지 이유일 뿐입니다.

그리고 그게 당신의 답입니다: 해당 커밋을 바이트 단위의 조각들로 쪼개고 그 조각들을 다시 이진탐색하세요. 제 경험상으로, 그 커밋을 쪼개는 일 자체는 대부분의 경우에 그 버그를 상당히 분명하게 만들기에 충분합니다. □

Quick Quiz 11.15:

이미 존재하는 조건적 락킹 도구들은 이런 가짜 실패 기능을 제공하지 않는 이유가 뭔가요? ■

Answer:

조건적 락킹 도구들이 진실만을 말한다는 사실에 의존적인 락킹 알고리즘들이 존재합니다. 예를 들어, 만약 조건적 락 실패가 어떤 다른 쓰래드가 이미 어떤 일을 하고 있음을 나타낸다면, 가짜 실패는 그 일이 결코 완료가 되지 못하게 만들 수 있어서, 결과적으로 프로그램 수행이 한 구간에서 나아가지 못하게 될겁니다. □

Quick Quiz 11.16:

그건 웃긴 이야기네요!!! 어쨌든, 좀 늦더라도 올바른 답을 얻는게 잘못된 답을 얻는 것보다는 낫지 않겠어요???

Answer:

이 질문은 아예 답을 계산하지 않는, 그리고 그렇게 함으로써, 또한 그 답을 계산하는데 드는 비용을 고려하게 만드는 선택지를 고려하게 만듭니다. 예를 들어, 짧은 기간의 날씨 예측과 같은, 정확한 모델들이 존재하지만

정말로 그 날씨가 와버리기보다 먼저 그 모델을 수행하기를 원한다면 커다란(그리고 비싼) 클러스터로 구성된 슈퍼컴퓨터들을 필요로 하는 경우를 생각해 보세요.

그리고 이 경우에, 그 모델이 실제 날씨보다 빠르게 수행되는 것을 방지하는 성능 버그는 모든 날씨 예측을 방지해 버립니다. 그 커다란 클러스터로 구성된 슈퍼컴퓨터들을 구입한 목적은 모두 날씨를 예측하기 위해서였다는 점을 생각해 보면, 그 모델을 날씨보다 빠르게 수행하지 못한다면, 그 모델을 아예 수행하지 않는 편이 나을 겁니다.

안전성에 민감한 리얼타임 컴퓨팅 분야에서는 더 많은 가혹한 예들이 발견될 수도 있을 겁니다. □

Quick Quiz 11.17:

하지만, 어플리케이션을 병렬화하기 위해 필요한 모든 어려운 일을 해내기로 했다면 왜 그걸 올바르게 하지 않는거죠? 왜 최적의 성능과 선형적인 확장성보다 못한 것에 안주하는 겁니까? ■

Answer:

전 정말로 당신의 정신과 포부에 경의를 표합니다만, 당신은 프로그램의 완료에 걸리는 딜레이가 높은 비용이 될 수도 있다는 점을 잊고 있습니다. 극단적인 예를 들어 보면, 단일 쓰레드로 짜인 어플리케이션에서의 40%의 성능 저하가 매일 한 사람을 죽게 만든다고 생각해 보세요. 더 나아가서 당신이 사람들과 함께 여덟개의 CPU를 가진 시스템에서 순차적 버전에 비해서 50% 빠르게 동작하는 병렬 프로그램을 하루만에 빠르고 지저분하게 만들어 냈지만(hack), 최적의 병렬 프로그램은 네달동안의 고통스러운 설계, 코딩, 디버깅, 그리고 최적화를 필요로 한다고 상상해 보세요.

백명이 넘는 사람들은 그 빠르고 더럽게 만들어진 버전을 더 좋아할 거라고 충분히 말할 수 있습니다. □

Quick Quiz 11.18:

하지만, 예를 들어 캐시와 메모리 배치 사이의 간섭에 의한 것과 같은 다른 에러 유발 요인들은 어떻게 하죠? ■

Answer:

메모리 배치의 변경은 실제로 비현실적으로 수행 시간을 줄여버리는 결과를 초래할 수 있습니다. 예를 들어, 어떤 마이크로벤치마크는 거의 항상 L0 캐시의 associativity를 오버플로우 시키지만, 올바른 메모리 배치에서 만큼은 모두 맞아떨어진다고 생각해보세요. 이게 정말 문제라면, 메모리 배치를 완전히 제어할 수 있도록 마이크로벤치마크를 huge page를 사용해서 수행해보는 방안 (또는 커널에서 수행하거나 기계 위에서 곧바로)을 생각해 보세요. □

Quick Quiz 11.19:

테스트 되는 코드를 격리시키기 위해 제안된 이 테크닉들은 특히나 그 코드가 커다란 어플리케이션에서 돌아가고 있다면 그 코드의 성능에 영향을 끼치지 않을까요? ■

Answer:

실제로 그럴 수도 있습니다. 마이크로 벤치마킹을 위한 과정에서 대부분은 테스트하고자 하는 코드를 그 어플리케이션에서 끄집어 냘테지만요. 그러나, 어떤 이유로 테스트 되는 코드를 그 어플리케이션 내에 두어야만 한다면, Section 11.7.6에서 언급된 테크닉들을 사용해야 할 겁니다. □

Quick Quiz 11.20:

이 방법은 좀 이상하군요! 왜 우리가 통계 수업시간에 배웠던 것처럼 평균과 표준편차를 사용하지 않죠? ■

Answer:

평균과 표준편차는 이런 일을 하라고 만들어진게 아니기 때문입니다. 이를 확인하기 위해, 다음의 데이터 집합에 평균과 표준편차를 적용하게 되면, 1%의 측정 에러가 나옵니다:

49,548.4 49,549.4 49,550.2 49,550.9 49,550.9
49,551.0 49,551.5 49,552.1 49,899.0 49,899.3
49,899.7 49,899.8 49,900.1 49,900.4 52,244.9
53,333.3 53,333.3 53,706.3 53,706.3 54,084.5

문제는 평균과 표준편차는 측정 에러에 대한 가정을 전혀 하고 있지 않다는 것이고, 따라서 49,500 근처의 값과 49,900 근처의 값들 사이의 차이가 통계적으로 상당하다고 생각하게 될것인데, 실은 추정된 측정 에러의 한계선 안에 있습니다.

물론, 절대적인 차이보다 표준편차를 사용해서 비슷한 효과를 얻을 수 있도록 Listing 11.2와 비슷한 스크립트를 만드는 것도 가능할 것인데, 이는 흥미 있는 독자 여러분의 몫으로 남겨두겠습니다. 동일한 데이터 값의 문자열들로부터 나타날 수 있는 divide-by-zero 에러를 없앨 수 있도록 조심하세요! □

Quick Quiz 11.21:

하지만 신뢰되는 데이터 그룹의 y축 값들이 모조리 0이면 어떡하죠? 그러면 스크립트는 0이 아닌 값들을 제거하지 않을까요? ■

Answer:

실제로 그럴 겁니다! 하지만 당신의 성능 측정이 자주 정확히 0이란 값을 내놓는다면, 당신의 성능 측정 코드를 좀 더 자세히 들여다 볼 필요가 있을 수 있습니다.

평균과 표준편차에 기반하는 많은 방법들이 이런 종류의 데이터 집합에 대해서 비슷한 문제를 가지고 있음을 알아두시기 바랍니다. □

G.12 Formal Verification

Quick Quiz 12.1:

왜 locker 에 미치지 못한 statement 가 있는 거죠? 이건 전체 상태-공간 탐색이 아니었나요? ■

Answer:

locker 프로세스는 무한 루프이므로, 이 프로세스의 종료까지 제어가 닿지를 않습니다. 하지만, 단조적으로 증가되는 변수가 존재하지 않기 때문에, Promela 는 이 무한 루프를 작은 수의 상태만 가지고도 모델링 할수가 있습니다. □

Quick Quiz 12.2:

이 예제에 있어서 Promela 코딩 스타일 문제들은 뭐가 있나요? ■

Answer:

몇가지가 있습니다:

1. `sum` 의 선언은 `init` 블록 안으로 옮겨져야 하는데, 그 외의 곳에서는 어디서도 사용되지 않기 때문입니다.
2. 단정문 코드는 초기화 루프 바깥으로 옮겨져야 합니다. 그렇게 되면 초기화 루프는 하나의 어토믹 블락 안에 위치할 수 있어서, 상태 공간을 훨씬 줄일 수 있습니다(얼마나 줄일 수 있을까요?).
3. 단정문 코드를 감싸고 있는 어토믹 블록은 `sum` 과 `j`의 초기화를, 그리고 단정문도 포함하도록 확장되어야 합니다. 이것 역시 상태 공간을 줄일 것입니다(이번에도, 얼마나 줄일 수 있을까요?). □

Quick Quiz 12.3:

이 `do-od` 문을 좀 더 간단하게 코딩하는 방법은 없을까요? ■

Answer:

있습니다. 이걸 `if-fi` 로 바꾸고 `break` 문을 없애버리세요. □

Quick Quiz 12.4:

왜 line 12-21 과 line 44-56 에 어토믹 블락이 있나요,

그 어토믹 블락들 안의 오퍼레이션들은 현존하는 제품화된 마이크로프로세서 중 어떤 것도 어토믹한 구현을 제공하지 않는데도 말이죠? ■

Answer:

그 오퍼레이션들은 단정문을 위한 것들일 뿐이기 때문입니다. 그것들은 알고리즘 자체를 위한 것이 아닙니다. 따라서 그것들을 어토믹으로 표시해도 문제가 되지 않고, 그것들을 어토믹으로 표시하는 것은 Promela 모델을 통해 탐색되어야 하는 상태 공간을 굉장히 줄여주게 됩니다. □

Quick Quiz 12.5:

Line 24-27 에서 카운터들을 다시 합해보는 것은 정말로 필요한 건가요? ■

Answer:

그렇습니다. 이걸 확실히 보기 위해서, 이 라인들을 지우고 모델을 돌려보세요.

대안적으로는, 다음과 같은 단계들을 생각해 보세요:

1. 한 프로세스가 RCU read-side 크리티컬 섹션 안에 있어서, `ctr[0]` 의 값은 0이고 `ctr[1]` 은 2입니다.
2. 한 업데이트 쓰레드가 수행을 시작하고, 카운터들의 합이 2임을 보게 되고 따라서 빠른 수행경로는 실행될 수 없습니다. 따라서 락을 잡습니다.
3. 두번째 업데이트 쓰레드가 수행을 시작하고, `ctr[0]` 을 값 0을 가져옵니다.
4. 첫번째 업데이트 쓰레드가 `ctr[0]` 에 1을 더하고, 인덱스를 바꾸고 (이제 0이 됩니다), `ctr[1]` 에서 1을 뺍니다 (이제 1이 됩니다).
5. 두번째 업데이트 쓰레드가 `ctr[1]` 의 값을 가져오는데, 지금은 1입니다.
6. 두번째 업데이트 쓰레드는 이제 원래의 읽기 쓰레드가 아직 완료되지 않았음에도 빠른 수행 경로를 진행해도 된다고 잘못된 결론을 내리게 됩니다. □

Quick Quiz 12.6:

하지만 다른 formal-verification 도구들은 종종 특정 부류의 버그들을 찾기 위해 설계됩니다. 예를 들어, 극히 일부의 formal-verification 도구들은 해당 스페 쌍의 예러만을 찾아낼 겁니다. 그러니, 이 “분명히 믿을 수 없습니다”라는 말은 약간 너무한 거 아닌가요? ■

Answer:

많은 formal-verification 도구들이 어떤 방향으로 특수화 되어 있는 것은 분명한 사실입니다. 예를 들어,

Promela 는 현실적인 메모리 모델들을 다루지 않고 (비록 Promela 에 그것들이 프로그램 될 수는 있지만요 [DMD13]), CBMD [CKL04] 는 확률적인 hang 과 데드락을 파악하지 못하며, Nidhugg [LSLK14] 는 데이터의 비결정성에 연관된 버그는 찾지 못합니다. 하지만 이는 이 도구들이 찾기 위해 설계된 버그 외의 것을 찾을 거라고 믿을 수는 없음을 의미합니다.

또한, 그렇기에 formal-verification 도구들을 만드는 사람들은 분명하게 어떤 부류의 버그들을 그들의 도구들이 발견할 수 없고 파악할 수 없는지에 대해 “진실을 말해야” 합니다. 그러지 않는다면, 실제 사용자가 어떤 버그를 파악하지 못하는 도구를 처음 발견하면, 그 사용자는 그 도구에 상당히 거칠고 극단적으로 공식적인 비난을 가할 겁니다. 맞습니다, 맞아요, 여러분이 최고의 노력을 다했다고 말할 것이 존재하겠죠, 하지만 적절한 면책 조항 없이 그걸 너무 앞에 놓으면 여러분의 도구가 그로부터 회복될지 안될지도 모를 부정적인 반응의 더미를 쉽게 이끌어낼 수도 있습니다.

경고했어요! □

Quick Quiz 12.7:

여기에서 설명된 QRCU 알고리즘의 정확성에 대한 두개의 독립적인 증명을 가지고 있고, 올바르지 않음에 대한 증명이 다른 알고리즘은 어떤지를 다루고 있는데, 왜 여전히 의문의 여지가 남는 거죠? ■

Answer:

항상 의문의 여지가 존재합니다. 이 경우에는, 정확성에 대한 두개의 증명이 실제 세계 메모리 모델들을 신경쓰지 않고 있으므로, 이 두개의 증명들은 잘못된 메모리 순서규칙 가정에 기반하고 있을 수 있다는 점을 명심 하시기 바랍니다. 더욱이, 두 증명 모두 같은 사람에 의해 만들어졌으므로, 동일한 애러를 포함하고 있을 가능성이 높습니다. 다시 말하지만, 항상 의심의 여지가 존재합니다. □

Quick Quiz 12.8:

와우, 거 참 대단하네요! 이제, 저는 40GB 의 메인 메모리를 가진 기계가 없다면 뭘 해야 하는거죠??? ■

Answer:

진정하세요, 이 질문에 대한 많은 정당한 답들이 있습니다:

- 해당 모델을 더 최적화 해서, 메모리 소비량을 줄이세요.
- 리눅스 커널의 코드에 있는 주석부터 시작해서 연필과 종이 증명 방법을 실행하세요.

- 비록 코드의 정확성을 증명할 수는 없지만 숨겨진 버그들을 찾아줄 수 있는, 신중히 생각한 고문 테스트를 고안하세요.
- 작은 컴퓨터들로 이루어진 클러스터를 사용해서 모델 체크를 하는 도구를 만들고 사용하려는 움직임이 일부 있습니다. 하지만, Paul 은 사용할 수 있는 커다란 컴퓨터가 여럿 있어서 그런 도구를 직접 사용해 본 적은 없음을 알아두시기 바랍니다.
- 당신의 문제를 적용하기에 맞는 크기의 메모리 크기를 가진, 구매할 만한 가격대의 시스템이 나오길 기다리세요.
- 짧은 시간 동안 커다란 시스템을 대여하기 위해 클라우드 컴퓨팅 서비스들 가운데 하나를 고려해 보세요. □

Quick Quiz 12.9:

왜 간단하게 `rcu_update_flag` 의 값을 증가시키고, `rcu_update_flag` 의 기존 값이 0일 경우에만 `dynticks_progress_counter` 의 값을 증가시키는 방식을 사용하지 않는거죠??? ■

Answer:

이는 NMI 의 존재 시에 실패합니다. 이를 자세히 보기 위해, `rcu_irq_enter()` 가 `rcu_update_flag` 를 증가시킨 직후, 하지만 `dynticks_progress_counter` 를 증가시키기 전에 NMI 를 받았다고 생각해 봅시다. NMI 에 의해 호출된 `rcu_irq_enter()` 의 인스턴스는 `rcu_update_flag` 의 원래 값이 0이 아닌 것으로 보게 될 것이고, 따라서 `dynticks_progress_counter` 의 값을 증가시키지 않을 겁니다. 이는 RCU grace-period 에게 이 CPU 에서 NMI 핸들러가 실행되었음을 알 수 있는 증거를 남기지 않을 것이고, 따라서 이 NMI 핸들러 내에서의 모든 RCU red-side 크리티컬 섹션들은 RCU 보호를 깨트릴 겁니다.

그 정의에 의해 마스킹 될 수 없는 NMI 핸들러의 존재 가능성은 정말로 이 코드를 복잡하게 만듭니다. □

Quick Quiz 12.10:

하지만 line 7 이 우리가 가장 바깥의 인터럽트에 있음을 알게 된다면, 우린 항상 `dynticks_progress_counter` 의 값을 증가시켜야 하는 것 아닌가요? ■

Answer:

수행 중인 태스크를 인터럽트 했다면 그렇지 않습니다! 그런 경우에는, `dynticks_progress_counter` 는 이미 `rcu_exit_nohz()` 에 의해 값이 증가되었을 것이고, 이 경우에 대해서는 값을 한번 더 증가시킬 필요가 없을 겁니다. □

Quick Quiz 12.11:

이 섹션에서 보인 모든 코드 가운데 버그들을 찾아냈나요? ■

Answer:

당신이 맞았는지 보기 위해 다음 섹션을 읽어보세요. □

Quick Quiz 12.12:

왜 `rcu_exit_nohz()` 와 `rcu_enter_nohz()` 사이의 메모리 배리어는 Promela 에 모델링 되지 않은거죠? ■

Answer:

Promela 는 sequential consistency 를 가정하므로, 메모리 배리어를 모델링 할 필요가 없습니다. 사실, 그대신 page 207 의 Listing 12.13 처럼 메모리 배리어의 부재를 명시적으로 모델링 해야 합니다. □

Quick Quiz 12.13:

`rcu_exit_nohz()` 에 이어서 `rcu_enter_nohz()` 가 뒤따르는 경우를 모델링 하는건 좀 이상하지 않나요? 그보다는 진입 후에 빠져나가는 상황을 모델링하는게 더 자연스럽지 않을까요? ■

Answer:

그게 더 자연스러울 수 있습니다만, 우린 우리가 뒤에서 추가할 liveness 체크를 위해 이 특정한 순서가 필요합니다. □

Quick Quiz 12.14:

잠깐만요! 이 리눅스 커널에서, `dynticks_progress_counter` 와 `rcu_dyntick_snapshot` 은 per-CPU 변수들입니다. 그런데 왜 그것들이 per-CPU 변수들이 아니라 하나의 글로벌 변수로 모델링 된거죠? ■

Answer:

해당 grace-period 코드는 각각의 CPU 의 `dynticks_progress_counter` 와 `rcu_dyntick_snapshot` 을 분리해서 처리하기 때문에, 우린 이 상태를 하나의 CPU 로 뭉칠 수 있습니다. 만약 그 grace-period 코드가 특정 CPU 의 특정 값을 가지고 뭔가 특별한 일을 하려 했다면, 우린 정말로 여러개의 CPU 들을 모델링 해야 할겁니다. 하지만 다행히도, 우린 하나의 CPU 는 grace-period 처리를 수행하고 있고 다른 하나는 dynticks-idle 모드를 들어가고 빠져나오는 두개의 CPU 에만 우리를 안전히 국한시킬 수 있습니다. □

Quick Quiz 12.15:

Line 25 와 26 에 `gp_state` 의 연속된 두개의 변경이 있는데, 어떻게 line 25 에서의 변경이 사라지지 않을 거라고 확신할 수 있을까요? ■

Answer:

Promela 와 spin 이 모든 가능한 상태 변경의 시퀀스를 추적한다는 점을 다시 상기하시기 바랍니다. 따라서, 타이밍은 무의미합니다: Promela/spin 은 어떤 상태 변수가 명시적으로 방해를 하지 않는 한은 그 두개의 상태들 사이의 모든 모델을 적당히 섞어낼 겁니다. □

Quick Quiz 12.16:

하지만 `EXECUTE_MAINLINE()` 내의 statement 들이 어토믹 하지 않게 수행되어야 하는 경우라면 어떻게 하겠습니까? ■

Answer:

가장 쉬운 방법은 각각의 statement 를 각자의 `EXECUTE_MAINLINE()` 안에 넣는 것입니다. □

Quick Quiz 12.17:

하지만 `dynticks_nohz()` 프로세스가 “if” 나 “do” 문을 가지고 있는데 그 안의 조건절들이 그 분기 본체들은 어토믹하지 않게 수행되는 형태라면 어떻게 되죠? ■

Answer:

뒤의 섹션에서 보게 되겠지만, 명시적인 라벨과 “goto” 문을 사용하는게 한가지 방법입니다. 예를 들면, 아래와 같은 것은:

```
if
:: i == 0 -> a = -1;
:: else -> a = -2;
fi;
```

다음과 같은 식으로 모델링 될 수 있습니다:

```
EXECUTE_MAINLINE(stmt1,
if
:: i == 0 -> goto stmt1_then;
:: else -> goto stmt1_else;
fi)
stmt1_then: skip;
EXECUTE_MAINLINE(stmt1_then1, a = -1; goto stmt1_end)
stmt1_else: skip;
EXECUTE_MAINLINE(stmt1_then1, a = -2)
stmt1_end: skip;
```

하지만, 이 매크로가 “if” 문의 경우에 있어서도 도움이 될지는 명확하지 않은데, 따라서 이런 종류의 상황들에 대해서는 뒤의 섹션들에서 정리하겠습니다. □

Quick Quiz 12.18:

Line 45 와 46 (`in_dyntick_irq = 0;` 와 `i++;`) 은 왜 어토믹하게 수행되는 건가요? ■

Answer:

이 코드 라인들은 모델을 제어하는 부분에 속하지 모델링되는 코드에 속하지 않으므로, 이것들을 어토믹하지

않게 수행시킬 이유가 없습니다. 이것들을 굳이 어토믹하게 모델링 하는건 상태 공간의 크기를 줄이기 위해서입니다. □

Quick Quiz 12.19:

이 dynticks_irq() 프로세스가 모델링할 수 없는 인터럽트들의 특성은 무엇이 있을까요? ■

Answer:

그런 특성 가운데 하나는 뒤의 섹션에서 다루게 될, 중첩된 인터럽트들입니다. □

Quick Quiz 12.20:

Paul은 항상 그의 코드를 이렇게 고통스럽도록 점진적인 방법으로 작성하나요? ■

Answer:

항상 그렇지는 않지만, 매우 매우 자주 그렇습니다. 이 경우, Paul은 인터럽트 핸들러를 포함한 가장 작은 코드 조각으로 시작했는데, 인터럽트들을 Promel에서 어떻게 모델링 하는지에 대한 확신이 없었기 때문입니다. 일단 동작하게 하고 나서는, 그는 다른 기능들을 추가해 갔습니다. (하지만 그가 이걸 다시 하게 된다면, 그는 “장난감” 핸들러를 가지고 시작할 겁니다. 예를 들어, 한 변수의 값을 두번 증가시키는 핸들러를 가지고 그 값이 항상 짹수임을 검증하는 메인 코드를 만들 겁니다.)

왜 점진적 방법을 사용하는가? Brian W. Kerninghan에 의한 다음의 것들을 고려해 보세요:

디버깅은 코드를 처음 작성하는 것보다 두배 만큼 어렵습니다. 따라서, 당신이 코드를 할 수 있는 한 한 현명하게 작성한다면, 그 정의에 따라, 당신은 그걸 디버깅 하기에 충분히 똑똑하지 않습니다.

이는 코드 작성과정을 최적화하려는 노력은 그것의 최소한 66%의 중점을 디버깅 과정을 최적화하는데에 쏟아져야 하는데, 설명 코딩 자체에 쏟는 시간과 노력을 증가시키더라도 그렇습니다. 점진적 코딩과 테스트는 코딩 자체에 드는 노력을 증가시키는 대신에 디버깅 과정을 최적화하는 한가지 방법입니다. Paul은 코딩과 디버깅을 하는데에 (매주는 말할 것도 없고) 모든 날들을 전념할 호사를 부릴 수 있는 기회는 거의 없기 때문에 이 방법을 사용합니다. □

Quick Quiz 12.21:

하지만, 만약 NMI 핸들러가 IRQ 핸들러가 완료되기 전에 동작하기 시작하면, 그리고 그 NMI 핸들러가 두 번째 IRQ 핸들러가 시작될 때까지 돌아가면 어떤 일이 발생할까요? ■

Answer:

이는 하나의 CPU에 몰아넣은 상황에선 일어날 수 없는 일입니다. 첫번째 IRQ 핸들러는 NMI 핸들러가 리턴하기 전까지는 완료될 수 없습니다. 따라서, dynticks와 dynticks_nmi 변수들 각각이 주어진 시간 기간동안 짹수를 가졌다면, 연관된 CPU는 그 기간 중의 어느 시점에는 quiescent 상태에 정말로 있었을 겁니다. □

Quick Quiz 12.22:

이건 여전히 상당히 복잡하네요. 왜 그냥 dyntick-idle 모드에 있는 각 CPU들에 대해 bit의 값이 설정되어 있는 cpumask_t를 갖고 IRQ나 NMI 핸들러에 들어갈 때에는 그 비트의 값을 지우고, 빠져나올 때에는 그 값을 설정하는 식으로 하지 않는거죠? ■

Answer:

이 방법이 기능적으로는 올바르겠지만, 이는 커다란 머신에서는 지나치게 커다란 IRQ 들어가고 빠져나올 때의 오버헤드를 초래할 겁니다. 반면에, 이 섹션에서 이야기한 방법은 각각의 CPU가 IRQ와 NMI에 들어가고 나올 때에 per-CPU 데이터만을 만지게 하므로 훨씬 적은 IRQ에 들어가고 빠져나올 때의 오버헤드를 초래할 것이고, 특히 커다란 기계에선 더욱 그러할 겁니다. □

Quick Quiz 12.23:

하지만 x86은 강한 메모리 순서 규칙을 가지고 있어요! 왜 이 메모리 모델을 정형화 시켜야 하는거죠? ■

Answer:

사실, 학계에서는 x86 메모리 모델을 완화된 것으로 여기는데, 앞의 store가 뒤의 load와 재배치될 수 있기 때문입니다. 학계의 시점에서 볼 때, 강한 메모리 모델은 어떠한 재배치도 절대적으로 허용하지 않아서 모든 쓰레드들이 그들에게 보일 수 있는 모든 오퍼레이션들의 순서에 대해 동의할 수 있는 것입니다. □

Quick Quiz 12.24:

Listing 12.24의 line 8은 왜 레지스터들을 초기화 시키죠? 왜 그것들을 line 4와 5에서 대신 초기화 시키지 않나요? ■

Answer:

두 방식 모두 잘 동작합니다. 하지만, 일반적으로는 명시적 인스트럭션 사용보다 초기화를 사용하는게 낫습니다. 이 예제에서의 명시적 인스트럭션은 그 사용법을 보이기 위해 사용되었습니다. 또한, 이 도구의 웹사이트 (<http://www.cl.cam.ac.uk/~pes20/ppcmem/>)에서 사용 가능한 리트머스 테스트들 가운데 많은 것들은 명시적 초기화 인스트럭션들을 사용하도록 자동으로 생성되었습니다. □

Quick Quiz 12.25:

Listing 12.24 의 line 17 의 Fail: 라벨에서는 무슨 일이 벌어지게 되는거죠? ■

Answer:

atomic_add_return() 의 Powerpc 버전 구현은 stwcx 인스트럭션의 condition-code 레지스터에 있는 0이 아닌 상태값을 설정함으로써 통신을 하며 bne 인스트럭션을 통해 테스트하게 되는 성공 여부가 실패로 드러나면 루프를 돌게 됩니다. 실제로 루프를 모델링하는 것은 상태 공간의 폭증을 유발하게 되므로, 그대신에 우리는 Fail: 라벨로 브랜치하고, P0의 r3 레지스터의 값이 초기값 2인 형태로 모델링을 종료하여서, exists 단정문의 실패를 유발하지 않게 합니다.

이 트릭이 일반적으로 적용 가능한 것인지에 대해서는 일부 논쟁이 있습니다만, 전 아직 이게 실패하는 예제를 본적이 없습니다. □

Quick Quiz 12.26:

ARM 리눅스 커널도 비슷한 버그를 가지고 있나요? ■

Answer:

ARM에서 리눅스는 atomic_add_return() 함수의 어셈블리어 구현의 앞과 뒤에 smp_mb() 를 넣어두기 때문에 이 특정한 버그는 ARM에는 존재하지 않습니다. PowerPC는 더이상 이 버그를 가지고 있지 않습니다; 이 버그는 오래전에 고쳐졌습니다. 리눅스 커널이 가지고 있을 수도 있는 또 다른 버그들을 찾는 것은 독자 여러분의 몫으로 남겨두겠습니다. □

Quick Quiz 12.27:

Listing 12.30에 보인 것과 같은 리트머스 테스트를 herd로 돌려 보려면 뭘 해야 하나요? ■

Answer:

v4.17(또는 그보다 나중의) 리눅스 커널 소스 코드를 알고, tools/memory-model/README의 설명을 따라서 필요한 도구들을 설치하세요. 이어서 이 도구들을 사용해 여러분이 고른 리트머스 테스트를 수행하기 위해 다음 설명을 따르세요. □

Quick Quiz 12.28:

잠깐만요!!! 포인터를 RCU read-side 크리티컬 섹션 밖으로 훌리는건 심각한 버그가 아닌가요??? ■

Answer:

맞아요, 보통 심각한 버그입니다. 하지만, 이 경우, 업데이트 쓰레드는 그런 포인터 유출을 올바르게 처리할 수 있도록 잘 구성되었습니다. 하지만 이런 종류의 일을 하는 버릇을들이진 마시고, 더 일반적인 방법을 적용하기 위해 충분히 고민하기 전에 이런 방법을 쓰진 말아주세요. □

Quick Quiz 12.29:

Listing 12.33에서, 왜 읽기 쓰레드는 P1() 이 라인 45에서 c의 값을 0으로 만들기 바로 전에 읽어오고, 이 같은 값을 c의 값이 0이 된 뒤에 되돌려 넣어서, 이 0으로 만드는 동작을 의미 없게 만들 수 없나요? ■

Answer:

이 읽기 쓰레드는 라인 24에서 다음 원소로 넘어가기 때문에, 읽어온 값을 같은 원소로의 포인터에 저장하는 걸 막습니다. □

Quick Quiz 12.30:

Listing 12.33에서, 라인 48 바로 앞에서 synchronize_rcu() 를 한번만 호출하면 어떨까요? ■

Answer:

그렇게 하면 P0() 가 메모리 해제된 원소를 접근할 수 있으니까요. 하지만 제 말만 믿지 말고, 직접 herd로 돌려 보세요! □

Quick Quiz 12.31:

Listing 12.33에서도, 라인 48 가 smp_store_release() 대신에 WRITE_ONCE() 를 사용할 순 없나요? ■

Answer:

좋은 질문입니다. 2018년 말 기준으로, 답은 “아무도 모른다”입니다. 많은 부분이 ARMv8의 conditional-move 인스트럭션의 의미 보장에 달려 있습니다. 이 의미가 명확해지기 전까지는 smp_store_release() 를 쓰는게 안전한 선택입니다. □

Quick Quiz 12.32:

하지만 충분히 낮은 단계의 소프트웨어는 모든 의도와 목적에 있어 블랙햇으로부터의 공격에 내성이 있지 않나요? ■

Answer:

불행히도, 그렇지 않습니다.

한번은, Paul E. McKenney는 리눅스 커널 RCU가 그런 공격에 대해 내성이 있다고 생각했는데, Row Hammer의 발전은 그렇지 않음을 보였습니다. 무엇보다도, 그 블랙햇들이 시스템의 DRAM을 건들 수 있다면, 저수준 소프트웨어의 모든 부분을 건들 수 있는데, 여기에 RCU 조차도 포함됩니다. □

Quick Quiz 12.33:

L4 마이크로커널의 전체 검증을 생각해 보면, 이런 정형적 검증에 대한 제한적인 시각은 약간 시대에 뒤쳐진 것 아닌가요? ■

Answer:

안타깝지만, 그렇지 않습니다.

L4 마이크로커널의 첫번째 전체 검증은 많은 수의 Ph.D. 학생들이 각각 매우 느린 속도로 진행한, 손으로 하는 코드 검증으로 이루어진 역작이었습니다. 이런 수준의 노력은 대부분의 소프트웨어 프로젝트들에는 적용될 수가 없는데, 변화의 비율이 너무 거대하기 때문입니다. 더 나아가서, 비록 L4 마이크로커널이 형식적 검증의 시점에서 보기에는 커다란 소프트웨어 작품이긴 합니다만, LLVM, GCC, 리눅스 커널, Hadoop, MongoDB, 그 외의 커다란 많은 것들과 같은 많은 수의 프로젝트들에 비교하면 매우 작은 것입니다. 또한, 이 검증은 일부 연구자들이 인정했듯이, 한계를 가지고 있습니다: https://wiki.sel4.systems/FrequentlyAskedQuestions#Does_seL4_have_zero_bugs.3F.

정형적 검증이 마침내 더 최근의, 커다란 수준의 자동화에 관련된 L4 검증을 포함해서 어떤 전망을 내놓기 시작하고 있기는 하지만, 전망 가능한 미래에 테스트를 완전히 대체할 기회는 현재로써는 보이지 않습니다. 그리고 이 점에 있어서 제가 틀렸다고 증명되면 전 즐거울 겁니다만, 그런 증명은 실제 소프트웨어를 검증하는 실제 도구를 통한 형태여야 하지, 자극적인 미사여구를 통한 형태가 되어선 안될 겁니다.

언젠가는 정형적 검증이 지금은 회귀 검증으로 알려진 영역을 포함해 많은 검증에 사용될 수도 있을 겁니다. Section 17.4에서는 이 가능성성이 현실이 되기 위해 무엇이 필요한지 알아봅니다.

□

G.13 Putting It All Together

Quick Quiz 13.1:

레퍼런스 획득을 단순히 레퍼런스 카운터의 값이 0이 아닌 경우에만 레퍼런스를 획득하는 compare-and-swap 오퍼레이션으로 간단하게 만들지는 않는거죠? ■

Answer:

이 방법이 마지막 레퍼런스의 해제와 새로운 레퍼런스 획득 사이의 경주를 해결할 수는 있겠지만, 데이터 구조체가 해제되고 전혀 다른 종류의 구조체로 재할당되는 것을 방지하는데에 있어서는 어떤 일도 해주지 않습니다. “간단한 compare-and-swap 오퍼레이션”이 다른 종류의 구조체에 적용되면 정의되지 않은 결과를 낼 가능성이 상당히 큽니다.

짧게 말해서, compare-and-swap 과 같은 어토믹 오퍼레이션의 사용은 타입 안정성이나 존재 보장을 필요로 합니다. □

Quick Quiz 13.2:

한 CPU 가 마지막 레퍼런스를 해제한 직후에 다른 CPU 가 레퍼런스를 획득하는 경우에 대해서도 보호를 해줘야 하지 않나요? ■

Answer:

CPU 는 합법적으로 다른 레퍼런스를 얻기 위해서는 이미 레퍼런스를 가지고 있어야 하기 때문입니다. 따라서, 한 CPU 가 마지막 레퍼런스를 해제했다면, 새로운 레퍼런스를 획득할 수 있는 CPU 는 존재할 수가 없습니다. 이와 같은 사실이 Listing 13.2 의 line 22 의 어토믹하지 않은 검사를 가능하게 합니다. □

Quick Quiz 13.3:

Listing 13.2 의 line 22 에서 atomic_sub_and_test() 가 호출된 직후에, 어떤 다른 CPU 가 kref_get() 을 호출했다고 생각해 봅시다. 이는 이 다른 CPU 가 이제 비합법적으로 해제된 오브젝트로의 레퍼런스를 갖게 된 거 아닌가요? ■

Answer:

그런 일은 이 함수가 올바르게 사용된다면 일어날 수 없는 일입니다. 이미 레퍼런스를 가지고 있지 않다면 kref_get() 을 호출하는 것은 비합법적인 일어서 kref_sub() 는 카운터의 값을 0으로 감소시킬 수 없었을 겁니다. □

Quick Quiz 13.4:

kref_sub() 가 0을 리턴해서 release() 함수가 호출되지 않았음을 알렸다고 생각해 봅시다. 어떤 조건에서 호출자는 이 오브젝트의 존재의 지속에 의존할 수 있을까요? ■

Answer:

호출자는 최소 하나의 레퍼런스가 계속해서 존재할 것임을 알지 못한다면 오브젝트의 존재 지속에 의존할 수 없습니다. 일반적으로, 호출자는 이를 알 방법이 없을 것이고, 따라서 kref_sub() 후에 오브젝트를 참조하는 것을 주의깊게 피해야만 합니다. □

Quick Quiz 13.5:

왜 그냥 해제 함수로 kfree() 를 넘기지 않는거죠? ■

Answer:

일반적으로 kref 구조체는 더 커다란 구조체에 포함되어 있게 되므로, kref 필드만이 아니라 전체 구조체를 해제시킬 필요가 있습니다. 이는 일반적으로 container_of() 와 kfree() 를 호출하는 wrapper 함수를 정의하는 것으로 이뤄질 수 있습니다. □

Quick Quiz 13.6:

레퍼런스 카운트의 값이 0인지에 대한 검사는 왜 간단히 어토믹 값 증가 오퍼레이션을 갖는 “if” 문의 “then” 절에 들어갈 수 없는거죠? ■

Answer:

“if” 조건이 완료되었고 레퍼런스 카운터의 값이 1이라는 걸 알게 되었다고 해봅시다. 이어서 레퍼런스 해제 오퍼레이션이 실행되어서 이 레퍼런스 카운터의 값을 0으로 바꾸었고 오브젝트 해제 오퍼레이션을 시작시킵니다. 하지만 이제 “then” 절은 이 카운터의 값을 다시 1로 증가시킬 수가 있어서 오브젝트가 해제된 후에 사용되는 상황을 가능하게 해버리고 맙니다. □

Quick Quiz 13.7:

어토믹하지 않은 `atomic_read()` 와 `atomic_set()` 이라구요? 이건 또 무슨 농담이죠??? ■

Answer:

그렇게 보일수도 있겠습니다만, 현재 문제시 되는 어토믹 변수에 어떤 다른 CPU도 접근을 하지 않는 상황에서는 실제 어토믹 인스트럭션의 오버헤드는 낭비가 될 수 있습니다. 다른 CPU가 접근하지 안는 경우의 두 가지 예는 초기화와 정리 작업입니다. □

Quick Quiz 13.8:

대체 왜 그런 글로벌 락이 필요했던 거지요? ■

Answer:

특정 쓰레드의 `__thread` 변수들은 그 쓰레드가 종료될 때 없어집니다. 따라서 다른 쓰레드의 `__thread` 변수들을 접근하는 모든 오퍼레이션은 쓰레드 종료와 동기화되어야 할 필요가 있습니다. 그런 동기화가 없다면, 방금 종료된 쓰레드의 `__thread` 변수로의 접근은 `segmentation fault`를 초래할 겁니다. □

Quick Quiz 13.9:

어쨌든, `read_count()` 의 정확성을 대체 뭘까요? ■

Answer:

Page 49 의 Listing 5.5 를 참고하세요. 동시적인 `inc_count()` 의 실행이 존재하지 않는다면, `read_count()` 는 분명한 결과를 내놓을 것은 분명합니다. 하지만, `inc_count()` 의 동시적인 실행이 존재한다면, 그 합계 값은 `read_count()` 가 그 합산을 진행함에 따라 실제로 달라질 것입니다. 그렇다면 하나, 쓰레드의 생성과 종료는 `final_mutex` 에 의해 배제되므로, `counters` 안의 포인터들은 상수로 유지될 것입니다.

메모리의 즉석 스냅샷을 얻어올 수 있는 가상의 기계를 상상해 봅시다. 이 기계가 `read_count()` 의 실행 시작지점의 스냅샷과 `read_count()` 의 실행 종료 지점의 스냅샷을 만들어낸다고 생각해 봅시다. 그렇다면

`read_count()` 는 이 두 스냅샷들 사이의 어떤 시점에서의 각 쓰레드의 카운터에 접근을 할 것이고, 따라서 이 두개의 스냅샷들에 의해 값이 포괄적으로 한정지어지는 결과를 얻어오게 될 것입니다. 따라서, 전체 합계는 이 두개의 스냅샷으로부터 각각 얻어와질 수 있는 합계들의 쌍에 의해 그 값이 한정지어질 것입니다 (다시 말하지만, 포괄적으로).

따라서 예상되는 에러는 이 두개의 스냅샷으로부터 얻어올 수 있는 두개의 합계의 쌍들 사이의 차이의 절반일 것이고, 이는 `read_count()` 의 실행 시간에 단위 시간당 `inc_count()` 의 예상되는 호출 횟수를 곱한 값의 절반입니다.

또는, 수식을 선호하는 분들을 위해 표시하면:

$$\epsilon = \frac{T_r R_i}{2} \quad (G.12)$$

로, ϵ 는 `read_count()` 의 리턴 값에 예측되는 에러이고, T_r 은 `read_count()` 가 실행되는데 걸리는 시간이고, R_i 는 단위 시간당 `inc_count()` 호출 횟수의 비율입니다. (그리고 당연하지만, T_{mr} 과 R_i 는 같은 단위 시간을 사용해야 합니다: 마이크로세컨드와 마이크로세컨드당 호출 횟수, 초와 초당 호출 횟수, 뭐가 됐든, 같은 단위를 사용하기만 한다면.) □

Quick Quiz 13.10:

이봐요!!! Listing 13.5 의 line 46 은 앞서 존재한 `countarray` 구조체의 값을 수정하잖아요! 이 구조체는 일단 한번 `read_count()` 에 접근 가능하게 되면 상수로 남게 된다고 하지 않았어요??? ■

Answer:

실제로 전 그렇게 말했습니다. 그리고 `count_unregister_thread()` 가 현재 그렇듯이 `count_register_thread()` 가 새로운 구조체를 할당하도록 하는 것이 가능할 겁니다.

하지만 그건 불필요한 일입니다. 에러가 메모리의 스냅샷에 기반을 둔 `read_count()` 에 의해 최대값이 제한된다는 유도를 다시 생각해 보세요. 새로운 쓰레드들은 그 값이 0인 `counter` 값과 함께 시작되므로, 이 유도는 우리가 `read_count()` 의 실행 중간에 새로운 쓰레드를 추가한다고 해도 지켜집니다. 따라서, 흥미롭게도, 새로운 쓰레드를 추가할 때에, 이 구현은 새로운 구조체를 할당하는 효과를 실제로는 할당을 하지 않으면서도 얻을 수 있게 됩니다. □

Quick Quiz 13.11:

우와! Listing 5.5 는 라인수가 42 밖에 되지 않는데 반해 Listing 13.5 는 69 라인이나 되는군요. 이 추가적인 복잡도가 정말로 가치가 있는 건가요? ■

Listing G.6: Localized Correlated Measurement Fields

```

1 struct measurement {
2     double meas_1;
3     double meas_2;
4     double meas_3;
5 };
6
7 struct animal {
8     char name[40];
9     double age;
10    struct measurement *mp;
11    struct measurement meas;
12    char photo[0]; /* large bitmap. */
13 };

```

Answer:

이는 당연하게도 경우에 따라 다르게 결정되어야 합니다. 선형적으로 확장되는 `read_count()` 구현이 필요하다면, Listing 5.5에 보인 락 기반의 구현은 당신을 위한 동작을 하지 않을 겁니다. 반면에, 만약 `count_read()`의 호출이 충분히 드물다면, 락 기반 버전이 더 간단하고 따라서 더 나을 수도 있습니다. 대부분의 크기 차이는 구조체 정의, 메모리 할당, 그리고 NULL 리턴 체크로 인한 것이니 하지만 말입니다.

물론, 더 나은 질문은 “왜 이 언어는 `__thread` 변수들로의 쓰레드를 넘어서는 접근을 구현하지 않는거죠?”가 될겁니다. 무엇보다, 그런 구현은 락킹과 RCU의 사용을 불필요하게 만들 겁니다. 이는 결국 Listing 13.5에 보여진 구현의 확장성과 성능상의 이득에 더해서 Listing 5.5에 보여진 것보다도 더 간단한 구현이 가능하게 할 겁니다! □

Quick Quiz 13.12:

하지만 Listing 13.9에 보인 방법은 추가적인 캐시 미스를 초래할 수 있어서, 추가적인 읽기 쪽의 오버헤드를 초래할 수 있지 않나요? ■

Answer:

실제로 그럴 수 있습니다.

이 캐시 미스 오버헤드를 없애기 위한 한가지 방법이 Listing G.6에 보여져 있습니다: 간단히 `measurement` 구조체의 인스턴스 하나를 `meas`라는 이름으로 `animal` 구조체 내에 내장시키고, `->mp` 필드를 통해 이 `->meas` 필드를 가리키는 것이죠.

측정치 업데이트는 이제 다음과 같이 진행될 수 있습니다:

1. 새로운 `measurement` 구조체를 할당하고 새로운 측정치를 그 안에 집어넣습니다.
2. `rcu_assign_pointer()`를 사용해서 `->mp`가 이 새로운 구조체를 가리키도록 합니다.

3. 하나의 grace period 가 지나가길 기다리는데, 예를들어 `synchronize_rcu()`나 `call_rcu()`를 사용합니다.
4. 새로운 `measurement` 구조체의 측정치들을 내장된 `->meas` 필드로 복사합니다.
5. `rcu_assign_pointer()`를 사용해서 `->mp`가 다시 이 기존의 내장된 `->meas` 필드를 가리키도록 합니다.
6. 또 다른 하나의 grace period 가 지나간 후, 새로운 `measurement` 구조체를 메모리에서 해제시킵니다.

이 방법은 일반적인 경우에서의 추가적인 캐시 미스를 제거하기 위해 더 무거운 업데이트 절차를 사용합니다. 이 추가적인 캐시 미스는 업데이트가 실제로 진행중일 때에만 일어날 겁니다. □

Quick Quiz 13.13:

하지만 이 스캐닝은 크기 재조정이 되고 있는 크기 재조정 가능한 해시 테이블에 대해서는 어떻게 동작하나요? 그런 경우, 기존의 해시테이블도 새로운 해시테이블도 해당 해시 테이블에 모든 원소들을 담고 있다고 보장될 수 없는데요! ■

Answer:

사실입니다, Section 10.4에서 이야기된 크기 재조정 가능한 해시 테이블들은 크기 재조정 진행 중에 모두 스캔 될 수 없습니다. 이를 위한 한가지 간단한 방법은 `hashtab` 구조체의 `->ht_lock`을 스캐닝 중에 잡는 것입니다만, 이 방법은 두개 이상의 스캔이 동시에 진행되지 못하도록 합니다.

또 다른 방법은 크기 재조정 진행 중에는 업데이트들이 새로운 해시 테이블만이 아니라 기존의 것도 변형시키도록 하는 것입니다. 이는 스캐닝이 기존의 해시 테이블에서도 모든 원소들을 볼 수 있도록 합니다. 이를 구현하는 것은 독자 여러분의 뜻으로 남겨두겠습니다. □

G.14 Advanced Synchronization

Quick Quiz 14.1:

배터리로 동작하는 시스템의 경우에는 어떻죠? 그것들은 그 시스템으로 흘러들어오는 에너지를 전혀 필요로 하지 않아요. ■

Answer:

금방이든 나중이든, 배터리는 재충전되어야 하는데, 그러지 않으면 그 시스템은 동작을 멈추게 될 것이므로 이는 시스템으로 흘러들어오는 에너지를 필요로 하게 됩니다. □

Quick Quiz 14.2:

하지만 queueing theory에서의 결과를 놓고 생각해 보면, 낮은 리소스 활용률은 평균 응답 시간만을 개선할 뿐이지 최악의 경우의 응답시간은 개선하지 못하지 않을까요? 그리고 최악의 경우에서의 응답시간이야말로 대부분의 real-time 시스템들이 정말로 신경쓰는 것이 아니던가요? ■

Answer:

맞습니다, 하지만 ...

그런 queueing-theory의 결론들은 리눅스 커널이라면 무한한 수의 task 들로 연관될 수 있는, 무한한 “호출하는 인구”를 가정하고 있습니다. 2016년 중반의 시점에서, 어떤 실제 시스템도 무한한 수의 task 들을 지원하지 않으며, 따라서 무한한 호출하는 인구를 가정한 결과는 무한보다는 적은 응용성을 갖게 될 것이라 기대될 겁니다.

또다른 queueing-theory의 결론은 유한한 호출 인구수를 갖는데, 이 경우는 깔끔하게 그 한계가 제한되어 있는 응답 시간을 갖습니다 [HL86]. 이런 결론들은 실제 시스템을 더 잘 모델링 하고, 이런 모델링들은 리소스 활용율의 감소에 따른 평균 응답시간과 최악의 경우 응답시간의 감소를 모두 예측합니다. 이런 결론들은 락킹과 같은 동기화 메커니즘을 사용하는 동시성 시스템을 모델링하는데도 확장될 수 있습니다 [Bra11].

짧게 요약해서, 정확하게 실제 세계의 real-time 시스템을 묘사하는 queueing-theory의 결론들은 줄어드는 리소스 활용율에 따라 최악의 경우의 응답시간도 줄어듬을 보입니다. □

Quick Quiz 14.3:

형식적 검증은 수십년간 집중된 연구로 인해 이미 상당히 실용 가능한 수준입니다. 추가적인 진보가 정말로 필요한 건가요, 아니면 이건 그저 실무자의 게으르기를 계속하고 형식적 검증의 대단한 위력을 무시하려는 변명일 뿐인가요? ■

Answer:

아마도 이 상황은 이론가들의 실제 소프트웨어의 복잡한 세계로 뛰어들지 않기 위한 변명일 수도 있겠는데요? 더 자세히 말해보자면, 다음과 같은 진보가 필요합니다:

1. 형식적 검증은 더 커다란 소프트웨어 작품들을 처리할 수 있어야만 합니다. 행해진 가장 큰 검증은은 약 10,000 라인의 코드를 갖는 시스템에 대한 검증뿐이었고, 그것들은 real-time 응답시간들보다는 훨씬 간단한 속성들에 대한 검증이었습니다.

2. 하드웨어 제조사들은 정형적인 시간 보장사항에 대한 내용을 제공해야 하게 될겁니다. 이는 하드웨어가 훨씬 더 간단했던 시절에는 일반적인 일이었습니다만, 오늘날의 복잡한 하드웨어는 최악의 경우의 성능에 대해서는 과하게 복잡한 표현을 초래하게 되었습니다. 안타깝게도, 에너지 효율성에 대한 관심은 제조사들을 이보다도 더 복잡한 세계로 떠밀고 있습니다.

3. 타이밍 분석은 개발 방법론과 IDE 들에 합쳐질 필요가 있습니다.

그렇게 말했긴 하지만, 최근의 실제 컴퓨터 시스템의 메모리 모델에 대한 정형화 작업 [AMP¹¹, AKNT13]을 놓고 보면 희망이 있습니다. □

Quick Quiz 14.4:

Real-time과 real-time이 아닌 것을 무엇이 “real-time이 아닌 시스템과 어플리케이션에 대해서 간단히 이뤄질 수 있는지”로 구분하는 것은 우스운 일입니다! 그런 구별을 위한 이론적 기초는 전혀 존재치 않아요!!! 더 나은 것을 할 수는 없을까요??? ■

Answer:

이 구분법은 엄격한 이론적 관점에서는 틀림없이 만족스럽지 못합니다. 하지만 한편으로는, 이것은 개발자가 어떤 어플리케이션이 쉽게 짠 비용으로 real-time이 아닌 방법을 사용해서 개발될 수 있는지, 또는 더 어렵고 비싼 real-time 접근법이 필요한지를 결정하기 위해 필요한 것입니다. 달리 말하자면, 이론은 상당히 중요합니다만, 우리처럼 일이 제대로 행해지기를 바라는 사람들에게 있어서는, 이론은 실전을 지원할 뿐이지, 그외의 것은 아닙니다. □

Quick Quiz 14.5:

하지만 reader-writer 락에 대해서 한번에 하나의 read 권한 획득만을 허용한다면, 그건 배타적 락과 똑같은 거 아닌가요??? ■

Answer:

실제로 그렇습니다, API만 제외하고는 말이지요. 그리고 그 API가 중요한데, 그게 리눅스 커널이 -rt 패치셋이 웃기도록 커다란 크기로 커지지 않고도 real-time 기능들을 제공하도록 해주기 때문에 중요합니다.

하지만, 이 방법은 read-side 의 확장성을 분명하고 상당히 제한합니다. 리눅스 커널의 -rt 패치셋은 몇 가지 이유들로 인해 이 한계점들을 가지기로 했습니다: (1) Real-time 시스템은 전통적으로 상대적으로 작은 크기였고, (2) Real-time 시스템은 일반적으로 프로세스 제어에 중점을 두었으므로, I/O 서브시스템에서의 확장성 제한에 영향을 받지 않을 것이며, (3) 많은 리눅스 커널의 reader-writer 락은 RCU 로 변경되었습니다.

그렇다고는 하나, 리눅스 커널이 언젠가는 우선순위 증폭을 위해 reader-writer 락의 read-side 병렬성에 제한을 주는 상황은 가능합니다. □

Quick Quiz 14.6:

Listing 14.2 의 line 17 에서의 `t->rcu_read_unlock_special.s` 의 로드 직후에 preemption 이 발생했다고 생각해 봅시다. 그렇게 되면 해당 task 가 `rcu_read_unlock_special()` 를 수행시키지 못하게 되어서, 자기 자신을 현재 grace period 를 막고 있는 task 들의 리스트로부터 삭제하는 것을 막아서, 그 grace period 가 무한정 길어질 수 있도록 할 수 있지 않을까요? ■

Answer:

그건 실제로 문제이고, RCU 의 스케줄러 쪽 후킹을 통해 해결되어졌습니다. 만약 그 후킹된 scheduler 코드가 `t->rcu_read_lock_nesting` 의 값이 음수임을 보게 된다면, 그 코드는 컨텍스트 스위치가 완료되도록 하기 전에 필요하다면 `rcu_read_unlock_special()` 을 호출합니다. □

Quick Quiz 14.7:

하지만 fail-stop 베그에도 불구하고 올바르게 동작하는 게 가치있는 fault-tolerance 속성 가운데 하나 아닌가요? ■

Answer:

그렇고 아닙니다.

Non-blocking 알고리즘들이 fail-stop 베그들의 존재 하에서도 fault tolerance 를 제공할 수 있다는 점에서 그려합니다만, 이는 실질적인 fault tolerance 에는 심하게 충분치 못하다는 점에서 그렇지 않습니다. 예를 들어, 여러분이 wait-free 대기열을 가지고 있고, 방금 하나의 원소를 거기서 꺼낸 쓰레드가 하나 있다고 생각해 보세요. 만약 그 쓰레드가 fail-stop 베그로 죽는다면, 이 쓰레드가 막 꺼낸 원소는 실질적으로는 잃어버리게 된 겁니다. 진정한 fault tolerance 는 단순한 non-blocking 속성보다 더한 것을 필요로 하고, 그것은 이 책의 범위 밖의 것입니다. □

Quick Quiz 14.8:

전 잘 모르겠지만 이 리스트 앞에 “포함한다” 는 단어를 봤어요. 다른 제약도 존재하는 건가요? ■

Answer:

실제로 존재하구요, 많은 것들이 존재합니다. 하지만, 그것들은 그것들은 특정 상황에 종속적인 경향을 갖고, 그중 많은 것들은 앞서 언급된 제약들의 세련된 형태로 생각될 수 있습니다. 예를 들어, 데이터 구조의 선택에 있어서의 많은 제약들은 “모든 크리티컬 섹션은 제한된 길이의 시간만을 소모해야함” 제약을 지키는데 도움이 될겁니다. □

Quick Quiz 14.9:

Real-time 시스템들은 많은 경우 safety-critical 어플리케이션들에 사용된다는 점을 놓고 보면, 그리고 수행시간 메모리 할당은 많은 safety-critical 상황에서 숨겨진다는 점을 생각해보면, `malloc()` 호출은 뭐때매 있는거죠??? ■

Answer:

2016년 초에 있어, 수행 시간 메모리를 숨기는 상황이 멀티쓰레드 컴퓨팅에서 그렇게까지 신나지는 않습니다. 따라서 수행시간 메모리 할당은 safety criticality 에 추가적인 장애는 아닙니다. □

Quick Quiz 14.10:

`update_cai()` 을 보호하기 위해 어떤 동기화가 필요하지 않나요? ■

Answer:

실제로 그렇고, 여러분은 이 책의 앞에서 이야기된 기술들을 얼마든지 사용할 수 있습니다. □

G.15 Advanced Synchronization: Memory Ordering

Quick Quiz 15.1:

이 글은 첫번째 버전 후 거의 완전히 다시 쓰여졌습니다. 메모리 순서 규칙은 2017년 후반에는 그렇게 많이 바뀌지 않았을 텐데, 뭘 다시 쓴 걸까요? ■

Answer:

초기의 이 섹션은 2005년에 쓰여진 리눅스 저널의 기사 두개 [McK05a, McK05b] 를 그 근간으로 했습니다. 그때 후로, C 와 C++ 메모리 모델 [Bec10] 가 정형화 되었고 (그리고 비평당했습니다 [BS14, BD14, VBC¹⁵, BMN¹⁵, LVK¹⁷, BGV17]), 컴퓨터 시스템들을 위한 실행될 수 있는 정식 메모리 모델들이 표준이 되었고 [MSS12, McK11c, SSA¹¹, AMP¹¹, AKNT13, AKT13, AMT14, MS14, FSP¹⁷, ARM17], 리눅스 커널을 위한 메모리 모델조차 생겼습니다 [AMM^{17a}, AMM^{17b}, AMM¹⁸].

2005년 후의 이런 진행사항 때문에, 그동안은 완전한 재작성의 적기였습니다! □

Quick Quiz 15.2:

컴파일러도 Listing 15.1 의 Thread P0() 와 Thread P1() 의 메모리 액세스 순서를 바꿀 수 있죠, 그렇죠? ■

Answer:

일반적으로, 컴파일러 최적화는 CPU 가 할 수 있는 것보다 더 극단적이고 심오한 순서 재배치를 가져옵니다. READ_ONCE() 와 WRITE_ONCE() 는 컴파일러가 순서를 재배치 하는걸 막아줍니다. 그리고 그외에도 많은 걸 막아주기 때문에, 이 섹션에서의 예제들은 READ_ONCE() 와 WRITE_ONCE() 를 많이 사용할 겁니다. READ_ONCE() 와 WRITE_ONCE() 에 대한 자세한 정보를 위해선 Section 15.3 을 참고 바랍니다. □

Quick Quiz 15.3:

하지만 잠시만요!!! Table 15.1 의 row 2 에서 x0 와 x1 모두 동시에 두개의 값, 0 과 1 을 가지고 있어요. 어떻게 이게 가능한거죠??? ■

Answer:

나중에 이야기 하겠지만, 아래쪽에 좀 더 일을 빠듯하게 처리되도록 하는 cache-coherence 프로토콜이 존재하는데, Appendix C.2 에서 이에 대해 다릅니다. 하지만 어떤 변수가 동시에 두개의 값을 갖는다는게 신기하다고 생각하신다면, Section 15.2.1 까지 잠깐 기다려 주시기 바랍니다. □

Quick Quiz 15.4:

하지만 이 값들은 또다시 캐시에서 메인 메모리로 비워져야 하는거 아닌가요? ■

Answer:

놀라울 수 있겠지만, 꼭 그럴 필요는 없습니다! 어떤 시스템들에서는, 두개의 변수들이 빈번하게 사용된다면, 이 변수들은 CPU 의 캐시들 사이에서 움직이게 되고 메인 메모리에는 위치하지 않게 됩니다. □

Quick Quiz 15.5:

Table 15.3 의 열들은 상당히 무작위적이고 복잡해 보입니다. 이 표의 개념적 근본이 무엇인가 있나요? ■

Answer:

각 열들은 전력과 오버헤드가 증가되는 하드웨어 메커니즘들에 대략적으로 연관되어 있습니다.

WRITE_ONCE() 행은 “SV” 열로 표시되듯이 하나의 변수로의 액세스는 항상 완벽히 순서잡힌다는 사실을 사용합니다. 여러 변수들로의 접근들에 대해 순서를 제공하는 모든 다른 오퍼레이션들 또한 이 같은-변수 순서 규칙을 제공한다는 걸 알아두시기 바랍니다.

READ_ONCE() 열은 (2018 년에 있어) 컴파일러들과 CPU 들은 사용자가 볼 수 있는 예측적 스토어를 탐닉하지 않아서, 주소, 데이터, 또는 수행이 앞의 로드에 의존적인 모든 스토어는 해당 로드가 완료된 후에 행해진다는 사실을 사용합니다. 하지만, 이 보장사항은 Sections 15.3.2 과 ?? 에서 설명된 대로 의존성이 주의 깊게 구성되었다는 가정 아래의 이야기입니다.

“_relaxed() RMW operation” 열은 값을 리턴하는 _relaxed() RMW 는 로드와 스토어를 한다는 사실을 보이는데, 이 로드와 스토어는 READ_ONCE() 와 WRITE_ONCE() 만큼 좋은 효과를 냅니다.

smp_read_barrier_depends() 열은 DEC Alpha 의 예외가 있긴 하지만, 컴파일러들과 CPU 들은 사용자가 볼 수 있는 주소 의존성들은 깨지 않는다는 사실을 사용하는데, 역시 이 의존성들이 Section 15.3.2 에서 설명한 대로 주의 깊게 구성되었다는 가정 하이긴 합니다. 하지만, v4.15 리눅스 커널 기준으로, READ_ONCE() 는 의존성 순서 규칙을 제공한다는 사실은 smp_read_barrier_depends() 의 필요를 줄임을 의미합니다.

*_dereference() 열은 rCU_dereference() 등에 의해 제공되는 주소와 데이터 종속성 순서 규칙을 사용합니다.

“Successful *_acquire()” 열은 많은 CPU 가 특별한 “acquire” 형태의 로드와 atomic RMW 인스트럭션들을 가지고 있으며, 많은 다른 CPU 가 앞의 로드들을 뒤의 로드들과 스토어들에 대해 순서 맞춰주는 가벼운 메모리 배리어 인스트럭션을 가지고 있다는 사실을 사용합니다.

“Successful *_release()” 열은 많은 CPU 가 특수한 “release” 형태의 store 와 atomic RMW 인스트럭션들을 가지고 있으며, 많은 다른 CPU 가 앞의 로드들을 뒤따르는 스토어들에 대해 순서 맞춰주는 가벼운 메모리 배리어 인스트럭션들을 가지고 있다는 사실을 사용합니다.

smp_rmb() 열은 많은 CPU 들이 앞의 로드들을 뒤따르는 로드들에 대해 순서맞춰주는 가벼운 메모리 배리어 인스트럭션들을 가지고 있다는 사실을 사용합니다. 비슷하게, smp_wmb() 열은 많은 CPU 들이 앞의 스토어들을 뒤따르는 스토어들에 대해 순서맞춰주는 가벼운 메모리 배리어 인스트럭션들을 가지고 있다는 사실을 사용합니다.

따라서 이 순서 맞추기 오퍼레이션들 중 어느것도 앞의 스토어들이 뒤따르는 로드들에 대해 순서맞춰줄 것을 요구하지 않는데, 이는 이 오퍼레이션들이 앞의 스토어들을 뒤따르는 로드들에 대해 재배치하는 게 삶의 목표인 스토어 베피에 간섭하지 않는다는 것을 의미합니다. 이런 오퍼레이션들의 비용이 가벼운 것은 이 오퍼레이션들의 스토어 베피에 간섭하지 않는다는 정책 덕분입니다.

`smp_mb()` 열은 Itanium 의 예외가 있지만 대부분의 플랫폼에서 사용 가능한 전체 메모리 배리어에 연관됩니다. 하지만, Itanium 에서 조차, `smp_mb()` 는 Section 15.4.4 에서 이야기되는 것처럼 `READ_ONCE()` 와 `WRITE_ONCE()` 에 대해 `smp_mb()` 가 완전한 순서를 제공합니다.

“Successful Non-Relaxed None-void RMW” 열은 (x86 과 같은) 일부 플랫폼에서 `atomic RMW` 인스트럭션들은 그 앞과 뒤 사이에 전체 순서 규칙을 제공한다는 사실을 사용합니다. 따라서 리눅스 커널은 full-strength non-void `atomic RMW` 오퍼레이션들이 이 오퍼레이션들이 성공한 경우에 대해서는 전체 순서 규칙을 제공할 것을 요구합니다. (full-strength `atomic RMW` 오퍼레이션의 이름들은 `_relaxed`, `_acquire`, 또는 `_relaxed`로 끝나지 않습니다.) 앞서 언급되었듯, 이 오퍼레이션들이 성공하지 못한 경우는 “`_relaxed()` RMW operation” 행에 다루어져 있습니다.

하지만, 리눅스 커널은 `atomic_inc()` 와 같은 `void` 또는 `_relaxed()` `atomic RMW` 오퍼레이션들에 대해서는 어떠한 순서 보장도 제공할 것을 요구하지 않습니다, `atomic_inc()` 의 예에서처럼요. 따라서, 이 오퍼레이션들과 실패한 non-void `atomic RMW` 오퍼레이션들은 앞의, 또는 뒤의 메모리 액세스 모두에 대해 완전한 순서를 보장하기 위해 `smp_mb__before_atomic()` 을 앞세우고 뒤에 `smp_mb__before_atomic()` 을 뒤에 배치해야 할 겁니다. 이 표의 `smp_mb__before_atomic()` 과 `smp_mb__after_atomic()` 열의 “a” 항목이 이야기 하듯이, `smp_mb__before_atomic()` (또는, 유사하게, `smp_mb__after_atomic()`) 과 `atomic RMW` 오퍼레이션 사이에서는 어떤 메모리 접근에 대해서도 순서 보장을 제공할 필요가 없습니다.

요약해서, 이 테이블에서의 모든 무작위성은 그 아래에 위치한, Chapter 3 에서 앞서 설명된 대로 물리 법칙에 의해서만 제약되는 하드웨어의 특성 탓입니다. □

Quick Quiz 15.6:

Table 15.3 은 왜 `smp_mb__after_unlock_lock()` 과 `smp_mb__after_spinlock()` 을 빼먹고 있나요? ■

Answer:

이 두 기능들은 좀 더 특수화 되어 있고, 현재로썬 Table 15.3 에 맞추기 어려워 보입니다. `smp_mb__after_unlock_lock()` 기능은 락 획득 직후에 위치되도록 되었고, 이 기능은 모든 CPU 들이 앞의 크리티컬 섹션들의 액세스들이 해당 `smp_mb__after_unlock_lock()` 를 뒤따르는 모든 액세스들보다, 그리고 모든 뒤의 크리티컬 섹션의 액세스들보다 전에 이루어진 것으로 보이도록 보장합니다. 여기서 “모든 CPU 들” 은 해당 락을 잡지 않은 CPU 들도 포함하며, “앞의 크리티컬 섹션” 은 해당 락을 잡는 앞의 크리티컬 섹션은

물론이고 `smp_mb__after_unlock_lock()` 을 수행한 CPU 에서 해제한 모든 다른 락들을 사용하는 크리티컬 섹션들을 포함합니다.

`smp_mb__after_spinlock()` 은 `smp_mb__after_unlock_lock()` 과 같은 보장을 제공하지만, 또한 `smp_mb__after_spinlock()` 을 수행한 CPU 에 의해 수행된 다른 액세스들이 보일 것에 대한 추가적 보장을 제공합니다. 어떤 스토어 S 가 앞의 어떤 락 획득 전에 수행되었고 어떤 로드 L 이 `smp_mb__after_spinlock()` 뒤에 수행되었다면, 모든 CPU 들은 S 가 L 전에 일어난 것으로 보게 됩니다. 달리 말하면, 어떤 CPU 가 스토어 S 를 수행하고, 락을 잡고, `smp_mb__after_spinlock()` 을 수행하고서, 로드 L 을 수행한다면, 모든 CPU 들은 S 가 L 전에 일어난 것으로 보게 됩니다. □

Quick Quiz 15.7:

하지만 특정 프로젝트가 이 경험으로부터의 법칙들의 범위 내에서 설계되고 코딩 될 수 있다고 알 수 있죠? ■

Answer:

이 챕터의 나머지 부분들의 대부분의 목적은 정확히 이 질문에 답하는 것입니다! □

Quick Quiz 15.8:

특정 상황에서 어떤 메모리 배리어들이 충분히 강력한지 어떻게 이야기 할 수 있나요? ■

Answer:

아, 그건 답변하는데 이 챕터의 나머지 부분의 대부분을 필요로 할 만큼 깊은 질문입니다. □

Quick Quiz 15.9:

잠깐만요!!! 자동으로 리트머스 테스트들을 분석하는 이 도구들은 어디서 찾을 수 있나요??? ■

Answer:

v4.17 (또는 그보다 최신의) 리눅스 커널 소스 코드를 얻어오고, 필요한 도구들을 설치하기 위해 `tools/memory-model/README` 의 가이드를 따르세요. 그리고 나선 여러분이 고른 리트머스 테스트에 대해 이 도구들을 실행시키기 위한 가이드를 더 따라가세요. □

Quick Quiz 15.10:

Listing 15.3 의 코드에서의 어떤 가정이 실제 하드웨어에서는 성립하지 않을까요? ■

Answer:

이 코드는 특정 CPU 가 자신의 값을 보는 것을 멈추자마자, 곧바로 마지막으로 동의된 값을 보게 될 것이라 가정합니다. 실제 하드웨어에서, 어떤 CPU 들은 이 마지막 값을 보게 되기 전에 중간의 결과를 일부 보게 될 수도 있습니다. 따라서 이 섹션의 뒤에서 이야기될 그림들의

데이터를 만드는데 사용된 실제 코드는 좀 더 복잡합니다. □

Quick Quiz 15.11:

어떻게 CPU 들이 하나의 변수를 동시에 서로 다르게 볼 수가 있는거죠? ■

Answer:

Section 15.1.1 에서 논의된 대로, 많은 CPU 들이 최근의 스토어 값을 기록하는 스토어 베퍼를 가지고 있으며, 이 값은 연관된 캐시 라인이 해당 CPU 로 올라오기 전에는 외부에 보여지지 않습니다. 따라서, 각 CPU 가 하나의 시점에 특정 변수에 대해 서로 다른 값을 보고 있는 것이—그리고 메인 메모리는 또 다른 값을 가지고 있는 것이 가능합니다. 메모리 배리어가 발명된 이유들 중 하나는 소프트웨어가 이런 종류의 상황을 우아하게 처리할 수 있도록 해주기 위함이었습니다. □

Quick Quiz 15.12:

CPU 1 과 4 는 값을 동의하는데에 그렇게 오랜 시간이 걸렸는데, CPU 2 와 3 은 어떻게 그렇게 빨리 값에 동의하는 건가요? ■

Answer:

CPU 2 와 3 은 같은 코어의 하드웨어 쓰레드들이어서 같은 캐시 계층을 공유하며, 따라서 매우 낮은 통신 응답시간을 갖습니다. 이게 NUMA, 또는, 보다 정확히는, NUCA 효과입니다.

이는 CPU 2 와 3 가 왜 값에 대해 동의하지 않는 순간이 존재하긴 하는가에 대한 질문을 떠올리게 합니다. 가능한 한가지 이유는 이들이 커다란 공유된 캐시 외에 작은 개별 캐시를 갖고 있을 수 있다는 것입니다. 여기서의 짧은 10-나노세컨드 동안의 비동의된 시간과 해당 코드에 메모리 순서 강제 오퍼레이션이 아예 없었다는 것을 놓고 보면, 또 다른 가능할 법한 이유는 인스트럭션 재배치입니다. □

Quick Quiz 15.13:

하지만 왜 load-load 재배치를 사용자가 볼 수 있게 하나요? 겹치는 스토어가 없는 일반적인 경우에만 예측적 수행을 진행할 수 있게 해서 이 재배치가 보이지 않게 하는게 어떤가요? ■

Answer:

그럴 수 있고 많이들 그렇니다만, 강한 순서 규칙의 CPU 를 갖는 시스템들은 실제로 조금 느릴 수 있습니다. 하지만, 예측적 수행은 약점도 갖는데, 특히 예측이 자주 틀려서 롤백해야 하는 경우, 그리고 배터리로 동작하는 시스템에서 그렇습니다. 하지만 미래의 시스템은 이런

약점을 극복할 수도 있을 겁니다. 그 전까지는, 우린 제조사가 완화된 순서의 CPU 를 계속 만들거나 예상할 수 있겠습니다. □

Quick Quiz 15.14:

강력한 순서규칙의 시스템들은 불필요한 `smp_rmb()` 와 `smp_wmb()` 호출로 인한 성능 비용을 왜 지불해야 하죠? 완화된 순서규칙의 시스템들은 자신들의 순서를 지켜주지 않는 선택으로 인한 모든 비용을 책임져야 하지 않나요? ■

Answer:

실제로 그렇게 되고 있습니다. 강력한 순서규칙의 시스템에서, `smp_rmb()` 와 `smp_wmb()` 는 어떤 인스트럭션도 만들지 않고, 대신 캠파일러를 제약할 뿐입니다. 따라서, 이 경우, 완화된 순서규칙의 시스템들은 실제로 그들의 메모리 순서 규칙상의 선택으로 인한 모든 비용을 책임지고 있습니다. □

Quick Quiz 15.15:

하지만 정말로 모든 플랫폼에서 Listing ?? 과 15.11 의 `exists` 절이 발동되지 않는다는 걸 어떻게 알 수 있죠? ■

Answer:

여기에 답변을 하기 위해선 먼저 플랫폼들을 세개의 큰 그룹으로 나눠 볼 필요가 있습니다: (1) Total-store-order (TSO) platform, (2) Weakly ordered platform, 그리고 (3) DEC Alpha 입니다.

TSO 플랫폼은 앞의 스토어들을 뒤의 로드에 대해서 재배치 할 수 있는 걸 제외하곤 모든 메모리 레퍼런스들의 순서를 지켜줍니다. Listing ?? 의 line 21 과 22 의 address dependency 는 로드 뒤에 로드가 따라오는 형태이므로, TSO 플랫폼은 이 address dependency 를 지켜줍니다. 이 플랫폼들은 또한 Listing 15.11 의 line 20 과 21 에서의 address dependency 도 지켜주는데, 이것은 로드 뒤에 스토어가 따라오는 형태이기 때문입니다. Address dependency 는 로드로 시작되어야만 하기 때문에, TSO 플랫폼들은 암묵적으로, 하지만 완벽하게 address dependency 를 지켜줍니다.

Weakly ordered platform 들은 관계되지 않은 액세스들의 순서는 지켜주지 않을 수 있습니다. 하지만, Listing ?? 과 15.11 의 address dependency 는 관계가 없지 않습니다: address dependency 가 존재합니다. 이 하드웨어는 종속성을 추적하고 필요한 순서 규칙을 지켜줍니다.

Weakly ordered platform 에서 이 규칙에 대한 하나의 (유명한) 예외가 있는데, 그 예외는 DEC Alpha 의 load-to-load address dependency 입니다. 그리고 이게 v4.15 전의 리눅스 커널에서 DEC Alpha 가 Listings ?? 의

line 21에 `lockless_dereference()`를 통한 명시적 메모리 배리어 제공을 필요로 하는 이유입니다. 하지만, DEC Alpha도 load-to-store address dependency는 추적을 하며, 이 때문에 v4.15 전 리눅스 커널이라 해도 Listings 15.11의 line 20에 `lockless_dereference()`가 필요 없는 것입니다.

정리해 보면, 현존하는 플랫폼들은 TSO 플랫폼들 (x86, mainframe, SPARC, ...)과 같이 address dependency를 지켜주거나, address dependency를 추적하는 하드웨어를 가지고 있거나 (ARM, PowerPC, MIPS, ...), 또는 `READ_ONCE()`를 통해 제공되는, 필요한 메모리 배리어를 가지고 있거나 (v4.15와 이후 리눅스 커널에서의 DEC Alpha), `rcu_dereference()`에 의해 제공되는 메모리 배리어를 필요로 합니다 (v4.14 이전 리눅스 커널에서의 DEC Alpha). □

Quick Quiz 15.16:

SP, MP, LB, 그리고 이제는 S. 이 리트머스 테스트의 약어들은 모두 어디서 왔고 사람들은 이걸 어떻게 외우죠?

Answer:

최고의 성적표는 악명 높은 `test6.pdf` [SSA+11]입니다. 불행히도, 모든 약자들이 SB (store buffering), MP (message passing), 그리고 LB (load buffering) 같이 외우기 쉬운 약자는 아니지만, 약자들의 리스트는 있습니다. □

Quick Quiz 15.17:

잠깐만요!!! Listing 15.12의 line 18은 로드는 `volatile`로 마킹하는 `READ_ONCE()`를 사용하는데, 이 말은 컴파일러가 설명 그 값이 나중에 0으로 곱해진다 해도 로드 인스트럭션을 만들어 내야 함을 의미합니다. 그런데도 컴파일러가 data dependency를 깨지 못하도록 그렇게 까지 고생을 해야 하나요? □

Answer:

맞습니다, 컴파일러는 `volatile` 로드에 대해선 반드시 로드 인스트럭션을 만들어 내야 하는게 분명합니다. 하지만 그렇게 로드된 값을 0으로 곱한다면, 컴파일러는 그 곱셈의 결과를 상수 0으로 바꿀 수 있으며, 이는 많은 플랫폼에서 data dependency를 깨버립니다.

더 나쁜건, 이 종속된 스토어가 `WRITE_ONCE()`를 사용하지 않는다면, 컴파일러는 이 스토어를 로드 위로 들어올려서, TSO 플랫폼에서 조차도 순서규칙을 제공하지 못하게 만들 수 있습니다. □

Quick Quiz 15.18:

프로그래밍 언어 표준에 지켜진다고 되어있으면, control dependency는 더 믿을만 하지 않을까요??? □

Listing G.7: Litmus Test Distinguishing Multicopy Atomic From Other Multicopy Atomic

```

1 C C-MP-OMCA+o-o-o+o-rmb-o
2
3 {
4 }
5
6 P0(int *x, int *y)
7 {
8     int r0;
9
10    WRITE_ONCE(*x, 1);
11    r0 = READ_ONCE(*x);
12    WRITE_ONCE(*y, r0);
13 }
14
15 P1(int *x, int *y)
16 {
17     int r1;
18     int r2;
19
20     r1 = READ_ONCE(*y);
21     smp_rmb();
22     r2 = READ_ONCE(*x);
23 }
24
25 exists (1:r1=1 /\ 1:r2=0)

```

Answer:

시간이 흐르면, 어쩌면 그렇게 표준이 만들어질 수 있을 겁니다. □

Quick Quiz 15.19:

하지만 Listing 15.15에서, P2()의 r1과 r2가 값 2와 1을 각각 얻고, P3()의 r1과 r2가 값 1과 2를 각각 얻게 되는것 역시 만만치 않게 나쁘지 않을까요? □

Answer:

맞아요, 그렇습니다. 여기서 `exists` 절을 그런 결과를 검사하도록 수정하고 어떻게 되는지 한번 보세요. □

Quick Quiz 15.20:

Multicopy atomic와 다른 multicopy atomic 사이의 다른 동작에 대한 특정한 예를 들어볼 수 있겠습니까? □

Answer:

Listing G.7 (`C-MP-OMCA+o-o-o+o-rmb-o.litmus`)의 그런 테스트를 보입니다.

Multicopy-atomic 플랫폼에서, P0()의 line 10에서의 x로의 스토어는 P0()와 P1()에게 동시에 보여야만 합니다. 이 스토어는 P0()에게 line 11에서 보이게 되고, line 12에서의 P0()의 y로의 스토어 전에, P0()의 x로의 스토어는 P1()을 포함해서 y로의 스토어 전에 보여야만 합니다. 따라서, line 20에서 P1()의 y로부터의 로드가 값 1을 리턴하면, line 21에서의 `smp_rmb()`가 이 두 로드의 수행 순서를 강제하므로, line 22에서의 x 역시 그래야만 합니다. 따라서, line 25의 `exists` 절은 multicopy-atomic 플랫폼에선느 발동되지 않습니다.

반면, other-multicopy-atomic 플랫폼에서는 `P0()` 가 자신의 스토어를 일찍 볼 수 있으므로, `P1()` 이 이 두 개의 스토어를 보는 순서에 대해서는 제약이 없어서 `exists` 절이 발동될 수 있을 겁니다. □

Quick Quiz 15.21:

대체 누가 공유된 스토어 버퍼를 갖는 시스템을 설계할 생각 따위를 하겠어요??? ■

Answer:

이는 코어당 여러 하드웨어 쓰레드를 갖는 시스템에서는 매우 자연스러운 설계입니다. 하드웨어의 관점에서 는 자연스럽습니다, 이게요! □

Quick Quiz 15.22:

하지만 `P0()` 와 `P1()` 은 스토어 버퍼와 캐시를 공유 해야 하는데 `P2()` 는 자기만의 캐시와 스토어 버퍼를 갖는다는게 공평한가요??? ■

Answer:

어쩌면 Figure 15.8 에 보인 것처럼 `P3()` 가 존재해서 `P2()` 의 스토어 버퍼와 캐시를 공유할 수도 있을 겁니다. 하지만 꼭 그래야 하는 건 아니죠. 일부 플랫폼은 서로 다른 코어들이 서로 다른 수의 쓰레드들을 불능화 시키는 걸 가능하게 해서, 하드웨어가 당장 처리해야 할 워크로드의 필요에 맞게 조정될 수 있게 합니다. 예를 들어, 워크로드의 싱글 쓰레드로 돌아가는 중요한 지점은 하나의 쓰레드만 돌아갈 수 있는 코어에 할당되어서 이 워크로드의 해당 부분을 이 하나의 쓰레드가 해당 코어의 모든 가능한 자원을 사용할 수 있게 할 수 있을 겁니다. 워크로드의 더 높은 병렬성을 갖지만 캐시미스에 취약한 부분은 더 나은 처리량을 제공하기 위해 모든 하드웨어 쓰레드를 사용할 수 있는 코어들에 할당될 수 있을 겁니다. 이렇게 향상된 처리량은 하나의 하드웨어 쓰레드가 캐시 미스에 의해 멈춰 있는 동안, 다른 하드웨어 쓰레드는 진행을 이룰 수 있기 때문이기도 할 겁니다. 이런 경우, 성능 요구사항은 독특한 사람의 관점에서 의 공평성보다 우선합니다. □

Quick Quiz 15.23:

Table 15.4 대로라면, `P1()` 의 스토어는 그렇게 빨리 끝나는데 `P0()` 의 스토어는 왜 그렇게 오래 걸리나요? 달리 말하자면, Listing 15.16 의 line 32 에 있는 `exists` 절은 정말로 실제 시스템에서도 발동되는 건가요? ■

Answer:

정말로 발동될 수 있다는 사실을 받아들여야 합니다. Akira Yokosawa 는 litmus7 이라는 도구를 사용해 POWER8 시스템에서 이 리트머스 테스트를 돌려봤습니다. 1,000,000,000 번의 시도 중에, 4 번 `exists` 절이

Listing G.8: R Litmus Test With Write Memory Barrier (No Ordering)

```

1 C C-R+o-wmb-o+o-mb-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     WRITE_ONCE(*x0, 1);
8     smp_wmb();
9     WRITE_ONCE(*x1, 1);
10 }
11
12
13 P1(int *x0, int *x1)
14 {
15     int r2;
16
17     WRITE_ONCE(*x1, 2);
18     smp_mb();
19     r2 = READ_ONCE(*x0);
20 }
21
22 exists (1:r2=0 /\ x1=2)

```

발동되었습니다. 따라서, `exists` 절의 발동 확률은 백 만번에 한번도 아니고, 일억번 중 한번입니다. 하지만 실제 시스템에서도 발동된다는 것은 사실입니다. □

Quick Quiz 15.24:

하지만 이 리트머스 테스트에 최소 세개의 쓰레드가 존재하지 않는다면 전파에 대해서는 걱정할 필요가 없을 거예요, 그렇죠? ■

Answer:

그렇지 않습니다.

Listing G.8 (`C-R+o-wmb-o+o-mb-o.litmus`) 은 propagation 을 필요로 하는 두개 쓰레드의 리트머스 테스트를 보이는데, 여기선 두쓰레드 사이에 store-to-store 와 load-to-store 연결만이 존재하기 때문입니다. `P0()` 가 `smp_wmb()` 를 통해 순서를 제대로 잡았고 `P1()` 이 `smp_mb()` 를 통해 완전히 순서를 잡았지만, 이 연결들의 근본적인 반 임시적 성격은 line 22 의 `exists` 절이 정말로 발동될 수 있음을 의미합니다. 이 발동을 막으려면, line 8 의 `smp_wmb()` 는 `smp_mb()` 가 되어서, 각각의 임시적이지 않은 링크마다 한번씩, 전파가 두번 발생하게 만들어야 합니다. □

Quick Quiz 15.25:

`smp_mb()` 가 propagation 속성을 갖는다면, Listing 15.18 line 29 의 `smp_mb()` 는 왜 `exists` 절이 발동되는 걸 막지 못하는 거죠? ■

Answer:

대략적 경험상의 법칙으로는, `smp_mb()` 배리어의 propagation 속성을 프로세스들 사이에 하나의 store-to-load

Listing G.9: 2+2W Litmus Test (No Ordering)

```

1 C C-2+2W+o-o+o-o
2 {
3 }
4
5 P0(int *x0, int *x1)
6 {
7     WRITE_ONCE(*x0, 1);
8     WRITE_ONCE(*x1, 2);
9 }
10
11
12 P1(int *x0, int *x1)
13 {
14     WRITE_ONCE(*x1, 1);
15     WRITE_ONCE(*x0, 2);
16 }
17
18 exists (x0=1 /\ x1=1)

```

연결에 순서를 지키기에만 충분합니다. 불행히도, Listing 15.18은 한개가 아니라 두개의 store-to-load 연결을 가지고 있는데, 첫번째는 line 21에서의 `READ_ONCE()`로부터 line 28의 `WRITE_ONCE()`로의 것이고 두번째는 line 30의 `READ_ONCE()`로부터 line 11의 `WRITE_ONCE()`로의 것입니다. 따라서, `exists` 절이 발동되는 것을 막기 위해선 한개가 아니라 두개의 `smp_mb()`를 필요로 합니다.

이 경험상의 법칙에 대한 특수한 예외로, 하나의 `release-acquire` 묶음은 프로세스들 사이의 하나의 `load-to-store` 링크를 가질 수 있고, 여전히 사이클을 금지합니다. □

Quick Quiz 15.26:

하지만 Listing 15.20 (`C-2+2W+o-wmb-o+o-wmb-o.litmus`)에 보인 것과 같이 순서잡힌 스토어만을 사용하는 리트머스 테스트에서, 한 연구는 ARM과 Power 같은 완화된 순서규칙의 시스템에서조차도 사이클이 사라짐을 보였습니다 [SSA¹¹]. 이를 놓고 보면, `store-to-store`는 정말로 항상 반 임시적인가요??? ■

Answer:

이 리트머스 테스트는 실제로 매우 흥미로운 경우입니다. 여기서 순서는 주어진 특정 완화된 순서규칙의 하드웨어 설계 위에서도 자연적으로 분명히 주어지는데, 이는 관련된 물리 법칙과 캐시 일관성 프로토콜 수학으로부터의 위대한 선물로 여겨질 수 있을 겁니다.

불행히도, 누구도 훨씬 나은 대안적 구현을 갖지 못한 이 선물을 소프트웨어에 사용한 예를 갖지 못했습니다. 따라서, C11도 리눅스 커널 메모리 모델도 Listing 15.20에 연관된 보장을 제공하지 않습니다. 이는 line 20의 `exists` 절이 발동될 수 있음을 의미합니다.

물론, Listing G.9 (`C-2+2W+o-o+o-o.litmus`)에 보인 것과 같이 배리어가 없다면 실제 완화된 순서규칙의

Listing G.10: LB Litmus Test With No Acquires

```

1 C C-LB+o-data-o+o-data-o+o-data-o
2 {
3     int x0=0;
4     int x1=1;
5     int x2=2;
6 }
7
8 P0(int *x0, int *x1)
9 {
10     int r2;
11
12     r2 = READ_ONCE(*x0);
13     WRITE_ONCE(*x1, r2);
14 }
15
16
17 P1(int *x1, int *x2)
18 {
19     int r2;
20
21     r2 = READ_ONCE(*x1);
22     WRITE_ONCE(*x2, r2);
23 }
24
25 P2(int *x2, int *x0)
26 {
27     int r2;
28
29     r2 = READ_ONCE(*x2);
30     WRITE_ONCE(*x0, r2);
31 }
32
33 exists (0:r2=2 /\ 1:r2=0 /\ 2:r2=1)

```

하드웨어 위에서도 순서 보장이 존재하지 않게 됩니다. □

Quick Quiz 15.27:

의존성 만을 사용하는 Listing 15.21와 비슷한 리트머스 테스트를 짤 수 있나요? ■

Answer:

Listing G.10은 무의미하지만 매우 실제적인 예제입니다. 더 유용한 (하지만 여전히 사실적인) 리트머스 테스트를 만드는 건 독자 여러분의 몫으로 남겨둡니다. □

Quick Quiz 15.28:

Listing 15.25에 보인 것과 같이 하나의 `load-to-store` 링크와 하나의 `store-to-store` 링크와 함께 짧은 `release-acquire` 체인이 있다고 해봅시다. 각 `non-store-to-load` 링크가 하나씩만 있으므로, `exists` 절은 발동되지 않을 겁니다, 그렇죠? ■

Answer:

아닙니다. 문제되는건 `non-store-to-load` 링크의 갯수입니다. 하나의 `non-store-to-load` 링크만이 존재한다면, 하나의 `release-acquire` 체인은 여기서의 `exists` 절이 발동되는 걸 막을 수 있습니다. 하지만, 두개 이상의 `non-store-to-load` 링크가 존재한다면, 예를 들어 `store-to-store`,

load-to-store, 또는 그런 것들의 어떤 조합이 존재한다면, 각각의 non-store-to-load 링크 사이에 최소 하나의 전체 배리어 (smp_mb() 나 그보다 나은 것들)를 가져야 합니다. 따라서, Listing 15.25에서 exists 절이 발동되는 걸 막으려면 P0()의 또는 P1()의 액세스들 사이에 전체 배리어가 추가되어야 합니다. □

Quick Quiz 15.29:

Store-to-load 링크, load-to-store 링크, 그리고 store-to-store 링크를 이야기 했군요. Load-to-load 링크에 대해선 어떻죠? ■

Answer:

Load-to-load 링크의 컨셉에서의 문제는 같은 변수로부터의 두개의 로드가 같은 값을 리턴한다면, 그것들 사이의 순서를 특정할 방법이 없다는 겁니다. 이것들 사이의 순서를 특정할 유일한 방법은 다른 값을 리턴했을 때만 존재하는데, 그러기 위해선 연관된 스토어가 있어야만 합니다. 그리고 그 연관된 스토어는 load-to-load 링크가 아니라 load-to-store 링크에 이어 store-to-load 링크가 존재하는 것이 됩니다. □

Quick Quiz 15.30:

왜 컴파일러는 일반적 변수에의 스토어를 아무 때나 만들 수 없는거죠? ■

Answer:

컴파일러는 데이터 레이스로부터 숨겨져 있기 때문입니다. 일반적 스토어 앞에 스토어를 만들어내는 경우는 상당히 특수합니다: 코드가 만들어진 스토어가 없다 해도 데이터 레이스를 가지고 있다면, CPU, 쓰레드, 시그널 해설러, 또는 인터럽트 핸들러와 같은 다른 것들은 이 만들어진 스토어를 볼 수 없습니다.

하지만 WRITE_ONCE()에서와 같이 원래의 스토어가 volatile 이라면, 모든 컴파일러가 어떤 다른 쓰레드에서 시그널을 보내는 스토어에 관련된 부작용이 있을 수 있음을 알게 되어서 해당 변수에의 데이터 레이스로부터 자유로운 액세스를 가능하게 합니다. 이 스토어를 만들어 냈으므로써, 컴파일러는 데이터 레이스를 만들어내는, 해서는 안될 일을 할 수도 있습니다. 그리고 만약 이 코드가 이미 데이터 레이스를 가지고 있다면, 개발자의 바램과는 상관없이 컴파일러가 원하는대로 어떤 코드든 만들어낼 수 있는, 비정의된 행동의 무서운 유령을 이미 불러낸 것입니다.

volatile과 어토믹 변수들의 경우, 컴파일러는 명시적으로 스토어를 만들지 못하도록 되어 있습니다. □

Quick Quiz 15.31:

Listing ??의 line 6에서 &reserve_int에서의 비교 대신 이 포인터를 그냥 디레퍼런스 할 수는 없나요? ■

Listing G.11: Breakable Dependencies With Non-Constant Comparisons

```

1 int *gp1;
2 int *gp2;
3 int *p;
4 int *q;
5
6 p = rcu_dereference(gp1);
7 q = READ_ONCE(gp2);
8 if (p == q)
9     handle_equality(p);
10 do_something_with(*p);

```

Listing G.12: Broken Dependencies With Non-Constant Comparisons

```

1 int *gp1;
2 int *gp2;
3 int *p;
4 int *q;
5
6 p = rcu_dereference(gp1);
7 q = READ_ONCE(gp2);
8 if (p == q) {
9     handle_equality(q);
10    do_something_with(*q);
11 } else {
12     do_something_with(*p);
13 }

```

Answer:

일단, do_something_with() 전에 handle_reserve() 가 호출되어야 할 겁니다.

하지만 메모리 순서 규칙에 더 관계있게는, 컴파일러는 이 비교를 디레퍼런스 앞으로 옮길 권리를 가지고 있는데, 이는 컴파일러가 하드웨어가 의존성을 표시해둘 변수 p 대신 &reserve_int를 사용하게 할 수 있습니다. □

Quick Quiz 15.32:

하지만 두 포인터 변수를 비교하는건 안전할 거예요, 그렇죠? 무엇보다, 컴파일러는 두 변수의 값을 모르니, 비교의 결과가 어떨지 모를 거잖아요? ■

Answer:

불행히도, 컴파일러는 여러분의 의존성 연결을 깨기 충분할 만한 정보를 얻을 수 있는데, 예를 들어, Listing G.11에 보인 것처럼 그렇습니다. 컴파일러는 이 코드를 Listing G.12에 보인 것처럼 변환할 수 있고, handle_equality()가 인라인 함수로 만들어져서 레지스터가 더 필요하고 레지스터가 부족한 경우 특히 이런 변경을 만들 수 있습니다. 변경된 코드의 line 10은 q를 사용하는데, p와 같긴 하지만, 이 변수는 하드웨어에게 의존성을 갖도록 표시되진 않을 겁니다. 따라서, 이 변경된 코드는 line 10이 line 6 뒤에 순서지어지도록 보장하지 못합니다.⁸ □

⁸ 이 예제를 제공해준 리눅스 토발즈에게 감사를.

Quick Quiz 15.33:

하지만 line 35에서의 조건은 line 36이 line 34 뒤로 순서 지어지게 하는 control dependency를 제공하지 않나요? ■

Answer:

맞아요, 하지만, 아닙니다. 그래요, control dependency가 존재합니다, 하지만 control dependency들은 뒤의 로드들을 순서짓지 않고, 뒤의 스토어들만을 순서짓습니다. 여러분이 정말 순서규칙을 필요로 한다면, 여러분은 line 35와 36 사이에 `smp_rmb()`를 위치시킬 수 있습니다. 또는 더 일관적이게, `update()`가 이 구조체를 재사용하는 대신에 두 구조체를 할당하게 할 수 있을 겁니다. □

Quick Quiz 15.34:

Listing ??의 `P1()`에 `smp_mb()`를 대신 더할 수는 없을까요? ■

Answer:

리눅스 커널 메모리 모델을 생각하지 않는다면요. (해보세요!) 하지만, `P0()`의 `WRITE_ONCE()`를 `smp_mb()`보다 적은 오버헤드를 보통 갖는 `smp_store_release()`로 대신 사용할 수 있습니다. □

Quick Quiz 15.35:

Alpha의 `smp_read_barrier_depends()`는 왜 `smp_rmb()`가 아니라 `smp_mb()`죠? ■

Answer:

Alpha는 `mb`와 `wmb` 인스트럭션만을 가지고 있어서, `smp_rmb()`는 어떻든간에 Alpha의 `mb` 인스트럭션으로 구현될 겁니다. 또한, `smp_read_barrier_depends()`가 리눅스 커널에 추가되었던 시점에는 Alpha가 의존성 있는 스토어를 순서 지켜주는지 확실치 않았고, 따라서 `smp_mb()`는 어떤 경우에든 안전한 선택이었습니다.

하지만, 리눅스 커널 v4.15는 `smp_read_barrier_depends()`를 `READ_ONCE()`와 Alpha의 어토믹 read-modify-write 오퍼레이션들 일부에 넣어서, 커널 핵심 코드 어디에서도 `smp_read_barrier_depends()`가 필요치 않게 만들었습니다. 이는 `READ_ONCE()`를 제외하고는 어떤 리눅스 커널 핵심 코드도 DEC Alpha에 대해 신경을 쓸 필요가 없음을 의미해서, 커널에서 Alpha 지원을 제거하기 위한 Paul E. McKenney의 인센티브를 크게 줄였음을 의미합니다. □

Quick Quiz 15.36:

DEC Alpha는 가장 완화된 메모리 순서 규칙을 갖는 만큼 중요하지 않나요? ■

Answer:

DEC Alpha가 상당한 비난을 받긴 하지만, 같은 CPU에서 같은 변수로의 읽기들은 재배치하지 않습니다. 또한 Java와 C11 메모리 모델을 괴롭히는 out-of-thin-air 문제도 막습니다 [BD14, BMN⁺15, BS14, Jef14, MJST16, Š11, VBC⁺15]. □

Quick Quiz 15.37:

Load-to-store와 store-to-store 링크에는 더 무거운 순서 규칙이 필요하지만 store-to-load 링크에는 그렇지 않죠? 대체 뭐가 store-to-load 링크를 그렇게 특별하게 하는 건가요??? ■

Answer:

Load-to-store와 store-to-store 링크는 Section 15.2.7.2의 Figure 15.10과 15.11에 보인 것처럼 임시적이지 않을 수 있음을 상기하세요. Load-to-store와 store-to-store 링크의 이 반 임시적인 특성이 강한 순서 규칙을 필요로 하게 만듭니다.

반면에, store-to-load 링크는 Listing 15.12과 15.13에 보인 것처럼 임시적입니다. 이 store-to-load 링크의 임시적 특성이 최소한의 순서규칙의 사용을 가능하게 합니다. □

G.16 Ease of Use

Quick Quiz 16.1:

원소를 지울 때에도 비슷한 알고리즘을 사용할 수 있습니까? ■

Answer:

네, 하지만, 각각의 쓰레드는 가운데 하나를 삭제하기 위해 연속된 세개의 원소의 락을 잡아야 하므로, N 개의 쓰레드가 존재한다면, 데드락이 없도록 하기 위해서는 리스트에 ($N + 1$ 개가 아니라) $2N + 1$ 개의 원소가 존재해야만 합니다. □

Quick Quiz 16.2:

그러군요! 이처럼 깎여져나갈 가치가 있는 알고리즘을 가지고 나타난 누군가를 포용해 본 적 있나요??? ■

Answer:

그건 Paul일 수 있을 겁니다.

그는 다섯명의 철학자들이 참가하는 비위생적인 스파게티 저녁식사에 관련된, *Dining Philosopher's Problem*을 생각하고 있었습니다. 다섯개의 접시가 있지만 다섯개의 포크만이 테이블에 있다는 점을 가지고, 그리고 각각의 철학자는 식사를 위해 한번에 두개의 포크가 필요하다는 점을 가지고, 누군가는 데드락을 예방하는

포크 할당 알고리즘을 생각해 낼 수 있을 겁니다. Paul의 응답은 “조용! 그냥 다섯개 더 포크를 가져와!”였습니다.

이건 그 자체로는 괜찮습니다만, Paul은 이내 이와 똑같은 해결책을 순환형 링크드 리스트에 적용했습니다.

이것 역시 그렇게 나쁘진 않았을 겁니다만, 그는 누군가에게 그에 대해 이야기를 해야만 했습니다! □

Quick Quiz 16.3:

이 규칙에 대한 예외를 대 보세요. ■

Answer:

한가지 예외는 주어진 상황 하에서는 유일하게 동작하는 어렵고 복잡한 알고리즘이 될 수 있을 겁니다. 또 다른 예외는 주어진 상황에서 동작하는 것으로 알려진 것 중에서는 가장 간단한, 어렵고 복잡한 알고리즘이 될 수 있을 겁니다. 하지만, 이런 경우들에 있어서 조차도, 더 간단한 알고리즘을 내놓기 위해 조금 시간을 써보는 게 좋을 겁니다! 무엇보다도, 여러분이 어떤 작업을 하는 첫번째 알고리즘을 만들어내게 된다면, 더 간단한 것을 하나 만드는 것은 그렇게까지 어렵지는 않을 겁니다. □

무효화는 많은 충돌과 재시도를 만들어내고, 심지어 락킹에 비해 성능과 확장성을 떨어뜨릴 수도 있을 겁니다. □

Quick Quiz 17.3:

HTM 성능과 확장성에 상대적으로 적은 업데이트가 중요한 이유가 뭐죠? ■

Answer:

업데이트가 많을수록, 충돌의 가능성성이 커지고, 따라서 재시도의 가능성성이 커져서 성능이 하락됩니다. □

Quick Quiz 17.4:

동기화 메커니즘의 선택에 관계 없이 어떻게 red-black 트리가 트리 내의 모든 원소의 열거를 효율적으로 할 수 있을까요??? ■

Answer:

많은 경우에, 이 열거는 정확하지 않아도 좋습니다. 이런 경우들에 있어서, hazard pointer나 RCU가 특정한 삽입이나 삭제와의 낮은 conflict 확률을 유지하면서 읽기 쓰레드들을 보호하는데 사용될 수 있습니다. □

Quick Quiz 17.5:

하지만 왜 디버거는 트랜잭션의 앞의 인스턴스의 스텝들을 다시 추적하기 위해 재시도에 의존하면서 브레이크포인트를 트랜잭션의 성공되는 명령문 줄에 설정해 두는 것으로 single stepping을 흉내낼 수 없나요? ■

Answer:

이 방법은 높은 확률로 동작할 수 있을 겁니다만, 대부분의 사용자들에게는 상당히 놀라운 형태로 실패할 수 있습니다. 이를 보기 위해, 다음 트랜잭션을 생각해 봅시다:

```

1 begin_trans();
2 if (a) {
3   do_one_thing();
4   do_another_thing();
5 } else {
6   do_a_third_thing();
7   do_a_fourth_thing();
8 }
9 end_trans();

```

사용자가 line 3에 트랜잭션을 abort 시키고 디버거에 들어가게 될 브레이크포인트를 설정했다고 생각해 봅시다. 브레이크포인트가 시작되고 디버거가 모든 쓰레드를 정지시키는 사이에, 어떤 다른 쓰레드가 a의 값을 0으로 설정했다고 생각해 봅시다. 사용자가 이 프로그램을 single-step 하면, 짜잔! 프로그램은 이제 then-절 대신 else-절에 들어와 있습니다.

G.17 Conflicting Visions of the Future

Quick Quiz 17.1:

메모리의 mmap() 리전 내의 데이터 구조체로 표현되는 지속성 없는 기능들은 어떨까요? 그런 기능들로 만들어진 크리티컬 섹션 내에서의 exec()가 존재한다면 어떤 일이 벌어질까요? ■

Answer:

exec() 된 프로그램이 그 똑같은 메모리 영역을 매핑한다면, 이 프로그램은 원칙적으로 그 락을 놓아주어야 합니다. 이 방법이 소프트웨어 엔지니어링 관점에서도 말이 되는 소리인지에 대한 판단은 독자 여러분의 몫으로 남겨두도록 하겠습니다. □

Quick Quiz 17.2:

해당 락 변수와 캐시 라인을 공유하는, 자주 쓰여지는 변수가 왜 문제가 될까요? ■

Answer:

락이 그것이 보호하는 변수와 같은 캐시라인에 있다면, 하나의 CPU에 의한 그 변수들로의 쓰기는 모든 다른 CPU들에 있는 그 캐시 라인을 무효화 시킵니다. 이런

이는 제가 사용성이 좋은 디버거라 부르는 것이 아닙니다. □

Quick Quiz 17.6:

하지만 누가 텅 빈 락 기반의 크리티컬 섹션을 필요로 하나요??? ■

Answer:

Section 7.2.1 의 Quick Quiz 7.18 의 답을 보시기 바랍니다.

하지만, 진행 보장이 없는 강력한 어토믹 HTM 구현들에 대해서, 텅 빈 크리티컬 섹션에 기반한 메모리 기반의 락킹 설계는 transactional lock elision 의 존재에도 올바르게 동작할 거라는 주장이 있습니다. 비록 저는 이 주장에 대한 증명을 보지는 못했습니다만, 이 주장에는 직선적인 합리성이 존재합니다. 주요 아이디어는, 강력한 어토믹 HTM 구현에 있어서, 특정 트랜잭션의 결과는 그 트랜잭션이 성공적으로 완료되기 전까지는 보여지지 않는다는 것입니다. 따라서, 트랜잭션이 시작된 것을 볼 수 있다면, 그것이 이미 완료되었음이 보장되는데, 이 말은 뒤따르는 텅 빈 락 기반의 크리티컬 섹션은 성공적으로 그것을 “기다릴” 것을 의미합니다—무엇보다도, 기다림이 요구되지 않습니다.

이 이야기는 (많은 STM 구현을 포함하는) weakly atomic 시스템에는 적용되지 않고, 통신에 메모리 이외의 수단을 사용하는 락 기반의 프로그램들에는 적용되지 않습니다. 그런 수단으로는 시간의 흐름 (예를 들어, hard real-time 시스템)이나 우선순위의 흐름 (예를 들어, soft real-time 시스템)이 있습니다.

Priority boosting 에 의존하는 락킹 설계는 특히 흥미로운 경우입니다. □

Quick Quiz 17.7:

락 기반의 텅 빈 크리티컬 섹션들을 생략하지 않는 방법으로 간단하게 락킹의 시간 기반 메세징 semantic 을 transactional lock elision 에서 처리할 수는 없을까요? ■

Answer:

그럴수도 있습니다만, 이는 불필요하고 불충분할 겁니다.

텅 빈 크리티컬 섹션이 조건적 컴파일에 의한 것이라면 이 방법은 필요가 없습니다. 여기서는, 해당 락의 유일한 목적은 데이터를 보호하는 것이므로, 이를 생략시키는 것이 해야 할 옳은 일일 것입니다. 실제로, 락 기반의 텅 빈 크리티컬 섹션을 남겨두는 것은 성능과 확장성을 떨어뜨릴 수 있습니다.

또 다른 한편, 락 기반의 비어있지 않은 크리티컬 섹션이 락킹의 데이터 보호화 시간 기반의 메세징 semantic 에 의존하고 있을 수도 있습니다. 그런 경우에 transactional lock elision 을 사용하는 것은 올바르지 않고, 버그를 초래할 수 있습니다. □

Quick Quiz 17.8:

최신 하드웨어 [MOZ09] 에서, 누가 병렬 소프트웨어가 타이밍에 의존해서 동작할 거라고 기대할 수 있겠습니까? ■

Answer:

짧게 답하자면 일반적으로 구할수 있는 하드웨어에서, 짧은 시간 단위의 타이밍에 기반한 동기화 설계들은 무모하고 모든 조건 하에서 올바르게 동작할 거라고 예상될 수 없습니다.

그렇다고는 하나, 훨씬 더 결정론적인, hard real-time에서의 사용을 위해 설계된 시스템들이 있습니다. 여러분이 그런 시스템을 사용하게 되는 (있을 수 없을 법한) 상황이라면 여기 시간 기반의 동기화가 동작할 수 있는지 보이는 예가 있습니다. 다시 말하지만, 일반적인 마이크로프로세서는 매우 비결정론적인 성능 특성들을 가지고 있으므로, 이를 일반적인 마이크로프로세서 위에서는 시도하지 마세요.

이 예는 하나의 제어 쓰레드와 함께 복수개의 worker 쓰레드를 사용합니다. 각각의 worker 쓰레드는 외부로 나가는 데이터에 연관되고, 각 단위의 일을 수행한 후에 (예를 들어, `clock_gettime()` 시스템콜로 얻어오는) 현재 시간을 per-thread `my_timestamp` 변수에 저장합니다. 이 예의 real-time 특성은 다음과 같은 제한을 갖습니다:

1. 특정 worker 쓰레드가 자신의 타임스탬프를 `MAX_LOOP_TIME` 기간이 넘도록 업데이트 하지 못하는 것은 치명적인 에러입니다.
2. 락들은 글로벌 상태에 접근하고 업데이트하는데 절약적으로 사용되어야 합니다.
3. 락들은 각각의 쓰레드 우선순위 내에서는 엄격한 FIFO 순서로 얻어집니다.

Worker 쓰레드들이 일을 받는걸 완료하면, 이들은 어플리케이션의 다른 부분들로부터 그들을 풀어내고 -1로 초기화 한 per-thread `my_status` 변수의 상태값을 설정해야 합니다. 쓰레드들은 종료되지 않습니다; 그대신 뒤이어 처리해야 할 것들을 처리해주기 위해 쓰레드 풀에 들어갑니다. 제어 쓰레드는 필요한 만큼 worker 쓰레드를 할당 (그리고 재할당) 하고, 또한 쓰레드 상태들의 히스토그램을 관리합니다. 제어 쓰레드는 worker 쓰레드보다 높지는 않은 real-time 우선순위로 동작합니다.

Worker 쓰레드의 코드는 다음과 같습니다:

```

1  int my_status = -1; /* Thread local. */
2
3  while (continue_working()) {
4      enqueue_any_new_work();
5      wp = dequeue_work();
6      do_work(wp);
7      my_timestamp = clock_gettime(...);
8  }
9
10 acquire_lock(&departing_thread_lock);
11 /*
12  * Disentangle from application, might
13  * acquire other locks, can take much longer
14  * than MAX_LOOP_TIME, especially if many
15  * threads exit concurrently.
16  */
17
18 my_status = get_return_status();
19 release_lock(&departing_thread_lock);
20
21 /* thread awaits repurposing. */

```

제어 쓰레드의 코드는 다음과 같습니다:

```

1  for (;;) {
2      for_each_thread(t) {
3          ct = clock_gettime(...);
4          d = ct - per_thread(my_timestamp, t);
5          if (d >= MAX_LOOP_TIME) {
6              /* thread departing. */
7              acquire_lock(&departing_thread_lock);
8              release_lock(&departing_thread_lock);
9              i = per_thread(my_status, t);
10             status_hist[i]++;
11         }
12     }
13  /* Repurpose threads as needed. */
14 }

```

Line 5는 해당 쓰레드가 종료되었는지를 추론하는데에 시간의 흐름을 사용하고, 만약 그렇다면 line 6-10을 수행합니다. Line 7과 8의 락 기반의 텅 빈 크리티컬 섹션은 종료되는 프로세스의 모든 쓰레드는 완료되었음을 보장합니다 (락은 FIFO 순서로 얻어짐을 기억하세요!).

다시 말하건대, 이것들을 일반적인 마이크로프로세서 위에서 수행하려 시도하지 마세요. 무엇보다도, hard real-time 사용을 위해 설계된 시스템을 사용할 권한을 얻기도 충분히 어렵습니다! □

Quick Quiz 17.9:

하지만 Listing 17.1의 `boostee()` 함수는 그 락을 반대 순서로 잡고 있어요! 이는 deadlock을 초래할 수 있지 않을까요? □

Answer:

Deadlock은 일어나지 않을 겁니다. Deadlock이 일어나려면, 두개의 다른 쓰레드가 각각 두개의 락을 반대 순서로 잡아야 하는데, 이 예에서는 그런 일은 없습니다. 하지만, lockdep [Cor06a]과 같은 deadlock detector들은 이에 거짓 양성 반응을 보일 수 있습니다. □

Quick Quiz 17.10:

그래서 많은 사람들이 락킹을 대신하는 작업을 시작하고는 대부분은 락킹을 최적화 하는 것으로 결론을 내리나요??? □

Answer:

그들은 최소한 어떤 유용한 것을 얻습니다! 그리고 시간이 흐름에 따라 HTM에 추가적인 진보가 있을 수 있습니다. □

Quick Quiz 17.11:

SEL4 프로젝트에서 사용된 다양한 검증기들의 획기적인 성격이 있는데, 이 챕터는 왜 이걸 더 깊게 다루지 않나요? □

Answer:

SEL4 프로젝트에서 사용된 검증기들이 정말로 사용 가능한지에 대해서는 의혹의 여지가 없습니다. 하지만, SEL4가 단일 CPU 프로젝트 외의 것들에 사용된 지는 (2017년에 이르러) 2년밖에 되지 않았습니다. 그리고 SEL4가 멀티 프로세서 기능을 늘려가기 시작했지만, 리눅스 커널의 기존의 Big Kernel Lock (BKL)과 유사한, 매우 크게 락을 잡는 락킹 방식을 사용하고 있습니다. SEL4의 검증기를 별별 프로그래밍 책에 더하는게 말이 되는 날도 올거라 믿습니다만, 불행히도, 지금은 그때가 아닙니다. □

Quick Quiz 17.12:

Listing 17.2의 line 28에서 해당 컨디션을 그냥 `exists` 절에 넣는 대신 왜 별개의 `filter` 커맨드를 사용하나요? 그리고 `cmpxchg_acquire()` 대신 `xchg_acquire()`를 사용하는게 더 간단하지 않겠어요? □

Answer:

이 `filter` 절은 `herd` 툴이 `exists` 절보다 더 이른 차리 단계에서 수행을 멈추게 해주는데, 이는 상당한 속도 향상을 가져다 줍니다.

Table G.2: Emulating Locking: Performance Comparison (s)

#	Lock	cmpxchg_acquire()		xchg_acquire()	
		filter	exists	filter	exists
2	0.004	0.022	0.039	0.027	0.058
3	0.041	0.743	1.653	0.968	3.203
4	0.374	59.565	151.962	74.818	500.96
5	4.905				

`xchg_acquire()` 어토믹 오퍼레이션은 락 획득이 성공하든 실패하든 쓰기를 하게 되는데, 이는 `xchg_acquire()`를 사용하는 모델은 락 획득 실패의 경우에는 쓰기를 하지 않을 `cmpxchg_acquire()`를 사용하는 모델보다 많은 오퍼레이션을 갖게 될 것을 의미합니다. 더 많은 쓰기는 Table G.2 (C-SB+1-o-o-u+1-o-o-*u.litmus, C-SB+1-o-o-u+1-o-o-u*-C.litmus, C-SB+1-o-o-u+1-o-o-u*-CE.litmus, C-SB+1-o-o-u+1-o-o-u*-X.litmus, 그리고 C-SB+1-o-o-u+1-o-o-u*-XE.litmus)에서 보이는 것과 같이 더 많은 조합의 폭증을 의미합니다. 이 테이블은 `cmpxchg_acquire()` 가 `xchg_acquire()` 보다 성능이 높음을, 그리고 `filter` 절의 사용이 `exists` 절의 사용보다 성능이 높음을 보입니다. □

Quick Quiz 17.13:

알려진 버그들의 MTBF 들이 아직 발견되지 않은 버그들의 MTBF 에 대한 좋은 추측이 될 수 있음을 어떻게 아나요? ■

Answer:

모릅니다만, 그건 문제가 되지 않습니다.

이를 이해하기 위해, 7% 예측은 차후에 발견되는, 추가된 버그들에만 적용됨을 알아두시기 바랍니다: 발견되지 않은, 추가된 버그들은 무시됩니다. 따라서, 알려진 버그들의 MTBF 통계는 차후에 발견되는, 추가된 버그들에 대한 좋은 예측이 될 수 있습니다.

이 섹션 전체의 핵심은, 우리가 실제로 발견되지 않은 버그들보다 사용자들을 괴롭히는 버그들에 더 주의를 기울여야 한다는 것입니다. 이는 물론 우리가 아직 사용자들을 괴롭히지 않은 버그들은 무시해도 된다고 말하려는건 아니고, 다만 우리가 가장 중요하고 급한 버그들을 먼저 고치는데 우리의 노력의 우선순위를 뒤야 한다는 이야기입니다. □

Quick Quiz 17.14:

하지만 formal-verification 도구들은 이 수정으로 만들 어지는 모든 버그들을 곧바로 발견해 낼텐데, 이게 왜 문제죠? ■

Answer:

실제 세계의 formal-verification 도구들은 (formal verification 의 더 떠들썩한 지지자들의 상상 속에서만 존재하는 것들과 반대로) 전지전능하지 않고, 따라서 특정한 종류의 버그들만 찾아낼 수 있기 때문에 문제가 됩니다. 하나님 예를 들어 보면, formal-verification 도구들은 누락된 단정문이나, 동등하게, 명세에서 누락된 부분에 연관된 버그들은 발견하지 못할 겁니다. □

Quick Quiz 17.15:

하지만 많은 formal-verification 도구들이 한번에 하나의

버그만 찾을 수 있어서, 이 도구가 다음 버그를 찾기 전에 버그 각각을 먼저 고쳐야만 합니다. 그런 도구를 가지고 어떻게 버그 수정 노력의 가치가 높아질 수 있겠습니까? ■

Answer:

제품 환경에서는 적절치 않지만 도구가 다음 버그를 찾을 수 있게 해주는 간단한 수정을 가하는게 하나의 방법이 될 수 있습니다. 또 다른 방법은 발견된 버그들이 더이상 발생할 수 없도록 설정이나 입력을 제한하는 겁니다. 비슷한 방법들이 여러가지 있습니다만, 일반적인 테마는 해당 도구의 시점에서 보그를 고치는 것이 제품 수준의 버그 수정을 만들고 겸중하는 것보단 훨씬 쉽다는 것이며, 핵심은 제품 수준의 버그 수정을 만들고 겸중하는데 필요한 더 큰 노력의 가치를 높이는 것입니다. □

Quick Quiz 17.16:

Table 17.5에 보인 점수표에 테스트는 어떻게 올라갈까요? ■

Answer:

테스트는 모두 파란 셀을 가질 겁니다만, 세번째 줄(오버헤드)는 불가능한 버그를 찾을 때의 테스트의 어려움에 따라서 다른 색이 될 수도 있는 예외가 있습니다.

달리 말해서, 불가능한 버그들은 또한 부적절한 버그이기도 해서, 여러분의 마일리지는 매우 다를 수 있을 겁니다.

많은 부분이 여러분의 설치 환경 크기에 의존적입니다. 여러분의 코드가 (대략) 10,000 개 시스템에서만 돌아간다면, Murphy 는 매우 친절한 사람일 수도 있습니다. 모든것이 잘못될 수 있고, 그럴 겁니다. 결국은요. 어쩌면 지질 시대적 시간 안에 말입니다.

하지만 여러분의 코드가 2017년 말의 리눅스 커널이 그렇다 이야기되었듯 200억개의 시스템에서 돌아가고 있다면, Murphy 는 진짜 짜증나는 놈일 수 있어요! 모든 것은 잘못될 수 있고, 그럴 것이며, 매우 빨리 잘못될 수 있습니다!!! □

Quick Quiz 17.17:

하지만 Table 17.5에 보인 것들 외에도 상당히 많은 formal-verification 시스템들이 존재하지 않나요? ■

Answer:

실제로 그렇습니다! 이 표는 Paul 이 사용해본 것들에 주목하고 있지만, 다른 것들도 유용하다고 알려져 있습니다. Formal verification 은 seL4 프로젝트 [SM13]에서 많이 사용되었고, 그 도구들은 이제 동시성의 너무 크지 않은 단계들을 다룰 수 있습니다. 더 최근에, Catalin Marinas 는 리눅스 커널의 queued spinlock 구현상의 일부 forward-progress 버그들을 찾아내는데에 Lamport

의 TLA 도구 [Lam02]를 사용했습니다. Will Deacon은 이 버그들을 고쳤고 [Dea18], Catalin은 Will의 수정을 검증했습니다 [Mar18]. □

G.18 Important Questions

Quick Quiz A.1:

이 예제에서 어떤 SMP 코딩 애러가 보이거나요? 전체 코드를 보기 위해선 `time.c` 파일을 보세요. ■

Answer:

- 루프에서 `barrier()` 나 `volatile` 을 사용하지 않음.
- 업데이트 쪽에서 메모리 배리어를 사용하지 않음.
- 생성자와 소비자 사이의 동기화가 없음. □

Quick Quiz A.2:

소비자의 연속적인 읽기들 사이에 어떻게 그렇게 큰 간격이 존재하게 된걸까요? 전체 코드를 위해선 `timelocked.c` 파일을 보세요. ■

Answer:

- 소비자는 긴 시간동안 `preemption` 당했을 수 있습니다.
- 오랫동안 수행되는 인터럽트가 소비자를 지연시켰을 수 있습니다.
- 생성자는 소비자가 수행되는 CPU에 비해 더 빠른 CPU 위에서 수행되었을 수 있습니다 (예를 들어, CPU들 가운데 하나는 발열 처리나 에너지 소비 제한에 의해 자신의 클럭 주파수를 낮췄을 수 있습니다). □

Quick Quiz A.3:

RCU read-side 기능만을 유일한 동기화 수단으로 사용하는 프로그램의 한 부분을 생각해 봅시다. 이는 parallelism 또는 concurrency 인가요? ■

Answer:

그렇습니다. □

Quick Quiz A.4:

두번째 (스케줄러 기반의) 관점의 어떤 부분에서 락 기반의 CPU 당 하나의 쓰레드를 사용하는 워크로드가 “concurrent”로 여겨질 수 있을까요? ■

Listing G.13: Deadlock in Lock-Based RCU Implementation

```

1 void foo(void)
2 {
3     spin_lock(&my_lock);
4     rCU_read_lock();
5     do_something();
6     rCU_read_unlock();
7     do_something_else();
8     spin_unlock(&my_lock);
9 }
10
11 void bar(void)
12 {
13     rCU_read_lock();
14     spin_lock(&my_lock);
15     do_something();
16     spin_unlock(&my_lock);
17     do_whatever();
18     rCU_read_unlock();
19 }

```

Answer:

해당 워크로드를 임의의 형태로 나누고 끼워넣으려 하는 사람입니다. 물론, 임의의 분할은 락 획득을 연관된 락 해제로부터 떼어내는 일로 귀결될 것인데, 이는 다른 쓰레드가 락을 획득하려 하는 것을 방지하게 될겁니다. 만약 그 락이 순수한 스픬너라면, 이는 데드락을 초래 할수도 있습니다. □

G.19 “Toy” RCU Implementations

Quick Quiz B.1:

Listing B.1에서의 RCU 구현의 데드락이 다른 RCU 구현에서의 데드락이 될 수 없는 이유는 뭘까요? ■

Answer:

Listing G.13의 함수 `foo()` 와 `bar()` 가 다른 CPU들에서 동시에 호출된다고 생각해 봅시다. `foo()` 는 `my_lock()` 을 line 3에서 잡는데, 그동안 `bar()` 는 line 13에서 `rcu_gp_lock` 을 잡습니다. `foo()` 가 line 4로 진행되면, `bar()` 에게 잡혀있는 `rcu_gp_lock` 을 잡으려 합니다. 그리고는 `bar()` 는 line 14로 넘어가서 `foo()`에게 잡혀 있는 `my_lock` 을 잡으려 시도합니다.

각 함수가 이제 서로가 잡고 있는 락을 기다리게 되는 고전적인 deadlock 상황이 됩니다.

다른 RCU 구현들은 `rcu_read_lock()` 안에서 스픬하지도 블록하지도 않기 때문에 데드락이 예방됩니다. □

Quick Quiz B.2:

왜 Listing B.1의 RCU 구현에서는 RCU 읽기 쓰레드들이 병렬로 수행될 수 있도록 간단하게 reader-writer 락을 사용하지 않았나요? ■

Answer:

누군가는 실제로 reader-writer 락을 이런식으로 사용할 수도 있겠습니다. 하지만, 교재의 reader-writer 락은 메모리 경쟁에 취약해서 정말로 병렬 수행이 가능해지려면 RCU read-side 크리티컬 섹션들이 상당히 길어져야 할겁니다 [McK03].

한편으로는, `rcu_read_lock()`에서 읽기 권한을 획득하는식의 reader-writer 락 사용은 앞서 언급된 데드락 조건은 막을 수 있을 겁니다. □

Quick Quiz B.3:

Figure B.2의 line 15-18의 루프에서는 락들을 일단 모두 다 잡고나서는 한번에 모두 풀어주는게 더 깔끔하지 않나요? 무엇보다, 이렇게 바꾸면 어떤 읽기 쓰레드도 존재하지 않는 시점이 생기게 되어서 모든 것들이 매우 간단해질 겁니다. ■

Answer:

이 변경은 다시 deadlock 을 가능하게 할 것이므로, 안 되고, 더 깔끔하지도 않아요. □

Quick Quiz B.4:

Figure B.2에 보여진 구현은 deadlock 으로부터 자유로울까요? 그렇다면, 또는 그렇지 않다면, 왜죠? ■

Answer:

데드락 시나리오 중 하나는 한 락이 `synchronize_rcu()`을 감싸고 잡히고 같은 락이 한 RCU read-side 크리티컬 섹션에 잡힐 때가 될 수 있을 겁니다. 하지만, 이 상황은 어떤 RCU 구현에서도 데드락을 유발할 수 있습니다. 무엇보다, `synchronize_rcu()` 기능은 모든 전부터 존재한 RCU read-side 크리티컬 섹션들이 끝나길 기다려야 하지만, 그런 크리티컬 섹션들 가운데 하나가 `synchronize_rcu()`를 수행한 쓰레드가 잡고 있는 락에 스판하고 있다면, RCU의 정의상 피할 수 없는 데드락을 갖게 됩니다.

또 다른 데드락 시나리오는 RCU read-side 크리티컬 섹션들을 중첩시키려 할 때일 겁니다. 이 데드락은 이 구현 특유의 것이고 재귀적 락을 사용하거나 `rcu_read_lock()`을 통해선 읽기 권한을, `synchronize_rcu()`를 통해선 쓰기 권한을 획득하는 reader-writer 락을 사용해서 막을 수도 있을 겁니다.

하지만, 앞의 두 경우를 제외하면, 이 RCU 구현은 어떤 데드락 상황도 만들지 않습니다. 이는 어떤 다른 쓰레드의 락을 획득하게 되는 경우는 `synchronize_rcu()`를 수행할 때 뿐이며, 이 경우에 그 락은 곧바로 해제되기 때문에 앞의 경우처럼 `synchronize_rcu()` 전후로 잡히는 락과 연관되는 데드락을 제외하고는 데드락 사이클을 예방합니다. □

Quick Quiz B.5:

Figure B.2에 보인 RCU 알고리즘의 예를 들어 POSIX pthread 처럼 여러곳에서 사용 가능한 기능들만을 사용하고 있는 점도 장점 아닌가요? ■

Answer:

이는 실제로 장점입니다만 `rcu_dereference()` 와 `rcu_assign_pointer()`는 여전히 필요함을 잊지 말아야 하는데, 이는 `rcu_dereference()`를 위한 `volatile` 조정과 `rcu_assign_pointer()`를 위한 메모리 배리어의 필요를 뜻합니다. 물론, 대부분의 Alpha CPU들은 두 기능 모두에 메모리 배리어가 필요합니다. □

Quick Quiz B.6:

하지만 `synchronize_rcu()`을 감싸고 락을 잡고 같은 락을 RCU read-side 크리티컬 섹션 내에서 잡으면 어떻게 되죠? ■

Answer:

사실, 이것은 모든 합법적인 RCU 구현에서 데드락을 일으킬 겁니다. 하지만 `rcu_read_lock()`은 정말로 데드락 사이클에 참가하고 있는 걸까요? 그렇게 믿는다면, Section B.9의 RCU 구현을 보게 될 때 같은 질문을 해보시기 바랍니다. Section B.9. □

Quick Quiz B.7:

`synchronize_rcu()` 가 10-밀리세컨드 지연을 포함하고 있는데 어떻게 grace period 가 40 나노세컨드 만에 끝날수가 있나요? ■

Answer:

이 update 쪽 테스트는 읽기 쓰레드들 없이 수행되었고, 따라서 `poll()` 시스템 콜은 결코 호출되지 않았습니다. 또한, 실제 코드는 이 `poll()` 시스템 콜을 주석처리 해서 이 update-side 코드의 진정한 오버헤드를 측정하기에 더 좋게 되어 있습니다. 이 코드의 모든 제품에서 사용하기에는 `poll()` 시스템 콜을 사용하도록 하는 편이 좋을 겁니다만 다시 말하지만 제품에서 사용하기에는 이 섹션의 뒤에서 이야기될 다른 구현이 더 결맞을 수도 있습니다. □

Quick Quiz B.8:

Figure B.3의 RCU 구현은 동시에 `synchronize_rcu()` 가 너무 오래 기다리고 있을 때에는 왜 간단히 `rcu_read_lock()` 을 기다리게 만들지 않는거죠? 그렇게 하면 `synchronize_rcu()` 의 starvation 을 막을 수 있지 않나요? ■

Answer:

Although this would in fact eliminate the starvation, it would also mean that `rcu_read_lock()` would spin or

block waiting for the writer, which is in turn waiting on readers. If one of these readers is attempting to acquire a lock that the spinning/blocking `rcu_read_lock()` holds, we again have deadlock.

In short, the cure is worse than the disease. See Section B.4 for a proper cure. □

Quick Quiz B.9:

Listing B.6의 `synchronize_rcu()`의 line 5의 메모리 배리어는 바로 뒤에 스핀락 획득이 있는데도 왜 필요한 거죠? ■

Answer:

스핀락 획득은 스핀락의 크리티컬 섹션이 이 획득 전으로 “흘러나오지” 않게 보장할 뿐입니다. 이는 스핀락 획득 앞의 코드가 크리티컬 섹션 안으로 재배치되는 것은 막지 않습니다. 그런 재배치는 RCU로 보호되는 리스트의 삭제 작업이 `rcu_idx` 보정 뒤로 재배치되도록 해서 새로이 시작하는 RCU read-side 크리티컬 섹션이 최근에 삭제된 데이터 원소를 보게 만들어 버릴 수 있습니다.

독자를 위한 연습문제: Promela/spin 같은 도구를 사용해서 Listing B.6의 메모리 배리어를 가운데 (존재한다면) 무엇이 정말로 필요한 것인지 가려내보세요. 이 도구들의 사용법을 위해선 Section 12를 참고하세요. 처음으로 옳고 완벽한 답변은 인정을 받을 겁니다. □

Quick Quiz B.10:

Listing B.6에서 카운터는 왜 두번 뒤집히는 거죠? 한번의 뒤집고 기다리는 사이클만으로도 충분하지 않나요? ■

Answer:

두번의 뒤집기가 모두 필요합니다. 이를 확인하기 위해 저는 다음과 같은 일련의 이벤트를 생각해 보세요:

1. Listing B.5 `rcu_read_lock()`의 line 8에서 `rcu_idx`를 가져오고 그 값이 0임을 확인합니다.
2. Listing B.6 `synchronize_rcu()`의 line 8에서 `rcu_idx`를 가져오고 그 값이 0임을 확인합니다.
3. `synchronize_rcu()`의 line 10-13에서 `rcu_refcnt[0]`의 값이 0임을 확인하고 리턴합니다. (질문은 line 14-20이 사라지면 어떻게 되는지이니까요.)
4. `rcu_read_lock()`의 line 9와 10은 각각 이 쓰레드의 `rcu_read_idx`에 0을 저장하고, `rcu_refcnt[0]`의 값을 증가시킵니다. 실행은 이제 read-side 크리티컬 섹션의 안으로 들어갑니다.

5. `synchronize_rcu()`의 또 다른 인스턴스가 다시 `rcu_idx`를 바꾸는데, 이번에는 그 값을 0으로 바꿉니다. `rcu_refcnt[1]`의 값이 0이므로, `synchronize_rcu()`는 곧바로 리턴합니다. (`rcu_read_lock()`은 `rcu_refcnt[0]`을 증가시켰지, `rcu_refcnt[1]`을 증가시키지 않았으니까요!)

6. Step 4 전에 시작된 RCU read-side 크리티컬 섹션이 완료되지 않았음에도 step 5에서 시작한 grace period가 종료되는 것이 허가되었습니다. 이는 RCU 시맨틱을 위반하는 것이고 업데이트가 RCU read-side 크리티컬 섹션에 여전히 레퍼런스 하고 있는 데이터 원소를 해제시킬 수 있게 할 수 있습니다.

독자를 위한 연습문제: `rcu_read_lock()`이 line 8 뒤에서 매우 긴 시간(몇시간정도!) preemption 당한다면 어떤 일이 일어날까요? 이 구현은 그런 경우에도 똑바로 동작할까요? 그 답의 이유는 뭐죠? 맞고 완벽한 첫번째 답은 인정을 받을 겁니다. □

Quick Quiz B.11:

어토믹 값 증가와 값 감소가 그렇게 비싸다고 하면, Listing B.5의 line 10에서는 어토믹하지 않은 값 증가를, line 25에서는 어토믹하지 않은 값 감소를 하지 그래요? ■

Answer:

어토믹하지 않은 오퍼레이션들을 사용하면 값 증가와 감소가 사라지게 될 수 있고, 이는 이 구현이 실패하게 할 수 있습니다. `rcu_read_lock()`과 `rcu_read_unlock()`에서 어토믹하지 않은 오퍼레이션들을 사용하는 안전한 방법을 위해선 Section B.5를 참고하세요. □

Quick Quiz B.12:

집어쳐요! `rcu_read_lock()` 안에 `atomic_read()`가 뻔히 보인다구요!!! 왜 `rcu_read_lock()`이 어토믹 오퍼레이션을 포함하고 있지 않은 척 하시는거죠??? ■

Answer:

해당 `atomic_read()` 기능은 실제로는 어토믹한 며신 인스트럭션을 실행하지 않고, 그저 `atomic_t`로부터의 평범한 로드를 수행합니다. 이 기능의 목적은 컴파일러의 타입 검사를 쉽게 해주려는 것입니다. 리눅스 커널이 8비트 CPU에서 수행된다면, 16비트 포인터를 저장하는데에 일부 8-bit 시스템에서의 8비트 액세스 두번이 행해지는 “store tearing”을 막을 필요도 있을 겁니다. 하지만 감사하게도, 누구도 리눅스를 8비트 시스템에서 사용하고 있는 것 같지는 않습니다. □

Quick Quiz B.13:

좋아요, 우리가 N 쓰레드들을 가지고 있다면 우리는 $2N$ 10 밀리세컨드의 기다리는 호출 (`flip_counter_and_wait()` 당 한 세트)을 할 수 있을텐데, 우리가 각 쓰레드를 위해 오직 한번 기다린다고 가정해도 그렇습니다. ■

Answer:

기다리는 것은 오로지 해당 쓰레드가 여전히 앞에서 시작된 RCU read-side 크리티컬 섹션 안에 있을 때 뿐이라는 점을, 그리고 하나의 쓰레드를 기다리는 것은 모든 다른 쓰레드들에게 여전히 수행중일 수도 있는 모든 앞서 시작한 RCU read-side 크리티컬 섹션들을 완료할 기회를 준다는 점을 기억하세요. 따라서 우리가 $2N$ 간격을 기다리게 되는 경우는 모든 앞의 쓰레드들에의 모든 기다림에도 불구하고 직전의 쓰레드가 여전히 앞서 시작된 RCU read-side 크리티컬 섹션 안에 있을 때 뿐입니다. 짧게 말해서, 이 구현은 불필요하게 기다리지는 않을 겁니다.

하지만, RCU 를 사용하는 코드를 스트레스 테스트하고 있다면, 부정확하게 RCU 로 보호되고 있는 데이터 원소로의 레퍼런스를 RCU read-side 크리티컬 섹션 밖에서도 쥐고 있게 되는 버그를 더 잘 잡기 위해서는 `poll()` 구문을 없애고 싶을 수도 있을 겁니다. □

Quick Quiz B.14:

이 모든 장난감 RCU 구현들은 `rcu_read_lock()` 과 `rcu_read_unlock()` 안에 어토믹 오퍼레이션들을 가지고 있거나 쓰레드의 수에 따라 선형적으로 증가하는 `synchronize_rcu()` 의 오버헤드를 갖습니다. 어떤 환경에서라면 RCU 구현이 이 세개의 기능들이 모두 결정적인 ($O(1)$) 의 오버헤드와 대기시간을 갖는 가벼운 구현을 가질 수 있을까요? ■

Answer:

특수한 목적의 RCU 유니프로세서 구현이 이 이상적인 상황을 만들 수 있을 겁니다 [McK09c]. □

Quick Quiz B.15:

짝수만으로도 해당 태스크를 무시해도 좋다고 `synchronize_rcu()` 에 말하기에 충분하다면 Listing B.14 의 line 10 과 11 은 왜 단순히 `rcu_reader_gp` 에 0을 할당하지 않나요? ■

Answer:

0을 (또는 어떤 다른 짝수의 상수를) 할당하는 것은 실제로 동작할 것입니다만 `rcu_gp_ctr` 의 값을 할당하는 것은 개발자에게 언제 연관된 쓰레드가 마지막으로 RCU read-side 크리티컬 섹션을 끝냈는지와 같은, 디버깅을 위한 가치 있는 도움을 제공할 수 있습니다. □

Quick Quiz B.16:

Listing B.14 의 line 19 와 31 에서의 메모리 배리어들은 왜 필요한 건가요? line 20 과 30 에서의 락킹이 충분한데 메모리 배리어는 피할 수 있지 않나요? ■

Answer:

락킹 기능들은 단지 크리티컬 섹션을 가두는 것만을 보장하기 때문에 이 메모리 배리어들이 필요합니다. 락킹 도구들은 다른 코드가 크리티컬 섹션 안으로 훌러들어오는 것을 막기 위한 어떤 의무도 가지고 있지 않습니다. 따라서 이런 종류의, 컴파일러에 의해서든 CPU 에 의해서든 행해질 수 있는 코드의 움직임을 방지하기 위해 이 두개의 메모리 배리어들이 필요합니다. □

Quick Quiz B.17:

Section B.6 에서 설명한 update-side batching 이 Listing B.14 에 보인 구현에 적용될 수도 있지 않을까요? ■

Answer:

실제로, 약간의 수정과 함께라면 그럴 수 있습니다. 이 작업은 독자의 연습문제로 남겨두겠습니다. □

Quick Quiz B.18:

Listing B.14 의 line 3-4 에서 읽기 쓰레드들이 preemption 당할 수 있다는 사실은 진짜 문제일까요? 달리 말하자면, 정말 실패를 만들 수 있는 실제의 이벤트들이 존재하나요? 그렇지 않다면, 왜죠? 그렇다면, 그 이벤트들은 어떤 것이고, 그 실패는 어떻게 해결될 수 있을까요? ■

Answer:

진짜 문제입니다, 그리고 실패를 이끌어내는 일련의 이벤트들이 존재하며, 이를 해결하기 위한 방법들이 여럿 있습니다. 더 자세한 내용을 위해서는 Section B.8 의 끝부분의 Quick Quizz 들을 참고하세요. 이에 대한 토론을 거기에 두는 이유는 (1) 당신에게 생각할 시간을 더 주고, (2) 그 섹션에서 추가되는 중첩 지원은 카운터를 오버플로우 시키는데 걸리는 시간을 훨씬 줄여주기 때문입니다. □

Quick Quiz B.19:

이 복잡한 비트 조정을 하는 대신에 앞의 섹션에서 그랬듯이 별도의 쓰레드별 중첩 수준 변수를 갖지 않는 건가요? ■

Answer:

별도의 쓰레드별 변수의 분명한 단순성은 주의를 돌리는 것일 뿐입니다. 이 방법은 조심스럽게 오퍼레이션들을 순서맞추는 데에서 훨씬 큰 복잡도를 만들어내는데, 특히 시그널 핸들러들이 RCU read-side 크리티컬 섹션들을 가질 수 있게 허용되는 경우에서 특히 그렇습니다.

하지만 그냥 제 말에서 멈추지 말고, 코딩을 직접 해보시고 그렇게 해서 뭐가 나오는지 한번 보시기 바랍니다!

□

Quick Quiz B.20:

Listing B.16에 보여진 알고리즘에서, 어떻게 하면 전역 변수인 `rcu_gp_ctrl`가 오버플로우 되는데 걸리는 시간을 두배로 늘릴 수 있을까요? ■

Answer:

한가지 방법은 line 33과 34에서의 비교의 규모를 써드별 `rcu_reader_gp` 변수와 `rcu_gp_ctrl+RCU_GP_CTR_BOTTOM_BIT` 사이의 동일 여부 검사로 바꾸는 게 될겁니다. □

Quick Quiz B.21:

다시, Listing B.16에 보여진 알고리즘에서, 카운터 오버플로우는 치명적인가요? 그 이유는 무엇이죠? 만약 치명적이라면, 그걸 고치기 위해 뭘 할 수 있을까요? ■

Answer:

실제로 치명적일 수 있습니다. 이를 보기 위해, 다음의 일련의 이벤트들을 생각해 봅시다:

1. Thread 0 가 `rcu_read_lock()`에 들어와 아직 중첩되지 않은 상태임을 확인하고 글로벌 변수 `rcu_gp_ctrl`의 값을 가져옵니다. Thread 0는 그리고나서 (자신의 쓰레드별 변수 `rcu_reader_gp`에 값을 저장하기 전에) 상당히 긴 시간동안 `preemption` 당합니다.
2. 다른 쓰레드들이 반복적으로 `synchronize_rcu()`를 호출해서 `rcu_gp_ctrl`의 새로운 값이 Thread 0가 가져왔을 때의 값보다 `RCU_GP_CTR_BOTTOM_BIT` 적은 값이 됩니다.
3. Thread 0는 이제 다시 수행을 시작하고, 자신의 쓰레드별 변수인 `rcu_reader_gp`에 값을 저장합니다. 이 값은 전역변수인 `rcu_gp_ctrl`의 현재 값보다 `RCU_GP_CTR_BOTTOM_BIT + 1` 만큼 큽니다.
4. Thread 0가 RCU로 보호되는 데이터 원소 A로의 레퍼런스를 얻습니다.
5. Thread 1이 이제 thread 0가 방금 레퍼런스를 얻어간 원소 A를 제거합니다.
6. Thread 1이 `synchronize_rcu()`를 호출해서 글로벌 변수 `rcu_gp_ctrl`의 값을 `RCU_GP_CTR_BOTTOM_BIT` 만큼 증가시킵니다. 그리고는 모든 쓰레드별 `rcu_reader_gp` 변수의 값을 검사하지만, thread 0의 값은 (부정확하게도) 자신이 thread 1의 `synchronize_rcu()` 호출 뒤에 시작되었다고

알려서 thread 1은 thread 0가 RCU read-side 크리티컬 섹션을 완료하기를 기다리지 않게 됩니다.

7. Thread 1은 thread 0가 여전히 레퍼런스를 가지고 있는 데이터 원소 A를 메모리 해제시켜버리게 됩니다.

이 시나리오는 Section B.7에서 보인 구현에서도 역시 일어날 수 있음에 주의하세요.

이 문제를 고치는 한가지 방법은 64-bit 카운터를 사용해서 오버플로우에 필요한 시간이 컴퓨터 시스템의 일반적인 수행시간을 넘어서도록 하는 것입니다. x86 CPU 계열의 최신 CPU들은 64-bit 카운터들을 `cmpxchg64b` 인스트럭션을 통해 어토믹하게 조정할 수 있게 함을 알아두세요.

또다른 방법은 비슷한 효과를 얻기 위해 grace period 가 일어나도록 허용되는 비율에 제한을 두는 것입니다. 예를 들어, `synchronize_rcu()`는 자신이 호출된 마지막 시간을 기록해 두고, 그 뒤의 모든 수행은 이 시간을 체크하고 원하는 간격을 유지하는데 필요한 만큼 블록될 수 있을 겁니다. 예를 들어, 카운터의 아랫쪽 네개의 비트들이 중첩을 위해 전용화 되어 있다면, 그리고 grace period는 초당 열번까지 일어나는 것이 허용되어 있다면, 이 카운터가 오버플로우 되는데에는 300일 이상이 걸릴 겁니다. 하지만, 이 방법은 이 시스템이 CPU에 성능이 제한되는 높은 우선순위의 리얼타임 쓰레드를 300일 이상 돌리게 될 가능성이 있는 경우에는 도움이 되지 않습니다. (아마도 희박한 가능성이지만 먼저 고려해보는게 최선입니다.)

세번째 방법은 이 경우에는 시스템에서 리얼타임 쓰레드를 사용할 수 없도록 관리하는 것입니다. 이 경우, `preemption` 당한 프로세스는 우선순위를 높여갈 것이고, 따라서 카운터가 오버플로우 날 기회를 얻기 전까지의 수행을 길게 할 것입니다. 물론, 이 전략은 리얼 타임 어플리케이션들에는 별로 도움이 되지 않습니다.

마지막 방법은 `rcu_read_lock()`이 전역 변수 `rcu_gp_ctrl`의 값을 자신의 쓰레드별 변수 `rcu_reader_gp` 마운터에 저장한 후에 다시 검사해서 전역 변수 `rcu_gp_ctrl`의 새로운 값이 적절하지 않다면 다시 일을 시도하는 것입니다. 이 방법은 동작하지만, `rcu_read_lock()`에 예측 불가한 실행 시간을 가져오게 됩니다. 달리 말하면, 당신의 어플리케이션이 카운터가 오버플로우 나기에 충분한 시간만큼 `preemption` 당하면, 당신은 예측 가능한 실행 시간을 기대할 수 없을 겁니다!

□

Quick Quiz B.22:

Listing B.18의 line 14에 보인 추가적인 메모리 배리어는 `rcu_quiescent_state`의 오버헤드를 많이 늘리지 않을까요? ■

Answer:

실제로 그렇습니다! 따라서 이 RCU 구현을 사용하는 어플리케이션은 `rcu_quiescent_state` 를 아껴서 사용하고, 대부분의 경우에는 그대신 `rcu_read_lock()` 과 `rcu_read_unlock()` 을 사용해야 합니다.

하지만, 이 메모리 배리어는 호출자에 의해 실행될 뒤따르는 RCU read-side 크리티컬 섹션 전에 다른 쓰레드들이 line 12-13 의 저장 결과들을 볼 수 있도록 하기 위해 반드시 필요합니다. □

Quick Quiz B.23:

Listing B.18 의 line 19 와 22 의 메모리 배리어들은 왜 필요한 건가요? ■

Answer:

Line 19 의 메모리 배리어는 `rcu_thread_offline()` 에 앞서는 어떤 RCU read-side 크리티컬 섹션들도 컴파일러나 CPU 에 의해 line 20-21 의 값 할당 뒤로 재배치 되지 않게 합니다. Line 22 에서의 메모리 배리어는 엄밀하게 말하면 불필요한데, `rcu_thrad_offline()` 뒤에 RCU read-side 크리티컬 섹션들을 두는 것은 금지된 행위이기 때문입니다. □

Quick Quiz B.24:

분명히 해두겠는데, 2008 년의 POWER 시스템들의 클락 주파수는 상당히 높았지만, 5GHz 클락 주파수도 루프가 50 피코세컨드만에 실행되게 하는데에는 부족해요! 무슨 일이 벌어진 거죠? ■

Answer:

측정을 하는 루프는 한쌍의 텅빈 함수들만을 가지고 있으므로, 컴파일러는 이것을 최적화해서 없애버립니다. 이 측정 루프는 매번의 `rcu_quiescent_state()` 호출마다 1,000 번 넘어가므로, 이 측정은 한번의 `rcu_quiescent_state()` 호출마다 대략 천번의 오버헤드를 가진 걸로 치는 셈입니다. □

Quick Quiz B.25:

코드가 라이브러리에 있다는 사실이 왜 Listing B.18 와 B.19 에 보여진 RCU 구현의 사용에 어려움을 가져올 수 있는 건가요? ■

Answer:

라이브러리 함수는 호출자에 대한 제어가 전혀 존재치 않고 따라서 호출자가 `rcu_quiescent_state()` 를 주기적으로 실행할 것을 강제하지 못합니다. 다른 편으로는, 주어진 RCU 로 보호되는 데이터 구조체에 많은 레퍼런스를 가지고 있을 수도 있는 라이브러리 함수는 `rcu_thrad_online()` 을 매 원소마다,

`rcu_quiescent_state()` 를 주기적으로, 그리고 `rcu_thread_offline()` 을 종료될 때에 호출할 수도 있을 겁니다. □

Quick Quiz B.26:

하지만 락을 `synchronize_rcu()` 전후에 걸쳐 잡고, 같은 락을 RCU read-side 크리티컬 섹션에서 잡으면 어떻게 되나요? 이건 데드락이 되어야 할텐데, 하지만 어떻게 어떤 코드도 만들지 않는 기능이 데드락 사이클에 참여될 수가 있죠? ■

Answer:

RCU read-side 크리티컬 섹션은 둘러싸는 `rcu_read_lock()` 과 `rcu_read_unlock()` 너머로 확장되어서 앞과 뒤의 `rcu_quiescent_state()` 에 닿음을 알아두시기 바랍니다. 이 `rcu_quiescent_State` 는 `rcu_read_lock()` 을 곧바로 뒤따르는 `rcu_read_unlock()` 으로 생각될 수 있습니다.

비록 그렇다 해도, 실제 데드락 자신은 RCU read-side 크리티컬 섹션 내에서와 `synchronize_rcu()` 에서의 락 획득에 연구되지, `rcu_quiescent_state()` 와 연루되지는 않을 겁니다. □

Quick Quiz B.27:

Grace period 가 RCU read-side 크리티컬 섹션들로 통제된다면, RCU로 보호되는 데이터 구조체는 어떻게 RCU read-side 크리티컬 섹션 내에서 업데이트 될 수 있을까요? ■

Answer:

이 상황이 `call_rcu()` 와 같은 비동기적 grace-period 기능들의 존재 이유 중 하나입니다. 이 기능은 RCU read-side 크리티컬 섹션 내에서 실행될 수도 있고, 이 특정 RCU 콜백은 하나의 grace period 가 종료된 이후에 뒤늦게 실행될 것입니다.

RCU read-side 크리티컬 섹션 내에서 RCU 업데이트를 할 수 있는 능력은 상당히 편리할 수 있고, (허구의) reader-writer 락킹에서의 무조건적인 read-to-write 업그레이드로 비유될 수 있습니다. □

G.20 Why Memory Barriers?

Quick Quiz C.1:

Writeback 메세지는 어디서 와서 어디로 가나요? ■

Answer:

Writeback 메세지는 해당 CPU 에서, 또는 일부 설계에서는 해당 CPU 의 캐시의 해당 레벨에서 발생합니다— 또는 심지어 여러 CPU 들 사이에 공유된 캐시에서도.

핵심은 해당 캐시는 현재 데이터 아이템을 위한 공간이 없어서 공간을 만들기 위해 캐시에서 일부 데이터를 제거해야 한다는 겁니다. 다른 캐시나 메모리에 데이터의 복사본이 일부 존재한다면, 그 부분은 writeback 메세지 필요 없이 그냥 버려질 수도 있습니다.

반면, 만약 제거될 데이터의 모든 부분이 수정된 상태여서 최신 버전이 이 캐시에만 존재한다면, 그런 데이터 아이템들은 어딘가 다른곳에 복사되어야만 합니다. 이 복사 과정이 “writeback 메세지”를 통해 이루어집니다.

Writeback 메세지의 목적지는 새 값을 쓸 수 있는 곳이어야 합니다. 이는 메인 메모리가 될 수도 있지만, 다른 캐시일 수도 있습니다. 만약 그게 캐시라면, 그 캐시는 보통 같은 CPU 의 높은 레벨 캐시로, 예를 들어, 레벨-1 캐시는 레벨-2 캐시에 writeback 을 할 수도 있습니다. 하지만, 일부 하드웨어 설계는 CPU 간 writeback 을 허용해서, CPU 0 의 캐시는 CPU 1 에 writeback 메세지를 날릴 수 있느릅니다. 이는 보통 CPU 1 이 어떻게든, 예를 들어, 최근에 읽기 리퀘스트를 했다던지와 같이 그 데이터에 흥미를 표했다면 행해질 수 있습니다.

한마디로, writeback 메세지는 공간이 부족한 시스템의 어떤 부분에서 보내질 수 있고, 그 데이터를 수용할 수 있는 시스템의 다른 부분에서 받게 됩니다. □

Quick Quiz C.2:

두개의 CPU 들이 같은 캐시 라인을 동시에 무효화 하려고 하면 어떻게 되나요? ■

Answer:

그 CPU 들 중 하나가 먼저 공유 버스에의 액세스를 얻고, 그 CPU 가 “이깁니다”. 이기지 못한 CPU 는 해당 캐시 라인의 카피를 무효화 시키고 “invalidate acknowledge” 메세지를 이긴 CPU 에게 보내야 합니다.

물론, 진 CPU 는 곧바로 “read invalidate” 요청을 보낼 것이라 예상할 수 있고, 따라서 이긴 CPU 의 승리는 떳떳한 것이 될 겁니다. □

Quick Quiz C.3:

커다란 멀티프로세서에서 “invalidate” 메세지가 생기면, 모든 CPU 가 “invalidatge acknowledge” 응답을 보내야만 합니다. 그로 인한 “invalidate acknowledge” 의 “폭풍우” 가 시스템 버스를 완전히 뒤덮지 않을까요? ■

Answer:

커다란 규모의 멀티프로세서가 그렇게 구현되어 있다면 그렇겠죠. 커다란 멀티프로세서들, 특히 NUMA 구조의 경우에는, “dicrectory-based” 라 불리는 캐시 일관성 프로토콜을 사용해서 이런 문제 등의 여러 문제들이 나타나지 않게 합니다. □

Quick Quiz C.4:

SMP 머신들이 실제로 메세지 전달을 어떻게든 사용한다면, 애초에 왜 SMP 에 신경을 쓰는거죠? ■

Answer:

이 주제에 대해서는 지난 수십년 동안 상당한 논쟁이 있었습니다. 한 대답은 캐시 일관성 프로토콜은 상당히 간단해서 하드웨어만으로 구현되어 소프트웨어 메세지 전달로는 얻을 수 없는 대역폭과 대기시간을 얻을 수 있다는 겁니다. 또 다른 대답은 진정한 사실은 커다란 SMP 머신과 작은 SMP 머신의 클러스터의 상대적 가격으로 인한 경제 규모에서 찾을 수 있습니다. 세번째 대답은 SMP 프로그래밍 모델이 분산 시스템의 것보다 쉽다는 겁니다만 HPC 클러스터들과 MPI 의 출현을 가지고 반박할 수도 있겠습니다. 그렇게 논쟁은 계속되는거죠. □

Quick Quiz C.5:

앞에 설명된 지연되는 상태 변경들은 하드웨어에서 어떻게 처리하나요? ■

Answer:

추가적인 상태를 더해서 처리합니다만, 한번에 일부 라인들만 상태 변경을 한다는 사실 때문에 이 추가적인 상태들이 실제로 캐시 라인에 쓰여질 필요는 없습니다. 상태 변경을 지연해야 하는 요구사항은 실제 세계 캐시 일관성 프로토콜을 이 부록에서 설명된 지나치게 간략화된 MESI 프로토콜에 비해 훨씬 복잡하게 만드는 문제 중 하나입니다. Hennessy 와 Patterson 의 컴퓨터 구조에 대한 오래된 소개 문서 [HP95] 에서 이런 문제들을 다룹니다. □

Quick Quiz C.6:

어떤 오퍼레이션들의 시퀀스가 CPU 의 캐시를 모두 “invalid” 상태로 돌려 놓을까요? ■

Answer:

해당 CPU 의 인스트럭션 셋에 특별한 “내 캐시 비우기” 인스트럭션이 있지 않다면 그런 시퀀스는 없습니다. 대부분의 CPU 들은 그런 인스트럭션을 갖습니다. □

Quick Quiz C.7:

하지만 스토어 버퍼의 주목적이 멀티프로세서 캐시 일관성 프로토콜의 응답 지연시간을 숨기기 위해서라면, 왜 유니프로세서들도 스토어 버퍼를 가지고 있는거죠? ■

Answer:

스토어 버퍼의 목적은 멀티프로세서 캐시 일관성 프로토콜의 응답 지연시간을 숨기는 것만이 아니라 일반적인 메모리 지연시간을 숨기려는 것이기 때문입니다. 메모리는 유니프로세서의 캐시보다 훨씬 느리기 때문에,

유니프로세서의 스토어 버퍼는 write-miss 대기 시간을 줄이는데 도움을 줄 수 있습니다. □

Quick Quiz C.8:

앞의 step 1에서, 왜 CPU 0은 그냥 “invalidate”가 아니라 “read invalidate”를 보내는거죠? ■

Answer:

해당 캐시 라인은 변수 a 외에도 많은 정보를 담고 있기 때문입니다. □

Quick Quiz C.9:

Section C.4.3 의 첫번째 시나리오의 스텝 1에서, 왜 “read invalidate”가 아니라 “invalidate”를 보내는거죠? CPU 0은 “a” 외에도 이 캐시 라인을 공유하는 다른 변수들의 값을 필요로 할수도 있지 않나요? ■

Answer:

CPU 0은 “a”를 담고 있는 캐시 라인의 read-only 복사본을 가지고 있기 때문에, 해당 캐시 라인을 공유하는 다른 변수들의 값을 이미 알고 있습니다. 따라서 “invalidate” 메세지 만으로도 충분합니다. □

Quick Quiz C.10:

뭐라구요??? CPU 는 while 루프가 끝나기 전까지는 assert() 를 수행할 수 없는데 왜 여기에 메모리 배리어가 필요해요? ■

Answer:

CPU 들은 예측적으로 수행을 할 수 있어서 while 루프가 완료되기 전에 단정문을 수행하는 것과 같은 효과를 일으킬 수 있습니다. 더욱이, 컴파일러들은 일반적으로 현재 수행중인 쓰레드만이 해당 변수의 값을 수정한다고 가정하고, 따라서 이 가정으로 인해 컴파일러는 a 읽기를 루프보다 앞으로 당겨올 수 있습니다.

사실, 일부 컴파일러들은 이를 루프를 다음과 같이 무한 루프를 감싸는 브랜치로 바꿀 수도 있습니다:

```

1 void foo(void)
2 {
3     a = 1;
4     smp_mb();
5     b = 1;
6 }
7
8 void bar(void)
9 {
10    if (b == 0)
11        for (;;) {
12            continue;
13        smp_mb();
14        assert(a == 1);
15 }

```

이런 최적화가 만들어지면, 해당 단정문은 아예 수행이 안될 수도 있습니다. 컴파일러가 당신의 병렬 코드를 없애버리는 현상을 막기 위해서는 volatile 캐스팅이나 (가능하다면) C++ relaxed atomic 들을 사용해야 합니다. 한마디로, 컴파일러들도 CPU 들도 최적화를 공격적으로 하기 때문에, 컴파일러 지시어나 메모리 배리어를 이용해 당신의 제약을 분명하게 그것들에게 알려야 합니다. □

Quick Quiz C.11:

각 CPU 는 자신의 메모리 액세스를 순서대로 보게 된다는 보장 사항은 각 유저 레벨 쓰레드 역시 자신의 메모리 액세스를 순서대로 볼 것이라고 보장하나요? 그렇다면 왜 그렇고, 아니라면 왜 아니죠? ■

Answer:

아니요. 한 쓰레드가 한 CPU 에서 다른 CPU 로 옮겨 가는데, 옮겨져 가는 CPU 는 해당 쓰레드가 옮겨져 온 기존 CPU 에서 한 최근의 메모리 오퍼레이션들을 다른 순서대로 인지할 수 있는 경우를 생각해 보세요. 유저 모드에서의 일관성을 위해선, 커널 해커들이 컨텍스트 스위치 경로에서마다 메모리 배리어를 반드시 사용해 줘야 합니다. 하지만, 이미 컨텍스트 스위치를 안전하게 하기 위해 필요시되는 락킹이 유저 레벨 태스크가 자기 자신의 액세스들을 순서대로 볼 수 있도록 하는데 필요한 메모리 배리어들을 제공해야만 하게 되어 있습니다. 그렇다면 해도, 커널 레벨에서든 유저 레벨에서든 당신이 매우 최적화된 스케줄러를 설계하고 있다면, 부디 이 시나리오를 기억해 두세요! □

Quick Quiz C.12:

CPU 1 의 “while” 과 “c” 값 대입문 사이에 메모리 배리어를 넣는 것으로 이 코드를 고칠 수 있지 않을까요? 고칠 수 있다면 왜이고 고칠 수 없다면 그건 또 왜죠? ■

Answer:

고칠 수 없습니다. 그런 메모리 배리어는 그저 CPU 1에 지역적인 순서만을 강제합니다. CPU 0의 액세스들과 CPU 1의 액세스들 사이의 상대적인 순서에 대해선 어떤 영향도 끼치지 않으므로, 단정문은 여전히 실패할 수 있습니다. 하지만, 모든 주류 컴퓨터 시스템들은 “타동성”을 제공하기 위한 하나 또는 여러개의 메커니즘을 제공해서, 직관적인 인과 순서를 제공합니다: B 가 A 의 액세스들로 인한 현상을 보게 되면, 그리고 C 가 B 의 액세스들로 인한 현상을 보면, C 는 A 의 액세스들로 인한 현상 역시 봐야만 합니다. 짧게 말해서, 하드웨어 설계자들은 소프트웨어 개발자들을 위한 조금의 연민 정도는 가지고 있습니다. □

Quick Quiz C.13:

Listing C.3에서 CPU 1 과 2 의 line 3-5 가 인터럽트

핸들러 안에서 수행되고, CPU 2 의 line 9 는 프로세스 레벨에서 수행된다고 생각해 봅시다. 달리 말하자면, 이 표의 세개의 열 모두의 코드가 같은 CPU 에서 수행되지만, 앞의 두개의 열의 코드는 인터럽트 핸들러에서 수행되고, 세번째 열의 것은 프로세스 레벨에서 수행되어서, 세번째 열의 코드는 앞의 두 열에 의해 인터럽트 당할 수 있다고 생각해 봅시다. 코드가 정확히 동작하도록 하는데, 달리 말하자면 단정문이 실패하지 않도록 하는데 어떤 변경이 필요할까요? 필요하다면 무엇일까요? ■

Answer:

단정문은 “e” 의 로드 오퍼레이션이 “a” 의 로드 오퍼레이션 이전에 이루어졌음을 분명히 해야 합니다. 리눅스 커널에서는 `barrier()` 를 앞의 예들에서 단정문에 사용되었던 메모리 배리어처럼 사용되는 것으로 이를 달성할 수 있습니다. 예를 들어보면, 해당 단정문은 다음과 같이 수정될 수 있습니다:

```
r1 = e;
barrier();
assert(r1 == 0 || a == 1);
```

앞의 두 열의 코드에 대해서는 변경이 필요 없는데, 인터럽트 핸들러는 인터럽트 당하는 코드의 관점에서 보기에는 어토믹하게 수행되기 때문입니다.

□

Quick Quiz C.14:

Listing C.3 의 예에서 CPU 2 가 `assert(e==0 || c==1)` 을 수행하면 단정문은 실패할 수 있을까요? ■

Answer:

해당 CPU 가 “타동성” 을 지원하는가에 달려 있습니다. 달리 말하자면, CPU 0 는 CPU 0 의 “c” 로부터의 로드 와 “e” 로의 스토어 사이의 메모리 배리어와 함께 CPU 1 의 “c” 에의 스토어 오퍼레이션을 바라본 후에 “e” 에 스토어를 행했습니다. 만약 다른 CPU 가 CPU 0 의 “e” 에의 스토어를 본다면, 그 CPU 는 CPU 1 의 스토어도 볼 것이라고 보장될 수 있을까요?

제가 신경쓰는 모든 CPU 들은 타동성을 제공한다고 이야기합니다. □

G.21 Read-Copy Update Implementations

Quick Quiz D.1:

Classic RCU read-side 크리티컬 섹션 안에서는 왜 잠드는 행위가 금지되어 있었나요? ■

Answer:

잠드는 행위는 Classic RCU 에서는 quiescent state 인 컨텍스트 스위치를 암시하며, RCU 의 grace-period 팀지는 RCU read-side 크리티컬 섹션 내에서는 quiescent state 가 결코 나타나지 말아야 할것을 필요로 하기 때문입니다. □

Quick Quiz D.2:

quiescent state 에서 컨텍스트 스위치를 제거해버리고, user-mode 수행과 idle loop 를 quiescent state 로 남겨둠으로써 Classic RCU read-side 크리티컬 섹션에서의 잠드는 행위를 허용하는건 어떻습니까? ■

Answer:

이는 상당한 kernel-mode 수행으로 이루어진 부하를 갖는 시스템 (e.x: 커널 쓰레드로 인해) 은 grace period 의 완료를 하지 못해서 금방이든 나중이든 메모리 부족을 일으킬 겁니다. □

Quick Quiz D.3:

`synchronize_sched()` 에 의해 구분되는 업데이트들이 순서대로 수행될 것이라고 가정해도 되는 이유가 무엇이죠? ■

Answer:

이 특성은 RCU 가 동작할 수 있기 위한 측면에서 `synchronize_sched()` 에 필요한 것이기 때문입니다. 예를 들어, 리스트에서 객체를 하나 제거하고, `synchronize_sched()` 를 호출하고, 이어서 해당 객체를 메모리에서 해제시키는 코드 시퀀스를 생각해 봅시다. 이 속성이 주어지지 않는다면, 해당 객체는 그것이 리스트에서 제거되기도 전에 메모리에서 해제된 것으로 나타날 수 있는데, 이는 `synchronize_sched()` 가 막을 수 있다고 여겨지는 상황 그 자체입니다! □

Quick Quiz D.4:

`synchronize_srcu()` (Figure D.10) 의 line 17 은 왜 line 18 의 mutex 해제보다 앞서야 하죠? 이 두 라인이 서로 바뀌게 하려면 어떤 변경이 있어야 할까요? 그런 변경은 의미가 있을까요? 왜 그럴까요? ■

Answer:

그순서가 반대가 된 상태에서, CPU 0 가 `synchronize_srcu()` 의 line 13 에 도달했으면, CPU 1 과 CPU 2 가

또 다른 `synchronize_srcu()` 를 각각 수행하기 시작했으며, CPU 3 는 `srcu_read_lock()` 을 수행하기 시작했다고 생각해 봅시다. CPU 0 가 line 13 에서 카운터의 값을 증가시키기 직전에 CPU 1 이 `synchronize_srcu()` 의 line 6 에 도달했다고 생각해 봅시다. 가장 중요한 건, CPU 3 가 뒤따르는 SPCU read-side 크리티컬 섹션에서 `srcu_read_lock()` 을 다른 순서로 수행해서 CPU 0 가 `sp->completed` 를 증가시키기 전에 SPCU 로 보호되는 어떤 데이터 구조로의 레퍼런스를 획득했지만, CPU 0 가 이 증가 작업을 한 후에 `srcu_read_lock()` 을 수행합니다.

이렇게 되면 CPU 0 는 line 15-16 에서의 “while” 루프를 빠져나오고 mutex 를 해제하기 전에 CPU 3 가 SPCU read-side 크리티컬 섹션을 완료하기를 기다리지 않습니다 (기억하세요, CPU 는 코드를 재배열할 수 있습니다).

이제 CPU 2 가 이 mutex 를 뒤이어서 획득하고, 또다시 `sp->completed` 를 증가시킵니다. 이 CPU 는 이제 CPU 3 가 SPCU read-side 크리티컬 섹션을 완료하기를 line 15-16 에서의 루프를 빠져나가고 mutex 를 해제하기 전에 기다려야 합니다. 하지만 CPU 3 가 다시 순서를 뒤바꿔서, SPCU read-side 크리티컬 섹션을 들어갈 때 얻어온 포인터로의 마지막 레퍼런스를 수행하기 전에 `srcu_read_unlock()` 을 완료한다고 생각해 봅시다.

CPU 1 은 이제 mutex 를 획득하지만, `sp->completed` 카운터가 둘 씩이나 증가되었음을 확인하게 되고, 따라서 빠른 종료를 취하게 됩니다. 이 호출자는 CPU 3 가 여전히 레퍼런스 하고 있는 원소를 메모리에서 해제시켜버릴 수도 있습니다 (CPU 3 의 비순차적 수행 때문에요).

이런 정말 같지 않은, 하지만 완전히 가능한 시나리오를 방지하기 위해, `synchronize_srcu()` 내에서의 마지막 `synchronize_sched()` 는 반드시 mutex 해제를 앞서야 합니다.

다른 해결 방안은 `synchronize_srcu()` 의 line 7 에서의 비교 구문이 해당 카운터의 최소 세개의 값 증가를 체크하도록 바꾸는 것이 될겁니다. 하지만, 그런 변경은 해시 테이블이 복수의 쓰래드들을 사용해 업데이트 되거나 unload 되는 것과 같은 “bulk update” 시나리오의 응답시간을 증가시킬 겁니다. 현재의 코드에서, `synchronize_srcu()` 의 동시적 호출에 의한 응답시간은 최대 두개의 SPCU grace period 를 취하게 될 것인데, 이 변경을 가하면, 세개의 SPCU grace period 를 필요로하게 될겁니다.

어떤 접근법이 정말로 더 나은 것인지를 판단하기 위해서는 더 많은 경험이 필요할 겁니다. 다만, 먼저 여러 동시적 업데이트 쓰래드에 의한 SPCU 의 사용이 먼저 있어야 할겁니다. □

Quick Quiz D.5:

잠깐만요! 이 새로운 락들을 가지고, 데드락은 어떻게 막나요? ■

Answer:

한번에 한개의 `rcu_node` 구조체의 락만을 잡도록 하는 것으로 데드락이 막아집니다. 이 알고리즘은 두개의 락을 더 사용하는데, 하나는 grace-period 진천과 동시에 CPU hotplug 오퍼레이션이 수행되는 것을 막고 (`onofflock`) 또하나는 한번에 하나의 CPU 만이 quiescent state 가 빨리 끝나도록 강제하는데에 사용됩니다 (`fqslock`). 이것들은 락킹 계층에 반하고, 따라서 `fqslock` 은 `onofflock` 보다 먼저 획득되어야만 하는데, 이말은 `rcu_node` 구조체의 락들보다 먼저 획득되어야만 한다는 말입니다.

또한, 실제 사용에서의 효율이 중요하듯이, 한바에 하나의 `rcu_node` 의 락만을 잡는 것을 거부함은 어떤 것이 잡혀있는지를 추적할 필요가 없음을 의미합니다. 그런 추적은 불필요할 뿐 아니라 고통스러울 겁니다. □

Quick Quiz D.6:

왜 64-배 감소에서 멈추는 거죠? 왜 그이상 가서 수백배 까지 줄이지 않는거예요? ■

Answer:

RCU 는 수백개의 CPU 을 갖는 시스템에서도 문제없이 동작하기 때문에, 64개의 CPU 들이 하나의 락을 경쟁하도록 하는 것으로도 충분합니다. 이 락들은 상당히 드물게 획득되어지므로, 각각의 CPU 는 grace period 마다 한번씩 정도만 이 일을 하게 될 것이고, grace period 는 밀리세컨드 단위까지 길어짐을 기억해 두시기 바랍니다. □

Quick Quiz D.7:

하지만 전 McKenney 의 Quick Quiz 2 에의 계으른 변명 따위 신경쓰지 않아요!!! 저는 하나의 락에 경쟁하는 CPU 들의 수를 16이나 그정도 쯤까지 더 합리적인 수준으로 낮추고 싶어요!!! ■

Answer:

좋아요, 그럼 그렇게 해보세요! `CONFIG_RCU_FANOUT=16` 으로 설정하고 (`NR_CPUS=4096` 에 대해) 나면 가장 낮은 단계에서의 256 `rcu_node` 구조체, 중간 단계에서의 16 개의 `rcu_node` 구조체, 그리고 하나의 root 레벨 `rcu_node` 를 갖게 되어 세단계의 계층을 갖게 될 겁니다. 이에 대해 지불하게 될 비용은 더 많은 `rcu_node` 구조체들이 어떤 CPU 들이 자신의 quiescent state 를 완료하는데 도움이 필요한지를 체크하는데 더 많은 작업이 걸릴 거라는 겁니다 (64 대신 256 이 되는거죠). □

Quick Quiz D.8:

좋아요, 근데 색깔은 뭘 의미하나요? ■

Answer:

(rcu_ctrlblk 을 포함해서) rCU_state 에 비슷한 데 이터 구조들은 노란색으로, 어떤 CPU 들이 들어와 있는지를 파악하는데 사용되는 bitmap 들을 포함한 것들은 펑크로, 그리고 per-CPU rCU_data 구조체들은 파란색으로 표시되어 있습니다. (rcu_dynticks 와 같이) 전력을 아끼기 위해 사용되는 데이터 구조체들은 초록색으로 칠해져 있습니다. □

Quick Quiz D.9:

그런 어처구니 없는 버그가 있다면, Linux 는 대체 어떻게 동작하고 있는거죠? ■

Answer:

리눅스 커널은 (상대적으로) 암전한 디바이스 드라이버들을 가지고 있기 때문입니다. 만약 그것들 가운데 일부가 RCU read-side 크리티컬 섹션 내에서 spin 을 수 밀리세컨드까지 한다면 이는 이 버그를 일으킬 수 있습니다. 그러나 이 버그는 고쳐져야만 하고, 이 RCU 변종은 그런 수정을 합니다. □

Quick Quiz D.10:

하지만 이 state diagram 은 dyntick-idle CPU 들이 reschedule IPI 들을 맞게 될 것을 보이고 있지 않나요? 그게 그것들을 깨워버리지 않을까요? ■

Answer:

아니요. RCU 는 CPU 그룹들을 처리하고 있음을 명심하세요. 하나의 특정한 그룹은 dyntick-idle CPU 들과 어떻게든 quiescent state 를 지나는 것을 막도록 관리되는 평범한 모드의 CPU 들을 모두 포함하고 있을 수 있습니다. 뒤쪽 그룹들만이 reschedule IPI 를 받을 겁니다; dyntick-idle CPU 들은 단지 extended quiescent state 를 표시되어질 뿐입니다. □

Quick Quiz D.11:

하지만 한 CPU 가 bit 값 설정하는 CPU 가 종료되기 전에 (자신의 bit 의 값을 해제하면서) quiescent state 를 지나감을 이야기 하려 하면 어떻게 되나요? ■

Answer:

여기서 고려할 세개의 경우가 존재합니다:

1. 아직 초기화 되지 않은 leaf rCU_node 구조체에 연관된 CPU 가 quiescent state 를 보고하려 합니다. 이 CPU 는 이미 자신의 bit 의 값을 해제했고, 따라서 자신의 quiescent state 를 보고하는 것을 포기할 겁니다. 나중의 quiescent state 가 새로운 grace period 를 위해 동작될 겁니다.

2. 현재 초기화 중인 leaf rCU_node 구조체에 연관된 CPU 가 quiescent state 를 보고하려 합니다. 이 CPU 는 해당 rCU_node 구조체의 ->lock 이 잡혀 있음을 보게 되고, 따라서 그 락이 해제될 때까지 spin 을 하게 됩니다. 하지만 일단 이 락이 해제되면, rCU_node 구조체는 초기화 되었을 것이므로, 다음 경우로 합쳐집니다.

3. 이미 초기화 된 leaf rCU_node 에 연관된 CPU 가 quiescent state 를 보고하려 합니다. 이 CPU 는 자신의 bit 에 값이 설정된 것을 보게 되고, 따라서 이를 해제하려 합니다. 만약 이게 해당 leaf node 의 마지막 CPU 라면, 계층의 다음 레벨로 올라갈 겁니다. 하지만, 이 CPU 는 시스템에서 quiescent state 를 보고하려는 마지막 CPU 일 수가 없는데, 초기화를 하는 CPU 는 아직 검사되어졌을 수가 없기 때문입니다.

따라서, 모든 세개의 경우에 있어서, 잠재적인 경주 상황은 모두 올바르게 해결됩니다. □

Quick Quiz D.12:

Bit 값 설정 CPU 가 종료되기 전에 모든 CPU 들이 quiescent state 를 지나감을 보고하려고 해서 새로운 grace period 를 시작도 하기 전에 종료해 버리면 무슨 일이 일어나나요? ■

Answer:

Bit 의 값을 설정하는 CPU 는 초기화 중에 quiescent state 를 지나갈 수가 없는데, irq 들을 불능화 시켰기 때문입니다. 따라서 해당 bit 들은 0이 아닌 값으로 남아있어서, 데이터 구조가 완전히 초기화 되기 전에 grace period 가 종료되는 것을 막습니다. □

Quick Quiz D.13:

한 CPU 가 dyntick-idle 모드에서 빠져나오고선 다른 CPU 가 첫번째 CPU 가 dyntick-idle 모드에 있었음을 알게 되자마자 quiescent state 를 지나가버리면 어떻게 되나요? 두 CPU 모두 동시에 quiescent state 를 보고하려 해서, 혼란이 생기지 않을까요? ■

Answer:

두 CPU 모두 같은 leaf rCU_node 구조체의 락을 잡으려 할 겁니다. 락을 잡으려 하는 첫번째 것이 quiescent state 를 보고하고 연관된 bit 의 값을 지을 거고, 두번째 것은 락을 잡고나서 이 bit 이 이미 지워져 있음을 보게 될 겁니다. □

Quick Quiz D.14:

하지만 모든 CPU 들이 dyntick-idle 모드에 있으면 어떻게 되죠? 이게 현재의 RCU grace period 가 영원히 끝나지 못하게 하자는 않을까요? ■

Answer:

실제로 그럴겁니다! 하지만, RCU 콜백들을 가지고 있는 CPU들은 dyntick-idle 모드에 빠질 수 없게 되어 있어서, 모든 CPU들이 dyntick-idle 모드에 빠질 수 있는 유일한 방법은 시스템 내에 RCU 콜백이 정말 하나도 없을 때입니다. 그리고 시스템에 RCU 콜백이 하나도 없다면, RCU grace period 가 끝나길 기다려야 할 이유도 없죠. 사실, RCU grace period 가 시작될 필요도 없는 겁니다.

만약 어떤 irq 핸들러가 RCU 콜백이 연관된 CPU에 보이게 해서 해당 CPU가 dyntick-idle 모드의 바깥으로 나오도록 강제할 거고, 결국 현재의 RCU grace period 가 종료되도록 하는 `call_rcu()` 를 한다면 RCU가 재시작 될겁니다. □

Quick Quiz D.15:

`force_quiescent_state()` 가 세단계 state machine 이란 것을 놓고 보면, 모든 CPU들을 스캐닝 하는 것 때문에 스캐닝 응답시간을 세배로 늘리는 것 아닌가요?

Answer:

아, 하지만 이 세단계는 같은 CPU 위에서 back-to-back으로 수행되진 않을 거고, 더 나아가서 첫번째 (초기화) 단계는 스캐닝을 아예 하지 않아요. 따라서, 이 세단계 알고리즘에서의 스캐닝 응답시간은 한단계 알고리즘의 것과 크게 다르지 않습니다. 스캐닝 응답시간이 문제가 된다면, state machine 이 CPU들을 점진적으로 스캔하도록 상태를 `per-leaf-rcu_node` 에 저장하는 방식으로 코드를 고치는게 한가지 방법이 될 수 있습니다. 하지만 일단은 실제 세계에서 발생하는 문제를 제게 보여주세요, 그러면 제가 그걸 고치겠습니다! □

Quick Quiz D.16:

하지만 `->onofflock` 을 잡는 또 다른 이유는 여러개의 동시적인 online/offline 오퍼레이션들을 방지하기 위함이 맞지요? ■

Answer:

분명, 아닙니다! CPU-hotplug 코드의 동기화 설계는 복수의 동시적인 CPU online/offline 오퍼레이션들을 방지하므로, 한번에 하나의 CPU의 online/offline 오퍼레이션만이 수행될 수 있습니다. 따라서, `->onofflock` 의 유일한 목적은 CPU online 또는 offline 오퍼레이션이 grace-period 초기화와 동시에 수행되는 것을 막는 것입니다. □

Quick Quiz D.17:

Global 한 `->onofflock` 의 획득을 위한 동작들을 모두 보면, 수천개의 CPU들이 동작하는 경우에는 이게 상당한 락 경쟁이 되지 않을까요? ■

Answer:

실제로, grace period 당 이 락에 대한 세개의 획득 동작만이 있을 것이고, 각각의 grace period 는 수 밀리세컨드 동안 유지됩니다. 이런 획득들 가운데 하나는 현재 grace period 를 위한 CPU 초기화에 의해서 이루어지고, 나머지 두개는 CPU의 online화와 offline화입니다. 이 나중 두개의 동작은 CPU-hotplug 락킹으로 인해 동시에 수행될 수는 없으므로, 언제든 이 락에 대해 최대 두개의 CPU 들만이 경쟁하게 됩니다.

따라서 `->onofflock`에 대한 락 경쟁은 수천개의 CPU를 가진 시스템에서도 문제가 되지 않습니다. □

Quick Quiz D.18:

Dyntick-idle CPU 탐지와 offline CPU 탐지를 합쳐서 코드를 단순화 시키는 건 어떤가요? ■

Answer:

그런 병합 작업이 최종적으로는 옳은 일이 될겁니다. 하지만, 그러기 위해서는 다음과 같은 도전이 존재합니다:

1. CPU들은 그것들이 유보된 RCU 콜백들을 가지고 있는 동안은 dyntick-idle 모드에 빠질 수 없는데, CPU는 유보된 콜백들을 가진채로 offline으로 빠질 수 있습니다. 이 말은 offline이 되는 CPU들은 다른 CPU에게 자신의 콜백들을 옮겨야 한다는 의미이며, 따라서 우린 CPU들이 그냥 offline으로 빠지도록 할 수 없습니다.
2. 오늘날의 리눅스 시스템은 실제 CPU 갯수보다 훨씬 많은 NR_CPUS 를 가지고 동작합니다. 따라서 통합을 하는 방법은 애초에 존재하지도 않으면서 offline이 아닌 CPU들을 불필요하게 기다리는 것 이 될 수 있습니다.
3. RCU는 이미 부팅 중간에 CPU들이 하나씩 online이 되는 상황에서도 동작할 수 있으며, 따라서 online 과정을 처리해야만 합니다. 이 온라인 과정은 grace-period 초기화와 배타적으로 수행되어야 하며, 따라서 `->onofflock` 은 여전히 사용되어져야 합니다.
4. CPU들은 종종 매우 빈번하게 dyntick-idle 모드를 들어갔나 나왔다 하며, 따라서 dyntick-idle 모드에 들어가고 나오는 코드 경로를 무겁게 하는건 합리적이지 않습니다. □

Quick Quiz D.19:

`rcu_data` 구조체의 `lock` 을 획득할 때 그냥 bottom halves (softirq)를 비활성화시키는게 어떤가요? 그게 더 빠르지 않겠어요? ■

Answer:

이 락은 irq 핸들러들에서 수행될 수 있는 `call_rcu()`에서 호출된 함수에서 회득될 수 있기 때문입니다. 따라서, 이 락을 회득할 때 irq 들은 반드시 비활성화 되어야만 합니다. □

Quick Quiz D.20:

Leaf `rcu_node` 구조체의 `qsmask` 와 `qsmaskinit` 필드들은 어떤가요? 이 필드들의 어떤 bit 들이 이 `rcu_node` 구조체에 의해 처리되는 각 CPU 들에 연관되는지를 알기 위한 어떤 방법이 필요하지 않나요? ■

Answer:

실제로 그렇습니다! 각 CPU 의 `rcu_data` 구조체의 `grpmask` 필드가 이 일을 합니다. □

Quick Quiz D.21:

`Offline` 이 되는 건 모든 진행중인 grace period 를 처리해야 할 `extended quiescent state` 인데도 왜 CPU 가 `online` 이 될 때 `qs_pending` 의 값을 1 로 설정하는 거죠? ■

Answer:

이게 CPU 가 `online` 이 되는 것과 새로운 grace period 가 시작하는 사이의 race 를 해결하는 걸 돋기 때문입니다. □

Quick Quiz D.22:

왜 `passed_quiesc_completed` 에 마지막으로 완료된 grace period 의 수를 기록하는거죠? 그건 어떤 grace period 도 진행중이지 않을 때에 보여진 quiescent state 들이 올바르지 않게 다음에 시작되는 grace period 에 적용되는 것에 이 RCU 구현이 취약해 지게 하지 않나요? ■

Answer:

한 grace period 의 종료 근처에서 알려진 quiescent state 가 올바르지 않게 다음 grace period 에 적용되는 race 를 막기 위해, 특히 dyntick 과 CPU-offline grace period 들을 위해 우린 마지막으로 완료된 grace period 수를 기록합니다. 따라서, `force_quiescent_state()` 와 그 부류들은 모두 그런 race 들을 막기 위해 마지막으로 완료된 grace period 수를 체크합니다.

이제 이 dyntick 과 CPU-offline grace period 들은 어떤 grace period 가 실제로 살아있을 때에만 체크됩니다. 어떤 grace period 도 진행중이지 않을 때에 기록될 수 있는 유일한 quiescent state 들은 스스로 파악되는 quiescent state 들로, `passed_quiesc_completed`, `passed_quiesc`, 그리고 `qs_pending`에 기록되는 것들입니다. 이 변수들은 연관된 CPU 가 새로운 grace period 가 시작했음을 알게 됐을 때마다 초기화 되어서,

시대에 뒤져버린 quiescent state 가 새로운 grace period 에 적용되는 것을 막습니다.

그렇지만, grace-period 응답시간을 최적화 하는 건 `completed`에 대해서 `gpnum` 이 추적될 것을 필요로 할수 있습니다. □

Quick Quiz D.23:

실제 CPU 들의 수보다 많은 `NR_CPUS` 를 갖는 시스템을 운영하는 이유가 뭐죠? ■

Answer:

이는 다양한 시스템에서 돌아가는 하나의 리눅스 커널 바이너리를 만들 수 있게 해서 운영과 검증을 간단하게 해주기 때문입니다. □

Quick Quiz D.24:

이 웃기는 여러 꼬리를 가진 리스트 보다는 여러개의 리스트를 그냥 유지하는게 어때요? ■

Answer:

Lai Jiangshan 덕에, 이 여러 꼬리를 가진 리스트 방법은 콜백 처리를 단순화 시킵니다. □

Quick Quiz D.25:

그래서 일부 불쌍한 CPU 는 모든 각각의 offline CPU 아래에서도 quiescent state 들을 알려야 한다는 건가요? 으웩! 그건 적은 수의 CPU 를 가지고 있지만 큰 값의 `NR_CPUS` 를 가진, 흔하지 않은 시스템에서는 지나친 오버헤드가 되지 않을까요? ■

Answer:

실제로는, 그러지 않을 겁니다!

Offline CPU 들은 `qsmask` 와 `qsmaskinit` bit mask 들에서 빠져있고, 따라서 RCU 는 일반적으로 이것들을 무시합니다. 하지만, offline CPU 가 `qsmask` bit 을 설정되고 있는 결과가 나오게 하는 `online/offline` 오퍼레이션들에서의 race 가 존재합니다. 이 race 들은 물론 올바르게 처리되어야 하며, 그게 처리되게 하는 방법은 다른 CPU 들에게 RCU 가 offline CPU 로부터의 quiescent state 를 기다리고 있다고 알려주는 겁니다. □

Quick Quiz D.26:

그럼 이 앞에서 이야기된 이 구조체의 필드들은 뭘로 보호되나요? ■

Answer:

아무것도 보호하지 않는데, 그것들은 컴파일 시점이나 부팅 시점에 그 값이 설정되는 상수들이기 때문입니다. 물론, `->node` 배열 안의 `rcu_node` 안의 필드들은 바뀔 수도 있겠습니다만, 그것들은 별도로 보호됩니다. □

Quick Quiz D.27:

전 RCU read-side 처리가 빠를 거라고 생각했는데요! Figure D.21 에 보인 함수들은 너무 쓰레기가 많이 들어있어서 이건 느릴 수밖에 없겠는걸요! 이게 뭘니까? ■

Answer:

외양은 착각을 일으킬 수 있습니다. `preempt_disable()`, `preempt_enable()`, `local_bh_disable()`, 그리고 `local_bh_enable()` 는 각각 로컬 데이터에 대한 하나의 atomic 하지 않은 변경을 가합니다. 그것조차도 `CONFIG_PREEMPT` 를 가정한 것이고, 그렇지 않다면 `preempt_disable()` 과 `preempt_enable()` 함수는 아무 코드도 수행하지 않으며 컴파일러 지시어도 내놓지 않습니다. `__acquire()` 와 `__release()` 함수들은 아무 코드도 (아무 컴파일러 지시어도) 만들지 않고 문법 분석 버그 탐색 프로그램인 `sparse` 에 사용될 뿐입니다. 마지막으로, `rcu_read_acquire()` 와 `rcu_read_release()` 는 실제로 그 비용이 비쌀 수 있는 경우인, 락 순서 디버깅 기능인 “lockdep” 이 활성화 되어 있는 경우가 아니라면 아무 코드도 (아무 컴파일러 지시어도) 내놓지 않습니다.

짧게 말해서, 여러분이 디버깅 옵션을 켜놓은 커널 해커가 아니라면, 이 함수들은 매우 가볍고, 일부 경우에는 완전히 오버헤드가 없습니다. 그리고, 포틀랜드 지역 가구 판매사에서 밀하는 걸 인용하자면, “free is a very good price”. ■

Quick Quiz D.28:

Figure D.22 의 line 13 에서 현재 CPU 의 `rcu_data` 구조체로의 레퍼런스를 가져오는데에 간단히 `__get_cpu_var()` 를 사용하는게 어떤가요? ■

Answer:

우리는 `call_rcu()` 에서 호출되었거나 (이 경우라면 우린 `__get_cpu_var(rcu_data)` 를 사용해야 할 겁니다) `call_rcu_bh()` 에서 호출되었을 수 있습니다 (이 경우라면 `__get_cpu_var(rcu_bh_data)` 를 사용해야 합니다). 우리가 넘긴 `rcu_state` 구조체가 뭔가에 관계없이 `->rda[]` 배열을 사용하는 것은 어떤 API 의 `__call_rcu()` 가 호출되었는가에 관계없이 올바르게 동작합니다 (Lai Jiangshan 에 의해 제안되었습니다 [Jia08]). ■

Quick Quiz D.29:

Figure D.23 의 line 29-32 에서 `rcu_pending()` 이 항상 두번 호출된다는 점을 생각해보면 이 두개의 구조체들에 대한 검사들을 하나로 합칠 방법이 있어야 하는거 아닌가요? ■

Answer:

미안해요, 이건 훼이크 질문이었어요. C 언어의 단락 boolean 표현에 대한 평가 규칙은 `rcu_state` 에 대한 `__rcupending()` 호출이 0을 리턴했을 때에만 `rcu_bh_state` 를 위한 두번째 호출을 수행할 것을 보장합니다.

이런 순서로 두개의 함수 호출이 이루어지는 이유는 “`rcu_bh`” 보다는 “`rcu`” 가 더 자주 사용되기 때문으로, 따라서 첫번째 호출이 0이 아닌 값을 리턴할 확률이 두 번째 것보다 높습니다. ■

Quick Quiz D.30:

Figure D.23 의 line 42 는 `in_hardirq()` 검사도 해야 하지 않습니까? ■

Answer:

아니요. `rcu_read_lock_bh()` 기능은 softirq 를 비활성화 하지, hardirq 를 비활성화 하지는 않습니다. `call_rcu_bh()` 는 앞서 존재한 “`rcu_bh`” read-side 크리티컬 섹션이 완료되기만 기다리면 되므로, 우린 `in_softirq()` 만을 검사합니다. ■

Quick Quiz D.31:

하지만 Figure D.24 의 `__rcu_process_callbacks` 에서 grace period 가 실제로 진행중인지도 체크해 봐야 하지 않을까요? ■

Answer:

실제로 우린 그렇게 합니다! 그리고 `force_quiescent_state()` 가 하는 첫번째 일이 바로 그 검사입니다. ■

Quick Quiz D.32:

Figure D.24 에서 두개의 CPU 들이 새로운 grace period 를 동시적으로 시작하려 시도하면 어떻게 되나요? ■

Answer:

해당 CPU들 가운데 하나는 루트 `rcu_node` 구조체의 락을 획득할 것이고, 해당 CPU 가 grace period 를 시작할 겁니다. 다른 CPU 는 이후에 이 락을 획득하고 `rcu_start_gp()` 를 호출할텐데, 이 함수는 grace period 가 이미 진행 중임을 보게 될 것이고, 곧바로 락을 해제하고 리턴할 겁니다. ■

Quick Quiz D.33:

해당 코드는 `rcu_node` 계층의 root 부터 leaf 까지를 어떻게 횡단하나요? ■

Answer:

해당 코드는 그런 횡단을 할 필요가 없고, 따라서 이를 처리하는 특수한 일이 필요 없습니다. ■

Quick Quiz D.34:

C-preprocessor 매크로는 너무 1990년대 스러워요! 왜 요즘 시대에 걸맞게 Figure D.29 의 RCU_DATA_PTR_INIT() 을 함수로 바꾸지 않는거죠? ■

Answer:

왜냐하면, 특정 CPU 의 per-CPU 변수 인스턴스로의 레퍼런스를 함수에 넘길 수는 있겠지만, 특정 per-CPU 변수의 인스턴스의 전체 집합으로의 레퍼런스를 함수에 넘길 좋은 방법이 없기 때문입니다. 물론 누군가는 포인터들의 배열을 만들고 그 배열로의 레퍼런스를 넘길 수도 있겠습니다만, 그건 RCU_DATA_PTR_INIT() 매크로가 가장 먼저 하는 일 중 하나입니다. □

Quick Quiz D.35:

Figure D.29 의 line 25-26 에서 online CPU 가 마지막으로 알려졌을 때와 line 27 에서 register_cpu_notifier() 가 호출된 시점 사이에서 어떤 CPU 가 online 이 되면 어떤 일이 벌어지나요? ■

Answer:

이 시점에서는 하나의 CPU 만이 online 이므로, 다른 CPU 가 online 이 되는 유일한 방법은 이 CPU 가 해당 CPU 를 online 으로 두는 것으로, 성립되지 않는 이야기입니다. □

Quick Quiz D.36:

Figure D.30 의 line 41 에서는, 우리가 다양한 락들을 사용해 grace period 들을 배제시켰음에도, 그리고 모든 앞서 존재한 grace period 들은 이 기준에 offline 이 된 CPU 들을 기다리지 않을 것임에도, 왜 cpu_quiet() 를 호출하는거죠? ■

Answer:

새로운 grace period 는 line 40 에서 ->onofflock 이 해제된 직후에 시작되었을 수 있습니다. cpu_quiet() 는 그런 grace period 를 진척시키는 도움을 줄겁니다. □

Quick Quiz D.37:

하지만 작은 시스템이어서 rCU_node 계층이 하나의 구조체만을 갖는다면 어떻게 되나요? Figure D.32 의 코드에서, 이 경우에 무엇이 동시의 grace-period 초기화를 방지하나요? ■

Answer:

Line 16 에서의 rCU_node 구조체의 ->lock 획득이 grace-period 초기화를 배제시키는데, 초기화 역시 새로운 grace period 를 위한 rCU_node 구조체의 초기화를 위해 이 똑같은 락을 획득해야 하기 때문입니다.

이 ->onofflock 은 multi-node 계층들을 위해서만 필요하며, 그런 경우에 커다란 시스템에서는 놀랍도록

큰 비용이 될, 모든 rCU_node 구조체의 ->lock 필드들을 획득하고 잡는 것에 대한 대체로 사용됩니다. □

Quick Quiz D.38:

하지만 Figure D.32 의 line 25 가 정말로 이 루프를 끝낼까요? 그렇다면, 또는 그렇지 않다면 왜죠? ■

Answer:

Line 25 가 이 루프를 끝내는 유일한 방법은 모든 CPU 들이 offline 이 되려 할 때입니다. 이는 2.6.28 버전까지의 리눅스 커널에서는 일어날 수 없는 일입니다만, shutdown 과정 중에 모든 CPU 들이 오프라인이 되도록 설계되는 다른 환경이 있을 수도 있습니다. □

Quick Quiz D.39:

Figure D.32 의 line 26 이 상당히 비순차적으로 수행되어서 lastcomp 는 어떤 앞의 grace period 로 설정되어 있지만 현재 grace period 는 여전히 이제 offline 이 된 CPU 를 기다리고 있다고 생각해 봅시다. 이런 경우, cpu_quiet() 호출은 이 quiescent state 를 보고하는데 실패하고, 따라서 이 grace period 가 이 이제는 offline 이 된 CPU 를 영원히 기다리게 되지 않을까요? ■

Answer:

먼저, line 16 과 12 에서의 락 획득은 line 26 의 수행이 그렇게까지 비순차적으로 되지 못하게 합니다. 그러나, line 26 이 그렇게까지 극적으로 잘못 순서지어지는 일 이 발생한다 하더라도, force_quiescent_state() 가 결국은 호출되어어서, 현재 grace period 가 offline CPU 로부터의 quiescent state 를 기다리고 있었다는 걸 알리게 될 겁니다. 그렇게 되면 force_quiescent_state() 는 이 offline 이 된 CPU 에 extended quiescent state 가 있는 것으로 보고할 겁니다. □

Quick Quiz D.40:

Offline CPU 가 extended quiescent state 에 있음에도, 왜 Figure D.32 의 line 28 은 자신이 어떤 grace period 를 처리하고 있는지 신경써야 하는거죠? ■

Answer:

이 경우엔 실제로 그런 신경을 쓸 필요가 없습니다. 하지만, 많은 다른 경우에는 실제로 신경을 써야 하므로, cpu_quiet() 함수는 grace-period 숫자를 인자로 받으며, 따라서 어떤 값을 넘기길 해야 합니다. □

Quick Quiz D.41:

하지만 Figure D.32 의 이 리스트 이동은 모든 offline 이 되는 CPU 의 콜백들이 설령 호출될 준비가 되어 있는 상태였을지라도 다른 grace period 로 가도록 만듭니다.

이건 비효율적이지 않나요? 뿐만 아니라, offline 이 되고는 online 으로 돌아오는 CPU 들의 불행한 패턴은 특정 콜백이 영원히 호출되지 않게 할 수 있지 않나요? ■

Answer:
비효율적이지만, 간단합니다. 이게 흔히 수행되는 코드 경로가 아니란 점을 놓고 보면, 이건 괜찮은 트레이드 오프입니다. Starvation 문제는 문제가 될 수 있겠지만, online 과 offline 과정이 여러 grace period 에 관여되는 경우엔 예외일 겁니다. □

Quick Quiz D.42:

Figure D.34 의 `check_for_new_grace_period()` 안에 `note_new_gpnum()` 을 그대로 집어넣지 않나요? ■

Answer:
`note_new_gpnum()` 은 각각의 새로운 grace period 를 위해 호출되어야만 하며, 이는 이 CPU 에 시작된 것들과 다른 CPU 들에 의해 시작된 것들을 포함하기 때문입니다. 반면에, `check_for_new_grace_period()` 는 일부 다른 CPU 들이 grace period 를 시작한 경우에 대해서만 호출됩니다. □

Quick Quiz D.43:

하지만 Figure D.37 의 line 15 까지는 초기화가 없었어요! 만약 CPU 가 새로운 grace period 를 알게 되었지만 곧바로 quiescent state 를 보고하려 하면 어떻게 되죠? 이러면 좀 혼란스러워지지 않을까요? ■

Answer:

두 가지 흥미로운 경우가 있습니다.

첫 번째 경우는, 계층상에 하나의 `rcu_node` 구조체만 있는 경우입니다. `rcu_start_gp()` 에서 수행중인 CPU 는 현재 `rcu_node` 구조체의 락을 잡고 있으므로, quiescent state 를 보고하려 하는 CPU 는 초기화가 완료되기 전까지는 이 락을 잡지 못할 것이어서 평범한 시점에 quiescent state 를 보고하게 될 겁니다.

두 번째 경우는 여러개의 `rcu_node` 구조체가 존재하고 quiescent state 를 보고하려고 하는 CPU 에 연관된 leaf `rcu_node` 구조체는 이미 해당 CPU 의 `->qsmask` bit 의 값이 0 으로 설정되어 있는 경우입니다. 따라서, 이 quiescent state 를 보고하려 하는 CPU 는 포기를 할 것이고, 해당 CPU 의 나중의 quiescent state 가 새로운 grace period 에 적용될 겁니다. □

Quick Quiz D.44:

이봐요! Figure D.37 의 line 37 의 non-leaf `rcu_node` 구조체의 상태 분배 시에 그락들을 잡아야 하지 않나요??? ■

Answer:

그 락들을 잡을 필요가 없습니다. 그 이유는 다음과 같습니다:

1. 이 새로운 grace period 는 끝날 수 없는데, 이 수행 중인 CPU (초기화를 하고 있는) 는 quiescent state 를 지나지 않을 것이기 때문입니다. 따라서, 또 다른 `rcu_start_gp()` 호출과의 race 는 없습니다.
2. 이 수행중인 CPU 는 `->onofflock` 을 잡으므로, CPU-hotplug 오퍼레이션과의 race 는 없습니다.
3. 이 leaf `rcu_node` 구조체들은 아직 초기화 되지 않았고, 따라서 이것들은 각자의 `->qsmask` bit 들이 값 해제되어 있습니다. 이 말은 quiescent state 를 보고하려 하는 모든 다른 CPU 들은 leaf 단계에서 멈춰서 있게 될 것이고, 따라서 현재의 CPU 와 non-leaf `rcu_node` 구조체들에서 race 를 겪지 않게 될것을 의미합니다.
4. `rcu_node` 구조체들에 RCU tracing 함수들이 접근하기 하지만, 수정하진 않습니다. 이 함수들과의 race 들은 따라서 무해합니다. □

Quick Quiz D.45:

Figure D.37 의 line 36-37 의 루프를 line 40-44 에 합치는 건 어떤가요? ■

Answer:

그렇게 할 거였다면, non-leaf `rcu_node` 구조체의 락을 불필요하게 잡게 되거나 이 루프의 매 패스마다 leaf node 인지에 대한 보기 싫은 체크를 해야 할 겁니다. (Quiescent state 를 보고하려 시도할 CPU 들과의 race 때문에 leaf `rcu_node` 구조체들의 락을 잡아야만 했음을 다시 말합니다.)

그러나, 매우 큰 시스템에서의 경험은 그런 병합 작업이 실제로는 하는게 나은 것으로 드러나게 할 수도 있습니다. □

Quick Quiz D.46:

Figure D.39 의 line 11-12 가 앞의 grace period 로부터의 quiescent state 를 현재의 grace period 에게 보고하는 것을 방지하는 건 무엇인가요? ■

Answer:

만약 그런 일이 일어날 수 있다면, 그건 심각한 버그인데, 해당 CPU 는 현재 grace period 의 시작보다 먼저 시작한 RCU read-side 크리티컬 섹션에 있을 수 있기 때문입니다.

이런 경우를 위해 CPU 에 대해 신경써야 할 경우들이 몇 가지 있습니다:

1. Online 으로 남아있고 계속해서 활성 상태.
2. 최소한 현재 grace period 의 한 부분동안은 dynticks-idle 모드에 있었음.
3. 최소한 현재 grace period 의 한 부분동안은 offline 이었음.

첫번째 경우에는, 앞의 grace period 는 이 CPU 가 명시적으로 quiescent state 를 보고하지 않았다면, 즉 `->qs_pending` 이 0이 아니라면 종료될 수가 없습니다. 이는 다시 말해 line 7-8 이 리턴할 것을 의미하며, 따라서 제어 흐름은 `check_for_new_grace_period()` 가 새로운 grace period 를 알리지 않았다면 `cpu_quiet()` 까지 도달하지 않음을 의미합니다. 하지만, 만약 현재 grace period 가 알려졌다면, `->passed_quiesc` 를 0 으로 만들었을 것이고, 이 경우 line 9-10 이 리턴하게 되므로, 이 경우에도 `cpu_quiet()` 는 호출되지 않습니다. 마지막으로, `->passed_quiesc` 가 호출될 수 있는 유일한 방법은 `rcu_check_callbacks()` 가 Figure D.39 의 `rcu_check_quiescent_state()` 의 line 5 와 9 사이에서 `scheduling-clock` 인터럽트가 발생해서 `rcu_check_callbacks()` 가 호출된 경우일 겁니다. 하지만, 이는 현재의 grace period 중에 quiescent state 가 발생하는 경우가 될 것으로, 이 경우는 현재 grace period 에 대해 보고되는게 완전히 합법적입니다. 따라서 이 경우는 완전히 해결됩니다.

문제시 되는 CPU 가 새로운 quiescent state 의 일부를 dynticks-idle 모드로 보낸 경우인 두번째 경우에 있어서는, dynticks-idle 모드는 extended quiescent state 이며, 따라서 이 quiescent state 를 현재의 grace period 에게 보고하는 것은 허용 가능한 일임을 알아두시기 바랍니다.

문제의 CPU 가 새로운 quiescent state 의 일부를 offline 으로 보낸 경우인 세번째 경우에 대해서는, offline CPU 들은 extended quiescent state 에 있는 것이어서 이번에도 현재의 grace period 에게 보고되는 것은 허용 가능합니다.

따라서 앞의 grace period 로부터의 quiescent state 는 현재의 grace period 에게 보고되지 않습니다. □

Quick Quiz D.47:

Figure D.40 의 line 22-23 은 수행중인 CPU 의 RCU 콜백들을 촉진시켜도 안전함을 아는 거죠? ■

Answer:

명시된 CPU 는 아직 quiescent state 를 지나지 않았으므로, 그리고 우리가 연관된 leaf node 의 락을 잡고 있으므로, 우리는 현재의 grace period 가 아직 끝나지 못했을 것임을 알고 있습니다. 따라서, 현재 대기열에 들어있는 콜백들은 모두 다음 grace period 가 시작된 후에 등록되었더라도 그것들은 이미 대기열에 들어와

있고 다음 grace period 는 아직 시작되지 않았으므로 안전함을 알 수 있습니다. □

Quick Quiz D.48:

Figure D.41 의 line 2 의 인자 `mask` 는 `unsigned long` 인데, 이게 어떻게 64 개 이상의 CPU 들을 갖는 시스템들을 다룰 수 있겠습니까? ■

Answer:

`mask` 는 명시된 leaf `rcu_node` 구조체에만 상관있으므로, 해당 `rcu_node` 구조체에 연관된 CPU 들을 표현할 수 있을 만큼만 크면 충분합니다. 최대 64 개의 CPU 들이 (32-bit 시스템이라면 32 CPU 들) 하나의 `rcu_node` 구조체에 연관될 수 있으므로, `unsigned long` `mask` 인자로도 충분합니다. □

Quick Quiz D.49:

Dynticks-idle 이나 offline CPU 들에 있는 RCU 콜백들은 어떻게 호출되나요? ■

Answer:

그것들은 호출되지 않습니다. RCU 콜백들을 가진 CPU 들은 dynticks-idle 모드에 들어갈 수 없게 되어있으므로, dynticks-idle CPU 들은 RCU 콜백을 가질 수 없습니다. CPU 가 offline 이 될 때에는, 이것들의 RCU 콜백들은 online CPU 로 넘어가고, 따라서 offline CPU 는 역시 RCU 콜백을 가질 수 없습니다. 따라서, dynticks-idle 이나 offline CPU 에서의 콜백들은 호출될 필요가 없습니다. □

Quick Quiz D.50:

Figure D.43 의 line 14-17 은 왜 tail 포인터를 조정하는 거죠? ■

Answer:

어떤 tail 포인터라도 호출될 준비가 된 sublist 의 마지막 콜백을 가리키고 있었다면, 그것들은 `->nxtlist` 포인터를 가리키도록 바꿔어야만 합니다. 이 상황은 호출될 준비가 된 sublist 를 따르는 sublist 가 텅 비었을 경우 발생합니다. □

Quick Quiz D.51:

Figure D.45 의 코드는 어떻게 중첩된 NMI 들을 처리하나요? ■

Answer:

NMI 들은 중첩되지 않으므로 중첩된 NMI 들을 처리할 필요가 없습니다. □

Quick Quiz D.52:

Figure D.47 의 line 8 과 9 사이에는 왜 메모리 배리어가 없죠? 이는 `->dynticks` 와 `->dynticks_nmi` 필드의

두 값이 동시에 0이었던 적이 없는데도 짹수 값을 가져오도록 할 수 있지 않나요? ■

Answer:

먼저, Figure D.44, D.45, 그리고 D.46 를 다시 한번 보시고 dynticks 와 dynticks_nmi 는 결코 동시에 훌수 값을 가질 수 없음을 알아두시기 바랍니다 (특히 Figure D.45 의 line 6 과 17 을 잘 보시고, NMI 에서 인터럽트는 일어날 수 없음을 다시 상기하세요).

물론, 이 함수들의 메모리 배리어의 위치를 놓고 보면, 다른 CPU 에겐 두 카운터들이 동시에 훌수인 것으로 보일 수도 있습니다만, 논리적으로 이는 일어날 수 없고, 해당 CPU 가 실제로는 dynticks-idle 모드를 지났음을 알리게 될 겁니다.

이제, line 8 이 ->dynticks 의 값을 얻어오는 시점에서 ->dynticks_nmi 가 훌수 값을 가지고 있었고, line 9 가 ->dynticks_nmi 의 값을 얻어온느 시점에서 ->dynticks 값은 훌수 값이었다고 생각해 봅시다. 두개의 카운터들은 동시에 훌수일 수 없다는 점을 놓고 보면, 이 두개의 값 가져오기 동작 사이에 두개의 카운터가 모두 짹수 값을 갖는 시점, 즉 해당 CPU 가 dynticks-idle 모드였던 시간이 있었다는 이야기가 되는데, 이는 곧 필요시되는대로, quiescent state 입니다.

그런데, 왜 Figure D.47 의 line 13 의 `&&` 는 `==` 로 바뀔 수 없을까요? 음, 그럴 수도 있지만, 이는 도움이 되기보다는 헷갈리기만 할 수 있습니다. □

Quick Quiz D.53:

Figure D.55 의 line 12-13 에서는 왜 두 jiffy 를 더 기다리는 거죠? ■

Answer:

이 추가된 딜레이이는 이 CPU 에게 스스로를 보고할 기회를 주어서, stall 된 코드의 더 나은 스택트레이스를 얻을 수 있게 합니다. 물론, 이 CPU 가 인터럽트가 불능화 된 채 spin 하고 있다면 스스로를 보고하지 않을 것이어서, 다른 CPU 들은 더 짧은 딜레이 만에 이 일을 해야 할 겁니다. □

Quick Quiz D.54:

Figure D.56 에서 stall 경고가 출력되게 전에 grace period 가 종료되는 건 누가 막나요? ■

Answer:

이 함수의 호출자는 이 CPU 가 아직 quiescent state 를 보고하지 않았음을 체크했고, preemption 은 꺼져있기 때문에, quiescent state 가 이 사이에 보고될 방법은 없습니다. □

Quick Quiz D.55:

`print_cpu_stall()` 은 안그러는데 Figure D.57 의

`print_other_cpu_stall()` 은 왜 grace period 의 종료를 검사해야 하나요? ■

Answer:

다른 CPU 들은 언제든 quiescent state 를 지날 수 있고, 따라서 이 grace period 는 중간에 끝났을 수 있습니다. □

Quick Quiz D.56:

Preemptible-RCU read-side 크리티컬 섹션 내에서 호출되는 블록킹 기능들이 우선순위 상속에 결리기 쉬워야 한다는 점이 중요한 이유가 뭐죠? ■

Answer:

블록당한 읽기 쓰레드들은 RCU grace period 를 멈추게 만들어서 OOM 을 일으킬 수 있기 때문입니다. 예를 들어, 한 읽기 쓰레드가 RCU read-side 크리티컬 섹션 내에서 `wait_event()` 를 호출했고, 그 이벤트가 절대 일어나지 않는다면, RCU grace period 는 비결정적으로 지속될 것이고, 이는 이 시스템이 금방이든 나중이든 OOM 을 일으킬 것을 보장합니다. 따라서, 그런 OOM 을 막기 위해 이런 읽기 쓰레드들이 read-side 크리티컬 섹션에 대해 진행을 할 수 있도록 하는 어떤 방법이 있어야만 합니다. Priority boosting 은 그런 진행을 강제하기 위한한가지 방법입니다만, 읽기 쓰레드들이 priority boosting 을 통해 깨어날 수 있다던지 하는 제한된 블록킹에 있을 때에만 가능합니다.

물론, 우선순위 상속 외에도 우선순위 역전 문제를 해결하는 priority ceiling, preemption disabling 등의 다른 방법들이 존재합니다. 하지만, 리눅스 커널에서 우선순위 상속이 사용되는 좋은 이유가 존재하고, 그런 이유로 RCU 에서 사용하기로 했습니다. □

Quick Quiz D.57:

Non-CONFIG_PREEMPT 커널 내에서 블록될 수 있는 기능들을 사용할 수 있게 하는 게 가능할까요, 그리고 만약 그렇다면, 어떤 조건 하에서 가능할까요? ■

Answer:

테스트와 벤치마크가 preemptible RCU 가 classic RCU 가 완전히 사라질 수 있을 정도로 잘 동작한다는 것을 보인다면, 그리고 우선순위 상속이 semaphore 들과 같은 블록킹 동기화 기능들을 위해서도 구현된다면, 그런 기능들은 RCU read-side 크리티컬 섹션에서 사용될 수 있을 겁니다. □

Quick Quiz D.58:

`__rcu_advance_callbacks()` 의 line 38-43 은 line 7-37 이 수행되지 않음에도 수행될 수가 있다는 거죠? 둘 다 카운터 뒤집기 직후에 수행되는데, 다른 시간이 아니지 않아요? ■

Answer:

다음과 같은 이벤트들을 생각해 보세요:

1. CPU 0 가 `rcu_try_flip_idle()` 의 line 5-12 를 수행합니다.
2. CPU 1 이 `__rcu_advance_callbacks()` 를 수행합니다. `rcu_ctrlblk.completed` 는 값이 증가되었으므로, line 7-37 이 수행됩니다. 하지만, `rcu_flip_flag` 변수들 중 어느것도 값이 설정되지 않았으므로, line 38-43 은 수행되지 않습니다.
3. CPU 0 가 `rcu_try_flip_idle()` 의 line 13-15 를 수행합니다.
4. 후에, CPU 1 이 다시 `__rcu_advance_callbacks()` 를 수행합니다. 카운터는 이제 마지막 수행 이후로 값이 증가했습니다만, `rcu_flip_flag` 변수들은 모두 설정되어있으므로, line 38-43 만이 수행됩니다. □

Quick Quiz D.59:

`rcu_read_unlock()` 의 `ACCESS_ONCE()` 가 컴파일러에 의해 재배치 된다면 어떤 문제가 발생할 수 있나요? ■

Answer:

1. `rcu_flipctr_idx` 를 읽어오는 코드 (line 14) 에 `ACCESS_ONCE()` 가 없어진다면, 컴파일러는 `idx` 를 제거할 수 있습니다. 또한 `rcu_flipctr` 의 값 감소를 읽어오고-감소시키고-저장하기로 컴파일 할 수 있어서, 이 읽어오기와 저장하기에 그때마다 각각 `rcu_flipctr_idx` 를 읽어올 수 있습니다. 만약 이 읽어오기와 저장하기 사이에 NMI 가 발생한다면, 그리고 해당 NMI 핸들러가 `rcu_read_lock()` 을 포함하고 있다면, `rcu_flipctr_idx` 의 값은 중간에 바뀌어 버릴 것이고, `rcu_flipctr` 값이 잘못되어버려서, 정확히 grace period 를 파악하는 능력을 파괴해 버릴 겁니다.
2. Line 14 에서 `ACCESS_ONCE()` 가 없어질 경우 생길 수 있는 또 다른 문제는 컴파일러가 이 코드를 `rcu_read_lock_nesting` 의 값 감소 (line 16) 뒤로 재배치 할 수 있기 때문에 발생합니다. 이 경우, 이 두 코드 사이에 NMI 가 발생한다면, 해당 NMI 핸들러 내에서의 `rcu_read_lock()` 은 `rcu_flipctr_idx` 의 값을 망쳐버릴 수 있어서, 잘못된 `rcu_flipctr` 가 감소될 수 있게 할 수 있습니다. `rcu_read_lock()` 에서의 비슷한 상황에서처럼, 이는 너무 빠른 grace-period 종료, 무한한 grace period, 또는 둘 다를 일으킬 수 있습니다.

3. `rcu_read_lock_nesting` 의 업데이트가 컴파일러에 의해 `rcu_flipctr` 의 값 감소와 바뀔 수 있게 `ACCESS_ONCE()` 매크로가 없다면, 그리고 그 사이에 NMI 가 발생한다면, 해당 NMI 핸들러 내에서의 `rcu_read_lock()` 은 옳지 못하게도 자신이 `rcu_read_lock()` 에 의해 보호되고 있다고 착각하고, `rcu_flipctr` 변수의 값을 증가시키게 될겁니다.

`rcu_read_lock_nesting` 을 읽어오는 코드 (line 7) 에서도 `ACCESS_ONCE()` 가 필요한지에 대해서는 명확치 않습니다. □

Quick Quiz D.60:

`rcu_read_unlock()` 내의 `ACCESS_ONCE()` 를 포함한 코드가 CPU 에 의해 재배치 되면 어떤 문제가 일어날 수 있을까요? ■

Answer:

전혀 없어요! `rcu_read_unlock()` 의 코드는 같은 CPU 에서 돌아가는 scheduling-clock 인터럽트 핸들러와 상호 동작하며, 따라서 재배치에 문제가 없는데 이는 CPU 들은 스스로의 액세스에 대해서만큼은 프로그램 순서대로 보게 되기 때문입니다. 다른 CPU 들은 `rcu_flipctr` 에 액세스 하긴 합니다만, 이 다른 CPU 들은 다른 변수들에는 접근하지 않기 때문에, 순서는 상관없습니다. □

Quick Quiz D.61:

Irq 들이 비활성화 되어 있지 않다면 `rcu_read_unlock()` 에 어떤 문제가 있을 수 있나요? ■

Answer:

1. Irq 들을 비활성화 하는 것은 `preemption` 을 비활성화 시키는 추가 효과를 일으킵니다. 이 코드가 line 17 의 중간에서 현재 CPU 의 `rcu_flipctr` 배열의 복사본을 고르는 부분과 `rcu_flipctr_idx` 로 가리켜지는 원소의 값의 감소 사이에서 `preemption` 당한다고 생각해 보세요. 프로그램 수행은 어떤 다른 CPU 위에서 재개될 수 있겠습니다. 만약 이 수행 재개가 원래 CPU 에서 수행되는 `rcu_read_lock()` 또는 `rcu_read_unlock()` 과 동시에으로 일어났다면, 하나의 값 증가나 값 감소가 사라져 버리게 되어서 너무 빠른 grace period 의 종료, 무기한적인 grace period 의 연장, 또는 심지어 둘 다 일어날 수가 있습니다.

2. Preemption 을 비활성화 시키는데 실패한다면 어떤 task 의 우선순위를 높일지 정하는데 `rcu_read_lock_nesting` 에 의존하는 RCU priority boosting 에도 영향을 끼칠 수 있습니다. 만약 `rcu_read_lock_nesting` 의 업데이트 (line 16) 와 `rcu_flipctr` 의 업데이트 (line 17) 사이에서 preemption 이 일어난다면, grace period 는 이 task 가 재개되기 전까지 멈출 겁니다. 하지만 이 RCU priority booster 는 이 특정 task 가 grace period 를 멈추고 있단 걸 알 수가 없으므로, 필요한 boosting 은 일어날 수가 없습니다. 따라서, 만약 CPU-bound realtime task 들이 돌아가고 있다면, 이 preemption 당한 task 는 결코 수행 재개되지 않을 것이어서 grace period 를 무한하게 멈춰있게 하고 결국은 OOM 을 초래할 겁니다.

물론, 이런 상황들 모두 irq 를 비활성화 하기보다는 preemption 을 비활성화 시키는 것으로 해결할 수 있습니다. (제가 사용한 CPU 들은 두 방법 사이에서 큰 차이를 보이지 않았습니다만, 다른 것들은 다를지도 모르지요.) □

Quick Quiz D.62:

`rcu_read_lock()` 의 irq 비활성화가 preemption 비활성화로 대체되었다고 생각해 봅시다. GP_STAGES 에 어떤 영향이 있을 수 있을까요? ■

Answer:

GP_STAGES 의 어떤 유한한 값도 충분치 않습니다. Oleg Nesterov 에 감사건대, 다음의 시나리오가 이를 보입니다:

낮은 우선순위의 Task A 가 CPU 0 에서 `rcu_read_lock()` 을 수행했고, 따라서 `per_cpu(rcu_flipctr, 0)[0]` 의 값을 증가시켜서, 이제 값이 1이 된다고 생각해 봅시다. 더 나아가서 Task A 가 이제 무한정 preemption 당한다고 생각해 봅시다.

이 상황에서 다음의 이벤트들이 발생한다고 생각해 봅시다:

1. Task B 가 역시 CPU 0 에서 `rcu_read_lock()` 을 수행하기 시작해서, 여전히 0의 값을 갖는 `rcu_ctrlblk.completed` 의 낮은 쪽 bit 을 가져옵니다.
2. Task B 가 현재의 grace-period stage 가 완료되기 에 충분한, 또한 RCU grace-period state machine 이 `rcu_ctrlblk.complete` 카운터가 진행되기에 충분한 수의 scheduling-clock 인터럽트들에 인터럽트 당해서 그 바닥 bit 이 이제 1의 값이 되고 모든 CPU 들이 이 값 증가 오퍼레이션을 확인합니다.

3. CPU 1 이 `index==0` 카운터들의 값의 합을 계산하기를 시작하는데 이제 Task A 의 값 증가에 의해 1 의 값을 갖는 `per_cpu(rcu_flipctr, 0)[0]` 부터 시작합니다. 따라서 CPU 1 의 지역 변수 `sum` 은 1이 됩니다.
4. Task B 가 인터럽트로부터 돌아와서 `rcu_read_lock()` 수행을 재개하고, `per_cpu(rcu_flipctr, 0)[0]` 의 값을 증가해서 그 값은 이제 2가 됩니다.
5. Task B 가 CPU 2 로 옮겨집니다.
6. Task B 가 RCU read-side 크리티컬 섹션 수행을 완료하고, `rcu_read_unlock()` 을 수행하는데, 이는 `per_cpu(rcu_flipctr, 2)[0]` 의 값을 감소시켜서 그 값은 이제 -1이 됩니다.
7. CPU 1 은 이제 `per_cpu(rcu_flipctr, 1)[0]` 의 값과 `per_cpu(rcu_flipctr, 2)[0]` 의 값을 자신의 로컬 변수 `sum` 에 더해서 값 0을 얻습니다.
8. CPU 1 은 이제 잘못되게도 모든 앞의 RCU read-side 크리티컬 섹션들이 완료되었다는 결론을 내리고, 다음 RCU grace-period stage 로 넘어가게 됩니다. 이는 어떤 다른 task 가 Task A 가 아직도 사용중인 데이터를 메모리 해제시켜버릴 수 있다는 의미입니다!

이 이벤트들은 무한정 반복될 수 있어서, 어떤 유한한 값의 GP_STAGES 로 Task A 를 망쳐버리는 걸 막을 수 없습니다. 이 이벤트들은 `rcu_ctrlblk.completed` 의 값 증가를 확인하는 CPU 들에 의해 만들어지는 약속의 중요성을 잘 보입니다.

따라서, `rcu_read_lock()` 이 irq 비활성화 없이 있을 수 있기 위해서는 grace-period state 로의 더 많은 변화가 필요합니다. □

Quick Quiz D.63:

왜 `rcu_dereference()` 가 메모리 배리어를 앞설 수 없나요? ■

Answer:

해당 메모리 배리어는 인터럽트 핸들러 안에서 수행되고, 인터럽트들은 PC 의 하나의 값만큼 정확하기에 인터럽트는 정확히 코드의 한 순간에서 발생하기 때문입니다. 따라서, 만약 `rcu_dereference()` 가 해당 메모리 배리어를 앞선다면, 해당 인터럽트는 `rcu_dereference()` 뒤에 발생했을 것이고, 따라서 이 인터럽트는 또한 이 RCU read-side 크리티컬 섹션을 시작한 `rcu_read_lock()` 뒤에 발생했을 것입니다. 이는 `rcu_read_lock()` 이 grace-period 카운터의 이전 값을

사용하도록 할 수 있는데, 이는 결국 연관된 `rcu_read_unlock()` 이 두번째가 아니라 첫번째 “기준 카운터들이 0 [0]” 이벤트를 앞설 수도 있음을 의미합니다. 이는 결국 read-side 크리티컬 섹션이 훨씬 짧았을 것을—이 방법의 핵심은 가장 긴 RCU read-side 크리티컬 섹션을 판별해 내고자 했던 것이란 점에서 생산적이지 않았을 것을 의미하게 됩니다. □

Quick Quiz D.64:

‘CPU 0 는 CPU 1 의 값 증가를 CPU 1 의 앞선 마지막 메모리 배리어 만큼 빠른 시점에 볼 수도 있다’ 를 더 정확히 말하려면 어떻게 말해야 할까요? ■

Answer:

첫째로, 부정확한 말의 문제는 그게 적어도 대중적인 마이크로프로세서들에서는 실제로는 존재하지 않는, 하나의 전역적인 시간대가 존재하는 것 같은 인상을 준다는 것임을 알아두는게 중요합니다. 둘째로, 메모리 배리어들은 인지의 순서에 대한 것이지, 시간에 대한 것이 아니라는 것을 알아두는게 중요합니다. 마지막으로, 앞의 말을 더 정확히 하려면 다음과 같을 겁니다: “만약 CPU 0 가 CPU 1 의 값 증가로 만들어지는 값을 로드한다면, CPU 0 의 모든 이를 뒤따르는 로드 오퍼레이션은 CPU 1 의 연관된 스토어 오퍼레이션들이 CPU 1 의 앞의 마지막 메모리 배리어를 앞섰다면 해당 스토어 오퍼레이션들로 인한 값들을 읽게 됩니다.”

이 더 정확한 버전도 좀 움찔거리는 공간을 남겨두고 있습니다. “뒤따르는” 이란 단어는 명시적인 메모리배리어나 해당 CPU 의 메모리 순서규칙에 의해 “뒤로 순서지어진” 이라는 의미가 되어야만 합니다. 또한, 메모리 배리어들은 연관된 오퍼레이션들을 순서짓기 충분할 만큼 강력해야만 합니다. 예를 들어, CPU 1 의 기준의 마지막 메모리 배리어는 스토어 오퍼레이션들을 순서지어야 합니다 (예를 들어, `smp_wmb()` 나 `smp_mb()` 여야 합니다). 비슷하게, 만약 CPU 0 가 자신의 마지막 로드가 CPU 1 의 값 증가를 본 로드를 뒤따른다는 걸 보장하기 위해 명시적 메모리 배리어가 필요하다면, 이 메모리 배리어는 `smp_rmb()` 이거나 `smp_mb()` 여야 합니다.

일반적으로, 병렬 알고리즘을 제공할 때 상당한 신경을 써야 합니다. □

Dictionaries are inherently circular in nature.

*“Self Reference in word definitions”,
David Levary et al.*

Appendix H

Glossary and Bibliography

Associativity: 캐시가 동시에 쥐고 있을 수 있는, 해당 캐시 내에서 동일하게 해시되는 캐시라인들의 갯수. 각각의 해시 값 별로 네개의 캐시 라인을 들고 있을 수 있는 캐시는 “four-way set-associative” 캐시라 명칭되며, 각각의 해시 값 별로 한개의 캐시 라인만을 들고 있을 수 있는 캐시는 “direct-mapped” 캐시라고 불리워집니다. Associativity 가 그 용량과 동일한 캐시는 “fully associative” 캐시라 불리워집니다. Fully associative 캐시는 associativity 미스를 제거할 수 있는 장점이 있습니다만, 하드웨어적 한계 때문에, fully associative 캐시는 일반적으로 크기가 제한됩니다. 최신 마이크로프로세서에 장착되는 커다란 캐시의 associativity 는 일반적으로 two-way에서 eight-way 사이입니다.

Associativity Miss: 연관된 CPU 가 최근에 캐시의 특정 set 이 담고 있을 수 있는 것보다 더 많은, 해당 set 으로 해시되는 데이터를 접근해서 발생하는 캐시 미스. Fully associative 캐시는 associativity 미스를 일으키지 않습니다 (또는, 동일하게, fully associative 캐시에서, associativity 와 capacity 미스는 동일하다고 말할 수 있겠습니다).

Atomic: 특정 오퍼레이션은 그 중간 상태를 관찰할 수 없도록 되어 있다면 “atomic” 하다고 여겨집니다. 예를 들어, 대부분의 CPU 에서, 올바르게 정렬된 포인터로의 store 는 어토믹한데, 다른 CPU 들은 기존 값 또는 새로운 값을 볼 수 있지만, 새로운 값의 일부와 기존 값의 일부가 결합된 값을 볼 수는 없도록 보장되기 때문입니다.

Cache: 근래의 컴퓨터 시스템들에서 CPU 는 빈번하게 사용되는 데이터를 담고 있을 캐시를 갖습니다. 이런 캐시는 매우 간단한 해시 함수를 사용하는 하드웨어로 구현된 해시 테이블로 생각될 수 있습니다만, 각각의 해시 bucket (하드웨어 타입에서는 “set”이라 명명됩니다) 은 제한된 수의 데이터 항목만을 담고 있을 수 있습니다. 각각의 캐시의 해시

bucket 이 담고 있을 수 있는 데이터 항목의 갯수는 해당 캐시의 “associativity” 라고 명칭됩니다. 이런 데이터 항목들은 일반적으로 “cache line” 이라 불리우는데, CPU 와 메모리 사이에 돌아다니는 고정된 길이의 데이터 블락이라고 생각될 수 있습니다.

Cache Coherence: 모든 CPU 들이 특정 변수에 대해 일련의 변화되는 값을 보게 되는 대부분의 근래의 SMP 기계들의 속성은 적어도 해당 변수에 대해 하나의 전역적인 값 변화의 순서로 일관성을 갖는다는 겁니다. Cache coherence 또한 특정 변수에 대한 일련의 store 들의 마지막에는 모든 CPU 들이 그 변수의 마지막 값에 대해 동의를 할 것을 보장해 줍니다. Cache coherence 는 하나의 변수에 의해 얻어진 일련의 값들에 대해서만 적용됨을 알아두시기 바랍니다. 반면에, 메모리 일관성 모델은 여러개의 변수들에 대한 load 와 store 가 어떻게 일어난 것으로 보이게 되는지를 설명합니다. 더 자세한 내용을 위해선 Section 15.2.6 을 참고하세요.

Cache Coherence Protocol: 메모리 일관성과 순서를 강제하고 다른 CPU 들이 각자의 캐시에 담겨있는 데이터의 일관적이지 않은 상태를 보는 것을 막아주는, 일반적으로 하드웨어로 구현되는 통신 프로토콜.

Cache Geometry: 캐시의 크기와 associativity 는 그것의 geometry 라 불리웁니다. 각각의 캐시는 이차원 배열로, 캐시 라인들의 행 (“set”) 은 같은 해시 값을 갖고, 캐시 라인들의 열 (“ways”) 는 그 안의 모든 캐시 라인이 서로 다른 해시 값을 갖는 것으로 생각될 수 있습니다. 특정 캐시의 associativity 는 그 열의 수이고 (따라서 “way” 라 불립니다—two-way set-associative 캐시는 두개의 “way” 를 갖습니다), 캐시의 크기는 행의 수와 열의 수의 곱입니다.

Cache Line: (1) CPU 와 메모리 사이를 돌아다니는

데이터의 단위로, 일반적으로 그 크기는 2의 거듭 제곱입니다. 일반적인 캐시라인의 크기는 16 바이트에서 256 바이트 사이입니다.

(2) 데이터의 캐시라인 하나 단위를 담아둘 수 있는 CPU 캐시의 물리적 위치.

(3) 데이터의 캐시라인 하나 단위를 담아둘 수 있는, 그러나 또한 캐시 라인 경계로 정렬되어 있는 메모리 상의 물리적 위치. 예를 들어, 256-바이트 캐시 라인을 갖는 시스템에서 메모리 상의 캐시 라인의 첫번째 word 의 주소는 0x00 으로 끝날 겁니다.

Cache Miss: CPU 가 필요로 하는 데이터가 해당 CPU 의 캐시 안에 존재하지 않으면 하나의 캐시 미스가 발생합니다. 해당 데이터는 여러가지 이유로 캐시에 없을 수 있는데, 다음과 같은 이유들이 있을 수 있습니다: (1) 이 CPU 는 기존에 해당 데이터를 액세스한 적이 없거나("startup" 또는 "warmup" 미스), (2) 이 CPU 는 최근에 자신의 캐시가 담고 있을 수 있는 것보다 더 많은 데이터에 액세스를 해서, 오래된 데이터 중 일부는 제거되었거나 ("capacity" 미스), (3) 이 CPU 는 특정 set 에 해당 set¹ 이 담아둘 수 있는 것보다 많은 데이터에 액세스를 했거나 ("associativity" 미스), (4) 이 CPU 가 해당 데이터에 액세스한 후에 어떤 다른 CPU 가 해당 데이터에 (또는 같은 캐시 라인의 어떤 다른 데이터에) 쓰기를 수행해서 ("communication miss"), 또는 (5) 이 CPU 가 해당 캐시라인의 다른 CPU 의 캐시에 복사되어 있거나 해서 read-only 인데 쓰기를 수행 해서입니다.

Capacity Miss: 연관된 CPU 가 최근에 캐시가 담을 수 있는 것보다 많은 데이터를 액세스 해서 발생하는 캐시 미스.

Code Locking: 크리티컬 섹션의 한 집합을 보호하기 위해 "global lock" 이 사용되어서 특정 쓰레드의 그런 집합으로의 액세스가 그 쓰레드가 어떤 데이터에 접근하려 하는가에 의해서가 아니라 현재 그 크리티컬 섹션들의 집합을 차지하고 있는 쓰레드들의 집합에 기반해서만 허용되거나 거부되는 간단한 락킹 디자인. Code-locking 을 사용하는 프로그램의 확장성은 그 코드에 의해 제한됩니다; 해당 데이터 집합의 크기를 증가시키는 것은 일반적으로 확장성을 증가시키지 못할 겁니다(사실, 일반적으로는 "lock contention" 을 증가시켜서 확장성을 떨어뜨립니다). "Data locking" 에 대비됩니다.

Communication Miss: 이 CPU 가 해당 캐시라인에 액세스한 후에 어떤 다른 CPU 가 해당 캐시라인에

¹ 하드웨어 캐시 용어에서, "set" 이라는 말은 소프트웨어 캐시를 논할 때의 "bucket" 이란 말과 동일한 의미로 사용됩니다.

액세스해서 발생하는 캐시미스.

Critical Section: 어떤 동기화 메커니즘으로 보호되어서 그 수행이 그 기능으로 제한되는 코드의 부분. 예를 들어, 크리티컬 섹션들의 한 집합이 같은 global lock 으로 보호된다면, 한번에 그 크리티컬 섹션들 가운데 하나만이 수행됩니다. 만약 한 쓰레드가 그런 크리티컬 섹션 가운데 하나를 수행하고 있다면, 모든 다른 쓰레드는 그 첫번째 쓰레드가 해당 집합 내의 크리티컬 섹션들의 수행을 모두 완료하기 전까지는 대기해야만 합니다.

Data Locking: 각각의 데이터 구조 인스턴스가 각자의 락을 가지고 있는 확장성 있는 락킹 디자인. 각각의 쓰레드가 이 데이터 구조의 서로 다른 인스턴스를 사용한다면, 이 모든 쓰레드들은 동시에 크리티컬 섹션을 수행하고 있을 수 있습니다. 데이터 락킹은 증가하는 CPU 의 수와 증가하는 데이터 인스턴스의 갯수에 따라 자동적으로 확장되는 장점을 갖습니다. "Code locking" 과 대비됩니다.

Direct-Mapped Cache: 하나의 way 만을 가지고 있어서, 하나의 해시값마다 하나의 캐시라인만을 담고 있을 수 있는 캐시.

Embarrassingly Parallel: 쓰레드를 추가하는 것이 연산 과정의 전체적인 비용을 크게 증가시키지 않아서 (충분한 CPU 가 사용 가능한 상태라는 가정 하에) 쓰레드가 추가됨에 따라서 선형적으로 속도가 증가하게 되는 문제나 알고리즘.

Exclusive Lock: 한번에 하나의 쓰레드만이 해당 락이 보호하고 있는 크리티컬 섹션에 들어갈 수 있도록 하는 상호 배타적인 메커니즘.

False Sharing: 두개의 CPU 가 각각 한 쌍의 데이터 항목 중 하나씩에 빈번하게 쓰기를 하지만, 이 한쌍의 데이터 항목이 같은 캐시 라인에 위치해 있다면, 이 캐시 라인은 반복적으로 무효화되어서, 이 두 CPU 의 캐시들 사이를 "ping-pong" 하길 반복하게 됩니다. 이는 "cache bouncing" 이라고도 불리는 "cache thrashing" 현상의 혼한 원인입니다(리눅스 커뮤니티에서는 앞의 표현이 더 혼합니다). False sharing 은 성능과 확장성을 모두 크게 떨어뜨릴 수 있습니다.

Fragmentation: 많은 양의 사용되지 않은 메모리가 존재하지만 비교적 작은 메모리 할당 요청들을 충족해줄 수 있도록 맞춰져 있지 않은 메모리 풀을 단편화(fragment) 되었다고 합니다. 할당된 메모리 블록들 사이에 작은 조각의 메모리 공간이 존재하도록 메모리 공간이 조개졌을 때 external fragmentation

이 발생하며, 특정한 또는 특정한 종류의 메모리 할당 요청이 실제로 필요한 것보다 많은 메모리를 할당받았을 때 internal fragmentation 이 발생합니다.

Fully Associative Cache: Fully associative 캐시는 하나의 set 만을 가지고 있어서, 해당 set 은 그 용량이 허용하는한 메모리의 어떤 부분집합도 담고 있을 수 있습니다.

Grace Period: Grace period 는 어떤 시간 간격으로, 해당 시간 간격에 앞서 시작된 모든 RCU read-side 크리티컬 섹션은 이 시간 간격의 종료 전에 종료됩니다. 많은 RCU 구현들은 각각의 쓰레드가 최소 하나의 quiescent state 를 지나는 사이의 시간 간격으로 정의합니다. RCU read-side 크리티컬 섹션은 그 정의에 의해 quiescent state 를 포함할 수 없으므로, 이 두개의 정의는 거의 항상 서로 교체될 수 있습니다.

Heisenbug: 추적하기 위해 기록을 추가하거나 print 문을 추가하면 발견되지 않게 되는, 타이밍에 민감한 버그.

Hot Spot: 매우 많이 사용되어서 연관된 락에 대한 높은 수준의 contention 을 초래하는 데이터 구조. 이런 상황의 한 예로는 형편없는 해시 함수를 사용한 해시 테이블이 있을 수 있습니다.

Humiliatingly Parallel: 쓰레드를 추가하면 연산의 전체 비용이 상당히 줄어들어서 (충분한 CPU 가 사용 가능한 상태라는 가정 하에) 쓰레드를 추가함에 따라 선형적 속도증가를 초월하는 속도 증가를 초래하는 문제나 알고리즘.

Invalidation: 한 CPU 가 하나의 데이터 항목에 쓰기를 하려 하면, 해당 CPU 는 먼저 이 데이터 아이템이 다른 CPU 의 캐시에는 존재하지 않음을 보장해야 합니다. 만약 필요하다면, 쓰기를 하는 CPU 는 해당 데이터의 사본을 자신의 캐시에 담고 있는 모든 CPU 에게 “invalidation” 메세지를 보내서 다른 CPU 의 캐시로부터 해당 항목을 제거합니다.

IPI: 하나의 CPU 에서 다른 CPU 로 보내어지는 프로세서 간의 인터럽트. IPI 는 리눅스 커널에서 많이 사용되는데, 예를 들어 스케줄러가 CPU 에게 높은 우선순위 프로세스가 현재 수행 가능 상태임을 알리는데 사용됩니다.

IRQ: 인터럽트 요청 (Interrupt request) 으로, 리눅스 커널 커뮤니티에서는 “interrupt” 의 약자로 사용되어서, “irq handler” 와 같은 용례로 사용됩니다.

Linearizable: 일련의 오퍼레이션들은 모든 CPU 들 과 / 또는 쓰레드들의 관찰된 내용과 일관적인 전체적인 해당 오퍼레이션들의 순서가 존재한다면 “linearizable” 하다고 표현합니다. Linearizability 는 많은 연구자들에 의해 중요시됩니다만, 실용적인 면에서는 기대되는 것보다 유용하지 못합니다 [HKLP12].

Lock: 크리티컬 섹션을 보호하는데 사용될 수 있는 소프트웨어 추상화의 하나로, “상호 배타성 (mutual exclusion) 메커니즘” 의 한 예. “배타적 락” 은 한번에 하나의 쓰레드만이 해당 락으로 보호되는 크리티컬 섹션들의 집합에 들어갈 수 있도록 해주며, “reader-writer lock” 은 읽기를 하는 쓰레드라면 몇 개의 쓰레드든지, 쓰기를 하는 쓰레드라면 하나의 쓰레드만이 해당 락으로 보호되는 크리티컬 섹션들의 집합에 들어갈 수 있도록 해줍니다. (분명히 하자면, 주어진 reader-writer 락의 크리티컬 섹션들 가운데 하나라도 쓰기 쓰레드가 존재한다면, 어떤 읽기를 하는 쓰레드도 해당 락의 크리티컬 섹션들 가운데 하나도 들어갈 수 없을 것이고, 그 반대도 마찬가지입니다.)

Lock Contention: 락은 매우 많이 사용되어 해당 락을 얻으려 기다리는 CPU 가 많은 경우 contention 을 겪는다고 표현됩니다. 병렬 알고리즘을 설계하고 병렬 프로그램을 구현할 때에 Lock contention 을 줄이는 것이 많은 경우 중요한 고심거리입니다.

Memory Consistency: 변수들의 그룹에 대한 액세스들의 순서가 어떻게 일어난 것을 보여야만 하는가에 대한 제약을 만들어내는 속성들의 집합. 메모리 일관성 모델은 학계에서 인기있으며 매우 강력한 모델인 sequential consistency 부터 process consistency, release consistency, 그리고 weak consistency 까지 다양합니다.

MESI Protocol: Modified, exclusive, shared, 그리고 invalid (MESI) 상태를 갖는 캐시 일관성 프로토콜로, 이 때문에 이 프로토콜은 해당 캐시의 캐시라인이 가질 수 있는 상태들의 이름을 본따서 그렇게 이름 지어졌습니다. Modified 상태의 캐시라인은 최근에 이 CPU 에 의해 쓰기가 되어진 상태로, 연관된 메모리 영역의 현재 값의 유일한 표현입니다. Exclusive 상태의 캐시 라인은 값이 새로 씌여지지는 않았지만, 해당 캐시라인은 다른 CPU 의 캐시에 복사되지 않았음이 보장되기에 이 CPU 가 언제든 그 위에 쓰기를 할 권리를 가진 상태입니다 (메인 메모리 상의 연관된 영역은 최신 버전이지만 말입니다). Shared 상태의 캐시라인은 어떤 다른 CPU 의 캐시에 복사되어 있는 (또는 복사되어 있을 수

있는) 상태로, 이 CPU 는 이 캐시 라인에 쓰기를 하기 전에 그런 다른 CPU 들과 상호작용을 해야만 함을 의미합니다. Invalid 상태의 캐시라인은 값을 포함하고 있지 않아서, 메모리로부터 데이터가 로드되어질 수 있는 상태인 해당 캐시의 “빈 공간”을 나타냅니다.

Mutual-Exclusion Mechanism: 쓰레드의 “크리티컬 섹션”과 연관된 데이터로의 액세스를 조절하는 소프트웨어 추상화.

NMI: Non-maskable interrupt. 이름이 이야기하듯, 이는 가려질 수 없는, 매우 높은 우선순위의 인터럽트입니다. 이것들은 프로파일링과 같은 하드웨어의 특수한 목적에 사용됩니다. 프로파일링을 하는 데에 NMI 를 사용함으로써 얻을 수 있는 이득은, 인터럽트를 비활성화 시킨 채 수행되는 코드에 대해서도 프로파일링을 할 수 있다는 것입니다.

NUCA: CPU 들의 그룹들이 캐시 그리고/또는 스토어 버퍼를 공유하는, Non-uniform cache architecture. 따라서 한 그룹 내의 CPU 들은 다른 그룹 내의 CPU 들과 할 수 있는 것에 비해 같은 그룹 내의 CPU 들과 캐시라인을 더 빠르게 교환할 수 있습니다. 하드웨어 쓰레드를 갖는 CPU 로 구성된 시스템에서는 일반적으로 NUCA 아키텍쳐를 갖게 됩니다.

NUMA: 메모리가 뱅크 단위로 쪼개어져 있고 각각의 뱅크는 “NUMA node” 라 불리우는, 특정 CPU 들의 그룹에 “가까운” 구조인 Non-uniform memory architecture. NUMA 기계의 한 예는 Sequent 의 NUMA-Q 시스템으로, 네개의 CPU 들로 구성된 각각의 그룹들이 하나씩 메모리 뱅크를 근처에 두고 있습니다. 특정 그룹 내의 CPU 들은 그들의 메모리에 다른 그룹의 메모리보다 훨씬 빨리 액세스 할 수 있습니다.

NUMA Node: 커다란 NUMA 기계 내에서의 가까이 위치한 CPU 들과 거기 연관된 메모리의 그룹. 하나의 NUMA 노드는 NUMA 구조를 가질 수도 있음을 알아 두시기 바랍니다.

Pipelined CPU: 많은 장점과 단점을 가지고 있는, 어떤 의미에선 조립 공정 라인과 비슷한, CPU 내부의 인스트럭션들의 내부 흐름인 pipeline 을 가진 CPU. 1960년대부터 1980년대 초까지, pipeline 을 내장한 CPU 는 슈퍼컴퓨터의 영역에만 있었습니다만, 1980년대 후반부터는 (80486 과 같은) 마이크로프로세서에서도 나타나기 시작했습니다.

Process Consistency: 각각의 CPU 가 자신의 스토어 오퍼레이션은 program order 대로 발생한 것으로

보이지만 다른 CPU 들은 복수의 CPU 들로부터의 액세스를 다른 순서로 발생한 것으로 볼 수 있는 메모리 일관성 모델.

Program Order: 특정 쓰레드의 인스트럭션들이 지금에 와서는 미신적 존재가 되어버린, 다음 인스트럭션의 수행이 진행되기 전에 현재 인스트럭션을 완전히 수행하는, “in-order” CPU 에 의해 수행되는 순서. (그런 CPU 들이 이제는 고대의 미신과 전설상의 존재로만 남게된 것은 그것들은 엄청나게 느리기 때문입니다. 이 고대의 공룡들은 Moore’s-Law 가 가져온 CPU 클럭 주파수 향상의 많은 희생자들 가운데 하나입니다. 어떤 사람들은 이 야수들이 지구를 다시 한번 더 정복할 것이라고 이야기하지만, 그 외의 사람들은 그런 말을 아예 무시합니다.)

Quiescent State: RCU 에서, RCU 로 보호되는 데이터 구조로의 레퍼런스가 하나도 잡혀 있지 않은, 일반적으로는 RCU read-side 크리티컬 섹션의 바깥의 모든 지점. 모든 쓰레드가 최소한 하나의 quiescent state 를 지나는 동안의 모든 시간 간격은 “grace period” 라고 불리워집니다.

Read-Copy Update (RCU): Reader-writer 락킹이나 reference counting 의 대체물로 생각될 수 있는 하나의 동기화 메커니즘. RCU 는 읽기 쓰레드들에게 매우 낮은 오버헤드의 액세스를 제공하는 반면, 쓰기 쓰레드에게는 앞서 존재한 읽기 쓰레드들의 성능 이득을 위해 기존 버전을 유지해야하는 추가적 오버헤드를 일으킵니다. 읽기 쓰레드들은 블락되지도 spin 하지도 않고, 따라서 데드락에 참여될 수 없습니다만, 정상적인 데이터를 볼 수 있고 업데이트와 동시에 수행될 수 있습니다. 따라서 RCU 는 정상적인 데이터가 (라우팅 테이블에서처럼) 지연되거나 (리눅스 커널의 System V IPC 구현에서처럼) 막아질 수 있는 읽기가 대부분인 환경에 가장 적합합니다.

Read-Side Critical Section: 어떤 reader-writer 동기화 메커니즘의 읽기 권한 획득으로 보호되는 코드의 일부분. 예를 들어, 한 크리티컬 섹션들의 집합이 특정 전역적 reader-writer 락의 읽기 권한 획득으로 보호된다면, 크리티컬 섹션들의 첫번째 집합은 그 락의 read-side 크리티컬 섹션이 됩니다. 수에 상관없이 복수의 쓰레드들이 read-side 크리티컬 섹션을 동시에 수행할 수 있습니다만, 어떤 쓰레드도 write-side 크리티컬 섹션을 수행하고 있지 않은 경우에만 그렇습니다.

Reader-Writer Lock: Reader-writer 락은 수에 관계없이 복수의 읽기를 하는 쓰레드들을, 또는 단 하나

의 쓰기 쓰레드들을 해당 락으로 보호되는 크리티컬 섹션들의 집합으로 들어갈 수 있도록 하용하는 mutual-exclusion 메커니즘입니다. 쓰기를 하려는 쓰레드는 모든 앞서 존재한, 읽기를 하는 쓰레드들이 해당 락을 놓을 때까지 기다려야만 하고, 비슷하게, 앞서 존재한 쓰기가 존재한다면, 쓰기를 하려는 모든 쓰레드는 해당 쓰기 쓰레드가 해당 락을 놓기를 기다려야 합니다. Reader-writer 락에 있어서의 핵심 고려사항은 “fairness”입니다: 끝나지 않는 읽기 쓰레드의 연속은 쓰기 쓰레드를 starve 시킬 수 있고, 그 반대로 마찬가지입니다.

Sequential Consistency: 모든 메모리 레퍼런스가 하나의 전역적인 순서에 일관적인 순서로 일어난 것으로 보이도록, 그리고 각각의 CPU의 메모리 레퍼런스가 모든 CPU들에게 프로그램 순서로 일어난 것으로 보이도록 하는 메모리 일관성 모델.

Store Buffer: CPU에서 지연된 쓰기를 기록하며 그사이 연관된 캐시라인들은 해당 CPU에서 사용할 수 있도록 사용되는 CPU 내부의 레지스터들의 작은 집합. “Store queue”라고도 불립니다.

Store Forwarding: 소프트웨어에게 CPU가 메모리 오퍼레이션들을 program order대로 진행한 것으로 보일 것을 보장하기 위해 CPU가 스托어 버퍼와 캐시 사이를 오가도록 하는 하나의 조정.

Super-Scalar CPU: 하나의 scalar (non-vector) CPU는 여러개의 인스트럭션들을 동시에 수행할 수 있습니다. 이는 여러개의 인스트럭션들을 조립 공정의 방식으로 수행하는 pipelined CPU의 진화된 형태입니다—super-scalar CPU에서는, 각각의 pipeline의 stage가 하나의 인스트럭션 이상을 처리할 수 있게 됩니다. 예를 들어, 만약 조건이 정확히 맞아 떨어진다면, 1990년대 중반에 나온 Intel Pentium Pro CPU는 하나의 클락 사이클당 두개의 (그리고 어떤 경우엔 세개의) 인스트럭션들을 처리할 수 있습니다. 따라서, 200MHz Pentium Pro CPU는 초당 최대 4억개의 인스트럭션을 수행 완료하거나 “retire” 시킬 수도 있습니다.

Teachable: 교사가 완전히 이해할 수 있고, 따라서 가리키기 간편한 주제, 컨셉, 방법, 또는 메커니즘.

Transactional Memory (TM): 오퍼레이션들의 어토믹한 시퀀스이며 atomicity, consistency, isolation을 제공하지만 durability를 제공하지 않는다는 점에서 고전적인 트랜잭션과는 다른 “트랜잭션”을 지원하는 공유메모리 동기화 설계. 트랜잭션 메모리는 하드웨어로 구현 (하드웨어 트랜잭션 메모리 또는 HTM이라 불림) 되거나, 소프트웨어로

구현 (소프트웨어 트랜잭션 메모리 또는 STM이라 불림) 되거나, 또는 하드웨어와 소프트웨어의 조합으로 구현 (“unbounded” 트랜잭션 메모리, 또는 UTM이라 불림) 될 수 있습니다.

Unteachable: 교사가 잘 이해하지 못하고 있고, 따라서 가르치기가 어려운 주제, 컨셉, 방법, 또는 메커니즘.

Vector CPU: 하나의 인스트럭션을 여러개의 데이터 항목에 동시적으로 적용시킬 수 있는 CPU. 1960년대부터 1980년대까지는 슈퍼컴퓨터들만이 vector 기능을 가지고 있었지만, x86 CPU들의 MMX와 PowerPC CPU들의 VMX의 발전은 벡터 처리를 대중들에게 가져다 주었습니다.

Write Miss: 캐시 라인이 다른 CPU의 캐시에 복사되어 있거나 하는 이유로 read-only 상태인 캐시라인에 CPU가 쓰기를 시도했기 때문에 발생하는 캐시 미스.

Write-Side Critical Section: 어떤 reader-writer 동기화 메커니즘의 읽기 권한 획득으로 보호되는 코드의 부분. 예를 들어, 한 크리티컬 섹션들의 집합이 특정 global reader-writer 락의 쓰기 권한 획득으로 보호되어 있고 두번째 크리티컬 섹션 집합은 같은 reader-writer 락의 읽기 권한 획득으로 보호되어 있다면, 첫번째 크리티컬 섹션 집합은 해당 락의 write-side 크리티컬 섹션이 됩니다. 한번에 하나의 쓰레드만이 write-side 크리티컬 섹션을 수행할 수 있으며, 이 때 어떤 쓰레드도 동시에 연관된 read-side 크리티컬 섹션들을 수행하고 있지 않아야 합니다.

Bibliography

- [AA14] Maya Arbel and Hagit Attiya. Concurrent updates with RCU: Search tree as an example. In *Proceedings of the 2014 ACM Symposium on Principles of Distributed Computing*, PODC '14, pages ???–???, Paris, France, 2014. ACM.
- [AAKL06] C. Scott Ananian, Krste Asanovic, Bradley C. Kuszmaul, and Charles E. Leiserson. Unbounded transactional memory. *IEEE Micro*, pages 59–69, January–February 2006. Available: <http://www.cag.csail.mit.edu/scale/papers/utm-ieeemicro2006.pdf> [Viewed December 21, 2006].
- [AB13] Samy Al Bahra. Nonblocking algorithms and scalable multicore programming. *Commun. ACM*, 56(7):50–61, July 2013.
- [ABD⁺97] Jennifer M. Anderson, Lance M. Berc, Jeffrey Dean, Sanjay Ghemawat, Monika R. Henzinger, Shun-Tak A. Leung, Richard L. Sites, Mark T. Vandervoorde, Carl A. Waldspurger, and William E. Weihl. Continuous profiling: Where have all the cycles gone? In *Proceedings of the 16th ACM Symposium on Operating Systems Principles*, pages 1–14, New York, NY, October 1997.
- [ACHS13] Dan Alistarh, Keren Censor-Hillel, and Nir Shavit. Are lock-free concurrent algorithms practically wait-free?, December 2013. ArXiv:1311.3200v2.
- [ACMS03] Andrea Arcangeli, Mingming Cao, Paul E. McKenney, and Dipankar Sarma. Using read-copy update techniques for System V IPC in the Linux 2.5 kernel. In *Proceedings of the 2003 USENIX Annual Technical Conference (FREENIX Track)*, pages 297–310, San Antonio, Texas, USA, June 2003. USENIX Association.
- [Ada11] Andrew Adamatzky. Slime mould solves maze in one pass . . . assisted by gradient of chemo-attractants, August 2011. <http://arxiv.org/abs/1108.4956>.
- [Adv02] Advanced Micro Devices. *AMD x86-64 Architecture Programmer’s Manual Volumes 1-5*, 2002.
- [AGH⁺11a] Hagit Attiya, Rachid Guerraoui, Danny Hendler, Petr Kuznetsov, Maged M. Michael, and Martin Vechev. Laws of order: Expensive synchronization in concurrent algorithms cannot be eliminated. In *38th ACM SIGACT-SIGPLAN Symposium on Principles of Programming Languages*, pages 487–498, Austin, TX, USA, 2011. ACM.
- [AGH⁺11b] Hagit Attiya, Rachid Guerraoui, Danny Hendler, Petr Kuznetsov, Maged M. Michael, and Martin Vechev. Laws of order: Expensive synchronization in concurrent algorithms cannot be eliminated. *SIGPLAN Not.*, 46(1):487–498, January 2011.

- [AHS⁰³] J. Appavoo, K. Hui, C. A. N. Soules, R. W. Wisniewski, D. M. Da Silva, O. Krieger, M. A. Auslander, D. J. Edelsohn, B. Gamsa, G. R. Ganger, P. McKenney, M. Ostrowski, B. Rosenburg, M. Stumm, and J. Xenidis. Enabling autonomic behavior in systems software with hot swapping. *IBM Systems Journal*, 42(1):60–76, January 2003.
- [AKNT13] Jade Alglave, Daniel Kroening, Vincent Nimal, and Michael Tautschig. Software verification for weak memory via program transformation. In *Proceedings of the 22nd European conference on Programming Languages and Systems*, ESOP’13, pages 512–532, Rome, Italy, 2013. Springer-Verlag.
- [AKT13] Jade Alglave, Daniel Kroening, and Michael Tautschig. Partial orders for efficient Bounded Model Checking of concurrent software. In *Computer Aided Verification (CAV)*, volume 8044 of *LNCS*, pages 141–157. Springer, 2013.
- [Ale79] Christopher Alexander. *The Timeless Way of Building*. Oxford University Press, New York, 1979.
- [Alg13] Jade Alglave. Weakness is a virtue. In *(EC)² 2013: 6th International Workshop on Exploiting Concurrency Efficiently and Correctly*, page 3, 2013.
- [AM15] Maya Arbel and Adam Morrison. Predicate RCU: An RCU for scalable concurrent updates. *SIGPLAN Not.*, 50(8):21–30, January 2015.
- [Amd67] Gene Amdahl. Validity of the single processor approach to achieving large-scale computing capabilities. In *AFIPS Conference Proceedings*, pages 483–485, Washington, DC, USA, 1967. IEEE Computer Society.
- [AMD17] AMD. OpenCL™ zone—accelerate your applications, January 2017. <http://developer.amd.com/tools-and-sdks/opencl-zone/>.
- [AMM^{17a}] Jade Alglave, Luc Maranget, Paul E. McKenney, Andrea Parri, and Alan Stern. A formal kernel memory-ordering model (part 1), April 2017. <https://lwn.net/Articles/718628/>.
- [AMM^{17b}] Jade Alglave, Luc Maranget, Paul E. McKenney, Andrea Parri, and Alan Stern. A formal kernel memory-ordering model (part 2), April 2017. <https://lwn.net/Articles/720550/>.
- [AMM¹⁸] Jade Alglave, Luc Maranget, Paul E. McKenney, Andrea Parri, and Alan Stern. Frightening small children and disconcerting grown-ups: Concurrency in the Linux kernel. In *Proceedings of the Twenty-Third International Conference on Architectural Support for Programming Languages and Operating Systems*, ASPLOS ’18, pages 405–418, Williamsburg, VA, USA, 2018. ACM.
- [AMP¹¹] Jade Alglave, Luc Maranget, Pankaj Pawan, Susmit Sarkar, Peter Sewell, Derek Williams, and Francesco Zappa Nardelli. PPCMEM/ARMMEM: A tool for exploring the POWER and ARM memory models, June 2011. <http://www.c1.cam.ac.uk/~pes20/ppc-supplemental/pldi105-sarkar.pdf>.
- [AMT14] Jade Alglave, Luc Maranget, and Michael Tautschig. Herding cats: Modelling, simulation, testing, and data-mining for weak memory. In *Proceedings of the 35th ACM SIGPLAN Conference on Programming Language Design and Implementation*, PLDI ’14, pages 40–40, Edinburgh, United Kingdom, 2014. ACM.
- [And90] T. E. Anderson. The performance of spin lock alternatives for shared-memory multiprocessors. *IEEE Transactions on Parallel and Distributed Systems*, 1(1):6–16, January 1990.

- [And91] Gregory R. Andrews. *Concurrent Programming, Principles, and Practices*. Benjamin Cummins, 1991.
- [ARM10] ARM Limited. *ARM Architecture Reference Manual: ARMv7-A and ARMv7-R Edition*, 2010.
- [ARM17] ARM Limited. *ARM Architecture Reference Manual (ARMv8, for ARMv8-A architecture profile)*, 2017.
- [Ash15] Mike Ash. Concurrent memory deallocation in the objective-c runtime, May 2015. mikeash.com: just this guy, you know?
- [ATC⁺11] Ege Akpinar, Sasa Tomic, Adrian Cristal, Osman Unsal, and Mateo Valero. A comprehensive study of conflict resolution policies in hardware transactional memory. In *TRANSACT 2011*, New Orleans, LA, USA, June 2011. ACM SIGPLAN.
- [ATS09] Ali-Reza Adl-Tabatabai and Tatiana Shpeisman. Draft specification of transactional language constructs for c++, August 2009. URL: <https://software.intel.com/sites/default/files/ee/47/21569> (may need to append .pdf to view after download).
- [BA01] Jeff Bonwick and Jonathan Adams. Magazines and vmem: Extending the slab allocator to many CPUs and arbitrary resources. In *USENIX Annual Technical Conference, General Track 2001*, pages 15–33, 2001.
- [Bas18] JF Bastien. P1152R0: Deprecating volatile, October 2018. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2018/p1152r0.html>.
- [BC05] Daniel Bovet and Marco Cesati. *Understanding the Linux Kernel*. O'Reilly Media, Inc., third edition, 2005.
- [BD13] Paolo Bonzini and Mike Day. RCU implementation for Qemu, August 2013. <http://lists.gnu.org/archive/html/qemu-devel/2013-08/msg02055.html>.
- [BD14] Hans-J. Boehm and Brian Demsky. Outlawing ghosts: Avoiding out-of-thin-air results. In *Proceedings of the Workshop on Memory Systems Performance and Correctness*, MSPC '14, pages 7:1–7:6, Edinburgh, United Kingdom, 2014. ACM.
- [Bec10] Pete Becker. Working draft, standard for programming language C++, November 2010. Available: <http://open-std.org/jtc1/sc22/wg21/docs/papers/2010/n3225.pdf> [Viewed: March 4, 2011].
- [Bec11] Pete Becker. Working draft, standard for programming language C++, February 2011. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2011/n3242.pdf>.
- [BG87] D. Bertsekas and R. Gallager. *Data Networks*. Prentice-Hall, Inc., 1987.
- [BGV17] Hans-J. Boehm, Olivier Giroux, and Viktor Vafeiades. P0668r1: Revising the C++ memory model, July 2017. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2017/p0668r1.html>.
- [Bha14] Srivatsa S. Bhat. percpu_rwlock: Implement the core design of per-CPU reader-writer locks, February 2014. <https://patchwork.kernel.org/patch/2157401/>.
- [BHG87] Philip A. Bernstein, Vassos Hadzilacos, and Nathan Goodman. *Concurrency Control and Recovery in Database Systems*. Addison Wesley Publishing Company, 1987.

- [BHS07] Frank Buschmann, Kevlin Henney, and Douglas C. Schmidt. *Pattern-Oriented Software Architecture Volume 4: A Pattern Language for Distributed Computing*. Wiley, Chichester, West Sussex, England, 2007.
- [BJ12] Rex Black and Capers Jones. Economics of software quality: An interview with Capers Jones, part 1 of 2 (podcast transcript), January 2012. <http://www.informit.com/articles/article.aspx?p=1824791>.
- [BK85] Bob Beck and Bob Kasten. VLSI assist in building a multiprocessor UNIX system. In *USENIX Conference Proceedings*, pages 255–275, Portland, OR, June 1985. USENIX Association.
- [BLM05] C. Blundell, E. C. Lewis, and M. Martin. Deconstructing transactional semantics: The subtleties of atomicity. In *Annual Workshop on Duplicating, Deconstructing, and Debunking (WDDD)*, June 2005. Available: http://www.cis.upenn.edu/acg/papers/wddd05_atomic_semantics.pdf [Viewed June 4, 2009].
- [BLM06] C. Blundell, E. C. Lewis, and M. Martin. Subtleties of transactional memory and atomicity semantics. *Computer Architecture Letters*, 5(2), 2006. Available: http://www.cis.upenn.edu/acg/papers/cal06_atomic_semantics.pdf [Viewed June 4, 2009].
- [BMMM05] Luke Browning, Thomas Mathews, Paul E. McKenney, and James Moody. Apparatus, method, and computer program product for converting simple locks in a multiprocessor system. US Patent 6,842,809, US Patent and Trademark Office, Washington, DC, January 2005.
- [BMN⁺15] Mark Batty, Kayvan Memarian, Kyndylan Nienhuis, Jean Pichon-Pharabod, and Peter Sewell. The problem of programming language concurrency semantics. In Jan Vitek, editor, *Programming Languages and Systems*, volume 9032 of *Lecture Notes in Computer Science*, pages 283–307. Springer Berlin Heidelberg, 2015.
- [BMP08] R. F. Berry, P. E. McKenney, and F. N. Parr. Responsive systems: An introduction. *IBM Systems Journal*, 47(2):197–206, April 2008.
- [Boe05] Hans-J. Boehm. Threads cannot be implemented as a library. *SIGPLAN Not.*, 40(6):261–268, June 2005.
- [Boh01] Kristoffer Bohmann. Response time still matters, July 2001. URL: http://www.bohmann.dk/articles/response_time_still_matters.html [broken, November 2016].
- [Bor06] Richard Bornat. Dividing the sheep from the goats, January 2006. Seminar at School of Computing, Univ. of Kent. Abstract is available at https://www.cs.kent.ac.uk/seminar_archive/2005_06/abs_2006_01_24.html. Retracted in July 2014: http://www.eis.mdx.ac.uk/staffpages/r_bornat/papers/camel_hump_retraction.pdf.
- [BPP⁺16] Adam Belay, George Prekas, Mia Primorac, Ana Klimovic, Samuel Grossman, Christos Kozyrakis, and Edouard Bugnion. The IX operating system: Combining low latency, high throughput, and efficiency in a protected dataplane. *ACM Trans. Comput. Syst.*, 34(4):11:1–11:39, December 2016.
- [Bra07] Reg Braithwaite. Don't overthink fizzbuzz, January 2007. <http://weblog.raganwald.com/2007/01/dont-overthink-fizzbuzz.html>.

- [Bra11] Björn Brandenburg. *Scheduling and Locking in Multiprocessor Real-Time Operating Systems*. PhD thesis, The University of North Carolina at Chapel Hill, 2011. URL: <https://www.cs.unc.edu/~anderson/diss/bbbdiss.pdf>.
- [BS14] Mark Batty and Peter Sewell. The thin-air problem, February 2014. <http://www.cl.cam.ac.uk/~pes20/cpp/notes42.html>.
- [But97] David Butenhof. *Programming with POSIX Threads*. Addison-Wesley, Boston, MA, USA, 1997.
- [BW14] Silas Boyd-Wickizer. *Optimizing Communications Bottlenecks in Multiprocessor Operating Systems Kernels*. PhD thesis, Massachusetts Institute of Technology, 2014. <https://pdos.csail.mit.edu/papers/sbw-phd-thesis.pdf>.
- [CAK⁺96] Crispin Cowan, Tito Autrey, Charles Krasic, Calton Pu, and Jonathan Walpole. Fast concurrent dynamic linking for an adaptive operating system. In *International Conference on Configurable Distributed Systems (ICCD'S'96)*, page 108, Annapolis, MD, May 1996.
- [CBM⁺08] Calin Cascaval, Colin Blundell, Maged Michael, Harold W. Cain, Peng Wu, Stefanie Chiras, and Siddhartha Chatterjee. Software transactional memory: Why is it only a research toy? *ACM Queue*, September 2008.
- [CHP71] P. J. Courtois, F. Heymans, and D. L. Parnas. Concurrent control with “readers” and “writers”. *Communications of the ACM*, 14(10):667–668, October 1971.
- [CKL04] Edmund Clarke, Daniel Kroening, and Flavio Lerda. A tool for checking ANSI-C programs. In Kurt Jensen and Andreas Podelski, editors, *Tools and Algorithms for the Construction and Analysis of Systems (TACAS 2004)*, volume 2988 of *Lecture Notes in Computer Science*, pages 168–176. Springer, 2004.
- [CKZ12] Austin Clements, Frans Kaashoek, and Nickolai Zeldovich. Scalable address spaces using RCU balanced trees. In *Architectural Support for Programming Languages and Operating Systems (ASPLOS 2012)*, pages 199–210, London, UK, March 2012. ACM.
- [CKZ⁺13] Austin T. Clements, M. Frans Kaashoek, Nickolai Zeldovich, Robert T. Morris, and Eddie Kohler. The scalable commutativity rule: Designing scalable software for multicore processors. In *Proceedings of the Twenty-Fourth ACM Symposium on Operating Systems Principles, SOSP '13*, pages 1–17, Farmington, Pennsylvania, 2013. ACM.
- [Cli09] Cliff Click. And now some hardware transactional memory comments..., February 2009. URL: <http://www.cliffc.org/blog/2009/02/25/and-now-some-hardware-transactional-memory-comments/>.
- [CLRS01] T.H. Cormen, C.E. Leiserson, R.L. Rivest, and C. Stein. *Introduction to Algorithms, Second Edition*. MIT electrical engineering and computer science series. MIT Press, 2001.
- [Com01] Compaq Computer Corporation. Shared memory, threads, interprocess communication, August 2001. Available: http://h71000.www7.hp.com/wizard/wiz_2637.html.
- [Cor02] Compaq Computer Corporation. *Alpha Architecture Reference Manual*. Digital Press, fourth edition, 2002.

- [Cor04a] Jonathan Corbet. Approaches to realtime Linux, October 2004. URL: <http://lwn.net/Articles/106010/>.
- [Cor04b] Jonathan Corbet. Finding kernel problems automatically, June 2004. <http://lwn.net/Articles/87538/>.
- [Cor04c] Jonathan Corbet. Realtime preemption, part 2, October 2004. URL: <http://lwn.net/Articles/107269/>.
- [Cor06a] Jonathan Corbet. The kernel lock validator, May 2006. Available: <http://lwn.net/Articles/185666/> [Viewed: March 26, 2010].
- [Cor06b] Jonathan Corbet. Priority inheritance in the kernel, April 2006. Available: <http://lwn.net/Articles/178253/> [Viewed June 29, 2009].
- [Cor08] Jonathan Corbet. Linux weekly news, November 2008. Available: <http://lwn.net/> [Viewed November 26, 2008].
- [Cor10a] Jonathan Corbet. Dcache scalability and rcu-walk, December 2010. Available: <https://lwn.net/Articles/419811/> [Viewed May 29, 2017].
- [Cor10b] Jonathan Corbet. sys_membarrier(), January 2010. <https://lwn.net/Articles/369567/>.
- [Cor11] Jonathan Corbet. How to ruin linus's vacation, July 2011. Available: <https://lwn.net/Articles/452117/> [Viewed May 29, 2017].
- [Cor12a] Jonathan Corbet. ACCESS_ONCE(), August 2012. <http://lwn.net/Articles/508991/>.
- [Cor12b] Jonathan Corbet. Relocating RCU callbacks, October 2012. <http://lwn.net/Articles/522262/>.
- [Cor13a] Jonathan Corbet. Is the whole system idle?, July 2013. <http://lwn.net/Articles/558284/>.
- [Cor13b] Jonathan Corbet. (nearly) full tickless operation in 3.10, May 2013. <http://lwn.net/Articles/549580/>.
- [Cor14a] Jonathan Corbet. ACCESS_ONCE() and compiler bugs, December 2014. <https://lwn.net/Articles/624126/>.
- [Cor14b] Jonathan Corbet. Relativistic hash tables, part 1: Algorithms, September 2014. <http://lwn.net/Articles/612021/>.
- [Cor14c] Jonathan Corbet. Relativistic hash tables, part 2: Implementation, September 2014. <http://lwn.net/Articles/612100/>.
- [Cor16] Jonathan Corbet. Time to move to C11 atomics?, June 2016. <https://lwn.net/Articles/691128/>.
- [Cor18] Jonathan Corbet. membarrier(2), October 2018. <http://man7.org/linux/man-pages/man2/membarrier.2.html>.
- [Cra93] Travis Craig. Building FIFO and priority-queuing spin locks from atomic swap. Technical Report 93-02-02, University of Washington, Seattle, Washington, February 1993.
- [CRKH05] Jonathan Corbet, Alessandro Rubini, and Greg Kroah-Hartman. *Linux Device Drivers*. O'Reilly Media, Inc., third edition, 2005. URL: <https://lwn.net/Kernel/LLD3/>.
- [CSG99] David E. Culler, Jaswinder Pal Singh, and Anoop Gupta. *Parallel Computer Architecture: a Hardware/Software Approach*. Morgan Kaufman, 1999.

- [Dat82] C. J. Date. *An Introduction to Database Systems*, volume 1. Addison-Wesley Publishing Company, 1982.
- [DBA09] Saeed Dehnadi, Richard Bornat, and Ray Adams. Meta-analysis of the effect of consistency on success in early learning of programming. In *PPIG 2009*, pages 1–13, University of Limerick, Ireland, June 2009. Psychology of Programming Interest Group.
- [DCW⁺11] Luke Dalessandro, Francois Carouge, Sean White, Yossi Lev, Mark Moir, Michael L. Scott, and Michael F. Spear. Hybrid NOrec: A case study in the effectiveness of best effort hardware transactional memory. In *Proceedings of the 16th International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS)*, ASPLOS '11, pages ???–???, Newport Beach, CA, USA, 2011. ACM.
- [Dea18] Will Deacon. [PATCH 00/10] kernel/locking: qspinlock improvements, April 2018. <http://lkml.kernel.org/r/1522947547-24081-1-git-send-email-will.deacon@arm.com>.
- [Den15] Peter Denning. Perspectives on OS foundations. In *SOSP History Day 2015, SOSP '15*, pages 3:1–3:46, Monterey, California, 2015. ACM.
- [Dep06] Department of Computing and Information Systems, University of Melbourne. CSIRAC, 2006. <http://www.cis.unimelb.edu.au/about/csirac/>.
- [Des09a] Mathieu Desnoyers. *Low-Impact Operating System Tracing*. PhD thesis, Ecole Polytechnique de Montréal, December 2009. Available: <http://www.lttng.org/pub/thesis/desnoyers-dissertation-2009-12.pdf> [Viewed December 9, 2009].
- [Des09b] Mathieu Desnoyers. [RFC git tree] userspace RCU (urcu) for Linux, February 2009. <http://liburcu.org>.
- [DFGG11] Aleksandar Dragovejic, Pascal Felber, Vincent Gramoli, and Rachid Guerraoui. Why STM can be more than a research toy. *Communications of the ACM*, pages 70–77, April 2011.
- [DHJ⁺07] Giuseppe DeCandia, Deniz Hastorun, Madan Jampani, Gunavardhan Kakulapati, Avinash Lakshman, Alex Pilchin, Swaminathan Sivasubramanian, Peter Vosshall, and Werner Vogels. Dynamo: Amazon’s highly available key-value store. *SIGOPS Oper. Syst. Rev.*, 41(6):205–220, October 2007.
- [DHK12] Vijay D’Silva, Leopold Haller, and Daniel Kroening. Satisfiability solvers are static analyzers. In *Static Analysis Symposium (SAS)*, volume 7460 of *LNCS*, pages 317–333. Springer, 2012.
- [DHL⁺08] Dave Dice, Maurice Herlihy, Doug Lea, Yossi Lev, Victor Luchangco, Wayne Mesard, Mark Moir, Kevin Moore, and Dan Nussbaum. Applications of the adaptive transactional memory test platform. In *3rd ACM SIGPLAN Workshop on Transactional Computing*, pages 1–10, Salt Lake City, UT, USA, February 2008.
- [Dig89] Digital Systems Research Center. *An Introduction to Programming with Threads*, January 1989.
- [Dij65] E. W. Dijkstra. Solution of a problem in concurrent programming control. *Communications of the ACM*, 8(9):569, Sept 1965.
- [Dij68] Edsger W. Dijkstra. Letters to the editor: Go to statement considered harmful. *Commun. ACM*, 11(3):147–148, March 1968.

- [Dij71] Edsger W. Dijkstra. Hierarchical ordering of sequential processes. *Acta Informatica*, 1(2):115–138, 1971. Available: <http://www.cs.utexas.edu/users/EWD/ewd03xx/EWD310.PDF> [Viewed January 13, 2008].
- [DKS89] Alan Demers, Srinivasan Keshav, and Scott Shenker. Analysis and simulation of a fair queuing algorithm. *SIGCOMM '89*, pages 1–12, 1989.
- [DLM⁺10] Dave Dice, Yossi Lev, Virendra J. Marathe, Mark Moir, Dan Nussbaum, and Marek Oleszewski. Simplifying concurrent algorithms by exploiting hardware transactional memory. In *Proceedings of the 22nd ACM symposium on Parallelism in algorithms and architectures*, SPAA '10, pages 325–334, Thira, Santorini, Greece, 2010. ACM.
- [DLMN09] Dave Dice, Yossi Lev, Mark Moir, and Dan Nussbaum. Early experience with a commercial hardware transactional memory implementation. In *Fourteenth International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS '09)*, pages 157–168, Washington, DC, USA, March 2009.
- [DMD13] Mathieu Desnoyers, Paul E. McKenney, and Michel R. Dagenais. Multi-core systems modeling for formal verification of parallel algorithms. *SIGOPS Oper. Syst. Rev.*, 47(2):51–65, July 2013.
- [DMLP79] Richard A. De Millo, Richard J. Lipton, and Alan J. Perlis. Social processes and proofs of theorems and programs. *Commun. ACM*, 22(5):271–280, May 1979.
- [DMS⁺12] Mathieu Desnoyers, Paul E. McKenney, Alan Stern, Michel R. Dagenais, and Jonathan Walpole. User-level implementations of read-copy update. *IEEE Transactions on Parallel and Distributed Systems*, 23:375–382, 2012.
- [Dov90] Ken F. Dove. A high capacity TCP/IP in parallel STREAMS. In *UKUUG Conference Proceedings*, London, June 1990.
- [Dre11] Ulrich Drepper. Futexes are tricky. Technical Report FAT2011, Red Hat, Inc., Raleigh, NC, USA, November 2011.
- [DSS06] Dave Dice, Ori Shalev, and Nir Shavit. Transactional locking II. In *Proc. International Symposium on Distributed Computing*. Springer Verlag, 2006.
- [Dug10] Abhinav Duggal. Stopping data races using redflag. Master’s thesis, Stony Brook University, 2010.
- [Edg13] Jake Edge. The future of realtime Linux, November 2013. URL: <http://1wn.net/Articles/572740/>.
- [Edg14] Jake Edge. The future of the realtime patch set, October 2014. URL: <http://1wn.net/Articles/617140/>.
- [EGCD03] T. A. El-Ghazawi, W. W. Carlson, and J. M. Draper. UPC language specifications v1.1, May 2003. Available: <http://upc.gwu.edu> [Viewed September 19, 2008].
- [EGMdB11] Stephane Eranian, Eric Gouriou, Tipp Moseley, and Willem de Bruijn. Linux kernel profiling with perf, June 2011. <https://perf.wiki.kernel.org/index.php/Tutorial>.
- [Ell80] Carla Schlatter Ellis. Concurrent search and insertion in avl trees. *IEEE Transactions on Computers*, C-29(9):811–817, September 1980.

- [ELLM07] Faith Ellen, Yossi Lev, Victor Luchangco, and Mark Moir. Snzi: scalable nonzero indicators. In *Proceedings of the twenty-sixth annual ACM symposium on Principles of distributed computing*, PODC '07, pages 13–22, Portland, Oregon, USA, 2007. ACM.
- [Eng68] Douglas Engelbart. The demo, December 1968. URL: <http://douengelbart.org/firsts/dougs-1968-demo.html>.
- [ENS05] Ryan Eccles, Blair Nonneck, and Deborah A. Stacey. Exploring parallel programming knowledge in the novice. In *HPCS '05: Proceedings of the 19th International Symposium on High Performance Computing Systems and Applications*, pages 97–102, Guelph, Ontario, Canada, 2005. IEEE Computer Society.
- [Eri08] Christer Ericson. Aiding pathfinding with cellular automata, June 2008. <http://realtimecollisiondetection.net/blog/?p=57>.
- [ES90] Margaret A. Ellis and Bjarne Stroustrup. *The Annotated C++ Reference Manual*. Addison Wesley, 1990.
- [ES05] Ryan Eccles and Deborah A. Stacey. Understanding the parallel programmer. In *HPCS '05: Proceedings of the 19th International Symposium on High Performance Computing Systems and Applications*, pages 156–160, Guelph, Ontario, Canada, 2005. IEEE Computer Society.
- [ETH11] ETH Zurich. Parallel solver for a perfect maze, March 2011. URL: <http://nativesystems.inf.ethz.ch/pub/Main/WebHomeLecturesParallelProgrammingExercises/pp2011hw04.pdf> [broken, November 2016].
- [Fel50] W. Feller. *An Introduction to Probability Theory and its Applications*. John Wiley, 1950.
- [Fos10] Ron Fosner. Scalable multithreaded programming with tasks. *MSDN Magazine*, 2010(11):60–69, November 2010. <http://msdn.microsoft.com/en-us/magazine/gg309176.aspx>.
- [FPB79] Jr. Frederick P. Brooks. *The Mythical Man-Month*. Addison-Wesley, 1979.
- [FRK02] Hubertus Francke, Rusty Russell, and Matthew Kirkwood. Fuss, futexes and furwocks: Fast userlevel locking in linux. In *Ottawa Linux Symposium*, pages 479–495, June 2002. Available: <http://www.kernel.org/doc/ols/2002/ols2002-pages-479-495.pdf> [Viewed May 22, 2011].
- [FSP⁺17] Shaked Flur, Susmit Sarkar, Christopher Pulte, Kyndylan Nienhuis, Luc Maranget, Kathryn E. Gray, Ali Sezgin, Mark Batty, and Peter Sewell. Mixed-size concurrency: Arm, power, c/c++11, and sc. *SIGPLAN Not.*, 52(1):429–442, January 2017.
- [GAJM15] Alex Groce, Iftekhar Ahmed, Carlos Jensen, and Paul E. McKenney. How verified is my code? falsification-driven verification (t). In *Proceedings of the 2015 30th IEEE/ACM International Conference on Automated Software Engineering (ASE)*, ASE '15, pages 737–748, Washington, DC, USA, 2015. IEEE Computer Society.
- [Gar90] Arun Garg. Parallel STREAMS: a multi-processor implementation. In *USENIX Conference Proceedings*, pages 163–176, Berkeley CA, February 1990. USENIX Association.

- [Gar07] Bryan Gardiner. IDF: Gordon Moore predicts end of Moore’s law (again), September 2007. Available: <http://blog.wired.com/business/2007/09/idf-gordon-mo-1.html> [Viewed: November 28, 2008].
- [GC96] Michael Greenwald and David R. Cheriton. The synergy between non-blocking synchronization and operating system structure. In *Proceedings of the Second Symposium on Operating Systems Design and Implementation*, pages 123–136, Seattle, WA, October 1996. USENIX Association.
- [GDZE10] Olga Golovanevsky, Alon Dayan, Ayal Zaks, and David Edelsohn. Trace-based data layout optimizations for multi-core processors. In *Proceedings of the 5th International Conference on High Performance Embedded Architectures and Compilers*, HiPEAC’10, pages 81–95, Pisa, Italy, 2010. Springer-Verlag.
- [GG14] Vincent Gramoli and Rachid Guerraoui. Democratizing transactional programming. *Commun. ACM*, 57(1):86–93, January 2014.
- [Gha95] Kourosh Gharachorloo. Memory consistency models for shared-memory multiprocessors. Technical Report CSL-TR-95-685, Computer Systems Laboratory, Departments of Electrical Engineering and Computer Science, Stanford University, Stanford, CA, December 1995. Available: <http://www.hpl.hp.com/techreports/Compaq-DEC/WRL-95-9.pdf> [Viewed: October 11, 2004].
- [GHH⁺14] Alex Groce, Klaus Havelund, Gerard J. Holzmann, Rajeev Joshi, and Ru-Gang Xu. Establishing flight software reliability: testing, model checking, constraint-solving, monitoring and learning. *Ann. Math. Artif. Intell.*, 70(4):315–349, 2014.
- [GHJV95] Erich Gamma, Richard Helm, Ralph Johnson, and John Vlissides. *Design Patterns: Elements of Reusable Object-Oriented Software*. Addison-Wesley, 1995.
- [GKAS99] Ben Gamsa, Orran Krieger, Jonathan Appavoo, and Michael Stumm. Tornado: Maximizing locality and concurrency in a shared memory multiprocessor operating system. In *Proceedings of the 3rd Symposium on Operating System Design and Implementation*, pages 87–100, New Orleans, LA, February 1999.
- [GKP13] Justin Gottschlich, Rob Knauerhase, and Gilles Pokam. But how do we really debug transactional memory? In *5th USENIX Workshop on Hot Topics in Parallelism (HotPar 2013)*, San Jose, CA, USA, June 2013.
- [GKPS95] Ben Gamsa, Orran Krieger, E. Parsons, and Michael Stumm. Performance issues for multiprocessor operating systems, November 1995. Technical Report CSRI-339, Available: <ftp://ftp.cs.toronto.edu/pub/reports/csri/339/339.ps>.
- [Gle10] Thomas Gleixner. Realtime linux: academia v. reality, July 2010. URL: <http://1wn.net/Articles/397422/>.
- [Gle12] Thomas Gleixner. Linux -rt kvm guest demo, December 2012. Personal communication.
- [GMTW08] D. Guniguntala, P. E. McKenney, J. Triplett, and J. Walpole. The read-copy-update mechanism for supporting real-time applications on shared-memory multiprocessor systems with Linux. *IBM Systems Journal*, 47(2):221–236, May 2008.
- [Gol18] David Goldblatt. P1202: Asymmetric fences, October 2018. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2018/p1202r0.pdf>.

- [GPB⁺07] Brian Goetz, Tim Peierls, Joshua Bloch, Joseph Bowbeer, David Holmes, and Doug Lea. *Java: Concurrency in Practice*. Addison Wesley, Upper Saddle River, NJ, USA, 2007.
- [Gra91] Jim Gray. *The Benchmark Handbook for Database and Transaction Processing Systems*. Morgan Kaufmann, 1991.
- [Gra02] Jim Gray. Super-servers: Commodity computer clusters pose a software challenge, April 2002. Available: [http://research.microsoft.com/en-us/um/people/gray/papers/superservers\(4t_computers\).doc](http://research.microsoft.com/en-us/um/people/gray/papers/superservers(4t_computers).doc) [Viewed: June 23, 2004].
- [Gri00] Scott Griffen. Internet pioneers: Doug Englebart, May 2000. Available: <http://www.ibiblio.org/pioneers/englebart.html> [Viewed November 28, 2008].
- [Gro01] The Open Group. Single UNIX specification, July 2001. <http://www.opengroup.org/onlinepubs/007908799/index.html>.
- [Gro07] Dan Grossman. The transactional memory / garbage collection analogy. In *OOPSLA '07: Proceedings of the 22nd annual ACM SIGPLAN conference on Object oriented programming systems and applications*, pages 695–706, Montreal, Quebec, Canada, October 2007. ACM. Available: http://www.cs.washington.edu/homes/djg/papers/analogy_oopsla07.pdf [Viewed December 19, 2008].
- [GRY12] Alexey Gotsman, Noam Rinetzky, and Hongseok Yang. Verifying highly concurrent algorithms with grace (extended version), July 2012. <http://software.imdea.org/~gotsman/papers/recycling-esop13-ext.pdf>.
- [GT90] Gary Graunke and Shreekant Thakkar. Synchronization algorithms for shared-memory multiprocessors. *IEEE Computer*, 23(6):60–69, June 1990.
- [Har16] "No Bugs" Hare. Infographics: Operation costs in CPU clock cycles, September 2016. <http://ithare.com/infographics-operation-costs-in-cpu-clock-cycles/>.
- [HCS⁺05] Lorin Hochstein, Jeff Carver, Forrest Shull, Sima Asgari, and Victor Basili. Parallel programmer productivity: A case study of novice parallel programmers. In *SC '05: Proceedings of the 2005 ACM/IEEE conference on Supercomputing*, page 35, Seattle, WA, USA, 2005. IEEE Computer Society.
- [Hei27] W. Heisenberg. Über den anschaulichen Inhalt der quantentheoretischen Kinematik und Mechanik. *Zeitschrift für Physik*, 43(3-4):172–198, 1927. English translation in “Quantum theory and measurement” by Wheeler and Zurek.
- [Her90] Maurice P. Herlihy. A methodology for implementing highly concurrent data structures. In *Proceedings of the 2nd ACM SIGPLAN Symposium on Principles and Practice of Parallel Programming*, pages 197–206, Seattle, WA, USA, March 1990.
- [Her91] Maurice Herlihy. Wait-free synchronization. *ACM TOPLAS*, 13(1):124–149, January 1991.
- [Her93] Maurice Herlihy. A methodology for implementing highly concurrent data objects. *ACM Transactions on Programming Languages and Systems*, 15(5):745–770, November 1993.

- [Her05] Maurice Herlihy. The transactional manifesto: software engineering and non-blocking synchronization. In *PLDI '05: Proceedings of the 2005 ACM SIGPLAN conference on Programming language design and implementation*, pages 280–280, Chicago, IL, USA, 2005. ACM Press.
- [HHK⁺13] A. Haas, T.A. Henzinger, C.M. Kirsch, M. Lippautz, H. Payer, A. Sezgin, and A. Sokolova. Distributed queues in shared memory—multicore performance and scalability through quantitative relaxation. In *Proc. International Conference on Computing Frontiers*, Ischia, Italy, 2013. ACM.
- [HKLP12] Andreas Haas, Christoph M. Kirsch, Michael Lippautz, and Hannes Payer. How FIFO is your concurrent FIFO queue? In *Proceedings of the Workshop on Relaxing Synchronization for Multicore and Manycore Scalability*, Tucson, AZ USA, October 2012.
- [HL86] Frederick S. Hillier and Gerald J. Lieberman. *Introduction to Operations Research*. Holden-Day, 1986.
- [HLM02] Maurice Herlihy, Victor Luchangco, and Mark Moir. The repeat offender problem: A mechanism for supporting dynamic-sized, lock-free data structures. In *Proceedings of 16th International Symposium on Distributed Computing*, pages 339–353, Toulouse, France, October 2002.
- [HLM03] Maurice Herlihy, Victor Luchangco, and Mark Moir. Obstruction-free synchronization: Double-ended queues as an example. In *Proceedings of the 23rd IEEE International Conference on Distributed Computing Systems (ICDCS)*, pages 73–82, Providence, RI, May 2003. The Institute of Electrical and Electronics Engineers, Inc.
- [HM93] Maurice Herlihy and J. Eliot B. Moss. Transactional memory: Architectural support for lock-free data structures. In *ISCA '93: Proceeding of the 20th Annual International Symposium on Computer Architecture*, pages 289–300, San Diego, CA, USA, May 1993.
- [HMB06] Thomas E. Hart, Paul E. McKenney, and Angela Demke Brown. Making lockless synchronization fast: Performance implications of memory reclamation. In *20th IEEE International Parallel and Distributed Processing Symposium*, Rhodes, Greece, April 2006. Available: http://www.rdrop.com/users/paulmck/RCU/hart_ipdps06.pdf [Viewed April 28, 2008].
- [HMBW07] Thomas E. Hart, Paul E. McKenney, Angela Demke Brown, and Jonathan Walpole. Performance of memory reclamation for lockless synchronization. *J. Parallel Distrib. Comput.*, 67(12):1270–1285, 2007.
- [HMDZ06] David Howells, Paul E. McKenney, Will Deacon, and Peter Zijlstra. Linux kernel memory barriers, March 2006. <https://www.kernel.org/doc/Documentation/memory-barriers.txt>.
- [Hoa74] C. A. R. Hoare. Monitors: An operating system structuring concept. *Communications of the ACM*, 17(10):549–557, October 1974.
- [Hol03] Gerard J. Holzmann. *The Spin Model Checker: Primer and Reference Manual*. Addison-Wesley, Boston, MA, USA, 2003.
- [Hor18] Jann Horn. Reading privileged memory with a side-channel, January 2018. <https://googleprojectzero.blogspot.com/2018/01/reading-privileged-memory-with-side.html>.

- [HOS89] James P. Hennessy, Damian L. Osisek, and Joseph W. Seigh II. Passive serialization in a multitasking environment. Technical Report US Patent 4,809,168 (lapsed), US Patent and Trademark Office, Washington, DC, February 1989.
- [How12] Phil Howard. *Extending Relativistic Programming to Multiple Writers*. PhD thesis, Portland State University, 2012.
- [HP95] John L. Hennessy and David A. Patterson. *Computer Architecture: A Quantitative Approach*. Morgan Kaufman, 1995.
- [Hra13] Adam Hraška. Read-copy-update for helenos. Master's thesis, Charles University in Prague, Faculty of Mathematics and Physics, Department of Distributed and Dependable Systems, 2013.
- [HS08] Maurice Herlihy and Nir Shavit. *The Art of Multiprocessor Programming*. Morgan Kaufmann, Burlington, MA, USA, 2008.
- [HW92] Wilson C. Hsieh and William E. Weihl. Scalable reader-writer locks for parallel systems. In *Proceedings of the 6th International Parallel Processing Symposium*, pages 216–230, Beverly Hills, CA, USA, March 1992.
- [HW11] Philip W. Howard and Jonathan Walpole. A relativistic enhancement to software transactional memory. In *Proceedings of the 3rd USENIX conference on Hot topics in parallelism*, HotPar'11, pages 1–6, Berkeley, CA, 2011. USENIX Association.
- [HW13] Philip W. Howard and Jonathan Walpole. Relativistic red-black trees. *Concurrency and Computation: Practice and Experience*, pages n/a–n/a, 2013.
- [IBM94] IBM Microelectronics and Motorola. *PowerPC Microprocessor Family: The Programming Environments*, 1994.
- [Ima17] Imagination Technologies, LTD. *MIPS®Architecture For Programmers Volume II-A: The MIPS64®Instruction Set Reference Manual*, 2017. <https://imgtec.com/?do-download=4302>.
- [Inm85] Jack Inman. Implementing loosely coupled functions on tightly coupled engines. In *USENIX Conference Proceedings*, pages 277–298, Portland, OR, June 1985. USENIX Association.
- [Inm07] Bill Inmon. Time value of information, January 2007. URL: <http://www.b-eye-network.com/view/3365>.
- [Int92] International Standards Organization. *Information Technology - Database Language SQL*. ISO, 1992. Available: <http://www.contrib.andrew.cmu.edu/~shadow/sql/sql1992.txt> [Viewed September 19, 2008].
- [Int02] Intel Corporation. *Intel Itanium Architecture Software Developer's Manual Volume 3: System Architecture*, 2002.
- [Int04a] Intel Corporation. *IA-32 Intel Architecture Software Developer's Manual Volume 2B: Instruction Set Reference, N-Z*, 2004. Available: <ftp://download.intel.com/design/Pentium4/manuals/25366714.pdf> [Viewed: February 16, 2005].
- [Int04b] Intel Corporation. *IA-32 Intel Architecture Software Developer's Manual Volume 3: System Programming Guide*, 2004. Available: <ftp://download.intel.com/design/Pentium4/manuals/25366814.pdf> [Viewed: February 16, 2005].

- [Int04c] International Business Machines Corporation. *z/Architecture principles of operation*, May 2004. Available: <http://publibz.boulder.ibm.com/epubs/pdf/dz9zr003.pdf> [Viewed: February 16, 2005].
- [Int07] Intel Corporation. *Intel 64 Architecture Memory Ordering White Paper*, 2007. Available: <http://developer.intel.com/products/processor/manuals/318147.pdf> [Viewed: September 7, 2007].
- [Int11] Intel Corporation. *Intel 64 and IA-32 Architectures Software Developer's Manual, Volume 3A: System Programming Guide, Part 1*, 2011. Available: <http://www.intel.com/Assets/PDF/manual/253668.pdf> [Viewed: February 12, 2011].
- [Jac88] Van Jacobson. Congestion avoidance and control. In *SIGCOMM '88*, pages 314–329, August 1988.
- [Jac93] Van Jacobson. Avoid read-side locking via delayed free, September 1993. private communication.
- [Jac08] Daniel Jackson. MapReduce course, January 2008. Available: <https://sites.google.com/site/mriap2008/> [Viewed January 3, 2013].
- [Jef14] Alan Jeffrey. Jmm revision status, July 2014. <http://mail.openjdk.java.net/pipermail/jmm-dev/2014-July/000072.html>.
- [Jia08] Lai Jiangshan. [RFC][PATCH] rcu classic: new algorithm for callbacks-processing, June 2008. Available: Linux-kernel git SHA-1 5127bed588a2 [Viewed July 9, 2016].
- [JLK16a] Yeongjin Jang, Sangho Lee, and Taesoo Kim. Breaking kernel address space layout randomization (KASLR) with Intel TSX, July 2016. Black Hat USA 2018 <https://www.blackhat.com/us-16/briefings.html#breaking-kernel-address-space-layout-randomization-kaslr-with-intel-tsx>.
- [JLK16b] Yeongjin Jang, Sangho Lee, and Taesoo Kim. Breaking kernel address space layout randomization with Intel TSX. In *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security*, CCS '16, pages 380–392, Vienna, Austria, 2016. ACM.
- [JMRR02] Benedict Joseph Jackson, Paul E. McKenney, Ramakrishnan Rajamony, and Ronald Lynn Rockhold. Scalable interruptible queue locks for shared-memory multiprocessor. US Patent 6,473,819, US Patent and Trademark Office, Washington, DC, October 2002.
- [Joh77] Stephen Johnson. Lint, a C program checker, December 1977. Computer Science Technical Report 65, Bell Laboratories.
- [Joh95] Aju John. Dynamic vnodes – design and implementation. In *USENIX Winter 1995*, pages 11–23, New Orleans, LA, January 1995. USENIX Association. Available: https://www.usenix.org/publications/library/proceedings/neworl/full_papers/john.a [Viewed October 1, 2010].
- [Jon11] Dave Jones. Trinity: A system call fuzzer. In *Proceedings of the 13th Ottawa Linux Symposium*, pages ???–???, Ottawa, Canada, June 2011.
- [JSG12] Christian Jacobi, Timothy Slegel, and Dan Greiner. Transactional memory architecture and implementation for IBM System z, December 2012. The 45th Annual IEEE/ACM International Symposium on MicroArchitecture, URL: <http://www.microarch.org/micro45/talks-posters/3-jacobi-presentation.pdf>.

- [Kaa15] Frans Kaashoek. Parallel computing and the os. In *SOSP History Day*, October 2015.
- [KCH⁺06] Sanjeev Kumar, Michael Chu, Christopher J. Hughes, Partha Kumar, and Anthony Nguyen. Hybrid transactional memory. In *Proceedings of the ACM SIGPLAN 2006 Symposium on Principles and Practice of Parallel Programming*, New York, New York, United States, 2006. ACM SIGPLAN. <http://princeton.kumarbhope.com/papers/PPoPP06/ppopp06.pdf>.
- [Kel17] Michael J. Kelly. How might the manufacturability of the hardware at device level impact on exascale computing?, 2017. URL: <https://openparallel.com/multicore-world-2017/program-2017/abstracts2017/>.
- [KFC11] KFC. Memristor processor solves mazes, March 2011. <http://www.technologyreview.com/blog/arxiv/26467/>.
- [Kis14] Jan Kiszka. Real-time virtualization - how crazy are we? In *Linux Plumbers Conference*, Duesseldorf, Germany, October 2014. URL: <http://www.linuxplumbersconf.org/2014/ocw/sessions/1935>.
- [KL80] H. T. Kung and P. Lehman. Concurrent manipulation of binary search trees. *ACM Transactions on Database Systems*, 5(3):354–382, September 1980.
- [KLP12] Christoph M. Kirsch, Michael Lippautz, and Hannes Payer. Fast and scalable k-fifo queues. Technical Report 2012-04, University of Salzburg, Salzburg, Austria, June 2012.
- [Kni08] John U. Knickerbocker. 3D chip technology. *IBM Journal of Research and Development*, 52(6), November 2008. URL: <http://www.research.ibm.com/journal/rd52-6.html> [Link to each article is broken as of November 2016; Available via <http://ieeexplore.ieee.org/xpl/tocresult.jsp?isnumber=5388557>].
- [Knu73] Donald Knuth. *The Art of Computer Programming*. Addison-Wesley, 1973.
- [KS08] Daniel Kroening and Ofer Strichman. *Decision Procedures: An Algorithmic Point of View*. Springer Publishing Company, Incorporated, 1 edition, 2008.
- [KS17a] Michalis Kokologiannakis and Konstantinos Sagonas. Stateless model checking of the linux kernel’s hierarchical read-copy update (Tree RCU). Technical report, National Technical University of Athens, January 2017. <https://github.com/michalis-/rcu/blob/master/rcupaper.pdf>.
- [KS17b] Michalis Kokologiannakis and Konstantinos Sagonas. Stateless model checking of the Linux kernel’s hierarchical read-copy-update (Tree RCU). In *Proceedings of International SPIN Symposium on Model Checking of Software*, SPIN 2017, New York, NY, USA, July 2017. ACM.
- [KWS97] Leonidas Kontothanassis, Robert W. Wisniewski, and Michael L. Scott. Scheduler-conscious synchronization. *ACM Transactions on Computer Systems*, 15(1):3–40, February 1997.
- [LA94] Beng-Hong Lim and Anant Agarwal. Reactive synchronization algorithms for multiprocessors. In *Proceedings of the sixth international conference on Architectural support for programming languages and operating systems*, ASPLOS VI, pages 25–35, San Jose, California, USA, October 1994. ACM. URL: <http://groups.csail.mit.edu/cag/pub/papers/pdf/reactive.pdf>.
- [Lam74] Leslie Lamport. A new solution of Dijkstra’s concurrent programming problem. *Communications of the ACM*, 17(8):453–455, August 1974.

- [Lam02] Leslie Lamport. *Specifying Systems: The TLA+ Language and Tools for Hardware and Software Engineers*. Addison-Wesley Longman Publishing Co., Inc., Boston, MA, USA, 2002.
- [Lea97] Doug Lea. *Concurrent Programming in Java: Design Principles and Patterns*. Addison Wesley Longman, Reading, MA, USA, 1997.
- [LHF05] Michael Lyons, Bill Hay, and Brad Frey. PowerPC storage model and AIX programming, November 2005. <http://www.ibm.com/developerworks/systems/articles/powerpc.html>.
- [Lis88] Barbara Liskov. Distributed programming in Argus. *Commun. ACM*, 31(3):300–312, 1988.
- [LLO09] Yossi Lev, Victor Luchangco, and Marek Olszewski. Scalable reader-writer locks. In *SPAA '09: Proceedings of the twenty-first annual symposium on Parallelism in algorithms and architectures*, pages 101–110, Calgary, AB, Canada, 2009. ACM.
- [LLS13] Yujie Liu, Victor Luchangco, and Michael Spear. Mindicators: A scalable approach to quiescence. In *Proceedings of the 2013 IEEE 33rd International Conference on Distributed Computing Systems, ICDCS '13*, pages 206–215, Washington, DC, USA, 2013. IEEE Computer Society.
- [LMKM16] Lihao Liang, Paul E. McKenney, Daniel Kroening, and Tom Melham. Verification of the tree-based hierarchical read-copy update in the Linux kernel. Technical report, Cornell University Library, October 2016. <https://arxiv.org/abs/1610.03052>.
- [LMKM18] Lihao Liang, Paul E. McKenney, Daniel Kroening, and Tom Melham. Verification of tree-based hierarchical Read-Copy Update in the Linux Kernel. In *2018 Design, Automation & Test in Europe Conference & Exhibition, DATE 2018, Dresden, Germany, March 19–23, 2018*, 2018.
- [Loc02] Doug Locke. Priority inheritance: The real story, July 2002. URL: <http://www.linuxdevices.com/articles/AT5698775833.html> [broken, November 2016], page capture available at <http://www.math.unipd.it/%7Etullio/SCD/2007/Materiale/Locke.pdf>.
- [Lom77] D. B. Lomet. Process structuring, synchronization, and recovery using atomic actions. *SIGSOFT Softw. Eng. Notes*, 2(2):128–137, 1977. URL: <http://portal.acm.org/citation.cfm?id=808319#>.
- [Lov05] Robert Love. *Linux Kernel Development*. Novell Press, second edition, 2005.
- [LR80] Butler W. Lampson and David D. Redell. Experience with processes and monitors in Mesa. *Communications of the ACM*, 23(2):105–117, 1980.
- [LS86] Vladimir Lanin and Dennis Shasha. A symmetric concurrent b-tree algorithm. In *ACM '86: Proceedings of 1986 ACM Fall joint computer conference*, pages 380–389, Dallas, Texas, United States, 1986. IEEE Computer Society Press.
- [LS11] Yujie Liu and Michael Spear. Toxic transactions. In *TRANSACT 2011*, San Jose, CA, USA, June 2011. ACM SIGPLAN.
- [LSLK14] Carl Leonardsson, Kostis Sagonas, Truc Nguyen Lam, and Michalis Kokologiannakis. Nidhugg, July 2014. <https://github.com/nidhugg/nidhugg>.
- [LVK⁺17] Ori Lahav, Viktor Vafeiadis, Jeehoon Kang, Chung-Kil Hur, and Derek Dreyer. Repairing sequential consistency in c/c++11. *SIGPLAN Not.*, 52(6):618–632, June 2017.

- [LZC14] Ran Liu, Heng Zhang, and Haibo Chen. Scalable read-mostly synchronization using passive reader-writer locks. In *2014 USENIX Annual Technical Conference (USENIX ATC 14)*, pages 219–230, Philadelphia, PA, June 2014. USENIX Association.
- [MAK⁺01] Paul E. McKenney, Jonathan Appavoo, Andi Kleen, Orran Krieger, Rusty Russell, Dipankar Sarma, and Maneesh Soni. Read-copy update. In *Ottawa Linux Symposium*, July 2001. URL: <https://www.kernel.org/doc/ols/2001/read-copy.pdf>, http://www.rdrop.com/users/paulmck/RCU/rclock_OLS.2001.05.01c.pdf.
- [Mar17] Luc Maraget. Aarch64 model vs. hardware, May 2017. <http://pauillac.inria.fr/~maranget/cats7/model-aarch64/specific.html>.
- [Mar18] Catalin Marinas. Queued spinlocks model, March 2018. <https://git.kernel.org/pub/scm/linux/kernel/git/cmarinas/kernel-tla.git>.
- [Mas92] H. Massalin. *Synthesis: An Efficient Implementation of Fundamental Operating System Services*. PhD thesis, Columbia University, New York, NY, 1992.
- [Mat13] Norm Matloff. *Programming on Parallel Machines*. University of California, Davis, Davis, CA, USA, 2013.
- [MBM⁺06] Kevin E. Moore, Jayaram Bobba, Michelle J. Moravan, Mark D. Hill, and David A. Wood. LogTM: Log-based transactional memory. In *Proceedings of the 12th Annual International Symposium on High Performance Computer Architecture (HPCA-12)*, Austin, Texas, United States, 2006. IEEE. Available: http://www.cs.wisc.edu/multifacet/papers/hpca06_logtm.pdf [Viewed December 21, 2006].
- [MBWW12] Paul E. McKenney, Silas Boyd-Wickizer, and Jonathan Walpole. RCU usage in the linux kernel: One decade later, September 2012. Technical report paulmck.2012.09.17, <http://rdrop.com/users/paulmck/techreports/survey.2012.09.17a.pdf>.
- [McK90a] Paul E. McKenney. Stochastic fairness queuing. In *IEEE INFOCOM'90 Proceedings*, pages 733–740, San Francisco, June 1990. The Institute of Electrical and Electronics Engineers, Inc. Revision available: <http://www.rdrop.com/users/paulmck/scalability/paper/sfq.2002.06.04.pdf> [Viewed May 26, 2008].
- [McK90b] Paul E. McKenney. Stochastic fairness queuing. Technical Report ITSTD-7186-PA-89-11, SRI International, Menlo Park, CA, March 1990. To appear in INFOCOM'90.
- [McK91] Paul E. McKenney. Stochastic fairness queuing. *Internetworking: Theory and Experience*, 2:113–131, 1991.
- [McK95] Paul E. McKenney. Differential profiling. In *MASCOTS 1995*, pages 237–241, Toronto, Canada, January 1995.
- [McK96] Paul E. McKenney. *Pattern Languages of Program Design*, volume 2, chapter 31: Selecting Locking Designs for Parallel Programs, pages 501–531. Addison-Wesley, June 1996. Available: <http://www.rdrop.com/users/paulmck/scalability/paper/mutexdesignpat.pdf> [Viewed February 17, 2005].
- [McK99] Paul E. McKenney. Differential profiling. *Software - Practice and Experience*, 29(3):219–234, 1999.

- [McK03] Paul E. McKenney. Using RCU in the Linux 2.5 kernel. *Linux Journal*, 1(114):18–26, October 2003. Available: <http://www.linuxjournal.com/article/6993> [Viewed November 14, 2007].
- [McK04] Paul E. McKenney. *Exploiting Deferred Destruction: An Analysis of Read-Copy-Update Techniques in Operating System Kernels*. PhD thesis, OGI School of Science and Engineering at Oregon Health and Sciences University, 2004.
- [McK05a] Paul E. McKenney. Memory ordering in modern microprocessors, part I. *Linux Journal*, 1(136):52–57, August 2005. Available: <http://www.linuxjournal.com/article/8211> <http://www.rdrop.com/users/paulmck/scalability/paper/ordering.2007.09.19a.pdf> [Viewed November 30, 2007].
- [McK05b] Paul E. McKenney. Memory ordering in modern microprocessors, part II. *Linux Journal*, 1(137):78–82, September 2005. Available: <http://www.linuxjournal.com/article/8212> <http://www.rdrop.com/users/paulmck/scalability/paper/ordering.2007.09.19a.pdf> [Viewed November 30, 2007].
- [McK05c] Paul E. McKenney. Re: [fwd: Re: [patch] real-time preemption, -rt-2.6.13-rc4-v0.7.52-01], August 2005. Available: <http://lkml.org/lkml/2005/8/8/108> [Viewed March 14, 2006].
- [McK05d] Paul E. McKenney. A realtime preemption overview, August 2005. URL: <http://lwn.net/Articles/146861/>.
- [McK06a] Paul E. McKenney. RCU Linux usage, October 2006. Available: <http://www.rdrop.com/users/paulmck/RCU/linuxusage.html> [Viewed January 14, 2007].
- [McK06b] Paul E. McKenney. Sleepable RCU, October 2006. Available: <http://lwn.net/Articles/202847/> Revised: <http://www.rdrop.com/users/paulmck/RCU/srcu.2007.01.14a.pdf> [Viewed August 21, 2006].
- [McK07a] Paul E. McKenney. The design of preemptible read-copy-update, October 2007. Available: <http://lwn.net/Articles/253651/> [Viewed October 25, 2007].
- [McK07b] Paul E. McKenney. Immunize rcu_dereference() against crazy compiler writers, October 2007. Git commit: <https://git.kernel.org/pub/scm/linux/kernel/git/torvalds/linux.git/commit/?id=97b430320ce7>.
- [McK07c] Paul E. McKenney. [PATCH] QRCU with lockless fastpath, February 2007. Available: <http://lkml.org/lkml/2007/2/25/18> [Viewed March 27, 2008].
- [McK07d] Paul E. McKenney. [patch rfc 0/9] RCU: Preemptible RCU, September 2007. Available: <http://lkml.org/lkml/2007/9/10/213> [Viewed October 25, 2007].
- [McK07e] Paul E. McKenney. Priority-boosting RCU read-side critical sections, February 2007. <http://lwn.net/Articles/220677/>.
- [McK07f] Paul E. McKenney. RCU and unloadable modules, January 2007. Available: <http://lwn.net/Articles/217484/> [Viewed November 22, 2007].

- [McK07g] Paul E. McKenney. Using Promela and Spin to verify parallel algorithms, August 2007. Available: <http://lwn.net/Articles/243851/> [Viewed September 8, 2007].
- [McK07h] Paul E. McKenney. What is RCU?, 07 2007. Available: <http://www.rdrop.com/users/paulmck/RCU/whatisRCU.html> [Viewed July 6, 2007].
- [McK08a] Paul E. McKenney. Hierarchical RCU, November 2008. <http://lwn.net/Articles/305782/>.
- [McK08b] Paul E. McKenney. RCU part 3: the RCU API, January 2008. Available: <http://lwn.net/Articles/264090/> [Viewed January 10, 2008].
- [McK08c] Paul E. McKenney. What is RCU? part 2: Usage, January 2008. Available: <http://lwn.net/Articles/263130/> [Viewed January 4, 2008].
- [McK09a] Paul E. McKenney. Hunting heisenbugs, November 2009. Available: <http://paulmck.livejournal.com/14639.html> [Viewed June 4, 2010].
- [McK09b] Paul E. McKenney. RCU: The Bloatwatch edition, March 2009. Available: <http://lwn.net/Articles/323929/> [Viewed March 20, 2009].
- [McK09c] Paul E. McKenney. Re: [PATCH fyi] RCU: the bloatwatch edition, January 2009. Available: <http://lkml.org/lkml/2009/1/14/449> [Viewed January 15, 2009].
- [McK09d] Paul E. McKenney. Transactional memory everywhere?, September 2009. <http://paulmck.livejournal.com/tag/transactional%20memory%20everywhere>.
- [McK10] Paul E. McKenney. Lockdep-RCU, February 2010. <https://lwn.net/Articles/371986/>.
- [McK11a] Paul E. McKenney. 3.0 and RCU: what went wrong, July 2011. <http://lwn.net/Articles/453002/>.
- [McK11b] Paul E. McKenney. Concurrent code and expensive instructions, January 2011. Available: <http://lwn.net/Articles/423994> [Viewed January 28, 2011].
- [McK11c] Paul E. McKenney. Validating memory barriers and atomic instructions, December 2011. <http://lwn.net/Articles/470681/>.
- [McK11d] Paul E. McKenney. Verifying parallel software: Can theory meet practice?, January 2011. <http://www.rdrop.com/users/paulmck/scalability/paper/VericoTheoryPractice.2011.01.28a.pdf>.
- [McK12a] Paul E. McKenney. Making RCU safe for battery-powered devices, February 2012. Available: <http://www.rdrop.com/users/paulmck/RCU/RCUdynticks.2012.02.15b.pdf> [Viewed March 1, 2012].
- [McK12b] Paul E. McKenney. Retrofitted parallelism considered grossly sub-optimal. In *4th USENIX Workshop on Hot Topics on Parallelism*, page 7, Berkeley, CA, USA, June 2012.
- [McK12c] Paul E. McKenney. Signed overflow optimization hazards in the kernel, August 2012. <http://lwn.net/Articles/511259/>.
- [McK13] Paul E. McKenney. Structured deferral: synchronization via procrastination. *Commun. ACM*, 56(7):40–49, July 2013.
- [McK14a] Paul E. McKenney. *Is Parallel Programming Hard, And, If So, What Can You Do About It? (First Edition)*. kernel.org, Corvallis, OR, USA, 2014.

- [McK14b] Paul E. McKenney. N4037: Non-transactional implementation of atomic tree move, May 2014. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2014/n4037.pdf>.
- [McK14c] Paul E. McKenney. Proper care and feeding of return values from `rcu_dereference()`, February 2014. https://www.kernel.org/doc/Documentation/RCU/rcu_dereference.txt.
- [McK14d] Paul E. McKenney. The RCU API, 2014 edition, September 2014. <http://lwn.net/Articles/609904/>.
- [McK14e] Paul E. McKenney. Recent read-mostly research, November 2014. <http://lwn.net/Articles/619355/>.
- [McK15a] Paul E. McKenney. Formal verification and Linux-kernel concurrency. In *Compositional Verification Methods for Next-Generation Concurrency*, Dagstuhl Seminar Proceedings, Dagstuhl, Germany, 2015. Schloss Dagstuhl - Leibniz-Zentrum fuer Informatik, Germany.
- [McK15b] Paul E. McKenney. Practical experience with formal verification tools. In *Verified Trustworthy Software Systems Specialist Meeting*. The Royal Society, April 2015. <http://www.rdrop.com/users/paulmck/scalability/paper/Validation.2016.04.06e.SpecMtg.pdf>.
- [McK15c] Paul E. McKenney. RCU requirements part 2 — parallelism and software engineering, August 2015. <http://lwn.net/Articles/652677/>.
- [McK15d] Paul E. McKenney. RCU requirements part 3, August 2015. <http://lwn.net/Articles/653326/>.
- [McK15e] Paul E. McKenney. Requirements for RCU part 1: the fundamentals, July 2015. <http://lwn.net/Articles/652156/>.
- [McK17] Paul E. McKenney. Verification challenge 6: Linux-kernel Tree RCU, June 2017. <https://paulmck.livejournal.com/46993.html>.
- [MCM02] Paul E. McKenney, Kevin A. Clossen, and Raghupathi Malige. Lingering locks with fairness control for multi-node computer systems. US Patent 6,480,918, US Patent and Trademark Office, Washington, DC, November 2002.
- [MCS91] John M. Mellor-Crummey and Michael L. Scott. Algorithms for scalable synchronization on shared-memory multiprocessors. *Transactions of Computer Systems*, 9(1):21–65, February 1991.
- [MD92] Paul E. McKenney and Ken F. Dove. Efficient demultiplexing of incoming tcp packets. In *SIGCOMM '92, Proceedings of the Conference on Communications Architecture & Protocols*, pages 269–279, Baltimore, MD, August 1992. Association for Computing Machinery.
- [MDJ13a] Paul E. McKenney, Mathieu Desnoyers, and Lai Jiangshan. URCU-protected hash tables, November 2013. <http://lwn.net/Articles/573431/>.
- [MDJ13b] Paul E. McKenney, Mathieu Desnoyers, and Lai Jiangshan. URCU-protected queues and stacks, November 2013. <https://lwn.net/Articles/573433/>.
- [MDJ13c] Paul E. McKenney, Mathieu Desnoyers, and Lai Jiangshan. User-space RCU, November 2013. <https://lwn.net/Articles/573424/>.

- [MDR16a] Paul E. McKenney, Will Deacon, and Luis R. Rodriguez. Semantics of MMIO mapping attributes across architectures, August 2016. <https://lwn.net/Articles/698014/>.
- [MDR16b] Paul E. McKenney, Will Deacon, and Luis R. Rodriguez. Semantics of MMIO mapping attributes across architectures, August 2016. <https://lwn.net/Articles/698014/>.
- [Mer11] Rick Merritt. IBM plants transactional memory in CPU, August 2011. EE Times <http://www.eetimes.com/electronics-news/4218914/IBM-plants-transactional-memory-in-CPU>.
- [MER13] Paul E. McKenney, Dietmar Eggemann, and Robin Randhawa. Improving energy efficiency on asymmetric multiprocessing systems, June 2013. <https://www.usenix.org/system/files/hotpar13-poster8-mckenney.pdf>.
- [Met99] Panagiotis Takis Metaxas. Fast dithering on a data-parallel computer. In *Proceedings of the IASTED International Conference on Parallel and Distributed Computing and Systems*, pages 570–576, Cambridge, MA, USA, 1999. IASTED.
- [MG92] Paul E. McKenney and Gary Graunke. Efficient buffer allocation on shared-memory multiprocessors. In *IEEE Workshop on the Architecture and Implementation of High Performance Communication Subsystems*, pages 194–199, Tucson, AZ, February 1992. The Institute of Electrical and Electronics Engineers, Inc.
- [MGM⁺09] Paul E. McKenney, Manish Gupta, Maged M. Michael, Phil Howard, Joshua Triplett, and Jonathan Walpole. Is parallel programming hard, and if so, why? Technical Report TR-09-02, Portland State University, Portland, OR, USA, February 2009. Available: <http://www.cs.pdx.edu/pdfs/tr0902.pdf> [Viewed February 19, 2009].
- [MHS12] Milo M. K. Martin, Mark D. Hill, and Daniel J. Sorin. Why on-chip coherence is here to stay. *Communications of the ACM*, 55(7):78–89, July 2012.
- [Mic03] Maged M. Michael. Cas-based lock-free algorithm for shared deques. In Harald Kosch, László Böszörmenyi, and Hermann Hellwagner, editors, *Euro-Par*, volume 2790 of *Lecture Notes in Computer Science*, pages 651–660. Springer, 2003.
- [Mic04] Maged M. Michael. Hazard pointers: Safe memory reclamation for lock-free objects. *IEEE Transactions on Parallel and Distributed Systems*, 15(6):491–504, June 2004.
- [Mic08] Microsoft. *FlushProcessWriteBuffers* function, 2008. <https://docs.microsoft.com/en-us/windows/desktop/api/processthreadsapi/nf-processthreadsapi-flushprocesswritebuffers>.
- [Mil06] David S. Miller. Re: [PATCH, RFC] RCU : OOM avoidance and lower latency, January 2006. Available: <https://lkml.org/lkml/2006/1/7/22> [Viewed February 29, 2012].
- [MJST16] Paul E. McKenney, Alan Jeffrey, Ali Sezgin, and Tony Tye. Out-of-thin-air execution is vacuous, July 2016. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2016/p0422r0.html>.

- [MK88] Marshall Kirk McKusick and Michael J. Karels. Design of a general purpose memory allocator for the 4.3BSD UNIX kernel. In *USENIX Conference Proceedings*, Berkeley CA, June 1988.
- [MKM12] Yandong Mao, Eddie Kohler, and Robert Tappan Morris. Cache craftiness for fast multicore key-value storage. In *Proceedings of the 7th ACM European Conference on Computer Systems*, EuroSys '12, pages 183–196, Bern, Switzerland, 2012. ACM.
- [ML82] Udi Manber and Richard E. Ladner. Concurrency control in a dynamic search structure. Technical Report 82-01-01, Department of Computer Science, University of Washington, Seattle, Washington, January 1982.
- [ML84] Udi Manber and Richard E. Ladner. Concurrency control in a dynamic search structure. *ACM Transactions on Database Systems*, 9(3):439–455, September 1984.
- [MLH94] Peter Magnusson, Anders Landin, and Erik Hagersten. Efficient software synchronization on large cache coherent multiprocessors. Technical Report T94:07, Swedish Institute of Computer Science, Kista, Sweden, February 1994.
- [MM00] Ingo Molnar and David S. Miller. brlock, March 2000. URL: [http://kernel.nic.funet.fi/pub/linux/kernel/v2.3/patch-
html/patch-2.3.49/linux_include_linux_brlock.h.html](http://kernel.nic.funet.fi/pub/linux/kernel/v2.3/patch-html/patch-2.3.49/linux_include_linux_brlock.h.html).
- [MMTW10] Paul E. McKenney, Maged M. Michael, Josh Triplett, and Jonathan Walpole. Why the grass may not be greener on the other side: a comparison of locking vs. transactional memory. *ACM Operating Systems Review*, 44(3), July 2010.
- [MMW07] Paul E. McKenney, Maged Michael, and Jonathan Walpole. Why the grass may not be greener on the other side: A comparison of locking vs. transactional memory. In *Programming Languages and Operating Systems*, pages 1–5, Stevenson, Washington, USA, October 2007. ACM SIGOPS.
- [Mol05] Ingo Molnar. Index of /pub/linux/kernel/projects/rt, February 2005. URL: <http://www.kernel.org/pub/linux/kernel/projects/rt/>.
- [Mol06] Ingo Molnar. Lightweight robust futexes, March 2006. Available: <http://lxr.linux.no/#linux+v2.6.39/Documentation/robust-futexes.txt> [Viewed May 22, 2011].
- [Moo03] Gordon Moore. No exponential is forever—but we can delay forever. In *IBM Academy of Technology 2003 Annual Meeting*, San Francisco, CA, October 2003.
- [Mor04] James Morris. Recent developments in SELinux kernel performance, December 2004. Available: http://www.livejournal.com/users/james_morris/2153.html [Viewed December 10, 2004].
- [MOZ09] Nicholas Mc Guire, Peter Odhiambo Okech, and Qingguo Zhou. Analysis of inherent randomness of the linux kernel. In *Eleventh Real Time Linux Workshop*, Dresden, Germany, September 2009.
- [MP15a] Paul E. McKenney and Aravinda Prasad. Recent read-mostly research in 2015, December 2015. <http://lwn.net/Articles/667593/>.
- [MP15b] Paul E. McKenney and Aravinda Prasad. Some more details on read-log-update, December 2015. <https://lwn.net/Articles/667720/>.

- [MPA⁺06] Paul E. McKenney, Chris Purcell, Algae, Ben Schumin, Gaius Cornelius, Qwertyus, Neil Conway, Sbw, Blainster, Canis Rufus, Zoicon5, Anome, and Hal Eisen. Read-copy update, July 2006. <http://en.wikipedia.org/wiki/Read-copy-update>.
- [MPI08] MPI Forum. Message passing interface forum, September 2008. Available: <http://www.mpi-forum.org/> [Viewed September 9, 2008].
- [MR08] Paul E. McKenney and Steven Rostedt. Integrating and validating dynticks and preemptable RCU, April 2008. Available: <http://lwn.net/Articles/279077/> [Viewed April 24, 2008].
- [MRP⁺17] Paul E. McKenney, Torvald Riegel, Jeff Preshing, Hans Boehm, Clark Nelson, Olivier Giroux, Lawrence Crowl, JF Bastian, and Michael Wong. Marking memory order consume dependency chains, February 2017. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2017/p0462r1.pdf>.
- [MS93] Paul E. McKenney and Jack Slingwine. Efficient kernel memory allocation on shared-memory multiprocessors. In *USENIX Conference Proceedings*, pages 295–306, Berkeley CA, February 1993. USENIX Association. Available: <http://www.rdrop.com/users/paulmck/scalability/paper/mpalloc.pdf> [Viewed January 30, 2005].
- [MS95] Maged M. Michael and Michael L. Scott. Correction of a memory management method for lock-free data structures, December 1995. Technical Report TR599.
- [MS96] M.M Michael and M. L. Scott. Simple, fast, and practical non-blocking and blocking concurrent queue algorithms. In *Proc of the Fifteenth ACM Symposium on Principles of Distributed Computing*, pages 267–275, May 1996. Available: <http://www.research.ibm.com/people/m/michael/podc-1996.pdf> [Viewed January 26, 2009].
- [MS98a] Paul E. McKenney and John D. Slingwine. Read-copy update: Using execution history to solve concurrency problems. In *Parallel and Distributed Computing and Systems*, pages 509–518, Las Vegas, NV, October 1998.
- [MS98b] Maged M. Michael and Michael L. Scott. Nonblocking algorithms and preemption-safe locking on multiprogrammed shared memory multiprocessors. *J. Parallel Distrib. Comput.*, 51(1):1–26, 1998.
- [MS01] Paul E. McKenney and Dipankar Sarma. Read-copy update mutual exclusion in Linux, February 2001. Available: http://lse.sourceforge.net/locking/rcu/rcupdate_doc.html [Viewed October 18, 2004].
- [MS05] Paul E. McKenney and Dipankar Sarma. Towards hard realtime response from the Linux kernel on SMP hardware. In *linux.conf.au 2005*, Canberra, Australia, April 2005. Available: <http://www.rdrop.com/users/paulmck/RCU/realtimeRCU.2005.04.23a.pdf> [Viewed May 13, 2005].
- [MS08] MySQL AB and Sun Microsystems. MySQL Downloads, November 2008. Available: <http://dev.mysql.com/downloads/> [Viewed November 26, 2008].
- [MS09] Paul E. McKenney and Raul Silvera. Example power implementation for c/c++ memory model, February 2009. Available: <http://www.rdrop.com/users/paulmck/scalability/paper/N2745r.2009.02.27a.html> [Viewed: April 5, 2009].

- [MS12] Alexander Matveev and Nir Shavit. Towards a fully pessimistic STM model. In *TRANSACT 2012*, San Jose, CA, USA, February 2012. ACM SIGPLAN.
- [MS14] Paul E. McKenney and Alan Stern. Axiomatic validation of memory barriers and atomic instructions, August 2014. <http://lwn.net/Articles/608550/>.
- [MSA⁺02] Paul E. McKenney, Dipankar Sarma, Andrea Arcangeli, Andi Kleen, Orran Krieger, and Rusty Russell. Read-copy update. In *Ottawa Linux Symposium*, pages 338–367, June 2002. Available: http://www.linux.org.uk/~ajh/ols2002_proceedings.pdf.gz [Viewed June 23, 2004].
- [MSFM15] Alexander Matveev, Nir Shavit, Pascal Felber, and Patrick Marlier. Read-log-update: A lightweight synchronization mechanism for concurrent programming. In *Proceedings of the 25th Symposium on Operating Systems Principles*, SOSP ’15, pages 168–183, Monterey, California, 2015. ACM.
- [MSK01] Paul E. McKenney, Jack Slingwine, and Phil Krueger. Experience with an efficient parallel kernel memory allocator. *Software – Practice and Experience*, 31(3):235–257, March 2001.
- [MSM05] Timothy G. Mattson, Beverly A. Sanders, and Berna L. Massingill. *Patterns for Parallel Programming*. Addison Wesley, Boston, MA, USA, 2005.
- [MSMB06] Paul E. McKenney, Dipankar Sarma, Ingo Molnar, and Suparna Bhattacharya. Extending RCU for realtime and embedded workloads. In *Ottawa Linux Symposium*, pages v2 123–138, July 2006. Available: http://www.linuxsymposium.org/2006/view_abstract.php?content_key=184 <http://www.rdrop.com/users/paulmck/RCU/OLSRtrCU.2006.08.11a.pdf> [Viewed January 1, 2007].
- [MSS04] Paul E. McKenney, Dipankar Sarma, and Maneesh Soni. Scaling dcache with RCU. *Linux Journal*, 1(118):38–46, January 2004.
- [MSS12] Luc Maranget, Susmit Sarkar, and Peter Sewell. A tutorial introduction to the ARM and POWER relaxed memory models, October 2012. <https://www.cl.cam.ac.uk/~pes20/ppc-supplemental/test7.pdf>.
- [MT01] Jose F. Martinez and Josep Torrellas. Speculative locks for concurrent execution of critical sections in shared-memory multiprocessors. In *Workshop on Memory Performance Issues, International Symposium on Computer Architecture*, Gothenburg, Sweden, June 2001. Available: http://iacoma.cs.uiuc.edu/iacoma-papers/wmpi_locks.pdf [Viewed June 23, 2004].
- [MT02] Jose F. Martinez and Josep Torrellas. Speculative synchronization: Applying thread-level speculation to explicitly parallel applications. In *Proceedings of the 10th International Conference on Architectural Support for Programming Languages and Operating Systems*, pages 18–29, San Jose, CA, October 2002.
- [Mud01] Trevor Mudge. POWER: A first-class architectural design constraint. *IEEE Computer*, 34(4):52–58, April 2001.
- [Mus04] Museum Victoria Australia. CSIRAC: Australia’s first computer, 2004. URL: <http://museumvictoria.com.au/csirac/>.
- [MW07] Paul E. McKenney and Jonathan Walpole. What is RCU, fundamentally?, December 2007. Available: <http://lwn.net/Articles/262464/> [Viewed December 27, 2007].

- [MW08] Paul E. McKenney and Jonathan Walpole. Introducing technology into the Linux kernel: a case study. *SIGOPS Oper. Syst. Rev.*, 42(5):4–17, 2008.
- [MWB⁺17] Paul E. McKenney, Michael Wong, Hans Boehm, Jens Maurer, Jeffrey Yasskin, and JF Bastien. P0190R4: Proposal for new `memory_order_consume` definition, July 2017. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2017/p0190r4.pdf>.
- [MWPF18a] Paul E. McKenney, Ulrich Weigand, Andrea Parri, and Boqun Feng. Linux-kernel memory model, September 2018. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2018/p0124r6.html>.
- [MWPF18b] Paul E. McKenney, Ulrich Weigand, Andrea Parri, and Boqun Feng. Linux-kernel memory model, April 2018. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2018/p0124r5.html>.
- [Mye79] Glenford J. Myers. *The Art of Software Testing*. Wiley, 1979.
- [Nes06a] Oleg Nesterov. Re: [patch] cpufreq: mark `cpufreq_tsc()` as `core_initcall_sync`, November 2006. Available: <http://lkml.org/lkml/2006/11/19/69> [Viewed May 28, 2007].
- [Nes06b] Oleg Nesterov. Re: [rfc, patch 1/2] qrcu: "quick" srcu implementation, November 2006. Available: <http://lkml.org/lkml/2006/11/29/330> [Viewed November 26, 2008].
- [NVi17a] NVidia. Accelerated computing — training, January 2017. <https://developer.nvidia.com/accelerated-computing-training>.
- [NVi17b] NVidia. Existing university courses, January 2017. <https://developer.nvidia.com/educators/existing-courses>.
- [ON06] Robert Olsson and Stefan Nilsson. TRASH: A dynamic LC-trie and hash data structure, August 2006. <http://www.nada.kth.se/~snilsson/publications/TRASH/trash.pdf>.
- [ONH⁺96] Kunle Olukotun, Basem A. Nayfeh, Lance Hammond, Ken Wilson, and Kunyung Chang. The case for a single-chip multiprocessor. In *ASPLOS VII*, Cambridge, MA, USA, October 1996.
- [Ope97] Open Group. The single UNIX specification, version 2: Threads, 1997. Available: <http://www.opengroup.org/onlinepubs/007908799/xsh/threads.html> [Viewed September 19, 2008].
- [PAB⁺95] Calton Pu, Tito Autrey, Andrew Black, Charles Consel, Crispin Cowan, Jon Inouye, Lakshmi Kethana, Jonathan Walpole, and Ke Zhang. Optimistic incremental specialization: Streamlining a commercial operating system. In *15th ACM Symposium on Operating Systems Principles (SOSP'95)*, pages 314–321, Copper Mountain, CO, December 1995.
- [Pat10] David Patterson. The trouble with multicore. *IEEE Spectrum*, 2010:28–32, 52–53, July 2010.
- [Pen18] Roman Penyaev. [PATCH v2 01/26] introduce `list_next_or_null_rr_rcu()`, May 2018. <http://lkml.kernel.org/r/20180518130413.16997-2-roman.penzaev@profitbricks.com>.
- [Pet06] Jeremy Peters. From reuters, automatic trading linked to news events, December 2006. URL: <http://www.nytimes.com/2006/12/11/technology/11reuters.html?ei=5088&en=e5e9416415a9eeb2&ex=1323493200>.
- ..

- [Pig06] Nick Piggin. [patch 3/3] radix-tree: RCU lockless readside, June 2006. Available: <http://lkml.org/lkml/2006/6/20/238> [Viewed March 25, 2008].
- [Pik17] Fedor G. Pikus. Read, copy, update... Then what?, September 2017. <https://www.youtube.com/watch?v=rxQ5K91o034>.
- [Pok16] Michael Pokorny. The deadlock empire, February 2016. <https://deadlockempire.github.io/>.
- [Pos08] PostgreSQL Global Development Group. PostgreSQL, November 2008. Available: <http://www.postgresql.org/> [Viewed November 26, 2008].
- [Pug90] William Pugh. Concurrent maintenance of skip lists. Technical Report CS-TR-2222.1, Institute of Advanced Computer Science Studies, Department of Computer Science, University of Maryland, College Park, Maryland, June 1990.
- [Pug00] William Pugh. Reordering on an Alpha processor, 2000. Available: <https://www.cs.umd.edu/~pugh/java/memoryModel/AlphaReordering.html> [Viewed: June 23, 2004].
- [Pul00] Geoffrey K. Pullum. How Dr. Seuss would prove the halting problem undecidable. *Mathematics Magazine*, 73(4):319–320, 2000. <http://www.lel.ed.ac.uk/~gpullum/loopsnoop.html>.
- [PW07] Donald E. Porter and Emmett Witchel. Lessons from large transactional systems, December 2007. Personal communication <20071214220521.GA5721@olive-green.cs.utexas.edu>.
- [Ray99] Eric S. Raymond. *The Cathedral and the Bazaar: Musings on Linux and Open Source by an Accidental Revolutionary*. O'Reilly, 1999.
- [RC15] Pedro Ramalhete and Andreia Correia. Poor man's rcu, August 2015. <https://github.com/pramalhe/ConcurrencyFreaks/blob/master/papers/poormanurcu-2015.pdf>.
- [RD12] Ravi Rajwar and Martin Dixon. Intel transactional synchronization extensions, September 2012. Intel Developer Forum (IDF) 2012 ARCS004.
- [Reg10] John Regehr. A guide to undefined behavior in c and c++, part 1, July 2010. <http://blog.regehr.org/archives/213>.
- [Rei07] James Reinders. *Intel Threading Building Blocks*. O'Reilly, Sebastopol, CA, USA, 2007.
- [RG02] Ravi Rajwar and James R. Goodman. Transactional lock-free execution of lock-based programs. In *Proceedings of the 10th International Conference on Architectural Support for Programming Languages and Operating Systems*, pages 5–17, Austin, TX, October 2002.
- [RH02] Zoran Radović and Erik Hagersten. Efficient synchronization for nonuniform communication architectures. In *Proceedings of the 2002 ACM/IEEE Conference on Supercomputing*, pages 1–13, Baltimore, Maryland, USA, November 2002. The Institute of Electrical and Electronics Engineers, Inc.
- [RH03] Zoran Radović and Erik Hagersten. Hierarchical backoff locks for nonuniform communication architectures. In *Proceedings of the Ninth International Symposium on High Performance Computer Architecture (HPCA-9)*, pages 241–252, Anaheim, California, USA, February 2003.

- [RH17] Geoff Romer and Andrew Hunter. An RAII interface for deferred reclamation, February 2017. Available: <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2017/p0561r0.html> [Viewed May 29, 2017].
- [RHP⁺07] Christopher J. Rossbach, Owen S. Hofmann, Donald E. Porter, Hany E. Ramadan, Aditya Bhandari, and Emmett Witchel. TxLinux: Using and managing hardware transactional memory in an operating system. In *SOSP'07: Twenty-First ACM Symposium on Operating Systems Principles*, Stevenson, WA, USA, October 2007. ACM SIGOPS. Available: <http://www.sosp2007.org/papers/sosp056-rossbach.pdf> [Viewed October 21, 2007].
- [Ros06] Steven Rostedt. Lightweight PI-futexes, June 2006. Available: <http://lxr.linux.no/#linux+v2.6.39/Documentation/pi-futex.txt> [Viewed May 22, 2011].
- [Ros10a] Steven Rostedt. tracing: Harry Potter and the Deathly Macros, December 2010. Available: <http://lwn.net/Articles/418710/> [Viewed: August 28, 2011].
- [Ros10b] Steven Rostedt. Using the TRACE_EVENT() macro (part 1), March 2010. Available: <http://lwn.net/Articles/379903/> [Viewed: August 28, 2011].
- [Ros10c] Steven Rostedt. Using the TRACE_EVENT() macro (part 2), March 2010. Available: <http://lwn.net/Articles/381064/> [Viewed: August 28, 2011].
- [Ros10d] Steven Rostedt. Using the TRACE_EVENT() macro (part 3), April 2010. Available: <http://lwn.net/Articles/383362/> [Viewed: August 28, 2011].
- [Ros11] Steven Rostedt. lockdep: How to read its cryptic output, September 2011. <http://www.linuxplumbersconf.org/2011/ocw/sessions/153>.
- [Roy17] Lance Roy. rcutorture: Add CBMC-based formal verification for SRCU, January 2017. URL: <https://www.spinics.net/lists/kernel/msg2421833.html>.
- [RSB⁺97] Rajeev Rastogi, S. Seshadri, Philip Bohannon, Dennis W. Leinbaugh, Abraham Silberschatz, and S. Sudarshan. Logical and physical versioning in main memory databases. In *Proceedings of the 23rd International Conference on Very Large Data Bases*, VLDB '97, pages 86–95, San Francisco, CA, USA, August 1997. Morgan Kaufmann Publishers Inc.
- [RTY⁺87] Richard Rashid, Avadis Tevanian, Michael Young, David Golub, Robert Baron, David Black, William Bolosky, and Jonathan Chew. Machine-independent virtual memory management for paged uniprocessor and multiprocessor architectures. In *2nd Symposium on Architectural Support for Programming Languages and Operating Systems*, pages 31–39, Palo Alto, CA, October 1987. Association for Computing Machinery. Available: <http://www.cse.ucsc.edu/~randal/221/rashid-machvm.pdf> [Viewed February 17, 2005].
- [Rus00a] Rusty Russell. Re: modular net drivers, June 2000. Available: <http://oss.sgi.com/projects/netdev/archive/2000-06/msg00250.html> [Viewed April 10, 2006].
- [Rus00b] Rusty Russell. Re: modular net drivers, June 2000. Available: <http://oss.sgi.com/projects/netdev/archive/2000-06/msg00254.html> [Viewed April 10, 2006].

- [Rus03] Rusty Russell. Hanging out with smart people: or... things I learned being a kernel monkey, July 2003. 2003 Ottawa Linux Symposium Keynote <http://ozlabs.org/~rusty/ols-2003-keynote/ols-keynote-2003.html>.
- [Rut17] Mark Rutland. compiler.h: Remove ACCESS_ONCE(), November 2017. Git commit: <https://git.kernel.org/pub/scm/linux/kernel/git/torvalds/linux.git/commit/?id=b899a850431e>.
- [SAH⁺03] Craig A. N. Soules, Jonathan Appavoo, Kevin Hui, Dilma Da Silva, Gregory R. Ganger, Orran Krieger, Michael Stumm, Robert W. Wisniewski, Marc Auslander, Michal Ostrowski, Bryan Rosenburg, and Jimi Xenidis. System support for online reconfiguration. In *Proceedings of the 2003 USENIX Annual Technical Conference*, pages 141–154, San Antonio, Texas, USA, June 2003. USENIX Association.
- [SATG⁺09] Tatiana Shpeisman, Ali-Reza Adl-Tabatabai, Robert Geva, Yang Ni, and Adam Welc. Towards transactional memory semantics for c++. In *SPAA '09: Proceedings of the twenty-first annual symposium on Parallelism in algorithms and architectures*, pages 49–58, Calgary, AB, Canada, 2009. ACM.
- [Sch35] E. Schrödinger. Die gegenwärtige Situation in der Quantenmechanik. *Naturwissenschaften*, 23:807–812; 823–828; 844–949, November 1935. English translation: <http://www.tuhh.de/rzt/rzt/it/QM/cat.html>.
- [Sch94] Curt Schimmel. *UNIX Systems for Modern Architectures: Symmetric Multiprocessing and Caching for Kernel Programmers*. Addison-Wesley Longman Publishing Co., Inc., Boston, MA, USA, 1994.
- [Sco06] Michael Scott. *Programming Language Pragmatics*. Morgan Kaufmann, Burlington, MA, USA, 2006.
- [Sco13] Michael L. Scott. *Shared-Memory Synchronization*. Morgan & Claypool, San Rafael, CA, USA, 2013.
- [Seq88] Sequent Computer Systems, Inc. *Guide to Parallel Programming*, 1988.
- [Sew] Peter Sewell. The semantics of multiprocessor programs. Available: <http://www.cl.cam.ac.uk/~pes20/weakmemory/> [Viewed: June 7, 2010].
- [Sey12] Justin Seyster. *Runtime Verification of Kernel-Level Concurrency Using Compiler-Based Instrumentation*. PhD thesis, Stony Brook University, 2012.
- [SF95] Janice M. Stone and Robert P. Fitzgerald. Storage in the PowerPC. *IEEE Micro*, 15(2):50–58, April 1995.
- [Sha11] Nir Shavit. Data structures in the multicore age. *Commun. ACM*, 54(3):76–84, March 2011.
- [She06] Gautham R. Shenoy. [patch 4/5] lock_cpu_hotplug: Redesign - lightweight implementation of lock_cpu_hotplug, October 2006. Available: <http://lkml.org/lkml/2006/10/26/73> [Viewed January 26, 2009].
- [SHW11] Daniel J. Sorin, Mark D. Hill, and David A. Wood. *A Primer on Memory Consistency and Cache Coherence*. Synthesis Lectures on Computer Architecture. Morgan & Claypool, 2011.
- [SM95] John D. Slingwine and Paul E. McKenney. Apparatus and method for achieving reduced overhead mutual exclusion and maintaining coherency in a multiprocessor system utilizing execution history and thread monitoring. Technical Report US Patent 5,442,758, US Patent and Trademark Office, Washington, DC, August 1995.

- [SM97] John D. Slingwine and Paul E. McKenney. Method for maintaining data coherency using thread activity summaries in a multicomputer system. Technical Report US Patent 5,608,893, US Patent and Trademark Office, Washington, DC, March 1997.
- [SM98] John D. Slingwine and Paul E. McKenney. Apparatus and method for achieving reduced overhead mutual exclusion and maintaining coherency in a multiprocessor system utilizing execution history and thread monitoring. Technical Report US Patent 5,727,209, US Patent and Trademark Office, Washington, DC, March 1998.
- [SM13] Thomas Sewell and Toby Murray. Above and beyond: seL4 noninterference and binary verification, May 2013. <https://cps-vo.org/node/7706>.
- [Smi15] Richard Smith. Working draft, standard for programming language C++, May 2015. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2015/n4527.pdf>.
- [Smi18] Richard Smith. Working draft, standard for programming language C++, July 2018. <http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2018/n4762.pdf>.
- [SMS08] Michael Spear, Maged Michael, and Michael Scott. Inevitability mechanisms for software transactional memory. In *3rd ACM SIGPLAN Workshop on Transactional Computing*, Salt Lake City, Utah, February 2008. ACM. Available: http://www.cs.rochester.edu/u/scott/papers/2008_TRANSACT_inevitability.pdf [Viewed January 10, 2009].
- [SNGK17] Dimitrios Siakavaras, Konstantinos Nikas, Georgios Goumas, and Nectarios Koziris. Combining htm and rcu to implement highly efficient balanced binary search trees. In *12th ACM SIGPLAN Workshop on Transactional Computing*, Austin, TX, USA, February 2017.
- [SPA94] SPARC International. *The SPARC Architecture Manual*, 1994.
- [Spi77] Keith R. Spitz. Tell which is which and you'll be rich, 1977. Inscription on wall of dungeon.
- [Spr01] Manfred Spraul. Re: RFC: patch to allow lock-free traversal of lists with insertion, October 2001. URL: <http://lkml.iu.edu/hypermail/linux/kernel/0110.1/0410.html>.
- [Spr08a] Manfred Spraul. Re: [RFC, PATCH] v4 scalable classic RCU implementation, September 2008. Available: <http://lkml.org/lkml/2008/9/6/86> [Viewed December 8, 2008].
- [Spr08b] Manfred Spraul. [RFC, PATCH] state machine based rcu, August 2008. Available: <http://lkml.org/lkml/2008/8/21/336> [Viewed December 8, 2008].
- [SR84] Z. Segall and L. Rudolf. Dynamic decentralized cache schemes for MIMD parallel processors. In *11th Annual International Symposium on Computer Architecture*, pages 340–347, June 1984.
- [SRK⁺11] Justin Seyster, Prabakar Radhakrishnan, Samriti Katoch, Abhinav Duggal, Scott D. Stoller, and Erez Zadok. Redflag: a framework for analysis of kernel-level concurrency. In *Proceedings of the 11th international conference on Algorithms and architectures for parallel processing - Volume Part I*, ICA3PP'11, pages 66–79, Melbourne, Australia, 2011. Springer-Verlag.

- [SRL90a] L. Sha, R. Rajkumar, and J. P. Lehoczky. Priority inheritance protocols: An approach to real-time synchronization. *IEEE Trans. Comput.*, 39(9):1175–1185, 1990.
- [SRL90b] Lui Sha, Ragunathan Rajkumar, and John P. Lehoczky. Priority inheritance protocols: An approach to real-time synchronization. *IEEE Transactions on Computers*, 39(9):1175–1185, 1990.
- [SS94] Duane Szafron and Jonathan Schaeffer. Experimentally assessing the usability of parallel programming systems. In *IFIP WG10.3 Programming Environments for Massively Parallel Distributed Systems*, pages 19.1–19.7, Monte Verita, Ascona, Switzerland, 1994.
- [SS06] Ori Shalev and Nir Shavit. Split-ordered lists: Lock-free extensible hash tables. *J. ACM*, 53(3):379–405, May 2006.
- [SSA⁺11] Susmit Sarkar, Peter Sewell, Jade Alglave, Luc Maranget, and Derek Williams. POWER and ARM litmus tests, 2011. <https://www.cl.cam.ac.uk/~pes20/ppc-supplemental/test6.pdf>.
- [SSHT93] Janice S. Stone, Harold S. Stone, Philip Heidelberger, and John Turek. Multiple reservations and the Oklahoma update. *IEEE Parallel and Distributed Technology Systems and Applications*, 1(4):58–71, November 1993.
- [SSRB00] Douglas C. Schmidt, Michael Stal, Hans Rohnert, and Frank Buschmann. *Pattern-Oriented Software Architecture Volume 2: Patterns for Concurrent and Networked Objects*. Wiley, Chichester, West Sussex, England, 2000.
- [SSVM02] S. Swaminathan, John Stultz, Jack Vogel, and Paul E. McKenney. Fairlocks – a high performance fair locking scheme. In *Proceedings of the 14th IASTED International Conference on Parallel and Distributed Computing and Systems*, pages 246–251, Cambridge, MA, USA, November 2002.
- [ST87] William E. Snaman and David W. Thiel. The VAX/VMS distributed lock manager. *Digital Technical Journal*, 5:29–44, September 1987.
- [ST95] Nir Shavit and Dan Touitou. Software transactional memory. In *Proceedings of the 14th Annual ACM Symposium on Principles of Distributed Computing*, pages 204–213, Ottawa, Ontario, Canada, August 1995.
- [Ste92] W. Richard Stevens. *Advanced Programming in the UNIX Environment*. Addison Wesley, 1992.
- [Sut08] Herb Sutter. Effective concurrency, 2008. Series in Dr. Dobbs Journal.
- [Sut13] Adrian Sutton. Concurrent programming with the Disruptor, January 2013. Presentation at Linux.conf.au 2013, URL: https://www.youtube.com/watch?v=ItptT_vmRHyl.
- [SW95] Richard L. Sites and Richard T. Witek. *Alpha AXP Architecture*. Digital Press, second edition, 1995.
- [SZJ12] KC Sivaramakrishnan, Lukasz Ziarek, and Suresh Jagannathan. Eliminating read barriers through procrastination and cleanliness. In *Proceedings of the 2012 International Symposium on Memory Management, ISMM ’12*, pages 49–60, Beijing, China, 2012. ACM.
- [Tal07] Nassim Nicholas Taleb. *The Black Swan*. Random House, 2007.

- [TDV15] Joseph Tassarotti, Derek Dreyer, and Victor Vafeiadis. Verifying read-copy-update in a logic for weak memory. In *Proceedings of the 2015 Proceedings of the 36th annual ACM SIGPLAN conference on Programming Language Design and Implementation*, PLDI '15, pages 110–120, New York, NY, USA, June 2015. ACM.
- [The08] The Open MPI Project. Open MPI, November 2008. Available: <http://www.open-mpi.org/software/> [Viewed November 26, 2008].
- [The11] The Valgrind Developers. Valgrind, November 2011. <http://www.valgrind.org/>.
- [The12] The OProfile Developers. Oprofile, April 2012. <http://oprofile.sourceforge.net>.
- [TMW11] Josh Triplett, Paul E. McKenney, and Jonathan Walpole. Resizable, scalable, concurrent hash tables via relativistic programming. In *Proceedings of the 2011 USENIX Annual Technical Conference*, pages 145–158, Portland, OR USA, June 2011. The USENIX Association.
- [Tor01] Linus Torvalds. Re: [Lse-tech] Re: RFC: patch to allow lock-free traversal of lists with insertion, October 2001. URL: <http://lkml.org/lkml/2001/10/13/105>, <http://lkml.org/lkml/2001/10/13/82>.
- [Tor03a] Linus Torvalds. Linux 2.5.69, May 2003. Available: <http://marc.theaimsgroup.com/?l=linux-kernel&m=105209603501299&w=2> [Viewed June 23, 2004].
- [Tor03b] Linus Torvalds. Linux 2.5.70, May 2003. Available: <http://marc.theaimsgroup.com/?l=linux-kernel&m=105400162802746&w=2> [Viewed June 23, 2004].
- [Tor03c] Linus Torvalds. Linux 2.6, August 2003. Available: <ftp://kernel.org/pub/linux/kernel/v2.6> [Viewed June 23, 2004].
- [Tor08] Linus Torvalds. Move ACCESS_ONCE() to <linux/compiler.h>, May 2008. Git commit: <https://git.kernel.org/pub/scm/linux/kernel/git/torvalds/linux.git/commit/?id=9c3cdc1f83a6>.
- [Tra01] Transaction Processing Performance Council. TPC, 2001. Available: [http://www\(tpc.org](http://www(tpc.org)) [Viewed December 7, 2008].
- [Tre86] R. K. Treiber. Systems programming: Coping with parallelism, April 1986. RJ 5118.
- [Tri12] Josh Triplett. *Relativistic Causal Ordering: A Memory Model for Scalable Concurrent Data Structures*. PhD thesis, Portland State University, 2012.
- [TS93] Hiroaki Takada and Ken Sakamura. A bounded spin lock algorithm with preemption. Technical Report 93-02, University of Tokyo, Tokyo, Japan, 1993.
- [TS95] H. Takada and K. Sakamura. Real-time scalability of nested spin locks. In *Proceedings of the 2nd International Workshop on Real-Time Computing Systems and Applications*, RTCSA '95, pages 160–167, Tokyo, Japan, 1995. IEEE Computer Society.
- [Tur37] Alan M. Turing. On computable numbers, with an application to the entscheidungsproblem. In *Proceedings of the London Mathematical Society*, volume 42 of 2, pages 230–265, 1937.

- [TZK⁺13] Stephen Tu, Wenting Zheng, Eddie Kohler, Barbara Liskov, and Samuel Madden. Speedy transactions in multicore in-memory databases. In *Proceedings of the Twenty-Fourth ACM Symposium on Operating Systems Principles*, SOSP '13, pages 18–32, Farmington, Pennsylvania, 2013. ACM.
- [Ung11] David Ungar. Everything you know (about parallel programming) is wrong!: A wild screed about the future. In *Dynamic Languages Symposium 2011*, Portland, OR, USA, October 2011. Invited talk presentation.
- [Uni08a] University of California, Berkeley. BOINC: compute for science, October 2008. Available: <http://boinc.berkeley.edu/> [Viewed January 31, 2008].
- [Uni08b] University of California, Berkeley. SETI@HOME, December 2008. Available: <http://setiathome.berkeley.edu/> [Viewed January 31, 2008].
- [Uni10] University of Maryland. Parallel maze solving, November 2010. <http://www.cs.umd.edu/class/fall2010/cmsc433/p3/>.
- [Val95] John D. Valois. Lock-free linked lists using compare-and-swap. In *Proceedings of the Fourteenth Annual ACM Symposium on Principles of Distributed Computing*, PODC '95, pages 214–222, Ottawa, Ontario, Canada, 1995. ACM.
- [VBC⁺15] Viktor Vafeiadis, Thibaut Balabonski, Soham Chakraborty, Robin Morisset, and Francesco Zappa Nardelli. Common compiler optimisations are invalid in the c11 memory model and what we can do about it. *SIGPLAN Not.*, 50(1):209–220, January 2015.
- [VGS08] Haris Volos, Neelam Goyal, and Michael M. Swift. Pathological interaction of locks with transactional memory. In *3rd ACM SIGPLAN Workshop on Transactional Computing*, Salt Lake City, Utah, USA, February 2008. ACM. Available: http://www.cs.wisc.edu/multifacet/papers/transact08_txlock.pdf [Viewed September 7, 2009].
- [Vog09] Werner Vogels. Eventually consistent. *Commun. ACM*, 52:40–44, January 2009.
- [Š11] Jaroslav Ševčík. Safe optimisations for shared-memory concurrent programs. *SIGPLAN Not.*, 46(6):306–316, June 2011.
- [Wei63] J. Weizenbaum. Symmetric list processor. *Commun. ACM*, 6(9):524–536, September 1963.
- [Wei12] Frédéric Weisbecker. Interruption timer périodique, 2012. http://www.dailymotion.com/video/xtxtew_interruption-timer-periodique-frederic-weisbecker-kernel-recipes-12_tech.
- [Wei13] Stewart Weiss. Unix lecture notes, May 2013. Available: http://www.compsci.hunter.cuny.edu/~sweiss/course_materials/unix_lecture_notes/ [Viewed April 8, 2014].
- [Wik08] Wikipedia. Zilog Z80, 2008. Available: <http://en.wikipedia.org/wiki/Z80> [Viewed: December 7, 2008].
- [Wik12] Wikipedia. Labyrinth, January 2012. <http://en.wikipedia.org/wiki/Labyrinth>.
- [Wil12] Anthony Williams. *C++ Concurrency in Action: Practical Multithreading*. Manning, Shelter Island, NY, USA, 2012.

- [WKS94] Robert W. Wisniewski, Leonidas Kontothanassis, and Michael L. Scott. Scalable spin locks for multiprogrammed systems. In *8th IEEE Int'l. Parallel Processing Symposium*, Cancun, Mexico, April 1994. The Institute of Electrical and Electronics Engineers, Inc.
- [WTS96] Cai-Dong Wang, Hiroaki Takada, and Ken Sakamura. Priority inheritance spin locks for multiprocessor real-time systems. In *Proceedings of the 2nd International Symposium on Parallel Architectures, Algorithms, and Networks*, ISPAN '96, pages 70–76, Beijing, China, 1996. IEEE Computer Society.
- [xen14] xenomai.org. Xenomai, December 2014. URL: <http://xenomai.org/>.
- [Xu10] Herbert Xu. bridge: Add core IGMP snooping support, February 2010. Available: <http://marc.info/?t=12671985540006&r=1&w=2> [Viewed March 20, 2011].
- [YHLR13] Richard M. Yoo, Christopher J. Hughes, Konrad Lai, and Ravi Rajwar. Performance evaluation of Intel® Transactional Synchronization Extensions for high-performance computing. In *Proceedings of SC13: International Conference for High Performance Computing, Networking, Storage and Analysis*, SC '13, pages 19:1–19:11, Denver, Colorado, 2013. ACM.
- [Yod04a] Victor Yodaiken. Against priority inheritance, September 2004. Available: <http://www.yodaiken.com/papers/inherit.pdf> [Viewed May 26, 2007].
- [Yod04b] Victor Yodaiken. Temporal inventory and real-time synchronization in RTLinuxPro, September 2004. URL: <http://www.yodaiken.com/papers/sync.pdf>.
- [Zel11] Cyril Zeller. CUDA C/C++ basics: Supercomputing 2011 tutorial, November 2011. <https://www.nvidia.com/docs/I0/116711/sc11-cuda-c-basics.pdf>.
- [Zha89] Lixia Zhang. *A New Architecture for Packet Switching Network Protocols*. PhD thesis, Massachusetts Institute of Technology, July 1989.
- [Zij14] Peter Zijlstra. Another go at speculative page faults, October 2014. <https://lkml.org/lkml/2014/10/20/620>.

If I have seen further it is by standing on the shoulders of giants.

Isaac Newton, modernized

Appendix I

Credits

I.1 L^AT_EX Advisor

With this release, Akira Yokosawa officially takes on the role of L^AT_EX advisor, a capacity he has been acting in for quite some time. This role perhaps most notably includes the care and feeding of the style guide laid out in Appendix F. This work includes table layout, listings, fonts, rendering of math, acronyms, bibliography formatting, and epigraphs. Akira also perfected the cross-referencing of quick quizzes, allowing easy and exact navigation between quick quizzes and their answers.

This role also includes the build system, which Akira has optimized and made much more user-friendly. His enhancements have included automating response to bibliography changes and automatically determining which source files are present.

I.2 Reviewers

- Alan Stern (Chapter 15).
- Andy Whitcroft (Section 9.5.2, Section 9.5.4).
- Artem Bityutskiy (Chapter 15, Appendix C).
- Dave Keck (Appendix C).
- David S. Horner (Section 12.1.5).
- Gautham Shenoy (Section 9.5.2, Section 9.5.4).
- “jarkao2”, AKA LWN guest #41960 (Section 9.5.4).
- Jonathan Walpole (Section 9.5.4).
- Josh Triplett (Chapter 12).
- Michael Factor (Section 17.2).
- Mike Fulton (Section 9.5.2).

- Peter Zijlstra (Section 9.5.3).
- Richard Woodruff (Appendix C).
- Suparna Bhattacharya (Chapter 12).
- Vara Prasad (Section 12.1.5).

Reviewers whose feedback took the extremely welcome form of a patch are credited in the git logs.

I.3 Machine Owners

A great debt of thanks goes to Martin Bligh, who originated the Advanced Build and Test (ABAT) system at IBM’s Linux Technology Center, as well as to Andy Whitcroft, Dustin Kirkland, and many others who extended this system.

Many thanks go also to a great number of machine owners: Andrew Theurer, Andy Whitcroft, Anton Blanchard, Chris McDermott, Cody Schaefer, Darrick Wong, David “Shaggy” Kleikamp, Jon M. Tollefson, Jose R. Santos, Marvin Heffler, Nathan Lynch, Nishanth Aravamudan, Tim Pepper, and Tony Breeds.

I.4 Original Publications

1. Section 2.4 (“What Makes Parallel Programming Hard?”) on page 13 originally appeared in a Portland State University Technical Report [MGM⁰⁹].
2. Section 6.5 (“Retrofitted Parallelism Considered Grossly Sub-Optimal”) on page 87 originally appeared in 4th USENIX Workshop on Hot Topics on Parallelism [McK12b].
3. Section 9.5.2 (“RCU Fundamentals”) on page 129 originally appeared in Linux Weekly News [MW07].

4. Section 9.5.3 (“RCU Usage”) on page 136 originally appeared in Linux Weekly News [McK08c].
5. Section 9.5.4 (“RCU Linux-Kernel API”) on page 146 originally appeared in Linux Weekly News [McK08b].
6. Section 9.5.5 (“RCU Related Work”) on page 150 originally appeared in Linux Weekly News [McK14e].
7. Section 9.5.5 (“RCU Related Work”) on page 150 originally appeared in Linux Weekly News [MP15a].
8. Chapter 12 (“Formal Verification”) on page 199 originally appeared in Linux Weekly News [McK07g, MR08, McK11c].
9. Section 12.3 (“Axiomatic Approaches”) on page 228 originally appeared in Linux Weekly News [MS14].
10. Chapter 15 (“Advanced Synchronization: Memory Ordering”) on page 271 originally appeared in the Linux kernel [HMDZ06].
11. Chapter 15 (“Advanced Synchronization: Memory Ordering”) on page 271 originally appeared in Linux Weekly News [AMM⁺17a, AMM⁺17b].
12. Section 15.3.2 (“Address- and Data-Dependency Difficulties”) on page 293 originally appeared in the Linux kernel [McK14c].
13. Section 15.4 (“Memory-Barrier Instructions For Specific CPUs”) on page 294 originally appeared in Linux Journal [McK05a, McK05b].
14. Appendix D.1 (“Sleepable RCU Implementation”) on page 375 originally appeared in Linux Weekly News [McK06b].
15. Appendix D.2 (“Hierarchical RCU Overview”) on page 381 originally appeared in Linux Weekly News [McK08a].
16. Appendix D.4 (“Preemptible RCU”) on page 423 originally appeared in Linux Weekly News [McK07a].
3. Figure 3.3 (p 18) by Melissa Broussard.
4. Figure 3.4 (p 19) by Melissa Broussard.
5. Figure 3.5 (p 19) by Melissa Broussard.
6. Figure 3.6 (p 20) by Melissa Broussard.
7. Figure 3.7 (p 20) by Melissa Broussard.
8. Figure 3.8 (p 20) by Melissa Broussard.
9. Figure 3.10 (p 23) by Melissa Broussard.
10. Figure 5.3 (p 47) by Melissa Broussard.
11. Figure 6.1 (p 67) by Korniliос Kourtis.
12. Figure 6.2 (p 68) by Melissa Broussard.
13. Figure 6.3 (p 68) by Korniliос Kourtis.
14. Figure 6.4 (p 71) by Korniliос Kourtis.
15. Figure 6.13 (p 79) by Melissa Broussard.
16. Figure 6.14 (p 80) by Melissa Broussard.
17. Figure 6.15 (p 80) by Melissa Broussard.
18. Figure 7.1 (p 96) by Melissa Broussard.
19. Figure 7.2 (p 96) by Melissa Broussard.
20. Figure 10.11 (p 164) by Melissa Broussard.
21. Figure 10.12 (p 165) by Melissa Broussard.
22. Figure 11.1 (p 179) by Melissa Broussard.
23. Figure 11.2 (p 179) by Melissa Broussard.
24. Figure 11.3 (p 185) by Melissa Broussard.
25. Figure 11.6 (p 196) by Melissa Broussard.
26. Figure 14.1 (p 250) by Melissa Broussard.
27. Figure 14.2 (p 251) by Melissa Broussard.
28. Figure 14.3 (p 252) by Melissa Broussard.
29. Figure 14.10 (p 260) by Melissa Broussard.
30. Figure 14.11 (p 260) by Melissa Broussard.
31. Figure 14.14 (p 262) by Melissa Broussard.
32. Figure 14.15 (p 269) by Sarah McKenney.

I.5 Figure Credits

1. Figure 3.1 (p 17) by Melissa Broussard.
2. Figure 3.2 (p 18) by Melissa Broussard.

33. Figure 14.16 (p 269) by Sarah McKenney.
34. Figure 15.2 (p 272) by Melissa Broussard.
35. Figure 15.5 (p 279) by Akira Yokosawa.
36. Figure 15.14 (p 298) by Melissa Brossard.
37. Figure 16.2 (p 307) by Melissa Broussard.
38. Figure 17.1 (p 309) by Melissa Broussard.
39. Figure 17.2 (p 310) by Melissa Broussard.
40. Figure 17.3 (p 310) by Melissa Broussard.
41. Figure 17.4 (p 311) by Melissa Broussard.
42. Figure 17.8 (p 322) by Melissa Broussard.
43. Figure 17.9 (p 323) by Melissa Broussard.
44. Figure 17.10 (p 323) by Melissa Broussard.
45. Figure 17.11 (p 324) by Melissa Broussard.
46. Figure A.2 (p 346) by Melissa Broussard.
47. Figure D.1 (p 375) by Melissa Broussard.
48. Figure G.2 (p 481) by Korniliос Kourtis.

Figure 9.23 was adapted from Fedor Pikus's "When to use RCU" slide [Pik17].

I.6 Other Support

We owe thanks to many CPU architects for patiently explaining the instruction- and memory-reordering features of their CPUs, particularly Wayne Cardoza, Ed Silha, Anton Blanchard, Tim Slegel, Juergen Probst, Ingo Adlung, Ravi Arimilli, Cathy May, Derek Williams, H. Peter Anvin, Andy Glew, Leonid Yegoshin, Richard Grisenthwaite, and Will Deacon. Wayne deserves special thanks for his patience in explaining Alpha's reordering of dependent loads, a lesson that Paul resisted quite strenuously!

Portions of this material are based upon work supported by the National Science Foundation under Grant No. CNS-0719851.